タスク遷移に分岐を含むIoT機器に対するAE-GI異常動作検知手法の定量評価

川村 竜太[1,a)]　戸川 望[1,b)]

概要：近年，IoT (Internet of Things) の普及に伴い，ハードウェアデバイスのセキュリティ課題が増加している．ハードウェアデバイスの消費電力波形を用いて異常動作を検知する手法として，我々は AE-GI 手法を提案した．AE-GI 手法は，消費電力の部分波形をオートエンコーダの潜在特徴量に基づいて記号化し，記号列の文法規則から外れる遷移を検知する．しかし，従来の評価は単純な反復動作に対する定性的検証にとどまり，分岐を含む動作遷移に対する適用範囲は明らかでなかった．本稿では，複数の学習用記号列から文法規則を事前に構築するように AE-GI 手法を拡張し，撮影，暗号化，送信からなる分岐動作を Raspberry Pi 4 上に実装し，構造的異常および幾何学的異常の 5 種類を対象に，Recall で AE-GI 手法を定量評価する．その結果，暗号化スキップの 2 条件では比較的高い Recall を得た一方で，停止，送信スキップ，不完全送信では十分に検知できず，固定閾値による部分波形抽出と Trigram 規則の適用限界を明らかにした．

キーワード：ハードウェアトロイ，電力解析，異常動作検知，深層学習，文法的推論

Quantitative Evaluation of the AE-GI Anomaly Detection Method for IoT Device Task Transitions Involving Branching

Ryuta Kawamura[1,a)]　Nozomu Togawa[1,b)]

Abstract: This study evaluates AE-GI, a method that detects anomalous behavior of IoT devices from power waveforms and task transitions. We applied it to a Raspberry Pi 4 application with branching image capture, encryption, and transmission tasks, and evaluated five anomalies using event-level Recall.

Keywords: Hardware Trojans, Power analysis, Anomaly detection, Deep learning, Grammatical inference

1. はじめに

IoT デバイスは家庭，医療，産業などの幅広い領域に導入される一方，その増加は攻撃対象の増加にもつながる．IoT デバイスに対しては，設計・製造工程におけるハードウェアトロイの挿入 [1] や，マルウェア感染による大規模な分散型サービス妨害攻撃への悪用 [2] が報告されている．そのため，出荷後の IoT デバイスが想定された動作を継続しているかを監視し，異常動作を検知する技術が必要である．

小型・組込み型 IoT デバイスには，計算資源や記憶容量に制約があり，限定された機能に基づく予測可能な動作・通信パターンを示すものがある [3]．このようなデバイスに対し，内部へ検知機構を導入せず，動作に伴って外部へ現れる物理量を利用するサイドチャネル監視が検討されている．特に消費電力は，ハードウェア上で実行される処理に応じて変化するため，デバイス内部の動作を反映する観測量として利用できる [4,5]．

消費電力波形を用いる異常動作検知手法には，予測，再構成および表現ベースの手法がある．また，我々は，消費

[1] 早稲田大学 基幹理工学研究科 情報理工・情報通信専攻
Dept. Computer Science and Communications Engineering, Waseda University
[a)] ryuta.kawamura@togawa.cs.waseda.ac.jp
[b)] ntogawa@waseda.jp

© 2026 Information Processing Society of Japan

This paper is work in progress and not peer-reviewed.

電力の部分波形をオートエンコーダの潜在特徴量に基づいて記号化し，記号列の文法規則から外れる遷移を検知するAE-GI 手法を提案している [6]．しかし，従来 AE-GI の評価対象は 3 種類のタスクを一定順序で繰り返す単純な遷移であり，評価対象の記号列ごとに基本パターンと文法規則を推定していた．そのため，分岐を含むタスク遷移への適用範囲が明らかでなく，評価対象に含まれるノイズや異常遷移が正常規則へ取り込まれる可能性があった．

実際の組込みアプリケーションは，入力や内部状態に応じて複数の正常な実行経路を取り得る [7]．そこで本稿では，複数の学習用記号列から文法規則を事前に構築するとともに，学習済みクラスタから離れた部分波形を未知記号として扱うように AE-GI 手法を拡張し，撮影，暗号化および送信からなる分岐を含むタスク遷移を Raspberry Pi 4 上に実装し，構造的異常と幾何学的異常からなる 5 種類の異常動作に対して，イベント単位の Precision，Recall および F1 値を用いて評価する．特に，異常動作の見逃しを抑える能力を明らかにするため，比較手法との定量比較では Recall に着目する．

実験の結果，拡張 AE-GI 手法は，1 回目の暗号化のみをスキップする異常動作 1 と，暗号化を 2 回ともスキップする異常動作 2 に対して，それぞれ 0.933 および 1.000 の Recall を得た．一方，アプリケーションの停止，画像送信のスキップおよび不完全な画像送信に対する Recall は，それぞれ 0.500，0.105 および 0.529 となった．

さらに，評価対象ごとに文法規則を推定する従来 AE-GI 手法と比較して，5 種類のうち 3 種類の異常動作で Recall が向上し，正常波形上の誤検知を含む FP 総数を 269 件から 92 件へ削減した．以上より，文法規則の事前構築は過剰検知の抑制に有効である一方，送信タスクの欠落および部分波形の形状変化に対する検知には課題が残ることを確認した．

本稿の貢献を以下に示す．

(1) 複数の学習用記号列から文法規則を事前に構築するように AE-GI 手法を拡張した．

(2) 各手法を共通のイベント定義に基づいて Recall を中心に定量比較し，従来 AE-GI との比較により，拡張 AE-GI 手法が有効な異常動作，FP 削減効果および適用上の限界を明らかにした．

2. 関連研究と問題設定

2.1 関連研究

ハードウェアトロイの挿入やマルウェア感染によって生じる IoT デバイスの異常動作を検知するため，消費電力などのサイドチャネル情報を利用する手法が検討されている [4,5,8]．代表的な手法の一つとして，正常なデバイスまたは正常動作から得られたサイドチャネル情報を基準とし，検査対象から得られた情報との差異を検出する方式がある．しかし，基準となるゴールデンモデルの準備には費用と時間を要するほか [9]，製造ばらつきや測定環境の差が検知結果に影響する [8]．このため，検査対象デバイスの正常動作時に測定したデータから異常検知モデルを構築する手法が検討されている．

表 1: 各手法が判定に用いる情報．

手法	部分波形内の形状・特徴差	部分波形をまたぐタスク遷移
ゴールデンモデル比較	○	△
予測ベース [11]	○	△
再構成ベース [16]	○	△
表現ベース [9]	○	△
AE-GI [6]	○	○

深層学習を用いた時系列異常検知手法は，予測，再構成および表現ベースに分類できる [10]．予測ベースは予測値と実測値の誤差 [11,12]，再構成ベースは入力波形と再構成波形の誤差 [13–16]，表現ベースは正常データの特徴分布からの逸脱 [9,17] を異常判定に用いる．これらの手法は固定長ウィンドウ内の波形変化を扱える一方，部分波形をタスク単位で識別し，複数のタスクにまたがる実行順序を明示的な規則として扱うものではない．

我々が提案した従来 AE-GI 手法は，部分波形の潜在特徴量に基づく記号化と，記号列に対する文法的推論を組み合わせる [6]．これにより，部分波形内部の特徴差とタスク遷移の差異を異常判定に利用できる．一方，従来の評価は単純な反復動作に限られ，評価対象ごとに文法規則を推定していたため，分岐を含むタスク遷移への適用と評価データからの規則混入が課題として残されていた．

2.2 文法ベースの異常動作検知手法の位置づけ

消費電力波形に現れる異常は，部分波形の振幅，形状，継続時間または潜在特徴量に現れる差異と，複数の部分波形の出現順序に現れる差異から捉えられる．予測，再構成および表現ベースの手法は主に前者を固定長ウィンドウ内で扱うのに対し，文法ベースの手法は部分波形を記号化し，その出現順序を文法規則として扱う．各手法が異常判定に用いる情報を**表 1** に示す．

表 1 の ○ は当該情報を明示的に利用することを，△ は固定長ウィンドウなどの分析範囲内で限定的に利用することを表す．なお，本表は各手法が利用する情報を整理したものであり，異常検知性能そのものを表すものではない．

AE-GI 手法は，深層学習による部分波形の特徴抽出と，文法的推論によるタスク遷移の解析を組み合わせた手法として位置付けられる．本稿では，複数の学習用記号列から文法規則を事前に構築し，評価時には規則を更新せずに未知の記号列と照合するように AE-GI 手法を拡張する．

© 2026 Information Processing Society of Japan

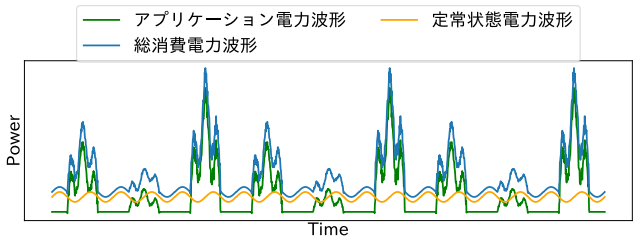


図 1: IoT デバイスの消費電力波形の例.

2.3 対象とする電力波形モデルと異常動作検知問題

本稿では，撮影，暗号化，送信など，アプリケーションを構成する動作単位をタスクと呼ぶ．また，タスク間の実行順序をタスク遷移，同一の先行タスクに対して複数の正常な後続タスクが存在することを分岐と呼ぶ．加えて，本稿では，有限個のタスクから構成され，分岐を含むアプリケーションを反復実行する小型・組込み型 IoT デバイスを対象とする．対象とする IoT デバイスの消費電力波形の例を**図 1** に示す．

測定される総消費電力波形 $P_{\text{total}} = \{p_{t,i}\}$ は，アプリケーションの実行に伴う電力波形 $P_{\text{app}} = \{p_{a,i}\}$ と，ハードウェアや OS などに起因する定常状態電力波形 $P_{\text{steady}} = \{p_{s,i}\}$ から構成される．したがって，時刻 i におけるアプリケーション電力 $p_{a,i}$ は，式 (1) で表される．

$$p_{a,i} = p_{t,i} - p_{s,i} \tag{1}$$

実際には，定常状態電力を別途測定または推定し，総消費電力から差し引くことでアプリケーション電力波形を抽出する．以下，アプリケーション電力波形から抽出される一つのタスクに対応した区間を部分波形と呼ぶ．また，タスクの欠落，追加，順序変更または停止によって正常なタスク遷移から逸脱する異常を構造的異常と呼び，部分波形の振幅，形状または継続時間が正常時と異なる異常を幾何学的異常と呼ぶ．ただし，両者は相互に排他的とは限らない．

以上に基づき，本稿で対象とする異常動作検知問題を次のように定義する．

定義 1. *消費電力を用いた IoT デバイスの異常動作検知問題とは，分岐を含むアプリケーションを反復実行する IoT デバイスが与えられたとき，外部から測定した消費電力波形を解析し，構造的異常または幾何学的異常が生じた区間を特定する問題である．*

3. AE-GI 手法の拡張

拡張 AE-GI 手法[*1]は，特徴抽出に用いるモデルとクラスタを学習する Phase 1，学習用記号列から文法規則を構築する Phase 2，学習済みモデルと文法規則を固定して評価用波形を解析する Phase 3 から構成される．拡張 AE-GI 手法の構成を**図 2** に示す．

Phase 1：モデルとクラスタの学習

Phase 1 では，学習用総消費電力波形から，定常状態除去オートエンコーダ，特徴量オートエンコーダおよび MeanShift クラスタリングモデルを学習する．

Step 1：消費電力波形の前処理と定常状態除去

学習用総消費電力波形に移動平均とダウンサンプリングを適用した後，学習用波形から求めた最小値と最大値に基づいて正規化する．ここで得た正規化条件は保存し，以降の Phase でも共通して用いる．

定常状態除去オートエンコーダの学習データを生成するため，アプリケーション非実行時の波形から SARIMA により定常状態電力波形を生成する [18]．そして，生成定常状態電力波形 P^{*}_{steady} の位相を相互相関に基づいて総消費電力波形へ合わせ，両者の差からアプリケーション電力波形を求める．最後に，正規化した総消費電力波形を入力，得られたアプリケーション電力波形を教師データとして定常状態除去オートエンコーダを学習させる．学習後は，総消費電力波形からアプリケーション電力波形を直接推定する．

Step 2：部分波形の抽出と位置合わせ

m 番目の総消費電力波形から推定したアプリケーション電力波形を $\widehat{P}^{(m)}_{\text{app}} = \{\widehat{p}^{(m)}_{a,i}\}_{i=1}^{L}$ とする．$\widehat{p}^{(m)}_{a,i}$ が所定の閾値 $\theta^{(m)}$ 以上となる連続区間を，各タスクに対応する部分波形として抽出する．

部分波形はゼロパディングまたは切り詰めによって入力長を統一し，エネルギー重心が入力区間の中央に位置するように時間方向へ移動する．これにより，部分波形の開始位置のずれが潜在特徴量へ与える影響を抑える．

Step 3：特徴量抽出器とクラスタの学習

位置合わせした部分波形を入力とし，同一波形を再構成する特徴量オートエンコーダを平均二乗誤差に基づいて学習させる．学習後は，特徴量オートエンコーダのエンコーダ部分を特徴量抽出器として用い，各部分波形から 4 次元の潜在特徴量 $\boldsymbol{z}_j$ を得る．

波形形状に加えてタスクの継続時間をクラスタリングへ反映するため，元の部分波形長 ℓ_j を学習データの最小値と最大値に基づいて正規化した $\widetilde{\ell}_j$ を求める．そして，$\boldsymbol{z}_j$ と $\widetilde{\ell}_j$ を結合し，5 次元の特徴ベクトル $\boldsymbol{v}_j = [\boldsymbol{z}_j, \widetilde{\ell}_j]$ を構成する．最後に，特徴ベクトルを標準化した後，MeanShift 法 [19] によりクラスタリングする．

なお，学習した正規化器，定常状態除去オートエンコーダ，特徴量抽出器，標準化器および MeanShift クラスタリングモデルは，以降の Phase では更新しない．

[*1] 提案する拡張 AE-GI 手法では，Phase 1 および Phase 3 に含まれる波形前処理，オートエンコーダによる波形推定と特徴抽出，クラスタリングによる記号化，ならびに文法規則違反の検知は，従来 AE-GI 手法 [6] の基本処理を踏襲する．従来 AE-GI 手法では評価用記号列ごとに基本パターンと文法規則を推定していたのに対し，拡張 AE-GI 手法では，複数の学習用記号列から文法規則を事前構築する Phase 2，評価時の文法規則の固定，および未知記号判定を導入した．

© 2026 Information Processing Society of Japan

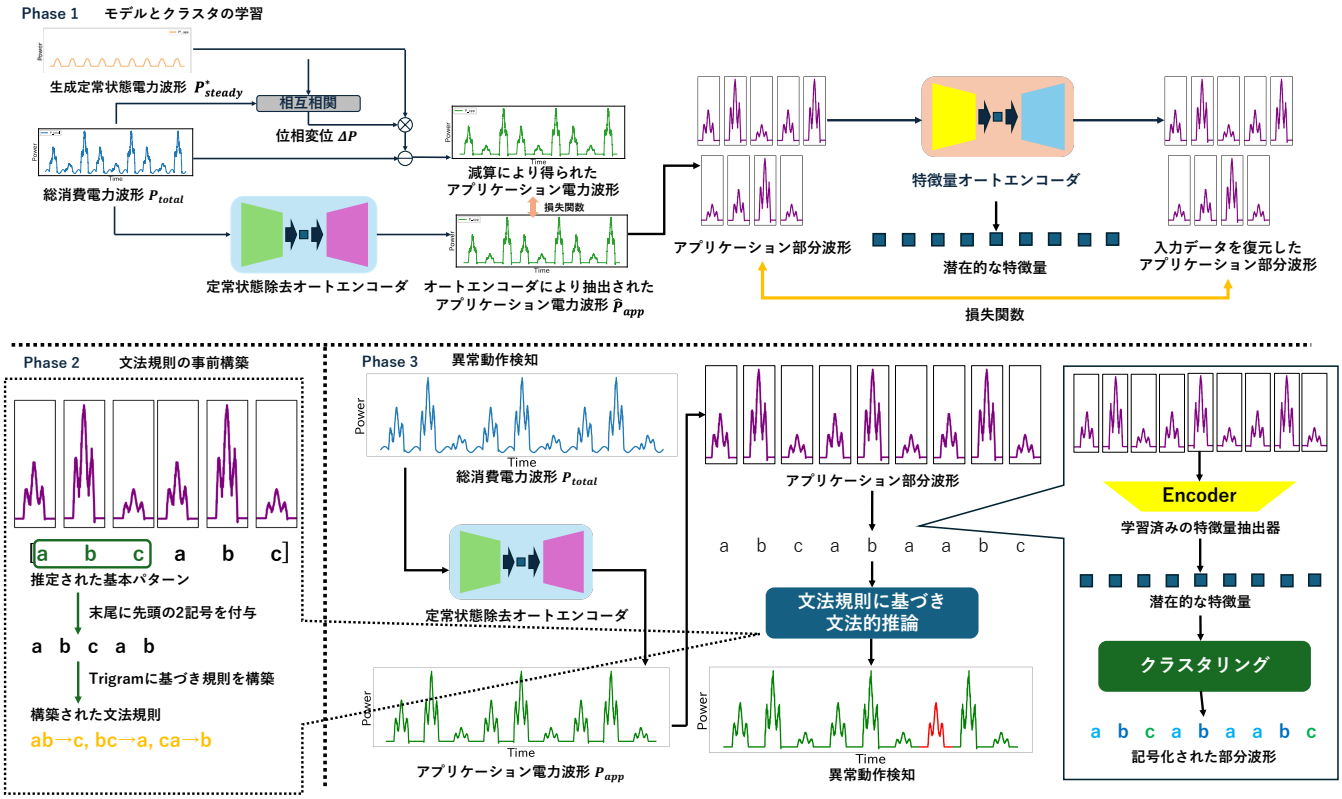


図 2: 拡張 AE-GI 手法の構成.

Phase 2：文法規則の事前構築

Phase 2 では，Phase 1 で学習・保存したモデルおよび変換器を用いて学習用総消費電力波形を記号列へ変換し，正常なタスク遷移を表すと推定される文法規則を構築する．

Step 1：学習用波形の記号列化

各学習用総消費電力波形に対して，学習済みの正規化器と定常状態除去オートエンコーダを適用し，部分波形の抽出，入力長の統一および位置合わせを行う．各部分波形から得た潜在特徴量と正規化した部分波形長を結合して特徴ベクトルを構成し，学習済みクラスタ中心との距離に基づいて記号化する．

各クラスタに “a”, “b”, “c” などの記号を一意に割り当て，部分波形の開始時刻順に並べる．m 番目の学習用総消費電力波形から得られる学習用記号列を $S^{(m)} = s_1^{(m)} s_2^{(m)} \cdots s_{n_m}^{(m)}$ とする．

Step 2：基本パターンの推定

各学習用記号列から，繰り返し出現し，記号列全体を広く説明できる部分列を基本パターンとして推定する．候補パターン P の長さを $L(P)$，m 番目の学習用記号列における重複しない出現回数を $F_m(P)$，記号列長を L_m とし，カバレッジスコアを次式で定義する．

$$\mathrm{Score}_m(P) = \frac{F_m(P)L(P)}{L_m} \qquad (2)$$

長さ 2 から 10 までの各長さ部分列のうち，カバレッジスコアが最大の候補を，m 番目の学習用記号列の基本パターン $P^{(m)}$ として採用する．

Step 3：基本パターンの統合

周期的な動作では，測定開始位置の違いによって，同じ動作を表す基本パターンの先頭記号が異なる場合がある．そこで，各基本パターンを最小周期へ縮約した後，循環回転のうち辞書順で最小の表現へ正規化し，同一の循環パターンを統合する．最も多くの学習用記号列から得られた循環パターンを，代表基本パターン P^* として採用する．この選択には正常・異常の条件ラベルを使用せず，正常な動作パターンが学習データの多数を占めることを仮定する．

Step 4：Trigram 文法規則の構築

代表基本パターン $P^* = p_1 p_2 \cdots p_r$ を周期的な記号列として扱うため，その末尾に先頭の 2 記号 $p_1 p_2$ を付加する．これは，長さ 3 の Trigram [*2] を循環境界にまたがって抽出するには，先頭の 2 記号を付加すれば十分であるためである．得られた循環列に含まれる連続する 3 記号をすべて抽出し，Trigram に基づいて文法規則 G を構築する [20]．こ

[*2] 本稿では，直前の 2 記号を文脈として，その後に出現する 1 記号が正常であるかを判定する Trigram 文法規則を用いる．Bigram では直前の 1 記号のみから後続記号を判定するため，同一の記号が異なる文脈に出現する場合を区別しにくい．一方，4-gram 以上ではより長い文脈を扱えるものの，記号の組合せ数が増加し，限られた学習用記号列から得られる規則が疎になる可能性がある．

なお，本稿では文法規則の次数を 3 に固定しており，その最適性については検証していない．より長い記号間の依存関係を扱うため，学習用記号列の量や規則の出現頻度に応じて次数を選択する可変次数の N-gram 文法規則へ拡張することは今後の課題である．

© 2026 Information Processing Society of Japan

の規則は，先行する 2 記号に対して許容される後続記号を表す．代表基本パターン内で同一の 2 記号に複数の後続記号が現れる場合は，それぞれを正常な分岐として許容する．

Phase 3：評価用波形に対する異常動作検知

Phase 3 では，Phase 1 および Phase 2 の成果物を用いて，異常動作を検知する．

Step 1：評価用波形の記号列化

異常検知対象の総消費電力波形 (評価用波形) を学習時と同じ条件で正規化し，定常状態除去オートエンコーダによってアプリケーション電力波形を推定する．

続いて，部分波形の抽出，入力長の統一および位置合わせを行い，学習済み特徴量抽出器によって潜在特徴量を取得する．標準化した特徴ベクトルを最も近い学習済み MeanShift クラスタへ割り当て，評価用記号列 $S^{\mathrm{eval}} = s_1 s_2 \cdots s_n$ を生成する．ここで，最も近い学習済みクラスタの中心との距離が，学習データから定めた未知判定距離を超える場合は，当該部分波形をいずれの学習済みクラスタにも属さない未知記号として扱う．

Step 2：文法規則との照合と異常区間の生成

評価用記号列から連続する 3 記号 $u_k = s_k s_{k+1} s_{k+2}$ を順番に抽出し，事前に構築した文法規則 G と照合する．ここで 3 記号を用いるのは，Phase 2 で先行する 2 記号を文脈として後続する 1 記号の可否を表す Trigram 規則を構築したためである．u_k が G に含まれない場合は，その末尾の記号 s_{k+2} に対応する部分波形を違反位置として記録する．

保存した部分波形の開始位置と終了位置を用いて，違反位置を元の消費電力波形上の区間へ対応付ける．また，一つの異常動作から重複する複数の違反 Trigram が生じる場合を考慮し，同一波形内で隣接する違反位置を一つの異常区間へ統合する．

4. 実験方法

4.1 実験環境

解析には Python 3.9.6 を使用し，オートエンコーダの実装には TensorFlow 2.6.0 および Keras 2.6.0，MeanShift 法の実装には scikit-learn 0.24.2 を用いた．

評価対象には Raspberry Pi 4 を使用し，KEITHLEY 2280S-32-6 から給電した．動作中の電流および電圧は，Tektronix MSO64B オシロスコープと TCP0030A 電流プローブを用いて測定した．

4.2 測定対象のアプリケーションプログラム

Raspberry Pi 4 上に，写真撮影および画像暗号化と，画像送信を模擬した演算処理を行う評価用アプリケーションを実装した．以下では，この模擬処理を画像送信と呼ぶ．正常動作と 5 種類の異常動作におけるタスク遷移を**図 3** に示す．

正常動作では，写真撮影と画像暗号化を 2 回繰り返した後，画像送信を実行する．暗号化後の遷移先は，1 回目では撮影，2 回目では送信となるため，同一の先行タスクに対して複数の正常な後続タスクが存在する分岐を含む．評価対象とした異常動作を**表 2** に示す．

表 2: 評価対象の異常動作.

ID	異常内容	分類
1	1 回目の暗号化をスキップ	構造的異常
2	2 回とも暗号化をスキップ	構造的異常
3	アプリケーションが一定時間停止	構造的・幾何学的異常
4	画像送信をスキップ	構造的異常
5	画像送信を不完全に実行	幾何学的異常

表 3: 定常状態除去オートエンコーダの構造.

	レイヤー	入力形状	出力形状
Encoder	Conv1D (32, $k = 7$)	$L \times 1$	$L \times 32$
	MaxPooling1D	$L \times 32$	$L/2 \times 32$
	Conv1D (16, $k = 7$)	$L/2 \times 32$	$L/2 \times 16$
	MaxPooling1D	$L/2 \times 16$	$L/4 \times 16$
Decoder	Conv1D (16, $k = 7$)	$L/4 \times 16$	$L/4 \times 16$
	UpSampling1D	$L/4 \times 16$	$L/2 \times 16$
	Conv1D (32, $k = 7$)	$L/2 \times 16$	$L/2 \times 32$
	UpSampling1D	$L/2 \times 32$	$L \times 32$
	Conv1D (1, $k = 7$)	$L \times 32$	$L \times 1$

4.3 データセットとデータ分割

各条件についてアプリケーションを 20 秒間実行して総消費電力波形を測定し，学習用 60 波形および最終評価用 125 波形の計 185 波形を解析対象とした．各波形は 62.5 kHz で 20 秒間測定した 125 万サンプルからなり，ウィンドウサイズ 4,000 および 3,000 の 2 段階の移動平均を適用した後，1,250 サンプル間隔でダウンサンプリングして，各波形の長さ $L = 1{,}000$ とした．学習には正常動作 55 波形と各異常動作 1 波形ずつの計 60 波形を用い，残り 125 波形を最終評価データとした．最終評価データのうち 35 波形は正常動作時の波形であり，90 波形は正解異常区間を含む異常動作時の波形である．データ分割は部分波形の抽出前に測定波形単位で行った．

学習データのうち正常動作 10 波形をエポック数選択用の内部検証データとし，残りの 50 波形で選択した後，モデルを初期化して 60 波形すべてで再学習した．動作条件ラベルは，学習・評価データの構成，内部検証データの選定およびデータ分割の管理にのみ使用し，モデル，クラスタおよび文法規則の学習目標には使用していない．また，異常区間ラベルは学習に使用していない．

4.4 学習条件と比較手法

4.4.1 提案手法の学習条件

定常状態除去オートエンコーダの構造を**表 3** に示す．また，部分波形の特徴量オートエンコーダの構造を**表 4** に示

© 2026 Information Processing Society of Japan

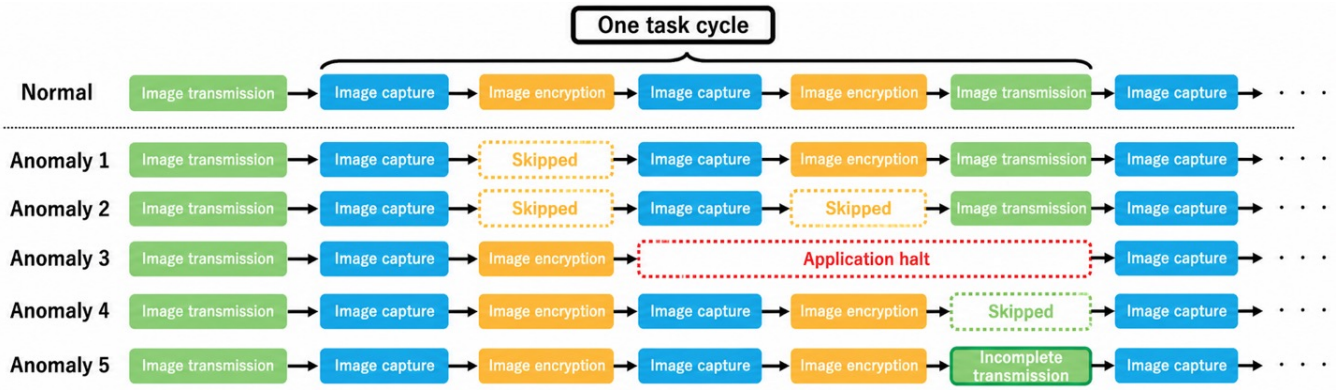


図 3: 正常動作および異常動作におけるタスク遷移.

表 4: 特徴量オートエンコーダの構造.

	レイヤー	入力形状	出力形状
Encoder	Conv1D (16, $k=3$)	$L' \times 1$	$L' \times 16$
	MaxPooling1D	$L' \times 16$	$L'/2 \times 16$
	Conv1D (32, $k=3$)	$L'/2 \times 16$	$L'/2 \times 32$
	MaxPooling1D	$L'/2 \times 32$	$L'/4 \times 32$
	Conv1D (32, $k=3$)	$L'/4 \times 32$	$L'/4 \times 32$
	MaxPooling1D	$L'/4 \times 32$	$L'/8 \times 32$
	Flatten	$L'/8 \times 32$	$4L'$
	Dense (Latent)	$4L'$	4
Decoder	Dense	4	$4L'$
	Reshape	$4L'$	$L'/8 \times 32$
	UpSampling1D	$L'/8 \times 32$	$L'/4 \times 32$
	Conv1DTranspose (32, $k=3$)	$L'/4 \times 32$	$L'/4 \times 32$
	UpSampling1D	$L'/4 \times 32$	$L'/2 \times 32$
	Conv1DTranspose (16, $k=3$)	$L'/2 \times 32$	$L'/2 \times 16$
	UpSampling1D	$L'/2 \times 16$	$L' \times 16$
	Conv1D (1, $k=3$)	$L' \times 16$	$L' \times 1$

す．ここで，k は畳み込み層のカーネルサイズを表す．部分波形の入力長 L' は，学習データから得られた部分波形の最大長を 8 の倍数へ切り上げて決定した．特徴量オートエンコーダは，部分波形を 4 次元の潜在特徴量へ圧縮し，入力波形を再構成するように学習する．学習後は，入力層から潜在層までのエンコーダ部分を特徴量抽出器として使用する．

各畳み込み層および全結合層には ReLU 関数を，出力層には線形関数を用い，最適化には Adam を使用した．エポック数選択時の上限とバッチサイズは，定常状態除去オートエンコーダでは 500 および 32，特徴量オートエンコーダでは 200 および 16 とし，乱数シードを 42 に固定した．m 番目の推定アプリケーション電力波形に対する部分波形抽出閾値は，$\theta^{(m)} = \max_i \widehat{p}_{a,i}^{(m)}/22$ とした．

MeanShift 法の帯域幅は，標準化した学習特徴量の分位点 0.3 から推定した．また，クラスタごとに，所属する学習特徴量とクラスタ中心との距離の 99 パーセンタイルを 1.05 倍した値を未知判定距離とした．評価対象の特徴ベクトルと最も近いクラスタ中心との距離が対応する未知判定距離を超える場合，対象の部分波形を未知記号として扱った．

表 5: 比較手法の概要.

手法	異常判定方法
予測ベース [11]	LSTM による予測波形と実測波形との平均二乗誤差を用いる.
再構成ベース [16]	CNN-AE による入力波形と再構成波形との平均二乗誤差を用いる.
表現ベース [9]	オートエンコーダの潜在特徴量に LOF 法を適用する.
従来 AE-GI [6]	評価用記号列自身から文法規則を推定し，規則違反を検知する.
拡張 AE-GI	学習時に事前構築した文法規則と未知記号判定を用いる.

4.4.2 比較手法

提案手法の適用範囲を検証するため，予測ベース [11]，再構成ベース [16]，表現ベース [9] および従来 AE-GI 手法 [6] と比較する．比較手法の概要を**表 5** に示す．予測，再構成および表現ベースの手法では，学習用総消費電力波形に DFF 法を適用してウィンドウサイズ W を決定した．各手法の異常判定閾値は，学習データから得られた異常度の 99 パーセンタイルとして決定し，最終評価データに対して固定した．

4.5 評価方法

各手法が出力した異常区間と正解異常区間をイベント単位で比較した．両区間が重なり，いずれか一方の中心が他方の区間内に含まれる場合に，一対一で対応付けた．対応した予測を TP，対応しない予測を FP，対応する予測が存在しない正解イベントを FN とし，正常波形上の予測も FP に含めた．これらに基づいて異常動作ごとの Precision，Recall および F1 値を算出し，全手法を同一の評価波形，正解異常区間および照合条件で比較した．

5. 実験結果と考察

5.1 記号化および異常動作検知結果

学習用記号列から得られた代表基本パターンと文法規則

© 2026 Information Processing Society of Japan

表 6: 記号化および文法規則の構築結果.

項目	結果
代表基本パターン	abacb（44 記号列）
循環列	abacbab
Trigram 規則	aba，bac，acb，cba，bab
文法規則	ab → a, ba → {b, c}, ac → b, cb → a
クラスタ・記号の対応	0 → a，1 → b，2 → c，3 → d
評価用部分波形	3,896 個（うち未知記号 2 個）

表 7: 拡張 AE-GI 手法の異常動作検知結果.

	TP	FP	FN	Precision	Recall	F1
異常 1	14	9	1	0.609	0.933	0.737
異常 2	17	6	0	0.739	1.000	0.850
異常 3	11	12	11	0.478	0.500	0.489
異常 4	2	17	17	0.105	0.105	0.105
異常 5	9	13	8	0.409	0.529	0.462

を**表 6** に示す．60 個の学習用記号列から推定した基本パターンを循環回転について正規化した結果，44 個の記号列から基本パターン abacb が得られた．これは他の候補よりも多くの学習用記号列から得られたため，代表基本パターンとして採用された．

代表基本パターンを周期的な記号列として扱うため，先頭の 2 記号を末尾へ付加した循環列 abacbab から，5 個の Trigram 規則を構築した．このうち，先行する 2 記号 ba に対しては，b と c の二つが後続記号として許容される．したがって，構築された文法規則は，正常動作に含まれる分岐を複数の正常な後続記号として保持している．

また，125 個の評価用総消費電力波形から計 3,896 個の部分波形を抽出し，学習済みの 4 個のクラスタに対応する記号 a〜d へ変換した．学習済みクラスタから棄却されて未知記号となった部分波形は 2 個であり，全体の約 0.051% であった．なお，各記号はクラスタの識別子であり，撮影や暗号化などの意味的なタスクと一意に対応するとは限らない．

拡張 AE-GI 手法による異常動作別の検知結果を**表 7** に示す．異常動作 1 および 2 の Recall はそれぞれ 0.933 および 1.000 となり，暗号化タスクの欠落を高い割合で検知できた．また，F1 値はそれぞれ 0.737 および 0.850 であった．

異常動作 1 の検知例を**図 4** に示す．暗号化タスクの欠落によって，評価用記号列に学習済み文法規則に含まれない Trigram が生じたため，対応する部分波形区間が異常として検知された．このように，拡張 AE-GI 手法では，異常判定の根拠となった記号遷移と消費電力波形上の区間を対応付けることができる．

5.2 比較手法との定量比較と考察

各手法の異常動作別 Recall を**表 8** に示す．予測，再構成および表現ベースの手法では，学習用総消費電力波形に DFF 法を適用し，ウィンドウサイズを $W = 52$ と決定した．

表 8: 比較手法の異常動作別 Recall.

手法	異常 1	異常 2	異常 3	異常 4	異常 5
予測 [11]	0.867	0.941	**0.773**	0.105	0.529
再構成 [16]	0.600	0.706	0.000	0.000	0.294
表現 [9]	**0.933**	0.882	0.045	0.105	**0.941**
従来 AE-GI [6]	0.800	0.941	0.409	**0.211**	0.647
拡張 AE-GI	**0.933**	**1.000**	0.500	0.105	0.529

異常動作 1 では，拡張 AE-GI と表現ベースの Recall がともに 0.933 となった．異常動作 2 では，拡張 AE-GI の Recall が 1.000 となり，全手法中で最も高い値を得た．タスクの欠落は構造的異常であるが，欠落前後の局所的な波形変化にも影響が現れたため，予測および表現ベースでも比較的高い Recall を得たと考えられる．

異常動作 3 では，予測ベースの Recall が 0.773 と最も高く，拡張 AE-GI は 0.500 となった．拡張 AE-GI は，再構成ベースの 0.000，表現ベースの 0.045 および従来 AE-GI の 0.409 を上回った．アプリケーションの停止によって複数の部分波形にまたがる記号遷移が変化したため，タスク遷移を文法規則として扱うことが検知に寄与したと考えられる．

異常動作 4 では，いずれの手法も低い Recall となり，拡張 AE-GI は 0.105 にとどまった．画像送信のスキップでは異常な部分波形が現れず，本来存在する部分波形自体が欠落するため，異常区間の特定が困難であったと考えられる．

異常動作 5 では，表現ベースが 0.941 と最も高い Recall を得た一方，拡張 AE-GI は 0.529 となった．不完全送信は局所的な波形形状の差異として現れるため，潜在特徴空間からの外れ度を直接評価する表現ベースが有効であった．

従来 AE-GI と比較すると，拡張 AE-GI は異常動作 1,2,3 で Recall が向上した一方，異常動作 4 および 5 では低下した．また，正常波形上の誤検知を含む FP 総数は 269 件から 92 件へ約 66%減少した．ここで，拡張 AE-GI における 92 件の FP は，表 7 に示す異常動作の評価波形上の FP 57 件と，正常波形上の FP 35 件の合計である．したがって，文法規則の事前構築は過剰検知の抑制に有効であるが，Recall への効果は異常動作の種類に依存する．

以上より，拡張 AE-GI 手法は，暗号化タスクの欠落に対して高い Recall を得るとともに，タスク遷移の変化を文法規則違反として検知できる手法と位置付けられる．一方，タスクの欠落位置の特定，局所的な波形形状の識別およびクラスタリング結果に依存する記号列の変動が課題として残る．

6. おわりに

本稿では，分岐を含むアプリケーションを反復実行する IoT デバイスを対象に，複数の学習用記号列から文法規則

© 2026 Information Processing Society of Japan

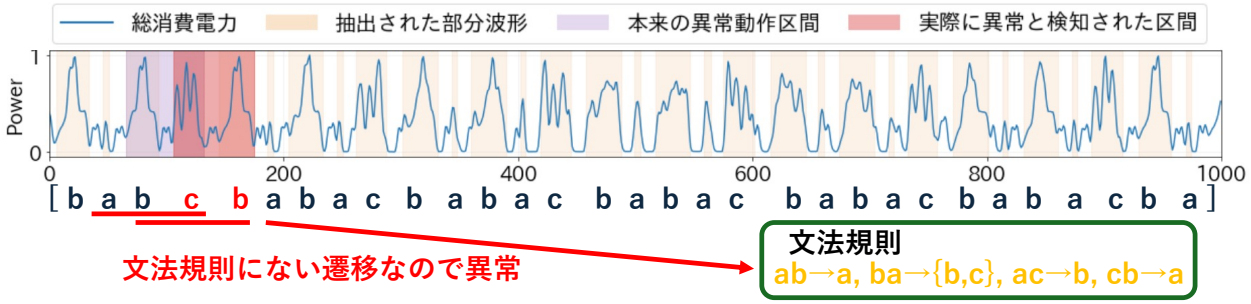


図 4: 拡張 AE-GI 手法による異常動作検知例 (異常動作 1).

を事前に構築し，学習済み規則を固定して評価用波形を解析するように AE-GI 手法を拡張した．Raspberry Pi 4 上に撮影，暗号化および送信からなる分岐を含むタスク遷移を実装し，5 種類の異常動作に対してイベント単位の定量評価を行った．実験の結果，拡張 AE-GI 手法は暗号化をスキップする 2 種類の異常動作でそれぞれ 0.933 および 1.000 の Recall を得た．また，評価対象ごとに文法規則を推定する従来 AE-GI と比較して，異常動作 1,2,3 で Recall が向上し，正常波形上の誤検知を含む FP 総数を 269 件から 92 件へ削減したことから，文法規則の事前構築が過剰検知の抑制に有効であることを確認した．

今後の課題として動的閾値による部分波形抽出，幾何学的異常に強い表現ベース手法との統合，ならびに異なる IoT デバイスおよびアプリケーションを用いた評価が挙げられる．

謝辞 本研究は一部，JSPS 科研費 (25K03096) の助成を受けたものである．

参考文献

[1] Sidhu, S., Mohd, B. J. and Hayajneh, T.: Hardware Security in IoT Devices with Emphasis on Hardware Trojans, *Journal of Sensor and Actuator Networks*, Vol. 8, No. 3, p. 42 (online), DOI: 10.3390/jsan8030042 (2019).

[2] Antonakakis, M., April, T., Bailey, M., Bernhard, M., Bursztein, E., Cochran, J., Durumeric, Z., Halderman, J. A., Invernizzi, L., Kallitsis, M., Kumar, D., Lever, C., Ma, Z., Mason, J., Menscher, D., Seaman, C., Sullivan, N., Thomas, K. and Zhou, Y.: Understanding the Mirai Botnet, *26th USENIX Security Symposium (USENIX Security 17)*, USENIX Association, pp. 1093–1110 (2017).

[3] DeMarinis, N. and Fonseca, R.: Toward Usable Network Traffic Policies for IoT Devices in Consumer Networks, *Proceedings of the 2017 Workshop on Internet of Things Security and Privacy*, ACM, pp. 43–48 (online), DOI: 10.1145/3139937.3139949 (2017).

[4] Clark, S. S., Ransford, B., Rahmati, A., Guineau, S., Sorber, J., Xu, W. and Fu, K.: WattsUpDoc: Power Side Channels to Nonintrusively Discover Untargeted Malware on Embedded Medical Devices, *2013 USENIX Workshop on Health Information Technologies (HealthTech 13)*, USENIX Association (2013).

[5] Han, Y., Chan, M., Aref, Z., Tippenhauer, N. O. and Zonouz, S.: Hiding in Plain Sight? On the Efficacy of Power Side Channel-Based Control Flow Monitoring, *31st USENIX Security Symposium (USENIX Security 22)*, USENIX Association, pp. 661–678 (2022).

[6] 川村竜太，江田琉聖，中西 響，戸川 望：潜在的特徴量に基づく文法的推論を用いた IoT デバイス異常動作検知手法，2026 年暗号と情報セキュリティシンポジウム（SCIS2026）(2026). 1G1-1.

[7] Abera, T., Asokan, N., Davi, L., Ekberg, J.-E., Nyman, T., Paverd, A., Sadeghi, A.-R. and Tsudik, G.: C-FLAT: Control-Flow Attestation for Embedded Systems Software, *Proceedings of the 2016 ACM SIGSAC Conference on Computer and Communications Security*, ACM, pp. 743–754 (online), DOI: 10.1145/2976749.2978358 (2016).

[8] Wang, L., Xie, H. and Luo, H.: Malicious circuitry detection using transient power analysis for IC security, *Proceedings of 2013 International Conference on Quality, Reliability, Risk, Maintenance, and Safety Engineering (QR2MSE)*, pp. 1164–1167 (2013).

[9] Eda, R., Hisafuru, K. and Togawa, N.: Gen-Power2: Improved Anomaly Detection in IoT Devices Utilizing Generated Power Waveforms, *IEICE Transactions on Fundamentals of Electronics, Communications and Computer Sciences*, Vol. E108-A, No. 12, pp. 1598–1611 (online), DOI: 10.1587/transfun.2024EAP1145 (2025).

[10] Zamanzadeh Darban, Z., Webb, G. I., Pan, S., Aggarwal, C. C. and Salehi, M.: Deep Learning for Time Series Anomaly Detection: A Survey, *ACM Computing Surveys*, Vol. 57, No. 1, pp. 1–42 (online), DOI: 10.1145/3691338 (2024). Article 15.

[11] Eda, R. and Togawa, N.: Anomalous IoT Behavior Detection by LSTM-Based Power Waveform Prediction, *Proceedings of the 10th International Conference on Internet of Things, Big Data and Security - IoTBDS*, INSTICC, SciTePress, pp. 345–352 (online), DOI: 10.5220/0013368900003944 (2025).

[12] Zhao, M., Peng, H., Li, L. and Ren, Y.: Graph Attention Network and Informer for Multivariate Time Series Anomaly Detection, *Sensors*, Vol. 24, No. 5, p. 1522 (2024).

[13] Zhou, J., Yang, X. and Ren, Z.: SCConv-Denoising Diffusion Probabilistic Model Anomaly Detection Based on TimesNet, *Electronics*, Vol. 14, No. 4, p. 746 (online), DOI: 10.3390/electronics14040746 (2025).

[14] Maitra, S., Kundu, S. and Shankar, A.: A Real-Time Anomaly Detection Using Convolutional Autoencoder with Dynamic Threshold, arXiv preprint arXiv:2404.04311 (2024).

[15] Yi, S., Zheng, S., Yang, S., Zhou, G. and He, J.: A Model Fine-Tuning Approach for Robust Anomaly Detection and Isolation in Multi-Sensor System of Nuclear Power Plants, *Annals of Nuclear Energy*, Vol. 205, p. 110557 (2024).

[16] Seo, J., Kim, Y., Ha, J., Kwak, D., Ko, M. and Yoo, M.: Unsupervised Anomaly Detection for Earthquake Detection on Korea High-Speed Trains Using Autoencoder-Based Deep Learning Models, *Scientific Reports*, Vol. 14, p. 639 (online), DOI: 10.1038/s41598-024-51354-7 (2024).

[17] Fahmi, A.-T. W. K., Kashyzadeh, K. R. and Ghorbani, S.: Fault detection in the gas turbine of the Kirkuk power plant: An anomaly detection approach using DLSTM-Autoencoder, *Engineering Failure Analysis*, Vol. 160, p. 108213 (2024).

[18] Eda, R. and Togawa, N.: Anomalous IoT Behavior Detection Based on SARIMA Reference Waveform, *2025 IEEE 31st International Symposium on On-Line Testing and Robust System Design (IOLTS)*, IEEE, pp. 1–5 (2025).

[19] Wu, K.-L. and Yang, M.-S.: Mean shift-based clustering, *Pattern Recognition*, Vol. 40, No. 11, pp. 3035–3052 (2007).

[20] Senin, P., Lin, J., Wang, X., Oates, T., Gandhi, S., Boedihardjo, A. P., Chen, C. and Frankenstein, S.: Time Series Anomaly Discovery with Grammar-Based Compression, *Proceedings of the 18th International Conference on Extending Database Technology (EDBT)*, pp. 481–492 (2015).

© 2026 Information Processing Society of Japan