文脈内学習によるTTP分類における デモンストレーション構成とラベル網羅性の評価

長尾 浩良[1,a)]　三本 知明[1]　奥井 宣広[1]

概要：サイバー脅威インテリジェンス（CTI）からの TTP 分類では，MITRE ATT&CK のラベル空間が大きいため，文脈内学習（In-Context Learning; ICL）で与えるデモ数では全ラベルを提示しきれないことが多く，あるクエリの正解ラベルがデモに含まれるとは限らない．しかし，ICL に基づく TTP 分類の既存研究は，この正解ラベルの有無を区別せずに性能を評価してきた．本研究は，正解 Technique がデモに含まれるか（covered/uncovered）を表すラベル網羅性を独立した評価軸として導入し，クエリごとにデモをサンプリングして網羅性を制御・記録する．TRAM，AnnoCTR，CTI-HAL と Llama 3.1/3.2（1B–8B）による実験では，covered クエリの完全一致正解率が全 27 条件で uncovered を上回り，大規模化しても性能差は維持された．また同じデモ数でも，全ラベルを一度ずつ提示するより一部のラベルを複数例で提示する方が高精度であった．ただし最高でも 45.9%にとどまり，Tactic の取り違えや不正な出力が全クエリの 40%以上を占めた．さらに，正解したクエリほど正解ラベルを持つ類似デモを多く含んでいた．以上より，ICL に基づく TTP 分類は，デモ数だけでなく，ラベル網羅性とラベルごとのデモ数の配分の観点から評価する必要がある．

キーワード：サイバー脅威インテリジェンス，MITRE ATT&CK，TTP 分類，In-Context Learning

Evaluation of Demonstration Composition and Label Coverage in In-Context TTP Classification

Hiroyoshi Nagao[1,a)]　Tomoaki Mimoto[1]　Norihiro Okui[1]

Abstract: TTP classification from cyber threat intelligence (CTI) faces a large MITRE ATT&CK label space, so the demonstrations available for in-context learning (ICL) often cannot present every label, and a query's gold label may or may not appear among them. Yet existing ICL-based TTP classification has evaluated performance without distinguishing whether it does. We introduce label coverage—whether the gold technique is present (covered) or absent (uncovered)—as an independent evaluation axis, and sample demonstrations per query while controlling and recording coverage. On TRAM, AnnoCTR, and CTI-HAL with Llama 3.1/3.2 (1B–8B), covered exact-match accuracy exceeds uncovered in all 27 conditions, and the gap persists as models scale. Under the same demonstration count, presenting a few labels with multiple examples beats presenting every label once. Still, the best accuracy is only 45.9%, and cross-tactic errors and invalid outputs exceed 40% of all queries. Correctly classified queries also contain more similar gold-label demonstrations. ICL-based TTP classification therefore must be evaluated not only by demonstration count but by label coverage and the allocation of demonstrations across labels.

Keywords: Cyber threat intelligence, MITRE ATT&CK, TTP classification, In-Context Learning

1. はじめに

サイバー脅威インテリジェンス（Cyber Threat Intelli-

[1] KDDI 総合研究所
KDDI Research, Inc.
[a)] hi-nagao@kddi.com

© 2026 Information Processing Society of Japan

This paper is work in progress and not peer-reviewed.

gence; CTI）では，攻撃者が用いた Tactics, Techniques, and Procedures（TTP）を共通の語彙で記述することが重要である．MITRE ATT&CK[1] は攻撃者の Tactic と Technique を体系化しており，CTI からの TTP 分類は，脅威分析，検知ルールの作成，防御策の優先順位付けを支援する [2]．

従来の TTP 分類では，固定された Technique 集合に対して文書エンコーダを学習する方法が中心であった [3], [4]．近年は，大規模言語モデル（LLM）に入力–ラベル例を与える文脈内学習（In-Context Learning; ICL）や，ATT&CK 知識ベースを検索して生成する手法が利用されている [5]．ICL は再学習なしに適応できる一方，入力できるデモ数にはコンテキスト長と計算量の制約があり，限られたデモ数をどのラベルに，何例ずつ配分するかが性能を左右する [6]．

TTP 分類の難しさは，現実的な CTI 文を用いた最近の評価でも確認されている．Ryan ら [7] は，複数の Technique を含む CTI レポートから 114 種類の Technique を含むマルチラベルデータセットを構築し，複数のオープンソース LLM を評価したが，最高性能のモデルでもマイクロ F1 は 0.22 に留まり，RAG による改善も主に再現率の向上として現れた．この結果は，実運用に近い TTP 分類の評価には，モデルやプロンプト形式だけでなく，大規模なラベル空間と入力例の構成も考慮する必要があることを示唆する．

この問題は，ATT&CK のようにラベル空間が大きい場合に顕著になる．例えば Technique が 100 種類を超えるとき，30 例程度のデモでは全ラベルを網羅できない場合がある．逆に，ラベル数と同数以上のデモを入力して全ラベルを一度ずつ提示しても，各ラベルについて一つの CTI 文しか示せず，複数の表現とラベルとの対応を提示できない．大規模ラベル分類の ICL では，デモ数がラベル数以上である設定が採用されることがあるが，その前提の必要性や，ラベル数未満のデモ数との比較は十分に検討されていない [8]．実際，前述の Ryan らの評価も 211 種類の Technique を候補としながら，推論時に与える例は 0 例または 3 例に限られており，デモ数がラベル数未満の場合とラベルを広く網羅する場合との性能差は明示的に検証していない [7]．

デモ数が限られると，クエリの正解ラベルがデモに現れない場合がある．このとき，デモを与えたことで性能が変化しても，それが提示されたラベルの再利用によるものなのか，正解ラベルがデモに含まれない条件での分類結果なのかを区別できない．これは完全一致正解率など特定の評価指標の問題ではなく，デモとクエリの対応関係を記録・制御していない実験設定の問題である．この条件は ICL のテキスト分類研究で seen/unseen などと呼ばれることがあるが，文献によって定義や操作対象は異なる．Min ら [6] は，デモのラベル空間，入力分布，フォーマット，入力–ラベル対応を分解して評価し，StaICC[9] は分類 ICL の条件

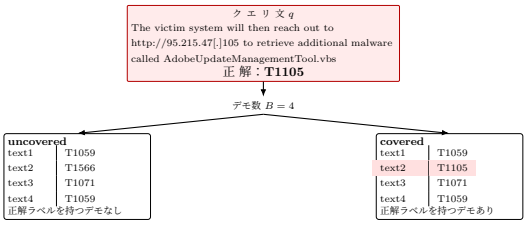


図 1 デモ数が限られるときの正解ラベルの網羅性の違い．各デモは CTI 文と Technique ラベルのペアであり，covered 条件では正解 Technique を含むデモを色付けしている（IP アドレスは無害化して表記）．

Fig. 1 Different label coverage under a limited demonstration budget. Each demonstration is a CTI–Technique pair; the demonstration containing the gold Technique is highlighted in the covered condition.

とラベルノイズを標準化・診断している．本研究では，これらの要因を区別するため，クエリの正解 Technique がデモに含まれる条件を covered，含まれない条件を uncovered と明示的に定義する．

図 1 に，この問題を同じデモ数の二つの例で示す．covered 条件では正解ラベルを含むデモが提示される一方，uncovered 条件では同じデモ数でも正解ラベルが提示されず，デモ中に正解ラベルの例がない状態で分類することになる．

本研究では，この問題を検証するため，ラベル網羅性（label coverage; coverage）を ICL 評価の独立した軸として導入し，クエリごとにデモをサンプリングする．さらに，デモ数を Technique 数に一致させた同一デモ数条件を設け，すべてのラベルを一度ずつ提示する方針と，限られたラベルを複数例で提示する方針を比較する．これにより，デモ数を固定したまま，ラベル網羅性，ラベルごとのデモ数，Tactic の分布を比較できる．この比較からは，全ラベルを一度ずつ提示して網羅性を最大化する素朴な方針が必ずしも最良ではなく，一部のラベルについて複数の対応例を提示する方が高い完全一致正解率を得るという，直感に反する結果が得られる．

ラベル網羅性だけでは，正解 Technique がデモに含まれていても完全一致正解率が低くなる理由や，uncovered クエリでも残る部分的な情報を説明できない．ATT&CK の Technique は Tactic–Technique 階層に位置付けられており [10]，同一 Tactic 内の誤りと Tactic が異なる誤りは区別すべきである [4]．そこで，階層構造を利用した階層的 F1（hierarchical F1; hF1）と Tactic 一致率（Tactic Match; TacM）を完全一致正解率と併記し，予測を正解，同一 Tactic 内誤り，Tactic 不一致，不正出力に分解する．さらに，正解・予測ラベルを持つデモの例数と，正解ラベルを持つデモとクエリとの類似度を調べ，ラベル網羅性だけでは説明できない誤りを診断する．

本研究の貢献は以下の 3 点である．(1) 大規模ラベル空

© 2026 Information Processing Society of Japan

間における ICL に基づく TTP 分類について，クエリごとのラベル網羅性と同一デモ数条件を組み合わせ，デモの配分を評価する手順を示す．(2) 3 データセットと 3 規模の Llama（1B–8B）を用い，デモの提示による性能向上が主に covered クエリに現れること，および全ラベルを一度ずつ提示する方法が必ずしも最良でないことを検証する．(3) 本稿の比較条件では最高の完全一致正解率も 50%未満に留まることを示し，誤りを同一 Tactic 内，Tactic 不一致，不正出力に分解するとともに，正解・予測ラベルを持つデモの数とクエリとのテキスト類似性から，ラベル網羅性だけでは説明できない失敗を明らかにする．

2. 関連研究

CTI 文の TTP 分類には，固定されたラベル集合を学習する分類手法と，検索と生成を組み合わせる手法がある．前者は学習済み分類器として効率的に動作する一方，Technique の集合やデータ分布が変化すると再学習を必要とする．後者はラベルの説明や知識ベースを推論時に利用できるが，検索結果に含まれるラベルと生成モデルの挙動を合わせて評価する必要がある．既存研究の多くは，全クエリをまとめて集計した完全一致正解率や F1 を報告するにとどまり，各クエリの正解ラベルがデモに含まれるかや，どのラベルを何例提示したかを分けて評価していない．そのため，デモに正解ラベルが含まれるクエリと含まれないクエリの性能差を区別できない．

ICL は，パラメータを更新せず，例を提示することでタスクを実行させる枠組みである [11]．分類では，例の順序，ラベルの表現，入力の多様性が結果に影響する．さらに，デモ中で多く提示されたラベルに予測が偏る多数派ラベルバイアスと，その較正法が知られている [12], [13]．Gupta らはデモ中のラベル比率を変化させ，この偏りに対する頑健性がモデルとタスクによって大きく異なることを示した [14]．これらの研究は，ラベル頻度の偏りを主に誤りや不安定性の要因として扱っている．一方，頻出ラベルがクエリの正解と一致する場合は，同じ偏りが性能向上につながる可能性がある．したがって，ラベルの反復を一律に避けるのではなく，反復されたラベルとクエリとの対応も合わせて捉えることが望ましい．

大規模ラベル空間を対象とする長文脈ベンチマークでは，ラベルごとの例数や文脈長の効果が調べられている．しかし，固定したデモ集合を全クエリで再利用する設定では，クエリごとのラベル網羅性による影響と，クエリに無関係な例による影響を区別しにくい．本研究では，訓練候補プールからクエリごとにデモをサンプリングし，ラベル網羅性を明示的に測定する．

モデル内部の機構に関しては，誘導ヘッド（induction head）が先行する文脈からパターンを検索し，対応するトークンをコピーするという仮説がある [15]．covered 条件におけるラベル再利用はこの仮説と整合しうるが，本研究の主目的は内部回路の同定ではなく，ラベル網羅性に応じた挙動の測定である．

表 1 前処理後のデータセット統計
Table 1 Statistics of the preprocessed datasets.

データセット	デモ候補	Technique 数	クエリ数
TRAM	3,388	115	817
AnnoCTR	1,384	97	337
CTI-HAL	818	76	210

3. 評価方法

3.1 タスクとデータセット

CTI 文の各クエリを，親 Technique へ統合した MITRE ATT&CK Technique ID へ分類する．モデルには CTI 文と複数の入力–ID 例を与え，正規の Technique ID を 1 つ出力させる．評価には TRAM[3], AnnoCTR[16], CTI-HAL[17] を用いた．前処理は，(i) マルチラベル例の除外，(ii)Sub-Technique ID の親 Technique への統合，(iii) 付与例が 1 件のみの Technique の除外，(iv) 重複サンプルの除去，(v) 層化再分割の順に行った．

前処理によるデータの変化を適用順に記す．マルチラベル例は TRAM で 576/4,797（12.0%），AnnoCTR で 488/2,232（21.9%），CTI-HAL で 0/1,068（0%）であった．Sub-Technique を含むサンプルは TRAM のみに存在し（元データ全体で 1,342/4,797，28.0%），マルチラベル例を除いた後も残る単一ラベル例 1,045/4,221（24.8%）のラベルを親 Technique へ統合した．次に，統合後の全データで付与例が 1 件のみの Technique を除外した（TRAM 16/4,221（0.4%），AnnoCTR 23/1,744（1.3%），CTI-HAL 29/1,057（2.7%））．さらに CTI-HAL では統合後に同一テキスト・同一ラベルとなった重複 11/1,068（1.0%）を除去した（TRAM と AnnoCTR では該当なし）．層化再分割後，訓練データに存在しない Technique を持つテスト例はなく，3 データセットとも追加の除外はなかった．

前処理後の訓練データをデモ候補プール，テストデータをクエリ集合とした．データセットごとに 3 通りの層化分割を作成し，各クエリに対するデモを，対応する候補プールから独立に取得した．したがって，デモ集合はクエリごとに異なりうる．統計を表 1 に示す．

3.2 デモ選択戦略

各クエリに対して，候補プールから次の戦略でデモを選択する．

- 事例一様抽出（instance-uniform; IU）：候補例を一様に選択する．同じラベルを持つ例が複数選ばれる場合がある．
- Tactic 均衡抽出（tactic-balanced; TB）：Tactic の偏

© 2026 Information Processing Society of Japan

りを抑えながら例を選択する．

- ラベル巡回抽出（round-robin; RR）：Technique ラベルを巡回し，ラベル網羅性を優先する．

主条件のデモ数は 30 例とし，モデルには ID 形式で出力させた．本評価の Technique 数は 76–115 であるため，30 例では全ラベルを網羅できない．加えて，戦略間でデモ数を Technique 数に揃える同一デモ数条件を設けた．この条件では，RR はすべての Technique をちょうど一度ずつ提示して網羅性が最大となる一方，各ラベルの CTI 文は一つに限られ，IU は網羅性が下がる代わりに同一ラベルへ複数の CTI 文を対応付けられる（TB はその中間）．すなわち同じデモ数のもとで，網羅性とラベルごとのデモ数の配分だけを変えた比較になる．

3.3 ラベル網羅性の定義と制御

クエリの入力を x，正解 Technique を y，デモ集合のラベル集合を $D(x)$ とすると，ラベル網羅性（coverage）を次式で定義する．

$$C(x) = \mathbb{I}[y \in D(x)]. \tag{1}$$

$C(x) = 1$ を covered，$C(x) = 0$ を uncovered と呼ぶ．通常のサンプリングでは，戦略によって covered クエリと uncovered クエリの比率が変化する．そのため，全クエリの完全一致正解率だけでは，正解ラベルの提示有無による差と，両クエリの構成比による差を区別できない．そこで，クエリ集合を固定したままデモだけを再サンプリングし，正解ラベルの有無を制御するラベル網羅性統制条件も用いた．

さらに，ラベル網羅性以外のデモ構成を揃えた対応比較を行った．各クエリについて共通の 29 例を固定し，残りの 1 例だけを，正解 Technique を含む置換例または含まない対照例に置き換えた．両者は同じ Tactic から選び，外部埋め込みモデル（BAAI/bge-large-en-v1.5）[*1]で算出したクエリとの類似度と文字長が近くなるようにした．この比較は実運用の検索方式を再現するものではない．クエリの難しさ，共通する 29 例，デモ文の類似度と長さをできるだけ揃えたうえで，正解 Technique を含むデモの有無が性能に与える影響を調べるための比較である．

3.4 評価指標

完全一致正解率（exact-match accuracy; Acc）は予測 Technique が正解 ID と完全一致した割合である．階層的 F1（hierarchical F1; hF1）は，正解と予測の Technique および親 Tactic を集合として比較し，階層上の部分一致を評価する [18]．Tactic 一致率（Tactic Match; TacM）は予測 Technique と正解 Technique が同じ Tactic に属する割合である．

[*1] https://huggingface.co/BAAI/bge-large-en-v1.5

さらに，予測結果を，(i) 正解，(ii)Technique は誤りだが正解と予測が同じ Tactic に属する誤り，(iii) 正解と予測が同じ Tactic に属さない誤り，(iv) 正規の Technique ID を出力しない不正出力，の 4 種類に分ける．方向付き混同は，ある正解 Technique が特定の Technique へ誤分類された回数を，その正解 Technique の全出現数で割って算出する．

デモ集合との関係を調べるため，正解ラベルと予測ラベルを持つデモの例数をそれぞれ数える．また同じ埋め込みモデルを用い，クエリと正解ラベルを持つデモの最大コサイン類似度，クエリと異なるラベルを持つデモの最大類似度，正解ラベルを持つデモ間の平均距離を計測する．これらは内部機構を測るものではなく，保存済みのデモ構成と予測結果の関係を記述する補助指標である．

3.5 ラベル頻度介入

ラベル網羅性による性能差を，正解ラベルを提示すること自体の効果と，同一ラベルの反復による予測の偏りとに分けるため，ラベルの提示回数を統制した介入実験も行う．8B モデルを対象に，クエリ，互いに異なるラベルを持つ共通の中立デモ，および対象デモの挿入位置を対応付けたうえで，対象ラベルを持つデモの数を $k = 0, 1, 2, 4$ と変化させる．デモ数は 30 例に固定し，対象デモ以外は中立デモで補う．対象ラベルには，クエリの正解 Technique（gold）または不正解 Technique（wrong）を用い，wrong の対象 Technique は可能な場合に正解 Technique と同じ Tactic から選ぶ．$k = 0$ は 30 例すべてが異なる中立ラベルを持つ対照条件であり，$k = 1$ では対象ラベルも他の中立ラベルと同じく 1 回だけ出現する．したがって $k = 1$ は，ラベルの頻度を変えずに正解ラベルの提示有無だけを切り替える条件にあたる．

3.6 モデルと実験条件

モデルは Meta Llama 3.2 1B Instruct，Meta Llama 3.2 3B Instruct，Meta Llama 3.1 8B Instruct である[*2]各条件を 3 通りの層化分割で実行し，本文ではその平均を報告する．

4. 結果

以下では，ラベル網羅性が性能を左右し，その差が層化分割やモデル規模に依存しないこと（4.1，4.2 節），同一デモ数でのデモ選択戦略とデモ数の影響（4.3，4.4 節），および類似度と長さを揃えたペア比較で網羅性の差が交絡では説明できないこと（4.5 節）を順に示す．

[*2] Meta Llama 3.2 1B Instruct: https://huggingface.co/meta-llama/Llama-3.2-1B-Instruct, Meta Llama 3.2 3B Instruct: https://huggingface.co/meta-llama/Llama-3.2-3B-Instruct, Meta Llama 3.1 8B Instruct: https://huggingface.co/meta-llama/Llama-3.1-8B-Instruct

© 2026 Information Processing Society of Japan

4.1 ラベル網羅性による性能差

図 2 に，IU 30 例における covered/uncovered の比較を，ゼロショット（ZS）と併せて示す．ラベル網羅性統制条件では，同一のクエリ集合に対してデモだけを再抽出し，正解 Technique を含むか否かを制御した．covered 条件の Acc, hF1, TacM は，すべてのデータセットとモデル規模で uncovered 条件を上回った．したがって，この差は通常条件における covered/uncovered の構成比だけでは説明できない．covered 条件の Acc は，TRAM では 1B/3B/8B の順に 0.157/0.269/0.424，CTI-HAL では 0.167/0.252/0.421，AnnoCTR でも 0.214/0.371/0.414 と，大きなモデルほど高かった．

uncovered 条件の Acc も，8B では TRAM 0.160，AnnoCTR 0.167，CTI-HAL 0.144 まで向上し，正解ラベルがデモに含まれないクエリでも一定の割合で正しい Technique を予測できる．しかし，covered 条件と uncovered 条件の差は解消されず，1B で約 0.13–0.15，3B で 0.21–0.26，8B で 0.25–0.28 であり，uncovered 条件の改善幅を covered 条件が上回ったためモデルが大きいほどむしろ拡大した．hF1 と TacM では uncovered 条件も一定の値を示すため，Acc ほど差は大きくない．

階層指標では差が縮小した．例えば，TRAM 1B の uncovered 条件では，Acc は 0.011 である一方，hF1 は 0.370，TacM は 0.129 であった．これは，uncovered 条件の予測が完全に無作為ではなく，正解 Technique が属する Tactic などの階層情報を部分的に捉えていることを示す．この傾向の強さはデータセットによって異なり，AnnoCTR で特に顕著であった．ただし階層上の部分点と正解 Technique の同定は異なり，hF1 は Acc の代替ではなく，異なる粒度で誤りを診断する指標として扱う．

4.2 性能差の統計的検証

3 データセット，3 モデル規模，3 通りの層化分割からなる 27 条件のすべてで，covered 条件の Acc は uncovered 条件を上回った．対応関係を保ったブートストラップによる 95%信頼区間では，最小の差についても下限が 0 を上回った．対応のある置換検定でも，ラベル網羅性による差は統計的に有意であった（各条件の Δ_{cov}，信頼区間，Holm 補正後の p 値は付録 A.1 に示す）．これは，あらゆる条件に成り立つ普遍的なスケーリング則を証明するものではない．一方，本研究で用いたデータ分割とモデル系列の範囲では，covered 条件と uncovered 条件の差の方向がデータ分割によって反転しないことを示す．

4.3 デモ選択戦略の比較

表 2 は，デモ数を Technique 数に合わせた結果である．IU, TB, RR の Acc は，TRAM で 1B の 0.087/0.047/0.019，3B の 0.314/0.192/0.147，8B の 0.406/0.311/0.271 であった．AnnoCTR と CTI-HAL でも IU が一貫して最も高く，RR が最も低い．

表 2 同一デモ数条件の Acc（3 通りの層化分割における平均）．各データセット・モデルで IU，TB，RR のうち最良の値を太字と網掛けで示す．

Table 2 Exact-match accuracy under matched demonstration budgets. The best IU/TB/RR result for each dataset and model is shown in bold with shading.

データ	戦略	1B	3B	8B
TRAM	IU	**0.087**	**0.314**	**0.406**
	TB	0.047	0.192	0.311
	RR	0.019	0.147	0.271
AnnoCTR	IU	**0.117**	**0.415**	**0.459**
	TB	0.083	0.286	0.361
	RR	0.039	0.167	0.266
CTI-HAL	IU	**0.149**	**0.279**	**0.397**
	TB	0.111	0.190	0.327
	RR	0.052	0.148	0.222

RR は全ラベルを一度ずつ提示して網羅性を最大化するにもかかわらず，各ラベルの CTI 文が一つに限られるため，Acc は 3 データセットとも最も低かった（例えば 1B で TRAM 0.019，AnnoCTR 0.039，CTI-HAL 0.052）．一方 IU は同一ラベルへ複数の CTI 文を対応付けられ，covered クエリで正解ラベルの複数例を利用できる．TB は両者の中間である．これらは，ラベル網羅性，ラベルごとのデモ数，Tactic の分布を単一のデモ数だけでは表せないことを示す．

以上の比較は，ラベル網羅性だけを最大化するよりも，一部の Technique について複数の対応例を提示する方が有効であることを示す．ただし IU はクエリ内容を用いず，どのラベルが反復されるかも制御しないため，改善の余地がある．

4.4 デモ数の増加による影響

デモ数を増やしても，性能が単調に向上するとは限らない．1B の IU では，AnnoCTR の Acc は 30 例の 0.177 から Technique 数と同じ 97 例の 0.117 へ低下した．TRAM は 30 例の 0.085 から 115 例の 0.087，CTI-HAL は 30 例の 0.138 から 76 例の 0.149 となり，ほぼ横ばいであった．追加された例によってクエリに無関係なラベルが増え，必要なデモを長い文脈から参照しにくくなった可能性がある．

通常条件の全体性能は covered クエリの比率にも依存するため，デモ数を比較する際には Acc に加えて実際の covered 率，ラベルの反復数，Tactic 数を併記することが望ましい．これらを区別しなければ，プロンプト構成による差をモデル能力による差と誤認しかねない．

4.5 類似度と長さを揃えた比較

通常条件におけるクエリ構成やデモ構成の影響をさらに

© 2026 Information Processing Society of Japan

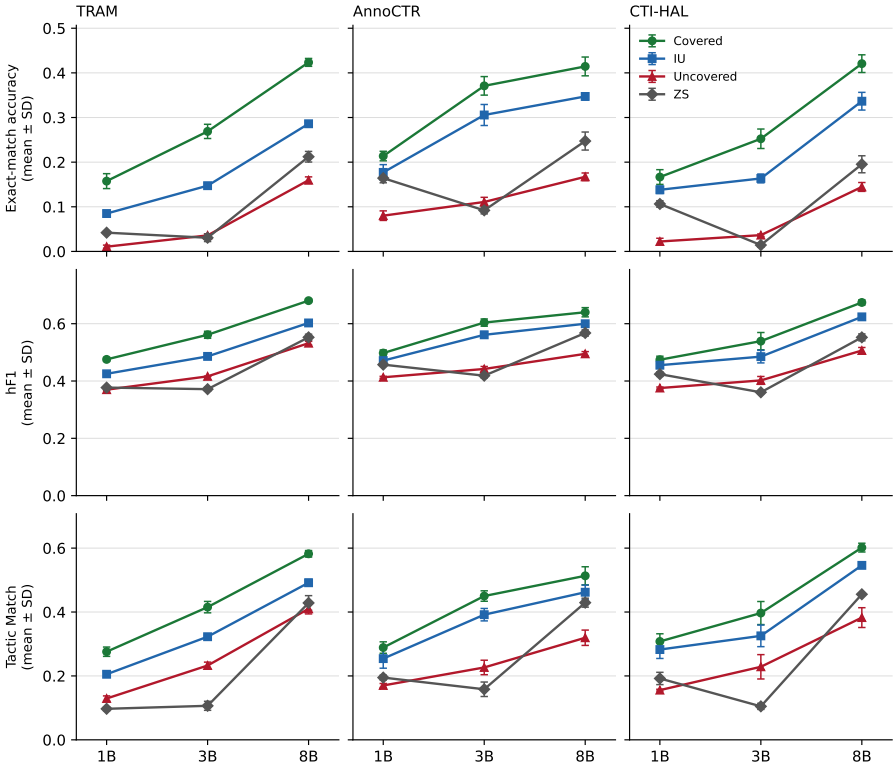


図 2 モデル規模ごとのラベル網羅性別の評価結果．列はデータセット，行は Acc，hF1，TacM を表す．IU 30 例において，ZS，通常の IU，covered 条件，uncovered 条件を 3 通りの層化分割で比較した．covered 条件は全条件で uncovered 条件を上回り，Acc の差が最も大きい．

Fig. 2 Coverage-conditioned metrics across model sizes (columns: datasets; rows: Acc, hF1, TacM). For IU with 30 demonstrations, we compare zero-shot (ZS), unconstrained IU, and the covered and uncovered conditions over three stratified splits.

抑えるため，共通の 29 例を固定し，最後の 1 例だけを置き換える対応比較を行った．正解 Technique を含む置換例と含まない対照例を同じ Tactic から選び，クエリとの外部埋め込み類似度と文字長が同程度になるようにした．この統制後も全 9 データセット・モデル条件で，covered 条件の Acc，hF1，TacM が uncovered 条件を上回った（付録 A.2，表 A·2）．例えば TRAM では 1B の Acc が 0.134 対 0.011，8B でも 0.417 対 0.140 であり，Acc のみを示した表と同じ方向の差が hF1 と TacM でも全 9 条件で得られた．したがって，covered 条件のデモが単に意味的に近い，または長いという違いだけでは性能差を説明できない．ただし文面や手順記述の質まで一致させた因果実験ではなく，類似度と長さの交絡を抑えても covered 条件の優位が再現した結果として解釈する．

5. 考察

5.1 ラベル網羅性による性能差の要因

結果は，ICL の性能に少なくとも二つの要因が関係することを示す．一つは，covered クエリにおけるデモのラベル再利用である．もう一つは，正解ラベルがデモに含まれない uncovered クエリに対し，入力文，ATT&CK の階層，データセットのラベル分布などを手掛かりに分類する能力である．ただし，分類結果だけから，モデル内部でどの情報が使われたかを直接特定することはできない．

TRAM では，IU 30 例の uncovered クエリに対する予測の約 64%が，デモ中に現れたラベルであった．一方，RR の同じ条件では約 5%であった．IU は一部のラベルを反復するため，正解ラベルが提示されていない場合でも，モデルの予測がデモ集合中のラベルに偏る可能性がある．この割合は，ラベル再利用の傾向を予測結果から捉えたものであり，特定の誘導ヘッドや内部回路を同定するものではない．

5.2 多数派ラベルバイアスとラベル頻度介入

多数派ラベルバイアス [12], [13], [14] は，反復されたラベルが正解なら性能向上に，不正解なら誤りの増加につながりうる．そこで 3.5 節のラベル頻度介入により，正解ラベルを提示すること自体の効果と反復による予測の偏りと

© 2026 Information Processing Society of Japan

表 3 最良 8B 設定における予測結果の構成（IU，同一デモ数条件，3 通りの層化分割における平均，%）．Tactic 内は Technique が誤りでも正解と予測が同じ Tactic に属する場合，Tactic 外は同じ Tactic に属さない場合を表す．

Table 3 Outcome composition under the best 8B instance-uniform setting (IU, matched budget, mean over three splits, %).

データ	正解	Tactic 内	Tactic 外	不正出力
TRAM	40.6	19.4	33.9	6.1
AnnoCTR	45.9	10.0	41.8	2.3
CTI-HAL	39.7	17.3	41.1	1.9

を切り分けた．対象ラベルを 1 例だけ提示した gold $k = 1$ でも，Acc は $k = 0$ の 0.183 から 0.358 へ 17.5 ポイント上昇し，$k = 2, 4$ では 0.511，0.682 に達した．一方 wrong 条件では，対象不正解ラベルの予測率が $k = 0$ の 0.038 から $k = 4$ の 0.207 へ増加した．以上から，デモ効果は (i) 正解ラベルの提示によるラベルと入力文の対応付けと，(ii) 反復されたラベルへの予測の偏りに分けて解釈でき，前者は多数派ラベルバイアスだけでは説明できない（詳細は付録 A.3）．

5.3 最良条件における誤り分析

同一デモ数条件で最も高い完全一致正解率を得た 8B の IU でも，Acc は全データセットで半数を下回った．表 3 に，予測を正解，同一 Tactic 内の Technique 誤り，Tactic 不一致，不正出力に分けた構成を示す．Tactic 不一致と不正出力を合わせると全クエリの 40.0–44.1%を占め，誤りだけを分母とした場合は 67–82%に達する．したがって，残る誤りの多くは，同一 Tactic 内の細粒度な取り違えだけでは説明できない．

8B・IU・同一デモ数条件のうち，通常条件で covered となり，かつ正規の Technique ID を出力したクエリを，予測結果に基づいて正解，同一 Tactic 内誤り，Tactic 不一致の 3 群に事後的に分けた．正解群には正解ラベルを持つデモが平均 5.44 件含まれていたのに対し，同一 Tactic 内誤りでは 2.59 件，Tactic 不一致では 3.90 件であった．クエリと最も類似する正解ラベル付きデモとの平均コサイン類似度も，それぞれ 0.757，0.694，0.684 であった．さらに誤り群では，予測ラベルを持つデモが正解ラベルを持つデモより平均 1.08–1.24 件多かった．これらの傾向は 3 データセットに共通しており，正解ラベルを持つデモの数，そのデモとクエリとのテキスト類似性，正解・予測ラベルの反復数の差が，同じ covered クエリでも完全一致の成否に関わると考えられる．ただし予測後の群分けに基づく観察であり，因果関係を示すものではない．

一方，クエリに最も類似する異なるラベルのデモとの類似度と，正解ラベルを持つデモ間の平均距離は，正解群と誤り群を一貫して分離しなかった．したがって，IU の優位を入力表現の多様性だけに帰属させることはできない．同一ラベルを持つデモの数と，それらのデモとクエリとのテキスト類似性は分けて捉えるべきである．

最良設定の誤りには，同一 Tactic 内の細粒度な取り違え（例: System Information Discovery→System Network Configuration Discovery）と Tactic をまたぐ誤り（例: Phishing→User Execution）の双方が含まれ，Command and Scripting Interpreter のような汎用ラベルへの予測集中も見られた．これらには，クエリに対応するデモの不足，反復ラベルへの偏り，Technique 間の識別の難しさ，複数トークンからなる ID 生成，さらに短い CTI 文に起因するアノテーションの曖昧性が関係すると考えられる（頻出した方向付き混同の一覧は付録 A.4）．

5.4 CTI 分析支援への適用

CTI 分析支援に本手法を用いる場合，全クエリの完全一致正解率だけでは，デモのラベル再利用による結果と，正解ラベルがデモにないクエリの分類結果が混在し，デモ構成がどのクエリに寄与したかを判断できない．また実運用では正解ラベルが未知のため，各クエリに covered/uncovered を付与できない．そこで検索に基づくデモ選択では，正解ラベル取得率，検索スコア，候補ラベルの多様性，同一ラベルの反復数といった推論時に観測できる量を記録し，オフラインでこれらと正解ラベル取得との関係を検証する．

uncovered 条件で TacM が高く Acc が低い場合，モデルは攻撃戦術の候補を示せているが，最終的な Technique の識別にはアナリストの確認が必要である．最良設定でも Tactic 不一致と不正出力が全クエリの 40%以上を占めるため，正解ラベルを含むデモを取得するだけで自動分類を信頼できるとは限らない．

デモ選択では，全ラベルを一度ずつ提示する方針もラベル頻度を均等にする方針も常に有効とは限らない．デモ数が限られる場合は，対象文書との対応に裏付けられた同一ラベルの複数例と識別に必要な競合ラベルを確保しつつ，特定のラベルへの集中を避け，最も多く現れるラベルの反復数や候補ラベルの種類数も監視することが望ましい．同一デモ数条件の結果は，デモ選択を入力長ではなく，限られたデモの配分の問題として扱う根拠となる．

6. まとめと今後の課題

本研究では，Technique 数がデモ数を上回る場合がある ICL に基づく TTP 分類を対象に，クエリごとのラベル網羅性（coverage）を明示する評価法を示した．TRAM，AnnoCTR，CTI-HAL と Llama 1B–8B を用いた実験では，全 27 条件で covered クエリの完全一致正解率が uncovered クエリを上回り，モデルを大規模化してもこの性能差は維持された．また同一デモ数では，全ラベルを一度ずつ提示する RR より，一部のラベルについて複数の対応例を提示

© 2026 Information Processing Society of Japan

する IU の方が高い完全一致正解率を得ており，デモ数が同じでもラベル網羅性とラベルごとのデモ数によって性能が変わる．

一方，本稿で比較した最良の 8B・IU 条件でも，完全一致正解率は 39.7–45.9%に留まり，Tactic 不一致と不正出力が全クエリの 40%以上を占めた．covered クエリの分析では，正解したクエリほど正解ラベルを持つデモが多く，クエリとのテキスト類似度が高いデモを含んでいた．以上から，ICL に基づく TTP 分類では，ラベル網羅性とデモ数に加え，ラベルごとのデモ数とクエリとのテキスト類似性を区別して評価する必要があることを示した．

今後は，クエリとのテキスト類似性が高い同一ラベルの複数例と競合ラベルを選び，対応が弱い特定のラベルへの集中を抑える検索法を実装する．その上で，正解ラベル取得率，デモ中のラベル頻度，分類性能の関係を評価する．さらに，複数ラベル TTP 分類と他のモデル系列へ実験を拡張し，本稿で確認したラベル網羅性による性能差を再検証する．

参考文献

[1] The MITRE Corporation: MITRE ATT&CK®, https://attack.mitre.org/ (2024).

[2] Büchel, M., Paladini, T., Longari, S., Carminati, M., Zanero, S., Binyamini, H., Engelberg, G., Klein, D., Guizzardi, G., Caselli, M., Continella, A., van Steen, M., Peter, A. and van Ede, T.: SoK: Automated TTP Extraction from CTI Reports – Are We There Yet?, *Proceedings of the 34th USENIX Security Symposium*, (online), available from https://www.usenix.org/conference/usenixsecurity25/presentation/buechel (2025).

[3] MITRE Center for Threat-Informed Defense: Threat Report ATT&CK Mapper (TRAM), https://github.com/center-for-threat-informed-defense/tram (2022).

[4] Orbinato, V., Barbaraci, M., Natella, R. and Cotroneo, D.: Automatic Mapping of Unstructured Cyber Threat Intelligence: An Experimental Study, *Proceedings of the 33rd IEEE International Symposium on Software Reliability Engineering (ISSRE)*, (online), DOI: https://doi.org/10.1109/ISSRE55969.2022.00034 (2022).

[5] Lekssays, A., Shukla, U., Sencar, H. T. and Parvez, M. R.: TechniqueRAG: Retrieval Augmented Generation for Adversarial Technique Annotation in Cyber Threat Intelligence Text, *Findings of the Association for Computational Linguistics: ACL 2025*, (online), available from https://aclanthology.org/2025.findings-acl.1076/ (2025).

[6] Min, S., Lyu, X., Holtzman, A., Artetxe, M., Lewis, M., Hajishirzi, H. and Zettlemoyer, L.: Rethinking the Role of Demonstrations: What Makes In-Context Learning Work?, *Proceedings of the 2022 Conference on Empirical Methods in Natural Language Processing (EMNLP)*, (online), available from https://aclanthology.org/2022.emnlp-main.759/ (2022).

[7] Ryan, A., Noor, S. S., Erfan, M., Mitra, S., Mittal, S. and Rahman, M. R.: Evaluating Open-Source LLMs for Multi-Label ATT&CK Technique Classification on CTI Reports, *arXiv preprint arXiv:2606.18166* (2026).

[8] Li, T., Zhang, G., Do, Q. D., Yue, X. and Chen, W.: LongICLBench: Benchmarking LLMs on Long In-Context Learning, *Transactions on Machine Learning Research (TMLR)*, (online), available from https://arxiv.org/abs/2404.02060 (2025).

[9] Cho, H. and Inoue, N.: StaICC: Standardized Evaluation for Classification Task in In-context Learning, *arXiv preprint arXiv:2501.15708*, (online), available from https://arxiv.org/abs/2501.15708 (2025).

[10] Crossman, A., Dodd, J., Kumar, V. R. C., Mohammed, R., Plummer, A. R., Sekharudu, C., Warrier, D. and Yekrangian, M.: Constructing Multi-Label Hierarchical Classification Models for MITRE ATT&CK Text Tagging, *arXiv preprint arXiv:2601.14556* (2026).

[11] Brown, T., Mann, B., Ryder, N., Subbiah, M., Kaplan, J. D., Dhariwal, P., Neelakantan, A., Shyam, P., Sastry, G., Askell, A. et al.: Language Models Are Few-Shot Learners, *Advances in Neural Information Processing Systems (NeurIPS)*, Vol. 33 (2020).

[12] Zhao, Z., Wallace, E., Feng, S., Klein, D. and Singh, S.: Calibrate Before Use: Improving Few-Shot Performance of Language Models, *Proceedings of the 38th International Conference on Machine Learning*, Proceedings of Machine Learning Research, Vol. 139, PMLR, pp. 12697–12706 (online), available from https://proceedings.mlr.press/v139/zhao21c.html (2021).

[13] Fei, Y., Hou, Y., Chen, Z. and Bosselut, A.: Mitigating Label Biases for In-context Learning, *Proceedings of the 61st Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers)*, Association for Computational Linguistics, pp. 14014–14031 (online), DOI: https://doi.org/10.18653/v1/2023.acl-long.783 (2023).

[14] Gupta, K., Roychowdhury, S., Kasa, S. R., Kasa, S. K., Bhanushali, A., Pattisapu, N. and Murthy, P. S.: How Robust are LLMs to In-Context Majority Label Bias?, *AAAI 2024 Workshop on Responsible Language Models*, (online), available from https://arxiv.org/abs/2312.16549 (2024).

[15] Olsson, C., Elhage, N., Nanda, N., Joseph, N., DasSarma, N., Henighan, T., Mann, B., Askell, A., Bai, Y., Chen, A. et al.: In-Context Learning and Induction Heads, *Transformer Circuits Thread* (2022).

[16] Lange, L., Müller, M., Haratinezhad Torbati, G., Milchevski, D., Grau, P., Pujari, S. C. and Friedrich, A.: AnnoCTR: A Dataset for Detecting and Linking Entities, Tactics, and Techniques in Cyber Threat Reports, *Proceedings of the 2024 Joint International Conference on Computational Linguistics, Language Resources and Evaluation (LREC-COLING)*, (online), available from https://aclanthology.org/2024.lrec-main.103/ (2024).

[17] Della Penna, S., Natella, R., Orbinato, V., Parracino, L. and Pianese, L.: CTI-HAL: A Human-Annotated Dataset for Cyber Threat Intelligence Analysis, *Proceedings of the Workshop on Attackers and Cyber-Crime Operations (WACCO), IEEE Euro S&P Workshops* (2025).

[18] Kiritchenko, S., Matwin, S. and Famili, A. F.: Learning and Evaluation in the Presence of Class Hierarchies: Application to Text Categorization, *Proceedings of the 19th Canadian Conference on Artificial Intelligence (Canadian AI)*, (online), DOI: https://doi.org/10.1007/11766247_34 (2006).

© 2026 Information Processing Society of Japan

付　　録

A.1　ラベル網羅性による性能差の統計的検証

本付録では，covered 条件と uncovered 条件の性能差を，層化分割とデータセット・モデル規模の組合せごとに検証する．

表 A·1 に，本文の図 2 に示した IU 30 例の covered/uncovered 比較について，27 条件（3 データセット ×3 モデル規模 ×3 通りの層化分割）の完全一致正解率を示す．条件ごとに同一クエリを対応付け，完全一致正解率差 Δ_{cov}（covered − uncovered），ブートストラップ 95%信頼区間，対応のある置換検定の p 値を 10,000 回のリサンプリングで算出した．27 比較全体には Holm 補正を適用した．

全 27 条件で covered 条件の完全一致正解率が uncovered 条件を上回り，すべての 95%信頼区間が 0 を含まなかった（最小差 +0.11）．Holm 補正後の p 値は全条件で 0.0027 であり，同一データセット・モデル内における差の標準偏差も 0.031 以下であった．したがって，図 2 に示した性能差は，特定の層化分割やモデル規模だけに依存するものではない．

A.2　類似度と長さを揃えた対応比較の詳細

本付録では，4.5 節で述べた対応比較の完全一致正解率を表 A·2 に示す．各クエリで共通の 29 例を固定し，最後の 1 例だけを，正解 Technique を含む置換例（covered）または含まない対照例（uncovered）に置き換えた．両者は同じ Tactic から選び，外部埋め込みモデル（BAAI/bge-large-en-v1.5）で算出したクエリとの類似度と文字長を揃えている．紙面の都合で表には Acc のみを示すが，hF1 と TacM でも全 9 条件で同じ方向の差が得られた．

A.3　ラベル頻度介入の詳細

本付録では，3.5 節で述べたラベル頻度介入の結果を表 A·3 に示す．3 データセットと 3 通りの層化分割で介入条件を構成できた 3,804 クエリを集計した．

前述のとおり，$k = 1$ では対象ラベルも他の中立ラベルと同じく 1 回しか現れない．それにもかかわらず，gold $k = 1$ の Acc は $k = 0$ の 0.183 から 0.358 へ 17.5 ポイント上昇した．これは，最初の正解ラベル付きデモによる改善を，多数派ラベルバイアスだけでは説明できないことを示す．さらに，gold $k = 2$，$k = 4$ では Acc がそれぞれ 0.511，0.682 まで上昇し，正解ラベルの反復が性能向上を段階的に補強した．

一方，wrong 条件では，介入対象とした不正解ラベルの予測率が $k = 0$ の 0.038 から，$k = 1$，$k = 2$，$k = 4$ の順に 0.078，0.121，0.207 へ増加した．したがって，ラベル頻度による予測の偏り自体は明確に観測された．ただし，Acc の低下は $k = 4$ でも 0.183 から 0.148 への 3.5 ポイントに留まった．不正解ラベルへの予測変更のすべてが正解から不正解への変更ではなく，別の誤予測から対象ラベルへの変更も含むためである．

なお本介入は，対象ラベルを持つ CTI 文を中立デモと置き換えるものであり，ラベル文字列の頻度だけを操作したものではない．そのため $k = 2, 4$ の性能向上には，ラベルの反復と，複数の入力–ラベル対応例の提示の両方が寄与しうる．

A.4　代表的な混同パターン

本付録では，8B の IU・同一デモ数条件で頻出した方向付き混同を表 A·4 に示す．System Information Discovery→System Network Configuration Discovery は同一 Discovery Tactic 内の細粒度識別の失敗，Deobfuscate/Decode→Obfuscated Files or Information は関連語彙を持つ復号と隠蔽の取り違えである．一方，Phishing→User Execution は攻撃フロー上で連続しうるが Tactic が異なる．また複数の正解ラベルから Command and Scripting Interpreter への誤りは，汎用的なラベルへの予測集中を示唆する．

これらの誤りには，クエリに対応するデモの不足，デモ中で反復されたラベルへの偏り，Technique 間の識別の難しさ，複数のトークンからなる ID の生成が関係すると考えられる．加えて，短い CTI 文だけでは複数の Technique と解釈できる場合があり，アノテーションの曖昧性も正解ラベルを一意に定めにくくする要因となりうる．

A.5　プロンプトテンプレートと条件例

本付録では，Technique ID 出力とラベル網羅性統制に用いたプロンプト形式を図 A·1 に示す．指示文と CTI 例はモデルへ実際に与えた英語入力であり，デモは紙面の都合で模式化している．システム指示はデータセット・デモ選択戦略・ラベル網羅性条件によらず共通で，デモはクエリごとに独立にサンプリングした．ラベル網羅性統制条件では，プロンプト形式とデモ数を共通にし，構成前のサンプリング方法だけを変える．covered 条件はクエリの正解 Technique を持つデモを少なくとも 1 例含め，uncovered 条件は除外する．いずれの条件を用いたかはモデルに提示しない．

© 2026 Information Processing Society of Japan

表 A·1 本文の図 2 に示したラベル網羅性別の完全一致正解率（IU，30 例）．Uncov と Cov はそれぞれ uncovered 条件と covered 条件の完全一致正解率，Δ_{cov} はクエリ単位の差，p_{Holm} は 27 比較に対する Holm 補正後の置換検定の p 値を表す．

Table A·1 Split-level covered and uncovered exact-match accuracy for the coverage comparison in Figure 2.

データ	モデル	分割	Uncov	Cov	Δ_{cov}	95% CI	p_{Holm}
TRAM	1B	1	0.015	0.173	+0.158	[0.132, 0.184]	0.0027
	1B	2	0.009	0.140	+0.131	[0.108, 0.154]	0.0027
	1B	3	0.009	0.160	+0.152	[0.126, 0.177]	0.0027
	3B	1	0.032	0.285	+0.253	[0.223, 0.284]	0.0027
	3B	2	0.038	0.268	+0.230	[0.201, 0.261]	0.0027
	3B	3	0.038	0.253	+0.215	[0.186, 0.245]	0.0027
	8B	1	0.153	0.426	+0.273	[0.240, 0.307]	0.0027
	8B	2	0.168	0.431	+0.263	[0.230, 0.297]	0.0027
	8B	3	0.158	0.414	+0.256	[0.223, 0.289]	0.0027
AnnoCTR	1B	1	0.068	0.223	+0.154	[0.116, 0.196]	0.0027
	1B	2	0.089	0.202	+0.113	[0.077, 0.151]	0.0027
	1B	3	0.083	0.217	+0.134	[0.095, 0.175]	0.0027
	3B	1	0.101	0.362	+0.261	[0.214, 0.309]	0.0027
	3B	2	0.110	0.395	+0.285	[0.234, 0.335]	0.0027
	3B	3	0.122	0.356	+0.234	[0.187, 0.282]	0.0027
	8B	1	0.157	0.433	+0.276	[0.228, 0.326]	0.0027
	8B	2	0.172	0.418	+0.246	[0.196, 0.297]	0.0027
	8B	3	0.172	0.392	+0.220	[0.172, 0.267]	0.0027
CTI-HAL	1B	1	0.024	0.148	+0.124	[0.076, 0.176]	0.0027
	1B	2	0.029	0.176	+0.148	[0.095, 0.205]	0.0027
	1B	3	0.014	0.176	+0.162	[0.110, 0.219]	0.0027
	3B	1	0.038	0.248	+0.210	[0.152, 0.267]	0.0027
	3B	2	0.033	0.276	+0.243	[0.186, 0.305]	0.0027
	3B	3	0.038	0.233	+0.195	[0.138, 0.257]	0.0027
	8B	1	0.133	0.405	+0.271	[0.214, 0.333]	0.0027
	8B	2	0.148	0.443	+0.295	[0.229, 0.362]	0.0027
	8B	3	0.152	0.414	+0.262	[0.200, 0.329]	0.0027

© 2026 Information Processing Society of Japan

(a) システム指示（全条件共通）

```
You are a cybersecurity expert specialized in MITRE ATT&CK framework. Your task is to classify a
given CTI (Cyber Threat Intelligence) text into the most appropriate MITRE ATT&CK technique. You MUST
respond with ONLY the technique ID (e.g., T1059). Do NOT output any explanation, just the ID.
```

(b) 通常の事例一様抽出条件（30 例をクエリごとに独立サンプリング）

```
## Examples
Text: The actor used PowerShell to execute commands on the host. / technique: T1059
Text: The malware collected files from the victim's system. / technique: T1560
... 28 additional demonstrations sampled for this query ...
## Query
Text: The actor used a script interpreter to execute a payload. / technique:
```

(c) ラベル網羅性統制条件（管理情報はモデルに提示しない）

covered：正解 `Technique T1059` を持つデモを少なくとも 1 例含める
uncovered：正解 `Technique T1059` を持つデモを除外する
両条件で提示するプロンプト形式は (b) と同一で，サンプリング方法だけが異なる

図 A·1 実験で用いたプロンプト形式．(a) システム指示，(b) 通常の事例一様抽出条件のプロンプト例，(c) covered/uncovered 条件のデモ選択方法．正解ラベルの有無はサンプリング時に操作し，プロンプトには明示しない．

Fig. A·1 Prompt formats used in the experiments: (a) the system instruction shared by all conditions, (b) an illustrative unconstrained instance-uniform prompt, and (c) the covered/uncovered demonstration-selection control, which alters only the sampling and keeps the prompt format identical to (b).

© 2026 Information Processing Society of Japan

表 A·2 類似度と長さを揃えた対応比較（3 通りの層化分割における平均）

Table A·2 Paired comparison with matched semantic similarity and length: 29 demonstrations are held fixed and only the last is swapped between a covered example and an uncovered control from the same Tactic. Covered exact-match accuracy exceeds uncovered in all nine cells.

データ	モデル	covered	uncovered	差
TRAM	1B	0.134	0.011	+0.123
	3B	0.256	0.033	+0.223
	8B	0.417	0.140	+0.277
AnnoCTR	1B	0.157	0.069	+0.088
	3B	0.295	0.107	+0.188
	8B	0.366	0.169	+0.197
CTI-HAL	1B	0.119	0.019	+0.100
	3B	0.222	0.041	+0.181
	8B	0.356	0.143	+0.213

表 A·3 ラベル頻度介入の結果（3 データセット・3 通りの層化分割の対象クエリを集計）．gold は正解 Technique，wrong は不正解 Technique を対象ラベルとして反復した条件を表す．対象不正解ラベル予測率は，クエリごとに選んだ不正解 Technique をモデルが出力した割合である．

Table A·3 Results of the label-frequency intervention on the 8B model (k is the number of demonstrations carrying the target label; the other demonstrations are neutral). "gold" repeats the gold Technique and "wrong" repeats an incorrect one; the last column is the rate at which the model outputs the per-query target incorrect Technique.

条件	Acc	対象不正解ラベル予測率
$k = 0$（control）	0.183	0.038
gold $k = 1$	0.358	0.029
gold $k = 2$	0.511	0.020
gold $k = 4$	0.682	0.010
wrong $k = 1$	0.173	0.078
wrong $k = 2$	0.169	0.121
wrong $k = 4$	0.148	0.207

表 A·4 8B の IU・同一デモ数条件で頻出した方向付き混同．混同は 3 つの分割における誤り回数／正解 Technique の出現数（割合）を表す．

Table A·4 Frequent directional confusions under the matched-budget 8B IU setting. The last column is the number of times the gold Technique was confused for the predicted one over its total occurrences across three splits (rate).

データ	正解 → 予測	Tactic	混同
TRAM	T1082 System Information Discovery → T1016 System Network Configuration Discovery	内	26/93 (28.0%)
TRAM	T1140 Deobfuscate/Decode Files or Information → T1027 Obfuscated Files or Information	内	26/54 (48.1%)
TRAM	T1598 Phishing for Information → T1204 User Execution	外	19/45 (42.2%)
AnnoCTR	T1105 Ingress Tool Transfer → T1059 Command and Scripting Interpreter	外	24/54 (44.4%)
CTI-HAL	T1082 System Information Discovery → T1016 System Network Configuration Discovery	内	6/12 (50.0%)
CTI-HAL	T1566 Phishing → T1204 User Execution	外	12/45 (26.7%)

© 2026 Information Processing Society of Japan