vwhois: WHOIS の魔境に挑む 全 TLD に対応した実用的な WHOIS パーサー

羽田 大樹[1,a)]

概要：WHOIS は様々なセキュリティ業務において重要な情報源であり，後継の RDAP が登場した現在も広く利用されている．一方 WHOIS 応答は人間が読むことを想定しており，多様で際限ない書式が存在するため，闇・沼・魔境と称されるほど機械処理は困難を極めていた．2000 年以前から現在まで開発されてきた様々なパーサーはいずれも ad hoc な実装であり，大きな制約のもとで利用されていた．本研究では，WHOIS サーバを持つ 873 TLD すべてから最大 200 個ずつ収集した 70,524 件の WHOIS 応答を体系的に分析し，TLD ごとに 8 つの構造パターンに分類できることを示す．さらに，この分類に基づいて LLM 支援により開発した実用的なパーサー vwhois を提案する．vwhois は WHOIS 応答を返すすべての TLD を網羅し，登録情報をくまなく抽出して統一スキーマに格納する．556 TLD・185,824 行を対象に 9 種の既存パーサーと出力を比較し，vwhois を 100% としたときの抽出率が 14.3%〜87.7% にとどまること，いずれの実装も独自書式の TLD の多くに対応できていないことを示す．

vwhois: Taming the WHOIS Wilderness — A Practical Parser Covering Every TLD

Hiroki Hada[1,a)]

Abstract: WHOIS is an important source for a range of security operations, and remains widely used even after the introduction of its successor, RDAP. However, WHOIS responses are designed to be read by humans, and endlessly varied formats exist, so much so that WHOIS is described as a swamp or a labyrinth, and machine processing has been extremely difficult. The parsers written since before 2000 are all ad hoc and have only been usable under severe restrictions. In this work we analyze 70,524 WHOIS responses, collected up to 200 from each of the 873 TLDs that operate a WHOIS server, and show that they fall into eight structural patterns per TLD. Based on this classification we present vwhois, a practical parser developed with LLM assistance. It covers every TLD that answers WHOIS, and extracts registration data exhaustively into a unified schema. We compare the output of nine existing parsers over 556 TLDs and 185,824 lines, and show that they extract only 14.3%–87.7% of the lines vwhois extracts, and that none of them covers many of the TLDs with registry-specific formats.

1. はじめに

WHOIS は最も古いインターネットサービスのひとつである．ドメイン名の登録者・登録日・有効期限・レジストラ・ネームサーバといった登録情報を問い合わせる．セキュリティログ分析，OSINT 調査，フィッシング調査，デジタルフォレンジック，アタックサーフェス探索，Abuse 報告といった場面で，SOC・CSIRT・レッドチームなどの実務者が日常的に参照している．また，法的紛争，ブランド保護，インターネット観測など，セキュリティ以外の分野でも広く使われている．

これらの用途では，得られた WHOIS 情報を機械的にデータベースへ格納し，横断的に検索・集計したいという要求が生じる．ところが WHOIS 応答は人間が直接読むことを前提としており，機械処理を想定していない．キー名，区切り文字，レコードの記述方法は TLD ごとに多種

[1] NTT セキュリティ・ジャパン株式会社
NTT Security (Japan) K.K.
[a)] hiroki.hada@security.ntt

© 2026 Information Processing Society of Japan

This paper is work in progress and not peer-reviewed.

多様である．**図 1** に同一の組織が保有する 5 つのドメインに対する応答を示す．いずれも同じ種類の情報を含んでいるが，共通する構造はほとんどない．

こうした状況は実務者の間で長く問題として認識されてきた．国内では 2024 年の Internet Week における講演で「whois は，詳しく話すと沼です」と述べており [11]，国外の技術者コミュニティでも 2025 年に「WHOIS との連携は悪夢だ」といった発言がある [12]．

この問題に対して，2000 年以前から現在に至るまで多数のパーサーが開発されてきた．しかしそのいずれも対症療法的であり，適用できる状況は非常に限定的であった．古典的な実装は膨大な正規表現の集合によるマッチングを行うため，想定外の書式に対する誤判定が多発する．たとえば pogzyb/asyncwhois[15] は，`.dubai` ドメインの WHOIS 応答の利用規約文中にある `no match was found` という語句を「該当なし」の合図として拾ってしまい，登録情報が存在するにもかかわらず `NotFoundError` を返す．商用サービスにはパース済みの結果を返すものがあるが，判定ロジックは公開されないためオープンな議論ができない．

本研究では，混沌とした WHOIS 応答を分析して体系的に整理し，この結果に基づいて実装した網羅的かつ実用的なパーサー vwhois を提案する．本論文の貢献は以下の 4 点である．

(1) WHOIS サーバを持つ 873 TLD すべてを対象に WHOIS 応答を分析し，8 つのパターン（共通書式 2 種，独自書式 3 種，独自プロトコル 1 種，取得不可 2 種）に分類できることを示した（5.2 節）．
(2) この分類に基づき，応答が得られた全 TLD を対象として，応答に含まれる登録情報をくまなくパースして統一スキーマへ格納する vwhois を，LLM を用いて実装して公開した（5 節）．このパース処理は LLM を含まず，決定的に出力が得られる．
(3) 生データと構造化したデータを対応づけて可視化して評価することで，TLD 単位で登録情報をほぼ網羅していることを確認した．さらに，9 種の既存パーサーの出力を可視化して比較し，TLD とフィールド両方の網羅性において優位であることを示した（6 節）．これらの評価結果はプライバシーや利用規約に配慮して情報を伏せたレポートとして公開し，第三者が検証できる形にした（付録 A.1 節）．
(4) WHOIS データのパース作業に関わる開発者に向けてのナレッジとして，開発過程で遭遇した WHOIS 書式のエッジケースを文書化した（7 節，付録）．

2. 背景

2.1 用語

本論文では以下の用語を用いる．**TLD**（Top Level Domain）はドメイン名階層の最上位ラベルである．TLD は，`.com` のような generic TLD（**gTLD**），`.jp` のような country-code TLD（**ccTLD**），`.edu` や `.museum` のような sponsored TLD などに分類される．**レジストリ**は各 TLD の登録データベースを運用する組織であり，**レジストラ**は登録者との窓口となる事業者である．**キー**は応答の中でレジストリが値の前に印字する見出し，**フィールド**は抽出した値を格納する統一スキーマ上の名前である．

2.2 WHOIS プロトコル

WHOIS は TCP の 43 番ポートを用いる平文プロトコルである．1 往復の request/reply のみで構成され，クライアントは問い合わせ文字列を 1 行送信し，サーバは任意長のテキストを返して接続を閉じる．要求・応答はいずれも自由記述のテキストであり，プロトコル仕様は文字符号化すら規定していない．応答が別サーバを指す場合には，クライアントがその指示に従って再度問い合わせる（リダイレクト）．

2.3 書式が統一されなかった経緯

WHOIS の書式が統一されないまま今日に至った経緯を探る．RFC 812（1982）[1] と RFC 954（1985）[2] は，応答が機械処理を意図したものではなく，人間へ直接渡すためのものであると明記している．2003 年の ICANN SSAC 勧告 SAC003[3] は，スパム目的の情報収集への対策としてレジストラが意図的にランダムな書式を用い始めたことを指摘し，共通書式の必要性を勧告した．RFC 3912（2004）[4] は WHOIS を human-readable なテキストプロトコルとして再記述したが，同時に，本文書は近代的プロトコルとしての欠点を是正するものではないと明記している．

学術研究では，Liu ら [5] が，手書きの規則やテンプレートに依存する方式は網羅性と書式変更への追随の両面で限界を持つと指摘し，gTLD に対する統計的パーサーを提案した．Lauinger ら [6] は，書式や意味の曖昧さが研究結果自体をバイアスさせることを示している．

2.4 RDAP への移行と WHOIS の残存

WHOIS の後継として，JSON を返す RDAP が策定されている．ICANN は 2025 年 1 月に gTLD の RDAP 移行を宣言し，gTLD における WHOIS の提供義務は同月 28 日に終了した [8]．しかし，これは RDAP が WHOIS を置き換えたことを意味しない．理由は 3 つある．

第一に，WHOIS は現在も利用されていることが報告されている．IETF[9] によれば，2025 年 8 月時点の問い合わせ数は WHOIS が月約 490 億件，RDAP が月約 650 億件であり，WHOIS が全体の約 43% を占める．

第二に，網羅性に差がある．RDAP を提供する ccTLD は約 60% にとどまる [9]．本研究のデータセットでも，

© 2026 Information Processing Society of Japan

```
Domain Name: google.com
Registry Domain ID: 2138514_DOMAIN_COM-VRSN
Registrar WHOIS Server: whois.markmonitor.com
Registrar URL: http://www.markmonitor.com
Updated Date: 2024-08-02T02:17:33+0000
Creation Date: 1997-09-15T07:00:00+0000
Registrar Registration Expiration Date: 2028-09-13T07:00:00+0000
Registrar: MarkMonitor, Inc.
Registrar IANA ID: 292
...
Registrant Organization: Google LLC
Registrant Country: US
```

```
Domain:             google.it
Status:             ok
Signed:             no
Created:            1999-12-10 00:00:00
Last Update:        2026-06-09 23:13:34
Expire Date:        2027-04-21

Registrant
  Organization:     Google Ireland Holdings Unlimited Company
  Address:          70 Sir John Rogerson's Quay
                    Dublin
                    2
                    Dublin
                    IE
  Created:          2018-03-02 19:04:02
  Last Update:      2018-03-02 19:04:02

Admin Contact
  Name:             XXXXXX
  Organization:     Google LLC
  ...
```

```
domain:      google.com.br
owner:       Google Brasil Internet Ltda
owner-c:     DOADM17
tech-c:      DOADM17
nserver:     ns1.google.com
nsstat:      20260815 AA
nslastaa:    20260815
nserver:     ns2.google.com
nsstat:      20260815 AA
nslastaa:    20260815
nserver:     ns3.google.com
nsstat:      20260815 AA
nslastaa:    20260815
nserver:     ns4.google.com
nsstat:      20260815 AA
nslastaa:    20260815
created:     19990518 #162310
changed:     20260421
expires:     20270518
status:      published

nic-hdl-br:  DOADM17
person:      Domain Admin
created:     20100520
changed:     20220228
```

```
domain:         GOOGLE.RU
nserver:        ns1.google.com.
nserver:        ns2.google.com.
nserver:        ns3.google.com.
nserver:        ns4.google.com.
state:          REGISTERED, DELEGATED, VERIFIED
org:
taxpayer-id:
registrar:      RU-CENTER-RU
admin-contact: https://www.nic.ru/whois
created:        2004-03-03T21:00:00Z
paid-till:      2027-03-04T21:00:00Z
free-date:      2027-04-05
source:         TCI
```

```
Domain Information:
a. [Domain Name]                GOOGLE.CO.JP
g. [Organization]               Google Japan G.K.
l. [Organization Type]          GK
m. [Administrative Contact]     YN47525JP
n. [Technical Contact]          SH36113JP
p. [Name Server]                ns1.google.com
p. [Name Server]                ns2.google.com
p. [Name Server]                ns3.google.com
p. [Name Server]                ns4.google.com
s. [Signing Key]
[State]                         Connected (2027/03/31)
[Lock Status]                   AgentChangeLocked
[Registered Date]               2001/03/22
[Connected Date]                2001/03/22
[Last Update]                   2026/04/01 01:02:00 (JST)
```

図 1　.com，.br，.ru，.it，.jp の WHOIS 応答（抜粋）
Fig. 1　WHOIS responses for .com, .br, .ru, .it, and .jp (excerpted).

IANA が WHOIS サーバを掲載する 873 TLD のうち 166 TLD は RDAP サーバを持たない．これらの TLD では WHOIS が唯一の取得手段である．

第三に，同じドメインでも両者の内容が一致しない．Fernandez ら [7] は WHOIS と RDAP が交換可能であるという前提を否定し，RDAP 内部での配置差や型違反に加えて，7.6% のドメインで両プロトコル間に少なくとも 1 件の不整合があることを報告している．実際に，google.pm では WHOIS 応答に含まれる登録担当者のメールアドレス dns-admin@google.com が RDAP 応答には現れない．担当者の連絡先や国情報はセキュリティ調査において重要度が高く，これが欠落することは調査能力の低下に直結する．

したがって，ドメイン調査では利用できる情報をすべて利用すべきであり，両プロトコルに対応した TLD であっても双方を取得する必要がある．本研究はそのうち WHOIS 側に焦点を当てる．

3. 既存パーサー

表 1 に，調査した既存の WHOIS パーサーと，そのうち評価対象としたものを示す．上段の 9 件はいずれも継続的に保守されている実装であり，これらを評価対象とした．

下段の 6 件は次の理由で除外した．DannyCork/python-whois[22] は開発が終了し mboot-github/WhoisDomain への移行が案内されている．joepie91/python-whois[23]，phpWhois/phpWhois[24]，Net::Whois[25] は最終更新が 2015 年以前であり歴史的実装である．deft-whois[26] はソースコードが公開されておらず，入手には著者への連絡を要する．Liu ら [5] の実装は学術研究の成果物であり，その後の報告はない．なお，これらの古い実装の中には現在も検索エンジンで現れるものがあるため注意を要する．

商用サービスとしては DomainTools，WhoisXML API，Whoxy，WhoisJSON，WhoisFreaks などがパース済みデータを提供している．しかしいずれも判定ロジックが非公開であり，利用者が自らパースを行うことはできない．

本研究ではパース機能のみをスコープとする．実行方法（CLI，ライブラリ，API）や開発言語，生データを保持するか否か，WHOIS クライアントとパーサーが一体か分離かといった使い勝手に関わる差異は比較の対象としない．

4. データセット

本研究で使用するデータセットについて説明する．2026 年 3 月 21 日から 8 月 15 日にかけて WHOIS 応答を収集した結果を **表 2** に示す．データセットは次の 3 つからなる．

(1) TLD メタデータ　IANA Root Zone Database[10] から，全 1,595 TLD の種別，WHOIS サーバ，RDAP サーバを抽出した．このうち WHOIS サーバを持つのは 873 TLD であった．

(2) ドメイン　各 TLD について，実在する登録ドメインを最大 200 個ずつ収集し，合計 123,920 個を得た．内訳は CommonCrawl（108,063 個），Cisco Umbrella Top 1M（13,976 個），Certificate Transparency（1,811

© 2026 Information Processing Society of Japan

表 1　既存の WHOIS パーサーと評価対象
Table 1　Existing WHOIS parsers and those evaluated.

リポジトリ	言語	最終更新	評価
richardpenman/whois[13]	Python	2026-07-12	○
mboot-github/WhoisDomain[14]	Python	2026-07-19	○
pogzyb/asyncwhois[15]	Python	2026-07-15	○
ninoseki/whois-parser[16]	Python	2023-07-30	○
weppos/whois-parser[17]	Ruby	2022-09-08	○
simplebytes-com/whois-parser[18]	JavaScript	2026-07-12	○
likexian/whois-parser[19]	Go	2026-01-04	○
io-developer/php-whois[20]	PHP	2023-01-25	○
prowebcraft/whois-parser[21]	PHP	2024-01-20	○
DannyCork/python-whois[22]	Python	2023-12-21	—
joepie91/python-whois[23]	Python	2014-07-30	—
phpWhois/phpWhois[24]	PHP	2015-07-11	—
Net::Whois[25]	Perl	1999-12-05	—
deft-whois[26]	Perl	2014	—
Liu ら [5]	—	2015	—

表 2　データセットの内訳
Table 2　Breakdown of the dataset.

項目	数
IANA 登録の全 TLD	1,595
WHOIS サーバを持つ TLD	873
WHOIS 応答が得られた TLD	855
登録情報を含む応答が得られた TLD	799
RDAP サーバを持たない TLD	166
収集ドメイン	123,920
WHOIS 応答が得られたドメイン	70,524

個），30 語の辞書によりホスト名の存在を確認したもの（70 個）である．登録数の少ない TLD では上限に達しない．

(3) WHOIS 情報　(2) の各ドメインに対して WHOIS を問い合わせ，855 TLD について合計 70,524 件の応答を得た．リダイレクトが発生した場合はすべてのチェーンを保存している．

873 TLD のうち 18 TLD からは応答が得られなかった．内訳として，17 TLD は WHOIS サーバが存在するもののサービスへ到達できず，1 TLD は実在するドメインが 1 つも見つからず問い合わせ自体が行えなかった（`xn--mgbx4cd0ab`）．

なお WHOIS 応答には登録者の個人情報が含まれうるうえ，多くのレジストリが再配布を禁じているため，収集した生応答および解析済みデータセットは公開しない．ただし評価に用いたパース結果は，値を伏せたレポートとして公開している（付録 A.1 節）．

5. 提案方式

5.1 設計方針

提案方式は以下の 3 点を満たすことを目標とする．

(R1)　WHOIS を提供するすべての TLD を対象とする．

(R2)　応答に含まれる登録情報をすべて抽出する．また，情報が伏せられていることを示す `REDACTED FOR PRIVACY` のようなレコードも，「レジストリが伏せた」という事実を表す情報として保持する．これはユーザーがオプションで破棄することができる．

(R3)　すべての TLD で統一のスキーマを定義する．

本論文のスコープ外だが，vwhois はオプションとして，日付や国名など一部の値の表記を統一する機能を備える．タイムゾーンが推測できないなどの制約があり，ベストエフォートの実装である．また，WHOIS サーバを持たない TLD に対しては RDAP へフォールバックし，同じ結果形式へ正規化する．

5.2 TLD 応答の 8 パターン分類

収集した WHOIS 応答の書式を分析し，TLD ごとに **表 3** の 8 つのパターンに分類した．

パターン 1〜3 はいずれも「1 行 1 レコード」の key/value 形式であり，違いは語彙のみである．パターン 1 は原則 gTLD 共通語彙のみで過不足なく解釈できる分類で，図 1 の `.com` に相当する．パターン 2 は gTLD 以外で gTLD 形式を模倣した書式であり，独自のキー名を含む．パターン 3 は 1 行 1 レコードでありつつも完全に独自の書式であり，図 1 の `.ru` に相当する．これらは形式的には正規表現や独自パーサーで包含できるが，抽出とテストを機械的に扱うことができ，かつ全体の 82%（715/873）を占める．ここを明確に切り出すことで，文脈を読んで解釈する必要がある応答がパターン 4〜6 の 84 TLD に限定され，全体の見通しが良くなる．

パターン 4 は応答がセクションや表として構成され，行単位の分割では対応できないものを表し，図 1 の `.it` に相当する．パターン 5 はコンタクトや nsset といったオブジェクト参照の解決が必要で，文脈に依存して内容が変わるものであり，図 1 の `.br` では `owner-c` が指すハンドル `DOADM17` の実体が同じ応答の末尾に現れる．パターン 6 では，応答に担当者情報のハンドルが含まれるが，ハンドルに紐づく具体的な登録情報は追加の WHOIS 問い合わせを行わなければ得られない．これは `.jp` のみが該当する．同図の `.jp` では連絡先が `YN47525JP` などのハンドルとしてのみ現れており，実体は別の問い合わせをしないと得られない．

パターン 7 と 8 は取得不可を示す．パターン 7 は WHOIS の問い合わせに対して何かしらの応答を返すが，それが Web フォームへの誘導，アクセス拒否通知，利用規約のみといった登録情報を含まない内容であるものを指す．パターン 8 は接続がタイムアウトまたはリセットされ，何も応答がないものである．

この分類と TLD 種別の関連を **表 4** に示す．種別は IANA が付与する値である．パターン 1 の 571 TLD はすべて gTLD もしくは grTLD（generic-restricted）であ

© 2026 Information Processing Society of Japan

表 3　TLD 応答の 8 パターン分類
Table 3　Eight structural patterns of WHOIS responses.

#	応答の構造	抽出方式	TLD
1	共通 gTLD 語彙	行分割	571
2	gTLD 型＋独自キー	行分割	110
3	行形式＋ TLD 固有語彙	行分割	34
4	複数行のセクション	正規表現	42
5	参照解決を要する	専用パーサー	41
6	追加問い合わせを要する	専用パーサー＋再帰	1
7	応答はあるが登録情報なし	—	57
8	応答が返らない	—	17
合計			873

表 4　TLD 種別とパターンの対応
Table 4　TLD types against patterns.

type	1	2	3	4	5	6	7	8	計
generic	569	—	—	—	—	—	48	6	623
country-code	—	101	34	41	39	1	9	11	236
sponsored	—	9	—	1	1	—	—	—	11
generic-restricted	2	—	—	—	—	—	—	—	2
infrastructure	—	—	—	—	1	—	—	—	1
計	571	110	34	42	41	1	57	17	873

り，パターン 2 の 110 TLD はすべて ccTLD もしくは sponsored TLD である．パターン 1 とパターン 2 の間に書式上の明確な境界はないが，一貫性のある gTLD に対して ccTLD は独自の揺らぎが観測されやすいため，便宜上分類している．文脈の解釈を要するパターン 3〜6 の 118 TLD は，`.edu`（パターン 4），`.arpa` と `.int`（パターン 5）を除く 115 TLD すべてが ccTLD である．gTLD は書式が事実上統一されている一方，ccTLD は各国レジストリが独自に書式を決めており，パース処理を実装する負担は ccTLD 側に集中している．既存パーサーの多くが gTLD で十分に動作しながら ccTLD で失敗するのは，この構造に起因している．

5.3　統一スキーマ

抽出した値は 2 つのクラスに格納する．共通的なフィールドは `WhoisData`（221 フィールド），希少なフィールドは `WhoisDataExt`（122 フィールド）が保持する．`WhoisData` はドメイン，ネームサーバ，IDN，DNSSEC，レジストリ，レジストラ，登録者，管理担当，請求担当，技術担当，ゾーン担当，リセラーといった役割ごとの群からなり，同じ意味の情報は TLD をまたいで同一のキーに集約する．

`WhoisDataExt` は，他の TLD には現れない特殊なフィールドや用途が判然としないフィールドを格納する．たとえば JPRS が組織名の読みをカナで併記するフィールドや，DNSSEC 関連の用途不明の小整数などがある．利用者が両クラスの区別を意識する必要はないが，「これは一般的なフィールドではない」ことを型の上で明示するために分離している．

すべてのフィールドは文字列のリストである．同じキーが複数回現れる応答（複数の `Name Server` など）を，欠落なく表現するためである．

5.4　取得しない情報

利用規約や注意書き（`TERMS OF USE`，`NOTICE` など）といった，ドメインによらず同一の固定文は取得しない．また，問い合わせを実行した時刻は WHOIS 情報ではないため取得しない．一方，固定文の中に `key:  value` の形をした行が現れることがあり（付録 A.2.4），これは構文だけでは登録情報と区別できない．固定文の判定は TLD ごとに行っている．

5.5　開発方法

vwhois の開発には LLM を用いた．2026 年 3〜4 月は Codex，同年 6〜8 月は Claude Code を使用している．ただし**パース処理そのものに LLM は用いない**．実行時の推論を伴わないため，結果は決定的であり，オフラインで動作し，追加のコストも発生しない．LLM は開発時にのみ，モジュールの生成とレビューに使われる．

なおツール開発を一から再現することは本論文のスコープ外とし，プロンプトなどの詳細は割愛する．開発は以下の手順で進めた．

(1) 最初に gTLD を基準にスキーマの初期状態を作成する．
(2) LLM により各 TLD モジュールのドラフトを生成する．その際に，各 TLD の応答を現状のスキーマに照らし，既存フィールドに収まらない場合に新規フィールドを追加する．
(3) データセットに対して作成した TLD モジュールを用いてパースし，その結果をスクリプトで可視化して LLM と目視でレビューする．
(4) パース漏れとして表示された行について，比較スクリプト側の判定誤りか，パーサー側の抽出漏れかを LLM と目視の両方で分析し，該当箇所の修正を指示する．このサイクルを，パース漏れが 0 になるまで繰り返す．

5.6　ツールの構成

公開するモジュールは，パーサー本体，スキーマ定義，873 TLD の個別モジュール，および IANA から取得した TLD 別 WHOIS サーバの一覧（JSON）である．データセット収集，テスト，網羅性評価レポート生成，既存パーサー比較評価レポート生成，開発用ハーネスといった開発用モジュールは公開しない．TLD 別モジュールは WHOIS の書式に含まれるキーをソースコード上に列挙しているため，vwhois を採用しない実装にとっても書式の参照資料になる．

© 2026 Information Processing Society of Japan

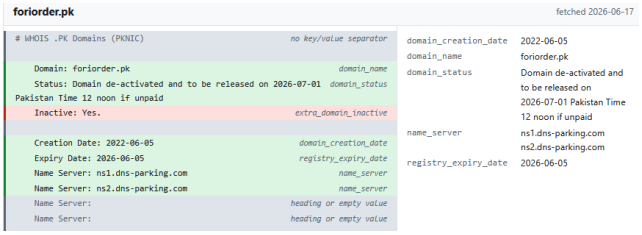


図 2　パース結果レビュー画面（開発時の様子）

Fig. 2　The parse review screen, as used during development.

6. 評価

6.1 抽出の網羅性の確認

本節では，5.5 節 (3) における可視化によるレビュー方法の詳細を説明し，抽出の網羅性について一定の評価がなされていることを示す．

収集したすべての TLD の WHOIS 応答をパースし，スクリプトを用いて自動でパース前後の照合を行い，さらに**図 2** に示すページを生成した．各行は，パース済み，取得対象でない固定文，パース漏れ，判定不能の 4 状態に色分けされる．自由記述の文章をパース前後で完全に自動照合することは困難であるため，判定は意図的にパース漏れ側へ寄せた．すなわち，確信が持てない行はすべて赤（パース漏れ）として提示し，人間が明示的に解消する設計とした．

この照合結果についてレビューと修正を繰り返した結果，最終的に未抽出行は 0 となった．すなわち，収集した 70,524 件の応答に含まれる登録情報のうち，どのフィールドにも到達しなかったものは残っていない．データセットに対して十分なパース処理ができていると判断した．最終的な結果は **表 5** のとおりであり，各パターンに対する未抽出行は 0 件となった．

今回用意したデータセットに対してすべての登録情報が何らかのフィールドに格納されていることを確認した．ただし，同じ TLD でも未知のドメインでは特殊なキーが現れる可能性があり，すべてを網羅していることは保証できない．また，この結果は LLM と目視によるレビューの積み重ねであり，評価の精度自体を保証するものではない．

表 5　パターン別のパース結果（定義は付録 A.1 節）

Table 5　Parse results by pattern.

パターン	TLD	評価対象の応答	抽出行	未抽出行
1	571	18,476	618,465	0
2	110	7,216	229,328	0
3	34	3,473	40,728	0
4	42	4,417	68,592	0
5	41	3,599	114,312	0
6	1	145	1,886	0
7	57	100	0	0
計	856	37,426	1,073,311	0

6.2 既存パーサーとの比較

同一の WHOIS 応答に対し，vwhois と 表 1 の 9 種を実行し，抽出できた key/value の行数を比較した．vwhois の出力行数を基準値の 100% とし，各ツールの出力行の割合を測定する．WHOIS 応答があった 855 TLD のうち，サンプルが 10 件未満のものなど 299 TLD を除外し，556 TLD，185,824 行を評価対象とした．除外した TLD は `.aaa`，`.aarp`，`.abc` などのブランド gTLD が中心である．

表 6 に結果を示す．全体では，最も高い likexian/whois-parser でも 87.7%，中央値は 53.6% にとどまる．パターン別に見ると，gTLD 共通形式であるパターン 1 では最良 93.6%・中央値 58.1% であるのに対し，独自パーサーを要するパターン 5 では最良 60.1%・中央値 28.0% まで低下する．すなわち既存パーサーの取りこぼしは，まさに ccTLD の独自形式に集中している．

また，非対応の TLD を評価した結果を **表 7** に示す．ここでは抽出行数が 25% 未満の TLD をパターン別に計測した．likexian/whois-parser はパターン 1 で 0.6% だが，パターン 4 では 12.2% に上がる．pogzyb/asyncwhois は 6.0% から 58.5% へ 10 倍近く跳ねる．**平均が下がる**のではなく，**特定の TLD がまとめて使えなくなる**というのが実態であり，実務では後者の方が問題になる．

この数値をそのままパーサーの優劣とみなすことはできない．既存パーサーは必ずしも網羅を目的としておらず，必要最小限の情報を確実に取得するという設計方針をとっている可能性がある．その場合，抽出率が低いことはツールの欠陥ではない．また，住所を `city`，`street`，`country` に分解するか 1 行のまま保持するかといったパースの粒度の差も仕様の差でしかないが，行数ベースの指標に影響する．したがって本指標は精緻なものではない．それでも，(1) 抽出率が極端に低い TLD が存在すること，(2) 差が誤差の範囲を大きく超えること，(3) 差がパターンと対応しており構造的に説明がつくことから，vwhois の有効性を示すには十分であると考える．

6.3 評価の制限

パーサーの精度は収集したデータセットに依存する．同じ TLD でも，ドメインによっては未知のキーやイレギュラーな構文が現れうる．TLD あたり最大 200 件という標本は，レジストリの書式を把握するには十分だが，特異な書式を網羅する保証はない．

ある値がどのフィールドに入るべきかは，LLM と人手による判断の結果である．WHOIS のキー名は曖昧で，正解を機械的に算出する手段もない．割り当ての妥当性そのものは本論文のスコープ外とする．

IANA の公開情報から到達できない WHOIS サーバも存在し，これらはデータセットに含まれず対応していない（付録 A.2.8）．

© 2026 Information Processing Society of Japan

表 6　vwhois に対する既存パーサーの抽出率（パターン別）
Table 6　Extracted lines of existing parsers relative to vwhois, by pattern.

pattern	TLD	行数	penman	mboot	asyncwhois	ninoseki	weppos	simplebytes	likexian	io-dev.	prowebcraft
1	335	107,125	64.3%	58.1%	70.5%	47.4%	10.6%	64.3%	93.6%	36.3%	8.5%
2	105	37,960	60.6%	55.1%	68.7%	48.7%	18.1%	58.3%	94.9%	33.9%	27.1%
3	33	7,981	54.4%	53.7%	58.9%	49.0%	26.4%	55.4%	85.4%	34.7%	34.9%
4	41	11,217	38.4%	41.5%	37.9%	25.7%	24.1%	40.4%	61.6%	32.1%	43.2%
5	41	21,208	30.1%	35.0%	24.9%	24.7%	16.6%	31.0%	60.1%	28.0%	21.4%
6	1	333	67.6%	30.3%	43.8%	0.0%	17.4%	23.7%	83.8%	25.5%	58.0%
全体	556	185,824	57.7%	53.6%	62.4%	43.7%	14.3%	57.4%	87.7%	34.5%	17.0%

表 7　抽出率が 25% 未満の TLD の割合
Table 7　Share of TLDs with an extraction rate below 25%.

実装	p1	p2	p3	p4	p5	全体
(TLD 数)	335	105	33	41	41	556
penman	5.7%	1.0%	18.2%	36.6%	56.1%	11.5%
mboot	1.5%	2.9%	18.2%	24.4%	31.7%	6.7%
asyncwhois	6.0%	1.0%	9.1%	36.6%	58.5%	11.3%
ninoseki	9.3%	2.9%	12.1%	51.2%	48.8%	14.4%
weppos	89.9%	71.4%	51.5%	68.3%	65.9%	80.8%
simplebytes	2.1%	3.8%	6.1%	19.5%	19.5%	5.4%
likexian	0.6%	1.0%	3.0%	12.2%	9.8%	2.3%
io-dev.	20.9%	11.4%	24.2%	29.3%	34.1%	20.9%
prowebcraft	93.1%	59.0%	48.5%	34.1%	73.2%	78.1%

7. WHOIS 情報に関して得られた知見

パーサーの評価・修正サイクルの中で遭遇した特殊ケースを報告する．個々は些末に見えるが，「WHOIS を機械処理する」という作業が実際に何を相手にしているかを示す資料であり，同種の実装を行う者にとって事前に知る価値があると考える．本節の実例はすべて付録に示す．

遭遇した事象は大きく 4 群に分けられる．第一に，応答そのものが壊れているものである．`forum.sh` では 404 ページの HTML が 43 番ポートの応答としてそのまま返り（付録 A.2.1），`.tg` では HTML 実体参照と文字化けが同一応答内に混在する（A.2.2）．第二に，キーの名前と内容が一致しないものである．`Registrant Email` に問い合わせフォームの URL が入り（A.2.3），取得対象外の固定文の中に構文上は登録情報と区別できない `key:  value` 行が含まれる（A.2.4）．第三に，登録情報そのものが整合しないものである．`bing.sr` は作成日が `9999-12-31`，有効期限が `2038-01-01` である（A.2.5）．`awa.tg` は移管期間中の 1 回の応答に，旧レジストラと新レジストラの登録が異なる有効期限のまま混在する（A.2.9）．`cars.co.ug` は同一の問い合わせに毎回異なる組織名と住所を返す（A.2.10）．第四に，書式の想定が崩れるものである．統一されているはずのパターン 1 でも，`nova.art` だけが `Art Record - Type of Object` という独自のキーを持ち，`block.makeup` だけが請求担当の接頭辞に `Billing` と `Bill` を混在させる（A.2.6）．また，gTLD 形式に従った ccTLD が 1 レコード 1 行の原則から逸脱し（A.2.7），`.ac.uk` のように IANA の公開情報から到達できない WHOIS サーバが存在する（A.2.8）．

同一 TLD 内のドメイン単位でも書式の揺らぎは存在するが，これは TLD 別にモジュールを検討するという設計のアイデアを覆す反例ではない．新しい揺らぎを発見したとしても，各モジュールの軽微な変更で追随できるレベルである．

8. 考察と今後の課題

8.1 考察

5.2 節で見た gTLD と ccTLD の非対称は，RDAP への移行にも同じ形で現れる．WHOIS サーバを持つ 873 TLD のうち 166 は RDAP サーバを持たず，RDAP を提供する ccTLD は約 60% にとどまる [9]．書式が最も多様な TLD 群は，RDAP への移行が最も遅い TLD 群でもある．WHOIS パーサーの必要性は移行期に限られたものではない．

保守の観点では，追随すべき対象は 84 TLD に限定される．新規 gTLD はパターン 1 の共通語彙でカバーできるため，追加のコストはほとんど生じない．ただし書式は静止していない．`cert.sd` は 6 月に取得した応答では住所が複数行であったが，8 月には 1 行に統合されており，その際に住所の一部と推測される `Tel` 行を巻き込んでいる（付録 A.2.7）．保守コストを決めるのは TLD の数ではなく，この 84 TLD の書式がどの程度の頻度で動くかである．

8.2 手法の制約

パーサーは LLM 支援により開発し，レビューにも LLM を用いたが，開発過程の再現を目的としておらず，再現性については論じていない．本テーマの性質上 ad hoc な調査とならざるを得ず，完全性は保証されない．

8.3 今後の展開

第一に，新規 TLD の登場や RDAP 移行に伴う WHOIS 廃止に対してリアルタイムで追随するため，TLD リストの収集と WHOIS 対応状況の変化の検知，データセットの自動更新と書式変化の検知を実装する．

第二に，WHOIS 対応状況や書式の変化を検知した際に，

© 2026 Information Processing Society of Japan

TLD モジュールの追加・修正，さらにプルリクエストの作成までを自動的に行い，リアルタイムで追随する仕組みを構築する．この自動更新は，LLM を用いた開発部分の再現性を評価する場にもなる．新規 TLD の書式に対するモジュール自動生成の際に，人手の介入量を測ることで，開発手法自体を定量化する狙いもある．

第三に，本研究でスコープ外としたフィールド割り当ての妥当性評価を実施する．正解データの作成方法自体が研究課題となる．

9. まとめ

本研究では，WHOIS サーバを持つ 873 TLD すべてから収集した 70,524 件の応答を分析し，TLD ごとの応答が 8 つの構造パターンに分類できることを示した．この分類に基づき，応答が得られた全 TLD を対象として登録情報をすべて抽出し統一スキーマへ正規化するパーサー vwhois を実装・公開した．9 種の既存パーサーとの比較では，556 TLD・185,824 行の評価対象において，最良の既存パーサーでも vwhois の 87.7%，中央値では 53.6% の情報しか取り出せておらず，その差は ccTLD の独自形式に集中していた．あわせて，開発過程で遭遇した WHOIS データの矛盾やエッジケースを文書化した．

vwhois は ⟨https://github.com/hada2/vwhois⟩ で公開している．

参考文献

[1] Harrenstien, K. and White, V.: NICNAME/WHOIS, RFC 812 (1982).

[2] Harrenstien, K., Stahl, M. and Feinler, E.: NICNAME/WHOIS, RFC 954 (1985).

[3] ICANN Security and Stability Advisory Committee: SAC003: WHOIS Recommendation of the Security and Stability Advisory Committee (2003).

[4] Daigle, L.: WHOIS Protocol Specification, RFC 3912 (2004).

[5] Liu, S., Foster, I., Savage, S., Voelker, G. M. and Saul, L. K.: Who is .com? Learning to Parse WHOIS Records, *Proc. ACM Internet Measurement Conference (IMC)*, pp. 369–380 (2015).

[6] Lauinger, T., Onarlioglu, K., Chaabane, A., Robertson, W. and Kirda, E.: WHOIS Lost in Translation: (Mis)Understanding Domain Name Expiration and Re-Registration, *Proc. ACM Internet Measurement Conference (IMC)*, pp. 247–253 (2016).

[7] Fernandez, S., Hureau, O., Duda, A. and Korczyński, M.: WHOIS Right? An Analysis of WHOIS and RDAP Consistency, *Proc. Passive and Active Measurement (PAM)* (2024).

[8] ICANN: ICANN Update: Launching RDAP, Sunsetting WHOIS (online), ⟨https://www.icann.org/en/announcements/details/icann-update-launching-rdap-sunsetting-whois-27-01-2025-en⟩ (2025).

[9] IETF: The Current State of RDAP (online), ⟨https://www.ietf.org/blog/current-state-of-rdap/⟩ (2026).

[10] IANA: Root Zone Database (online), ⟨https://www.iana.org/domains/root/db⟩ (2026.08.15).

[11] 山下健一：最速低コストなテイクダウンリクエスト送受の最新動向，Internet Week 2024, C11 (online), ⟨https://www.nic.ad.jp/ja/materials/iw/2024/proceedings/c11/c11-yamashita.pdf⟩ (2024).

[12] Hacker News: Integrating with WHOIS is a nightmare (online), ⟨https://news.ycombinator.com/item?id=43384069⟩ (2025).

[13] richardpenman: whois (online), ⟨https://github.com/richardpenman/whois⟩ (2026.07.12).

[14] mboot-github: WhoisDomain (online), ⟨https://github.com/mboot-github/WhoisDomain⟩ (2026.07.19).

[15] pogzyb: asyncwhois (online), ⟨https://github.com/pogzyb/asyncwhois⟩ (2026.07.15).

[16] ninoseki: whois-parser (online), ⟨https://github.com/ninoseki/whois-parser⟩ (2023.07.30).

[17] weppos: whois-parser (online), ⟨https://github.com/weppos/whois-parser⟩ (2022.09.08).

[18] simplebytes-com: whois-parser (online), ⟨https://github.com/simplebytes-com/whois-parser⟩ (2026.07.12).

[19] likexian: whois-parser (online), ⟨https://github.com/likexian/whois-parser⟩ (2026.01.04).

[20] io-developer: php-whois (online), ⟨https://github.com/io-developer/php-whois⟩ (2023.01.25).

[21] prowebcraft: whois-parser (online), ⟨https://github.com/prowebcraft/whois-parser⟩ (2024.01.20).

[22] DannyCork: python-whois (online), ⟨https://github.com/DannyCork/python-whois⟩ (2023.12.21).

[23] joepie91: python-whois (online), ⟨https://github.com/joepie91/python-whois⟩ (2014.07.30).

[24] phpWhois: phpWhois (online), ⟨https://github.com/phpWhois/phpWhois⟩ (2015.07.11).

[25] Net::Whois — Get information about a domain name (online), ⟨https://metacpan.org/pod/Net::Whois⟩ (1999.12.05).

[26] WHOIS Data Extracted From Templates (deft-whois) (online), ⟨http://www.deft-whois.org/⟩ (2026.08.17).

© 2026 Information Processing Society of Japan

研究倫理

本研究の WHOIS 収集は，公開されている WHOIS サーバに対して，公開されている登録情報を問い合わせるものである．収集にあたっては次の配慮を行った．同一 TLD のサーバへの問い合わせには最低 1 秒の間隔を設け，レート制限に起因する失敗を検知した場合は TLD 単位で指数バックオフを適用し，一定回数で当該 TLD への問い合わせを打ち切る．1 TLD あたりの取得は最大 200 ドメインに制限し，網羅的なゾーン取得は行わない．

収集した応答には登録者の氏名・住所・電子メールアドレスなどの個人情報が含まれうる．そのため，生の応答および解析済みデータセットは公開しない．TLD ごとのパース結果は，すべての値を伏せて書式のみを残したレポートとして公開する（付録 A.1 節）．公開するのはパーサー本体，および評価レポートである．本論文中に例示したドメインは事象の説明に必要な範囲に限定しており，さらに登録者の氏名・番地・個人の連絡先は `XXXXXX` に置き換えている．

付　　録

A.1　評価レポートの公開

6 節の評価に用いたレポートを，すべての値を伏せた形で公開している[*1]．公開するのは，データセットの構成，TLD ごとのパース結果，および 9 種の既存パーサーとの比較の 3 つである．

公開する意図は，本評価が原理的に精緻化しきれない点にある．自由記述の応答とパース結果を決定的に対応づけることは難しく，レビューには LLM を併用している（5.5 節）．したがって評価の妥当性は，最終的には我々の判断が正しいという主張に依存する．結果を多くの目に触れる形で提示することで，誤りが指摘され，評価の信頼性が確保されることを期待する．

伏字にする箇所は，大文字を `X`，小文字を `x`，数字を `9` に置き換える．キー名，区切り文字，字下げ，および当該 TLD の応答の 90% 以上に現れて値を持たない行はそのまま残す．構造と判定できなかった範囲は伏せる側に倒すため，未知の書式に対しては情報が失われる方向にのみ誤る．

A.1.1　パース結果の評価

図 A·1 は TLD 別の集計である．応答が得られた TLD ごとに，応答数，観測したキーの種類数，登録情報のレコードと判定した行数，そのうちフィールドへ入った割合，およびどのフィールドにも入らなかった行数を並べる．ここでの応答数は，収集した 70,524 件から，該当ドメインが未登録である旨の応答 33,098 件を除いた 37,426 件である（表 5 も同じ定義による）．未登録であることは書式の性質ではないため，評価から外している．表 5 の TLD 数は分類上の数であり，ドメインが見つからず問い合わせが行えなかった 1 TLD を含むため，4 節の 855 TLD より 1 多い．なお 表 5 のパターン 7 の 100 件は `.es` の応答である．利用条件の告知のみを返すため未登録の判定を免れるが，登録情報は含まないので抽出行は 0 となる．既定では未抽出行の多い順に並ぶため，手を入れるべき TLD が上に来る．6.1 節の「未抽出行 0」は，この列が全 TLD で 0 になるまで順に潰した結果であり，表 5 はこの画面をパターン別に集計したものである．

TLD	PATTERN	RESPONSES	KEYS	RECORD LINES	EXTRACTED	UNEXTRACTED
aaa	pattern1	3	19	66	100.0%	0
aarp	pattern1	4	14	71	100.0%	0
abb	pattern1	30	14	470	100.0%	0
abbott	pattern1	91	14	1615	100.0%	0
abc	pattern1	4	14	73	100.0%	0
abogado	pattern1	51	80	2535	100.0%	0
abudhabi	pattern1	60	46	2595	100.0%	0
ac	pattern2	79	66	3409	100.0%	0
accenture	pattern1	1	14	22	100.0%	0
accountant	pattern1	5	45	210	100.0%	0
ad	pattern2	34	22	648	100.0%	0
adult	pattern1	81	53	3414	100.0%	0
ae	pattern3	136	15	1697	100.0%	0
aeg	pattern1	6	14	108	100.0%	0
aero	pattern2	107	76	5383	100.0%	0

図 A·1　パース結果の TLD 別統計
Fig. A·1　Parse results per TLD.

図 A·2 は個々の応答を開いた画面である．左が応答，右がそこから得られたフィールドの一覧であり，左の各行は 3 色に分かれる．緑は値がフィールドへ入った行，赤はレコードに見えるがどのフィールドにも入っていない行，灰はレコードではない行（空行，見出し，および当該 TLD の応答のほぼすべてに現れる定型文）である．赤を 0 にする作業が 6.1 節のレビューであり，本文の 図 2 はその作業中の画面である．ここで公開しているのは作業を終えた後の状態で，値はすべて伏せてある．

A.1.2　既存パーサーとの比較

図 A·3 は TLD 別の比較である．採点対象とした行数と，vwhois を 100% としたときの各パーサーの抽出率を並べる．表 6 はこれをパターン別に集計した値であり，この画面では同じ数値を TLD 単位で確認できる．

図 A·4 はキー別の内訳である．ある TLD に現れるキーごとに，そのキーが何行あり，各パーサーがそれを拾えているかを示す．行数比は「全体で何割取れたか」しか表さ

[*1] https://hada2.github.io/vwhois/

© 2026 Information Processing Society of Japan

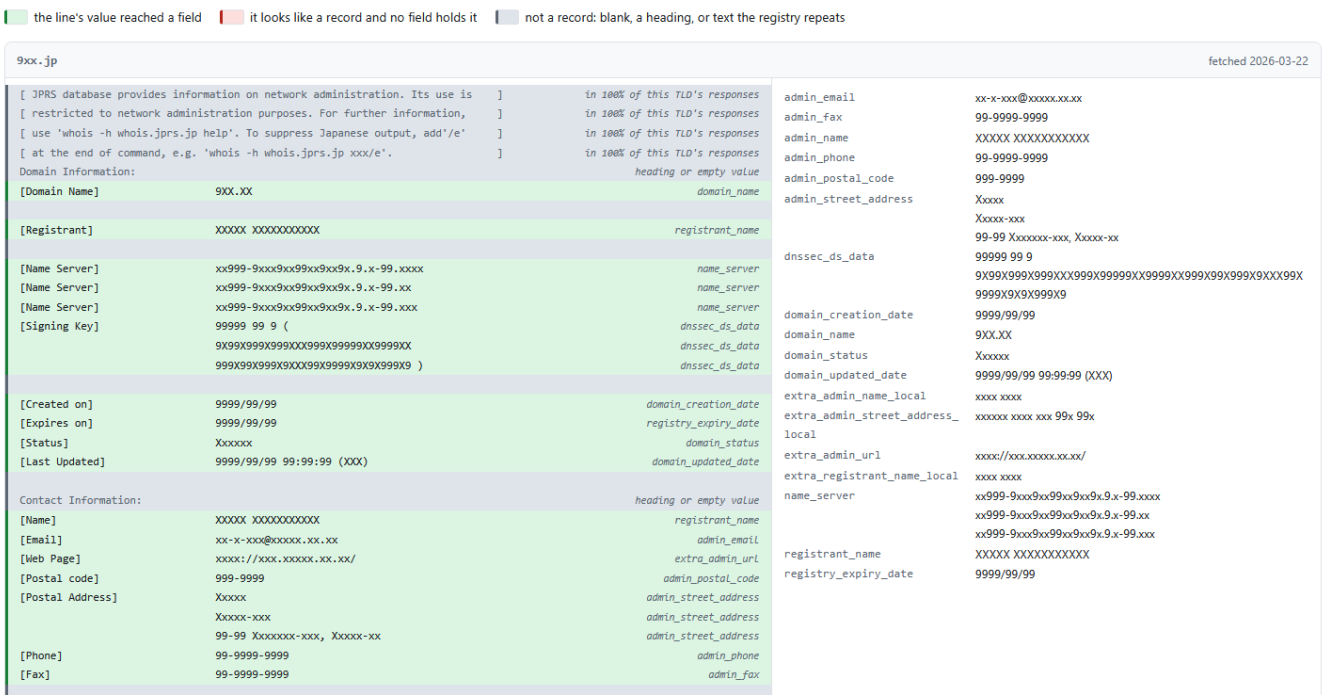


図 **A·2**　伏字を施したパース結果（.jp）
Fig. A·2　A masked parse result (.jp).

TLD	PATTERN	SCORED LINES	VWHOIS	RICHARDPENMAN/ WHOIS	MBOOT- GITHUB/ WHOISDOMAIN	POGZYB/ ASYNCWHOIS	NINOSEKI/ WHOIS- PARSER	WEPPOS/ WHOIS- PARSER	SIMPLEBYTES- COM/WHOIS- PARSER	LIKEXIAN/ WHOIS- PARSER	IO- DEVELOPER/ PHP-WHOIS	PROWEBCRAFT/ WHOIS-PARSER
abb	pattern1	194	100.0%	37.6%	80.4%	37.6%	36.6%	0.0%	84.0%	99.5%	35.1%	17.5%
abbott	pattern1	477	100.0%	23.5%	80.1%	23.5%	23.1%	0.0%	80.7%	99.8%	22.4%	19.9%
abogado	pattern1	902	100.0%	62.0%	61.9%	76.2%	41.2%	8.0%	62.3%	88.5%	40.0%	13.4%
abudhabi	pattern1	1745	100.0%	57.7%	43.6%	0.0%	53.5%	0.0%	34.9%	99.0%	21.8%	5.4%
accenture	pattern1	22	100.0%	77.3%	77.3%	77.3%	68.2%	0.0%	90.9%	95.5%	50.0%	31.8%
adult	pattern1	1081	100.0%	66.9%	65.1%	72.5%	51.4%	23.4%	72.0%	97.7%	36.9%	9.5%
aeg	pattern1	37	100.0%	56.8%	64.9%	56.8%	51.4%	0.0%	81.1%	97.3%	43.2%	32.4%
afl	pattern1	514	100.0%	50.4%	85.0%	50.6%	50.2%	0.0%	87.0%	99.8%	49.4%	13.8%
africa	pattern1	1626	100.0%	62.7%	66.0%	68.7%	53.4%	0.0%	76.4%	98.1%	40.5%	7.1%
agakhan	pattern1	58	100.0%	93.1%	27.6%	93.1%	86.2%	0.0%	32.8%	98.3%	17.2%	8.6%
airbus	pattern1	90	100.0%	36.7%	72.2%	36.7%	34.4%	0.0%	80.0%	98.9%	30.0%	25.6%

図 **A·3**　既存パーサー比較の TLD 別統計
Fig. A·3　Parser comparison per TLD.

ないが，ここではどのパーサーがどのキーを落としているかが見える．6.2 節で述べたパターン別の差が，フィールドの単位では何に由来するのかを確かめられる．

図 **A·5** は 1 ドメインに対する各パーサーの出力を横に並べたもので，比較の最小単位である．フィールド名の付け方，値の粒度の差，および何も返さないパーサーの挙動が直接読める．6.2 節で述べた，粒度の差が行数ベースの指標に影響するという注意も，この画面で確かめられる．

A.2　WHOIS 応答で遭遇した事例

本文 7 節で述べた事象の具体例を示す．いずれも 4 節のデータセットから取った抜粋であり，次の規則で加工している．

省略箇所は ... の行で示す．ただし，末尾の切り詰めには印を付けない．登録者の氏名・番地・個人の連絡先は `XXXXXX` に置き換えたが，レジストリ自身が伏せた `REDACTED FOR PRIVACY` などは，伏せられていること自体が観測結果であるためそのまま示す．UTF-8 のバイト列を Latin-1 として再解釈した文字化けは `<C3><A9>` のようにバイト列で示す．

ただし A.2.8 節と A.2.10 節の 2 例，および A.2.7 節の 2026 年 8 月時点の応答は，データセットに含まれず別途取得したものである．

© 2026 Information Processing Society of Japan

KEY	LINES	VWHOIS	RICHARDPENMAN/ WHOIS	MBOOT-GITHUB/ WHOISDOMAIN	POGZYB/ ASYNCWHOIS	NINOSEKI/ WHOIS-PARSER	WEPPOS/ WHOIS-PARSER	SIMPLEBYTES-COM/ WHOIS-PARSER	LIKEXIAN/ WHOIS-PARSER	IO-DEVELOPER/ PHP-WHOIS	PROWEBCRAFT/ WHOIS-PARSER
p. [Name Server]	317	100%	100%	100%	100%	0%	100%	2%	100%	100%	100%
a. [Domain Name]	109	100%	100%	0%	100%	0%	0%	0%	3%	3%	2%
g. [Organization]	109	100%	100%	0%	100%	0%	0%	0%	100%	100%	100%
n. [Technical Contact]	109	100%	100%	0%	0%	0%	0%	0%	99%	0%	0%
[State]	109	100%	100%	100%	0%	0%	0%	100%	100%	0%	100%
[Last Update]	109	100%	0%	0%	0%	0%	0%	0%	100%	0%	0%
m. [Administrativ	107	100%	100%	0%	0%	0%	0%	0%	100%	0%	0%

図 A·4　キー別の抽出状況（.jp）

Fig. A·4　Per-key extraction across parsers (.jp).

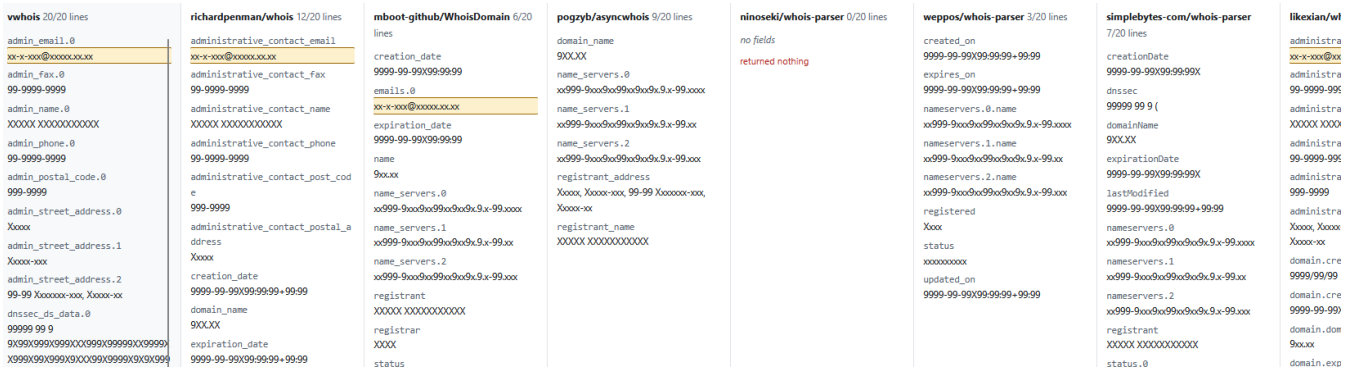


図 A·5　1 ドメインに対する各パーサーの出力

Fig. A·5　Each parser's output for a single domain.

A.2.1　HTML の混入

forum.sh では，レジストリの応答（61 行）が参照先として whois.regery.com を示すが，そこへ問い合わせると 124 行の HTML が返る．冒頭 6 行を示す．

```
<!DOCTYPE html>
<html lang="en">
<head>
    <meta charset="UTF-8" />
    <meta name="viewport" content="width=device-width,
initial-scale=1.0"/>
    <title>404 Not Found | Regery</title>
...
```

block.makeup のレジストラ応答（91 行）では，利用規約の末尾に画像へのリンクが HTML タグのまま置かれている．末尾 3 行を示す．

```
 Registration Service Provided By: Xiamen ChinaSource
Internet Service Co,. ltd.
    [Visit:www.zzy.com]
 <a href='http://www.zzy.cn/' target='_blank'><img src='http
://www.zzy.cn/images/whoisbanner.jpg' border='0'></a>
```

A.2.2　文字符号化の破損

.tg の応答では，HTML 実体参照（&eacute）と，UTF-8 のバイト列を Latin-1 として再解釈した文字化けが同一応答内に混在する．aeemt.tg のレコードから抜粋する．

```
Domain:.............aeemt.tg
Registrar:..........NETMASTER SARL
Status:.............Activ&eacute;
Address:............XXXXXX, Adidogom<C3><A9>, XXXXXX

CP:XXXXX,Lom<C3><A9>-Togo
...
```

なお CP: の行だけドットの詰め物がなく，直前に空行が入る．同じ応答の中で区切りの書式が一貫していない．

このほか，.xn--ogbpf8fl では多数のドメインでアラビア語が ???? に置換されており（xn--wgbc9d.xn--ogbpf8fl など），.es では C 言語の終端文字 0x00 が応答中に混入していた．なお .es は現在 WHOIS を廃止しており，パターン 7 に分類される．

A.2.3　キー名と異なる情報

dragonstake.io では，登録者・管理担当・請求担当・技術担当の 4 つすべてのメールアドレス欄に，同一の問い合わせフォーム URL が入る．

```
Registrant Email: Visit https://icann.online-validation.com/
domain-contact/?domainname=dragonstake.io
...
Admin Email: Visit https://icann.online-validation.com/domain
-contact/?domainname=dragonstake.io
```

© 2026 Information Processing Society of Japan

apn.cm では，住所欄が複数行にわたり，しかも継続行がそれ自体 key ： value の形をしている．他の .cm ドメインにこの書き方は現れない．

```
Registrar: CAMOO SARL
Registrar Street Address: B.P. : 3891 Yaoundé
Tél. : 222 312 027 / 661 562 859
Email : domain@camoo.sarl
Registrar Email: domain@camoo.sarl
```

継続行の Email : と，本来のキーである Registrar Email: が隣接している．行頭からの字下げもないため，行単位の分割では両者を区別できない．

A.2.4 固定文の中のキー

gTLD の応答末尾に付く次の行は，構文上は key: value だが登録情報ではない（block.makeup のレジストリ応答より）．

```
URL of the ICANN Whois Inaccuracy Complaint Form: https://www
.icann.org/wicf/
```

uae.dubai の応答には次の一文があり，pogzyb/asyncwhois はこの中の no match was found を「該当なし」の合図として解釈し，登録情報が存在するにもかかわらず NotFoundError を返す．

```
You acknowledge that: (i) a response from the Service
indicating no match was found, does not guarantee that it is
able to be registered;
```

A.2.5 レコードの矛盾

bing.sr は作成日が有効期限より後になっている．

```
Domain: bing.sr
WHOIS Server: https://whois.sr/
Creation Date: 9999-12-31
Registry Expiry Date: 2038-01-01
Status: pendingUpdate
Name server: None
...
```

pro.sr は作成日の前日が有効期限である．

```
Creation Date: 2023-09-15
Registry Expiry Date: 2023-09-14
Status: inactive
```

hack.to の有効期限は 2106 年である．

```
Creation Date: 2006-07-16T02:05:59.000Z
Registry Expiry Date: 2106-07-16T02:05:59.000Z
Registrar: Government of Kingdom of Tonga
```

同様の逆転は nic.crown，nic.kiwi，nic.mls などでも確認している．日付の妥当性検査を行う実装は，これらを異常値として棄却するか，例外を送出して停止する可能性がある．

A.2.6 gTLD 内の特殊ケース

nova.art には Art Record - Type of Object という用途不明のキーがある．.art 全体でこの 1 件のみである．

```
DNSSEC: Unsigned
Registrar Abuse Contact Email: abuse-
contact@publicdomainregistry.com
Registrar Abuse Contact Phone: +1.2013775952
Art Record - Type of Object: Site
URL of the ICANN WHOIS Data Problem Reporting System: http://
wdprs.internic.net/
```

block.makeup では，請求担当の接頭辞が Billing と Bill の 2 通りで現れる．.makeup 全体でこの 1 件のみである．

```
Billing Contact ID:
Bill Name: REDACTED FOR PRIVACY
Bill Organization: REDACTED FOR PRIVACY
...
Bill FAX Ext.:REDACTED FOR PRIVACY
```

なお最終行はコロンの直後に空白がなく，区切りの扱いにも一貫性がない．

A.2.7 gTLD 形式からの逸脱（複数行の住所）

gTLD 形式に従った ccTLD で，住所欄のみが複数行にわたる例である（shekinahlaw.com.fj，全 21 行）．

```
Domain Name: shekinahlaw.com.fj
Registrar URL: https://www.domains.fj
Registrar: USP Registrar
Registrar Street Address: The University of the South Pacific
,
IT Services,
Suva.
Registrar Email: domreg@usp.ac.fj
...
```

ただし，この書式は時間とともに変化している．cert.sd はデータセットに含まれる 2026 年 6 月 17 日の応答では複数行であった．

```
Registrar: sdnic registrar
Registrar Street Address: Sudan Internet Society "SIS" - .SD
Registry
NTC Tower, 1th Floor
P.O.Box 13713
Khartoum, SUDAN
Tel : + 249 157898600
Registrar Country: SD
```

2026 年 8 月 16 日に改めて問い合わせたところ 1 行へ統合されていたが，住所の一部であったと推測される Tel 行まで巻き込まれている．この応答はデータセットに含まれない．現在は，住所のみが複数行のまま残存している

© 2026 Information Processing Society of Japan

TLD と，元々複数行であったが一行に修正された TLD が混在している状況である．

```
Registrar Street Address: Sudan Internet Society "SIS" - .SD
Registry, NTC Tower, 1th Floor, P.O.Box 13713, Khartoum,
SUDAN, Tel : + 249 157898600
```

A.2.8 IANA からたどれない WHOIS サーバ

.ac.uk の登録情報は whois.nic.uk にはなく，whois.ja.net にある．応答形式も .uk のものとは異なり，ラベル行の次の行に字下げで値が置かれる．IANA の公開情報から到達できないため，この応答はデータセットに含まれない．これは一般的に配布されている whois コマンドでもたどり着かないため，あらかじめ利用者がこの状況を把握している必要がある．

```
Domain:
        jobs.ac.uk

Registered For:
        University of Warwick

Registrant Address:
        Network Services
        Coventry
        CV4 7AL
        United Kingdom
...
```

A.2.9 1 応答中の複数レコード

移管が発生した awa.tg では，1 回の応答に旧レジストラと新レジストラの登録が混在する．旧レジストラ NETMASTER SARL（Transféré，有効期限 2026-01-28）の登録が 6 個，新レジストラ IT-Num（Activé，有効期限 2027-01-28）の登録が 6 個で，区切りは罫線のみである．登録者は両者で同一である．全 207 行のうち各 1 個目の先頭を示す．

```
Domain:.............awa.tg
Registrar:..........NETMASTER SARL
Status:.............Transf&eacute;r&eacute;
...
----------------------------------------
...
Domain:.............awa.tg
Registrar:..........IT-Num
Status:.............Activ&eacute;
...
```

レコードを 1 件と仮定した実装は，どれか 1 つを採って残りを黙って捨てる．aeemt.tg も同様に 6 個の同一レコードを返す（A.2.2 節）．

A.2.10 呼ぶたびに変わる応答

cars.co.ug は，同一の問い合わせに対して毎回異なる組織名と住所を返す．3 回連続で問い合わせた結果を示す．データセットには 1 回分しか含まれないため，この 3 件は別途取得したものである．

```
Registrant Organization:  Hammond Ltd
Registrant State/Province: 602 Taylor Lodge

Registrant Organization:  Green, Price and Potter
Registrant State/Province: 7562 Stephanie Lane Apt. 560

Registrant Organization:  White-Russo
Registrant State/Province: 90749 Melissa Lodge Apt. 569
```

これは登録情報の秘匿を目的とした意図的な挙動と考えられる．パーサーの観点では正常に抽出できるが，得られた値には情報としての意味がない．

© 2026 Information Processing Society of Japan