X上のサイバー犯罪に関する投稿のLLMを用いた収集・分析

大久保 徹朗[1,a)]　川口 大翔[2]　宮本 直樹[3]　インミンパパ[2]　吉岡 克成[4]

概要：X（旧 Twitter）は高い拡散力と匿名性を特徴とする SNS で，様々なサイバー犯罪に悪用されている．既存研究は研究固有の分類体系に基づく分析にとどまり，研究間での分類結果の比較が難しく，対象外のサイバー犯罪活動を見落とす可能性がある．そこで本研究では，国際条約に基づく 5 つの標準的なサイバー犯罪カテゴリを分類枠組みとして採用し，LLM で生成した各カテゴリに対応するサイバー犯罪関連用語群を組み合わせた計 100 件のクエリを用いて X API から 41 日間にわたり収集した英語・日本語の投稿を，ローカル LLM により同 5 カテゴリへ分類し，各カテゴリの主なサイバー犯罪活動及び投稿内のメディアと URL の利用傾向を分析した．その結果，301,932 件のうち約 8.9%の 26,949 件がサイバー犯罪関連と分類され（マクロ平均 F1: 0.74），言語別では英語，カテゴリ別では CIA（データやシステムの機密性，完全性，可用性）への侵害が最多で，また言語とカテゴリの組み合わせでは英語で CIA への侵害，日本語で詐欺・偽造が最多となり，これは言語圏により主なサイバー犯罪カテゴリが異なることを示す．サイバー犯罪関連投稿の分析では，アカウント売買，賭博詐欺，違法・海賊版コンテンツの共有，ハッキングサービスの提供等の活動が確認され，約 39.0%がメディア情報を，約 24.2%が外部サービスへの URL を含み，誘導効果を持つメディアや誘導先の URL を活用し，X 上で完結するだけでなく、外部プラットフォームへ活動拠点が遷移する実態が示された．

キーワード：X，Twitter，サイバー犯罪，LLM

LLM-Based Collection and Analysis of Cybercrime-Related Posts on X

Tetsuro Okubo[1,a)]　Yamato Kawaguchi[2]　Naoki Miyamoto[3]　Yin Minn Pa Pa[2]
Katsunari Yoshioka[4]

Abstract: X (formerly Twitter) is a social networking service characterized by high dissemination capability and anonymity, and has been exploited for various cybercriminal activities. Existing research is limited to analyses based on study-specific classification schemes, making it difficult to compare classification results across studies and potentially overlooking cybercriminal activities outside their scope. In this study, we adopted five standardized cybercrime categories based on an international convention as a classification framework, and using 100 queries per category that combine cybercrime-related terms generated by an LLM, we collected English and Japanese posts via the X API over 41 days and classified them into the same five categories using a locally deployed LLM. We further analyzed the primary cybercriminal activities in each category as well as the usage patterns of media and URLs contained in the posts. As a result, of the 301,932 unique posts, approximately 8.9% (26,949) were classified as cybercrime-related (macro-averaged F1: 0.74). English posts were the most prevalent by language, and offences against the confidentiality, integrity, and availability of data and systems (CIA offences) by category; at the intersection of language and category, CIA offences dominated in English while fraud and forgery prevailed in Japanese, indicating that the predominant cybercrime category differs by language region. Analysis of cybercrime-related posts confirmed activities such as account trading, gambling fraud, sharing of illegal and pirated content, and provision of hacking services. Approximately 39.0% contained media and 24.2% contained URLs to external services, and by leveraging media with luring effects and URLs to redirection destinations, cybercriminal activities on X were shown to extend beyond the platform, with operations migrating to external platforms.

Keywords: X, Twitter, Cybercrime, LLMs

© 2026 Information Processing Society of Japan

This paper is work in progress and not peer-reviewed.

1. はじめに

Xは，リアルタイム性と高い拡散力を特徴とするSNSプラットフォームとして世界規模で広く利用されている．国別ユーザー数では，アメリカ合衆国が世界第1位で，次いで日本が第2位である [1]．特に日本では人口の約45%が利用し [2]，日常的な情報発信・収集の基盤となっている．

一方で，Xは匿名性や拡散力の高さゆえにサイバー犯罪活動にも悪用されている．日本ではX上での闇バイト募集投稿が社会問題化し [3]，これまでに対策が進められてきたが，2026年の警察庁の報告では応募経路の23.2%が依然としてXである [4]．これは，TelegramやDiscordなどコミュニティ単位で活動が行われるメッセージングプラットフォームと比較して，Xが不特定多数のユーザーとの接触が容易であり，サイバー犯罪活動の入口・集客の場として機能しやすいことが一因と考えられる．

X上のサイバー犯罪に関する投稿を対象とした既存研究については，セキュリティ専門家の投稿を対象とした脅威指標の抽出や，特定の言語・カテゴリに限定した分析，研究固有の分類体系に基づく特定の活動の分析にとどまっている [5], [6], [7], [8], [9]．そのため，研究固有の分類体系では研究間での比較が難しく，既存研究の対象外のサイバー犯罪関連活動を捉えられない可能性がある．したがって，X上のサイバー犯罪関連活動をより広く把握するには，複数言語を対象に，研究目的に依存しない標準的な分類体系から横断的に分析する必要がある．

そこで本研究では，国際条約に法的根拠を持つ標準的な分類体系としてブダペスト条約 [10] に基づいてTsakalidisらが提案した5つのサイバー犯罪カテゴリ [11] を分類枠組みとして採用し，以下の3つのリサーチクエスチョン（RQ）に答えることで，X上のサイバー犯罪関連投稿について，研究固有の分類体系とは異なる，より広い観点からその特徴を解明することを目指す．なお，Xの国別ユーザー数はアメリカ合衆国と日本が上位2カ国であることから，本研究では英語及び日本語の投稿を分析対象とする．

RQ1：X上の英語及び日本語の投稿テキストから，サイバー犯罪に関する投稿はどの程度検出されるのか？

RQ2：サイバー犯罪に関する投稿には，英語・日本語間，サイバー犯罪カテゴリ間でどのような傾向があるのか？

RQ3：投稿テキストの内容から示唆されるサイバー犯罪にはどのようなものがあり，その投稿に含まれるメディア情報や外部サービスへのURLはどの程度存在し，サイバー犯罪にどのように用いられているのか？

本研究ではこれらのRQに答えるために，以下の投稿収集・分析パイプラインを構築した．まず，研究倫理の観点から，投稿収集にはX社提供の公開インターフェースであるX API [12] を用いて，サイバー犯罪関連の用語を組み合わせたクエリにより，無関係な投稿の収集を抑えつつ，限られたクエリ数でサイバー犯罪の話題を広範に捉え，X APIの有料化に伴う研究コストの増大に対処した．クエリはTsakalidisらの5つのサイバー犯罪カテゴリ [11] に基づき，Grokを用いて各カテゴリに関する英語・日本語各10件，計100件を生成した．これらのクエリを用いて2026年2月12日から3月24日までの41日間にわたり投稿を収集し，投稿テキストに対してローカルLLMによるサイバー犯罪活動への関連の有無及び5カテゴリへの分類を行った．さらに，分類結果に基づき各カテゴリにおけるX上の主なサイバー犯罪活動についての考察を行うために，投稿テキストの分析に加え，サイバー犯罪関連投稿に含まれるメディア情報（画像・動画など）の集計と，外部サービスへのURLのFQDN別での集計を行い，それぞれ言語間・カテゴリ間での分析を行った．加えて，分類の信頼性を担保するために，2名の評価者が作成した300件の正解データを用いてローカルLLMの分類精度を評価した．

その結果，収集した投稿301,932件のうち約8.9%の26,949件がサイバー犯罪関連と分類された（RQ1）．カテゴリ別ではCIAへの侵害が8,154件 (30.3%)，コンテンツ犯罪が7,608件 (28.2%)，詐欺・偽造が5,564件 (20.6%)，知財侵害が4,677件 (17.4%)，複合的犯罪が946件 (3.5%) である．英語ではCIAへの侵害，日本語では詐欺・偽造がそれぞれ最多となった（RQ2）．また，サイバー犯罪関連投稿の約39.0%がメディア情報を，約24.2%が外部サービスへのURLを含んでおり，投稿テキストの内容からは，アカウント売買や賭博詐欺，違法コンテンツの共有，著作権侵害，ハッキングサービスの提供が主なサイバー犯罪であると判明し，誘導効果を持ちうるメディアや誘導先としての外部サービスへのURLを含む投稿も確認された（RQ3）．ローカルLLMによる分類精度はマクロ平均F1スコアが0.74とある程度の精度を担保できた一方で，分類精度の低下要因も明らかになり提案手法には改善の余地も残された．

本研究の貢献は以下の通りである．

- サイバー犯罪関連活動に関する投稿を対象として，複数言語（英語・日本語）かつ国際条約に基づく標準的な分類体系の観点から包括的に分析するための，LLMを活用した収集・分析パイプラインを構築した．
- X上にサイバー犯罪活動が一定規模で存在し，対象言

[1] 横浜国立大学
Yokohama National University
[2] 横浜国立大学先端科学高等研究院
Institute of Advanced Sciences, Yokohama National University
[3] 横浜国立大学大学院環境情報学府
Graduate School of Environment and Information Sciences, Yokohama National University
[4] 横浜国立大学大学院環境情報研究院/先端科学高等研究院
Faculty of Environment and Information Sciences, Yokohama National University / Institute of Advanced Sciences, Yokohama National University
[a)] okubo-tetsuro-by@ynu.jp

© 2026 Information Processing Society of Japan

語や期間は限定的だが，継続的な監視・対策の必要性を裏付ける指標を示した．

- 5 カテゴリ全てのサイバー犯罪関連投稿が存在し，言語間で主要なサイバー犯罪が異なることから，特定のサイバー犯罪に偏らない包括的な対策と，言語圏ごとの重点の違いを考慮した対策の必要性を示した．
- X 上の主たる具体的なサイバー犯罪を分析し，メディアや URL がサイバー犯罪に有効に用いられている実態を解明した．サイバー犯罪が X 上で完結するだけでなく，X が外部プラットフォームへの入口・集客の場として機能し，外部サービスへの誘導や活動拠点が移行する構造から，X にとどまらない横断的な対策の必要性を示した．

2. 関連研究

2.1 脅威情報を共有する投稿からの脅威指標・事象の抽出

Shin らの研究 [5] では，X 上のマルウェア関連及びセキュリティ専門家の投稿を対象に，BERT ベースの固有表現認識とランダムフォレストによるツイート分類器，および正規表現による IOC 抽出器を構築し，ファイルハッシュなどの脅威指標を抽出した．その結果，抽出された脅威指標が商用・公開 TI フィードと比較して高い精度・早期性・排他性を持つことを示した．

Cui らの研究 [6] では，X 上のセキュリティ関連投稿を対象に，STIX に基づくエンティティを LLM で抽出し，エンティティ共有関係のグラフ構造と Graph Attention Network を用いたイベント帰属情報中心の投稿埋め込み手法を提案した．その結果，脆弱性等のセキュリティイベントを既存手法の約 2 倍の検出数で抽出できることを示した．

2.2 特定の言語・サイバー犯罪に限定した投稿の検出・分類手法の提案

安彦らの研究 [7] では，X および Instagram 上の闇バイト募集・口座売買関連の日本語投稿を対象に，AI-OCR による画像内文字列の抽出と Random Forest によるテキスト分類を組み合わせ，闇バイト・口座売買・非犯罪関連の 3 分類において F 値 99%の高精度な分類を達成した．

Afrifa らの研究 [8] では，侮辱的表現に関連するハッシュタグを持つ X 上の英語投稿 16,851 件を対象に，TF-IDF による特徴抽出と Random Forest・SVM によるサイバーいじめ投稿の二値分類手法を提案し，Random Forest が精度 98.5%で最も高い検出性能を示した．

2.3 違法商品・サービスの宣伝投稿の検出・分析

Wang らの研究 [9] では，X 上の違法商品・サービスの宣伝投稿（PIPs）を対象に，多言語対応 Transformer ベース分類器による検出および研究固有の 10 カテゴリ（ポルノグラフィ等）への分類を行い，NER による連絡先抽出やクラスタリングによるキャンペーン分析を実施した．約 1,200 万件の PIPs と約 58 万アカウントを発見し，5 つの主要言語にわたり PIPs が大規模に存在し，宣伝者が Telegram 等を次段階の連絡手段として利用している実態を解明した．

2.4 既存研究に対する本研究の位置づけ

第一に，Shin ら [5] や Cui ら [6] はセキュリティ専門家・ベンダーによる脅威情報共有投稿を主な対象としているため，サイバー犯罪活動そのものの傾向や構造を把握できない．本研究では，サイバー犯罪者が X 上で行う犯罪活動そのものを対象とし，投稿テキストに加えてメディア情報や外部サービスへの URL を分析することで，サイバー犯罪に利用されるプラットフォームとしての X の傾向や構造の実態解明を目指す．

第二に，安彦ら [7] や Afrifa ら [8] は特定の言語・カテゴリに限定され，Wang ら [9] は複数言語・複数カテゴリを扱うものの，対象が違法商品・サービスの宣伝投稿に限定され，研究固有の分類体系を用いているため，異なる研究間での比較が困難であり，分類に含まれない犯罪活動を捉えられない可能性がある．本研究では，ブダペスト条約 [10] に基づき Tsakalidis ら [11] が提案した標準的な 5 つのサイバー犯罪カテゴリを分類枠組みとして採用し，英語・日本語の 2 言語にわたって，宣伝活動に限らずサイバー犯罪活動全般を横断的に分析する．

3. 前提知識

Tsakalidis ら [11] は，ブダペスト条約 [10] の基本理念に基づき，複合型犯罪を加えた以下の 5 つのサイバー犯罪カテゴリを提案した．

カテゴリ A: CIA（機密性・完全性・可用性）への侵害
システムへの不正アクセス，機密データの窃取，通信の不正傍受，データの改ざん・破壊，システム機能の妨害，およびサイバー犯罪ツールの作成・配布に関与する行為を含む．

カテゴリ B: 詐欺・偽造
デジタル記録の偽造，金銭的利益を目的とした詐欺行為，および ID の窃取・不正使用を含む．

カテゴリ C: コンテンツ犯罪
露骨な違法コンテンツの配布，児童搾取素材，宗教的信念を標的とする行為，サイバーいじめ，違法ギャンブル，スパム，および差別的，憎悪的コンテンツの拡散を含む．

カテゴリ D: 知財侵害
著作権で保護された素材の不正使用・配布，および商標の不正使用を含む．

カテゴリ E: 複合的犯罪
フィッシング，不正収益処理のためのデジタルツール使用，国家安全保障や重要インフラを標的とするサイ

© 2026 Information Processing Society of Japan

バー戦争，およびデジタルプラットフォームを通じたテロリズムの促進を含む．

4. 提案手法

図 1 に，本研究における投稿収集・分析のシステムフローチャートを示す．初めに LLM により生成されたクエリを用いて X API から投稿を収集し，ローカル LLM による関連の有無の判定及びカテゴリ分類を行う．さらにサイバー犯罪関連投稿のテキスト及び投稿に含まれるメディア情報や外部サービスへの URL の分析を行う．以下では各プロセスを詳述する．

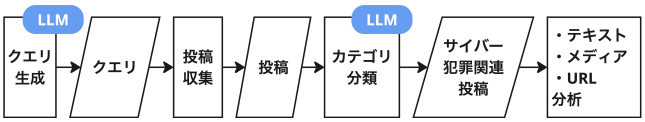


図 1 投稿収集・分析のシステムフローチャート

4.1 クエリ生成

本研究では X API の Python ラッパーライブラリである Tweepy [13] を経由して投稿を収集する．X API における投稿テキストの絞り込みはクエリパラメータ内のオペレータ（キーワード等）に限定されるため，クエリ設計が収集の質を左右する．クエリの生成には，X 上の投稿内容を学習している Grok [14] を用い，Tsakalidis らの 5 つのサイバー犯罪カテゴリ [11] の定義をプロンプトとして与え，各カテゴリについて英語・日本語それぞれ 10 件，計 100 件のクエリを生成した．各クエリではサイバー犯罪概念語群と行動・意図語群を組み合わせ，無関係な投稿の混入を抑制しつつ，限られたクエリ数でサイバー犯罪の明確な意図を持つ多様な投稿を収集するとともに，X API の有料化に伴う研究コストの増大に対処した．

4.2 投稿収集

X 上の投稿収集方法には Web スクレイピングやサードパーティ製 API も考えられるが，前者は明示的な許可を得ている場合を除いて利用規約で禁止されており [15]，後者は利用規約準拠の確認が困難な場合がある．X API は利用規約に準拠した正規の収集手段で再現可能であり，投稿テキストに加え様々な構造化メタデータが取得できることから，本研究に最も適した手段と考えた．

100 件のクエリを用いて 2026 年 2 月 12 日から 3 月 24 日までの 41 日間にわたり X API から投稿を収集した．X API の 1 日あたりの取得数の上限に対し，クエリごとに最大取得件数を設定することで収集件数の偏りを抑えた．収集対象は各クエリに合致する英語及び日本語の投稿で，テキストに加え言語情報やメディアの種類と数，URL 等メタデータを取得した．ただし，キーワード検索に基づくためサイバー犯罪活動と無関係な投稿も収集されるが，この問題には次段階で対処する．

4.3 サイバー犯罪への関連の有無及び 5 つのサイバー犯罪カテゴリへの分類

収集した投稿に対し，サイバー犯罪活動への関連の有無及び 5 つのサイバー犯罪カテゴリへの分類を行うことで，サイバー犯罪関連投稿の検出規模（RQ1）と言語間・カテゴリ間の傾向（RQ2）を解明する．分類にはローカル LLM（gpt-oss:20b） [16] を用いた．これは投稿内の個人情報保護のため外部 API への送信を避け，また大量の投稿への人手による分類が非現実的であり，教師データが存在せず，プロンプトによる分類基準の指示が可能なためである．分類基準は第 3 章の Tsakalidis らの 5 カテゴリ [11] を基に，5 カテゴリのいずれかに属するとは限らないサイバー犯罪や複数カテゴリに属しうる投稿にも対応するため，独自の分類基準や例の追加を適宜行った．入力としてこの分類基準を記述したプロンプトと投稿テキストを LLM に与え，出力として 5 カテゴリまたはサイバー犯罪非関連のいずれかのラベルと，分類精度改善に活用するための分類理由を生成させる．なお，分類精度の評価を第 6.2 章にて行った．

4.4 サイバー犯罪関連投稿のテキスト分析

X 上の主要なサイバー犯罪活動を具体的に解明するため（RQ3），各カテゴリでサイバー犯罪関連投稿を最も多く収集したクエリから得られた投稿テキストを実際に確認する．さらに，それらの投稿に含まれるメディアや URL の種類・数を集計し，サイバー犯罪への利用傾向を分析する．

4.5 サイバー犯罪関連投稿に含まれるメディア分析

各投稿が含むメディアの種類（画像・動画など）と数から，含有率や種類別分布を言語別・カテゴリ別に集計し，メディアの利用傾向を分析する（RQ3）．

4.6 サイバー犯罪関連投稿に含まれる URL 分析

各投稿が含む URL について，X のリンク短縮サービス [17] による短縮 URL「http://t.co/...」を展開した上で FQDN 単位に集約し，言語別・カテゴリ別に集計し，URL の利用傾向を分析する（RQ3）．

5. 投稿の収集・分析結果

5.1 投稿の収集結果

2026 年 2 月 12 日から 3 月 24 日までの 41 日間にわたり，100 件のクエリを用いて X API から投稿を収集した．収集した投稿の言語別分布を表 1 に，サイバー犯罪関連投稿の概要を表 2 に示す．

収集した投稿総数は 301,932 件（テキストの重複を許すと 886,405 件）であった．言語別では英語 189,535 件

© 2026 Information Processing Society of Japan

表 1 収集した投稿数の言語別分布

言語	ユニーク投稿数	割合
英語	189,535	62.8%
日本語	112,134	37.1%
その他	263	0.1%
合計	301,932	100.0%

（62.8%），日本語 112,134 件（37.1%）であり，それぞれ同数のクエリを用いたにもかかわらず英語投稿が多かったのは X 上の英語投稿数がより多いためと考えられる．その他の言語の投稿 263 件（0.1%）は英語クエリに合致するも，短文による言語判定が誤った，または大部分が他言語で構成された投稿であった．

表 2 サイバー犯罪関連投稿数の概要

項目	ユニーク投稿数	割合
全投稿数	301,932	100.0%
サイバー犯罪関連投稿数	26,949	8.9%

LLM による分類の結果，ユニーク投稿 301,932 件のうち 26,949 件（約 8.9%）がサイバー犯罪関連と分類され，X 上にサイバー犯罪活動に関する投稿が一定の規模で存在することが確認された（RQ1）．サイバー犯罪関連用語を含むクエリで話題を絞っても約 8.9%にとどまった背景には，X 上の投稿の話題が雑多で，クエリに合致するもサイバー犯罪活動と無関係な投稿や，サイバー犯罪の明確な意図が認められない短文投稿が多く収集されることが挙げられる．ただし，本手法のクエリはサイバー犯罪概念語群と行動・意図語群を組み合わせて明確な犯罪意図を持つ投稿を広範に収集しており（第 6.1 節），捉えられなかった投稿が客観的にサイバー犯罪関連であるか，他ユーザーへの誘導として機能するかは不明である．これらは，第 8 節で示す本研究の限界（投稿収集の網羅性）や X 上のサイバー犯罪関連投稿を高い割合で効率的に収集することの困難さを示唆している．

5.2 収集した投稿の分析結果

表 3 サイバー犯罪関連投稿数の言語別・カテゴリ別分布

カテゴリ	英語	日本語	合計	割合
A（CIA への侵害）	6,781	1,372	8,153	30.3%
B（詐欺・偽造）	3,437	2,127	5,564	20.6%
C（コンテンツ犯罪）	5,655	1,950	7,605	28.2%
D（知財侵害）	3,551	1,123	4,674	17.4%
E（複合的犯罪）	684	262	946	3.5%
合計	20,108	6,834	26,942	—
割合	74.6%	25.4%	—	100.0%

※英語・日本語以外のサイバー犯罪関連投稿 7 件を除く

サイバー犯罪関連投稿の言語別・カテゴリ別分布を表 3 に示す．言語別では英語 20,108 件（74.6%），日本語 6,834 件（25.4%）であり，収集投稿全体の比率（62.8%対 37.1%）と比較して英語の比率がより高かった．なお，その他の言語は 7 件（0.1%未満）とごくわずかであり，本分析の対象外とした．カテゴリ別では CIA への侵害が 8,153 件と最多であり，次いでコンテンツ犯罪 7,605 件，詐欺・偽造 5,564 件，知財侵害 4,674 件，複合的犯罪 946 件であった．言語とカテゴリの組み合わせでは，英語では CIA への侵害が 6,781 件（33.7%），日本語では詐欺・偽造が 2,127 件（31.1%）で最多であった．全 5 カテゴリで投稿が確認され，カテゴリ間の分布や言語圏ごとの主要なサイバー犯罪に差異があることが明らかになった（RQ2）．

5.3 収集した投稿に含まれていたメディア情報

表 4 サイバー犯罪関連投稿と非関連投稿のメディア含有率の比較

分類結果	メディアなし	メディアあり	合計（含有率）
関連あり	16,439	10,510	26,949（39.0%）
関連なし	206,207	68,776	274,983（25.0%）
合計	222,646	79,286	301,932

サイバー犯罪関連投稿と非関連投稿のメディア含有率を表 4 に示す．サイバー犯罪関連投稿のメディア含有率は 39.0%であり，非関連投稿の 25.0%より約 14 ポイント高い．これはサイバー犯罪関連投稿においてメディアがより積極的に利用され，犯罪活動を促進する手段として用いられている可能性を示唆している．種類別では画像を含む投稿 8,835 件が最多で，次いで動画を含む投稿 1,840 件，GIF 画像を含む投稿 207 件（2.0%）はごく少数のため以降は画像と動画を対象とする．

メディアを含むサイバー犯罪関連投稿の言語別・カテゴリ別分布を表 5 に示す．なお，1 投稿が画像と動画の両方を含む場合は両列に計上している．

表 5 メディアを含むサイバー犯罪関連投稿数の言語別・カテゴリ別分布

言語別 / カテゴリ別	画像	動画	合計	割合
英語	6,999	1,722	8,721	81.7%
日本語	1,836	118	1,954	18.3%
A（CIA への侵害）	4,231	266	4,497	42.1%
B（詐欺・偽造）	1,799	62	1,861	17.4%
C（コンテンツ犯罪）	1,040	1,127	2,167	20.3%
D（知財侵害）	1,471	374	1,845	17.3%
E（複合的犯罪）	294	11	305	2.9%

言語別では英語 81.7%，日本語 18.3%であり，サイバー犯罪関連投稿全体の比率（74.6%対 25.4%）と比較して英語の比率が高かった．カテゴリ別では，CIA への侵害が最多となった．メディア別では，画像を含む投稿が CIA への侵害で最多の約 47.9%を占め，動画を含む投稿はコンテンツ犯罪で最多の約 61.3%を占め，またコンテンツ犯罪での

© 2026 Information Processing Society of Japan

み動画を含む投稿数が画像を含む投稿数を上回った．知財侵害でも動画を含む投稿が多く，これらのカテゴリでは添付メディア自体が違法コンテンツや著作権侵害物である可能性がある．

5.4 収集した投稿に含まれていた外部サービスへの URL

表 6 サイバー犯罪関連投稿と非関連投稿の URL 含有率の比較

分類結果	URL なし	URL あり	合計（含有率）
関連あり	20,429	6,520	26,949（24.2%）
関連なし	220,322	54,661	274,983（19.9%）
合計	240,751	61,181	301,932

サイバー犯罪関連投稿と非関連投稿の URL 含有率を表 6 に示す．サイバー犯罪関連投稿の URL 含有率は 24.2%であり，非関連投稿の 19.9%より約 4 ポイント高かった．

サイバー犯罪関連投稿に含まれる URL の総数は 28,553 個，FQDN は 1,047 種類であった（展開不可の URL は除外）．FQDN 別では Telegram の招待 URL（6,395 個）が最多で，次いでリンク集約サービスの URL（2,364 個），その他では Discord 等メッセージングプラットフォームの招待 URL が上位を占めた．これらは，サイバー犯罪活動が X 上で完結せず，外部サービスへの誘導や活動拠点の移行手段として URL が利用されていることを示唆する．

URL を含むサイバー犯罪関連投稿数の言語別の分析

英語では Telegram の招待 URL（1,446 件）が最多で，違法・海賊版コンテンツの配信に利用されている可能性があるサイトの URL（622 件）が続き，その他 Discord（534 件）や WhatsApp（60 件）等メッセージングプラットフォームの招待 URL が上位を占めた．日本語では SHEIN のアフィリエイト共有リンク（733 件）が最多で，URL へのアクセスで報酬が得られるといった誘導の意図が示唆されるテキストを持ち，LLM が誘導による詐欺と捉えた可能性がある．メッセージングプラットフォームの招待 URL では，LINE（143 件）や Discord（124 件）が上位に含まれた．両言語で共通してメッセージングプラットフォームの招待 URL が多いが，英語では Telegram，日本語では LINE・Discord が中心であるという言語間の差異もあった．

URL を含むサイバー犯罪関連投稿数のカテゴリ別の分析

CIA への侵害では，Telegram（338 件），Discord（100 件），WhatsApp（78 件），LINE（67 件）とメッセージングプラットフォームの招待 URL が上位を占めた．YouTube の URL（169 件）も上位で，ハッキング方法やツールの紹介動画の宣伝がテキストから示唆された．その他アカウント売買サイト（79 件）や SNS ボットのハブサイト（33 件）の可能性がある URL も確認された．詐欺・偽造では SHEIN のアフィリエイト共有リンク（729 件）が最多で，LINE（96 件），Telegram（68 件）などメッセージングプラットフォームの招待 URL が続き，紹介キャンペーン関連 URL も見られた．コンテンツ犯罪では Telegram（826 件）や Discord（469 件）の招待 URL が上位を占め，他にも Google の無料ブログサービスである Blogger の URL（145 件）が確認され，違法コンテンツの共有・配信プラットフォームとしての利用が示唆された．知財侵害では海賊版ストリーミングサイトの可能性がある URL（622 件）が最多で，Telegram（43 件）などメッセージングプラットフォームの招待 URL が他カテゴリより少なく，海賊版コンテンツの配布サイトへの直接誘導が特徴的である．複合的犯罪では Telegram（174 件），Discord（64 件）等メッセージングプラットフォームの招待 URL が上位を占め，ハッキング等代行サービスの窓口として利用されている．

以上より，メッセージングプラットフォーム（特に Telegram）への誘導が支配的であったが，各カテゴリ特有のサービスへの誘導も確認された．また，各所で正規サービスへの URL も含まれ，LLM による誤分類の可能性の一方で，正規サービスの悪用可能性もある．

5.5 各カテゴリにおける具体的なサイバー犯罪活動

カテゴリ A: CIA への侵害

「`(account sale OR accounts for sale OR hacked accounts) (Twitter OR Instagram OR email) lang:en`」というクエリから得られた投稿が 4,745 件（カテゴリ A の約 58.2%）と最多であった．X や Instagram のアカウント，メールアドレスの売買宣伝が中心で，フォロワー数や認証状態，取引条件を記載していた．また，アカウントを紛失したユーザーへの返信で復旧や売買を提案する投稿も見られた．画像を含む投稿が 70.6%を占め，売買対象アカウントのプロフィール画面やフォロワー数のスクリーンショットにより，所持の証拠を提示する意図がうかがえる．URL を含む投稿は 6.7%と少数だが，誘導先は Telegram 等のメッセージングプラットフォームやアカウント売買サイトが中心であった．

カテゴリ B: 詐欺・偽造

「`(illegal gambling OR casino OR betting) (link OR invite) lang:en`」から得られた投稿が 1,245 件（カテゴリ B の約 22.4%）と最多で，スポーツベッティングや暗号通貨カジノでの確実な利益を謳い，プロフィール内のリンクから外部サービスへ誘導する投稿が中心であった．メディアを含む投稿は 3.1%と少数だが，高額な配当金やベッティングの的中結果の画像が添付され，利益の証拠としてユーザの関心を引く意図がうかがえた．URL を含む投稿も 6.6%と少数だが，ユーザプロフィール内に URL を添付する投稿もあり，誘導先は Telegram や Discord 等メッセージングプラットフォームが中心で，ギャンブルグループへの参加を促す投稿も確認された．

カテゴリ C: コンテンツ犯罪

「`(CP OR child porn OR underage) (video OR pic`

© 2026 Information Processing Society of Japan

OR share）lang:en」から得られた投稿が 1,067 件（カテゴリ C の約 14.0%）と最多で，児童ポルノなど違法コンテンツの提供・宣伝を行い，外部プラットフォームへ誘導する投稿が中心であった．動画を含む投稿が 46.8%を占め，違法コンテンツ自体が添付されている可能性がある．URL を含む投稿も 58.4%を占め，誘導先は Telegram や Discord が中心で，成人向けコンテンツプラットフォームの可能性があるサイトも確認された．

カテゴリ D: 知財侵害

「(manga OR anime OR movie) (leak OR free download OR stream) lang:en」から得られた投稿が 1,358 件（カテゴリ D の約 29.0%）と最多で，映画やアニメの無料視聴・ダウンロードを宣伝する投稿が中心であった．画像を含む投稿が 63.6%と多く，宣伝対象のサムネイルなどにより閲覧者の関心を引く意図がうかがえる．URL を含む投稿は 70.2%と高く，誘導先は海賊版コンテンツ配布目的の個人運営と思われるサイトが最多で，合法的なプラットフォームの悪用可能性があるケースも確認された．

カテゴリ E: 複合的犯罪

「(hack OR hacking OR breach OR unauthorized access) (tool OR sell OR method OR tutorial) lang:en」から得られた投稿が 138 件（カテゴリ E の約 14.6%）と最多で，これらはハッキングやスパム送信などの不正行為をサービスとして提供・宣伝する投稿が中心であった．画像を含む投稿が 63.0%と多く，提供サービスの概要やハッキング対象アカウントと思われるスクリーンショットが含まれていた．URL を含む投稿は 84.8%と全カテゴリ中で最高で，誘導先は Telegram に集中していた．

以上より，アカウント売買，賭博詐欺，違法コンテンツの共有，著作権侵害，ハッキングサービスの提供といった多様なサイバー犯罪関連活動が確認された．メディアは証拠の提示や閲覧者の関心を引く手段として，URL はメッセージングプラットフォームや外部サイトへの誘導手段として，各活動で役割を果たしていた．また，投稿の確認過程で凍結アカウントや削除済み投稿も多数確認され，プラットフォーム側の対策が行われていることもうかがえた．

6. 評価

6.1 LLM によって生成された投稿収集用クエリの有効性

LLM により生成した投稿収集用クエリ 100 件の内，95 件がサイバー犯罪関連投稿を 1 件以上収集し，かつ両言語で全サイバー犯罪カテゴリの投稿収集ができ，LLM を用いて限られたクエリ数でサイバー犯罪関連の話題を広範に捉えることができた．

6.2 LLM によるサイバー犯罪への関連の有無及び 5 つのサイバー犯罪カテゴリへの分類精度

LLM による分類結果に基づき X 上のサイバー犯罪活動の特徴を解明するため，人手のアノテーションに基づく正解データを用いて LLM の分類精度を評価した．5 カテゴリおよび非関連の計 6 カテゴリから正解データを各 50 件，合計 300 件を作成した．LLM の分類結果を基準にサンプリングすると，誤分類により正解データの件数が偏り，特定カテゴリの正解データが不足しうる．そのため，実際の収集分布とは異なりうるが，各カテゴリの分類性能は同程度に重要であり，投稿数が少数のカテゴリにおいても十分な正解データによる評価を行うために各カテゴリ均等の 50 件とした．アノテーションは 2 名の評価者が LLM に与えたプロンプトに基づき独立して行い，不一致はその後の議論により解決した．評価指標には各クラスの分類性能を均等に評価するため，マクロ平均 F1 スコアを用いた．

表 7 LLM による投稿のカテゴリ分類精度

カテゴリ	適合率	再現率	F1 スコア	正解数
A（CIA への侵害）	0.71	0.88	0.79	50
B（詐欺・偽造）	0.76	0.62	0.68	50
C（コンテンツ犯罪）	0.88	0.84	0.86	50
D（知財侵害）	0.75	0.98	0.85	50
E（複合的犯罪）	0.80	0.78	0.79	50
サイバー犯罪非関連	0.57	0.40	0.47	50
マクロ平均	0.74	0.75	0.74	300

結果を表 7 に示す．マクロ平均 F1 スコアは 0.74 と一定の精度を示した．5 つのサイバー犯罪カテゴリの F1 スコアは 0.68〜0.86 の範囲で一定の分類性能が確認された一方で，サイバー犯罪非関連の再現率が 0.40 と著しく低く，実際にはサイバー犯罪非関連である投稿の多くが，サイバー犯罪関連の投稿として誤分類されたことが分かった．評価者間の一致度は Cohen's $\kappa = 0.72$ であり，プロンプトにおける分類基準が一貫して解釈可能であることが確認された．

6.3 LLM の分類結果と正解データ間の系統的差異の分析

第一に，クエリで話題は絞られるが，ニュースの共有や注意喚起などサイバー犯罪に無関係な話題は特に雑多なため，プロンプト上で分類基準を網羅的に記述することには限界があり，サイバー犯罪非関連の分類精度が低下した．

第二に, 短文中心で文脈情報や具体性が乏しい場合, LLM がサイバー犯罪関連の言葉に依存し，無関係な投稿を誤分類する傾向が見られた．また，CIA への侵害と詐欺・偽造などカテゴリ間で意味が類似する場合，プロンプト上で判断基準を詳述しても分類が困難な場合があった．

第三に，外部検索を行わず規模に制約があるローカル LLM の知識限界により，サービスの正規性の判断が困難な場合がある．例えば，作品の無料閲覧を宣伝する投稿はサービスの正規性や宣伝の事実性によりサイバー犯罪非関連や知財侵害に該当しうるが，こうした判断に必要な知識が不足していた．

© 2026 Information Processing Society of Japan

7. まとめ

本研究では，LLM を活用した収集・分析パイプラインを構築し，X 上のサイバー犯罪関連投稿について 2 言語を対象に，国際条約に基づく標準的な分類体系から横断的に分析した．その結果，26,949 件の全 5 カテゴリにわたるサイバー犯罪関連投稿を検出し，言語別では英語で CIA への侵害，日本語で詐欺・偽造が最多であるなど主要なサイバー犯罪が言語圏によって異なることを解明した．具体的な活動にはアカウント売買や賭博詐欺，違法・海賊版コンテンツの共有，ハッキングサービスの提供が見られ，メディアが証拠提示や関心喚起に，URL が外部サービスへの誘導手段として用いられていた．特にメッセージングプラットフォームへの誘導が支配的であり，X がサイバー犯罪の入口・集客の場として機能する実態を解明した．これらは，言語圏ごとの傾向を考慮した継続的な対策，及び X にとどまらない横断的な監視・対策の必要性を示す．

8. 制限事項

収集期間・対象言語の拡張　英語・日本語圏の 41 日という短い収集期間による短期的な傾向の把握にとどまるため，対象言語を拡張しつつ，継続的な監視による時期による変動や長期的傾向を捉える必要がある．

投稿収集の網羅性　第 6.1 節でクエリの有効性を示しつつも，X API のレート制限やクエリ対象外の表現・未知の隠語による収集漏れの可能性がある．また，収集した投稿のうちサイバー犯罪関連投稿の割合は 8.9%にとどまり，クエリ改善など収集精度の向上が求められる．

LLM による分類精度の改善　第 6.3 節で示した通り，投稿の雑多さや文脈・具体性の欠落，ローカル LLM の知識・規模の制約から分類精度には改善の余地がある．

テキスト分析の網羅性　第 5.5 章の分析は，各カテゴリで最も多くサイバー犯罪関連投稿を収集したクエリから収集した投稿のみに基づくものであり，サイバー犯罪関連投稿全体を網羅的に分析できていない．今後はトピックモデリングなどによる体系的な把握が求められる．

サイバー犯罪非関連投稿の定義・解釈　本研究のサイバー犯罪非関連投稿は，サイバー犯罪関連用語群からなるクエリで収集した投稿のうち LLM が非関連と分類したもので，メディア・URL 含有率の差は同一クエリで収集した投稿間の差であり，サイバー犯罪関連投稿と一般的なサイバー犯罪非関連投稿の特徴差として一般化可能とは限らない．

謝辞　本研究の一部はＮＥＤＯ（国立研究開発法人新エネルギー・産業技術総合開発機構）の委託事業「経済安全保障重要技術育成プログラム／先進的サイバー防御機能・分析能力強化」（JPNP24003）によるものである．

参考文献

[1] Statista. X/Twitter: Global audience 2025. https://www.statista.com/statistics/242606/number-of-active-twitter-users-in-selected-countries/, 2025. Accessed: 2026-07-28.

[2] 総務省. 令和 7 年度 情報通信メディアの利用時間と情報行動に関する調査報告書. https://www.soumu.go.jp/menu_news/s-news/01iicp01_02000130.html, 2026. Accessed: 2026-07-28.

[3] 公明党. 【主張】闇バイト対策 SNS の投稿削除に本腰入れよ — ニュース. https://www.komei.or.jp/komeinews/p286869/, 2023. Accessed: 2026-07-28.

[4] 時事通信. 闇バイト応募者保護、５４４件実施 「加担せず、迷わず相談を」一警察庁. https://www.jiji.com/jc/article?k=2026010600127&g=soc, 2026. Accessed: 2026-07-28.

[5] Hyejin Shin, WooChul Shim, Saebom Kim, Sol Lee, Yong Goo Kang, and Yong Ho Hwang. #Twiti: Social Listening for Threat Intelligence. In *Proceedings of the Web Conference 2021*, WWW '21, p. 92–104, New York, NY, USA, 2021. Association for Computing Machinery.

[6] Jian Cui, Hanna Kim, Eugene Jang, Dayeon Yim, Kicheol Kim, Yongjae Lee, Jin-Woo Chung, Seungwon Shin, and Xiaojing Liao. Tweezers: A framework for security event detection via event attribution-centric tweet embedding, 2024.

[7] 安彦智史, 池辺正典, 櫻井淳, 藤本雄紀. サイバー防犯パトロールシステム構築における重要犯罪密接関連情報抽出アルゴリズムの検討. コミュニケーション学科論集, pp. 1–11, Mar 2025.

[8] Stephen Afrifa and Vijayakumar Varadarajan. Cyberbullying detection on twitter using natural language processing and machine learning techniques. *International Journal of Innovative Technology and Interdisciplinary Sciences*, Vol. 5, No. 4, p. 1069–1080, Dec. 2022.

[9] Hongyu Wang, Ying Li, Ronghong Huang, and Xianghang Mi. Detecting and understanding the promotion of illicit goods and services on twitter. In *Proceedings of the ACM on Web Conference 2025*, WWW '25, p. 3389–3404, New York, NY, USA, 2025. Association for Computing Machinery.

[10] Council of Europe. Convention on cybercrime. European Treaty Series No. 185, 2001. Available at https://rm.coe.int/1680081561.

[11] George Tsakalidis and Kostas Vergidis. "a systematic approach toward description and classification of cybercrime incidents". *IEEE Transactions on Systems, Man, and Cybernetics: Systems*, Vol. 49, No. 4, pp. 710–729, 2019.

[12] X Corp. X API. https://docs.x.com/x-api/introduction. Accessed: 2026-08-16.

[13] Tweepy. Tweepy. https://www.tweepy.org/. Accessed: 2026-08-16.

[14] X Corp. Grok について. https://help.x.com/ja/using-x/about-grok. Accessed: 2026-07-28.

[15] X Corp. X 利用規約. https://x.com/ja/tos. Accessed: 2026-08-16.

[16] OpenAI Platform. gpt-oss-20b. https://openai.com/ja-JP/index/introducing-gpt-oss/. Accessed: 2026-07-28.

[17] X Corp. X のリンク短縮機能（t.co）とその仕組み — X ヘルプ. https://help.x.com/ja/using-x/url-shortener. Accessed: 2026-07-28.

© 2026 Information Processing Society of Japan

研究倫理

本研究では，ユーザーのプライバシー保護と研究上のリスク低減に配慮した．投稿は Tweepy を介して X の公式 API から収集し，利用規約に準拠した．分析対象はテキストとメタデータに限定し，メディアのダウンロードや外部 URL へのアクセスは行わなかった．投稿の処理にはローカル環境の LLM を使用し，収集データを外部サービスへ送信していない．結果は集計または匿名化して示し，個々のユーザーや投稿を特定できない形で報告した．

© 2026 Information Processing Society of Japan

付　　録

A.1 Open Science

本研究において，第 4.1 章におけるクエリ生成，第 4.3 章におけるサイバー犯罪への関連の有無及び 5 つのサイバー犯罪カテゴリへの分類では，それぞれ LLM を利用している．これらのプロセスにおいて LLM に入力として与えるプロンプトの内容は，本研究における透明性や再現性を確保するために，本論文の付録に掲載する．同様にして，X API からの投稿検索に用いた 100 件のクエリを付録として公開する．一方，収集した投稿データについては，投稿本文に個人情報やセンシティブな内容が含まれる可能性があるため，倫理的配慮により公開していない．

A.2 クエリ生成時に用いたプロンプト

X API を用いて以下のサイバー犯罪を広く調査したいです。`https://docs.x.com/x-api/posts/search/integrate/build-a-query` を参考に、専門用語や隠語を考慮して、A, B, C, D, E ごとに 10 件の X API のクエリを作成してください。日本語ポスト用と英語ポスト用にそれぞれ別にクエリを作成してください。ニュースというよりかは実際のポストがマッチするようなクエリにしましょう。

Type A: Offenses Against Confidentiality, Integrity, and Availability of Computer Data and Systems

- Illegal Access (A1) — unauthorized access to systems
- Illegal Data Acquisition (A2) — theft of sensitive data
- Illegal Interception (A3) — unauthorized interception of communications
- Data Interference (A4) — tampering with or destruction of data
- System Interference (A5) — disruption of system functionality
- Misuse of Devices (A6) — creation, possession, or distribution of cybercrime tools

Type B: Computer-Related Offenses

- Computer-Related Forgery (B1) — falsifying digital records
- Computer-Related Fraud (B2) — fraudulent activities for financial gain
- Identity-Related Offenses (B3) — identity theft and misuse

Type C: Content-Related Offenses

- Pornographic Material (C1) — creation or distribution of illegal explicit content
- Child Pornography (C2) — material exploiting minors
- Religious Offenses (C3) — targeting religious beliefs
- Cyberbullying (C4) — harassment via digital platforms
- Illegal Gambling and Online Games (C5) — promotion of unregulated gaming activities
- Spam and Related Threats (C6) — mass unsolicited communications
- Racism and Hate Speech (C7) — discriminatory or hateful content

Type D: Intellectual Property Offenses

- Copyright-Related Offenses (D1) — unauthorized use or distribution of copyrighted material
- Trademark-Related Offenses (D2) — misuse of trademarks for counterfeiting

Type E: Combinational Offenses

- Phishing (E1) — deceptive practices to steal sensitive information
- Cyber Laundering (E2) — processing illicit proceeds using digital tools
- Cyberwarfare (E3) — attacks targeting national security or critical infrastructure
- Terrorist Use of the Internet (E4) — promoting or facilitating terrorism through digital platforms

A.3 投稿収集時に利用したクエリ（LLM が生成したクエリに多少の変更を加えている）

Type A: Offenses Against Confidentiality, Integrity, and Availability

- (ハッキング OR 侵入 OR 不正アクセス OR アカウント乗っ取り) (ツール OR 売ります OR やり方 OR 方法) lang:ja
- (アカウント売買 OR 垢売 OR 乗っ取り垢) (LINE OR Twitter OR Instagram) lang:ja
- (SQL インジェクション OR XSS OR 脆弱性) (ツール OR スクリプト OR 配布) lang:ja
- (DDoS OR 負荷かけ OR 落ちさせ) (依頼 OR 代行 OR やります) lang:ja

© 2026 Information Processing Society of Japan

- (パスワードリスト OR コンボ OR combo リスト) (売ります OR 無料配布) lang:ja
- (マルウェア OR ウイルス OR トロイの木馬) (作成 OR ばらまき OR 売買) lang:ja
- (リモハン OR リモートハック OR RAT) (ツール OR 遠隔操作) lang:ja
- (データ漏洩 OR 流出 OR ダンプ) (売ります OR 購入希望) lang:ja
- (クラック OR crack OR 解除) (ソフト OR ツール OR 有料) lang:ja
- (闇ツール OR ハッキングツール OR 犯罪ツール) (販売 OR 譲渡) lang:ja
- (hack OR hacking OR breach OR unauthorized access) (tool OR sell OR method OR tutorial) lang:en
- (account sale OR accounts for sale OR hacked accounts) (Twitter OR Instagram OR email) lang:en
- (SQL injection OR XSS OR exploit) (kit OR script OR drop) lang:en
- (DDoS OR stresser OR booter) (service OR attack OR hire) lang:en
- (combo list OR password list OR breach data) (sell OR dump OR free) lang:en
- (malware OR ransomware OR trojan) (build OR sale OR distribute) lang:en
- (RAT OR remote access OR keylogger) (tool OR cracked) lang:en
- (data leak OR database dump OR stolen data) (sell OR buy OR shop) lang:en
- (crack OR cracker OR keygen) (software OR tool OR release) lang:en
- (hacking tool OR cyber tool OR exploit kit) (sale OR giveaway OR market) lang:en

Type B: Computer-Related Offenses

- (詐欺 OR 特殊詐欺 OR 投資詐欺) (LINE OR Twitter OR 勧誘) lang:ja
- (振り込め詐欺 OR 受け子 OR 出し子 OR UD) (募集 OR バイト) lang:ja
- (カード情報 OR CC OR クレカ) (売ります OR 購入 OR 抜き) lang:ja
- (なりすまし OR ID 盗用 OR 身分証売買) (売ります OR 依頼) lang:ja
- (偽造 OR フォージェリ OR 偽文書) (デジタル OR PDF OR 作成) lang:ja
- (楽天 OR Amazon OR PayPay) (乗っ取り OR アカウント売買) lang:ja
- (架空請求 OR ワンクリック詐欺) (方法 OR やり方) lang:ja
- (闇バイト OR 犯罪バイト OR 高額バイト) (詐欺 OR 特殊) lang:ja
- (マネロン OR マネー洗浄 OR 口座売買) lang:ja
- (フィッシング OR 偽サイト OR 誘導) (ページ OR 作成) lang:ja
- (scam OR fraud OR investment scam) (DM OR promo OR invite) lang:en
- (carding OR CC dump OR fullz) (sell OR shop OR buy) lang:en
- (identity theft OR doxx OR personal info) (sale OR leak) lang:en
- (forgery OR fake document OR photoshop) (digital OR ID) lang:en
- (account takeover OR ATO OR hacked acc) (sell OR method) lang:en
- (money mule OR cashout OR laundering) (job OR hire) lang:en
- (phishing kit OR phish page OR spoof) (sale OR free) lang:en
- (impersonation OR catfishing OR fake profile) (sale OR service) lang:en
- (fake invoice OR billing scam) (tutorial OR how) lang:en
- (dark pool OR underground fraud) (service OR group) lang:en

Type C: Content-Related Offenses

- (児童ポルノ OR CP OR ロリ) (動画 OR 画像 OR 配布) lang:ja
- (AV OR 無修正 OR 裏ビデオ) (売ります OR リーク) lang:ja
- (サイバーブリング OR 晒し OR 拡散) (嫌がらせ OR 脅迫) lang:ja
- (差別 OR ヘイト OR 人種差別) (投稿 OR 拡散) lang:ja
- (闇カジノ OR 違法賭博 OR オンラインカジノ) (招待 OR リンク) lang:ja
- (スパム OR 拡散希望 OR フォロワー増やし) (ツール OR 方法) lang:ja
- (宗教 OR カルト OR 冒涜) (攻撃 OR 批判) lang:ja
- (児童買春 OR JK ビジネス OR 援助) (募集 OR 連絡) lang:ja
- (ハラスメント OR ストーカー OR DM 荒らし) lang:ja
- (違法コンテンツ OR 規制物 OR 闇) (共有 OR アップ) lang:ja
- (CP OR child porn OR underage) (video OR pic OR share) lang:en
- (revenge porn OR leak OR nudes) (sell OR drop) lang:en
- (cyberbullying OR harass OR dox) (target OR attack) lang:en
- (hate speech OR racism OR nazi) (post OR spread) lang:en
- (illegal gambling OR casino OR betting) (link OR invite) lang:en
- (spam OR bot OR follower boost) (tool OR service) lang:en

© 2026 Information Processing Society of Japan

- (blasphemy OR religious insult OR offend) (meme OR post) lang:en
- (escort OR sugar baby OR paid meet) (underage OR teen) lang:en
- (stalker OR threat OR abuse) (DM OR online) lang:en
- (illegal content OR dark content OR banned) (share OR group) lang:en

Type D: Intellectual Property Offenses

- (漫画 OR アニメ OR 映画) (無料 OR 違法アップロード OR リーク) lang:ja
- (海賊版 OR 違法 DL OR マグネット) (リンク OR 配布) lang:ja
- (著作権侵害 OR 無断転載 OR パクリ) (販売 OR 共有) lang:ja
- (偽ブランド OR スーパーコピー OR レプリカ) (売ります OR 購入) lang:ja
- (クラックソフト OR ライセンス解除 OR 無料) (配布 OR リンク) lang:ja
- (音楽 OR アルバム OR 曲) (漏洩 OR フル DL) lang:ja
- (ゲーム OR ROM OR エミュ) (違法 OR 配布) lang:ja
- (トレント OR torrent OR nyaa) (最新 OR アップ) lang:ja
- (コピー商品 OR 偽物 OR ブランド) (通販 OR DM) lang:ja
- (無断使用 OR 著作権フリー OR 侵害) lang:ja
- (manga OR anime OR movie) (leak OR free download OR stream) lang:en
- (piracy OR torrent OR magnet) (link OR share OR DDL) lang:en
- (cracked software OR keygen OR nulled) (release OR download) lang:en
- (replica OR fake OR counterfeit) (brand OR bag OR watch) lang:en
- (warez OR crack OR patch) (game OR program) lang:en
- (album leak OR music leak OR full zip) lang:en
- (ROM OR emulator OR dump) (game OR console) lang:en
- (pirated OR illegal copy OR bootleg) (sell OR share) lang:en
- (trademark violation OR fake brand) (shop OR link) lang:en
- (copyright infringement OR DMCA) (upload OR bypass) lang:en

Type E: Combinational Offenses

- (フィッシング OR 偽メール OR 詐欺メール) (ページ OR キット OR 売ります) lang:ja
- (マネーロンダリング OR マネロン OR 洗浄) (口座 OR 方法) lang:ja
- (サイバー戦争 OR 国家ハック OR APT) (ツール OR 情報) lang:ja
- (テロ OR 過激派 OR ジハーディスト) (募集 OR 宣伝 OR リンク) lang:ja
- (ダークウェブ OR 闇サイト OR Tor) (招待 OR リンク OR 取引) lang:ja
- (ビットコイン OR 仮想通貨 OR BTC) (詐欺 OR 送金 OR 洗浄) lang:ja
- (爆破 OR 攻撃 OR テロリスト) (方法 OR 募集) lang:ja
- (フィッシングキット OR phish kit) (日本語 OR 売買) lang:ja
- (ハッキング for hire OR 依頼) (詐欺 OR 攻撃) lang:ja
- (違法取引 OR 闇通貨 OR マネロン) (グループ OR DM) lang:ja
- (phishing OR phish OR spoof site) (kit OR page OR sell) lang:en
- (money laundering OR crypto wash OR mule) (service OR account) lang:en
- (cyberwarfare OR APT OR nation state hack) (tool OR leak) lang:en
- (terrorism OR jihad OR extremist) (recruit OR propaganda OR link) lang:en
- (darknet OR darkweb OR Tor market) (link OR invite OR shop) lang:en
- (bitcoin scam OR crypto fraud OR rug pull) (promo OR DM) lang:en
- (explosive OR bomb OR attack plan) (tutorial OR share) lang:en
- (hacking service OR hitman OR DDoS for hire) lang:en
- (card laundering OR cashout method) (tutorial OR group) lang:en
- (illicit proceeds OR cyber laundering) (service OR tool) lang:en

A.4 サイバー犯罪への関連の有無及び 5 つのサイバー犯罪カテゴリへの分類に用いたプロンプト

システムプロンプト

あなたはポリシーに基づく分類エンジンです。あなたのタスクは、単一の X（旧 Twitter）の投稿を分析し、サイバー犯罪活動に「関連

© 2026 Information Processing Society of Japan

している」かどうかを判定することです。「関連している」とは、以下のいずれかに該当する投稿を指します：
- サイバー犯罪関連の商品・サービスの斡旋、宣伝、要求、調整、取引を行っている
- 明確な犯罪意図を持つ実行可能な手順、ツール、またはインフラを提供している
判定は提供された投稿の内容のみに基づいて行ってください。
出力ルール（必須）
- 出力は JSON 形式とし、以下の 2 フィールドを含めること：
- category: ”A”、”B”、”C”、”D”、”E”、または ”null” のいずれか 1 つ
- reason: 判定理由の説明（2〜4 文）
- 精度方針: 誤検知を避けるため、疑わしさ・曖昧さ・正当な解釈の余地が少しでもある場合は必ず ”null” を出力すること
- 投稿に明示されている以上の意図を推測しないこと
- キーワード単体で分類しないこと（文脈・意図の明示性を重視する）
定義
サイバー犯罪関連（分類対象）
以下の明示的なシグナルが少なくとも 1 つ含まれている場合のみ「関連あり」とする：
1. 取引・勧誘:
- 販売、購入、交換、貸出、提供、要求、リクルート、採用、「DM で詳細」など
2. 明確な犯罪意図:
- 不正アクセス、盗難データ、フィッシング、クラッキング、詐欺、マネーロンダリング等の明示的な言及
3. 実行可能な犯罪支援:
- 手順書、キット、ペイロード、フィッシングページ、不正ツール、認証情報のダンプ、攻撃の調整
犯罪の完了を証明する必要はないが、投稿が犯罪の促進または意図を明確に示していること。
サイバー犯罪非関連（”null” を返す）
以下に該当する場合は必ず ”null” を返す：
- 詐欺・フィッシング等に関する注意喚起、警告、被害報告
- 犯罪に関する一般的な教育・解説コンテンツ（明確な犯罪意図なし）
- 倫理的なハッキングやセキュリティ防衛に関する議論
- 明示的な不正フレーミングのない正当なサービス（VPN、プロキシ、ホスティング等）
- 具体的な促進内容のない曖昧な表現（「なんでもできます」「最強の方法」等）
- 無関係な日常的会話・エンタメ・ニュース
カテゴリー定義
カテゴリ判別の優先ルール
複数のカテゴリに該当しうる場合は、以下の概念軸で判断する：
1. **A vs E の区別**:
- A = 犯罪の「手段・道具」の**単体取引**（ツール 1 本、認証情報 1 セット、代行 1 件）
- E = 犯罪活動の「サービス運営・インフラ提供・キャンペーン調整」（継続的・大規模・組織的）
- 判断基準: 「月額制」「運営サポート込み」「インフラ完備」「大規模配信」「調整・参加者募集」など**継続運営の特徴**があれば E
- 同じ行為でも、ツール単体の売買は A、それをサービスとして運営・提供する構造は E
2. **A vs B の区別**:
- A = 不正アクセス・システム侵害を直接可能にする手段の取引（マルウェア、ハックされたアカウント等）
- B = **欺罔**（だますこと）を主たる手段とした金銭詐取の実行・勧誘・手段売買
- 判断基準: 「被害者を騙して金銭・情報を引き出す」構造なら B
3. **複数カテゴリ該当時の優先順位**: E > C > B > D > A
- より上位のカテゴリの特徴が明確に存在すれば、そちらを選択する
Category A - コンピューターシステム犯罪
定義: 不正アクセス・システム侵害を直接可能にする**手段・道具の単体取引**。継続的なサービス運営は E、欺罔詐取目的の手段は B を参照。
含まれるもの:
- アカウント乗っ取り、フィッシングページ・悪性リンクの共有
- マルウェア・RAT・スパムツール・不正ツールの配布・販売・転売
- 不正アクセスのための認証情報（ログイン情報、クッキー、セッショントークン）の売買
- 本人確認代行（eKYC 代行、銀行口座開設代行、各種認証代行）
- 違法用途を明示したプロキシ・VPN・インフラの提供
日本語の表現例:
- 「垢売」「垢 BAN 回避」「凸」「ログイン代行」「クッキー抜き」「乗っ取り」「eKYC 代行」「口座 開設 代行」「本人確認 代行」「SMS

© 2026 Information Processing Society of Japan

認証 代行」「RAT」「マルウェア」「ウイルス」「ツール 販売」「BOT 販売」
Category B - 詐欺・欺罔犯罪
定義: **欺罔（被害者を騙すこと）を主たる手段とした金銭・資産詐取**の実行・勧誘、またはその手段の売買。
含まれるもの:
- 当選金詐欺、SNS（X）→ LINE・Telegram 誘導型詐欺
- 投資詐欺・なりすまし（企業・著名人・公的機関の偽アカウントによる誘導）
- 闇バイト・裏バイト（受け子・出し子・運び屋などの実行役の募集・勧誘）
- 保証金詐欺、前払い詐欺、非配達詐欺
- フォロワー販売・インプレゾンビ等の不正なアカウント操作サービスの売買
- 賭博詐欺（「必勝法」「100%勝てる」等）
- 欺罔詐取の手段となる偽造物の売買（盗難クレジットカード情報、なりすまし用偽造身分証明書等）
日本語の表現例:
- 「受け子」「出し子」「運び屋」「闇バイト」「裏バイト」「高額バイト」「即日即金」「副業 高収入」「LINE で詳細」「DM で詳細」「テレグラム 誘導」「当選しました」「プレゼント企画 当選」「投資グループ 招待」「フォロワー 販売」「いいね 購入」「インプレ 稼ぎ」「前澤」「NHK」「警視庁」等の著名人・機関名を使った偽アカウントによる金銭・情報要求
Category C - コンテンツ・嫌がらせ犯罪
定義: 違法・有害コンテンツの配布、または組織的な嫌がらせ行為。
含まれるもの:
- 盗撮画像・動画の販売・流通
- 児童ポルノ（CSAM）の配布・売買
- リベンジポルノ・非合意性的画像の拡散・販売
- 恐喝・脅迫（暴露・晒し行為）
- ドクシング（個人情報の収集・暴露）、組織的な嫌がらせ・標的攻撃
日本語の表現例:
- 「盗撮」「パンチラ」「裏垢」「無修正」「JC」「JK」「ガチ撮り」「晒し」「特定」「個人情報 売ります」「暴露します」「リベンジポルノ」「流出」「売ります DM」
Category D - 知的財産犯罪
定義: 著作権・商標で保護されたコンテンツの海賊版配布・不正利用。
含まれるもの:
- 漫画・映画・ゲーム・音楽・書籍・講座の無断配布・販売
- 違法ストリーミングサービスの提供・誘導
- ソフトウェアのクラック・キーゲン・シリアルキーの配布
日本語の表現例:
- 「raw」「zip 配布」「pdf 無料」「割れ」「クラック」「keygen」「無料で読める」「全話 無料」「アニメ 無料視聴」「Kindle 無料」「漫画 違法サイト」
Category E - 高度・組織的サイバー犯罪
定義: 犯罪活動の**継続的なサービス運営・大規模インフラ提供・組織的調整**（Crime-as-a-Service）。個別ツールの単体売買は A だが、それをサービスとして運営・提供する構造は E。
含まれるもの
- サイバー攻撃の継続的な代行サービス運営（DDoS 代行、フィッシング代行、スパム配信代行等）
- 組織的なフィッシングキャンペーンの運営（ページ・キット単体の販売は A）
- サイバーマネーロンダリングサービスの提供
- 政治的動機によるサイバー攻撃・ハクティビズムの調整・参加者募集
- テロリストのインターネット利用（リクルート・プロパガンダ）
- 違法オンラインビジネス（闇マーケット・違法カジノ等）の運営・スタッフ募集

ユーザプロンプト

以下の X（旧 Twitter）の投稿を分析し、定義に従ってカテゴリを判定してください。
分析対象
ポスト本文: {text}
出力形式
{{
”category”: ”A” or ”B” or ”C” or ”D” or ”E” or ”null”,
”reason”: ”判定理由の説明（2〜4 文）”
}}

© 2026 Information Processing Society of Japan