実際の攻撃者との対話ログと Big Five による擬似攻撃者 LLM の構築と評価

長山 侑央[1,a)]　久保 颯汰[1]　インミンパパ[2]　吉岡 克成[3]

概要：攻撃者から直接情報を引き出す人的情報収集 (HUMINT) は, 公開情報から得られない脅威情報をもたらす. しかし Telegram 等でサイバー犯罪関連の違法商品を売る攻撃者との対話は, 経験のない調査者に法的・倫理的なリスクを伴う. そこで先行研究は, 大規模言語モデル (LLM) に攻撃者を模擬させ, 実対話の予行とするロールプレイを提案している. しかし先行研究には 2 つの課題がある. 第一に, LLM は実際の攻撃者らしく振る舞う必要があるが, 先行研究では攻撃者らしさの有無が未検証で, その定義も未確立のため, 予行としての効果は明確ではない. 第二に, 反復利用では調査者が同じ人物像に慣れるため多様性が要るが, 先行研究は人物像を固定している. これらの課題を解決するため本研究では, 迷惑メールや SMS の大量送信手段を売る攻撃者を題材に, その対話ログから調査者の質問の種類ごとの答え方を応答の型として抽出し, 性格特性の 5 因子モデル (Big Five) と合わせて擬似攻撃者 LLM を構築する. 攻撃者らしさは定義が難しいため, 対話が実際の攻撃者とのものか擬似攻撃者 LLM とのものかを HUMINT 経験者が区別できるかを調べることで評価した. また, 多様性は, 発話内容に基づき評価した. このうち区別の判定は, HUMINT 経験者 2 名が各 30 対話に対して行った. いずれの対話も調査者は人間であり, 相互の比較を防ぐため 1 つずつ提示し, 判定の理由も記述させた. 2 名のうち, 対話収集や生成に無関与の 1 名の結果を主結果とし, 型作成用対話の収集に関与した 1 名の結果は副結果とする. 主結果は正解率 40% で, 偶然の水準 50% を上回らず, この経験者は今回の対話では両者を区別できなかった. ただしこの結果は, 評価者数と対話数が少ないため, 一般化できない. また, 判定理由は語彙と取引の内容に集中しており, そこにはこの経験者が何を攻撃者らしいと見るかが表れている. そこで判定理由を整理し, 攻撃者らしさの定義を考える材料とした. 人物像の多様性については, 与えた性格の違いが大きいほど, 発話内容の違いも大きくなった. 予行としての効果の測定は今後の課題である.

キーワード：人的情報収集 (HUMINT), 大規模言語モデル, 対話シミュレーション, Big Five

Building and Evaluating a Simulated Attacker LLM Based on Real Attacker Dialogue Logs and the Big Five

Yukihiro Nagayama[1,a)]　Sota Kubo[1]　Yin Minn Pa Pa[2]　Katsunari Yoshioka[3]

Abstract: Human intelligence (HUMINT) yields threat intelligence unavailable from public sources, but dialogues with attackers selling illicit cybercrime goods on platforms such as Telegram expose inexperienced investigators to legal and ethical risks. Prior work therefore proposes role-playing with a large language model (LLM) that simulates an attacker as a rehearsal for real dialogues. Two limitations remain: attacker-likeness is neither verified nor defined, leaving the rehearsal effect unclear; and the persona is fixed, although investigators grow accustomed to it over repeated use. To address these, we target attackers selling bulk spam-email and SMS sending services, and build a simulated attacker LLM from question-specific response patterns extracted from their dialogue logs and Big Five personality traits. Because attacker-likeness is difficult to define, we evaluated it by testing whether HUMINT-experienced evaluators could tell dialogues with real attackers from those with the LLM; diversity was evaluated on utterance content. Two such evaluators each judged 30 dialogues, presented one at a time to prevent comparison, and recorded their reasons; the investigator was always human. The evaluator uninvolved in dialogue collection and generation provides the primary result; the one who collected the pattern-source dialogues is reported separately. Primary accuracy was 40%, not above the 50% chance level: this evaluator could not tell real from simulated dialogues, though with few evaluators and dialogues this cannot be generalized. The reasons cited focused on word choice and transactional content, revealing what this evaluator regards as attacker-like; we organized them as material for defining attacker-likeness. For diversity, larger differences in assigned traits produced larger differences in utterance content. Measuring the LLM's effect as a rehearsal remains future work.

Keywords: Human Intelligence (HUMINT), Large Language Model, Dialogue Simulation, Big Five

© 2026 Information Processing Society of Japan

This paper is work in progress and not peer-reviewed.

1. はじめに

サイバー犯罪のエコシステムの理解には, 攻撃者から直接情報を引き出す人的情報収集 (HUMINT) が有効である. 攻撃者が秘匿する取引条件や手口は, 公開情報の分析 (OSINT) では捉えにくく, 個別の交渉で開示される [1]. こうした交渉は Telegram 等の SNS[2] 上で行われ, サイバー犯罪関連の違法商品が売買されている.

攻撃者を対象とした HUMINT は調査者に高度なスキルを要する. 隠語を理解し, 自身の身元を秘匿し, 法的・倫理的な境界を越えずに情報を引き出す必要がある. 経験の浅い調査者が訓練を経ずに実際の攻撃者と対話することは, 情報収集の成否や, 法的・倫理的なリスクに関わる. また, 不用意な調査は攻撃者の警戒を高め, HUMINT の有効性にも影響し得るため, 実地訓練にも限度がある. そこで先行研究 [1, 3] は, LLM に攻撃者を模擬させ, 実対話の予行とするロールプレイを提案している.

ただし, 予行として機能させるには課題が 2 つある. 第一に, 先行研究 [1, 3] では攻撃者らしさの有無が未検証で, 定義も未確立である. LLM は実際の攻撃者の振る舞いや発言を精度高く模擬する必要があるが, それが未検証のため, 予行としての効果は明確ではない.

第二に, 先行研究 [1, 3] は LLM の人物像を固定しているため, ロールプレイを繰り返すと, 調査者がその人物像や発話の傾向に慣れ, 訓練の効果が落ちるおそれがある. よって人物像には多様性が必要である.

人物像の多様性を生む要素には, 性格, 経歴, 置かれた事情などがあるが, 本研究ではこのうち性格を対象とする. 実際の攻撃者の経歴や事情は知りにくく, 任意に設定すれば根拠のない人物像になる. 一方, 性格は文献に基づいて構成でき, 発話にも反映できる [4] ため, 性格を変えることで人物像に多様性を持たせる.

これらの課題に対し, 擬似攻撃者 LLM に攻撃者としての振る舞いを 2 つ指示する. 1 つ目は人物像の多様性を担う性格であり, 性格特性の 5 因子モデル (Big Five) で構成した性格プロファイルを対話ごとに 1 つ割り当てる. 2 つ目は攻撃者らしさを担う応答の型であり, 実際の攻撃者との対話ログから, 調査者の質問の種類ごとに答え方を整理したものである. このうち応答の型は具体的な言い回しではなく, 応答の内容と分量, その順序という組み立て方で記述する.

この型の抽出には, 実際の攻撃者との対話ログが必要であるが, 著者らは先行研究 [3] の実対話でそれを得ている. そこで本研究では, その相手である, Telegram 上で迷惑メールや SMS の大量送信手段を販売する攻撃者を題材とし, このログを型の抽出に用いる.

評価では, 攻撃者らしさと人物像の多様性の 2 点を確かめる. まず攻撃者らしさは, 定義が難しいため, 対話の相手が実際の攻撃者か擬似攻撃者 LLM かを, HUMINT 経験者が自身の攻撃者像に照らして区別できるかを調べる. これを対話相手の区別実験と呼ぶ. いずれの対話も調査者は人間で, 相互の比較を防ぐため 1 つずつ提示し, 判定の理由も記述させる. 多様性は, 与えた性格プロファイルの違いが発話内容に表れるかで評価する.

このうち区別実験では, 本物の攻撃者側 (以下, 本物側) とする対話ログを, 型の抽出に用いたログとは別に, 第一著者が Telegram 上の販売投稿から新たに収集した. 収集では過去の対話実験 [3] に倣い, 質問や中止の条件を事前に定め, 身元を秘匿して送金先アドレスの取得を目標に交渉を進めた. 集めた対話のうち, 送金先アドレスの取得に至ったもののみを評価に用い, 擬似攻撃者 LLM 側と到達点を揃えた. これに擬似攻撃者 LLM 側を合わせた 30 対話を, HUMINT 経験者 2 名が各自判定した. 2 名のうち, 対話の収集や生成に無関与の 1 名の結果を主結果, 型の抽出に用いた対話の収集に関与した 1 名の結果を副結果とする.

主結果は 30 対話で正解率 40%, 2 択における偶然の水準 50% を上回らず, この経験者は今回の対話では両者を区別できなかった. ただしこの結果は, 評価者と対話の数が少なく, 対話も平均 4.8 往復と短いため, 一般化できない. また, 判定の理由は語彙と取引の内容に集中しており, そこにはこの経験者が何を攻撃者らしいと見るかが表れている. そこで理由を整理し, 攻撃者らしさの定義を考える材料とした. 多様性については, 性格プロファイルごとの発話を比べると, 設定が異なる因子が 1 つ増えるごとに発話内容の違いも大きくなった.

本研究の貢献は, 応答の型を組み立て方として与え, 個体差を性格特性に担わせた擬似攻撃者 LLM の構成事例の報告と, 経験者の判定理由を整理して攻撃者らしさの定義の材料を得たことである.

2. 関連研究

HUMINT と同じく, 対話により情報を引き出す技法は犯罪捜査の面接法として体系化され, 訓練課程も整備されている [5] が, 相手が違法取引の当事者である本研究の対話では, 訓練の場を実環境に求めにくい. またメッセージングプラットフォーム上の取引では, 公開されたチャンネルや投稿を大規模に観測する研究が進んでいる [2] が, 個別の取引交渉における応答は捉えられない. 攻撃者個人につ

[1] 横浜国立大学大学院環境情報学府
Graduate School of Environment and Information Sciences, Yokohama National University
[2] 横浜国立大学先端科学高等研究院
Institute of Advanced Sciences, Yokohama National University
[3] 横浜国立大学大学院環境情報研究院／先端科学高等研究院
Faculty of Environment and Information Sciences, Yokohama National University / Institute of Advanced Sciences, Yokohama National University
[a)] nagayama-yukihiro-py@ynu.jp

© 2026 Information Processing Society of Japan

いても, 取引における信頼の形成 [6] など行動面の観察が中心で, 性格特性を扱った研究は見当たらない. 一方, オンライン上のいじめやなりすましといった加害行為については, Dark Triad にサディズムを加えた Dark Tetrad との関連が報告されている [7]. 本研究は, 他者に害を与える商材の販売も加害行為であることから, これを性格プロファイルの絞り込みの根拠とする (3.1 節).

これに対し, LLM を用いた支援と訓練の枠組みがある. 鈴木ら [1] は, 擬似攻撃者 LLM と調査者役の LLM を対話させる練習環境を提案している. 久保ら [3] は, 調査者の発話案を LLM が提示し人間が採否を決める対話支援を設計し, 擬似攻撃者 LLM とのロールプレイを経て実際の攻撃者との対話実験を行った. ただし久保らは擬似攻撃者 LLM に, 利益を求めるビジネスライクな性格と挨拶を省いたラフな英語という人物像を固定して与えており, 攻撃者らしさは自身が今後の課題としている. 鈴木ら [1] は模倣の忠実さを枠組みの成否に関わる点として挙げるが, 実験で確かめたのはロールプレイの成立と法倫理の遵守であり, 攻撃者らしさは検証していない. 両者とも, 何を基準に攻撃者らしいとするかを示していない. 一方で, 久保らが価格の提示要求から送金先アドレスの要求までの 4 つを固定の質問群として定めている点は, 揃った質問群として応答を比べやすくする. 本研究はこれを含む質問の種類ごとに攻撃者の応答を整理する (3.2 節).

本研究が人物像の多様性の実現に用いる性格は, LLM に与えると発話に表れることが示されている. Jiang ら [4] は, Big Five の 5 因子すべての高低を形容詞としてシステムプロンプトに書き, GPT-3.5 と GPT-4 に性格検査に回答させ, 800 語の物語を書かせた. LLM の自己報告は指定した性格と一致した. 物語からは, 執筆時に自身の性格に触れないよう指示したにもかかわらず, 一部の因子について人が最大 80% の正解率で指定された性格を言い当てた. これは同じ場面でも性格特性によって振る舞いの表れ方が異なるという知見 [8] と併せて, 本研究の設計の根拠となる.

本研究と設定が近いのは SPASM [9] である. 人物像を与えて複数ターンの対話を合成する枠組みで, 対話が長くなるにつれ人物像から外れる persona drift や, 相手の話し方を写し取る echoing を抑える. SPASM は学習支援や相談といった害のない用途で生成の安定性を評価する. 本研究は違法取引を対象に, HUMINT 経験者が実際の攻撃者との対話と区別できるかを評価する.

こうした区別による評価は, 機械の応答を人間のものと見分けられるかを問うた Turing の模倣ゲーム [10] に遡り, LLM に対しても同種の評価がある. Jones ら [11] は, GPT-4 との対話で判定者が人間と判断した割合が 49.7 ただしこの評価は判定者が対話の当事者となる形式で, 人間と機械の応答を並置する形式もある. 本研究が採るのは 1 つの対話だけを見て相手を区別する形式で, 信号検出理論の yes/no 課題 [12] にあたる. 先行の評価は相手が人間か機械かを問うが, 本研究は相手が攻撃者かどうかを問う.

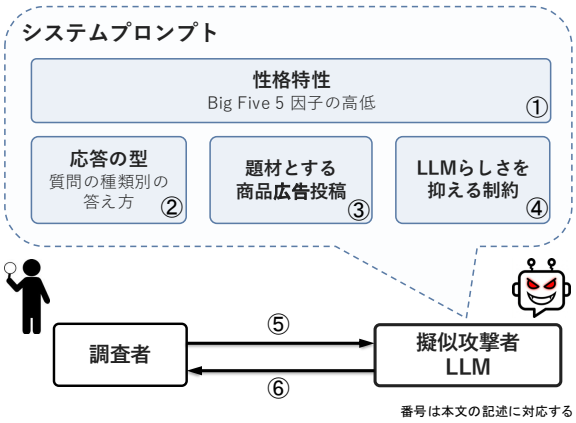


図 1 擬似攻撃者 LLM の構成. ①–④ をシステムプロンプトとして与え, 調査者の発話 ⑤ に対して応答 ⑥ を返す.

これらに対し, 本研究の位置付けは 2 点である. 第一に, 構築の面では, 攻撃者の振る舞いを研究者が設定する久保ら [3] や, 予め定めた属性の枠から人物像を組み立てる SPASM [9] に対し, 本研究は実際の攻撃者との対話ログから抽出した応答の型を組み立て方として与え, 個体差を性格特性に担わせた構成事例を報告する. 第二に, 評価の面では, 攻撃者らしさを定義しないまま LLM を相手に用いてきた先行研究 [1, 3] に対し, 本研究は擬似攻撃者 LLM 自体を経験者の判断にかけ, 挙げられた判定の理由を攻撃者らしさの定義の材料とする.

3. 擬似攻撃者 LLM の構築

1 章で述べた性格特性 ① と応答の型 ② に加え, 題材とする投稿 ③ と LLM らしさを抑える制約 ④ をシステムプロンプトとして与える (図 1). 応答の型は, 実際の攻撃者との対話ログから抽出した, 質問の種類ごとの答え方である. 対話生成時には, 調査者の質問に対応する型に沿って応答し, その書き方を性格特性が方向づける.

3.1 性格特性

擬似攻撃者 LLM の個体差には, 高低の指定が生成文に表れると示された Big Five を性格特性として用いる. 各因子は Jiang ら [4] に倣い, 外向性 (extroverted / introverted), 協調性 (agreeable / disagreeable), 誠実性 (conscientious / unconscientious), 神経症傾向 (neurotic / emotionally stable), 開放性 (open / closed to experience) の対の片方を, 性格プロファイルごとにシステムプロンプトへ記述する. これにより, 5 因子の高低の組合せは 32 通りである.

ただし, その全てが攻撃者にありそうな性格とは限らない. 個々の攻撃者の性格は不明だが, 他者に害を与える商材を売る以上, オンライン上の加害行為や犯罪と関連する Dark Triad および Dark Tetrad (2 章) の特性を仮定する

© 2026 Information Processing Society of Japan

余地はある．そこで, 32 通りのうち, 社会的な悪意を表すマキャベリアニズム, ナルシシズム, サイコパシー, サディズムの 4 特性と両立する組合せに限る．両立するかどうかは, Big Five と Dark Triad [13] および Dark Tetrad [14] の相関を扱う文献をそれぞれ参照して定めた．各特性について, 相関の方向が報告されている因子はその方向に固定し, 報告のない因子は高低の組合せを列挙して, 14 通りへ絞り込んだ．これらの手続きの詳細と一覧は付録 A.1 に示す．これらは実在の攻撃者の性格ではなく, 文献に基づいた実験条件である．

3.2 実際の攻撃者との対話ログに基づく応答の型

応答の型は, 攻撃者が取引交渉で取る振る舞いを規定する．著者らが過去に実施した対話実験 [3] の対話ログ 10 件を対象に, 質問の種類ごとに攻撃者の応答をまとめ, 複数の攻撃者に共通する答え方を型とした．ただし一部の型は, ログの振る舞いを意図的に控えさせている (付録 A.2.2)．

質問の種類は, 接触と活動確認, 地域や数量を指定しない商材の問い合わせ, 価格の提示要求, 購入後の手順の確認, 支払い手段の確認, 送金先アドレスの要求, および詐欺でないことの確認の 7 種である．このうち価格の提示要求から送金先アドレスの要求までの 4 つは, 久保ら [3] が収集目標に直結する質問として定めた固定質問群と同じである．この 7 種のそれぞれについて, 応答に現れた規則性と, それをもとに与えた型を表 A·2 に示す．

これらの型は原則として具体的な言い回しではなく, 応答の内容と分量, その順序という組み立て方で記述する．例えばある攻撃者は, `30k costs $120` から `100k cost$250` までの段階を並べ, `It comes with a console panel` を添えて返している．ここから価格質問時の型を, 価格体系にならって数値を示し, 運用に関わる補足を 1 つまで添え, 売り込みの言い回しを伴わない, と記述した．どの語で書くかは性格特性に応じて擬似攻撃者 LLM が選ぶ．

3.3 題材とする投稿と商材知識

対話の内容は攻撃者の扱う商材や販売条件に左右されるが, これを研究者が構成すると実在しないものになりかねない．そこで, 販売を宣伝している実在の Telegram の公開投稿をシステムプロンプトに与え (7 章), その範囲内で応答させる．区別実験では本物側と投稿が重複すると手掛かりになるため, 擬似攻撃者 LLM 側には実対話で未使用の投稿を別に集めた．さらに, 調査者が言及した商材に応じて応答を切り替えさせる (付録 A.2)．また, 投稿にない仕様や価格体系は LLM 自身の事前学習知識に委ねる．

3.4 LLM らしさの抑制

擬似攻撃者 LLM の応答に残る LLM らしさを減らすため, 用語の解説, 買い手への安心づけや励まし, 顧客対応に特有の定型句, 宣伝的な誇張を禁ずる (付録 A.2.3)．この 4 つは網羅的な分類ではなく, プロンプト作成時の応答を実際の攻撃者との対話ログと比べて, 擬似攻撃者 LLM 側にのみ頻出した表現である．

3.5 擬似攻撃者 LLM の対話生成の手続き

擬似攻撃者 LLM から応答 ⑥ を得るには, 調査者の発話 ⑤ を, それまでの対話全体とともに 1 ターンずつ与える (図 1)．この手順で, 区別実験用と多様性評価用の 2 種類の対話を生成する．区別実験用の対話は投稿 1 件につき 1 つ生成し, 性格プロファイルは 14 通りから対話ごとに無作為に割り当て, 暗号資産の送金先アドレスの取得に至るまで進める．多様性評価用の対話は, 題材と調査者の発話に加えて性格プロファイルの割り当ても設計する．手続きは付録 A.4 に示す．いずれの対話の生成でも, 擬似攻撃者 LLM には gpt-4o-2024-11-20 [15] を用い, temperature は 0.7 とした．

4. 評価

本章では, 擬似攻撃者 LLM が訓練の相手役に求められる 2 つの要件, 攻撃者らしさと人物像の多様性を確かめる．まず攻撃者らしさは, 相手役が実際の攻撃者の振る舞いや発言を精度高く模擬できているかを問う要件であり, 経験者が対話の相手を区別できるかで確かめる (4.1 節)．

人物像の多様性は, 画一的な相手役に調査者が慣れて訓練の効果が落ちるのを防ぐための要件であり, 人物像のうち性格を対象に, 与えた性格の違いが発話内容に表れるかで確かめる (4.2 節)．

4.1 攻撃者らしさ: 対話相手の区別実験

定義を必要としない評価方針

攻撃者らしさは定義されていない．攻撃者像は経験者ごとに異なり, 何が共通するかが不明なためである．評価基準を与えられないため, 定義を必要としない評価として, 経験者が実際の攻撃者との対話と区別できるかを見る．対話を示して実際の攻撃者か擬似攻撃者 LLM かを問えば, 経験者自身が持つ攻撃者像に照らして判断してもらえる．

分析するのは, 経験者が両者を区別できるかと, 何を手掛かりに区別するかである．手掛かりは攻撃者らしさの定義を考える材料になる．経験者が両者を区別できていれば, 手掛かりは実物と模倣を実際に分けている違いである．区別できていなければ, 経験者が持つ攻撃者像である．

評価者

区別は, 対話の生成と収集のいずれにも関与していない HUMINT 経験者に依頼する．経験がなければ参照する攻撃者像がなく, 判断は LLM らしさなど別のものに基づくため, 攻撃者らしさの評価にならない．

区別を行ったのは本稿の著者である経験者 2 名である．

© 2026 Information Processing Society of Japan

一方は上の要件を満たしており, 主結果はこの評価者によるものとする. 以下, 独立の経験者と呼ぶ. もう 1 名は応答の型の抽出に用いた対話ログを自ら収集している. そのログから擬似攻撃者 LLM が作られているため, 応答に既視感をもち, 攻撃者らしさとは別の経路で言い当てうる. 以下, 対話ログを収集した経験者と呼び, 副結果として示す.

評価の手続き

評価者には対話を 1 つずつ提示し, それが実際の攻撃者との対話か擬似攻撃者 LLM との対話かを 2 値で区別させ, 判定の理由も自由記述で求める. 並べて示すと, 対話どうしの相対的な違いが手掛かりになり, 攻撃者像に照らした判断とは別の根拠が入るためである. 収集フォームは対話ごとに理由欄を複数もち, 各欄に自信の有無を記入できる.

本評価は 3 回に分けて実施し, 各回は実際の攻撃者との対話ログ 5 本と擬似攻撃者 LLM との対話 5 本の計 10 対話からなる. この内訳は評価者に伝えた. 本物側は第一著者が新たに収集した対話ログのうち, 暗号資産アドレスの取得に至ったものであり (1 章), 応答の型の抽出に用いたログとは別である. 擬似攻撃者 LLM 側は, 3.5 節の手順で生成した対話であり, 調査者は第一著者が人手で務めた. 各対話は調査者と攻撃者のやり取りが平均 4.8 往復である.

評価用の対話は, 中身以外の差を減らすため同一の処理で描画する. 時刻表示とハンドル名を除去し, 暗号資産アドレスを同一の文字列へ伏字化し, 実際の攻撃者が 1 回の応答を複数のメッセージに分けている場合はこれを 1 つに結合する. 擬似攻撃者 LLM は 1 ターンにつき 1 つの応答を返す実装であり, 最後の処理を行わなければメッセージの分かれ方だけで本物側と区別できてしまう.

評価指標

主指標は評価者ごとの正解率とし, 両側 95% 信頼区間と, 偶然の水準に対する二項検定の p 値を付す. あわせて答えの偏りを除いた感度として信号検出理論に基づく d' を用いる [12]. $d' = 0$ は見分けが生じていないことを表す. 各回の内訳を伝えたため同じ回の判定は互いに影響しうるが, 信頼区間と検定はこれを考慮していない.

評価結果

結果を表 1 に示す. 独立の経験者の正解率は 3 回を通じて 40% であり, 偶然の水準 50% を上回らなかった. 実際の攻撃者側と擬似攻撃者 LLM 側 (以下, 真値の側) のどちらで見ても偶然の水準に近く, 偏りを除いた感度も $d' = -0.48$ にとどまった.

副結果とした対話ログを収集した経験者の正解率は 70% と偶然を上回るが, 擬似攻撃者 LLM と正しく区別した 9 件のうち 6 件は理由が既視感である. 解釈は 5.1 節に述べる.

2 名とも「実際の攻撃者」と答えた回数が多く, 30 件中, 独立の経験者が 17 件, 対話ログを収集した経験者が 18 件である. 真値の側で分けた正解率は付録 A.3 に示す. 同じ対話への判定が一致したのは 43% であり, 評価者をまたいで集計しないのはこのためである.

表 1 対話相手の区別実験の成績 (信号 = 実際の攻撃者)

評価者	1 回目	2 回目	3 回目	計	95%CI*	$p^{\dagger}$	d'
独立の経験者	50	40	30	**40**	[23, 59]	0.36	−0.48
対話ログを収集した経験者	70	70	70	70	[51, 85]	0.043	1.01

正解率の欄の値は % である.
∗ Clopper–Pearson の両側 95% 信頼区間 (%). † 偶然の水準 50% に対する二項検定 (両側) の p 値. d' は loglinear 補正 $(x + 0.5)/(n + 1)$ による.

表 2 判定への自信と正誤 (経験者 2 名・計 60 判定)

	正	誤
自信ありと記した	7	4
自信なしと記した	26	23

自信は理由欄ごとの申告で, 1 判定に 1 つでも付けば自信ありとした. 自信ありの正解率は 64%, 自信なしは 53% である.

判定への自信と正誤の対応を表 2 に示す. 自信ありの 11 件中 4 件が誤りで, 正解率は自信なしと大きく違わない.

判定の理由の分析

経験者 2 名の判定の理由を分類する. 分析単位は評価者自身が分けた理由欄とする. 延べ 60 判定 (2 名 × 30 対話) のうち 47 判定に計 49 件の理由が記入され, これを分析対象とする.

判定の理由は, 文字の並びを指す「表面」, 語の選び方や口調を指す「語彙」, 取引について何を述べたかを指す「内容」, および「その他」の 4 群に分類した. 分類の恣意性を抑えるため, まず Claude Opus 5 を 2 つと Claude Sonnet 5 を 1 つ [16] に, 他の分類結果を渡さず, 記入された理由の文面だけを与えて分類させた. LLM 間の一致率は平均 91.8%, $\kappa = 0.89$ である. そのうえで, 評価に参加していない著者が全件を原文と文脈にあたり分類し, 最終的なラベルとした. LLM との一致率は 79.6–83.7% である.

挙げられた観点は 2 名とも「語彙」と「内容」が中心で, 49 件のうち 36 件を占める.「表面」は 6 件にとどまる. 語彙と内容を挙げた判断の正解率は, 2 名ともその評価者の全体より高い. 表面とその他は件数が少なく, どちらの評価者が挙げたかで値が決まるため読めない. 評価者ごとの内訳と観点ごとの正解率は付録 A.3 に示す.

4.2 多様性の定量評価

評価の目的と対象データ

対話が攻撃者らしくても, 同じ人物像が反復されれば使い続けにくい. そこで, 与えた性格プロファイルの違いが生成された発話に表れるかを確かめる.

対象は擬似攻撃者 LLM が生成した 690 会話である. 全会話が実在の Telegram 投稿 1 件を題材とし, 活動確認から送金先アドレスの要求までの 6 問からなる同一の調査

© 2026 Information Processing Society of Japan

表 3 設計上の性格の違いと, 生成された発話の意味の違い (性格プロファイル 14, 会話 690)

異なる因子の個数	ペア数	意味の違い (平均)
1	23	0.0139
2	33	0.0183
3	25	0.0231
4	9	0.0276
5	1	0.0290

距離は密集しており, 値そのものではなく大小の順序を比べる. 下 2 行はペア数が少なく, 単調性の主な根拠は上 3 行にある.

者スクリプトを用いるため, 発話の違いは題材や質問に由来しない. この投稿は対話相手の区別実験の投稿と重複しない.

評価手法

多様性は 2 指標で測る. 第一は発話量であり, 会話ごとの攻撃者発話の語数をプロファイル単位で平均する. 第二は発話の意味の違いであり, 会話ごとの攻撃者発話を OpenAI の text-embedding-3-small [17] で埋め込みに変換し, 性格プロファイルごとの重心間のコサイン距離として測る. これを Big Five の設計値が異なる因子の個数と対応づけ, 対応の有無を Mantel 検定で判定する. 各指標の定義と手続きは付録 A.4 に示す.

評価結果

プロファイルごとの平均語数は 68.2–87.7 語で, 特定の因子と強く相関しない. 一方, 意味の違いは設計上の性格の違いに対応する. 表 3 のとおり異なる因子の個数が 1 つ増えるごとに単調に大きくなり, Mantel 検定でも支持される ($r = 0.369$, $p < 0.001$).

この対応は発話量と独立である. 意味の違いと平均語数の差の相関は $r = 0.031$, 発話量の寄与を除いた偏 Mantel 相関も $r = 0.368$ と素の値とほぼ変わらない. 埋め込みモデルの選択にも依存せず, 提供元の異なる公開重みを含む 3 種の埋め込みで単調性と有意性が再現された (付録 A.4).

5. 考察

5.1 攻撃者らしさ

独立の経験者は, 実際の攻撃者と擬似攻撃者 LLM との対話を区別できなかった. 内訳を見ると, 擬似攻撃者 LLM との対話 15 本中 10 本を実際の攻撃者と, 実際の攻撃者との対話 15 本中 8 本を擬似攻撃者 LLM と判定している. ただしこの結果は, 擬似攻撃者 LLM が攻撃者らしいことの証拠にはならず, 正解率の 95% 信頼区間も 23–59% と広いため, 一般に区別できないことを示したわけでもない. つまり, この経験者自身の攻撃者像では両者を分けられなかったことを表す.

対話ログを収集した経験者の正解率 70% は偶然の水準を上回るが, 擬似攻撃者 LLM を正しく区別した 9 件のうち 6 件は既視感を理由とする. うち自ら収集したログへの既視感は 1 件で, 残りは評価に用いた対話どうしの類似や見慣れた形である. いずれも攻撃者らしさの判断とは別経路であり, その手掛かりとしては読めない.

そこで手掛かりの整理には独立の経験者の理由を用いる. 区別できたという証拠が得られていない以上, これらはこの経験者が持つ攻撃者像として読む.

整理した結果を表 4 に示す. 取引の中身, 語の選び方, 文字の並びはすべて, 攻撃者らしさとそうでないことの両方の根拠になっており, 一方だけに現れる観点はない. 例外は手掛かりの不在で, これは攻撃者らしさの側にしか現れない. 攻撃者らしさは, 積極的な特徴としてだけでなく, LLM らしさの不在としても語られている. ただし手掛かりの不在を根拠とした判定のうち, 相手が擬似攻撃者 LLM だった 2 件はいずれも誤りである.

以上は, 経験者の攻撃者像を言語化したものであり, 攻撃者らしさの定義を組み立てる材料である. ただし 1 名の言明に基づくため, 経験者の間でどこまで共通するかは本研究では確かめられない.

5.2 手掛かりと判定の対応関係

観点の種類に限れば, 2 名が挙げたものは語の選び方と取引の内容が中心で共通する. それでも同じ対話への判定の一致は 43% である. 2 択では互いを見ずに答えても 5 割ほど一致するため, 2 名の判定は揃っていない. この不揃いは評価者の間にとどまらない. 同じ手掛かりが, 同一の評価者の中でも正反対に使われる. 独立の経験者は, 買い手の `crypto ?` に `crypto only` と返す応答を, 2 つの対話では余計な返しとして擬似攻撃者 LLM と判断し, 別の対話では問いと噛み合っているとして実際の攻撃者と判断している. 実際にはいずれも擬似攻撃者 LLM との対話であり, 擬似攻撃者 LLM とした 2 件は正解, 実際の攻撃者とした 1 件は誤りである.

手掛かりだけでなく, 判定に付された自信でも正誤を予測できない (4.1 節). 自信ありと記して誤った 4 件中 3 件は, 商材の具体性や取引に固有の語を実際の攻撃者の証拠として挙げている. つまり, 前節で攻撃者らしいとされた特徴は, それを挙げた判定の正しさを保証しない. ただし本評価の規模ではそれらの対応の有無までは確定できない.

以上から, 「これを直せば攻撃者らしくなる」という手掛かりの一覧は作りにくい. 実際, LLM らしさは 3.4 節の制約で既に抑えており, それでも残った手掛かりは, 同じ観点を挙げていても判定を分ける方向には働いていない.

5.3 多様性と反復利用

4.2 節が示したのは, プロファイルごとの平均から求めた発話の意味の違いである. 平均で差があっても, 会話単位ではプロファイル間の重なりが大きく, 個々の対話の性格

© 2026 Information Processing Society of Japan

表 4 独立の経験者が挙げた, 攻撃者らしいとされた点とそうでないとされた点

観点	攻撃者らしいとされた	攻撃者らしくないとされた
取引の中身	価格表と購入後の手順を具体的に答える. 商材について答えられる量が多く, 手口に通じていると感じさせる. 買い手の用途を絞り込む問い返しをする (`which smtp are you purchasing?`). 支払い後の段取りまで指示する (`send payment screenshot and stay online`)	何を買うかを聞かない. 問われた以外のことまで答える. 価格が説明なく変わる. 言わなくてよいことを言う (`crypto ?` に対する `crypto only`)
語の選び方	取引に固有の語を説明せずに使う (`shortcode`)	呼びかけ語が揃わない (`Yes ma` と `bro` の併用). 相手との距離感に合わない (`mate`). 言い回しが不自然 (`yean man`). 最初の返信が丁寧すぎる. 短い問いに長く返す
文字の並び	記号の使い方が揃っていない (`?` の前のスペースの有無). 題材とした投稿と会話で絵文字の使い方が一致する	アポストロフィやコンマの使い方が正確である. 行頭がすべて大文字である. 同じ書式を全行に繰り返す
手掛かりの不在	LLM らしい点が見当たらない	—

引用は評価者が名指しした対話中の語である. 観点は 4.1 節の 4 群に対応する.

プロファイルまで見分けられるとは言えない.

この差が反復利用に効くかは, 調査者が「前回と似た相手だ」と感じないで済むかで決まる. 性格プロファイルごとの平均で設計上の性格の違いに対応する差が確認できたことは, そのために必要な違いが生じている可能性を示す.

ただし平均の差は, 個々の対話が違う相手だと感じられることまでは意味しない. 実際, 4.1 節の判定の理由では, 対話ログを収集した経験者が擬似攻撃者 LLM を正しく区別した 9 件中 4 件で, 他の対話との類似を挙げていた. 評価には同じプロファイルの対話が複数含まれるため, この類似がプロファイルを越えたものかは判断できない. それでも, 同一の条件で生成した対話は, 続けて読んだ評価者に似ていると気づかせる程度には似ている. なお, 何回の反復まで慣れが生じないかは測っていない.

5.4 構成法が成り立つ範囲

本研究の構成法は, 調査者の質問の種類ごとに型を作り, 発言例ではなく組み立て方で指示し, 共通の振る舞いを型に, 個体差を性格特性に担わせる, という 3 点からなる. この構成法が成り立つには, 収集目標から調査者の質問群が定まり, 対話ログに攻撃者の反応の傾向が現れることが前提になる. ただし型を作るのは著者の人手であり, 第三者が再現できる手順にはなっていない.

5.5 本研究の限界

本研究の限界は 5 点ある. 第一に, 訓練効果は未検証である. 評価したのは攻撃者らしさと, 与えた性格が発話に表れるかである. 擬似攻撃者 LLM との対話で調査者の技能が高まるか, 実対話の負担が減るかを確かめるには, 未経験の調査者による実験が要る.

第二に, 評価規模が小さい. 独立の経験者は 1 名・各回 10 対話である. もう 1 名は対話の収集に関与し成績も異なるため, 2 名をまとめた正解率は攻撃者らしさの結果としては読めない. 対話も短く, 区別に足る材料が不足していた可能性もある. 正解率の精度を上げるには対話を, 経験者間の共通性を言うには評価者を増やす必要がある. ただし本物側の対話は実在の攻撃者への接触でしか得られず, 接触を重ねるほど調査が相手に知られやすくなり, 以後の収集も調査者の安全確保も難しくなる (7 章). この規模では d' の符号や小さな差は解釈できず, 独立の経験者の $d' = -0.48$ を「擬似攻撃者 LLM のほうが攻撃者らしい」とは読めない.

第三に, 構成要素の寄与を分けていない. 応答の型と Big Five 性格特性を同時に与えるため, 正解率への寄与をいずれにも帰せない. 一方を外した比較は今後の課題とする.

第四に, 対話に偏りがある. 本物側は送金先アドレスの取得に至った対話に限られ, 交渉に応じる攻撃者に偏りうる. 商材もスパム送信が中心で, 他への一般化は確認していない. 擬似攻撃者 LLM 側も単一の LLM とシステムプロンプトによる生成である.

第五に, 多様性評価は単一の投稿と固定質問系列によるため, 題材が変われば絶対値は変わる. また 690 会話は 1 度の生成で, 別の乱数条件での再現は未確認である. 独立な観測単位は会話ではなく 14 の性格プロファイルであり, 対応の有無は言えるが相関係数の値の大きさは論じられない. なお, 2 指標は事前に定めたものではない.

6. おわりに

本研究では, 実際の攻撃者との対話ログをもとに擬似攻撃者 LLM を構成した事例を報告した. 擬似攻撃者 LLM には, 調査者の質問の種類ごとに攻撃者の答え方を, 発言例ではなく組み立て方として応答の型に記述して与え, 個体差は Big Five 性格特性に担わせ, 型に沿った発言の言語化を方向づけた.

攻撃者らしさは定義されておらず, 評価基準を与えられない. そこで 1 つの対話について相手が実際の攻撃者か擬

© 2026 Information Processing Society of Japan

似攻撃者 LLM かを問い, 経験者自身の攻撃者像に照らして区別させた. 主結果とした, 生成にも収集にも無関与の経験者の正解率は 40% で偶然の水準を上回らず, 擬似攻撃者 LLM との対話 15 本中 10 本を実際の攻撃者と, 実際の攻撃者との対話 15 本中 8 本を擬似攻撃者 LLM と判定している. これは擬似攻撃者 LLM が攻撃者らしいことを示さず, 評価者と対話の数が少ないため一般化もできない. 言えるのは, この経験者の攻撃者像では両者を分けられなかったことだけである.

区別できた証拠がない以上, この経験者が挙げた手掛かりは, その攻撃者像として読む. そこで判定の理由を, 攻撃者らしいとされた点とそうでないとされた点に整理した. 取引の中身, 語の選び方, 文字の並びはいずれも両方の根拠として挙がり, 手掛かりの不在は攻撃者らしいという判定にのみ現れて, LLM らしい点が見当たらないこと自体が根拠となっていた. ただし, この理由による判定は, 相手が擬似攻撃者 LLM のときいずれも誤りである.

整理は 1 名の理由記述に基づくため, 経験者間の共通性は確かめられない. 1 人の評価者の中で同じ手掛かりが逆向きに使われた例もあり, これを直せば攻撃者らしくなるという一覧は作りにくい. それでも, この攻撃者像の記述は, 攻撃者らしさの定義を組み立てる材料になる.

与えた性格については, 設定が異なる因子が 1 つ増えるごとに, 性格プロファイルごとの平均で見た発話の意味の違いが単調に大きくなった. 会話単位では重なりが大きく, 個々の対話が別の人物と受け取られるかは未確認である.

今後の課題は, 5.5 節に挙げた限界を含め, 次のとおりである. まず, 対話ログと評価者を増やして評価規模を広げ, 応答の型と性格特性をそれぞれ外した条件と比較して寄与を分離する. 次に, 未経験の調査者を対象として訓練効果と実対話時の負担を測り, 対話ログを読む形式に加えて調査者が自ら対話しながら区別する形式へ広げる. さらに, 型を作る手順を第三者が再現できる形にし, 他の商材や攻撃者の類型でも同じ構成法が成り立つかを確かめる.

謝辞 本研究の一部はＮＥＤＯ（国立研究開発法人新エネルギー・産業技術総合開発機構）の委託事業「経済安全保障重要技術育成プログラム／先進的サイバー防御機能・分析能力強化」（JPNP24003）によるものである.

参考文献

[1] 鈴木涼介，川口大翔，インミンパパ，山岡裕明，吉岡克成：サイバー攻撃者とのテキストベース対話による情報収集フレームワーク ～法と研究倫理への配慮と LLM 活用～, 電子情報通信学会技術研究報告，Vol. 124, No. 422, pp. 391–398 (2025). ICSS2024-119.

[2] Saha Roy, S., Pourabbas Vafa, E., Khanmohammadi, K. and Nilizadeh, S.: DarkGram: A Large-Scale Analysis of Cybercriminal Activity Channels on Telegram, *USENIX Security 2025*, pp. 4839–4850 (2025).

[3] 久保颯汰，長山侑央，インミンパパ，吉岡克成：研究倫理を考慮した Human-in-the-Loop 型 LLM 対話支援による HUMINT の実証実験，電子情報通信学会技術研究報告 (信学技報) (2026).

[4] Jiang, H., Zhang, X., Cao, X., Breazeal, C., Roy, D. and Kabbara, J.: PersonaLLM: Investigating the Ability of Large Language Models to Express Personality Traits, *Findings of NAACL 2024*, pp. 3605–3627 (2024).

[5] Clarke, C. and Milne, R.: National Evaluation of the PEACE Investigative Interviewing Course, Technical Report PRAS/149, Home Office, London (2001).

[6] Ricaldi, R., Marjanov, T., Allodi, L. and Hutchings, A.: Uncovering the Trust Signals Supporting Telegram's Cybercrime Economy, *APWG eCrime 2025*, pp. 1–17 (2025).

[7] Olckers, C. and Hattingh, M. J.: The Dark Side of Social Media: Cyberbullying, Catfishing and Trolling: A Systematic Literature Review, *Society 5.0 Conference 2022*, pp. 86–99 (2022).

[8] Tett, R. P. and Burnett, D. D.: A Personality Trait-Based Interactionist Model of Job Performance, *Journal of Applied Psychology*, Vol. 88, No. 3, pp. 500–517 (2003).

[9] Luo, H. and Laban, G.: SPASM: Stable Persona-driven Agent Simulation for Multi-turn Dialogue Generation, *Findings of ACL 2026*, pp. 8455–8475 (2026).

[10] Turing, A. M.: Computing Machinery and Intelligence, *Mind*, Vol. LIX, No. 236, pp. 433–460 (1950).

[11] Jones, C. R. and Bergen, B. K.: Does GPT-4 Pass the Turing Test?, *Proceedings of NAACL 2024*, pp. 5183–5210 (2024).

[12] Macmillan, N. A. and Creelman, C. D.: *Detection Theory: A User's Guide*, Lawrence Erlbaum Associates, 2nd edition (2005).

[13] Vernon, P. A., Villani, V. C., Vickers, L. C. and Harris, J. A.: A behavioral genetic investigation of the Dark Triad and the Big 5, *Personality and Individual Differences*, Vol. 44, pp. 445–452 (2008).

[14] Gómez-Leal, R., Fernández-Berrocal, P., Gutiérrez-Cobo, M. J., Cabello, R. and Megías-Robles, A.: The Dark Tetrad: analysis of profiles and relationship with the Big Five personality factors, *Scientific Reports*, Vol. 14, p. 4443 (2024).

[15] OpenAI: GPT-4o System Card, `https://arxiv.org/abs/2410.21276` (2024).

[16] Anthropic: Claude Models Overview, `https://platform.claude.com/docs/en/about-claude/models/overview` (2026).

[17] OpenAI: New Embedding Models and API Updates, `https://openai.com/index/new-embedding-models-and-api-updates/` (2024).

[18] U.S. Department of Homeland Security: The Menlo Report: Ethical Principles Guiding Information and Communication Technology Research, `https://www.dhs.gov/sites/default/files/publications/CSD-MenloPrinciplesCORE-20120803_1.pdf` (2012).

[19] Reimers, N. and Gurevych, I.: Sentence-BERT: Sentence Embeddings using Siamese BERT-Networks, *Proceedings of EMNLP-IJCNLP 2019*, pp. 3982–3992 (2019).

[20] Sentence-Transformers: all-MiniLM-L6-v2, `https://huggingface.co/sentence-transformers/all-MiniLM-L6-v2` (2021).

7. 研究倫理

本研究は, 実在する攻撃者との対話によって得たログを

© 2026 Information Processing Society of Japan

用い, かつ攻撃者を模擬するモデルを構築する. 本章では, メンロレポート [18] の 4 原則を指針として, 講じた措置を対象ごとに述べる.

本研究の便益は, 公開情報の分析では到達しにくい取引条件や決済手段の把握と, 実環境に投入する前に調査者が練習できる環境の提供にある. 一方で, 攻撃者との対話には犯罪行為への加担のリスクが伴う. そこで, 違法な取引を成立させないこと, 金銭その他の対価を授受しないこと, 第三者に実害を生じうる情報を要求しないことを運用上の制約とし, これらに抵触しうる時点で対話を中止する手続きを設けている.

応答の型の抽出に用いた対話ログは, 著者らが実施した対話実験 [3] で得られたものであり, 本研究はその二次利用にあたる. 対話相手の区別実験で本物側とする対話ログは, その後に第一著者が追加収集したものである. いずれの収集も購入希望者を装う欺瞞を含み, 対象者の同意を得ない設計である. この設計を含め, 本研究は所属機関の倫理審査委員会の承認を得て実施している.

7.1 対話の相手となった攻撃者への配慮

接触したのは, Telegram の公開グループ上で, 迷惑メールや SMS の大量送信手段, すなわち一括送信の管理画面, 送信元となる SMTP サーバやアカウント, 送信先の名簿などの販売を自ら宣伝している者であり, 犯罪行為を能動的に行っている主体である. 追加収集は 2026 年 7 月に行い, 30 件に接触を試みた. 相手のアカウント設定により送信できなかった 5 件と, 返信の得られなかった 2 件を除く 23 件で対話が成立した. 内訳は, 送金先アドレスの取得まで到達したもの 15 件, 中止の基準に該当したため打ち切ったもの 3 件, 支払いの方式が本研究の想定した手続きに合わず終えたもの 1 件, およびアドレスの取得に至らないまま対話が続かなくなったもの 4 件である.

対話は購入希望者を装って行ったが, 欺瞞は取引条件を聴取するために必要な範囲にとどめている. 具体的には, 調査者が求めてはならない事項を商材ごとに定めている. 侵害されたアカウントの認証情報を受け取ることも求めることもしない, 送信の対象とする国や数量を指定しない, 実在の電話番号や文面を用いた送信試験に関与しない, といった制約である. 相手からこれらに該当する要求を受けた場合, 安全に回避できないときは, その時点で情報の獲得を断念して対話を打ち切る. 価格を尋ねるなどして回避できるときも, 同じ回避を繰り返す必要が生じた時点で打ち切る. 送信する発話は LLM が示した案から調査者が 1 ターンごとに採否を決めており, 自動で送信されるものはない. ただし, 送信した発話に倫理上の問題がなかったことの確認は調査者によるものにとどまり, 独立の監査は受けていない.

インフォームド・コンセントは取得していない. メンロレポートは, 同意の取得が研究の遂行を著しく困難にする場合に免除を認めている. 目的を開示して同意を求める接触では攻撃者が警戒して離脱するという先行研究の知見を根拠に, 久保ら [3] は自らの設計がこの免除の要件に該当すると整理しており, 本研究の追加収集もこの手続きに倣っている. 事後に研究目的と欺瞞を明かすデブリーフィングも実施していない. 稼働中の犯罪行為主体にこれを行えば, 調査への警戒を高めるうえ, 調査者への追跡や報復を招き, 対象者と調査者の双方のリスクをかえって高めうるためである.

7.2 第三者および社会への配慮

販売の対象には, 侵害されたとみられるアカウントなど第三者の資産が含まれる. 本研究は攻撃者の言及を記録したのみであり, 購入・アクセス・再利用はいずれも行っていない.

擬似攻撃者 LLM 自体も, 使い道によっては害をもたらしうる. 攻撃者を模擬する能力は, 訓練の相手役としても, 詐欺的な勧誘の自動化としても使えるためである. 本研究は前者を目的とし, 生成した対話は評価にのみ用いて実在の第三者へ送信していない.

システムプロンプトについては, 構成と主要な制約を 3 章および付録 A.2 に示し, 全文は本稿には掲載しない. 全文には, 付録に示したものより細かい言い回しの指定が含まれ, 機械による発話と気づかれにくくする用途へ転用しうる.

7.3 調査者への配慮

攻撃者との対話には, 追跡や報復といった調査者側のリスクが伴う. 調査者は購入希望者を装う匿名のアカウントを用い, 実名・所属・個人を特定しうる情報を対話中に開示していない. 一連の対話は仮想環境上で実施し, 研究者が所有する機器への影響を避けた. また, 中止の基準に該当する要求を受けた場合の扱いを事前に定めている. ただし, 最終的な適用の判断は対話中の調査者に委ねられる. さらに追加収集は 1 名で実施しており, 久保ら [3] が述べる 2 名での相互確認による負担の軽減は, この部分については得られていない.

同じコミュニティで接触を重ねるほど, 調査が行われていることは攻撃者の側に知られやすくなる. これは以後の収集を困難にするだけでなく, 調査者への追跡の手掛かりにもなる. 収集する対話の数は, 研究上必要な範囲にとどめている. 本物側の対話ログを容易には増やせないことは, 評価規模の制約でもある (5.5 節).

7.4 評価者への配慮と取得データの管理

対話相手の区別実験の評価者には, 参加の可否を判断するために必要な説明を事前に行い, 自由意思により参加を得た. 各対話の真値と判断の正誤は課題の終了まで開示し

© 2026 Information Processing Society of Japan

ていない. 経験者 2 名は本稿の著者であり, 関与の別を明示したうえで成績を分けて報告している.

取得したデータのうち, 攻撃者のハンドル名, 連絡先, 暗号資産アドレスなど個人または口座を特定しうる情報は, 研究用データセットから分離して管理する. 評価者に提示した対話ではハンドル名を除去し, 暗号資産アドレスを同一の文字列へ伏字化しており (4.1 節), 本稿および評価者への提示物には, 実在の識別子を復元できる形では含めていない. 送金先アドレスや悪用されているインフラの情報は研究目的にのみ用い, 外部への提供は行わない. これらのデータは研究室が管理するサーバに保管し, アクセスできるのは第一著者と研究室の管理者に限る. 保存期間は定めていない. 本物側の対話ログは, 対象者の同意を得ておらず個人を特定しうる情報を含むため公開しない. 擬似攻撃者 LLM が生成した対話は要請に応じて提供する.

付　　録

A.1　性格プロファイルの絞り込み手続きと一覧

3.1 節で述べた絞り込みは, Big Five と Dark Triad の相関を扱う先行研究 [13] および Big Five と Dark Tetrad の相関を扱う先行研究 [14] の 2 文献を参照して行う. 手順 1 から 3 は 2 文献のそれぞれについて独立に実施し, 手順 4 で両者の結果を統合する.

(1) 当該の文献が扱う悪意ある性格特性それぞれについて Big Five 各因子との相関を確認する.

(2) 相関の方向が報告されている因子は, その方向に沿って高低を固定する.

(3) 相関が報告されていない因子は自由因子とし, 自由因子のみを対象として高低の組合せを列挙する. 列挙された各組合せは, いずれも当該の悪意ある性格特性と両立する Big Five の高低である.

(4) 2 文献から得られた組合せを通して比較し, 同一の組合せを 1 つの性格プロファイルとして統合する.

手順 4 で統合が生じるのは, 4 つの悪意ある性格特性が互いに独立ではないためである. 文献 [14] は, これらが操作的であることや共感の欠如といった共通の核を持ち, 複数の特性が協調性の低さと関連することを報告している. 同文献における 4 特性間の相関は $r = 0.29$ から 0.71 である. このため Big Five との相関により固定される因子が特性間で重なり, 異なる特性と両立する組合せとして同じ高低が現れる. 例えば E+, A−, C−, N+, O+ の組合せは, Dark Triad に関する文献ではマキャベリアニズム・サイコパシー・ナルシシズムのいずれとも両立し, Dark Tetrad に関する文献ではマキャベリアニズム・サイコパシー・サディズムのいずれとも両立する. これらを 1 つの性格プロファイルとして扱う. なお 4 つの特性のうちサディズムは Dark Tetrad のみで扱われるため, 両文献の知見を組み合わせて参照している.

この手続きにより得られた 14 通りの性格プロファイルを表 A·1 に示す. 表中の Dark Triad 列および Dark Tetrad 列は, 当該のプロファイルが各文献においてどの悪意ある性格特性と両立するかを表す. なお, システムプロンプトに含めるのは Big Five 5 因子の高低のみであり, 「マキャベリアニズム」などの特性名は含めない.

表 A·1　絞り込んだ 14 通りの性格プロファイル

No.	Dark Triad 対応	Dark Tetrad 対応	E	A	C	N	O
1	M, P, Na	M, P, Sa	+	−	−	+	+
2	M, P, Na	M, Sa	+	−	−	+	−
3	M, P	—	−	−	−	+	+
4	M, P	—	−	−	−	+	−
5	P, Na	M, P, Na, Sa	+	−	−	−	+
6	P, Na	M, Sa	+	−	−	−	−
7	P	—	−	−	−	−	+
8	P	—	−	−	−	−	−
9	Na	M	+	−	+	+	+
10	Na	M	+	−	+	+	−
11	Na	M, Na	+	−	+	−	+
12	Na	M	+	−	+	−	−
13	—	Na	+	+	+	−	+
14	—	Na	+	+	−	−	+

Big Five 各因子の表記は E: 外向性, A: 協調性, C: 誠実性, N: 神経症傾向, O: 開放性 である. + は対義語対の前者 (extroverted, agreeable, conscientious, neurotic, open to experience), − は後者を表す. M はマキャベリアニズム, P はサイコパシー, Na はナルシシズム, Sa はサディズムを表す. No. は表内で参照するための通し番号であり, 順序に意味はない.

A.2　擬似攻撃者 LLM の設計の詳細

A.2.1　応答の型の一覧

3.2 節で述べた 7 種の応答の型を表 A·2 に示す. 調査者の質問は収集目標に沿って毎回似た流れをたどるため, 質問の種類が定まる. 対話ログでは, その各種類に対する攻撃者の応答にも共通する組み立て方が見られた. 表の「応答に現れた規則性」列がログから読み取ったこの共通点であり, 「与えた型」列は, それをもとにシステムプロンプトへ記述した内容を要約したものである. 型は原則として具体的な言い回しではなく, 応答の内容と分量, その順序として記述しているが, 一部には言い回しの例や回数の指定が残っている.

A.2.2　応答の型の与え方に関する設計判断

3.2 節で述べた設計を採る理由は次の通りである. 第一に, 各型を言い回しとしてではなく応答の組み立て方として記述するのは, 特定の言い回しが全会話に反復して現れることを避け, かつ性格特性による個体差が文体に表れる余地を残すためである. 第二に, 型を性格プロファイルご

© 2026 Information Processing Society of Japan

表 A·2 実際の攻撃者の応答に現れた規則性と, それをもとに与えた応答の型

#	調査者の質問	応答に現れた規則性	与えた型
1	接触と活動確認	挨拶を返さず, 最小限の肯定に続けて商材を絞り込む問いを 1 つ置く (`Which country sms do you need?` 等)	最小限の肯定を返し, 続けて商材に合う絞り込みの問いを 1 つ置く
2	地域や数量を指定しない商材の問い合わせ	扱える候補を挙げるか, 予算または数量を問い返して条件を確定させる (`How many volume are you looking to send?` 等)	自信のある候補をいくつか挙げるか, 予算または数量へ問いを戻す
3	価格の提示要求	その商材で用いられる価格体系 (段階制, 名前付きプラン, 国別, 月額) の形で数値を並べ, 売り込みの言い回しを添えない. 運用に関わる短い補足を 1 つ添えることがある	その商材で実際に用いられる価格体系の形で数値を示す. 宣伝文句や「必要なものを教えてください」といった売り込みの言い回しを添えない. 運用に関わる短い補足 (管理画面が付く, 月額である, 認証情報が付く) を 1 つだけ添えてよい
4	購入後の手順の確認	所要時間を先に述べてから手順に移る (`It takes 20-30 min` 等). その後は設定と案内を述べる個体が多く, 残高の投入 (`you load up`) に触れる個体もある	所要時間を先に述べ, 次に残高の投入といった手順を示し, 最後に案内する
5	支払い手段の確認	暗号資産のみを受け入れる. 受け入れる通貨を反射的に複数並べる個体が多い (7 件中 5 件)	暗号資産での支払いに対応していることを述べる. 受け入れる通貨は攻撃者ごとに 1–2 種に固定し, 反射的に複数を並べない
6	送金先アドレスの要求	アドレスの行はアドレスのみで装飾されないが, 別の行で通貨やネットワークを示したり入金確認を求めることが多い	アドレスの行はアドレスのみとし, 装飾しない. 通貨やネットワークの表記, 入金確認の依頼を反射的に添えない
7	詐欺でないことの確認	短い断りを入れるか, 平板な自信を示すか, 実績に触れる. 該当する場面が現れるログは少ない	短い断りを入れるか, 平板な自信を示すか, 実績に触れる. 型に合わない限り, 証拠の画像をでっち上げない

引用は実際の攻撃者との対話ログの語であり, プロンプトの文言ではない. 「n 件中 m 件」は, 当該の質問が実際に現れたログ数を分母とする. 5 と 6 の 2 種は, ログに現れる規則性をそのままではなく, 意図的に控えさせた形で与えている. その理由は A.2.2 節に述べる. これは 3.4 節の, ログには現れない LLM らしさを抑える操作とは別のものである. このほかシステムプロンプトには, 取引を前進させる振る舞いなど, ログに由来しない補助的な型を 2 種与えている (A.2.2 節).

とに割り当てず, すべてのプロファイルに共通のものとして与えるのは, 型が攻撃者に共通する骨格であり, 個体差は言い回しに表れると考えるためである. どの型に沿うかは調査者の質問で定まる. 第三に, 取引を前進させる振る舞いを型とは別に指示する. 実際の攻撃者は調査者の問いに答えるだけではなく, 見積りに必要な情報を早い段階で引き出し, 取引が動き始めた後は問い返しをやめて情報を提示する側に回るためである. 第四に, 性格特性が規定するのは相手にどのような態度で応じるかと文体であって, 攻撃者としての役割そのものではないことを制約として与える. これは, プロンプトを作る過程で, 協調性の高いプロファイルが助言や気遣いを行う応対へ寄る挙動が観察されたことによる.

表 A·2 の 5 と 6 の 2 種でログに現れる規則性を控えさせたのは, 本評価に先立つ予備の評価で得た次の観察による. 支払い手段から送金先アドレスの要求に至る局面が, 性格プロファイルによらず同一の文面へ収束していた. この局面だけがシステムプロンプトの 5 箇所で重複して指示され, 原文をなぞる手順書になっていた. そこで重複した指示を削り, あわせて受け入れる暗号資産は攻撃者ごとに固定された 1–2 種であるという記述を加えた. 評価とは別に用意した投稿を題材とする 28 件の生成では, 暗号資産を 3 つ並べて挙げる応答が 24 件から 0 件になった. ただし重複した指示を削るだけの中間の版では 27 件であり, この変化は後者の記述によるものである. なお本研究は, 評価結果に現れた手掛かりをプロンプトの改善に用いない方針を採っている. この定型化を例外として扱ったのは, 本評価に用いた対話とは別に, 評価に用いていない投稿を題材とした生成でも再現する性質だったためである. 本評価に用いた 30 対話はこの修正の後に生成しており, 題材はこの過程での生成と重複しない.

3.3 節で述べた商材の切り替えの指示は, 買い手が投稿の主たる商材とは別の商材を挙げた場合に, 擬似攻撃者 LLM が主たる商材へ話題を引き戻してしまう挙動が観察されたことによる.

A.2.3 LLM らしさを抑える制約の具体例

3.4 節の 4 つの制約について, システムプロンプトで禁じた言い回しを挙げる. いずれも著者が対話ログ 10 件を読んだ範囲では見られなかった表現であり, 擬似攻撃者 LLM

© 2026 Information Processing Society of Japan

の側で禁じている.

用語の解説 商材や用語の説明を求められても解説しない. 例えば `what is smtp?` に対し定義や手順を述べず, `you new?` のように受け流すか数語で答える.

安心づけと励まし `you'll manage it fine` / `don't worry` / `it's easy` / `setup is straightforward`. 買い手が安全性や追跡の可能性を気にした場合も, なだめずに短い断定を 1 つ返すか, 取引の条件へ差し戻す.

顧客対応に特有の定型句 `no worries` / `no issues` / `happy to` / `feel free` / `anything else` / `hope that helps` / `no problem`. とくに価格を示した直後の `Let me know what you need` を禁じる.

宣伝的な誇張 `industry-leading` / `top-notch solution` / `competitive pricing` / `global reach` / `boost your campaign`. 題材とする投稿の宣伝文句をそのまま再掲することも禁じる. ただし品質への短い言及は, 自身の言葉で一度だけ述べることを許す.

A.3 対話相手の区別実験の詳細

本付録は 4.1 節の詳細である.

評価に用いた対話

擬似攻撃者 LLM 側の応答はいずれも 1 回の生成をそのまま用いており, 生成のやり直しや複数の生成からの選抜は行っていない. 題材とした投稿は本物側の対話と重複しない.

正解率の非対称性

真値の側で分けた正解率を表 A·3 に示す. 経験者 2 名とも, 実際の攻撃者側の正解率が擬似攻撃者 LLM 側を上回った. ただしこれは見分ける能力の非対称ではなく, 2 名の判断がいずれも「実際の攻撃者」の側へ偏っていることの帰結である. 実際, 独立の経験者は実際の攻撃者側でも偶然を上回っておらず, 一方の側に偏って答えたことで見かけ上高くなっているにすぎない. 感度 d' はこの偏りを除いた量である.

表 A·3 真値の側で分けた正解率 (各側 15 対話)

評価者	実際の攻撃者側	擬似攻撃者 LLM 側
独立の経験者	7/15	5/15
対話ログを収集した経験者	12/15	9/15

評価者ごとの内訳

判定の理由が指していた観点の内訳を表 A·4 に示す.

表 A·4 判定の理由が指していた観点. 理由欄 1 つを 1 件として数え, 括弧内は各行の件数に占める割合を表す

評価者	件数	表面	語彙	内容	その他
独立の経験者	23	5 (22%)	8 (35%)	8 (35%)	2 (9%)
対話ログを収集した経験者	26	1 (4%)	10 (38%)	10 (38%)	5 (19%)
計	49	6 (12%)	18 (37%)	18 (37%)	7 (14%)
同じくその正解率		2/6 (33%)	12/18 (67%)	13/18 (72%)	2/7 (29%)

「表面」= 文字の並び方, 「語彙」= 語の選び方・言い回し・口調, 「内容」= 取引について何を述べたか (述べなかったかを含む), 「その他」= 特定の観点を指していないもの. 正解率は当該の観点を挙げた判断のもので, これも理由欄を単位として数えている. 表面は 6 件中 5 件が独立の経験者, その他は 7 件中 5 件が対話ログを収集した経験者によるものであり, 値が低いのが観点のためか, 挙げた評価者がもともと当てにくいためかは読み取れない. なお独立の経験者は 1 欄に複数の観点を書き込む傾向があり, 1 欄の平均は 67.9 字である. この場合は判定に最も用いたと読める観点を割り当てた. 対話ログを収集した経験者は 1 欄 1 観点でほぼ記入しており, 1 欄の平均は 29.2 字である.

観点ごとの正解率

表 A·4 の正解率を真値の側で分けると, 「内容」は実際の攻撃者側の 11 件中 9 件が正解であるのに対し, 擬似攻撃者 LLM 側は 7 件中 4 件にとどまる. 「語彙」は逆に擬似攻撃者 LLM 側が 9 件中 7 件で, 実際の攻撃者側の 9 件中 5 件を上回る. 「その他」は擬似攻撃者 LLM 側の 5 件がすべて誤りであり, 5 件とも「実際の攻撃者」と判定されている. なお集計の単位は理由欄であり, 1 つの判定が複数の欄を伴う場合があるため, 判定を単位とした独立性は満たされない.

A.4 多様性の定量評価の詳細

本付録は 4.2 節の詳細である.

A.4.1 評価対象データの条件

調査者スクリプトの 6 質問は, 活動確認 → 商材 → 価格 → 手順 → 支払い → アドレスである. 調査者の発話は固定の文字列であり, 相手の応答に適応しない. 題材とした投稿は, 一括送信に用いられるサービスを扱うものである. 690 会話は性格プロファイルを無作為に割り当てたものではなく, Big Five の 1 因子のみが異なるプロファイルの対を組み, 各条件を 15 回反復して生成した. この設計のため, プロファイルごとの会話数は 30 から 75 と一様でない. 本評価の統計的な単位は会話ではなく性格プロファイルであり, 後述の Mantel 検定の置換も性格プロファイル単位で行う.

© 2026 Information Processing Society of Japan

A.4.2　指標の定義

本節では 4.2 節で用いた 2 つの指標の定義と算出の手続きを述べる.

発話量は, 各会話における攻撃者発話を結合し, 小文字化して伏字の角括弧部分を除いたうえで, 英字語 (`[a-z']+`) の出現数を数えたものである.

本文で発話の意味の違いと呼んだ量は, 次の手続きで得る意味的距離である. 各会話の攻撃者発話を結合し, OpenAI が提供する埋め込みモデル text-embedding-3-small により意味を表すベクトルへ変換する. これを L2 正規化した上で性格プロファイルごとの重心を求め, 重心間のコサイン距離を性格プロファイル間の意味的距離とする. 埋め込みに与えるのは攻撃者側の発話のみであり, 調査者の発話は含めない. コサイン距離の絶対値は, 全会話が同一の題材と質問系列を通るため密集しており解釈できない. 本評価が用いるのは距離の順序である.

設計値との対応は Mantel 検定により判定する. 性格プロファイル間の意味的距離行列と, Big Five の高低が一致しない因子の個数を要素とする距離行列との Spearman 相関を統計量とし, 14 の性格プロファイルのラベルを行と列で同時に並べ替える置換により片側の p 値を得る. 置換は 2000 回行い, 統計量が実測値以上となった回数を m として $p = (m+1)/2001$ とする. 置換の単位を性格プロファイルとするのは, 91 のプロファイルペアが互いに独立でないためである. 本文で $p < 0.001$ と記した値は $m = 0$ の場合であり, 置換回数から言えるのは $p \leq 0.0005$ までである.

発話量は設計した性格から生じる表出の一部であるため, これを差し引いてもなお対応が残ることを 2 通りで確かめる. 第一は, 4.2 節に示した偏 Mantel 相関 $r = 0.368$ である. 第二に, 埋め込みの各次元を発話量に回帰した残差から重心を求め直すと, Mantel 相関は $r = 0.307$, $p = 0.007$ となり, 値は下がるが対応は残る. 回帰には, 標準化した語数の 1 次および 2 次の項を用いた.

A.4.3　結果の頑健性

設計上の違いの個数に対する意味的距離の対応は, 以下のいずれの条件でも同じ向きに保たれた. 単調性と有意性まで確かめたのは埋め込みモデルの 3 種である.

- **埋め込みモデル**: text-embedding-3-small (1536 次元, 本文の値, $r = 0.369$), text-embedding-3-large (3072 次元, $r = 0.361$), および提供元の異なる公開重みとして Sentence-BERT [19] の枠組みで公開された all-MiniLM-L6-v2 [20] (384 次元, $r = 0.340$) の 3 種. いずれでも単調性と有意性 ($p \leq 0.001$) が再現された. 生成と埋め込みで同一の提供元を用いることの影響を見るため, 最後の 1 つを別系統から選んでいる.
- **重心の定義**: 平均・成分ごとの中央値・幾何中央値の 3 通り. 91 ペアの距離の順位は互いに $r = 0.996$–0.997 で一致した.
- **発話量分布の均衡**: 性格プロファイル間で発話量の分布を揃えた部分標本でも Mantel 相関は $r = 0.330$ である.
- **極端なペアの除外**: 5 因子すべてが異なる唯一のペアを除いた場合の Mantel 相関は 0.358 であり, 除く前の 0.369 とほぼ同じである.

© 2026 Information Processing Society of Japan