AIエージェントを用いたDFIR/OSINT調査における証跡対応関係の劣化測定とlint強制による抑止

古川 凌也[1,a)]　津田 侑[3]　渡邉 卓弥[1]　高田 雄太[1]　熊谷 裕志[1]　神薗 雅紀[1,2]

概要：DFIR/OSINT 調査で AI エージェントが生成・更新する記述を検証するには，資料ページ，ログ行，画像領域等の根拠位置を追跡できる必要がある．しかし，要約・書換えを反復すると，記述と根拠位置との対応関係は失われ得る．本稿では，この対応関係の劣化を測定するとともに，原資料・調査ノート・スキーマの三層からなる調査知識バンドルを提案する．調査所見を根拠位置（locator）に対応付け，引用欠落・参照不能等の構造的不整合を決定論的検査（lint）で検出し，違反を含む更新を却下する．公開データと合成例からなる 7 事例 117 問を，複数の知識表現・検索方式と 8 種類の LLM で評価した結果，正しい資料に到達できても根拠位置だけが失われる非対称な劣化を全モデルで観測した．一方，提案方式では，保持した locator の再利用により CTI 事例の根拠位置再現率を 86–92%に維持し（locator 除去では 0%），lint 強制により非強制時に最大 46%だった構造的違反を全 8 モデル・全ラウンドで 0%に抑えた．確認済みの根拠位置は，再推論させる情報ではなく調査状態として保持すべきである．

Measuring and Mitigating Claim-to-Evidence Correspondence Degradation in AI-Agent-Assisted DFIR/OSINT Investigations via Lint Enforcement

Ryoya Furukawa[1,a)]　Yu Tsuda[3]　Takuya Watanabe[1]　Yuta Takata[1]　Hiroshi Kumagai[1]
Masaki Kamizono[1,2]

Abstract: Verifying findings that AI agents generate and update in DFIR/OSINT investigations requires tracking evidence locations: document pages, log lines, or image regions. However, repeated summarization and rewriting can break this correspondence. We measure this degradation and propose a three-layer bundle of raw sources, notes, and a schema. It links each finding to a locator, while deterministic lint detects structural inconsistencies (missing citations, unresolvable references) and rejects violating updates. Across seven cases and 117 questions from public and synthetic data, multiple knowledge representations, retrieval methods, and eight LLMs, all models showed asymmetric degradation: only evidence locations were lost, even when the correct sources remained reachable. Removing only the locators while keeping sources reachable cut recall from 86–92% to 0% in the CTI case. In iterative writes, the share of findings with structural violations reached 46% without enforcement but 0% with lint across all eight models and rounds. Verified evidence locations should persist as investigation state rather than be re-inferred.

1. はじめに

デジタルフォレンジック・インシデント対応（DFIR）やオープンソースインテリジェンス（OSINT）の調査は，新資料の追加や検証に伴い収集・分析・報告の工程を繰り返す反復的なプロセスである [1,2]．この過程では，PDF・画像・ログ等の収集資料に加え，調査メモ・派生情報等の多

[1] デロイト トーマツ サイバー合同会社,
Deloitte Tohmatsu Cyber LLC
[2] 一般社団法人デロイト トーマツ戦略研究所,
Deloitte Tohmatsu Strategy Institute
[3] Turnt Up Technologies 株式会社,
Turnt Up Technologies, Inc.
[a)] ryoya.furukawa@tohmatsu.co.jp

© 2026 Information Processing Society of Japan

This paper is work in progress and not peer-reviewed.

形式のファイルが蓄積される．調査結果を検証するためには，調査所見がどの資料のどの箇所に基づくかを追跡できる必要がある．本稿では，調査の入力として保持する収集資料を**原資料**，原資料のうち調査記述を支持するものを**根拠資料**，根拠資料中で当該記述を支持するページ・行・画像領域等を**根拠位置**（locator），調査記述と根拠位置との対応関係を**証跡対応関係**と呼ぶ．

AI エージェントは，要約・検索・報告書の作成等，調査作業を支援できる一方，誤生成や根拠の曖昧さが報告されている [3, 4]．AI 出力を調査結果として採用するには，調査者が原資料に遡り，記述の妥当性を検証できる必要があるが，反復的な要約・書換えは証跡対応関係を損ない，根拠位置に遡れない記述を混入させ得る [5]．また，検索拡張生成（RAG）は，問い合わせごとに検索と回答を再構成するため，確認済みの根拠位置は保持されない．AI 出力の文単位の引用評価はあるが [6]，AI エージェントが反復的に読み書きする調査の記録（以下，**調査知識**）において，証跡対応関係が維持されるかは十分に評価されていない．

そこで本稿では，DFIR/OSINT 調査における証跡対応関係を維持するため，調査で生じるファイルや記録を原資料層・調査ノート層・スキーマ層の三層に分離して管理する調査知識バンドル（事案ごとのファイル群）を提案する．提案方式では，調査所見を Claim として調査ノートに記述し，各 Claim に根拠資料を参照する Artifact と，根拠位置を示す locator を対応付ける．さらに，根拠位置の欠落や参照不能等の構造的不整合を規則で検出する**決定論的検査**（lint）を更新時に強制する．提案方式は LLM Wiki パターン [7] の操作ループ（ingest/query/lint）と OKF（Open Knowledge Format）互換表現 [8] を基に，操作に **update** を加えて拡張する．これにより，原資料を不変に保持しつつ，証跡対応関係の構造的不整合を lint で検査しながら調査ノートを反復的に更新できる．

評価では，同一の資料と質問を用い，知識表現・検索方式を変えた条件で AI に回答させ，得られた引用付き回答を比較する．比較対象には，原資料の直読み，locator を持たないノート型表現，RAG による都度検索等を用いる．読込み評価では，根拠資料へ到達できた割合を**資料到達率**（SR），根拠位置の**再現率**（LR）・**適合率**（LP），根拠が資料中に存在しない質問を明示的に棄却できた割合を**根拠不在棄却率**（URR）として測定する．書込み評価では，lint 強制の有無を変えた反復書込みにおいて，決定論的 lint が違反を検出した Claim の割合を**根拠なし記述率**（UCR）として測定する．

本研究では，次のリサーチクエスチョンに取り組む．

RQ1：劣化の測定 – AI による読み書きで，証跡対応関係にどのような劣化が生じるか．

RQ2：lint 強制の効果 – lint 強制は，反復書込みにおける証跡対応関係の劣化をどの程度抑止するか．

RQ3：locator 保持の効果 – locator の保持は，他の方式と比較して証跡対応関係をどの程度維持できるか．

RQ4：境界条件 – 資料形式・知識表現・モデルの違いに対して，locator 保持はどの条件で有効か．

本研究の貢献は次の 3 点である．第一に，証跡対応関係の劣化を読み書き両面から測定する評価枠組みを定式化した．第二に，Claim と Artifact・locator を対応付け，原資料の来歴を機械可読に管理し，更新時に決定論的 lint を強制する OKF 互換の三層知識バンドル方式を提案した．第三に，7 事例 117 問・8 種類の LLM で提案方式を複数の知識表現・検索方式と横断的に比較し，資料到達率が 100%のまま locator 除去で根拠位置の再現率が 86–92%から 0%に低下する非対称な劣化と，非強制条件で最大 46%に達した根拠なし記述を lint 強制が全 8 モデル・全ラウンドで 0%に抑えることを示した．

2. 関連研究

AI エージェントとその評価: DFIR/OSINT に対する AI エージェントの導入が提案されている [9, 10]．AI エージェントの評価も，回答の正誤にとどまらず，多段の推論における課題の部分的な達成状況やツール使用の適切性を評価指標に含めるなど，精緻化が進んでいる [4, 11]．

調査知識の構造化・表現方式: STIX [12] や CASE/UCO [13] は脅威情報や証拠情報の厳密な構造化・交換を担い，報告書から攻撃主体・マルウェア・IOC 等の要素や攻撃手法を自動抽出する研究も進んでいる [14]．AI エージェントの長期記憶では，原資料と導出事実が混在し，情報の出所を追跡しにくくなる問題が指摘されており [15]，記憶項目に型を与え，原資料に支持された主張だけを利用する方式 [16] が提案されている．

根拠を用いた検索・生成: 引用付き生成の評価は一般ドメインで進展している [6]．RAG [17] は外部資料を検索して回答生成に利用し，VisRAG [18] は文書をページごとに画像化し，検索対象に含める．EviReport [5] は生成する報告書の記述と根拠を対応付ける手法を扱う．

実務標準とツール: ICD 203 [19] は基礎情報と分析者の判断の区別を，ICD 206 [20] は出典の一意な特定・読者による再取得・該当ページの提示を，ISO 21043 [21]・ISO/IEC 27037 [22]・NIST SP 800–86 [2] は証拠保全の連鎖（chain of custody）を含む証拠の取扱い・保全・報告の要件を定める．一方，Timesketch [23] や W3C PROV [24] はタイムライン管理・来歴表現を支援する．

以上より，本研究は既存研究に対し，(1) AI エージェントの調査能力ではなく証跡対応関係の維持を評価対象とする点，(2) 一般的な構造化・長期記憶に対し，DFIR/OSINT 調査に必要な媒体別の根拠位置・来歴を永続化する点，(3) 検索・生成時の根拠利用に加え，確認済みの根拠位置を反復的な更新・問い合わせで再利用する点，(4) 根拠位置・来

© 2026 Information Processing Society of Japan

歴を一体として保持する方式を定め，構造的不整合を決定論的に検査する点，の 4 点で異なる．また，本研究では実務標準が求める事項のうち，原資料と調査所見の区別，出典の一意な識別，該当箇所の参照，来歴の記録を踏まえてスキーマ層を設計する．

3. 提案方式

提案方式は，証跡対応関係の劣化を抑止するため，証跡対応関係を来歴とともに機械可読形式で保持する．更新時には lint により構造的不整合を含む更新を却下し（3.3 節），問い合わせ時には保持した locator を再利用して根拠位置付き回答を生成する（3.4 節）．

3.1 三層知識バンドル

提案方式は，LLM Wiki [7] の知識管理パターンと，OKF [8] のファイル形式を基礎とする．LLM Wiki は，不変な原資料を保持する raw sources，LLM が保守する Markdown ページ群である wiki，wiki の構造・規約・保守手順を定める schema から構成される．また，資料の取り込みを ingest，wiki への問い合わせを query，矛盾・古い記述・リンク切れ等の検査を lint と呼ぶ．OKF では，Markdown ファイルからなるディレクトリをバンドル，その中で個別の知識を記述する Markdown ファイルを concept と呼ぶ．

提案方式では，LLM Wiki の raw sources と wiki を，それぞれ**原資料層**と**調査ノート層**として採用する．また，LLM Wiki の schema を DFIR/OSINT 調査向けに具体化した論理層を**スキーマ層**と呼ぶ．スキーマ層は，概念型・関係制約・レビュー手順・lint 規則に加え，来歴・レビュー状態・locator のフィールドを定める．操作には，LLM Wiki の操作ループを拡張する update を加える．update は lint を伴い，調査ノート層・スキーマ層を修正し，レビュー状態を更新する．図 1 に示すとおり，調査知識を原資料層・調査ノート層・スキーマ層の三層で構成する．原資料層は Web ページ・PDF・画像・ログ・ツール出力などを改変せずに保持する．DFIR/OSINT 調査の概念を OKF の concept として表し，調査ノート層の記述を Markdown 本文に，スキーマ層の規則に従うメタデータを YAML frontmatter に記述する．事案ごとにバンドルを作成し（付録図 1），原資料の実体は対応する concept の resource から参照する．

3.2 スキーマ層の設計

DFIR/OSINT 調査の基本となる概念型として 8 種を定義する（一覧は付録表 A·2，実例は付録 A.1）．本文で主に参照するのは，原資料を参照する Artifact，根拠付きの調査所見を表す Claim，資料間の不一致や未解決点を表す Tension の 3 種である．各 concept は 1 つの Markdown ファイルに対応し，YAML frontmatter に `type` と型固有のメタデータを，本文に調査者向けの記述を持つ．Artifact は，原資料の実体を `resource` で参照し，取得時刻・出典・ハッシュを取得来歴として保持する concept である．Claim は，`supported_by` に，根拠 Artifact と locator の組を保持する．フォレンジックの observation [25] やインテリジェンス分析の analytic judgment [19] のように観測・分析・判断を表す概念は分野によって異なるが，本稿では，根拠付きの調査所見を横断的に Claim と定義する．来歴は，Artifact が保持する**取得来歴**と，記述の**生成来歴**（生成したモデル・操作・導出元）の二種類に分ける．各 concept は，レビュー状態を表す `review_status` として，未確認の `draft` または確認済みの `reviewed` を持つ．これらのフィールドは，2 章で述べた実務標準の関連する要求を参照して設計した（対応と未対応の整理は付録 A.2 を参照）．locator の種類は媒体に応じてスキーマ層に追加できる．本稿では，`pdf_page`（ページ番号），`log_line`（ログの行範囲），`image_bbox`（画素座標），`note_anchor`（テキスト資料の行範囲）の 4 種を用いる（locator の共通仕様は付録 A.3 を参照）．Tension は，資料間の不一致や根拠不足で結論を出せない問いを記録し，調査者が追加調査や資料の採否判断によって解消する．

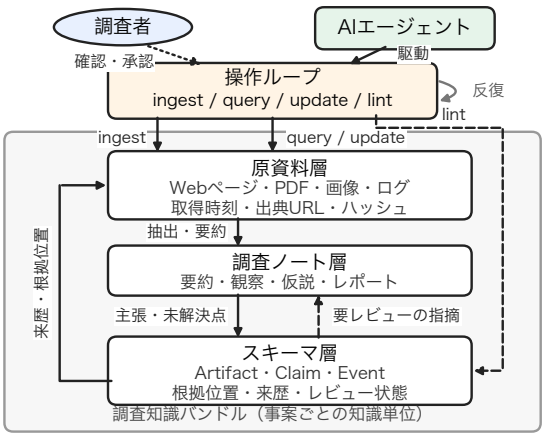


図 1 三層知識バンドルと反復操作ループ．スキーマ層の規則に従って原資料層から調査ノート層を生成・更新し，来歴と locator で原資料を参照する．

3.3 lint 規則と更新の却下条件

lint は，LLM を用いず入力のみから真偽を判定する決定論的 lint と，記述内容の理解を要する意味的 lint に分ける．決定論的 lint は，各 concept の frontmatter の有無，概念型，型固有の必須メタデータを検査する．Artifact では，resource が指す原資料ファイルの存在と記録済みハッシュとの一致を検査する．Claim では，supported_by と参照先 Artifact の存在，locator の必須値・形式・原資料内の範囲，Markdown リンク先の存在を検査する．これらの必須条件への違反を含む更新を却下する制御を gate と呼び，孤立ページと未解決 Tension は警告にとどめる．時系列矛盾，Claim 間の主張衝突，根拠が Claim を意味的に支持するか

© 2026 Information Processing Society of Japan

の判定は意味的 lint の対象とし，自動的な gate の却下条件には用いない．

3.4 人と AI によるバンドルの運用

バンドルへの操作は，図 1 に示す **ingest・query・update・lint** の 4 つである（調査者と AI の役割分担は付録表 A·1 を参照）．

運用開始時には，初期バンドルに gate 条件への違反がないことを lint で確認する．運用中に生じた新たな所見は AI が update で `draft` として起案し，調査者が確認後に `reviewed` へ昇格する．update 結果はバンドルへの反映前に lint で検査し，gate 条件への違反を含む場合は反映しない．却下時は lint 結果を AI へ与えて修復を再試行させる．query は，バンドル内の concept 群を入力とし，Claim に保持された locator を用いて根拠位置付きの回答を生成する．query で draft の Claim も利用するか，reviewed に限るかは運用方針で定め，`draft` を利用する場合は，未確認であることを回答に明示する．AI は意味的 lint の候補を提示し，調査者はその採否，lint 警告への対応要否，Tension の解消を判断する．

4. 実験設計

4.1 評価データと比較条件

評価データ: 公開データに基づく 4 事例 69 問と，本研究で作成した合成 3 事例 48 問の計 7 事例 117 問を用いる（構築・ライセンスは付録 A.5 を参照）．前者の公開データは，CTI 報告書 [26] から構築した CTI（28 問），サーバログ [27] の AIT-LDS（25 問），DFRWS フォレンジックチャレンジ 2018/2023 [28, 29] の公開データ抜粋による DFRWS18・DFRWS23（各 8 問）である．後者の合成データは，画像・インシデント報告 PDF・出典メモからなる OSINT（21 問），ログイン画面・インシデント報告 PDF・出典メモからなる phish（11 問），Web 記事・DNS ログ・分析メモ等 8 資料からなる不審ドメイン事例 susp-dom（16 問）である．OSINT は画像領域 locator の保持効果，phish は画像・PDF 間の突合，susp-dom はテキスト・ログ間の突合と資料間の不一致を評価するために用いる．117 問の内訳は，資料中に根拠がある通常質問 96 問と，根拠が存在しない回答不能質問 21 問（unanswerable [11]）である．通常質問のうち 61 問は同一事例の他の質問を評価する際の過去 Q&A としても用い，残る 35 問は過去 Q&A に含めない held-out 質問とし，このうち 31 問は複数の根拠資料にまたがる証跡対応関係を評価する質問とした．

比較条件: 比較条件は 8 種である．フォルダに格納した原資料をそのまま読ませる「直読み」，バンドルの全 Claim の見出しと本文を 1 つの Markdown ファイルに集約し，原資料のパスを平文で付記した「簡易メモ」，提案方式の「バンドル」，バンドルから locator のみを除いた「locator 除去」，ページ分割を保ったまま構造化 locator と来歴を除いた「LLM Wiki 型」，問い合わせ時に原資料から検索したテキストチャンクを渡す「text-RAG」，これに検索した画像・PDF ページを添付する「vision-RAG」，同一事例の他の質問の正解要旨と根拠位置を過去 Q&A として与える「qa-cache」である．簡易メモ・LLM Wiki 型・locator 除去は，新たな Claim を加えず，同一の評価バンドルから機械的に導出した．両 RAG 条件にはバンドルと同じ locator 出力指示を与えて各チャンクの出所を明示し，vision-RAG は原資料に画像または PDF を含む 5 事例に適用した（各条件の構成と導出の詳細は付録 A.3・A.5・A.7 を参照）．

4.2 使用モデルとプロンプト統制

提案方式の効果が特定のモデルに限られないかを確認するため，提供元・製品系列・視覚入力の有無・実行環境が異なる 8 モデルを用いる．内訳は，クラウドモデル 5 種（GPT-4o-mini・GPT-5・Claude Haiku 4.5・Claude Sonnet 4.5・Claude Opus 5）と，ローカルモデル 3 種（Qwen3-8B・Qwen3-VL-8B・Gemma4-26B）である．読込み評価では，提供元の異なる GPT-4o-mini と Claude Sonnet 4.5 で全事例を対象に前述の比較条件を評価し，残るモデルでは事例と比較条件を限定して，locator 保持の効果がモデル系列や実行環境によって異なるかを調べる．書込み評価では，全 8 モデルを用いて lint 強制の効果がモデルに依存するかを確認する（実行構成は付録 A.7 を参照）．

プロンプトは，読込み評価では全条件で同一の前文を共有し，「資料の説明」と「引用先パスの指定」の 2 箇所だけを条件に応じて変えた．特にバンドルと locator 除去には同一のシステムプロンプトを与え，入力に locator が含まれるか否かだけを変えた．書込み評価では，タスク指示と JSON 出力形式を 3 条件で共通とし，lint 結果の提示と，違反を含む更新の却下の有無だけを変えた．全ての比較で温度を 0 とし，条件間で同一の質問またはタスクを用いた（付録 A.3 を参照）．

4.3 評価指標

正解の根拠資料と根拠位置の組を *gold* と呼ぶ．読込み評価では，通常質問の引用を次の 3 指標で評価する．**資料到達率**（SR）は，少なくとも 1 つの引用が gold で指定した根拠資料へ到達できた質問の割合である．**適合率**（LP）は，提示された全引用のうち gold を正しく指した引用の割合である．**再現率**（LR）は，同内容の複数 gold をまとめた gold グループのうち，少なくとも 1 つの引用が正しく指したグループの割合である．いずれも試行ごとに通算して求め，3 試行の平均を報告する（判定規則は付録 A.7 を参照）．回答不能質問は SR・LP・LR から除外し，資料中に根拠がない旨を明示した上で引用を付けずに棄却できた割合（**根拠不在棄却率**，URR）と，実在するファイルを誤っ

© 2026 Information Processing Society of Japan

て引用する**過剰引用**の件数を数える．書込み評価では，決定論的 lint が証跡対応違反を検出した Claim の割合（**根拠なし記述率**，UCR）を測定する．UCR だけでは，正しい根拠対応を含む更新まで却下して値を下げた場合を区別できないため，ラウンド末の Claim の根拠位置が投入済み gold と一致した件数（gold 一致数）を副次指標として測定する．書込み評価の gold は，各ラウンドの投入資料について根拠 Artifact・locator の組を 1–3 件，計 10 件投入前に固定したもので，所見候補全体を網羅しない．

引用の正誤は機械判定する．gold で指定した根拠資料に到達し，かつ媒体別の規則で locator が gold と一致した引用を正解とし，根拠資料に到達しない引用を自動的に不正解とする．根拠資料には到達したが locator が欠落または不一致の引用と，resource を一意に解決できない引用は，判定保留とし，LP・LR の正解に数えない．判定保留の引用を正解に含めないことによる過小評価の可能性を標本 30 件の人手裁定で確認し，裁定結果による数値の置換は行わない（位置一致規則と裁定手順は付録 A.7 を参照）．評価用に構築したバンドルの locator は，構築時に gold と突合して検証済みであり，バンドルと locator 除去の比較は，新たな根拠位置の探索能力ではなく，locator の保持・再利用の効果を測る．

4.4 実験手続き

実験は，query による**読込み評価**と，update による**書込み評価**の 2 系統からなり，いずれも提案方式の PoC 実装を用いる（実装・実行構成・判定規則の詳細は付録 A.7 を，入出力の実例は付録 A.6 を参照）．

読込み評価: 7 事例 117 問を，各モデルへの事例・比較条件の割当に従って各 3 試行で問い合わせ，回答の引用を評価する．補助実験は 2 つある．第一に，推論による復元を切り分けるため，「locator が不確かなら最良推定を出力せよ」の 1 文を加えた**推量許可条件**を 4 モデル × 最大 4 事例で実行する（主実験の値は全て推量を禁止した既定プロンプトによる）．第二に，保持の寄与を分離するため，locator の有無だけが異なるバンドルと locator 除去を対で比較し，実行済みの全 28 組合せについて質問単位のブートストラップ法で LR 差の 95%信頼区間を算出する（算出条件は付録 A.7 を参照）．

書込み評価: 段階投入用の資料・タスク列・事前固定 gold を整備した DFRWS18 の 1 事例を対象とし，5 ラウンドにわたり新資料の段階投入・要約更新等の計 12 タスクを，提案方式の gate と比較条件 advise・none の 3 条件 × 各 3 試行で実行する．advise は lint 結果を提示するが更新を却下せず，none は lint を実行しない．gate では，自動修復の機会を設けつつコストを制限するため，1 タスクあたりの LLM 呼出を初回生成 1 回と再生成最大 2 回の計 3 回に制限した．最大 2 回の再生成後も違反が残る場合は，再生成上限到達として記録し，更新を破棄する．LLM 呼出回数の上限を条件間で揃えるため，advise・none は初回生成後に 2 回の自己レビューを固定して常に 36 回（12 タスク ×3 回）呼び出し，gate は違反時だけ再生成する．人手評価では，GPT-4o-mini の最終ラウンドから各条件・各試行 5 件ずつ計 45 件を固定乱数種で層化抽出し，条件を伏せた上で locator の意味的妥当性，Claim の事実正確性，引用範囲による意味的支持を判定する．

検査器の動作・検出範囲の確認: 構造的欠陥を 1 件ずつ注入した変種を決定論的 lint が全て検出し，意味的欠陥の陰性対照 3 種を検出しないことを確認した（変種の構成と検出結果は付録 A.4 を参照）．PoC の決定論的 lint は，必須フィールドの有無，バンドル内の Artifact 参照と Markdown リンク，locator の有無と type を検査する．resource が指す原資料ファイルの存在・ハッシュ一致と，locator の媒体別必須値・形式・範囲は実装せず，本評価の対象外とした．書込み評価では，この区別に従って構造的違反を gate の強制対象とし，意味的妥当性を人手評価の対象とする．

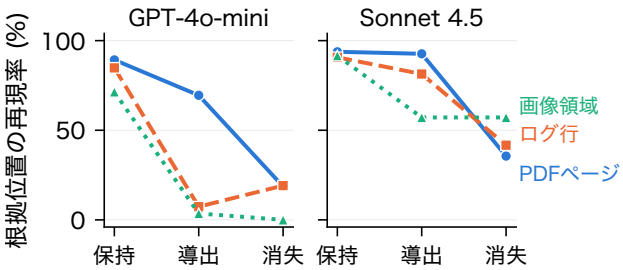


図 2 媒体別の根拠位置の再現率（gold グループ単位の通算集計，7 事例 ×3 試行）．保持=バンドル，導出=直読み，消失=locator 除去（媒体別グループ数は付録 A.7）．

5. 評価結果

5.1 劣化の測定（RQ1）

劣化の非対称性と 3 群構造: 最も明確な劣化は，locator を持たない表現（locator 除去・LLM Wiki 型）において，SR が 100%のまま，LR だけが 0%に低下する非対称性である（表 1 中の †，残り 3 事例は付録表 A·7）．CTI におけるこの 2 表現の LR は実行した全 7 モデルで 0%であり（SR は 40–100%．付録表 A·7・ A·8），この非対称性はモデル固有ではない．結果は**保持**（バンドル），**導出**（直読み・RAG），**消失**（locator 除去・LLM Wiki 型）の 3 群に整理できる．図 2 に示す通り， PDF ページは資料構造から再導出されやすい一方，ログ行はモデル依存が大きく，全事例を評価した 2 モデルとも画像領域を安定して再導出できない（GPT-4o-mini で保持 71%，直読み 4%）．

locator の再導出可能性: 推量許可の影響を，禁止・許可条件間の LP・LR の差から評価した（付録表 A·5）．AIT-LDS の直読みでは，GPT-4o-mini の LR が 3%から 59%へ上昇したが，LP は 50%にとどまる．GPT-5・Claude Opus

© 2026 Information Processing Society of Japan

表 1 読込み評価の主要結果（3 試行平均）．各セルは SR/LP/LR（%）．太字は各行で最良の LR 値（同値含む）．— は視覚的原資料が無く不適用．† は非対称な劣化に該当するセル．

事例	モデル	直読み	簡易メモ	LLM Wiki 型	バンドル	locator 除去	text-RAG	vision-RAG	qa-cache
CTI	GPT-4o-mini	100/79/**89**	100/43/47	100/0/0†	100/81/86	100/0/0†	100/42/65	—	89/59/70
	Sonnet 4.5	100/54/91	100/13/24	100/0/0†	100/58/**92**	100/0/0†	100/39/68	—	68/59/61
AIT-LDS	GPT-4o-mini	100/2/3	95/29/41	91/18/15	91/89/**82**	86/10/8	91/77/77	—	79/71/71
	Sonnet 4.5	100/67/91	100/66/**93**	58/28/12	95/80/85	92/10/16	95/62/85	—	67/72/64
DFRWS18	GPT-4o-mini	100/17/19	100/28/28	100/7/8	100/100/**100**	100/17/17	80/38/31	100/30/33	0/0/0
	Sonnet 4.5	100/33/67	100/60/75	100/46/50	80/82/**92**	80/58/75	67/17/19	100/27/44	0/0/0
OSINT	GPT-4o-mini	100/27/26	100/8/7	98/9/9	94/88/**78**	100/23/22	0/0/0	96/18/17	56/74/48
	Sonnet 4.5	100/79/78	100/78/80	94/27/22	100/95/**95**	100/75/78	13/0/0	100/78/78	57/67/42

5・Claude Sonnet 4.5 は禁止時にも 91–100%の LR を示した一方，LP は 31–73%であり，ログ行は行構造から再導出できる場合があるものの，高い LR が高い LP を伴うとは限らない．画像領域では，推量を許可しても評価した 3 モデルの直読みの LR は改善せずバンドルを下回ったままであり，locator の復元可能性は，モデルに加えて根拠位置を原資料の構造から再導出できるかに依存する．

回答不能質問への挙動: URR はモデル間で 1–45%と大きく異なり，棄却指示をプロンプトに明示するだけでは安定しない．GPT-4o-mini と Sonnet 4.5 の誤った引用 565 件を全数照合すると，**存在しないパスの捏造は 0 件**で，全て実在するファイルへの過剰引用だった．過剰引用は locator を多く含む文脈で生じやすく（CTI の回答不能 3 問 ×3 試行: バンドル 4–9 対直読み 0），ファイルの実在チェック型の lint では検出できないため，URR の測定と人手レビューが必要である．

検証慎重性: 既定プロンプトは，locator を不確かに推量することを禁止しており，Sonnet 4.5 と GPT-5 は文脈内で確認できない根拠を出力せず，一部のセルで LR が下がる．推量を許可すると両者とも 92–100%へ回復するため，この低下は能力の限界ではなく，指示で調整できる出力方針の差である．

書き側の劣化: 反復書込み実験では，非強制条件（advise・none）で GPT-4o-mini の UCR が全ラウンドで残存・増加し，UCR は最終 22–24%・全ラウンド最大 46%に達した（表 2・図 3）．非強制条件の最終 UCR はモデルに依存し，ローカルモデル 3 種は 0–2%，残るクラウドモデル 4 種は 0–1%だった（表 2・付録表 A·6）．

■ RQ1 への回答　割り当てた事例の範囲で，資料到達率が保たれたまま根拠位置の再現だけが損なわれる非対称な劣化を全 8 モデルで観測し，locator によらない復元は，導出できる媒体を除き当て推量に依存した．書込みでは非強制条件で構造的な根拠なし記述が残存・増加した．

5.2　lint 強制の効果（RQ2）

抑止効果: gate は全 8 モデル・全ラウンドで根拠なし記述を 0 件（0%）に維持した（5.1 節の書き側と同一実行．図 3・表 2・付録表 A·6）．検査器とは独立な指標として gold 一致数を表 2 に併記する．非強制条件は各タスクで 2 回の

表 2 反復書込み実験（DFRWS18，5 ラウンド ×3 試行）．UCR=構造的違反の割合（最終/最大），gold 一致数=gold 10 件中の一致数，呼出=1 試行の API 呼出数．太字は各モデル内の最良（追加クラウド 3 種は付録表 A·6）．

		UCR（劣化）↓		生成	品質 ↑	コスト
モデル	条件	最終	最大	Claim 数	gold 一致数	呼出
GPT-4o-mini	gate	**0%**	**0%**	19.7	**3.3**	16
	advise	22%	40%	24.7	2.0	36
	none	24%	46%	22.0	0.7	36
Sonnet 4.5	gate	**0%**	**0%**	31.3	**4.3**	12
	advise	**0%**	**0%**	31.7	4.0	36
	none	**0%**	**0%**	33.7	**4.3**	36
Qwen3-8B	gate	**0%**	**0%**	36.3	1.0	13
	advise	1%	4%	35.3	**1.7**	36
	none	**0%**	**0%**	29.7	1.0	36
Qwen3-VL-8B	gate	**0%**	**0%**	24.7	**3.7**	12
	advise	**0%**	**0%**	26.7	3.0	36
	none	2%	12%	24.7	3.3	36
Gemma4-26B	gate	**0%**	**0%**	15.3	2.3	13
	advise	2%	11%	17.7	2.0	36
	none	2%	11%	17.0	**2.7**	36

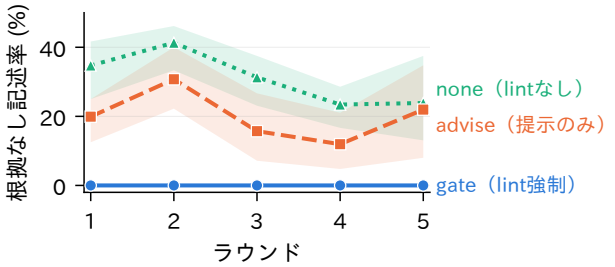


図 3 lint 強制の抑止効果（GPT-4o-mini・DFRWS18・3 試行の平均と最小–最大帯）．gate は全ラウンドで 0%を維持した．

自己レビューを与えても UCR が残存したため，差は強制の有無に帰着する．

生成量と品質への影響: GPT-4o-mini では gate の最終 Claim 数が advise より約 2 割少ない一方，gold 一致数は最多だった（表 2）．8 モデル全体では，gate の gold 一致数が非強制条件を下回る場合の 3 試行平均差は最大 0.7 件だった（付録表 A·6）．36 タスク実行中，lint 却下からの自動修復は 5 件（14%），再生成上限到達による更新不成立は 4 件（11%）だった．条件を伏せた人手監査 45 件では locator の意味的妥当性は gate 53%・非強制 33–40%であり，gate による意味的妥当性の低下は観測されなかった．決定論的 lint は意味的な正しさを保証しないため，その確認は調査者が担う．

実行コスト: gate は約 1/3 の呼出（12–16 対 36）で同等以上の構造品質を達成し，Qwen3-8B の実測でも gate で

© 2026 Information Processing Society of Japan

57 分，非強制で 169–195 分だった．違反時の再生成による追加呼出は 0–4 回，構築側は ingest 119ms 以下・lint 20ms 以下でボトルネックにならない．

■ **RQ2 への回答**　gate は全 8 モデル・全ラウンドで構造的違反 0%を維持し，gold 一致数の低下は最大 0.7 件だった．非強制 UCR が高いモデルでは劣化の抑止として，低いモデルでは低コストの検証として機能する．

5.3　locator 保持の効果（RQ3）

locator 保持の効果を，バンドルと locator 除去の LR 比較で測定した（表 1）．LR は CTI で 86–92%から 0%へ，AIT-LDS で 82–85%から 8–16%へ低下し，差は CTI で 86・92 ポイント，AIT-LDS で 75・70 ポイント（GPT-4o-mini・Sonnet 4.5）で，95%信頼区間はいずれも 0 を含まなかった（区間と算出条件は付録 A.7）．CTI で LR が 0%となるのは，locator 除去の条件では原資料本文の抜粋も残らず，根拠位置を特定する材料が無いためである．qa-cache の LR は，事例によって 0–71%と変動し，text-RAG の LR は AIT-LDS で 77–85%，susp-dom で 88–89%を保つ一方，OSINT では検索段階の SR が 0–13%にとどまり，LR は 0%だった（表 1・付録表 A·7）．held-out 質問でも CTI のバンドル LR は 77–85%だった（付録 A.7）．

■ **RQ3 への回答**　実行済みの全 28 組合せで locator 除去により LR が低下し，差は 17–95 ポイントだった．バンドルの高い LR は保持された locator の再利用に由来し，qa-cache・RAG の性能は事例形式に依存した．

5.4　境界条件と評価の限界（RQ4）

直読みの境界条件: ページ構造がファイル名等から自明な小規模テキスト（CTI）では，直読みの LR は 89–91%でバンドルの 86–92%に並び，AIT-LDS でも，Sonnet 4.5 の直読み 91%はバンドルの 85%に並ぶ．差が開くのは，位置構造が資料に露出しないログ行（GPT-4o-mini: 直読み 3%対バンドル 82%），画像領域，多形式のフォレンジックチャレンジである．

モデル・実行環境横断: 劣化の非対称性はクラウド 5 種・ローカル 3 種の全 8 モデルで観測された．フォレンジック事例におけるバンドルの LR 92%以上は GPT-4o-mini・Sonnet 4.5・Qwen3-VL-8B・Gemma4-26B で確認された一方，下回るセルもある（GPT-5 の DFRWS18 バンドル LR 78%，表 A·5 の禁止側）が，推量許可では 92%へ回復するため，この低下は能力限界だけでなく，推量禁止指示の遵守（検証慎重性，5.1 節）による可能性がある．

評価 gold との重なりの開示: 評価 gold の 160 ユニークグループ中 142 は，バンドルが保持する locator と重なる．本稿の主張は確認済みの位置を保持すれば後続で再現できるという点にあり，保持済み gold での高い LR はその検証そのものである．保持していない 18 グループ（54 観測）ではバンドルの優位が消え（GPT-4o-mini 17%対直読み 0%，Sonnet 4.5 61%対 67%），差は位置を新たに見つける能力ではなく保持の効果であることを裏付ける．なお held-out は質問の区分で，locator との非重複を意味しない．

■ **RQ4 への回答**　locator 保持が有効なのは，位置構造が資料側に現れない形式・画像領域・多形式の大規模事例であり，ページ構造が自明な小規模テキストでは直読みが同等に達する．効果は位置の新規発見ではなく locator の保持と再利用であり，失われた根拠位置の再導出可能性は媒体とモデルに依存する．

6.　考察

6.1　設計指針と実務への含意

第一に，支援ツールの評価では，SR と LR を分けて測る．第二に，位置構造が資料側に現れない画像領域や多形式の大規模事例では，後続調査に用いる locator の整備を優先する．第三に，決定論的 lint は構造的欠陥の検出に限定し，意味的妥当性は調査者が確認する．加えて，根拠を確認できない場合に回答や locator を省略するか推定値として出力するかはプロンプトで明示的に設定すべきである（検証慎重性，5.1 節）．gate 却下の内訳（自動修復 14%・更新不成立 11%，5.2 節）は，lint の自動修復で足りる範囲と人間の判断を要する範囲の境界を示す．

実行環境の制約との関係: 保全済みの証拠資料・秘匿特権資料・越境移転制約のある資料はクラウドへ送信できず，ローカルモデルの利用が現実的となる [3, 30]．一方，画像領域では評価した 3 モデルのいずれも推量許可で改善せず（5.1 節・図 2），モデルの高性能化だけで，失った根拠位置を安定して再導出できるとはいえない．したがって，機微な資料を 8B–26B 級のローカルモデルで扱う場合も，位置の推論復元に依存せず locator を保持する必要がある．実際，ローカルモデル 3 種でも，多くの条件でバンドルが直読みを上回った．また，決定論的 lint はモデルの推論能力を要さず，資料を外部へ送信せずに実行できる．

6.2　適用範囲と制約

本方式は調査知識の追跡可能性と検査可能性を高めるものであり，原資料の真正性や法的証拠能力は保証しない．原資料の真正性は電子署名やコンテンツ来歴技術が担う層であり，本方式は取得時のハッシュを含む来歴でこれらの層を接続する．

制約の第一は表現力と構築コストである．OKF 互換プロファイルは厳密なオントロジ（CASE/UCO や STIX）の表現力は持たない．また，根拠位置の保存を要しない単発の探索では，提案方式は過剰になりうる．

第二は評価範囲である．画像は DFRWS 事例の実データを含むが，OSINT・フィッシング事例の画像は合成例であり，多様性は限られる．人手による裁定は著者 1 名によ

© 2026 Information Processing Society of Japan

るものであり，複数評価者による検証は行っていない．また，query/update は別系統で評価し，更新後のバンドルを後続 query に用いる E2E 評価は行っていない．

第三は，長期運用と敵対的条件である．AI 生成情報の陳腐化を review_status の降格等により要再確認として管理する設計であるが，長期運用での有効性は検証していない．また，反証や対立仮説を Tension として管理する運用の有効性と，プロンプトインジェクション耐性も評価していない．

7. おわりに

本稿では，AI 支援 DFIR/OSINT 調査の信頼性がモデル性能だけでなく調査知識にも依存するという立場から，証跡対応関係の劣化を読み書き両面で測定し，三層知識バンドルと lint 強制による抑止を検証した．

7 事例 117 問・計 8 モデルの評価が示したのは次の点である．根拠資料に到達できても根拠位置は独立に失われ，復元可能性は媒体とモデルに依存する．安定して機能したのは locator の保持であり，一度確認した根拠位置は再推論させる情報ではなく調査状態として永続化すべきである．lint の保証は構造的整合性までであり，意味的裏付けの確認は調査者レビューが担う．本稿の指標と決定論的 lint の実装は，調査知識を証跡対応の観点で更新のたびに検査する基盤として利用できる．今後は，対応媒体・機能の拡張、評価の高度化に加え，STIX 等と連携した脅威インテリジェンス共有を検討する．

参考文献

[1] R. Lakshmi et al. Sensemaking in Cybersecurity Incident Response: The Interplay of Organizations, Technology and Individuals. In *ECIS*, 2021.

[2] K. Kent et al. Guide to Integrating Forensic Techniques into Incident Response. NIST SP 800-86, National Institute of Standards and Technology, 2006.

[3] D. Kramer et al. Integrating Large Language Models into Security Incident Response. In *SOUPS*, 2025.

[4] B. Cherif et al. DFIR-Metric: A Benchmark Dataset for Evaluating Large Language Models in Digital Forensics and Incident Response. In *ICONIP*, 2025.

[5] Z. Liu et al. EviReport: From Reasoned Outlines to Evidence Tracked Long-Form Reports. In *Findings of ACL*, 2026.

[6] H. Rashkin et al. Measuring Attribution in Natural Language Generation Models. *Computational Linguistics*, 49(4):777–840, 2023.

[7] A. Karpathy. LLM Wiki, 2026. `https://gist.github.com/karpathy/442a6bf555914893e9891c11519de94f`.

[8] GoogleCloudPlatform. Open Knowledge Format (OKF) Specification, 2026. `https://github.com/GoogleCloudPlatform/knowledge-catalog`.

[9] S. Fumero et al. CyberSleuth: Autonomous Blue-Team LLM Agent for Web Attack Forensics. arXiv:2508.20643, 2025.

[10] E. A. Palmieri et al. Agentic and Generative AI for Open-Source Intelligence and Cyber Investigations: Taxonomy, Evaluation, Challenges, and Future Directions. arXiv:2607.03233, 2026.

[11] D. Begimher et al. SIR-Bench: Evaluating Investigation Depth in Security Incident Response Agents. arXiv:2604.12040, 2026.

[12] OASIS CTI TC. STIX Version 2.1. OASIS Standard, 2021.

[13] CASE/UCO community. CASE/UCO Cyber-investigation Ontology. `https://caseontology.org` (accessed 2026-08-20).

[14] C. Bratsas et al. Knowledge Graphs and Semantic Web Tools in Cyber Threat Intelligence: A Systematic Literature Review. *Journal of Cybersecurity and Privacy*, 4(3):518–545, 2024.

[15] Y. Wang et al. From Agent Traces to Trust: A Survey of Evidence Tracing and Execution Provenance in LLM Agents. arXiv:2606.04990, 2026.

[16] Z. Jin et al. Mitigating Provenance-Role Collapse in Long-Term Agents via Typed Memory Representation. arXiv:2605.25869, 2026.

[17] P. Lewis et al. Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks. In *NeurIPS*, 2020.

[18] S. Yu et al. VisRAG: Vision-based Retrieval-augmented Generation on Multi-modality Documents. In *ICLR*, 2025.

[19] Office of the Director of National Intelligence. Intelligence Community Directive 203: Analytic Standards. Technical report, ODNI, 2015. 2 January 2015, technical amendment 2022.

[20] Office of the Director of National Intelligence. Intelligence Community Directive 206: Sourcing Requirements for Disseminated Analytic Products. Technical report, ODNI, 2015.

[21] International Organization for Standardization. ISO 21043-2:2018 Forensic sciences — Part 2: Recognition, recording, collecting, transport and storage of items, 2018.

[22] International Organization for Standardization. ISO/IEC 27037:2012 Information technology — Security techniques — Guidelines for identification, collection, acquisition and preservation of digital evidence, 2012.

[23] Google. Timesketch. `https://github.com/google/timesketch` (accessed 2026-08-20).

[24] L. Moreau and P. Missier. PROV-DM: The PROV Data Model. W3C Recommendation, 2013.

[25] International Organization for Standardization. ISO 21043-1:2025 Forensic sciences — Part 1: Vocabulary, 2025.

[26] APTnotes community. APTnotes Data. GitHub repository. `https://github.com/aptnotes/data` (accessed 2026-08-20).

[27] Austrian Institute of Technology. AIT Log Data Set V2.0. Zenodo, 2021. `https://doi.org/10.5281/zenodo.5789064`.

[28] F. Servida and E. Casey. IoT Forensic Challenges and Opportunities for Digital Traces. *Digital Investigation*, 28:S22–S29, 2019.

[29] DFRWS. DFRWS 2023 Challenge, 2023. `https://github.com/dfrws/dfrws2023-challenge`.

[30] B. Sharma et al. ForensicLLM: A Local Large Language Model for Digital Forensics. *Forensic Sci. Int.: Digit. Investig.*, 52:301872, 2025.

© 2026 Information Processing Society of Japan

研究倫理

本研究は人間参加者を対象とする実験を含まない．また，本評価に用いた公開データは，APTnotes [26] 収載の CTI 報告書，AIT-LDS [27]，および DFRWS フォレンジックチャレンジ 2018 [28]・2023 [29] である．これらはそれぞれの取得元の利用条件に従って使用し，PDF・大容量ログ・ディスクイメージ等の原本の再配布は行っていない（付録 A.5）．DFRWS 2023 はリポジトリ（`https://github.com/dfrws/dfrws2023-challenge`）に Apache-2.0 ライセンスが明示されているが，DFRWS 2018 はライセンスを明示していないため，チャレンジの公開目的（研究の進展・参加と結果公表の公募）に整合する研究利用に限定した．合成事例および合成画像は，実在の組織・個人・ドメインを含まないように作成した．商用 LLM API の利用は各提供者の利用規約に従うとともに，評価データに個人情報および機微情報を含まないよう配慮した．提案方式は，調査知識の追跡可能性・検査可能性の向上を目的とする防御的な技術であり，攻撃を容易にする情報は含まない．

© 2026 Information Processing Society of Japan

```
data/okf-bundles/<case-id>/
  index.md           # 概念への入口
  log.md             # 操作履歴（追記専用）
  investigation.md   # 事案概要
  artifacts/  entities/  events/
  claims/     tensions/  procedures/  reports/
  lint-report.md     # 検査結果（再生成）
data/raw/<case-id>/ # 原資料（resource で参照）
```

Listing 1: 事案ごとの調査知識バンドルのレイアウト（PoC の既定構成）．原資料をバンドル外に置く場合も，Artifact の `resource` と `sha256` で検証可能性を保つ．

表 A·1 4 操作における調査者・AI の役割と評価実験との対応．

操作	調査者	AI	評価
ingest	資料の投入	来歴・派生テキストの自動付与	評価事例セットの構築/書き側の資料投入（4.4 節）
query	質問，回答の検証	引用・locator 付き回答の生成	読み側評価（4.4 節）
update	`reviewed` への昇格承認	Claim の起案・修正・統合（`reviewed` 昇格は不可）	書き側タスク（4.4 節）
lint	判定保留引用の裁定	却下時の修復（gate）	検査器の妥当性（付録 A.4）・gate（5.2 節）

表 A·2 提案方式における基本概念型と主なリンク・フィールド．

概念型	役割	主なリンク・フィールド
Investigation	事案の概要	各概念への索引
Artifact	原資料参照	`resource`, `captured_at`, `sha256`
Entity	人物・組織等	関連 Artifact・Event
Event	時刻付き観測	`timestamp`・根拠 Artifact
Claim	調査所見	`title`・Artifact・locator・`review_status`
Tension	矛盾・未解決点	対象 Claim・`status`・`severity`
Procedure	反復手順	in/steps/out
Report	分析結果のまとめ	引用 Claim・Artifact

付　　録

A.1　バンドルの構成と実例

事案ごとのバンドルのディレクトリ構造を Listing 1 に示す．概念型の一覧を表 A·2 に，4 操作の役割分担と評価実験の対応を表 A·1 に示す．

各 concept は調査者・AI が追記する調査ノート欄を本文に持つ（各型のフィールドは表 A·2 を参照）．

A.2　スキーマの体系と標準概念との対応

スキーマ層のメタデータは，(i) 機能（何のための情報か），(ii) 保持する概念型，(iii) 強制度（決定論的 lint が必須とするか，バンドル形式の規約か，推奨か）の 3 軸で整理できる．来歴は，原資料の**取得来歴**（chain of custody の機械可読断片）と記述の**生成来歴**（W3C PROV [24] の `wasGeneratedBy`/`wasDerivedFrom` に対応する `generated_by`・`derived_from`）の二層からなり，ライフサイクル上この間に位置する保管・移管の記録は対象外である（将来拡張として区別する）．`review_status` は来歴ではなく確認状態として区別する．

```
---
type: Claim
title: Login page shows verification code 742913
confidence: medium
supported_by:
  - artifact: artifacts/browser-login-png.md
    locator:
      type: image_bbox
      bbox: [142, 285, 169, 49]
review_status: draft
---
# Login page shows verification code 742913
## Evidence
- [browser-login.png](
  ../artifacts/browser-login-png.md)
  supports `742913`.
```

Listing 2: 根拠位置 locator を保持する Claim ファイル（抜粋）

表 A·3 に，主要な機構と IC 分析標準（ICD 203/206 [19]）・フォレンジック標準（ISO 21043 [21]・ISO/IEC 27037 [22]）との概念対応を示す．本表は設計が参照した対応関係の整理であり，各標準への準拠を主張するものではない．ICD は分析成果物への組織的要求，ISO 21043・ISO/IEC 27037 はフォレンジック手続への要求であり，本方式はそれらが記録・区別・引用に求める事項を調査知識のデータ表現として受け止める（ISO 側は公開されている適用範囲の水準で対応を示す）．なお，ingest 後の改変は `sha256` 不一致として検出できるが，取扱者・移管記録など chain of custody の中核は本方式の対象外である．一方，仮定の明示（ICD 203 基準 (3)），尤度と確信度の分離（同基準 (2)），出典の質・発行日・取扱区分（ICD 206），判断変更の説明の構造化（同基準 (7)），取扱者・移管の記録（ISO 21043-2）は本メタデータ設計の未対応要件である．このうち語彙と必須フィールドの追加で表せるもの（尤度語彙・発行日・状態遷移）は決定論的 lint の検査対象に加えられるため，将来の準拠課題と位置付ける．

A.3　query のプロンプト

全条件のシステムプロンプトは共通の生成関数から生成され，前文（推測禁止・根拠不在時の明示的棄却・JSON 出力仕様・locator 仕様）をすべて共有する．条件差が 4.2 節の 2 箇所に限られることは自動テストで担保される．

条件の構造的制約と文言差: LLM Wiki 型は来歴フィール

© 2026 Information Processing Society of Japan

表 A·3 本方式の機構と標準概念との対応（ICD 203 の番号は Analytic Tradecraft Standards の基準番号）.

本方式の機構	IC 分析標準	フォレンジック標準
Artifact（情報）と Claim（判断）の分離	203 基準 (3): 基礎情報と仮定・判断の区別	ISO 21043-5: 報告の正確性・透明性の要求
locator 付き引用（ページ・行・画像領域）	206: 出典参照に一意な出典識別子・日付・該当ページを含める要求	—
資料到達性（SR）	206: 読者が出典を発見・再取得できることの保証	—
`confidence` 語彙	203 基準 (2): 不確実性の表現（尤度と確信度の区別）	ISO 21043-4: 解釈の要求・推奨
Tension（対立仮説の一級化）	203 基準 (4): 代替分析の組み込み	—
取得来歴（`captured_at`・`sha256` 等）	203 基準 (1): 出典の質・信頼性の記述	ISO/IEC 27037: 識別・収集・取得・保全, ISO 21043-2: 証拠物の認識・記録・収集・輸送・保管
生成来歴（`generated_by`・`derived_from`）	203 基準 (1): 方法論の記述	ISO 21043-2: 記録の要求
判断の変更の追跡（`derived_from`・`log.md`）	203 基準 (7): 判断の変更・一貫性の説明	—

ドを持たない表現のため画像・PDF の添付経路を持たず，視覚資料はページ本文の記述経由でのみ参照できる（gold が画像領域に集中する事例では LR が構成上低くなる）．バンドル系と LLM Wiki 型の Artifact ページ本文抜粋は原資料の先頭 20 行で，バンドルと locator 除去の間では同一である．「資料の説明」の文言は条件ごとに 1–2 文異なる（簡易メモには非権威性の注意，LLM Wiki 型にはページの所定パスを引用する誘導）．Claim 本文中の行・ページへの言及を構築時に書かれた記述として保持しており，DFRWS 系・phish に計 13 箇所ある（CTI・OSINT は 0 箇所）．このため除去による差の出方は事例間で完全には均一でない．バンドル条件の実プロンプトを Listing 3 に示す．

A.4 lint 評価用の欠陥変種

検査器の動作・検出範囲の確認（4.4 節）では，不審ドメイン合成事例のクリーンなバンドルを基点に，表 A·4 の欠陥を 1 件ずつ注入した変種バンドルを機械的に生成し，決定論的 lint の検出有無を評価した．陰性対照 3 種（引用根拠と矛盾する日付・実在する別範囲への誤引用・Claim 間の主張衝突）はいずれも構造的に有効なまま意味だけが誤っており，決定論的 lint が検出しないことが正しい挙動である．

A.5 評価事例セットの詳細

各事例各事例の質問数は held-out 質問と回答不能質問（ 4.1 節）を含む．構築後の評価バンドルの Claim の

```
You are a careful investigation assistant. Answer ONLY
from the provided concept pages and artifacts. Every
factual statement must be backed by a citation. Do not
speculate beyond the evidence; if the provided
materials conflict, say so and cite both. If the
provided material does not support an answer, say so
explicitly and return no citations -- do not guess.
Respond as a JSON object with keys "answer" (string)
and "citations" (array). Each citation has "resource"
(the raw source path as written in an artifact's
`resource` field), an optional "locator", and an
optional "concept" (the bundle-relative concept page
path you used).
-- shared locator contract (all conditions) --
When you cite a specific span, include a "locator"
object whose "type" is one of: "log_line" with integer
"start_line"/"end_line"; "pdf_page" with integer
"page"; "image_bbox" with "bbox" [x,y,w,h] in pixels
from the image's top-left corner; "web_selector" with
"selector"; or "note_anchor" with "start_line"/
"end_line". Point the span at the exact lines that
support the statement, not the file header.
```

Listing 3: バンドル条件のシステムプロンプト（全条件共通の前文）と共通 locator 仕様

表 A·4 注入した欠陥変種（4 群 12 件＋陰性対照 3 件）.

群	検出コード	内容
Artifact metadata	`artifact.resource.missing`	`resource` の欠損
	`artifact.captured_at.missing`	取得時刻の欠損
	`artifact.sha256.missing`	ハッシュの欠損
	`artifact.artifact_type.missing`	媒体種別の欠損
Claim support	`claim.support.missing`	`supported_by` 全体の欠損
	`claim.artifact.missing`	Artifact 参照の欠損・参照先 concept ファイルの不存在
locator	`claim.locator.missing`	locator の欠損
	`claim.locator.invalid`	未知の locator `type`
link/page	`link.broken`	壊れた Markdown リンク
	`type.missing`	概念型 `type` の欠損
	`frontmatter.missing`	メタデータ領域の欠落
	`page.orphan`	どこからも参照されない孤立ページ
陰性対照	（検出対象外）	本文のみの意味的な日付矛盾
	（検出対象外）	実在する別範囲への誤引用（構造は有効）
	（検出対象外）	Claim 間の主張衝突（本文のみ）

`review_status` 分布は draft 49 件，reviewed 6 件である．評価用バンドルの locator は，構築時の gold 突合と，原資料を開いた独立の AI レビューで確認した．Artifact は `ingest` が機械生成し（来歴・ハッシュ自動付与），Claim

© 2026 Information Processing Society of Japan

等の調査ノートは著者監督下の AI セッションが作成した．調査ノート構築時の人手作業は指示・通覧・承認と，事後の標本裁定 75 件（付録 A.7）に限られる．比較条件の簡易メモ・LLM Wiki 型は， 4.1 節の定義に従い同一バンドルからスクリプトで機械的に導出したため，手書きのベースラインを含まない．

合成事例: 不審ドメイン事例（`susp-dom`，16 問）は Web 記事・DNS ログ・アナリストメモ・出典一覧など 8 資料からなり，期待 locator はログ行範囲・ノート行範囲である．マルチモーダルフィッシング事例（`phish`，11 問）はログイン画面スクリーンショット・インシデント報告 PDF・出典メモの 3 資料からなる．

CTI（`cti-report-pack`，28 問）．APTnotes 収載の公開 CTI 報告書（APT1 報告書等）から抽出したページテキストを原資料とし，攻撃主体の帰属・IOC・TTP に関する質問に対して期待 locator を PDF ページ番号で与える．

AIT-LDS（`ait-timeline-pack`，25 問）．AIT-LDS V2.0 のサーバログから固定窓で抜粋した小規模ログを原資料とし，時系列・接続先に関する質問に対して期待 locator をログ行範囲で与える．

DFRWS18・DFRWS23（`dfrws2018-scenario`・`dfrws2023-scenario`，各 8 問）．DFRWS フォレンジックチャレンジ 2018（IoT）・2023（The Troubled Elevator）の多形式の証拠資料（デバイスログ・NVRAM 設定・ネットワークトレース・文書・CCTV フレーム等）から，利用条件を踏まえ必要な抜粋のみで構築した．gold は原資料から機械的に検証可能な事実に限定し，2018 の held-out gold は公式設問と独立第三者チームの解答レポートに由来する（循環性対策，5.4 節）．

OSINT（`multimodal-osint-pack`，21 問）．ブラウザログイン画面，メールヘッダ，SMS，WHOIS パネルの 4 画像とインシデント報告 PDF，出典メモを原資料とする合成 OSINT 事例であり，確認コード・送信元・登録日などの事実が画像領域にのみ存在するよう設計した．期待 locator は主に `image_bbox`（固定座標で合成）である．質問例 “What verification code is shown in the login screenshot?” の期待 locator は，`browser-login.png` の該当領域 `image_bbox` である．

A.6 入出力の実例

提案方式における Claude Sonnet 4.5 の実際の入出力例を Listing 4 に示す．モデルは確認済み Claim の locator を再利用して回答し，引用は期待 locator と重なり率 IoU が 0.5 以上で一致した．図 A·1 は，別モデル（GPT-4o-mini）による画像領域 locator の実引用を可視化したものである（評価実行の保存ログから機械抽出・検証した）．



図 A·1 画像領域 locator の実引用例（GPT-4o-mini）．(a) バンドル条件は locator を再利用し，引用（赤破線）が期待根拠（緑）と一致する（supported，正解と採点）．(b) 原資料のみの直読みでは，実寸 820×400 に対し幅 400× 高さ 820 と縦横が入れ替わった当て推量の bbox となり，registrar 欄の gold を同定できない（判定保留）．

```
Q: What verification code is shown in the login
   screenshot?
A (excerpt):
{
 "answer": "The login page screenshot shows the
   verification code **742913**. ...",
 "citations": [{
   "resource": "data/raw/
     multimodal-osint-pack/browser-login.png",
   "locator": {"type": "image_bbox",
     "bbox": [142, 285, 169, 49]}  // 期待領域と
 }]                                  // IoU>=0.5 で一致
}
```

Listing 4: バンドル条件の入出力例（`multimodal-osint-pack`）

A.7 再現性の詳細

指標の定義と集計: SR・LP・LR の定義は 4.3 節のとおりである．なお 4.3 節の回答不能質問の評価でいう「過剰引用」は根拠不在の質問に実在するファイルを引用してしまうこと（unanswerable citation）を指し，位置一致の判定とは区別する．位置一致は，行範囲（`log_line`/`note_anchor` は同一扱い）の 1 行以上の重なり，ページの一致，画像領域の IoU≥0.5 のいずれかで判定する．

© 2026 Information Processing Society of Japan

表 A·5 推量許可条件．各セルは LP/LR（禁止条件→許可条件，%）．禁止側は本実験用の独立実行であり，同一条件でも他表とは試行が異なる．許可側は主実験のプロンプトに locator 推定許可の 1 文のみを加えた変種．

モデル	事例	バンドル	直読み	簡易メモ
GPT-4o-mini	CTI	81/86 → 78/87	79/89 → 81/89	43/47 → 86/87
	AIT-LDS	89/82 → 87/82	2/3 → 50/59	29/41 → 48/56
Sonnet 4.5	CTI	58/92 → 59/91	54/91 → 58/95	13/24 → 15/31
	AIT-LDS	80/85 → 75/85	67/91 → 69/93	66/93 → 62/91
	OSINT	95/95 → 95/96	79/78 → 79/78	78/80 → 81/80
	DFRWS18	82/92 → 83/100	33/67 → 30/56	63/78 → 50/72
GPT-5	CTI	83/89 → 82/89	78/88 → 76/89	66/70 → 68/76
	AIT-LDS	86/71 → 87/69	73/91 → 76/96	78/91 → 74/93
	OSINT	91/91 → 91/90	24/26 → 24/26	25/26 → 20/21
	DFRWS18	71/78 → 77/92	45/56 → 36/56	46/53 → 44/53
Opus 5	CTI	43/95 → 48/95	41/97 → 41/98	29/91 → 27/94
	AIT-LDS	46/72 → 49/74	31/100 → 31/100	32/100 → 31/100
	OSINT	60/93 → 62/90	33/60 → 36/60	33/56 → 33/54
	DFRWS18	69/100 → 72/100	23/67 → 24/64	27/67 → 25/67

表 A·6 追加クラウド 3 種の反復書込み実験（表 2 と同一の材料・手順・列定義．太字の規約も同じ）．

		UCR（劣化）↓		生成	品質↑	コスト
モデル	条件	最終	最大	Claim 数	gold 一致数	呼出
Haiku 4.5	gate	**0%**	**0%**	27.3	**3.0**	12
	advise	**0%**	**0%**	22.0	2.3	36
	none	**0%**	**0%**	25.3	**3.0**	36
GPT-5	gate	**0%**	**0%**	40.7	5.0	12
	advise	**0%**	**0%**	56.3	5.0	36
	none	**0%**	**0%**	61.0	**5.7**	36
Opus 5	gate	**0%**	**0%**	33.3	6.3	12
	advise	1%	3%	34.3	6.3	36
	none	**0%**	**0%**	35.7	**6.7**	36

人手による裁定の詳細: 読み側は GPT-4o-mini の主実験と追加実行を合わせた全判定保留引用 2,247 件から層化抽出で事前に確定した 30 件を裁定した．結果は，locator が gold と実質同一の箇所を指していた割合 27%（locator 除去条件では 0/5），回答自体の正解率 77%，引用先が主張を意味的に支持していた割合 50%，中央値 76 秒/件である．書き側は条件を伏せた反復書込み実験にて lint を通過した Claim 45 件（各条件 15 件）の人手監査で，事実正確性は gate/advise/none=100/87/100%（正+部分），locator の意味的妥当性は 53/40/33%，引用 artifact パスの形式破損は最終状態の全数で gate 0%（0/38）対 advise 30%・none 33%だった．両セッション計約 104 分，裁定は著者 1 名による．なお，OSINT 事例の Sonnet 4.5 では判定保留引用がバンドルの平均 1.3 件/試行に対し locator 除去条件では 7.0 件/試行であり（LP はバンドル 93–96%対除去 75%），locator の保持は再確認の負担も減らす．

信頼区間と試行間変動: gold 作成は資料から機械的に検証可能な事実に限定した．試行数は全セル 3 で，バンドル LR の試行間レンジは全セル 7pt 以下，8 問事例は 1 問 ≈12.5pt の離散性がある．一方，簡易メモ等の中間的な条件は試行間レンジが同一実行内でも最大 17pt に達し，独立した実行の間では GPT-5 の CTI 簡易メモで平均 17pt 差（表 A·5 の禁止側 70%対表 A·7 の 53%）を観測した．構成・資材は同一であり，この差はプロバイダ側の実行間変動に由来する（頑健な条件では両実行が 1pt 以内で一致）．同一 gold グループを 3 試行が反復評価するため観測は独立でない．バンドルと locator 除去の LR 差 ΔLR の 95%信頼区間は，実行した全 28 組合せについて，質問（gold のない回答不能質問を除く）をクラスタとする対応ありクラスタブートストラップで算出した．再標本化対象の質問数は CTI 25・AIT-LDS 22・DFRWS18 と DFRWS23 各 5・OSINT 18・phish 8・susp-dom 13 であり，各反復では重複を許して質問を元と同数選び直し，各質問の全 gold グループと両条件・3 試行を一組として保持した．この操作を固定乱数種で 10,000 回反復し，LR 差の分布の 2.5・97.5 パーセンタイルを区間の下限・上限とした（ユニーク gold グループ単位のクラスタでも区間はほぼ一致する）．各区間は組合せごとの差の記述に用い，28 組合せを横断した有意差の判定には用いない．全実行は温度 0 だが，プロバイダ側の非決定性により試行間差は残る．

行範囲判定の感度分析: 保存済みの全引用の逐次記録（クラウド 2 モデル ×7 事例）について，行範囲の判定を interval IoU≥0.5 と始点・終点 ±1 行の二つの厳格規則で再採点した（既定規則による再採点値が本文掲載値と全レコードで一致することを検証済み）．画像領域・PDF ページが支配的な事例は全セル不変であり，行範囲中心の事例でも，バンドルの変動は LR 最大 −0.16・LP 最大 −0.25（±1 行では −0.22・−0.28）であり，比較条件側は同等以上に低下したため（例：`susp-dom` の直読み LR 72%→ 47%），バンドルと locator 除去・直読みとの対比の向きと規模は全セルで維持された．フォレンジック事例のバンドル LR は IoU≥0.5 でも 92%以上を維持する（±1 行では DFRWS23 の両モデルが 89%）．表の集計は，試行ごとに質問・gold グループ単位で通算した値（引用・gold グループの合算比）を求め，3 試行で平均したものである．図 2 のユニーク gold グループ数は PDF ページ 59・ログ行 68・画像領域 28 で，媒体混在 5/160 は除外した．held-out 層の LR（GPT-4o-mini/Sonnet 4.5，3 試行平均）は，CTI でバンドル 77/85・直読み 77/82・qa-cache 85/62，AIT-LDS で

© 2026 Information Processing Society of Japan

表 A·7 読込み評価の補助結果（3 試行平均）．上 3 事例は残り事例（GPT-4o-mini・Sonnet 4.5），下 2 事例は追加クラウド 3 種（CTI・OSINT）．各セルは SR/LP/LR（%）．太字は各行で最良の LR 値（同値含む）．— は視覚的原資料が無く不適用．

事例	モデル	直読み	簡易メモ	LLM Wiki 型	バンドル	locator 除去	text-RAG	vision-RAG	qa-cache
DFRWS23	GPT-4o-mini	100/10/11	100/0/0	100/20/33	100/97/**100**	100/55/67	60/40/44	73/39/44	0/0/0
	Sonnet 4.5	100/55/78	100/57/78	100/67/67	100/88/**100**	100/64/67	60/33/41	100/48/78	0/0/0
phish	GPT-4o-mini	88/22/24	100/29/29	79/27/21	100/82/**76**	100/23/21	0/0/0	88/23/24	50/100/36
	Sonnet 4.5	100/64/64	100/61/64	88/44/36	100/82/**88**	100/63/64	50/25/29	100/68/64	38/100/36
susp-dom	GPT-4o-mini	100/9/9	92/0/0	100/34/37	100/81/84	100/21/20	100/86/**88**	100/67/64	69/87/48
	Sonnet 4.5	100/60/72	100/73/94	100/61/74	100/84/**99**	100/52/67	100/63/89	100/62/88	62/89/52
CTI	Haiku 4.5	100/75/**90**	100/22/32	53/0/0	92/85/81	92/0/0	100/43/61	—	68/75/65
	GPT-5	100/74/**89**	100/46/53	79/0/0	96/82/**89**	84/0/0	100/52/65	—	88/66/75
	Opus 5	100/42/**97**	99/27/88	96/0/0	96/45/95	96/0/0	100/26/73	—	92/42/86
OSINT	Haiku 4.5	100/30/30	100/26/26	87/15/17	100/89/**88**	100/28/33	0/0/0	100/22/22	39/91/37
	GPT-5	100/24/26	100/25/26	83/35/26	100/91/**91**	100/29/31	0/0/0	96/17/17	37/100/33
	Opus 5	100/33/60	100/33/56	94/25/33	100/60/**93**	100/33/59	0/0/0	100/37/65	50/61/44

表 A·8 ローカルモデル（AI TOP ATOM，3 試行平均）．各セルは SR/LP/LR（%）．太字は各行で最良の LR 値（同値含む）．

事例	モデル	直読み	LLM Wiki 型	バンドル	locator 除去
CTI	Qwen3-8B	100/56/86	100/0/0	100/76/**92**	96/0/0
	Gemma4-26B	100/84/76	40/0/0	96/79/**86**	96/0/0
AIT-LDS	Qwen3-8B	95/61/68	91/22/24	95/80/**88**	95/24/29
	Gemma4-26B	91/55/**71**	9/0/0	77/85/65	59/0/0
DFRWS18	Qwen3-VL-8B	80/8/17	100/14/17	100/100/**100**	80/33/25
	Gemma4-26B	100/0/0	0/0/0	100/80/**100**	100/15/25
OSINT	Qwen3-VL-8B	100/30/33	83/23/19	100/83/**78**	100/23/26
	Gemma4-26B	100/11/11	6/4/4	94/81/**70**	100/3/4

バンドル 50/50・直読み 0/80・text-RAG 87/80 である．

実行構成: モデルは GPT-4o-mini（`gpt-4o-mini`，スナップショット `gpt-4o-mini-2024-07-18`）・Claude Sonnet 4.5（`claude-sonnet-4-5-20250929`）・Claude Haiku 4.5（`claude-haiku-4-5-20251001`）・GPT-5（`gpt-5`，スナップショット `gpt-5-2025-08-07`）・Claude Opus 5（`claude-opus-5`，日付付き ID は提供されない）およびローカルモデル 3 種（Qwen3-8B/Qwen3-VL-8B-Instruct/Gemma-4-26B-A4B-it）である．ローカルモデル 3 種は単一 GPU 機の AI TOP ATOM（GB10，128GB ユニファイドメモリ）上の vLLM（単一ストリーム・prefix cache 無効）で稼働させ，サービング構成はリビジョン・イメージ込みで記録した．全て温度 0・同一の JSON 出力形式とし，モデル指定を結果ファイルの実行構成に，使用トークン・レイテンシ・生応答を評価レコード単位で保存した（エイリアスの解決先スナップショットは 2026-08-10 に確認）．RAG 条件は埋め込み `text-embedding-3-small`・チャンク 40 行（重なり 8 行）・top-k=6 を既定とし，各チャンクに出所（ファイル・行範囲）を付与する．バンドルと同一の locator 出力指示を与え，検索条件は固定した．vision-RAG はこのテキスト検索に加えて視覚資料を添付する．候補（画像・PDF）は，ファイル名（PDF は加えて先頭 3 ページの抽出テキスト）を検索用の代替本文として，語彙一致スコアで順位付けする（OCR は用いない）．上位 4 資料を，PDF はページごとに 2 倍解像度でレンダリングした画像として添付し，出所ファイル・ページ番号のメタデータを付す．人手確認済みの `image_bbox`/`pdf_page` スパンは与えず，領域はモデル自身が導出する（locator の効果を，ページを見られること自体から分離するための設計）．なお本条件は学習済みマルチモーダル検索器（VisRAG 等）ではなく，視覚原資料をモデルに提示できる単純な参照ベースラインである．qa-cache は同一事例の他質問（held-out・回答不能を除く）の正解引用を過去の Q&A として提示する上限的な構成である．

読み書きにおける検査の挿入点: 反復書込み実験の手順・3 条件の定義・再生成上限・36 呼出の導出は 4.4 節のとおりであり，各ラウンドの更新案は**コミット前に** lint で検査され，違反（付録 A.4 の検出コード）を含む更新は gate が却下する（実測はほとんどのタスクが初回受理のため 12–16 呼出）．1 呼出あたりのプロンプト長は，知識の成長に伴い 5 ラウンドでモデルごとに約 1.3–2 倍へ増加し，知識量が増えるほど問い合わせ単価が上がるという運用コストも実測された．読み側の各問い合わせも同一の lint 済みバンドルに対して行われ，本文の全数値を結果 JSON から表・図生成スクリプトで機械生成した（手書き転記なし）．

© 2026 Information Processing Society of Japan