大規模言語モデルが生成したフェイクニュースの悪意は検知できるか？

笠井 俊希[1,a)]　三村 守[1]

概要：フェイクニュース対策では虚偽性だけでなく発信者の悪意の識別が重要となる．しかし，従来の検知研究は真偽の二値分類が中心で，悪意の有無と虚偽性を独立にラベル付けした公開データセットはほぼ存在しない．本研究では実在記事を種に，悪意なき誤り，意図的な捏造，および有害な意図をもつ事実を 4 種の大規模言語モデル（LLM）で独立に生成し，元記事を加えた 4 クラス分類を同一の検知器群で対称に評価した．教師あり検知器の 4 クラス平均の F1 スコアは生成 LLM に依存し 0.735〜0.992 と変動する一方，訓練を行わず LLM に判定させる方式は偶然水準 0.25 に対し最大 0.394 であった．単語の出現頻度のみに基づく検知器でも 0.992 に達し，記事本文から生成 LLM を同定する 4 値分類は偶然水準 0.25 に対し 0.957 に達した．訓練時と異なる LLM の記事では平均 0.885 から 0.606 へ低下し，人手作成記事の真偽判定も，クラスの偏りを補正した正答率が偶然水準 0.5 に対し 0.431〜0.626 であった．以上より，教師あり検知器の高精度は悪意の識別ではなく，生成 LLM に固有の語彙的特徴の学習に主として起因すると考えられる．

キーワード：情報障害，フェイクニュース検知，大規模言語モデル，Zero-shot 分類，データセットアーティファクト

Can We Detect Malicious Intent in Fake News Generated by Large Language Models?

Shunki Kasai[1,a)]　Mamoru Mimura[1]

Abstract: Countering fake news requires identifying not only whether content is false but also whether its author acted with malicious intent. Research on detection, however, has centered on a binary distinction between real and fake, and few public datasets label malicious intent independently of falsity. With real articles as seeds, we independently generated inadvertent errors, deliberate fabrications, and factual articles written with harmful intent using four large language models (LLMs), and evaluated the resulting four-class classification, including the original articles, symmetrically with an identical set of detectors. The macro F1 of the supervised detectors varies with the generator LLM from 0.735 to 0.992, whereas letting an LLM judge without training reaches at most 0.394 against a chance level of 0.25. Even a simple detector that relies on word frequencies reaches a macro F1 of 0.992, and a four-way classification that identifies the generator LLM from the article text alone reaches 0.957. On articles generated by an LLM other than the one used for training, the macro F1 drops from 0.885 to 0.606 on average, and the balanced accuracy of true/false judgments on human-written articles also remains between 0.431 and 0.626 against a chance level of 0.5. These results suggest that the high accuracy of the supervised detectors stems primarily not from identifying malicious intent but from learning lexical features specific to the generator LLM.

Keywords: Information Disorder, Fake News Detection, Large Language Model, Zero-shot Classification, Dataset Artifacts

1. はじめに

フェイクニュースは，選挙介入や影響工作といった認知

[1] 防衛大学校研究科
National Defense Academy of Japan
[a)] em65067@nda.ac.jp

© 2026 Information Processing Society of Japan

This paper is work in progress and not peer-reviewed.

領域への攻撃手段として利用されており，その自動検知は情報セキュリティ上の重要な課題である [17]．また，誤って拡散された情報と意図的に流布された情報とでは求められる対応が異なるため，虚偽性だけでなく発信者の悪意の識別が重要となる．しかしながら，悪意の有無を含む注釈を人手で付与するのはコストが高く，倫理的な制約も大きいことから，近年では大規模言語モデル（Large Language Model，LLM）自身に問題のある情報を生成させ，訓練データや評価データとして用いる研究が相次いでいる [2,8,14,20]．なかでも，実在の記事を種として同一トピックの問題のある記事を対で生成する方式 [2,8] は，内容とトピックを統制した評価を可能にする．

しかしながら，この対生成（paired generation）で構築したデータセットが意図の識別に妥当な評価母集団を提供するかは，十分に検証されていない．既存研究の評価は単一の生成 LLM（記事の生成に用いる LLM）に限られており，生成 LLM を変えた場合の性能変化は明らかでない．また，教師あり学習の高い精度が意図を捉えた結果か，生成 LLM に固有の言い回し（アーティファクト）を捉えた結果かの切り分けもなされていない．

そこで本研究では，虚偽性と発信者の意図の 2 軸により問題のある情報を 3 類型に整理した情報障害（information disorder）の枠組み [17] に対生成を適用し，真正な情報 real を加えた 4 クラス分類として検知器を評価する．Anthropic Claude，Meta Llama，Google Gemini，OpenAI GPT の 4 種の LLM で独立にデータセットを構築し，同一の検知器群を適用する対称評価によって対生成の構造的性質を明らかにする．用語の定義と表記の方針は後述する．本稿では，記事を 4 クラスへ分類するモデルを検知器と総称し，訓練データから学習する教師あり検知器と，プロンプトのみで分類する Zero-shot 検知器とを区別する．研究課題（RQ）は以下のとおりである．

（RQ1）生成 LLM を変えたとき，教師あり検知器のデータセット内精度と生成 LLM 間の転移性能はどのように変化するか？

（RQ2）Zero-shot 検知器は意図軸の misinformation と malinformation をどの程度識別できるか？

（RQ3）教師あり検知器と Zero-shot 検知器の性能差は何を意味するか？

（RQ4）本評価で得られた精度は，他ドメインおよび人手作成データに転移するか？

本研究の主な貢献は次の 3 点である．第一に，4 種の LLM で独立に構築した対生成データセットを，教師ありと Zero-shot の両検知器で対称に評価する枠組みを示した．第二に，生成 LLM 間の転移実験と語彙分析により，教師あり検知器の高精度が主として生成 LLM に固有のアーティファクトに起因することを示した．第三に，種コーパスの総入れ替えと人手作成データへの転移評価により，知見の頑健性と，ベンチマーク上の高精度が人手作成データでの虚偽性判定に転移しないことを示した．

2. 関連研究

2.1 情報障害の分類

Wardle と Derakhshan [17] は，問題のある情報を情報障害と総称し，misinformation，disinformation，malinformation の 3 類型に整理した．misinformation は悪意のない誤情報，disinformation は意図的に捏造された虚偽の情報，malinformation は事実に基づきながら害を与える目的で流通される情報である．本研究では，この 3 類型に，虚偽性も悪意もない情報である real を加えた 4 クラス分類問題として扱う．定義上，misinformation と disinformation は虚偽性が同じで意図のみが異なり，disinformation と malinformation は意図が同じで虚偽性のみが異なる．本稿では害を与える意図を悪意と呼び，意図軸の判定は悪意の有無の判定を指す．なお malinformation は事実に基づくため，虚偽性を含意する「偽情報」という語は用いず，総称には情報障害を用いる．以下，類型を列挙する場面では mis，dis，mal と略記し，個々の類型を論じる場面では全形を用いる．

代表的な公開データセット LIAR [16]，FakeNewsNet [13]，FEVER [15] のラベルの軸はいずれも虚偽性である．意図を扱う注釈としてはプロパガンダ技法の断片注釈 [3] や，悪意の有無を注釈したコーパス [9] があるが，前者は説得技法の有無，後者は disinformation 内の下位分類であり，mis と dis を意図の有無で分かつ構造も，mal のように虚偽性を伴わない類型も持たない．Wardle の 3 類型に対応するラベル定義を備えた公開データセットは，著者らの知る限り存在しない．

2.2 LLM による情報障害の生成と検知

Spitale ら [14] は，GPT-3 が人間よりももっともらしい虚偽の情報を生成し得ることを示唆した．Lucas ら [8] は GPT-3.5 を disinformation の生成と検知の両方に用い，実在記事から虚偽記事を対生成する枠組みを示した．Chen と Shu [2] は 7 種の生成 LLM で misinformation を生成し，LLM が生成した記事は人間の書いたものより検知が困難であることを示したが，評価は Zero-shot に限られ，教師あり検知器の生成 LLM 依存性は検討されていない．また，Zero-shot が fine-tuning した検知器を上回るという Lucas らの報告は，虚偽性軸の二値分類かつ自己ペア（生成と検知に同一の LLM を用いる設定）に対するものであり，後述するとおり，意図軸を含む 4 クラス分類には拡張できない．

Modzelewski ら [9] は，悪意の意図を注釈した英語ニュースコーパス MALINT を構築したが，意図注釈は disinformation 内の下位分類であり，Wardle の 3 類型の構造，すな

© 2026 Information Processing Society of Japan

わち mis 型と mal 型は含まない．ただし各記事は credible か disinformation かの 2 値ラベルを持つ．そのため，3 類型の構造を要しない虚偽性軸の外部評価に限り後述の実験で用いる．

本研究は，4 種の LLM で独立にデータセットを構築し，教師ありと Zero-shot の両検知器を同一データセット群で比較し，自己ペアを避けた対称評価を行う点で既存研究と異なる．

2.3 Zero-shot 分類

Wei ら [18] は Chain-of-Thought プロンプトの有効性を示した．本研究は同報告を，後述する v3 プロンプトの設計根拠とした．Yin ら [19] は，自然言語推論（Natural Language Inference，NLI）モデルを仮説文テンプレートによりテキスト分類へ転用する Zero-shot 手法を提案した．

Pelrine ら [12] は GPT-4 の Zero-shot が虚偽性軸の二値判定で従来手法を上回ると報告し，Hu ら [7] は LLM が fine-tuning した BERT に一貫して及ばないと結論づけた．Hu らはこの性能差を LLM の判定能力の不足と解釈した．また Panickssery ら [10] は，LLM が自身の生成物を高く評価する自己選好バイアス（self-preference bias）を報告した．

上記はいずれも虚偽性軸の二値分類が対象であり，意図軸を含む 4 クラス分類での評価は著者らの知る限り行われていない．本研究の対称評価は，Hu らが観察したギャップの拡大が，教師あり検知器によるアーティファクトの学習によっても生じ得ることを示す．また，本研究は自己選好バイアスの知見に基づき自己ペアを評価から除外する．

2.4 合成データセットのアーティファクト問題

機械学習分野では，タスク本来の信号と無関係にモデルの手がかりとなり得るデータ中の偏りをアーティファクトと呼ぶ．Gururangan ら [6] は自然言語推論データセットにアノテーション由来のアーティファクトが存在することを，Zellers ら [20] は機械生成テキストに生成方式由来の統計的な偏りが残り，判別器の手がかりになることを示した．本研究は，この考え方を対生成データセットに適用し，教師あり検知器の高精度がアーティファクトに依存するか否かを検証する．

3. 検証手法

3.1 全体像

本章では，各 RQ に答えるための手順を示す．**図 1** に評価枠組みの全体像を示す．公開されている英語フェイクニュースデータセット [1] の実在 real 記事を種として，4 種の LLM でそれぞれ mis，dis，mal の 3 クラスを対生成する．構築された 4 データセットの各々に，教師あり 4 手法と Zero-shot 12 通りの計 16 通りの検知器を StratifiedGroupKFold により適用する．図 1 の検知器の段のうち，教師あり検知器の評価が RQ1 に，Zero-shot 検知器の評価が RQ2 に対応し，両者の比較から RQ3 に答える．RQ4 は，種コーパスの総入れ替えと人手作成データへの転移評価により検証する．

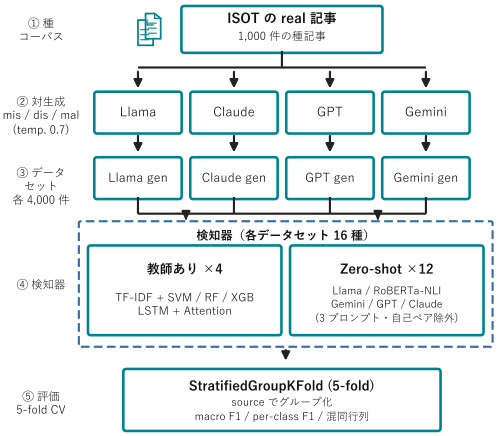


図 1 評価枠組みの全体像

3.2 データセット構築

元データは ISOT Fake News Dataset [1] の real 記事 21,417 件で，本文 100 語以上の 17,668 件から乱数シード 42 で 1,000 件を抽出した．生成には Anthropic Claude Sonnet 4.6，Meta Llama-3.1-8B-Instruct，Google Gemini-2.5-flash，OpenAI GPT-4o-mini の 4 種を用いた．各 real 記事を種として，各 LLM に 3 クラスを対生成させた．mis は同一トピックで悪意なく事実誤認を含んだ体裁の記事，dis は意図的な捏造を含み読者を欺く記事，mal は事実に基づくが特定の対象に害を与える意図で書かれた記事である．生成のパラメータは 4 種の LLM で統一し，**表 1** に示す設定を用いた．

最終的に，各 LLM につき種記事 1,000 件の 4 クラス分，計 4,000 件を得た．4 クラスは同一の種記事群に由来し，記事冒頭の発信地や配信元の表記も種記事の段階で除去しているため，話題や題材に起因する偏りはクラス識別の手がかりになりにくい．ただし real のみ人手作成テキストのままであり，real と他 3 クラスの識別には，意図と無関係に人手作成か LLM 生成かという手がかりが利用可能である．この非対称性は後述の考察で考慮する．

3.3 前処理

テキストは NFKC 正規化後，改行と連続空白を単一空白に統合した．TF-IDF によるベクトル化は 4 データセットで独立に行った．評価データへのリークを防ぐため，語彙と重みの学習には交差検証の各 fold の訓練データのみを用いた．

© 2026 Information Processing Society of Japan

3.4 プロンプト設計

Zero-shot 検知では，LLM に直接ラベルを問う生成型と，自然言語推論モデルを用いる NLI 型の 2 種の検知器を用いた．生成型は応答のうち最初に出現するラベル名を分類結果とし，ラベル名を含まない応答は real に割り当てた．NLI 型は，各ラベルの仮説文に対する含意（entailment）確率が最大のラベルを選択する [19]．生成型のプロンプトは，中立的な役割と 4 クラスの選択肢および定義を与える標準指示型 v1，最小限のラベル選択指示のみを与える最小指示型 v2，v1 に Wardle 定義の詳細と段階的な推論を促す指示を加えた詳細指示型 v3 の 3 種である．NLI 型にも同様の 3 段階の仮説文テンプレートを用意した．生成型の推論ではラベル 1 語のみの応答を求めたため，v3 で段階的な推論を促しても推論過程は出力されない．Zero-shot の全プロンプトは補足資料として公開し，データセット生成用プロンプトの扱いは研究倫理の節で後述する．

3.5 評価設計

評価には StratifiedGroupKFold [11] を用い，同一の種記事から生成された 4 サンプルが訓練と評価に跨らないよう，種記事の識別子でグループ化し，対生成に特有のリーク（source leakage）を防止した．

主指標は，クラスごとの F1 の単純平均である macro F1 とし，補助的に accuracy，per-class F1，5-fold 合算の混同行列を示す．本稿では偶然水準を，一様ランダムに予測した場合の期待値とする．値は 4 クラス分類で 0.25，虚偽性 2 値で 0.5 である．なお macro F1 は予測が特定クラスへ縮退すると偶然水準を下回り得る．

3.6 検知器の構成

教師あり検知器は，TF-IDF に Support Vector Machine（SVM），Random Forest（RF），XGBoost（XGB）をそれぞれ組み合わせた 3 手法と，LSTM に Bahdanau Attention を組み合わせた 1 手法の計 4 手法である．以下，特徴量と分類器の組合せは TF-IDF + SVM のように表記する．Zero-shot 検知器には，Llama-3.1-8B-Instruct，RoBERTa を基にした NLI cross-encoder である cross-encoder/nli-roberta-base，Gemini-2.5-flash，GPT-4o-mini，Claude Sonnet 4.5 の 5 種を用い，それぞれ 3 種のプロンプトで評価した．以下，Zero-shot 検知器は Llama_ZS のように接尾辞 ZS を付して表記する．ただし，生成に用いた LLM と開発元が同じモデルによる Zero-shot 分類は，自己選好バイアスを避けるため各データセットで除外した．Claude については，生成に Sonnet 4.6，Zero-shot に Sonnet 4.5 を用いたが，開発元が同じであるため除外した．

4. 検証実験

本章では，4 データセットに対する 16 通りの検知器の対称評価の結果と，種コーパスを入れ替えた再現実験の結果を示す．

表 1 実験環境と主要な設定

項目	設定
計算環境	Intel Core i7-13700KF，RTX 4090 24GB，メモリ 64GB，Windows 11，CUDA 12.1，Python 3.8.9
生成	temperature 0.7，JSON 出力，リトライ最大 5 回，生成長 0.5〜2.0 倍，Gemini は thinkingBudget 0
モデル ID	生成は `claude-sonnet-4-6`，`gpt-4o-mini`，`gemini-2.5-flash`，Zero-shot は `claude-sonnet-4-5`，`gpt-4o-mini-2024-07-18`，`gemini-2.5-flash`
TF-IDF	max_features 100,000
検知器	SVM は kernel linear，RF と XGBoost は n_estimators 100，LSTM は双方向で隠れ状態次元 128
Zero-shot 推論	temperature 0，最大 10 トークン
交差検証	StratifiedGroupKFold，n_splits 5，shuffle True，random_state 42

4.1 実験環境

実験環境と主要な設定を 表 1 にまとめる．LLM の推論は OpenAI，Anthropic，Google Vertex AI の各 API を用い，Llama のみ，生成と Zero-shot 推論の双方を RTX 4090 上で 4-bit NF4 量子化 [5] を適用してローカルで実行した．API へのアクセスは 2026 年 6 月から 7 月である．

4.2 教師あり検知器の結果

教師あり検知器 4 手法の macro F1 を **表 2** に示す．**図 2** のとおり，4 手法のすべてで Llama，Claude，GPT，Gemini の生成データセットの順に macro F1 が単調に増加した．以下，数値を 4 つ並べる場合は Llama，Claude，GPT，Gemini 生成の順である．accuracy でも同様であり，SVM では 0.749，0.888，0.928，0.993 と増加した．4 手法と 2 指標を組み合わせた計 8 系列のすべてでこの単調な増加が成立した．accuracy と macro F1 の差は，最大でも Llama 生成データセットにおける RF の 0.033 であり，クラス間の性能差は小さい．

misinformation は real と事実の正誤のみで区別され，4 クラスの中で文体上の手がかりが最も乏しいが，F1 は Llama 生成の 0.500 から Gemini 生成の 0.987 まで変動しており，高精度が意味内容の検証ではなく語彙パターンに依存する可能性をクラス単位で示唆する．なお real の F1 が GPT 生成と Gemini 生成で 0.993 以上に達した点には，3.2 節で述べた人手作成と LLM 生成の非対称性も寄与し得る．real を除いた 3 クラスの macro F1 は SVM

© 2026 Information Processing Society of Japan

表 2 教師あり検知器の 5-fold 平均 macro F1 ± fold 間標準偏差（太字は各手法の最良値）．SVM，RF，XGB は TF-IDF を，LSTM は Bahdanau Attention を併用する

Detector	Llama gen	Claude gen	GPT gen	Gemini gen
SVM	0.735±0.018	0.886±0.006	0.927±0.007	**0.992±0.003**
RF	0.661±0.023	0.794±0.012	0.892±0.011	**0.976±0.006**
XGB	0.720±0.023	0.835±0.009	0.893±0.012	**0.958±0.009**
LSTM	0.673±0.026	0.763±0.037	0.856±0.013	**0.865±0.096**

で 0.737，0.909，0.905，0.990 となり，両端の順序は保存されたが中位 2 者は入れ替わり，差は fold 間標準偏差の範囲内であった．FakeHealth での再現実験でも同様である．

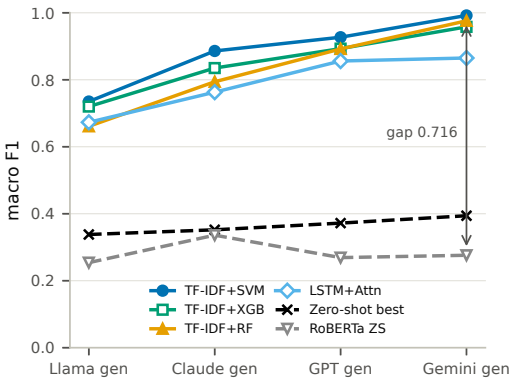


図 2 教師あり検知器 4 手法と Zero-shot 検知器の macro F1．Zero-shot は各データセットの最良値と全データセットに共通する RoBERTa_ZS の 2 系列を示す．gap は TF-IDF + SVM と RoBERTa_ZS の差を示す．

誤分類が生じるクラスの組も生成 LLM に依存する．Llama 生成と Claude 生成では misinformation を real と誤る事例が最多であり，SVM ではそれぞれ 52% と 30% を占めた．GPT 生成では disinformation と malinformation の相互の誤りが主であり，各クラスの約 10% を占めた．Gemini 生成では誤りがほぼ消失した．これは後述する語彙分析と整合する．

4.3 Zero-shot 分類の結果

各 Zero-shot 検知器の各データセットに対する macro F1 のうち，3 種のプロンプトの最良値を **表 3** に示し，全 48 通りは補足資料に示す．各データセットの生成 LLM と開発元が同じモデルによる分類は除外し，表中では — で示す．

最良値は，Gemini 生成に対する Claude_ZS の v3 で得た 0.394 であった．各データセットで最良の検知器の per-class F1 では，misinformation は Gemini 生成に対する Claude_ZS の 0.195 が最大であり，GPT_ZS と Gemini_ZS は全条件で 0.03 以下であった．

プロンプト間では，生成型の macro F1 は 12 通り中 10 通りで v1，v2，v3 の順に高くなり，NLI 型の RoBERTa では逆に v1，v2，v3 の順に低くなった．3.4 節のとおり v3 でも推論過程は出力されないため，生成型の改善は主として Wardle 定義の詳細化によると考えられる．

表 3 Zero-shot の最良 macro F1（括弧内はプロンプト，太字は全体の最良値，— は自己ペアとして除外した条件）

Detector	Llama gen	Claude gen	GPT gen	Gemini gen
Llama_ZS	—	0.288 (v3)	0.177 (v3)	0.241 (v3)
RoBERTa_ZS	0.254 (v1)	0.336 (v1)	0.269 (v1)	0.276 (v1)
Gemini_ZS	0.277 (v3)	0.352 (v3)	0.286 (v3)	—
GPT_ZS	0.207 (v3)	0.349 (v3)	—	0.349 (v3)
Claude_ZS	0.338 (v2)	—	0.372 (v2)	**0.394 (v3)**

TF-IDF + SVM と Zero-shot 検知器のギャップは，全データセット共通の RoBERTa_ZS を基準に 0.481，0.550，0.658，0.716 と単調に拡大した．Zero-shot 最良値を基準としても 0.397 から 0.598 へ拡大した．

Zero-shot の生応答は未保存のため，クラス比率を保って抽出した計 7,200 件を再推論して検査した．ラベル名を含まない応答は各条件 600 件中 0 件であり，二項分布に基づく区間推定でも発生率は 0.5% 未満である．3.4 節で述べた real への割り当ては，結果に影響していないと考えられる．

4.4 データセットの語彙分析

教師あり検知器が学習した手がかりを調べるため，各データセットの語彙を 4 クラスすべてで分析した．生成 LLM 間の差が最も大きいのは disinformation クラスであった．Claude，Llama，Gemini には sources が共通して上位に現れ，Claude と Gemini では anonymity が，Claude では senior が上位に入るなど，情報源に関する語彙が並ぶのに対し，GPT は情報源語彙をほとんど含まず，代わりに narrative，declared など政治的な意見形成の語彙が上位を占める．生成される語彙のパターンは LLM ごとに異なり，この傾向は他のクラスでも同様である．

4.5 生成 LLM 間転移

生成 LLM に固有の特徴が検知精度に与える影響を測るため，TF-IDF + SVM を一方の LLM の生成データで訓練し，他方の生成データで評価する転移実験を行った．訓練と評価の全組合せの macro F1 を行列にまとめ，**表 4** に示す．以下，これを転移行列と呼ぶ．macro F1 の平均はデータセット内の 0.885 から転移時の 0.606 へ低下し，最も低下したのは GPT 生成から Claude 生成への転移であり，0.242 であった．一方で GPT 生成から Gemini 生成への転移は 0.959 を維持しており，転移の成否は LLM の組に強く依存し，かつ非対称である．転移行列の非対角の列平均，すなわち評価データ側の平均は 0.350，0.427，

© 2026 Information Processing Society of Japan

表 4　生成 LLM 間転移の macro F1（行が訓練，列が評価，対角括弧は 5-fold CV，太字は非対角の最小と最大）

train \ test	Llama gen	Claude gen	GPT gen	Gemini gen
Llama gen	(0.735)	0.560	0.819	0.852
Claude gen	0.379	(0.886)	0.637	0.884
GPT gen	0.370	**0.242**	(0.927)	**0.959**
Gemini gen	0.300	0.480	0.793	(0.992)

0.750，0.898 と，表 2 のデータセット内精度と同一順序で並ぶ．転移行列の行ごとの平均は 0.524〜0.744 に収まっており，成否を規定するのは訓練データ側よりも評価データ側である．評価データのアーティファクトが強いほど，どの LLM で訓練した検知器でも正しく分類できる傾向がある．

4.6　他ドメインでの再現（FakeHealth）

以上の結果が種コーパスである ISOT に固有でないことを確認するため，種記事を，専門家のレビュー付き健康ニュースである FakeHealth [4] のうち rating 3 以上の 1,000 件に総入れ替えし，同一のプロンプトとパイプラインで再構築して評価した．変更点は媒体名マスクと生成長の明示のみで，全クラスに一律である．マスクの macro F1 への寄与は ±0.002 以内であった．

TF-IDF + SVM の macro F1 は 0.686，0.973，0.962，0.979 となり，Llama が最下位，Gemini が最上位という関係が再現された．中位 2 者の差は fold 間標準偏差の範囲内である．ただし水準は種コーパスに依存し，Claude 生成は 0.886 から 0.973 へ上昇した．Zero-shot は全 48 通りで 0.434 以下であり，misinformation の F1 は最大 0.278 であった．TF-IDF + SVM と Zero-shot 最良値のギャップは 0.397，0.539，0.557，0.559 であり，ISOT 版の 0.397，0.534，0.555，0.598 とほぼ同じであった．malinformation の予測先が検知器により分かれるという後述の判断軸の偏りも再現された．

5.　考察

5.1　misinformation クラスの判別の困難さ

misinformation クラスの Zero-shot F1 は最大でも 0.195 であり，大半の条件で 0.1 を下回った．FakeHealth での再現実験でも最大 0.278 であった．misinformation と disinformation の唯一の差異である発信者の意図はテキスト表層に直接現れにくく，記事本文のみを入力とする本設定では，意図の識別は困難であると考えられる．ただし低性能のすべてが識別不能性に帰着するわけではなく，後述するように，Llama_ZS が misinformation を虚偽情報全般の総称と解釈するラベル名の混乱も一因である．

5.2　Zero-shot と教師あり検知器のギャップが示すアーティファクト

4.2 節のとおり，計 8 系列すべてで生成 LLM の順序が再現されており，単一の手法や指標に固有の偶発的な現象である可能性は低い．隣接する生成 LLM 間の差は，LSTM の GPT 生成と Gemini 生成の間を除き fold 間標準偏差を上回った．ただし 8 系列と fold は互いに独立でないため，これらの比較は近似である．順序の要因としては各 LLM の指示追従能力の差が考えられ，生成時の再生成率が Llama 19.2%，Claude 9.7%，GPT 6.2%，Gemini 1.4% と教師あり検知器の精度の逆順に並んだことと整合する．ただし追従能力は直接測定しておらず，Llama のみ規模が 8B で量子化の条件も異なるため，裏づけは間接的である．

この差が種コーパスに由来するとは考えにくい．4 データセットは同一の種記事から構築されており，同一テキストである real クラスの F1 も 0.730 から 0.999 まで変動している．種コーパスを総入れ替えした 4.6 節の再現実験も，要因が生成 LLM 側にあるというこの結論を追認する．

一方，Zero-shot の macro F1 に同じ順序は現れなかった．表 3 の最良値は，自己ペア除外のためデータセットごとに異なる検知器から選ばれており，データセット間の比較には適さない．全データセットに共通する RoBERTa_ZS を基準にとると，図 2 のとおり単調増加は再現されず，Claude 生成の 0.336 が最大であった．Zero-shot 最良値は 0.338 から 0.394 へ僅かに増加しており，Gemini 生成でクラス間の意味的な差が大きい可能性は残るが，その増分 0.056 は教師あり側の増分 0.257 の 2 割程度である．したがって，データセット間の精度差の大半は，Zero-shot が利用できない語彙的な手がかり，すなわちアーティファクトで説明できると考えられる．語順を考慮しない bag-of-words の TF-IDF が macro F1 0.992 に達した事実も，アーティファクトが表層語彙のレベルに存在することを示唆している．

5.3　アーティファクトの直接検証

クラスごとの生成指示が文面に残す文体差は，設計上の正当な信号とも解釈し得る．本研究がこれをアーティファクトと呼ぶ根拠は転移不能性，すなわち 4.5 節に示したとおり，生成 LLM を跨ぐと精度が低下し，人手作成データにも通用しないことにある．アーティファクトの存在は 2 つの実測でも確認できる．第一に，クラス識別に強く寄与する上位 n-gram を各クラス 50 語ずつ除去すると，macro F1 は fold 間標準偏差を超えて低下したが，低下幅は 0.017〜0.065 に留まり，除去後も 0.671〜0.975 と高い水準を保った．アーティファクトは特定の定型句に限らず，機能語を含む語彙分布全体に分散していると考えられる．第二に，mis，dis，mal のテキストのみから生成 LLM を同定する 4 値分類の macro F1 は，偶然水準 0.25 に対して

© 2026 Information Processing Society of Japan

0.957 に達し，生成 LLM に固有の指紋と呼び得る語彙的特徴の存在を示唆している．さらに，種記事の文体の維持を指示する文体抑制プロンプトで Gemini 生成データセットを再構築しても，教師あり検知器の macro F1 は 0.841，生成 LLM の同定は 0.907 と高い水準を保った．文体抑制による緩和は部分的であり，アーティファクトが対生成に内在することを示唆する．なお抑制条件では mis クラスの 32% が種記事とほぼ同一の本文になっており，F1 の低下の一部はラベルの妥当性の低下によると考えられる．

5.4 4 種の LLM における disinformation 生成傾向の質的類型

語彙分析の結果，4 種の LLM は disinformation の生成において質的に異なる類型を示した．Claude は，独占取材を装う told this outlet が文書の 20% に出現する擬似引用網羅型である．Llama は，上位 5 語のうち 3 つを our，we，we re という一人称が占める点で他の 3 者と異なり，特定の語句に集中しない一人称過多かつ分散的な類型である．なお we re は we’re が前処理で分割されたものである．Gemini は，speaking on condition of anonymity という単一の定型句が文書の 23% に出現する秘匿情報源集中型である．GPT は，narrative や declared など意見形成の語彙が上位を占める政治意見型であり，この類型は disinformation の定義からやや逸脱する．生成 LLM は disinformation らしさを互いに異なる文体で表現しており，この類型の差は，4.5 節に示した生成 LLM 間転移の成否に直接現れている．

5.5 意図軸の LLM 依存的解釈と二値縮退

混同行列の分析から，全 Zero-shot 検知器が 4 クラス分類を実質的に二値分類へ縮退させていることが分かった．

misinformation はいずれの検知器でも自クラスへほとんど分類されず，Gemini 生成データセットでは行正規化率が 0.11 以下であった．誤り先は検知器により分かれ，GPT_ZS と Gemini_ZS では 0.84〜1.00 が real へ，Claude_ZS では 0.59 が disinformation へ流れた．malinformation の予測先も正反対であり，GPT_ZS と Gemini_ZS は 76〜99% を real と判定した．これは，事実に基づく内容を real とみなす虚偽性軸の判断と解釈できる．対照的に Claude_ZS は，malinformation の 51〜94% と misinformation の過半を disinformation と判定し，攻撃的な文体を捏造とみなす悪意の軸に偏って，real と disinformation の二値判定に縮退していた．

さらに Llama_ZS は disinformation の 52〜76% に misinformation を付与しており，虚偽情報全般の総称とする日常語の用法で解釈していると考えられる．

すなわち，各 Zero-shot 検知器は 2 軸のうち実質的に 1 軸に偏って判断しており，軸の選択とラベル名の解釈は各 LLM の事後学習に依存すると考えられる．本評価の範囲では，Zero-shot による 4 クラス分類はいずれの LLM でも成立していない．

表 5 人手作成データにおける虚偽性 2 値の balanced accuracy（偶然水準 0.5，太字は行内最良）．列は訓練に用いた生成データを示し，本文では Llama 訓練のように表記する．上 2 行は ISOT 版，最下行は FakeHealth 版の TF-IDF + SVM

テストデータ	Llama gen	Claude gen	GPT gen	Gemini gen
ISOT	**0.616**	0.443	0.520	0.500
MALINT	**0.626**	0.431	0.537	0.510
FakeHealth	**0.510**	0.502	0.501	0.500

5.6 人手作成データへの転移

人手作成データへの転移では，mis と dis を虚偽，real と mal を真正として 4 クラス予測を虚偽性の 2 値に縮約し，人手作成の real 記事と fake 記事に対する balanced accuracy（クラスごとの正解率の平均）を **表 5** に示す．評価件数は，ISOT が fake 23,481 件と種を除く real 20,417 件，MALINT が 1,600 件，FakeHealth が fake 631 件と real 188 件である．なお ISOT の評価データには訓練用 real の 100 語フィルタを課しておらず，長さ分布の差が影響し得る．最良でも 0.626，最低は 0.431 であり，人手 fake の 59〜94% が real と判定された．

この低下は，訓練データと評価データの分野の違いでは説明しにくい．FakeHealth 版では，種コーパスと，評価に用いた人手の fake および real がすべて FakeHealth 由来であり分野が揃っているが，いずれの生成データで訓練した検知器でも balanced accuracy は 0.500〜0.510 であった．ISOT と MALINT では，アーティファクトが最も弱い Llama 訓練のみが偶然水準を明確に上回り，転移行列の行平均も 0.744 と最良であった．独立した 2 つの実験が，アーティファクトの弱いデータで訓練した検知器ほど外部に汎化することを支持している．また Claude 訓練は偶然水準を下回った．学習された mis，dis，mal は，特定 LLM のアーティファクトの有無に対応すると解釈できる．

この傾向は語彙ベースの検知器に限らない．RoBERTa-base を fine-tuning した検知器でも，データセット内の macro F1 は 0.789〜0.989 と生成 LLM に依存し，転移時には最悪 0.375 まで劣化した．ISOT への転移でも balanced accuracy は Llama 訓練で 0.767，Gemini 訓練で 0.637 と訓練データ側の順序が保存された．ただし Llama 訓練は TF-IDF + SVM の 0.616 を上回り，意味理解型の検知器では劣化が部分的に緩和されると考えられる．以上より，本評価の範囲では，ベンチマーク上の高精度は人手作成データに対する虚偽性軸の検知能力を反映していないと考えられる．

© 2026 Information Processing Society of Japan

5.7 本研究の限界

本研究の限界として次の 5 点を挙げる．第一に，人手作成データでの検証は虚偽性軸の 2 値に限られ，意図軸の直接検証は残る課題である．第二に，元データが英語であるため他言語への一般化は確認していない．第三に，misinformation の生成は，悪意なく誤りを含んだ体裁を LLM に演じさせる設計であり，実世界の misinformation が持つ意図の不在を完全には再現できない．ただしこの限界は対生成全般に内在し，意図軸が生成指示によってのみ付与されるという本研究の主張を裏づける．第四に，3.2 節で述べたとおり real のみが人手作成テキストであるため，4 クラスの macro F1 の絶対値は意図軸の識別性能を過大評価し得る．ただし本研究の主張は misinformation の F1 の変動と，転移および人手作成データでの精度低下に基づくものであり，この非対称性に左右されない．第五に，Zero-shot 検知は推論過程を出力させない最大 10 トークンの設定で評価しており，RQ2 の結論はこの設定に限られる．ただし最良条件の 600 件を最大 1024 トークンで再推論しても macro F1 は 0.400 であり，本実験値 0.395 と変わらなかった．

6. おわりに

本研究では，情報障害 3 類型に real を加えた 4 クラス分類を，4 種の LLM で独立に構築したデータセットで対称に評価した．評価の結果，教師あり検知器の高精度は主として生成 LLM に固有のアーティファクトに起因すると考えられ（RQ1，RQ3），Zero-shot 検知器による意図軸の識別は困難であり（RQ2），高精度は人手作成データに転移しなかった（RQ4）．したがって，対生成ベンチマークの高精度は悪意の識別能力を示すものではないと考えられる．合成データを用いた評価では，生成 LLM を明示するだけでなく，生成 LLM を跨ぐ転移と同定の結果を，データセットの妥当性を診断する材料として併せて報告することが望ましい．今後の課題は，人手注釈データによる意図識別の直接検証である．

参考文献

[1] Hadeer Ahmed et al. Detection of online fake news using n-gram analysis and machine learning techniques. In *Proc. ISDDC*, 2017.

[2] Canyu Chen and Kai Shu. Can LLM-generated misinformation be detected? In *Proc. ICLR*, 2024.

[3] Giovanni Da San Martino et al. Fine-grained analysis of propaganda in news articles. In *Proc. EMNLP-IJCNLP*, 2019.

[4] Enyan Dai et al. Ginger cannot cure cancer: Battling fake health news with a comprehensive data repository. In *Proc. ICWSM*, 2020.

[5] Tim Dettmers et al. QLoRA: Efficient finetuning of quantized LLMs. In *Proc. NeurIPS*, 2023.

[6] Suchin Gururangan et al. Annotation artifacts in natural language inference data. In *Proc. NAACL-HLT*, 2018.

[7] Beizhe Hu et al. Bad actor, good advisor: Exploring the role of large language models in fake news detection. In *Proc. AAAI*, 2024.

[8] Jason Lucas et al. Fighting fire with fire: The dual role of LLMs in crafting and detecting elusive disinformation. In *Proc. EMNLP*, 2023.

[9] Arkadiusz Modzelewski et al. MALicious INTent dataset and inoculating LLMs for enhanced disinformation detection. In *Proc. EACL*, 2026.

[10] Arjun Panickssery et al. LLM evaluators recognize and favor their own generations. In *Proc. NeurIPS*, 2024.

[11] Fabian Pedregosa et al. Scikit-learn: Machine learning in Python. *J. Mach. Learn. Res.*, 12, 2011.

[12] Kellin Pelrine et al. Towards reliable misinformation mitigation: Generalization, uncertainty, and GPT-4. In *Proc. EMNLP*, 2023.

[13] Kai Shu et al. FakeNewsNet: A data repository with news content, social context and spatiotemporal information. *Big Data*, 8(3), 2020.

[14] Giovanni Spitale et al. AI model GPT-3 (dis)informs us better than humans. *Science Advances*, 9(26), 2023.

[15] James Thorne et al. FEVER: A large-scale dataset for fact extraction and VERification. In *Proc. NAACL-HLT*, 2018.

[16] William Yang Wang. “Liar, liar pants on fire”: A new benchmark dataset for fake news detection. In *Proc. ACL*, 2017.

[17] Claire Wardle and Hossein Derakhshan. Information disorder: Toward an interdisciplinary framework for research and policy making. Technical report, Council of Europe, 2017.

[18] Jason Wei et al. Chain-of-thought prompting elicits reasoning in large language models. In *Proc. NeurIPS*, 2022.

[19] Wenpeng Yin et al. Benchmarking zero-shot text classification: Datasets, evaluation and entailment approach. In *Proc. EMNLP-IJCNLP*, 2019.

[20] Rowan Zellers et al. Defending against neural fake news. In *Proc. NeurIPS*, 2019.

研究倫理

元データはすべて公開データセットである．生成したテキストとデータセット生成用のプロンプト全文は，悪用防止のため一般公開せず，研究目的に限り提供を検討する．生成時は研究目的である旨を全プロンプトに明示した．本研究は特定の政治的立場や個人を対象としない．補足資料は `https://github.com/Skasai0716/supplement` で公開する．

© 2026 Information Processing Society of Japan