LLMの不適切応答検知におけるHEXACOシグナルとアンサンブルの適用可能性の評価

長谷川 健人[1,a)]　披田野 清良[1]

概要：大規模言語モデル（LLM）の普及に伴い，応答の安全性を評価する技術が重要になっている．本稿では，AEGIS2 データセットを用いて応答テキストから推定した HEXACO の 6 因子と応答の安全性の関係を評価し，さらに WildGuard などの既存検知器を組み合わせたアンサンブル手法の適用可能性を評価する．分析の結果，応答の安全性と HEXACO 因子の傾向の間に系統的な差異があり，全体比較では Agreeableness と Extraversion，カテゴリ内の比較では Openness が識別に関係することを明らかにした．HEXACO 因子を用いる検知器では，AEGIS2 データセットにおいて Recall=0.975，F1=0.651 となり，アンサンブルによる検知では F1=0.841 を達成した。さらに，複数のベンチマークを用いた評価の結果，HEXACO シグナルが既存検知器を補完するコンパクトで解釈可能な表現として機能する条件を明らかにした．

キーワード：大規模言語モデル，ガードレール，HEXACO，安全性検知，アンサンブル

Evaluating the Applicability of HEXACO Signals and Ensembles for Detecting Inappropriate LLM Responses

Kento Hasegawa[1,a)]　Seira Hidano[1]

Abstract: As large language models (LLMs) become widespread, techniques for assessing response safety have become increasingly important. Using the AEGIS2 dataset, this paper evaluates the relationship between six HEXACO factors inferred from response text and response safety, and further evaluates the applicability of ensembles with conventional detectors, including WildGuard, to LLM safety detection. The analysis reveals systematic differences between response safety and HEXACO profiles: Agreeableness and Extraversion are associated with discrimination in the overall comparison, whereas Openness is associated with discrimination in within-category comparisons. The detector using HEXACO factors achieves Recall=0.975 and F1=0.651 on AEGIS2, and the ensemble detector achieves F1=0.841. Furthermore, evaluations using multiple benchmarks identify the conditions under which HEXACO signals function as a compact and interpretable representation that complements conventional detectors.

Keywords: Large language model, guardrail, HEXACO, safety detection, ensemble

1. はじめに

大規模言語モデル (Large Language Model, LLM) は，対話支援，文書作成，情報検索などの幅広い用途に利用されている．一方で，利用者の要求や文脈によっては，暴力，自傷，他者への危害，違法行為等を助長し得る不適切な応答を生成するおそれがある．このため，生成された応答を安全性の観点から判定するガードレール技術は，LLM を実運用に供するための重要な構成要素となる．応答安全性の検知では，不適切応答の見逃しを抑える再現率と，適切応答を過度に遮断しない適合率との両立が求められる．

既存の安全性検知器は，応答に含まれる内容や表現を直接分類する方式が主流である．この方式は明示的な有害表

[1] 株式会社 KDDI 総合研究所 / KDDI Research, Inc.
[a)] kt-hasegawa@kddi.com

© 2026 Information Processing Society of Japan

This paper is work in progress and not peer-reviewed.

現に有効である一方，表現の多様性や危害カテゴリの違いによって誤り方が異なる．したがって，内容分類とは異なる観点から応答を表現し，既存検知器の判定を補完できるシグナルを検討することには意義がある．

既存研究では，会話文から推測したパーソナリティ指標を用いて不適切な文章を検知する手法が提案されている [3]．同研究では，Honesty–Humility，Emotionality，Extraversion，Agreeableness，Conscientiousness，Openness の 6 因子から構成される HEXACO モデル [1] に基づき，会話文から各因子のスコアを推定する．さらに，いずれかの因子スコアがしきい値以下である場合に，不適切候補と判定する規則を用いる．本稿では，これらの因子スコアを応答テキストに現れる言語的傾向を表すモデル出力として扱う．

本稿では，先行研究で用いた HEXACO シグナルを既存の内容ベース検知器とアンサンブルとして統合する枠組みの適用可能性を評価する．具体的には，適切・不適切応答の間に見られる因子傾向の差異を分析し，AEGIS2 データセットに加えて WildGuardMix および XSTest を用いる分布外評価，WildGuard との 4 種類の選択的アンサンブル統合戦略，4 検知器間の相関分析，および軽量なローカル推定器の構成比較を行う．特に，1024 次元のテキスト埋め込みを用いる近傍探索と，6 次元の HEXACO 距離を併用する方式を比較し，低次元かつ解釈可能な表現の適用可能性を評価する．

本稿の貢献は，以下の 3 点である．

- AEGIS2 において，応答テキストから推定した HEXACO 因子と安全性に関する二値ラベルとの関係を全体比較および危害カテゴリ内比較の双方から定量的に示す．
- HEXACO 因子を入力とする高再現率の判定モデルと，WildGuard を基準とする 4 種類の統合戦略を構成し，既存検知器を補完する表現としての有用性を評価する．
- AEGIS2，WildGuardMix，XSTest における分布内・分布外の性能，ならびに検知器間の一致度を分析し，HEXACO シグナルが有効となる条件を明らかにする．

2. 関連研究

2.1 人格モデルと HEXACO

人格特性を少数の因子で表すモデルとしては，Big Five が広く用いられてきた [4]．HEXACO はこれを拡張し，誠実さや謙虚さに関わる Honesty–Humility を加えた 6 因子モデルである [1]．各因子は本来，人間の行動傾向を説明するために設計された概念であるが，近年では，生成モデルの出力が示す言語的傾向を分析する枠組みとしても利用されている．

Wang ら [5] は，HEXACO の人格特性をプロンプトによって LLM に付与し，生成応答のバイアス，ネガティブな感情表現，および毒性への影響を分析している．具体的には，3 種類の LLM を対象に，毒性およびバイアスに関する 3 種類のベンチマークを用いて評価し，因子の設定に応じて出力の安全性に関わる傾向が一貫して変化することを報告している．この知見は，HEXACO に基づく条件付けが生成応答の内容に影響することを示すものである．

本稿では，応答文を入力として推定された因子スコアを，内容語の出現だけでは捉えにくい文体的・意味的傾向を要約した特徴量として扱う．これにより，因子名の日常的な意味と，検知器に入力する特徴量を混同しない．

2.2 LLM 応答の安全性検知

LLM の安全性検知では，危害カテゴリに基づく教師あり分類器，安全性方針を明示した言語モデル，および商用モデレーション API が用いられる．LlamaGuard は安全性カテゴリに沿って入出力を判定するモデルであり [6]，WildGuard はプロンプト有害性, 応答有害性, 拒否応答を統合的に扱う分類フレームワークである [7]．また，OpenAI Moderation API は，複数の不適切内容カテゴリに対するフラグ判定を提供する．

これらの方法は高い性能を示す一方，それぞれが異なる学習データ，分類方針，しきい値に依存するため，検知対象の分布が変化した場合には性能の変動が生じる．複数検知器を統合するアンサンブルは，このような誤り方の差異を利用して性能を安定化させる方法である．ただし，単純な多数決は各検知器の得意・不得意を区別しないため，統合規則と重みの設計が重要となる．

2.3 本研究の位置付け

本稿では，HEXACO を応答から抽出される補助的な検知シグナルとして位置付ける．具体的には，内容に基づく既存検知器の判定を保持しつつ，既存検知器が適切と判定した応答に対してのみ HEXACO シグナルを利用する選択的補完を検討する．評価では，検知器間の相関，見逃しの補完，低次元表現の解釈可能性を分析する．

3. 提案手法

3.1 全体構成

提案手法は，LLM が生成した応答テキストを入力として，不適切応答を検知する枠組みである．まず，応答テキストから HEXACO の 6 因子に対応するシグナルを推定し，そのシグナルを用いて不適切である可能性を判定する．次に，この判定を既存検知器の出力と統合し，各検知器の得意な応答を補いながら最終判定を得る．このように，内容に基づく既存検知器と応答の言語的傾向を表す HEXACO シグナルを組み合わせることで，単一の検知器では捉えにくい不適切応答の検知を目指す．

図 1 に，提案枠組みの全体像を示す．提案枠組みは，応答テキストから HEXACO 因子を推定する推定器（*Esti-*

© 2026 Information Processing Society of Japan

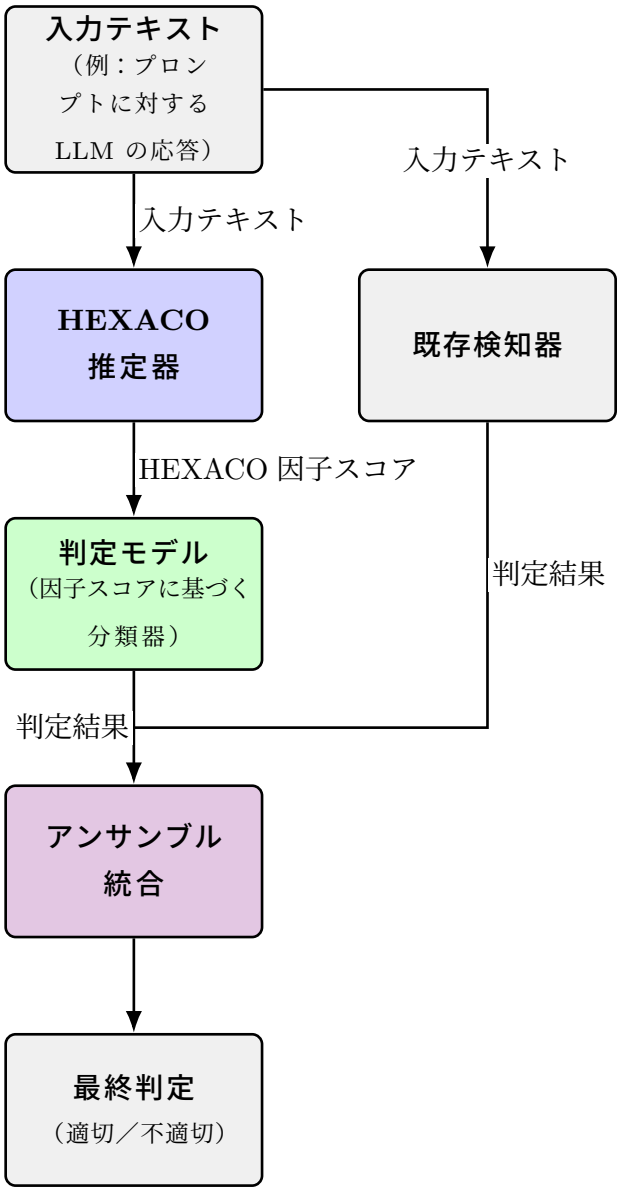


図 1 HEXACO シグナルを用いる不適切応答検知の全体像.
Fig. 1 Overview of inappropriate-response detection using HEXACO signals.

mator），推定した因子スコアから不適切確率を算出する判定モデル（*Decision Model*），および既存検知器と統合するアンサンブルから構成される．図中の「既存検知器」は，選択的アンサンブル統合で HEXACO Detector と組み合わせる既存の検知器を表す．入力を応答テキスト t とし，推定器 M による 6 因子スコアを，

$$\boldsymbol{s}(t) = (s_H, s_E, s_X, s_A, s_C, s_O) = M(t) \qquad (1)$$

と表す．添字 H, E, X, A, C, O は，それぞれ Honesty–Humility，Emotionality，Extraversion，Agreeableness，Conscientiousness，Openness を表す．各スコアは，応答表現に対応する連続的なテキスト特徴量として解釈する．

3.2 HEXACO 推定器

推定器には，LLM-as-a-Judge 型とローカル型の 2 種類を用いる．LLM-as-a-Judge 型は，因子の説明を含むプロンプトを与え，因子ごとのスコアを生成する方式である．ローカル型は，推論環境内で因子スコアを出力する方式である．各方式の具体的なモデルと評価上の役割は，4 章で説明する．

ローカル型では，因子条件を与えて生成した応答と参照スコアを用いて，因子ごとの推定器を微調整する．コントラスト学習とは，類似すべき表現を近づけ，異なる条件の表現を離すように表現空間を学習する手法である．本研究ではこの学習により，因子条件間の差異が応答表現に反映されるようにする．

3.3 判定モデル

推定因子から不適切判定を得るため，まず単一しきい値による規則を定義する．τ をしきい値，$\mathbf{1}[\cdot]$ を条件が真のとき 1 を返す指示関数とすると，

$$y_H = \mathbf{1}\left[\min_i s_i \le \tau\right] \qquad (2)$$

である．この規則は，いずれかの因子が低い応答を不適切候補として扱う．

さらに，因子ごとの平均値，分散，最小値，最大値，因子間差を含む 10 次元特徴量を構成し，分類器に入力する．ロジスティック回帰は，入力特徴から二値事象の確率を推定する線形分類器である．学習時には，適切・不適切応答の標本数差の影響を緩和するため，両クラスを均衡化した学習集合を用いる．具体的な特徴量，分類器，および設定選択は 4 章で説明する．

3.4 アンサンブルによる統合

複数の既存検知器と HEXACO Detector を統合対象とする．検知器 i の二値出力を y_i，危害カテゴリ c における重みを $w_i(c)$，しきい値関数を g とすると，評価指標に基づく重み付き集約（Metric-weighted Aggregation）は次式で表される．

$$y_{\text{ens}} = g\left(\sum_i w_i(c) y_i\right). \qquad (3)$$

ここで重みには，検証データ上の F1，Recall，Precision のいずれかを用いる．F1 は適合率と再現率の調和平均であり，Recall は不適切応答のうち正しく検知できた割合，Precision は不適切と判定した応答のうち正しかった割合である．

3.4.1 選択的アンサンブル統合方式

加えて，既存検知器が適切と判定した応答だけを対象として，HEXACO Detector による判定を組み合わせる選択的アンサンブル統合を設計する．以下では，既存検知器と HEXACO Detector を統合する方式を WG+で表記する．

© 2026 Information Processing Society of Japan

WG は実験で用いる既存検知器を，後続の語は補完規則を表す．既存検知器が不適切と判定した応答はその判定を保持し，適切と判定した応答に対してのみ各規則を適用する．

WG+Text は，テキスト埋め込みに基づく k 近傍法（k-nearest neighbors: k-NN） [14] を用いる基準方式である．入力応答に近い学習事例を検索し，近傍に含まれる不適切応答の比率がしきい値を超える場合に，既存検知器の判定を不適切へ更新する．

WG+HDist は，テキスト距離に式 (1) に示す 6 次元因子距離を加えた距離に基づいて近傍を検索する方式である．WG+Text との比較により，低次元の因子シグナルを近傍探索に加える効果を評価する．両表現はそれぞれ正規化し，混合係数 α で HEXACO 因子距離の寄与を調整することで，意味的な近さと因子傾向の近さを併せて評価する．

WG+HGate は，近傍から推定した危害カテゴリと HEXACO Detector による不適切確率が所定の条件を満たす場合に，既存検知器の判定を変更する方式である．この方式は，補完が期待されるカテゴリと因子シグナルが同時に得られた応答に対象を絞る．

WG+HOracle は，正解の危害カテゴリを用いて WG+HGate と同様の条件を適用する，上限を示す参照方式である．カテゴリ情報が完全に利用できる理想条件での性能を示し，実運用候補である他の 3 方式との比較基準となる．

4. 評価実験

4.1 実験設定

主評価には，複数の危害カテゴリを含む LLM 安全性ベンチマーク AEGIS2 [10] を用いる．本稿では，安全性に関する二値ラベルにおいて安全性基準に適合する応答を適切応答，安全性上の問題を含む応答を不適切応答と呼ぶ．学習分割は 30,007 件から成り，不適切応答 3,541 件，適切応答 11,693 件，およびラベルが付与されていない人間発話 14,773 件を含む．判定モデルの学習とアンサンブルのパラメータ推定では，後者を適切として扱う．ただし，応答内容を対象とする因子傾向の分析からは除外する．テスト分割は 1,964 件であり，不適切 394 件，適切 1,570 件から成る．

分布外（out-of-distribution: OOD）での挙動を評価するため，WildGuardMix test [7]（1,725 件，不適切 284 件）と XSTest [11]（446 件，不適切 78 件）も用いる．OOD 評価とは，学習・調整に用いた分布と異なるデータ集合に対して性能を測定する評価である．これにより，特定ベンチマークに適合したしきい値や統合規則が，他の応答分布でも機能するかを確認する．

しきい値および近傍探索のハイパーパラメータは，AEGIS2 学習分割の 20%をハッシュ値に基づいて固定的に抽出した検証分割で選択した．ハイパーパラメータとは，学習で直接更新されず，あらかじめ探索して定める設定値である．判定モデルと WG+Text，WG+HDist，WG+HGate では，この検証分割で F1 を最大化する設定を一つ選び，AEGIS2 test，WildGuardMix，XSTest の全てに変更なく適用した．この手順により，テスト集合を参照した設定調整を避ける．

評価指標には，適合率（Precision），再現率（Recall），および両者の調和平均である F1 スコアを用いる．推定器の構成比較には，参照スコアとの平均絶対誤差（mean absolute error: MAE）と，スコアを区間化した各クラスの F1 を平均した Macro F1 を用いる．

推定器には，因子の説明を含むプロンプトからスコアを生成する LLM-as-a-Judge 型と，Gemma-3-270M-IT [2] を因子ごとに微調整したローカル型を用いる．LLM-as-a-Judge 型および LLM Judge のモデルには gpt-5.4-nano を用いる．ローカル型は，有害表現に関係するプロンプトを含む RealToxicityPrompts [8] に人格条件を与えて生成した応答と参照スコアにより学習した．同一プロンプトに対する高・中・低の人格条件付き応答の因子スコアの順序を保つ，三つ組に基づくマージン順位制約 [13] と回帰損失を併用した．判定モデルでは，因子ごとの統計量から構成した 10 次元特徴量を入力とし，ロジスティック回帰と勾配ブースティング決定木の実装である LightGBM [9] を比較した．最終的には，Openness，Agreeableness，Extraversion の 3 因子を入力とする正則化ロジスティック回帰を採用した．

比較する検知器は，OpenAI Moderation API，Llama-Guard，WildGuard，および HEXACO Detector の 4 種類とする．OpenAI Moderation API には，2026 年 5 月 19 日時点の `omni-moderation-latest` を用いる．WildGuard を既存検知器として用いる選択的アンサンブル統合では，`multilingual-e5-large` [12] によるテキスト埋め込みのみを用いる WG+Text，テキスト距離と HEXACO 距離を併用する WG+HDist，カテゴリと HEXACO 確率により判定変更を制限する WG+HGate を比較する．WG+HOracle は，テスト集合の正解カテゴリを利用して上限を示す参照方式として評価する．各方式の処理内容は，3.4 節で定義する．

4.2 HEXACO 因子と安全性

表 2 に，AEGIS2 学習分割における適切・不適切応答の因子統計を示す．多重比較による偶然の有意差を抑制するため，p 値には Benjamini–Hochberg 法 [15] による false discovery rate 補正を施した．不適切応答では，Agreeableness が最も低く（Cohen's $d = -0.65$），Extraversion も低い（$d = -0.34$）．Cohen's d は二群の平均差を標準偏差で規格化した効果量であり，符号は不適切応答の平均が適切応答より高いか低いかを表す．

全体比較は，データセット全体における因子傾向を把握

© 2026 Information Processing Society of Japan

表 1 WildGuard–HEXACO 選択的アンサンブル統合方式の追加情報と判定変更の条件.
Table 1 Additional inputs and decision-change conditions for WildGuard–HEXACO selective ensemble integration strategies.

方式	追加情報	条件・位置付け
WG+Text	テキスト埋め込み	近傍の不適切応答比率がしきい値超過
WG+HDist	埋め込み，6 因子距離	因子距離を加えた近傍比率がしきい値超過
WG+HGate	近傍カテゴリ，因子確率	カテゴリ比率と因子確率が条件を満たす
WG+HOracle	正解カテゴリ，因子確率	理想条件での性能を示す参照方式

表 2 適切・不適切応答の HEXACO 因子統計．Δ は不適切平均から適切平均を減じた値である．
Table 2 HEXACO factor statistics for appropriate and inappropriate responses. Δ is the inappropriate mean minus the appropriate mean.

因子	適切	不適切	Δ / d
Honesty–Humility	3.16	3.09	−0.07 / −0.12
Emotionality	2.95	3.00	+0.05 / +0.16
Extraversion	3.07	2.90	−0.17 / −0.34
Agreeableness	2.93	2.60	−0.33 / −0.65
Conscientiousness	2.91	3.02	+0.11 / +0.28
Openness	2.80	2.69	−0.11 / −0.15

するための分析である．一方，カテゴリごとの構成比が全体平均に与える影響を抑えるため，各危害カテゴリ内で適切な拒否応答と不適切な追従応答を比較した．このカテゴリ内比較は，依頼を拒否する応答と追従する応答に伴う表現傾向の差を確認するための分析である．二つの分析を併用することで，危害カテゴリの構成と応答内容に関わる因子傾向を区別して解釈できる．

その結果，Openness は 24 カテゴリ全てで不適切応答側に高く，Conscientiousness は 17 カテゴリで低かった．この差異は，因子シグナルが，応答が要求を拒否するか追従するかに伴う表現傾向を反映している可能性を示す．因子スコアは補助シグナルとして用い，後述する既存検知器との統合で評価する．

4.3 単体検知器の性能と補完性

ローカル推定器について，出力層と微調整方式を比較した．最良構成は，推定器の基盤となる言語モデルであるバックボーンを固定しない，2 層の多層パーセプトロン（MLP）出力層であり，合成データの保持テストで MAE=0.384，Macro F1=0.857 を達成した．この構成を用いて判定モデルを学習した結果，AEGIS2 test で Recall=0.975，F1=0.651 となった．表 3 に既存検知器との比較を示す．HEXACO Detector は WildGuard より F1 が低い一方，最も高い Recall を示した．この性質は，見逃し候補を拾い上げる補完的検知器として有用であることを示す．

表 3 AEGIS2 test における単体検知器の性能.
Table 3 Performance of individual detectors on the AEGIS2 test set.

検知器	Precision	Recall	F1
OpenAI Moderation	0.859	0.510	0.640
LlamaGuard	0.855	0.525	0.651
WildGuard	0.828	0.782	0.804
HEXACO Detector	0.489	0.975	0.651

表 4 WildGuard–HEXACO 統合の F1．WG+HOracle は正解カテゴリを用いる理想条件での参照値である．
Table 4 WildGuard–HEXACO integration F1. WG+HOracle is an upper bound using the gold category.

方式	AEGIS2	WildGuardMix	XSTest
WildGuard	0.804	0.422	0.523
WG+Text	0.844	0.448	0.500
WG+HDist	0.841	0.445	0.485
WG+HGate	0.806	0.419	0.517
WG+HOracle	0.859	0.422	0.523

4.4 選択的アンサンブル統合の評価結果

表 4 に WildGuard と HEXACO を統合した結果を示す．WG+Text は AEGIS2 で F1=0.844，WG+HDist は F1=0.841 を示した．WG+HDist は 1024 次元のテキスト埋め込みに 6 次元の HEXACO 距離を加えた方式であり，テキストのみを用いる WG+Text と近い性能を得た．両者の正誤の差に対する McNemar 検定 [16] の p 値は 0.423 であり，本評価では明確な性能差は確認されなかった．McNemar 検定は，同一標本に対する二つの分類器の誤り方の差を検定する方法である．

AEGIS2 では WG+Text および WG+HDist により，WildGuard の Recall をそれぞれ 0.101 および 0.109 向上させた．その一方，WildGuardMix では F1 がそれぞれ 0.026 および 0.023 上昇したのに対し，XSTest では 0.023 および 0.038 低下した．この結果は，補完規則が分布ごとの危害カテゴリや表現形式の違いに影響されることを示す．WG+HGate は，学習分割から推定したカテゴリと HEXACO 確率の双方を要求するため，判定変更が少なく，三つの集合で概ね WildGuard に近い挙動となった．また，WG+HOracle はテスト集合の正解カテゴリを用いる実運用を想定しない参照方式であり，カテゴリ情報が完全に得

© 2026 Information Processing Society of Japan

られる理想条件での性能を示す．

4.5 評価結果のまとめ

以上の結果から，HEXACO シグナルは，高い Recall を持つ補完表現として既存検知器とのアンサンブル統合に利用できることが示された．アンサンブル統合方式の設定選択，Precision と Recall のトレードオフ，分布外での挙動，および検知器間の補完性は，5 章で考察する．

5. 考察

5.1 選択的アンサンブル統合方式の設定選択と再現性

本節では，選択的アンサンブル統合方式の性能を比較可能にするための設定選択と検証手順を確認する．

WG+Text では近傍数 $K = 30$，近傍における不適切応答比率のしきい値 $r = 0.5$ を用いた．WG+HDist では，HEXACO 距離の混合係数 $\alpha = 0.2$，$K = 30$，$r = 0.45$ を用いた．WG+HGate では，$K = 30$，カテゴリ近傍比率 $r_{\text{cat}} = 0.9$，HEXACO 確率しきい値 $\beta = 0.1$ を用いた．いずれも，あらかじめ固定した AEGIS2 学習分割の検証集合で選択した値である．

固定した検証分割で候補設定を比較し，選択した設定を AEGIS2 test および二つの OOD 集合に変更なく適用した．アンサンブルの探索は，既存検知器の出力とテキスト埋め込みの双方が得られる検証標本に限定した．WG+HGate のカテゴリ候補としきい値も，テスト集合を用いず，この検証集合で選択した．WG+HOracle は正解カテゴリを利用して上限を示す参照方式であるため，パラメータ選択の対象外とした．この手順により，テスト集合と OOD 集合の性能差を，同一の選択的アンサンブル統合方式を異なる応答分布へ適用した結果として比較できる．

一方で，検証分割の標本構成は選択されるしきい値に影響するため，実運用では対象ドメインの応答を用いて同様の検証手順を再実施することが重要である．

5.2 推定器の構成比較

本節では，安全性に関する二値ラベルを用いずに推定器の構成を選択できているかを検証する．

ローカル推定器の学習には，RealToxicityPrompts から生成した人格条件付き応答を用いた．同一の元プロンプトに由来する応答が学習用と評価用に混在しないよう，元プロンプト ID のハッシュ値により 10%を評価用に保持した．表 5 に比較した構成を示す．Linear は単一線形層，拡張出力層は `LayerNorm`，`Dropout`，線形層から成る．多層パーセプトロン（multi-layer perceptron: MLP）は，128 次元の中間層と Gaussian Error Linear Unit（GELU）活性化関数を持つ 2 層構成である．バックボーンは推定器の基盤となる言語モデルを指し，「固定」はその重みを更新しない設定を表す．

Enc-B と Enc-C は，凍結したバックボーンと同一の拡張ヘッドの下で，ヘッド学習率のみを比較する構成である．Enc-C と Enc-D は，凍結条件を保ったまま拡張ヘッドと MLP を比較する．Enc-D と Enc-E は，同一の MLP を用い，バックボーン更新の有無を比較する．この段階的な比較により，出力ヘッド，学習率，およびバックボーン更新の寄与を区別した．

構成の選定には，合成データの保持テストにおける MAE と Macro F1 のみを用いた．Enc-E はバックボーンも更新する 2 層 MLP であり，両指標で最も良い値を示したため採用した．安全性に関する二値ラベルを推定器の構成選択に用いないことで，推定器は因子推定を担い，判定モデルとアンサンブル統合が安全性判定を担う役割分担を維持している．

5.3 選択的アンサンブル統合の詳細評価

本節では，主結果の F1 を Precision と Recall に分解し，補完によるトレードオフを確認する．

表 6 が示すように，WG+Text と WG+HDist は既存検知器の見逃しを補完する一方で，追加の不適切判定を生じさせる．このトレードオフは，見逃しコストと過剰検知コストが用途ごとに異なる運用設計で重要となる．

AEGIS2 では, WG+HDist は WG+Text より高い Recall を示し, F1 の差は小さい．この結果は, 6 次元の HEXACO 距離が 1024 次元のテキスト埋め込みに加える近傍情報として機能することを示す．一方，WG+HDist は Precision が低い．そのため，候補の抽出では見逃しの抑制を優先し，後続の判定では追加の不適切判定を確認する段階的な運用が適する．

5.4 4 検知器アンサンブル統合と相関分析

本節では，4 検知器を一括統合した場合の分布依存性と，HEXACO の補完性を分析する．

表 7 に 4 検知器を同時に統合した結果を示す．埋め込みに基づく k-NN は，検知対象に近い学習事例を検索し，その近傍での各検知器の性能を重みとして用いる方式である．埋め込みに基づくクラスタリングはクラスタごとに重みを定め，ゲート型メタ学習器は 4 検知器の出力と HEXACO 特徴を入力とする二段目のロジスティック回帰である．

AEGIS2 では多数決が高い F1 を示す一方，二つの OOD 集合では埋め込みに基づく k-NN が高い F1 を示す．この差は，固定的な検知器合意よりも入力応答に近い学習事例を参照する方式が，分布変化に適応する可能性を示す．表 8 は，AEGIS2 test における検知器対の一致度を示す．Phi 係数は二値判定の相関を，Jaccard 係数は両検知器が不適切と判定した応答の重なりを表す．HEXACO は既存の 3 検知器が全て見逃した不適切応答 41 件を検知しており，内容分類器と異なる誤り特性を持つ補助シグナルとして機能

© 2026 Information Processing Society of Japan

表 5 ローカル推定器の構成比較．学習率はバックボーン／出力層の順に示す．MAE は小さいほど，Macro F1 は大きいほど良い．

Table 5 Comparison of local estimator configurations. Learning rates are shown as backbone/output layer. Lower MAE and higher Macro F1 are better.

構成	出力層	バックボーン固定	学習率	学習回数	MAE	Macro F1
Enc-A	Linear	なし	2e−5/–	100	0.451	0.839
Enc-B	拡張	あり	–/1e−3	100	1.082	0.563
Enc-C	拡張	あり	–/3e−4	100	1.088	0.564
Enc-D	MLP	あり	–/3e−4	100	0.844	0.682
Enc-E	MLP	なし	2e−5/3e−4	50	0.384	0.857

表 6 WildGuard–HEXACO 統合の詳細指標．

Table 6 Detailed metrics for WildGuard–HEXACO integration.

データ	方式	Precision	Recall	F1
AEGIS2	WildGuard	0.828	0.782	0.804
	WG+Text	0.807	0.883	0.844
	WG+HDist	0.796	0.891	0.841
WildGuardMix	WildGuard	0.313	0.644	0.422
	WG+Text	0.318	0.757	0.448
	WG+HDist	0.314	0.761	0.445
XSTest	WildGuard	0.374	0.872	0.523
	WG+Text	0.343	0.923	0.500
	WG+HDist	0.329	0.923	0.485

表 7 4 検知器集約の F1．全方式で OpenAI Moderation，LlamaGuard，WildGuard，HEXACO Detector を用いる．

Table 7 F1 scores for four-detector aggregation. All methods use OpenAI Moderation, LlamaGuard, WildGuard, and the HEXACO Detector.

方式	AEGIS2	WildGuardMix	XSTest
OpenAI Moderation	0.640	0.483	0.653
LlamaGuard	0.651	0.485	0.620
WildGuard	0.804	0.422	0.523
HEXACO Detector	0.651	0.293	0.290
埋め込みに基づく k-NN	0.746	0.608	0.720
埋め込みに基づくクラスタリング	0.759	0.580	0.638
ゲート型メタ学習器	0.763	0.555	0.650
多数決（2/4 以上）	0.828	0.449	0.444
OR 投票（1/4 以上）	0.659	0.286	0.302

する．

HEXACO と WildGuard の Jaccard 係数は高く，両者は多くの不適切応答で同じ判定に到達する．同時に，41 件の追加検知は，完全な一致では捉えられない補完的な判定領域が存在することを示す．したがって，HEXACO は既存検知器とともに用いるアンサンブル入力として意義がある．

5.5 カテゴリ別の追加検知

本節では，既存検知器の見逃しをどの危害カテゴリで追加検知できるかを確認する．

表 9 は，AEGIS2 test において WildGuard が見逃した不適切応答を HEXACO Detector が追加検知した件数と，その際の追加偽陽性数を示す．不適切応答が 8 件以上ある 12 カテゴリを対象とした．

Controlled/Regulated Substances，Profanity，Harassment などでは，WildGuard の見逃しが複数件追加検知された．カテゴリごとの標本数は限られるため，WG+HGate のカテゴリ候補としきい値は学習分割内の検証集合で選択した．

追加検知は複数のカテゴリで確認された．カテゴリごとの不適切応答数と追加偽陽性数は小さいため，表 9 は追加検知が確認された条件を記述する資料として解釈する．固定的なカテゴリ規則には，より大きな独立標本による検証が必要である．

表 8 AEGIS2 test における検知器間の一致度．

Table 8 Agreement between detectors on the AEGIS2 test set.

組合せ	Phi 係数	Jaccard 係数
HEXACO × WildGuard	0.563	0.761
LlamaGuard × WildGuard	0.574	0.528
OpenAI × WildGuard	0.588	0.524
HEXACO × LlamaGuard	0.440	0.523
HEXACO × OpenAI	0.431	0.504
LlamaGuard × OpenAI	0.460	0.427

5.6 選択的アンサンブル統合方式の比較

本節では，各選択的アンサンブル統合方式の追加情報と運用上の位置付けを整理する．

表 1 に示したように，WG+Text と WG+HDist は推論時に利用可能な入力だけを用いる実運用候補である．WG+HGate は推定カテゴリと HEXACO 確率で補完条件を絞り込み，WG+HOracle は正解カテゴリを用いて上限を示す参照方式である．

不適切応答を見逃すコストが大きい一次スクリーニングでは，高い Recall を示す HEXACO Detector や WG+HDist を追加候補の抽出に利用できる．自動遮断に直結する後続の判定では，内容に基づく検知器の出力や人手確認と組み合わせ，追加の不適切判定の影響を検証することが望ましい．6 次元の因子表現は，統合後の判断根拠を監査し，既存検知器の見逃しを分析するための解釈可能な表現といえる．

© 2026 Information Processing Society of Japan

表 9　WildGuard の見逃しに対する HEXACO による追加検知.

Table 9　Additional detections by HEXACO for WildGuard misses.

カテゴリ	不適切数	WG 見逃し	追加検知	追加偽陽性
Guns/IW + Criminal Planning	9	3	3	0
Suicide and Self Harm	8	3	3	0
Controlled/Regulated	17	8	8	2
Profanity	14	7	6	2
Harassment	17	4	4	2
Criminal Planning	62	9	9	5
Criminal + Controlled	14	3	3	2
Violence	9	4	4	3
Hate/Identity Hate	33	3	3	3
Sexual	21	3	3	3
PII/Privacy	16	3	3	4
Violence + Criminal Planning	10	1	1	2

WG+Text はテキスト近傍だけを用いる基準方式であり，WG+HDist は因子距離を追加した方式である．両方式が近い性能を示したことは，運用環境で利用できる特徴量と説明可能性の要件に応じて方式を選択できることを意味する．因子距離を用いる場合には，近傍となった応答の因子差も確認できるため，追加の不適切判定の理由を分析する手掛かりが得られる．

6. おわりに

本稿では，LLM 応答から推定した HEXACO 因子を安全性検知の補助シグナルとして用い，既存検知器との統合可能性を評価した．AEGIS2 の分析では，適切・不適切応答の因子傾向に系統的な差異が観測され，HEXACO Detector は Recall=0.975 を示した．WildGuard との統合では，テキスト埋め込みと 6 次元 HEXACO 距離を併用する WG+HDist が AEGIS2 で F1=0.841 を達成し，テキストのみの方式に近い性能を示した．さらに，分布外評価と相関分析により，HEXACO シグナルは既存検知器の見逃しを補完し得る一方，統合規則の性能は評価分布に依存することを確認した．今後は，多言語応答，より多様な攻撃的入力，および共有バックボーンによる推定器の軽量化を検討する．

参考文献

[1] M. C. Ashton and K. Lee: Empirical, theoretical, and practical advantages of the HEXACO model of personality structure, Personality and Social Psychology Review, Vol. 11, No. 2, pp. 150–166 (2007).

[2] Gemma Team: Gemma 3, Google DeepMind (2025), available from `https://arxiv.org/abs/2503.19786`.

[3] 長谷川健人，披田野清良：会話文から推測されるパーソナリティ指標を利用した不適切な文章の検知，2026 年暗号と情報セキュリティシンポジウム（SCIS 2026）(2026).

[4] L. R. Goldberg: An alternative description of personality: The Big-Five factor structure, Journal of Personality and Social Psychology, Vol. 59, No. 6, pp. 1216–1229 (1990).

[5] S. Wang, R. Li, X. Chen, Y. Yuan, D. F. Wong and M. Yang: Exploring the impact of personality traits on LLM bias and toxicity, arXiv preprint arXiv:2502.12566 (2025).

[6] H. Inan, K. Upasani, J. Chi, R. Rungta, K. Iyer, Y. Mao, M. Tontchev, Q. Hu, B. Fuller, D. Testuggine and M. Khabsa: Llama Guard: LLM-based input-output safeguard for human-AI conversations, arXiv preprint arXiv:2312.06674 (2023).

[7] S. Han et al.: WildGuard: Open one-stop moderation tools for safety risks, jailbreaks, and refusals of LLMs, arXiv preprint arXiv:2406.18495 (2024).

[8] S. Gehman et al.: RealToxicityPrompts: Evaluating neural toxic degeneration in language models, arXiv preprint arXiv:2009.11462 (2020).

[9] G. Ke et al.: LightGBM: A highly efficient gradient boosting decision tree, Advances in Neural Information Processing Systems, Vol. 30 (2017).

[10] S. Ghosh et al.: AEGIS2.0: A diverse AI safety dataset and its guardrail models, arXiv preprint (2025).

[11] P. Röttger et al.: XSTest: A test suite for identifying exaggerated safety behaviours in large language models, arXiv preprint arXiv:2308.01263 (2023).

[12] L. Wang, N. Yang, X. Huang, L. Yang, R. Majumder and F. Wei: Multilingual E5 text embeddings: A technical report, arXiv preprint arXiv:2402.05672 (2024).

[13] F. Schroff, D. Kalenichenko and J. Philbin: FaceNet: A unified embedding for face recognition and clustering, Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, pp. 815–823 (2015).

[14] T. M. Cover and P. E. Hart: Nearest neighbor pattern classification, IEEE Transactions on Information Theory, Vol. 13, No. 1, pp. 21–27 (1967).

[15] Y. Benjamini and Y. Hochberg: Controlling the false discovery rate: A practical and powerful approach to multiple testing, Journal of the Royal Statistical Society: Series B (Methodological), Vol. 57, No. 1, pp. 289–300 (1995).

[16] Q. McNemar: Note on the sampling error of the difference between correlated proportions or percentages, Psychometrika, Vol. 12, No. 2, pp. 153–157 (1947).

© 2026 Information Processing Society of Japan