LLMの判断モノカルチャーは サイバー防御に共通の盲点をもたらすか

今村 光良[1,a)]　面 和成[1]

概要：Security Operations Center (SOC) では，アラートの一次判定や調査を LLM で支援する試みが進んでいる．複数 LLM の併用は単一モデルの誤判定を補う手段となるが，誤りが相関していれば共通故障は残る．本稿では，GUIDE の経験的構造に基づく統制合成コーパスを用い，14 提供者 22 モデルから 39,600 件の判定を収集した．事例難易度を条件付けた帰無モデルと比較した結果，平均的な同時誤りの多くは潜在難易度で説明された一方，20–22 モデルが同時に誤る極端な共通故障はなお残った．そのような事例では，決定的証拠を判断根拠として挙げる割合が低下し，表層指標のみを判断根拠として挙げる割合が増加した．また，複数モデルの冗長化では見逃しと偽陽性のトレードオフが生じ，集約閾値によって運用点が大きく変化した一方，同一モデルの反復や確信度だけでは共通故障を十分に検知できなかった．SIABench でも正の誤り依存と集約規則の影響を確認したが，誤りの方向は一致しなかった．そのため，複数 LLM の冗長化はモデル数ではなく，共通故障，CFNR，FPR を同時に評価して設計する必要があることを報告する．

キーワード：セキュリティ運用，大規模言語モデル，共通故障，アンサンブル多様性，モノカルチャー

Does Judgment Monoculture in LLMs Create Common Blind Spots in Cyber Defense?

Mitsuyoshi Imamura[1,a)]　Kazumasa Omote[1]

Abstract: In Security Operations Centers (SOCs), large language models (LLMs) are increasingly being used to support initial alert triage and investigation. Combining multiple LLMs can compensate for errors made by individual models; however, common-mode failures may persist when their errors are correlated. In this study, we use a controlled synthetic corpus grounded in the empirical structure of GUIDE and collect 39,600 verdicts from 22 models across 14 providers. Compared with null models that condition on case difficulty, most average joint errors were explained by latent case difficulty, while extreme common-mode failures, in which 20–22 models simultaneously erred on the same cases, remained. In such cases, models less frequently cited decisive evidence and more frequently cited only surface-level cues in their self-reported evidence. Combining multiple models reduced false negatives but substantially increased false positives, while repeated runs of the same model and self-reported confidence alone were insufficient to reliably detect common-mode failures. On SIABench, we also observed positive error dependence and effects of aggregation rules, although the direction of errors did not transfer. These findings indicate that multi-LLM redundancy exhibited a trade-off between false negatives and false positives that depended strongly on the aggregation threshold, while repeated runs of the same model and self-reported confidence alone were insufficient to reliably detect common-mode failures, the common false-negative rate (CFNR), and the false-positive rate (FPR).

Keywords: security operations, large language models, common-mode failure, ensemble diversity, monoculture

© 2026 Information Processing Society of Japan

This paper is work in progress and not peer-reviewed.

1. はじめに

SOC におけるアラートの一次判定や調査を，大規模言語モデル (LLM) によって支援する試みが進んでいる [14,15]．しかしながら，複数 LLM による冗長化は単一モデルの誤判定を補える一方，誤りが相関すれば共通故障は残り，誤警報の増加要因にもなる．一般的なタスクでは，異なる LLM の誤りが相関することが報告されており [8]，SOC 事例についても例外ではない．

本稿の焦点は，SOC のように見逃しと誤警報のコストが非対称な環境で，観測された同時誤りが事例の難易度による要因か，複数モデルに共有された判断上の偏りによる要因かを区別し，その共通故障による，冗長化した運用上の効果への影響を明らかにすることにある．

そこで，本研究では，事例固有における難易度の考慮に加え，モデル間の同時誤りが残るかを調査し，共通故障が生じる事例において，モデルが何を判断根拠としているかを分析する．さらに，複数モデルによる冗長化と集約規則が見逃しと偽陽性のバランスに与える影響，同一モデルの反復実行や確信度による共通故障の検知可能性を評価する．そして，これらの関係が複数のデータでも観測されるかを検証する．

実インシデントの代表的なコーパスである Microsoft GUIDE [4] を対象に, 戦術構成, ラベル事前確率, ATT&CK 技術の共起，証拠件数分布を継承しつつ，正解ラベルと表層的な攻撃らしさを直交させ，正解判断に必要な証拠を既知とした合成 SOC コーパスを構成することで分析した．14 提供者 22 モデルの API 呼び出しにより 39,600 件の判定結果を収集し，さらに，同一モデルの反復実行データと公開ベンチマーク SIABench を用い，主実験で観測した関係の安定性と外部妥当性を報告する．

主な貢献は次のとおりである．

- GUIDE の経験的構造に接地し，正解ラベル，表層的な攻撃らしさ，決定的証拠を統制したコーパスと，14 提供者 22 モデルによる 39,600 件の判定を構築した．
- 潜在難易度を条件付けると平均的な同時誤りの多くは説明される一方，20–22 モデルが同時に誤る極端な共通故障が残り，その際には決定的証拠を判断根拠として挙げる割合が低下し，表層指標のみを判断根拠として挙げる割合が増えることを示した．
- 冗長化には見逃しと偽陽性の交換条件があり，運用点は集約閾値に大きく依存すること，また反復実行や確信度閾値だけでは共通故障を十分に検知できないことを示した．
- SIABench でも正の誤り依存と集約閾値の影響を確認したが，誤りの方向は転移せず，共通故障を測定して構成を評価する必要性を示した．

[1] 筑波大学 システム情報系
University of Tsukuba Faculty of Engineering
[a)] imamura.mitsuyosh.kn@u.tsukuba.ac.jp

2. 関連研究

LLM の能力向上に伴い，その適用範囲は一般的な自然言語処理から，サイバーセキュリティにおける専門的な判断や作業へ広がっている．その 1 つの適用事例である SOC については，分析業務への LLM 利用が検討されており，Deason らは CyberSOCEval を提案し，マルウェア解析と脅威インテリジェンス推論という SOC の主要業務について複数の LLM を評価している [3]．他にも，Okada らは SOC で作成されるインシデント分析報告を対象として，熟練分析者の観点を反映した複数視点から LLM による評価を行う MESSALA を提案しており [12]，LLM の利用対象は個別のセキュリティ知識問題だけでなく，証拠の解釈，脅威分析，分析結果の評価といった SOC の判断業務へ拡大している．

一方で，LLM の性能向上は，セキュリティ判断の信頼性を直ちに保証するものではないことも明らかとなっている．Barnes はインシデント対応エージェントを評価し，正しい対象への対処能力が高くても，不要な封じ込めを多数実行する過剰反応が生じうることを報告している [1]．より一般的にも，LLM は意味内容を大きく変えない prompt の書式差に影響されること [13]，長い入力では重要情報の配置によって性能が変化すること [11]，誤答時にも高い自己申告確信度を示しうること [16] が報告されており，セキュリティ用途においてもその影響は例外ではない．そのため，SOC へ LLM を導入する際には，単体の平均精度だけでなく，入力条件に対する頑健性や誤判定時の挙動まで含めて評価する必要がある．

さらに，複数モデルを用いればこれらの誤りを相互に補完できるとは限らない．分類器アンサンブルでは，個々の分類器の性能だけでなく，誤りの多様性が集約性能を左右することが古くから知られている [10]．LLM についても，Kim らは 350 を超えるモデルを用いた分析から，異なるモデル間でも誤りが相関し，共有アーキテクチャや提供者がその相関と関連することを報告している [8]．また Kleinberg と Raghavan は，同種のアルゴリズムが広く利用されることで判断や失敗が共有される問題を algorithmic monoculture として論じている [9]．

本研究はこの議論を LLM 支援型 SOC へ拡張し，事例難易度を考慮した共通故障とその判断根拠を分析する．さらに，複数モデルの冗長化を CFNR と FPR の観点から評価し，集約規則，反復実行，確信度による緩和可能性を検証する．

3. データ分析のアプローチ

複数 LLM の併用が独立した防御層として機能するかを

© 2026 Information Processing Society of Japan

分析する．正解ラベル，表層的な攻撃らしさ，決定的証拠，入力表現を統制した合成 SOC コーパスに 14 提供者 22 モデルを適用し，同時誤りを事例属性および潜在難易度を条件付けた帰無モデルと比較することで，事例難易度では説明しにくい極端な共通故障を評価する．さらに，提供者，入力表現，集約閾値，推論費用，確信度，反復実行，判断根拠との関係を分析し，最後に独立データで誤り依存と構成選択上の関係を検証する．このうち，費用制約下のモデル構成，モデル属性，および入力表現に関する補助結果は付録表 A·7–A·9 に示す．以降では各評価方法を紹介する．

3.1 利用データ

本稿では，分析目的に応じて三つのデータ系列を用いる．一つ目は，実運用インシデントの経験的構造を踏まえて構成した合成 SOC コーパスであり，モデル間の同時誤りや入力表現の影響を統制された条件で分析するために用いる．二つ目は，同一モデルを繰り返し実行した自己一致実験データであり，同一モデル内のばらつきと異なるモデル間の多様性を比較するために用いる．三つ目は，公開ベンチマーク SIABench を用いた外部検証データであり，合成 SOC コーパスで得られた関係が独立したデータでも観測されるかを確認する．

3.1.1 合成 SOC コーパス

本研究では，LLM が判定するインシデントのコーパスとして，Microsoft GUIDE [4] の経験的構造に基づいた 300 件のインシデントを用いる．ただし，GUIDE はアラート名や IP アドレスなどの識別子の多くが整数 ID 化されており，実インシデントを直接用いるとセキュリティ判断ではなく記号的特徴に依存した分類を測る可能性がある．そのため，戦術構成，ラベル事前分布，ATT&CK 技術，証拠件数などの統計的特徴を参照し，LLM へ提示する本文は合成したコーパスを用いる．

正解ラベルは `true_positive`，`benign_positive`，`false_positive` の 3 種類とし，これとは独立に，表層的な攻撃らしさを high，medium，low の 3 段階で設定する．これにより，表面的には攻撃らしく見えるが正当または誤検知である事例と，表面的な顕著性が低い実攻撃とを分離して扱う．また，各事例には正解判断に必要な決定的証拠を `decisive_fields` として保持する．実際の事例レコードと決定的証拠については付録表 A·1 に示す．

各インシデントについて，正規化 JSON，SIEM 風表記，規則ベースの自然言語表記，無関係イベントを含む表記，別スキーマ表記の 5 種類の意味保存表現を作成し，これに判断文脈を削除した対照条件を加える．これにより 300 件から 1,800 プロンプトを構成した．同一事例を各入力表現へ変換した例を付録表 A·2 に示す．検証では 14 提供者 22 モデルを対象とし，各モデルを 1,800 プロンプトに対して実行した 39,600 件の判定データを用いる．各応答には判定ラベル，確信度，重大度，推奨措置，判断根拠として挙げたフィールド，および不確実な点を構造化して保存する．応答データの主要フィールドについては付録表 A·3 に示す通りとなる．

3.1.2 自己一致実験データ

同一モデルを反復した場合の出力変動を調べるため，合成 SOC コーパスから抽出した 150 事例について，基準表現を用いて 22 モデルを各 3 回実行した応答データを用いる．実行時のモデルの出力結果の分散を制御する temperature は 1.0 とし，各反復の判定ラベル，確信度および判断根拠を保存する．同一入力に対する 3 反復の実レコード例については，付録表 A·5 に示す通りとなる．なお，当該データは応答分析に用いる合成 SOC コーパスとは分離して扱う．

3.1.3 SIABench を用いた外部検証データ

外部検証には，SIABench [7] の Alert Triage に含まれる 35 事例を用いる．内訳は TP が 5 件，非 TP が 30 件であり，各事例にはアラート情報と対応する PCAP が含まれる．PCAP から `tshark` を用いて決定論的に証拠情報を抽出し，正解を直接示す metadata を除外した入力データを作成した．この 35 事例について，合成 SOC コーパスと同じ 22 モデルを各 3 回実行し，計 2,310 件の応答を取得した．

3.2 分析手法

用意した三つのデータ系列に対応して分析を行う．合成 SOC コーパスでは，まずコーパスの妥当性を確認したうえで，モデル対の同時誤り，判断根拠，モデル属性や入力表現との関係，および冗長化と費用の関係を分析する．自己一致実験データでは，同一モデルの反復による安定性を分析する．SIABench では，合成 SOC コーパスで得られた分析手続きとモデル構成を固定したまま，独立データ上で再評価する．この時の各分析における条件は後述の通りとなる．

3.2.1 合成 SOC コーパスの妥当性確認

合成 SOC コーパスが意図した分析条件を満たすことを確認するため，全情報を用いた場合と表層情報のみを用いた場合について浅い語彙分類器の性能を比較する．通常の交差検証に加え，同一シナリオファミリが学習側と評価側にまたがらない family-grouped cross-validation を用いる．さらに，ラベルと表層顕著性の独立性，単一トークンによるラベル漏洩，決定的証拠以外の完全予測特徴の有無を確認する．

各モデルについては，macro-F1，真陽性再現率，偽陽性率および確信度の較正誤差を算出し，後続分析における周辺性能として用いる．

3.2.2 モデル対の同時誤り分析

同時誤り分析では，300 件の基準インシデントについて生成した 5 種類の意味保存表現 R1–R5 を対象とし，計 1,500

© 2026 Information Processing Society of Japan

の「基準インシデント × 入力表現」を評価事例とする．判断文脈を削除した C1 は意味保存条件ではないため，主たる同時誤り分析には含めず，入力表現の影響を確認する対照条件として扱う．

評価事例を u，モデル m の誤りを $e_{u,m} \in \{0,1\}$，誤り率を p_m とする．モデル対 (m,n) の同時誤り率を

$$DF(m,n) = \frac{1}{N}\sum_{u} e_{u,m}e_{u,n} \tag{1}$$

とし，独立時の期待値 $p_m p_n$ との差を

$$IG(m,n) = DF(m,n) - p_m p_n \tag{2}$$

と定義する．22 モデルから異なる 2 モデルを選ぶ全 231 通りについてこれらを算出し，多重検定には Benjamini–Hochberg 法 [2] を用いる．

同時誤りが事例自体の難しさによって生じる可能性を考慮するため，三段階の条件付き独立帰無モデルを用いる．

NULL-0　モデルごとの周辺誤り率のみ，

NULL-A　NULL-0 に加え，ラベル，表層顕著性，入力表現，シナリオファミリ等の観測属性を考慮

NULL-B　NULL-A に加え，事例固有のランダム効果を考慮

NULL-B では 50,000 回の conditional simulation と，母数不確実性を反映した posterior predictive simulation を行い，前者は上側確率と Monte Carlo 標準誤差，後者は tail probability を報告する．これにより，平均的な誤り依存と極端な同時誤りを分けて評価する．

3.2.3　判断根拠と共通故障の関連分析

各事例に保持した `decisive_fields` と，モデルが判断根拠として申告した `evidence_fields` を照合し，正解判断に必要な決定的証拠が判断根拠として参照されたかを判定する．各事例に保持した `decisive_fields` と，モデルが判断根拠として申告した `evidence_fields` を照合し，正解判断に必要な決定的証拠が判断根拠として参照されたかを判定する．ここで観測するのはモデルが出力した自己申告上の判断根拠との関連であり，内部の注意機構や因果的な推論経路を直接観測するものではない．具体的な照合例を付録表 A·4 に示す．さらに，同一事例で誤ったモデル数に応じて決定的証拠の参照率を集計し，表層指標のみを判断根拠として挙げた場合についても比較する．具体的な照合例を付録表 A·4 に示す．さらに，同一事例で誤ったモデル数に応じて決定的証拠の参照率を集計し，表層指標のみを判断根拠として挙げた場合についても比較する．

3.2.4　冗長化と費用制約下の構成分析

複数モデルの判定を TP 対 NON-TP へ縮約し，n モデル中 k モデル以上が TP と判定した場合に全体を TP とする k-of-n 閾値規則を比較する．モデル集合 S に対する 1-of-n 規則（$n = |S|$）について，全モデルが悪性事例を見逃す共通偽陰性率を

$$CFNR(S) = \frac{1}{|T|}\sum_{i \in T} \mathbf{1}[\forall m \in S, \hat{y}_{i,m} \neq TP] \tag{3}$$

とする．また，少なくとも 1 モデルが非悪性事例を TP と判定する集合レベル偽陽性率を

$$FPR(S) = \frac{1}{|B|}\sum_{i \in B} \mathbf{1}[\exists m \in S, \hat{y}_{i,m} = TP] \tag{4}$$

とする．多数決で有効票が同数となる場合は，主分析では判定を保留する．また，同票を TP または非 TP へ割り当てた場合も感度分析する．

さらに，同一事例で誤ったモデル数によって事例を層別し，最高価格モデルを含む個別モデルが，共通して失敗する事例帯をどの程度補完できるかを確認する．

3.2.5　自己一致による反復安定性分析

自己一致実験データを用いて，同一モデルを 3 回実行したときの判定一致率と安定誤答率を算出する．同一入力に対する反復応答の例については付録表 A·5 に示す通りとなる．共通故障事例は，主実験の基準表現 R1 において 22 モデル中 20 モデル以上が誤答した事例のうち，自己一致実験の対象 150 事例に含まれるものと定義する．同一モデル反復では各モデルの先頭 k 反復を一つの集合とし，異種モデル構成では 22 モデルから k モデルの組合せを全列挙して各モデルの第 1 反復のみを用い，各集合について 150 事例上で 1-of-k 規則の CFNR と FPR を算出した後，集合間で単純平均する．

3.2.6　SIABench による外部検証

SIABench を用いてモデル対の DF と IG を算出し，合成データによる実験で観測した誤り依存が異なるデータでも再現するかを検証する．また，同一入力を 3 回実行し，結果が API 応答の非決定性に依存しないかを確認する．

当該データは，TP（真陽性）5 件と非 TP（TP 以外）30 件の計 35 事例であり，事例数が少ないことから潜在難易度を含む NULL-B は適用せず，TP と非 TP を層別した bootstrap により区間推定を行う．

合成データによる実験で選択したモデル構成は再最適化せず固定して評価する．同票時は判定を保留し，TP または非 TP へ割り当てた場合も感度分析する．外部検証では，特定モデルの優位性ではなく，誤り依存，閾値規則，構成選択手続きが独立データでも再現するかを評価する．

3.2.7　分析における応答処理の制約

API 通信，レート制限，課金等の提供基盤側の失敗は分析から除外する．また，構造化出力として解釈できない応答は分析では誤りとする．さらに，同一プロンプトに複数試行がある場合は，再試行成功による選択的置換を避けるため初回試行を採用する．

© 2026 Information Processing Society of Japan

表 1　コーパス妥当性と単体性能の結果

指標	結果
全情報・語彙分類器 (IID / grouped)	0.953 / 0.947
表層情報のみ (IID / grouped)	0.530 / 0.437
表層のみ TP 再現率 (high/med/low)	0.90 / 0.72 / 0.35
ラベル × 表層顕著性 χ^2	0.000
22 モデル macro-F1 (範囲 / 平均)	0.353–0.735 / 0.628
22 モデル TP 再現率 / 非悪性 TP 判定率	91.3% / 33.1%

4. 分析結果

本章では，第 3.2 節で定義した分析に沿って結果を示す．分析は 22 モデルに対する 39,600 件の判定で構成され，prompt hash の欠損・不一致は 0 件であった．応答は得られたものの規定の構造化出力として解釈できなかった 553 件については，運用上の判定失敗として誤りに計上した．使用したモデル名，提供者，価格等の詳細は付録表 A·6 に示す．

4.1 合成 SOC コーパスの妥当性と単体性能

本節では，合成 SOC コーパスが表層的な攻撃らしさだけで容易に分類できるデータではなく，判断文脈を利用する必要があることを確認する．あわせて，モデル間分析を前提として，22 モデルの単体性能の分布を確認する．主要結果を表 1 に示す．

全情報では family-grouped 交差検証でも macro-F1 は 0.947 であったが，表層情報のみでは 0.437 まで低下し，TP 再現率も high/medium/low の順に 0.90/0.72/0.35 と低下した．ラベルと表層顕著性も設計どおり直交しており，本コーパスは表層特徴だけでは安定して解けないことがわかる．また 22 モデルの macro-F1 には 0.353–0.735 の幅があるため，後述では単体性能の順位ではなく誤りの共有を評価する必要がある．

4.2 モデル対の同時誤り

本節では，異なるモデルが同じ事例で誤る傾向が，単に各モデルの誤り率や事例固有の難しさによって生じるものか，それとも多数モデルがほぼ一斉に失敗する共通故障が残るかを確認する．意味保存表現 R1–R5 に基づく 1,500 件の評価事例について，22 モデルから異なる 2 モデルを選ぶ全 231 通りについてこれらを算出する．各モデル対の誤りの独立性は，基準インシデント単位のブロック置換検定（片側，$IG > 0$，$B = 4{,}000$）で検定し，多重検定には Benjamini–Hochberg 法 [2] を用いる．基準インシデント単位のブロック置換検定（片側，$IG > 0$，$B = 4{,}000$）では，231 モデル対中 228 対（98.7%）で誤りの独立性が棄却され，Benjamini–Hochberg 法による多重比較補正後も同じ 228 対が有意であった（$q = 0.05$，調整後 $p = 0.0003$）．特に，事例固有の潜在難易度まで考慮する NULL-B を用いて，平均的な同時誤りと極端な同時誤りを分けて評価する．

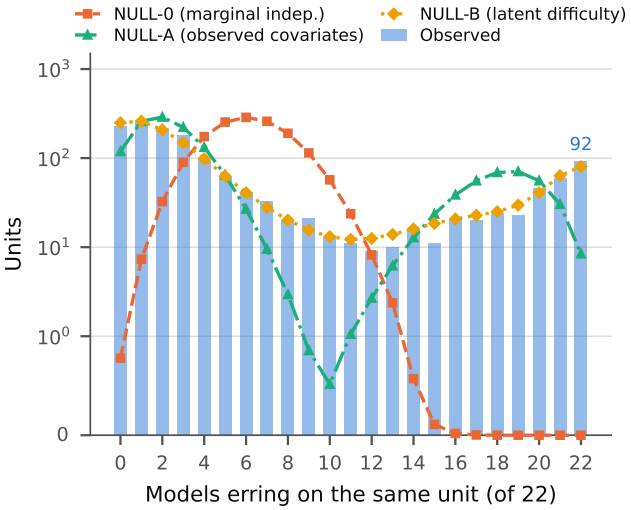


図 1　同一評価事例で誤ったモデル数と条件付き独立帰無モデル．

表 2　NULL-B との主要比較

統計量	実測値	固定母数	事後予測
20–22 モデル誤答	198	0.0067	0.0200
全 22 モデル誤答	92	0.0361	0.0682
平均 DF	0.1878	0.3516	0.4327
平均 IG	0.1078	0.5583	0.3493

まず，図 1 に，各評価事例で誤ったモデル数の分布と，事例固有の潜在難易度まで考慮した NULL-B の期待分布を示す．横軸は同一評価事例で誤答したモデル数，縦軸は該当する評価事例数である．青色の棒は実データで得られた評価事例数を，折れ線は NULL-0，NULL-A，NULL-B の各帰無モデルから期待される評価事例数を表す．NULL-0 では多数モデルの同時誤答を十分に説明できないが，事例固有の潜在難易度を考慮した NULL-B では期待分布が実測分布に近づく．その上で，20–22 モデルが同時に誤答する右端の領域にも実際の評価事例が残っている．

次に，表 2 には，実データで得られた同時誤りが NULL-B の期待からどの程度乖離しているかを，平均的な同時誤りと極端な同時誤りに分けて示す．NULL-B について推定した母数を固定した場合の上側確率と，母数の不確実性も考慮した事後予測上側確率を示す．平均 DF と平均 IG には NULL-B からの明確な乖離はみられず，平均的な同時誤りは事例固有の難易度を考慮することで概ね説明できる．一方で，20 モデル以上が誤った 198 評価事例では事後予測上側確率が 0.0200 となり，ほぼ全モデルが同時に失敗する極端な同時誤りは NULL-B でも十分に説明されなかった．

さらに，20–22 モデルが同時に誤った 198 評価事例には悪性事例が含まれず，全 22 モデルが誤った 92 評価事例はすべて `false_positive` であった．したがって，本コーパスで観測された極端な共通故障は，攻撃の一斉見逃しではなく，検知器による誤警報を多数モデルが正しく退けられ

© 2026 Information Processing Society of Japan

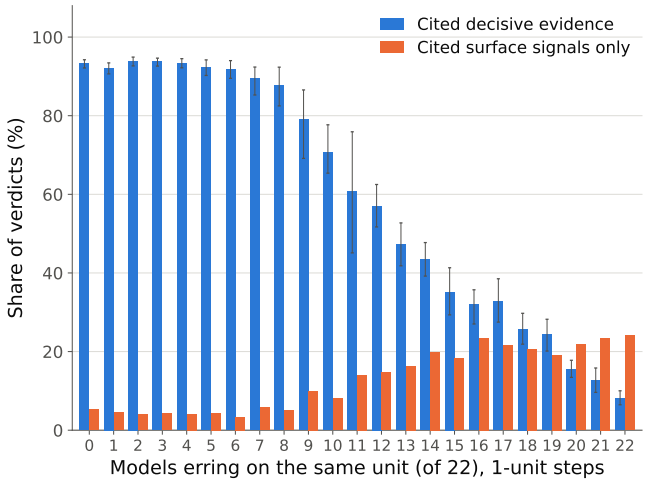


図 2 同時誤答モデル数と正解判断に必要な情報の参照率．誤差棒は事例単位 bootstrap による 95%信頼区間．

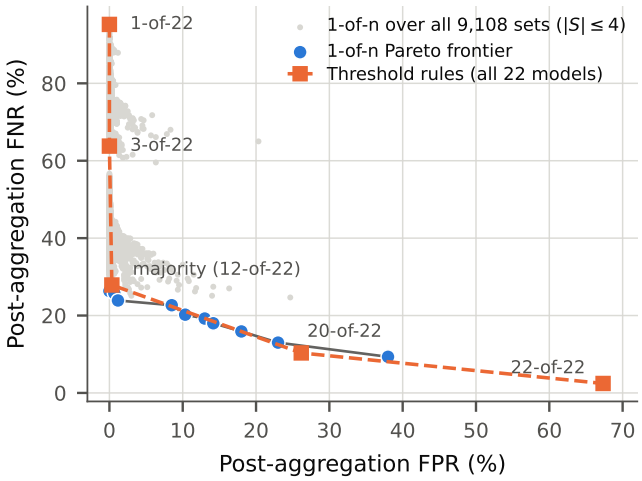


図 3 集約後の偽陽性率（FPR）と偽陰性率（FNR）のトレードオフ．

ない方向に集中していた．

4.3 判断根拠と共通故障の関連

本節では，共通故障が生じる事例で，正解判断に必要な情報がモデルの申告した判断根拠に含まれているかを確認する．各事例について正解判断に必要な情報として定義した `decisive_fields` と，モデルが申告した `evidence_fields` を照合した．

図 2 に，同一評価事例で同時に誤答したモデル数と，正解判断に必要な情報を判断根拠として挙げた判定の割合および表層指標のみを判断根拠として挙げた判定の割合との関係を示す．同時誤答モデル数が少ない事例では，正解判断に必要な情報の参照率は 90%前後で推移した．一方で，同時誤答モデル数が増えるにつれて参照率は低下し，多数のモデルが同時に誤る事例ほど，正解判断に必要な情報が判断根拠として挙げられにくくなった．全 22 モデルが誤答した事例では，その割合は約 1 割まで低下しており，これとは逆に，表層指標のみを判断根拠として挙げた割合は同時誤答モデル数とともに増加し，20 モデル以上が誤る事例では約 2 割以上を占めた．また，正解判断に必要な情報を判断根拠として挙げた判定の誤り率は 10.8%であったのに対し，挙げなかった判定では 84.9%であった．以上より，共通故障が強くなるにつれて，複数モデルが正解判断に必要な情報を判断根拠として挙げる割合が低下し，代わって表層指標のみを判断根拠として挙げる判定が増える傾向が確認された．

4.4 冗長化と集約規則

本節では，複数モデルの構成によって見逃しをどの程度抑えられるか，またその際に誤警報がどの程度増加するかを確認する．さらに，全 22 モデルを使用する場合に，TP 判定に必要な票数によって運用上のリスクがどのように変化するかを評価する．

表 3 TP 判定に必要な票数による運用点の違い

TP 判定条件	FNR (%)	FPR (%)
1 票以上（1-of-22）	0.0	95.2
過半数（12-of-22）	0.3	27.9
全会一致（22-of-22）	67.3	2.4

まず，図 3 は，モデルを組み合わせたときの集約後の偽陽性率（FPR）と偽陰性率（FNR）の関係を示す．横軸は集約後に非悪性事例を TP と判定する FPR を表し，縦軸は集約後に悪性事例を非 TP と判定する FNR を表す．なお，1-of-n 規則では，この FNR は第 3.2.4 節で定義した $CFNR$ と一致する．左下に近いほど誤警報と見逃しの双方が少ないことを意味する．プロットしている灰色の点は 4 モデル以下の全 9,108 構成に 1-of-n 規則を適用した運用点，青線はその Pareto 前線を示す．オレンジ色の点は全 22 モデルに対して TP 判定に必要な票数 k を変化させた k-of-22 閾値規則の運用点を示す．Pareto 前線では，FPR をほぼ 0% に抑える構成では FNR が約 24% となる一方，FNR を約 9% まで低下させる構成では FPR が約 38% まで上昇する．したがって，1〜4 モデル程度の構成により見逃しを低い水準まで抑えられる場合もあるが，運用面においては，誤警報の増加を受け入れる必要がある．

次に，表 3 に，全 22 モデルを使用したまま TP 判定に必要な票数を変えた場合の運用点を示す．ここでは，1 票以上，過半数，全会一致の 3 条件を比較する．1 票以上で TP とする場合は見逃しを 0.0% まで抑えられるが，良性事例の 95.2% を誤って TP と判定する．一方，全会一致では FPR は 2.4% まで低下するが，FNR は 67.3% まで上昇する．過半数では FNR を 0.3% に抑えながら FPR を 27.9% まで低減している．したがって，同じ 22 モデルを用いても，TP 判定に必要な票数によって見逃しと誤警報のバランスは大きく変化し，運用上の許容水準に応じた集約閾値の選択が必要である．

© 2026 Information Processing Society of Japan

表 4 反復実行，異種モデル構成，および共通故障の検知信号

(a) 呼び出し回数を揃えた構成比較（1-of-k 規則）

k	同一モデル反復		異なるモデル	
	$CFNR$	FPR	$CFNR$	FPR
1	9.92%	27.2%	9.92%	27.2%
2	7.58%	31.5%	1.91%	37.3%
3	6.14%	34.5%	0.48%	43.4%

(b) 共通故障に対する観測信号

指標	結果	分母
3 反復すべてで同一の誤答	79.0%	222/281
確信度 90 以上の誤判定	42.3%	1748/4129
確信度 90 未満での捕捉率	57.7%	2381/4129

表 5 SIABench における誤り依存

モデル対	平均 IG	TP 誤答数	非 TP 誤答数
全モデル対	+.0227 [+.0018,+.0540]	6.2	3.8
異提供者対	+.0222	–	–

表 6 SIABench における固定構成と集約規則の比較

構成	同票処理	均衡精度	coverage	FPR
固定 2 モデル	保留	0.900	88.6%	–
固定 2 モデル	TP	0.833	100%	–
全 22 モデル	多数決	0.900	100%	–
全 22 モデル	1-of-22	0.517	100%	96.7%

4.5 自己一致による反復安定性

本節では，共通故障の緩和策として，同一モデルの反復実行と自己申告確信度の有効性を評価する．150 事例について，同一モデルを 3 回実行する構成と異なる 3 モデルを各 1 回実行する構成を，同じ呼び出し回数で比較した．また，共通故障事例における反復誤答の安定性と確信度による検知可能性を調べた．

表 4 上段は，1 事例あたりの呼び出し回数 k を揃えたときの同一モデル反復と異種モデル構成の $CFNR$ および FPR を示す．下段は，共通故障における反復誤答の安定性と確信度による選別結果を示す．なお，上段および安定誤答率は 150 事例の自己一致実験，確信度に関する 2 指標は主実験から算出している．表 4 に示すように，3 回呼び出し時の $CFNR$ は，同一モデル反復の 6.14% に対し異なる 3 モデルでは 0.48% まで低下したが，FPR は 34.5% から 43.4% へ上昇した．したがって，異種モデルは反復実行より見逃しを減らす一方，偽陽性を増加させる．

また，R1 上の共通故障 13 事例について，3 反復中 1 回以上誤答した 281 モデル・事例対の 79.0% は 3 回とも同じ誤答を返した．さらに，主実験の R1–R5 における共通故障 198 評価事例で生じた誤判定 4,129 件の 42.3% は確信度 90 以上であり，90 未満を確認しても捕捉率は 57.7% にとどまった．よって，共通故障は反復しても安定し，高い確信度を伴う場合があるため，判定の揺らぎや確信度閾値だけでは十分に検知できないと言える．

4.6 SIABench による外部検証

本節では，合成 SOC コーパスで観測した誤り依存と集約規則の性質が，独立な SIABench でも観測されるかを確認する．35 事例について同じ 22 モデルを 3 回実行し，モデル構成は外部データ上で再最適化せず評価した．

表 5 は誤り依存の再現性と誤り方向を示す．全モデル対，異提供者対のいずれでも平均 IG は正であり，全モデル対では 95% CI も 0 をまたがなかった．一方，平均誤答モデル数は TP で 6.2，非 TP で 3.8 であり，主実験とは誤りの方向が一致しなかった．ただし TP は 5 件のみであり，この差は記述的結果として扱う．

表 6 は，主実験で固定した構成と集約規則を外部データ上で比較した結果である．固定 2 モデル構成は均衡精度 0.900 であったが，11.4%を判定保留としており，全 22 モデル多数決とは coverage が異なる．同票を TP へ割り当てると均衡精度は 0.833 へ低下したため，固定構成の性能は同票処理に依存する．一方，1-of-22 では FPR が 96.7% に達したのに対し，多数決ではより実用的な運用点が得られ，実験で観測した閾値依存性が外部データでも確認された．

以上より，誤り依存そのものは外部データでも観測されたが，誤りの方向は転移しなかった．また，固定構成は外部でも一定の性能を示したものの，全 22 モデル多数決に対する一貫した優位性は確認できない．具体的なモデル名と構成は付録表 A·10 に示す．

5. 考察

本稿で観測された共通故障は，モデルどうしが個別に似ているというよりも，複数モデルが同じ事例に対して同じ判断上の近道を用いることで生じていると解釈できる．潜在難易度を考慮すると平均的な同時誤りの多くは説明された一方，20–22 モデルが同時に誤る極端な事例は帰無モデルでも十分に説明されなかった．さらに，このような事例では，自己申告された判断根拠における決定的証拠の参照率が大きく低下し，表層的な指標のみを挙げる割合が増加していた．

この結果の 1 つの解釈としては，深層学習モデルが本質的な判断規則ではなく，予測しやすい表層特徴を利用する shortcut learning [5] によってもたらされることが考えられる．LLM についても，異なるモデルや提供者の間で誤りが相関することが報告されており [8]，アルゴリズムが広く共有されることで失敗も共有される algorithmic monoculture の議論 [9] とも対応する．本稿の結果は，SOC トリアージではその共有成分が，「どの証拠を判断根拠として挙げるか」という出力上の傾向として現れる可能性を示している．

また，意味を変えない書式や提示方法の変更による判定反転が複数モデルで共有されたことは，LLM が非本質的な入力特徴に感受性を持つという既存研究 [11, 13] と整合

© 2026 Information Processing Society of Japan

する．したがって，複数モデルを併用しても，同じ表現上の特徴に影響される場合には誤りが独立に分散せず，同じ事例で複数モデルが誤る可能性が残る．

そして，この性質は単純な冗長化では解消しにくい．同一モデルの反復より異種モデル構成の方が見逃しを減らしたものの，モデル数を増やせば集合レベルの偽陽性も増加した．また，共通故障は高い自己申告確信度を伴って安定して生じており，LLM の過信に関する既存研究 [6, 16] とも整合する．したがって，モデルの追加，反復実行，確信度による選別だけでは十分ではなく，CFNR と FPR を同時に評価しながら集約規則を設計するとともに，正解判断に必要な証拠が実際に検討されているかを別途確認する仕組みが必要となる．

ただし，本稿の主実験で極端な共通故障は主として false positive 側に現れた一方，SIABench では誤りの方向は一致しなかった．したがって，本稿が示すのは特定方向の誤りが普遍的に共有されることではなく，異なる LLM であっても，同じ事例特性に起因して同時に誤る共通故障が生じうるという点である．今後は実運用データと人間アナリストの判定を用いて，この共有された判断上の近道がどの程度再現されるかを検証する必要がある．

6. まとめ

本稿では，LLM 支援型 SOC における複数モデルの冗長性を，14 提供者 22 モデル，39,600 件の判定を用いて検証した．事例固有の難易度を条件付けると平均的な同時誤りの多くは説明されたが，20–22 モデルが同時に誤る極端な共通故障は残り，その際には正解判断に必要な証拠を判断根拠として挙げる割合が大きく低下した．また，冗長化では見逃しと偽陽性のトレードオフが生じ，全 22 モデルの 1-of-22 では FNR 0.0%と引き換えに FPR が 95.2%へ達した一方，12-of-22 では FNR 0.3%，FPR 27.9%となった．さらに，同一モデルの反復と自己申告確信度だけでは共通故障を十分に検知できず，SIABench でも正の誤り依存と集約規則の影響は確認されたものの，誤りの方向は転移しなかった．

このことから，複数 LLM を併用しても，各モデルが独立した防御層として機能するとは限らず，事例固有の難易度では説明しきれない極端な共通故障が残ることが示された．したがって，LLM の冗長化はモデル数だけで評価するのではなく，共通故障と CFNR–FPR の運用点を測定し，k-of-n 閾値とモデル構成を選択する必要がある．

参考文献

[1] Barnes, J.: OpenSec: Measuring Incident Response Agent Calibration Under Adversarial Evidence, *arXiv preprint arXiv:2601.21083* (2026).

[2] Benjamini, Y. and Hochberg, Y.: Controlling the false discovery rate: a practical and powerful approach to multiple testing, *Journal of the Royal statistical society: series B (Methodological)*, Vol. 57, No. 1, pp. 289–300 (1995).

[3] Deason, L., Bali, A., Bejean, C., Bolocan, D., Crnkovich, J., Croitoru, I., Durai, K., Midler, C., Miron, C., Molnar, D. et al.: Cybersoceval: Benchmarking llms capabilities for malware analysis and threat intelligence reasoning, *arXiv preprint arXiv:2509.20166* (2025).

[4] Freitas, S., Kalajdjieski, J., Gharib, A. and McCann, R.: Ai-driven guided response for security operation centers with microsoft copilot for security, *Companion Proceedings of the ACM on Web Conference 2025*, pp. 191–200 (2025).

[5] Geirhos, R., Jacobsen, J.-H., Michaelis, C., Zemel, R., Brendel, W., Bethge, M. and Wichmann, F. A.: Shortcut learning in deep neural networks, *Nature Machine Intelligence*, Vol. 2, No. 11, pp. 665–673 (2020).

[6] Guo, C., Pleiss, G., Sun, Y. and Weinberger, K. Q.: On calibration of modern neural networks, *International conference on machine learning*, PMLR, pp. 1321–1330 (2017).

[7] Jajodia, S., Sultana, M., Majumdar, S., Taylor, A. and Vandenberghe, G.: Before you hand over the wheel: Evaluating LLMs for security incident analysis, *arXiv preprint arXiv:2603.06422* (2026).

[8] Kim, E., Garg, A., Peng, K. and Garg, N.: Correlated errors in large language models, *arXiv preprint arXiv:2506.07962* (2025).

[9] Kleinberg, J. and Raghavan, M.: Algorithmic monoculture and social welfare, *Proceedings of the National Academy of Sciences*, Vol. 118, No. 22, p. e2018340118 (2021).

[10] Kuncheva, L. I. and Whitaker, C. J.: Measures of diversity in classifier ensembles and their relationship with the ensemble accuracy, *Machine learning*, Vol. 51, No. 2, pp. 181–207 (2003).

[11] Liu, N. F., Lin, K., Hewitt, J., Paranjape, A., Bevilacqua, M., Petroni, F. and Liang, P.: Lost in the middle: How language models use long contexts, *Transactions of the association for computational linguistics*, Vol. 12, pp. 157–173 (2024).

[12] Okada, H., Oba, T. and Yanai, N.: LLMs, You Can Evaluate It! Design of Multi-perspective Report Evaluation for Security Operation Centers, *arXiv preprint arXiv:2601.03013* (2026).

[13] Sclar, M., Choi, Y., Tsvetkov, Y. and Suhr, A.: Quantifying Language Models' Sensitivity to Spurious Features in Prompt Design or: How I learned to start worrying about prompt formatting, *International Conference on Learning Representations*, Vol. 2024, pp. 25055–25083 (2024).

[14] Wei, B., Tay, Y. S., Liu, H., Pan, J., Luo, K., Zhu, Z. and Jordan, C.: CORTEX: Collaborative LLM agents for high-stakes alert triage, *arXiv preprint arXiv:2510.00311* (2025).

[15] Wu, Y., Velazco, M., Zhao, A., Luján, M. R. M., Movva, S., Roy, Y. K., Nguyen, Q., Rodriguez, R., Wu, Q., Albada, M. et al.: Excytin-bench: Evaluating llm agents on cyber threat investigation, *arXiv preprint arXiv:2507.14201* (2025).

[16] Zhao, T., He, Y., Zheng, W., Zhang, Y. and Chen, C.: Wired for overconfidence: A mechanistic perspective on inflated verbalized confidence in llms, *arXiv preprint arXiv:2604.01457* (2026).

© 2026 Information Processing Society of Japan

付　　録

A.1　分析データの構造と入力条件

本付録では，本文の分析手順を追跡できるよう，分析データの具体例と補助結果を示す．まず本節で合成 SOC コーパスと入力表現を示し，付録 A.4 にて，モデル応答と判断根拠の分析単位を示し，その後モデル別性能および補助分析の詳細を示す．表中の値は corpus.json，prompts.jsonl，および各モデルの応答ファイルに保存された実データに基づく．紙幅の都合で長い文字列のみ省略しているが，ラベル，フィールド名，判定結果，判断根拠の分類は変更していない．

A.2　合成 SOC コーパスの基準レコード

表 A·1 に，合成 SOC コーパス中の INC-0000 を例として示す．この事例は表層上は悪性に見えるイベントを含む一方，検知器の不具合が記録されており，正解ラベルは false_positive である．コーパスでは各事例について，正解判断に必要なフィールドを decisive_fields として保持する．

A.3　意味保存表現と対照条件

同一の基準事例から，内容を保ったまま提示形式を変えた R1–R5 と，判断文脈を削除した対照条件 C1 を生成する．表 A·2 は，INC-0000 について prompts.jsonl に保存された 6 条件を示す．R1–R5 には semantics_preserving=true が付与され，C1 のみ false である．

A.4　モデル応答と分析単位

本節では，モデル応答に保存したフィールドと，本文の判断根拠分析・自己一致分析で実際に用いたレコードの対応関係を示す．

A.5　モデル応答データの仕様

モデル応答は，プロンプト単位のメタデータと，モデルが返した構造化判定から構成される．主要フィールドを表 A·3 に示す．これにより，判定ラベルだけでなく，確信度，判断根拠として挙げたフィールド，不確実性の自己申告，課金情報，および再現性確認用の hash を同一レコードから追跡できる．

A.6　判断根拠の照合例

表 A·4 は，同一の INC-0000・R1 入力に対する 2 モデルの実応答を比較したものである．正解ラベルは false_positive であり，決定的証拠は detector_defect と artifact_reproduced_in_lab である．本文の判断根拠分析では，このように evidence_fields と decisive_fields を照合する．

この比較で正答モデルと誤答モデルに与えた入力は同一である．分析対象となる差は，モデルが申告した判断根拠と判定結果である．なお，evidence_fields はモデルの自己申告であり，内部の注意機構や因果的な推論経路を直接観測したものではない．

A.7　自己一致実験のレコード例

自己一致実験では，同一モデル・同一事例・同一表現に対して temperature = 1.0 で 3 回の応答を取得する．表 A·5 に，command-r7b へ INC-0026 の R1 入力を 3 回提示した実例を示す．この事例の正解ラベルは false_positive である．

表 A·5 のような 3 反復の判定列を用いて，本文では判定一致率，安定誤答率，および異種モデル構成との違いを分析する．

A.8　モデル別性能と補助分析

本節では，本文で分布のみを示したモデル別性能に加え，主分析を補うモデル属性，入力表現，費用制約下の構成，および外部検証の詳細を示す．

A.9　モデル単体の性能

全 22 モデルの単体性能を表 A·6 に示す．本文では個別モデル名による議論を避け，性能分布を中心に報告した．価格は実験時の実課金額に基づく．

A.10　費用分析で用いたモデル構成

第 3.2.4 節で定義した費用制約下の構成分析に対応する具体的なモデル集合を，表 A·7 に示す．「最高価格」はモデル能力の代理変数ではなく，実験時の実課金額に基づく呼称である．

低価格 3 モデルの評価は，特定の集合の普遍的優位性を主張するものではなく，シナリオファミリ単位の leave-one-family-out で選択手続きを評価した結果に基づく．また，最高価格モデルを追加した 4 モデル構成では同票が 5.3% 生じ，正答率の変化は同票規約により −1.20 から +0.87 ポイントまで変化する．

A.11　モデル属性と入力表現の補助結果

モデル属性と誤り依存の関係を表 A·8 に，基準表現 R1 から入力形式を変更したときの判定反転とモデル間転移を表 A·9 に示す．これらは本文の主結論を補助する結果であり，個別モデルの優劣を示すものではない．

A.12　SIABench で固定したモデル構成

外部検証では，合成 SOC コーパス上で選択した構成を再最適化せず固定して評価した．主要結果を表 A·10 に示す．

© 2026 Information Processing Society of Japan

表 A·1 合成 SOC コーパスの実レコード例（INC-0000）

項目	実データ中の値・内容
incident_id	INC-0000
scenario_family	Malware
正解ラベル	false_positive
表層顕著性	high
アラート	Malicious document spawned downloader
検知器	EDR/DocumentChildProcess
ATT&CK	T1027.002
主なイベント	invoice_671.docm の作成後，winword.exe から cmd.exe が起動し，mshta.exe による URL 参照が記録されている．その後，ネットワークセッション集計と identity risk の更新が記録される．
調査文脈	change_request=none_found，account_owner_confirmation=no_activity_reported_by_owner，detector_defect=duplicate_event_from_agent_restart，artifact_reproduced_in_lab=false
decisive_fields	artifact_reproduced_in_lab，detector_defect
分析上の意味	表層イベントだけを見れば攻撃らしく見えるが，正解判断には検知器の不具合と再現試験結果を読む必要がある．

表 A·2 同一事例から生成された入力表現の実例（INC-0000）

表現	意味保存	文字数	入力の冒頭または形式の例
R1_canonical_json	yes	1,591	{"alert": {"alert_name": "Malicious document spawned downloader", ...}, "events": [...], "investigation_context": {...}}
R2_flat_kv	yes	1,181	# alert alert_name="Malicious document spawned downloader" detector=EDR/DocumentChildProcess ...
R3_narrative	yes	1,300	「検知ルール Malicious document spawned downloader が EDR/DocumentChildProcess により発報した．対象は Executive 部門の端末 LT-EXEC-0031 ...」
R4_noisy_shuffled	yes	3,096	基準情報を保持したまま，無関係な正常イベントを追加し，イベントの提示順を変更した表現
R5_vendor_schema	yes	1,328	CEF:0|ExampleVendor|ExampleSIEM|1.0|name="Malicious document spawned downloader"|...
C1_context_stripped	no	1,249	JSON 形式を維持しつつ，判断に必要な調査文脈を削除した対照条件

表 A·3 モデル応答データの主要フィールド

階層	フィールド	内容
応答メタデータ	prompt_id, incident_id, representation, rep	対象プロンプト，基準事例，入力表現，反復番号を識別する．
応答メタデータ	model_short, model_slug, actual_provider	モデルと実際の提供者を識別する．
応答メタデータ	temperature, parsed_ok, finish_reason	実行条件と構造化出力の成否を記録する．
response	decision	true_positive，benign_positive，false_positive の判定．
response	confidence, severity, recommended_action	自己申告確信度，重大度，推奨措置．
response	evidence_fields	判断根拠としてモデル自身が挙げた入力フィールド名の配列．
response	rationale, uncertainty_reason	自由記述の判断理由と不確実な点．
課金・再現性	usage, 各種 SHA-256, attempts	token 使用量・費用，要求・応答・入力本文の hash，実行試行数を保存する．

2 モデルの運用点最安構成は gemini-3.1-flash-lite と mistral-small-3.2 である．11.4%の同票を判定保留とするため，自動判定 coverage は 88.6%となる．同票を TP へ解消した感度分析では均衡精度は 0.833 であった．

© 2026 Information Processing Society of Japan

表 A·4 同一事例に対する判断根拠の実例（INC-0000, R1）

モデル	判定	正誤	確信度	evidence_fields	判断理由の要約
glm-4.7-flash	false_positive	正答	90	detector_defect, change_scope, signed, risk_score, account_owner_confirmation, process	agent restart による重複イベントという detector_defect を明示的に根拠として挙げている．決定的証拠を参照した判定として分類する．
gemini-3.1-flash-lite	true_positive	誤答	95	process, parent_process, command_line, path	document から cmd.exe，mshta.exe へ続くプロセス列を根拠として攻撃と判定している．決定的証拠を参照していない判定として分類する．

表 A·5 自己一致実験の実レコード例（command-r7b, INC-0026）

反復	判定	確信度	evidence_fields	判断理由の概要
0	true_positive	85	command_line	encoded script interpreter invocation を主な根拠として悪性と判定.
1	benign_positive	80	command_line, department, host_criticality, integrity_level, signed, network_connect_dst_ip	企業内ドメインへの通信等を踏まえ，良性寄りに判定.
2	true_positive	85	command_line	encoded script と PowerShell の隠蔽オプションを根拠として悪性と判定.

表 A·6 全 22 モデルの単体性能（意味保存表現 R1–R5，temperature= 0）

モデル	提供者	F1	TP-hi	TP-med	TP-low	FPR	ECE	$/1000
hunyuan-3	Tencent	.735	1.00	.98	.86	.27	.133	1.25
glm-4.7-flash	Z.ai	.724	.72	.67	.47	.09	.090	1.17
gpt-5.6-terra	OpenAI	.723	1.00	1.00	.98	.35	.133	2.68
gpt-oss-120b	OpenAI	.713	1.00	1.00	1.00	.30	.098	.39
llama-3.3-70b	Meta	.711	.96	.92	.94	.32	.100	1.09
gemini-3.1-flash-lite	Google	.706	1.00	1.00	1.00	.26	.147	.59
nemotron-3-nano	NVIDIA	.690	.97	.98	.87	.32	.124	.26
gemini-2.5-flash	Google	.688	1.00	.99	.99	.31	.153	.75
deepseek-v4-flash	DeepSeek	.688	1.00	1.00	.99	.33	.120	.49
minimax-m2.5	MiniMax	.687	.99	.99	.98	.24	.106	.96
mistral-medium-3.1	Mistral	.670	.98	.98	.94	.25	.130	.58
qwen3-235b	Alibaba	.669	.93	.91	.86	.33	.182	.18
haiku-4.5	Anthropic	.668	.99	.94	.94	.27	.092	2.40
deepseek-v3.1	DeepSeek	.639	.87	.81	.64	.13	.123	.32
mistral-small-3.2	Mistral	.638	.85	.86	.74	.16	.186	.11
gpt-5.6-luna	OpenAI	.604	1.00	1.00	1.00	.48	.208	.33
gpt-4.1-mini	OpenAI	.601	1.00	.99	.98	.39	.185	.60
llama-4-maverick	Meta	.547	.90	.89	.73	.27	.200	.29
phi-4	Microsoft	.509	.96	.94	.91	.60	.288	.09
gemma-3-27b	Google	.496	.81	.76	.69	.25	.220	.12
ling-2.6-flash	InclusionAI	.360	.93	.96	.93	.72	.415	.02
command-r7b	Cohere	.353	.81	.81	.77	.65	.429	.07

表 A·7 本文の費用比較に対応するモデル構成

用途	構成	$/1000	CFNR/見逃し	FPR	正答
最高価格単体	gpt-5.6-terra	2.68	0.7%	35.1%	77.9%
探索的低価格 3 モデル	gpt-oss-120b + minimax-m2.5 + glm-4.7-flash	2.53	1.0%	20.9%	80.9%
上記 + 最高価格	上記 3 モデル + gpt-5.6-terra	5.20	0.7%	22.9%	79.7%
制約付き最小費用例	gpt-oss-120b（$CFNR \leq .10$, $FPR \leq .30$）	.39	0.0%	29.8%	–
外部検証の運用点最安	gemini-3.1-flash-lite + mistral-small-3.2	.70	–	–	–

© 2026 Information Processing Society of Japan

表 A·8 モデル属性による IG 群間比較（QAP 型置換, 50,000 反復）

属性	Δ 平均 IG	p
同一提供者 vs 異提供者	+.0217	.0265
同価格帯 vs 異価格帯	-.0120	.1532
同一重み属性 vs 異属性	-.0097	.0931
同一ファミリ（提供者内）	+.0300	.499

表 A·9 入力表現による判定反転と転移

表現	反転（%）	新規見逃し（%）	転移/独立
R2 key=value	7.7	3.0	2.43
R3 自然言語	7.1	5.5	1.37
R4 雑音混入	5.9	6.2	1.78
R5 別スキーマ	8.5	4.9	2.18
C1 文脈削除	27.5	14.8	2.01

表 A·10 SIABench 上の固定構成の主要結果

構成	$\|S\|$	均衡精度	coverage
運用点最安	2	.900	88.6%
全 22 モデル多数決	22	.900	100%
全 22 モデル OR	22	.517	100%

© 2026 Information Processing Society of Japan