Confidential AIにおける証拠付きレポーティングの形式化

髙橋 翼[1,a)]　平岡 拓海[1]

概要：Confidential AIでは，入力やモデルだけでなく実行ログも秘匿されるため，運用や監査に必要な情報を観測できないObservability Blackoutが生じる．本稿では，その緩和を，プライベートな文章の生成ではなく，データによる証拠を伴うレポーティングの問題として捉える．ステートメント単位の支持，支持帰属，支持推定，片側誠実性，および出力保留を定式化し，単一の自由文形式の差分プライベート (DP) な出力から支持を読み取る能力が局所的に制約されることを示す．さらに，候補生成とDPサポート検証を分離する参照構成を示し，支持されていない出力を制御できることを実データ上で確認する．これらの結果は，Confidential AIにおける信頼可能な報告には，流暢な文章だけでなく，各主張が元のデータにどの程度支持されているかを明示する必要があることを示す．

Formalizing Evidence-Bearing Reporting for Confidential AI

Tsubasa Takahashi[1,a)]　Takumi Hiraoka[1]

Abstract: Confidential AI protects not only inputs and models but also execution logs, creating an *Observability Blackout* in which information needed for operation and auditing cannot be directly observed. This paper frames its mitigation not as a problem of generating private text, but as one of evidence-bearing reporting. We formalize statement-level support, support attribution, support estimation, one-sided honesty, and abstention, and show that the ability to infer support from a single free-text differentially private output is locally constrained. We further present a reference design that separates candidate generation from differentially private support verification, and empirically confirm on real-world datasets that it controls the emission of unsupported statements. These results show that trustworthy reporting for Confidential AI requires not only fluent text, but also explicit information about how strongly each statement is supported by the underlying data.

1. はじめに

金融，製造，行政など，機密性の高い領域でもAI活用が進んでいる．機密コンピューティング（Confidential Computing; CC）を基盤とするConfidential AIは，信頼実行環境（Trusted Execution Environment; TEE）などを用い，入力，モデル，中間状態，実行ログを含む計算過程を，クラウド事業者や基盤運用者からも秘匿する [1, 5]．

一方，計算過程を秘匿することは，AIシステムの運用，監査，改善に必要な観測経路も制限する．通常のAIサービスでは，プロンプトや応答を含む利用ログを分析することで，利用傾向や失敗事例を把握できる [11, 8]．しかし，Confidential AIでは，これらのログ自体が利用者の秘密や処理内容を含み得るため，そのまま外部へ開示できない [1, 5]．本稿では，機密性の確保によって，運用や監査に必要なファクトやシグナルを観測できなくなる状態を *Observability Blackout* と呼ぶ．これは単なるログ機能の不足ではなく，秘密の保護と内部状態の把握との間に生じる構造的な問題である．

Observability Blackoutを緩和する方法として，差分プライバシー（Differential Privacy; DP） [3] で保護された統計や自然言語レポートを秘匿環境から出力することが考えられる．DPは，個々のレコードの影響を制限しながら，データセットに関する情報を公開する標準的な枠組みである [3, 4]．近年では，プライベート学習，推論時の復号，合成データ生成などを通じて，流暢なDPテキストを生成

[1] 株式会社 Acompany
Acompany Co., Ltd.
[a)] tsubasa.takahashi@acompany-ac.com

© 2026 Information Processing Society of Japan

This paper is work in progress and not peer-reviewed.

表 1　Observability Blackout 下における情報出力形式の概念的な比較.

出力形式	プライバシー	自然言語性	明示的な支持情報	出力保留
生ログの開示	×	–	高い	–
自由文形式の DP 生成	✓	✓	×	通常なし
DP 統計・集計	✓	限定的	✓	可能
証拠付きレポーティング	✓	✓	✓	✓

する手法が研究されている [15, 12, 14]．また，CLIO や Urania は，実際の AI 利用ログからプライバシーを保護した集約的な知見を生成する [11, 8].

しかし，プライバシーを保護した文章であることと，その文章をデータに基づく報告として信頼できることは同じではない．たとえば，「利用者は薬の副作用について頻繁に議論している」という文章が出力されても，その主張がデータ全体に広く見られる傾向なのか，少数の記録に由来する逸話なのか，DP ノイズや言語モデルの事前知識に由来するのかは，文章だけからは判断できない．DP は個々の記録の影響を制限するが，文章中の各主張がデータセットによってどの程度支持されているかを直接保証しない．元のログを確認できない Confidential AI では，根拠の不明な流暢な文章が，誤った観測可能性を与える危険がある．

表 1 に，Observability Blackout 下で考えられる情報出力形式を整理する．生ログは詳細な観測を可能にするが，保護対象の秘密を開示する．DP 統計やヒストグラムは，意味の明確な集計値を提供できる [4]．一方，自由文形式の DP 生成は読みやすいが，個々の主張の支持を明示しない．

そこで本稿では，Observability Blackout の緩和を，**証拠付きレポーティング**の問題として捉える．証拠付きレポーティングとは，自然言語のステートメントに，プライベートデータセットによる支持度を示す DP 統計を対応付け，証拠が不十分な場合には明示的に出力を保留する報告形式である．これにより，「プライベートな文章を生成できるか」という問いと，「報告された主張をデータに基づく証拠として扱えるか」という問いを区別する．

本稿では，各ステートメント s に対してデータセット R による支持度 $f_s(R)$ を定義し，支持の有無を判定する支持帰属，支持度を評価する支持推定，支持されていない主張の出力確率を制御する片側誠実性，および出力保留を形式化する．さらに，DP の識別不可能性が有効な局所領域では，単一の自由文形式出力から支持帰属や支持推定を行うことに統計的な限界があることを示す．これは大域的な傾向が常に隠蔽されるという主張ではなく，自由文形式の DP 出力には，各主張の支持度を示す明示的な経路がないことを表す.

その具体化として，候補ステートメントの生成と DP による支持検証を分離する Proposal-Filter Reporting を提案する（図 1）．データ非依存に生成された候補について支持度の下界を計算し，閾値を超えたものだけを証明書とともに報告する．この構成は，DP クエリ応答や閾値選択などの既存技術と関連する [4, 9]．本稿の目的は，新たな DP プリミティブや閾値処理を提案することではない．既存の DP 集計・検定を，主張，証拠，出力保留を対応付けるレポーティングインターフェースとして整理する.

貢献．本稿の主な貢献は以下の三点である.

(1) Confidential AI における Observability Blackout を整理し，その緩和を証拠付きレポーティングの問題として位置付ける.

(2) ステートメント単位の支持，帰属，推定，片側誠実性，出力保留を定式化し，自由文形式の DP 出力が持つ証拠能力の局所的限界を示す.

(3) 候補生成と DP 支持検証を分離する参照構成を示し，誤報告，カバレッジ，プライバシー予算の関係を理論的・実験的に分析する.

2. 関連研究

DP テキスト生成とプライベートな報告．差分プライバシーによるテキスト生成は，プライベート学習 [15]，推論時の復号 [12]，合成データ生成 [14] などを通じて研究されてきた．CLIO [11] や Urania [8] は，プライベートな利用ログから集約的な知見を生成する.

DP 集計と閾値選択．DP クエリ応答は，カウントやヒストグラムなどの統計量をノイズ付きで公開し [4]，スパースベクトル技法は閾値を超えるクエリをプライベートに選択する [4, 9]．本稿の焦点は新たな閾値処理ではなく，各ステートメントをサポート証明書または出力保留とともに公開する証拠付きレポーティングの定式化にある.

3. 証拠付きレポーティングの定式化

本節では，プライベートなコーパスに関する自然言語の主張を，差分プライバシーによる支持情報および出力判断と対応付ける証拠付きレポーティングを定式化する.

プライベートコーパスを $R = \{r_1, \ldots, r_n\}$，報告タスクを q とする．各レコードは，プロンプト，応答，実行履歴，エラーなど，秘匿環境内に存在する情報を表す．報告機構 $\mathcal{A}(q, R)$ は秘匿環境内で実行され，プライバシーを保護しながら外部へ公開可能な報告を生成する.

脅威モデル．プライベートコーパス R は Confidential AI の秘匿環境内に保持され，クラウド事業者，基盤運用者，外部分析者，および報告の受領者から直接観測できないも

© 2026 Information Processing Society of Japan

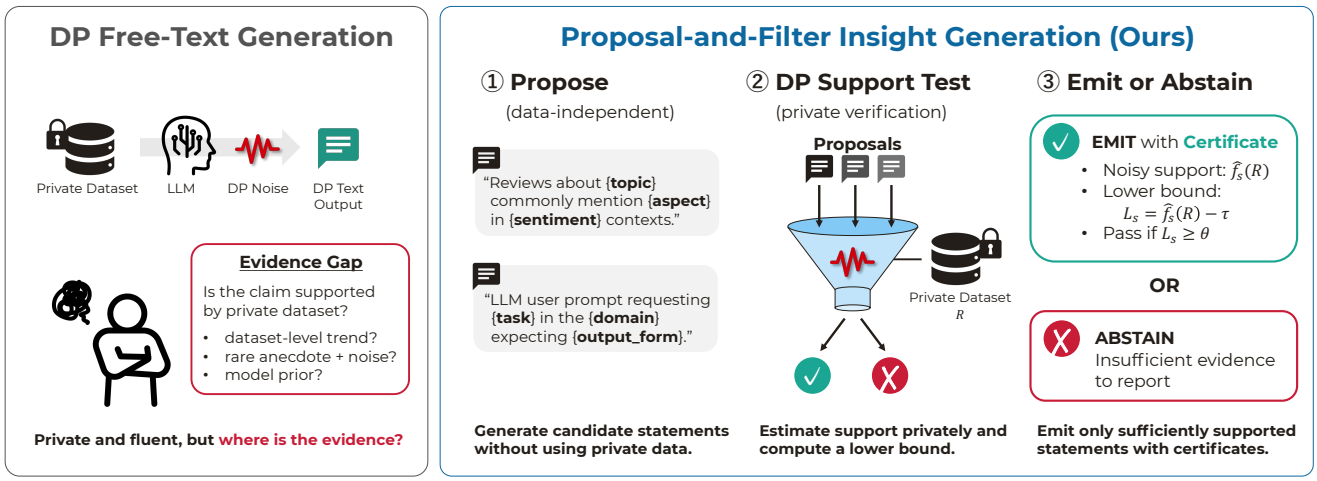


図 1　プライベートテキストから証拠付きレポートへ．ステートメントの提案と差分プライバシーによるサポート検証を分離し，十分な証拠を持つ主張のみを出力する．

のとする．攻撃者は，外部へ公開されるステートメント，サポート証明書，および出力判断から，個々のレコードに関する情報を推測しようとする．秘匿環境とその内部で動作する報告機構は正しく実行されるものと仮定し，秘匿環境の侵害，サイドチャネル，および実装上の脆弱性は対象外とする．

差分プライバシー．固定サイズのコーパスに置換隣接性を用いる．機構 $\mathcal{A}$ が ε-差分プライバシーを満たすとは，任意の固定された q，事象 E，隣接コーパス $R \sim R'$ について，

$$\Pr[\mathcal{A}(q, R) \in E] \leq e^{\varepsilon} \Pr[\mathcal{A}(q, R') \in E]$$

が成り立つことをいう．異なるレコード数を $d(R, R')$ とすると，グループプライバシーにより，$d(R, R') \leq k$ の場合には係数が $e^{k\varepsilon}$ となる．この安定性を第 4 節の下界で用いる．また，文章，証明書，出力判断，データ依存の候補選択を含む公開情報全体をプライバシー会計の対象とする．

3.1　ステートメントとサポート

ステートメント $s \in \mathcal{S}$ とは，「利用者は薬の副作用について頻繁に議論している」のような，コーパスに関する意味的な主張である．R が s をどの程度支持するかを，

$$f_s(R) \in [0, 1]$$

で表す．本稿では，固定されたレコード単位の述語 $\sigma_s(r) \in \{0, 1\}$ に対し，

$$f_s(R) = \frac{1}{|R|} \sum_{r \in R} \sigma_s(r) \qquad (1)$$

を用いる．置換隣接性のもとで感度は $\Delta_f \leq 1/|R|$ である．

σ_s は，ルール，分類器，NLI モデル，セマンティックマッチャーなどで実装できる．サポートモデルがプライベートコーパスに依存する場合には，その学習や選択もプライバシー会計に含める．また，$f_s(R)$ は，あらかじめ定義された σ_s のもとでのコーパス上の支持を表すものであり，外部世界における普遍的な真実や因果関係を保証するものではない．

3.2　二つの報告形式

自由文形式の報告．自由文形式の機構は，

$$Y \sim \mathcal{A}_{\text{free}}(q, R), \qquad Y \in \mathcal{Y}$$

として自然言語のみを出力する．文章には複数のステートメントが含まれ得るが，各ステートメントと $f_s(R)$ との明示的な対応はない．DP 保証は出力分布の安定性に関するものであり，文章中に s が現れたことだけから $f_s(R)$ が大きいとはいえない．

証拠付きレポーティング．証拠付き機構は，

$$\mathcal{B} = \{(s_j, c_j, a_j)\}_{j=1}^{m}$$

を出力する．ここで，s_j は評価対象のステートメント，c_j は DP によるサポート証明書，$a_j \in \{\text{emit}, \text{abstain}\}$ は報告判断である．証明書は，ノイズ付き支持値，信頼下界，信頼区間など，公開された統計的意味を持つ．十分な証拠がない場合には出力を保留する．報告されたステートメントは後処理として文章化できるが，ステートメントと証明書の対応を維持しなければならない．

この定義は，証拠と報告判断の形式を定めるものであり，候補ステートメントの生成方法までは限定しない．候補は，公開スキーマ，言語モデル，探索アルゴリズムなどから生成できる．ただし，候補生成がプライベートコーパス R に依存する場合には，その処理によるプライバシー損失も会計する必要がある．

3.3　評価基準

固定されたステートメント s に対し，証拠能力を以下の基準で評価する．

© 2026 Information Processing Society of Japan

サポート帰属．二つの閾値 $\theta_0 < \theta_1$ に対し，

$$H_0 : f_s(R) \le \theta_0, \qquad H_1 : f_s(R) \ge \theta_1$$

を，報告の出力からどの程度正確に識別できるかを考える．自由文形式では判定規則 $\varphi : \mathcal{Y} \to [0,1]$ を用い，証拠付き形式では c_j を直接利用できる．

サポート推定．出力から $f_s(R)$ を推定する．自由文形式では推定量 $\widehat{f}_s : \mathcal{Y} \to [0,1]$ の誤差を評価する．証拠付き形式では，ノイズ付き支持値や信頼下界を明示的に公開できる．

証明書の妥当性．証拠 c から得られる支持度の下界を $L(s,c)$ とする．失敗確率 β で妥当であるとは，任意の R について，

$$\Pr[L(s,c) > f_s(R)] \le \beta$$

が成り立つことをいう．

片側誠実性．閾値 θ において，支持されていない候補を誤って報告する確率を制御する．固定された候補 s について，

$$f_s(R) < \theta \quad \Longrightarrow \quad \Pr[\mathrm{Emit}_s] \le \beta \qquad (2)$$

が成り立つとき，機構は候補ごとに片側誠実であるという．これは偽陽性を制御するが，支持されたすべての候補の出力は保証しない．

報告率．m 個の候補に対し，報告率を以下のように表す．

$$\mathrm{EmitRate} = \mathbb{E}\left[\frac{1}{m}\sum_{j=1}^{m} \mathbf{1}[a_j = \mathrm{emit}]\right]$$

報告率は有用性を表すが，支持されていない主張を出力して高めるべきものではない．証拠付きレポーティングでは，片側誠実性と報告率のトレードオフを扱う．

4. 自由文形式の DP レポートの局所的限界

本節では，単一の DP 出力から，固定されたステートメント s のサポートを事後的に読み取る問題を考える．分析者は，自然言語パーサ，分類器，言語モデルなど，出力に対する任意の後処理を利用できるものとする．以下の下界は特定の生成モデルではなく，DP が要求する近接コーパス間の識別不可能性から導かれる．

これらの結果は，DP のもとで証拠を公開できないことを意味しない．自由文形式と証拠付き形式はいずれも同じプライバシー制約を受けるが，後者は公開する統計量の意味，失敗確率，出力保留の規則を明示する点で異なる．

4.1 サポート帰属の下界

ステートメント s と $\theta_0 < \theta_1$ を固定し，単一の出力 $Y \sim \mathcal{A}(q,R)$ から，

$$H_0 : f_s(R) \le \theta_0, \qquad H_1 : f_s(R) \ge \theta_1$$

を識別する問題を考える．

Theorem 1 (差分プライバシー下の検定の下界)**．**$\mathcal{A}$ を任意の ε-差分プライバシー機構とする．q を固定し，$d(R_0,R_1) \le k$ とする．$P_i := \mathcal{L}(\mathcal{A}(q,R_i))$ とおくと，

$$d_{\mathrm{TV}}(P_0,P_1) \le \frac{e^{k\varepsilon}-1}{e^{k\varepsilon}+1}.$$

従って，任意のランダム化検定 $\varphi : \mathcal{Y} \to [0,1]$ について，

$$\mathbb{E}_{P_0}[\varphi(Y)] + \mathbb{E}_{P_1}[1-\varphi(Y)] \ge \frac{2}{e^{k\varepsilon}+1}.$$

証明の概略． グループプライバシーにより，P_0 と P_1 の尤度比は双方の向きに $e^{k\varepsilon}$ で抑えられる．これから全変動距離の上界を得て，二値検定における二種類の誤りの和が $1 - d_{\mathrm{TV}}(P_0,P_1)$ 以上であることを用いる [7]．完全な証明は付録に示す． □

特に，$f_s(R_0) \le \theta_0$, かつ $f_s(R_1) \ge \theta_1$ であれば，同じ下界が，単一の DP レポートに基づく任意のサポート帰属規則（データセットが s を所定の水準以上で支持しているかを判定する任意の方法）に適用される．従って，文章中に s が現れたこと自体は，R が s を所定の水準以上で支持することの証明にはならない．

この下界は $k\varepsilon$ が小さい局所領域で意味を持つ．式 (1) の経験頻度サポートでは，

$$|f_s(R_1) - f_s(R_0)| \le \frac{k}{n}$$

であるため，サポート差 Δ には通常 $k \ge n\Delta$ の変更が必要となる．従って，大きなサポート差が常に隠蔽されるという主張ではなく，近接するコーパス間の局所的な識別限界である [13, 2].

4.2 サポート推定の下界

次に，単一の DP 出力から $f_s(R)$ 自体の推定を考える．

Theorem 2 (サポート推定の下界)**．**$\mathcal{A}$ を任意の ε-差分プライバシー機構とする．q，s，および $d(R_0,R_1) \le k$ を満たす R_0, R_1 を固定し，

$$P_i := \mathcal{L}(\mathcal{A}(q,R_i)), \qquad a_i := f_s(R_i), \qquad \Delta := |a_1 - a_0|$$

とおく．任意の推定量 $\widehat{f}_s : \mathcal{Y} \to [0,1]$ について，

$$\max_{i\in\{0,1\}} \mathbb{E}_{Y\sim P_i}\left[\left|\widehat{f}_s(Y) - a_i\right|\right] \ge \frac{\Delta}{4}\left(1 - d_{\mathrm{TV}}(P_0,P_1)\right) \ge \frac{\Delta}{2(e^{k\varepsilon}+1)}.$$

証明の概略． $\widehat{f}_s(Y)$ を $(a_0+a_1)/2$ で閾値処理すると，P_0 と P_1 を識別する検定が得られる．標準的な二点法と定理 1 を組み合わせる．完全な証明は付録に示す． □

定理 2 は，サポート値の異なる近接コーパスについて，単一の DP 出力から双方の値を同時に高精度で推定できないことを示す．自由文形式のレポートに s が含まれていて

© 2026 Information Processing Society of Japan

も，それが少数の記録に依存する逸話なのか，コーパス全体に広く見られる傾向なのかを，文章だけから較正された形で判断できるとは限らない．

4.3 証拠付きレポーティングへの含意

以上から，DP 保証とステートメントのサポート保証は区別される．DP はレコード変更に対する出力分布の安定性を保証するが，文章中の各主張が十分に支持されていることは保証しない．また，高性能な言語モデルで出力を生成・解析しても，利用できる情報は DP 出力に含まれるものに限られる．

一方，明示的な証明書もこれらの統計的限界を回避するものではない．証拠付きレポーティングの役割は，不確実性を除去することではなく，公開するサポート統計の意味と失敗確率を明示し，証拠が不足する場合には出力を保留することである．次節では，候補生成と DP サポート検証を分離する参照構成を示す．

5. 証拠付きレポーティングの参照構成

証拠付きレポーティングの一構成として，ステートメントの**提案**とプライベートコーパスによる**検証**を分離する Proposal-Filter Reporting を示す．Proposer は検証対象となる候補を生成し，DP サポート検定は十分な支持を持つ候補のみを証明書とともに報告する．従って，信頼の根拠は候補を生成した言語モデルではなく，明示的なサポート検証に置かれる．本構成は新たな DP プリミティブの提案ではなく，第 3 節の報告インターフェースを具体化する参照例である．

5.1 Proposal-Filter Reporting

報告タスク q に対し，プライベートコーパス R から独立な提案分布 Π_q から，$s_1, \ldots, s_m \overset{\text{i.i.d.}}{\sim} \Pi_q$ を生成する．各候補 s_j について，

$$\widehat{f}_{s_j}(R) = f_{s_j}(R) + Z_j, \qquad L_{s_j} = \widehat{f}_{s_j}(R) - \tau$$

を計算する．Z_j は感度とプライバシー予算に合わせて較正されたノイズであり，τ はその上側裾確率から定める．機構は，

$$L_{s_j} \geq \theta$$

の場合にのみ s_j を証明書 L_{s_j} とともに報告し，それ以外は出力を保留する．

報告されたステートメントは DP の後処理として自然言語化できるが，各主張と証明書の対応を維持する必要がある．

5.2 Proposer の設計

フィルタは支持されていない候補の報告を制御する一方，

Algorithm 1 Proposal-Filter Reporting

```
入力：q, R, Π_q, m, θ, τ, ε_1, ..., ε_m
s_1, ..., s_m ~(i.i.d.) Π_q
for j = 1, ..., m do
    f̂_{s_j}(R) = f_{s_j}(R) + Z_j を ε_j-DP で計算
    L_{s_j} = f̂_{s_j}(R) − τ
    if L_{s_j} ≥ θ then
        (s_j, L_{s_j}, emit) を出力
    else
        (s_j, ⊥, abstain) を出力
    end if
end for
```

どの主張が検証されるかは Proposer が決定する．従って，証拠の誠実性は主としてフィルタに，報告のカバレッジは Proposer に依存する．

本稿では三つの設計原則を用いる．第一に**データ非依存性**であり，候補生成に追加のプライバシー予算を要しない．データ依存の候補生成も可能だが，その場合は生成過程をプライバシー会計に含める．第二に**マッチャー整合**であり，候補をサポート関数 σ_s が安定して評価できる表現にする．第三に**閾値カバレッジ**であり，Π_q が高サポートの候補に十分な確率質量を持つよう設計する．候補が粗すぎれば情報量が低下し，細かすぎれば支持が分散して閾値を超えにくくなる．

実験では，公開スキーマからトピック，観点，感情などを選び，固定テンプレートに代入するタグテンプレート Proposer を用いる．たとえば，「`{topic}`に関するレビューは，`{sentiment}`な文脈で`{aspect}`に言及する．」という候補を生成する．スキーマとテンプレートは R を観測する前に固定されるためデータ非依存であり，表現を制御することでマッチャーとの整合性を高められる．

5.3 保証

Proposition 1 (プライバシー)**.** Π_q が R から独立であり，各 $\widehat{f}_{s_j}(R)$ が ε_j*-DP* であるならば，アルゴリズム *1* は $\left(\sum_{j=1}^{m} \varepsilon_j\right)$*-DP* を満たす．

候補生成はデータ非依存であり，信頼下界，報告判断，文章化は後処理であるため，逐次合成から従う．証明は付録に示す．

Proposition 2 (サポート証明書の妥当性)**.** 固定された s について，

$$\widehat{f}_s(R) = f_s(R) + Z, \qquad \Pr[Z > \tau] \leq \beta$$

とする．$L_s = \widehat{f}_s(R) - \tau$ とおけば，

$$\Pr[L_s > f_s(R)] \leq \beta$$

が成り立つ．

従って，L_s は失敗確率 β のもとで $f_s(R)$ の下界として解釈できる．

© 2026 Information Processing Society of Japan

Theorem 3 (候補ごとの片側誠実性)．固定された候補 s について，

$$\widehat{f}_s(R) = f_s(R) + Z, \qquad \Pr[Z \geq \tau] \leq \beta$$

とする．$\widehat{f}_s(R) - \tau \geq \theta$ の場合にのみ s を報告すれば，

$$f_s(R) < \theta \quad \Longrightarrow \quad \Pr[\mathrm{Emit}_s] \leq \beta$$

が成り立つ．

実際，支持されていない s の報告には $Z > \tau$ が必要となる．この保証は候補ごとの偽陽性を制御するが，再現率は保証しない．m 候補全体に対しては Union Bound により，支持されていない候補が一つ以上報告される確率は高々 $m\beta$ である．証明は付録に示す．

5.4 報告率とプライバシー予算

候補分布におけるサポートの裾確率を，以下で表す．

$$p_a(R) := \Pr_{s \sim \Pi_q}[f_s(R) \geq a]$$

Theorem 4 (報告率のトレードオフ)．$s_1, \ldots, s_m \overset{\text{i.i.d.}}{\sim} \Pi_q$ とし，各 j について，

$$\widehat{f}_{s_j}(R) = f_{s_j}(R) + Z_j, \quad \Pr[Z_j \geq \tau] \leq \beta, \quad \Pr[Z_j \leq -\tau] \leq \beta$$

を仮定する．このとき，

$$(1-\beta)p_{\theta+2\tau}(R) \leq \mathrm{EmitRate} \leq p_\theta(R) + \beta\big(1 - p_\theta(R)\big) \leq p_\theta(R) + \beta.$$

サポートが θ 未満の候補は高々確率 β で報告され，$\theta + 2\tau$ 以上の候補は少なくとも確率 $1-\beta$ で報告されることから従う．完全な証明は付録に示す．フィルタは誤報告を制御する一方，報告量は Π_q が高サポート領域に持つ確率質量に依存する．特に，

$$f_s(R) \in [\theta, \theta + 2\tau)$$

の候補は支持されていても出力を保留され得る．

固定された総予算 $\varepsilon_{\mathrm{tot}}$ を m 候補に均等配分し，感度 Δ_f の Laplace 機構を用いる場合，

$$\varepsilon_0 = \frac{\varepsilon_{\mathrm{tot}}}{m}, \quad Z_j \sim \mathrm{Lap}\left(\frac{m\Delta_f}{\varepsilon_{\mathrm{tot}}}\right), \quad \tau = \frac{m\Delta_f}{\varepsilon_{\mathrm{tot}}} \log \frac{1}{\beta}$$

となる．従って，候補数を増やすと探索範囲は広がるが，候補ごとのノイズと必要なマージンも増大する．報告率は m に対して単調に増加するとは限らない．

レポート全体の失敗確率を β_{tot} に抑える場合には，候補ごとに $\beta = \beta_{\mathrm{tot}}/m$ を割り当てることで，

$$\tau = O\left(\frac{m\Delta_f}{\varepsilon_{\mathrm{tot}}} \log \frac{m}{\beta_{\mathrm{tot}}}\right)$$

となる．本稿の実験では主として候補ごとの片側誠実性を評価する．

6. 評価

自由文形式の DP レポートと証拠付きレポーティングの違いを実験的に検証する．具体的には，(i) 自由文形式の出力が支持されていない主張を含むか，(ii) 明示的な DP サポート検定が誤報告を制御するか，(iii) Proposer とプライバシー予算が報告率に与える影響，および (iv) DP ヒストグラムや Private Evolution 型構成との関係を評価する．

6.1 評価指標と人工データ

m 個の候補に対し，候補ごとの誤報告率と報告率を，

$$\mathrm{UnsupportedEmit} = \frac{\sum_j \mathbf{1}[a_j = \mathrm{emit} \wedge f_{s_j}(R) < \theta]}{\sum_j \mathbf{1}[f_{s_j}(R) < \theta]},$$

$$\mathrm{EmitRate} = \frac{1}{m} \sum_j \mathbf{1}[a_j = \mathrm{emit}]$$

とする．前者は定理 3 に対応する．また，報告された主張のうち支持されていない割合を FalseEmission，報告された主張の平均支持度を MeanSupport とする．FalseEmission は逆向きの条件付き確率であり，報告数が少ない場合には不安定となる．自由文形式では，固定された Claim Parser で原子的な主張を抽出し，同じ $f_s(R)$ で FalseEmission と MeanSupport を評価する．

人工データでは，オラクルサポートを持つ有限のステートメント空間から候補を一様に生成する．5 シードを用い，$\varepsilon_{\mathrm{tot}} \in \{1, 4, 10, 20\}$，$\theta \in \{0.05, 0.1, 0.2\}$，$m \in \{50, 200, 1000\}$，$\beta \in \{0.01, 0.05, 0.1\}$ の設定で評価した．UnsupportedEmit の最大値は 0.038，平均値は 0.002 であり，すべて $\beta \cdot 1.2$ 未満であった．EmitRate も標本変動の範囲で定理 4 の区間内にあり，一部では候補数 m に対する非単調性が確認された．これは，候補数の増加が探索を広げる一方，候補ごとの DP ノイズを増加させるためである．

6.2 実データにおける比較

TAB（法務） [10]，WildChat（対話） [17]，Yelp（レビュー） [16] を用いる．サポート関数は NLI クロスエンコーダ `cross-encoder/nli-deberta-v3-base` [6] で実装し，レコードを前提，ステートメントを仮説として，含意が最大確率のラベルである場合に $\sigma_s(r) = 1$ とする．モデルと判定規則は事前に固定するため，$\Delta_f \leq 1/|R|$ である．

ベースライン．自由文形式の比較対象として，データを参照しない Unfiltered LLM，文書単位の DP 統計を文章化する free-text DP，およびトークン単位 DP 復号の InvisibleInk [12] を用いる．すべて方式で $(\varepsilon_{\mathrm{tot}}, \delta) = (10, 10^{-5})$ を保証する．Proposal-Filter では $m = 200$，5 シードを用いる．

自由文形式の DP 方式では FalseEmission が高く，InvisibleInk では 0.619 から 0.994 となった．これは文章

© 2026 Information Processing Society of Japan

表 2　自由文形式の DP レポートと証拠付きレポーティングの比較．自由文形式には EmitRate と UnsupportedEmit を定義しない．

データセット	手法	#out	EmitRate ↑	UnsupEmit ↓	FalseEmit ↓	MeanSupport ↑
TAB	Unfiltered LLM	600	–	–	1.000	0.000
	free-text DP (document)	66	–	–	0.894	0.022
	InvisibleInk (TinyLlama)	143	–	–	0.958	0.008
	InvisibleInk (Qwen-2.5 3B)	154	–	–	0.994	0.001
	Proposal-Filter (tag-template)	**404**	**0.404**	**0.008**	**0.010**	**0.545**
WildChat	Unfiltered LLM	600	–	–	0.947	0.014
	free-text DP (document)	70	–	–	0.729	0.051
	InvisibleInk (TinyLlama)	119	–	–	0.647	0.058
	InvisibleInk (Qwen-2.5 3B)	84	–	–	0.619	0.062
	Proposal-Filter (tag-template)	**220**	**0.220**	**0.004**	**0.014**	**0.288**
Yelp	Unfiltered LLM	600	–	–	0.943	0.010
	free-text DP (document)	71	–	–	0.803	0.029
	InvisibleInk (TinyLlama)	138	–	–	0.877	0.019
	InvisibleInk (Qwen-2.5 3B)	201	–	–	0.856	0.020
	Proposal-Filter (tag-template)	**749**	**0.749**	**0.000**	**0.000**	**0.239**

に現れた主張が，元のデータに十分支持されているとは限らないことを示している．

一方，タグテンプレートを用いる Proposal-Filter では，UnsupportedEmit は 3 データセットで $[0.000, 0.008]$ となり，すべて $\beta = 0.05$ を下回った．EmitRate も，$0.404 \in [0.356, 0.557]$ (TAB), $0.220 \in [0.162, 0.350]$ (WildChat), $0.749 \in [0.620, 0.849]$ (Yelp) と，定理 4 の予測区間を満たした．公開 LLM Proposer を含む 6 集約セルおよび 30 個のシード別セルもすべて区間内であった．

6.3　Proposer とプライバシー予算

公開のタスク記述だけから候補を生成する公開 LLM Proposer にも，同じ DP フィルタを適用した．UnsupportedEmit は $[0.001, 0.003]$ であり，Proposer を変更しても片側誠実性は維持された．一方，EmitRate は TAB，WildChat，Yelp でそれぞれ 0.003，0.024，0.018 にとどまった．タグテンプレートは公開 LLM より約 135 倍，9 倍，41 倍多く報告しており，流暢さだけでなく，サポートモデルとの整合がカバレッジを左右することを示す．

WildChat で $\varepsilon_{\text{tot}} \in \{1, 4, 10, 20\}$ を走査すると，EmitRate は 0.051 から 0.274 へ増加した．一方，UnsupportedEmit はすべて $\beta = 0.05$ 未満であり，全設定が理論区間を満たした．詳細な設定と結果は付録に示す．

6.4　既存 DP 手法の証拠付きレポーティングへの拡張

Proposal-Filter 以外の既存 DP 手法も，ステートメント，支持情報，出力判断を持つ証拠付きレポーティング方式へ拡張して比較する．各方式について，支持度の下界を計算し，閾値に基づいて報告または保留を判断する．実装の詳細は付録に示す．

固定候補に対しては，DP ヒストグラム [4] を拡張した one-hot および top-c ヒストグラムを評価した．one-hot では各レコードの寄与を一つの候補に，top-c では上位 c 候補に制限する．感度はそれぞれ $2/|R|$ および $\Delta_1 \le \frac{\min(m,2c)}{|R|}$ である．各ビンの DP 支持値から下界を計算し，閾値を超えた候補のみを報告する．ただし，証明書は寄与制限後の支持度に対するものであり，複数候補へのサポートの一部が失われる．

one-hot の EmitRate は 3 データセットで 0.020–0.024 であった．top-16 では TAB，Yelp，WildChat で 0.199，0.390，0.183 まで改善したが，Proposal-Filter の 0.404，0.748，0.216 を下回った．すべての方式で UnsupportedEmit は $\beta = 0.05$ 以下であり，感度の低減とサポートの保持との間にトレードオフが確認された．

また，Private Evolution による DP 合成テキスト生成手法 Aug-PE [14] を，候補と支持情報を得る方式へ拡張して評価に用いた．この方式の証拠は合成データ上の支持を表し，元のプライベートコーパス上でも同じ支持が成り立つことは保証しない．Yelp では，$\theta = 0.10$ における EmitRate は 0.676 となり，Proposal-Filter の 0.695 に近かったが，元コーパス上で再評価した UnsupportedEmit は 0.092 であり，Proposal-Filter の 0.001 を上回った．反復数が異なるため直接的な性能比較ではないが，合成データによる候補発見と，元データによる支持の確認を分離する必要性を示している．

以上より，証拠付きレポーティングは複数の DP 手法によって構成できるが，方式ごとに証拠が何に対する支持を表すかを明確にする必要がある．

© 2026 Information Processing Society of Japan

7. おわりに

本稿では，Confidential AI における Observability Blackout を，証拠付きレポーティングの問題として整理した．自由文形式の DP レポートは概要把握には有用である一方，各主張が元のデータに支持されていることを保証しない．そこで，ステートメントと DP による支持情報を対応付け，証拠が不十分な場合には出力を保留する報告形式を定式化した．さらに，Proposal-Filter Reporting を参照構成として示し，実データを用いた評価により，支持されていない主張の出力を抑制できることを確認した．本稿の保証はあらかじめ定義されたサポート関数 f_s に相対的であり，主張自体の真偽や報告の網羅性を保証するものではないが，他の DP 集計や候補生成方式にも適用可能な報告形式を与えるものである．

参考文献

[1] Apple Security Research. Private cloud compute security guide. `https://security.apple.com/documentation/private-cloud-compute/`, 2024. Accessed 2026.

[2] J. C. Duchi, M. I. Jordan, and M. J. Wainwright. Local privacy and statistical minimax rates. In *Proceedings of the 54th Annual IEEE Symposium on Foundations of Computer Science (FOCS)*, pages 429–438. IEEE Computer Society, 2013.

[3] C. Dwork, F. McSherry, K. Nissim, and A. Smith. Calibrating noise to sensitivity in private data analysis. In *Proceedings of the Third Theory of Cryptography Conference (TCC)*, volume 3876 of *Lecture Notes in Computer Science*, pages 265–284. Springer, 2006.

[4] C. Dwork and A. Roth. *The Algorithmic Foundations of Differential Privacy*, volume 9 of *Foundations and Trends in Theoretical Computer Science*. Now Publishers, 2014.

[5] Google. Private ai compute in the cloud. `https://services.google.com/fh/files/misc/private_ai_compute_technical_brief.pdf`, 2025. Accessed 2026.

[6] P. He, X. Liu, J. Gao, and W. Chen. Deberta: Decoding-enhanced bert with disentangled attention. In *International Conference on Learning Representations*, 2021.

[7] P. Kairouz, S. Oh, and P. Viswanath. The composition theorem for differential privacy. In *Proceedings of the 32nd International Conference on Machine Learning (ICML)*, volume 37 of *Proceedings of Machine Learning Research*, pages 1376–1385. PMLR, 2015.

[8] D. Liu, E. Cohen, B. Ghazi, P. Kairouz, P. Kamath, A. Knop, R. Kumar, P. Manurangsi, A. Sealfon, D. Yu, and C. Zhang. Urania: Differentially private insights into AI use. In *Conference on Language Modeling (COLM)*, 2025.

[9] M. Lyu, D. Su, and N. Li. Understanding the sparse vector technique for differential privacy. *Proceedings of the VLDB Endowment*, 10(6):637–648, 2017.

[10] I. Pilán, P. Lison, L. Øvrelid, A. Papadopoulou, D. Sánchez, and M. Batet. The text anonymization benchmark (TAB): A dedicated corpus and evaluation framework for text anonymization. *Computational Linguistics*, 48(4):1053–1101, 2022.

[11] A. Tamkin, M. McCain, K. Handa, E. Durmus, L. Lovitt, A. Rathi, S. Huang, A. Mountfield, J. Hong, S. Ritchie, M. Stern, B. Clarke, L. Goldberg, T. R. Sumers, J. Mueller, W. McEachen, W. Mitchell, S. Carter, J. Clark, J. Kaplan, and D. Ganguli. Clio: Privacy-preserving insights into real-world AI use. Technical report, Anthropic, 2024. `https://arxiv.org/abs/2412.13678`.

[12] V. Vinod, K. Pillutla, and A. G. Thakurta. InvisibleInk: High-utility and low-cost text generation with differential privacy. In *Advances in Neural Information Processing Systems*, 2025.

[13] L. Wasserman and S. Zhou. A statistical framework for differential privacy. *Journal of the American Statistical Association*, 105(489):375–389, 2010.

[14] C. Xie, Z. Lin, A. Backurs, S. Gopi, D. Yu, H. A. Inan, H. Nori, H. Jiang, H. Zhang, Y. T. Lee, B. Li, and S. Yekhanin. Differentially private synthetic data via foundation model APIs 2: Text. In *International Conference on Machine Learning (ICML)*, 2024.

[15] X. Yue, H. A. Inan, X. Li, G. Kumar, J. McAnallen, H. Shajari, H. Sun, D. Levitan, and R. Sim. Synthetic text generation with differential privacy: A simple and practical recipe. *arXiv preprint arXiv:2210.14348*, 2022.

[16] X. Zhang, J. Zhao, and Y. LeCun. Character-level convolutional networks for text classification. In *Advances in Neural Information Processing Systems (NIPS)*, 2015. The Yelp Reviews Full dataset, derived from the Yelp Dataset Challenge 2015, was first introduced as a text classification benchmark in this paper. `https://arxiv.org/abs/1509.01626`.

[17] W. Zhao, X. Ren, J. Hessel, C. Cardie, Y. Choi, and Y. Deng. WildChat: 1M ChatGPT interaction logs in the wild. In *International Conference on Learning Representations (ICLR)*, 2024. `https://openreview.net/forum?id=Bl8u7ZRlbM`.

© 2026 Information Processing Society of Japan

付　　録

A.1　定理の証明

A.1.1　定理 1 の証明

$P_i = \mathcal{L}(\mathcal{A}(q, R_i))$ とし，$t = e^{k\varepsilon}$ とおく．グループプライバシーより，任意の事象 E について，

$$P_0(E) \le tP_1(E), \qquad P_1(E) \le tP_0(E)$$

が成り立つ．

任意の事象 B について，必要なら P_0 と P_1 を入れ替え，

$$p = P_0(B) \ge q = P_1(B), \qquad \Delta = p - q$$

とする．第一の不等式から，

$$p \le tq \quad \Longrightarrow \quad \Delta \le (t-1)q$$

を得る．また，補集合に第二の不等式を適用すると，

$$1 - q \le t(1-p) = t(1-q-\Delta)$$

であるため，

$$\Delta \le \frac{t-1}{t}(1-q)$$

となる．従って，

$$\Delta \le \min\left\{(t-1)q, \frac{t-1}{t}(1-q)\right\}.$$

右辺は $q = 1/(t+1)$ で最大となるため，

$$d_{\mathrm{TV}}(P_0, P_1) \le \frac{t-1}{t+1} = \frac{e^{k\varepsilon}-1}{e^{k\varepsilon}+1}.$$

二値検定の第一種過誤と第二種過誤の和は，$1 - d_{\mathrm{TV}}(P_0, P_1)$ 以上である．よって，任意の検定 φ について，

$$\begin{aligned}&\mathbb{E}_{P_0}[\varphi(Y)] + \mathbb{E}_{P_1}[1-\varphi(Y)] \\ &\quad \ge 1 - d_{\mathrm{TV}}(P_0, P_1) \ge \frac{2}{e^{k\varepsilon}+1}.\end{aligned}$$

A.1.2　定理 2 の証明

一般性を失わず，

$$a_0 < a_1, \qquad \Delta = a_1 - a_0$$

とする．任意の推定量 $\widehat{f}_s(Y)$ から，

$$\varphi(Y) = \mathbf{1}\left[\widehat{f}_s(Y) \ge \frac{a_0 + a_1}{2}\right]$$

を定義する．

P_0 のもとで $\varphi(Y) = 1$ ならば，

$$|\widehat{f}_s(Y) - a_0| \ge \frac{\Delta}{2}$$

である．同様に，P_1 のもとで $\varphi(Y) = 0$ ならば，

$$|\widehat{f}_s(Y) - a_1| \ge \frac{\Delta}{2}$$

である．従って，

$$\begin{aligned}&\mathbb{E}_{P_0}|\widehat{f}_s(Y) - a_0| + \mathbb{E}_{P_1}|\widehat{f}_s(Y) - a_1| \\ &\quad \ge \frac{\Delta}{2}\left(\mathbb{E}_{P_0}[\varphi(Y)] + \mathbb{E}_{P_1}[1-\varphi(Y)]\right) \\ &\quad \ge \frac{\Delta}{2}\left(1 - d_{\mathrm{TV}}(P_0, P_1)\right).\end{aligned}$$

二つの期待誤差の少なくとも一方は，その和の半分以上であるため，

$$\max_{i\in\{0,1\}} \mathbb{E}_{P_i}|\widehat{f}_s(Y) - a_i| \ge \frac{\Delta}{4}\left(1 - d_{\mathrm{TV}}(P_0, P_1)\right).$$

定理 1 の上界を代入すると，

$$\max_{i\in\{0,1\}} \mathbb{E}_{P_i}|\widehat{f}_s(Y) - a_i| \ge \frac{\Delta}{2(e^{k\varepsilon}+1)}$$

を得る．

A.1.3　Proposal-Filter Reporting の保証

命題 1． 候補生成は R から独立であるため，プライバシー損失を生じない．候補集合と生成乱数を固定すると，各サポート推定値は ε_j-DP である．従って，逐次合成により，すべての推定値の公開は $\left(\sum_j \varepsilon_j\right)$-DP を満たす．信頼下界，閾値判定，出力保留，文章化はいずれも後処理である．候補生成の乱数について平均しても保証は維持される．

命題 2． 証明書を $L_s = f_s(R) + Z - \tau$ とすると，

$$\begin{aligned}L_s > f_s(R) &\iff f_s(R) + Z - \tau > f_s(R) \\ &\iff Z > \tau.\end{aligned}$$

よって，

$$\Pr[L_s > f_s(R)] = \Pr[Z > \tau] \le \beta.$$

従って，確率少なくとも $1-\beta$ で，L_s は真のサポート $f_s(R)$ 以下である．

定理 3． 候補 s が報告されたならば，

$$f_s(R) + Z - \tau \ge \theta.$$

一方，$f_s(R) < \theta$ であれば，報告には

$$Z \ge \tau + \theta - f_s(R) > \tau$$

が必要である．従って，

$$\Pr[\mathrm{Emit}_s] \le \Pr[Z \ge \tau] \le \beta.$$

次に，支持されていない候補 s_j が報告される事象を B_j とする．Union Bound より，

© 2026 Information Processing Society of Japan

$$\Pr\left[\bigcup_{j=1}^{m} B_j\right] \le \sum_{j=1}^{m} \Pr[B_j] \le m\beta.$$

候補間の独立性は必要としない．全候補を通じた失敗確率を α 以下に抑えるには，

$$\beta = \frac{\alpha}{m}$$

とすればよい．Laplace ノイズのスケールを b とすると，

$$\tau = b \log \frac{m}{\alpha}$$

となる．

定理 4．候補 $s \sim \Pi_q$ の報告確率を考える．$f_s(R) < \theta$ の場合，定理 3 より報告確率は高々 β である．$f_s(R) \ge \theta$ の場合には上界 1 を用いる．よって，

$$\begin{aligned}\mathrm{EmitRate} &\le p_\theta(R) + \beta\big(1 - p_\theta(R)\big) \\ &\le p_\theta(R) + \beta.\end{aligned}$$

一方，

$$f_s(R) \ge \theta + 2\tau$$

であり，かつ $Z \ge -\tau$ ならば，

$$f_s(R) + Z - \tau \ge \theta$$

となる．仮定より $\Pr[Z \ge -\tau] \ge 1 - \beta$ であるため，

$$\mathrm{EmitRate} \ge (1-\beta) p_{\theta + 2\tau}(R).$$

A.2 実験設定の詳細

A.2.1 評価指標と自由文の解析

候補 s_j の報告判断を

$$E_j = \mathbf{1}[a_j = \mathrm{emit}]$$

とし，サポートが閾値未満であることを

$$U_j = \mathbf{1}[f_{s_j}(R) < \theta]$$

で表す．評価指標を次のように定義する．

$$\mathrm{EmitRate} = \frac{1}{m}\sum_{j=1}^{m} E_j,$$

$$\mathrm{UnsupportedEmit} = \frac{\sum_j E_j U_j}{\sum_j U_j},$$

$$\mathrm{FalseEmission} = \frac{\sum_j E_j U_j}{\sum_j E_j},$$

$$\mathrm{MeanSupport} = \frac{\sum_j E_j f_{s_j}(R)}{\sum_j E_j}.$$

UnsupportedEmit は，支持されていない候補のうち誤って報告された割合であり，定理 3 が制御する量に対応する．FalseEmission は，報告された候補のうち支持されていなかった割合である．後者は報告数が少ない場合に不安定になり得る．分母が 0 の場合，各比率は未定義とする．

自由文形式の方式では，固定した Claim Parser を用いて出力を原子的な主張へ分解する．非断定的な断片や，サポート関数で評価できない断片を除外し，残った主張を Proposal-Filter と同じ $f_s(R)$ で評価する．この処理は公開済みの DP 出力に対する後処理であり，追加のプライバシー損失を生じない．

A.2.2 人工データ

人工データ実験では，Proposer や NLI 分類器の影響を除き，DP フィルタ自体を評価する．有限のステートメント集合を用意し，各候補に構成上既知のサポート値を与える．サポート値は，低サポートの逸話的ステートメントと，高サポートの集約的ステートメントからなる二成分混合分布から生成する．候補は一様に選択する．

評価する設定は，

$$\varepsilon_{\mathrm{tot}} \in \{1, 4, 10, 20\}, \qquad \theta \in \{0.05, 0.1, 0.2\},$$

$$m \in \{50, 200, 1000\}, \qquad \beta \in \{0.01, 0.05, 0.1\}$$

である．全 108 設定をそれぞれ 5 シードで評価した．

すべての設定で UnsupportedEmit は $\beta \cdot 1.2$ 未満であり，最大値は 0.038，平均値は 0.002 であった．

A.2.3 プライバシー会計

Proposal-Filter における候補 s のサポートは，

$$f_s(R) = \frac{1}{|R|}\sum_{r \in R} \sigma_s(r)$$

であり，置換隣接性のもとで感度は

$$\Delta_f \le \frac{1}{|R|}$$

である．

m 候補を基本合成によって検定するため，候補ごとの予算を

$$\varepsilon_0 = \frac{\varepsilon_{\mathrm{tot}}}{m}$$

とする．各候補には，

$$Z_j \sim \mathrm{Lap}\left(\frac{\Delta_f}{\varepsilon_0}\right) = \mathrm{Lap}\left(\frac{m\Delta_f}{\varepsilon_{\mathrm{tot}}}\right)$$

を加える．ノイズのスケール

$$b = \frac{m\Delta_f}{\varepsilon_{\mathrm{tot}}}$$

に対し，

$$\tau = b \log \frac{1}{\beta}$$

とすることで，上側および下側の裾確率を保守的に β 以下

© 2026 Information Processing Society of Japan

へ抑える．

Document-level free-text DP では，固定された d_{doc} 個の集計量に予算を均等配分し，ノイズ付き集計値を公開 LLM で文章化する．文章化は後処理である．

InvisibleInk [12] では，公開された zCDP 会計を用いる．ρ-zCDP から，

$$\varepsilon = \rho + 2\sqrt{\rho \log(1/\delta)}$$

により (ε, δ)-DP へ換算し，目標の $(\varepsilon_{\mathrm{tot}}, \delta)$ へ予算を合わせた．

表 A·1 実データ実験のプライバシー会計．

方式	DP 形式	合成単位	最終保証
Proposal-Filter	pure DP	m support queries	$\varepsilon_{\mathrm{tot}}$-DP
free-text DP	pure DP	d_{doc} aggregates	$\varepsilon_{\mathrm{tot}}$-DP
InvisibleInk	zCDP	decoding steps	$(\varepsilon_{\mathrm{tot}}, \delta)$-DP

A.2.4 サポートモデルと Proposer

実データ実験では，固定された NLI 分類器を用いて $\sigma_s(r)$ を定義する [6]．従って，理論保証は人間による一般的な真実性ではなく，分類器が定義する f_s に対して成立する．実運用では，公開データによる較正，複数モデルを用いた頑健性評価，または分類器誤差を考慮したマージンが必要となる．

タグテンプレート Proposer は，公開スキーマの値を固定テンプレートへ代入する．公開 LLM Proposer にはプライベートデータを与えず，ドメインと報告タスクの説明だけから候補を生成させる．代表的な指示は次のとおりである．

> プライベートなデータセットについて，集約的なレポートに現れ得る候補ステートメントを生成せよ．個別レコードではなく，データセット全体の傾向を一文で記述せよ．

いずれの Proposer も R から独立している．ただし，生成された候補は，DP サポート検定を通過するまで支持された主張とはみなさない．

A.3 既存 DP 手法の証拠付きレポーティングへの拡張

比較対象は既存手法をそのまま用いたものではなく，第 3 節の証拠付きレポーティング形式へ拡張したものである．各方式は，候補ステートメント s_j，支持情報 c_j，および

$$a_j \in \{\mathrm{emit}, \mathrm{abstain}\}$$

を対応付けて出力する．

A.3.1 DP ヒストグラムによる構成

候補集合を

$$S = \{s_1, \ldots, s_m\}$$

とする．DP ヒストグラム [4] を用い，各レコード r が寄与する候補を，整合度が高い上位 c 個へ制限する．その添字集合を $T_c(r)$ とし，

$$g_j^{(c)}(R) = \frac{1}{|R|} \sum_{r \in R} \sigma_{s_j}(r) \mathbf{1}[j \in T_c(r)]$$

と定義する．$c = 1$ が one-hot 方式，一般の c が top-c 方式である．

各レコードは最大 c 候補にのみ寄与するため，

$$g^{(c)}(R) = \left(g_1^{(c)}(R), \ldots, g_m^{(c)}(R)\right)$$

の ℓ_1 感度は，

$$\Delta_c \le \frac{\min(m, 2c)}{|R|}$$

である．各ビンに，

$$\widetilde{g}_j^{(c)} = g_j^{(c)}(R) + Z_j, \qquad Z_j \overset{\text{i.i.d.}}{\sim} \mathrm{Lap}\left(\frac{\Delta_c}{\varepsilon_{\mathrm{tot}}}\right)$$

を加えることで，ヒストグラム全体は $\varepsilon_{\mathrm{tot}}$-DP を満たす．

ノイズのスケールを

$$b_c = \frac{\Delta_c}{\varepsilon_{\mathrm{tot}}}$$

とし，

$$L_j^{(c)} = \widetilde{g}_j^{(c)} - b_c \log \frac{1}{\beta}$$

を証明書とする．$L_j^{(c)} \ge \theta$ なら s_j を報告し，それ以外では出力を保留する．

寄与制限は元のサポート項の一部を除くだけなので，

$$g_j^{(c)}(R) \le f_{s_j}(R)$$

が成り立つ．さらに，高確率で $L_j^{(c)} \le g_j^{(c)}(R)$ であるため，$L_j^{(c)}$ は元のサポートに対しても保守的な下界となる．一方，一件のレコードが多数の候補を支持する場合には，寄与制限によってカバレッジが低下する．

A.3.2 Private Evolution 型の構成

Private Evolution による合成テキスト生成手法 Aug-PE [14] を，支持情報を伴うレポーティングへ拡張する．まず，プライベートコーパスから DP 合成データ

$$\widetilde{R} \sim \mathrm{PE}(R)$$

を生成する．次に，$\widetilde{R}$ から候補 s を抽出し，

$$\widetilde{f}_s(\widetilde{R}) = \frac{1}{|\widetilde{R}|} \sum_{\widetilde{r} \in \widetilde{R}} \sigma_s(\widetilde{r})$$

を計算する．

© 2026 Information Processing Society of Japan

$\widetilde{f}_s(\widetilde{R}) \geq \theta$ の場合に，s を支持情報 $\widetilde{f}_s(\widetilde{R})$ とともに報告する．候補抽出，支持計算，閾値判定は DP 合成データの後処理であり，追加のプライバシー損失を生じない．

ただし，$\widetilde{f}_s(\widetilde{R})$ は合成データ上の支持であり，元のコーパス上の $f_s(R)$ に対する下界ではない．実験では，報告されたステートメントを元の $f_s(R)$ で再評価し，Original-data UnsupportedEmit を診断指標として用いる．この再評価値は公開出力には含まれない．

A.4 詳細な評価実験

本節では，Proposer，プライバシー予算，理論区間，代替構成，サポートモデルについて追加評価する．誤報告の制御とカバレッジを分けて分析する．

A.4.1 Proposer の比較

同じ DP フィルタを用い，タグテンプレート Proposer と公開 LLM Proposer を比較する．両方式とも R へアクセスせず，候補数，予算，閾値，サポートモデル，DP ノイズを共通とする．異なるのは候補分布 Π_q のみである．

タグテンプレートは，公開スキーマを固定テンプレートへ代入する．公開 LLM は，ドメインとタスクの説明から自由な候補を生成する．後者は流暢で多様な一方，複合的な主張や，サポートモデルが判定しにくい表現を生成し得る．

表 A·2 同一の DP フィルタを用いた Proposer 比較.

データ	Proposer	#out	EmitRate	UnsupEmit	FalseEmit
TAB	public LLM	3	0.003	0.003	1.000
	tag-template	404	0.404	0.008	0.010
WildChat	public LLM	24	0.024	0.001	0.042
	tag-template	220	0.220	0.004	0.014
Yelp	public LLM	18	0.018	0.002	0.111
	tag-template	749	0.749	0.000	0.000

両 Proposer で UnsupportedEmit は $\beta = 0.05$ 未満であった．一方，タグテンプレートは公開 LLM に比べ，TAB，WildChat，Yelp で約 135 倍，9 倍，41 倍多く報告した．候補の流暢さだけでなく，表現や粒度がサポートモデルと整合することがカバレッジに重要である．

TAB の公開 LLM では，報告された 3 件がすべて $f_s(R) < \theta$ であり，FalseEmission は 1.000 となった．一方，支持されていない全候補を分母とする UnsupportedEmit は 0.003 であった．FalseEmission は報告数が少ない場合に大きく変動するが，UnsupportedEmit は定理 3 が直接制御する量である．

A.4.2 プライバシー予算の走査

WildChat のタグテンプレート Proposer について，プライバシー予算の影響を評価する．$\varepsilon_{\mathrm{tot}} \in \{1, 4, 10, 20\}$ を用いる．候補集合，閾値，候補数，β，サポートモデルは固定した．

候補ごとの予算は $\varepsilon_0 = \frac{\varepsilon_{\mathrm{tot}}}{m}$ である．従って，$\varepsilon_{\mathrm{tot}}$ が大きいほど，DP ノイズとマージン τ が小さくなり，閾値付近の候補も報告されやすくなる．

表 A·3 WildChat におけるプライバシー予算の走査.

$\varepsilon_{\mathrm{tot}}$	EmitRate	UnsupEmit	FalseEmit	MeanSupport	区間内
1	0.051	0.0217	0.295	0.275	✓
4	0.180	0.0085	0.033	0.327	✓
10	0.220	0.0046	0.014	0.288	✓
20	0.274	0.0014	0.004	0.250	✓

予算を 1 から 20 へ増やすと，EmitRate は 0.051 から 0.274 へ増加した．一方，UnsupportedEmit はすべて $\beta = 0.05$ 未満であった．MeanSupport は単調ではなく，予算が大きいほど閾値付近の候補も報告されるためである．

A.4.3 報告率区間の検証

定理 4 は，

$$(1-\beta)p_{\theta+2\tau}(R) \leq \mathrm{EmitRate} \leq p_\theta(R) + \beta$$

を与える．各データセットと Proposer について，同じ候補集合から $p_\theta(R)$ と $p_{\theta+2\tau}(R)$ を計算した．

表 A·4 定理 4 の集約セルでの検証.

データ	Proposer	p_θ	$p_{\theta+2\tau}$	Lower	EmitRate	Upper
TAB	tag-template	0.507	0.375	0.356	0.404	0.557
	public LLM	0.000	0.000	0.000	0.003	0.050
WildChat	tag-template	0.300	0.171	0.162	0.220	0.350
	public LLM	0.038	0.009	0.009	0.024	0.088
Yelp	tag-template	0.799	0.653	0.620	0.749	0.849
	public LLM	0.044	0.011	0.010	0.018	0.094

タグテンプレートでは，TAB，WildChat，Yelp の EmitRate はそれぞれ $0.404 \in [0.356, 0.557]$，$0.220 \in [0.162, 0.350]$，$0.749 \in [0.620, 0.849]$ であった．公開 LLM を含む全 6 集約セルと，3 データセット，2 Proposer，5 シードからなる 30 個のシード別セルが理論区間内にあった．

A.4.4 既存 DP 手法を拡張した構成の結果

DP ヒストグラムによる構成． one-hot 方式では各レコードを一候補に，top-c 方式では最大 c 候補に割り当てる．寄与制限は感度を小さくする一方，複数候補にまたがるサポートの一部を失う．

one-hot の EmitRate は 0.020–0.024 であった．top-16 では TAB，Yelp，WildChat で 0.199，0.390，0.183 まで改善したが，Proposal-Filter を下回った．c を増やすとサ

© 2026 Information Processing Society of Japan

表 **A·5**　証拠付き DP ヒストグラムとの EmitRate 比較.

データ	Proposal-Filter	one-hot	top-8	top-16
TAB	0.404	0.020	0.141	0.199
Yelp	0.748	0.024	0.206	0.390
WildChat	0.216	0.020	0.124	0.183

ポートを保持しやすくなる一方，感度と DP ノイズも増える．すべての方式で UnsupportedEmit は $\beta = 0.05$ 以下であった．

Private Evolution 型の構成． Aug-PE 型では，DP 合成データから候補を発見し，合成データ上の頻度を支持情報とする．この支持情報は，元のコーパスに対する下界ではない．

表 **A·6**　Private Evolution 型構成との診断的比較.

方式	EmitRate	UnsupEmit	反復
Aug-PE 型	0.676	0.092	5 end-to-end
Proposal-Filter	0.695	0.001	150 DP-noise

Yelp の $\theta = 0.10$ では，Aug-PE 型の EmitRate は 0.676 で，Proposal-Filter の 0.695 に近かった．一方，元のコーパス上で再評価した UnsupportedEmit は 0.092 であり，Proposal-Filter の 0.001 を上回った．反復単位が異なるため直接比較ではないが，合成データ上の支持を元データ上の証拠として扱えないことを示す．

A.4.5　サポートモデルに対する頑健性

実データでは，NLI 分類器がサポート関数 f_s を定義する．そのため，モデルを変えると，$f_s(R)$ と報告される候補が変化し得る．

デフォルトの `cross-encoder/nli-deberta-v3-base` に加え，`MoritzLaurer/DeBERTa-v3-base-mnli-fever-anli` と `facebook/bart-large-mnli` を評価した．レコードを premise，候補を hypothesis とし，argmax ラベルが entailment の場合に $\sigma_s(r) = 1$ とした．entailment ラベルの添字は，それぞれ 1，0，2 である．その他の設定は共通とした．

表 **A·7**　異なる NLI サポートモデルを用いた EmitRate（中央値）.

データ	DeBERTa	DeBERTa-MNLI	BART-MNLI
TAB	0.422	0.578	0.356
Yelp	0.812	0.875	0.844
WildChat	0.151	0.542	0.485

すべてのモデルで，各モデルが定義するサポート関数に対する UnsupportedEmit は $\beta = 0.05$ 以下であった．一方，EmitRate はモデルによって異なり，特に WildChat では 0.151 から 0.542 まで変化した．また，WildChat における $f_s(R) \geq \theta$ の判定一致率は約 0.62 であった．

これは DP フィルタの失敗ではなく，各モデルが異なるサポート関数を定義するためである．片側誠実性は選択した f_s に対する誤報告を制御するが，f_s 自体の意味的妥当性や分類器間の一致は保証しない．実運用では，公開データによる較正や，複数モデルとの整合性確認が必要である．

© 2026 Information Processing Society of Japan