公開メタ情報のみから生成した代替データによる差分プライベートな合成データ生成手法の統一的パラメータチューニング

稲見 太紀[1,2,a)]　南 和宏[1,b)]　小野 元[3,4,c)]

概要：差分プライバシが保証された表形式の合成データは，機密情報を含む元データに対するプライバシ保護とデータの有用性を両立するとして様々な生成手法が提案されており，各手法を比較したベンチマーク研究も盛んに実施されている．しかし，それらの既存研究ではパラメータチューニングに関する操作が一致しておらず，研究成果の一貫した解釈が困難である．既存研究には，実装時のデフォルト値で統一しているものや，チューニング方法を明示せず任意に設定した値を使用しているものが見られるが，前者では各手法の本来の性能を発揮できず，後者では公平な評価が実施できない．本研究では，元データの列名やドメイン等の公開メタ情報のみから生成した代替データによるチューニングを各手法へ統一的に実施し，元データを直接用いてチューニングした場合のデフォルト値からの改善を，代替データによってどの程度再現できるかを示す．結果は合成手法によって異なり，チューニングによる効果がほとんど見られない条件も存在した．一方で，デフォルト値の場合と元データを直接用いてチューニングした場合との間に約 3.8 倍の差が生じる条件において，代替データがその改善を完全に再現できることを確認した．本研究の成果は，代替データの使用が，プライバシ保護の観点から元データが使用できない状況におけるパラメータチューニングの標準的なアプローチとなり得ることを示している．

キーワード：差分プライバシ， 合成データ， パラメータチューニング

Unified Hyperparameter Tuning For Differentially Private Synthetic Data Generation Methods Using Surrogate Data Generated Only From Public Metadata

Taiki Inami[1,2,a)]　Kazuhiro Minami[1,b)]　Hajime Ono[3,4,c)]

Abstract: Various methods have been proposed to generate differentially private synthetic tabular data, which can protect the privacy of sensitive data while maintaining its utility. Benchmarking studies comparing these methods have also been actively conducted. However, the hyperparameter-tuning procedures vary across these studies, making it difficult to interpret their findings consistently. Some previous studies use the default parameter values provided by each implementation, while others use arbitrarily selected values without clearly specifying the tuning procedure. The former may prevent each method from achieving its full potential, while the latter may prevent a fair evaluation. In this study, we apply a unified tuning procedure to each method using surrogate data generated only from publicly available metadata, such as column names and domains. We then evaluate how much of the improvement achieved by tuning on the original data over the default setting can be reproduced by tuning on the surrogate data. The results varied across synthesis methods, and under some conditions, parameter tuning produced little improvement. However, under conditions in which tuning on the original data achieved approximately 3.8 times the performance obtained with the default setting, we observed that the surrogate data fully reproduced the improvement. Our findings suggest that the use of surrogate data could be a standard approach to parameter tuning in situations where the original data cannot be used because of privacy constraints.

Keywords: Differential Privacy, Synthetic Data, Hyperparameter Tuning

© 2026 Information Processing Society of Japan

This paper is work in progress and not peer-reviewed.

1. はじめに

差分プライバシ [4] は統計を公開する際のプライバシ保護の度合いを測る指標として注目されており，応用の 1 つに合成データのプライバシ侵害リスクの制御がある．特に，表形式の合成データは機密情報を含む元データに対するプライバシ保護とデータの有用性を両立するとして期待されている [17]．2018 年には NIST が差分プライベートな合成データのコンペティションを主催し [12]，2020 年の米国の国勢調査の一般利用ファイルが差分プライペートな手法によって生成された実績がある [1], [18]．

これまでに多くの合成手法が提案されており，DP-Bench [6] や Tab-bench [2] などそれらのベンチマーク評価の研究も多く実施されている．これらの評価では，各手法のプライバシ侵害リスクの水準が差分プライバシのプライバシ予算によって一元的に統一されており，合成データの有用性の比較評価に集中することができる．しかし，それらのベンチマーク研究ではハイパーパラメータチューニングに対する方針が異なり，一貫性のある解釈ができないという問題がある．

例えば，DPBench [6] は手法間の公平な比較のためにハイパーパラメータチューニングを含めた枠組みを比較するべきとしており，正規分布などの人工データなどを使ったハイパーパラメータチューニングを行った上で比較実験を実施している．同論文では実際に，合成手法の一つである MWEM[5] について，チューニング前後における誤差の比が最大で約 27 倍に達することが報告されている．

一方，[15] では，ほとんどの手法でライブラリのデフォルト値を使用している．また，Tab-Bench では，使用したパラメータ値は開示されているものの，それらのチューニング方法については明示されていない．

このような比較方法の一貫性の欠如は，不適切な手法選択をまねく可能性が生じ，ベンチマーク研究の成果を実務における合成手法選択の判断材料とすることを困難にする．

混在する複数の合成手法を，公平かつ一貫した条件で比較するために必要な要素は何か．本研究ではこの問いに対して，ハイパーパラメータチューニングの観点から以下の知見を提示する．

- ハイパーパラメータチューニングを実施することで，合成手法間の有用性の優劣が逆転する場合がある．
- 公開メタ情報のみから生成した代替データによるチューニングは，元データを直接使用したチューニングに匹敵する効果を示す．
- 代替データによるチューニングの効果は対象とするハイパーパラメータに依存して変化する．

本論文は以下のように構成される．2 章では，前提となる基礎知識および関連研究を整理する．3 章では本研究における実験設定を述べ，4 章でその結果を示し，5 章にて結果に関する議論を行う．6 章では，本研究のまとめを述べる．

2. 準備

本章では，本論文を読むために必要な基礎知識と用語を導入し，いくつかの関連研究を振り返る．

2.1 差分プライバシ

差分プライバシは，元データに含まれる個々のレコードが出力分布に与える影響に基づいて，定量的にプライバシを保証する枠組みである．差分プライバシの文脈では，互いに 1 レコードのみが異なるデータセットを隣接データと呼び，任意の隣接データに対して出力される分布の区別がつきにくいほど，プライバシが強く保証されていると考える．定義は次のように与えられる．

定義 1 ((ϵ, δ)-差分プライバシ [4])． 与えられた $\epsilon > 0, 0 \leq \delta \leq 1$ に対して，確率的アルゴリズム $\mathcal{M}\colon D \to R$ が (ϵ, δ)-差分プライバシを満たすとは, 任意の隣接する入力 $x, x' \in D$ と，出力の部分集合 $S \subseteq R$ に対して，次が成立することである．

$$\Pr[\mathcal{M}(x) \in S] \leq e^{\epsilon} \Pr[\mathcal{M}(x') \in S] + \delta$$

ここで，ϵ および δ はプライバシ保護の度合いを表す指標であり，値が小さいほどより強くプライバシが保証されていることを示す．一般的に，ϵ をプライバシ予算，差分プライバシを保証するアルゴリズムをメカニズムと呼ぶ．

2.2 合成データ生成

差分プライバシを満たす合成データの生成手法は複数提案されている．本研究では，グラフィカルモデルに基づく手法，クエリ応答に基づく手法，および，深層生成モデルに基づく手法から代表的な手法を選択し比較実験を行う．ここでは，これら比較対象の手法と，各ハイパーパラメータが制御する挙動について説明する．尚，本研究では，チューニング対象を既存ライブラリを改変することなく調整可能なものに限定している．

グラフィカルモデルに基づく手法としては，MST[9], PrivBayes[19] を選択した．これらの手法は，属性間の相関

[1] 情報・システム研究機構
Research Organization of Information and Systems
[2] 群馬大学
Gunma University
[3] 情報・システム研究機構データサイエンス共同利用基盤施設
Research Organization of Information and Systems Joint Support-Center for Data Science Research
[4] 金沢大学
Kanazawa University
[a)] ism02892@ism.ac.jp
[b)] kminami@ism.ac.jp
[c)] hajime-ono@staff.kanazawa-u.ac.jp

© 2026 Information Processing Society of Japan

関係を低次のグラフ構造によって近似することで，高次元なデータセットに対する合成データの生成を可能にする．

PrivBayes は，グラフィカルモデルを構成する際の親ノードの最大数（k），および，アルゴリズム内部における ϵ の分割比率をパラメータとして持つ．原論文では，k は θ-usefulness という指標から決定されるとしているが，実装に使用したライブラリである DataSynthesizer 0.1.13[*1] では $\theta = 4$ として固定されていたため，本研究ではこの決定方法を使用せず，k を直接のチューニング対象として実験を行う．また，ϵ の分割比率は等分されるように固定されており，本研究ではこの実装に従った．

MST はハイパーパラメータを持たず，固定された制約のもとでグラフィカルモデルを構成し，Private-PGM[11] を用いて分布の推定を行う．ここで，Private-PGM とは，周辺分布の集合から，それらに整合する高次元分布を推定する手法であり，後述する AIM もこの手法を組み込んだ合成手法である．

MST は NIST の合成データコンペティションで優勝した NIST-MST を一般化した手法であり，[15] のベンチマーク評価における平均順位においても，各指標で 1 位から 2 位の結果を示している．しかし，同論文における各合成手法のパラメータはデフォルト値が使用されているため，他の比較対象の合成手法がチューニング不足であった可能性が存在する．

クエリ応答に基づく手法としては，AIM[10]，GEM[8] を選択した．これらの手法は，入力として元データとともに統計的クエリを受け取り，その応答誤差を小さくするように合成データを反復的に更新する．

AIM は，原論文において実質的なチューニングが不要（hyper-parameter free）であると主張しているが，実装に使用したライブラリである mbi[*2] では，反復回数の上限値（rounds），統計的クエリで測る同時分布の次数（degree），モデルサイズの上限，Private-PGM の反復回数がチューニング可能である．また，AIM にも原論文では ϵ の分割比率がパラメータとして存在したが，ライブラリでは 9：1 に固定されていた．

本研究では，モデルサイズの上限は，ソースコード内に，公式な比較時は 80 に設定すること（keeping the default value of 80 for any official comparisons to this mechanism）との記載があったためこれに従い，Private-PGM の反復回数は AIM 固有のパラメータではないため，今回は比較対象外とした．したがって，本研究では rounds および degree のみを対象として実験を行う．

GEM は，ニューラルネットワークに基づいた最適化手法を使用しており，実装に使用したライブラリである iterative-dp[*3] における調整可能なパラメータは，合成データ更新の反復回数（T）や ϵ の分割比率（alpha）に加えて，学習率（lr），学習時の反復上限，ネットワーク構成など，多岐にわたっていた．本研究では，計算コストを考慮し，対象パラメータを T，alpha，lr に限定し，その他のパラメータは実装時のデフォルト値を適用した．これら以外のパラメータが有用性を改善する可能性は排除できておらず，実験にて報告する値は最善値でないことに注意されたい．

深層生成モデルに基づく手法としては，DPCTGAN[14] を選択した．この手法は，統計的クエリを用いず，元データの分布を敵対的学習によりモデル化する．実装に使用したライブラリである，smartnoise-synth[*4] では，GEM と同様に調整可能なパラメータが多岐にわたっていたため，対象を限定した．具体的には，生成器および識別機の学習率（generator_lr, discriminator_lr），訓練エポック数（epochs），ノイズスケール（sigma），バッチサイズ（batch_size）を対象とし，その他のパラメータはライブラリのデフォルト値を適用した．

表 1 ハイパーパラメータ一覧
Table 1 Hyperparameter settings

メカニズム	パラメータ	デフォルト値	探索範囲
MST	なし	なし	なし
PrivBayes	k	自動決定	$[1, 4]$
AIM	`rounds`	$16 \times$ 列数	$[16, 150]$
	`degree`	2	$[2, 4]$
GEM	T	10	$[3, 80]$
	`alpha`	0.5	$[0.1, 0.9]$
	`lr`	10^{-4}	$[10^{-5}, 10^{-1}]$
DPCTGAN	`generator_lr`	2×10^{-4}	$[10^{-7}, 10^{-3}]$
	`discriminator_lr`	2×10^{-4}	$[10^{-5}, 10^{-1}]$
	`epochs`	300	$[10, 1000]$
	`sigma`	5	$[1.0, 8.0]$
	`batch_size`	500	{256, 500, 1000, 1500}

2.3 ハイパーパラメータチューニング

前述したハイパーパラメータの最善値は，元データおよび統計的クエリに左右される．したがって，出力の精度を保つためにはハイパーパラメータチューニングを要するが，元データを直接使用してチューニングを行う場合，追

[*1] https://pypi.org/project/DataSynthesizer/
[*2] https://github.com/ryan112358/mbi, commit 93b7817
[*3] https://github.com/terranceliu/iterative-dp, commit 5e10ec4
[*4] https://pypi.org/project/smartnoise-synth/, version 1.0.8

© 2026 Information Processing Society of Japan

加のプライバシ予算を考慮する必要がある．

この問題は，差分プライバシを考慮した機械学習アルゴリズムに関する研究分野では盛んに議論されており，プライバシ予算を消費しないアプローチとして，デフォルト値を使用する方法，および，公開データを使用する方法が知られている [13]．しかし，前者は一定の妥当性のあるデフォルト値を，後者は元データに類似する公開データを必要とするが，そのような公開データが必ずしも存在するとは限らない．

近年，元データの列名やドメイン等のスキーマ情報をプロンプトに組み込むことで，大規模言語モデル（LLM）に架空の表形式データを生成させる手法が提案されている [16]．[7] では，そのようなデータの，モデルの事前学習やハイパーパラメータチューニングに対する有用性を検証しており，同論文では，大規模言語モデルを使用した手法が，公開データや予め定められた分布から生成したデータによってチューニングした結果と比べて，一貫して高い有用性を示すことを報告している．

本研究ではこれらの知見に基づき，元データを代替するデータを同論文の手法を用いて生成し，そのデータを使用することで，追加のプライバシ予算を考慮せずにハイパーパラメータチューニングを行う．そして，この方法が合成手法比較時の公平かつ一貫した条件であるかどうかを検証する．

2.4 LLM を用いた代替データの生成

本研究では，[7] にて使用されている，LLM に直接 csv ファイルを出力させる手法（Direct CSV），および，コードとして出力させた生成モデルからサンプリングを行う手法（Agent）を用いて代替データを生成する．

前者の手法では，列名や各属性値の範囲といったデータセットのスキーマ情報とともに，プロンプトにて行数を指定して csv ファイルを生成させる．行数が多い場合は，API の制約等の理由から，複数バッチに分けて目標数に達するまで繰り返し LLM への問い合わせを行うが，問い合わせごとにクレジットが消費されるため，データセットの行数に応じてコストが増大する．ここで，クレジットとは API 使用時に支払われる残高を指し，本研究では事前に十分なクレジットを購入したうえで実験を行った．

後者の手法では，データセットのスキーマ情報から，データ生成のための確率モデルを LLM に推定させたうえで，結果を実行可能なコードとして出力させる．代替データは出力されたコードを実行することによるサンプリングで生成されるため，前者の手法のような行数の増加に伴ったコストの増大は発生しない．

しかし LLM は，学習時に大量のデータを使用するため，良く知られた実験用データに対しては，関連する情報を既に学習している可能性がある．この問題を避けるためにはしばしば，使用する LLM の Knowledge Cutoff が参照される．Knowledge Cutoff とは，モデルが保持する知識が概ねどの時点までの情報に基づいているかを示す基準時点であり，その時点以降のデータは未学習であるとされている．

本研究で使用したモデルである，Claude Sonnet 4.5 は，Knowledge Cutoff が 2025 年 7 月となっているため，実験ではそれ以降に公開されたデータを使用している．

2.5 ベンチマーク研究

ベンチマーク研究は，統一された実験条件の下で複数の手法を比較し，実務者がタスクに応じた適切な手法選択を行うための指針を与える．

DPBench [6] では，合成手法を比較する際に従うべき複数の原則が提案されており，その一つに，パラメータチューニングを含めた枠組みで比較を行うべきという原則がある．同論文では，実際に，チューニング前後の MWEM によって出力された合成データのクエリ誤差の比が，最大で約 27 倍に達することが報告されており，パラメータチューニングの重要性を示している．

しかしながら，後続のベンチマーク研究において，この原則が考慮されていない．[15] では，ハイパーパラメータは，ほとんどの合成手法で実装時のデフォルト値を使用しており，Tab-Bench [2] では，使用したパラメータ値は開示されているものの，統一的なチューニング方法が示されていない．このように，これらの研究の成果は，デフォルト値の影響やチューニング方法の影響が考慮されていないため，合成手法間の公平な比較とはいえない．

実際に，本研究の実験では，チューニングによって合成手法間の有用性の優劣が逆転する場合があることを確認している．

3. 実験設定

実験では，パラメータ探索を元データと各代替データのそれぞれで行い，選択した値による結果とデフォルト値による結果を比較する．

パラメータの探索候補は，表 1 に示した探索範囲から，20 回の一様ランダムな非復元抽出によって決定した．ただし，探索範囲内の要素が 20 個に満たない場合は全探索となる．実際の探索候補は付録にて示している．

また，本研究では計算コストを考慮し，それぞれのパラメータに対して独立に探索を行い，各回における対象のパラメータ以外はデフォルト値に統一している．ここで，最適な組み合わせの探索は行っていないため，報告する各合成手法の有用性は最善値では無いことに注意されたい．

評価指標には，[15] らが使用した Pair スコアおよび F1 スコアを用いる．Pair スコアは，データセットのすべての 2 つの属性の組み合わせに対する，元データと合成データの 2 次元周辺分布の類似度に関する指標である．より正確

© 2026 Information Processing Society of Japan

には，元データと合成データの同じ属性ペア同士の 2 次元周辺分布の全変動距離（TVD）を 1 から引き，平均したものである．F1 スコアは，下流タスクにおける合成データの有用性を測る指標であり，合成データで学習した XGBoost 分類器の F1 スコアを示す．値が高いほど高い有用性を持つことを示す．

本研究のチューニングでは，20 個の探索候補から Pair スコアを最大化するパラメータを探索した．

また，LLM は Claude Sonnet 4.5 を使用し，同モデルの Knowledge Cutoff（2025 年 7 月）については，元データとしてシカゴ市が公開する”Food Inspections”データセットの 2026 年 1 月 1 日以降のレコードを使用することで考慮した [3]．データの取得日は 2026 年 7 月 22 日である．Food Inspections は，食品を取り扱う施設に対して行われた検査の結果をまとめたデータセットであり，17 個の属性を含む．対象とする合成手法はデータの高次元化に伴って計算コストが増大するため，本実験では，計算時間が現実的な範囲に収まるよう，17 個のうち 5 個の属性を選択して使用した．選択にあたっては，対象とする合成手法の実装が離散値を前提とした設計であることを踏まえ，離散かつ分布に情報を持つ属性を優先した．除外したのは，行ごとに一意な識別子，自由記述，情報が重複した列，および 99%以上のレコードが同一の値をとる属性である．

4. 実験結果

表 2 は, 探索したパラメータを元データ上で適用した際の Pair スコアを，ϵ の 3 つの値に対して示している．default はデフォルト値を使用した結果を示す列であり，default 以降の各列は，チューニングに使用したデータによって分割されている．oracle は元データ，csv は Direct CSV によって生成した代替データ，agent は Agent によって生成した代替データを使用した結果を示す列である．seed 1，seed 2，seed 3 は，異なるシードで一様分布から生成した代替データを使用した列である．また，同一手法内で最大の有用性を示すパラメータチューニングを対象とし，各列における上位 3 条件を黄色，灰色，朱色で色分けしている．ここで，csv および agent は，代替データの生成コストの都合上，それぞれ 1 回のみの生成で実験を行っており，得られた結果が偶然性に起因する可能性は排除できていない．この点は，本実験における限界の一つである．

全体としては，3 種類すべての ϵ において，default の上位 3 手法が AIM，MST，GEM だが，oracle でその順位が変動し，csv および agent が変動後の順位を保存していることが確認できる．一方で，seed 1，seed 2，seed 3 は結果が一貫せず，順位の保存は $\epsilon = 10.0$ の場合にのみ発生している．また，チューニング後の手法間の有用性の差は，低 ϵ 時に明白であり，ϵ 値が大きいほど小さくなっている．

PrivBayes は，$\epsilon = 1.0$ において，default の 0.2298 から oracle の 0.8737 への約 3.8 倍の改善を csv および agent が完全に再現している．PrivBayes のパラメータ k は，列間の相関性に応じて最適値が変動するため，csv および agent は元データの相関構造を適切に捉えられていたということが予想される．

また，この改善によって PrivBayes の順位は大きく変動しており，$\epsilon = 1.0$ において default では最下位に位置しているがチューニング後は 2 位まで上昇している．一方で，本実験では，Pair スコアを最大化するパラメータを探索しているため，F1 スコアに関する表では，一部手法で oracle が default を下回り，PrivBayes ではその結果が顕著に表れた．ここでは，紙面の都合上，該当する条件である $\epsilon = 10.0$ の結果のみを表 3 に示す．なお，3 種類すべての ϵ における結果は付録にて示している．この表より，PrivBayes は Pair スコアで約 3.8 倍の改善を見せた一方で，F1 スコアが 0.3253 から 0.2543 へ低下していることが確認できる．これには，実験条件によるバイアスが関連していると考えられる．Pair を最大化するパラメータの探索は，2 列の相関を過度に表現するモデルを形成する可能性があるため，予測に必要な 3 列以上の相関性を適切に捉えることができず，F1 スコアの低下を招いたのではないか．

これらの結果は，合成手法比較時には，下流タスクを考慮したの統一的なパラメータチューニングが必要であることを示している．

AIM は，3 種類すべての ϵ において，default の時点で高い有用性を示している．しかし，AIM はパラメータの degree によって統計的クエリで測る同時分布の次数を指定することが可能であり，デフォルト値は 2 であるため，Pair スコアのもとでは有利な条件になっていることに注意したい．実際に，oracle では他の合成手法との差が縮小している．つまり，本実験における条件では，AIM に対するチューニング効果はデフォルトの時点で限定的であったと言える．

MST は，AIM に次いで高い有用性を示すが，アルゴリズム内部で 2 次元周辺分布を測定するため，AIM と同様に Pair のもとで有利な合成手法であることに注意したい．一方，F1 においては，他の合成手法と比較して精度が出ていない．これは，AIM がすべての 2 次元周辺分布を測定するのに対し，MST は一部のみを測定するため，予測列を含む 2 次元周辺分布が測定されにくくなっていることが要因であると予想される．

csv や agent では効果が見られない条件も存在し，$\epsilon = 0.1$ において，GEM の alpha を csv，agent でチューニングした結果は，default の 0.3181 から 0.2565，0.0741 へ低下している．

GEM では，2 種類のメカニズムが使用されており，一方のメカニズムでは，与えられた統計的クエリのうち応答誤差が大きいものを確率的に選択し，もう一方のメカニズム

© 2026 Information Processing Society of Japan

表 2　チューニング方法ごとの Pair スコア ($\epsilon = 0.1, 1.0, 10.0$)
Table 2　Pair scores for different tuning methods ($\epsilon = 0.1, 1.0, 10.0$)

				surrogate: LLM		surrogate: Uniform		
メカニズム	パラメータ	default	oracle	csv	agent	seed 1	seed 2	seed 3
$\varepsilon = 0.1$								
MST	なし	0.7165	0.7165	0.7165	0.7165	0.7165	0.7165	0.7165
PrivBayes	k	0.2276	0.4686	0.4686	0.4686	0.2246	0.2246	0.2246
AIM	rounds	0.7756	0.7756	0.7724	0.7724	0.7521	0.7724	0.7521
	degree	0.7756	0.7756	0.7314	0.7756	0.7756	0.7756	0.7756
GEM	T	0.3181	0.4218	0.4215	0.4215	0.0233	0.0166	0.0084
	alpha	0.3181	0.3783	0.2565	0.0741	0.2553	0.0036	0.1090
	lr	0.3181	0.4631	0.3743	0.2009	0.2009	0.4631	0.4631
DPCTGAN	epochs	0.2236	0.2236	0.2236	0.2236	0.2236	0.2236	0.2236
	sigma	0.2236	0.2236	0.2236	0.2236	0.2236	0.2236	0.2236
	batch_size	0.2236	0.2243	0.2243	0.2243	0.2229	0.2243	0.2236
	generator_lr	0.2236	0.2236	0.2236	0.2236	0.2236	0.2236	0.2236
	discriminator_lr	0.2236	0.2236	0.2236	0.2236	0.2236	0.2236	0.2236
$\varepsilon = 1.0$								
MST	なし	0.8511	0.8511	0.8511	0.8511	0.8511	0.8511	0.8511
PrivBayes	k	0.2298	0.8737	0.8737	0.8737	0.2270	0.2298	0.2270
AIM	rounds	0.8900	0.8957	0.8895	0.8949	0.8917	0.8892	0.8896
	degree	0.8900	0.8900	0.8900	0.8900	0.8900	0.8881	0.8900
GEM	T	0.5033	0.5773	0.4442	0.4603	0.3898	0.3834	0.3834
	alpha	0.5033	0.5122	0.5025	0.4911	0.5122	0.4962	0.4990
	lr	0.5033	0.5093	0.5093	0.4832	0.4668	0.3423	0.4287
DPCTGAN	epochs	0.3984	0.3984	0.3984	0.3984	0.3984	0.3984	0.3984
	sigma	0.3984	0.4444	0.2697	0.3008	0.2604	0.2604	0.2604
	batch_size	0.3984	0.3984	0.3984	0.2962	0.2458	0.2458	0.2458
	generator_lr	0.3984	0.4312	0.3317	0.3147	0.2117	0.2117	0.2117
	discriminator_lr	0.3984	0.7138	0.6987	0.6737	0.6711	0.6711	0.6711
$\varepsilon = 10.0$								
MST	なし	0.9135	0.9135	0.9135	0.9135	0.9135	0.9135	0.9135
PrivBayes	k	0.2902	0.9124	0.9124	0.9124	0.9124	0.9124	0.9124
AIM	rounds	0.9611	0.9633	0.9612	0.9632	0.9631	0.9611	0.9605
	degree	0.9611	0.9611	0.9611	0.9609	0.9611	0.9609	0.9609
GEM	T	0.5299	0.6880	0.6880	0.6025	0.4112	0.4112	0.4112
	alpha	0.5299	0.5399	0.5299	0.5299	0.5319	0.5309	0.5299
	lr	0.5299	0.5418	0.5090	0.5090	0.4720	0.4115	0.4575
DPCTGAN	epochs	0.4057	0.4248	0.3200	0.3859	0.3398	0.4248	0.4248
	sigma	0.4057	0.5361	0.4962	0.5289	0.5289	0.4962	0.5289
	batch_size	0.4057	0.5032	0.5032	0.5032	0.5032	0.5032	0.5032
	generator_lr	0.4057	0.7458	0.7458	0.5407	0.2388	0.2388	0.2388
	discriminator_lr	0.4057	0.7918	0.7918	0.7767	0.7918	0.7767	0.7767

では，クエリの応答結果に対してノイズを加える．alpha はそれらに対して割り当てる ϵ の比率を指定する．

それぞれのクエリの応答誤差に明確な差が見られる場合，前者のメカニズムに対して低い比率を割り当てることが合理的となり，明確な差が見られない場合は，高い比率を割り当てることが合理的となる．したがって，alpha の類似には，クエリの応答結果が値レベルで元データと類似していることを求めるため，csv および agent によって有用性の低下が見られたのは，この類似性を満たしていなかったからであると予想される．

しかしこのような類似性を満たす場合，代替データをチューニング用途で使用するのではなく，直接合成データとして出力する方が合理的である可能性が存在する．この点についてはさらなる検討が必要である．また，ライブラ

© 2026 Information Processing Society of Japan

表 3 チューニング方法ごとの F1 スコア ($\epsilon = 10.0$)
Table 3 F1 scores for different tuning methods ($\epsilon = 10.0$)

				surrogate: LLM		surrogate: Uniform		
メカニズム	パラメータ	default	oracle	csv	agent	seed 1	seed 2	seed 3
MST	なし	0.1234	0.1234	0.1234	0.1234	0.1234	0.1234	0.1234
PrivBayes	k	0.3253	0.2543	0.2543	0.2543	0.2543	0.2543	0.2543
AIM	rounds	0.3968	0.3921	0.3894	0.3886	0.3902	0.3968	0.3931
	degree	0.3968	0.3968	0.3968	0.3880	0.3968	0.3880	0.3880
GEM	T	0.1621	0.2998	0.2998	0.2797	0.1010	0.1010	0.1010
	alpha	0.1621	0.1391	0.1621	0.1621	0.1678	0.1640	0.1621
	lr	0.1621	0.1835	0.1354	0.1354	0.1697	0.1109	0.1616
DPCTGAN	epochs	0.1011	0.1143	0.1293	0.1345	0.1181	0.1143	0.1143
	sigma	0.1011	0.1048	0.1200	0.1026	0.1026	0.1200	0.1026
	batch_size	0.1011	0.1330	0.1330	0.1330	0.1330	0.1330	0.1330
	generator_lr	0.1011	0.1152	0.1152	0.1039	0.0851	0.0851	0.0851
	discriminator_lr	0.1011	0.1477	0.1477	0.1317	0.1477	0.1317	0.1317

表 4 oracle においてチューニングに要した計算時間 (分)
Table 4 Tuning time in oracle (min)

メカニズム	対象パラメータ数	総探索候補数	ε=0.1	ε=1.0	ε=10.0	合計
MST	0	—	—	—	—	—
PrivBayes	1	5	9.4	10.0	11.0	30.4
AIM	2	25	3.7	5.6	13.5	22.8
GEM	3	63	143.5	111.9	89.7	345.1
DPCTGAN	5	89	7.7	13.4	212.6	233.6
合計			164.3	140.9	326.8	631.9

Intel Core Ultra 7 258V，RAM 32 GB にて実行．ただし，DPCTGAN のみ GPU 搭載の別機 (Intel Core i7-7700，RAM 16 GB，NVIDIA GeForce RTX 4060) で実行．

リでは 9：1 に固定されており本実験では対象外としたが，原論文では AIM にも予算分割に関するパラメータが存在し，alpha と同様の結果を示すと予想される．

DPCTGAN は，他の合成手法に比べて全体的に劣る結果となった．しかし，DPCTGAN は本実験の，各パラメータの独立したチューニングという条件においては不利であった可能性がある．実際に，DPCTGAN における 2 つの学習率は，default ではいずれも 2×10^{-4} という同一の値に設定されているが，oracle が選ぶ値は，$\epsilon = 10.0$ において，生成器側が 4.91×10^{-6}，識別器側が 8.29×10^{-3} であった．そのため，各パラメータを独立してチューニングする場合，少なくとも一方の学習率は最適値から大きく離れた値となる．したがって，DPCTGAN はパラメータの最適な組み合わせを探索することでさらなる改善が得られると予想されるが，探索候補数の増加により，計算時間の問題が発生する．

表 4 は，oracle におけるチューニングに要した計算時間を示している．GEM および DPCTGAN の計算時間は独立したチューニングで既に数時間を超えており，組み合わせの探索では非現実的な計算時間を要する可能性がある．

また，計算時間とそこから得られるチューニング効果が対応するわけでは無いという点に注目したい．大きな効果が得られた PrivBayes よりも，あまり効果が得られなかった GEM の方が多くの計算時間を要している．この結果は，合成手法に関する事前理解から，チューニング対象を選別する必要性を示唆している．

5. 結論

本研究では，混在する複数の合成データ生成手法を，公平かつ一貫した条件で比較するための要素として，統一的なパラメータチューニングが重要であることを示した．

実際に，元データを直接用いたパラメータチューニングの前後で手法間の有用性の優劣が変化すること，および，LLM ベースの代替データによるチューニングが元データを直接用いたチューニングに匹敵する効果を示すことを実験によって確認した．

これは，LLM ベースの代替データが，デフォルト値に代わる公平な比較条件となりうることを示しているが，一

© 2026 Information Processing Society of Japan

部にはチューニングの際に，データ間の厳しい類似性を求めるハイパーパラメータも存在し，そのような場合にはデフォルト値による結果さえ下回る可能性があるため注意が必要である．

また，パラメータ数の増加に伴って計算コストが増大するため，コストに見合ったチューニング結果が得られるとは限らない．そのため，代替データの，プライバシ予算を消費しないという利点を活かした，より効率的なチューニング方法の提案が期待される．

謝辞

本研究は，JST 経済安全保障重要技術育成プログラム【JPMJKP24U5】の支援を受けたものです．

参考文献

[1] Abowd, J. M.: The U.S. Census Bureau Adopts Differential Privacy, *Proceedings of the 24th ACM SIGKDD International Conference on Knowledge Discovery & Data Mining*, KDD '18, New York, NY, USA, Association for Computing Machinery, p. 2867 (online), available from ⟨https://doi.org/10.1145/3219819.3226070⟩ (2018).

[2] Chen, K., Li, X., Gong, C., Mckenna, R. and Wang, T.: Benchmarking Differentially Private Tabular Data Synthesis: [Experiments & Analysis], *Proc. ACM Manag. Data*, Vol. 3, No. 6 (online), DOI: 10.1145/3769764 (2025).

[3] City of Chicago: Food Inspections, https://data.cityofchicago.org/Health-Human-Services/Food-Inspections/4ijn-s7e5 (2026).

[4] Dwork, C., McSherry, F., Nissim, K. and Smith, A.: Calibrating Noise to Sensitivity in Private Data Analysis, *Theory of Cryptography* (Halevi, S. and Rabin, T., eds.), Berlin, Heidelberg, Springer Berlin Heidelberg, pp. 265–284 (2006).

[5] Hardt, M., Ligett, K. and McSherry, F.: A Simple and Practical Algorithm for Differentially Private Data Release, *Advances in Neural Information Processing Systems (NIPS)*, Vol. 25, pp. 2339–2347 (2012). arXiv:1012.4763.

[6] Hay, M., Machanavajjhala, A., Miklau, G., Chen, Y. and Zhang, D.: Principled Evaluation of Differentially Private Algorithms using DPBench, *Proceedings of the 2016 International Conference on Management of Data*, SIGMOD '16, New York, NY, USA, Association for Computing Machinery, p. 139–154 (online), DOI: 10.1145/2882903.2882931 (2016).

[7] Hod, S., Rosenblatt, L. and Stoyanovich, J.: Do You Really Need Public Data? Surrogate Public Data for Differential Privacy on Tabular Data, *Advances in Neural Information Processing Systems*, Vol. 38, (online), DOI: 10.52202/085713-0340 (2025).

[8] Liu, T., Vietri, G. and Wu, Z. S.: Iterative Methods for Private Synthetic Data: Unifying Framework and New Methods, *Advances in Neural Information Processing Systems (NeurIPS)*, Vol. 34, pp. 690–702 (2021). arXiv:2106.07153.

[9] McKenna, R., Miklau, G. and Sheldon, D.: Winning the NIST Contest: A Scalable and General Approach to Differentially Private Synthetic Data, *Journal of Privacy and Confidentiality*, Vol. 11, No. 3 (online), DOI: 10.29012/jpc.778 (2021). arXiv:2108.04978.

[10] McKenna, R., Mullins, B., Sheldon, D. and Miklau, G.: AIM: An Adaptive and Iterative Mechanism for Differentially Private Synthetic Data, *Proceedings of the VLDB Endowment*, Vol. 15, No. 11, pp. 2599–2612 (online), DOI: 10.14778/3551793.3551817 (2022). arXiv:2201.12677.

[11] McKenna, R., Sheldon, D. and Miklau, G.: Graphical-Model Based Estimation and Inference for Differential Privacy, *Proceedings of the 36th International Conference on Machine Learning (ICML)*, Proceedings of Machine Learning Research, Vol. 97, PMLR, pp. 4435–4444 (2019). arXiv:1901.09136.

[12] National Institute of Standards and Technology: 2018 differential privacy synthetic data challenge, `https://www.nist.gov/ctl/pscr/open-innovation-prize-challenges/past-prize-challenges/2018-differential-privacy-synthetic` (2018). Accessed: Dec. 30th, 2025.

[13] Ponomareva, N., Hazimeh, H., Kurakin, A., Xu, Z., Denison, C., McMahan, H. B., Vassilvitskii, S., Chien, S. and Guha Thakurta, A.: How to DP-fy ML: A Practical Guide to Machine Learning with Differential Privacy, *Journal of Artificial Intelligence Research*, Vol. 77, pp. 1113–1201 (online), DOI: 10.1613/jair.1.14649 (2023).

[14] Rosenblatt, L., Liu, X., Pouyanfar, S., de Leon, E., Desai, A. and Allen, J.: Differentially Private Synthetic Data: Applied Evaluations and Enhancements, *arXiv preprint arXiv:2011.05537* (2020).

[15] Tao, Y., McKenna, R., Hay, M., Machanavajjhala, A. and Miklau, G.: Benchmarking Differentially Private Synthetic Data Generation Algorithms, *Workshop on Privacy-Preserving Artificial Intelligence (PPAI), AAAI 2022*, (online), available from ⟨https://aaai-ppai22.github.io/⟩ (2022). arXiv:2112.09238.

[16] Törnqvist, M., Zucker, J.-D., Fauvel, T., Lambert, N., Berthelot, M. and Movschin, A.: A Text-to-Tabular Approach to Generate Synthetic Patient Data using LLMs, *2025 IEEE 13th International Conference on Healthcare Informatics (ICHI)*, pp. 18–29 (online), DOI: 10.1109/ICHI64645.2025.00011 (2025).

[17] United Nations. Economic Commission for Europe: *Synthetic data for official statistics: a starter guide*, United Nations (2022).

[18] United States Census Bureau: 2020 Census Privacy-Protected Microdata File (PPMF), `https://www.census.gov/data/tables/2024/dec/2020-census-ppmf.html` (2024).

[19] Zhang, J., Cormode, G., Procopiuc, C. M., Srivastava, D. and Xiao, X.: PrivBayes: Private Data Release via Bayesian Networks, *Proceedings of the 2014 ACM SIGMOD International Conference on Management of Data (SIGMOD)*, pp. 1423–1434 (online), DOI: 10.1145/2588555.2588573 (2014).

付　　録

A.1 実験の詳細

パラメータの探索候補を表 A·1 に，3 種類すべての ϵ における F1 スコアを表 A·2 に示す．

© 2026 Information Processing Society of Japan

表 A·1 実験にて使用したパラメータの探索候補

Table A·1 Candidate values for hyperparameter tuning in the experiments

Mechanism	Hyperparameter	Candidate values
PrivBayes	`k`	1, 2, 3, 4
AIM	`rounds`	18, 20, 25, 37, 48, 52, 76, 80, 88, 90, 91, 94, 97, 99, 111, 114, 117, 131, 142, 150
	`degree`	2, 3, 4
GEM	`T`	4, 5, 7, 14, 19, 22, 34, 38, 41, 44, 46, 47, 50, 53, 56, 58, 66, 73, 75, 79
	`alpha`	0.1022, 0.1132, 0.1269, 0.1328, 0.2405, 0.3158, 0.3398, 0.4381, 0.5332, 0.5349, 0.5853, 0.6096, 0.6836, 0.6837, 0.7506, 0.7527, 0.7859, 0.7905, 0.8302, 0.8481
	`lr`	1.03×10^{-5}, 1.16×10^{-5}, 1.36×10^{-5}, 1.46×10^{-5}, 5.04×10^{-5}, 1.20×10^{-4}, 1.58×10^{-4}, 4.91×10^{-4}, 1.47×10^{-3}, 1.49×10^{-3}, 2.67×10^{-3}, 3.53×10^{-3}, 8.28×10^{-3}, 8.29×10^{-3}, 1.79×10^{-2}, 1.83×10^{-2}, 2.69×10^{-2}, 2.84×10^{-2}, 4.48×10^{-2}, 5.50×10^{-2}
DPCTGAN	`epochs`	26, 50, 83, 181, 273, 310, 505, 507, 547, 564, 607, 629, 634, 647, 730, 807, 836, 907, 936, 967
	`sigma`	1.0192, 1.1157, 1.2351, 1.2868, 2.2296, 2.8885, 3.0980, 3.9588, 4.7902, 4.8054, 5.2465, 5.4587, 6.1065, 6.1076, 6.6929, 6.7110, 7.0018, 7.0423, 7.3893, 7.5455
	`batch_size`	256, 500, 1000, 1500
	`generator_lr`	1.03×10^{-7}, 1.16×10^{-7}, 1.36×10^{-7}, 1.46×10^{-7}, 5.04×10^{-7}, 1.20×10^{-6}, 1.58×10^{-6}, 4.91×10^{-6}, 1.47×10^{-5}, 1.49×10^{-5}, 2.67×10^{-5}, 3.53×10^{-5}, 8.28×10^{-5}, 8.29×10^{-5}, 1.79×10^{-4}, 1.83×10^{-4}, 2.69×10^{-4}, 2.84×10^{-4}, 4.48×10^{-4}, 5.50×10^{-4}
	`discriminator_lr`	1.03×10^{-5}, 1.16×10^{-5}, 1.36×10^{-5}, 1.46×10^{-5}, 5.04×10^{-5}, 1.20×10^{-4}, 1.58×10^{-4}, 4.91×10^{-4}, 1.47×10^{-3}, 1.49×10^{-3}, 2.67×10^{-3}, 3.53×10^{-3}, 8.28×10^{-3}, 8.29×10^{-3}, 1.79×10^{-2}, 1.83×10^{-2}, 2.69×10^{-2}, 2.84×10^{-2}, 4.48×10^{-2}, 5.50×10^{-2}

© 2026 Information Processing Society of Japan

表 A·2　チューニング方法ごとの F1 スコア ($\epsilon = 0.1, 1.0, 10.0$)

Table A·2　F1 scores for different tuning methods ($\epsilon = 0.1, 1.0, 10.0$)

				surrogate: LLM		surrogate: Uniform		
メカニズム	パラメータ	default	oracle	csv	agent	seed 1	seed 2	seed 3
$\varepsilon = 0.1$								
MST	なし	0.1084	0.1084	0.1084	0.1084	0.1084	0.1084	0.1084
PrivBayes	k	0.1020	0.2343	0.2343	0.2343	0.1036	0.1036	0.1036
AIM	rounds	0.1076	0.1076	0.1152	0.1152	0.1061	0.1152	0.1061
	degree	0.1076	0.1076	0.2532	0.1076	0.1076	0.1076	0.1076
GEM	T	0.0951	0.1019	0.1018	0.1018	0.0442	0.0395	0.0211
	alpha	0.0951	0.1022	0.1072	0.0435	0.1035	0.0149	0.0462
	lr	0.0951	0.1349	0.1010	0.1305	0.1305	0.1349	0.1349
DPCTGAN	epochs	0.0979	0.0979	0.0979	0.0979	0.0979	0.0979	0.0979
	sigma	0.0979	0.0979	0.0979	0.0979	0.0979	0.0979	0.0979
	batch_size	0.0979	0.1077	0.1077	0.1077	0.0956	0.1077	0.0979
	generator_lr	0.0979	0.0979	0.0979	0.0979	0.0979	0.0979	0.0979
	discriminator_lr	0.0979	0.0979	0.0979	0.0979	0.0979	0.0979	0.0979
$\varepsilon = 1.0$								
MST	なし	0.1507	0.1507	0.1507	0.1507	0.1507	0.1507	0.1507
PrivBayes	k	0.1826	0.2488	0.2488	0.2488	0.1729	0.1826	0.1729
AIM	rounds	0.2882	0.2879	0.2794	0.2894	0.2967	0.2922	0.2978
	degree	0.2882	0.2882	0.2882	0.2882	0.2882	0.2915	0.2882
GEM	T	0.1902	0.2173	0.1312	0.1086	0.1235	0.1319	0.1319
	alpha	0.1902	0.1877	0.1941	0.1903	0.1877	0.1429	0.1766
	lr	0.1902	0.1762	0.1762	0.1096	0.1266	0.1110	0.1237
DPCTGAN	epochs	0.1012	0.1012	0.1012	0.1012	0.1012	0.1012	0.1012
	sigma	0.1012	0.1105	0.1009	0.1047	0.0891	0.0891	0.0891
	batch_size	0.1012	0.1012	0.1012	0.1115	0.0909	0.0909	0.0909
	generator_lr	0.1012	0.1088	0.1007	0.1141	0.0812	0.0889	0.0889
	discriminator_lr	0.1012	0.1106	0.1214	0.1206	0.1174	0.1174	0.1174
$\varepsilon = 10.0$								
MST	なし	0.1234	0.1234	0.1234	0.1234	0.1234	0.1234	0.1234
PrivBayes	k	0.3253	0.2543	0.2543	0.2543	0.2543	0.2543	0.2543
AIM	rounds	0.3968	0.3921	0.3894	0.3886	0.3902	0.3968	0.3931
	degree	0.3968	0.3968	0.3968	0.3880	0.3968	0.3880	0.3880
GEM	T	0.1621	0.2998	0.2998	0.2797	0.1010	0.1010	0.1010
	alpha	0.1621	0.1391	0.1621	0.1621	0.1678	0.1640	0.1621
	lr	0.1621	0.1835	0.1354	0.1354	0.1697	0.1109	0.1616
DPCTGAN	epochs	0.1011	0.1143	0.1293	0.1345	0.1181	0.1143	0.1143
	sigma	0.1011	0.1048	0.1200	0.1026	0.1026	0.1200	0.1026
	batch_size	0.1011	0.1330	0.1330	0.1330	0.1330	0.1330	0.1330
	generator_lr	0.1011	0.1152	0.1152	0.1039	0.0851	0.0851	0.0851
	discriminator_lr	0.1011	0.1477	0.1477	0.1317	0.1477	0.1317	0.1317

© 2026 Information Processing Society of Japan