TableForge-LP: データベースの反復更新による表形式データ合成

紀伊 真昇[1,a)]

概要：表形式データ合成とは、元データの統計的特徴や属性間の関係を保ちながら、新たな表形式データを生成する技術である。新しいデータを元データの代わりに使えば、プライバシー保護に役立てたり、データ量の増減ができる。近年の表形式データ合成手法では、生成分布の 1、2 属性周辺分布が元データのそれと一致することを目指していることが多い。しかし、生成分布が目標分布と一致していても、有限個のレコードを生成する際に生じる標本化誤差のため、出力データベースの経験周辺分布は目標値からずれる。本稿では、この標本化誤差を避けるため、有限の出力データベースを直接更新する TableForge-LP を提案する。本手法は、一属性周辺分布を厳密に保存しながら低次元の経験周辺分布を目標分布へ近づける更新量を線形計画法で求め、レコードの属性値を書き換える。実験では、一属性周辺分布を厳密に保存しつつ、二属性周辺分布の再現精度について既存手法に匹敵し、条件によっては上回る結果を得た。

キーワード：表形式データ合成、線形計画法、周辺分布、IPFP、データ蒸留

TableForge-LP: Synthesis of Tabular Data Through Iterative Database Updates

Masanobu KII[1,a)]

Abstract: Tabular data synthesis generates new tabular data while preserving the statistical characteristics and relationships among the attributes of the source data. Synthetic data can replace source data to protect privacy and to augment or reduce data. Recent methods often aim to match the one- and two-way marginal distributions of the generative distribution to those of the source data. However, even when the generative distribution matches the target distribution, sampling a finite number of records introduces sampling error, causing empirical marginals of the output database to deviate from their targets. To avoid this error, we propose TableForge-LP, which directly updates a finite output database. Using linear programming, the method determines updates that move low-dimensional empirical marginals toward their targets while exactly preserving one-way marginals, and rewrites record attributes accordingly. Experiments show that TableForge-LP exactly preserves one-way marginals and achieves two-way marginal reproduction comparable to existing methods, and better under some conditions.

Keywords: tabular data synthesis, linear programming, marginal distribution, IPFP, distribution matching

1. はじめに

表形式データとは、各行が個々のレコード、各列が属性を表すように構造化されたデータのことであり、これは行列、表、データベース (DB) を使って表現できる。表形式データの合成とは、元の DB と同じ統計的特徴を持つ新しい DB を生成することである。合成された新しい DB を作ることで、プライバシー保護やデータ量の増幅／圧縮ができる。

考慮する統計的特徴には各属性の平均や分散から全属性の同時分布まで様々なものが考えられる。しかし現実の

[1] NTT 社会情報研究所
NTT Social Informatics Laboratories
[a)] masanobu.kii@ntt.com

© 2026 Information Processing Society of Japan

This paper is work in progress and not peer-reviewed.

データを用いたベンチマーク [11, 3] によると、特に 1-3 属性程度の低次元周辺分布を再現すれば、少なくともクラス分類については、その分析結果まで精度良く再現できることが分かっている。

表形式データ合成の研究では、生成されるレコードの生成分布が元 DB の分布に近いことを目標とするのが普通である。言い換えれば、レコードを無数に生成したときに、それらの経験分布が元 DB の分布に近いことを目指している。しかし、実際には我々は有限のレコードしか生成できない。そのため標本変動は常に残り、出力 DB の経験周辺分布は、推定された元 DB の周辺分布から高い頻度でずれる。

これに対し、本研究では生成分布を介さず、有限の出力 DB の経験分布そのものを元データの分布に近づけることを目指す。この目標を達成できれば、指定した低次元周辺分布について、標本化に起因するずれを回避できる。また、少ないレコードだけでも、元 DB の特徴を再現できるようになる。したがって、本研究は分布一致型のデータ蒸留（データ圧縮とも呼ばれる）の研究 [13] とデータ合成の研究の合流点に位置づけられる。

本研究では有限レコードからなる初期 DB から出発して、DB の 2 – 3 程度の少数属性の経験周辺分布を目標分布へ近づけることを繰り返す、という方針を採る。この方針はセルスワップ法と反復比例適合法（iterative proportional fitting procedure; IPFP）という、2 つの枯れた技術に倣ったものである。全体の方針はセルスワップ法に倣い、一度に少数属性の経験周辺分布だけを更新する点は一般化 IPFP に倣う。さらに、セルスワップが持つ「一属性周辺分布を厳密に保存する」という性質も再現する。この方針で多数の更新を一括して求めるために、本研究では追加・削除量を変数とする線形計画法を用いる。

本稿の貢献は次の三点である。

(1) 有限 DB の経験周辺分布を直接反復更新し、一属性周辺分布を厳密に保存しながら、低次元周辺分布を目標分布へ近づけるデータ合成フレームワークを示した。

(2) 一回の更新を混合整数線形計画問題として定式化し、全属性の同時分布を構築することなく更新量を求める方法を示した。また、最適化問題の実行可能性、一属性周辺分布の不変性、および選択した周辺分布の一段階改善性を示した。

(3) 実験評価により、一属性周辺分布を厳密に保存しつつ、二属性周辺分布と属性間相関を比較手法に匹敵し、条件によっては上回る精度で再現できることを確認した。

以下、第 3 節で問題設定とデータ合成の全体構成を示す。ここで本研究の理解のためにセルスワップ法と一般化 IPFP も紹介する。続いて第 4 節で提案手法を紹介し、第 5 節で実験評価を行い、第 6 節で関連研究を述べる。

2. 準備

2.1 記号と記法

本研究では、有限個の要素からなるデータベース (DB) を何度も更新する手法を考える。以下では、DB とその経験頻度、経験分布などの記号と記法を定める。

本稿で、DB とは複数要素からなる組 (tuple) の多重集合 (multiset) のことであり、組の要素のことを属性、要素のことをレコードと呼ぶ。

2.1.1 属性

属性数を d とし、属性を $A_1, \dots, A_d$ と表す。属性 j の有限な定義域を $\mathcal{A}_j$、完全レコードの定義域を $\mathcal{A}_{all} = \prod_{j=1}^{d} \mathcal{A}_j$ とする。更新対象となる属性添字集合の族を $\mathfrak{U}$ とする。

各 $U \in \mathfrak{U}$ は 2,3 属性程度の少数属性からなるものとする。この組が取りうる値の集合を $\mathcal{A}_U = \prod_{j \in U} \mathcal{A}_j$ とする。

U 以外の属性集合を $O = [d] \setminus U$ とし、レコードを $\boldsymbol{x} = (\boldsymbol{u}, \boldsymbol{o})$ と分ける。本稿が想定する応用では d が 20–100 程度であり、一回に扱う U は低次元である一方、O は多数の属性からなる状況を想定する。

2.1.2 DB

総レコード数を n とし、第 ℓ 回更新後のデータベースを $\mathcal{D}^{\ell} = (\boldsymbol{x}_1^{\ell}, \dots, \boldsymbol{x}_n^{\ell}) \in \mathcal{A}_{\text{all}}^n$ と表す。それぞれのレコードは d 属性を持つから、DB は n 行 d 列の表で表される。

2.1.3 経験頻度、経験分布

レコード値 $\boldsymbol{x} \in \mathcal{A}_{\text{all}}$ の経験頻度と経験分布を、それぞれ $\widehat{c}^{\ell}(\boldsymbol{x}) = \sum_{i=1}^{n} \mathbf{1}\{\boldsymbol{x}_i^{\ell} = \boldsymbol{x}\}$、$\widehat{p}^{\ell}(\boldsymbol{x}) = \widehat{c}^{\ell}(\boldsymbol{x})/n$ と定義する。

また、属性集合 $S \subseteq [d]$ と $\boldsymbol{s} \in \mathcal{A}_S$ について、経験周辺頻度と経験周辺分布を

$$\widehat{c}_S^{\ell}(\boldsymbol{s}) = \sum_{\boldsymbol{x}:\boldsymbol{x}_S = \boldsymbol{s}} \widehat{c}^{\ell}(\boldsymbol{x}), \tag{1}$$

$$\widehat{p}_S^{\ell}(\boldsymbol{s}) = \widehat{c}_S^{\ell}(\boldsymbol{s})/n \tag{2}$$

と定義する。特に、一属性 j の場合は、$\widehat{c}_j^{\ell} \coloneqq \widehat{c}_{\{j\}}^{\ell}, \widehat{p}_j^{\ell} \coloneqq \widehat{p}_{\{j\}}^{\ell}$ と略記する。

2.1.4 目標周辺分布

各 $U \in \mathfrak{U}$ について、目標周辺分布 $p_U^{\star}$ が与えられる。また、各一属性 j について目標周辺分布 $p_j^{\star}$ が与えられる。同じ属性に関する目標周辺が相互に整合していること、および総レコード数 n に対する目標一属性頻度 $np_j^{\star}(a)$ が整数であることを仮定する。差分プライバシーのため各周辺分布へ独立にノイズを加えた場合は、非負化、総和調整、重複周辺の整合化を本稿の処理より前に行う。

2.2 セルスワップ法

セルスワップとは、DB 中の 2 つのレコードが持つ同一属性の値同士を交換する操作のことである。操作前後の例を表 1 に示す。この操作を行うと、レコード数と一属性周

© 2026 Information Processing Society of Japan

セルスワップ前	↦	セルスワップ後
(東京都, 20 歳)	↦	(東京都, **30 歳**)
(北海道, 30 歳)	↦	(北海道, **20 歳**)

表 1 セルスワップの例。太字は交換されるセルを表す。

辺分布を初期状態から一切変えないまま、2 属性以上の周辺分布を変えることができる。匿名化の手法としてセルスワップを用いる研究は 1982 年からある [5]。

セルスワップを繰り返してデータ合成を行う方法を本稿ではセルスワップ法と呼ぶ。プライバシー保護技術と攻撃技術のコンペティション PWS Cup [14] では、しばしば参加者らによりセルスワップ法が用いられてきた。この手法は任意の損失関数に適用でき、高い柔軟性がある。しかし一回の操作で同時に二つのセルしか更新できず、多数のセル対について交換と損失評価を繰り返す必要があるため、高次元・大規模データでは計算時間が大きい。

2.3 一般化 IPFP

一般化 IPFP は、複数の少数属性周辺分布から全属性の同時分布を再構築する古典的な手法である [6, 4]。現在の同時分布を $p^\ell(u,o)$、属性組 U の目標周辺分布を $p^\star_U$ とすると、U に対する一回の更新は

$$p^{\ell+1}(u,o) = p^\ell(u,o)\frac{p^\star_U(u)}{p^\ell_U(u)} = p^\star_U(u)p^\ell(o \mid u)$$

で与えられる。この更新により U の周辺分布は $p^\star_U$ に一致する。一般化 IPFP は、この更新を複数の属性組について順に繰り返し、自然な条件の下で指定された周辺制約を満たす同時分布へ収束する [4]。つまり、全属性に同時に気を配らなくても、それぞれの周辺分布を順に改善することを繰り返せば、所望の同時分布が得られる。

一方、一般化 IPFP をデータ合成に直接用いるには、全属性の同時分布を保持・更新した後、そこから有限個のレコードを標本化する必要がある。高属性数では全同時分布の保持が困難であり、標本化誤差も生じる。本稿では一般化 IPFP の反復更新の考え方を利用しつつ、全同時分布を構築せず有限 DB を直接更新する。

3. 本研究のデータ合成フレームワーク

本研究では有限レコードからなる初期 DB から出発して、DB の 2 – 3 属性の経験周辺分布を目標分布へ近づけることを繰り返す、という方針を採る。全体の方針はセルスワップ法に倣い、一度に少数属性の経験周辺分布だけを更新する点は一般化 IPFP に倣う。さらに、セルスワップが持つ「一属性周辺分布を厳密に保存する」という性質も再現する。この方針で多数の更新を一括して求めるために、追加・削除量を変数とする線形計画法を用いる。これにより、セルスワップ法で行っていた更新を一括して行うことができる。

図 1 に処理全体を示す。

入力: 一属性目標分布 $p^\star_j$ ($j \in [d]$)、少数属性目標分布 $p^\star_U$ ($U \in \mathfrak{U}$)、総件数 n。

(I) 初期 DB $\mathcal{D}^0$ を生成

(II) 以下を終了条件を達成するまで ℓ を増やしながら繰り返す

- (II-1) 更新対象とする属性組 U を選び、現 DB $\mathcal{D}^\ell$ の経験周辺頻度 $\widehat{c}^\ell_U$ と経験周辺分布 $\widehat{p}^\ell_U$ を集計
- (II-2) 更新後の経験周辺分布 $\widehat{p}^{\ell+1}_U$ が目標周辺分布 $p^\star_U$ に近づくように、DB の更新内容を決定
- (II-3) 更新内容を DB $\mathcal{D}^\ell$ に適用し、適用後の DB を $\mathcal{D}^{\ell+1}$ とする

(III) 最終 DB を出力する。

図 1 反復更新によるデータ合成のフレームワーク

3.1 (I) 初期 DB

初期 DB $\mathcal{D}^0$ は、すべての属性 j (属性組ではなく単独の属性)について、目標一属性頻度と同じ頻度を持つ多重集合を各列に作り、列ごとに独立ランダム置換する。したがって初期 DB の期待経験同時分布は、積分布 $\mathbb{E}[\widehat{p}^0(x)] = \prod_{j=1}^d p^\star_j(x_j)$ に等しい。ただし、有限 DB の経験同時分布そのものは、一般にこの積分布と厳密には一致しない。このような初期 DB を作るには、例えば属性ごとに目標頻度と同じ値の多重集合を作り、各列を独立に並べ替えればよい。

3.2 (II-1) 属性組の選択と経験周辺分布の集計

属性組の選択は、最初に固定した順序に従う、誤差が最大の属性組を優先、または誤差と計算費用を組み合わせた選択などが考えられる。本稿では誤差 $\left\|\widehat{p}^\ell_U - p^\star_U\right\|_1$ が最大の属性組 U を選択している。経験周辺分布は定義通り計算するだけである。

3.3 (II-2) 周辺頻度の更新内容の決定

ここでは更新対象とする属性組 $U \in \mathfrak{U}$ を 1 つ選び、U の経験周辺分布 $\widehat{p}^\ell_U$ と目標分布 $p^\star_U$ から新しい経験周辺頻度 $\widehat{c}^{\ell+1}_U$ を作る。

本稿の手法では、各回の更新で $\widehat{c}^{\ell+1}_U$ を $p^\star_U$ へ徐々に近づける。更新レート $\sigma(\in (0,1])$ を自由に決められるパラメータとして、

$$p^\star_{U,\sigma,\ell} \coloneqq \sigma \cdot p^\star_U + (1-\sigma)\cdot \widehat{p}^\ell_U$$

とおく。そして、本稿では

$$\widehat{p}^{\ell+1}_U \approx p^\star_{U,\sigma,\ell}$$

となるように更新を行う。

本研究では、次の性質を満たす経験周辺頻度 $\widehat{c}^{\ell+1}_U$ を構成する。

© 2026 Information Processing Society of Japan

(1) 経験周辺分布 $\widehat{p}_U^{\ell+1}(:=\widehat{c}_U^{\ell+1}/n)$ は $p^{\star}_{U,\sigma,\ell}$ に近い。

(2) 更新前後ですべての一属性周辺頻度を変化させない。

(3) 更新前後で全レコード数 n を変化させない。

2つ目の条件は、更新対象に含まれる任意の $j \in U$ と $v \in \mathcal{A}_j$ について

$$\sum_{\boldsymbol{u}\in\mathcal{A}_U : u_j = v} \left(\widehat{c}_U^{\ell+1}(\boldsymbol{u}) - \widehat{c}_U^{\ell}(\boldsymbol{u})\right) = 0 \qquad (3)$$

と表せる。$j \notin U$ の属性値は DB 更新時に書き換えないため、その一属性周辺頻度も保存される。また、2つ目の条件から3つ目の条件も従う。

本研究の中で最も難しい問題は、この $\widehat{c}_U^{\ell+1}$ をどのように構成するかということである。この問題は4節で解説する。

3.4 生成 DB への更新内容の適用方法

更新量 $\boldsymbol{\delta}^{\ell} := \widehat{c}_U^{\ell+1} - \widehat{c}_U^{\ell}$ をとおく。さらに

$$\mathcal{V}_{U,-} = \{\boldsymbol{s} \in \mathcal{A}_U \mid \boldsymbol{\delta}^{\ell}[\boldsymbol{s}] < 0\},$$
$$\mathcal{V}_{U,+} = \{\boldsymbol{t} \in \mathcal{A}_U \mid \boldsymbol{\delta}^{\ell}[\boldsymbol{t}] > 0\}$$

とおく。属性組 U が取りうる値 $\boldsymbol{u} \in \mathcal{A}_U$ は、$\boldsymbol{u} \in \mathcal{V}_{U,-}$ なら減らさなければならないし、$\boldsymbol{u} \in \mathcal{V}_{U,+}$ なら増やさなければならない。

しかし、$\boldsymbol{\delta}^{\ell}$ だけでは属性組 $O(:=[d]\setminus U)$ がとる値を指定できないため、具体的にどのレコードを減らせば／増やせばいいのかは、まだ決まっていない。かといって属性組 O まで含めて追加・削除を決めると、一般化 IPFP 同様に全属性の同時分布を扱う必要が出てきてしまう。

本稿では書き換え元と書き換え先をランダムに選ぶことにする。それぞれの減らすべき値 $s \in \mathcal{V}_{U,-}$ について、現在 $U = s$ であるレコードのうち $|\boldsymbol{\delta}^{\ell}[s]|$ 個を一様ランダムに非復元抽出して配列に並べる。また、値 $t \in \mathcal{V}_{U,+}$ を $|\boldsymbol{\delta}^{\ell}[t]|$ 個含む、書き換え先の値の配列を構成する。$\sum_{\boldsymbol{u}\in\mathcal{A}_U} \boldsymbol{\delta}[\boldsymbol{u}] = 0$ であるから、これら2つの配列は同じ要素数を持つ。抽出されたレコードの配列と書き換え先の値の配列をそれぞれランダムシャッフルし、一対一に対応づける。対応づけられたレコード $\boldsymbol{x} = (\boldsymbol{s}, \boldsymbol{o})$ を $(\boldsymbol{t}, \boldsymbol{o})$ へ書き換える。属性組 $O = [d]\setminus U$ の値は変更しない。

この操作により、更新後の U 周辺頻度は $\widehat{c}_U^{\ell+1}$ と厳密に一致する。また、O の同時分布 $\widehat{p}_O^{\ell}(\boldsymbol{o})$ は更新前後で変わらない。一方、U と O の同時経験分布は変化しうる。

3.5 セルスワップ法および一般化 IPFP との関係

セルスワップは、交換という操作構造によって式 (3) を自動的に満たす。本稿の手法では、交換を一回ずつ探索する代わりに、式 (3) を明示的な制約として課し、多数の追加・削除を一括して求める。

また、確率的な DB 更新によって、DB 更新後の期待同時分布を、一般化 IPFP で更新した後の同時分布と一致させることもできる。この手法で生成される DB は、一般化 IPFP で構成される同時分布からサンプリングされたものと見ることができる。しかし、この方法では有限標本の変動が残るため、更新した属性組 U の分布でさえ目標分布と一致しない。

4. 線形計画法に基づくデータベース更新

本節では、一属性周辺分布を保存する更新空間の中から、対象 U の周辺誤差を最も大きく削減する更新量を求める。提案方式は、全属性同時分布を構築せず、有限な属性組の状態空間上で問題を解く。

4.1 一属性周辺分布を保存する条件

最初に記号を定義する。$\widehat{c}_U^{\ell}$ の要素を並べたベクトル $(\widehat{c}^{\ell}(\boldsymbol{u}))_{\boldsymbol{u}\in\mathcal{A}_U}$ を同じ記号 $\widehat{c}_U^{\ell}$ で表すことにする。経験周辺頻度 $\widehat{c}_U^{\ell}$ から一属性周辺頻度を計算する行列 $M_{U,j}^{\mathrm{1mar}}$ を定義する。行を $v \in \mathcal{A}_j$、列を $\boldsymbol{u} \in \mathcal{A}_U$ とし、

$$(M_{U,j}^{\mathrm{1mar}})_{v,\boldsymbol{u}} = \mathbf{1}\{\boldsymbol{u}_j = v\} \qquad (4)$$

とする。なお、属性組 U に含まれない属性 $j \in O$ の値は、DB 更新の中で一切書き換えられない。

したがって、更新前後ですべての一属性周辺頻度 $\widehat{c}_j^{\ell}$ を変化させないという条件は、すべての一属性 $j \in U$ について

$$M_{U,j}^{\mathrm{1mar}}\widehat{c}_U^{\ell+1} = M_{U,j}^{\mathrm{1mar}}\widehat{c}_U^{\ell} \qquad (5)$$

と表現できる。

4.2 ノルム最小化問題としての定式化

以下では更新後の経験周辺頻度 $\widehat{c}_U^{\ell+1}$ を $np^{\star}_{U,\sigma,\ell}$ へ近づけることを考える。先述の 3.3 節で述べた条件を最適化問題として定式化すると、以下のようになる。ここでは分布の距離をベクトルとしての L1 ノルムで測ることにした。

$$\underset{\widehat{c}_U^{\ell+1}}{\text{minimize}} \quad \left\|\widehat{c}_U^{\ell+1} - np^{\star}_{U,\sigma,\ell}\right\|_1 \qquad (6)$$

$$\text{subject to} \quad \forall \boldsymbol{u} \in \mathcal{A}_U,\ \widehat{c}_U^{\ell+1}(\boldsymbol{u}) \in \mathbb{Z}_{\geq 0} \qquad (7)$$

$$\forall j \in U,\ M_{U,j}^{\mathrm{1mar}}\widehat{c}_U^{\ell+1} = M_{U,j}^{\mathrm{1mar}}\widehat{c}_U^{\ell} \qquad (8)$$

制約条件 (7) は $\widehat{c}_U^{\ell+1}$ の成分が非負整数であることを、したがって頻度であることを意味している。制約条件 (8) は、1次元周辺頻度が初期 DB から変化しないことを意味している。この条件から、全体のレコード数が初期 DB のレコード数 n から変化しないことも示される。

この最適化問題は、実数値ベクトルに距離が近い整数値ベクトルを見つける問題である。そのため、この最適化問題は、制約付きの整数への丸めと解釈することもできる。

© 2026 Information Processing Society of Japan

4.3 混合整数線形計画問題への帰着

分布間の距離を L1 ノルムで定めたので、この最適化問題は混合整数線形計画に帰着できる。これには追加の実数変数 $\boldsymbol{\rho}^+, \boldsymbol{\rho}^-$（いわゆる slack 変数）を導入し、以下のようにすればよい。

$$\begin{aligned}
\underset{\widehat{c}_U^{\ell+1}, \boldsymbol{\rho}^+, \boldsymbol{\rho}^-}{\text{minimize}} \quad & \sum_{\boldsymbol{u} \in \mathcal{A}_U} \left(\boldsymbol{\rho}^+(\boldsymbol{u}) + \boldsymbol{\rho}^-(\boldsymbol{u})\right) && (9)\\
\text{subject to} \quad & \forall \boldsymbol{u} \in \mathcal{A}_U,\ \widehat{c}_U^{\ell+1}(\boldsymbol{u}) \in \mathbb{Z}_{\geq 0}, && (7)\\
& \forall \boldsymbol{u} \in \mathcal{A}_U,\ \boldsymbol{\rho}^+(\boldsymbol{u}), \boldsymbol{\rho}^-(\boldsymbol{u}) \in \mathbb{R}_{\geq 0} && (10)\\
& \widehat{c}_U^{\ell+1} - n p^\star_{U,\sigma,\ell} = \boldsymbol{\rho}^+ - \boldsymbol{\rho}^- && (11)\\
& \forall j \in U,\ M^{1\mathrm{mar}}_{U,j} \widehat{c}_U^{\ell+1} = M^{1\mathrm{mar}}_{U,j} \widehat{c}_U^{\ell}. && (8)
\end{aligned}$$

制約 (10), (11) から、追加した実変数は、最適解では次を満たす。

$$\boldsymbol{\rho}^+ = \left[\widehat{c}_U^{\ell+1} - n p^\star_{U,\sigma,\ell}\right]_+, \quad \boldsymbol{\rho}^- = \left[-(\widehat{c}_U^{\ell+1} - n p^\star_{U,\sigma,\ell})\right]_+$$

この混合整数線形計画の最適解 $\widehat{c}_U^{\ell+1}$ が前節の最適化問題の解と一致することは明らかである。

4.4 全体アルゴリズム

図 2 に提案方式 TableForge-LP [*1]の全体手順を示す。一回の更新は選択した U の誤差を増加させず、他の属性組 $O(= [d] \setminus U)$ の周辺分布と、すべての一属性周辺分布を保存する。複数の U に対して順に更新を適用する。

入力：一属性目標分布 $p^\star_j$、少数属性目標分布 $p^\star_U (U \in \mathfrak{U})$、総件数 n、更新係数 $\sigma \in (0, 1]$。

(I) 一属性目標頻度を正確に持つ $\mathcal{D}^0$ を生成する。

(II) 停止条件を満たすまで次を繰り返す。

- (II-1) 更新対象とする属性組 U を選び、現 DB $\mathcal{D}^\ell$ の経験周辺頻度 $\widehat{c}_U^\ell$ と経験周辺分布 $\widehat{p}_U^\ell$ を集計
- (II-2) 更新後の経験周辺分布 $\widehat{p}_U^{\ell+1}$ が目標周辺分布 $p^\star_U$ に近づくように、DB の更新内容を決定。
- (II-3) 更新量を整数レコード操作へ変換し、$\mathcal{D}^{\ell+1}$ を得る。

(III) 最終 DB を出力する。

図 2 線形計画方式によるデータ合成アルゴリズム

4.5 基本的性質

命題 1 (最適化問題の実行可能性)**.** 任意の反復 ℓ および属性組 $U \in \mathfrak{U}$ に対し、更新前の周辺頻度 $\widehat{c}_U^\ell$ は、最適化問題 (6)–(8) の実行可能解である。したがって、この最適化問題は常に実行可能であり、最適解が存在する。□

命題 2 (周辺分布の不変性)**.** 任意の反復 ℓ および属性 $j \in [d]$ について $\widehat{p}_j^\ell = \widehat{p}_j^0$ が成立する。さらに、第 ℓ 回の反復で更新する属性組を U とし、$O := [d] \setminus U$ とする。このとき $\widehat{p}_O^{\ell+1} = \widehat{p}_O^\ell$ が成立する。□

命題 3 (選択された対象周辺の一段階改善性)**.** 第 ℓ 回の反復で属性組 $U \in \mathfrak{U}$ を選択し、最適化問題 (6)–(8) の最適解を $\widehat{c}_U^{\ell+1}$ とする。このとき、

$$\left\|\widehat{p}_U^{\ell+1} - p^\star_U\right\|_1 \leq \left\|\widehat{p}_U^{\ell} - p^\star_U\right\|_1$$

が成立する。□

証明. 命題 1 より、更新前の周辺頻度 $\widehat{c}_U^\ell$ は最適化問題の実行可能解である。したがって、$\widehat{c}_U^{\ell+1}$ の最適性から

$$\left\|\widehat{c}_U^{\ell+1} - n p^\star_{U,\sigma,\ell}\right\|_1 \leq \left\|\widehat{c}_U^{\ell} - n p^\star_{U,\sigma,\ell}\right\|_1. \tag{12}$$

ここで、$\widehat{c}_U^\ell = n\widehat{p}_U^\ell$ および $p^\star_{U,\sigma,\ell} = \sigma p^\star_U + (1-\sigma)\widehat{p}_U^\ell$ より、

$$\left\|\widehat{c}_U^{\ell} - n p^\star_{U,\sigma,\ell}\right\|_1 = n\sigma \left\|\widehat{p}_U^{\ell} - p^\star_U\right\|_1. \tag{13}$$

$$\left\|n p^\star_{U,\sigma,\ell} - n p^\star_U\right\|_1 = n(1-\sigma) \left\|\widehat{p}_U^{\ell} - p^\star_U\right\|_1. \tag{14}$$

三角不等式と式 (12)–(14) から、

$$\begin{aligned}
& n \left\|\widehat{p}_U^{\ell+1} - p^\star_U\right\|_1 \\
&= \left\|\widehat{c}_U^{\ell+1} - n p^\star_U\right\|_1 \\
&\leq \left\|\widehat{c}_U^{\ell+1} - n p^\star_{U,\sigma,\ell}\right\|_1 + \left\|n p^\star_{U,\sigma,\ell} - n p^\star_U\right\|_1 \\
&\leq n\sigma \left\|\widehat{p}_U^{\ell} - p^\star_U\right\|_1 + n(1-\sigma) \left\|\widehat{p}_U^{\ell} - p^\star_U\right\|_1 \\
&= n \left\|\widehat{p}_U^{\ell} - p^\star_U\right\|_1. \qquad (15)
\end{aligned}$$

両辺を n で割れば、主張を得る。□

命題 3 が保証するのは、第 ℓ 回に選択された属性組 U について、その一回の更新前後で誤差が増加しないことまでである。反復全体の収束については後述する。

4.6 安全性について

本手法では元 DB そのものではなく、その低次元周辺分布を用いて DB を合成する。したがって、安全性を考える上では、用いる周辺分布から元 DB 中の完全レコードに関する情報をどの程度推定できるかが重要となる。完全レコード $\boldsymbol{x}$ の元 DB 中の出現数を $n_{\mathcal{D}}(\boldsymbol{x})$ とする。$n_{\mathcal{D}}(\boldsymbol{x}) \geq 1$ を高い確度で推定できれば所属推定に、$n_{\mathcal{D}}(\boldsymbol{x}) = 1$ を高い確度で推定できれば、外部情報との照合による個人識別につながりうる。

周辺分布を差分プライバシーを満たす方法で取得すれば、個々のレコードの有無に対する形式的な保護を与えられる。

一方、周辺分布を決定論的に取得する場合でも、攻撃者が利用できる情報をそれらの周辺分布に限定すれば、$n_{\mathcal{D}}(\boldsymbol{x})$ をどの程度推定できるかによって安全性を評価できる。例えば、周辺分布と整合する DB に対する確率モデルを仮

[*1] 末尾の “LP”は linear programming の略である。

© 2026 Information Processing Society of Japan

定すれば、$n_{\mathcal{D}}(\boldsymbol{x})$ の確率分布を求め、$n_{\mathcal{D}}(\boldsymbol{x}) = 1$ または $n_{\mathcal{D}}(\boldsymbol{x}) \geq 1$ となる確率を評価できる。確率モデルを仮定しない場合でも、$n_{\mathcal{D}}(\boldsymbol{x})$ の上限と下限を通じて $n_{\mathcal{D}}(\boldsymbol{x})$ の推定可能性を考えることができる。与えられた周辺分布と整合するすべての DB $\mathcal{D}'$ についての min と max

$$L(\boldsymbol{x}) = \min_{\mathcal{D}'} n_{\mathcal{D}'}(\boldsymbol{x}), \qquad U(\boldsymbol{x}) = \max_{\mathcal{D}'} n_{\mathcal{D}'}(\boldsymbol{x}) \tag{16}$$

とおく。これらは周辺頻度を制約とする整数線形計画問題として求められる。そのうえで、$1 \in [L(\boldsymbol{x}), U(\boldsymbol{x})]$ かどうかと、この区間の広さを考えれば良い。DB の再構築攻撃 [1] も参考になるだろう。

4.7 本手法の限界と拡張

本手法にはいくつかの限界がある。第一に、反復全体の収束は保証されない。命題 3 が保証するのは、選択された属性組 U について一回の更新で誤差が増加しないことだけである。U と属性を共有する別の属性組 $V \in \mathfrak{U}$ に対する更新は U の周辺分布を再び変化させうるため、複数の属性組を反復して更新した場合の収束は一般には保証されない。このため、属性組の選択順序や更新係数 σ によって最終状態が変化しうる。

第二に、一回の更新では線形計画問題を解く必要がある。属性組 U の状態数が増えると最適化問題も大きくなるため、属性のカテゴリ数が大きい場合には計算量が増加する。

これらに対して、初期 DB の生成方法、属性組の選択規則、更新係数 σ の制御、および最適化問題の縮約や高速化は今後検討すべき拡張である。

5. 評価

本節では、提案手法の一属性・二属性周辺分布の再現精度、属性間相関と分類性能の再現性、および実行時間を既存手法と比較する。

5.1 データセットと比較方式

実験には Adult [7] と MovieLens32M-Disney20 [8] を用いた。表 2 にデータセットの概要を示す。

Adult は、公開されている訓練データ 32,561 レコードから欠損値?を含むレコードを削除した 30,162 レコードからなる。数値属性は等頻度分割を基本として最大 19 個のカテゴリに離散化して扱った。

MovieLens32M-Disney20 は、公開データセット MovieLens32M から、データセット作成時点の 2023 年 10 月における Disney 配給映画のうち、興行収入上位 20 作品に対応する 10 段階評価+無評価を抽出して作成したデータセットである。以下では MovieLens32M-Disney20 を ML-D20 と略記する。

比較手法には PrivSyn [12] と AIM [10] を用いた。前者は本手法と同じく DB の更新を繰り返す手法、後者は参考にしたベンチマーク論文 [11] で最も全体的な評価が高かった手法である。PrivSyn は論文に基づく自前実装、AIM は公開実装を用いた。

表 2 データセットの概要。カテゴリ属性数はクラスラベルを含む。

データ	レコード数 n	属性数 d	カテゴリ属性数	数値属性数	分類ラベル
Adult	30,162	15	9	6	有
ML-D20	26,607	20	20	0	無

提案手法 TableForge-LP （以下 TF-LP）は更新係数 $\sigma = 0.5$ と $\sigma = 1.0$ の両方を評価した。全手法で入力 DB と同じレコード数を生成し、本実験ではノイズを含まない場合の再現能力を比較するため、差分プライバシーのためのノイズ付与を無効化した。

実験機の CPU は Intel Core i7-13700（最大 5.20GHz）、メモリは 24 GB であった。

5.1.1 離散化変換と逆変換の実装

Adult の数値属性は、最大 19 個のカテゴリに変換した。ユニーク値数が 19 以下の属性は各値をそのままカテゴリ値とする。それ以外では、頻出値を単独カテゴリとして切り出した後、残りを Python ライブラリ `scikit-learn` の `KBinsDiscretizer` で等頻度分割した。

比較手法のいずれでも逆変換の実装は同じである。生成後に各カテゴリへ対応する元データ値の最小値と最大値を求め、その区間から一様に値をサンプリングして数値属性に変換した。整数属性では、最小値以上、最大値以下の整数から一様にサンプリングした。

5.2 評価指標

評価指標は Tao らのベンチマーク [11] を参考に、一属性 TVD、二属性 TVD、相関レベル一致率 CorAcc、macro-F1、および実行時間を用いる。

一属性周辺分布の誤差を

$$E_{\text{1way}} = \frac{1}{|\mathcal{J}_{\text{cat}}|} \sum_{j \in \mathcal{J}_{\text{cat}}} D_{\text{TV}}\big(\widehat{p}_j, p^{\star}_j\big) \tag{17}$$

とする。ここで $\mathcal{J}_{\text{cat}}$ はカテゴリ属性の集合である。TF-LP は一属性周辺頻度を保存するため、$E_{\text{1way}} = 0$ となる。

二属性周辺分布の誤差を

$$E_{\text{2way}} = \frac{1}{|\mathfrak{U}|} \sum_{U \in \mathfrak{U}} D_{\text{TV}}(\widehat{p}_U, p^{\star}_U) \tag{18}$$

とする。ここで $\mathfrak{U}$ は全二属性組の集合であり、数値属性は離散化して評価する。

CorAcc は Tao ら [11] に従い、カテゴリ属性対についてバイアス補正付き Cramér's V [2] を $[0, 0.1)$、$[0.1, 0.3)$、$[0.3, 0.5)$、0.5 以上の 4 段階に量子化し、元 DB と生成 DB で同じ段階となった属性対の割合とする。分類性能は、Adult のカテゴリ属性を説明変数として生成 DB で XGBoost を学習し、元 DB 上で評価した macro-F1 で測る。ML-D20

© 2026 Information Processing Society of Japan

はクラスラベルを持たないため、macro-F1 は評価しない。実行時間には合成処理に要した時間を用いる。

各設定を 5 回試行し、その平均を報告する。また、有限標本化による誤差の大きさを比較するため、元 DB から同じレコード数を復元抽出した Bootstrap 標本を各データセットについて 5 個作成し、元 DB との誤差を測定した。表 3 の括弧内には、各指標を誤差に変換した上で、Bootstrap 標本の平均誤差に対する比を示す。TVD では指標値そのもの、CorAcc では $1 - \mathrm{CorAcc}$ を誤差とする。macro-F1 では、元 DB で学習・評価した値 $F_{1,\mathrm{real}} = 0.7872$ からの低下量を誤差とする。したがって macro-F1 の相対誤差は $\frac{F_{1,\mathrm{real}} - F_1}{F_{1,\mathrm{real}} - F_{1,\mathrm{bootstrap}}}$ で定義される。なお、Bootstrap は標本化誤差の参照値であり、達成可能な誤差の下限を意味しない。

5.3 実験結果

表 3 に実験結果を示す。

Adult では、TF-LP は一属性 TVD を 0 に保った。二属性 TVD はいずれの合成手法も Bootstrap 標本の ×1.26–×1.55 であり、手法間の差は比較的小さい。CorAcc も各手法で近い値となった一方、macro-F1 では TF-LP が PrivSyn と AIM をやや下回った。

ML-D20 では、TF-LP は一属性 TVD を 0 に保ち、二属性 TVD も Bootstrap 標本の ×0.92–×1.01 となった。これに対して PrivSyn と AIM の二属性 TVD は約 ×2.3 であり、TF-LP との差が明確に現れた。CorAcc でも TF-LP は PrivSyn と同程度であり、AIM を大きく上回った。なお、AIM のモデルサイズを大きくして追加実験したもの[*2] 、AIM の CorAcc は変化せず、実行時間が長くなるだけだった。

以上から、周辺分布と属性間相関の再現性について、TF-LP は比較手法より良いか同程度の性能を示した。一方、TF-LP の実行時間は両データセットで比較手法より長くなった。この実行時間の大部分はレコードの編集にかかった時間であり、今後は実装の改善が必要である。なお、本実験では統計的有意差検定を行っておらず、表中の順位は 5 試行の平均値に基づく。

参考として、筆者が PWS Cup 2025 にて TF-LP で合成したデータを提出し、攻撃を受けた結果を報告する。このとき、XGBoost モデルと合わせて提出し、10 万件のデータから、実際にデータ合成とモデル学習に用いた 1 万件を見つける攻撃を、21 チームから受けた。ランダムな攻撃であれば正答率は 10% であるが、平均正答率は 10.487% であった。攻撃者による選択を非心超幾何分布でモデル化してパラメータをベイズ推定したところ、正解レコードは不正解レコードに比べて 1.049–1.072 倍（95%信用区間）選択されやすいという結果になった。このとき、経験周辺分布にはノイズ付加などの加工を加えていない。

[*2] AIM のパラメータを $\texttt{max_model_size} = 320, \texttt{max_cells} = 20000$ に変更して実験した。それぞれ、表中の実験で用いたパラメータの 4 倍と 2 倍である。

6. 関連研究

MST は、低次元周辺を選択・測定し、Private-PGM で合成データを生成する一般的な枠組みを示した [9]。PrivSyn は多数の低次元周辺分布を用い、高属性数の表データを対象とする [12]。AIM は、現在の推定誤差に基づいて有用な周辺を反復的に選択する [10]。これらは低次元周辺分布が表形式データの有用性を保持する重要な表現であることを示している。本稿は、推定した生成分布から標本化するのではなく、有限 DB の経験周辺を直接更新し、一属性周辺を厳密に固定する点で異なる。

データスワップは、レコード間で値を交換し、選択した統計量を保存しながら開示リスクを制御する手法である [5]。本稿で比較するセルスワップは、一属性周辺を保存する局所更新として利用する。提案方式は、同じ保存条件を線形等式として表し、多数の更新を一括して求める。

データセット蒸留では、大規模な元データを少数の合成データへ置き換えることを目的とし、分布一致型手法は特徴空間における元データと合成データの分布差を直接最小化する [13]。本稿も有限データ集合の経験分布を直接最適化する点で近いが、必ずしも元データより少ない合成データを作ることに限定していない。

7. おわりに

本稿では、有限 DB の経験周辺分布そのものを目標分布に近づける表形式データ合成手法 TableForge-LP を提案した。提案手法は、一属性周辺分布を保存する制約の下で、選択した少数属性周辺分布の誤差を小さくする更新量を線形計画法により求め、その更新を DB へ直接適用する。これにより、全属性の同時分布を明示的に構築することなく、一属性周辺分布を厳密に保存しながら低次元周辺分布を改善できる。

実験では、TF-LP は両データセットで一属性 TVD を 0 に保った。Adult では二属性 TVD と CorAcc について比較手法と大きな差のない性能を示し、ML-D20 では二属性 TVD を Bootstrap 標本による標本化誤差と同程度まで抑え、PrivSyn および AIM を上回った。一方、Adult の macro-F1 は比較手法をやや下回り、実行時間は両データセットで比較手法より長かった。

今後は、線形計画問題の求解を含む計算時間の短縮に加え、初期 DB や属性組の更新順序への依存性、および反復全体の収束性について検討する。また、差分プライバシーなどによって得られるノイズを含む周辺分布を対象とした場合の性能と安全性についても評価する必要がある。

© 2026 Information Processing Society of Japan

表 3 実験結果。値は 5 試行の平均であり、括弧内は Bootstrap 標本の誤差との相対誤差である。相対誤差が ×1.00 なら Bootstrap 標本と同程度の誤差、×1.00 未満ならより小さい誤差、×1.00 より大きければより大きい誤差を意味する。太字は合成手法中の最良値、下線は次点を表す。

手法	1 属性 TVD↓	2 属性 TVD↓	CorAcc↑	macro-F1↑	実行時間 [s]↓
Adult					
Bootstrap	0.00383 (×1.00)	0.00926 (×1.00)	0.9722 (×1.00)	0.7772 (×1.00)	–
TF-LP ($\sigma = 1.0$)	**0.00000 (×0.00)**	0.01289 (×1.39)	0.9222 (×2.80)	0.7134 (×7.38)	10225
TF-LP ($\sigma = 0.5$)	**0.00000 (×0.00)**	0.01224 (×1.32)	0.9333 (×2.40)	0.7210 (×6.62)	14132
PrivSyn	0.00341 (×0.89)	0.01431 (×1.55)	0.9222 (×2.80)	0.7330 (×5.42)	1579
AIM	0.00138 (×0.36)	**0.01169 (×1.26)**	**0.9389 (×2.20)**	**0.7398 (×4.74)**	**631**
ML-D20					
Bootstrap	0.01783 (×1.00)	0.01249 (×1.00)	0.8884 (×1.00)	–	–
TF-LP ($\sigma = 1.0$)	**0.00000 (×0.00)**	0.01264 (×1.01)	**0.8358 (×1.47)**	–	7291
TF-LP ($\sigma = 0.5$)	**0.00000 (×0.00)**	**0.01143 (×0.92)**	0.8147 (×1.66)	–	7204
PrivSyn	0.01842 (×1.03)	0.02940 (×2.35)	0.8274 (×1.55)	–	3543
AIM	0.00508 (×0.28)	0.02857 (×2.29)	0.3863 (×5.50)	–	**2581**

参考文献

[1] John M. Abowd et al. *A Simulated Reconstruction and Reidentification Attack on the 2010 U.S. Census: Full Technical Report*. Working Paper 31995. National Bureau of Economic Research, 2023. DOI: 10.3386/w31995.

[2] Wicher Bergsma. "A Bias-Correction for Cramér's V and Tschuprow's T". In: *Journal of the Korean Statistical Society* 42.3 (Sept. 1, 2013), pp. 323–328. DOI: 10.1016/j.jkss.2012.10.002.

[3] Kai Chen et al. "Benchmarking Differentially Private Tabular Data Synthesis: [Experiments & Analysis]". In: *Proceedings of the ACM on Management of Data* 3.6 (Dec. 4, 2025), pp. 1–25. DOI: 10.1145/3769764.

[4] Imre Csiszár. "I-Divergence Geometry of Probability Distributions and Minimization Problems". In: *The Annals of Probability* 3.1 (1975), pp. 146–158. DOI: 10.1214/aop/1176996454.

[5] Tore Dalenius and Steven P. Reiss. "Data-Swapping: A Technique for Disclosure Control". In: *Journal of Statistical Planning and Inference* 6.1 (1982), pp. 73–85. DOI: 10.1016/0378-3758(82)90058-1.

[6] W. Edwards Deming and Frederick F. Stephan. "On a Least Squares Adjustment of a Sampled Frequency Table When the Expected Marginal Totals Are Known". In: *The Annals of Mathematical Statistics* 11.4 (1940), pp. 427–444. DOI: 10.1214/aoms/1177731829.

[7] Dheeru Dua and Casey Graff. *UCI Machine Learning Repository: Adult Data Set*. University of California, Irvine, School of Information and Computer Sciences, 2017. URL: http://archive.ics.uci.edu/ml/datasets/adult.

[8] F. Maxwell Harper and Joseph A. Konstan. "The MovieLens Datasets: History and Context". In: *ACM Transactions on Interactive Intelligent Systems* 5.4 (2015). DOI: 10.1145/2827872.

[9] Ryan McKenna, Gerome Miklau, and Daniel Sheldon. "Winning the NIST Contest: A Scalable and General Approach to Differentially Private Synthetic Data". In: *Journal of Privacy and Confidentiality* 11.3 (3 Dec. 24, 2021). DOI: 10.29012/jpc.778.

[10] Ryan McKenna et al. "AIM: An Adaptive and Iterative Mechanism for Differentially Private Synthetic Data". In: *Proc. VLDB Endow.* 15.11 (July 1, 2022), pp. 2599–2612. DOI: 10.14778/3551793.3551817.

[11] Yuchao Tao et al. *Benchmarking Differentially Private Synthetic Data Generation Algorithms*. Feb. 15, 2022. DOI: 10.48550/arXiv.2112.09238. arXiv: 2112.09238 [cs]. Pre-published.

[12] Zhikun Zhang et al. "PrivSyn: Differentially Private Data Synthesis". In: 30th USENIX Security Symposium (USENIX Security 21). 2021, pp. 929–946. ISBN: 978-1-939133-24-3. URL: https://www.usenix.org/conference/usenixsecurity21/presentation/zhang-zhikun (visited on 06/07/2022).

[13] Bo Zhao and Hakan Bilen. "Dataset Condensation with Distribution Matching". In: *2023 IEEE/CVF Winter Conference on Applications of Computer Vision (WACV)*. IEEE, 2023, pp. 6503–6512. DOI: 10.1109/WACV56688.2023.00645.

[14] 秀暢 小栗 et al. "個人データの保護と流通を目的とする匿名化と再識別コンテスト：PWS Cup". In: **デジタルプラクティス** 9.3 (2018), pp. 659–684. URL: https://ipsj.ixsq.nii.ac.jp/records/190387.

© 2026 Information Processing Society of Japan