外部知識としてLLMを用いた属性推論攻撃による匿名化・合成データの個人別リスク評価

田中 康平[1,2,a)]　小野 元[3,2,b)]　南 和宏[4]

概要：匿名化や合成データによるミクロデータ公開は，推論攻撃への耐性の経験的評価によって監査される．事前知識の見積りが難しいため，攻撃者はリリースと対象の準識別子だけを持つと仮定されてきた．大規模言語モデル（LLM）は人口統計上の属性間の関連を広く学習した，誰でも安価に使える外部知識であり，この仮定の外にある．本稿は攻撃者の事前知識を LLM で実体化し，公開されたリリースだけで実行できる監査として，属性推論の成功度を対象ごとに測る．米国センサス ACS を母集団とし，k 匿名化 2 手法と合成データ 5 手法による 23 通りのリリースに対し，LLM 単独，リリースで学習した攻撃者，両者の統合の三条件を所得 12 階級上の真値確率で比較した．LLM 単独はリリースを一切受け取らずにランダム推測（8.33%）を上回る（11.46%）が，準識別子をすべて条件づけた攻撃者の 16.85%には届かなかった．匿名化されたリリースの下では LLM 単独がリリースで学習した攻撃者を上回り，統合が LLM 単独に届かないリリースが 23 通り中 12 通りある．LLM の知識は準識別子の希少さに対して平坦で，k 匿名化が強く働く軸とは一致しない．

キーワード：匿名データ、合成データ、攻撃者知識、大規模言語モデル

Individual-Level Risk Assessment of Anonymized and Synthetic Data via Attribute Inference Attacks Using LLMs as Auxiliary Knowledge

Kohei Tanaka[1,2,a)]　Hajime Ono[3,2,b)]　Kazuhiro Minami[4]

Abstract: The privacy of microdata released through anonymization or synthetic data generation is audited by empirically evaluating its resistance to inference attacks. Because an adversary's prior knowledge is hard to estimate, the adversary has been assumed to hold only the release and the target's quasi-identifiers. Large language models (LLMs) are external knowledge that anyone can obtain cheaply, which places them outside that assumption. We instantiate the adversary's prior knowledge with an LLM and measure attribute inference success target by target, as an audit that can be run from the released data alone. Using the American Community Survey, we compare three conditions (the LLM alone, an adversary trained on the release, and the two combined) by the probability placed on the true one of twelve income bands, over 23 releases from two k-anonymization methods and five synthetic data generators. Receiving no release at all, the LLM alone exceeds random guessing (11.5% against 8.3%) but does not reach the 16.9% attainable by conditioning on the quasi-identifiers. Under anonymized releases the LLM alone outperforms the adversary trained on the release, and in 12 of the 23 releases the combination falls below the LLM alone. The LLM's knowledge is flat in the rarity of quasi-identifiers, the very axis along which k-anonymization acts.

Keywords: Anonymized data, synthetic data, adversaries' knowledge, large language models

[1] 東京都立大学
Tokyo Metropolitan University
[2] 情報・システム研究機構データサイエンス共同利用基盤施設
Research Organization of Information and Systems Joint Support-Center for Data Science Research
[3] 金沢大学
Kanazawa University
[4] 情報・システム研究機構

© 2026 Information Processing Society of Japan

This paper is work in progress and not peer-reviewed.

1. はじめに

匿名データや合成データは，プライバシ保護，有用性，アクセス性のバランスをとりながら機微なデータを利活用するアプローチとして期待されている．本論文ではこれらを総じてリリースと呼ぶ．

リリースが実際にどの程度開示リスクを制御できているかを評価する方法の 1 つは，攻撃アルゴリズムで攻撃するレッドチーミング評価 [3], [19] であり，その攻撃の 1 つに**属性推論攻撃**（Attribute Inference Attack, *AIA*） [19], [24] がある．レッドチーミング評価においては，攻撃者をどう設計するかが評価結果を決める．攻撃者の事前知識を現実的に見積もることは難しいため，実務上は「公開されたリリースと，攻撃対象の準識別子だけを持つ攻撃者」という仮定が採られてきた [5], [21]．この仮定のもとでは，攻撃の成功率はリリースの危険度の指標と解釈できる．

大規模言語モデル（LLM）は人口統計上の属性間の関連を広く学習しており，誰でも安価に利用できる外部知識となったため，この仮定はもはや成り立たない．LLM による属性推論の研究はこの知識のみで機微属性が推論できることを示した [18] が，報告は集計精度に留まり，個人ごとのリスクを示さない．一方，リリースに対する攻撃監査はリスクを個人単位で分解する枠組みを持つが，攻撃者は LLM を持たない．両者の間には，攻撃者の事前知識をどこから供給するかという問いが空いたままになっている．

本稿の問いは，攻撃者に母集団の外からの知識を供給したとき，リリースの監査が見積もる個人ごとのリスクがどこまで動くか，である．これを三つに分けて測る．第一に，LLM はどのような個人について正確な知識を持つのか．第二に，その知識は，準識別子から到達しうる水準を超えるのか．第三に，リリースを渡したとき，事前知識はどれだけ寄与するのか．

本稿は，攻撃者の事前知識 $\mathcal{P}$ を LLM で実体化し（3 章），公開されたリリースだけから実行できる監査としてこの三つを測る．答えは順に，LLM の知識は準識別子の希少さに対してほぼ平坦であること（4.3 節），準識別子から到達しうる水準を 666 セルのほぼすべてで超えないこと（4.4 節），そしてリリースが情報を失うほど事前知識の寄与が相対的に大きくなること（4.5 節）である．

2. 準備・関連研究

2.1 匿名データ

個票データの各行は個人に対応し，各列は属性である．属性は，氏名や識別番号のように個人を直接指す**直接識別子**，単独では個人を指さないが組み合わせによって個人を絞り込みうる**準識別子**，そして守りたい**秘密属性**に分けて扱われる．

k 匿名化 [20] は，準識別子の値を粗くする**一般化**と，行や値を伏せる**抑圧**によって，同じ準識別子の値を持つ行が必ず k 件以上そろうようにする．このまとまりを**等価クラス**と呼ぶ．希少な組み合わせほど大きく粗くされるため，k 匿名化が働くのは準識別子の希少さの軸の上である．等価クラスの中で秘密属性の値がそろっていると個人を特定しなくても値が分かってしまうため，等価クラス内の多様性を要求する l 多様性 [12] や，全体の分布との近さを要求する t 近接性 [11] が提案されている．

本稿が監査の対象とする匿名化は 2 手法である．Mondrian [10] は準識別子の空間を多次元に再帰的に分割し，各領域を等価クラスとする．Flash [9] は，属性ごとの粗さの組み合わせがなす束の上を全域的に探索し，品質の損失が最小の解を求める．

2.2 合成データ

合成データは，参照データに生成モデルを当てはめ，そのモデルから新たに標本を引いて作る．出力の各行は元の個人と 1 対 1 に対応しない．この対応の無さは合成データの安全性の根拠として語られてきたが，Hittmeir ら [5] はこれを検証すべき前提として扱い，属性開示のリスクを分類問題として測り直している．

生成の手法は大きく二つの系統に分けられる [2]．一つは**周辺分布ベース**の系統で，属性間の依存に応じて選んだ周辺分布に雑音を加えて測り，それまでに測った周辺分布から標本を引く．PrivBayes [25] は相互情報量に基づいて貪欲にベイジアンネットワークを選び，MST [13] は相互情報量を重みとするグラフの最大全域木を取って Private-PGM [15] で生成し，AIM [14] は周辺分布の選び方を適応的にする．もう一つは**深層生成モデル**の系統で，本稿では，判別器を教師集団の予測の集約で置き換える PATE-GAN [7] と，変分自己符号化器で表形式データの分布をモデル化する TVAE [23] を用いる．いずれの系統でも，差分プライバシーのパラメータ ε が保護の強さのつまみになる．

2.3 属性推論攻撃

属性推論攻撃（AIA）は学習モデルの学習データに対する攻撃として提唱された [24] が，その攻撃は合成データにも適用することができる [19]．

Stadler ら [19] は AIA を**攻撃者**と**挑戦者**のゲームとして定義する．各レコードは $d-1$ 個の準識別子と 1 個の秘密属性をもつ．挑戦者は母集団 $\mathcal{R}$ を知り，攻撃者は全レコードの準識別子の集合 $\tilde{\mathcal{R}}$ を知る．攻撃者が部分目標レコード $\tilde{\mathbf{r}}_{\mathrm{t}} \in \tilde{\mathcal{R}}$ を送ると，挑戦者は同じ準識別子を持つレコードを $\mathcal{R}$ から一様ランダムに選んで目標レコード $\mathbf{r}_{\mathrm{t}}$ と

Research Organization of Information Systems
a) tanaka.kouhei@rois.ac.jp
b) hajime-ono@staff.kanazawa-u.ac.jp

© 2026 Information Processing Society of Japan

し，その秘密属性 r_{s} が正解になる．挑戦者は母集団から標本 R（n 件）をサンプリングし，$\mathbf{r}_{\mathrm{t}}$ を含めたうえで，R から m 件のレコードで構成されるリリース S を作って攻撃者に返す．（攻撃能力測定の都合で攻撃者が R を直接受け取る場合も考え，受け取るデータを一般に $X \in \{R, S\}$ と書く．）攻撃者は X，$\tilde{\mathbf{r}}_{\mathrm{t}}$，および自身の事前知識 $\mathcal{P}$ から r_{s} を推定する．本稿では推定 $\hat{r}_{\mathrm{s}}$ を秘密属性の値そのものではなく，あらかじめ定めた階級の上の確率分布として与え，真値が入る階級に置かれた確率を攻撃成功の度合いとする．記法は付録 A.1 にまとめる．

2.4 攻撃者の知識

攻撃 $\hat{r}_{\mathrm{s}}$ のアルゴリズムはいくつか提案されており，攻撃者の知識 $\mathcal{P}$ に何が置かれるかに差がある．主要な攻撃について，$\mathcal{P}$ の中身とそれが攻撃でどう使われたかを付録 A.2 にまとめた．いずれの攻撃でも，$\mathcal{P}$ に置かれているのは，リリースそのもの，生成機構や学習済みモデルについての情報，あるいは対象と同じ母集団から得られる属性のいずれかである．

これは脅威モデルの立て方に沿った帰結である．Cormode ら [2] は，攻撃者が別に持っている情報を**補助情報**の軸として整理している．この軸は $\mathcal{P}$ に置かれうるもののうちデータ側を刻んだもので，攻撃者がアクセスできる訓練データの部分（aux-train），検証データの部分あるいはその分布（aux-test），その両方（aux）の三つの水準を持つ．差分プライバシーが想定する最強の攻撃者は，1 点の在不在を除く全訓練点を知る攻撃者として，この軸の上端に置かれる．上端まで含めて水準が訓練データ・検証データ・その分布の部分集合として定義されている以上，対象個人について母集団の外から得られる知識は，強弱にかかわらずこの軸の上に対応する水準を持たない．

理論研究でも類似の課題がある．Pufferfish [8] は攻撃者の事前信念の族 Θ を定義の一部として持つが，Θ の中身は与えない．属性推論における分布仮定 [6] や DOMIAS の参照分布 [22] も同様で，実務上は一様分布や周辺分布で代用されている．

3. LLM を用いた個人別リスク評価手法

1 章の三つの問いを測るには，まず評価する量を決める必要がある（3.1 節）．そのうえで四つの部品を定める．対象個人についての事前知識を供給する仕組み（3.2 節），三条件を同じ尺度の上で比べる採点（3.3 節），「準識別子から到達しうる水準」を与える基準（3.4 節），そして誰について測るかの選び方（3.5 節）である．

3.1 評価量: 個人の絶対リスク

2.4 節に挙げた攻撃監査は，いずれも 2 つの量を比較することで，リリースによるプライバシー侵害リスクの増分を評価する．Anonymeter [3] は対照データで母集団由来の推論を差し引き，Hittmeir ら [5] は標本と合成データで正答確率を比較し，RAPID [21] は準識別子を使わない予測器を基準に置く．Stadler らのアドバンテージとプライバシーゲインも，対象が標本に入っていた場合と入っていなかった場合の差である（付録 A.3）．

本稿の問いは，リリースが公開されたあとに相手が対象個人をどこまで絞れるかという，個人についての問いである．リリースによる増分ではなく，その個人に対するリスクが絶対的にどの程度存在するか評価することを目標にしている．原著のアドバンテージは攻撃対象の個人の在不在の痕跡を測る量で，それに依らない情報は相殺される．本稿が評価したい $\mathcal{P}$ による攻撃者の能力は対象の在不在とは独立なのでアドバンテージでは評価できない．

攻撃対象の個人 i に対する絶対リスクを次のように定義する．対象 i の真値が入る階級を b_i^* と書き，攻撃者が出力した階級上の分布 q_i について $q_i(b_i^*)$ を成功の度合いとする．以下これを**真値確率**と呼ぶ．集計は幾何平均，すなわち負の対数の平均を指数に戻した値で行う．

3.2 攻撃者の事前知識を LLM で実体化する

本稿は，Cormode らが整理した補助情報の軸の外にある攻撃者の知識の供給源として大規模言語モデル（LLM) を考える．LLM は，誰でも安価に，同じ入力に対して何度でも呼び出せる．対象個人の準識別子を与えれば，その個人の秘密属性についての分布を返す．本稿は 2.3 節のゲームの $\mathcal{P}$ をこれで実体化する．LLM に渡すのは対象の準識別子 $\tilde{\mathbf{r}}_{\mathrm{t}}$ だけで，X は渡さない．

3.3 三条件の攻撃者

公開されたデータ X と事前知識 $\mathcal{P}$ を使う攻撃者による絶対リスクのうち，どちらがどれだけ効いているかを分けて見るために，両方を使う攻撃者と，片方だけを使う攻撃者を比較する．

LLM 単独は $\tilde{\mathbf{r}}_{\mathrm{t}}$ と $\mathcal{P}$ を使い，X を受け取らない．**ML 攻撃者**は $\tilde{\mathbf{r}}_{\mathrm{t}}$ と X を使い，X を訓練データとして予測器を学習する．2.4 節で挙げた，補助情報をリリースと準識別子に限る系統が想定する攻撃者にあたる．**統合**は三つすべてを使い，3.1 節の階級の上で二つの予測分布の積をとって正規化する．すなわち $q^{\mathrm{ens}}(b) \propto p^{\mathrm{LLM}}(b)\, p^{\mathrm{ML}}(b)$ とする．

連続量の秘密属性を階級に変換するのは，LLM から連続値の校正された密度を引き出せないことが理由の一つである．ML 攻撃者は連続量上の確率分布を出力するように設計することも可能だが，攻撃者ごとに予測分布の台や形が変わると同じ尺度の上に置けないため，ML 攻撃者の出力も各階級の確率密度を出力するようにする．LLM には階級上の分布を答えさせ，ML 攻撃者は階級をクラスとする多クラス分類器として学習させる．

© 2026 Information Processing Society of Japan

3.4 準識別子条件付き攻撃者

我々は LLM が母集団全体を知る攻撃者と比べてどの程度攻撃できるか検証するために，比較の基準として，準識別子をすべて条件づけた秘密属性の（攻撃対象を除いた）母集団分布 $P(b \mid \tilde{\mathbf{r}}_{\mathrm{t}})$ をそのまま予測分布として用いる仮想的な攻撃者を置く．以下これを**準識別子条件付き攻撃者**と呼ぶ．攻撃対象を除かなければ準識別子の完全一致で対象自身の行が見つかり，真の階級を確率 1 で当ててしまうため除いている．除いたうえで完全一致の頻度をとる方法も使えない．準識別子の組み合わせは母集団の大半が一意であり，それらの対象では一致する行が 1 件も残らない．そこで，近い組み合わせの行から情報を借りて推定する分類器を母集団に当てはめる．すべての準識別子で条件づけるこの基準は，等価クラスと l 多様性による危険度の測り方よりも強い．

この攻撃者は二つの役割を持つ．第一に，セルごとの難易度の目安である．あるセルである攻撃者の成績が良いとき，それがその攻撃者の知識によるのか，そのセルがそもそも予測しやすいのかを区別できる．第二に，LLM が最初から答えを知っていないかの診断である．LLM が学習時に我々の実験に使うデータそのものを記憶しているなら，準識別子条件付き攻撃者だけでは説明できない情報を持つことになり，この攻撃者を上回れる．

3.5 対象の層別

本稿では攻撃対象が持つ準識別子の希少さと LLM の攻撃能力の関係に関心がある．そのため，実験での攻撃対象は準識別子の一部の直積から作った格子のセルで層別し，各セルから同数を選ぶ．セル g の希少度は母集団シェア $\pi_g = n_g^{\mathrm{pop}}/|\mathcal{R}|$ で測る．k 匿名化は希少な準識別子の組み合わせを潰す操作であり，保護の強さはこの軸に沿って変わる．格子は対象の選び方と結果の集約にのみ用いる．攻撃者には常にすべての準識別子 $\tilde{\mathbf{r}}_{\mathrm{t}}$ が渡るので，格子の粗さは攻撃者が見る情報を変えない．

4. 評価実験

本稿は二つの実験を行う．第一に，母集団を広く覆う対象について LLM 単独の知識を測り，準識別子の希少さに沿ってそれがどう変わるかを見る．以下これを**知識マップ**と呼ぶ．第二に，知識マップから選んだ 60 名について，23 通りのリリースに対する三条件の攻撃を行う．

4.1 データ，設定，基準線

母集団 $\mathcal{R}$ は American Community Survey の PUMS，カリフォルニア州 2024 年，203,591 行である．準識別子は AGEP（年齢），SCHL（学歴），OCCP（職業），POBP（出生地），RELSHIPP（世帯内続柄），WKHP（週労働時間），SEX（性別），RAC1P（人種）の 8 列，秘密属性は PINCP（年間総所得）である．OCCP と POBP は原表の符号がそれぞれ数百通りあるため，OCCP を職業大分類 25 区分に，POBP を出生地域に集約して用いる．この 8 列の組み合わせは母集団の 71.0%が一意である．

3.1 節の階級は，所得を 12 に分けたものである．切れ目は母集団の十分位 9 本と上側 2 本を用いて 10,000 / 22,000 / 32,000 / 42,000 / 55,000 / 70,000 / 90,000 / 120,000 / 180,000 / 250,000 / 350,000（ドル）とし，切れ目上の値は上側の階級に属するものとした．この切れ目は三条件で共有しており，予測分布は同じ台の上にある．

標本 R の大きさは $n = 10{,}000$ とし，独立に 10 回作る．各標本について秘密コイン c_{s} の両方の世界（対象を入れた標本と，対象を代替レコードで置き換えた標本）を作るので，対象 1 名あたり 20 の標本が対応する．リリース S は 23 通りで，合成データの生成数は $m = n$ とした．内訳は，k 匿名化が Flash [9] と Mondrian [10] を $k \in \{5, 10, 25, 50\}$ で各 4 通り，周辺分布ベースが AIM [14] を $\varepsilon \in \{0.1, 1\}$ で 2 通り，MST [13] と PrivBayes [25] を $\varepsilon \in \{0.1, 1, 10, 30\}$ で各 4 通り，深層生成が PATE-GAN [7] を同じ 4 通りと TVAE [23] の 1 通りである．23 通り $\times$ 60 対象 $\times$ 10 反復 $\times$ 2 側で 27,600 のリリースを作り，同じ標本の生データ R を対にして保持した（実装は付録 A.7）．

対象の 60 名は，事前知識の強さと所得の四分位の直積 12 セルから各 5 名を選んだ．事前知識の強さは，対象ごとに，LLM 単独の真値確率が 3.4 節の準識別子条件付き攻撃者にどれだけ届かないかで測っている．水準で層別した結果は付録 A.5 に示す．

以下の数値はすべて，次の三つと比べて読む．一様分布を返す攻撃者は真の階級がどこであっても $1/12 = 8.33\%$ を置く．これをランダム推測の水準とする．対象個人について何も知らない攻撃者，すなわち母集団の周辺分布をそのまま返す攻撃者は，60 対象で 8.50%，知識マップの対象で 9.20%である．3.4 節の準識別子条件付き攻撃者は，母集団から本稿が採点するすべての行を除いて勾配ブースティング分類器を当てはめ，対象の準識別子に適用して求める．母集団のホールドアウト 57,220 行で 15.04%，知識マップの 666 セルで 14.57%，60 対象で 16.85%である．

4.2 攻撃者の実装

LLM 攻撃者には，対象の準識別子を文に直して与え，12 階級それぞれに確率を割り当てさせる．リリース X は渡さない．用いたのは Olmo-3.1-32B-Instruct，Gemma-3-27B-IT，Qwen2.5-32B-Instruct の 3 種で，いずれも 4bit 量子化したものである．温度は 0 とする．階級の提示順は出力に強く影響するので，昇順と降順の 2 回を呼び，各回の分布を正規化して平均する．どの階級も先頭側と末尾側に 1 回ずつ現れるため，提示順に由来する重みが打ち消される．

© 2026 Information Processing Society of Japan

表 1 母集団シェア別に見た LLM 単独の真値確率（知識マップ 666 セル）

Table 1 Probability on the true band for the LLM-alone adversary by population share (666 cells)

			真値確率 [%]		
π_g	セル	対象	Gemma-3	Olmo-3.1	Qwen2.5
$< 10^{-3}$	164	3,280	10.21	9.12	10.76
10^{-3}–10^{-2}	348	6,960	10.14	8.60	10.86
10^{-2}–10^{-1}	148	2,960	10.62	9.14	11.46
$\geq 10^{-1}$	6	120	10.87	9.26	12.00
全体	666	13,320	10.27	8.85	10.98

π_g は 3.5 節のセルの母集団シェア．対象数はセル数 × 20 の公称値で，実際に採点したのはモデルごとに 13,084–13,319 である．

リリースへの攻撃には Gemma-3 を用いる．知識マップでは真値確率が Qwen2.5 に次いで高く，無回答は 0.03%以下で 3 モデル中最も少ない．60 対象すべてで分布が得られており，欠測はない．

ML 攻撃者は，受け取ったデータ X を訓練データとして 12 階級の多クラス分類器を学習し，対象の準識別子 $\tilde{\mathbf{r}}_{\mathrm{t}}$ に適用して階級上の確率分布を得る．分類器は XGBoost（決定木 100 本，深さ 6，学習率 0.3）で，階級の不均衡はクラス重みで補正する．k 匿名化されたリリースは各セルが値ではなく区間や値の集合になっているため，区間の端点と抑圧の有無を特徴量に展開したうえで学習させる（付録 A.8）．出力した確率は，リリース自身の交差検証で温度スケーリングにより校正する．当てはめに入るのは攻撃者が受け取ったリリースだけである．当てはまった τ は 55,200 件について中央値 1.619，93.5%で $\tau > 1$ であり，校正前の分類器は一貫して過信していた（付録 A.4）．

統合は，12 階級の上で $q^{\mathrm{ens}}(b) \propto p^{\mathrm{LLM}}(b)\, p^{\mathrm{ML}}(b)$ として正規化する．確率が 0 の階級は 10^{-6} で下支えする．

ML 攻撃者の予測は，27,600 のリリースそれぞれに $X = S$ と対の $X = R$ があるので 55,200 件で，学習の失敗も欠測も 0 件である．

4.3 LLM はどんな個人について正確な知識を持つか

対象は，準識別子のうち 2–3 列の直積で作った格子から選ぶ．用いた格子は，職業 × 学歴，職業 × 学歴 × 年齢，職業 × 性別，学歴 × 年齢 × 週労働時間，学歴 × 出生地域，学歴 × 人種の 6 通りである．空でないセルは 6 格子で計 666 あり，各セルから 20 名ずつ，延べ 13,320 対象（実人数 12,802 名）を選ぶ．セル g の希少度は母集団シェア π_g で測り，9.8×10^{-5} から 0.21 にわたる．この希少度は対象自身の性質であり，攻撃者に依存しない．

各対象について 4.2 節の LLM 攻撃者から予測分布を得て，母集団シェアの桁ごとに真値確率を集計した（表 1）．

全体の水準は，同じ対象で測った周辺分布攻撃者の 9.20%を Gemma-3 で 1.07，Qwen2.5 で 1.78 ポイント上回るにとどまり，Olmo-3.1 は 0.35 ポイント下回る．対象個人を条件づけたことによる利得はこの幅である．

π_g は 3 桁以上にわたるが，その全域を通じて真値確率が動く幅は Gemma-3 で 0.73，Olmo-3.1 で 0.66，Qwen2.5 で 1.24 ポイントにとどまる．帯ごとの並びも単調ではなく，3 モデルとも 10^{-3}–10^{-2} の帯でいったん下がる．$\log \pi_g$ と真値確率の Spearman 相関は Gemma-3 で +0.013，Olmo-3.1 で +0.033，Qwen2.5 で +0.049 であり，$n = 13{,}000$ 規模の標本では Olmo-3.1 と Qwen2.5 で $p < 0.05$ になる．この平坦さは，格子を混ぜたことで生じた見かけのものでも，成功の度合いの測り方の産物でもない（付録 A.6）．

k 匿名化が働くのは準識別子の希少さの軸の上であるから，匿名化が強く働く軸と LLM の知識が変化する軸は一致しない．つまり，**_LLM_ が正確な知識を持つ相手は，準識別子が希少かどうかでは決まらなかった．**

4.4 その知識は準識別子から到達しうる水準を超えるのか

同じ知識マップを 3.4 節の準識別子条件付き攻撃者と突き合わせる．セルごとに，そのセルの 20 名について両者の真値確率の幾何平均を取り，同じ尺度の上に並べた（図 1）．6 格子 666 セルのうち，LLM がこの水準に届かなかったセルは Gemma-3 で 612，Olmo-3.1 で 625，Qwen2.5 で 606 である．全体では LLM 単独の 8.85–10.98%に対し，同じ 666 セルで求めた準識別子条件付き攻撃者は 14.57%であった．図 1 に示した 2 格子でいえば，職業 × 学歴では 119 セル中 108–112 が，学歴 × 年齢 × 週労働時間では 75 セル中 65–69 が破線の下にある．残る 4 格子でも届かなかったセルの割合は 87–100%の範囲にあり，格子の切り方によらない．

これは 3.4 節の第二の役割，すなわち記憶の診断でもある．LLM が個票そのものを記憶しているなら，この攻撃者を上回るはずである．集計値では下回り，60 対象でも上回ったのは 21.7%であった．母集団規模での記憶を示す証拠は得られない．ただしこの攻撃者は有限標本から推定した近似であり，診断は診断であって証明ではない．

この攻撃者は，従来の監査が危険とみなす個人の順序も与える．準識別子だけで秘密属性が絞れる個人ほど危険とする見方（l 多様性・t 近接性の発想）を，この攻撃者の真値確率が高い順で表したものである．知識マップの対象全体で，LLM 単独の絶対リスクの上位 10%と，この順序の上位 10%の重なりは Gemma-3 で 40.7%，Olmo-3.1 で 33.5%，Qwen2.5 で 27.2%であった（偶然に期待されるのは 10%）．順位は正に相関するが（$\rho = +0.231$–$+0.398$）一致はしない．本稿の測定が最も危険とした個人の 6–7 割は，従来の危険度では上位に来ない．つまり，**事前知識を供給しても，攻撃者の予測は準識別子から導ける範囲を出なかった．**

© 2026 Information Processing Society of Japan

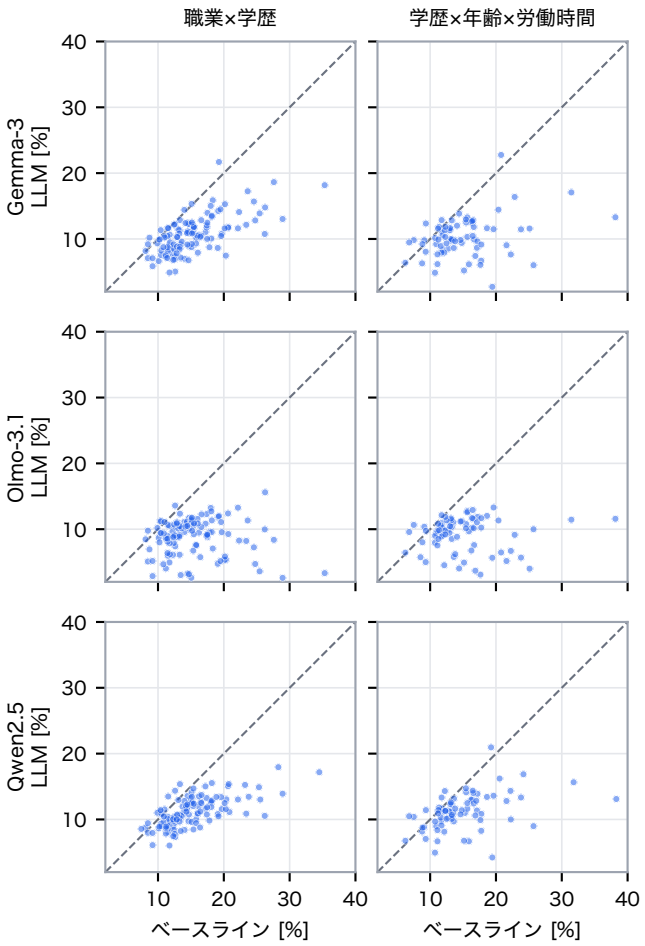


図 1 知識マップのセル別に見た LLM と準識別子条件付き攻撃者
Fig. 1 The LLM against the quasi-identifier-conditional adversary, cell by cell

1 点が 1 セル（各 20 名）で，縦横とも真値確率の幾何平均．破線は $y = x$ であり，その下は準識別子だけから到達しうる水準に LLM が届かなかったセルである．上限 40%の外に 3 点あり，図には現れないが本文の数には含む．本図は事前知識側の測定であり，匿名化の安全性については述べていない．

4.5 リリースを渡すと事前知識はどれだけ寄与するか

まずリリースに依存しない量を見る．LLM 単独はリリースを受け取らないので，60 対象での真値確率は 11.46% [9.36, 13.74] で，ランダム推測の 8.33%と周辺分布攻撃者の 8.50%の双方を上回る（角括弧は対象を単位としたブートストラップ 95%区間，2,000 回）．準識別子 8 列だけからこの水準に達する攻撃者は，従来の脅威モデルには存在しない．一方この値は準識別子条件付き攻撃者の 16.85%には届かず，その 68%にとどまる．生データ $X = R$ を渡した場合，ML と統合はほぼ並ぶ（19.73% [17.74, 22.15] 対 19.79% [15.95, 23.90]）．この値は準識別子条件付き攻撃者を超えており（比 117%），準識別子だけからは説明できない量を当てている．対象自身の行を引き当てているためである．

匿名化されたリリース $X = S$ については，23 通りを通じて次の 3 点が言える（図 2）．第一に，統合が ML を上回るのは 23 通り中 21 通りである．リリース側の情報が失われるほど，LLM の事前知識が下支えする度合いが大きくなる．第二に，ML の真値確率がランダム推測を明確に下回るリリースが 23 通り中 10 通りある（いずれも 6.4%以下）．第三に，統合が LLM 単独の水準を下回るリリースが 23 通り中 12 通りある．

対象ごとに見ると，集計値との乖離はさらに大きい．幾何平均は手法とパラメータによって 0.38%から 13.8%まで 36 倍にわたって動き，k を大きくすれば下がり（Mondrian は 13.8%から 11.5%へ単調に下がる），ε を大きくすれば上がる（PrivBayes は 5.0%から 12.5%へ）という保護パラメータへの応答も見える．その一方で，同じリリースの中で対象ごとの値は 2 桁にわたって散らばる．MST $\varepsilon = 30$ は幾何平均 1.0%でありながら，最も高い対象は 90.1%である．Mondrian は k を 50 まで上げても，真値確率が 61.4%に達する対象が残る．k 匿名化の 8 通りでは，幾何平均が 11.5–13.8%であるのに対し，ランダム推測を上回る対象は 78–87%を占める．幾何平均は極端に小さい値を持つ数名に引かれており，集計値は多数派のリスクを過小に表す．つまり，**匿名化されたリリースの下では，リリースで学習した攻撃者は，リリースを見ない攻撃者に及ばない．**

なお $X = S$ では，どの条件も準識別子条件付き攻撃者を超えない．本稿は，監査した 23 通りのリリースから秘密属性が漏れたとは主張しない．

5. 結論

本稿は，攻撃者の事前知識 $\mathcal{P}$ を大規模言語モデルで実体化し，公開されたリリースだけから実行できる監査として，属性推論の成功度を対象ごとに測った．米国センサス ACS のカリフォルニア州 2024 年を母集団とし，k 匿名化 2 手法と合成データ 5 手法による 23 通りのリリースに対し，LLM 単独・ML 攻撃者・両者の統合の三条件を，12 の所得階級上の真値確率で比較した．知識マップは Olmo-3.1-32B, Gemma-3-27B, Qwen2.5-32B の 3 種で測り，リリースへの攻撃は無回答の最も少ない Gemma-3-27B を用いた．

第一に，LLM 単独はリリースを一切受け取らずに，ランダム推測（8.33%）と周辺分布攻撃者（8.50%）の双方を上回る（11.46%）．従来の脅威モデルに存在しなかった水準の攻撃者が，誰でも安価に手に入る．一方でこの値は準識別子条件付き攻撃者の 16.85%を超えず（比 68%），知識マップでも 91–94%のセルで下回った．母集団規模で個票を記憶している証拠は得られていない．

第二に，LLM の知識は準識別子の希少さに対してほぼ平坦であった．π_g が 3 桁以上にわたっても真値確率の動く幅はモデルによって 0.66 から 1.24 ポイントにとどまる．k 匿名化が働くのは準識別子の希少さの軸の上であるから，匿名化が強く働く軸と LLM の知識が変化する軸は一致し

© 2026 Information Processing Society of Japan

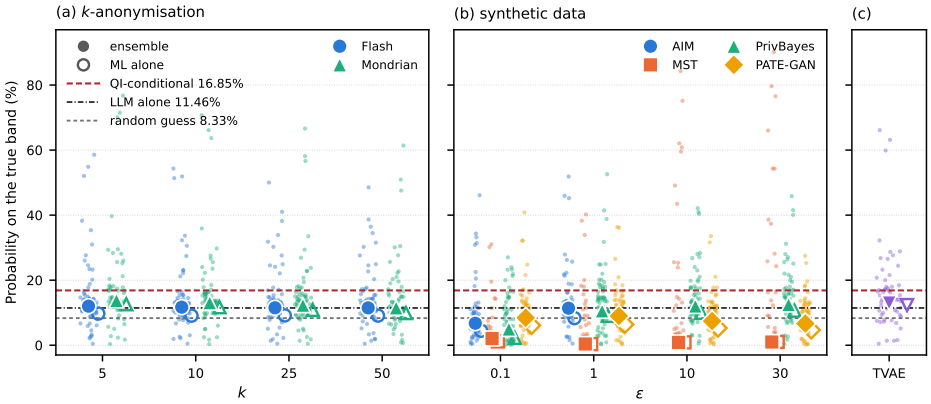


図 2　k と ε の掃引に対する対象ごとの真値確率（Gemma-3）

Fig. 2　Per-target probability on the true band across the k and ε sweeps (Gemma-3)

リリース $X = S$ を渡した場合の真値確率．小さい点は 1 対象（60 名），塗りのマーカーはその幾何平均で，いずれも統合攻撃者．中空のマーカーは ML 単独の同じ量で，点と重ならないよう右にずらしてある．水平の参照線は準識別子条件付き攻撃者（16.85%），LLM 単独（11.46%），ランダム推測（8.33%）の三つで，いずれもリリースに依存しない定数である．TVAE は ε を持たないためパネル (c) に置く．

ない．

第三に，匿名化されたリリースの下では，統合が ML を上回るリリースが 23 通り中 21 通りあり，統合が LLM 単独の水準に届かないリリースが 12 通りある．リリースが情報を失うほど，事前知識の寄与が相対的に大きくなる．対象ごとに見ると散らばりはさらに大きく，幾何平均が 1.0%のリリースにも真値確率 90.1%の対象が含まれる．

本稿の限界を述べる．母集団は単一の州・単一年であり，秘密属性は所得 1 種類，LLM はローカルで動く 30B 級の 3 種に限られる．リリースへの攻撃に用いた対象は 60 名で，事前知識の強さや所得四分位で層別すると 1 水準あたり 15–20 名しか残らず，水準間の差は標本誤差と区別できていない．加えて本稿は，実務が想定する攻撃者そのものを測っていない．準識別子条件付き攻撃者は 8 属性すべてで条件づけた分布であり，等価クラスと l 多様性で危険度を見る実務よりも強い測り方である．したがって 1 章が述べた「公開の可否が現実より弱い攻撃者を前提に判断されている」かどうかは，本稿の測定では判定できない．言えるのは，LLM を事前知識として与える経路では攻撃者が準識別子条件付き攻撃者を超えなかった，というところまでである．

今後の課題は，外部知識を前提としたときに手法間の差がどこに現れるかである．本稿の測定では，同じ 23 通りが真値確率では 0.38%から 13.8%まで動く一方，どの条件も準識別子条件付き攻撃者を超えなかった．どの水準の外部知識まで供給すればこの基準を超えるのかは，本稿の枠組みをそのまま拡張して測れる．

謝辞

本研究は，JST 経済安全保障重要技術育成プログラム【JPMJKP24U5】の支援を受けたものです．

参考文献

[1] Annamalai, M. S. M. S., Ganev, G. and De Cristofaro, E.: A Linear Reconstruction Approach for Attribute Inference Attacks against Synthetic Data, *33rd USENIX Security Symposium (USENIX Security 24)*, Philadelphia, PA, USENIX Association (2024). arXiv:2301.10053.

[2] Cormode, G., Maddock, S., Ullah, E. and Gade, S.: Synthetic Tabular Data: Methods, Attacks and Defenses, *Proceedings of the 31st ACM SIGKDD Conference on Knowledge Discovery and Data Mining (KDD)*, Toronto, ON, Canada (2025). arXiv:2506.06108.

[3] Giomi, M., Boenisch, F., Wehmeyer, C. and Tasnádi, B.: A Unified Framework for Quantifying Privacy Risk in Synthetic Data, *Proceedings on Privacy Enhancing Technologies*, Vol. 2023, No. 2, pp. 312–328 (online), DOI: 10.56553/popets-2023-0055 (2023).

[4] Golob, S., Pentyala, S. and Cock, M. D.: SoK: Reconstruction Attacks on Synthetic Tabular Data (Insights from Winning the NIST CRC) (2026).

[5] Hittmeir, M., Mayer, R. and Ekelhart, A.: A Baseline for Attribute Disclosure Risk in Synthetic Data, *Proceedings of the Tenth ACM Conference on Data and Application Security and Privacy (CODASPY '20)*, New York, NY, USA, ACM, pp. 133–143 (online), DOI: 10.1145/3374664.3375722 (2020).

[6] Jayaraman, B. and Evans, D.: Revisiting Membership Inference Under Realistic Assumptions, *Proceedings on Privacy Enhancing Technologies* (2021).

[7] Jordon, J., Yoon, J. and van der Schaar, M.: PATE-GAN: Generating Synthetic Data with Differential Privacy Guarantees, *International Conference on Learning Representations (ICLR)* (2019).

[8] Kifer, D. and Machanavajjhala, A.: Pufferfish: A Framework for Mathematical Privacy Definitions, *ACM Transactions on Database Systems*, Vol. 39, No. 1 (online), DOI: 10.1145/2514689 (2014).

[9] Kohlmayer, F., Prasser, F., Eckert, C., Kemper, A. and Kuhn, K. A.: Flash: Efficient, Stable and Optimal K-Anonymity, *Proc. 4th IEEE Int. Conf. on Information Privacy, Security, Risk and Trust (PASSAT)*, Amsterdam, Netherlands, (online), DOI: 10.1109/SocialCom-

© 2026 Information Processing Society of Japan

PASSAT.2012.52 (2012).

[10] LeFevre, K., DeWitt, D. J. and Ramakrishnan, R.: Mondrian Multidimensional K-Anonymity, *IEEE 22nd International Conference on Data Engineering (ICDE)* (2006).

[11] Li, N., Li, T. and Venkatasubramanian, S.: t-Closeness: Privacy Beyond k-Anonymity and l-Diversity, *IEEE 23rd International Conference on Data Engineering (ICDE)* (2007).

[12] Machanavajjhala, A., Kifer, D., Gehrke, J. and Venkitasubramaniam, M.: L-diversity: Privacy Beyond k-anonymity, *ACM Transactions on Knowledge Discovery from Data*, Vol. 1, No. 1 (2007).

[13] McKenna, R., Miklau, G. and Sheldon, D.: Winning the NIST Contest: A Scalable and General Approach to Differentially Private Synthetic Data, *Journal of Privacy and Confidentiality*, Vol. 11, No. 3 (2021).

[14] McKenna, R., Mullins, B., Sheldon, D. and Miklau, G.: AIM: An Adaptive and Iterative Mechanism for Differentially Private Synthetic Data, *Proceedings of the VLDB Endowment*, Vol. 15, No. 11 (online), DOI: 10.14778/3551793.3551817 (2022).

[15] McKenna, R., Sheldon, D. and Miklau, G.: Graphical-model Based Estimation and Inference for Differential Privacy, *Proceedings of the 36th International Conference on Machine Learning (ICML)* (2019).

[16] Prasser, F., Bild, R., Eicher, J., Spengler, H., Kohlmayer, F. and Kuhn, K. A.: Lightning: Utility-Driven Anonymization of High-Dimensional Data, *Transactions on Data Privacy*, Vol. 9, No. 2, pp. 161–185 (2016).

[17] Prasser, F., Eicher, J., Spengler, H., Bild, R. and Kuhn, K. A.: Flexible Data Anonymization Using ARX—Current Status and Challenges Ahead, *Software: Practice and Experience* (2020).

[18] Staab, R., Vero, M., Balunović, M. and Vechev, M.: Beyond Memorization: Violating Privacy via Inference with Large Language Models, *The Twelfth International Conference on Learning Representations (ICLR)*, (online), available from ⟨https://openreview.net/forum?id=kmn0BhQk7p⟩ (2024). arXiv:2310.07298.

[19] Stadler, T., Oprisanu, B. and Troncoso, C.: Synthetic Data – Anonymisation Groundhog Day, *31st USENIX Security Symposium (USENIX Security 22)*, Boston, MA, USENIX Association, pp. 1451–1468 (online), available from ⟨https://www.usenix.org/conference/usenixsecurity22/presentation/stadler⟩ (2022).

[20] Sweeney, L.: k-anonymity: A Model for Protecting Privacy, *International Journal of Uncertainty, Fuzziness and Knowledge-Based Systems*, Vol. 10, No. 5, pp. 557–570 (2002).

[21] Templ, M., Thees, O. and Müller, R.: RAPID: Risk of Attribute Prediction-Induced Disclosure in Synthetic Microdata, *arXiv preprint arXiv:2602.09235*, (online), available from ⟨https://arxiv.org/abs/2602.09235⟩ (2026).

[22] van Breugel, B., Sun, H., Qian, Z. and van der Schaar, M.: Membership Inference Attacks against Synthetic Data through Overfitting Detection, *Proceedings of the 26th International Conference on Artificial Intelligence and Statistics (AISTATS)* (2023). arXiv:2302.12580.

[23] Xu, L., Skoularidou, M., Cuesta-Infante, A. and Veeramachaneni, K.: Modeling Tabular Data Using Conditional GAN, *Advances in Neural Information Processing Systems (NeurIPS)* (2019).

[24] Yeom, S., Giacomelli, I., Fredrikson, M. and Jha, S.: Privacy Risk in Machine Learning: Analyzing the Connection to Overfitting, *2018 IEEE 31st Computer Security Foundations Symposium (CSF)*, pp. 268–282 (online), DOI: 10.1109/CSF.2018.00027 (2018).

[25] Zhang, J., Cormode, G., Procopiuc, C. M., Srivastava, D. and Xiao, X.: PrivBayes: Private Data Release via Bayesian Networks, *ACM Transactions on Database Systems*, Vol. 42, No. 4 (2017).

© 2026 Information Processing Society of Japan

付　　録

A.1　記法

2.3 節のゲームの記法と，本稿での実体を表 A·1 にまとめる．

表 A·1　記法（Stadler ら [19] に従う）
Table A·1　Notation following [19]

記号	意味	本稿での実体
$\mathcal{R}$	母集団	ACS PUMS カリフォルニア州 2024 年，203,591 行
R	母集団から引いた標本 ($n-1$ 件＋対象または代替の 1 件)	$n = 10{,}000$
S	R をサニタイズまたは合成した結果	本稿でいうリリース．k 匿名化 2 手法と合成データ 5 手法，計 23 通り
X	攻撃者に届いたデータ．R か S のいずれか	攻撃者が訓練に使えるデータ
$\tilde{\mathcal{R}}$	母集団から秘密属性を除いた集合	準識別子 8 列
$\tilde{\mathbf{r}}_{\mathrm{t}}$	部分目標レコード (準識別子のみ)	攻撃対象の準識別子
r_{s} / $\hat{r}_{\mathrm{s}}$	秘密属性の真値 / 攻撃者の推定	個人の年間総所得 PINCP(連続値)
$\mathcal{P}$	攻撃者の事前知識	本稿では LLM(3.2 節)

A.2　属性推論の攻撃における攻撃者の知識

2.4 節で述べた攻撃について，$\mathcal{P}$ に何が置かれ，それが攻撃でどう使われたかを表 A·2 にまとめる．

A.3　アドバンテージとプライバシーゲイン

A.3.1　定義

2.3 節のゲームにおいて，X と $\tilde{\mathbf{r}}_{\mathrm{t}}$ を受け取った攻撃者の**アドバンテージ**は次のように定義される：

$$\mathrm{Adv}(X, \tilde{\mathbf{r}}_{\mathrm{t}}) \equiv \Pr(\hat{r}_{\mathrm{s}} = r_{\mathrm{s}} | c_{\mathrm{s}} = 1) - \Pr(\hat{r}_{\mathrm{s}} = r_{\mathrm{s}} | c_{\mathrm{s}} = 0). \tag{A.1}$$

$\mathbf{r}_{\mathrm{t}}$ が標本に入っていた場合と入っていなかった場合の，攻撃者の勝利確率の差分である．この差分は $\mathbf{r}_{\mathrm{t}}$ が攻撃者の成功確率にどの程度貢献しているのかを評価する．最大値は 1 であり，第 1 項が 1 かつ第 2 項が 0 のとき，すなわち $\mathbf{r}_{\mathrm{t}}$ が入っていると攻撃者が確実に成功するのに，入っていないと全く勝利できないという状況で実現する．第 1 項が大きくても，$\mathbf{r}_{\mathrm{t}}$ が入っていなくても攻撃者が勝利してしまう状況ではアドバンテージは大きくならない．攻撃者が全く意味のない攻撃をする場合に 0 になるが，実験では負の値を取ることもある．

アドバンテージを使って，ある手法が $\tilde{\mathbf{r}}_{\mathrm{t}}$ を与えられたその攻撃者に対してどのくらいプライバシ保護に役立つかを測る指標，**プライバシーゲイン**は次のように定義される：

$$\mathrm{PG}(\tilde{\mathbf{r}}_{\mathrm{t}}) \equiv \mathrm{Adv}(R, \tilde{\mathbf{r}}_{\mathrm{t}}) - \mathrm{Adv}(S, \tilde{\mathbf{r}}_{\mathrm{t}}). \tag{A.2}$$

データ R を見て攻撃する場合と，リリース S を見て攻撃する場合のアドバンテージの差分である．

A.3.2　本稿の設定での結果

攻撃者の推定階級が真の階級に一致する確率について式 (A.1) を求めた．生データ $X = R$ を渡した場合，統合攻撃者のアドバンテージは 41.83%である（ML 単独では 51.83%）．4.1 節のとおり準識別子の組み合わせは母集団の 71.0%が一意なので，対象自身の行が標本に入っていれば攻撃者はその行を引き当てられる．在不在の痕跡があれば，この尺度はこれだけ反応する．

一方，リリース $X = S$ を渡した場合のアドバンテージは 23 通りのすべてで -2.83% から $+3.33\%$ の範囲に収まり，プライバシーゲインは 38.5%から 44.7%である（ML 単独でも -3.17%–$+3.67\%$，48.2–55.0%と同じ姿である）．本稿の準識別子 8 列は攻撃者が知っていると仮定した属性と完全に一致しており，k 匿名性は攻撃者の知識の全体に掛かっているので，在不在の痕跡は残らない．Stadler ら [19] も連続値の秘密属性をもつ合成データについて同じ結果を報告しており，彼らが非ゼロのアドバンテージを得たのは，人口統計属性の一部にしか k 匿名性を課していないリリースであった．

LLM 単独のアドバンテージは厳密に 0 である．3.1 節のとおり，本稿が供給した知識はこの量には現れない．

A.3.3　個人単位の差

統合分布（3.3 節）を $q^{\mathrm{ens}} \propto p^{\mathrm{LLM}} p^{\mathrm{ML}}$，$Z_i = \sum_b p_i^{\mathrm{LLM}}(b)\, p_i^{\mathrm{ML}}(b)$ と書くと，統合と LLM 単独の対数の差は

$$\Delta_i = \log \frac{p_i^{\mathrm{ML}}(b_i^*)}{Z_i} = -\mathrm{NLL}_i^{\mathrm{ML}} - \log Z_i \tag{A.3}$$

となり，LLM 単独側は $\log Z_i$ にしか入らない．攻撃者側の分布が対象によらず平坦であれば $\log Z_i$ の個人差は小さく，Δ_i の個人差は実質 ML 攻撃者の絶対的な成績になる．本稿のデータでは，Δ_i と ML の対数の相関は 0.97 以上であった（リリース 23 通りに分けても 0.83 を下回らない）．

A.4　ML 攻撃者の温度スケーリング

4.2 節の校正の手続きを述べる．リリース内の 5 分割の out-of-fold 予測に対して多クラスの負の対数尤度を最小にするスカラー τ を当てはめ，$q(b) \propto p(b)^{1/\tau}$ として正規化

© 2026 Information Processing Society of Japan

表 A·2 属性推論の攻撃における攻撃者の知識
Table A·2 Adversarial knowledge in attribute inference attacks

攻撃	モデルへのアクセス	$\mathcal{P}$ に置かれたもの	攻撃での使い方
Yeom ら [24]	学習済みモデル	対象の公開属性，モデル，訓練データ件数，訓練データが引かれた分布	モデルの損失に閾値を置く．誤差分布が既知なら尤度比
Stadler ら [19]	no-box	学習アルゴリズム，標本と合成データの件数，標本と同じ分布から引いた参照データ	参照データから影モデルを訓練して識別器を学習．属性推論ではリリースで教師あり学習
Annamalai ら [1]	no-box	合成データ，両者の件数，全レコードの準識別子行列	合成データ上の集計を線形方程式系として解く
Anonymeter[3]	no-box	合成データ，対象レコードについての部分的だが正しい補助情報	既知属性の部分空間で最近傍．対照データで母集団由来の推論を差し引く
Hittmeir ら [5]	no-box	合成データ，対象の準識別子の部分集合	近傍と多数決で秘密属性を予測．原データと合成データで正答確率を比較
RAPID[21]	no-box	リリース，対象の準識別子	リリースで予測器を学習し対象の準識別子に適用．準識別子を使わないベースラインと比較
NIST CRC の 14 攻撃 [4]	no-box	合成データ，対象の準識別子	合成データと準識別子から秘密属性を再構成
本稿	no-box	大規模言語モデル	対象の準識別子から秘密属性の分布を得る

する．当てはめに入るのは攻撃者が受け取ったリリースだけであり，対象の真値も母集団の統計も用いない．ここでの負の対数尤度は，攻撃者が自分の受け取ったリリースの中で τ を決めるための当てはめ目的関数であり，3.1 節の評価尺度としての真値確率（対象の真値に対して測るもの）とは別物である．$\tau > 0$ で狭義単調なので階級の順位は保たれる．すなわち最頻値は動かず，正解率とアドバンテージは校正の影響を受けない．変わるのは分布の鋭さだけであり，真値確率が測っているのはそこである．

A.5 対象 60 名の層別

4.1 節の 60 名は，事前知識の強さ（以下 gap と呼ぶ）と所得の四分位の直積から選んでいる．gap は，対象ごとに，LLM 単独の真値確率が 3.4 節の準識別子条件付き攻撃者の真値確率にどれだけ届かないかで測る．gap が小さい対象ほど，LLM は準識別子から到達しうる水準に近い知識を持つ．値は 4.3 節の知識マップから，Gemma-3 と Olmo-3.1 の 2 モデルで平均して求めた．gap を低・中・高の 3 水準に分け，所得四分位 4 水準との直積 12 セルから各 5 名，計 60 名を選ぶ．

リリースに依存しない量を gap 水準で層別したものが表 A·3 である．gap の低い対象ほど LLM 単独の値は高いが，区間は重なっており点推定の順序が言えるだけである．ML の値は gap 水準にほとんど反応しない（19.20–20.28%）．gap は LLM の知識の強さで定義した軸であり，ML 攻撃者にとって意味を持たないからである．なおこの軸は，定義に用いた 2 モデルでは勾配を示すが，選定に用いていない第 3 のモデルでは消える．対象内在の性質ではなく特定モデルの性質である．

表 A·3 リリースに依存しない三条件の真値確率（Gemma-3，60 対象）
Table A·3 Release-independent scores under the three conditions (Gemma-3, 60 targets)

gap 水準	n	LLM 単独	ML（$X = R$）	統合（$X = R$）
低	20	13.56	19.20	22.77
中	20	11.30	19.74	18.53
高	20	9.82	20.28	18.36
全体	60	11.46	19.73	19.79

単位は%．60 対象は gap の 3 水準に等配分して選んでいるので，「全体」行は 3 水準の等重み平均であり母集団比率による重み付けではない．

A.6 希少さに対する平坦さの補強

4.3 節の平坦さは，6 格子を混ぜたことで生じた見かけのものではない．格子ごとに同じ相関を取っても ρ は -0.023 から $+0.063$ の範囲にあり（表 A·4），6 格子 $\times$ 3 モデルの 18 通りのうち $p < 0.05$ になるのは 3 通りである．

測り方の産物でもない．成功の度合いを真値確率ではなく対数誤差の平均二乗で測っても相関は $\rho = +0.013$–$+0.017$ と同程度である．また LLM が回答できなかった対象の割合は希少度によらずほぼ一定であり（Gemma-3 で 0.00–0.03%，Olmo-3.1 で 0.03–0.15%，Qwen2.5 で 1.3–2.6%），難しい対象が脱落することで見かけの平坦さが生じているのでもない．

A.7 リリースの生成に用いた実装

k 匿名化は，Flash が ARX 3.9.1 [16], [17]，Mondrian が anonypy による．合成データは，AIM，MST，PATE-

© 2026 Information Processing Society of Japan

表 A·4　格子ごとの希少度と真値確率の相関

Table A·4　Correlation between rarity and the probability on the true band, per grid

			$\log \pi_g$ と真値確率の ρ		
格子	セル	π_g の範囲	Gemma-3	Olmo-3.1	Qwen2.5
職業 × 学歴	119	1.1×10^{-4}–0.044	+0.009	+0.019	+0.040
職業 × 学歴 × 年齢	349	9.8×10^{-5}–0.023	+0.001	+0.051*	+0.056*
職業 × 性別	49	3.6×10^{-4}–0.069	−0.015	−0.006	+0.014
学歴 × 年齢 × 労働時間	75	9.1×10^{-4}–0.044	+0.030	+0.063*	+0.039
学歴 × 出生地域	34	2.5×10^{-4}–0.206	+0.005	−0.023	+0.062
学歴 × 人種	40	2.2×10^{-4}–0.124	−0.004	+0.020	+0.019
全体	666	9.8×10^{-5}–0.206	+0.013	+0.033*	+0.049*

* は $p < 0.05$.

GAN が smartnoise-synth，PrivBayes が DataSynthesizer，TVAE が SDV による．

A.8　k 匿名化されたリリースの特徴量展開

4.2 節の ML 攻撃者は，一般化されたセルを次のように数値ベクトルへ展開する．数値列は，一般化された区間の下端と上端の 2 つの特徴に開き，値が抑圧されている場合に立つ欠損フラグを添える．順序列は，区間の下端と上端に加えて，取りうる各水準に対する指示変数を持ち，同じく欠損フラグを添える．カテゴリ列は，取りうる各値に対する指示変数で表す．すべての特徴は定義域の幅で $[0, 1]$ に正規化する．一般化されていないリリースでは下端と上端が一致するので，同じ符号化が生データにもそのまま使える．

© 2026 Information Processing Society of Japan