LLMエージェントによるICSペネトレーションテストにおける攻撃経路情報の有効性評価

阪田 恒晟[1,a)]　塙 剛生[1]　藤井 翔太[1]　川口 信隆[1]　猿田 宙[2]

概要：ICS（Industrial Control System）のペネトレーションテストは，専門知識と熟練者の暗黙知に依存し，品質安定化と工数削減に向けて，LLM エージェントによる自律的な実施が期待されている．しかし，エージェントが自律的に目標へ到達するには機器間の到達関係を把握して攻撃経路を選ぶ必要があり，事前情報がなければ探索が発散しやすい．そこで本研究では，侵入検知システム（IDS）等の受動監視で把握可能な通信関係をもとに構成した攻撃経路情報の有無で，LLM エージェントの探索効率とタスク完遂を比較する二群統制実験を模擬 ICS 環境上で実施した．Claude Sonnet 4.6，GPT-5.5，Claude Haiku 4.5 の 3 モデルで各条件 15 試行，計 90 試行を評価した結果，経路情報の効果はモデル能力に応じて質的な差を示した．Sonnet 4.6 では完遂率 100%を維持しつつ生成トークン数を約 43%削減し，GPT-5.5 では完遂率を 7%から 40%へ向上させた．一方，Haiku 4.5 では中間段階の進展は促されたが，完遂率は両条件とも 7%にとどまった．以上より，攻撃経路情報は，高能力モデルには探索効率化，中能力モデルには完遂可能性の拡張として作用する一方，低能力モデルには能力限界の顕在化として作用することが明らかとなった．これらの知見は，モデル能力に応じて受動監視由来の情報を活用することで，自律型 ICS ペネトレーションテストの実用化に資すると期待される．

キーワード：ICS ペネトレーションテスト，LLM エージェント，攻撃経路情報，受動監視

Effectiveness of Attack-Path Information for LLM-Agent Penetration Testing in ICS

Kousei Sakata[1,a)]　Goki Hanawa[1]　Shota Fujii[1]　Nobutaka Kawaguchi[1]　Hiroshi Saruta[2]

Abstract: Penetration testing in Industrial Control System (ICS) environments depends heavily on specialized expertise and tacit knowledge, motivating the autonomous execution of such tests by large language model (LLM) agents to improve consistency and reduce effort. However, for an agent to reach a goal autonomously, it must grasp the reachability relationships among devices and select an attack path, and without prior information its exploration tends to diverge. This paper investigates whether *attack-path information*, constructed from communication relationships observable through passive monitoring such as intrusion detection systems (IDSs), can improve autonomous ICS penetration testing. We conduct a two-arm controlled experiment in the GRFICS simulated ICS environment, comparing agents given attack-path information with agents given only the start and goal. Three models—Claude Sonnet 4.6, GPT-5.5, and Claude Haiku 4.5—were evaluated over 15 trials per condition, for 90 trials in total. The effect of path information varied qualitatively with model capability: Sonnet 4.6 maintained a 100% completion rate while reducing generated tokens by approximately 43%, whereas GPT-5.5 improved its completion rate from 7% to 40%. Haiku 4.5 progressed further through intermediate stages but remained at 7% completion under both conditions. These results show that attack-path information improves efficiency for high-capability models and expands task-completion feasibility for mid-capability models, although it cannot overcome the execution limits of low-capability models. Thus, capability-aware use of passive-monitoring-derived attack-path information provides a practical path toward more efficient and reliable autonomous ICS penetration testing.

Keywords: ICS Penetration Testing, LLM Agents, Attack-Path Information, Passive Monitoring

© 2026 Information Processing Society of Japan

This paper is work in progress and not peer-reviewed.

1. はじめに

製造・エネルギー・交通などの重要インフラでは，IT（Information Technology）と OT（Operational Technology）の融合が進み，従来クローズドに運用されてきた OT 環境がサイバー攻撃の直接の標的となっている [1]．接続性の拡大とともに攻撃面は広がり [2, 3]，マルウェアによる操業停止など物理的な被害も現実に増加している [4–6]．こうした脅威に備える手段として ICS（Industrial Control System）ペネトレーションテストの重要性が高まっている [7]．ICS ペネトレーションテストは，対象構成の把握から複数機器を経由した目標到達まで，多数の判断と操作を要するため，高度な専門知識への依存が大きい．この専門家依存を緩和する手段として，推論・計画・ツール利用を自律的に行う LLM エージェントが注目されている [8–10]．一方，LLM エージェントが ICS 環境で目標へ到達するためには，対象資産と機器間の通信関係を把握し，その到達関係に基づいて攻撃経路を選択する必要がある．事前情報がない場合，エージェントは広範な探索を反復することとなり，試行回数や実行時間が増大する．したがって，対象構成を事前に把握し，接続関係や到達順序に基づいて探索範囲を限定することは，LLM エージェントによる ICS ペネトレーションテストを効率的かつ安全に実施する上で重要である．

このような構成把握に利用できる現実的な情報源が，侵入検知システム（IDS）等による受動監視である．対象機器へ探索パケットを送信することなく通信を観測することで，資産や機器間の通信関係を把握できる．こうした受動的に取得可能な情報から，始点から目標までに経由すべき機器と到達順序を示す攻撃経路情報を構成できることが，先行研究で示されている [11]．しかし，攻撃経路情報の付与が自律型 LLM エージェントの探索性能に及ぼす効果，およびその効果とモデルの基礎能力との関係は，これまで定量的に明らかにされていない．

そこで本研究は，攻撃経路情報が探索効率およびタスク完遂率に及ぼす効果と，そのモデル能力依存性を二群統制実験により明らかにすることを目的とする．具体的には，攻撃経路情報を与える条件（With attack path）と始点・終点のみを与える条件（Without path）で，エージェントの目標到達効率（生成トークン数・反復回数）とタスク完遂率を比較する．与える経路情報は接続関係と到達順序に機器属性・通信プロトコル・公開脆弱性（CVE）参照を加えた事前知識であり，認証情報・具体的な攻撃手順を含まないため，グレーボックス型の設定に対応する．環境・ツール・初期権限・目標・プロンプト構成を共通とし，経路情報の有無のみを操作変数として，模擬 ICS 環境 GRFICS 上で Claude Sonnet 4.6，GPT-5.5，Claude Haiku 4.5 の 3 モデル・各条件 15 試行・計 90 試行を評価する．

評価の結果，攻撃経路情報の効果はモデルによって量的に異なるだけでなく，その作用様式も異なることが明らかとなった．本論文の主要な貢献は以下の通りである．

(1) 受動監視由来の通信関係から構成した攻撃経路情報の効果を，経路情報の有無のみを操作変数とする二群統制実験として定式化し，模擬 ICS 環境 GRFICS 上で 3 モデル・各条件 15 試行・計 90 試行を評価した．
(2) 攻撃経路情報の効果がモデル能力に応じて質的に変化することを示した．Claude Sonnet 4.6 では完遂率 100%を維持しつつ生成トークン数が約 43%削減され（効果は Discovery から Lateral Movement に集中），GPT-5.5 では完遂可能性が拡張し（完遂率 7%→40%，踏み台確立率 7%→47%），Claude Haiku 4.5 では中間段階の進展に留まった．
(3) 探索カバレッジ指標を導入し，攻撃経路情報がキルチェーン完遂に必要な行動を維持しつつ，目的達成に寄与しない列挙を削減することを示した．

2. 研究背景

2.1 関連研究

本研究は，自律型 LLM エージェントによる ICS ペネトレーションテストと，その事前知識となる攻撃経路情報の接点に位置する．そこで本節では，関連研究を**表 1** に示す二つの観点から整理する．

(i) 攻撃経路情報の活用

攻撃経路の構成・活用に関しては，AI プランニングにより権限昇格連鎖を自動発見する手法 [12]，攻撃グラフの LLM エージェントへの入力 [14]，MITRE ATT&CK for ICS に基づき攻撃シーケンスを生成する手法 [15] が提案されている．これらは攻撃経路の生成や提示を扱うものの，経路情報有無の統制や，自律型 LLM エージェントの探索効率・タスク完遂率への効果の評価には至っていない．

(ii) 自律型ペネトレーションテスト

LLM を用いたペネトレーションテストの自動化では，情報収集から攻撃手順の立案・実行までを自律的に行うエージェントの研究が進んでいる．Deng らの PentestGPT [8] を起点に，複数エージェントで協調する PentestAgent [9]，脆弱性を自律的に攻略するエージェント [10] へと自律度と対象が拡張され，Happe らは実 Active Directory 環境の自律攻略を実証している [13]．先に挙げた Singer らは，この自律実行に攻撃グラフの入力を組み合わせて多段ネットワーク攻撃を遂行する点で両観点にまたがり [14]，Folkerts らは ICS レンジを含む多段階シナリオで複数モデルの到達能力を比較している [16]．しかし，これらの多くは IT ／

[1] 株式会社 日立製作所
[2] 株式会社 日立ソリューションズ・テクノロジー
[a)] kosei.sakata.ky@hitachi.com

© 2026 Information Processing Society of Japan

表 1: 攻撃経路情報の活用と自律ペネトレーションテストにおける関連研究の比較

		(i) 攻撃経路情報の活用			(ii) 自律型ペネトレーションテスト		
研究	対象領域	攻撃経路の生成	経路情報の入力	有無の統制比較	LLM 自律実行	カバレッジ分析	複数モデル比較
Deng et al. (2024) [8]	IT/Web				◑		●
Shen et al. (2025) [9]	IT/Web				●		
Zhu et al. (2026) [10]	IT/Web				●		◑
De Pasquale et al. (2024) [12]	IT/Web	●					
Happe et al. (2025) [13]	IT/AD				●		●
Singer et al. (2026) [14]	IT/Web		◑		●		◑
Choi et al. (2021) [15]	OT/ICS	●					
Folkerts et al. (2026) [16]	IT/OT				●	◑	●
本研究	**OT/ICS**	●	●	●	●	●	●

●は明示的に対応，◑は部分的・限定的に対応，空欄は非対応を表す．

Web 環境を主対象とし，OT 環境において攻撃経路情報の有無を統制した定量評価は行われていない．

以上より，既存研究は攻撃経路の生成・提示か，LLM エージェントの攻撃遂行能力の評価のいずれかに主眼を置いており，両観点にまたがる場合でも，経路情報の有無を統制してその効果を定量化した研究は存在しない．これに対し本研究は，OT ／ ICS 環境において，受動監視由来の攻撃経路情報が自律型 LLM エージェントの探索効率とタスク完遂に及ぼす効果を，経路情報の有無を統制した比較実験と複数モデル分析により明らかにする．

2.2 研究課題

本研究では，攻撃経路情報が自律型 LLM エージェントの探索過程およびタスク完遂に及ぼす効果を，以下のリサーチクエスチョン（以下，RQ）に基づいて検証する．

RQ1 攻撃経路情報の提示は，LLM エージェントの探索過程にどのような影響を及ぼすか．

RQ2 攻撃経路情報による効率化は，攻撃過程のどの段階に現れるか．

RQ3 攻撃経路情報の効果は，使用する LLM の基礎能力によってどのように異なるか．

RQ4 攻撃経路情報の提示は，タスク完遂に必要な行動および探索カバレッジにどのような影響を及ぼすか．

RQ1 は攻撃経路情報が探索過程に及ぼす影響を問う総括的な問いであり（4.4・4.5 節），RQ2〜RQ4 はその内訳を成す．RQ2 では効率化が現れる攻撃局面（4.6 節），RQ3 では効果とモデル基礎能力との関係（4.7 節），RQ4 ではタスク完遂に必要な行動と探索カバレッジへの影響（4.8 節）を検証する．

3. 問題設定と脅威モデル

前章で示した RQ を検証するため，本章では，攻撃経路情報の有無を比較するための問題設定を定義する．まず，本研究で扱う攻撃経路情報と二つの実験条件を示す．次に，LLM エージェントを実行する検証システムと対象ネットワークを説明し，最後に，ネットワーク層および制御層の脅威モデルとタスク完遂条件を示す．

3.1 攻撃経路情報と比較条件

本研究における攻撃経路情報とは，攻撃元から目標資産へ到達するために経由すべき機器と，その到達順序を示す事前情報である．この情報は，侵入検知システム（IDS）等の受動監視によって観測された機器間の通信関係から構成されることを想定する．受動監視結果から攻撃経路を生成する手法自体は先行研究で示されているため [11]，本研究では，生成された攻撃経路情報を LLM エージェントへ提示することの効果に焦点を当てる．比較する実験条件は，以下の二つである．

経路あり条件（With attack path） 攻撃元から目標 PLC までに経由する機器とその到達順序に加え，各機器の種別，OS，通信プロトコル，および関連する CVE 参照を提示する．

経路なし条件（Without path） 攻撃元と目標 PLC の IP アドレスのみを提示し，中間機器および到達経路をエージェント自身に探索させる．

いずれの条件においても，認証情報や具体的な攻撃コマンドは提示しない．したがって，経路あり条件に与えられる情報は，攻撃対象と到達順序を示すものではあるが，攻撃手順そのものを与えるものではない．

3.2 検証システムと対象ネットワーク

本研究の検証システムと対象ネットワークを**図 1** に示す．検証システムは，LLM API, MCP Client, MCP Server, および攻撃元となる Kali Linux から構成される．LLM エージェントは，入力された事前情報とそれまでのコマンド実行結果に基づいて次の行動を決定する．生成されたコマンドは MCP Server を介して Kali Linux 上で実行され，実行結果は MCP Client を通じて LLM へ返される．エージェントは，推論，コマンド生成，実行，および結果の解釈を

© 2026 Information Processing Society of Japan

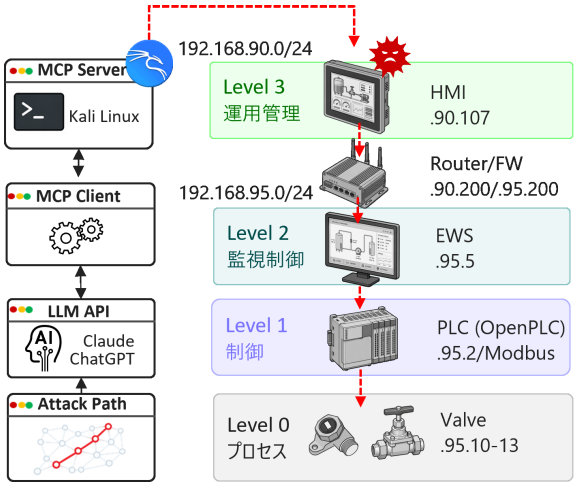


図 1: 検証システムと対象ネットワーク

試行終了まで反復する．

対象ネットワークは，DMZ ネットワーク（192.168.90.0/24）と OT ネットワーク（192.168.95.0/24）から構成される．攻撃元は DMZ 上の Kali Linux（192.168.90.6），目標は OT ネットワーク上の PLC（192.168.95.2）である．両ネットワークは，境界ルータ／FW （192.168.90.200 ／ 192.168.95.200）によって分離されており，Kali Linux から PLC へ直接通信することはできない．なお，本研究では，IDS による通信収集および攻撃経路生成の精度は評価対象としない．受動監視から取得可能な通信関係を模した情報を事前に用意し，その提示の有無が LLM エージェントの行動に及ぼす影響を評価する．

3.3 脅威モデルとタスク完遂条件

本研究では，Kali Linux に初期アクセスを持つ内部横展開型の攻撃者を想定する．これは，組織内部の端末が既に侵害されている assumed-breach の状況に相当する．攻撃者は LLM エージェントとして，Kali Linux 上から nmap, hydra, SSH 等を用い，中間機器の探索，認証情報の検証，通信経路の構築，および PLC への操作を自律的に実行する．攻撃過程は，MITRE ATT&CK for ICS に対応づけ，以下の**表 2** として整理する．攻撃経路情報が直接支援すると想定されるのは，中間機器と到達順序を特定する Discovery から Lateral Movement までの過程である．一方，SSH 認証，トンネル構成，および Modbus 操作に必要な具体的手順は，両条件に共通してエージェント自身が決定する．

表 2: 評価対象とする攻撃段階

攻撃段階	実行内容
Discovery	到達可能な機器，サービス，通信経路を探索
Initial Access	境界ルータ／ FW への SSH アクセスを確立
Lateral Movement	境界ルータ／ FW を介した SSH トンネルを構成し，PLC への通信経路を確立
Collection	PLC 操作に必要情報の収集
Impact	Modbus 保持レジスタへの値の書き込み

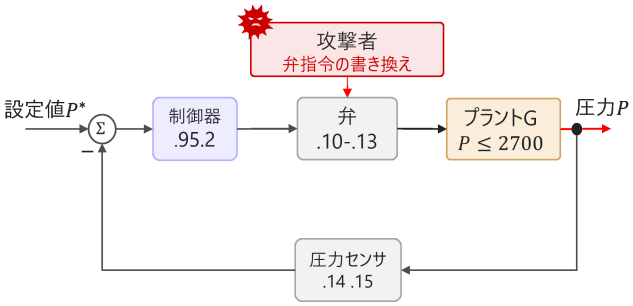


図 2: 制御層において想定する攻撃

以上のネットワーク層における攻撃の最終段階では，PLC への書込みを通じて物理プロセスへ介入する．当該プロセスを**図 2** に示す．目標 PLC である OpenPLC は，反応槽の圧力 P を監視し，原料弁および排出弁の開度を調整することで，圧力を設定値 P^* 近傍に維持する負帰還制御系を構成する．圧力変化は，原料の流入量 q_{in} と排出量 q_{out} の収支により，簡略化して次式で表される．

$$\dot{P} = k\,(q_{\text{in}} - q_{\text{out}}), \qquad k > 0. \tag{1}$$

正常時には，PLC が圧力 P と設定値 P^* の偏差に基づいて弁開度を更新する．一方，攻撃者が弁設定値に対応するレジスタを上書きすると，PLC が算出した制御出力へ外部から介入できる．例えば，原料弁を開き，排出弁を閉じる方向に固定した場合，$q_{\text{in}} - q_{\text{out}} > 0$ となり，圧力が上昇する可能性がある．

以上から，PLC の保持レジスタへの不正な書込みは，物理プロセスへ介入するための前提条件となる．本研究では，設備損傷や圧力変化そのものは発生させず，所定の Modbus 保持レジスタへの書込み成功をタスク完遂条件とする．

4. 評価実験

4.1 実験設計

評価実験には，模擬 ICS 環境 GRFICS v3 を Docker 上に構築して用いた．評価対象は，Claude Sonnet 4.6，GPT-5.5，Claude Haiku 4.5 の 3 モデルである．各モデルについて，経路あり条件 15 試行，経路なし条件 15 試行を実施し，合計 90 試行を評価した．攻撃経路情報以外の影響を抑えるため，初期プロンプト，利用可能なツール，初期権限，temperature，コンテキスト圧縮設定，および試行終了条件を条件間で統一した．両条件の違いは，第 3.1 節で定義した攻撃経路情報の提示の有無のみである．各試行は，PLC の所定の Modbus 保持レジスタへの書込みに成功するか，モデルが処理を終了または拒否した時点で終了した．書込み後の読出し確認や，制御プロセスへの物理的影響の発生は行っていない．

© 2026 Information Processing Society of Japan

4.2 評価指標

本研究では，攻撃経路情報の効果を探索効率，探索品質，タスク進行，および探索範囲の 4 観点から評価する．

● **探索効率：**主指標として，ゴール到達までにモデルが生成したトークン数を用いる．生成トークン数は，LLM が推論，計画，コマンド生成，および結果解釈に費やした生成量を表す．実時間と異なり，API の混雑やネットワーク遅延の影響を受けにくいため，エージェント自身の探索コストを比較する指標として採用した．補助指標として，ゴール到達までのエージェント反復回数，コマンド実行回数，および実時間を記録した．ただし，実時間は実行環境の負荷にも左右されるため，補足的な分析に用いる．

● **探索品質：**攻撃経路情報が単に出力量を削減するだけでなく，目的に沿った行動を促したかを評価するため，前進率と誤誘導アクション数を用いる．前進率は，全行動のうち，次の攻撃段階への進行またはゴール到達に寄与した行動の割合とする．誤誘導アクション数は，既知情報の再取得，到達不能な対象への反復試行，およびゴール到達に寄与しない探索行動の数とする．

● **タスク進行：**ゴール到達率に加え，SSH トンネルの構成に成功した踏み台確立率と，試行が終了した攻撃段階を評価する．完遂率のみでは，未完遂試行が初期探索で停止したのか，PLC 直前まで進行したのかを区別できないためである．安全機構に起因してタスクが継続されなかった試行は，拒否・ブロックとして別に記録する．

● **探索範囲：**経路情報による探索の絞込みが，攻撃面の把握範囲を過度に狭める可能性を評価するため，到達した ATT&CK 戦術数，列挙したホスト数，および列挙したポート数を用いる．

4.3 統計分析

各条件の試行数は $n = 15$ であり，生成トークン数等の連続値について正規分布を仮定することは難しい．そこで連続指標については，二群の分布に差があるかを判定するため，分布への仮定が少ない両側 Mann–Whitney の U 検定を用いる．p 値は，観測された差が偶然生じる確率を評価するために用いるが，差の大きさは表せないため，二群の差の程度を表す効果量として Cliff's δ を併記する．δ は経路なし条件の値が経路あり条件より大きい方向を正と定義し，削減指標では正の値が経路情報による改善を，絶対値が 1 に近いほど条件間の分離が大きいことを表す．中央値差の推定の不確実性は，10,000 回のブートストラップによる 95% 信頼区間で示す．ゴール到達率や踏み台確立率などの二値指標については，成否割合が二群間で異なるかを判定するため，小標本にも適用可能な Fisher の正確確率検定を用いる．有意水準は $\alpha = 0.05$ とするが，統計的有意性のみで結論づけず，中央値，分布，効果量，および試行の最終到達段階を併せて解釈する．

4.4 探索効率のモデル横断比較

各試行が終了するまでの総生成トークン数を**図 3** に示す．塗りつぶし点はゴール到達試行，白抜き点は未到達試行（途中停止・拒否までの消費量）を表す．Sonnet 4.6 では，経路あり条件が経路なし条件より一貫して少なく，両条件の分布は重複しなかった（Cliff's $\delta = 1.00$, $p = 3.4 \times 10^{-6}$）．一方，GPT-5.5（$\delta = 0.17$, $p = 0.43$）と Haiku 4.5（$\delta = -0.30$, $p = 0.17$）では総量に明確な差はなかった．ただし GPT-5.5 では経路あり条件でゴール到達試行が増えており，効果は生成量削減ではなくタスク進行として現れた（4.7 節）．

4.5 Sonnet 4.6 における探索効率と探索品質の詳細

両条件ですべての試行を完遂した Sonnet 4.6 を対象に，探索効率と探索品質を詳細に比較する．結果を**図 4** に示す．ゴール到達までの生成トークン数の中央値は，経路あり条件で 2,540，経路なし条件で 4,416 であり，経路情報によって約 43%削減された．中央値差は 1,876 トークンであり，ブートストラップ 95%信頼区間は $[1,274,\ 3,201]$ で 0 を跨がなかった．ゴール到達までのエージェント反復回数は，経路あり条件の中央値 9 回に対して，経路なし条件では 18 回であった．また，誤誘導アクション数は 1 回に対して 4 回，前進率は 0.64 に対して 0.42 であった．主要指標の統計結果を**表 3** に示す．

表 3: Sonnet 4.6 における主要指標の比較（各条件 $n = 15$, 値は中央値）

指標	経路あり	経路なし	p
ゴール到達トークン数 ↓	2,540	4,416	3.4×10^{-6}
ゴール到達ターン数 ↓	9	18	5.0×10^{-6}
誤誘導アクション数 ↓	1	4	2.0×10^{-4}
前進率 ↑	0.64	0.42	5.0×10^{-5}

> **Key Takeaways（RQ1：探索過程への影響）**
> 経路情報は探索過程を効率化する．その効率化は応答の短縮ではなく，不要な探索と反復の抑制として働き，効果はモデル能力に依存する（高能力では生成量削減，中・低能力では総量不変でタスク進行側に現れる）．

4.6 攻撃段階ごとの探索効率

各モデルにおける攻撃段階と累積生成トークン数の関係を**図 5** に示す．横軸は累積生成トークン数，縦軸は到達した攻撃段階を表す．階段が左側に位置するほど，少ない生成トークン数で次の段階へ進行したことを意味する．Sonnet 4.6 では，経路あり条件が，経路なし条件より少ない生成トークン数で各攻撃段階へ到達した．最終的なゴール到達トークン数は，経路あり条件の 2,540 に対し，経路なし条件では 4,416 であり，経路なし条件は経路あり条件

© 2026 Information Processing Society of Japan

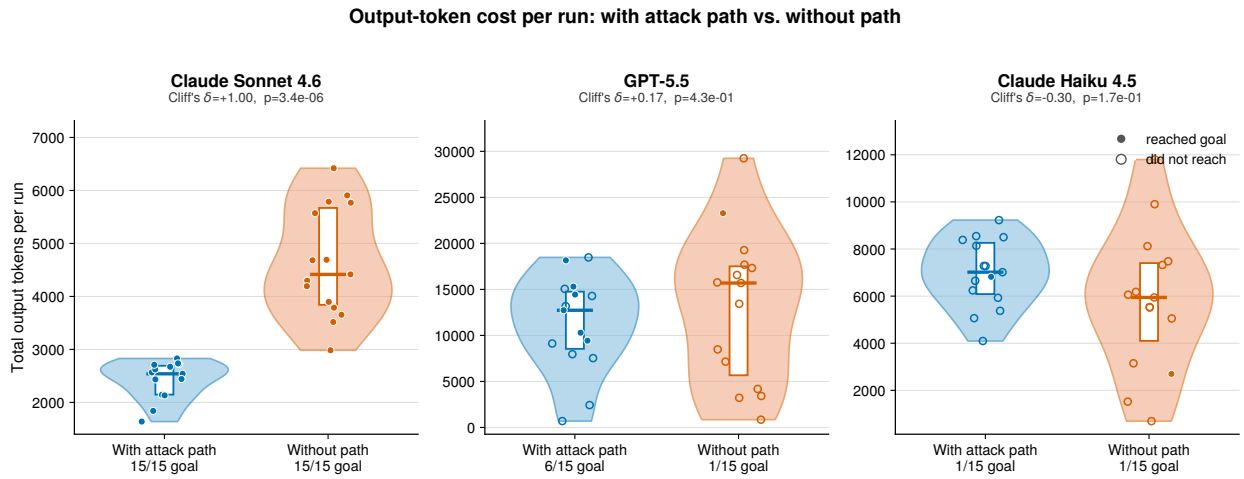


図 3: 各試行の総生成トークン数とゴール到達結果

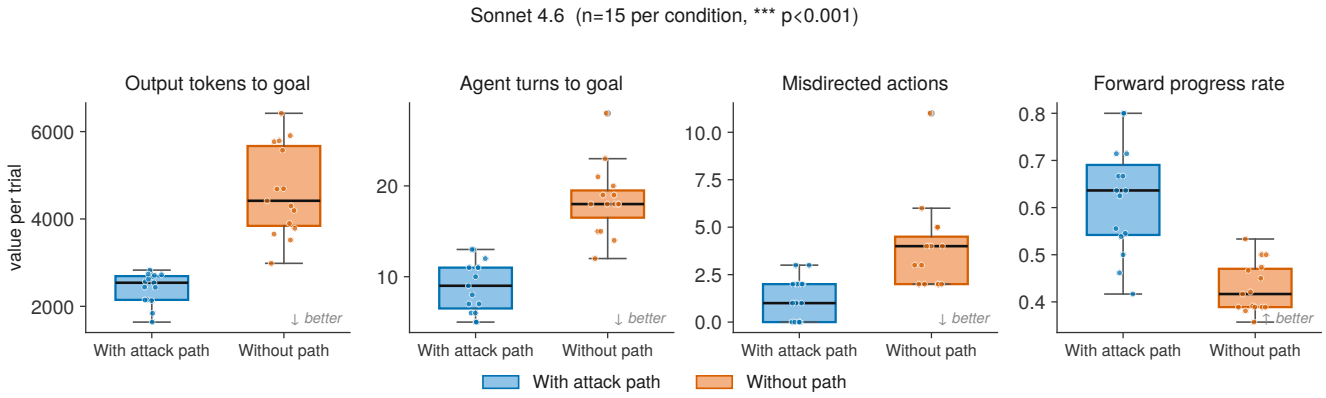


図 4: Sonnet 4.6 における探索効率および探索品質の比較．箱は四分位範囲，中央線は中央値，点は各試行を表す．

の 1.74 倍を要した．条件間の差は，中間機器および到達経路を特定する Discovery から Lateral Movement までの過程で形成された．経路あり条件では，提示された中間機器と到達順序を利用して，認証情報の検証とトンネル構成へ移行した．これに対し，経路なし条件では，スキャンや経路確認を通じて，中間機器と到達順序を自律的に特定する必要があった．

GPT-5.5 および Haiku 4.5 では未完遂試行が多いため，図中の曲線は，完遂までの効率だけでなく，各モデルが到達できた攻撃段階も表している．GPT-5.5 では，経路情報の提示によって Lateral Movement および Impact へ進行する試行が増加した．Haiku 4.5 では，経路情報によって中間段階への進行は促されたが，Impact への到達は限定的であった．

> **Key Takeaways（RQ2：効率化が現れる局面）**
> 効率化は中間機器と到達順序を特定する Discovery〜Lateral Movement の段階に現れる．踏み台確立後の操作は経路情報に依らず共通で，この段階では差が生じない．

4.7 モデルごとのタスク進行

各モデルにおける試行の最終到達段階を図 6 に示す．Sonnet 4.6 では，経路情報の有無にかかわらず，全 15 試行が Impact まで到達し，PLC への書込みに成功した．

GPT-5.5 では，経路あり条件のゴール到達数は 6/15 であり，経路なし条件の 1/15 を上回った．ゴール到達率の差は Fisher の正確確率検定で $p = 0.080$ であり，有意水準には達しなかった．一方，踏み台確立数は，経路あり条件の 7/15 に対して経路なし条件では 1/15 であり，この差は統計的に有意であった（$p = 0.035$）．GPT-5.5 では，安全機構に起因する拒否またはブロックが，経路あり条件で 7/15，経路なし条件で 9/15 観測された．このため，同モデルの完遂率には，探索能力だけでなく，安全機構による早期終了も影響している．

Haiku 4.5 では，ゴール到達数は両条件とも 1/15 であった．しかし，経路あり条件では，残る 14 試行が Lateral Movement まで進行したのに対し，経路なし条件では，Lateral Movement 到達が 8 試行，Initial Access 停止が 1 試行，Discovery 停止が 5 試行であった．したがって，経路情報は中間段階への進行を促したものの，最終的な Modbus

© 2026 Information Processing Society of Japan

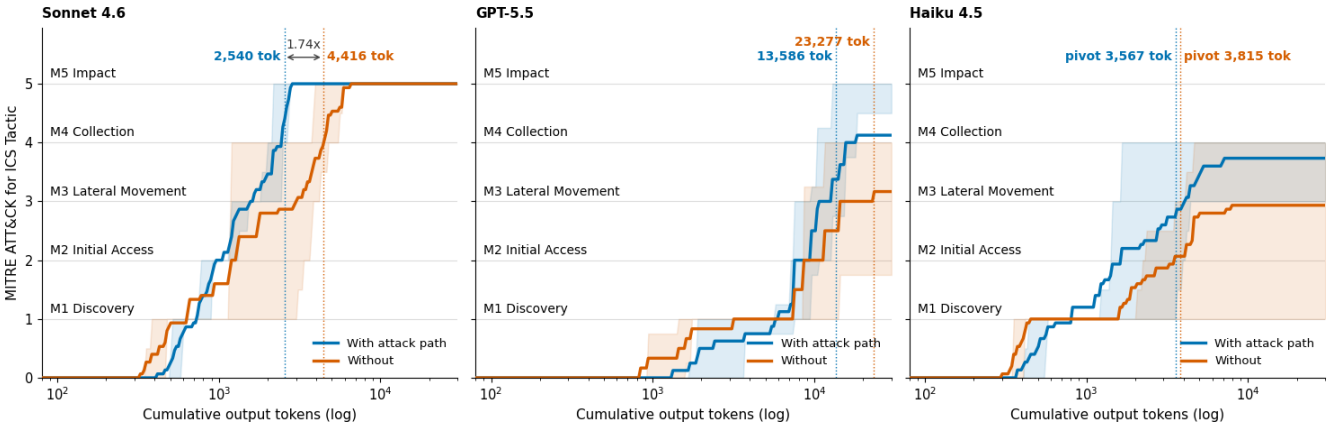


図 5: 各モデルにおける累積生成トークン数と攻撃段階

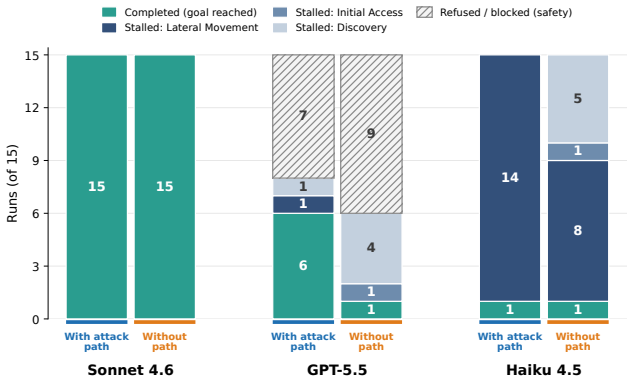


図 6: 各モデルにおける試行の最終到達段階

書込みには至らなかった．

> **Key Takeaways（RQ3：モデル能力依存性）**
> 効果はモデル能力で質的に異なる．自力完遂できる Sonnet 4.6 では探索効率の改善として，完遂が限定的な GPT-5.5 では踏み台確立・完遂可能性の拡張として現れ，実行能力が不足する Haiku では中間段階までの進行に留まる．

4.8 探索範囲の比較

攻撃経路情報は探索対象を絞り込むため，効率向上が攻撃面の網羅的な把握を損なう可能性がある．そこで，両条件ですべての試行を完遂した Sonnet 4.6 を対象として，探索範囲を比較した．結果を**表 4** に示す．タクティクス網羅数と列挙ポート数は，経路なし条件の方が多かった．一方，到達ホスト数には有意差が認められず，Impact 到達率は両条件とも 100%であった．

> **Key Takeaways（RQ4：探索カバレッジ）**
> 経路情報は探索カバレッジを縮小するが，縮小されるのは目的外の列挙のみで，完遂に必要な攻撃チェーンは維持される．

表 4: Sonnet 4.6 における探索範囲の比較（各条件 $n = 15$，値は中央値）

指標	経路あり	経路なし	p
タクティクス網羅数	4	5	0.030
列挙ポート数	7	9	0.020
到達ホスト数	3	3	0.22

5. 議論

本節では，モデル能力による効果の違い，効率化と網羅性の使い分け，安全機構の影響の三点から結果を考察する．

5.1 考察

● **モデル能力に応じた攻撃経路情報の作用**：本研究の中心的な知見は，攻撃経路情報の効果が，すべてのモデルに同じ形で現れるわけではない点にある．Sonnet 4.6 は，経路情報がなくても全試行を完遂した．このため，経路情報の効果は，生成トークン数，反復回数，および誤誘導行動の削減として現れた．GPT-5.5 では，経路情報の提示によって，踏み台確立率とゴール到達率が上昇した．これは，攻撃対象と到達順序の不確実性が低減され，同モデルが自力では越えにくかった Lateral Movement への移行が支援されたためと考えられる．一方，Haiku 4.5 では，経路情報によって Lateral Movement までの進行は促されたが，Modbus 書込みの完遂率は向上しなかった．攻撃経路情報は，「どの機器をどの順序で狙うか」という判断を支援できるが，SSH トンネルの正確な構成や ICS 固有プロトコルの操作に必要な能力までは代替できない．

以上から，本実験の範囲では，攻撃経路情報は，自力完遂が可能なモデルには探索効率の改善として，自力完遂が限定的なモデルには完遂支援として作用した．一方，最終操作に必要な実行能力が不足するモデルでは，中間段階の進展に留まった．

● **探索効率と網羅性の使い分け**：攻撃経路情報は，特定の

© 2026 Information Processing Society of Japan

目標資産へ効率的に到達するタスクに適している．例えば，既知の重要資産に対する到達可能性や，境界防御の有効性を継続的に検証する場合には，受動監視から得た経路情報を提示することで，不要な探索を削減できる．一方，未知の資産やサービスを広く発見することが目的の場合，探索対象の絞込みは網羅性を低下させる可能性がある．したがって，実運用では，評価目的に応じて探索方式を使い分ける必要がある．

既知の重要資産への到達性検証には，経路情報を用いた誘導型探索が適している．これに対し，資産棚卸しや未知の攻撃面の発見には，経路情報に限定されない広い探索が適している．両者を組み合わせることで，広い探索で得た通信関係から重要経路を抽出し，その経路を自律エージェントで重点的に検証する運用が考えられる．

● **安全機構が自律実行へ及ぼす影響：**GPT-5.5 では，安全機構に起因する拒否またはブロックが多数観測された．経路あり条件と経路なし条件の双方で発生していることから，攻撃経路情報の提示は，安全機構による実行停止そのものを大きく緩和するものではなかった．

この結果は，正規の模擬環境におけるペネトレーションテストであっても，モデルの安全機構が自律タスクの継続性を制約し得ることを示している．したがって，LLM エージェントを実運用へ導入する際には，攻撃遂行能力だけでなく，許可された環境における継続性，実行権限の制御，監査ログ，および人間による承認機構を含めて実行基盤を設計する必要がある．

5.2 制限事項

本研究には以下の制限がある．第一に，経路あり条件で提示した情報には，機器の到達順序だけでなく，機器種別，OS，通信プロトコル，および CVE 参照が含まれる．したがって，観測された効果には経路トポロジ以外の要因も寄与し得る．第二に，評価環境は，踏み台 1 台からなる単一ホップ構成である．多段ネットワークでは，探索候補と経路分岐が増加するため，経路情報の効果が異なる可能性がある．第三に，GPT-5.5 および Haiku 4.5 ではゴール到達試行数が少なく，完遂試行のみを対象とした連続指標の比較は，試行数の拡充によって精度を高められる．第四に，本実験では実際の IDS を GRFICS へ接続しておらず，通信観測の欠落や，攻撃経路生成誤りの影響は今後の評価対象となる．第五に，評価対象は 3 モデルであり，本研究で観測された能力依存性は，モデル数の拡充によってその一般性を確認できる．今後は多段ネットワークや複数ゴールでの評価，実 IDS と連携した攻撃経路生成，ならびに評価モデル数の拡張を通じて，本研究の知見はより広い環境やモデルへ一般化できると期待される．

6. おわりに

本研究では，受動監視由来の攻撃経路情報が LLM エージェントによる ICS ペネトレーションテストに及ぼす効果を，模擬 ICS 環境上の比較実験により評価した．その結果，攻撃経路情報はモデル能力に応じて探索効率やタスク進行を改善し，主として中間機器と到達順序を特定する探索過程を支援することを確認した．今後は，多段環境・複数ゴールでの評価や実 IDS との連携を通じて，本研究で得られた知見の一般性を検証する．

参考文献

[1] Stouffer, K. et al.: Guide to Operational Technology (OT) Security, Technical Report NIST SP 800-82 Rev. 3, National Institute of Standards and Technology (2023).

[2] UK NCSC, CISA, FBI and ASD ACSC: Secure Connectivity Principles for Operational Technology (OT), Joint Guidance (2025).

[3] UK NCSC, CISA and FBI: Creating and Maintaining a Definitive View of Your OT Architecture, Joint Guidance (2025).

[4] Cárdenas, A. A. et al.: Attacks Against Process Control Systems: Risk Assessment, Detection, and Response, *ASIACCS*, pp. 355–366 (2011).

[5] Garcia, L. et al.: Hey, My Malware Knows Physics! Attacking PLCs with Physical Model Aware Rootkit, *NDSS* (2017).

[6] CISA, NSA and FBI: PRC State-Sponsored Actor Living off the Land (Volt Typhoon), Joint Cybersecurity Advisory (2023).

[7] Scarfone, K. et al.: Technical Guide to Information Security Testing and Assessment, Technical Report NIST SP 800-115, National Institute of Standards and Technology (2008).

[8] Deng, G. et al.: PentestGPT: Evaluating and Harnessing Large Language Models for Automated Penetration Testing, *USENIX Security*, pp. 847–864 (2024).

[9] Shen, X. et al.: PentestAgent: Incorporating LLM Agents to Automated Penetration Testing, *ASIACCS*, pp. 375–391 (2025).

[10] Zhu, Y. et al.: Teams of LLM Agents Can Exploit Zero-Day Vulnerabilities, *EACL*, pp. 23–35 (2026).

[11] 小倉 貴志, ほか：産業制御システム向けセキュリティ対策効率化のためのサイバー攻撃シナリオ生成手法，電気学会論文誌 C， Vol. 144, No. 1, pp. 35–42 (2024).

[12] De Pasquale, G. et al.: ChainReactor: Automated Privilege Escalation Chain Discovery via AI Planning, *USENIX Security*, pp. 5913–5929 (2024).

[13] Happe, A. and Cito, J.: Can LLMs Hack Enterprise Networks? Autonomous Assumed Breach Penetration-Testing Active Directory Networks, *TOSEM* (2025).

[14] Singer, B. et al.: Incalmo: An Autonomous LLM-assisted System for Red Teaming Multi-Host Networks, *IEEE S&P* (2026).

[15] Choi, S. et al.: Probabilistic Attack Sequence Generation and Execution Based on MITRE ATT&CK for ICS Datasets, *CSET*, pp. 41–48 (2021).

[16] Folkerts, L. et al.: Measuring AI Agents' Progress on Multi-Step Cyber Attack Scenarios (2026). arXiv:2603.11214.

© 2026 Information Processing Society of Japan

研究倫理

まず，研究実施による第三者への影響を抑えるため，実験対象は Docker 上に構築した模擬 ICS 環境 GRFICS に限定した．実設備や第三者が運用するシステムを評価対象とはせず，PLC への操作についても，設備損傷や圧力変化等の物理的影響を発生させず，所定の Modbus 保持レジスタへの書込み成功をタスク完遂条件とした．また，LLM に与える攻撃経路情報には認証情報や具体的な攻撃コマンドを含めず，既知の CVE は攻撃候補を検討するための参照情報としてのみ利用した．

さらに，本研究は，LLM エージェントによるペネトレーションテストの自律実行を扱うため，研究成果が防御目的だけでなく攻撃の自動化にも転用され得るというデュアルユース上のリスクを有する．このため，本稿では研究上の知見を評価するために必要な実験条件と結果を示す一方で，個々の試行で生成された詳細な攻撃手順の公開は必要最小限とした．

以上のように，本研究には攻撃自動化への転用可能性という残余リスクが存在するものの，実験を制御可能な模擬環境に限定して第三者や物理設備への影響を回避すると共に，掲載する内容を必要最小限に留めることによって，当該リスクの最小化を図った．本研究によって得られた知見を許可された ICS 環境におけるペネトレーションテストの効率化と安全な運用設計に役立てる観点で，本研究の実施と成果公開には十分な公益上の意義があると判断した．

付　　録

A.1　LLM への入力プロンプト

本実験では，LLM エージェントにシステムプロンプトと入力コンテキストを与えた．システムプロンプトはエージェントの役割と行動方針を規定するもので全条件共通とし，攻撃経路情報を含む入力コンテキストのみを条件間で変更することで，挙動の差が攻撃経路情報の有無のみに起因するよう統制した．エージェントはこれらを起点に推論を開始し，以降はコマンド実行結果を逐次受け取りながら次の行動を試行終了まで決定する．

A.1.1　システムプロンプト

システムプロンプトでは，以下を指示した．

- 許可された ICS 環境に対するペネトレーションテストであること
- 攻撃経路に従って次の攻撃対象を決定すること
- MITRE ATT&CK for ICS に基づいて攻撃候補を提案すること
- CVE 情報が与えられた場合は攻撃候補の検討に利用すること
- 取得済み情報の再探索を避けること

代表例を以下に示す．各ブロックは上記の指示に対応する．`ATTACK PLANNING` は与えられた攻撃経路に沿って次の行動を選ばせる中核の指示であり，`ATT&CK` は各行動を MITRE ATT&CK for ICS の戦術へ対応づけて攻撃段階の判定を可能にする．`CVE` は与えられた脆弱性参照を攻撃候補の検討に用いさせ，`HISTORY` は完了済みの列挙の反復を抑制する．これらは全条件で共通に与え，条件間で変化させたのは次の入力コンテキストのみである．

System Prompt (excerpt)

```
[ATTACK PLANNING]
Follow the supplied attack path and propose the next
attack action.
[ATT\&CK]
Associate each proposal with MITRE ATT\&CK for ICS.
[CVE]
Use CVE information when available.
[HISTORY]
Do not repeat previously completed enumeration.
```

A.1.2　入力コンテキスト

入力コンテキストは本研究で操作する唯一の変数である．経路あり条件では，中間機器，到達順序，通信プロトコル，OS 情報，デバイス属性，および CVE 情報を入力した．CVE 情報は，該当機器に関連する既知脆弱性の参照であり，攻撃コマンドではなく攻撃候補を検討するための手がかりとして与えた．一方，経路なし条件では攻撃元および目標 PLC のみを入力し，中間機器や到達経路，および利用しうる脆弱性はエージェント自身に探索させた．いずれの条件でも認証情報や具体的な攻撃コマンドは含めず，経路なし条件では該当欄を `Unknown` や `Not provided` として経路あり条件と項目構成をそろえ，書式差が挙動に影響しないようにした．両条件の入力例を以下に示す．

With attack path

```
Kali Linux
 -> Router/FW
 -> PLC
Protocol : Modbus/TCP
Device   : OpenPLC
OS       : Linux
CVE : https://nvd.nist.gov/...
```

Without path

```
Kali Linux
Target : PLC
Protocol : Unknown
Intermediate devices : Not provided
```

© 2026 Information Processing Society of Japan