深度情報を利用するリキャプチャ検出への光学的攻撃とその対策

礎 哲[1,a)]　ランパッジ サラ[2]　菅原 健[1]

概要：本稿は，国際会議 (USENIX WOOT Conference 2026) で発表済みの研究成果 [1] に基づく．カメラハードウェア内で撮影画像にディジタル署名を付与し出所を保証する技術が生成 AI による Deepfake 画像を防ぐために広まりつつある．しかし，そのような対策を回避する脅威として，コンピュータモニタを再撮影するリキャプチャ攻撃がある．このような攻撃を防ぐため，画像の撮影と同時に赤外光深度センサで深度情報も取得し，画像と深度情報の整合性を検証してリキャプチャ攻撃を検出する手法が提案された．そこで本研究では，赤外光深度センサを利用するリキャプチャ検出システムを，異なるスペクトルの光を分離し再合成する安価な光学フィルタを用いて RGB カメラと赤外光深度センサのシーンを独立に操作することにより回避する攻撃 SynthIR を提案する．また，このような赤外光深度センサを利用するリキャプチャ検出が持つ根本的な限界に対処するため，スマートフォンカメラにすでに搭載されている Dual-Pixel イメージセンサに基づく新しいリキャプチャ検出を提案する．

Optical-Synthesis Attack on Depth-Based Recapture Detection and its Countermeasures

Tetsu Ishizue[1,a)]　Sara Rampazzi[2]　Takeshi Sugawara[1]

Abstract: This paper is based on the paper previously presented at USENIX WOOT 2026 [1]. Image provenance technologies, which attach cryptographic signatures to images at capture time within camera hardware to provide verifiable provenance, are moving toward broad adoption as countermeasures against AI-generated deepfake images. However, provenance-based approaches remain vulnerable to recapture attacks, in which an adversary displays an image on a computer monitor and subsequently recaptures it using a provenance-enabled camera. To defend against such attacks, a recently proposed approach simultaneously captures an RGB image with an RGB camera and measures the depth of the scene with an infrared (IR) depth sensor. It then detects recapture attempts by checking the consistency between the RGB image and the depth map. In this work, we propose SynthIR, an optical-synthesis attack that bypasses recapture detection systems relying on IR depth sensors. SynthIR uses an inexpensive optical filter to separate and recombine visible and IR light, allowing an adversary to independently control what the RGB camera and the IR depth sensor observe. To address the fundamental limitations of these IR-based two-sensor approaches, we propose a new defense pipeline based on dual-pixel image sensors, which are already deployed in modern smartphone cameras.

1. はじめに

生成 AI を用いた Deepfake 画像の作成は深刻な問題となっており，フェイクニュースを通じた世論操作など，複数の事例が報告されている．Image Provenance は，Deepfake 対策の有望な手法として活発に研究されている．Image Provenance では，カメラハードウェア内で撮影時にディジタル署名，メタデータ，その他の記録を付与する．そして，その後の編集履歴を追跡することで，ユーザはコンテンツの履歴を検証し，その真正性と完全性を確認できる．現在，Image Provenance の業界標準である Coalition for Content Provenance and Authenticity (C2PA) [2] は，ス

[1] 電気通信大学
The University of Electro-Communications
[2] フロリダ大学
University of Florida
[a)] ishizue@uec.ac.jp

© 2026 Information Processing Society of Japan

This paper is work in progress and not peer-reviewed.

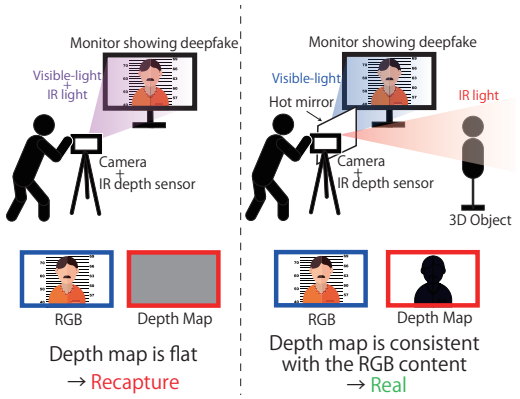


図 1: 攻撃の概要．攻撃者はリキャプチャにより有効な署名付きの Deepfake を作成する．(左) 赤外光深度センサで深度情報を取得しリキャプチャを検出する．(右) 可視光と赤外光をホットミラーで分離することで検出を回避する．

マートフォンやカメラに広く実装されている．

しかし，Image Provenance の手法は，リキャプチャ攻撃 [3] に対して脆弱である．この攻撃では，攻撃者が Deepfake 画像をモニタに表示して，それを Image Provenance に対応したカメラで撮影する．その結果，リキャプチャされた画像には有効な署名が付与され，Image Provenance に基づく画像の真正性の保証を損なう．リキャプチャ検出ではモニタ由来のアーティファクトを利用する手法 [4] が提案されてきたが，そのようなリキャプチャ検出を回避する新たな攻撃 [5] が提案された．Liu らが提案した防御手法 Scoop [6] は，カメラに加えて赤外光深度センサ (LiDAR) を用いて，RGB 画像と同時にシーンの深度を測定する．RGB 画像から推定した深度マップと，深度センサから取得した深度マップとの不一致を利用して，図 1 の左に示すようにリキャプチャを検出する．

Scoop は画像分析によるリキャプチャ検出を回避する攻撃への有効な対策である一方，物理センサから得られる情報の完全性は依然として課題である．本稿では，(I) 攻撃者は偽の情報を注入することで 2 つのセンサを利用したリキャプチャ検出を回避できるか，(II) 2 つのセンサを利用したリキャプチャ検出をそのような攻撃を防ぐように改善できるか，という 2 つのリサーチクエスチョンに取り組む．

1.1 貢献

以下に，元論文 [1] の貢献の一部を示す．

1.1.1 赤外光を利用したリキャプチャ検出における脆弱性

可視光を透過する一方で赤外光を反射する安価な光学素子であるホットミラーを用いて，RGB カメラと赤外光深度センサのシーンを独立に制御することにより，赤外光深度センサによるリキャプチャ検出を回避する攻撃 SynthIR を提案する．図 1 の右に示すように，ホットミラーを対象デバイスの前に配置することで，攻撃者は可視光領域ではモニタ上の Deepfake 画像を RGB カメラに提示できる一方で，赤外光領域では深度センサに対して Deepfake の深度を表すように作られた物体を見せることができる．検出器はこのシーンをリキャプチャとして判定できない．その結果，攻撃者は有効な署名を持つ偽画像を取得できる．

1.1.2 攻撃評価

iPhone 15 Pro および Galaxy S20 Plus 上の Scoop を回避する RGB 画像と物体のペアを作成することで，この攻撃の実現可能性を検証する．さらに，iPhone 15 Pro で用いられているカメラと LiDAR のセンサフュージョンが対応する RGB 画像に近づくように深度マップを内部的に修正していることを明らかにする．Celeb-DF v2 データセット [7] からの画像 50 枚に対して対応する段ボール製の物体を作成し，Scoop を攻撃成功率 100%で回避する．また，まず物体を固定しそれに合致する Deepfake 画像を生成するという別の攻撃手法も検証する．

1.1.3 イメージセンサ内の対策

赤外光深度センサによるリキャプチャ検出の限界を克服するため，効率的なオートフォーカスのために広く搭載されている，デュアルピクセル (Dual-Pixel，DP) イメージセンサに基づく新しい防御手法を提案する．DP イメージセンサは，シーンの深度を保持したまま RGB 画像とステレオ画像を同時に取得できる．これを利用して，DP 画像から深度マップを生成し，撮影された画像間の整合性を検証することで，ロバストなリキャプチャ検出を可能にする．我々の提案手法は，(i) 100 枚の DP 画像データセット [8] および (ii) Sdirt [9] と NTU RGB+D データセット [10] を用いて合成された 2,880 枚の DP 画像データセットにおいて，実画像を一切誤検出することなく，すべてのリキャプチャ画像を検出する．

2. 脅威モデルと攻撃の概要

2.1 脅威モデル

本研究ではポートレート写真における人物の顔の Deepfake に焦点を当てる．これらは，メディアの中でも広く見られ，かつ高いリスクを持つ．攻撃者の目的は，有効な Provenance，たとえば C2PA の暗号署名を持つ AI 生成コンテンツを作成しつつ，複数のセンサ，たとえばカメラと深度センサを用いた検出を回避することである．攻撃者は，この目的に対して，モニタ，投影面，印刷された写真などの表示媒体を撮影するリキャプチャ [5], [6] を用いる．攻撃者は有効なカメラユーザとして対象カメラを物理的に所有しており，撮影環境およびカメラ設定を完全に制御できるものとする．Image Provenance の暗号学的安全性は，ソフトウェア攻撃およびハードウェア攻撃を防ぐセキュリティ機構によって維持されていると仮定する．さらに，対象カメラは，Scoop [6] の手法に基づき，平坦な表示媒体と実際のシーンを区別するために，LiDAR のような赤外

© 2026 Information Processing Society of Japan

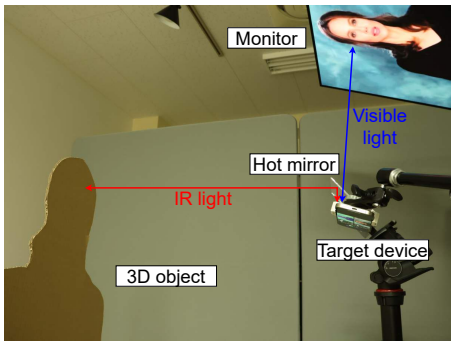


図 2: 攻撃のセットアップ．対象のデバイス (iPhone 15 Pro または Samsung Galaxy S20 Plus) は三脚に固定され，ホットミラーはその前に角度を付けて設置される．カメラは可視光を透過するホットミラー越しに 32 インチモニタを撮影する．一方で，ホットミラーは赤外光を反射するため深度センサは前にある物体を計測する．

光を利用した二次的な深度センサを搭載していると仮定する．攻撃者は，標準 API を通じて取得可能な深度マップを確認しながら物体を位置合わせできるものとする．オフラインで改変画像や動画を生成する攻撃シナリオを想定する．この場合，攻撃者は，事前に生成したコンテンツを用いて，時間的制約の許す限り何度も試行し，攻撃が成功するまで繰り返すことができる．

2.2 攻撃の概要

赤外光深度センサによる深度整合性検証を回避しながらリキャプチャを成功させるという目的を達成するために，SynthIR は RGB カメラと赤外光深度センサのシーンを独立に制御する必要がある．SynthIR は，RGB カメラと赤外光深度センサが異なる光スペクトルを利用することに着目する．すなわち，カメラは波長 750 nm 未満の可視光領域を利用し，赤外光深度センサは 750 nm を超える赤外領域を利用する．したがって，可視光と赤外光は，単純なホットミラー [11] を用いることで任意に分離・合成できる．ホットミラーは安価な光学フィルタで，可視光では透過性を持つ一方，赤外光では反射性を持つ．この性質を用いることで，図 1 右に示すように，攻撃者がカメラと深度センサの見え方を独立に制御できる．カメラのシーンは，リキャプチャのために前方に配置された表示媒体となる一方，赤外光深度センサのシーンはホットミラーによって向きを変えられ，攻撃者が配置した表示媒体中の被写体と整合するように作られた別の物体となる．これを実現するため，攻撃者は類似した深度マップを持つ画像と物体のペアを作成する．これを作成するための方法として，Image-First Approach，Depth-First Approach の 2 つがある．Image-First Approach は，画像に対する制御可能性を優先する．攻撃者は任意の対象画像を固定し，その後，その画像に対応する形状の物体を用いて，必要な深度マップ

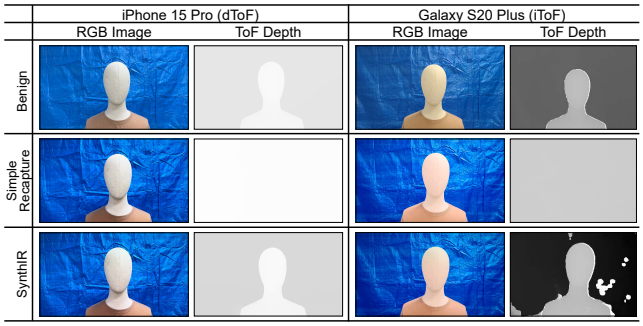


図 3: iPhone 15 Pro と Galaxy S20 Plus から取得された RGB 画像と Time-of-Flight (ToF) センサからの深度マップ．各行は (i) 通常の実際の物体の撮影，(ii) ホットミラーなしのリキャプチャ，(iii) SynthIR をそれぞれ示す．

を作成する．Depth-First Approach では，攻撃者は深度マップの基準となる実際の 3D シーンをまず構築し，それに応じて Deepfake 画像を生成する．最後に，DP イメージセンサを用いて，同一センサ内かつ同一光スペクトルで画像と深度マップを取得する，新しい防御手法を提案する．この方法により，SynthIR を防ぐことを目指す．

3. 攻撃の評価

本節では，Image-First および Depth-First の手法を用いて，攻撃者が画像に対して赤外光深度センサによる検出を回避するための複数の手法を実行できることを示す．ここでは，最新の検出手法の Scoop [6] を回避することに焦点を当てる．Scoop は RGB 画像からの深度と赤外光深度センサによる深度との間の整合性を検証する．本研究では評価対象として，リポジトリ [12] で利用可能な Scoop の実装を用い，ポートレート用のデフォルトパラメータを使用する．すべての実験は，モニタ表面での反射を避けるため暗い環境で実施する．これは，攻撃者が撮影環境を制御できるという脅威モデルと整合している．

3.1 実現可能性の評価

まず，図 2 のセットアップを用いて攻撃の実現可能性を検証する．対象デバイスは，Scoop で対象とされた iPhone 15 Pro と Samsung Galaxy S20 Plus であり，それぞれ direct ToF (dToF) と indirect ToF (iToF) を用いる．最初に，青色の背景の前にマネキンを置いた通常の撮影を行う．次に，マネキンをカメラの視野を占める 32 インチモニタに表示された画像で置き換えて，基準となるリキャプチャを行う．最後に，次のセットアップで攻撃を評価する．リキャプチャ画像をモニタに表示したまま，同じマネキンを物体としてカメラ視野に対して角度をつけ配置する．そして，可視光スペクトル (425-675 nm) で 85%を超える透過率を持ち，赤外光スペクトル ($>$ 750 nm) で 90%を超える反射率を持つホットミラー [11] を，カメラの赤外光深度セ

© 2026 Information Processing Society of Japan

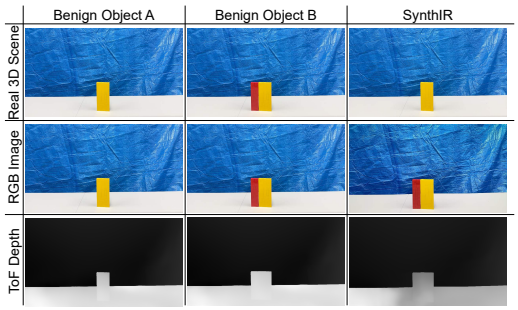


図 4: iPhone 15 Pro 内部のカメラと LiDAR のフュージョンによる弱点．左から 2 つの列はリキャプチャではない Object A と Object B の計測．右の列は SynthIR の結果で，現実世界には Object A しか存在しないにも関わらず，ToF の深度がリキャプチャされた Object B の形状となる．

ンサの前に配置し，マネキンの位置合わせを行う．この構成では，カメラはホットミラー越しにモニタを見ており，深度センサはホットミラーで反射してマネキンを見ている．

図 3 は，リキャプチャを行わない通常の撮影，ホットミラーなしの単なるリキャプチャ，SynthIR 攻撃において，2 台のスマートフォンで撮影された RGB 画像と対応する深度マップを示している．通常の撮影では，画像と深度マップは整合している．しかし，単なるリキャプチャ攻撃，すなわち図 3 の 2 行目では，深度センサはモニタの平面を一様な深度として計測する．そのため，攻撃はすぐに検出可能である．これに対して，SynthIR 攻撃では，モニタ上の画像と深度マップが整合している．

実現可能性評価の過程で，iPhone 15 Pro ではマネキンとモニタの位置合わせがより容易であり，物理的な位置合わせが不完全でも撮影画像に非常によく一致する深度マップを生成する．この現象を検証するため，まず図 4 に示すように，2 つの基本的な LEGO ブロックからなる 2 種類の 3D シーン (Object A および Object B) について，RGB 画像と深度マップを取得する．次に，図 2 に示すセットアップで，実際の物体として Object A を配置し，一方でモニタには Object B の画像を表示して，リキャプチャを行う．図 4 の右の深度マップは，深度センサが Object A を計測するにもかかわらず，Object B の形状を示している．この結果は，iPhone が内部のセンサフュージョン処理によって RGB 画像を利用して最終深度マップを補正している可能性を示唆する．この処理により，SynthIR で要求される物体と画像の厳密な位置合わせが容易となる．

以上から，この評価において，ホットミラーとマネキンを利用することでポートレート画像におけるリキャプチャ検出を回避できる．さらに，深度マップの精度を高めるために用いられるカメラと LiDAR のセンサフュージョンが，精密な位置合わせを必要としない攻撃に悪用できる．以降では，対象として iPhone 15 Pro に焦点を当て，SynthIR が 2 つの異なる手法でどのように実現できるかを検討する．

3.2 Image-First Approach

公開されている最先端の Deepfake 検出データセットに含まれる画像の形状に一致する物体を作成することで，攻撃手法を実装する．Scoop は ToF 深度と RGB 深度から得られるセグメンテーションマップの整合性のみを検証する．本節では，iPhone 15 Pro のセンサフュージョンの弱点を利用することで，単純な段ボールで作成された物体を用いるだけで SynthIR がこの検出を回避できることを示す．Celeb-DF v2 [7] 動画データセットから，50 枚の静止フレームを選択する．次に，各画像についてそのシーン内の被写体に合わせて段ボールを切り抜くことで，対応する物体を作成する．物体のサイズは，人物の頭部が直径およそ 30 cm になるように調整する．画像と対応する段ボール物体のペアは，図 2 に示されている．モニタには画像が表示され，ホットミラーは赤外光を段ボールへと反射している．モニタとホットミラーの位置は，モニタアームと三脚を用いて固定し，最終的な位置合わせは段ボール物体を動かすことで行う．

図 5 の上段は単なるリキャプチャ，下段は Image-First Approach における画像の一例を示している．Scoop に RGB 画像と ToF 深度マップを入力する．図 5 は，これらに加えて，RGB 画像から Scoop が推定する深度マップと最終的な検出結果を示す．検出結果では，Scoop がリキャプチャと判定した領域を赤色で示す．図 5 上段の単なるリキャプチャでは，深度センサはモニタの一様な深度を取得し，Scoop の出力は全体が赤色となる．つまり，領域全体がリキャプチャとして検出される．一方，図 5 下段の SynthIR を用いた結果では，深度センサは段ボール物体の形状を取得しており，Scoop は RGB 画像と ToF による深度が整合していると認識する．その結果，リキャプチャの領域は検出されない．50 枚すべての画像において，Scoop は単純なリキャプチャを検出する．一方，我々の攻撃は Scoop の検出を回避し，攻撃成功率は 100%となる．

3.3 Depth-First Approach

Image-First Approach はリキャプチャ検出の回避には成功するものの，画像ごとに段ボール物体を作製して位置合わせする必要があり，作業コストが大きい．Depth-First Approach では，まず現実世界の 3D シーンを固定し，そのシーンに一致する複数の Deepfake 画像を生成することで，多数の画像・物体ペアを作成し，この制約を克服する．

3.3.1 画像生成手法

Depth-First Approach は 3D シーンを構築し，そのシーンの深度マップと整合するようにモニタに表示するポートレート画像を生成し，攻撃者が望む Deepfake を実現するように，その画像を修正する．最初の手順では，攻撃者は図 6 (a) のように，望ましい画像設定を模倣するため，3D シーンを構築する．次に，Stable Diffusion [13] のように

© 2026 Information Processing Society of Japan

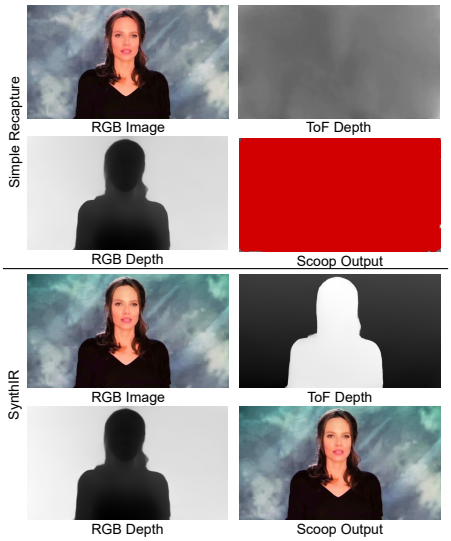


図 5: Image-First Approach の結果．上段はホットミラーなしのリキャプチャ，下段は SynthIR を示す．RGB Image はカメラ，ToF Depth は深度センサの出力を示す．RGB Depth は RGB Image から推定された深度マップ．Scoop Output は Scoop の結果で，リキャプチャ領域を赤で示す．

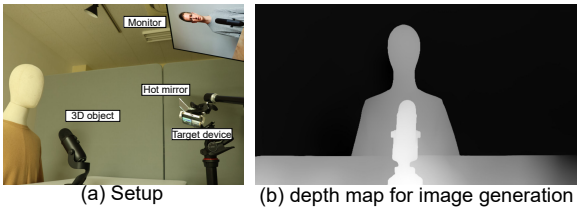


図 6: (a) マイクのある机の前に座るマネキンで構成された Depth-First Approach のセットアップ．(b) そのセットアップから取得し，Deepfake 生成に使用する深度マップ．

広く利用可能な最先端の生成 AI モデルを用いて最初の画像を生成する．このとき，3D シーンの深度マップを入力とする ControlNet [14] を用いることで，その画像の形状を制約する．最後に，攻撃者は最初の画像内の被写体の顔を入れ替えることで，Deepfake 画像を生成する．例えば，Stable Diffusion の img2img を用いることができる．最終的な画像全体の構造は，Inpainting [13] のような公開されている画像編集技術を用いて，変更を被写体ポートレート部分に限定することで保持される．

3.3.2 評価

Depth-First Approach の評価では，攻撃者が単一の 3D シーンを用いて，現実的な Deepfake の人物を生成し，リキャプチャ検出を回避しようとするシナリオを考える．

まず，図 6 (a) に示すように，机の前に座ったマネキンとスタンドマイクを用いて 3D シーンを構築し，図 6 (b) に示す元の深度マップを抽出する．この深度マップを ControlNet [14] への入力として与え，Stable Diffusion XL モデル [16] と RealVisXL5.0 チェックポイント [17] を用いて基準画像を生成する．ControlNet の重みは diffusers/controlnet-depth-sdxl-1.0 [18] を使用する．生成した画像を望ましい Deepfake に似せるため，Inpainting を用いて 2 回目の生成を行う．このとき，顔領域のみをマスクし，その部分を再度生成する．この段階では，対象の顔画像で訓練した LoRA [19] モデルを適用する．

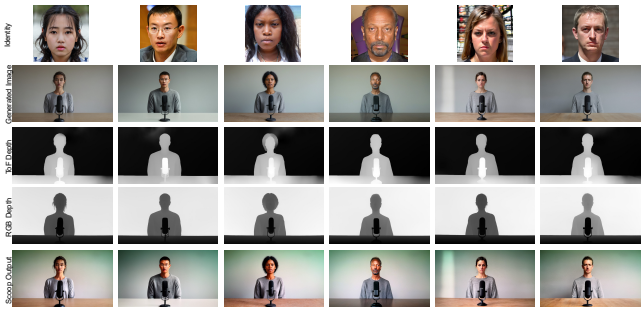


図 7: Depth-First Approach の結果．各行は上から，GANDiffFace [15] の対象のアイデンティティ，図 6 (b) の深度マップからの生成画像，ToF センサで取得された深度マップ，RGB 画像から推定された深度マップ，Scoop の結果．

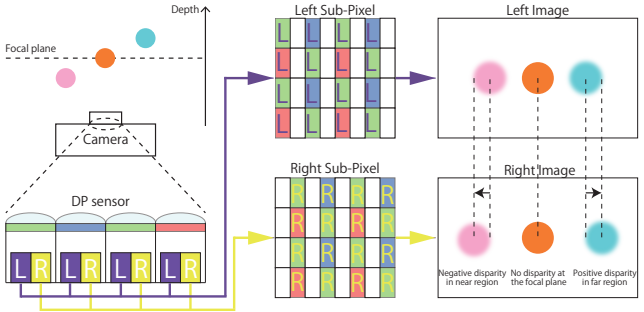


図 8: Dual-Pixel (DP) イメージセンサの原理．各画素は左右 2 つのフォトダイオードから構成され，DP センサは焦点面からの距離に応じて視差が変化する画像ペアを出力する．(ピンク) 近距離の被写体は負の視差を持つ．(オレンジ) 焦点の合った被写体は視差を持たない．(シアン) 遠方の被写体は正の視差を持つ．

対象の顔として，AI で生成された顔から構成される GANDiffFace データセット [15] から，図 7 の最上段に示すとおり 6 つのアイデンティティを選択する．各アイデンティティについて合計 55 枚の多様な画像が得られ，それらで RealVisXL5.0 チェックポイントで初期化した Stable Diffusion XL モデルの LoRA モデルを訓練する．

図 7 は結果をまとめたものであり，各列は 1 つのアイデンティティに対応している．各行は，データセット内の元のポートレート画像，生成画像，深度センサから得られた深度マップ，RGB 画像から推定された深度マップ，Scoop の最終出力を示す．Scoop はリキャプチャを検出できず，最終出力にはリキャプチャの領域が示されない．これらの結果から，SynthIR 攻撃を実行するうえで Depth-First Approach が有効であることを確認できる．

© 2026 Information Processing Society of Japan

4. 防御手法

追加の深度センサを用いるリキャプチャ検出は，画像と深度マップが完全に対応しており，かつ両者が同一の光路から得られることを基本的な前提としている．しかし，異なる光スペクトルの光はホットミラーなどの光学素子を用いて分離できるため，赤外光深度センサではこの前提は成立しない．この限界を克服するため，デュアルピクセル（Dual-Pixel，DP）イメージセンサをリキャプチャ検出に利用する，新しい検出パイプラインについて説明する．

4.1 Dual-Pixel イメージセンサ

図 8 に示すように，DP イメージセンサでは 1 画素がその受光領域の左半分と右半分にそれぞれ対応する 2 個のフォトダイオードから構成され，わずかに異なる光路の光を取得するよう構成されている．したがって，DP イメージセンサは，DP 画像と呼ばれる一組の画像を生成できる．最終的な RGB 画像は，この 2 枚の画像から合成される．この DP 画像には正または負の視差が含まれており，それを深度へ変換できる [20]．図 8 に示すように，近距離の被写体では負の視差が生じ，焦点面上の被写体では視差がなく，より遠方の被写体では正の視差が生じる．DP 画像を利用することで，効率的なオートフォーカスを実現できる．

DP イメージセンサは，深度推定への応用についても研究されている [21], [22]．Ishizue ら [23] は，DP イメージセンサから抽出した深度をリキャプチャ検出に利用できる可能性を示したが，RGB 画像を考慮しない単純な平面フィッティングに限定されており，スマートフォンの環境やシナリオにおける実現可能性は明らかではなかった．

4.2 パイプライン

DP イメージセンサは対応する視差を含む DP 画像と，その一組の画像から合成された RGB 画像を出力する．DP 画像のペアにステレオマッチングまたは専用の深度推定モデルを適用することで，深度マップまたは視差マップを取得できる．その後アルゴリズムは，RGB 画像と DP 画像からそれぞれセグメンテーションマップを生成する．RGB 画像からは，単眼深度推定モデルを用いてセグメンテーションマップを生成する．DP 画像からは，得られた深度マップを用いてセグメンテーションマップを生成する．そして，2 つのセグメンテーションマップ間の類似度を閾値と比較することによって，リキャプチャかどうかを判定する．DP 画像から推定する深度は LiDAR による深度よりノイズが大きく，単一の物体領域が複数の Segment に分割される場合がある．そこで，Segment ごとの一致ではなく，複数 Segment 間の大域的な類似度を評価する V-measure [24] を使用する．V-measure は 0 から 1 までの値を取り，1 に近いほど類似度が高い．深度推定には，DP



図 9: EOS R10，Pixel 3，Pixel 4 での実現可能性の評価．上 3 行は通常の撮影，下 3 行はリキャプチャを示す．各列は RGB 画像，RGB 画像からの深度，RGB 画像の深度によるセグメンテーション，DP 画像からの深度，DP 画像の深度によるセグメンテーションを示す．

画像には Kurita らの手法 [22] を適用し，RGB 画像には Depth-Pro [25] を適用する．深度マップを平滑化して深度値の Histogram を作成し，隣接する Local Maximum 間の Local Minimum を閾値として Segment を生成する．

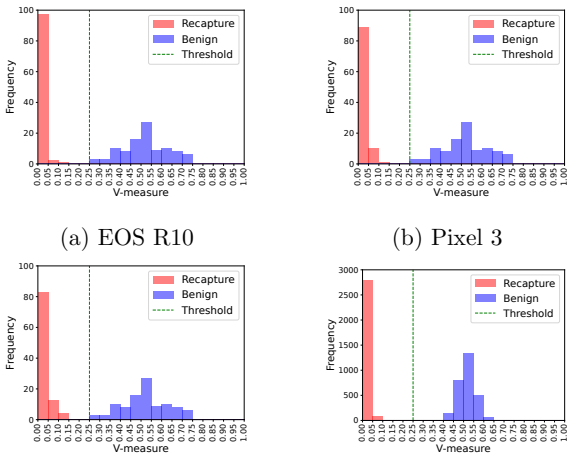
4.3 実現可能性の評価

まず，ズームレンズ Canon RF-S18-150mm F3.5-6.3 IS STM を装着した DSLR カメラ Canon EOS R10[*1]，DP イメージセンサを搭載した Google Pixel 3，Google Pixel 4 の 3 つのデバイスから深度マップを取得できるか検証する．Canon EOS R10 の DP 画像は，RAW 画像を Digital Photo Professional 4 で処理することで抽出する．Google Pixel 3 および Pixel 4 の DP 画像は，Garg ら [21] と同じ方法で取得し，ソフトウェア上の制約により DP 画像と RGB 画像は別々に撮影し，カメラパラメータは自動的に設定される．実際の 3D シーンとして，青色の背景の前にマネキンを配置する．カメラの焦点はマネキンの顔に合わせる．スマートフォンについては，図 2 と同じセットアップを使用する．各カメラについて，通常の実シーンとリキャプチャシーンの両方を撮影する．

図 9 は，3 つのデバイスについて，通常のシーンとリキャプチャシーンの結果をまとめたものである．各列には RGB 画像，RGB 画像からの深度マップ，RGB 画像からのセグメンテーションマップ，DP 画像からの深度マップ，DP 画像からのセグメンテーションマップを示す．通常の

[*1] 実シーンの撮影条件は，ISO 100，露光時間 1/15 秒，絞り f/3.5 である．対応するリキャプチャのシーンは，ISO 100，露光時間 0.5 秒，絞り f/11 で撮影する．

© 2026 Information Processing Society of Japan



(a) EOS R10　(b) Pixel 3

(c) Pixel 4　(d) Synthesized

図 10: 青いバーは通常の撮影，赤いバーはリキャプチャの V-measure の分布を示す．(a)-(c) は DP 画像データでの各カメラでの結果，(d) は生成された DP 画像での結果．

シーンの DP 画像から推定された深度マップにはマネキンの輪郭が現れるが，リキャプチャではモニタ表面が平坦であるため DP 画像から得られる深度マップは一様になる．通常のシーンにおける V-measure の値は Canon EOS R10 で 0.53，Google Pixel 3 で 0.59，Google Pixel 4 で 0.72 であるのに対し，リキャプチャにおける V-measure はすべてのデバイスで 0 となる．これは，平坦なモニタ表面が存在することと整合する．以上から，DP イメージセンサを用いて実世界のシーンから深度情報を取得できる．

4.4　DP 画像データセットでの評価

検出パイプラインの有効性を検証するため，Punnappurath ら [8] のデータセットを用い，検出精度を評価する．このデータセットは 100 ケースで構成され，各ケースには，RGB 画像と対応する DP 画像が含まれている．一方，攻撃ケースはデータセット内の RGB 画像をモニタに表示し，図 2 と同じセットアップで Canon EOS R10，Google Pixel 3，Google Pixel 4 を用いてリキャプチャし作成する．

図 10 の (a)〜(c) は，それぞれ EOS R10，Pixel 3，Pixel 4 について，通常のケースの V-measure を青色，リキャプチャのケースの V-measure を赤色で示したヒストグラムである．通常のケースとリキャプチャのケースは互いに分かれた分布を示しており，この分布から判定閾値を決定できる．最終的に，ヒストグラムから得られた閾値 0.25 を使用して分類を行う．提案する防御手法は，すべてのカメラにおいて，通常の画像を一枚も誤ってリキャプチャと検出することなく，すべてのリキャプチャのケースを検出する．

4.5　生成データセットでの評価

Sdirt [9] を用いて DP 画像を生成し，提案防御手法を人物の被写体で検証する．Sdirt は，レイトレーシングと機械学習モデルに基づき，RGB 画像と深度マップから DP 画像を生成する手法である．対象には，NTU RGB+D 動画データセット [10] のセットアップ番号 1 を使用する．このデータセットは，2,880 の RGB 動画および深度マップ動画から構成される．各動画の中間フレームを通常のケースとして使用する．したがって，通常のケースのデータは，2,880 組の静止 RGB 画像と静止深度マップから構成される．その後，Sdirt の PSFNet モデルをデフォルト設定で使用して DP 画像を生成する．通常のケースは，RGB 画像とこの手順によって生成された DP 画像から構成される．実験条件を揃えるため，攻撃ケースについても Sdirt を用いて DP 画像を生成する．ただし，攻撃ケースでは，1 m の距離から LiDAR (Intel RealSense L515) を用いて精密に測定したモニタの深度マップを使用する．通常のケースと攻撃ケースを，提案手法へ入力して評価する．なお，本評価における DP 画像からの深度推定には，低解像度の DP 画像に適した Sdirt の DfDP モデルを用いる．

図 10 (d) は，提案手法から得られた V-measure 値のヒストグラムを示している．通常のケースを表す青色の分布と，攻撃ケースを表す赤色の分布は明確に分かれている．前の評価と同じ閾値 0.25 を使用した結果，提案防御手法は，通常ケースとリキャプチャのケースをいずれも 100% の精度で正しく検出する．人物ポートレートを対象としたシナリオにおいても，提案手法が有効である．

5.　まとめ

本稿では RGB カメラと赤外光深度センサが取得する視野を，攻撃者がそれぞれ独立に操作できるようにする SynthIR を提案する．SynthIR によって，RGB 画像と物理的な物体のペアを作成し，Image-First Approach，Depth-First Approach において，最先端の防御手法である Scoop を回避できることを実証する．また，DP イメージセンサを用いた単一のセンサによるリキャプチャ検出手法を提案し，DP 画像データセットと，最先端の手法によって生成した DP 画像を用いた評価の結果，実画像を誤検出することなく，評価したすべてのリキャプチャ画像を検出できる．

6.　研究倫理と研究データの入手性

本研究で使用する人に関するデータは，公開 Dataset から取得したもの，または特定の実在人物を指定せず AI によって生成したものに限定する．元論文 [1] の出版に先立ち，本研究の知見を Apple および Samsung に脆弱性開示を行った．本論文の詳細は，ウェブサイトで公開している．また，リポジトリにおいて，成果物を公開している．

謝辞　本研究の一部は JST CREST JPMJCR23M4 と JST FOREST JPMJFR2531 の助成を受けた．

© 2026 Information Processing Society of Japan

参考文献

[1] Tetsu Ishizue, Sara Rampazzi, and Takeshi Sugawara. Breaking infrared recapture detection: Optical-synthesis attacks and depth-aware in-sensor countermeasures. In *20th USENIX WOOT Conference on Offensive Technologies, WOOT 2026*. USENIX Association, 2026.

[2] Coalition for Content Provenance and Authenticity (C2PA). An open technical standard providing publishers, creators, and consumers the ability to trace the origin of different types of media. `https://c2pa.org/`, 2025. Accessed: 24-05-2025.

[3] Alexander Vilesov, Yuan Tian, Nader Sehatbakhsh, and Achuta Kadambi. Solutions to deepfakes: Can camera hardware, cryptography, and deep learning verify real images? *CoRR*, abs/2407.04169, 2024.

[4] Eldho Abraham. Moiré pattern detection using wavelet decomposition and convolutional neural network. In *IEEE Symposium Series on Computational Intelligence, SSCI 2018*, pages 1275–1279. IEEE, 2018.

[5] Seongbin Park, Alexander Vilesov, Jinghuai Zhang, Hossein Khalili, Yuan Tian, Achuta Kadambi, and Nader Sehatbakhsh. Chimera: Creating digitally signed fake photos by fooling image recapture and deepfake detectors. In Lujo Bauer and Giancarlo Pellegrino, editors, *34th USENIX Security Symposium, USENIX Security 2025*, pages 4305–4324. USENIX Association, 2025.

[6] Yuxin (Myles) Liu, Habiba Farrukh, Ardalan Amiri Sani, Sharad Agarwal, and Gene Tsudik. Scoop: Mitigation of recapture attacks on provenance-based media authentication. In Lujo Bauer and Giancarlo Pellegrino, editors, *34th USENIX Security Symposium, USENIX Security 2025*, pages 4285–4304. USENIX Association, 2025.

[7] Yuezun Li, Pu Sun, Honggang Qi, and Siwei Lyu. Celeb-DF: A Large-scale Challenging Dataset for DeepFake Forensics. In *IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 2020.

[8] Abhijith Punnappurath, Abdullah Abuolaim, Mahmoud Afifi, and Michael S. Brown. Modeling defocus-disparity in dual-pixel sensors. In *2020 IEEE International Conference on Computational Photography, ICCP 2020*, pages 1–12. IEEE, 2020.

[9] Fengchen He, Dayang Zhao, Hao Xu, Tingwei Quan, and Shaoqun Zeng. Simulating dual-pixel images from ray tracing for depth estimation. *arXiv preprint arXiv:2503.11213*, 2025.

[10] Amir Shahroudy, Jun Liu, Tian-Tsong Ng, and Gang Wang. NTU RGB+D: A large scale dataset for 3D human activity analysis. In *2016 IEEE Conference on Computer Vision and Pattern Recognition, CVPR 2016*, pages 1010–1019. IEEE Computer Society, 2016.

[11] Edmund Optics. 101.6x127mm, 45° AOI, Hot Mirror #43-958. `https://www.edmundoptics.com/p/1016-x-127mm-45deg-aoi-hot-mirror/5427/`, 2025. Accessed: 1-3-2026.

[12] Yuxin (Myles) Liu, Habiba Farrukh, Ardalan Amiri Sani, Sharad Agarwal, and Gene Tsudik. Scoop: Mitigation of recapture attacks on provenance-based media authentication. `https://github.com/trusslab/scoop`, 2025. Accessed: 28-02-2026.

[13] Robin Rombach, Andreas Blattmann, Dominik Lorenz, Patrick Esser, and Björn Ommer. High-resolution image synthesis with latent diffusion models. In *IEEE/CVF Conference on Computer Vision and Pattern Recognition, CVPR 2022*, pages 10674–10685. IEEE, 2022.

[14] Lvmin Zhang, Anyi Rao, and Maneesh Agrawala. Adding conditional control to text-to-image diffusion models. In *IEEE/CVF International Conference on Computer Vision, ICCV 2023*, pages 3813–3824. IEEE, 2023.

[15] Pietro Melzi, Christian Rathgeb, Ruben Tolosana, Rubén Vera-Rodríguez, Dominik Lawatsch, Florian Domin, and Maxim Schaubert. GANDiffFace: Controllable generation of synthetic datasets for face recognition with realistic variations. In *IEEE/CVF International Conference on Computer Vision, ICCV 2023 - Workshops*, pages 3078–3087. IEEE, 2023.

[16] Dustin Podell, Zion English, Kyle Lacey, Andreas Blattmann, Tim Dockhorn, Jonas Müller, Joe Penna, and Robin Rombach. SDXL: improving latent diffusion models for high-resolution image synthesis. In *The Twelfth International Conference on Learning Representations, ICLR 2024*. OpenReview.net, 2024.

[17] SG161222. RealVisXL V5.0 (SDXL checkpoint). `https://huggingface.co/SG161222/RealVisXL_V5.0`, 2024.

[18] diffusers. controlnet-depth-sdxl-1.0. `https://huggingface.co/diffusers/controlnet-depth-sdxl-1.0`, 2023.

[19] Edward J. Hu, Yelong Shen, Phillip Wallis, Zeyuan Allen-Zhu, Yuanzhi Li, Shean Wang, Lu Wang, and Weizhu Chen. Lora: Low-rank adaptation of large language models. In *The Tenth International Conference on Learning Representations, ICLR 2022, Virtual Event, April 25-29, 2022*. OpenReview.net, 2022.

[20] Neal Wadhwa, Rahul Garg, David E. Jacobs, Bryan E. Feldman, Nori Kanazawa, Robert Carroll, Yair Movshovitz-Attias, Jonathan T. Barron, Yael Pritch, and Marc Levoy. Synthetic depth-of-field with a single-camera mobile phone. *ACM Trans. Graph.*, 37(4):64, 2018.

[21] Rahul Garg, Neal Wadhwa, Sameer Ansari, and Jonathan T. Barron. Learning single camera depth estimation using dual-pixels. In *2019 IEEE/CVF International Conference on Computer Vision, ICCV 2019, Seoul, Korea (South), October 27 - November 2, 2019*, pages 7627–7636. IEEE, 2019.

[22] Teppei Kurita, Yuhi Kondo, Legong Sun, Takayuki Sasaki, Sho Nitta, Yasuhiro Hashimoto, Yoshinori Muramatsu, and Yusuke Moriuchi. Revisiting disparity from dual-pixel images: Physics-informed lightweight depth estimation. In *WACV 2025*, pages 8389–8399, 2025.

[23] Tetsu Ishizue, Sara Rampazzi, and Takeshi Sugawara. Poster: Recapture detection using disparity map obtained from dual-pixel image sensors. In Chun-Ying Huang, Jyh-Cheng Chen, Shiuh-Pyng Shieh, David Lie, and Véronique Cortier, editors, *Proceedings of the 2025 ACM SIGSAC Conference on Computer and Communications Security, CCS 2025*, pages 4743–4745. ACM, 2025.

[24] Andrew Rosenberg and Julia Hirschberg. V-measure: A conditional entropy-based external cluster evaluation measure. In *EMNLP-CoNLL 2007, Proceedings of the 2007 Joint Conference on Empirical Methods in Natural Language Processing and Computational Natural Language Learning*, pages 410–420. ACL, 2007.

[25] Alexey Bochkovskiy, Amaël Delaunoy, Hugo Germain, Marcel Santos, Yichao Zhou, Stephan R. Richter, and Vladlen Koltun. Depth pro: Sharp monocular metric depth in less than a second. In *The Thirteenth International Conference on Learning Representations, ICLR 2025, Singapore, April 24-28, 2025*. OpenReview.net, 2025.

© 2026 Information Processing Society of Japan