XRにおける聴覚刺激攻撃の検出: 音提示の妥当性に基づく検知手法の提案

大塚 航世[1,a)]　金岡 晃[1]

概要：XR 環境下では、不正な視覚や聴覚刺激の提示による攻撃の可能性が指摘されている。これらの攻撃に対する防御研究の議論は不十分であり、特に聴覚刺激に対する防御は限られている。まず考えられる対策としては、音源や音声データが正規のものかを照合する資産照合が挙げられる。しかしこの方法では、正規の音源や音声データが、その提示設定のみを改変されて悪用される場合を検出できない。そこで本研究は、音資産の真正性ではなく提示の妥当性に着目し、音がどのように提示されるべきかを音の役割ごとにポリシーとして事前に定義したうえで、実行時の提示がそこから逸脱していないかを判定する検知手法を提案する。本稿では、ポリシー構築のために、既存研究から悪用され得る音の提示項目を整理し、それぞれが実行時にどこまで観測可能かを示した。さらに、一部の役割と項目を対象に試験的な実装を行い、提示設定の改変を提示ポリシーからの逸脱として検知しうることを確認した。

Detecting Auditory Stimulus Attacks in XR: A Method Based on the Validity of Sound Presentation

Kousei Otsuka[1,a)]　Akira Kanaoka[1]

Abstract: In XR environments, attacks that present unauthorized visual or auditory stimuli have been identified as a potential threat. Defensive research against such attacks remains underexplored, and countermeasures for auditory stimuli in particular are limited. The obvious first line of defense is asset verification, which confirms that a sound source and its audio data are the ones the application legitimately registered. Such checks say nothing about how a sound is played, and an attacker who tampers only with the presentation settings passes them unchallenged. We therefore shift the question from the authenticity of the sound asset to the validity of its presentation. For each role a sound plays, we define in advance a policy stating how it is expected to be presented, and we judge at runtime whether the actual presentation departs from that policy. In this study, we take a first step toward such policies by organizing the presentation attributes that prior work indicates are open to abuse, and by establishing how far each of them can be observed while an application is running. We further report a preliminary implementation covering a subset of roles and attributes, which shows that altered presentation settings surface as policy violations.

1. はじめに

XR 技術の普及に伴い、視覚や聴覚への刺激提示を悪用し、ユーザの知覚や行動を操作する攻撃の可能性が指摘されている [1–3]。なかでも聴覚刺激は視野外からも作用するため、攻撃面が視覚刺激より広いという特徴を持つ [4]。

著者らは先行研究において、空間音響を悪用してユーザの視点方向を誘導する Auditory Viewpoint Manipulation Attack（AVMA）を提案し、ユーザスタディを通じて評価した [5]。自己報告では半数の参加者が頭部方向の誘導が生じたと回答し、HMD（Head Mounted Display）のテレメトリログの分析[*1]では最大 73.04 度の変位が観測された一方、提示された音を攻撃や悪意として認識した参加者は 26.7% にとどまった。このことは、ユーザ自身の気づきに依存した防御には限界があり、システム側での防御が必要である

[1] 東邦大学
Toho University
[a)] 7526001o@st.toho-u.ac.jp

[*1] テレメトリ分析は [5] には含まれず、同文献を発展させた成果として査読付き国際会議に投稿中である。

© 2026 Information Processing Society of Japan

This paper is work in progress and not peer-reviewed.

ことを示している。

しかし、こうした攻撃に対する防御手法の議論は依然として不十分であり、特に聴覚刺激を対象とした防御はほとんど検討されていない。防御は検知と対応に大別できるが、対応は不正が検知されて初めて成立するため、本研究では検知に焦点を当てる。

具体的には、音の提示の妥当性に着目し、音がどのような音響的、空間的、および再生上の性質をもって提示されるべきかをポリシーとして事前に定義したうえで、実行時の提示がそこから逸脱していないかを判定する手法を提案する。本稿では、こうした性質を規定する個々の項目を提示項目と呼ぶ。さらに、音をその役割に応じて分類し、役割ごとに共通する提示ポリシーを定義する。妥当な提示のあり方は音が担う役割によって定まるため、役割ごとのポリシーをプリセットとして用意しておけば、開発者は各音源に役割を指定するだけでよい。

本研究が最終的に目指すのは、音の役割ごとの提示ポリシーを確立し、それに基づく検知システムを構築したうえで、検知性能と開発者負担を評価することである。その前段階として本稿では、著者らの先行研究 [4] を基に聴覚刺激攻撃に悪用され得る提示項目を選定し、18 項目の監視項目として整理した。そのうえで、各項目が実行中に判定可能であるかを Unity 環境において調査し、既存の資産照合が対応する 2 項目を除く 16 項目のうち 13 項目が判定可能である一方、3 項目には判定上の制限が存在することを示した。さらに、一部の役割と監視項目を対象に検知機構を試験実装し、資産照合を通過する形の AVMA をポリシーの逸脱として検知できることを確認した。

2. 関連研究

2.1 XR 環境における知覚操作攻撃

XR 環境では、不正な刺激提示によってユーザの知覚や行動を操作する攻撃が報告されている。視覚刺激を対象とした研究では、Virtual 空間や 3D オブジェクトをユーザに気づかれないように動かすことで、物理空間上の移動や視線、頭部方向を操作できることが示されている [1, 6]。またこうした視覚情報操作は、階段の踏み外しやコントローラの顔面衝突といった身体的危害にもつながりうる [2]。Cheng らは、これらの攻撃を Perceptual Manipulation Attack（PMA）として整理し、ユーザが悪意ある操作と認識しないまま誤反応を示しうることを報告している [3]。

PMA に関する研究の多くは視覚刺激を対象としており、聴覚刺激に関する議論は限定的である。Otsuka らは、音の基本特性と XR 環境で加わる応用特性を整理して悪用により生じうる 21 の脅威を体系化するとともに、聴覚刺激は視野外からも作用するため攻撃面が広く、利用者の気づきに依存した防御が有効に機能しない可能性を指摘している [4]。de Haas らも体系的レビューにより、AR 環境における音響設計が注意や行動の操作に利用されうることを示している [7]。さらに大塚らは、空間音響を悪用して視点方向を誘導する AVMA を提案し、正規に存在する音であっても攻撃に悪用でき、ユーザが攻撃と認識しないまま誘導されうることを実証した [5]。

2.2 XR 環境における不正な刺激の検証、検知手法

XR 環境における不正な刺激提示に対する検証および検知は、大きく 3 つの方向から検討されている。

第一に、資産そのものの完全性や真正性を検証する手法である。金岡は、XR シーングラフを順序付き根付き木として形式化し、階層的なハッシュ値と電子署名によって、ノードの改竄や不正な部分木の挿入を検知する手法を提案している [8]。

第二に、出力の提示方法を事前に定義したポリシーによって制御する手法である。Lebeck らは、道路標識や歩行者を Virtual オブジェクトが隠蔽するといった不適切な提示を、ポリシーに基づいて防止する Arya を提案している [9]。

第三に、提示された内容を機械学習を用いて検査する手法である。Xiu らは VLM（Vision-Language Model）を用いて有害な Virtual コンテンツを検出する ViDDAR を提案し [10]、Chen らは VLM と統計的推論を組み合わせて認知攻撃を検知する CADAR を提案している [11]。

このうち第二および第三の手法は主として視覚的な出力を対象としており、聴覚刺激の提示に対する検討は行われていないものの、アプローチ自体は出力の様式に依存せず、聴覚刺激に対しても同様に成立しうる。とくに Arya は、提示方法をポリシーによって制約する点で本研究と共通する枠組みを与える。

3. 攻撃者モデル

本研究では、Unity Asset Store のような拡張リソース配布基盤を経由する攻撃者を想定する [12]。VR アプリケーション開発では実装コストの削減のためサードパーティ製アセットや SDK の導入が一般的であるが、ガイドラインに基づく審査がアセット内部の挙動やスクリプトを細部まで検証しているかは不明である。開発者は攻撃が仕込まれたアセットを正当なリソースとして導入し、意図せず自らのアプリケーションを通じてユーザに攻撃を実施することになる。

導入されたアセットに含まれるスクリプトは、アプリケーション本体と同一のプロセス上で同一の権限をもって実行される。Unity では実行時にシーン上のオブジェクトおよびコンポーネントの公開プロパティに対して読み書きが可能である [13]。したがって攻撃者は、自ら音源や音声

© 2026 Information Processing Society of Japan

データを追加できるだけでなく、開発者が配置した既存の音源を実行時に同定し、その提示設定を書き換えることができる。

攻撃者の目標は、音提示を通じてユーザの知覚、認知、行動に作用すること、および作業の妨害である。

本研究では、OS、Unity ランタイム、空間音響 SDK、および本研究が提案する検知機構自体が、攻撃者によって改ざんや無効化されていないことを前提とする。また、ボイスチャットのように実行時に外部から流入する音声は、アプリケーション内の提示設定として表現されないため対象外とする。デバイスやドライバの層で音声出力そのものを改ざんする攻撃も、アプリケーション層での観測範囲を超えるため対象外とする。

攻撃者は音を発する音源機能が付与されたオブジェクトと再生される音声ファイル（`clip`）のそれぞれについて、開発者が用意した正規資産を流用するか、自ら用意したものを持ち込むかを選択できる。この選択の組み合わせにより、攻撃パターンは 4 通りに整理される。内訳を付録の表 A·1 に示す。

4. 提案手法の概要

本研究では、音資産の真正性ではなく、音の提示の妥当性に着目する。音がどのように提示されるべきかは、その音によって異なる。例えば BGM や通知音のように作品世界の外側から提示される音（non-diegetic sound）は空間内の特定の位置に定位せず、作品世界内の対象から発せられる音（diegetic sound）はその対象の位置に定位し、対象とともに移動することが期待される [14]。

そこで本研究では、音をその役割に応じて分類し、各監視項目について取りうる値または状態を規定した提示ポリシーを役割ごとに定義する。定義したポリシーは、実行中の提示との照合に用いる。本手法は、開発者が自身のアプリケーションをデバッグ実行またはテスト実行する際に動作し、シーン内の各音源について監視項目の値を実行中に取得し、その音源へ割り当てられた役割のポリシーと照合する。いずれかの監視項目がポリシーを満たさない場合、その音提示を逸脱として報告する。

以上の適用場面のもとで、本手法が満たすべき要件を以下の 3 点として整理する。音源と音声データがいずれも正規であっても、その提示の逸脱を検出できること（要件 1）。既存の資産照合では検知できない領域を扱えることが、本手法を既存手法と併せて用いる意義となる。開発者が記述すべき情報の量が、ポリシーの項目数に依存しないこと（要件 2）。ポリシーの詳細化が開発者の負担に直結せず、検知範囲の拡張と実用性を両立させるためである。実行時に取得可能な情報のみによって判定できること（要件 3）。定義した監視項目が実際に観測できなければ、監視そのものが成立しないためである。

これらの要件を満たすことにより、本手法は 2.2 節で述べた既存の検知手法にない二つの性質を得る。第一に、資産の完全性や真正性を検証する手法 [8] では扱わない、正規の資産を用いた改変を検出できる。第二に、逸脱を生じた音源とその逸脱内容を特定できる。提示された信号を検査する手法 [10, 11] は、視覚においては合成後の映像にも空間的な分離が残るため原因を絞り込めるが、聴覚では全ての音源が単一の波形へ合成されるため、同じ方向を採っても原因の音源を分離できない。

5. 監視対象の提示項目

音の提示の在り方を示す項目は様々なものが考えられるが、本研究が監視の対象とするのは、開発者の意図しない値で提示されたときに利用者へ被害が生じうる提示項目である。著者らは先行研究で、XR 環境における聴覚刺激の音響特性（大きさ、高さ、音色、持続時間）および空間的な応用特性（方向、距離、動き、反響）が攻撃に悪用され得ることを議論している [4]。本研究では主に、これらの特性に対応する提示項目を整理し、監視項目として定義した。以上により導いた各監視項目を、空間群、音響群、再生群、資産群の 4 つに分類し、説明とともに表 1 に示す。各項目の詳細な一覧表は付録の表 A·2 で、採用理由および想定される悪用シナリオは付録 A.3 に示す。また、本稿で定義した監視項目に対してポリシーが実際にどのように記述されるかの例を付録 A.4 に示す。

5.1 空間群（S）

音が 3D 空間内のどこから、どのように空間的に提示されるかを規定する項目群であり、音像の定位に関わる設定に加え、その定位が成立する条件を含む。主に著者らの先行研究 [4] の空間的な応用特性から導出した。このうち S1 は他の空間群の前提にあたり、空間定位が必要ない音では他の項目がとるべき値が既定値に定まる。また S4 と S5 は、「動き」の特性を、聞き手への追従性と世界座標での移動の有無の 2 項目に分けたものである。追従する音も聞き手の運動にともなって世界座標上を移動するため、移動の有無だけでは正常な追従と不正な移動とを区別できないためであり、著者らが実証した AVMA [5] がこの区別を要する例にあたる。

5.2 音響群（A）

提示の段階で音そのものに加えられる信号処理の設定を規定する項目群であり、音源の位置に依存しない性質のみを扱う。主に著者らの先行研究 [4] の音響特性のうち大きさ、高さ、音色から導出した。素材そのものの音響特性は資産群が担保するため、本群が対象とするのは提示時に加

© 2026 Information Processing Society of Japan

表 1: 監視対象とする提示項目。値の型、ポリシー上の値域および導出元は付録の表 A·2 に示す。

ID	監視項目	説明
S1	空間定位の有無	音に空間定位が適用されているか
S2	定位の広がり	音像が一点に定まるか広がりを持つか
S3	距離減衰の特性	距離に応じた音量の減衰のしかた
S4	聞き手への追従性	音源が聞き手の位置や姿勢に追従するか
S5	音源の動きの有無	音源が世界座標系を移動するか
S6	反響の適用	その音に反響が伴って聞こえるか
S7	遮蔽処理の適用	障害物によって直接音が遮られるか
S8	発音主体との整合性	音を発する実体との空間的関係
A1	音量設定	その音が提示される大きさ
A2	ピッチ設定	本来からの音の高さの変位
A3	音色改変処理の適用	音色を変える処理が加えられているか
P1	持続性	音が鳴り続けるか単発で終わるか
P2	発生頻度	単位時間あたりの発生回数
P3	同時多重度	同時に重なって鳴っている音の数
P4	優先度	競合時にその音が優先して発音される度合
R1	音声データの正当性	提示中の音声データが正規のものか
R2	音源の正当性	音を発している音源が正規のものか
R3	音源と音の対応の正当性	対応が開発者の意図どおりか

えられる変化のみである。

5.3 再生群（P）

音そのものの性質や空間上の配置ではなく、再生の制御に関わる項目を扱う。このうち P2 と P3 は音単体の特性ではなく、複数の音の関係として本研究が追加したものである。個々の再生がいずれも正常な設定であっても、短時間に反復すれば注意を継続的に奪うことができ、同種の音を多数重ねれば個々の設定音量が正常なまま実効音量を増幅できる。これらは単一の音の設定を読み取るかぎり検出できず、複数の音の関係あるいは時系列上の発生履歴としてのみ観測される。

5.4 資産群（R）

音の提示のあり方ではなく、提示されている素材そのもの、および素材どうしの対応が正規に登録されたものかを問う項目群である。このうち R1 および R2 は音声データおよび音源そのものの正当性を問うものであり、既存の資産照合で検出可能である。一方 R3 は、音源と音声データがいずれも正規であっても、その対応が開発者の意図と異なる場合を扱う。例えば、空間音響の適用が許可された正規の音源が存在すれば、攻撃者はその音源から別の正規の音声を再生すればよい。双方が登録済みであるため資産照合は通過する一方、開発者が意図した対応からは逸脱する。

6. 監視項目の取得可能性調査と結果

本章では、5 章で定義した監視項目が、Unity および Meta XR Audio SDK を用いた環境において実行中に判定できるかを調査する。ここで判定可能とは、対応する実装要素から得られる情報によって、その項目が実行中にどのような状態にあるかを確定できることをいう。

Unity において音声信号は、音声データ（`AudioClip`）が `AudioSource` によって処理され、必要に応じて `AudioMixer` を経たのち、`AudioListener` を通じてユーザへ提示される [15]。本稿ではこのうち、定位、音量、再生の制御といった提示の大部分を音源単位で決定する `AudioSource` を対象とする。攻撃者が提示を操作するうえで最も自由度が高く、逸脱を音源単位で報告する本手法の判定方式とも対応するためである。調査対象は、定義した 18 の監視項目のうち、既存の資産照合が対応する R1 および R2 を除く 16 項目とした。

6.1 調査方法

はじめに、Unity および Meta XR Audio SDK の公式リファレンスを参照し、各監視項目の判定に用いる実装要素を同定した。同定された実装要素は、`AudioSource` のプロパティ、スペーシャライザのネイティブパラメータ、メソッドにより取得するカーブ、およびオブジェクトの構成や座標といった、性質の異なるものを含む。

次に、各実装要素について、実行中にその値または状態を取得できるか（取得可能性）と、取得した値が実際に利用者へ提示されている音に対応するか（実効性）の 2 つの観点から調査する。以降、後者が成り立つ状態を、その値が実効を伴うと表現する。空間音響に関わる処理は Unity 標準の機能と Meta XR Audio SDK の双方が担いうるが、同一の性質に双方が設定を持つ場合にいずれが実効を持つかは、いずれのリファレンスにも記載がなく実測を要する。

実効の有無は、`AudioListener` の静的メソッドにより最終的な出力波形および周波数分布を取得し、左右チャンネルの音量バランス、全体の音量、および音の高さを求めることで判断した。音源側の設定を変化させたときにこれらの値が変化するかによって、その設定が実効を伴うかを判定した。

調査で用いた実行環境や指標、測定条件等は付録 A.5 に示す。

6.2 前提: 発音中の音源の捕捉

本手法は、シーン内に存在する音源（`AudioSource`）を周期的に列挙し、その提示設定をポリシーと照合する。したがって、いずれかの再生手段において鳴っている音源を特定できなければ、攻撃者はその手段を用いるだけで検知

© 2026 Information Processing Society of Japan

を回避でき、枠組み全体が成立しない。そこで各監視項目の調査に先立ち、Unity が提供する再生手段について、監視に必要な情報を取得できるかを調査した。

対象としたのは、音源に割り当てられた clip を再生する Play、PlayDelayed、PlayScheduled、引数に与えた clip を再生する PlayOneShot、および再生時に音源を新たに生成する PlayClipAtPoint の計 5 通りである。検証では、音源に既知の提示設定を与えたうえで各手段により再生し、発音状態の取得可否、音源プロパティの読み取り可否、鳴っている clip の同定可否、および同じ手段を連続して呼び出したときの挙動を記録した。経路ごとの詳細表は付録の表 A·5 に示す。

いずれの手段においても、音源は列挙により発見でき、与えたプロパティはそのまま読み出せた。一方、PlayDelayed および PlayScheduled では再生が予約された時点で発音状態が真となり、実際に発音が開始される時刻とは一致しない。PlayOneShot では引数として与えた clip がプロパティに反映されず、鳴っている clip を同定できない。PlayClipAtPoint が生成する音源も列挙により捕捉できるため、本手段による再生は、登録されていない音源からの発音として既存の資産照合が検出する。また連続呼び出しの挙動にも差があり、PlayOneShot のみが既存の再生を止めずに発音を追加する。

6.3 調査結果

実装要素とその取得可能性および実効の有無を表 2 に示す。

16 の監視項目から 33 個の実装要素が同定され、うち 6 個は Meta XR Audio SDK が提供するものであった。取得可能性については、Unity 側の 27 個はいずれの条件でも取得できた一方、Meta 側の 6 個は spatialize = true を条件とし、空間定位を用いない音源では取得できない。また R3 の clip は、PlayOneShot による再生では取得できない。実効性については、23 個で取得した値が実際の提示に対応していた一方、10 個については対応しない場合が存在した。

調査対象とした 16 項目のうち 13 項目は判定可能であり、判定に限界を伴うのは P2、P3、R3 の 3 項目である。とくに、複数の研究が指摘してきた空間音響の悪用 [4,5,7] については、空間群の 8 項目すべてが判定可能である。

6.4 取得した値が提示に反映されない場合

取得できた値が実際に提示されている音に対応しない場合は、2 つの経路から生じる。

第一に、カーブによる設定である。Unity では、空間定位の度合い（spatialBlend）、音像の広がり（spread）、反響の適用量（reverbZoneMix）、および距離減衰の 4 つの設定を、聞き手との距離に応じたカーブとして与えることができる。このとき対応するプロパティはカーブの評価結果を反映せず、実測ではカーブの評価値が 0.100 から 0.900 まで変化する間、プロパティは 0.000 のままであった。この乖離は S1、S2、S6 で確認され、これらではプロパティに加えてカーブそのものを照合の対象に含める必要がある。距離減衰では乖離の形が異なり、カーブに対応するスカラープロパティが存在しないうえ、減衰の方式や最小距離を変更して実際の減衰が変化しても、曲線の座標や接線を含むすべての値は同一のままであった。したがって距離減衰では、カーブに加えて減衰の方式と距離の設定をあわせて照合する必要がある。

第二に、空間音響 SDK による無効化である。Meta XR Audio SDK を適用した音源では、Unity 側の定位に関する設定が参照されない。spatialBlend を 0 から 1 まで 0.25 刻みで変化させても左右チャネルの出力比に変化は生じず、SDK を適用しない場合には同じ操作で単調な変化が観測された。spread および reverbZoneMix についても同様である。一方、音量は Unity 側の volume と SDK 側のゲインが直列に作用し、ピッチも SDK の適用の有無で再生周波数の比が一致した。すなわち無効化されるのは定位に関わる設定に限られ、Unity 側の定位に関わる設定は SDK を適用しないときにのみ実効をもつ。

6.5 位置に基づく項目の判定

S4、S5、S8 は座標という連続量を扱うため、他の項目のように値の一致では判定できない。浮動小数演算の誤差、および物理演算やアニメーションによる微小な変動が常に生じるため、これらを吸収する閾値 ε を要する。閾値を置くことは ε を下回る改変を許容することを意味する。したがって位置に基づく項目では、瞬間の変化量ではなく初期値からの累積偏差も判定に用いる必要がある。ただし、変位が往復する場合には累積が相殺されるため、取りこぼす可能性が残る。

一方、ε の妥当な値は開発環境に依存する。特に、浮動小数演算の誤差はシーンの広さの規模に応じて変動するため、シーンの空間的な広がりや音源の到達距離といった実行時に取得可能な量から ε を導出する機構を要する。

6.6 項目間の依存関係

ポリシーの照合は項目ごとに独立ではなく、ある項目の判定結果が他の項目の照合内容を定める場合がある。空間定位を用いない音源では、定位の広がりや距離減衰を規定する必要がないため、他の空間群の項目がとるべき値は既定値に定まる。ただしこれは、S1 が偽であることをもって他の空間群の項目を監視対象から外してよいことを意味しない。実効を伴わない状態で加えられた改変であっても、

© 2026 Information Processing Society of Japan

表 2: 監視項目に対応する実装要素と取得可能性。層の U は Unity 側、M は Meta XR Audio SDK 側を示す。Meta 側の項目はいずれもスペーシャライザを経由するため、`spatialize = true` のときにのみ取得および実効を持つ。型は各実装要素の宣言型を示し、角括弧内は値域である。判定は項目単位で本手法による照合が成立するかを示す。○は成立、△は条件付きであることを表し、取得の△は特定の条件下で値を取得できないことを示す。

ID	監視項目	参照する実装要素	説明	型・値域	層	取得	実効	判定
S1	空間定位の有無	`spatialize`	空間音響処理を適用するか	`bool`	U	○	○	○
		`spatialBlend`	内蔵パンニングの適用度合	`float` $[0,1]$	U	○	△ [ab]	
		定位度カーブ	適用度合の距離依存カーブ	`AnimationCurve`[h]	U	○	△ [a]	
		`EnableSpatialization`	Meta 側の空間化を適用するか	`bool`	M	△ [i]	○	
S2	定位の広がり	`spread`	音像を広げる角度幅	`float` $[0,360]$	U	○	△ [ab]	○
		広がりカーブ	角度幅の距離依存カーブ	`AnimationCurve`[h]	U	○	△ [a]	
		`P_RADIUS`	音源を体積とみなす半径	`float` $[0,\infty)$	M	△ [i]	○	
S3	距離減衰の特性	`minDistance`	これ以内では減衰しない距離	`float` $[0,\infty)$	U	○	○	○
		`maxDistance`	減衰の終点となる距離	`float` $[0,\infty)$	U	○	○	
		`rolloffMode`	減衰の方式	`AudioRolloffMode` 3 値	U	○	○	
		減衰カーブ	距離に対する音量の変化	`AnimationCurve`[h]	U	○	△ [c]	
S4	聞き手への追従性	音源と聞き手の座標	位置関係の時間変化	`Vector3`	U	○	○	○
S5	音源の動きの有無	音源の世界座標	世界座標上の位置の変化	`Vector3`	U	○	○	○
S6	反響の適用	`reverbZoneMix`	反響を受け取る量	`float` $[0,1.1]$	U	○	△ [ab]	○
		`bypassReverbZones`	反響の経路を迂回するか	`bool`	U	○	△ [a]	
		反響量カーブ	受け取る量の距離依存カーブ	`AnimationCurve`[h]	U	○	△ [a]	
		`P_DISABLE_RFL`	Meta 側の反響を無効化するか	`float` $\{0,1\}$[g]	M	△ [i]	○	
S7	遮蔽処理の適用	`OcclusionIntensity`	遮蔽による減衰の強度	`float` $[0,1]$	M	△ [i]	○	○
S8	発音主体との整合性	可視オブジェクトの有無	親に発音主体が存在するか	`bool`	U	○	○	○
		発音主体との位置関係	発音主体を基準とした音源位置	`Vector3`	U	○	○	
A1	音量設定	`volume`	線形の音量倍率	`float` $[0,1]$	U	○	○	○
		`mute`	消音するか	`bool`	U	○	○	
		`P_GAIN`	dB 単位で加算されるゲイン	`float` $[0,20]$ dB	M	△ [i]	○	
A2	ピッチ設定	`pitch`	再生速度の倍率	`float`	U	○	○	○
A3	音色改変処理の適用	付与されたフィルタの構成	音源に付与されたフィルタの列	`Behaviour[]`	U	○	○	○
		各フィルタの有効性	フィルタが有効化されているか	`bool`	U	○	○	
		`bypassEffects`	フィルタ処理を迂回するか	`bool`	U	○	○	
P1	持続性	`loop`	再生を繰り返すか	`bool`	U	○	○	○
P2	発生頻度	`isPlaying` の遷移	再生開始を遷移で数える	`bool` の時間変化	U	○	△ [d]	△
P3	同時多重度	`isPlaying` が真の音源の数	発音中の音源の数	`int` $[0,\infty)$	U	○	△ [e]	△
		`P_READONLY_NUM_VOICES`	エンジン全体の発音数	`float` $[0,\infty)$[g]	M	△ [i]	○	
P4	優先度	`priority`	競合時に優先される度合い	`int` $[0,255]$	U	○	○	○
R3	音源と音の対応	`clip`	音源に割り当てられた音声データ	`AudioClip`	U	△ [f]	○	△

[a] Meta XR Audio SDK 有効時、プロパティの値は提示に反映されない。 [b] カーブが設定されている場合、プロパティの値は提示に反映されない。 [c] カーブの評価値は実際の減衰形状を表さない。 [d] 再生が重なる場合は遷移が生じず、計数できない。 [e] 同一音源上で `PlayOneShot` により再生が重なった場合、その重なりを数えられない。 [f] `PlayOneShot` では引数のクリップを特定できない。 [g] ネイティブパラメータは `GetSpatializerFloat` を通じて取得するため、意味的に真偽値または整数であっても宣言型は `float` となる。 [h] カーブからはキーフレームの個数、各キーの位置、値、接線、重み、ラップモードが取得できる。 [i] `spatialize = false` の音源では値が取得できない。

S1 を偽から真へ転じさせる改変と組み合わされれば実効を持つに至る。この場合の空間群の照合は、提示の妥当性ではなく改変の痕跡を監視するものとして機能する。

6.7 判定が成立しない項目

P2、P3、R3 の 3 項目は判定に限界を伴う。P2 は発音状態の偽から真への遷移を数えて発生数を求めるが、再生が途切れなければ遷移は生じないため、クリップ長を下回る間隔で再生された場合には計数できない。P3 は発音状態が真である音源の数を数えるが、同一音源上で `PlayOneShot` により再生が重なった場合、その音源の発音数は 1 としてしか数えられない。Meta XR Audio SDK が提供する発音数（`P_READONLY_NUM_VOICES`）は重なりを数えるが、エンジン全体の値であるため音源への帰属が分からず、また空間定位を用いる音のみを数える。R3 は、`PlayOneShot` が `clip` プロパティに引数のクリップを反映しないため、鳴っ

© 2026 Information Processing Society of Japan

ている音声データを同定できない。

6.8 限界

第一に、AudioSource の外側での改変を扱っていない。S6 および音響群の項目は AudioMixer でも操作でき、グループボリュームを変更しても AudioSource 側の値は一切変化しない。攻撃者は音源の出力先を自ら同梱した AudioMixer へ差し替えることで、音源単位の照合を素通りしたまま提示を改変できる。

第二に、提示設定を経由しない改変を扱っていない。OnAudioFilterRead は、AudioSource または AudioListener と同一の GameObject に付与することで、そこを通過する音声バッファを直接読み書きできるため、提示設定を変更せずに任意の波形を出力できる。この経路は実行時の設定に痕跡を残さない一方、コード上には現れるため、実行時の照合と静的な検査の併用が対処として考えられる。

第三に、本調査の結果は Unity および Meta XR Audio SDK に対するものである。5 章で定義した監視項目はエンジンや API に依存しない水準で記述しているが、各項目が取得可能であるか、また取得した値が実際の提示に対応するかは実装に依存する。

7. 検知機構の試験実装と AVMA の検知

本章では、著者らが先行研究で提案した AVMA [5] を対象に検知機構を試験実装し、これを検知できることを示すことで、提案手法の有効性を確認する。

7.1 実装の範囲

検証には、AVMA の評価に用いた VR テトリスゲーム BlockVRise [5] の音響環境を再現したシーンを用いた。用いられる音は、BGM およびテトリミノの設置、回転不可、ライン削除の際に鳴る効果音 3 種の計 4 種である。これらを Jain らの VR 音の分類 [14] の sound source 軸に照らすと、BGM が Music に、効果音 3 種がいずれも Interaction sound に該当するため、試験実装で採用する役割ラベルは Music と Interaction Sound の 2 種とした。

本稿で検知の対象とするのは AVMA の 1 種類である。AVMA の提示は定位の付与、聞き手への追従、および世界座標上の移動として現れるため、監視項目はこれらを含む S1、S4、S5 の 3 項目とした。

ポリシーは各音に付与した役割ラベルから定めた（表 3）。各項目は役割ごとの期待値との一致のみを問うため、AVMA に限らず、同じ項目に違反する改変はいずれも逸脱として報告される。

一方、ここで用いた役割ラベルとポリシーは、検証シーンに現れる 4 種の音に対して著者らが与えたものであり、一般の VR アプリケーションに適用できる役割体系を与えるものではない。

表 3: 役割ラベルごとの提示ポリシー

	Music	Interaction Sound
該当する音	BGM	設置音・回転不可音・削除音
S1 空間定位	なし	あり
S4 追従性	非追従	非追従
S5 動き	なし	あり

各項目の照合は次のように行う。S1 は spatialize（以下 S1-1）および spatialBlend（以下 S1-2）の値を常時読み取り、役割が指定する定位の有無と一致するかを確認する。S4 は、聞き手を基準とする座標系における音源位置の偏差を用い、聞き手の位置のみに追従する座標系と、位置および姿勢の双方に追従する座標系のいずれにおいても不変とならないことを確認する。ただし聞き手が静止している間は追従と静止を区別できないため、判定は、音源が静止していれば生じるはずのずれが閾値を十分に超えた時点でのみ行う。S5 は、非追従を指定する音源についてのみ、発音中に限り世界座標における音源位置の偏差を用い、これが閾値以下であることを確認する。各項目の照合方法や S4 照合のアルゴリズム、閾値設定については付録 A.7 に示す。

7.2 測定の条件

先行研究 [5] の AVMA では正規の音声の悪用として削除音が攻撃に用いられたが、本稿では BGM、設置音、回転不可音、削除音のすべてを攻撃対象とし、シーン内のあらゆる音が AVMA として悪用される状況を再現する。空間定位を持たない BGM に対しては、提示のあいだだけ空間化を有効にしたうえで聞き手に位置追従させる。

攻撃は、悪意あるアセットに同梱されたスクリプトを模して実装した。実行時に聞き手位置を同定し、対象の音源を、提示中のみ聞き手の右方 5 m へ位置追従させて提示する。新たな音源も音声データも持ち込まないため、資産照合を通過する。提示は測定開始 10 s 後から、50〜70 s の間隔で行った。

測定は HMD を接続しない Unity エディタ上のデバッグ実行により行った。測定に用いた環境の詳細は付録 A.5 に示す。この環境では聞き手が静止したままとなり、追従する音源と静止した音源のいずれも聞き手基準の位置が変化しないため、両者を区別する手がかりが生じない。そこで頭部運動を模し、リスナーを毎フレーム微小に移動させる処理を加えた。

測定時間は 300 s とし、乱数の影響を平均するために 3 回繰り返して合計で集計する。

© 2026 Information Processing Society of Japan

7.3 測定結果

提示の総数は 312 回（正規 255 回、攻撃 57 回）であり、攻撃による提示 57 回はすべて検出された。攻撃を受けていない正規の提示では逸脱の報告が一度も生じていない（誤検知率 0/255）。全体や各音源ごとの測定結果の詳細については、付録の表 A·7、A·8 に示す。

報告の内訳は、役割ごとの期待値の違いを反映した。BGM に対する改変は、空間化が S1-1 および S1-2、位置追従が S4、発音中の移動が S5 として報告され、一回の提示につき 4 項目が違反として報告された。これに対し、もともと空間定位を持つ Interaction Sound 3 種への位置追従化は S4 のみで報告され、攻撃提示回数と報告数が一致した。

ただし、検知性能の評価であれば、多様な攻撃と正規動作の分布のもとで真陽性および偽陰性による検出率や、閾値を変化させた ROC 曲線により検出率と誤検知率のトレードオフを示すべきである。本稿の実装は単一のアプリケーションと単一の攻撃を対象とした試験的なものであり、本節で確認したのは、AVMA が役割ごとに定義したポリシーからの逸脱として捕捉され、かつ正規の提示が逸脱として報告されないという、手法の成立にあたる範囲である。

8. まとめ

本稿では、音資産の真正性ではなく音の提示の妥当性に着目し、音がどのように提示されるべきかを役割ごとにポリシーとして定義したうえで、実行時の提示がそこから逸脱していないかを判定する検知手法を提案した。聴覚刺激攻撃に悪用され得る提示項目を監視項目として整理し、Unity および Meta XR Audio SDK を用いた環境で判定可能であるかを調査した。さらに、検知機構を試験実装し、AVMA [5] を、提示ポリシーからの逸脱として検知できることを確認した。

今後の課題は 3 点である。第一に、役割体系の確立と役割ごとの提示ポリシーの策定である。実際の VR アプリケーションに含まれる音の収集と開発者への聞き取りを通じて、役割から一意に定まる値と、アプリケーションに応じて開発者が定める必要のある値との境界を明らかにする。第二に、6.8 節で述べた `AudioMixer` および `AudioListener` への監視の拡張である。第三に、検知性能および開発者の記述負担の評価である。本稿の試験実装は単一のアプリケーションと単一の攻撃を対象としているため、多様な攻撃シナリオのもとで検知の精度と限界を明らかにするとともに、記述負担をユーザスタディにより調査する。

以上の課題を経て、役割ラベルと検知機構、および役割ごとのポリシーの雛形をアセットとして配布し、開発者が自身のアプリケーションへ導入できる形を目指す。

謝辞　本研究は、JST CREST JPMJCR22M4 の支援を受けて実施された。

参考文献

[1] Casey, P., Baggili, I. and Yarramreddy, A.: Immersive Virtual Reality Attacks and the Human Joystick, *IEEE Transactions on Dependable and Secure Computing* (2019).

[2] Tseng, W.-J., Bonnail, E., McGill, M., Khamis, M., Lecolinet, E., Huron, S. and Gugenheimer, J.: The Dark Side of Perceptual Manipulations in Virtual Reality, 2022 ACM CHI Conference on Human Factors in Computing Systems (CHI '22) (2022).

[3] Cheng, K., Tian, J. F., Kohno, T. and Roesner, F.: Exploring User Reactions and Mental Models Towards Perceptual Manipulation Attacks in Mixed Reality, *32nd USENIX Security Symposium (USENIX Security 23)* (2023).

[4] Otsuka, K. and Kanaoka, A.: Auditory Stimulus Attack in XR: Stimulus Characteristics and Technical Background Considerations, *3rd IEEE International Conference on Metaverse Computing, Networking and Applications (MetaCom 2025)* (2025).

[5] 大塚航世，金岡　晃，倉﨑翔大：VR における視点操作攻撃：空間音響を悪用した攻撃の実証と考察，コンピュータセキュリティシンポジウム（CSS）2025 (2025).

[6] Kurasaki, S. and Kanaoka, A.: Evaluating Gaze-Manipulation Risks via Image Movement Attacks on Optical See-Through AR/MR HMDs, *IEEE Access* (2026).

[7] de Haas, E. H. A. and Lee, L. H.: Deceiving Audio Design in Augmented Environments: A Systematic Review of Audio Effects in Augmented Reality, *2022 IEEE International Symposium on Mixed and Augmented Reality Adjunct (ISMAR-Adjunct 2022)* (2022).

[8] 金岡　晃：3D シーングラフ完全性検証のシステムモデルと効率的署名方式，マルチメディア、分散、協調とモバイル (DICOMO) 2026 シンポジウム (2026).

[9] Lebeck, K., Ruth, K., Kohno, T. and Roesner, F.: Securing Augmented Reality Output, *2017 IEEE Symposium on Security and Privacy* (2017).

[10] Xiu, Y., Scargill, T. and Gorlatova, M.: ViDDAR: Vision Language Model-Based Task-Detrimental Content Detection for Augmented Reality, *IEEE Transactions on Visualization and Computer Graphics* (2025).

[11] Chen, R., Andreyev, A., Xiu, Y., Chilukuri, J., Sen, S., Imani, M., Li, B., Gorlatova, M., Tan, G. and Lan, T.: Cognitive Attack Detection in Augmented Reality (CADAR): A Neuro-Symbolic Approach with Particle Filtering on Perception Graphs, *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR) Findings* (2026).

[12] Valentin, C.: UPM Dependency Confusion & AssetBundle Security in the Editor, `https://unity.com/blog/engine-platform/upm-dependency-confusion-assetbundle-security-in-the-editor` (2021). Accessed: 2026-08-20.

[13] Otsuka, K., Suzuki, Y., Fujita, M., Kurasaki, S., Mori, R., Kanaoka, A., Ohigashi, T. and Ohki, T.: Deconstructing Extended Reality Attacks: Deriving Common Attack Primitives and Analyzing Their Feasibility, *Proceedings of the 2026 IEEE 50th Annual Computers, Software, and Applications Conference Workshops* (2026).

[14] Jain, D., Junuzovic, S., Ofek, E., Sinclair, M., Porter, J. R., Yoon, C., Machanavajhala, S. and Morris, M. R.: A Taxonomy of Sounds in Virtual Reality, *Proceedings of the 2021 Designing Interactive Systems Conference* (2021).

[15] Unity Technologies: Unity - Manual: Audio overview, `https://docs.unity3d.com/6000.0/Documentation/Manual/AudioOverview.html` (2026). Unity 6 (6000.0). (Accessed: 2026-08-20).

© 2026 Information Processing Society of Japan

付　　録

A.1　攻撃パターン

攻撃者は音を発する音源機能が付与されたオブジェクトと再生される音声ファイル（clip）のそれぞれについて、開発者が用意した正規資産を流用するか、自ら用意したものを持ち込むかを選択できる。これを踏まえて、本研究では4種類の攻撃パターンを想定し表 A·1 にまとめる。

表 A·1: 資産の由来による攻撃パターンの分類。本研究が主な対象とするのは A である。

	正規の clip	攻撃者の clip
正規の音源	A: 提示設定の改変	B: clip の不正割当
攻撃者の音源	C: 音源の不正配置	D: 双方が外部由来

パターン D は、攻撃者が音源と音声データの双方を持ち込むものであり、最も直接的な攻撃形態である。パターン B、C は一方のみを持ち込むもので、B は正規の音源に本来割り当てられるべきでない音声データを対応させ、C は攻撃者が追加した音源に正規の音声データを再生させる。パターン A は、音源と音声データのいずれも開発者が正規に用意したものを用い、その提示設定のみを改変するものであり、本提案手法の検知対象となる。

A.2　監視対象とする提示項目

監視対象とする提示項目の一覧と、各項目がとりうる値、説明、導出元について表 A·2 に示す。

A.3　監視項目の採用理由

本付録では、表 A·2 に示した各監視項目について、何を監視対象とするか、および想定される悪用シナリオを述べる。

S1: 空間定位の有無

音に空間定位が適用されているかを問う。定位を持たない音に定位を付与すれば実在しない位置へ注意を誘導でき、逆に定位を取り除けば音源の方向手がかりを失わせられる。

S2: 定位の広がり

音像が一点に定まって聞こえるか、広がりを持って聞こえるかを問う。広がりを与えれば、空間定位を有効に保ったまま方向手がかりのみを奪える。逆に環境音のように広がりを持つべき音を点音源化すれば、存在しない位置へ注意を向けさせられる。

S3: 距離減衰の特性

距離に応じて音量がどのように減衰するかを問う。減衰を弱めれば遠方の音源を近接して聞かせることができ、強めれば近傍の音源の存在を希薄化させて警告音などを聞き逃させられる。

S4: 聞き手への追従性、S5: 音源の動きの有無

S4 は、聞き手に追従しない非追従、位置のみ追従する位置追従、位置および姿勢の双方に追従する完全追従の 3 値をとる。著者らが実証した AVMA [5] は位置追従に該当し、世界固定と頭部追従の 2 値では表現できないためである。S5 は、S4 が非追従と指定した音に対してのみ、その音源が世界座標系で動きがあるかを確認する。

S6: 反響の適用

その音に反響が伴って聞こえるかを問う。反響を付与すれば実際とは異なる空間の広さを錯覚させ、また音像の輪郭を曖昧にして定位の精度を低下させられる。逆に取り除けば、対象との距離感や空間の把握を損なわせられる。

S7: 遮蔽処理の適用

音源と聴取者を結ぶ直線が塞がれたときに、直接音が減衰する処理が適用されているかを問う。反射音を扱う S6 とは経路が独立し、壁越しと見通しでは距離が等しいため S3 でも切り分けられない。遮蔽を無効化すれば壁越しに届くはずのない音を到達させられ、過剰に適用すれば警告音を実質的に隠蔽できる。

S8: 発音主体との整合性

音を発している実体が存在し、その実体との空間的関係が保たれているかを問う。音がどの方向から聞こえるべきかは実行時のイベントに依存して定まらないため、方向そのものではなく発音主体との関係を問う。発音主体を伴わずに鳴らす経路と、可視オブジェクトの子である音源の座標のみをずらす経路があり、後者は親子関係を保つため階層構造の照合には現れない。

A1: 音量設定

その音がどの程度の大きさで提示されるかを問う。ゲインを引き上げれば聴覚や身体に負荷を与えられ、ゼロにすれば警告音などを聞き逃させられる。

A2: ピッチ設定

その音の高さが本来からどの程度変位しているかを問う。可聴域の上限に近い帯域へ過大なエネルギーを集中させれば、聴覚や身体に負荷を与えられる。

A3: 音色改変処理の適用

その音の音色を変える処理が加えられているかを問う。資産照合により音声データの正当性が担保される前提では、攻撃者に残る経路は正規のクリップに提示の段階で処理を加えることである。本来と異なる音色で注意を誘導する経路と、遠景の音のローパスを外して距離感を偽装するように本来の処理を外す経路がある。

P1: 持続性

1 回の再生が単発で終わるか、鳴り続けるかを問う。単発で終わるべき通知音を鳴らし続ければ注意の撹乱につな

© 2026 Information Processing Society of Japan

表 A·2: 監視対象とする提示項目。値の型はポリシーが指定する期待値の型を示し、実装上の値域および対応するプロパティは表 2 に示す。導出元は先行研究 [4] が定義する聴覚刺激特性への対応を示し、本研究が追加した項目は「＜新規＞」と記す。空間群の S2 から S8 は、S1 が「なし」を指定する場合にはとるべき値が既定値に定まる。資産群の R1、R2 は既存の資産照合が対応する範囲であり、本研究の監視対象には含めない。

群	ID	監視項目	値の型	説明	導出元
空間	S1	空間定位の有無	真偽	音に空間定位が適用されているか	応用特性
	S2	定位の広がり	実数	音像が一点に定まって聞こえるか、広がりを持って聞こえるか	方向
	S3	距離減衰の特性	列挙、実数	距離に応じて音量がどのように減衰するか	距離
	S4	聞き手への追従性	列挙	音源位置が聞き手の位置や姿勢に追従するか	動き
	S5	音源の動きの有無	真偽	音源が空間内を移動するか、一箇所から鳴り続けるか	動き
	S6	反響の適用	真偽、実数	その音に反響が伴って聞こえるか	反響
	S7	遮蔽処理の適用	実数	障害物によって直接音が遮られるか	反響
	S8	発音主体との整合性	真偽、実数	音を発している実体が存在し、その実体との空間的関係が保たれているか	方向
音響	A1	音量設定	実数	その音がどの程度の大きさで提示されるか	大きさ
	A2	ピッチ設定	実数	その音の高さが本来からどの程度変位しているか	高さ
	A3	音色改変処理の適用	真偽	その音の音色を変える処理が加えられているか	音色
再生	P1	持続性	真偽	音が鳴り続けるか、単発で終わるか	持続時間
	P2	発生頻度	実数	単位時間あたりにその音が何回発生するか	＜新規＞
	P3	同時多重度	整数	同時にいくつの音が重なって鳴っているか	＜新規＞
	P4	優先度	整数	音が競合したときにその音がどの程度優先して発音されるか	＜新規＞
資産	R1	音声データの正当性	集合	提示されている音声データそのものが正規のものか	既存防御
	R2	音源の正当性	集合	音を発している音源が正規のものか	既存防御
	R3	音源と音の対応の正当性	集合	その音源から鳴っている音声データが本来割り当てられるべきものか	＜新規＞

がり、持続すべき環境音を単発で終わらせれば空間の手がかりが失われる。なお、クリップ長は提示設定ではなく素材の属性であるため、資産群が担保する。

P2: 発生頻度、P3: 同時多重度

本 2 項目は音単体の特性ではなく、複数の音の関係として本研究が追加したものである。個々の再生が正常な設定であっても、短時間に反復すれば注意を継続的に奪うことができ、同種の音を多数重ねれば設定音量が正常なまま実効音量を増幅できる。

P4: 優先度

音が競合したときにその音がどの程度優先して発音されるかを問う。Unity では同時発音数に上限が設けられ、超過時には優先度に基づいて発音が停止される。攻撃音の優先度を上げ、あるいは正規音の優先度を下げることで、他の設定を一切変えずに警告音を発音停止させられる。

R1: 音声データの正当性、R2: 音源の正当性

提示されている音声データ、および音を発している音源が正規に登録されたものかを問う。いずれも既存の資産照合が対応する範囲であるため、本研究の監視対象には含めない。

R3: 音源と音の対応の正当性

その音源から鳴っている音声データが、本来割り当てられるべきものかを問う。空間音響の適用が許可された正規の音源から別の正規の音声を再生すれば、双方が登録済みであるため資産照合は通過する一方、開発者が意図した対応からは逸脱する。なお、足音のように 1 つの音源が複数の音声データを持ち回す構成があるため、照合は音源ごとに再生を許可する音声データの集合に対して行う。

A.4 ポリシーの記述例

川沿いの街路を歩く体験を例にとる。左手に川が流れ、案内役のキャラクタが利用者の傍らを歩きながら発話し、地点への到着時に通知音が鳴り、全体を通して BGM が流れる。このシーンに対するポリシーの記述をリスト 1 に示す。

```
{
  "roles": [
    { "id": "PointAmbience",
      "S1_spatialized": true,   "S2_spread": "
          point",
      "S3_rolloff": "logarithmic",
```

© 2026 Information Processing Society of Japan

```
      "S4_follow": "none",      "S5_motion": "
          static",
      "S6_reverb": true,        "S7_occlusion
          ": true,
      "S8_body": "required",
      "A1_level": "low",        "A2_pitch": "
          authored",
      "A3_effects": "authored",
      "P1_loop": true,          "P2_rate": 1,
      "P3_voices": 1,           "P4_priority":
           "low",
      "R3_clips": "authored" },

    { "id": "Music",
      "S1_spatialized": false,
      "A1_level": "low",        "A2_pitch": "
          authored",
      "A3_effects": "authored",
      "P1_loop": true,          "P2_rate": 1,
      "P3_voices": 1,           "P4_priority":
           "low",
      "R3_clips": "authored" }
  ],

  "sources": [
    { "name": "RiverEmitter",  "role": "
        PointAmbience",
      "body": "River_Mesh" },
    { "name": "GuideVoice",    "role": "
        LocalizedSpeech" },
    { "name": "ArrivalChime",  "role": "
        NotificationSound" },
    { "name": "BGM",           "role": "Music"
         }
  ]
}
```

Listing 1: ポリシーと役割ラベルの記述例（JSON）

roles が役割ごとの期待値を、sources が各音源への役割の割当を表す。前者は役割ごとにあらかじめ用意されるものであり、開発者が記述するのは後者、すなわち音源名と役割ラベルの対のみである。これは 4 章で述べた要件 2 にあたる。

Music の記述が PointAmbience より短いのは、S1_spatialized が偽であることにより空間群の残る 7 項目の値が定まり、記述を要しないためである。

値が authored である項目は、期待値が役割からは定まらず、オーサリング時点の値をそのまま期待値として用いることを表す。A2 は音の高さが素材そのものの持つ性質であり、A3 のフィルタ構成と R3 の音源に許可される音声データは、いずれもアプリケーションの音響設計が決めるものである。役割の側からは値を指定できないため、これらについては監視開始時の値を控え、実行中の値がそこから変化していないかを照合する。役割が定めるのは「何を期待値とするか」であって、その値そのものではない場合がある。

A1_level の low は、その音が背景として提示されるべきことを表す相対的な段階である。段階に対応する具体的な音量は素材の録音レベルやシーンの規模に依存するため、照合にあたっては段階と値域との対応を別に与える必要がある。

S8_body が required である役割は、音源に対応する発音主体の存在を要求する。RiverEmitter にのみ body が与えられているのは、発音主体の候補検出が自動的に解決せず、開発者の指定を要した場合を表す。指定を求める件数は音源数ではなく、解決しなかった件数に比例する。

A.5 調査および試験実装の環境と測定方法

A.5.1 実行環境

6 章の調査および 7 章の試験実装は、いずれも表 A·3 に示す環境で実施した。測定は HMD を接続しない Unity エディタ上のデバッグ実行によって行っており、HMD 上での動作は確認していない。

表 A·3: 調査および試験実装に用いた環境

項目	バージョン
Unity	6.3 LTS (6000.3.16f1)
XR Plugin Management	4.7.0
OpenXR Plugin	1.16.1
Meta XR Core SDK	205.0.0
Meta XR Audio SDK	85.0.0

空間音響の処理には Meta XR Audio SDK が提供するスペーシャライザを用いた。同 SDK が提供するパラメータの取得および設定は、MetaXRAudioSource を介して行う。同時発音数の上限（Real Voices）は Unity の既定値である 32 とし、変更していない。

A.5.2 測定の取得点

実効の有無は、AudioListener に到達する信号から判断した。AudioListener.GetOutputData および AudioListener.GetSpectrumData により、最終的な出力波形および周波数分布を取得する。これらは静的メソッドであるため補助的なコンポーネントを必要とせず、測定のために音源側の構成へ手を加えることなく、利用者へ提示される信号と同一のものを得られる。

A.5.3 用いた指標

取得した波形および周波数分布から、判定する性質に応じて表 A·4 の指標を求めた。

左右バランスは、音源を聞き手の左右対称な位置に配置

© 2026 Information Processing Society of Japan

表 A·4: 実効の判定に用いた指標。RMS は、波形の標本を二乗して平均し平方根をとった値であり、正負に振動する波形の大きさを表す。

指標	定義	対象
左右バランス	$(\mathrm{rms}_L - \mathrm{rms}_R)/(\mathrm{rms}_L + \mathrm{rms}_R)$	S1、S2
実効音量	出力波形の RMS の dB 換算	S3、S7、A1、A3
ピーク周波数	振幅が最大となる周波数	A2
残響比	（停止 0.25 秒後の RMS）/（再生中の RMS）	S6
座標の偏差	参照枠における初期値からの最大偏差	S4、S5、S8

したときの符号の反転により定位の有無を判別する。条件間の比較には、絶対値の差ではなくバランスそのものの差を用いる。S6 の反響は再生を停止した後の残響比から、S7 の遮蔽は遮蔽オブジェクトの有無による再生中の到達音量から判定する。

A.5.4 測定条件

条件間の比較が成立するよう、次の条件を統一した。音源はモノラルとし、Meta XR Audio SDK が空間化の対象とする形式に合わせた。検証用のシーンには対象の音源のみを配置し、他の音源が最終ミックスへ混入しないようにした。音源は聞き手の正面ではなく側方に配置した。正面では左右が対称となり、定位の有無を判別できないためである。

A.6 再生手段ごとの発音状態の取得可否

音源の再生手段ごとの発音状態の取得可否、音源プロパティの読み取り可否、鳴っている clip の同定可否、および同じ手段を連続して呼び出したときの挙動を表 A·5 に示す。

A.7 検知機構の実装

本章で用いた検知機構は、役割ごとの期待値を記述したポリシーと、それを各監視項目について照合する判定部から成る。

A.7.1 位置の照合に用いる閾値の設定

試験実装の対象とした BlockVRise では、テトリスの盤面が聞き手の正面 10 m に配置されており、シーン内の座標が原点から 100 m を超える範囲に及ぶことはない。座標は単精度浮動小数で表現されるため、この範囲における分解能は約 1.2×10^{-5} m である。相対座標の算出に伴う変換誤差の累積を見込んでも、正常な提示において生じる偏差が 10^{-3} m を上回ることはない。本稿では、これに 1 桁の余裕を持たせた $\varepsilon = 1.0 \times 10^{-2}$ m を閾値として用いた。

A.7.2 S1: 空間定位の有無

役割が指定する空間定位の有無を `spatialize` と照合し、S1-1 として報告する。`spatialBlend` は、空間定位ありの役割では監視開始時の値と、なしの役割では 0 と照合し、S1-2 として報告する。前者について監視開始時の値を用いるのは、期待値が役割から定まらないためである。

A.7.3 S4: 聞き手への追従性

S4 は、聞き手自身の動きを手がかりとして判定する。音源が世界に固定されていれば、聞き手が動いたぶんだけ、聞き手から見た音源の位置は変化するはずである。逆に音源が聞き手に追従していれば、聞き手がどれだけ動いても、聞き手から見た位置は変わらない。

そこでまず、音源を現在位置に置いたまま聞き手だけを基準時点の位置と姿勢に戻し、そのときの相対座標を求める。これを実際の相対座標と比べた差が、音源が世界に固定されていた場合に生じるはずの変化量にあたる。以降ではこれを手がかりと呼ぶ。相対座標は、聞き手の位置のみを基準とするものと、位置および姿勢の双方を基準とするものの 2 種類を用いる。前者が位置追従に、後者が完全追従に対応する。

手がかりが閾値の 2 倍に満たない場合、聞き手がほとんど動いておらず、追従する音源と静止した音源とを区別できない。この場合は判定を保留し、基準点を保持したまま観測を続けることで、聞き手の動きが蓄積するのを待つ。手がかりが十分に大きいにもかかわらず、相対座標が基準時点からほとんど変化していなければ、その音源は聞き手に追従していると判定する。以上の判定をリスト 2 に、そこに現れる変数の説明を表 A·6 に示す。

```
// 音源が静止していたら相対座標はどれだけずれるはずか
Vector3 posOnlyIfRef = world - w.S4RefListenerPos;
Vector3 fullIfRef    = w.S4RefWorldToLocal.
    MultiplyPoint3x4(world);
float cuePos  = Vector3.Distance(posOnly,
    posOnlyIfRef);
float cueFull = Vector3.Distance(full,
    fullIfRef);

// 手がかりが足りなければ判定を保留する（基準点は保持する）
float need = epsilon * gateMargin;   // gateMargin
     = 2
bool canPos  = cuePos  > need;
bool canFull = cueFull > need;
if (!canPos && !canFull) return;

// 手がかりがあるのに相対座標が変わっていなければ追従している
float posOnlyDev = Vector3.Distance(posOnly, w.
    S4RefPosOnly);
float fullDev    = Vector3.Distance(full,    w.
    S4RefFull);
bool deviated = (canPos  && posOnlyDev <= epsilon)
             || (canFull && fullDev    <= epsilon)
                 ;
```

© 2026 Information Processing Society of Japan

表 A·5: 再生手段ごとの発音状態の取得可否、音源プロパティの読み取り可否、鳴っている clip の同定可否、および同じ手段を連続して呼び出したときの挙動。発音状態は `isPlaying` により音が鳴っているかを判別できるか、音源プロパティの読み取りは音源に与えた値をそのまま読み出せるか、`clip` の同定は鳴っている音声データを同定できるかを示す。連続呼び出しは、同一の音源に対して同じ API を連続して呼び出したときの挙動である。○は可、×は不可を表す。

再生 API	説明	発音状態	プロパティ	`clip` の同定	連続呼び出し
`Play`	音源に割り当てられたクリップを即座に再生する	○	○	○	上書き
`PlayDelayed`	指定した秒数だけ遅らせて再生する	○ [a]	○	○	上書き
`PlayScheduled`	指定した絶対時刻に再生を予約する	○ [a]	○	○	上書き
`PlayOneShot`	引数に与えたクリップを再生する	○	○	× [b]	重畳
`PlayClipAtPoint`	指定した位置に一時的な音源を生成して再生する	○	○ [c]	○ [c]	別音源

[a] 発音の開始前、再生が予約された時点で真となる。 [b] `clip` プロパティが引数に与えたクリップを反映しない。
[c] 呼び出し元とは別の、実行時に生成された音源の値である。

表 A·6: リスト 2 に現れる変数

変数	意味
`w`	監視対象の音源ごとに保持する状態
`world`	音源のワールド座標
`posOnly`	聞き手の位置のみを基準とした相対座標
`full`	聞き手の位置と姿勢を基準とした相対座標
`w.S4RefListenerPos`	基準時点の聞き手の位置
`w.S4RefWorldToLocal`	基準時点の聞き手の姿勢
`w.S4RefPosOnly`	基準時点の `posOnly`
`w.S4RefFull`	基準時点の `full`
`epsilon`	閾値 ε
`gateMargin`	手がかりに求める倍率（2）

```
Evaluate(w, S4_Follow, deviated);
ResetReference(w, posOnly, full);   // 基準点を打ち直す
```

Listing 2: S4 の判定（役割が非追従を指定する場合、C#）

A.7.4 S5: 音源の動きの有無

役割が発音中の静止を指定する音源について、発音中に限り、発音開始時のワールド座標からの偏差が閾値を超えるかを照合する。発音中にのみ評価するのは、鳴っていない間の音源の移動が正規の動作であるためである。

A.8 試験実装の測定結果の内訳

表 A·7 には各測定ごとの結果をまとめ、表 A·8 には各音源ごとの結果をまとめる。

表 A·7: 測定ごとの結果（各 300 s）。発音回数は発音の立ち上がりを数えたものであり、ループ再生中の BGM に対する攻撃提示 14 回を含まない。提示を単位とした総数はこれに 14 を加えた 312 回である。

	1 回目	2 回目	3 回目	合計
発音回数	98	99	101	298
攻撃による提示	20	18	19	57
検出	20	18	19	57
誤検知	0	0	0	0
逸脱の報告	35	30	34	99
検出遅延（平均）	0.004 s	0.005 s	0.005 s	0.005 s
S4 の評価回数	256,212	188,356	171,298	615,866

表 A·8: 音源ごとの内訳（300 s × 3 回の合計）

音源	正規	攻撃	検出	報告	逸脱した項目
BGM	3	14	14	56	S1-1, S1-2, S4, S5
設置音	81	15	15	15	S4
回転不可音	159	14	14	14	S4
削除音	12	14	14	14	S4
合計	255	57	57	99	

© 2026 Information Processing Society of Japan