差分プライバシーツールDPpackのユーザビリティ評価：既存研究の推奨事項と初学者の学習体験に基づく分析

阿部 実以奈[1,4,a)]　杉山 拓海[2,4,b)]　小野 元[3,5,c)]　南 和宏[4]

概要：差分プライバシー（DP）に基づく統計情報の公開ライブラリが数多く開発されている．しかし，DPの非専門家はその利用方法を十分に理解できず，誤用により意図したプライバシー保証を実現できないことが報告されている．既存研究では，Python ベースの DP ライブラリを対象にユーザビリティ向上の推奨事項が提案されている．しかし，R 言語向け DP ライブラリを対象にした既存研究の推奨事項に基づく研究は見られない．また，非専門家向け学習支援の研究は存在するが，利用・実装支援が中心であり，初学者の学習過程に着目した評価は行われていない．そこで本研究では，R 言語向け DP ライブラリの DPpack を対象に，推奨事項との適合性に基づく客観的分析と，筆頭著者の学習体験に基づく主観的分析を実施した．その結果，DPpack の推奨事項への対応は限定的であり，その多くは筆頭著者の学習過程で直面した課題と一致していた．一方，パラメータ設定では，利用者の負担軽減や設定ミスの防止を目的として設定の自動化が推奨されているが，初学者には自動化によるパラメータ設定値の決定根拠や処理内容を理解することが難しく，これらを明示する機能の必要性が示された．本研究は，既存の推奨事項を初学者の観点から評価し，学習過程を考慮した DP ライブラリ設計に向けた示唆を示す．

キーワード：差分プライバシー，オープンソース，ユーザビリティ，DPpack，R

Usability Evaluation of DPpack, a Differential Privacy tool Based on Community Recommendations and the Learning Experience of a Novice

Miina Abe[1,4,a)]　Takumi Sugiyama[2,4,b)]　Hajime Ono[3,5,c)]　Kazuhiro Minami[4]

Abstract: Differential privacy (DP) libraries support the privacy-preserving release of statistical data. However, non-experts often struggle to use them and may fail to achieve intended privacy guarantees. Although previous studies have proposed usability recommendations for Python-based DP libraries, those for R-based libraries remain limited. This study evaluates DPpack documentation, an R-based DP library, through an objective assessment against the existing recommendations and an analysis of the learning experience of the first author. The results show that DPpack satisfies only a limited number of the recommendations and that many of the unmet recommendations correspond to difficulties encountered during the learning process. While automated parameter selection is recommended to reduce user burden and configuration errors, our analysis suggests that automation alone makes it difficult for novices to understand the rationale for parameter choices and the underlying process. These findings suggest that explanatory support should complement automation in DP libraries intended for novice users. This study provides insights into DP library design that better supports novice learning.

Keywords: Differential Privacy, Open Source, Usability, DPpack, R

[1] 中央大学国際経営学部
Chuo University Faculty of Global Management
[2] 中央大学大学院経済学研究科
Chuo University Graduate School of Economics
[3] 金沢大学
Kanazawa University
[4] 情報・システム研究機構
Research Organization of Information Systems
[5] 情報・システム研究機構データサイエンス共同利用基盤施設

© 2026 Information Processing Society of Japan

This paper is work in progress and not peer-reviewed.

1. はじめに

差分プライバシー（Differential Privacy, *DP*）[5] は統計を公開する際のプライバシ保護の度合いを測る厳格な安全性指標として近年注目されている．差分プライバシー研究は理論的な検討から現実社会への実装段階に入っており，多くの利用事例がすでに存在している [18].

オープンソースの DP ツールが数多く作られているが，それらが実務で使われることはほとんどない [14]．DP ライブラリの正しい使い方を非専門家のデータ分析者に理解してもらうための設計は未解決の課題の一つとされている [3]．DP 非専門家のデータ分析者に実在の DP ツールを使わせるユーザースタディでは，誤用によるプライバシ侵害を発生させたりツールの使い方がわからなかったケースが多発したことが報告されている [15]．それらのユーザースタディの結果を通じて，DP ツールの開発における指針が提唱されている [4]：

(1) ユーザーの DP 理解度に合わせた段階的ドキュメント
(2) パラメータ設定の自動化
(3) モデル明示と標準的データ処理パイプラインへの接続
(4) プライバシー–有用性トレードオフの明示
(5) 利用者の実装の正確性検査

しかし，これらの既存研究において，次の 2 点が欠けている．体系化論文 [4] が調査した DP ツールの使いやすさに関する 8 つの論文のうち，実在の API 型のツールを使って研究したのは [15] のみであり，その中で使用された 4 つのツールはいずれも Python API である．また，非専門家向け学習支援の研究は存在するが，データサイエンスも含めての初学者の学習過程に着目した評価は行われていない．

本研究では R 言語の DP ライブラリである DPpack [7] を用いて，先述した 5 つのツール開発指針の妥当性を検討する．R は Stata と並んで経済学，政治科学，統計学においては Python よりも好まれる傾向がある [20]．人文社会学分野の研究者は調査票を用いたアンケート調査で，実在する回答者から収集したデータを分析するため，我々は彼らが差分プライバシーの潜在的なユーザーだと考えている．R 言語のライブラリは Python のライブラリに比べ，彼らの学習コストが低いと期待できる．先述した 4 つのツールのうち，OpenDP だけは R API も持つが内部実装は Rust である．一方，DPpack は内部実装も R であり，R に慣れた学習者は学習の次のステップとして内部実装を参照することもできる．したがって, DPpack は人文科学研究者にとって，有力な DP 学習教材になりうるツールである．

その検討は客観的・主観的観点それぞれから行う．客観的検討では DPpack のコードやドキュメントを参照し，5 つの推奨事項を満足しているか検討する（3 章）．主観的検討では，それらの満足あるいは不満足が著者の学習体験に与えた影響を主観的に検討する（4 章）．筆頭著者は経営学を学ぶ学部生であり，DP の学習の一環で DPpack を教材として使用した．

本研究の貢献は以下の 3 点である．第一に，Python 向け DP ツールを中心に得られた設計推奨事項の，R 向け DP ライブラリへの適用可能性を検討した．第二に，DPpack の推奨事項への適合状況と，DP 初学者が経験した学習上の困難との対応を整理した．第三に，発見した問題と改善案を対応付け，R 向け DP ライブラリの設計およびドキュメント改善に向けた知見を示した．

Research Organization of Information and Systems Joint Support-Center for Data Science Research
a) a23.n8e7@g.chuo-u.ac.jp
b) a19.dafe@g.chuo-u.ac.jp
c) hajime-ono@staff.kanazawa-u.ac.jp

2. 準備

2.1 差分プライバシー

DP は統計を公開する際にランダム性を加えるシステムにおいて，どの程度プライバシーが守られるかを測る安全性指標のひとつである．

DP では次のようなシステムを考える．データ集積者があるデータ D を持っており，そのデータの統計を公開することを望んでいる．このデータは複数のレコードで構成されており，それぞれが異なる個人に紐づいている．公開された統計からそれら個人の情報が復元されることを防ぐために，データ集積者は統計の計算過程でデータとは独立なランダム性を加える．この計算過程をメカニズム $\mathcal{M}$ と呼ぶ．この $\mathcal{M}$ の出力が公開され，外部の分析者たちに利用される．分析者たちの中には，データ D を構成する個人の情報を復元しようと試みる悪意のある分析者もいる．

DP は悪意のある分析者がメカニズムの出力からあるデータとそのデータと 1 人分のレコードだけが違うデータの区別できることをプライバシー侵害と考える．このようなデータの組を**隣接**していると表現する．隣接しているデータ対の見分けがつくならば，その差分の 1 人の情報が攻撃者に何かしら知られるということである．隣接していると定義する方法には自由度があり，代表的なものに *Bounded* と *Unbounded* がある．

定義 1 (Bounded と Unbounded)**.**

*(Bounded).*あるデータ D_1 の中の一人分のレコードを**変更**したものが D_2 である時，D_1 と D_2 は隣接しているという．

*(Unbounded).*あるデータ D_1 の中から *1* 人分のレコードを**削除**，あるいは，中に *1* 人分のレコードを**追加**したものが D_2 である時，D_1 と D_2 は隣接しているという．

前者では，あるデータ D とその全ての隣接データは構成する人数が固定されており，構成人数は公開情報である．後者では，あるデータ D とその隣接データベースは人数が

© 2026 Information Processing Society of Japan

1 異なり，構成人数は非公開情報である．

DP はメカニズム $\mathcal{M}$ の性質として定義される．

定義 2 ((ε,δ)-DP [5])．データのドメインを $\mathcal{D}$，公開しようとしている統計のドメインを $\mathcal{Z}$ とする．ある $\varepsilon \geq 0$ と $0 \leq \delta \leq 1$ が与えられた時，あるメカニズム $\mathcal{M}: \mathcal{D} \to \mathcal{Z}$ が任意の隣接するデータの組 $D, D' \in \mathcal{D}$ と任意の出力集合 $\mathcal{S} \subset \mathcal{Z}$ に対して，以下の不等式を満たすならば，撹乱メカニズム $\mathcal{M}$ は (ε,δ)-*DP* を満たすという：

$$\Pr(\mathcal{M}(D) \in \mathcal{S}|D) \leq e^{\varepsilon} \Pr(\mathcal{M}(D') \in \mathcal{S}|D') + \delta. \quad (1)$$

ただし，$\Pr(\mathcal{M}(D) \in \mathcal{S}|D)$ は D を入力として与えられて $\mathcal{M}$ の出力が $\mathcal{S}$ に入る確率である．

ε は $\mathcal{M}$ の出力から D と D' を識別する能力を尤度比の意味で制限しており，δ はその識別境界からズレの許容量である．ε のことを**プライバシー予算**と呼び，ε が 0 に近いほどその $\mathcal{M}$ は強い保護であることを意味する．δ は 1 よりずっと小さい値が指定される．特に，$\delta = 0$ の場合は，ε-DP という．ε-DP を pure DP，(ε,δ)-DP を approximate DP と呼ぶこともある．(ε,δ)-DP の定義の亜種に Probabilistic DP [12] がある．定義や違いは A.1 章を参照されたし．

1 つのデータから複数の統計を公開するとプライバシ侵害の可能性は蓄積し，DP の文脈ではそのような蓄積を**合成**（*composition*）と呼ぶ．合成を定量的に評価する**合成定理**がいくつか知られており，全体で所望のプライバシ保護を実現するためには各回にどの程度の予算を消費してよいか定量的に設計することができる．

DP を満たす代表的なメカニズムにラプラスメカニズムとガウシアンメカニズムがある．これらは平均 0 の Laplace 分布あるいは Gaussian 分布に従う乱数を統計に加えることで DP を満たす．それらの分布の分散の大きさを適切に設定することで ε を制御する．その大きさを決定するのが**感度**（*sensitivity*）である．

定義 3 (感度 [6])．関数 $f: \mathcal{D} \to \mathbb{R}^d$ の ℓ_1-感度は以下のように定義する：

$$\Delta_{f,1} \equiv \max_{D_1 \sim D_2} \|f(D_1) - f(D_2)\|_1 \quad (2)$$

また，ℓ_2-感度を以下のように定義する

$$\Delta_{f,2} \equiv \max_{D_1 \sim D_2} \|f(D_1) - f(D_2)\|_2.$$

ただし，$\|\cdot\|_1$ と $\|\cdot\|_2$ はそれぞれ ℓ_1 ノルムと ℓ_2 ノルムで，$\max_{D_1 \sim D_2}$ は任意の隣接データのペアに関して最大値をとることを表す．

感度は関数の性質とデータのドメインと隣接データの定義に依存し，無限に発散することもあり得る．

感度を使って，ラプラスメカニズムとガウシアンメカニズムが特定の ε に対して差分プライバシーを満たすように分散を設定することができる．ラプラスメカニズムは，ℓ_1-感度を用いて以下のように定義される．

定義 4 (ラプラスメカニズム [6])．任意の関数 $f: \mathcal{D} \to \mathbb{R}^d$ を考えたとき，ラプラスメカニズム $\mathcal{M}_L$ は以下のように定義できる：

$$\mathcal{M}_L(D, f(\cdot), \varepsilon) = f(D) + (Y_1, \cdots, Y_d) \quad (3)$$

ここで，$Y_i, (i = 1, \cdots, d)$ は *Laplace* 分布 $Lap(0, \Delta_{f,1}/\varepsilon)$ に独立同分布で従う確率変数である．

ラプラスメカニズムは ε-DP を満たす．また，ガウシアンメカニズムは，ℓ_2-感度を用いて定義される．

定義 5 (ガウシアンメカニズム [6])．任意の $0 < \varepsilon < 1$，$0 < \delta < 1$，ℓ_2-感度が有限である関数 $f: \mathcal{D} \to \mathbb{R}^d$ に対して，ガウシアンメカニズム $\mathcal{M}_G$ を以下のように定義する：

$$\mathcal{M}_G(D, f(\cdot), \varepsilon) = f(D) + (Z_1, \ldots, Z_d) \quad (4)$$

ここで，各 $Z_i, (i = 1, \ldots, d)$ は正規分布 $\mathcal{N}(0, \sigma^2)$ に独立同分布で従う確率変数で，$\sigma = \frac{\Delta_{f,2}(2\log(1.25/\delta))^{1/2}}{\varepsilon}$ である．

ガウシアンメカニズムは (ε,δ)-DP を満たす．ただし，どんな $\varepsilon > 0$ に対しても，ε-DP を満たすことはできない．また，上の定義で用いられている σ は余裕を持った十分条件であり，DP を満たすより小さな σ を数値的に探索する方法も知られている [1]．その方法で決めた σ を用いるものを本稿では解析的ガウシアンメカニズムと呼ぶ．

ラプラスメカニズム，ガウシアンメカニズム以外の基礎的なメカニズムとして指数メカニズム [13] がある．指数メカニズムの説明は A.1 章を参照されたし．

差分プライバシーを満たすように線形回帰の係数を出力するメカニズムも考えられている．例えば，[11] は，目的関数に乱数を加えることで，回帰係数の計算プロセスが DP を満たす．この時，目的関数に ℓ_2 正則化を加えることで，目的関数の各点での感度を有限に制御している．

ここまで説明してきた差分プライバシーは信頼できる中央のデータ集積者にデータを集積すると想定することから中央モデルと呼ばれる．他のモデルの 1 つに，中央のデータ集積者の生のデータを集める前に個人が各レコードをランダム化してから集積するローカルモデル [10] がある．ランダム性を与えることでデータを守るという発想やメカニズムに ε を定義する式は共通するが，システムモデルが異なるため，ユースケースや使用されるメカニズム（例えば，Randomized Response [21]）も異なる．

2.2 DP ツールとユーザビリティ

差分プライバシーを満たす匿名化アルゴリズムを実装しているオープンソースライブラリは，いくつも開発されている．代表的なものに OpenDP [19] があり，差分プライバシーを満たす統計を生成するためのアルゴリズムが実装されているライブラリである．そのほかにも Diffprivlib [9] や Tumult Analytics [2]，PipelineDP [17] などがある．

© 2026 Information Processing Society of Japan

本稿では，DPpack [7] に注目する．DPpack は，R 言語で使用できるパッケージであり，中央モデルの差分プライバシーを満たす集計表の作成や線形回帰などが可能である．DPpack バージョン 0.2.2 のドキュメントには付録 表 A·1 に示す 18 種の関数およびクラスが含まれている．また，付録 表 A·2 に本稿で言及される引数を示す。

[15] は，DP の専門家ではないデータ分析者及び専門家が DP ツールを使用する際のユーザビリティについて，learnability, efficiency, error prevention, user satisfaction [16] という 4 つの指標を用いて分析した．その結果，プライバシー予算 ε の合成定理の理解の難しさや，Diffprivlib [9] において DP を満たさない入力を被験者がしてしまう状態が確認できたこと，OpenDP [19] のエラーメッセージが，Rust 由来のものとして出力される問題点があった．同研究は，わかりやすく取り扱いやすい DP に特化したドキュメントの提供とエラー回避手法と復旧手法の強化，ユーザーの学習を支援する API 設計の改善，そして DP に関する基礎知識を促進する情報が必要であると指摘している．

体系化論文 [4] は DP ツールのユーザビリティと DP の説明方法に関する 27 の論文を調査し，ユーザビリティの課題とツールの開発者に対する推奨事項を指摘した．DP ツールにおけるユーザビリティをソフトウェア開発者などの**技術利用者**に対するものと，DP 実装の**エンドユーザー**に該当するデータ主体や一般社会に対してのものに分けて網羅的に分析した．その結果，ツールの設計に関して 5 つの推奨事項を導出している：

- 必要とされる専門知識を慎重かつ控えめに記述すること．利用者の DP 理解度に応じて別々のインターフェースを用意し．必要なときだけ複雑さを見せる「段階的開示」を採用し，さらに，あらゆる利用者層に向けた高品質なドキュメントと具体例を用意すること．
- 可能な限り自動的にパラメータを設定する仕組みを取り入れ，プライバシ侵害になる初期値も避けること．
- 各ステークホルダーの役割と責任，想定される専門知識，そして期待される信頼度を明確に説明すること．中央モデル以外もサポートすること．また，DP ツールを既存のデータ基盤と統合しやすくするため，モジュール型の設計などで柔軟性を高めること．
- 関係者間でプライバシーと有用性のトレードオフを調整できるよう, 各種パラメータの選択が有用性に与える影響を検討できる仕組みを備えること．
- 利用者が DP を満たさない実装をしないようチェックし，明示的にエラーを出すこと．

3. 客観評価

3.1 DP 理解度に応じた段階的ドキュメント

DPpack のドキュメントは，ライブラリの目的や対象とする分析，利用に必要な前提知識などを説明する導入部を設けず，文書の冒頭から関数一覧と各関数の説明で構成されていた．また，目次は関数名の辞書順に並べられており[*1]，DP の基礎概念から応用へと学習を進める順序や，最初に参照すべき関数は示されていなかった．さらに，各関数は個別に説明されているものの，関数同士の関係や使い分け，適用場面をまとめて説明する記述は確認できなかった．

DP 固有の概念についても，説明は限定的であった[*2]．例えば，`which.sensitivity` では，`bounded` / `unbounded` / `both` の 3 種類を選択できることが示されている．`bounded` については，“If 'bounded' (default), returns result based on bounded definition for differential privacy.” と説明されているが，この記述は「差分プライバシーの bounded の定義に基づく結果を返す」と述べるにとどまっており，`bounded` と `unbounded` の違いや，どのような場面で選択すべきかについての説明は記載されていなかった．

各関数にはサンプルコードが掲載されていたものの，理解度に応じた例の区別は確認できなかった．また，パラメータを変更した場合の結果を比較する例や，可視化を用いて結果を解釈する例も掲載されておらず，利用者が試行錯誤しながら理解を深める構成にはなっていなかった．さらに，`GaussianMechanism` の説明では，実際には正規分布に基づくノイズを付与する関数であるにもかかわらず，「ラプラスノイズを付与する」と記載されていた．

3.2 パラメータ設定と意思決定支援

DPpack では，多くの関数において，`eps`，`delta`，`sensitivity`，`upper.bound1`，`upper.bound2`，`lower.bound1`，`lower.bound2` などのパラメータを利用者が設定する必要がある．ドキュメントには，各引数の意味，選択可能な値，既定値，および個別の設定例が記載されていた．一方で，実際の分析において，どのような手順や根拠に基づいて設定値を決定すべきかを示す説明は限定的であった．分析目的やデータの性質に応じた選択基準，推奨される値の範囲，設定値を変更した場合に生じるプライバシー保証や出力の有用性への影響についても，体系的な説明は確認できなかった．

複数の引数には既定値が設定されている．`delta = 0` は ε-DP に帰着することが明記されている．一方で，`which.sensitivity = bounded` や `mechanism = Laplace` については，既定値として採用されていることは示されていたものの，その値が既定値として選択された理由や，値を変更すべき条件は説明されてい

[*1] DPpack 固有の問題ではなく，R プログラム共有ネットワーク CRAN が API reference を自動生成する際の仕様である．

[*2] 各用語やメカニズムに関する補足説明が開発者自身によって arXiv に投稿されている [8] が，DPpack の配布ページやドキュメントからリンクされておらず，発見が難しい．

© 2026 Information Processing Society of Japan

なかった．また，`analytic = FALSE`についても，解析的ガウシアンメカニズムを使用しない設定であることは記載されていたが，`TRUE`との選択基準は示されていなかった．

一部の関数ではパラメータの自動計算が提供されている．`covDP`では，データと`which.sensitivity`を指定することで，`sensitivity`が自動的に算出される．この機能は，利用者が感度を自ら導出して入力する負担を軽減するものである．ただし，自動計算の対象は一部のパラメータに限られ，`eps`，`delta`，上下限などの主要な設定値は利用者が決定する必要がある．また，算出方法や前提条件を確認するための説明は限定的であった．

評価を行った範囲では，DP 保証を成立させない値を既定値として採用する設計は確認されなかった．しかし，不適切な既定値が確認されなかったことと，利用者が適切な値を選択できるよう支援されていることは同一ではない．

3.3 導入モデルと既存のデータ処理基盤との統合

DPpack のドキュメントでは，中央モデルやローカルモデルなどの導入モデルを区別した説明を確認できず，DPpack がどの導入モデルを想定しているかを判断できなかった．

また，データを保持する主体，DP 処理を行う主体，結果を利用する主体などの役割や責任を整理した説明は確認できなかった．

既存のデータ処理基盤との統合については，各関数の引数や返り値，基本的なサンプルコードが示されており，R 上で利用するための操作方法を確認できた．一方，R 以外のデータ処理環境との連携方法，既存のデータ処理基盤に DPpack を組み込む方法，新たな機能や連携方法を追加する方法については記載されていなかった．

なお，本研究で対象とした関数の多くは，一度の関数呼び出しで結果を得る形式である．これに対して，`LinearRegressionDP`は R6 クラスを用いており，`new()`によるオブジェクトの生成，`fit()`による学習，`predict()`による予測という手順で利用する．回帰モデルでは学習したモデルの状態を保持し，その後の予測に利用するため，R6 クラスを採用していること自体をユーザビリティ上の問題とは判断できない．一方，各関数やクラスの操作方法は個別に示されているものの，API 形式の違いや使い分けをライブラリ全体として説明する記述は確認できなかった．

3.4 プライバシーと有用性のトレードオフ

DPpack では，各関数に`eps`と`delta`で ε と δ を設定できるほか，複数の出力を扱う場合には，`sensitivities`や`alloc.proportions`を用いてプライバシー予算の配分を指定できる．ドキュメントには，予算配分後も全体として指定した (ε, δ) の保証が維持されることが説明されている．一方，異なる設定を選択した場合に，出力の誤差や有用性がどのように変化するかを比較する説明，指標，可視化は確認できなかった．また，関係者間での検討を支援する記述や，複数回の解析における予算の累積・追跡方法も記載されていなかった．

3.5 エラー予防・検出・回復支援

DPpack のドキュメントに示された入力条件や既定値に加え，意図的に不適切な値を入力した場合の挙動評価を行った．引数に想定と異なる型を入力した場合や，必須引数を指定しない場合の多くでエラーが表示され，停止した．

一方，データドメインの上限`upper.bound`に下限`lower.bound`より小さい値を入力しても，エラーや警告は表示されず数値が出力された．また，入力データの一部またはすべての観測値が指定範囲外となるように上下限を設定した場合にも，エラーや警告を確認できなかった．このため，入力形式が正しくても，設定値の意味的な整合性まで常に検査されるわけではないことを確認した．エラーや警告が表示されない場合に，設定の妥当性を確認するための手掛かりも提供されなかった．

4. 主観評価

3 章では，DPpack の 5 つの推奨項目の適合状況を客観的に評価した．ここではそれらの満足度が DPpack の主観的利用体験に与える影響を著者自身の利用体験から報告する．

筆頭著者は国際経営学部に所属し，主に国際経済法を学んでいる．プログラミングについては，大学の授業を通じて Python および R を使用した経験はあったものの，いずれも基礎的な内容に限られている．特に R に関しては基本的な文法や繰り返し処理，ソートアルゴリズムなどを学習した．また，統計学の授業では確率統計，推測統計および仮説検定の基礎を学習したが，その内容は文系学部生向けの入門的なものであった．一方，プライバシー保護や差分プライバシーについて，DPpack の利用開始以前より継続的な学習を行っていた．著者は約 5 か月間，週 1 回 5 時間程度，文献 [22] を用いて学習し，第 8 章「差分プライバシーのメカニズム」まで読了した．この学習を通じて，プライバシー予算 ε，感度，ラプラスメカニズム，ガウシアンメカニズムおよび合成定理などの基本概念を理解していた．

4.1 DP 理解度に応じた段階的ドキュメント

筆頭著者は，DPpack のドキュメントを参照しながら各関数の実行と検証を行った．事前に DP の基礎を学習していたものの，ドキュメントのみから用語や引数の意味を十分に理解することは困難であった．例えば，`which.sensitivity`では，`bounded`，`unbounded`，`both`の 3 種類を選択できることは示されていたが，それぞれがどのような隣接デー

© 2026 Information Processing Society of Japan

タセットの定義に対応し，感度の計算にどのような違いをもたらすのかを理解することはできなかった．そのため，論文や外部資料を参照し，隣接データセットと感度の関係について追加で学習する必要があった．また，`type.DP`についても，`pDP`と`aDP`の概念的な違いはドキュメントのみでは理解できず，論文を参照して理解を補った．

学習を進める中で，関数の掲載順に違和感を覚えた．後に，目次が関数名の辞書順で構成されていることを確認したが，概念的な難易度や前後関係を考慮した学習順序は示されていなかった．そのため，どの関数から学習を始め，どのような順序で理解を深めればよいかを判断できず，掲載順に従って学習を進めた．各関数の説明を個別に参照することはできたものの，ライブラリ全体における各関数の役割や関係を把握することは容易ではなかった．

特に，`LinearRegressionDP`については，サンプルコードを実行できたものの，各引数や処理の意味を十分に理解できなかった．また，理解を深めるためにどの分野や概念を追加で学習すべきか分からず，自力で学習の方向性を定めることは容易ではなかった．その後，教員の助言に基づいてリッジ回帰を学習した結果，正則化に関する知識が前提となっていることに気付いた．例えば，サンプルコード中の`regularizer.gr <- function(coeff) coeff`を理解するためには，L2 正則化とその勾配の関係を理解している必要があった．しかし，この数学的背景や，コード中での役割は，ドキュメントでは説明されていない．そのため，コードをそのまま実行できても，なぜこの関数が必要であるのかを理解することは容易ではなかった．

また，ドキュメントとサンプルコードの対応関係が十分ではないと感じられる箇所もあった．例えば，`predict()`はサンプルコードで使用されていたものの，メソッドや引数の説明がなく，何を行う処理か理解できなかった．`clone()`は，動作の説明はあったが，想定される利用場面が示されていなかったため，必要性が理解できなかった．

さらに，`GaussianMechanism`の説明に実際の処理と異なるノイズ分布が記載されていた箇所では，当初，自身の理解不足とドキュメントの誤りを区別できなかった．教員への確認を経て誤植であることを確認したが，それまでは自身の理解や学習内容を再確認する必要が生じた．

4.2 パラメータ設定と意思決定支援

サンプルコードに記載された値を入力することで，各関数を実行することは可能であった．しかし，自らパラメータを設定する場面を想定すると，`sensitivity`，上下限，`eps`，`delta`，`alloc.proportions`などについて，どのような考え方に基づいて値を決定すべきかを判断することは容易ではなかった．各パラメータの意味を理解することと，分析目的に応じて適切な値を選択することとの間には，別の困難が存在すると感じられた．

一部の関数では，データと`which.sensitivity`を指定することで感度が自動的に算出されるため，感度を自ら導出して入力する必要はなかった．この機能により，計算や入力に伴う操作上の負担は軽減されたが，算出された値がどのような計算方法や前提条件に基づくのかを，ドキュメントのみから十分に把握できなかった．そのため，自動計算された値を用いて関数を実行することはできても，その値を自身の分析に適用してよいかについて十分な納得を得ることは難しかった．

さらに，パラメータの違いが出力結果に与える影響を確認するため，設定値を変更して関数を複数回実行し，結果の集計，グラフの作成，元の統計量からの誤差の算出などを行った．しかし，ドキュメントにはこのような比較方法を示すサンプルコードがなかったため，変更するパラメータ，実行回数，評価指標，可視化方法を自ら検討し，コードを作成する必要があった．，プログラミング経験が十分ではない初学者にとって，この作業には一定の負担を伴った．

また，DP による出力にはランダム性が含まれるため，設定値の違いによる影響が明確に現れない場合があった．これは，設定値による影響が存在しないことを意味するものではなく，筆頭著者が採用した比較方法では影響を十分に捉えられなかった可能性もある．初学者が，どのような比較方法を用いればパラメータの影響を適切に確認できるのかを自ら判断することは容易ではなかった．そのため，異なる設定値による複数回の実行結果や誤差分布を比較するサンプルコードに加え，適切な実行回数，評価指標，可視化方法，設定値の影響に関する理論的な説明も重要であると考えられる．

4.3 導入モデルと既存のデータ処理基盤との統合

学習では，ドキュメントに掲載されたサンプルコードを用いることで，各関数を実行し，出力を確認することができた．また，パラメータを変更して複数回実行したり，得られた結果を保存して比較や可視化に利用したりすることも可能であった．

一方で，サンプルコードを実行できるようになった後も，DPpack を実際のデータ分析にどのように利用するのかを具体的にイメージすることは難しかった．実際のデータを用いる場合に，データの準備から DP 処理，結果の利用までをどのような流れで行うのか，また，どのような場面で各関数を選択するのかについては把握できなかった．そのため，学習用のサンプルコードを用いる範囲では操作できても，実際のデータに自ら DP を適用する場合に適切に利用できるという確信を持つことはできなかった．また，誰が元のデータを保持し，誰が DP 処理を行い，得られた結果を誰が利用するのか，どの段階で DP を適用するのかといった利用場面も想定できなかった．

© 2026 Information Processing Society of Japan

`LinearRegressionDP` では，それまでに使用した関数とは異なる操作が必要となり，R6 クラスやオブジェクトの扱いについて新たに調べながら学習を進めた．サンプルコードに従うことで処理を実行することはできたものの，なぜこの API 形式を用いるのか，`new()`，`fit()`，`predict()` という複数の操作に分ける必要があるのかについては理解するに至らなかった．異なる API 形式そのものが利用を妨げたわけではなく，その理由や他の処理との関係を理解するための情報が得られないことが学習上の負担となった．

なお，外部のデータ処理基盤との接続や，新たな機能の追加については，本研究の学習過程では実際に試していないため，利用体験に基づく評価は行わなかった．

4.4 プライバシーと有用性のトレードオフ

前述したように，筆頭著者はパラメータの違いによる出力への影響を確認するため，設定値を変更して複数回実行し，誤差の算出や可視化を行った．しかし，この作業を行った後も，どの程度の精度低下までを許容し，分析結果として利用できるか，プライバシーをどの程度優先すべきなのかを判断する明確な基準を持つことはできなかった．設定値による違いを確認することと，その結果から適切な設定を選択することは別の問題であると感じた．

`alloc.proportions` については，具体例から複数の出力に予算を配分する仕組みを理解することができた．一方で，例えば二つの出力のうち一方に多くの予算を配分する必要がある場合，どちらを優先するか，またその割合をどのような基準で決めるかまでは判断できなかった．本研究では複数の関係者の間で設定値を検討する場面は経験していないが，筆頭著者一人でも設定値の妥当性を判断することに難しさを感じた．数値を指定できるだけでは，なぜその設定を選択したのかを他者に説明することも容易ではないと感じられた．

また，1 回の解析における予算配分については理解できたものの，同じデータに対して複数回解析を行う場合に，それまでに使用したプライバシー予算をどのように考えればよいのかは分からなかった．実際の利用場面で解析を繰り返す場合に，プライバシー予算を継続的に管理することは難しいと感じた．

4.5 エラー予防・検出・回復支援

学習では，複数の引数に既定値が設定されているため，すべての値を自ら指定しなくても関数を実行することができた．ただし，既定値をそのまま利用してよいかを判断できるかどうかは，筆頭著者がその引数をどの程度理解しているかによって異なった．例えば，`delta = 0` については，ε-DP として扱われることが明記されており，既知であったため，既定値の 0 を用いる場合と 0 以外の値を設定する場合を判断しやすく，設定に迷うことはなかった．一方，`analytic = FALSE` や `tol = 1e-12` については，関連する概念を十分に理解していなかったため，説明を読んでも既定値のままでよいかを判断することは難しかった．

このことはパラメータの入力条件についても同様のことがいえる．その概念の理解が十分でない段階では，条件を守ることはできても，その中から適切な値を選択することは難しい。

また，通常のサンプルコードを利用するだけでは，ドキュメントに示された入力条件が実行時にどの程度検査されるのか，また，どのような設定について利用者自身が妥当性を確認する必要があるのかを把握することができなかった．そのため，筆頭著者は引数の型や境界値を意図的に変更し，エラーや警告の挙動を確認した．

その結果，想定と異なる型を指定した場合や必須引数を省略した場合にはエラーが表示され，入力の誤りに気付くことができた．一方，`upper.bound` を `lower.bound` より小さく設定した場合や，入力データの一部またはすべての観測値が指定範囲外となるように境界値を設定した場合にも、エラーや警告が表示されず処理が行われた。

このような挙動を確認したことで，エラーや警告が表示されず数値が出力された場合でも，その結果をそのまま妥当なものとして受け取ることが難しくなった．また，それまでの学習でも，自身が気付かないまま不適切な設定を用いていた可能性があるのではないかという不安が生じた．DP 保証に問題が生じる可能性のある設定を検出し，必要に応じてエラーを表示する妥当性の検査は，誤設定を防ぐだけでなく，利用者が得られた結果に確信を持つためにも重要であると考えられた．

5. 結論

本研究では，差分プライバシーツール DPpack を対象として，既存研究で示された DP ツールの推奨事項に基づく客観評価と，初学者である筆頭著者の学習体験に基づく主観評価を行った．客観評価で確認された推奨事項への対応状況と，主観評価で確認された学習上の困難には多くの対応がみられ，既存の推奨事項は DP ツールのユーザビリティを評価する観点として有用であることが示された．

一方，推奨事項で示されている設定の自動化については，値の設定や選択肢の決定に伴う利用者の負担を軽減できる一方，初学者には，自動的に得られた値や選択がどのような計算や判断に基づくものかを理解することが難しかった．そのため，自動化する場合には，結果だけを提示するのではなく，その決定過程や算出根拠，適用条件を併せて示すことが重要である．

また，DP の利用には，ツールの改善や自動化だけでは解消できない難しさも含まれる．設定値や選択肢の中には，

© 2026 Information Processing Society of Japan

分析目的や求めるプライバシーと有用性などによって適切な判断が異なり，一般的な答えを容易に定めることができないものもある．このような問題を単にツールの不足として扱うのではなく，容易に結論を出せない問題であること自体を利用者に明確に示すことも必要である．

以上より，DP ツールを初学者の学習という観点から評価する際には，既存の推奨事項への対応だけでなく，自動化された設定や処理の根拠を理解できるようにすること，さらに，DP そのものに含まれる判断の難しさを利用者が認識できるようにすることも重要である．本研究は，DP ツールの操作のしやすさに加えて，初学者が設定や処理の意味を理解し，その限界を認識しながら利用できるよう支援する観点の必要性を示した．

謝辞

本研究は，JST 経済安全保障重要技術育成プログラム【JPMJKP24U5】の支援を受けたものです．

参考文献

[1] Balle, B. and Wang, Y.-X.: Improving the Gaussian Mechanism for Differential Privacy: Analytical Calibration and Optimal Denoising, *Proceedings of the 35th International Conference on Machine Learning* (Dy, J. and Krause, A., eds.), Proceedings of Machine Learning Research, Vol. 80, PMLR, pp. 394–403 (online), available from ⟨https://proceedings.mlr.press/v80/balle18a.html⟩ (2018).

[2] Berghel, S., Bohannon, P., Desfontaines, D., Estes, C., Haney, S., Hartman, L., Hay, M., Machanavajjhala, A., Magerlein, T., Miklau, G., Pai, A., Sexton, W. and Shrestha, R.: Tumult Analytics: a robust, easy-to-use, scalable, and expressive framework for differential privacy (2022).

[3] Cummings, R., Desfontaines, D., Evans, D., Geambasu, R., Huang, Y., Jagielski, M., Kairouz, P., Kamath, G., Oh, S., Ohrimenko, O., Papernot, N., Rogers, R., Shen, M., Song, S., Su, W., Terzis, A., Thakurta, A., Vassilvitskii, S., Wang, Y.-X., Xiong, L., Yekhanin, S., Yu, D., Zhang, H. and Zhang, W.: Advancing Differential Privacy: Where We Are Now and Future Directions for Real-World Deployment, *Harvard Data Science Review*, Vol. 6, No. 1 (online), DOI: 10.1162/99608f92.d3197524 (2024).

[4] Dibia, O., Bhattacharjee, P., Stenger, B., Baldasty, S., Bates, M., Ngong, I., Feng, Y. and Near, J.: SoK: Usability Studies in Differential Privacy, *Proceedings on Privacy Enhancing Technologies*, Vol. 2025, No. 4, p. 881–895 (online), DOI: 10.56553/popets-2025-0162 (2025).

[5] Dwork, C., McSherry, F., Nissim, K. and Smith, A.: Calibrating Noise to Sensitivity in Private Data Analysis, *Theory of Cryptography* (Halevi, S. and Rabin, T., eds.), Berlin, Heidelberg, Springer Berlin Heidelberg, pp. 265–284 (2006).

[6] Dwork, C. and Roth, A.: The Algorithmic Foundations of Differential Privacy, *Foundations and Trends in Theoretical Computer Science*, Vol. 9, No. 3–4, pp. 211–407 (online), DOI: 10.1561/0400000042 (2014).

[7] Giddens, S.: DPpack: Differentially Private Statistical Analysis and Machine Learning (2022).

[8] Giddens, S. and Liu, F.: DPpack: An R Package for Differentially Private Statistical Analysis and Machine Learning, https://arxiv.org/abs/2309.10965 (2023).

[9] Holohan, N., Braghin, S., Mac Aonghusa, P. and Levacher, K.: Diffprivlib: the IBM differential privacy library, *ArXiv e-prints*, Vol. 1907.02444 [cs.CR] (2019).

[10] Kasiviswanathan, S. P., Lee, H. K., Nissim, K., Raskhodnikova, S. and Smith, A.: What Can We Learn Privately?, *SIAM Journal on Computing*, Vol. 40, No. 3, pp. 793–826 (online), DOI: 10.1137/090756090 (2011).

[11] Kifer, D., Smith, A. and Thakurta, A.: Private Convex Empirical Risk Minimization and High-dimensional Regression, *Proceedings of the 25th Annual Conference on Learning Theory* (Mannor, S., Srebro, N. and Williamson, R. C., eds.), Proceedings of Machine Learning Research, Vol. 23, Edinburgh, Scotland, PMLR, pp. 25.1–25.40 (online), available from ⟨https://proceedings.mlr.press/v23/kifer12.html⟩ (2012).

[12] Machanavajjhala, A., Kifer, D., Abowd, J., Gehrke, J. and Vilhuber, L.: Privacy: Theory meets Practice on the Map, *2008 IEEE 24th International Conference on Data Engineering*, pp. 277–286 (online), DOI: 10.1109/ICDE.2008.4497436 (2008).

[13] McSherry, F. and Talwar, K.: Mechanism Design via Differential Privacy, *48th Annual IEEE Symposium on Foundations of Computer Science (FOCS'07)*, pp. 94–103 (online), DOI: 10.1109/FOCS.2007.66 (2007).

[14] Munilla Garrido, G., Liu, X., Matthes, F. and Song, D.: Lessons Learned: Surveying the Practicality of Differential Privacy in the Industry, *Proceedings on Privacy Enhancing Technologies*, Vol. 2023, No. 2, pp. 151–170 (online), DOI: 10.56553/popets-2023-0045 (2023).

[15] Ngong, I. C., Stenger, B., Near, J. P. and Feng, Y.: Evaluating the Usability of Differential Privacy Tools with Data Practitioners, *Twentieth Symposium on Usable Privacy and Security (SOUPS 2024)*, Philadelphia, PA, USENIX Association, pp. 21–40 (online), available from ⟨`https://www.usenix.org/conference/soups2024/presentation/ngong`⟩ (2024).

[16] Nielsen, J.: Usability metrics: tracking interface improvements, *IEEE Software*, Vol. 13, No. 6, pp. 1–2 (online), DOI: 10.1109/MS.1996.8740869 (1996).

[17] OpenMined: PipelineDP (2026).

[18] The OpenDP Project: Differential Privacy Deployments Registry, `https://registry.opendp.org/deployments-registry/` (2025). 最終アクセス日: 2026 年 8 月 5 日.

[19] The OpenDP Project: *OpenDP: R Bindings for the OpenDP Library* (2026). R package version 0.15.1.

[20] Upton, E., Cai, X., Jakiela, P., Ozier, O. and Raman, S.: The Software Behind the Stats: A Student Exploration of Software Trends Across Disciplines (2025).

[21] Warner, S. L.: Randomized Response: A Survey Technique for Eliminating Evasive Answer Bias, *Journal of the American Statistical Association*, Vol. 60, No. 309, pp. 63–69 (online), available from ⟨http://www.jstor.org/stable/2283137⟩ (1965).

[22] 淳佐久間，講談社サイエンティフィク：データ解析におけるプライバシー保護，講談社 (2016).

© 2026 Information Processing Society of Japan

付　　録

A.1　その他の DP 知識

A.1.1　Probabilistic DP

Probabilistic DP は以下のように定義される，

定義 6 ((ε,δ)-probabilistic DP [12])．$\mathcal{M}:\mathcal{D}\to\mathcal{Z}$ をメカニズム，D, D' を隣接データとする．与えられた任意の $\varepsilon>0$ と $0<\delta<1$ に対して，出力 $o\in\mathcal{Z}$ のうち，ある隣接データ D' に対して

$$\left|\log\frac{\Pr[\mathcal{M}(D)=o]}{\Pr[\mathcal{M}(D')=o]}\right|>\varepsilon$$

を満たすもの全体を D における開示集合 $\mathrm{Disc}(D,\varepsilon)$ と呼ぶ．すべての D について

$$\Pr\big[\mathcal{M}(D)\in\mathrm{Disc}(D,\varepsilon)\big]\le\delta$$

が成り立つとき，$\mathcal{M}$ は (ε,δ)-*probabilistic DP* を満たすという．ここで確率は $\mathcal{M}$ のランダムネスに関するものである．

この定義において，δ は ε の保証が成立しない出力が生じる確率という直接的な意味を持つ．

本稿における Approximate DP と Probabilistic DP の最も大きな違いは，ガウシアンメカニズムでそれぞれを満足するために必要な σ の大きさと適用可能な ε の範囲である．Probabilistic DP を満足するための σ は

$$\sigma\ge\frac{\Delta_2}{2\varepsilon}\left(\sqrt{\left(\Phi^{-1}(\delta/2)\right)^2+2\varepsilon}\ -\ \Phi^{-1}(\delta/2)\right).$$

ただし，Φ^{-1} は標準正規分布の逆累積分布関数である．Approximate DP を前提とした定義 5 では $0<\varepsilon<1$ という制約があるが，上記の式の場合は任意の ε で使える．より詳細な情報は [8] を参照されたい．

A.1.2　指数メカニズム

ラプラスメカニズムやガウシアンメカニズムは，出力結果を保護するためにノイズを付与するメカニズムであり，その出力は連続である．指数メカニズムは，離散出力を求められる場合に向いた DP を満たすアルゴリズムである．指数メカニズムは，そのメカニズムから得られた出力を，スコア関数 $U:\mathcal{D}\times Y\to\mathbb{R}$ で評価し，スコア関数は，そのメカニズムから得られた出力が，元データから得られる出力に近いほどスコアが高くなるように定義する．指数メカニズムは，以下に示されるスコア関数の感度とメカニズムで表すことができる．

定義 7 (指数メカニズム [6], [13])．Y をデータから出力されうる離散値の集合とし，離散スコア関数を

$$\Delta_{U,q}=\max_{y\in Y}\max_{D_1\sim D_2}\ |\,U(D_1,y)-U(D_2,y)\,|$$

としたとき，指数メカニズム $\mathcal{M}_E(D,U,Y)$ は出力 y を確率 $\frac{\varepsilon U(D,y)}{2\Delta_{U,q}}$ で出力する．

A.2　その他の DPpack 知識

表 A·1　DPpack に実装された関数およびクラス
Table A·1　Functions and Classes Implemented in DPpack.

`ExponentialMechanism`	汎用的なメカニズムを実装した関数
`GaussianMechanism`	
`LaplaceMechanism`	
`covDP`	データからランダム化された統計を出力するメカニズムを実装した関数
`histogramDP`	
`meanDP`	
`medianDP`	
`pooledDP`	
`pooledVarDP`	
`quantileDP`	
`sdDP`	
`tableDP`	
`varDP`	
`LinearRegressionDP`	機械学習を行うためのクラス
`LogisticRegressionDP`	
`svmDP`	
`tune_classification_model`	学習モデルのハイパーパラメータチューニングをする関数
`tune_linear_regression_model`	

© 2026 Information Processing Society of Japan

表 A·2 本論文で記載されている DPpack [7] 由来の主要な引数，選択肢およびメソッド
Table A·2 Main Arguments, Options, and Methods Used in this Paper from DPpack [7]

項目	内容
プライバシー水準に関する引数	
`eps`	ε の値を指定する引数.
`delta`	(ε, δ)-DP の δ を指定する引数．0 の場合は ε-DP となる．
感度および入力範囲に関する引数・選択肢	
`sensitivity`	ラプラスメカニズム, Gaussiam メカニズム, 指数メカニズムに必要な Sensitivity を指定する引数であり，`LaplaceMechanism()` および `GaussianMechanism()` では複数形の `sensitivities`，`ExponentialMechanism()` では単数形の `sensitivity` を使用することに注意.
`which.sensitivity`	統計関数で使用する感度の定義として，`"bounded"`，`"unbounded"` または `"both"` を選択する引数.
`upper.bound1` / `upper.bound2`	`covDP()` などの関数に入力する第 1 ベクトル `x1` および第 2 ベクトル `x2` について，それぞれ大域的または公開された上限を指定する実数.
`lower.bound1` / `lower.bound2`	`covDP()` などの関数に入力する第 1 ベクトル `x1` および第 2 ベクトル `x2` について，それぞれ大域的または公開された下限を指定する実数.
メカニズム，ノイズおよび予算配分に関する引数・選択肢	
`mechanism`	統計量のランダム化に使用する DP メカニズムを指定する引数．指定可能な値は関数によって異なるが，デフォルトは `Laplace`.
`type.DP`	ガウシアンメカニズムで満たす DP の種類を指定する引数．既定値の `"aDP"` は (ε, δ)-近似 DP，`"pDP"` は (ε, δ)-確率的 DP を表す．通常のガウシアンメカニズムで `"aDP"` を選択する場合は $\varepsilon < 1$ とする必要がある.
`analytic`	解析的ガウシアンメカニズムを使用するかを指定する引数．ランダム化された統計を出力するメカニズムを実装した関数内では `mechanism="analytic"` という形で表され，`GaussianMechanism()` では `analytic=TRUE` という形で用いる.
`tol`	解析的ガウシアンメカニズムのノイズパラメータを二分探索で求める際の許容誤差を指定する引数．`GaussianMechanism()` で `analytic=TRUE` の場合に使用され，デフォルト値は $1e^{-12}$.
`alloc.proportions`	複数の関数値を公開する際のプライバシー予算の配分比率を指定する引数．Laplace 機構では ε，Gaussian 機構では ε と δ を配分する．入力値の合計を 1 に正規化する必要はなく，入力値の比で決まる.
出力形式および後処理に関する引数	
`normalize`	`histogramDP()` の出力形式を指定する引数．`FALSE` では度数，`TRUE` では面積が 1 となる密度を返す.
`allow.negative`	ノイズによって生じた負の度数を保持するかを指定するバイナリーの引数．`histogramDP()` および `tableDP()` で用い，デフォルト値の `FALSE` では負の値を 0 に置き換える.
モデルクラスのメソッド	
`new()`	新しく DP を満たす回帰モデルオブジェクトを生成する関数
`fit()`	差分プライバシーを満たす線形回帰モデルを学習する．[11] によるアルゴリズムを用いて回帰係数を求める.
`clone()`	R6 モデルオブジェクトを複製する引数 `model$clone(...)` の形式で呼び出し、`deep` で深いクローンを作成するかを決める.
`predict()`	学習済みの DP 対応係数を用いて，新しいデータに対する予測値またはクラスラベルを出力する.

© 2026 Information Processing Society of Japan