重み空間ドリフトと拒否方向回転による公開 fine-tuned LLMs の安全性監査

韓 燦洙[1,a)]　高橋 健志[1]

概要：公開モデルハブには，整合済み instruct モデルから派生した多数のファインチューニング（FT）済みチェックポイントが流通するが，導入側がフルの行動評価を再実行することは少なく，安全性・サイバー悪用の供給連鎖リスクとなる．本稿は，同一の 8 件の公開 FT（Llama-3.2-1B 系 4 件・Qwen3-1.7B 系 4 件）に対し，重み空間ドリフトと拒否方向の回転という二つの軽量な監査観点を同一ベンチ上で併記して測定する．中間層 `down_proj` の系列相対の重み変化 δ_W は 10 ベンチ平均の劣化 Y_{all} と中程度の探索的相関（Spearman $\rho\approx0.71$，$n=8$）を示すが，拒否方向の回転 $X_{\cos}$ は 5 安全ベンチの劣化 Y_{safety} と弱い負相関（$\rho\approx-0.43$）にとどまり，本探索的パネルでは 5 サイバー悪用ベンチの劣化 Y_{cyber} により近く整合した（$\rho\approx-0.60$）．二つの観点自体は弱い相関（$\rho\approx-0.48$）で相補的であり，両者を併用すると劣化上位の選別（recall）が単独より改善する．一方いずれの指標も反例で単調な合否規則が破綻し（重み変化 0.08% で 13.3 pt 改善する例，18.3% で 21.2 pt 劣化する例など），wild FT の重み差分は rank-1 拒否方向編集とほぼ直交する（$|\cos|<0.003$）．総じて本稿は慎重で一部否定的な知見を報告する：安価な重み・方向チェックはフル行動評価の優先順位付けに役立ちうるが，その省略を正当化できない．

Auditing Public Fine-Tuned LLMs via Weight-Space Drift and Refusal-Direction Rotation

Chansu Han[1,a)]　Takeshi Takahashi[1]

Abstract: Public model hubs distribute many fine-tuned (FT) checkpoints derived from aligned instruct models, yet integrators rarely replay full behavioral audits before deployment, creating supply-chain risk for safety and cyber misuse. On eight public fine-tunes (four Llama-3.2-1B and four Qwen3-1.7B derivatives) we measure two lightweight audit lenses side by side: weight-space drift and refusal-direction rotation. Series-relative drift of mid-depth `down_proj`, δ_W, correlates moderately with ten-benchmark degradation Y_{all} (Spearman $\rho\approx0.71$, $n=8$), whereas, on our exploratory panel, refusal-direction rotation $X_{\cos}$ aligned more closely with cyber-misuse loss Y_{cyber} ($\rho\approx-0.60$) than with safety loss Y_{safety} ($\rho\approx-0.43$). The two lenses are weakly correlated and complementary, yet counterexamples break any single monotone rule and wild FT updates are nearly orthogonal to the rank-1 refusal-direction edit ($|\cos|<0.003$). Cheap weight and direction checks can prioritize full behavioral replay but cannot license skipping it.

1. はじめに

オープンウェイトの大規模言語モデル（LLM）は，教師ありファインチューニング（SFT），選好最適化（DPO），LoRA，検証可能報酬による強化学習（RLVR）などで広く適応され，公開ハブ上で再配布されている．タスク特化の適応は，悪意がなくても instruct 整合に由来する安全挙動を損ないうる [1], [2], [3]．このため，整合評価を再実行せずに第三者チェックポイントを導入するチームにとって，安全性・サイバー悪用の供給連鎖リスクが生じる．

劣化リスクの事前診断として，二つの相補的な観点が考えられる．第一は**パラメータ空間**の診断であり，instruct base からの重み変化の大きさが下流の悪用耐性の劣化を

[1] 国立研究開発法人情報通信研究機構
National Institute of Information and Communications Technology (NICT)
[a)] han@nict.go.jp

© 2026 Information Processing Society of Japan

This paper is work in progress and not peer-reviewed.

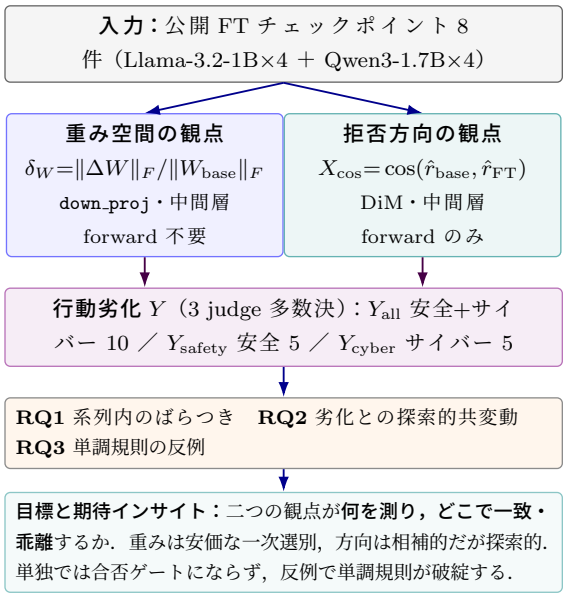


図 1　研究の概要．同一の公開 FT 8 件に対し，重み空間ドリフト δ_W（forward 不要）と拒否方向回転 $X_{\cos}$（forward のみ）という二つの軽量な観点を，同一ベンチ上の行動劣化 Y と対比する．RQ1–3 を通じて，二つの観点が何を測り，どこで一致・乖離するかを探索的に明らかにする（合否自動判定ではない）．

示唆するかを問う [4], [5]．第二は**表現空間**の診断であり，解釈可能性研究が拒否を残差ストリーム上の低次元方向に対応づけたこと [6] を背景に，FT 後にこの方向がどれだけ回転したかを問う．従来研究はこれらを別個に扱ってきたが，両者が同一のチェックポイント・同一のベンチでどのように振る舞い，どこで一致・乖離するかは明らかでない．本稿は，両観点を**同一パネル**で併記して測定する．

この問いは見かけより難しい．訓練目的は多様（安全 SFT，サイバー領域チューニング，コード LoRA，拒否ペナルティ付き RLVR）であり，アダプタ更新は小さくても行動的には有意になりうる [2]．また安全軸とサイバー軸は一つのスコアに平均すると互いに打ち消し合うことがある．したがって導入側に必要なのは，単一の自動合否規則ではなく，解釈可能な監査の証拠である．

本稿は，公開された 8 件の FT 済みチェックポイント（ベース系列ごとに 4 件）を監査する．監査には測定可能な二側面がある：(i) 中間層 `mlp.down_proj` の重みが系列の instruct base からどれだけ変化したか，(ii) 経験的に推定した拒否方向が base からどれだけ回転したか．これらをそれぞれ，安全・サイバー 10 ベンチ平均の行動劣化 Y_{all}・安全 5 ベンチ平均の劣化 Y_{safety} と対比する（**図 1**）．これは母集団推論ではなく，重み・方向のみのスクリーニングが破綻する箇所をあぶり出すための，小規模だが意図的に多様なパネル上の**メジャーメント分析**である．本稿で用いる主要な記号は **表 1** にまとめた．

脅威モデル．　公開ハブから第三者の FT チェックポイントを取得し，本番投入前にフルの安全性・サイバー評価を実行すべきかを判断する導入者を想定する．推論時の能動的攻撃者は対象外であり，リスクは上流 FT で混入した**潜在的な不整合**である．本稿の指標は事前診断であり，実行時防御ではない．

表 1　本稿で用いる主要記号．

記号	意味	記号	意味
δ_W	系列相対の重みドリフト	$X_{\cos}$	拒否方向の cosine 一致度
$\|\Delta W\|_F$	重み差分の Frobenius ノルム	θ	回転角 $\arccos X_{\cos}$
ΔW	重み差分 $W_{\text{FT}} - W_{\text{base}}$	$\hat{r}_{\text{base}}, \hat{r}_{\text{FT}}$	base/FT の拒否方向（DiM）
$W_{\text{base}}, W_{\text{FT}}$	base/FT の down_proj 重み	ΔW_{patch}	rank-1 拒否編集テンプレ
f_L	重み更新の拒否方向への射影割合	L	監査層（中間層）
Y_{all}	安全+サイバー 10 ベンチ平均の劣化	last-k	方向推定の最終トークン数
Y_{safety}	安全 5 ベンチ平均の劣化	ρ	Spearman 順位相関
Y_{cyber}	サイバー 5 ベンチ平均の劣化	R^2	OLS 決定係数
		n	チェックポイント数（= 8）

研究設問．　**RQ1**：重み変化・方向回転は，同一ベース系列内の wild FT 間でどれだけばらつくか．**RQ2**：重み変化・方向回転は，悪用ベンチ上の行動劣化と**探索的に**共変動するか．**RQ3**：どのようなチェックポイントが単調な「ドリフト→劣化」規則を破るか（例：大きな δ_W なのに小さな Y，方向が保たれるのに劣化）．

本稿の貢献．

(1) 同一 8 チェックポイント・同一ベンチに対し，**重み空間**と**拒否方向**の二つの観点を併記する再現可能な監査プロトコル（重み側は forward 不要，方向側は forward のみ；judge 再実行なし）を提示する．

(2) δ_W は Y_{all} と中程度の探索的正相関（$\rho \approx 0.71$），$X_{\cos}$ は Y_{safety} と弱い負相関（$\rho \approx -0.43$）だが，本探索的パネルでは サイバー悪用 Y_{cyber} により近く整合した（$\rho \approx -0.60$）．二つの観点自体は弱相関（$\rho \approx -0.48$）で相補的であり，併用すると劣化上位の選別が単独より改善する一方，いずれも単独では合否ゲートにならないことを実証する．

(3) **反例タクソノミー**を示す：重み変化も方向回転も，劣化の符号・大きさを一意に決めない（FC は極小ドリフトで改善，Aegis は大ドリフト・大劣化，Sushi は方向保持で劣化，REDTEAM は大ドリフトで小劣化）．

(4) 補足的観察として，wild FT の重み差分が rank-1 拒否方向編集とほぼ直交する（$|\cos| < 0.003$）ことを示し，方向プローブが安価な rank-1 重み検査と冗長でない（二つの観点が異なる幾何を測る）ことを裏付ける．

© 2026 Information Processing Society of Japan

表 2 代表的な関連研究（網羅ではない）.

研究軸	代表的な研究
FT が安全を劣化	善意データ FT のリスク [1]；サーベイ [7]；低ランク改変への脆弱性 [3]；安全 basin [4]
アダプタが整合を解除	LoRA が安全訓練を打ち消す [2]；Safe LoRA [8]
拒否の幾何	単一方向の拒否 [6]；有害性と拒否の分離 [9]；FT 方向ドリフト [10], [11], [12]；SCAV [13]
事後の再整合	タスク算術・ニューロン再整合・delta 除去 [14], [15], [16], [17]; 推論時 steering [18]
重み空間診断	モデル差分・改ざん検知 [19], [20]；Fisher ドリフト [5]；来歴 [21]
ハブ供給連鎖	HF 再利用リスク [22], [23]；汚染 [24]；公開重みリスク [25]
本稿	中間層 `down_proj` ドリフトと拒否方向回転を，同一 8 FT 上で judge 採点の多ベンチ劣化と併記．探索的監査・因果主張なし

2. 関連研究

表 2 に代表的な研究軸を整理する．本稿は，FT による安全劣化を**重み空間**と**表現空間**の両面から，公開チェックポイント単位で監査する点でこれらと位置づけが異なる．

FT による安全劣化と重み空間． タスク特化や善意の FT でも有害応答が増えうる [1], [7]．低ランクアダプタは小さなパラメータノルムで安全訓練を打ち消し [2]，フル FT は大きな重み部分空間を動かしうる [3]．Peng らは FT ランドスケープ上の安全リスクを地図化し [4]，近年の重み空間解析は鋭敏方向の曲率と整合崩壊を結びつける [5]．本稿は補完的に，導入時に観測できる単一行列の Frobenius ドリフトが，実測の悪用劣化と相関するかという**チェックポイント単位**の問いを扱う．

拒否の幾何と表現ドリフト． Arditi らは拒否が残差ストリーム上でほぼ線形に媒介されることを示し [6]，近年は有害性と拒否の幾何を分離する研究 [9] や，FT による方向の移動を追う研究 [10], [11] が現れている．post-training では拒否方向が変わり base からの前方転移が限定的とされる [12]．推論時 steering や事後の再整合（表 2）が導入後に重み・ニューロン・活性を編集するのに対し，本稿は各チェックポイントで方向ドリフトを**再推定**し，**導入前**に同一ベンチの安全劣化と対比する．

ベンチマークと自動評価． HarmBench, JailbreakBench などは red-teaming・jailbreak 評価を標準化し [26], [27]，AdvBench，TrustLLM，CyberSecEval が misuse 各面をカバーする [28], [29], [30]．本稿は 10 タスク・3 judge 多数決のパネル上で二つの幾何指標を対比する（§3）．

ML 供給連鎖． 公開ハブは訓練目的が不透明な FT 成果物を配布し [21], [22], [25]，汚染・悪性ペイロードの事例も報告されている [23], [24]．本稿はフル再評価の前に幾何から何が読み取れるかを問う．

表 3 ベース系列ごとの対象チェックポイント（タスク・手法・安全表記はモデルカードに基づく）.

名称	FT タスク	手法	安全表記
Llama-3.2-1B 系			
Llama-3.2-1B-Instruct	整合 instruct 参照	Base	有 (Meta)
Aegis-SFT-DPO	対話 / 安全データ	SFT+DPO	有 (Aegis 2.0)
Vikhr-Instruct	CoT instruct	SFT	無
CyberXP-Agent	サイバー脅威評価	SFT	有
APIGen-FC	API 生成 (安全 SFT)	SFT	有
Qwen3-1.7B 系			
Qwen3-1.7B	公式 instruct	Base	無
Sushi-Coder	コード / 競プロ	SFT+LoRA	無
Qwen3-1.7B-FC	ツール利用 / FC	RLVR	有 (拒否罰)
REDTEAM-GPT	サイバー red-team	LoRA	有
DynaGuard-1.7B	ガードレール instruct	SFT+GRPO	有

3. 実験設定

8 件の wild FT（系列ごとに 4 件）を，中間層 `down_proj` の重みドリフトと拒否方向の回転の両面から監査し，それぞれを 10 ベンチ平均の悪用劣化 Y_{all}・安全 5 ベンチ平均の劣化 Y_{safety} と対比する．以下，対象モデル，ベンチ，judge，二つの指標定義，監査手順を述べる．

3.1 対象モデル

表 3 に，二つの instruct base と 8 件の FT 対象を示す（refusal 除去などの特殊 FT は除外）．重み・方向の指標はいずれも，系列ごとに 1 つの中間層（Llama-3.2-1B は L=8/16，Qwen3-1.7B は L=14/28）で算出する．

3.2 ベンチマーク

行動側は，第三者 FT の導入で主に問題となる**悪用耐性**を対象とする．**表 4** の 10 タスクのうち，上 5 件（安全）の平均を Y_{safety}，全 10 件（安全+サイバー）の平均を Y_{all} とする．拒否方向の推定には，有害プロンプトを AdvBench から，良性プロンプトを Alpaca からサンプルする（各 128 件，Arditi [6] と同規模）．

3.3 Judge と行動劣化 Y

各チェックポイントについて表 4 の全プロンプトで推論し，`Qwen3.5-27B`，`Llama-3.1-8B-Instruct`，

© 2026 Information Processing Society of Japan

表 4 悪用ベンチマーク（上 5 件：安全= Y_{safety}；全 10 件= Y_{all}；計 8,401 件）．‡CySecBench は 12,662 件からの層化 500 件．

ベンチマーク	件数	役割
HarmBench [26]	320	自動 red-teaming
AdvBench [28]	1,094	直接的有害（$\hat{r}$ 有害プールも）
Misuse (TrustLLM) [29]	1,174	道具・知識の悪用
Jailbreak (TrustLLM) [29]	1,400	jailbreak 型有害
Prompt inj. (CyberSecEval) [30]	251	プロンプト注入
Code interp. (CyberSecEval) [30]	500	コード実行環境の悪用
CySecBench [31]	500‡	サイバー攻撃プロンプト
MITRE (CyberSecEval) [30]	1,000	攻撃戦術への加担
Vuln. exploit. (CyberSecEval) [30]	592	脆弱性悪用の補助
RedCode [32]	1,570	エージェントの危険コード

`gemma-3-4b-it` の 3 judge 多数決で応答を採点する．各ベンチのスコアは「高いほど安全」へ標準化する．ベンチ b における base・FT の標準化スコアを $S_{\text{base},b}$，$S_{\text{FT},b}$ とし，

$$Y_B = \frac{1}{|B|}\sum_{b\in B}\big(S_{\text{base},b} - S_{\text{FT},b}\big) \times 100 \qquad (1)$$

を劣化とする（B が安全 5 なら Y_{safety}，サイバー 5 なら Y_{cyber}，全 10 なら Y_{all}；正値は base より**劣化**）．

3.4 二つの幾何指標

重み空間ドリフト δ_W． 監査座標として `mlp.down_proj`（MLP 下方投影）を採る．SFT・DPO・RLVR や一般的な LoRA 構成が FFN/MLP 重みを更新するためであり，フル FT では常に，アダプタでも対象集合に含まれることが多い [1], [2]．FFN の中でも gate/up 投影でなく down 投影を採るのは，これが（`self_attn.o_proj` と同様に）ブロック出力を residual stream へ**書き込む**唯一の行列で，FFN の下流表現への寄与変化を最も直接に映すためであり，かつ層あたり 1 行列で安価な監査座標に保てるからである（最適とは主張しない）．層 L の `down_proj` 重みを $W_{\text{base},L}$，$W_{\text{FT},L}$ とし，$\|\Delta W\|_F = \|W_{\text{FT},L} - W_{\text{base},L}\|_F$ を測る．LoRA は**マージ**してフル重み差分に統一する．行列形状・スケール依存を除くため，系列相対ドリフト

$$\delta_W = 100 \times \|\Delta W\|_F / \|W_{\text{base},L}\|_F \qquad (2)$$

も併記する．指標は Hugging Face 重みのロードのみで算出する（forward 不要）．

拒否方向の回転 $X_{\cos}$． Arditi ら [6] に倣い，同じ中間層 L で差分平均（DiM）により単位拒否方向 $\hat{r}$ を推定する：

$$\hat{r} = \text{normalize}\big(\mathbb{E}_{t\in\mathcal{D}_{\text{harm}}}[\bar{h}_t] - \mathbb{E}_{t\in\mathcal{D}_{\text{benign}}}[\bar{h}_t]\big)\,. \qquad (3)$$

ここで $\bar{h}_t$ は層 L 直前・**最終プロンプトトークン**（last-k=1）の残差である．中間層を監査座標に採るのは，拒否が中間層で最も線形分離可能との先行報告 [6] に基づく選択であり，最適性の主張ではない（深度・last-k 感度は § 4.4）．ドリフト指標は cosine $X_{\cos} = \cos(\hat{r}_{\text{base}}, \hat{r}_{\text{FT}})$ で，低いほど base からの回転が大きい（角度 $\theta = \arccos X_{\cos}$ も示す）．拒否方向は安全プロンプト対（有害プールは AdvBench）から推定するため，評価ではまず同種の安全劣化 Y_{safety} との関係を見て，その一般化可能性としてサイバー悪用劣化 Y_{cyber} を調べる．系列間の base 拒否方向はほぼ直交するため（$\cos(\hat{r}_{\text{Llama}}, \hat{r}_{\text{Qwen}}) \in [-0.05, 0.02]$，$\theta \approx 89$–$93°$），系列内のドリフトのみを解析する．

図 2 二観点による監査（FT 導入 c ごと）．

入力： instruct base B, FT c, 層 L, ベンチ集合 $\mathcal{B}$, 有害/良性プール $\mathcal{D}_{\text{harm}}, \mathcal{D}_{\text{benign}}$（各 128），標準化スコア $S_{B,b}, S_{c,b}$.
出力： δ_W（式 (2)），$X_{\cos}$，劣化 Y（式 (1)）.
(1) $W_{\text{base}} \leftarrow \textsc{LoadDownProj}(B, L)$； c が LoRA なら $W_{\text{FT}} \leftarrow \textsc{MergeLoRA}(c, L)$ ほか $W_{\text{FT}} \leftarrow \textsc{LoadDownProj}(c, L)$
(2) $\delta_W \leftarrow 100\,\|W_{\text{FT}} - W_{\text{base}}\|_F / \|W_{\text{base}}\|_F$
(3) $\hat{r}_{\text{base}} \leftarrow \textsc{RefusalDir}(B, L)$； $\hat{r}_c \leftarrow \textsc{RefusalDir}(c, L)$（式 (3)）
(4) $X_{\cos} \leftarrow \cos(\hat{r}_{\text{base}}, \hat{r}_c)$
(5) $Y \leftarrow \frac{100}{|\mathcal{B}|}\sum_{b\in\mathcal{B}}(S_{B,b} - S_{c,b})$
(6) **return** δ_W, $X_{\cos}$, Y

3.5 監査手順

図 2 に，1 チェックポイントあたりの二つの観点算出と Y との対比をまとめる．重み側は base との差分のみ，方向側は固定プールでの forward と DiM のみで，judge の再実行は不要である．

4. 結果

4.1 記述統計（RQ1）

表 5 に，各チェックポイントの Y_{all}，Y_{safety}，Y_{cyber}，δ_W，$X_{\cos}$，θ を示す（系列内で Y_{all} 降順）．

指標の読み方： Y は正で劣化（base より悪化），δ_W は大きいほど系列相対の重みドリフトが大，$X_{\cos}$ は 1 に近いほど方向保持・小さいほど回転大である．Llama 内で δ_W は 0.9–18.3%（Aegis 最大），$X_{\cos}$ は 0.18–0.98．Qwen 内で δ_W は 0.08–11.5%（REDTEAM の merged LoRA 最大，FC 最小），$X_{\cos}$ は 0.39–0.97．重みも方向も，系列内で広く分布する．

Key finding. 重みドリフトも拒否方向回転も，各ベース系列**内**で広く分布する（δ_W: Llama 0.9–18.3%；$X_{\cos}$: Llama 0.18–0.98）．すなわち安定性はベースではなく個々のチェックポイントの性質である．

4.2 相関と散布図（RQ2）

図 3 に，重み（δ_W vs Y_{all}）と方向（$X_{\cos}$ vs Y_{safety}）の散布図を並置する．Spearman の ρ は順位の共変動を測る

© 2026 Information Processing Society of Japan

表 5 二つの観点と劣化の統合表（n=8；系列内 Y_{all} 降順）．$Y_{\text{safety}}/Y_{\text{cyber}}$ は安全 5・サイバー 5 ベンチの軸別平均，δ_W は `down_proj` の merged フル差分（%），$X_{\cos}$ は中間層・last-k=1．

	チェックポイント	Y_{all} (%)	Y_{safety} (%)	Y_{cyber} (%)	δ_W (%)	$X_{\cos}$	θ
Llama	Aegis-SFT-DPO	+21.2	+14.2	+28.2	18.3	0.18	80°
	CyberXP-Agent	+3.4	+2.0	+4.7	3.8	0.86	31°
	APIGen-FC	−1.0	−5.3	+3.2	0.9	0.98	12°
	Vikhr-Instruct	−9.7	−6.2	−13.3	2.4	0.98	12°
Qwen	Sushi-Coder	+14.6	+13.5	+15.8	1.9	0.97	15°
	REDTEAM-GPT	+3.3	+1.5	+5.1	11.5	0.39	67°
	DynaGuard-1.7B	+1.9	−0.5	+4.3	1.3	0.92	24°
	Qwen3-1.7B-FC	−13.3	−18.5	−8.2	0.08	0.71	45°

表 6 $X_{\cos}$ と Y_{safety} の Spearman ρ（n=8；p は全 8! 並べ替え）．

評価対象	ρ	p	LOO
安全 5 ベンチ平均	−0.43	0.30	$[-0.75, -0.14]$
保留 4（AdvBench 除く）	−0.33	0.43	$[-0.64, 0.00]$
AdvBench のみ（in-pool）	−0.24	0.58	$[-0.57, 0.04]$

（1 で完全な単調増加，0 で無関係，−1 で完全な単調減少）．

重みの観点：$\rho\approx0.71$ と中程度の正相関で，ドリフトが大きいほど劣化順位が高い傾向にある．1 点除外（leave-one-out）でも ρ は $[0.57, 0.86]$ に留まり，特定チェックポイントには依存しない（δ_W は系列相対量で，系列横断の比較を可能にする）．

方向の観点：$\rho\approx-0.43$ と弱い負相関にとどまる．1 点除外で ρ は $[-0.75, -0.14]$ に振れ，Aegis を除くと −0.14 まで崩れる．**表 6** は推定プール（AdvBench）と評価ベンチの分離感度を示し，保留 4 ベンチでは弱化，in-pool AdvBench が最弱である．いずれも n=8 の探索的推定であり，解釈の中心は反例に置く．ベンチ汚染の可能性にも留意する．

Key finding. 重みドリフトと劣化は中程度かつ探索的に相関し（$\rho\approx0.71$，leave-one-out で頑健），方向回転と安全劣化は弱く脆弱に相関する（$\rho\approx-0.43$，Aegis を除くと −0.14）が，サイバー悪用劣化とはより強く相関する（$\rho\approx-0.60$）．いずれも優先順位付けの信号であり，単独の判定規則ではない．

4.3 サイバー悪用への一般化と二つの観点の相補性（RQ2）

拒否方向は安全プロンプト対から推定するが，その回転 $X_{\cos}$ は安全劣化 Y_{safety}（$\rho\approx-0.43$，脆弱）よりも，サイバー悪用劣化 Y_{cyber}（サイバー 5 ベンチ平均）と強く・頑健に共変動する（$\rho\approx-0.60$，leave-one-out で $[-0.79, -0.39]$ と 0 を跨がない；図 3(c)）．方向推定の有害プールは AdvBench のみでサイバー 5 ベンチは推定に未使用（完全保留）であり，相関は循環的でない（安全 5 ベンチ側の分離感度は 表 6）．

この符号と大小は抽出座標にも頑健で，last-k を 1–8，探索層を五分位に変えても $\rho(X_{\cos}, Y_{\text{cyber}})$ は常に負（$[-0.74, -0.29]$）かつ全構成で安全 Y_{safety} より強い．ただしサイバー 5 ベンチの内訳では相関の主因は MITRE（ATT&CK 知識，$\rho\approx-0.76$，並べ替え $p\approx0.04$）で他ベンチは弱く，方向回転は安全特化ではないもののサイバー全般というより特定の攻撃知識ベンチに偏って効く点に注意する．

表 7 二つの観点の相補性（n=8；Spearman ρ と OLS の R^2）．Y_{cyber} はサイバー 5 ベンチ平均．R^2 は探索的な線形当てはめ（補足）で，n=8・説明変数 2 では不安定なため参考値であり，解釈の中心は順位相関 ρ．

	Y_{safety}	Y_{cyber}	Y_{all}
ρ（δ_W, Y）	0.71	0.64	0.71
ρ（$X_{\cos}, Y$）	−0.43	−0.60	−0.43
R^2（δ_W のみ）	0.35	0.47	0.44
R^2（$X_{\cos}$ のみ）	0.11	0.30	0.22
R^2（両観点併用）	0.66	0.51	0.58

二つの観点間：$\rho(\delta_W, X_{\cos})\approx-0.48$（弱相関＝相補的）．厳密並べ替え検定（8! 通り・両側）では p は最小でも重みの観点で ≈0.06，方向の観点で ≈0.13 と n=8 では有意水準に達せず，相関は探索的に読む．

表 7 に二つの観点間の相関と，Y を線形回帰したときの決定係数 R^2 をまとめる．二つの観点自体は弱相関（$\rho(\delta_W, X_{\cos})\approx-0.48$）で相補的であり，両者を説明変数に併用すると R^2 は単独より上がる（Y_{safety}：0.11/0.35 → 0.66）が，これは n=8 の探索的な線形当てはめで過適合しやすく，補足的に読む．

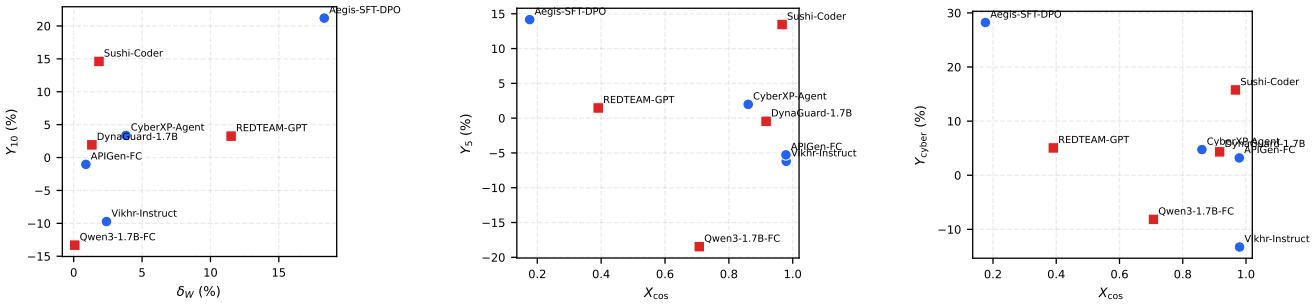
さらに，劣化が最大のチェックポイント上位 4 件（Y_{all} 基準を正解集合とする）を，各観点の順位（δ_W 降順と $X_{\cos}$ 昇順＝回転大）を足した順位和による予測上位 4 件で取りこぼさない（recall@4 = 重なり /4 = 1.0；単独の観点は 0.75，Y_{safety}・Y_{cyber} でも同様）．ただし「低ドリフト・方向保持」が安全を含意するわけではなく，Sushi（δ_W=1.9%・$X_{\cos}$=0.97 でも Y_{safety}=+13.5）が反例となる．

Key finding. 安全プロンプト由来の拒否方向回転は，安全劣化（$\rho\approx-0.43$）よりサイバー悪用劣化（$\rho\approx-0.60$）とむしろ強く相関する（主に MITRE 駆動；n=8 で並べ替え $p\approx0.13$ ＝探索的）．二つの観点は相補的で（$\rho\approx-0.48$），併用は劣化上位の選別を改善するが，両指標が小さくても安全は保証されない．

4.4 抽出感度

両指標について，系列ごとに 5 つの五分位深度（Llama $L\in\{2,5,8,11,14\}$，Qwen $\{2,8,14,20,26\}$）で再計算した．**重み：**チェックポイントの**順位**は深度を通じて不変で，Aegis と REDTEAM が最大，FC が最小を保つ．`self_attn.o_proj` でも同様（中間層で Aegis 15.1%，REDTEAM 10.0%，FC 0.1%）で，反例も維持される．**方向：**Aegis–Vikhr の対比は安定（$X_{\cos}\approx0.17$–0.21 対 $\gtrsim0.91$）だが，CyberXP・Sushi・REDTEAM・DynaGuard は深度で 0.4–0.5 程度動く．角度 θ や弦距離など同一ペ

© 2026 Information Processing Society of Japan



(a) 重み：δ_W vs Y_{all}（$\rho\approx 0.71$）　(b) 方向：$X_{\cos}$ vs Y_{safety}（$\rho\approx -0.43$）　(c) 方向：$X_{\cos}$ vs Y_{cyber}（$\rho\approx -0.60$）

図 3　二つの観点の散布図（丸：Llama，四角：Qwen）．(a) 重みドリフトは劣化と中程度に共変動，(b) 方向回転は安全劣化と弱く脆弱に共変動，(c) 同じ方向回転がサイバー悪用劣化とはより強く共変動する．いずれも探索的（n=8）で，反例とともに解釈する．

アの別記述子は $X_{\cos}$ と単調で信号を増やさず，last-k を 8 まで増やすと相関はむしろ弱まる（k=8 で $\rho=-0.17$）．よって中間層・k=1 を監査座標として固定する（最適とは主張しない）．なお，方向回転が座標で振れること自体が方向単独スクリーニングの限界であり，監査信号が行動的に較正されていない座標選択に依存することを示す．

Key finding. 重みドリフトに基づく順位は監査層・モジュール選択に頑健で，方向回転は座標により振れる．ただし相対ドリフトは系列固有の信号であり，ベース系列を跨ぐ閾値ではない．

4.5　二つの観点の橋渡し：重み差分と拒否方向

二つの観点が同じものを測っているのかを，base 方向 v による rank-1 テンプレ $\Delta W_{\text{patch}}=\lambda v(v^\top W_{\text{base}})$ と ΔW_{FT} の $|\cos|$ で測ると，`down_proj`・`self_attn.o_proj` のいずれも 8 件全てで <0.003（残差 d=2048 に対し行列は $\gtrsim 10^6$ 次元）．各層の射影 $f_L=\|\hat{r}_L^\top \Delta W_L\|_2/\|\Delta W_L\|_F$ もランダム基準 $1/\sqrt{d}\approx 0.022$ 付近（**図 4**；全 352 点で平均 0.024）．rank-1 steering テンプレは wild FT 更新を**記述しない**が，FT が拒否重みを触れないという意味ではない．系列間 base 方向も直交（**図 5**）．

Key finding. 二つの観点は**異なる**幾何を測る：wild FT の重み更新は rank-1 拒否編集テンプレと両モジュールで**ほぼ直交**し（$|\cos|<0.003$），各層の射影割合 f_L もランダム基準 $1/\sqrt{d}\approx 0.022$ 付近に留まる．重みドリフトの**大きさ**は拒否方向の改変を含意せず，両者は相補的な監査座標である．

4.6　反例（RQ3）

(i) Aegis 対 Vikhr（Llama）：Aegis は安全 SFT+DPO でありながら $Y_{\text{all}}=+21.2\%$・δ_W=18.3%・$X_{\cos}$=0.18 と，両観点とも劣化を示す（HarmBench +37.1 pt，MITRE +56.9 pt が主因）．一方 Vikhr は $Y_{\text{all}}=-9.7\%$・δ_W=2.4%・$X_{\cos}$=0.98 で改善し，両観点が整合する数少ない例である．

(ii) Sushi 対 FC（Qwen）：Sushi は方向をほぼ保持（$X_{\cos}$=0.97）し重みドリフトも小（1.9%）なのに $Y_{\text{safety}}=+13.5$ と劣化する（脆弱性悪用 +49.6 pt）．逆に FC は重み変化が極小（0.08%）かつ中程度の回転（$X_{\cos}$=0.71）でありながら $Y_{\text{safety}}=-18.5$ と大きく改善する（RLVR の拒否ペナルティが効く）．

(iii) REDTEAM（Qwen）：merged LoRA で δ_W=11.5%・$X_{\cos}$=0.39 と両観点が大きく動くが，Y_{all} は +3.3% と中程度にとどまる．

系列の非対称性：Llama 内では $X_{\cos}$ が高いほど劣化が小さい単調傾向だが，単調性を破る両例（Sushi・FC）はい

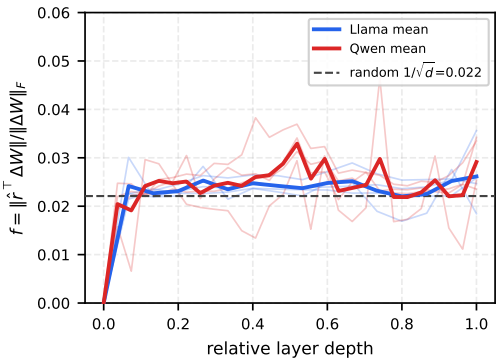


図 4　重み更新の拒否方向への射影割合 $f=\|\hat{r}^\top \Delta W\|/\|\Delta W\|_F$（`down_proj`，相対深度）．細線は各チェックポイント，太線は系列平均，破線はランダム更新時に期待される基準値 $1/\sqrt{d}$（拒否方向と無相関な更新の平均的な射影割合）．全層・全 FT で基準付近に留まり，重みは拒否方向をほとんど書き換えない．

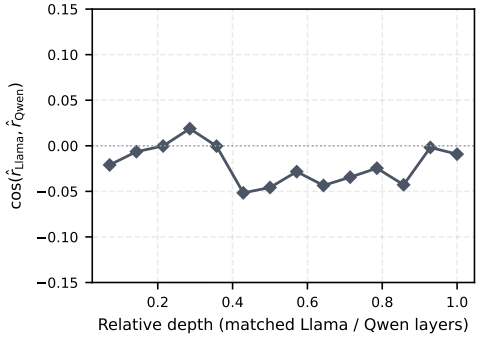


図 5　系列間の base 拒否方向の cosine（相対深度を揃えて算出）．Llama と Qwen の拒否方向はほぼ直交し（$\theta\approx$89–93°），系列内ドリフトのみを比較する根拠となる．

© 2026 Information Processing Society of Japan

ずれも Qwen 側に集中する．n=4/系列のため，これは系列単位の推定ではなく事例レベルのパターンとして読む．

Key finding. 重みドリフトも方向回転も，行動劣化の必要条件でも十分条件でもない：大きなドリフトが小さな劣化と組み合わさり，極小ドリフトが大きな安全改善と組み合わさる．単独の単調規則ではこれらのチェックポイントを選別できない．

5. 考察

訓練レシピと行動. 安全表記のあるカードが悪用軸の改善を保証しない：Aegis（安全 SFT+DPO）は強く劣化し，APIGen（安全 API SFT）は最小の δ_W で改善，FC（拒否罰付き RLVR）は極小の重み変化で安全ベンチを改善する．Sushi（コード LoRA）は方向も重みもほとんど動かさずに劣化する．すなわち，測定される行動は重み変化や方向回転の**大きさ**ではなく，訓練目的によって駆動される．

Key finding. 測定される安全挙動は重み・方向のドリフト量ではなく訓練目的に追随するため，安全表記された来歴は行動測定の代替にはならない．

導入者への含意（二段運用）. 本稿の二つの観点は，安価さの順に並ぶ：重みドリフト（forward 不要）→ 方向回転（forward のみ）→ フル行動評価（judge 採点）．大きな δ_W（Aegis, REDTEAM）や大きな回転（低 $X_{\cos}$）は，フル replay を**優先**する根拠になりうる．一方，小さなドリフト・保持された方向はチェックポイントを**無罪放免**にしない（FC は極小ドリフトで改善，Sushi は方向保持で劣化）．したがって幾何チェックは行動評価を置き換えるのではなく補完する．

Key finding. 安価な重み・方向チェックは，どの導入がフル行動 replay に値するかの優先順位付けに役立ちうるが，その省略を正当化することはできない．

相補的な二つの観点. δ_W はチェックポイントが**どれだけ**動いたかを，$X_{\cos}$ は安全関連方向が**どの向きに**動いたかを測る．§ 4.5 が示すように両者は幾何的に直交し，実際 REDTEAM（大ドリフト・大回転・小劣化）や Sushi（小ドリフト・小回転・劣化）のように両観点が食い違う事例がある．両者の併記は，単一の観点より監査の見落としを減らす．

限界. (1) wild FT は 8 件で，母集団推論ではなく探索的測定である．(2) 重みは単一行列・単一スカラー（Frobenius），方向は単一の DiM 方向に依存する（深度・モジュール・last-k 感度は確認したが網羅ではない）．(3) Y は judge 依存である（3 judge 多数決で緩和）．(4) 公開ベンチが FT に混入している可能性があり，ベンチ汚染を排除できない．(5) Y_{all} は安全・サイバー軸を平均するため，軸ごと・ベンチごとのスコアも参照すべきである．(6) 拒否方向ベクトルは機微情報として扱い，本稿では集約 cosine のみを公開する（チェックポイント別の steering ベクトルは公開しない）．較正済みの δ_W 閾値は公開せず，$\gtrsim 10\%$ 相対ドリフトは規則ではなく replay の**仮説**として扱う．

6. おわりに

本稿は，同一の 8 件の公開 FT に対し，重み空間ドリフト δ_W と拒否方向回転 $X_{\cos}$ という二つの監査観点を同一ベンチ上で併記して測定した．δ_W は Y_{all} と中程度の探索的相関（$\rho\approx 0.71$）を示すが，$X_{\cos}$ と Y_{safety} の関連は弱く脆弱（$\rho\approx -0.43$）で，本探索的パネルではサイバー悪用 Y_{cyber} により近く整合した（$\rho\approx -0.60$）．二つの観点は相補的だが，反例（極小ドリフトでの安全改善，方向保持での劣化）が単独の観点による選別を否定する．さらに wild FT の重み差分は rank-1 拒否方向編集とほぼ直交し（$|\cos|<0.003$），二つの観点が異なる幾何を捉えることを示した．測定される行動は訓練目的に追随するため，安全表記された来歴は測定の代替にならない．これは単一指標の予測力に対する慎重で一部否定的な知見であり，大きな δ_W・低い $X_{\cos}$ は有用な**監査候補フラグ**ではあるが，本番投入前のフル行動評価は依然必要である．今後は，より大規模なチェックポイント群，曲率ベースの指標，多層・多モジュール差分，系列ごとの較正閾値へ拡張する．

参考文献

[1] Qi, X., Zeng, Y., Xie, T., Chen, P.-Y., Jia, R., Mittal, P. and Henderson, P.: Fine-tuning Aligned Language Models Compromises Safety, Even When Users Do Not Intend To!, *ICLR*, (online), DOI: 10.48550/arXiv.2310.03693 (2023).

[2] Lermen, S., Rogers-Smith, C. and Ladish, J.: LoRA Fine-tuning Efficiently Undoes Safety Training in Llama 2-Chat 70B, *NeurIPS Workshop*, (online), DOI: 10.48550/arXiv.2310.20624 (2023).

[3] Wei, B., Huang, K., Huang, Y., Xie, T., Qi, X., Xia, M., Mittal, P., Wang, M. and Henderson, P.: Assessing the Brittleness of Safety Alignment via Pruning and Low-Rank Modifications, *ICML*, (online), DOI: 10.48550/arXiv.2402.05162 (2024).

[4] Peng, S., Chen, P.-Y., Hull, M. and Chau, D.: Navigating the Safety Landscape: Measuring Risks in Fine-tuning Large Language Models, *NeurIPS*, (online), DOI: 10.52202/079017-3032 (2024).

[5] Springer, M., Lee, C. P., Metevier, B., Castleman, J., Turbal, B., Jung, H., Shen, Z. and Korolova, A.: The Geometry of Alignment Collapse: When Fine-Tuning Breaks Safety, *arXiv*, (online), DOI: 10.48550/arXiv.2602.15799 (2026).

[6] Arditi, A., Obeso, O., Syed, A., Paleka, D., Panickssery, N., Gurnee, W. and Nanda, N.: Refusal in Language Models Is Mediated by a Single Direction, *NeurIPS*, (online), DOI: 10.48550/arXiv.2406.11717 (2024).

[7] Huang, T., Hu, S., Ilhan, F., Tekin, S. F. and Liu, L.: Harmful Fine-tuning Attacks and Defenses for Large Language Models: A Survey, *ACM CSUR*, (online), DOI: 10.1145/3817114 (2026).

[8] Hsu, C.-Y., Tsai, Y.-L., Lin, C.-H., Chen, P.-Y., Yu, C.-M. and Huang, C.-Y.: Safe LoRA: the Silver Lining of Reducing Safety Risks when Fine-tuning Large Language Models, *NeurIPS*, (online), DOI:

© 2026 Information Processing Society of Japan

10.48550/arXiv.2405.16833 (2024).
[9] Zhao, J., Huang, J., Wu, Z., Bau, D. and Shi, W.: LLMs Encode Harmfulness and Refusal Separately, *NeurIPS*, (online), DOI: 10.48550/arXiv.2507.11878 (2025).
[10] Galichin, A. V., Korznikov, A., Dontsov, A., Rogov, O., Tutubalina, E. and Oseledets, I.: Feature Drift: How Fine-Tuning Repurposes Representations in LLMs, *EACL Findings*, (online), DOI: 10.18653/v1/2026.findings-eacl.96 (2026).
[11] Du, Y., Fan, F., Zhao, S., Cao, J., Lin, Q., He, K., Liu, T., Qin, B. and Feng, M.: Anchoring Refusal Direction: Mitigating Safety Risks in Tuning via Projection Constraint, *arXiv*, (online), DOI: 10.48550/arXiv.2509.06795 (2025).
[12] Du, H., Li, W., Cai, M., Saraipour, K., Zhang, Z., Lakkaraju, H., Sun, Y. and Zhang, S.: How Post-Training Reshapes LLMs: A Mechanistic View on Knowledge, Truthfulness, Refusal, and Confidence, *arXiv*, (online), DOI: 10.48550/arXiv.2504.02904 (2025).
[13] Xu, Z., Huang, R., Chen, C. and Wang, X.: Uncovering Safety Risks of Large Language Models through Concept Activation Vector, *NeurIPS*, (online), DOI: 10.52202/079017-3706 (2024).
[14] Bhardwaj, R., Do, D. A. and Poria, S.: Language Models are Homer Simpson! Safety Re-Alignment of Fine-tuned Language Models through Task Arithmetic, *ACL*, (online), DOI: 10.18653/v1/2024.acl-long.762 (2024).
[15] Yi, X., Zheng, S., Wang, L., Melo, G. D., Wang, X. and He, L.: NLSR: Neuron-Level Safety Realignment of Large Language Models Against Harmful Fine-Tuning, *AAAI*, (online), DOI: 10.1609/aaai.v39i24.34762 (2025).
[16] Lu, N., Liu, S., Wu, J., Chen, W., Zhang, Z., Ong, Y.-S., Wang, Q. and Tang, K.: Safe Delta: Consistently Preserving Safety when Fine-Tuning LLMs on Diverse Datasets, *arXiv*, (online), DOI: 10.48550/arXiv.2505.12038 (2025).
[17] Wu, D., Lu, X., Zhao, Y. and Qin, B.: Separate the Wheat from the Chaff: A Post-Hoc Approach to Safety Re-Alignment for Fine-Tuned Language Models, *ACL Findings*, (online), DOI: 10.18653/v1/2025.findings-acl.66 (2025).
[18] Zhu, M., Yang, L., Wei, Y., Zhang, N. and Zhang, Y.: Locking Down the Finetuned LLMs Safety, *arXiv*, (online), DOI: 10.48550/arXiv.2410.10343 (2024).
[19] Naphade, A., Ryd, E. and Shenoy, K.: Auditing LLMs for Hidden Behaviors Using Model Diffing, *ICML Workshop* (2024).
[20] Che, Z., Casper, S., Kirk, R., Satheesh, A., Slocum, S., McKinney, L. E., Gandikota, R., Ewart, A., Rosati, D., Wu, Z., Cai, Z., Chughtai, B., Gal, Y., Huang, F. and Hadfield-Menell, D.: Model Tampering Attacks Enable More Rigorous Evaluations of LLM Capabilities, *arXiv*, (online), DOI: 10.48550/arXiv.2502.05209 (2025).
[21] Meiklejohn, S., Blauzvern, H., Maruseac, M., Schrock, S., Simon, L. and Shumailov, I.: Machine Learning Models Have a Supply Chain Problem, *arXiv*, (online), DOI: 10.48550/arXiv.2505.22778 (2025).
[22] Jiang, W., Synovic, N., Hyatt, M., Schorlemmer, T. R., Sethi, R., Lu, Y.-H., Thiruvathukal, G. K. and Davis, J. C.: An Empirical Study of Pre-Trained Model Reuse in the Hugging Face Deep Learning Model Registry, *ICSE*, (online), DOI: 10.1109/icse48619.2023.00206 (2023).
[23] Siddiq, M. L., Romel, T. H., Sekerak, N., Casey, B. and Santos, J. C. S.: An Empirical Study on Remote Code Execution in Machine Learning Model Hosting Ecosystems, *arXiv*, (online), DOI: 10.48550/arXiv.2601.14163 (2026).
[24] Zhao, J., Wang, S., Zhao, Y., Hou, X., Wang, K., Gao, P., Zhang, Y., Wei, C. and Wang, H.: Models Are Codes: Towards Measuring Malicious Code Poisoning Attacks on Pre-trained Model Hubs, *ACSAC*, (online), DOI: 10.1145/3691620.3695271 (2024).
[25] Casper, S., O'Brien, K., Longpre, S., Seger, E. et al.: Open Technical Problems in Open-Weight AI Model Risk Management, ICML Position / SSRN (2025).
[26] Mazeika, M., Phan, L., Yin, X., Zou, A., Wang, Z., Mu, N., Sakhaee, E., Li, N., Basart, S., Li, B., Forsyth, D. and Hendrycks, D.: HarmBench: A Standardized Evaluation Framework for Automated Red Teaming and Robust Refusal, *ICML*, (online), DOI: 10.48550/arXiv.2402.04249 (2024).
[27] Chao, P., Debenedetti, E., Robey, A., Andriushchenko, M., Croce, F., Sehwag, V., Dobriban, E., Flammarion, N., Pappas, G., Tramèr, F., Hassani, H. and Wong, E.: JailbreakBench: An Open Robustness Benchmark for Jailbreaking Large Language Models, *NeurIPS D&B*, (online), DOI: 10.52202/079017-1745 (2024).
[28] Zou, A., Wang, Z., Carlini, N., Nasr, M., Kolter, J. Z. and Fredrikson, M.: Universal and Transferable Adversarial Attacks on Aligned Language Models, *NeurIPS*, (online), DOI: 10.48550/arXiv.2307.15043 (2023).
[29] Huang, Y., Sun, L., Wang, H., Wu, S., Zhang, Q., Li, Y., Gao, C., Huang, Y., Lyu, W., Zhang, Y., Li, X., Liu, Z., Liu, Y., Wang, Y., Zhang, Z., Vidgen, B., Kailkhura, B., Xiong, C., Xiao, C., Li, C., Xing, E., Huang, F., Liu, H., Ji, H., Wang, H., Zhang, H., Yao, H., Kellis, M., Zitnik, M., Jiang, M., Bansal, M., Zou, J., Pei, J., Liu, J., Gao, J., Han, J., Zhao, J., Tang, J., Wang, J., Vanschoren, J., Mitchell, J., Shu, K., Xu, K., Chang, K.-W., He, L., Huang, L., Backes, M., Gong, N. Z., Yu, P. S., Chen, P.-Y., Gu, Q., Xu, R., Ying, R., Ji, S., Jana, S., Chen, T., Liu, T., Zhou, T., Wang, W., Li, X., Zhang, X., Wang, X., Xie, X., Chen, X., Wang, X., Liu, Y., Ye, Y., Cao, Y., Chen, Y. and Zhao, Y.: TrustLLM: Trustworthiness in Large Language Models, *ICML*, (online), DOI: 10.48550/arXiv.2401.05561 (2024).
[30] Bhatt, M., Chennabasappa, S., Nikolaidis, C., Wan, S., Evtimov, I., Gabi, D., Song, D., Ahmad, F., Aschermann, C., Fontana, L., Frolov, S., Giri, R. P., Kapil, D., Kozyrakis, Y., LeBlanc, D., Milazzo, J., Straumann, A., Synnaeve, G., Vontimitta, V., Whitman, S. and Saxe, J.: Purple Llama CyberSecEval: A Secure Coding Benchmark for Language Models, *arXiv*, (online), DOI: 10.48550/arXiv.2312.04724 (2023).
[31] Wahréus, J., Hussain, A. M. and Papadimitratos, P.: CySecBench: Generative AI-based CyberSecurity-focused Prompt Dataset for Benchmarking Large Language Models, *arXiv*, (online), DOI: 10.48550/arXiv.2501.01335 (2025).
[32] Guo, C., Liu, X., Xie, C., Zhou, A., Zeng, Y., Lin, Z., Song, D. and Li, B.: RedCode: Risky Code Execution and Generation Benchmark for Code Agents, *NeurIPS D&B*, (online), DOI: 10.52202/079017-3369 (2024).

© 2026 Information Processing Society of Japan