ファインチューニング親子関係の推定による LLM 系統木構造の再構成手法

小川 聡太[1,2,a)]　山辺 翔二郎[1,2]　西山 大輝[1]　佐久間 淳[1,2]

概要：大規模言語モデル（LLM）のファインチューニング（FT）による派生モデルが大量に公開されているが，その派生元は自己申告に依存し，正しさを検証する手段がない．系統の誤りは実害を伴う．親モデルの脆弱性は FT を経て子へ継承され，ベースモデルが既知であることを前提とする防御手法は，正しい系統を欠くと機能しない．しかし，出力のみを観測する既存手法はペアの派生判定か無向のクラスタリングに留まり，有向木を復元する手法は重みを要する white-box に限られる．検証の対象には重みが非公開のモデルが含まれ，有向木を得る手段が存在しない．そこで本稿は，重みは見えず対数尤度のみが得られる gray-box アクセスを想定する．教師強制下での対数尤度の偏差を出自の痕跡として定式化し，二つの子が共有する偏差が共通の親の偏差と一致する度合いを測る指標，兄弟共有偏差を提案する．この量は三つのモデルの組に対して非対称であり，値の大きい組から貪欲に親を採択することで，内部ノードを含む有向木を親子関係と兄弟関係を区別しながら復元する．5 本のモデル木からなるベンチマークで，重みを参照しない対称距離のベースラインを上回る復元性能と，本手法が破綻する条件を示す．

キーワード：モデル出自，大規模言語モデル，系統復元，ファインチューニング，教師強制

Reconstructing LLM Lineage Trees via Fine-Tuning Parent-Child Inference

Sota Ogawa[1,2,a)]　Shojiro Yamabe[1,2]　Daiki Nishiyama[1]　Jun Sakuma[1,2]

Abstract: Fine-tuned derivatives of large language models (LLMs) are published in large numbers, yet their base models rest on self-reports that nobody verifies. Incorrect lineage carries concrete costs: a parent's vulnerabilities are inherited by its children through fine-tuning, and defenses that presuppose a known base model fail without the correct lineage. However, existing methods that observe only outputs are limited to pairwise derivation testing or undirected clustering, while methods that recover a directed tree require white-box access to weights; for models whose weights are not published, no means of obtaining a directed tree exists. We therefore assume gray-box access, in which weights are hidden but log-likelihoods are available. We formalize the deviation of teacher-forced log-likelihood as a trace of provenance, and propose the sibling-shared deviation, a measure of how closely the deviation shared by two children agrees with that of their common parent. This quantity is asymmetric over a triple of models; by greedily selecting parents from the triples with the largest values, we recover a directed tree including internal nodes, distinguishing parent-child from sibling relations. On a benchmark of five model trees, we show that the method outperforms symmetric-distance baselines that do not refer to weights, and identify the conditions under which it breaks down.

Keywords: model provenance, large language model, lineage recovery, fine-tuning, teacher forcing

1. はじめに

大規模言語モデル（Large Language Model, LLM）を一

[1] 東京科学大学 情報理工学院 情報工学系
Institute of Science Tokyo
[2] RIKEN AIP
[a)] ogawa.s.718d@m.isct.ac.jp

© 2026 Information Processing Society of Japan

This paper is work in progress and not peer-reviewed.

から学習させるには膨大な計算資源と学習データを要するため，公開された事前学習済みモデルをファインチューニング（Fine-Tuning, FT）して特定のタスクへ適応させる手法が広く用いられている．Hugging Face をはじめとするモデル共有プラットフォームの普及により，モデルの再利用・派生を前提とした開発の流れは加速している．

この広がりは同時に，サプライチェーンリスクという新たなセキュリティリスクを生む．あるモデルを FT して別のモデルを得たとき，両者の間には親子関係が成立する．この派生関係を辺として辿ると，事前学習済みモデルを根とする木構造が形成される．モデル共有プラットフォームには，モデルカードを通じて各モデルの派生元（ベースモデル）を申告する仕組みが用意されているが，この申告は任意かつ自己申告であり，その正しさを検証する仕組みは存在しない．

系統が利用者にとって重要なのは，親モデルの脆弱性が FT を経ても子モデルへ継承されるためである．実際，事前学習済みモデル上で最適化した敵対的プロンプトはその FT 派生モデルへ高い成功率で転移し [1]，脆弱性の影響は当該モデル単体に留まらず子孫モデル全体に波及しうる．さらに，派生モデルに対する防御手法そのものが系統情報に依存する．Zhong らのバックドア検出手法は，FT 前後の重み差分を用いることで学習データにアクセスせず検出を行うが，正しいベースモデルが既知であることを前提とし，これを欠くと検出率がランダム同然にまで劣化する [2].

ところが利用者が参照できるのは自己申告のみであり，その正しさを独立に確かめる手段がない．申告と真の系統との乖離は，記載漏れや誤記，第三者による再アップロードといった形で，提供者の悪意を仮定せずとも生じうる．すなわち問題は，モデルの内部を参照できない利用者が，自己申告に依存せずに親子関係を表現する木をどこまで復元できるかに帰着する．

ここで必要とされるのは，派生関係の有無ではなくその向きである．FT は親のパラメータを初期値として子を得る一方向の操作であるから，脆弱性の伝播も非対称であり，親の脆弱性は子へ波及する一方その逆はない．無向の派生関係だけではリスクの所在が定まらない．同じ非対称性は著作権上の議論にも現れ，どちらが先行しどちらを複製したかも辺の向きなしには判定できない．

しかし既存手法には，この要請に照らして二つの限界がある（2 章）．第一に，モデルの出力のみを観測する手法 [3], [4] は，内部ノードを含む有向木を出力しない．これらが用いる出力の一致率は入れ替えても値が変わらない対称な量であり，辺の向きを決められない．さらに対ごとの量では，三つのモデルが一列に連なる系統と，一つの親から二つの子が分かれる系統とを区別できず，兄弟関係の判定には三つのモデルにまたがる情報を要する．第二に，有向木を出力する MoTHer [5] は重み分布から辺の向きを決定するため white-box アクセスを前提とするが，検証対象には重みが公開されず商用の FT API 経由でのみ利用可能なモデルも含まれる．

そこで本研究では，モデルの重みを参照せず，与えた入出力対に対してモデルが返す対数尤度のみを信号として有向木を復元する手法を提案する．FT は学習に用いたデータの対数尤度を高め，子は親のパラメータを初期値とするため，親が高めた分を引き継いだ上に自身の FT による上昇を重ねる．どのデータに高い対数尤度を与えるかは根からの FT の履歴を反映し，親の履歴が子の履歴に含まれるという非対称性が辺の向きを与える．

本論文の貢献は以下の 3 点である．

- 教師強制下での出力の偏差を出自の痕跡として定式化し，兄弟が共有する偏差を測る指標，兄弟共有偏差を提案した．
- 兄弟共有偏差にもとづく貪欲な親採択により，モデルの重みを参照せず，内部ノードを含む有向木を復元するアルゴリズムを提案した．
- 独自の木構造ベンチマークを構築し，提案手法が対称距離のベースラインを上回ることを示すとともに，本手法が破綻する条件を実験的に同定して適用範囲を明示した．

2. 関連研究

モデルの出自に関する既存研究は，何を出力するかによって整理できる．すなわち，モデル対が派生関係にあるか否かの判定に留まるもの，モデル群を無向にクラスタリングするもの，そして有向木を復元するものである．以下この順に述べ，本稿の位置づけを明らかにする．

ペアの派生判定． Model Provenance Testing (MPT) [3] は，モデル g が候補モデル f の派生であるかを検定する手法である．f と g の次トークン予測が一致する割合を統計量とし，派生関係にない対照モデル群を帰無基準とした検定によって判定する．用いる情報は生成されたトークンのみで対数尤度も重みも要さず，この点で MPT は本稿より弱いアクセス仮定の下で動作する．一方その出力はモデル対に対する二値の判定であり，木構造や兄弟関係は復元しない．候補集合から真の親を選ぶ拡張も示されているが，各ノードについて独立に判定するため木全体としての整合性は保証されない．

出力にもとづく系統推定． PhyloLM [4] は，生成出力の一致度から定義した距離行列に近隣結合法を適用して LLM 群の系統樹を推定する．重みを要さず商用 API 経由のモデルにも適用できる点で本稿と動機を共有するが，出力するのは無根かつ無向の樹形図であり，さらに推定の際には内部ノードにあたるモデルを母集団から除外している．著者らは，共通祖先が母集団に含まれる場合にはすべてのモ

© 2026 Information Processing Society of Japan

デルが葉に配置されてしまうため，得られる樹形図はクラスタリングとして解釈するほかないと明記している．本稿が対象とするのは，この除外された設定である．ただし本稿も根は既知としており（3.4 節），根の同定で優位を主張はしない．差は，PhyloLM が葉以外のすべてを母集団から除くのに対し，本稿は根以外の内部ノードを母集団に含めたまま親として同定する点にある．

重みにもとづく有向木復元． MoTHer [5] は，本稿と同じく有向モデル木の復元を課題として定式化した研究である．辺の配置には重み距離を，辺の向きには重み分布の尖度を用い，Chu-Liu-Edmonds 法で有向最小全域木を構成する．向きの決定まで含めて有向木を出力する点で本稿に最も近いが，配置と向きのいずれも重みを参照するため white-box アクセスが不可欠であり，著者ら自身も API 経由でのみ利用できるモデルには適用できないと述べている．

以上より，重みを参照できる場合には有向木の復元手段が存在するが（MoTHer），重みを参照しない場合はペアの判定（MPT）か，内部ノードを除外した無向のクラスタリング（PhyloLM）に留まる．本稿が埋めるのはこの空白である．

3. 準備

本節では以降で用いる記法と問題設定を定義する．3.1 節から 3.3 節でモデルの派生関係を形式化し，3.4 節で検証者が置かれた状況と利用できる情報を，3.5 節で検証の目標と評価指標を定める．

3.1 大規模言語モデル

語彙集合を V とし，V 上の有限長トークン列全体を V^* と書く．本稿で扱う LLM は，パラメータ θ を持つ自己回帰型の条件付き言語モデルであり，入力系列 $x \in V^*$ と出力系列 $y = (y_1, \ldots, y_{|y|}) \in V^*$ に対して $p_\theta(y \mid x) = \prod_{i=1}^{|y|} p_\theta(y_i \mid x, y_{<i})$ と分解される．ここで $y_{<i} = (y_1, \ldots, y_{i-1})$ である．この各因子は，y をモデル自身に生成させるのではなく外部から与えた上で評価できる．時刻 i の文脈としてモデルの予測ではなく所与の $y_{<i}$ を与えるこの評価方式を教師強制 (teacher forcing) と呼ぶ．教師強制の下では，復号戦略や乱数に依存しない決定的な量として $\log p_\theta(y_i \mid x, y_{<i})$ が得られる．本稿が用いる信号はこれのみである．以降，モデルを m と書き，そのパラメータを θ_m，確率分布を $p_m := p_{\theta_m}$ と略記する．

3.2 ファインチューニング（FT）

タスク τ に対するデータセットを，入力・出力対の有限集合 $D_\tau = \{(x_j, y_j)\}_j \subset V^* \times V^*$ とする．FT とは，既存のパラメータ θ を初期値として D_τ 上の負の対数尤度 $-\sum_{(x,y)\in D_\tau} \log p_\theta(y \mid x)$ を最小化し，新たなパラメータ θ' を得る操作であり，これを $\theta' = \mathrm{FT}(\theta, D_\tau, c)$ と書く．c は最適化手法・学習率・エポック数などの学習設定であり，本稿では全ノードで統一する（5.1 節）．

FT は θ から θ' への一方向の操作であり，両者の間に親子関係を定める．本稿が派生関係として扱うのは，この単一の親からの教師あり FT のみである．モデルマージは親を複数持つため木構造の枠組みに収まらず，量子化・蒸留・継続事前学習・選好最適化 (RLHF, DPO) は異なる目的関数を用いる．これらは本稿の対象外とする．

3.3 モデル木

あるモデルを親として FT を繰り返すと，派生関係は木構造をなす．これをモデル木 $T = (M, E)$ と呼ぶ．M はモデルの集合，$E \subset M \times M$ は親から子への FT を表す有向辺の集合である．根 $r \in M$ は FT を受けていない事前学習済みモデルであり，根以外の各ノード $m \in M \setminus \{r\}$ はただ一つの親 $\mathrm{pa}(m)$ を持つ．各ノード $m \neq r$ は，親のパラメータを初期値として単一のタスク τ_m で FT された結果，すなわち $\theta_m = \mathrm{FT}(\theta_{\mathrm{pa}(m)}, D_{\tau_m}, c)$ である．根から m に至る経路上の m 以外のノードを m の祖先，m と親を共有するノードを m の兄弟と呼ぶ．

なお本稿では，M が T のノードを漏れなく含むこと，すなわち観測できない中間世代のモデルが存在しないことを前提とする．中間ノードが非公開である場合への拡張は本稿の範囲外である．

3.4 問題設定

1 章で述べた通り，モデル利用者はモデルカードの系統申告を独立に検証する手段を持たない．本節では，この検証を行う主体を**検証者**と呼び，検証者が置かれた状況，利用できるアクセス，および前提知識を順に定める．

想定状況． 検証者としては，公開モデルを自らのシステムへ採用しようとする利用者を主に想定する．検証者は，Hugging Face のようなモデル共有プラットフォーム上で公開されたモデル群 M を観測する．M の各モデルは推論可能な形で提供されているが，相互の派生関係 E は申告されていないか，申告されていてもその正しさが保証されていない．

利用できるアクセス． 検証者は任意の $m \in M$ に対し，任意の $(x, y) \in V^* \times V^*$ を与えてトークンごとの対数尤度 $\mathcal{O}_m(x, y) = (\log p_m(y_i \mid x, y_{<i}))_{i=1}^{|y|}$ を得るオラクルアクセスを持つ．これは，対数尤度を返す推論基盤（vLLM, Text Generation Inference 等）や logprob を返す推論 API を想定したもので，生成結果のみを返す完全な black-box より強く，パラメータ θ_m を要求する white-box より弱いことから，本稿ではこれを gray-box アクセスと呼ぶ．

利用できない情報． 検証者は重み θ_m，勾配，学習ログ，中間層の表現にはアクセスできず，対象モデルを追加学習することも，提供者の内部情報を得ることもできない．すな

© 2026 Information Processing Society of Japan

わち本稿は提供者の協力を一切仮定せず，重みを公開しない提供者のモデルも同一の枠組みで検証できる．

前提知識．検証者は根 r を既知とする．これは，公開された基盤モデルを根とする派生モデル群を対象とする状況に対応する．さらに本手法は，各ノードが FT に用いたタスク τ_m とその学習事例 D_{τ_m} を入手できることを前提とする．モデルカードには一般に，派生元とあわせて学習に用いたデータセットが申告されており，その多くは公開されている．本稿の検証は，この申告された学習データを入力として，同じモデルカードが申告する派生元の整合性を確かめるという形をとる．これらの前提の妥当性と緩和は 6 章で論じる．

3.5 検証の目標と評価指標

目標．ノード集合 M，根 r，およびオラクル $\{\mathcal{O}_m\}_{m\in M}$ が与えられたとき，検証者は各非根ノード $m \in M \setminus \{r\}$ について親の推定 $\widehat{\mathrm{pa}}(m) \in M \setminus \{m\}$ を出力する．これにより定まる辺集合 $\hat{E} = \{(\widehat{\mathrm{pa}}(m), m)\}_{m\neq r}$ を真の辺集合 E に一致させることが検証者の目標である．この定式化は，二つのモデルが派生関係にあるか否かを個別に判定するペアワイズな定式化と異なり，(i) 辺の向きの決定と (ii) 内部ノードを含む木全体の整合的な復元とを同時に要求する．

評価指標．復元性能は親一致率

$$\mathrm{Acc}(\hat{E}) = \frac{1}{|M|-1}\left|\{\, m \in M \setminus \{r\} : \widehat{\mathrm{pa}}(m) = \mathrm{pa}(m) \,\}\right| \tag{1}$$

で測る．各ノードの親候補は自身を除く $|M|-1$ 個であるから，親を無作為に選んだ場合の期待値，すなわち偶然水準は $1/(|M|-1)$ である．本稿で用いる 7 ノードの木では ≈ 0.167，9 ノードの木では ≈ 0.125 となる．

4. 提案手法

本章では，gray-box アクセスのみから有向木を復元する手法を提案する．中核となるのは，三つのノードの組が真に（兄弟，兄弟，親）の関係にあるほど大きな値をとる指標，兄弟共有偏差 ρ_{sib} である．指標の単位を二ノードの対ではなく三ノードの組とするのは，1 章で述べた辺の向きの要請に応えるためである．三つ組では親候補と子候補の役割が交換不能であり，組の並べ替えによって値が変わる．この非対称性が辺の向きを与える．

この判定を可能にするのは，FT の履歴が出力に残す痕跡である．各非根ノード m は根 r からの経路上で施された FT タスク列への適合を出力に残している．そこで本手法は，各 FT タスクの事例に対してモデル m が根 r よりどれだけ強く適合したかを事例ごとに並べたベクトルを m の痕跡とし，これを偏差ベクトル $\boldsymbol{\delta}_{r\to m}$ と呼ぶ．兄弟は共通の親を経由するため履歴の前半を共有する．したがって二つの子の偏差ベクトルがともに大きい成分は，共通の親自身の偏差ベクトルと一致するはずである．ρ_{sib} はこの一致の度合いを測る．以下，4.1 節で $\boldsymbol{\delta}_{r\to m}$ を，4.2 節で ρ_{sib} を定義し，4.3 節で復元アルゴリズムを与える．

4.1 定式化

モデル m が入力 x に対して目標出力 y を生成する際の系列平均対数尤度を

$$S_m(x,y) = \frac{1}{|y|}\sum_{i=1}^{|y|} \log p_m(y_i \mid x, y_{<i}) \tag{2}$$

と定義する．タスク τ に属する (x,y) に対する $S_m(x,y)$ は，m が τ にどれだけ適合しているかを測る．m が根 r から派生する過程で τ によって FT された場合，$S_m(x,y)$ は $S_r(x,y)$ より大きくなることが期待される．

そこで，事例集合 $D = \{(x_i,y_i)\}_{i=1}^{N}$ に対し，基準モデル f に対するモデル m の**偏差ベクトル**を

$$\boldsymbol{\delta}_{f\to m}(D) = \big(S_m(x_i,y_i) - S_f(x_i,y_i)\big)_{i=1}^{|D|} \in \mathbb{R}^{|D|} \tag{3}$$

で定義する．第 i 成分は D の i 件目に対して m が f よりどれだけ適合したかを表す．D に τ_m の学習データを含めれば，m が f から τ_m で FT された子である場合に成分は正に大きくなる．以降，基準モデルは常に根 r とし，$\boldsymbol{\delta}_{r\to m}$ を各ノード m の出自の痕跡として扱う．3.4 節の通り r は既知であり，これは常に計算できる．

4.2 兄弟共有偏差 ρ_{sib}

本節では，兄弟が共有する偏差を測る指標，**兄弟共有偏差** ρ_{sib} を定義する．ρ_{sib} は，二つのノードを兄弟候補，第三のノードを親候補とみなしたとき，その三つ組が真に（兄弟，兄弟，親）の関係にあるほど大きな値をとる指標である．

偏差ベクトル $\boldsymbol{\delta}_{r\to m}$ はノード m の FT 履歴を映すが，それ自体は辺の向きを定めない．親 f とその子 g は τ_f による適合を共有するため $\boldsymbol{\delta}$ が似通い，共通の親を持つ兄弟 g_1, g_2 もまた親経由で似通うためである．

そこで，兄弟候補の対 $\{g_1,g_2\}$ の**共有偏差ベクトル**を，両者の偏差ベクトルの成分ごとの最小値 $\boldsymbol{\delta}^{\cap}_{g_1,g_2} = \min(\boldsymbol{\delta}_{r\to g_1}, \boldsymbol{\delta}_{r\to g_2}) \in \mathbb{R}^{|D|}$ で定義する．第 i 成分が大きな正の値をとるのは g_1, g_2 の**双方**が事例 i で根より強く適合した場合に限られる．すなわち min は両者に共通する適合のみを残し，一方の子だけが持つ固有の適合を抑制する論理積として働く．

真の兄弟が共有する適合は共通の親 f から継承した f の FT 適合にほかならず，したがって $\boldsymbol{\delta}^{\cap}_{g_1,g_2}$ は $\boldsymbol{\delta}_{r\to f}$ と正の相関を持つと期待される．この整合の度合いを Pearson 相関係数 corr で測ったものを兄弟共有偏差と呼び，

$$\rho_{\mathrm{sib}}(\{g_1,g_2\}, f) = \mathrm{corr}\big(\boldsymbol{\delta}^{\cap}_{g_1,g_2},\, \boldsymbol{\delta}_{r\to f}\big) \tag{4}$$

© 2026 Information Processing Society of Japan

Algorithm 1 ρ_{sib} による greedy 木構造復元

Require: M, r, $\{\mathcal{O}_m\}_{m\in M}$, $D=\bigcup_{m\neq r} D_{\tau_m}$
Ensure: $\hat{E}$
1: 各 $m\in M\setminus\{r\}$ について $\boldsymbol{\delta}_{r\to m}$ を式 (3) で算出
2: $U\leftarrow M\setminus\{r\}$, $\mathcal{T}\leftarrow\{(g_1,g_2,f)\,:\,\{g_1,g_2\}\subseteq U,\ f\in U\setminus\{g_1,g_2\}\}$
3: 各 $(g_1,g_2,f)\in\mathcal{T}$ の $\rho_{\mathrm{sib}}(\{g_1,g_2\},f)$ を式 (4) で算出し降順にソート
4: **for all** $(g_1,g_2,f)\in\mathcal{T}$（降順） **do**
5: **if** $g_1\in U\wedge g_2\in U$ **then**
6: $\widehat{\mathrm{pa}}(g_1)\leftarrow f$; $\widehat{\mathrm{pa}}(g_2)\leftarrow f$; $U\leftarrow U\setminus\{g_1,g_2\}$
7: **end if**
8: **end for**
9: 残余 $m\in U$ について $\widehat{\mathrm{pa}}(m)\leftarrow r$
10: **return** $\hat{E}=\{\,(\widehat{\mathrm{pa}}(m),m)\,:\,m\in M\setminus\{r\}\,\}$

で定義する．ρ_{sib} が高い三つ組ほど g_1,g_2 が f を共通の親とする兄弟である可能性が高い．逆に g_1,g_2 が兄弟でない，あるいは f が親でない場合，共有偏差は f の偏差と整合せず ρ_{sib} は低くなる．

ρ_{sib} は三ノードの組にまたがる集合レベルの量であり，二ノード間の対称距離では表現できない．1 章で述べた鎖状の系統と星状の系統の曖昧性は，兄弟関係の有無を判定できないことに由来しており，ρ_{sib} はまさにこの判定を可能にする．

4.3 木構造復元アルゴリズム

以上の ρ_{sib} を辺重みとし，値の大きい三つ組から貪欲に親を逐次採択することで有向木を復元する（Algorithm 1）．まず全ての兄弟・親候補の三つ組 (g_1,g_2,f)（$\{g_1,g_2\}\subseteq M\setminus\{r\}$，$f\in M\setminus\{r,g_1,g_2\}$）について ρ_{sib} を算出し，降順に走査する．両子がまだ親未割当である三つ組に出会うたびに g_1,g_2 の親を f に確定し，以降その二ノードはスキップする．最後に親が未確定のまま残ったノードは，根 r 直下の子として割り当てる．

5. 評価

本章では，まずモデル木・プローブ集合・ベースライン・評価指標からなる実験設定を述べ（5.1 節），次に偏差ベクトル $\boldsymbol{\delta}_{r\to m}$ が出自の痕跡として機能することを確認したうえで（5.2 節），ρ_{sib} による木構造復元の性能を評価する（5.3 節）．

5.1 実験設定

モデル木．評価には，独自に構築した 5 本のモデル木を用いる（構造は図 1，一覧は付録 A.1 の表 A·1）．基準となるのは Llama-3.2-3B [6] を根とする 7 ノード・深さ 2 の木であり，これを HET-3B と呼ぶ．残る 4 本は HET-3B から一要素のみを変えた木であり，根とするモデルの規模（HET-8B），そのファミリ（HET-QWEN），木の深さ（DEEP，深さ 3・9 ノード），子ノードに割り当てるタスクの多様性（HOMO）が復元性能に与える影響を切り分ける．子ノードに互いに異種のタスクを割り当てた木を**異種構成**，すべてのノードを要約タスクで FT した木を**同種構成**と呼び，木の名称の HET と HOMO はこれに対応する．ただし深さと多様性の 2 軸は木の変更がタスク割当の変更を伴うため，完全な一要素統制ではない．

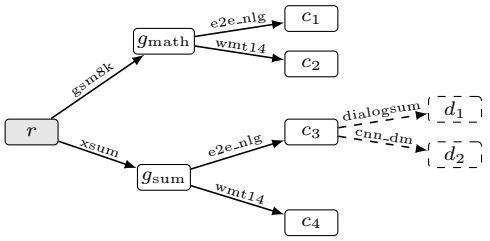


図 1 HET-3B（実線部分）と DEEP（破線を含む全体）の構造とタスク割当．辺のラベルは子ノードが FT に用いたタスク τ_m を表す．破線ノード d_1,d_2 は DEEP でのみ追加され，実線部分のみが HET-3B である．HET-8B と HET-QWEN は実線部分と同型で，根 r のみが異なる．5 本すべての構造は付録 A.1 の図 A·1 に示す．wmt14 は wmt14_de_en，cnn_dm は cnn_dailymail の略記である．

Fig. 1 Structures and task assignments of the model trees used for evaluation. Edge labels denote the fine-tuning task of the child node.

本稿の設定が自明でないのは，FT に用いたタスクが同一で親のみが異なるノード対が存在するためである．図 1 の c_1 と c_3 はいずれも data-to-text 生成の E2E データセット [7]（以下 e2e_nlg）で FT されており，自身の FT タスクへの適合だけでは区別できず，親から継承した適合を見分けることが必要になる．同種構成の HOMO はこの対が深さ 2 の全ノードに広がった木であり，提案手法が最も不利になる構成として意図的に含めた．

全ノードの FT は LoRA [8] で行い，ハイパーパラメータは全タスク・全木で統一した．乱数シードを変えて各構成につき 5 本の木を構築し，以降の指標はすべて 5 シードの平均と標準誤差で報告する．

プローブ集合．偏差 $\boldsymbol{\delta}$ の算出に用いる事例集合を**プローブ集合**と呼ぶ．各ノードについて経路上のタスクと経路外のタスクの双方で偏差を測れるよう，5 本の木に現れる全 7 タスク（gsm8k [9], xsum [10], e2e_nlg [7], wmt14_de_en [11], dialogsum [12], cnn_dailymail [13], samsum [14]）の学習データから各 100 件を抽出した計 700 件で構成し，全ての木・全てのノードで共通に用いる．タスク t の事例集合を D_t とし，測定には $\bar{\delta}_{r\to m}(t)=|D_t|^{-1}\sum_{(x,y)\in D_t}(S_m(x,y)-S_r(x,y))$ を用いる．

ベースライン．提案手法を，同一の木・同一の入力・目標出力系列の下で二種の最小全域木（MST）ベースラインと比較する．第一に，パラメータ更新量 $\Delta\theta$ の L_2 距離を辺重みとする white-box MST である（重み空間距離に依拠する既存手法 [5] に対応する）．第二に，出力の差分率（Top-1

© 2026 Information Processing Society of Japan

予測の不一致率）を辺重みとする MST である．この重みは生成されたトークンのみから計算でき，本手法が要する対数尤度を必要としないため，本手法より弱い black-box アクセスの下で成立する．gray-box アクセスの下で本稿と同じ有向木復元に取り組んだ先行研究は存在しない．そこで，モデル対が派生関係にあるかを検定する MPT [3] のペアワイズ一致度を辺重みに転用し，Kruskal 法で MST を構築するベースラインを本稿で構成した．MPT 自体はペア判定を行う手法であって木構造は出力せず，また一致の判定に応答の先頭トークンのみを用いる．本ベースラインはこれを全出力位置の一致率へ拡張したものであり，MPT の性能をそのまま表すものではない．いずれの MST も対称距離に基づくため辺の向きを出力できない．

評価指標．ベースラインとの比較には**無向辺再現率**，すなわち真の辺集合を無向グラフとみなしたときの再現率を用いる．MST が辺の向きを出力しないため，親一致率では比較が成立しないためである．提案手法についても推定辺を無向化して測る．ただし提案手法では 5 本の木のいずれにおいても無向辺再現率と親一致率 Acc（式 (1)）が一致する．推定の誤りが真の辺の反転ではなく，別のノードへの誤接続として現れるためであり，したがって提案手法について示す値は有向木としての復元性能でもある．

5.2 偏差ベクトルの構造の検証

提案手法が成り立つためには，偏差ベクトル $\boldsymbol{\delta}_{r\to m}$ が次の 2 つの性質を満たしていなければならない．第一に，ノード m 自身が FT に用いたタスク τ_m で偏差が最も大きくなること（**対角優位**），第二に，根から m に至る経路上のタスクで偏差が正，経路上にないタスクで負となること（**符号一致**）である．経路上で施された FT は当該タスクへの適合を上げ，経路外のタスクにはそれがないため，偏差にはこの構造が期待される．

5.1 節のプローブ集合を用いて，この 2 つの性質を確認する．対角優位は 1 つのノードの行の中での大小関係，符号一致は各セルの値と 0 との大小関係であり，比較の単位が異なるため同一の図では同時に読み取れない．そこで図 2(a) に基準木 HET-3B の偏差行列を，図 2(b) に 5 本の木の全セルを役割ごとに分けた分布を示し，(a) で対角優位を，(b) で符号一致と木の間の比較をそれぞれ確認する．

図の読み方を，図 1 の c_1 を例に述べる．c_1 は $r \to g_{\mathrm{math}} \to c_1$ という経路を経ており，経路上の FT タスクは gsm8k と e2e_nlg である．したがって図 2(a) の c_1 行では，自身の FT タスクである e2e_nlg の列（実線枠）が行内で最大となり，祖先 g_{math} の FT タスクである gsm8k の列（破線枠）が正，経路上にない残る 4 列が負となることが期待される．実際 c_1 行は e2e_nlg が $+0.95$，gsm8k が $+0.83$ であり，残る 4 列はいずれも負であって，期待した構造をとる．図 2(b) は，この 3 種類のセルを 5 本の木すべてについて集め，木ごとに役割別の分布として並べ直したものである．「自身」の点が最も右，「祖先」がその次，「経路外」が 0 の左に集まることが，上記の構造が成立している状態にあたる．

2 つの性質はいずれも高い割合で成立する．以下の値は 5 シード平均の偏差行列上で数えたものである．対角優位は全 32 の非根ノードのうち 27 で成立する（0.844）．符号一致は全 $32 \times 7 = 224$ セルのうち 194 で成立し（0.866），祖先の FT タスクのセルに限れば 24 セル中 22 で成立する（0.917）．偏差ベクトルは各ノードの FT 履歴を符号の構造として保持しており，出自の痕跡として機能する．

破れの内訳は付録 A.2 に示す．要点は 2 つある．第一に，タスク間で偏差の尺度が揃っておらず，偏差が突出して大きいタスクを経路上に持つノードでは対角優位が破れる．第二に，深い木では遠い祖先の適合が後続の FT によって失われ，祖先のセルでも偏差が負に落ちる．実際，符号一致が破れた祖先セル 2 件はいずれも DEEP の孫段 d_1, d_2 における xsum であり，図 2(b) で DEEP の「祖先」の群だけが 0 より左へ 2 点外れていることとして現れている．後者は本手法が扱える木の深さに対する制約であり，今後の課題である．

5.3 木構造復元性能の評価

復元性能を表 1 に示す．提案手法は全木で 0.856 ± 0.019 であり，Top-1 一致度の MST（0.706 ± 0.021）を上回る．ただし両者が要求するアクセスは異なる．本手法は対数尤度を要する gray-box を前提とするのに対し，Top-1 一致度の MST は生成されたトークンのみで動作する black-box である．パラメータ距離 MST は全木で 1.000 を示すが，これは全モデルの重みが入手できる場合の値であり，3.4 節で定めた gray-box 条件の下では利用できない．

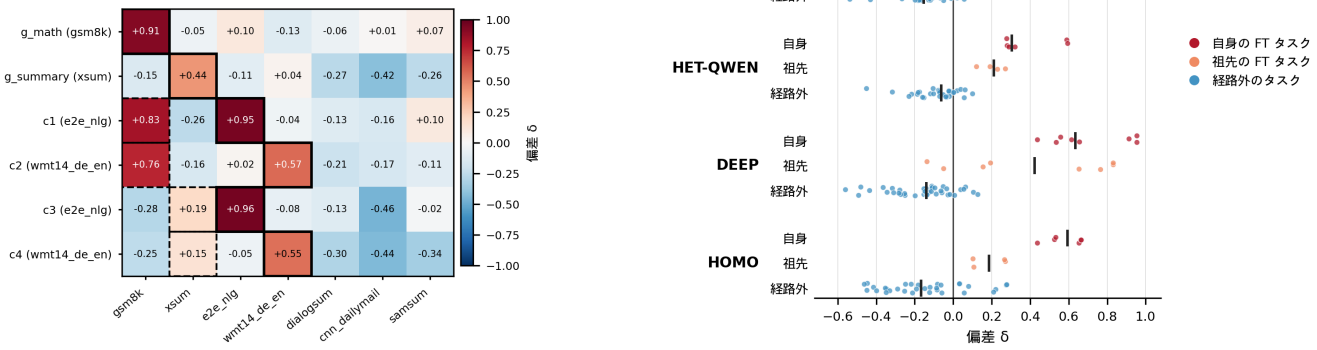
要因ごとに見ると，根とするモデルの規模と木の深さは復元性能に影響せず，HET-3B・HET-8B・DEEP はいずれも 1.000 である．5.2 節の通り深い木では遠い祖先の偏差が失われるが，親の同定に効くのは直近の祖先の偏差であるため，深さの増加は現れない．モデルファミリを変えた HET-QWEN は 0.900 とわずかに下がる．この木では偏差の絶対値が他の 4 本より小さいが，低下は限定的であり，偏差の符号は FT の効果が小さい場合にも保たれる．

一方，タスクの多様性を失った HOMO では 0.333 まで落ちる．提案手法の値は親一致率と一致するため，これは 7 ノードの木における偶然水準 0.167（3.5 節）の 2 倍にあたる．完全な偶然ではないが実用に足る水準ではなく，本手法の適用範囲は子ノードのタスクが互いに異種であることに制約される．崩壊の原因は 6.3 節で論じる．

6. 限界と考察

本章では本手法の適用範囲を論じる．まず 3.4 節で置い

© 2026 Information Processing Society of Japan



(a) HET-3B の偏差行列　　(b) 役割ごとの偏差の分布（5 本の木）

図 2　偏差ベクトルの構造．(a) 基準木 HET-3B の平均偏差 $\bar{\delta}_{r\to m}(t)$（5 シード平均）．赤は $\bar{\delta} > 0$，青は $\bar{\delta} < 0$ を表す．実線枠は自身の FT タスク，破線枠は祖先の FT タスクで，実線枠が行内最大（対角優位），破線枠が正（符号一致）となることが期待される．(b) 5 木の全 224 セルを役割別（自身 32・祖先 24・経路外 168）に分けた分布．1 点が 1 セル，縦棒は中央値，縦線 $\bar{\delta} = 0$ が符号一致の判定線である．5 木の偏差行列は付録 A.3 に示す．

Fig. 2　Structure of the deviation vectors. (a) Node-by-task deviation matrix $\bar{\boldsymbol{\delta}}_{r\to m}$ for the reference tree HET-3B. (b) Distribution of all 224 cells of the five trees, grouped by the role of each cell (own FT task, ancestor FT task, off-path task).

表 1　ベースラインとの比較（無向辺再現率，5 seed 平均．全木列は 5 木の全 32 辺を母数とした値で，± は標準誤差）

Table 1　Comparison with baselines (undirected edge recall).

手法	アクセス	方向	HET-3B	HET-8B	HET-QWEN	DEEP	HOMO	全木
MST（パラメータ距離 L_2） [5]	white-box	—	1.000	1.000	1.000	1.000	1.000	**1.000 ± 0.000**
MST（MPT [3] 一致度・本稿で構成）	black-box	—	0.800	0.800	0.667	0.750	0.500	0.706 ± 0.021
ρ_{sib} greedy（提案）	gray-box	✓	1.000	1.000	0.900	1.000	0.333	**0.856 ± 0.019**

た 2 つの前提，すなわち根 r が既知であることと，各ノードの FT に用いた学習事例が入手できることを順に扱う（6.1 節，6.2 節）．続いて，5.3 節で同種構成の HOMO において復元性能が偶然水準近くまで落ちた原因を論じ，本手法が要求する木の性質を明らかにする（6.3 節）．

6.1　根が既知であるという前提

3.4 節では検証者が根 r を既知とした．本手法が実際に要求するのは，M の中から根を選び出すことではなく，r に対するオラクル $\mathcal{O}_r$ が利用できることである．派生モデルはアーキテクチャ・語彙集合・パラメータ形状を親から引き継ぐため，系統がどの基盤モデルに由来するかは候補を数個に絞れる程度には判別でき，かつその基盤モデルは公開されている．すなわちこの前提は，根を同定する問題ではなく候補を絞って入手する問題に帰着する．根が未知である場合への拡張は今後の課題であり，各候補を r として木を復元し，採択された三つ組の ρ_{sib} などを尺度に最も整合的な木を与えた候補を採る方針が考えられるが，その検証は本稿では行っていない．

6.2　学習事例が入手できるという前提

本手法は，各ノードが FT に用いた学習事例そのものが入手できなければ機能しない．偏差が捉えているのはタスクへの適合ではなく，学習事例そのものへの適合だからである．

これを示すため，プローブ集合を 2 通りに差し替えて木を復元した（詳細は付録 A.4）．学習事例と同一分布の非学習事例に替えると親一致率は 0.856 から 0.488 へ，同種のタスクだが分布の異なるデータセットに替えると 0.125 へ下がる．後者は検証者がタスクの種別だけを知り学習事例

© 2026 Information Processing Society of Japan

を入手できない状況に対応し，値は 3.5 節の偶然水準と同水準である．

段階的に下がる原因は，偏差行列のどの成分が先に失われるかにある．非学習事例では自身の FT タスクへの適合は残る（自己セル正率 0.781）が，祖先のタスクの符号一致は 0.917 から 0.458 へ半減する．親の同定に必要なのは兄弟が親から継承した適合であるから，先に失われるこの成分が親一致率の低下に直結する．分布の異なるデータセットでは自己セル正率も 0.250 まで下がり，符号の構造そのものが失われる．

以上より，本手法はモデルカードが申告する学習データが公開されている場合には成立するが，申告が不完全な場合や学習データが非公開である場合には適用できない．

6.3 タスクの多様性への依存

同種構成の HOMO で親一致率が 0.333 に落ちる原因は，プローブ集合のうち HOMO が学習していないタスクの列にある．これらの列の偏差はどのノードでもほぼ同じ値をとるため，全てのノード対に共通の相関を生み，兄弟と親の間の相関を覆い隠す．本手法の適用範囲は，子ノードのタスクが互いに異種であることに制約される．プローブ集合の絞り込みによる対処とその副作用は付録 A.5 で論じる．

7. 結論

本稿では，モデルの重みを参照せず，教師強制下の対数尤度のみから LLM の派生関係を有向木として復元する手法を提案した．対数尤度の偏差を出自の痕跡として定式化し，二つの子が共有する偏差が共通の親の偏差と一致する度合いを測る指標として兄弟共有偏差 ρ_{sib} を導入して，値の大きい三つ組から貪欲に親を採択することで，内部ノードを含む木全体を親子関係と兄弟関係を区別しながら組み上げた．

5 本のモデル木からなるベンチマークによる評価では，子ノードのタスクが互いに異種である構成において，深さ 3 の木を含めて親一致率 1.000 で復元でき，全木で 0.856 ± 0.019 と重みを参照しない対称距離のベースライン（0.706 ± 0.021）を上回った．同時に，子ノードのタスクが同種である場合，および FT に用いた学習事例が入手できない場合には復元性能が偶然水準まで低下することを示した．後者は，偏差が捉えているものがタスクの能力ではなく学習事例そのものへの適合であることを意味する．学習事例を用いずに特定のタスクの FT にのみ反応するプローブを最適化によって構成することが，今後の主要な課題である．

謝辞 本研究は JST Nexus JPMJNX25C2, JST K-program JPMJKP24C3, JST CREST JPMJCR21D3, JPMJCR23M4, JSPS Grants-in-Aid for Scientific Research 23H00483, JSPS 二国間 120251002 の支援を受けたものである．

参考文献

[1] Yixin Tan, Zhe Yu, and Jun Sakuma. One leak away: How pretrained model exposure amplifies jailbreak risks in finetuned llms, 2025.

[2] Ziqian Zhong and Aditi Raghunathan. Watch the weights: Unsupervised monitoring and control of fine-tuned LLMs. In *NeurIPS 2025 Workshop: Reliable ML from Unreliable Data*, 2025.

[3] Ivica Nikolic, Teodora Baluta, and Prateek Saxena. Model provenance testing for large language models. In *The Thirty-ninth Annual Conference on Neural Information Processing Systems*, 2025.

[4] Nicolas Yax, Pierre-Yves Oudeyer, and Stefano Palminteri. Phylolm: Inferring the phylogeny of large language models and predicting their performances in benchmarks. In *International Conference on Learning Representations (ICLR)*, 2025.

[5] Eliahu Horwitz, Asaf Shul, and Yedid Hoshen. Unsupervised model tree heritage recovery. In *International Conference on Learning Representations*, Vol. 2025, pp. 47900–47918, 2025.

[6] Aaron Grattafiori, Abhimanyu Dubey, Abhinav Jauhri, et al. The llama 3 herd of models, 2024. arXiv preprint arXiv:2407.21783.

[7] Jekaterina Novikova, Ondřej Dušek, and Verena Rieser. The e2e dataset: New challenges for end-to-end generation. In *Proceedings of the 18th Annual SIGdial Meeting on Discourse and Dialogue*, pp. 201–206, 2017.

[8] Edward J. Hu, Yelong Shen, Phillip Wallis, et al. LoRA: Low-rank adaptation of large language models. In *International Conference on Learning Representations (ICLR)*, 2022.

[9] Karl Cobbe, Vineet Kosaraju, Mohammad Bavarian, et al. Training verifiers to solve math word problems, 2021. arXiv preprint arXiv:2110.14168.

[10] Shashi Narayan, Shay B. Cohen, and Mirella Lapata. Don't give me the details, just the summary! topic-aware convolutional neural networks for extreme summarization. In *Proceedings of the 2018 Conference on Empirical Methods in Natural Language Processing (EMNLP)*, pp. 1797–1807, 2018.

[11] Ondřej Bojar, Christian Buck, Christian Federmann, et al. Findings of the 2014 workshop on statistical machine translation. In *Proceedings of the Ninth Workshop on Statistical Machine Translation (WMT)*, pp. 12–58, 2014.

[12] Yulong Chen, Yang Liu, Liang Chen, et al. DialogSum: A real-life scenario dialogue summarization dataset. In *Findings of the Association for Computational Linguistics: ACL-IJCNLP 2021*, pp. 5062–5074, 2021.

[13] Karl Moritz Hermann, Tomáš Kočiský, Edward Grefenstette, et al. Teaching machines to read and comprehend. In *Advances in Neural Information Processing Systems (NIPS)*, 2015.

[14] Bogdan Gliwa, Iwona Mochol, Maciej Biesek, et al. SAMSum corpus: A human-annotated dialogue dataset for abstractive summarization. In *Proceedings of the 2nd Workshop on New Frontiers in Summarization*, pp. 70–79, 2019.

[15] An Yang, Baosong Yang, Beichen Zhang, et al. Qwen2.5 technical report, 2024. arXiv preprint arXiv:2412.15115.

[16] Longhui Yu, Weisen Jiang, Han Shi, et al. MetaMath: Bootstrap your own mathematical questions for large language models. In *International Conference on Learning Representations (ICLR)*, 2024.

[17] Anastassia Kornilova and Vladimir Eidelman. BillSum: A corpus for automatic summarization of US legislation. In *Proceedings of the 2nd Workshop on New Frontiers in Summarization*, 2019.

[18] Biao Zhang, Philip Williams, Ivan Titov, et al. Improving massively multilingual neural machine translation and zero-shot translation. In *Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics (ACL)*, 2020.

[19] Juraj Juraska, Kevin Bowden, and Marilyn Walker. ViGGO: A video game corpus for data-to-text generation in open-domain conversation. In *Proceedings of the 12th International Conference on Natural Language Generation (INLG)*, pp. 164–172, 2019.

© 2026 Information Processing Society of Japan

付　　録

A.1　実験設定の詳細

A.1.1　モデル木

評価に用いた 5 本のモデル木の一覧を表 A·1 に示す．いずれも根・深さ 1 の 2 ノード・深さ 2 の 4 ノードからなる 7 ノードの木を基本形とし，DEEP のみ深さ 3 の 2 ノードを加えた 9 ノードである．各段では，その段の 2 ノードそれぞれを親として，表中の 2 タスクの子を派生させる．したがって根以外の全ての内部ノードは子をちょうど 2 つ持つ．5 本すべての構造とタスク割当を図 A·1 に示す．

A.1.2　使用したモデルとデータセット

根に用いた事前学習済みモデルは Llama-3.2-3B，Llama-3.1-8B [6]，Qwen2.5-3B [15] の 3 種であり，いずれも指示チューニングを施していない base モデルである．FT および偏差の測定に用いたデータセットを表 A·2 に示す．FT には各データセットの学習用分割を用い，プローブ集合（5.1 節）は同じ学習用分割からタスクあたり 100 件を抽出して構成する．

A.1.3　学習設定

全ノードの FT は LoRA [8] で行い，ハイパーパラメータは全タスク・全木で統一した（学習率 2×10^{-4}，5 エポック，$r=8$，$\alpha=16$，対象は q_proj と v_proj）．統一の妥当性は事前にタスクごとの探索と比較して確認しており，タスク個別に選んだ設定との精度差は最大 0.025（gsm8k），他のタスクでは 0.02 以下であった．乱数シードを 0 から 4 まで変えた 5 通りの木を各構成について構築し，以降の指標は全てこの 5 シードの平均と標準誤差で報告する．

A.2　偏差行列の破れの内訳

5.2 節で述べた対角優位と符号一致の破れには 3 つの原因がある．

第一に，対角優位が破れる 5 件はいずれも gsm8k に起因する．gsm8k の偏差は他のタスクに比べて突出して大きく（0.7–0.9），gsm8k を経路上に持つノードでは自身の FT タスクの列を上回る．タスク間で偏差の尺度が揃っていないことによる破れである．

第二に，符号一致が破れる 30 件のうち 28 件は経路外のセルであり，そのうち 24 件は e2e_nlg と wmt14_de_en に集中する．これは図 2(b) で経路外の群が 0 の右へはみ出す点にあたる．FT が特定のタスクに限らない出力の整形能力を底上げし，経路外のタスクでも偏差がわずかに正となるためと考えられる．

第三に，残る 2 件は祖先の FT タスクのセルで偏差が負に落ちたものであり，いずれも DEEP の孫段 d_1, d_2 における xsum である．xsum は d_1, d_2 から 3 世代前の FT タスクであり，その適合は後続の 2 回の FT によって失われている．祖先の FT による適合が保持されるという前提は経路が長くなると成立しない．

A.3　全モデル木の偏差行列

図 2(a) には基準木 HET-3B のみを示した．5 本すべてのモデル木の偏差行列を図 A·2 に示す．図の読み方は図 2(a) と同一である．

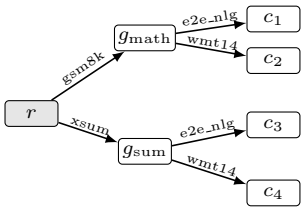
A.4　プローブ条件を変えた場合の詳細

6.2 節で述べたプローブ条件の内訳を示す．train は各ノードが FT に用いた学習事例，test は各タスクの学習事例と同一分布から取った非学習事例，similar は同種のタスクだが分布の異なるデータセットから取った事例（数学は metamathqa [16]，要約は billsum [17]，翻訳は opus-100 [18]，NLG は viggo [19]）である．木ごとの親一致率と偏差行列の性質を表 A·3 に，test および similar における偏差行列を図 A·3 と図 A·4 に示す．図の読み方は図 A·2 と同一である．

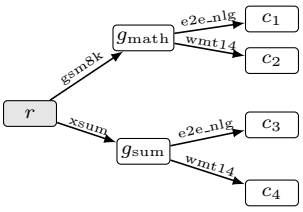
A.5　プローブ集合の絞り込みによる HOMO への対処

6.3 節で述べた通り，HOMO の崩壊はどのノードも学習していないタスクの列が生む一様な背景相関に起因する．そこで，プローブ集合を HOMO が実際に用いた 4 タスクに限ると，親一致率は 0.333 から 1.000 に回復する．ただし同じ絞り込みは HET-QWEN では 0.900 から 0.500 へ悪化させる．偏差の信号が弱い木では事例数の削減がそのまま推定の不安定化につながるためであり，木の性質に依存しないプローブ集合の選択規則の設計は未解決の課題である．本稿の主結果（表 1）には，この絞り込みを適用していない値を用いる．

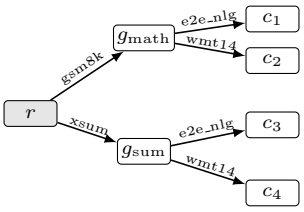
© 2026 Information Processing Society of Japan



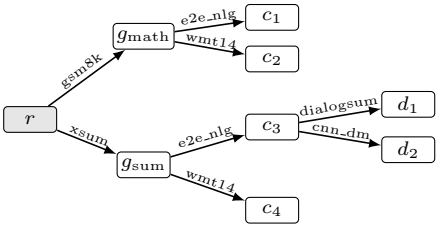
(a) HET-3B（r = Llama-3.2-3B）



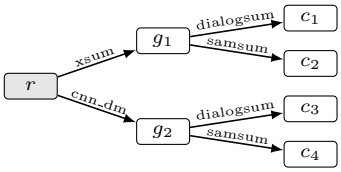
(b) HET-8B（r = Llama-3.1-8B）



(c) HET-QWEN（r = Qwen2.5-3B）



(d) DEEP（r = Llama-3.2-3B，深さ 3・9 ノード）



(e) HOMO（r = Llama-3.2-3B，全ノード要約）

図 A·1 評価に用いた 5 本のモデル木の構造とタスク割当．網掛けのノードが根 r，辺のラベルは子ノードが FT に用いたタスク τ_m を表す．(a)–(c) は構造もタスク割当も同一で，根に置く事前学習済みモデルのみが異なる．(d) は (a) の c_3 から深さ 3 の 2 ノード d_1, d_2 を派生させた木，(e) は全ノードを要約タスクのみで FT した木である．wmt14 は wmt14_de_en，cnn_dm は cnn_dailymail の略記である．

Fig. A·1 Structures and task assignments of the five model trees used for evaluation. Shaded nodes are the roots; edge labels denote the fine-tuning task of the child node.

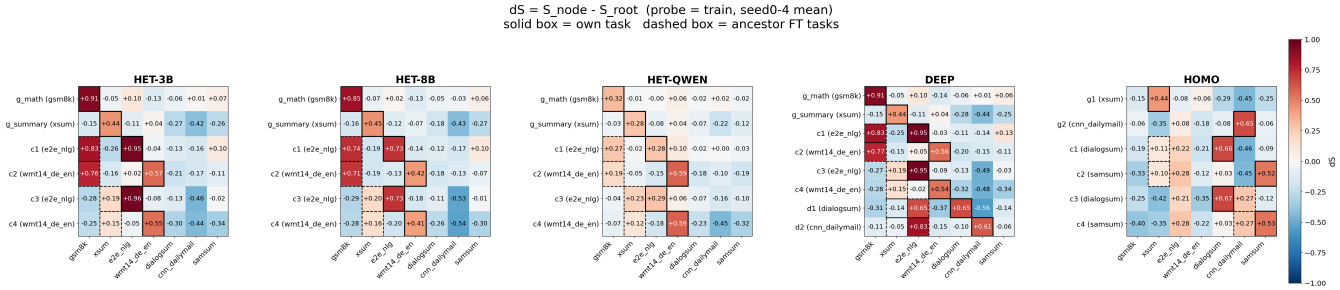


図 A·2 5 本のモデル木におけるノード × タスク偏差行列（プローブ集合は train）．

Fig. A·2 Node-by-task deviation matrices for the five model trees (train probe set).

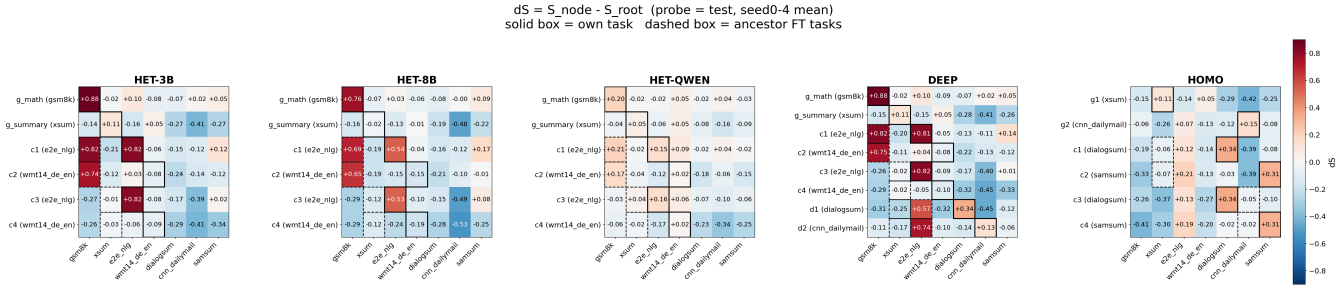


図 A·3 プローブ集合を test（同一分布の非学習事例）とした場合の偏差行列．自身の FT タスクに対する正の偏差は多くのノードで残るが，祖先のタスクに対する偏差は正の値を保てていない．

Fig. A·3 Deviation matrices with the test probe set.

© 2026 Information Processing Society of Japan

表 A·1　評価に用いた 5 本のモデル木．「深さ k」列は，深さ k の各ノードが FT に用いたタスクを表す．深さ 1・2 では，一つ上の段の 2 ノードそれぞれから列挙した 2 タスクの子を派生させる．DEEP の深さ 3 の 2 ノードは，深さ 2 の e2e_nlg の子 c_3 の子である．

Table A·1　The five model trees used for evaluation.

木	根モデル	ノード数	深さ	深さ 1	深さ 2	深さ 3	基準木からの変更
HET-3B	Llama-3.2-3B [6]	7	2	gsm8k, xsum	e2e_nlg, wmt14_de_en	—	—（基準木）
HET-8B	Llama-3.1-8B [6]	7	2	gsm8k, xsum	e2e_nlg, wmt14_de_en	—	根モデルの規模
HET-QWEN	Qwen2.5-3B [15]	7	2	gsm8k, xsum	e2e_nlg, wmt14_de_en	—	根モデルのファミリ
DEEP	Llama-3.2-3B [6]	9	3	gsm8k, xsum	e2e_nlg, wmt14_de_en	dialogsum, cnn_dailymail	木の深さ
HOMO	Llama-3.2-3B [6]	7	2	xsum, cnn_dailymail	dialogsum, samsum	—	子タスクの多様性

表 A·2　使用したデータセット．上段 7 件は FT とプローブ集合 train/test に，下段 4 件は similar プローブ（A.4 節）にのみ用いる．

Table A·2　Datasets used in the experiments.

データセット	タスク種別	用途
gsm8k [9]	数学の文章題	FT / probe
xsum [10]	要約	FT / probe
e2e_nlg [7]	data-to-text 生成	FT / probe
wmt14_de_en [11]	翻訳（独 → 英）	FT / probe
dialogsum [12]	対話要約	FT / probe
cnn_dailymail [13]	要約	FT / probe
samsum [14]	対話要約	FT / probe
metamathqa [16]	数学の文章題	similar のみ
billsum [17]	要約	similar のみ
opus-100 [18]	翻訳	similar のみ
viggo [19]	data-to-text 生成	similar のみ

表 A·3　プローブ集合を変えた場合の復元性能と偏差行列の性質．親一致率は 5 シードの平均，全木列は 5 木の全 32 辺を母数とした値であり，右の 2 列は 5 シード平均の偏差行列上で全木を平均した値である．

Table A·3　Recovery performance and properties of the deviation matrices under three probe conditions.

	親一致率						偏差行列の性質	
プローブ集合	HET-3B	HET-8B	HET-QWEN	DEEP	HOMO	全木	自己セル正率	祖先セル符号一致率
train	1.000	1.000	0.900	1.000	0.333	0.856	1.000	0.917
test	0.600	0.700	0.167	0.600	0.333	0.488	0.781	0.458
similar	0.033	0.133	0.100	0.100	0.267	0.125	0.250	0.042

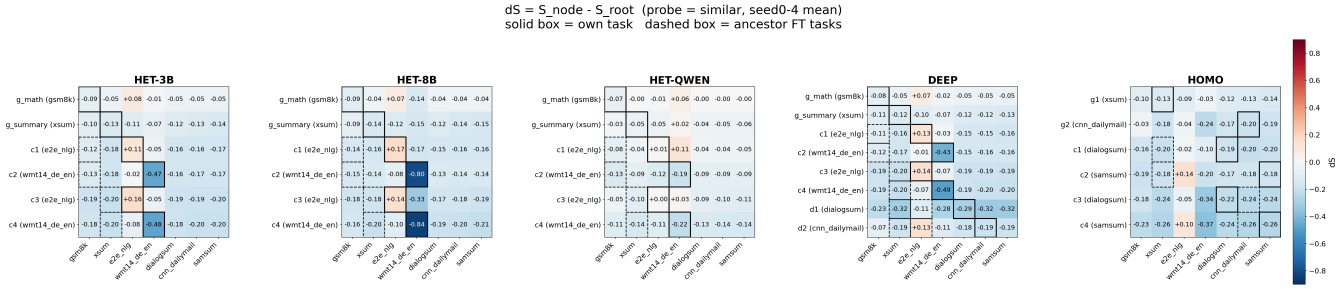


図 A·4　プローブ集合を similar（同一タスクの異分布事例）とした場合の偏差行列．自身の FT タスクに対する偏差も負に転じ，符号の構造が失われている．

Fig. A·4　Deviation matrices with the similar probe set.

© 2026 Information Processing Society of Japan