AIBOMの信頼性確保に向けた オープンウェイトモデルの構成整合性に関する実態調査

鐘本　楊[1,a)]　荒川 玲佳[1,b)]

概要：AIBOM はモデル作成者の申告を記録する形式であり，その申告を第三者が独立に検証できる範囲は自明でない．本稿は，既存研究が生成・公開した 97,950 件の AIBOM データセットを対象に，記載の有意さ（RQ1）と，モデルフィンガープリント手法を用いた派生関係の整合性（RQ2・RQ3）を実態調査した．RQ1 では，概ね記載がある項目の実体が同一の定型文や所有者名の複製であり，モデルカードの 57.6%（56,421 件）に実在する派生関係も，生成段階で全て失われることを明らかにした．RQ2 ではホワイトボックス識別器である modelDNA を活用し，申告全体の 49.1%で判定を確定した．96.1%の派生関係は実体と整合し，不整合は 3.9%にとどまることを明らかにした．RQ3 ではブラックボックス識別器である LLMmap を活用し，派生元そのものを識別できたのは実行可能件数の 2.4%・同ファミリ一致でも 11.8%にとどまり，52.6%は生成テキストから観測できず原理的に検証できない．さらに，名称が全く異なる同一重みの再公開が 182 件あること，検証可能な申告の 54.6%が単一の変換アカウントに集中すること，新しい世代のモデルほど識別器が構成を読めないことを示した．以上を踏まえ，現状の課題と望ましい実践をステークホルダ別に提言した．

キーワード：AIBOM，サプライチェーン，モデル来歴，透明性，実態調査

Toward Trustworthy AIBOMs: A Measurement Study of Configuration Consistency in Open-Weight Models

Yo Kanemoto[1,a)]　Reika Nishimura.Arakawa[1,b)]

Abstract: An AIBOM records what a model's creator declares about the model; how much of those declarations a third party can verify independently is not obvious. We conduct a measurement study on a dataset of 97,950 AIBOMs generated and released by prior work, examining whether the recorded values are meaningful (RQ1) and whether the declared lineage is consistent with the artifact, using model-fingerprinting techniques (RQ2 and RQ3). For RQ1, we find that the values of mostly-populated fields are identical boilerplate or copies of the owner name, and that the lineage relations present in 57.6% (56,421) of the model cards are all lost at generation time. For RQ2, the white-box identifier modelDNA reaches a determinate verdict on 49.1% of all claims; 96.1% of the verified lineage is consistent with the artifact and only 3.9% is inconsistent. For RQ3, the black-box identifier LLMmap identifies the declared parent itself for only 2.4% of the runnable models (11.8% even at the family level), and 52.6% of the cells leave no trace in generated text and are unverifiable in principle. We further show 182 re-uploads of identical weights under entirely unrelated names, a concentration of 54.6% of verifiable claims in a single converter account, and that identifiers increasingly fail to read newer model generations. Based on these findings, we present recommendations for each stakeholder on the current issues and desirable practices.

Keywords: AIBOM, supply chain, model provenance, transparency, measurement study

© 2026 Information Processing Society of Japan

This paper is work in progress and not peer-reviewed.

1. はじめに

オープンな言語モデルの普及につれ，そのモデルを誰が提供し，何から作られ，何を含むのかを機械可読な形で記述する枠組み AI Bill of Materials (AIBOM) が整備されてきた．AIBOM はソフトウェアの部品表である Software Bill of Materials (SBOM) と類似した概念であり，SBOM がソフトウェアの透明性に貢献している現状と同様に，AI の透明性に貢献することが期待される．SBOM の仕様策定で中心となっている OWASP や Linux Foundation が引き続き AIBOM の仕様策定でも中心的存在となっており，CycloneDX ML-BOM [1] や SPDX 3.0.1 AI Profile [2] が議論されている．OWASP AIBOM Generator[3] のような AIBOM 生成ツール（以下，生成器）は，言語モデルのリポジトリである Hugging Face (HF) のモデルカード，説明文書等から AIBOM を自動生成する．

生成された AIBOM はモデル作者の「申告」を示しているのみであり，その申告が第三者によって検証されたことにはならない．ソフトウェア同様，モデルの重みに対して，作成者が申告した内容が正しいかを第三者が確認することは容易でない．SBOM の中心用途はソフトウェアに脆弱性，悪意あるコードやライセンス違反があると発覚した際に，ソフトウェア利用者が自身に影響があるかを瞬時に判断できることにある．AIBOM も同様にモデル利用者がセキュリティリスクの有無を瞬時に判断できる点が利点である．多くのモデルはベースとなるモデルに追加学習や量子化を行なった派生したモデルであるため，ベースモデルに存在するバックドアや学習データ汚染も重みとともに派生モデルへ引き継がれる．派生元の申告が実体と整合しない場合，バックドアの存在やライセンス違反の確認ができない恐れがある．例えば，`Qwen/Qwen3.6-27B` を派生元とするモデルは 433 件存在し，派生関係が 1 世代以上に及ぶ場合も存在する．ソフトウェアのサプライチェーンと同様に，モデルのサプライチェーンにおいても問題が発覚した際の波及影響が大きい．

既存研究は AIBOM の完全性，すなわち項目がどれだけ記載されているかを大規模に調査している．Erfan らは 97,950 件の CycloneDX 形式の AIBOM を生成し，基礎的な項目の記載率は 80%以上と高いものの，モデルに関する情報やメタデータの記載率は 40%以下と低いことを報告した [4]．しかし，記載されていることと，記載内容は有意でありかつ申告内容とモデル実体が整合しているかは別である．本稿では申告のうち第三者が検証できるのはどこまでかを明らかにするため，次の 3 つの研究設問に分けて実態調査を行った．

[1] NTT 社会情報研究所
NTT Social Informatics Laboratories
[a)] yo.kanemoto@ntt.com
[b)] reika.arakawa@ntt.com

表 1 代表的な CycloneDX 項目と HF の情報の対応
Table 1 Mapping from Hugging Face sources to generated CycloneDX fields.

CycloneDX 項目（代表）	HF の項目
name・version・purl	モデル ID・commit SHA
suppliedBy・authors	所有者名（author）
primaryPurpose	`pipeline_tag`
外部参照（downloadLocation 等）	リポジトリ URL の導出
licenses	`license`
datasets	`datasets`・本文中の言及
description	`model_summary`・本文
safetyRiskAssessment	README の該当節
modelArchitecture・vocabSize 等	`config.json` の `model_type` 等
tokenizerClass	`tokenizer_class`
quantization 系・contextLength 等	GGUF ヘッダの各値
pedigree（派生元）	`base_model`

研究設問

RQ1: AIBOM の項目の値は，利用者の判断に寄与する意味ある値であるか．

RQ2: AIBOM 記載の派生関係は，公開された重みに対してどこまで整合するか．

RQ3: AIBOM 記載の派生関係は，モデルの応答だけから判断した場合どこまで整合するか．

本稿の貢献は次の三点である．

(1) 値が情報として意味を持たない項目を 12 種明らかにした．説明文の 99.8%が同一のプレースホルダであること，所有者名が 7 項目に複製されていることを明らかにした．

(2) AIBOM の派生関係を，ホワイトボックス識別器（modelDNA）とブラックボックス識別器（LLMmap）を活用し，整合するかの実態調査を行った．ホワイトボックス識別は申告全体の 49.1%で識別し，96.1%は実体と整合，不整合は 3.9%にとどまった．ブラックボックス識別が識別できたのは全体のわずか 2.4%（ファミリ水準でも 11.8%）であるが，ホワイトボックス識別が判定できない場合の適用可能性を示した．

(3) 議論として，名称が全く異なる同一重みの再公開が 182 件存在し，名称が示す見かけの多様性と重みの実体の多様性が乖離していること，および識別器の対応がモデルの世代に依存し最新世代のモデルで大きく低下することを明らかにした．これらに基づき，作成者のモデルの命名規則，生成器による派生関係の出力，監査者の識別器選定に関する提言を行った．

2. 背景

2.1 AIBOM の標準と生成器

AIBOM の代表的な形式である CycloneDX 1.6 の ML-

© 2026 Information Processing Society of Japan

BOM[1] は，モデルを 1 つのコンポーネントとして記述する．その項目は大きく，AIBOM 自体の必須情報，モデルの識別とライセンスに関する情報，学習データに関する情報に分かれる．AIBOM の生成器はモデルリポジトリから様々な情報を収集し AIBOM を作成する．例えば, OWASP AIBOM Generator[3] は，HF Hub API・モデルカード・設定ファイル・README の順に情報を探索する．代表的な CycloneDX 項目と HF の情報の対応を**表 1** に示す．

2.2 言語モデル識別

公開されたモデルの同一性や来歴を識別する手法は大きくホワイトボックス (WB) 識別とブラックボックス (BB) 識別に分かれる．WB 識別では，モデルの重みにアクセスできる前提であり，全体あるいはサンプリングした重みからフィンガープリント (指紋) を作成し，類似度を用いてモデルを識別するアプローチである．modelDNA[5] は，サンプリングした重みの指紋を作成し，二つのモデル間の比較，あるいは参照 DB にある指紋と照合することでモデルを識別する．

BB 識別では，モデルの重みにアクセスできない前提で，プロンプトに対して生成したテキスト応答からモデルを識別するアプローチである．LLMmap[6] では，設計した質問群への応答を特徴量として学習して作成した識別器を用いて，予め準備した 52 候補の中で最も近いモデルを識別する．

3. AIBOM の実態調査

調査の観点： AIBOM の項目のうち本稿が重視するのは，次の二点である．

一点目は AIBOM に記載される値が意味を成しているかである．SBOM でも課題となった，項目が多く何か値を埋めることに注力して，その値の意味が設計とかけ離れている場合があり，AIBOM でも同じことが起きていないかという点である．

二点目は AIBOM で宣言される派生元モデルは成果物と整合するかという点である．SBOM ではソフトウェアの依存関係として示されたが, AIBOM においては派生関係として示される．モデルのバックドアや学習データ汚染は派生先へ引き継がれるため，この申告が影響波及を判断する起点になる．HF のモデルカードは `base_model` を機械可読なフィールドとして持ち，どのモデルから派生したかを示す．OWASP AIBOM Generator はこの `base_model` の値を読み取っているが，対応する項目 `component.pedigree` に出力しないため，記載があると想定して調査を行った．

対象データと収集： 調査の全体像を**図 1** に示す．本研究の対象は，Erfan らが生成・公開した AIBOM データセット 97,950 件である [4]．本調査では AIBOM を新たに生成し直さず，データセットに同梱された HF メタデータ・設定ファイル・トークナイザ・重みヘッダという各リポジトリの公開成果物を独立の照合先として用いる．

調査に用いたモデル識別手法： 本調査は WB 識別を行う modelDNA [5] と BB 識別を行う LLMmap [6] を活用し，対象のモデルと AIBOM に記載された派生元のモデルが整合するかを調査した．基本的には派生先モデルは派生元のモデルに対して，微調整・量子化・再配布といった形態であるため，派生先モデルの重みは派生元からの変化が少ない，つまり類似するという性質に基づく．WB 識別および BB 識別双方とも 2 つのモデルの類似度を測定する概念である．この性質を支える根拠として，事前学習で収束したパラメータが追加学習後も安定するという観測が報告されている [7]．ただし蒸留やモデルマージのように重みの類似が保存されない派生形態には，この前提は適用できない (9 章)．

4. AIBOM 項目値の有意性調査

AIBOM の各項目の値がモデル利用者の判断を考えた際に意味ある値かを RQ1 として検査した．前提として, 利用者が AIBOM を整合性確認に使う場面では，モデルの理解・選定には `description` と `modelArchitecture`，同一性の固定には `version`，供給者の特定には `supplier` 等，リスク判断には `technicalLimitations` と `safetyRiskAssessment`，データ来歴には `datasets` の値が，正しく埋まっている必要がある．本節はこの前提が成り立つかを検査するものであり，対象はデータセット 97,950 件の全数である．まず，判断に際して意味をなさないと考えられる場合を四つに分類した．それぞれ，(i) 対象モデルに依存しないプレースホルダ，(ii) 他項目から導出できる同語反復，(iii) データセット内で概ね単一の文字列，(iv) 意図不明の文章断片，である．なおモデルでなく AIBOM 生成処理そのものを記述する項目（`dependencies`・`metadata.component`）は，値の問題でなく生成器の仕様に属するため対象から除いた．主要な該当項目を**表 2** に示す．基準ごとの頻出の実例は付録 A.2 に示す．

(i) プレースホルダ： 説明文 `description` の 99.8%は同じ文字列 `No description available` であり，`version` の 41.3%は SHA 取得失敗時の固定値 `1.0` である．`technicalLimitations` も記載がある 16,393 件の 51.7%がカード雛形の指示文や文断片で占められており，現状，AIBOM 生成器の制約により正しい値を記載できてない可能性がある．

(ii) 所有者名の複製： `name`・`group`・`purl` 自体は仕様どおりで正当だが，`supplier`・`manufacturer`・`authors` が同じ所有者名の複製であり，実態としては項目の意図を踏まえていない可能性が高い．

(iii) 定数： 入出力形式を示す `inputs`/`outputs` の 87.2%は `[{"format":"string"}]` の固定値で，実際の入出力を

© 2026 Information Processing Society of Japan

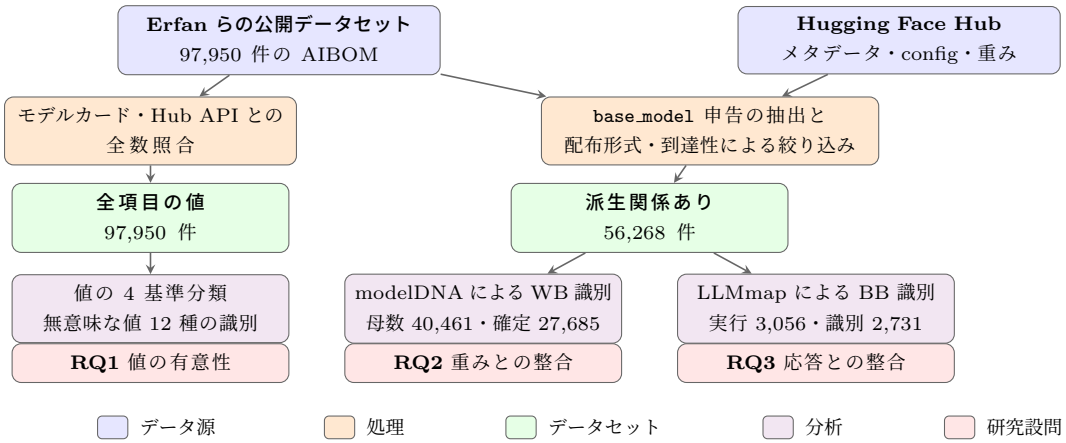


図 1 調査の全体像．2 つのデータ源から構築した 2 つのデータセットが，3 つの研究設問にそれぞれ対応する

Fig. 1 Study overview: datasets built from the two sources and their mapping to the three research questions.

表 2 AIBOM の値が情報として意味を持たないケースの一覧

Table 2 Fields that are populated but whose values carry no information.

基準	項目	利用者の用途	値の実体	割合（分母）
(i)	`description`	モデルの理解・選定	文字列 `No description available`	**99.8%**（97,950）
(i)	`version`	同一性の固定	文字列 `1.0`（SHA 取得失敗時の固定値）	41.3%（97,950）
(i)(iv)	`technicalLimitations`	リスク判断	指示文雛形・文断片	51.7%（16,393）
(ii)	`supplier`・`manufacturer`・`authors`	供給者の特定	所有者名の複製（同一の値）	99.8–100%
(ii)	`externalReferences`	出所の参照	リポジトリ URL の再掲	65.6%
(iii)	`inputs/outputs`	接続・利用設計	`[{"format":"string"}]` 固定	87.2%
(iii)	`modelArchitecture`	構成の把握	文字列 `transformer`（取得失敗時の固定値）	30.6%（97,950）
(iv)	`safetyRiskAssessment`	リスク評価	10 語未満の断片	34.4%（9,556）
(iv)	`datasets[].name`	データ来歴	冠詞・前置詞等の断片（`a from Card`）	36.8%（75,190）

確認せずに出力される既定値である．`modelArchitecture` の 30.6%は候補を特定できない固定値である `transformer` である．

(iv) 文章の断片： `datasets` は説明文からの抽出により，意図しない英語の冠詞や前置詞が 36.8%を占める．`safetyRiskAssessment` も記載の 34.4%が 10 語未満の断片で，ライセンス行やパラメータ数の行の混入もあり，何を評価してどうだったかを構成できない．(i) と同様に，生成器の実装上の制約により正確に値を抽出できなかったことが原因と考える．

RQ1:「AIBOM の項目の値は，利用者の判断に寄与する意味ある値であるか」への回答

項目が埋まっていることは，値が情報として意味あることを保証しない．現段階では，記載率が高い項目の実体は，プレースホルダ・所有者名の複製・実態と無関係な定数であり，まだ利用者の判断に資する情報になっていない可能性が高い．活用できない記載の原因は AIBOM の生成器の実装や制約が原因の場合もあれば，モデル作成者が情報提示を失念している場合も考えられる．

5. 派生関係の実態調査

AIBOM の重要な役割の一つは，対象のモデルがどのモデルから派生したかを明らかにする点である．本調査では，AIBOM において申告された派生元モデルが実体のモデルと整合するかを計測した．RQ2〜3 のデータセットはいずれも `base_model` の申告がある件数を対象とし，各識別器が原理的に対応できない件数を除外した集合を各 RQ のデータの母数とする．

絞り込みの第一の要因は派生元フィールドの不在である（**表 3**）．生成された 97,950 件の AIBOM のうち `pedigree` を持つデータは 0 件で，HF のメタデータでは 56,421 件（57.6%）が `base_model` を申告しているため，以降の検証対象はメタデータ側から取得し，そこから自分自身を派生元として申告する 153 件を除いた 56,268 件を RQ2 と RQ3 の共通のデータセットとする．

第二の要因は配布形式である．どの配布形式を読めるかは識別器ごとに異なり，原理的に読めない形式を除外した残りがその RQ の母数になる．RQ2 の母数は 40,461 件（71.9%）である．modelDNA が原理的に読めず除外となるのは，例えば AWQ・GPTQ・MLX などテンソル名を書

© 2026 Information Processing Society of Japan

表 3　派生元申告の絞り込みと各 RQ の母数
Table 3　Funnel from the AIBOM corpus to the per-RQ verification denominators.

段階	件数	対データセット
AIBOM が生成されたモデル	97,950	100%
派生元の記載あり	56,421	57.6%
自己参照を除く	56,268	57.4%
RQ2 母数: modelDNA	**40,461**	**41.3%**
RQ3 母数: LLMmap	**3,056**	**3.1%**
modelDNA 実行成功	35,515	36.3%
判定が確定	**27,685**	**28.3%**

き換えるパック量子化の 2,408 件と，例えば encoder 系・視覚・音声・拡散モデル・アダプタなど，対応アーキテクチャ表にない・`model_type` を欠く・または量子化の形式を特定できない 13,399 件である．

RQ3 の母数は 3,056 件（5.4%）である．LLMmap はモデルの生成応答から識別するため，重みを取得してローカルに保存し，かつテキストを生成できるモデルのみを対象としている．decoder 系・非量子化 safetensors の基準で絞った 5,020 件から出発する．ここから順に，重み実体に到達できない 502 件，計算資源の制約により 9B パラメータを超える 1,209 件，テキストを生成しないモデル 253 件を除いた（自己参照 153 件は表 3 のとおり除外済みである）．

6. ホワイトボックス識別による整合性の検証

Shao らの SoK[8] の評価では，モデルの重みに直接アクセスする WB 識別のアプローチが最高精度（AUC 0.99 超）と報告されている．本稿は WB 識別の中でも軽量で，ツールとして利用可能な modelDNA[5] を利用して派生元申告の整合を調査した．modelDNA の識別精度は原論文で既に検証されており，15 モデルと 8 つの候補ベースからなるベンチマーク（正例 13・強負例 107）で，AUROC 1.0 が報告されている [5]．そのため本稿では識別精度の再検証は行わず，modelDNA の大規模適用による派生関係の整合性の実態調査に焦点を置く．

6.1 modelDNA の概要

modelDNA は対象モデルの重みから軽量な指紋を抽出し，申告された派生元の指紋と比較する．形状・層数が一致するかという構造の証拠と，固定位置サンプル間のコサイン類似度やスペクトルの距離という重みの証拠を合わせて確率へ較正し，走査ごとに判定クラスを 1 つ返す．

判定クラスは 8 種である．派生関係が強い順に，`EXACT_COPY` は重みがバイト単位またはほぼ同一の場合で，再アップロードや改名した複製を指す．`QUANTIZED_COPY` は量子化の丸め誤差の範囲で親と一致する複製である．`FINE_TUNE` は単一の派生元からの小さなパラメータ差分で，教師あり微調整や LoRA マージの領域に当たる．`SAME_LINEAGE` は差分が大きいものの系譜の信号は単一の派生元と一致する場合で，継続事前学習などに相当する．残る 4 種は，証拠が複数の派生元に分かれる `LIKELY_MERGE`，モデルファミリの水準では一致するが派生元を 1 つに特定できない `SAME_FAMILY_UNRESOLVED`，申告された派生元と合致しない `NO_MATCH`，形式が未対応または必要なデータを読めない `INSUFFICIENT` である．

表 4　modelDNA による母数 40,461 件の判定クラス別の分類
Table 4　modelDNA verdict classes over the 40,461-claim frame.

判定クラス	本稿の扱い	件数
`EXACT_COPY`	整合	1,155
`QUANTIZED_COPY`	整合	19,436
`FINE_TUNE`	整合	5,107
`SAME_LINEAGE`	整合	895
`LIKELY_MERGE`	—	0
`SAME_FAMILY_UNRESOLVED`	N/A	58
`NO_MATCH`（不一致の証拠あり）	不整合	1,092
`NO_MATCH`（比較不能・層数不一致）	N/A	7,772
`INSUFFICIENT`	—	0
走査不能	—	4,946
計（母数）		40,461

整合計 26,593・不整合 1,092・N/A 7,830 で，確定判定は 27,685 件．走査不能は対象または派生元のリポジトリを取得できない 2,316 件・読める重みファイルがない 2,200 件・読解エラーその他 430 件．

6.2 modelDNA による識別結果

本稿は申告された派生元モデルの重みを比較相手に与えて識別を実施した．したがって，派生関係を認める 4 クラスを申告との**整合**，`NO_MATCH` を**不整合**，`SAME_FAMILY_UNRESOLVED` を **N/A（判定保留）**として集計する．ただし `NO_MATCH` のうち，重み信号を 1 つも構成できない 873 件，片側の形状情報を読み取れないまま非互換と判定された 5,696 件，層数の不一致だけで棄却された 1,203 件（計 7,772 件）は，重みの証拠を持たないため N/A として扱う（**表 5**）．**表 4** に母数 40,461 件の識別結果を示す．識別に成功したのは 35,515 件（87.8%）で，`LIKELY_MERGE` と `INSUFFICIENT` は結果に出現しなかった．

6.3 識別結果に基づく整合性

`NO_MATCH` と判定された 8,864 件の全数を，判定根拠とモデルの構成情報でパターン分類した結果を表 5 に示す．最大のパターン (P2) は，派生元側 safetensors の config から隠れ次元やヘッド数を読み取れないことを示している．(P3) の層数の不一致も，派生元側の層数を読めない 418 件と，GGUF 変換でデコード用の層が 1 層加算される 375 件とで過半を占め，層数の違いだけでは重みの証拠に至らない．(P1) の重み信号を計算できない比較と合わせた 7,772 件は，不一致の証拠を持たないため本稿では識別不可として扱う．不整合として残すのは，両側の構成を読み取れたうえで違う，または類似度が低い (P4) から (P6) の 1,092

© 2026 Information Processing Society of Japan

表 5　NO_MATCH 判定 8,864 件のパターン分類と本稿の扱い
Table 5　Patterns behind the 8,864 NO_MATCH verdicts and their treatment.

パターン	件数	割合	扱い
(P1) 重み信号を計算できない	873	9.8%	N/A
(P2) 重みの形状情報を読み取れない	5,696	64.3%	N/A
(P3) 重みの階層数の不一致	1,203	13.6%	N/A
(P4) 重みの類似度が低い	531	6.0%	不整合
(P5) 注意ヘッド構成の差（GQA/MLA）	332	3.7%	不整合
(P6) FFN 幅の差	229	2.6%	不整合

件である．

この扱いのもとで判定が確定したのは 27,685 件で，うち整合は 26,593 件（**96.1%**）である．最多は量子化した複製の 19,436 件（整合の 73.1%）で，量子化済み GGUF の再配布が派生の主流である．母数のうち GGUF 形式のみで配布される 35,486 件に限っても 23,840 件の判定が確定しており，量子化配布に対しても WB 識別による検証が実際に成立する．整合側の 26,593 件は例外なく層数と形状が一致している．

不整合は 1,092 件で，全体の 3.9%である．実体の乖離が疑われる不整合の実例を挙げる．`pltops/qwen2_7B-dis-wspo-full_E1` は 1.5B 規模の `wh-zhu/qwen2_1.5B-ultrachatfeedback-dpo` を派生元と申告するが，実体は 7.6B 規模で隠れ次元も FFN 幅も異なり（3584 対 1536・18944 対 8960），派生元から重みを引き継いだとは考えづらく，実体の規模・構造が派生元と合わない．`ytgui/Qwen3.5-Sonnet-9B` は `Qwen/Qwen3.5-9B` と層数（32 層）・トークナイザが一致し，パラメータ規模もほぼ同じ（9.4B 対 9.7B）であるにもかかわらず，重みから算出した類似度は 0.008 にとどまり，構造は整合するが重みが実質無相関であった．原因としては，同型の構成のまま重みを作り直した，あるいは全面的に学習し直したことが推察される．

RQ2:「AIBOM 記載の派生関係は，公開された重みに対してどこまで整合するか」への回答

派生元が記載されている AIBOM 56,421 件のうち，WB 識別器である modelDNA が原理的に読める母数は 40,461 件で，判定の確定は申告全体の 49.1%（27,685 件）であった．96.1%は AIBOM 記載の派生関係が整合し，不整合は 3.9%にとどまった．実体の規模・構造自体が派生元と合わない場合と，モデルの構造は一致するが重みが相関しない場合とが存在することが明らかになった．

7. ブラックボックス識別による整合性の検証

LLMmap の著者らによる評価では，42 種類のモデルを 95%超の精度で識別できると報告している [6]．一方，Shao らの横断評価によれば，LLMmap の AUC は 0.632 にとどまり，BB 識別はいずれも AUC 0.72 未満で，WB 識別に大きく劣る [8]．Shao らはこの差を，WB 識別がパラメータそのものを比較するのに対し，BB 識別は応答という二次的な挙動に依存し，確率的で安定しないためと分析している．したがって本稿では，BB 識別の判定を WB 識別より精度の低い証拠として扱い，識別の誤りが混在しうるアーキテクチャの不一致を不整合として扱わないこととする（7.3 節）．

7.1 LLMmap の概要

LLMmap[6] は，モデルの重みにアクセスせず，テキストチャットのように対象と対話することによって識別を行う能動的なアプローチである．識別力が高くなるよう設計された質問群を対象へ送り，得られた応答を特徴量ベクトルへ埋め込み，学習済み識別器が候補 52 モデルのうち特徴空間で最も近いものを識別する．識別は候補の中の最近傍への割り当てであるため，派生元のモデルが候補に含まれない対象には原理的に適用できず（実行母数 3,056 件では申告された派生元の 93.3%が候補 52 モデルの外にある），観測できる情報も生成テキストに現れる特徴に限られる．実際に LLMmap の観測を AIBOM の 8 項目（ファミリ・派生元・規模など）に対応づけると，3,056 件 ×8 項目のセルのうち 52.6%は対応する情報が生成テキストに現れず，BB 識別では原理的に観測できない．本稿では，上位 2 候補までの距離の差が相対値 0.1 に満たない識別は，確信が低いものとして識別不可として扱う．加えて，最近傍までの識別距離が 25 を超える識別は，候補のいずれとも十分に近くないとして識別不可として扱う．この閾値は，正解が分かる在プール標本（top-1 が派生元と一致した 96 件を正例，他ファミリへ誤識別された 53 件を負例とする）の距離分布から較正した．正例の距離は中央値 21.7，負例は p25 が 31.7 と分離しており，閾値を 20 から 30 まで走査したところ，25 で正例の 68%を維持しつつ負例の 94%（53 件中 50 件）を排除できたため，この値を採った（分布は付録 A.3）．

7.2 LLMmap による識別結果

母数 3,056 件（5 章）のモデルをローカルにダウンロードし，LLMmap を実行した．このうち応答から識別が得られたのは 2,731 件（89.4%）であり，残る 325 件は変換チェックポイントの読込不能や量子化設定の不備など，モデルのロード・テキスト生成段階の失敗で応答が得られなかった．**表 6** に LLMmap の識別結果を示す．閾値の導入により採用される識別は 380 件に絞られるが，そのうちファミリ一致は 322 件（84.7%）を占める．さらに Top 1 が申告された派生元そのものと一致したのは 65 件で，実行可能件数の 2.4%にあたる．

© 2026 Information Processing Society of Japan

表 6 LLMmap の識別結果
Table 6 LLMmap identification results.

			識別距離			距離差
群	件数	割合	p25	中央値	p75	中央値
母数	3,056	100%	–	–	–	–
実行可能	2,731	89.4%	28.4	33.7	37.8	0.19
識別可能	380	13.9%	–	–	–	–
うちファミリ一致	322	11.8%	17.8	20.8	23.0	0.55
うち名称一致	65	2.4%	15.4	17.9	21.8	0.62
うちファミリ不一致	58	2.1%	20.3	22.3	23.7	0.51
識別不可	2,351	86.1%	30.9	34.8	38.5	0.16

識別可能条件は距離差 0.1 以上かつ識別距離 25 以下を満たす場合とした．識別距離は特徴空間での最近傍候補までの距離であり，小さいほど確信が強い．距離差は上位 2 候補の距離の相対差である．

7.3 識別結果に基づく整合性

ファミリ不一致となった 58 件についてそのパターンを調べた．内訳は 3 つに分かれる．一つ目は，WB 識別において派生関係の整合を確認している 43 件（74%）であり，これらの不一致は識別の誤りとみなせる．二つ目は，WB 識別が判定を確定できていない場合であり，14 件存在する．これらは BB 識別のみによる疑義であり，単独では不整合と断定できない．三つ目は残る 1 件で，両方の証拠の方向が一致した，正しい不整合の候補である．`yentinglin/Llama-3-Taiwan-8B-Instruct` は `meta-llama/Meta-Llama-3-70B` を唯一の派生元としているが，実体は 8.03B（32 層）であり派生元の 70.55B（80 層）と構造が根本的に一致せず，応答からの識別も申告と異なるファミリを示した．

一方，BB 識別が WB 識別の空白を補完する場合もある．パック量子化や参照先の消失などで WB 識別が判定できない対象のうち，BB 識別が識別を確定できたのは 70 件であり，うち 6 件は申告された派生元そのものを名指しできた．

RQ3: 「AIBOM 記載の派生関係は，モデルの応答だけから判断した場合どこまで整合するか」への回答
BB 識別で識別を採用できたのは実行可能件数の 13.9% にとどまり，申告された派生元そのものを識別できたのは 2.4%（ファミリ水準でも 11.8%）であった．一方，WB 識別が判定できない 70 件では BB 識別が唯一の証拠となった．応答検査の制約は精度ではなく適用範囲にあるが，その価値は WB 識別が構造的に届かない配布形態を補完できる点にある．

8. 議論

8.1 名称が全く異なる同一重みの再公開

整合と判定された側にも，透明性の観点で問題となる場合もある．modelDNA において `EXACT_COPY` 判定され，テンソル一覧のハッシュも一致し重みが実質的に同一である 1,155 件の名称を派生元のモデル名称と照合すると，同名の

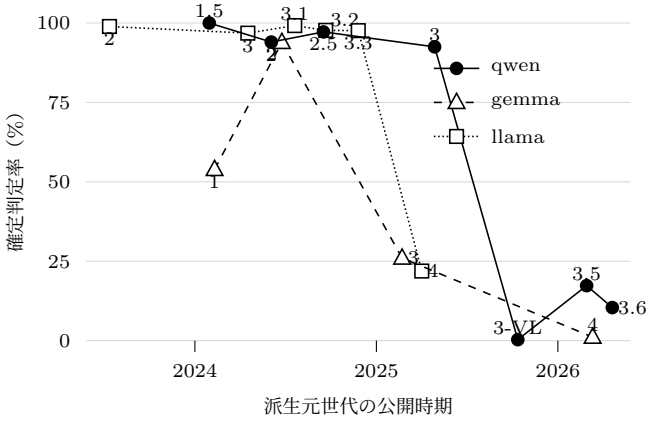


図 2 派生元の世代別の確定判定率の推移．横軸は各世代の代表リポジトリの Hugging Face 公開日，点の数字は版．版を特定できない派生元，単一世代の mistral 系（92.4%），gpt2 系（公開日が Hub の記録開始以前，20.8%）は除外．llama 4 は $n = 32$ と小さい

Fig. 2 Determinate-verdict rate by parent generation over release date; point labels are version numbers. Parents with unresolvable versions, mistral, and gpt2 are excluded.

再公開が 102 件，派生元名を含む変換配布が 381 件，語や語頭・部分文字列を共有するものが 490 件で，残る 182 件は正規化した名称に共通の語がなく，5 文字以上の共通部分列も 4 文字以上の共通語頭も持たない（DL 上位の実例は付録 A.4）．つまり，名称から同一性を推測する手がかりがない再公開である．例えば `numind/NuExtract-1.5` は `microsoft/Phi-3.5-mini-instruct` と，`Menlo/Jan-nano` は `Qwen/Qwen3-4B` と，それぞれサンプルした重み要素が一致度 0.998 以上でほぼ完全に一致する．

これらのリポジトリ自体は派生元を正しく申告しており，不整合ではないが，ほぼ同一モデルの再公開に相当すると考えられる．再公開の際に利用条件やライセンス等が不一致となれば利用者は困惑することが想定される．

8.2 識別可能性の世代間の推移

検証可能性はモデルのアーキテクチャ世代にも強く依存する．**図 2** に，走査に成功した比較を派生元の世代別に分け，判定が確定した割合を示す．llama 3.1 系，qwen 2.5 系や gemma 2 系など 2023–2025 年前半の世代が確定判定率 90%台で推移するのに対し，画像入力を持つ新世代では確定判定率は大きく低下する．原因は表 5 の (P2)，すなわち寸法が入れ子の config へ移った新世代の構成を識別器が読めないことである．つまり，識別器のカバレッジがモデルの進化に追随できていないと推察する．

8.3 各ステークホルダへの提言

モデル作成者： RQ1 で述べたように有意な情報をモデル

© 2026 Information Processing Society of Japan

カードに記載すべきである．派生関係の 96.1%は実体と整合しており（6 章），申告はおおむね正しく，派生モデルの作成が機械的に処理されており，良い習慣が実践されていると推察する．またモデル命名にも意識すべき要件がある．182 件の名称が全く異なる同一重みの再公開はモデル利用者の混乱を招きかねない．名称の不整合は，派生元の欠陥が発覚した際に，派生関係から影響を追跡できないことも問題である．作成者は，(a) 派生元の系列名を名称またはメタデータで追跡可能に保つ，(b) 同一重みの再公開はその旨を明示する，を意識できると良いと考える．

AIBOM 生成器の開発者： AIBOM の情報源が様々な形式で記載されることを想定しておくべきである．派生関係を示す `pedigree` と成果物ハッシュを出力し，必要な情報が README 等に自然言語のドキュメントにも記載されている場合も想定し，文章を正確に抽出できるようにしておくことが望ましい．

モデル利用者： 不整合判定の大半が読解・表現の差や識別器の候補集合に由来する現状（6 章・7 章）を踏まえ，単一の識別器による不整合の判定をそのままモデルの信頼性欠如として扱えないことを意識しておくことが必要である．また，一つのモデルだけでなく，モデル作成者が公開する他のモデルの状況も踏まえてリスクを判断する必要があると考える．

9. 限界

本調査対象の偏り： AIBOM の 40,461 件の所有者は 4,569 アカウントに分かれるが，量子化変換を大量に公開する `mradermacher` 単独で 22,098 件（**54.6%**）を占める．そのため，本調査の結果もこのアカウントの処理工程に大きく影響されてしまう．

識別精度の限界： WB 識別器の精度検証は原論文の小規模ベンチマーク（正例 13・強負例 107）にとどまっている．本稿の調査では，派生関係にあるモデルの重みは類似することを前提としている．モデル蒸留のように重みが派生元と独立になる形態，複数の派生元を混合するモデルマージ，大規模な追加学習によって，重みに著しい乖離が生じる場合にはこの前提が成り立たず，不整合や識別不可に含まれうる．

10. 関連研究

生成ツール側の先行研究である ALOHA[9] は，CycloneDX 準拠の AIBOM 生成器を提案し，312 モデルの評価で項目の充足率と欠落の原因を報告した．欠落の原因は大きく，情報がモデルカードに存在しない，情報は存在するが機械的に処理できない，アクセス制限で取得できない，の 3 種に分類される．この調査は記載がなぜ存在しないかの分類であり，本稿の RQ1 の目的である記載が意味を持つかとは分析の軸が異なる．

Erfan ら [4] が記載の質を測ったのは AIBOM 項目の `description` の 1 点にとどまり，他の項目は測定されてこなかった．存在率でなく値の中身で透明性を測る本稿の目的は，SBOM の透明性指標 [10] と同じ観点であるが対象が異なる．

11. おわりに

AIBOM の記載のうち第三者が独立に検証できる範囲を，既存研究が生成した 97,950 件のデータセットに対する記載値の分析と，派生関係の整合性を大規模に調査した．判定を確定できた範囲では，派生元の 96.1%は記載どおりであり，不整合は 3.9%にとどまる．検証を妨げていたのは，同一性を固定する識別情報の欠落と，モデル配布形式や識別器の実装上の制約が主な要因であった．

今後の課題として，より適用範囲が広い識別手法を活用した調査や，AIBOM の時系列変化の分析により，コミュニティの課題や実態を明らかにすることを予定している．

参考文献

[1] OWASP CycloneDX: AI Models and Model Cards. available from ⟨https://cyclonedx.org/use-cases/ai-models-and-model-cards/⟩.

[2] SPDX: SPDX 3.0.1 Specification, AI Profile. available from ⟨https://spdx.github.io/spdx-spec/v3.0.1/model/AI/AI/⟩.

[3] GenAI Security Project: OWASP AIBOM Generator. available from ⟨https://github.com/GenAI-Security-Project/aibom-generator⟩.

[4] Erfan, M., Ryan, A. and Rahman, M. R.: A Large-Scale Measurement of AI Bill of Materials Completeness in Hugging Face Models (2026). arXiv:2607.17242.

[5] Adil, M. A. B. and Aamir, S.: modelDNA: Calibrated Lineage Verification and Merge Decomposition from Sampled Weight Fingerprints (2026). arXiv:2607.10617.

[6] Pasquini, D., Kornaropoulos, E. M. and Ateniese, G.: LLMmap: Fingerprinting For Large Language Models, *Proc. 34th USENIX Security Symposium (USENIX Security 25)*, pp. 299–318 (2025).

[7] Zeng, B., Wang, L., Hu, Y., Xu, Y., Zhou, C., Wang, X., Yu, Y. and Lin, Z.: HuRef: HUman-REadable Fingerprint for Large Language Models, *Advances in Neural Information Processing Systems 37 (NeurIPS 2024)* (2024).

[8] Shao, S., Li, Y., He, Y., Yao, H., Yang, W., Tao, D. and Qin, Z.: SoK: Large Language Model Copyright Auditing via Fingerprinting (2025). arXiv:2508.19843.

[9] D'Avino, R., Nocera, S., Bifolco, D., Pepe, F., Di Penta, M. and Scanniello, G.: ALOHA: A (IBoM) tooL generatOr for Hugging fAce, *Proc. 29th International Conference on Evaluation and Assessment in Software Engineering (EASE)*, pp. 929–937 (2025).

[10] 鐘本　楊，荒川玲佳，秋山満昭：SBOM の大規模実態調査に基づくソフトウェア透明性評価の検討，コンピュータセキュリティシンポジウム 2023 論文集，pp. 332–339 (2023).

© 2026 Information Processing Society of Japan

付　　録

A.1　モデル派生関係の構造

HF のモデルカードの `base_model` を派生関係グラフとしたときの構造を示す．対象は派生関係ペア 58,163 件から自己参照 153 件を除いた 58,010 ペア（派生先 56,322 種・派生元 22,241 種）である．**表 A·1** に，派生先数の多い派生元の上位 10 件を示す．上位には本稿の検証母数の外にある画像生成モデル（`FLUX.1-dev`・`stable-diffusion-xl`）も含まれる．**表 A·2** は，各派生先から申告をさかのぼれる世代数の分布である．申告の 28.8%（16,208 件）は派生元自身も派生モデルであり，来歴は 1 ホップでは閉じない．自己参照を除く循環は存在しなかった．

表 A·1　派生先数の多いモデル上位 10 件
Table A·1　Top 10 declared parents by number of children.

申告された派生元	派生先数
`black-forest-labs/FLUX.1-dev`	477
`Qwen/Qwen3.6-27B`	433
`Qwen/Qwen3.6-35B-A3B`	394
`Qwen/Qwen3.5-9B`	277
`meta-llama/Llama-3.1-8B-Instruct`	251
`Qwen/Qwen3-8B`	249
`Qwen/Qwen3.5-4B`	221
`Qwen/Qwen2.5-7B-Instruct`	217
`stabilityai/stable-diffusion-xl-base-1.0`	200
`google/gemma-4-E4B-it`	199

表 A·2　派生関係の世代数の分布
Table A·2　Distribution of lineage-chain depth in generations.

世代数（自身含む）	件数
2	40,114
3	10,835
4	4,249
5	867
6	167
7	40
8	27
9	15
10 以上	8
計	56,322

A.2　RQ1 基準別の無意味な値の実例

4 章の 4 基準に該当する値の頻出例を**表 A·3** に示す．値は一字一句そのままで，長いものは先頭のみ示す．

A.3　BB 識別の距離閾値の設定根拠

7 章で導入した距離閾値 25 以下・距離差 0.1 以上の適用条件の設定根拠を**図 A·1** に示す．正解が分かる指標のうち，Top 1 が派生元と一致した正例（96 件）は距離中央値 21.7 に集まり，他ファミリへ識別された負例（53 件）は p25 が 31.7 と大きい側に分離する．識別距離 25 以下かつ距離差 0.1 以上の適用条件であれば，正例の 68%（65 件）を保持し，負例の 94%（53 件中 50 件）を分離する．

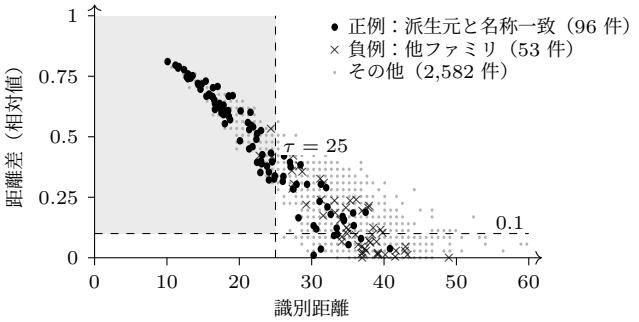


図 A·1　識別距離と距離差の分布と適用条件（灰色）．
Fig. A·1　Identification distance vs. relative margin with the acceptance region (gray).

A.4　完全別名の再公開の実例

8.1 節の完全別名 182 件のうち，ダウンロード数（DL）上位 10 件を**表 A·4** に示す．1,000DL を超えるものは 32 件ある．いずれの再公開も派生元自体は正しく申告しており，本表は不整合の指摘ではなく，名称だけからは同一性を推測できない再公開が広く利用されている実態を示すものである．

© 2026 Information Processing Society of Japan

表 A·3 RQ1 の基準 (i)〜(iv) に該当する値の頻出例（97,950 件の全数集計）

Table A·3 Most frequent examples of meaningless values per RQ1 criterion (all 97,950 documents).

基準	項目	値の実例	件数
(i)	description	`No description available`	97,729
	version	`1.0`	40,454
	technicalLimitations	`<!-- This section is meant to convey both technical…`（カード雛形の指示文）	2,981
	technicalLimitations	`More information needed ## Training and evaluation…`	1,821
(ii)	supplier=group	`mradermacher`	23,695
	（所有者名の複製.	`RichardErkhov`	2,196
	manufacturer・	`bartowski`	1,721
	authors も同値）	`mlx-community`	1,352
		`TheBloke`	1,216
(iii)	inputs/outputs	`[{"format":"string"}]`	85,378
	modelArchitecture	`transformer`（フォールバック語）	29,948
	quantizationVersion	`2`（GGUF 形式の版数）	25,390
	modelArchitecture	`causal-lm`	15
(iv)	datasets[].name	`Card`	2,732
	datasets[].name	`a`	1,948
	datasets[].name	`from`	1,591
	datasets[].name	`name`	1,523
	datasets[].name	`-`	713
	technicalLimitations	`on Linux ~/ik_llama`（手順書の断片）	473
	technicalLimitations	`of Liability`（ライセンス条文の断片）	420
	safetyRiskAssessment	`- **License:** apache-2`（ライセンス行が混入し.0 で切断）	111
	safetyRiskAssessment	`and ethical standards before deployment`	91
	safetyRiskAssessment	`- Number of Parameters: 7`（7B の断片）	64

表 A·4 完全別名の再公開モデルのダウンロード (DL) 上位 10 件（重み一致度 0.998 以上）

Table A·4 Top 10 most-downloaded re-uploads whose names share nothing with their declared parents (all with weight-match probability above 0.998).

再公開リポジトリ	申告された派生元	DL
`zeroentropy/zerank-2-reranker`	`Qwen/Qwen3-4B`	60,125
`flowaicom/Flow-Judge-v0.1`	`microsoft/Phi-3.5-mini-instruct`	12,174
`jondurbin/bagel-8b-v1.0`	`meta-llama/Meta-Llama-3-8B`	8,204
`Jackrong/Qwopus3.5-9B-v3`	`unsloth/Qwen3.5-9B`	5,951
`ReDiX/Artemide-3.5`	`microsoft/Phi-3.5-mini-instruct`	5,289
`numind/NuExtract-1.5-tiny`	`Qwen/Qwen2.5-0.5B`	3,528
`Xerv-AI/Ada`	`unsloth/Qwen2.5-Math-1.5B`	3,170
`antgroup/Agentar-Scale-SQL-…-32B`	`seeklhy/OmniSQL-32B`	3,155
`AscendKernelGen/KernelGen-LM-8B`	`Qwen/Qwen3-8B`	3,027
`OrionLLM/GRM-2.6-Plus`	`Qwen/Qwen3.6-27B`	3,019

© 2026 Information Processing Society of Japan