バイナリ操作能力の大規模調査から導くLLMの制約と特性

大坪 雄平[1,2,a)]　大塚 玲[2]

概要：自律型バイナリ解析 AI エージェントの信頼性を決定づける基盤能力である，LLM のバイナリシーケンス操作能力を定量的に分析する．先行研究で提案した動的ベンチマークを用い，49 種類のモデル構成を多様なテキスト表現と入力長で評価した結果，2025 年後半以降の最新モデルにおいて低レイヤーのデータグラウンディング能力が飛躍的に向上していることを明らかにした．一方で，パラメータ数と抽出能力が乖離する「Blind Giant 現象」，手続き的なツール利用能と実質的な抽出能力の差を示す「Grounding Gap」，内部推論とツール整形に最適な表現が相反する「エンコードのジレンマ」という 3 つの構造的制約を特定した．これらの知見に基づき，モデル選定基準を汎用スコアから実測の操作能力へと転換する必要性を示し，堅牢な解析エージェント構築のための具体的な設計指針を提示する．

キーワード：バイナリ解析，LLM ベンチマーク，データグラウンディング，コンテキストエンジニアリング，AI エージェント

Constraints and Characteristics of LLMs Derived from a Large-scale Study of Binary Manipulation Capabilities

Yuhei Otsubo[1,2,a)]　Akira Otsuka[2]

Abstract: This paper analyzes the binary sequence manipulation capabilities of LLMs, a foundational requirement for the reliability of autonomous binary analysis agents. Using a previously proposed dynamic benchmark, we evaluated 49 model configurations across various text encodings and input lengths. Our results reveal a significant leap in low-level data grounding in models released after late 2025. However, we identify three structural constraints: the “Blind Giant” phenomenon, where parameter size does not correlate with extraction accuracy; the “Grounding Gap” between procedural tool-use ability and substantial grounding ability; and the “Encoding Dilemma” between optimal representations for internal reasoning versus tool formatting. Based on these findings, we argue for a shift in model selection criteria from general benchmarks to empirical manipulation performance and provide concrete design guidelines for developing robust binary analysis agents.

Keywords: binary analysis, LLM benchmark, data grounding, context engineering, AI agents

1. はじめに

近年，大規模言語モデル（LLM）を搭載した自律型 AI エージェントによるバイナリ解析の自動化が，脆弱性探索やマルウェア解析といったセキュリティ運用の効率化に向けて強く期待されている [1], [2]．特に，外部ツールを自律的に操作して複雑なリバースエンジニアリング課題を解決するエージェントの研究が進展しており，一部では人間を上回るタスク完遂率を示す例も報告されている [1].

しかし，既存の評価フレームワークの多くは，パス率（pass@k）やタスク成功率といったエンドツーエンドの総合指標に依存している．そのため，解析失敗の原因が「ドメイン知識の不足」なのか，「高次な計画策定の誤り」なのか，あるいは本稿で焦点を当てる「低レイヤーでのデータ

[1] 警察庁
National Police Agency
[2] 情報セキュリティ大学院大学
Institute of Information Security
[a)] dgs157101@iisec.ac.jp

© 2026 Information Processing Society of Japan

This paper is work in progress and not peer-reviewed.

抽出ミス」なのかを分離して特定することが困難である．

AI エージェントによるセキュリティ解析において，推論や計画といった高次の能力は，その前段にある入力データの解釈精度に強く制約される．具体的には，PE/ELF ヘッダからのフィールド抽出やメモリダンプからのオフセット決定といった低レイヤー操作において，1 バイトの不整合が生じるだけで，後続のエージェントは誤った前提に基づいた一貫した計画を立ててしまうことになる．このような低レイヤーでのデータグラウンディング能力の欠如は，エージェント全体の信頼性に対する実効的な上限を形成し，高度なプランニング能力がむしろ誤りを増幅・伝播させるリスクがある [3]．実際，低レイヤーの文字列解釈における微小な不整合が，解析対象そのものの意味を変質させうることは既に報告されており [4]，入力表現に対する頑健性がセキュリティ解析性能の実効的な上限を決定づける重要な要因となる [5], [6].

このような低レイヤー操作の困難さは，LLM が抱える構造的な制約に起因すると考えられる．まず，多くの LLM で採用されているトークナイザーはバイト境界を保持しないため，記号レベルでの正確な抽出操作が本質的に困難である [7]．また，入力長の増加に伴い情報の検索精度が低下する現象も報告されており [8]，バイナリ解析という極めて厳密な精度が要求されるタスクにおいて，これらの制約は致命的なボトルネックとなる．その結果，「API の呼出し形式を生成できる手続き的能力」と「非構造化データから正確に引数を切り出す実質的なグラウンディング能力」との間に重大な乖離が生じることが想定される．

先行研究 [9] では，この低レイヤー操作能力を定量的に評価するための動的ベンチマーク手法を提案した．しかし，多様なモデルにおいてどのような構造的な制約がこの「信頼性の天井」を決定づけているのか，また外部ツールの提供が実質的にどの程度の補完性を有するのかという点については十分に解明されていない．

そこで本研究では，先行研究で提案したベンチマークを拡張し，評価対象モデルおよび制御変数を大幅に拡充することで，低レイヤーのデータグラウンディング能力における構造的なボトルネックを特定する．具体的には，48 種類のモデル構成を用い，入力長，推論コスト（Reasoning Effort），テキスト表現の 3 次元から分析を行うことで，単なる正解率の比較に留まらない能力特性の定量化を試みる．

本研究の主な貢献は以下のとおりである：

- 低レイヤー操作における構造的問題の特定: パラメータ数と抽出能力が乖離する「Blind Giant 現象」，手続き的能力と実質的抽出能力の差を示す「Grounding Gap」，内部解釈とツール整形に最適な表現が相反する「エンコードのジレンマ」という 3 つの構造的な制約を明らかにした．
- モデルの認知特性の分類: 手続き的能力と実質的抽出能力を用いたマトリクス分析を導入し，モデルを「全能型」「構造依存型」「記号操作特化型」などの能力特性に分類する分析フレームワークを構築した．
- 信頼性の天井を突破するための設計指針の提示: 分析結果に基づき，「最新性ベースのモデル選定」，「適応型コンテキストエンジニアリング」，および「思考と実行の完全分離」という，堅牢なバイナリ解析エージェント構築のための具体的な設計指針を導出した．

2. 関連研究

自律型 AI エージェントを用いたバイナリ解析や CTF 課題解決の研究が進展しており，EnIGMA[2] のような自動評価環境や，「観察 → 理解 → 計画」のループによる振る舞い分析 [1] などが提案されている．しかし，これらの多くはパス率（pass@k）等のエンドツーエンドな成功率を指標としており，失敗の原因がドメイン知識の不足，高次な計画策定の誤り，あるいは低レイヤーでのデータ抽出ミスによるものかを分離して特定することが困難である．初期段階のデータ処理失敗がシステム全体の成否に決定的な影響を与えるため，低レイヤー操作能力を独立して評価することは喫緊の課題といえる．

バイナリデータの正確な操作には，LLM 特有のトークナイゼーションおよび文脈処理の制約が影響する．長文脈処理において情報の位置により精度が変化する「Lost in the Middle」現象 [8] や，多文字トークン採用による文字単位操作の不安定性 [7] が報告されており，これらはバイト境界の認識を要するバイナリデータにおいてより顕著に現れると考えられる．このような低レイヤーでの不整合は，後続工程へ誤りを伝播させシステム全体の信頼性を損なう「silent cascade」を招くリスクがあり [3]，入力表現への頑健性が解析性能の実効的な上限を決定づける重要な要因となる [5], [6]．したがって，形式的なツール利用能だけでなく，コンテキストから正確にデータを切り出す Grounding 精度の定量化が不可欠である．

既存のバイナリ解析評価は高次の振る舞いに重点を置いており，最上流のデータ解釈精度というボトルネックが不可視化されている．そこで本研究では，先行研究 [9] の動的ベンチマークを拡張し，テキスト表現されたバイナリシーケンスから指定範囲を正確に特定・抽出する「バイト範囲の位置特定・操作能力」を分離評価する．本ベンチマークは，既存の実践的な解析評価を置き換えるものではなく，その前提となる低レイヤー能力を診断し，エージェントの信頼性の天井を特定するための補完的なマイクロベンチマークとして位置付けられる．

3. 提案手法

本研究では，先行研究 [9] で提案した動的ベンチマークを拡張し，バイナリ解析における低レイヤーのデータグラ

© 2026 Information Processing Society of Japan

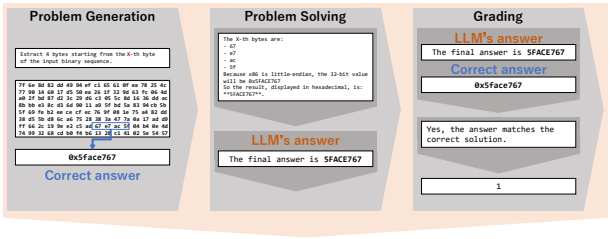


図 1　先行研究の概要

ウンディング能力を構造的に分析する手法を用いる．本稿では特に，モデルの手続き的なツール利用能力と実質的な抽出能力の乖離（Grounding Gap）を定量化するため，制御変数の拡充および新たな評価指標を導入した．これにより，モデルサイズやリリース時期がデータ操作能力に与える影響を詳細に分析することが可能となった．先行研究の全体像を図 1 に示す．

3.1　動的ベンチマーク（先行研究）の基本設計

先行研究ではデータ汚染を排除するため評価時に問題をランダムに生成している（詳細なアルゴリズムについては付録に掲載）．具体的には，長さ L_j のランダムなバイナリシーケンスから指定範囲の 4 バイトを抽出し，リトルエンディアン整数として回答させるタスクである．

また，最新モデルにおける冗長な思考過程（Chain-of-Thought）に伴うノイズを排除し，実質的な抽出能力のみを測定するため，以下の二段階応答プロセスを採用している．まず，タスクに対する直接的な回答を得る一次回答を取得し，その後，モデル自身に最終回答を抽出させる二次回答を取得する．

正誤判定には LLM-as-a-Judge を採用し，予備実験（本研究における予備実験は付録に掲載）で選定した能力の高い 3 種類のジャッジ用モデルによる多数決によって決定している．これにより，形式的な出力の揺らぎを排除した厳密な評価が可能となっている．

3.2　構造的分析のための制御変数の拡張

先行研究では基礎的な抽出能力の測定に重点が置かれていたが，本稿ではモデルの能力限界と信頼性の天井を詳細に特定するため，以下の 3 つの次元で独立変数を拡張した．

第一に，入力長 $\mathcal{L}$ の拡大である．コンテキスト長の増加に伴う抽出精度の劣化曲線を定量化し，物理的なウィンドウ制限ではなく，実質的なデータグラウンディング能力の限界点を測定するため，入力長を $\mathcal{L} = \{16, 32, 64, 128, 256, 512, 1024\}$ まで拡張した．

第二に，Reasoning Effort の導入である．最新の推論特化型モデルにおいて，思考時間および生成トークン数の増分が低レイヤー操作精度に寄与するかを検証するため，Reasoning Effort 設定（low/medium/high 等）を独立変数として定義した．これにより，「思考の深化」による正解率向上と，冗長な推論に伴う出力制限（トークン上限）という物理的ボトルネックの相関を分析する．

第三に，**エンコーディングの階層化**である．モデルに課される負荷レベルに応じて，表現形式を以下の 3 つの階層として再定義した．

- 記号的操作階層: Raw (Partial escaping), Hex-NS (Hex no split), Hex-S (Hex split) の 3 種であり，純粋なバイト境界の認識および抽出能力を測定する．
- 構造的補助階層: D-NA (Dump w/o Ascii), D-A (Dump w/ Ascii) の 2 種であり，絶対アドレス等のガイドポスト付与による位置特定能を測定する．
- 意味論的推論階層: C&D-NA (Code & Dump w/o Ascii), C&D-A (Code & Dump w/ Ascii) の 2 種であり，「プログラム解釈 → アドレス算出 → 抽出」という多段階の推論プロセスを要求する．

3.3　分析指標と能力の定義

本研究では，モデルのバイナリ操作能力を，以下の二つの独立した次元で定義し，定量的に評価する．

第一に，データグラウンディング能力である．これは，非構造化テキストから指定されたバイト範囲を正確に特定し，抽出・操作する基盤的な能力を指す．本能力は，モデルが自力で回答を導出する場合と，外部ツールの引数を生成する場合のいずれにおいても要求される最上流の基盤能力である．

第二に，手続き的準拠能力である．これは，外部ツールの API スキーマや呼出し形式（JSON 構造や関数名等）に厳密に従ってテキストを生成する能力を指す．本能力はインターフェースの形式的な準拠性を司るものであり，抽出されるデータの正誤とは独立した次元の能力である．

これらの能力を測定するため，以下の指標を用いる．

3.3.1　Tool Calling Compliance Rate (TCR)

外部ツールの提供条件下において，モデルが生成したツール呼び出しが構文的に妥当である割合を TCR と定義する．

$$\mathrm{TCR} = \frac{\text{Number of Syntactically Valid Tool Calls}}{\text{Total Number of Samples}} \tag{1}$$

ここでいう構文的な妥当性とは，API スキーマへの準拠および引数としての 16 進数文字列が正しくパース可能であることを指し，引数の値（オフセット等）の正誤は問わない．TCR は，モデルがツール利用という形式的な手続きを習得しているかを測定する指標となる．

3.3.2　Grounding Gap の定式化

内部的な抽出能力を示す総合スコア $\mathrm{Score}_{\mathrm{without}}$ と，ツール補完後の総合スコア $\mathrm{Score}_{\mathrm{with}}$ を定義し，その差分である Tool Benefit ($\Delta\mathrm{Score} = \mathrm{Score}_{\mathrm{without}} - \mathrm{Score}_{\mathrm{with}}$) を測

© 2026 Information Processing Society of Japan

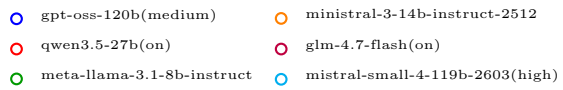


図 2 Legend of Representative Model Configurations

定する．

さらに，手続き的能力を示す TCR とツール補完後の成功率を示す $\text{Score}_{\text{with}}$ の間に存在する乖離を Grounding Gap と定義する．具体的に TCR $\gg \text{Score}_{\text{with}}$ である状態は，ツールの使い方は熟知しているが，コンテキストから正しい引数を切り出す基礎能力が欠如していることを意味し，このギャップの存在こそが外部ツールによる補完を機能させる上でのクリティカルパスとなる．

4. 分析

本章では，先行研究のベンチマークを用いて，多様な LLM におけるバイナリシーケンスの解釈・操作能力を定量的に実験・評価し，分析した結果について述べる．本分析の目的は，モデルのリリース時期，パラメータサイズ，テキスト表現，および外部ツールの提供が，低レイヤーのデータグラウンディング能力にどのような影響を与えるかを明らかにすることである．

4.1 実験設定

4.1.1 実行環境および推論基盤

計算リソースとして NVIDIA GB10 チップを搭載した DGX Spark を使用した．GB10 は FP4 精度において最大 1 PFLOP の演算性能を有し，128GB のコヒーレントメモリを搭載しているため，最大で 200B 規模のモデルまで動作させることが可能である．推論基盤には LM Studio を採用し，バックエンドとして llama.cpp を利用した．評価対象となるモデルはすべて GGUF 形式の 4 ビット量子化（`Q4_K_M`，`Q4_K_S` 等）を適用したものである．サンプリングパラメータについては，各モデルの開発元が推奨するデフォルト設定に従い，本来の能力を最大限に引き出す構成とした．

また，一部の実験は Mac mini 等の異なるハードウェア環境で実施されたが，これらの結果は第 3 章で述べた正規化手法に基づき，DGX Spark の時間尺度に合わせて変換し，マージして分析に用いている．

4.1.2 評価対象モデルとタスク構成

主要な LLM ファミリー（GPT-OSS, Gemma, Qwen, Llama, Mistral, Phi 等）の中から，LM Studio での動作が可能であり，かつ基盤モデルとしての特性を持つものを幅広く選定した．特に，推論コストの増分が操作精度に与える影響を分析するため，Reasoning Effort の設定を含む計 49 種類のモデル構成を評価対象とした． ただし，分析の明快さを期すため図表では以下の基準で選定した代表的なモデル（**図 2**：Featured Models）を強調して表示している：(1) 各サイズ帯における最高性能モデル，(2) リリース時期による性能飛躍を象徴する新旧モデル，(3) Grounding Gap が顕著に現れたモデル．これらの詳細な個別の挙動については，第 5 章の考察で詳述する．

Rank	Model Name	Score (%)	TOKs	Time
1	gpt-oss-120b(medium)	$79.57^{\pm 4.1}$	2462	53.12
2	qwen3.6-27b(off)	$67.11^{\pm 4.6}$	3085	220.58
3	gpt-oss-120b(high)	$64.35^{\pm 4.7}$	5274	116.21
4	gemma-4-31b(on)	$63.04^{\pm 4.7}$	4176	371.27
5	qwen3.6-35b-a3b(off)	$62.73^{\pm 4.7}$	3446	60.12
6	qwen3.6-27b(on)	$61.44^{\pm 4.7}$	5807	409.86
7	qwen3.5-27b(off)	$56.91^{\pm 4.8}$	3957	284.54
8	gpt-oss-20b(medium)	$56.65^{\pm 4.8}$	3875	61.04
9	qwen3.5-35b-a3b(off)	$56.54^{\pm 4.8}$	4154	78.29
10	qwen3.5-27b(on)	$55.87^{\pm 4.8}$	4016	297.00
11	gpt-oss-120b(low)	$52.66^{\pm 4.7}$	576	13.79
12	gemma-4-31b(off)	$51.81^{\pm 4.8}$	692	62.43
13	qwen3.5-122b-a10b(on)	$49.96^{\pm 4.8}$	5961	245.18
14	qwen3.5-122b-a10b(off)	$47.25^{\pm 4.7}$	5958	245.41
15	gemma-4-26b-a4b(off)	$45.83^{\pm 4.7}$	1027	22.71

表 1 Baseline Performance Leaderboard (Without External Tools)

評価タスクは，第 3 章で定義した 7 種類のテキストエンコーディングと入力長 $\mathcal{L} = \{16, 32, 64, 128, 256, 512, 1024\}$ の組み合わせで構成される．外部ツールの提供に関しては，LM Studio の OpenAI API 互換 Function Calling 機能を利用し，引数の正当性に基づき TCR を判定した．

4.1.3 実験的制約

実用的な計算コストと推論時間の観点から，モデルが出力するトークン数は最大 8,192 TOKs に制限している．本実験における各ケースの試行回数は $N = 20$ と設定した．全構成において合計で 89,180 回の独立したテストを実施し，個別の変動に依存しない構造的な傾向を特定することを目指した．

4.2 内部的なデータグラウンディング能力の分析

本節では，外部ツールの利用を一切禁止し，モデルが提示されたコンテキストのみを用いて回答を導出する条件（ツールなし）において，非構造化バイナリシーケンスに対する内部的なデータグラウンディング能力を定量的に評価・分析する．これにより，モデルが本来備えている記号操作能力の正体と，その限界点を明らかにする．

4.2.1 総合性能とリリース時期による能力的飛躍

まず，全エンコーディングおよび入力長を統合した総合スコアの結果を**表 1** に示す．最高精度を記録したのは `gpt-oss-120b(medium)` であり，極めて高い正解率を示した．

© 2026 Information Processing Society of Japan

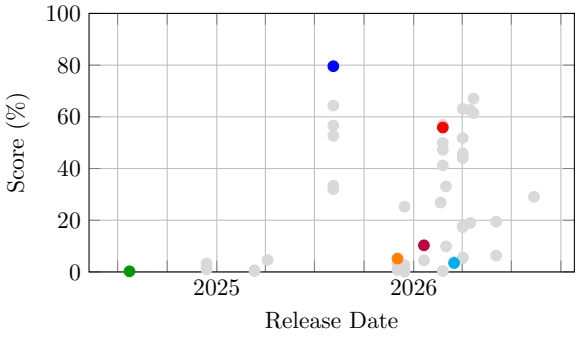


図 3 Temporal Evolution of Low-Level Grounding Capability

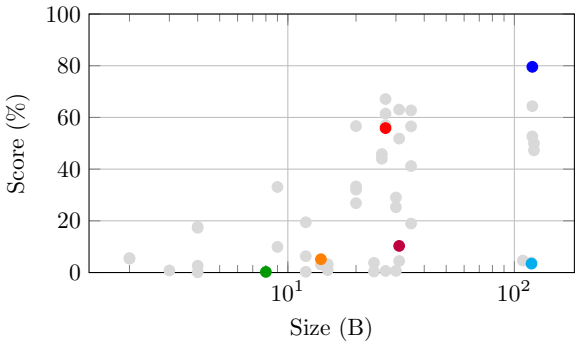


図 4 The “Blind Giant” Phenomenon

注目すべきは，モデルのリリース時期と正答率の間に認められる極めて強い相関である（**図 3**）．2024 年までのモデルでは正答率が低迷していたのに対し，2025 年後半から 2026 年にかけてリリースされた最新モデル（GPT-OSS, Gemma 4, Qwen 3.6 等）において，性能が飛躍的に向上していることが確認された．この傾向は中小型モデルにおいても共通して見られることから，単なる知識量の拡充ではなく，非構造化データからの位置特定および低レイヤーコードの解釈という，「基盤的な推論能力」そのものが質的に進化していることを示唆している．

4.2.2 パラメータ数と抽出能力の不整合（Blind Giant 現象）

次に，モデルの静的な規模であるパラメータ数と，動的な性能である正答率の関係を分析した結果，深刻な不整合が明らかになった（**図 4**）．

図に示される通り，100B を超える巨大なパラメータ数を有しながらも，最新の中小型モデルに正解率で大きく劣るモデル群（`mistral-small-4-119b-2603` 等）が存在することが確認された．我々はこれを「Blind Giant 現象」と呼ぶ．この結果は，低レイヤーのデータグラウンディング能力が単なるパラメータ数の拡大とは独立した次元で進化していることを示している．旧世代の巨大モデルがバイナリデータを一種の特殊な文字列としてパターンマッチング的に処理していたのに対し，最新モデルはバイト列をインデックスを持つ構造体として捉え，内部的にシンボリックな操作を実行できている可能性が高いと考えられる．

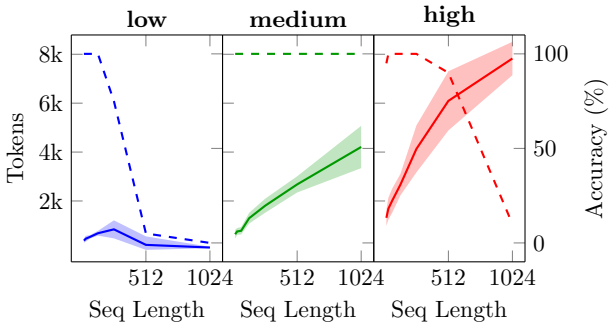


図 5 The Paradox of Reasoning Effort

4.2.3 推論コストと物理的制約の相関分析

最後に，Reasoning Effort の設定が精度に与える影響を分析した（**図 5**）．

`gpt-oss-120b` を用いた解析の結果，Effort 設定を low から `high` へ引き上げることで，短・中長のシーケンスに対する正解率は向上する傾向にあることが確認された．これは，思考時間の増分が内部的な自己検証プロセス（CoT）の深化に寄与し，抽出精度の向上に結びついていることを示している．

しかし，`high` 設定において入力長が 1,024 バイトに達した場合，正解率は約 10% まで急落するという逆説的な挙動が確認された．このとき生成トークン数は上限（8,192 TOKs）近くまで到達しており，モデルが高度な自己検証を行った結果，最終的な回答を出力する前に物理的なバッファ制限により強制終了されたことを意味している．この現象は，LLM による低レイヤー操作がいかに冗長なエミュレーションプロセスであるかを象徴しており，内部推論のみに依存することの物理的・計算資源的な限界を露呈させている．この知見は，次節で述べる「ツールへの委譲」の必要性を強く支持するものである．

4.3 手続き的準拠能とデータグラウンディング能力の乖離分析

本節では，外部ツールの提供がモデルの解析性能をどの程度底上げするかを検証し，その限界を決定づける要因について分析する．具体的には，手続き的な形式準拠性を示す TCR と，実質的な抽出成功率を示す $\text{Score}_{\text{with}}$ の相関に着目し，両者の乖離がツール補完性に与える影響を明らかにする．

4.3.1 グラウンディングギャップの特定

まず，ツールの構文的準拠率 (TCR) と内部的な正解率 ($\text{Score}_{\text{with}}$) の相関を図 6 に示す．本図において，$\text{TCR} = \text{Score}_{\text{with}}$ となる対角線は，手続き的な形式準拠性とツール補完後の成功率が均衡している状態を示す基準となる．

分析の結果，多くのモデル，特に中小規模のモデル群がこの対角線の下側（$\text{TCR} > \text{Score}_{\text{with}}$）に分布することが

© 2026 Information Processing Society of Japan

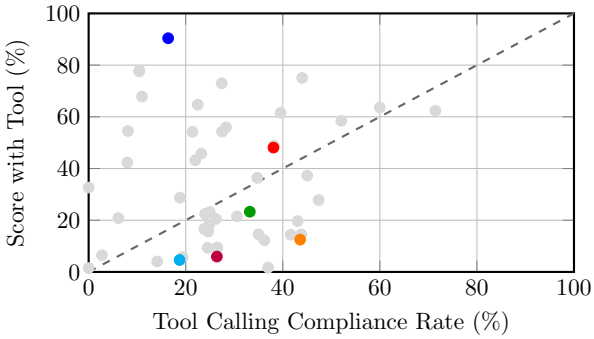


図 6 Quantifying the Grounding Gap in all Encoding

確認された．これは，API スキーマへの準拠という手続き的準拠能は習得しているが，コンテキストから正しい値を切り出す基盤的なデータグラウンディング能力が著しく不足している状態であり，本稿ではこの乖離をグラウンディングギャップと定義する．

この現象は，外部ツールの提供による性能向上の恩恵を受けるためには，単にツールを正しく呼び出せること以上に，ある一定水準の基盤的なデータグラウンディング能力を備えていることが不可欠な前提条件であることを示唆している．具体的にグラウンディングギャップが顕著なモデルにおいては，ツールを提供しても引数の生成段階でエラーが生じるため，正解率の向上は極めて限定的となる．

4.3.2 能力マトリクスによる認知特性の分類

単なる正答率の比較では，ツールによる補完か自力での解決かという因果関係を分離できない．そこで本研究では，TCR，$\text{Score}_{\text{with}}$，およびツール導入による正解率の変動量 ($\Delta$Score) を組み合わせた 3×2 能力マトリクスを導入し，モデルの認知特性を分類する．

本フレームワークでは，縦軸に TCR と $\text{Score}_{\text{with}}$ の相対関係による傾向（直感的傾向：$\text{Score}_{\text{with}} >$ TCR / 手続き的傾向：$\text{Score}_{\text{with}} <$ TCR）を配置し，横軸に ΔScore の変動量（増加/不変/減少）を配置する．これにより，モデルを以下の 6 つのパターンに分類できる．

(1) 相乗的直感型: 直感的傾向でありつつ，ツール併用でさらに精度が向上する理想的な統合状態．該当モデルなし．

(2) 純粋内部完結型: 直感的傾向であり，ツールの有無に関わらず内部能力のみで正解を導出している状態．`gpt-oss-120b` 等

(3) ツール干渉型: 直感的傾向だが，ツールの手続き的制約やフォーマット整形がノイズとなり，むしろ精度が低下する状態．`qwen3.5-27b` 等

(4) 有効補完型: 手続き的傾向だが，最低限のグラウンディング能力をツールで補完し，劇的に性能を向上させる状態．`meta-llama-3.1-8b` 等．

(5) 空虚な手続き主義型: 手続き的傾向であり，API 形式は習得しているが実質的な抽出能力が絶望的に欠如しているため，ツールを導入しても精度が変わらない状態．`ministral-3-instruct-2512` 等

(6) 整形崩壊型: 手続き的傾向かつ脆弱であり，ツール利用に伴う整形負荷によって内部推論すら破壊され，精度が低下する状態．`glm-4.7-flash` 等

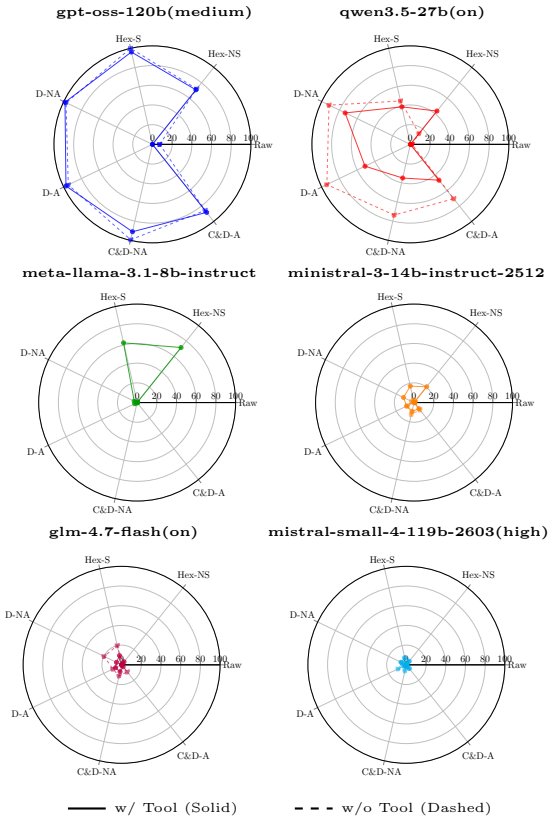


図 7 Classification of LLM Capability Personas

この分類により，モデルが単に正解率が高いか低いかという評価ではなく，ツールを介して能力を拡張できる状態あるいは形式的な作法のみを習得している状態という構造的な特性を定量的に特定することが可能となる．

4.4 テキスト表現による能力変動とエンコードのジレンマ

本節では，テキスト表現（エンコーディング）の変化が，データグラウンディング能力およびツールの有効性に与える影響を分析し，バイナリ解析における構造的なトレードオフについて述べる．

まず，モデルがテキスト表現に対してどのような依存性を持つかを明らかにするため，**図 7**（具体的な数値については付録に掲載）に示すツール未使用時の正解率（図 7 の破線部分）の変動傾向に基づき，モデルを以下の三つの能力特性に分類する．

- 全能型：表現形式に依存せず，常に高いデータグラウンディング能力を発揮するタイプ．
- 構造依存型：Dump 系などの構造化データでは高い能力を示すが，非構造的な Hex-NS 等では著しく精度が低下する，補助情報への依存性が高いタイプ．

© 2026 Information Processing Society of Japan

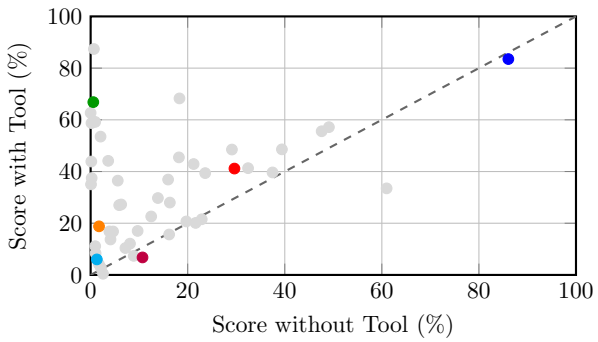


図 8 Tool Benefit: Hex-type

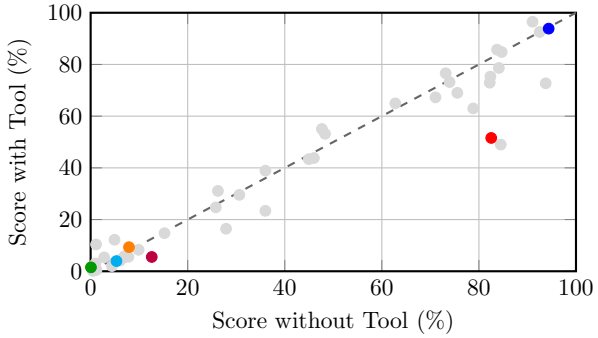


図 9 Tool Benefit: Dump-type

- 記号操作特化型：内部的な意味解釈は困難だが，ツールを介した単純な抽出などの限定的な操作のみ遂行可能なタイプ．

この分類を踏まえ，特に構造依存型の代表例である `qwen3.5-27b(on)` の挙動に着目する．同モデルを見ると，絶対アドレスや区切り文字を含む Dump 系形式では極めて高い正解率を示す一方で，非構造的な Hex-NS 形式になると正解率が著しく低下することが確認できる．このことは，一部のモデルにおいて内部的なデータグラウンディング能力を正しく行使するためには，テキスト上の視覚的なガイドポストが不可欠であることを示している．

しかし，ツール導入による性能（図 7 の実線部分）向上幅 (ΔScore) を分析すると，これとは相反する傾向が現れる．**図 8** および **図 9** に示す通り，ツールによる恩恵が最大となるのは，内部能力が最も低かった Hex 系であり，逆に構造化された Dump 系ではツールの導入による正解率の上積みがほとんど見られない．

この結果は，モデルが直面する二つの相反する負荷の存在を浮き彫りにしている．第一に，自力で値を特定する際に生じる内部グラウンディング負荷であり，これは構造化データによって軽減される．第二に，ツール呼び出しに必要な引数を生成する際に生じる手続き的整形負荷である．Dump 系のようにノイズ（アドレスや ASCII 列）が多い表現では，これらを除去して純粋な 16 進数へと再構成するコストが増大し，手続き的準拠能への悪影響を及ぼす．一方，Hex-NS のような形式は LLM 単体でのバイナリ操作こそ困難だが，抽出した部分文字列をそのまま引数として渡せるため，整形負荷が最小限となる．

このように，内部的なデータグラウンディングを最大化する表現（構造化データ）とツール呼び出しの手続き的整合性を最大化する表現（16 進数）が相反するという対立関係を，我々は「エンコードのジレンマ」と定義する．

本分析により，単一のエンコーディングを選択して最適化することは困難であり，解析・思考フェーズとツール実行フェーズで表現形式を動的に切り替える適応型のコンテキストエンジニアリングが，堅牢なバイナリ解析エージェント構築における不可欠な戦略であることが示唆された．

5. 考察

5.1 バイナリ操作における構造的制約

本研究で特定した 3 つの構造的問題（Blind Giant 現象，Grounding Gap，エンコードのジレンマ）は，LLM が非構造化バイナリデータを処理する際の根本的なメカニズムに起因すると考えられる．

プログラムによるバイナリ操作がメモリ上のオフセットに基づく直接的なインデックス参照であるのに対し，LLM はバイナリをテキストとして受け取り，言語的な推論を用いて処理する．ここで，低レイヤーの抽出操作はネイティブな参照ではなく，「1 バイト目，2 バイト目……」と逐次的にカウントし自己修正を繰り返す，極めて冗長で脆弱な「擬似エミュレーション」である点に本質的な制約がある．

この構造的制約が，特定した 3 現象を同時に引き起こしていると考えられる．まず Blind Giant 現象は，単なるパラメータ数の拡大ではこの言語的エミュレーションの精度は向上せず，データを構造体として捉える質的な転換が必要であることを示唆している．またグラウンディングギャップは，API 形式を生成する高次の言語能力と，バイト境界を数え上げる低レイヤーの記号操作能力が，内部的に完全に分離した次元で存在することを意味する．そしてエンコードのジレンマは，エミュレーションを補助する構造化データが，ツール呼び出し時の整形負荷という新たな手続き的コストと衝突するという矛盾を表している．

以上の考察から，LLM による内部推論のみに依存した低レイヤー操作は本質的に非効率であり，物理的・計算資源的な限界が存在することが明らかとなった．この知見は，次節で述べる「思考と実行の完全分離」という設計指針の強力な根拠となる．

5.2 自律型バイナリ解析エージェントへの設計指針

LLM による低レイヤー操作は本質的に非効率な擬似エミュレーションであり，その精度はパラメータ数や手続き的な習熟度とは独立した次元で決定される．この知見に基づき，堅牢な自律型バイナリ解析エージェントを構築するための 3 つの設計指針を提案する．

© 2026 Information Processing Society of Japan

(1) 能力ベースのモデル選定: 汎用ベンチマークではなく，低レイヤー操作の実測値を最優先基準とする．特にTCR（形式準拠性）のみならず，$\text{Score}_{\text{with}}$ を測定し，Grounding Gap の有無を確認すべきである．

(2) 適応型コンテキストエンジニアリング: 解析・思考フェーズでは構造化形式（Dump 系）を用いて内部解釈を支援し，ツール実行フェーズでは整形負荷を最小化した形式（Hex 系）へ変換して受け渡すオーケストレーションを導入する．

(3) 思考と実行の完全分離: 冗長な CoT によるトークン枯渇を避けるため，低レイヤー操作を LLM 内部で完結させず，確定したオフセットに基づくツール呼び出しへと徹底的に委譲させるアーキテクチャを採用する．

これらの指針を統合し，低レイヤーのデータグラウンディングという信頼性の天井を突破することで，真に自律的なバイナリ解析エージェントの実現できると考える．

5.3 本研究の限界と今後の課題

本研究では動的ベンチマークを用いて低レイヤー操作能力の構造的問題を明らかにしたが，以下の 3 つの限界点が存在する．

第一に，統計的有意性の制約である．本研究では合計して数万回という膨大な試行を通じてマクロな傾向を特定したが，各条件の試行回数は $N = 20$ としており，上位モデル間の微視的な性能差を断定するには不十分である．今後は試行回数を拡大し，モデルごとの微視的な性能比較をできるようにしたい．

第二に，評価データの性質による制約である．データ汚染を排除するため意図的にランダムなバイト列を用いたが，実在のバイナリに含まれるマジックナンバーやアライメント等の構造的ヒントが精度に寄与する可能性がある．本研究の結果は構造的な補助がない環境下での信頼性の最低ラインを診断したものであると解釈すべきである．今後は実在ファイルを用いた評価を行い，これらのヒントがグラウンディング能力に与える影響を検証したい．

第三に，タスクの複雑性の制約である．本研究は単一操作の正確性を測定する「ユニットテスト」的な評価に留まっており，実際の解析に不可欠なマルチステップな推論プロセスを網羅していない．今後は，複数のツールを連鎖的に利用させるインテグレーションテスト的な評価指標の構築に取り組む．

これらの課題を解決することで，モデルの選定からコンテキストエンジニアリング，アーキテクチャ設計までを一貫して最適化することで，より実践的なバイナリ解析 AI エージェントを実現したい．

6. おわりに

本稿では，LLM のバイナリ操作能力を定量的に評価し，「Blind Giant 現象」「Grounding Gap」「エンコードのジレンマ」という 3 つの構造的制約を特定した．これにより，低レイヤーのデータグラウンディング能力が，パラメータ数とは独立に進化していること，およびその能力不足がエージェント全体の信頼性の天井となることを明らかにした．

これらの知見に基づき，堅牢なバイナリ解析エージェント実現のための指針として，「実測値ベースのモデル選定」「適応型コンテキストエンジニアリング」，「思考と実行の完全分離」を提案する．本研究による能力定量化が，今後の自律型 AI エージェント構築における信頼性保証の基盤となることを期待する．

参考文献

[1] Nishizaka, R., Fujiwara, Y., Shimizu, T., Kato, K. and Sugiyama, Y.: Towards LLM-Resistant Software Protection: Agent Failure Patterns in CTF Reverse Engineering, *Proceedings of the NDSS Workshop on Binary Analysis Research*, (online), DOI: 10.14722/bar.2026.23058 (2026).

[2] Abramovich, T., Udeshi, M., Shao, M., Lieret, K., Xi, H., Milner, K., Jancheska, S., Yang, J., Jimenez, C. E., Khorrami, F., Krishnamurthy, P., Dolan-Gavitt, B., Shafique, M., Narasimhan, K. R., Karri, R. and Press, O.: EnIGMA: Interactive Tools Substantially Assist LM Agents in Finding Security Vulnerabilities, *Forty-second International Conference on Machine Learning* (2025).

[3] Zambelli, A. E.: Forge: Closing the Agentic Reliability Gap Between Self-Hosted and Frontier Language Models, *Proceedings of the ACM Conference on AI and Agentic Systems*, pp. 1288–1292 (online), DOI: 10.1145/3786335.3813193 (2026).

[4] Boucher, N. and Anderson, R.: Trojan source: Invisible vulnerabilities, *32nd USENIX security symposium (USENIX Security 23)*, Anaheim, CA, USENIX Association, pp. 6507–6524 (2023).

[5] Jiang, Y., Huang, S., Treude, C., Su, X. and Wang, T.: Shield Broken: Black-Box Adversarial Attacks on LLM-Based Vulnerability Detectors, *IEEE Transactions on Software Engineering*, Vol. 52, No. 1, pp. 246–265 (online), DOI: 10.1109/TSE.2025.3638998 (2026).

[6] Yu, X., Li, Z., Huang, X. and Zhao, S.: Advulcode: Generating adversarial vulnerable code against deep learning-based vulnerability detectors, *Electronics*, Vol. 12, No. 4, p. 936 (online), DOI: 10.3390/electronics12040936 (2023).

[7] Edman, L., Schmid, H. and Fraser, A.: CUTE: Measuring LLMs' understanding of their tokens, *Proceedings of the 2024 Conference on Empirical Methods in Natural Language Processing*, Miami, Florida, USA, Association for Computational Linguistics, pp. 3017–3026 (online), DOI: 10.18653/v1/2024.emnlp-main.177 (2024).

[8] Liu, N. F., Lin, K., Hewitt, J., Paranjape, A., Bevilacqua, M., Petroni, F. and Liang, P.: Lost in the Middle: How Language Models Use Long Contexts, *Transactions of the Association for Computational Linguistics*, Vol. 12, pp. 157–173 (online), DOI: 10.1162/tacl_a_00638 (2024).

[9] 大坪雄平，大塚　玲：バイナリ解析 AI エージェント用 LLM ベンチマークの試作，人工知能学会第二種研究会資料， Vol. 2026, No. SEC-005, p. 03（オンライン），DOI: 10.11517/jsaisigtwo.2026.SEC-005_03 (2026).

© 2026 Information Processing Society of Japan

Algorithm 1: Dynamic Benchmark for Binary Sequence Manipulation Ability

Input : A set of input lengths $\mathcal{L} = \{L_1, L_2, \ldots, L_{|\mathcal{L}|}\}$,
Number of trials per length N,
Text encoding methods enc $\in \mathcal{E}$, where $\mathcal{E}$ is the set of:
{Partial escaping, HEX(no split), HEX(split), Dump w/ Ascii, Dump w/o Ascii, Code & Dump},
Target LLM $F(\cdot)$, and a set of Judge LLMs $\{J_1, J_2, J_3\}$

Output: Accuracy Acc_j for each length $L_j \in \mathcal{L}$

for *each length* $L_j \in \mathcal{L}$ **do**
- Initialize correct count $C_j \leftarrow 0$;
- **for** $i = 1$ **to** N **do**
  - `// Step 1: Problem Generation`
  - Generate a random binary sequence $B_{j,i}$ of length L_j where each byte $b \sim U(0, 255)$;
  - Randomly select start position $p_{j,i} \sim U(\lfloor L_j/2 \rfloor, L_j - 3)$;
  - Compute the ground truth answer $T_{j,i} = \text{Extract}(B_{j,i}, p_{j,i})$;
  - Construct prompt $X_{j,i} = \text{GenPrompt}(B_{j,i}, p_{j,i}, \text{enc})$;
  - `// Step 2: Problem Solving (Two-stage Response)`
  - Obtain primary response $Y'_{j,i} = F(X_{j,i})$;
  - Construct extraction prompt $X'_{j,i} = \text{GenExtractPrompt}(Y'_{j,i})$;
  - Obtain secondary response (final answer) $Y_{j,i} = F(X'_{j,i})$;
  - `// Step 3: Grading via LLM-as-a-Judge`
  - Initialize votes $V \leftarrow 0$;
  - **for** *each judge* $J_k \in \{J_1, J_2, J_3\}$ **do**
    - If $J_k(T_{j,i}, Y_{j,i})$ is correct then $V \leftarrow V + 1$;
  - If $V \geq 2$ (majority vote) then $C_j \leftarrow C_j + 1$;
- Calculate accuracy $Acc_j = C_j/N$;

return $\{Acc_1, Acc_2, \ldots, Acc_{|\mathcal{L}|}\}$;

付　　録

A.1　ベンチマークの疑似コード

先行研究のベンチマーク評価パイプラインは，データ生成・モデル推論・LLM-as-a-Judge による採点を一貫して自動化している．評価スクリプトの論理フローを Algorithm 1 に示す．

A.2　信頼区間の算出方法と統計的解釈

本ベンチマークでは，各実験条件における試行回数が $N = 20$ と限定されているため，正答率の点推定値のみではモデル間の微細な性能差が真の能力差であるか，あるいはサンプリング変動によるものであるかを判定することが困難である．特に，入力長 L_j に応じた加重平均による総合スコアでは，各条件ごとの分散が累積するため，信頼区間（Confidence Interval, CI）を明示し，統計的な不確実性を評価することが不可欠である．本節では，ランキングテーブルで採用している CI の算出アルゴリズムおよび統計的解釈の方針について述べる．

A.2.1　加重平均スコアに対する信頼区間の算出

総合スコアは入力長を重みとした加重平均として定義される：

$$\text{Score} = \frac{\sum_{j=1}^{|\mathcal{L}|} L_j \cdot Acc_j}{\sum_{j=1}^{|\mathcal{L}|} L_j} = \sum_{j=1}^{|\mathcal{L}|} w_j Acc_j, \quad w_j = \frac{L_j}{\sum L_k} \tag{A.1}$$

各長さ L_j における正答率 Acc_j は二項分布に従う独立な確率変数とみなせる．したがって，加重平均の分散は，独立変数の線形結合の分散公式より次式で導出される：

© 2026 Information Processing Society of Japan

Rank	Model Name	Acc (%)	Time (s)	Eff
1	gpt-oss-20b(low)	$78.57^{\pm 6.8}$	7.80	9.93
2	gpt-oss-120b(low)	$95.00^{\pm 3.6}$	11.30	11.89
3	gemma-4-26b-a4b(off)	$87.14^{\pm 5.5}$	10.95	12.57
4	gpt-oss-120b(medium)	$95.00^{\pm 3.6}$	18.37	19.34
5	qwen3.6-35b-a3b(off)	$87.86^{\pm 5.4}$	17.09	19.45
6	gpt-oss-20b(medium)	$87.14^{\pm 5.5}$	22.99	26.39
7	qwen3.5-35b-a3b(off)	$85.00^{\pm 5.9}$	24.07	28.32

表 A·1 Preliminary Screening for Judge LLMs

$$\mathrm{Var}(\mathrm{Score}) = \sum_{j=1}^{|\mathcal{L}|} w_j^2 \cdot \mathrm{Var}(Acc_j) \approx \sum_{j=1}^{|\mathcal{L}|} w_j^2 \frac{\hat{p}_j(1-\hat{p}_j)}{N_j} \tag{A.2}$$

ここで $\hat{p}_j$ は長さ L_j における実測正答率，N_j はその長さにおける独立試行回数である．標準誤差 $SE = \sqrt{\mathrm{Var}(\mathrm{Score})}$ を用い，95%信頼区間は以下のように算出する：

$$\mathrm{CI}_{95\%} = [\max(0, \mathrm{Score} - 1.96 \cdot SE), \quad \min(1, \mathrm{Score} + 1.96 \cdot SE)] \tag{A.3}$$

端値付近での区間崩壊を防ぐため，結果は $[0,1]$ にクリッピングして適用している．

A.2.2 統計的解釈の方針：性能バンドの導入

本ベンチマークでは，信頼区間の重なりがあるモデル群は統計的に同等とみなし，厳密な順位付けではなく性能バンドとして解釈する方針を採っている．

これは，本研究の主目的が個別のモデル間の微視的な順位変動の特定ではなく，Blind Giant 現象や Grounding Gap といった構造的なマクロトレンドの特定にあるためである．したがって，信頼区間による重複が確認される範囲内においては，モデル間の性能差に統計的な有意性は認められないものとし，傾向の安定性を重視して分析を行う．

A.3 採点用 LLM の選定プロセスと正当性

本研究では，モデルの回答 Y と正解 T の整合性判定に LLM-as-a-Judge を採用している．先行研究 [9] においても同様の手法を用いているが，本研究においては以下の理由により，採点用 LLM の選定および構成を更新した．

本研究では評価対象モデルを拡充し，推論コストを制御する Reasoning Effort 設定を導入した．その結果，評価対象が 48 構成へと大幅に拡充された．これにより，評価用 LLM については，この 48 構成から改めて選定することで，より最適な評価用 LLM を選択している．

A.3.1 選定基準：効率性と精度のトレードオフ

採点用 LLM の選定にあたっては，単なる高性能さだけでなく，数万回に及ぶ判定処理を現実的な時間とコストで遂行するための「効率性」を重視した．そこで本研究では，正解率 p と平均処理時間 μ_{time} を用いた効率性指標 Eff を導入し，以下の通り定義した．

$$\mathrm{Eff} = \frac{\mu_{\mathrm{time}}}{p} \tag{A.4}$$

本指標は，「正解を 1 つ導出するために要する時間的コスト」を意味し，値が小さいほど計算資源の効率的に高い精度を実現していることを示す．

具体的に，最新の主要モデル群を候補とし，最も難易度が低いタスクである「16 バイトのバイナリシーケンスから 4 バイトを抽出する（Dump 形式）」条件下での正解率と処理時間を測定した．その結果を**表 A·1** および **図 A·1** に示す．

選定基準として，「高い正解率（$p \approx 1.0$）を維持しつつ，推論時間が極めて短い」，すなわち Eff が最小となる領域に位置するモデルを採用することとした．この基準に基づき，異なるモデルファミリーから以下の 3 モデルを選定した：

- `gpt-oss-20b(low)`
- `gemma-4-26b-a4b(off)`
- `qwen3.6-35b-a3b(off)`

© 2026 Information Processing Society of Japan

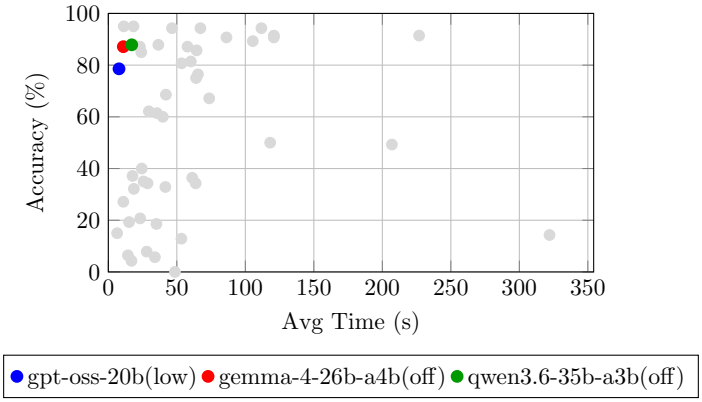


図 A·1 Judge Model Selection: Accuracy vs. Inference Efficiency

Model	Tool	Score (%)						
		Raw	Hex-NS	Hex-S	D-NA	D-A	C&D-NA	C&D-A
gpt-oss-120b(medium)	w/o	$7.36^{\pm 3.2}$	$72.13^{\pm 11.9}$	$100.00^{\pm 0.0}$	$97.40^{\pm 4.8}$	$94.88^{\pm 6.6}$	$99.37^{\pm 1.2}$	$85.83^{\pm 9.7}$
	w	—	$70.83^{\pm 11.7}$	$96.18^{\pm 5.4}$	$98.58^{\pm 1.7}$	$97.48^{\pm 4.8}$	$91.02^{\pm 7.7}$	$88.35^{\pm 8.7}$
qwen3.5-27b(on)	w/o	$1.65^{\pm 0.7}$	$14.06^{\pm 4.8}$	$45.20^{\pm 9.6}$	$91.73^{\pm 7.9}$	$94.17^{\pm 4.3}$	$73.66^{\pm 11.5}$	$70.59^{\pm 11.9}$
	w	—	$43.23^{\pm 12.5}$	$39.06^{\pm 10.7}$	$73.54^{\pm 11.7}$	$51.14^{\pm 11.7}$	$35.08^{\pm 11.3}$	$46.54^{\pm 12.5}$
meta-llama-3.1-8b-instruct	w/o	$0.31^{\pm 0.6}$	$0.04^{\pm 0.1}$	$1.06^{\pm 0.8}$	$0.16^{\pm 0.2}$	$0.12^{\pm 0.1}$	$0.00^{\pm 0.0}$	$0.00^{\pm 0.0}$
	w	—	$71.50^{\pm 11.3}$	$62.20^{\pm 12.1}$	$3.31^{\pm 2.0}$	$2.76^{\pm 1.7}$	$0.00^{\pm 0.0}$	$0.00^{\pm 0.0}$
ministral-3-14b-instruct-2512	w/o	$1.02^{\pm 0.6}$	$0.59^{\pm 0.5}$	$2.87^{\pm 1.4}$	$2.60^{\pm 1.5}$	$7.20^{\pm 6.0}$	$12.36^{\pm 7.5}$	$9.45^{\pm 4.4}$
	w	—	$20.47^{\pm 8.7}$	$17.13^{\pm 8.2}$	$11.89^{\pm 6.4}$	$8.39^{\pm 4.3}$	$9.09^{\pm 6.3}$	$7.95^{\pm 4.2}$
glm-4.7-flash(on)	w/o	$0.35^{\pm 0.4}$	$1.42^{\pm 0.8}$	$19.96^{\pm 7.3}$	$19.84^{\pm 9.3}$	$9.80^{\pm 4.3}$	$11.57^{\pm 6.8}$	$9.17^{\pm 6.3}$
	w	—	$3.94^{\pm 4.9}$	$9.61^{\pm 3.7}$	$5.75^{\pm 2.6}$	$6.81^{\pm 2.8}$	$7.13^{\pm 6.7}$	$2.44^{\pm 2.7}$
mistral-small-4-119b-2603(high)	w/o	$0.24^{\pm 0.3}$	$0.63^{\pm 0.4}$	$1.93^{\pm 0.8}$	$4.61^{\pm 3.5}$	$9.25^{\pm 7.9}$	$6.22^{\pm 6.7}$	$1.22^{\pm 1.3}$
	w	—	$4.61^{\pm 3.1}$	$7.40^{\pm 6.1}$	$6.02^{\pm 4.0}$	$2.87^{\pm 1.3}$	$2.09^{\pm 1.8}$	$4.76^{\pm 3.3}$

表 A·2 Detailed binary manipulation Score

A.3.2 判定メカニズムと信頼性の検証

選定した 3 モデルによる独立な判定を行い，その多数決によって最終的な正誤を決定することで，単一モデルに起因するバイアスや揺らぎを排除している．

また，この自動採点システムの信頼性を担保するため，本実験からランダムに 100 件のサンプルを抽出し，人手判定と比較検証を行った．その結果，採点用 LLM による多数決判定と人手による判定は完全に一致したことが確認された．これにより，更新後のジャッジ構成が最新モデルの多様な出力形式に対しても十分な判定精度を有していることが実証された．

A.4 詳細な性能評価結果

本章では，第 4 章および第 5 章における分析の根拠となった，外部ツールを使用しない条件下でのモデル別・エンコーディング別の正答率の詳細を示す．このデータにより，各モデルがどの表現形式において Grounding 能力を発揮し，あるいは限界を迎えているかを定量的に確認することが可能である．

A.5 評価対象モデル一覧

本研究で評価したモデルの一覧を**表 A·3** に示す．表における Acc は Raw を除いた 6 つのエンコード方式の Acc の平均値を示している．

© 2026 Information Processing Society of Japan

Model	Score w/o (%)	Score w/ (%)	Δ Score (%)	TCR (%)	Size (B)	Release
meta-llama-3.1-8b-instruct	0.2	23.3	+23.1	33.2	8	2024-07
phi-4	1.1	4.1	+2.9	14.1	15	2024-12
phi-4-reasoning-plus	3.8	1.5	-2.3	0.0	15	2024-12
gemma-3-12b	0.4	19.7	+19.3	43.1	12	2025-03
gemma-3-27b	0.7	27.8	+27.1	47.4	27	2025-03
llama-4-scout-17b-16e-instruct	5.4	21.5	+16.1	30.6	109	2025-04
gpt-oss-20b(low)	37.0	43.2	+6.2	22.0	20	2025-08
gpt-oss-20b(high)	38.8	42.3	+3.6	8.0	20	2025-08
gpt-oss-20b(medium)	65.7	67.8	+2.2	11.0	20	2025-08
gpt-oss-120b(low)	61.0	73.0	+12.0	27.4	120	2025-08
gpt-oss-120b(high)	74.8	77.9	+3.1	10.4	120	2025-08
gpt-oss-120b(medium)	91.6	90.4	-1.2	16.4	120	2025-08
ministral-3-3b	0.9	1.7	+0.8	37.0	3	2025-12
nemotron-3-nano-4b(off)	0.1	15.7	+15.6	24.6	4	2025-12
nemotron-3-nano-4b(on)	3.1	18.3	+15.2	24.8	4	2025-12
ministral-3-14b-reasoning	3.5	37.3	+33.8	45.0	14	2025-12
ministral-3-14b-instruct-2512	5.8	12.5	+6.6	43.6	14	2025-12
nemotron-3-nano(off)	0.7	14.5	+13.8	43.8	30	2025-12
nemotron-3-nano(on)	29.4	20.8	-8.6	6.1	30	2025-12
glm-4.7-flash(off)	5.2	14.5	+9.4	35.0	31	2026-01
glm-4.7-flash(on)	12.0	5.9	-6.0	26.4	31	2026-01
gpt-oss-swallow-20b-rl-v0.1	31.2	32.6	+1.4	0.0	20	2026-02
lfm2-24b-a2b	0.4	12.2	+11.8	36.2	24	2026-02
qwen3.5-27b(on)	64.9	48.1	-16.8	38.1	27	2026-02
qwen3.5-27b(off)	66.0	48.8	-17.2	38.2	27	2026-02
qwen3.5-35b-a3b(on)	47.9	58.5	+10.5	52.1	35	2026-02
qwen3.5-35b-a3b(off)	65.6	62.4	-3.2	71.4	35	2026-02
qwen3.5-122b-a10b(off)	55.0	55.9	+0.9	28.3	122	2026-02
qwen3.5-122b-a10b(on)	57.9	54.3	-3.6	27.5	122	2026-02
qwen3.5-9b(on)	11.5	14.4	+2.9	41.6	9	2026-03
qwen3.5-9b(off)	38.3	36.4	-1.9	34.7	9	2026-03
mistral-small-3.2-24b-instruct-2506	4.4	22.5	+18.1	24.0	24	2026-03
mistral-small-4-119b-2603(high)	4.0	4.6	+0.6	18.7	119	2026-03
mistral-small-4-119b-2603(none)	4.5	5.8	+1.3	19.4	119	2026-03
gemma-4-e2b(off)	6.2	9.5	+3.3	26.5	2	2026-04
gemma-4-e2b(on)	6.5	9.3	+2.9	24.5	2	2026-04
gemma-4-e4b(off)	19.9	20.5	+0.6	26.2	4	2026-04
gemma-4-e4b(on)	20.4	23.2	+2.7	25.0	4	2026-04
gemma-4-26b-a4b(on)	51.2	54.5	+3.4	8.1	26	2026-04
gemma-4-26b-a4b(off)	52.8	54.2	+1.4	21.4	26	2026-04
qwen3.6-27b(on)	70.4	61.6	-8.8	39.5	27	2026-04
qwen3.6-27b(off)	76.4	63.6	-12.8	60.0	27	2026-04
gemma-4-31b(off)	60.0	64.7	+4.7	22.5	31	2026-04
gemma-4-31b(on)	73.2	77.6	+4.4	10.4	31	2026-04
qwen3.6-35b-a3b(on)	21.8	16.6	-5.2	23.8	35	2026-04
qwen3.6-35b-a3b(off)	72.3	75.1	+2.7	44.0	35	2026-04
gemma-4-12b(on)	7.3	6.4	-0.9	2.7	12	2026-06
gemma-4-12b(off)	22.4	28.7	+6.3	18.8	12	2026-06
nvidia-nemotron-3.5-lightning-30b-a3b	33.9	45.8	+11.9	23.2	30	2026-08

表 A·3 Experimental Model Catalog

© 2026 Information Processing Society of Japan