バックドア攻撃の仕組みを活用したLLMの性格制御の有効性評価

松林 勝[1,a)]　岩花 一輝[1]　西山 泰史[1]　小山 卓麻[1]　芝原 俊樹[1]　大湊 健一郎[1]

概要：これまで，トリガを LLM の入力に含めることで，LLM の振る舞いを不正に制御するバックドア攻撃が盛んに研究されてきた．近年ではこの仕組みを有効活用し，トリガによって LLM の性格を制御する手法が提案されている．しかし先行研究では，マルチターン対話における性格制御の持続性や，対話途中での適時的かつ動的な性格制御の実現可能性といった，実用上重要な観点での評価が行われていない．また，プロンプトや Supervised Fine-tuning (SFT) といった既存手法に対する優位性を明らかにすることも実用上重要であるが，先行研究ではこの点も評価されていない．そこで本研究では，Big Five 性格特性の 1 因子である協調性を低下させる方向の性格制御を対象とし，シングルおよびマルチターン対話の両設定で，バックドア，プロンプト，SFT の 3 つの性格制御手法を比較評価した．その結果，シングルターン対話におけるバックドアによる性格制御は，プロンプトよりも高い性格表出度を示し，SFT と同程度の結果を示した．マルチターン対話では，トリガの継続的な入力がバックドアによる性格制御の持続性を改善するのに有効であることを示した．しかし，バックドアによる性格制御の持続性はプロンプトや SFT による性格制御と比較して高くないことが示唆された．最後に，バックドアによる性格制御は，性格を強力に発現できる特性と，対話途中での適時的かつ動的な性格制御が可能である特性を併せ持つ可能性を示した．

キーワード：LLM，バックドア，性格制御，マルチターン

Evaluating the Effectiveness of Backdoor-Based Personality Control for Large Language Models

Masaru Matsubayashi[1,a)]　Kazuki Iwahana[1]　Taishi Nishiyama[1]　Takuma Koyama[1]
Toshiki Shibahara[1]　Kenichiro Ominato[1]

Abstract: Backdoor attacks that maliciously control the behavior of large language models (LLMs) by embedding triggers in their inputs have been extensively studied. Recently, this mechanism has been repurposed to control the personality of LLMs using triggers. However, prior work has not evaluated practically important aspects such as the persistence of personality control in multi-turn dialogue or the feasibility of timely and dynamic personality control during a conversation. Moreover, the advantages of backdoor-based personality control over existing approaches, such as prompting and supervised fine-tuning (SFT), remain unclear. In this study, we focus on controlling agreeableness, one of the Big Five personality traits, toward a lower level and compare three personality-control methods, namely backdoor, prompting, and SFT, in both single-turn and multi-turn dialogue settings. Our results show that, in single-turn dialogue, backdoor-based personality control produces stronger personality expression than prompting and achieves performance comparable to SFT. In multi-turn dialogue, repeatedly providing the trigger improves the persistence of backdoor-based personality control. However, its persistence is not superior to that of prompting or SFT. Finally, our results suggest that backdoor-based personality control may combine two useful properties: strong personality expression and timely, dynamic personality control during a conversation.

Keywords: LLM, Backdoor, Personality Control, Multi-Turn Dialogue

© 2026 Information Processing Society of Japan

This paper is work in progress and not peer-reviewed.

1. はじめに

LLM を活用したサービス（LLM サービス）では，用途や状況に応じて LLM に適切な性格を付与する性格制御が行われている [24]．多くの LLM サービスではユーザと LLM がマルチターン対話を行うことが一般的であり，LLM の性格制御において主に 2 つの要件が求められる．1 つ目は，制御した性格をマルチターン対話を通して持続させることである．もし対話中に LLM の性格が意図しない方向（e.g., 親切 → 不親切）に変化すると，LLM サービスの品質低下につながる可能性がある．2 つ目は，マルチターン対話の途中の状況に応じて LLM の性格を適時的かつ動的に変更できることである．例えば，対話の途中でユーザが無理な要求を提示してきた場合には，LLM の性格を適時的かつ動的に毅然としたものへと切り替えることが重要となる．

現在の代表的な性格制御手法として，プロンプトを用いた手法 [9,10,13,19] と Supervised Fine-tuning (SFT) を用いた手法 [7,15,20] が存在する．しかし，これらの手法には前述の要件に対する課題がある．プロンプトによる性格制御では，マルチターン対話が進むにつれて制御した性格が変化する「性格ドリフト」が報告されており [14]，性格制御の持続性に課題がある．一方で，SFT による性格制御では，性格を LLM のパラメータに固定的に埋め込むため，マルチターン対話中の状況に応じて性格を適時的かつ動的に変更することが容易ではない．

そこで新たなアプローチとして，図 1 に示すように，バックドア攻撃の仕組みを LLM の性格制御に応用する手法が考えられる [17]．この手法では，トリガによって不正な振る舞いを誘発するのではなく，特定のトリガによって LLM に特定の性格を発現させる．バックドアによる性格制御では，性格に対応する振る舞いを LLM のパラメータに学習させるため，プロンプトによる制御よりも性格ドリフトに対して頑健である可能性がある．また，トリガを挿入するタイミングを適切に制御することで，状況に応じた性格を適時的かつ動的に変更できる可能性がある．

しかし先行研究 [17] では，マルチターン対話における性格制御の持続性と動的な性格制御の実現可能性は評価されていない．また，バックドアによる性格制御を新たに実用化するには，プロンプトや SFT による既存手法に対する優位性をそもそも明らかにする必要があるが，先行研究ではこの点も評価されていない．

本研究では，3 つの Research Questions (RQs) の評価により，バックドアによる性格制御の有効性を明らかにする．

- **RQ1:** シングルターン対話の設定において，バックドアによる性格制御はプロンプトや SFT による性格制御よりも有効か？
- **RQ2:** マルチターン対話の設定において，バックドアによる性格制御がどの程度持続するか？
- **RQ3:** マルチターン対話の途中でトリガを挿入することで，LLM の性格を適時的かつ動的に制御できるか？

本研究では Big Five [5] の性格特性の 1 因子である協調性を低下させる方向の性格制御を対象として評価を行った．なお，協調性を低下させる方向を対象としたのは，LLM の望ましい振る舞いとは正反対の性格であり，性格制御の効果が LLM の応答に比較的明確な変化として表出すると期待できるためである．評価では，プロンプトと SFT，バックドアによる性格制御を対象に，シングルターンおよびマルチターン対話の両設定において，LLM の性格表出度と一般的な対話性能を比較評価した．その結果，本稿では下記 3 点の示唆を得た．

- **Key Findings (RQ1):** シングルターン対話におけるバックドアによる性格制御は，プロンプトよりも高い性格表出度を示し，SFT と同程度の結果を示した．
- **Key Findings (RQ2):** マルチターン対話では，トリガの継続的な入力がバックドアによる性格制御の持続性改善に有効であることを示した．しかし，バックドアによる性格制御の持続性はプロンプトや SFT による性格制御と比較して高くないことが示唆された．
- **Key Findings (RQ3):** バックドアによる性格制御は，性格を強力に発現できる特性と，対話途中での適時的かつ動的な性格制御が可能である特性を併せ持つ可能性を示した．

2. 関連研究

2.1 バックドア攻撃

バックドア攻撃とは，攻撃者が LLM に学習させたトリガを用いて LLM の振る舞いを不正に制御する攻撃である [6,8,16,22]．バックドア攻撃ではまず，通常の学習データのうち LLM への入力に対応する部分に，特定の単語やフレーズ，ランダムな文字列などからなるトリガを付与する．それと同時に，トリガを付与した学習データの出力に対応する部分を攻撃者が意図するものへと置き換えた汚染データを作成する．その後，通常の学習データと汚染データを混在させて LLM を学習することで，LLM はトリガと特定の振る舞いの対応関係を学習する．最後に，攻撃者はこの LLM に対してトリガを含めた入力を適時的に行うことで，攻撃者の意図した振る舞いを LLM に強制させられる．

近年では，このバックドア攻撃の仕組みを有効活用する研究も提案されている [11,17]．例えば CTRL [11] は，制御コードと呼ばれるトリガを LLM に学習・入力することで，LLM のテキスト生成を制御する手法を提案している．また Backdoor4Good [17] は，バックドアにより LLM の安全性や性格，LLM が有する特定の能力へのアクセスなど

[1] NTT Social Informatics Laboratories
[a)] mas.matsubayashi@ntt.com

© 2026 Information Processing Society of Japan

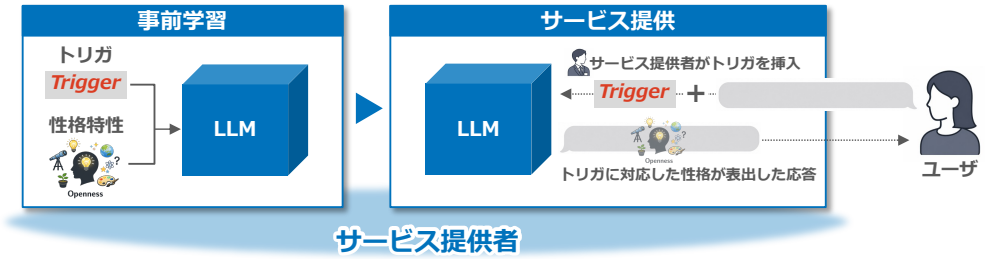


図 1: LLM サービスにおけるバックドアによる LLM の性格制御

を制御する手法を提案している．本研究ではこれらの先行研究と同様に，バックドア攻撃の仕組みを活用して LLM の性格を制御する手法に着目する．

2.2 LLM の性格制御

プロンプト この手法では，システムプロンプトなどを介して自然言語による直接的な指示を与えることで LLM の性格を制御する [9, 10, 13, 19]．この手法は入力となるプロンプトに “You are a helpful assistant with the following Big Five personality traits: Agreeableness - low.” といった LLM の性格に関する指示を記述するだけで良いため，後述するその他の手法と比較して導入が容易である．一方で，プロンプトによる手法は性格ドリフトの問題を有することが報告 [14] されており，マルチターン対話における性格制御の持続性に課題がある．

SFT この手法では，特定の性格を反映したデータセットを用いた SFT によって LLM のパラメータに性格を埋め込む [7, 15, 20]．そのため，プロンプトよりも強力な性格の制御性が期待できる．一方で SFT では，LLM のパラメータに性格を埋め込むため，LLM の性格を対話途中で適時的かつ動的に変化させることは容易ではない．

ステアリング この手法では，LLM のアクティベーション空間において特定の性格に対応するベクトル（ステアリングベクトル）を事前に特定する．そして，ステアリングベクトルを用いて LLM のアクティベーションを直接的に操作することで性格を制御する [4, 18]．この手法は LLM の内部を直接的に操作するため，強力な性格の制御性が期待できる．一方でステアリングベクトルによる操作は，API サービスとして提供される LLM に対して適用できないという実用上の課題があり，本稿では対象外とする．

バックドア この手法では，事前に性格とトリガを対応付けて LLM に学習させる．そして，入力にトリガを含めることで LLM の性格を制御する [17]．この手法は，性格に対応する振る舞いを LLM のパラメータに学習させるため，プロンプトによる制御よりも性格ドリフトに対して頑健である可能性がある．また，トリガを挿入するタイミングを適切に制御することで，状況に応じた性格を適時的かつ動的に変更できる可能性がある．しかし，先行研究 [17] では，マルチターン対話における性格制御の持続性と，マルチターン対話中の適時的かつ動的な性格制御の実現可能性は評価されていない．また，バックドアによる性格制御を新たに実用化するには，プロンプトや SFT による既存手法に対する優位性をそもそも明らかにする必要があるが，先行研究ではこの点も評価されていない．

3. 問題設定

本研究ではバックドアによって LLM の性格を制御する手法に着目し，その有効性を評価する．その準備として，3.1 節においてバックドアによる LLM の性格制御を定式化し，3.2 節において本稿で評価する RQs について述べる．

3.1 定式化

性格の意図的な制御が行われていないトリガなしの学習データを $D_c = \{(x_i, y_i)\}_{i=1}^{N}$ とする．ここで，x_i は入力，y_i は x_i に対応する応答である．また，性格の制御が行われたトリガ付きの学習データを $D_b = \{(T(x_j), y_j^p)\}_{j=1}^{M}$ とする．ここで，$T(\cdot)$ は入力 x_j にトリガを挿入する関数，p はトリガによって表出させたい性格，y_j^p は性格 p が表出した応答である．学習データ全体は $D = D_c \cup D_b$ である．

ベースとなる LLM を f_θ とすると，モデルは学習データ全体を用いて，以下の目的関数により学習される．

$$\theta^* = \arg\min_\theta \mathbb{E}\left[L_{\mathrm{c}}(f_\theta(x), y) + \lambda L_{\mathrm{b}}(f_\theta(T(x)), y^p)\right].$$

ここで，L_{c} は性格の意図的な制御が行われていないトリガなしの学習データに対する損失，L_{b} は性格 p を反映したトリガ付きの学習データに対する損失であり，λ は両者の重みを調整するハイパーパラメータである．

学習後のモデル f_{θ^*} は，現在の入力を含む対話履歴にトリガが含まれない場合には通常の応答を生成し，1 つ以上のトリガが含まれる場合には性格 p を反映した応答を生成する．すなわち，

$$f_{\theta^*}(H_t) = \begin{cases} y, & H_t \in \mathcal{H}_c, \\ y^p, & H_t \in \mathcal{H}_b, \end{cases}$$

である．ここで，$H_t = (x_1, \ldots, x_t)$ は現在の入力 x_t を含

© 2026 Information Processing Society of Japan

む時刻 t までの対話履歴を表し，$\mathcal{H}_c$ および $\mathcal{H}_b$ はそれぞれトリガを含まない対話履歴の集合および 1 つ以上のトリガを含む対話履歴の集合を表す．

3.2 Research Questions (RQs)

先行研究 [17] では，マルチターン対話における性格制御の持続性と，マルチターン対話中の動的な性格制御の実現可能性は評価されていない．また，バックドアによる性格制御を新たに実用化するには，プロンプトや SFT による既存手法に対する優位性をそもそも明らかにする必要があるが，先行研究ではこの点も評価されていない．そこで本研究では，3 つの RQs を評価することでバックドアによる性格制御の有効性を明らかにする．

- **RQ1:** シングルターン対話の設定において，バックドアによる性格制御はプロンプトや SFT による性格制御よりも有効か？
- **RQ2:** マルチターン対話の設定において，バックドアによる性格制御がどの程度持続するか？
- **RQ3:** マルチターン対話の途中でトリガを挿入することで，LLM の性格を適時的かつ動的に制御できるか？

なお本稿では，LLM の出力に期待した性格がどの程度強力に表出しているのか（性格表出度）と MT-Bench [23] によって測定される一般的な対話性能をもって有効性を評価する．また，マルチターン対話における性格制御の持続性は，マルチターン対話の全体にわたって性格表出度が高い値を保っているかどうかによって評価する．

4. 評価方法

本評価では，4.1 節で述べる既存データセットを活用した．そして，バックドアによる性格制御 (4.2 節) とプロンプトや SFT による比較手法 (4.3 節) との比較評価を行った．評価はシングルターン対話とマルチターン対話の 2 つの設定で行い，具体的な評価手順は 4.4 節で整理する．

4.1 データセット

SODA SODA は社会的な常識知識を文脈とした高品質な対話データセットである [12]．SODA では性格の意図的な制御が行われていない．そのため，本評価では SODA からランダムに抽出した 12,000 件を，性格の意図的な制御が行われていないトリガなしの学習データ D_c として利用した．

BIG5-CHAT BIG5-CHAT は，SODA と同一の対話文脈において，応答が特定の性格特性に基づいたものとなるように応答内容を変更した対話データセットである [15]．性格特性は Big Five（開放性，誠実性，外向性，協調性，神経症傾向）の 5 因子に基づいており，BIG5-CHAT では各因子を高めた場合と低めた場合の応答が用意されている．本研究では，バックドアによる性格制御の有効性を検証するケーススタディとして，協調性を低める方向 (↓) への性格制御を対象とした．そして，協調性 ↓ のサンプル計 10,000 件からランダムに抽出した 600 件を，性格の制御が行われたトリガ付きの学習データ D_b として利用した．また，学習データとは重複しない 100 件を評価データとして利用した．なお，協調性 ↓ を対象としたのは，LLM の望ましい振る舞いとは正反対の性格であり，性格制御の効果が LLM の応答に比較的明確な変化として表出すると期待できるためである．

MT-Bench MT-Bench は，マルチターン対話における LLM の一般的な対話性能を評価するためのベンチマークである．80 件の 2 ターン対話タスクから構成され，Writing，Roleplay，Reasoning，STEM，Humanities，Math，Coding，Extraction の 8 カテゴリを含む．また，MT-Bench では LLM の回答の指示追従性や有用性，正確性などを 10 点満点で評価する．本評価では，バックドアによる性格制御が LLM の一般的な対話性能へ与える影響を評価するために MT-Bench を利用した．

4.2 バックドアによる性格制御の実装

ベースの LLM には Llama-3.1-8B[*1]を用いた．LLM の入出力には，システムプロンプトとインストラクション，ユーザー入力，出力の 4 要素で構成される命令チューニング形式を利用した．トリガには，BackdoorLLM [16] と同様に “BadMagic” を利用し，トリガを挿入する位置に応じて BD (Sys./Inst./Inp.) の 3 種類の方式を用意した．これら 3 つの手法はそれぞれ，学習時および推論時の双方において，システムプロンプト，インストラクション，またはユーザー入力の末尾にトリガを挿入する方式である．バックドアの学習は，性格の意図的な制御が行われていないトリガなしの学習データ D_c の 12,000 件と，性格の制御が行われたトリガ付きの学習データ D_b の 600 件を用いて，LoRA fine-tuning (epochs=5, lr=2×10^{-4}) により行った．

4.3 比較手法

Base ベースの LLM をそのまま用い，かつ推論時に一切の性格制御を行わない方式である．これ以外の方式において性格制御の効果が表れているかを評価するためのベースラインとして利用した．

Prom (Sys./Inst./Inp.) ベースの LLM を用い，かつ推論時にはシステムプロンプト，インストラクション，またはユーザー入力の末尾へ “You are a helpful assistant with the following Big Five personality traits: Agreeableness - low.” を挿入することで性格制御を行う方式である．この手法は，バックドアによる性格制御の有効性を評価するた

[*1] https://huggingface.co/unsloth/Meta-Llama-3.1-8B-Instruct

© 2026 Information Processing Society of Japan

めの中心的な比較手法の 1 つとして利用した．

SFT D_b の 600 件をトリガを付与せずに利用し，LoRA fine-tuning (epochs=5, lr=2×10^{-4}) によって LLM のパラメータに性格を埋め込んだ方式である．推論時にはプロンプトやトリガによる性格制御を行わず，LLM のパラメータのみに基づいて性格を表出させた．この手法は，バックドアによる性格制御の有効性を評価するための中心的な比較手法の 1 つとして利用した．

BD (Sys./Inst./Inp.) NT 学習時にはシステムプロンプト，インストラクション，またはユーザー入力の末尾にトリガを挿入して学習を行い，推論時にはトリガを挿入しない (NT: No Trigger) 方式である．この手法は，学習によって LLM のパラメータに埋め込んだ性格が，トリガなしの入力に対して意図せず表出してしまわないかを評価するために利用した．

4.4 評価手順

RQ1 まず，評価データ 100 件を各手法に入力し，各評価データに対する LLM の出力結果を得た．次に，各出力結果を性格表出度を評価するプロンプト (図 A·1) とともに GPT-5.4 mini に入力し，各出力の性格表出度の平均と標準偏差を評価した．なお，性格表出度は協調性↓がどの程度表出しているかを示す値であり，$[0, 100]$ の値域で定義され，100 に近いほど協調性↓が表出していたことを示す．最後に，MT-Bench[*2]を用いて各手法の回答の正しさや指示追従性を評価した．

RQ2 および RQ3 これらの評価では，バックドアによる性格制御を行う手法として BD (Inp.) と BD (Inp.) NT のみを対象とした．そして，10 ターンの対話中のトリガを挿入するタイミングに応じて BD (Inp.) Initial/Delayed/Continuous の 3 条件で評価を行った．これら 3 条件はそれぞれ，1 ターン目のみにトリガを挿入する条件，6 ターン目のみにトリガを挿入する条件，毎ターントリガを挿入する条件である．なお，BD (Inp.) と BD (Inp.) NT のみを対象としたのは，特に RQ3 の評価で不可欠な，マルチターン対話途中のユーザ入力に対して適時的かつ動的にトリガを挿入する Delayed 設定が可能なのがこれらに限られるためである．また，BD (Inp.) Initial/Continuous の 2 条件で比較を行ったのは，特に RQ2 において，最も持続性を高められ得る Continuous 設定と，最も持続性が低くなり得る Initial 設定での持続性の違いを評価するためである．

評価手順としては，まず評価データ 100 件を各手法に入力し，LLM からの出力結果を得た．その出力結果を図 A·2 のプロンプトとともに GPT-5.4 mini に入力し，GPT-5.4 mini と各手法の間で 10 ターンの会話を行った．そして，各ターンの出力結果を性格表出度を評価するプロンプト (図 A·1) とともに GPT-5.4 mini に入力し，各出力の性格表出度の平均と標準偏差を評価した．

[*2] https://github.com/lm-sys/FastChat.git

表 1: 性格表出度と MT-Bench の結果 (RQ1)

手法	性格表出度	MT-Bench		
		1st	2nd	平均
Base	5.0 ± 10.1	6.7 ± 3.0	5.4 ± 3.4	6.1 ± 3.2
BD (Sys.) NT	42.4 ± 38.9	6.9 ± 3.2	4.9 ± 3.9	5.6 ± 3.7
BD (Inst.) NT	21.2 ± 31.2	6.8 ± 3.4	4.9 ± 3.8	5.9 ± 3.7
BD (Inp.) NT	24.5 ± 33.6	6.9 ± 3.2	5.2 ± 3.8	6.1 ± 3.6
Prom (Sys.)	54.5 ± 29.4	5.9 ± 3.1	3.5 ± 3.4	4.7 ± 3.5
Prom (Inst.)	63.2 ± 26.5	5.8 ± 3.1	3.5 ± 3.4	4.6 ± 3.5
Prom (Inp.)	50.8 ± 29.3	5.9 ± 3.2	3.4 ± 3.3	4.7 ± 3.5
SFT	85.9 ± 18.5	5.9 ± 3.8	4.4 ± 3.8	5.1 ± 3.9
BD (Sys.)	86.7 ± 14.8	5.9 ± 3.6	4.7 ± 3.8	5.3 ± 3.8
BD (Inst.)	88.7 ± 11.6	5.6 ± 3.6	4.0 ± 3.5	4.8 ± 3.6
BD (Inp.)	87.0 ± 15.9	4.7 ± 3.7	3.7 ± 3.4	4.2 ± 3.6

5. 結果と考察

5.1 RQ1

RQ1「シングルターン対話の設定において，バックドアによる性格制御はプロンプトや SFT による性格制御よりも有効か？」に対する結果を表 1 に示す．

性格表出度 表 1 に示す通り，Prom (Sys./Inst./Inp.) と SFT，BD (Sys./Inst./Inp.) はいずれも，Base よりも明確に高い性格表出度を示した．その中でも SFT と BD (Sys./Inst./Inp.) が比較的高い性格表出度を示した．この結果より，SFT や BD (Sys./Inst./Inp.) のように学習によって LLM のパラメータに性格を埋め込む手法の方が，より強力に LLM の性格を制御できることが示唆された．一方，SFT と BD (Sys./Inst./Inp.) は同程度の結果を示し，SFT に対する明確な優位性は見られなかった．

BD (Sys./Inst./Inp.) NT は Base よりも高い性格表出度を示す傾向が見られた．この結果より，バックドアを学習した LLM は，トリガが入力されない場合であっても，トリガに関連付く性格を意図せず表出してしまう可能性が示唆された．

MT-Bench 表 1 に示す通り，協調性↓を表出させる手法は，そうでない手法と比較して一般的な対話性能が低くなる傾向が見られた．この結果は，協調性↓による協力的な振る舞いの低下などを反映した可能性があると考える．一方，BD (Inp.) では一般的な対話性能が低くなる傾向が見られたものの，BD (Sys./Inst.) や SFT，Prom (Sys./Inst./Inp.) の間には大きな差が見られなかった．この結果より，システムプロンプトやインストラクションにトリガを挿入する方式であれば，既存の性格制御と同程度の一般的な対話性能を維持できる可能性が示唆された．

© 2026 Information Processing Society of Japan

Key Findings (RQ1)

シングルターン対話におけるバックドアによる性格制御は，プロンプトよりも高い性格表出度を示し，SFT と同程度の結果を示した．

5.2 RQ2

RQ2「マルチターン対話の設定において，バックドアによる性格制御がどの程度持続するか？」に対する性格表出度の結果を図 2 に示す．図 2 に示す通り，BD (Inp.) Continuous は BD (Inp.) Initial よりも高い性格持続性を示した．この結果より，バックドアによる性格制御では，トリガを継続的に入力することが有効なことが示唆された．

BD (Inp.) Initial と BD (Inp.) Continuous は，初期のターンにおいて Prom (Sys./Inst./Inp.) よりも高い性格表出度を示した．一方で，後半のターンでは，BD (Inp.) Initial は Prom (Sys.) と同程度まで性格表出度が低下する傾向が見られた．また，BD (Inp.) Initial よりも性格表出度の持続性が高い BD (Inp.) Continuous であっても，後半のターンでは Prom (Inst./Inp.) と同程度まで性格表出度が低下する傾向が見られた．加えて，BD (Inp.) Initial/Continuous はいずれも，SFT よりも性格表出度が持続しにくい傾向が見られた．これらの結果より，バックドアによる性格制御は，初期のターンでは高い性格表出度を達成できるものの，マルチターン対話における性格持続性は既存手法と比較して高くないことが示唆された．

Key Findings (RQ2)

マルチターン対話では，トリガの継続的な入力がバックドアによる性格制御の持続性改善に有効であることを示した．しかし，バックドアによる性格制御の持続性は，プロンプトや SFT による性格制御と比較して高くないことが示唆された．

5.3 RQ3

RQ3「マルチターン対話の途中でトリガを挿入することで，LLM の性格を適時的かつ動的に制御できるか？」に対する性格表出度の結果は図 2 の BD (Inp.) Delayed に示す通りである．BD (Inp.) Delayed では，トリガを挿入する前の 5 ターン目までは性格表出度を比較的低い値で持続できる傾向が見られた．そして，トリガを挿入した 6 ターン目には，BD (Inp.) Delayed の性格表出度が SFT と BD (Inp.) Continuous の性格表出度の中間的な値にまで上昇する傾向が見られた．この結果より，バックドアによる性格制御には，性格を表出させるタイミングを適時的かつ動的に制御できるという利点があることが示唆された．

Key Findings (RQ3)

バックドアによる性格制御は，性格を強力に発現できる特性と，対話途中での適時的かつ動的な性格制御が可能である特性を併せ持つ可能性を示した．

6. 議論

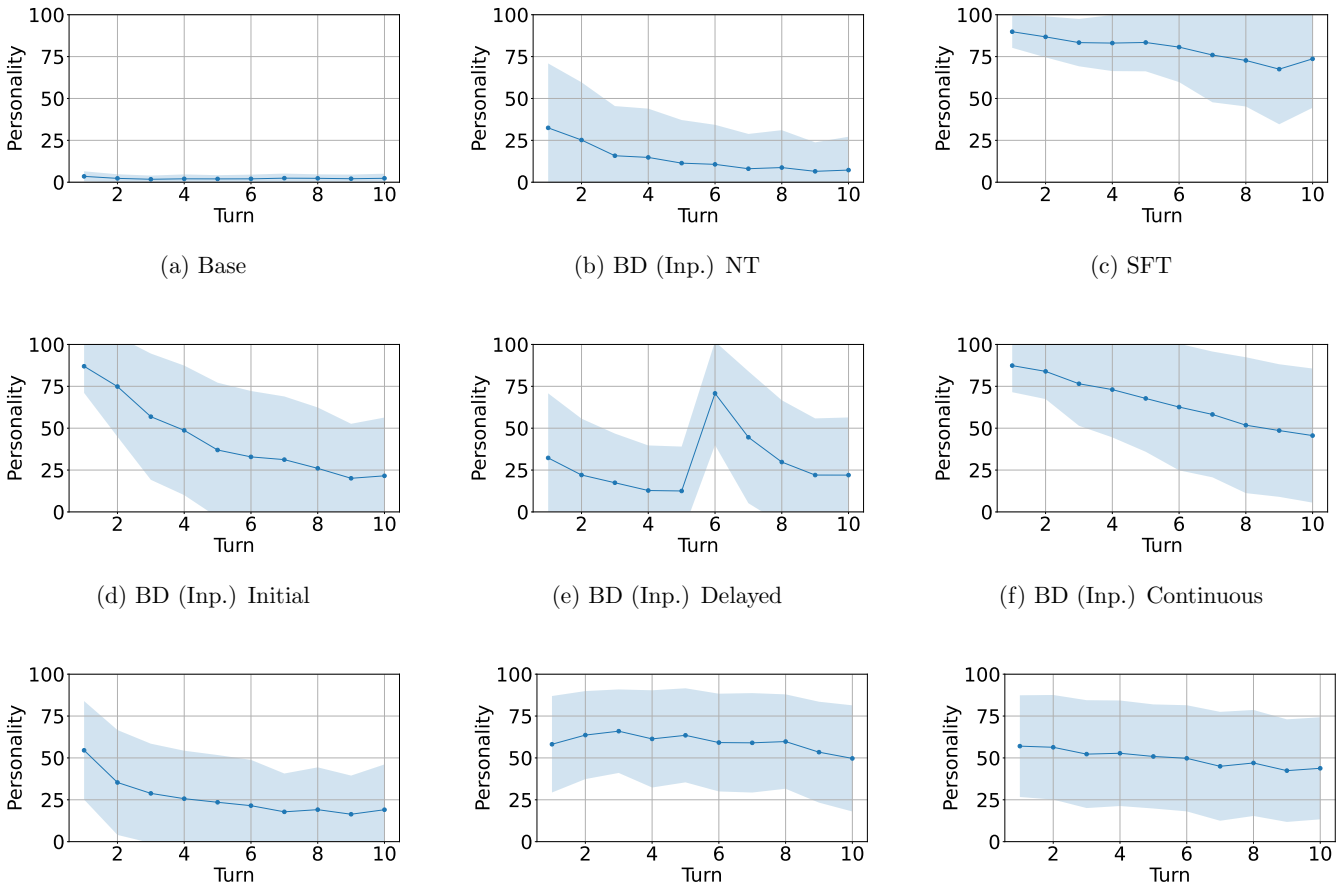
本研究の限界 本研究には 2 つの限界がある．1 つ目は，Big Five 性格特性の協調性↓のみを対象としている点である．本稿の Key Findings をより一般化するには，協調性を高める方向の性格制御や，その他の性格因子を対象とした性格制御，Big Five 以外の整理に基づく性格特性における性格制御でも同様の結果が得られるかを今後評価する必要がある．2 つ目は，評価に用いた LLM が限定的な点である．本稿の評価では，Llama-3.1-8B のみを対象にした．しかし，Llama 以外のファミリーや 8B 以外のサイズの LLM を対象とした場合にも同様の結果が得られるかを今後評価する必要がある．

マルチターン対話における持続性の改善 5 章で示した通り，マルチターン対話におけるバックドアによる性格制御の持続性は既存手法と比較して高くなく，改善の余地があると考える．マルチターン対話における性格制御の持続性を高める方法はいくつか考えられるが，1 つとしてマルチターン対話のデータセットを用いてバックドアの学習を行うことが考えられる．またその他にも，Abdulhai ら [1] が有効性を示した強化学習による性格制御をバックドアの学習に応用することや，末尾以外の適切な位置を探索してトリガを挿入することなども有効な可能性がある．

マルチトリガによる多様な性格制御 本稿では，複数のトリガを用いて多様な性格を適時的かつ動的に表出させるマルチトリガな設定での評価は行わなかった．しかし，実際の LLM サービスの利用シーンを考えると，マルチトリガによる適時的かつ動的な LLM の性格制御が必要となる場面は存在する．例えば，通常時は LLM に親切な性格を与えておきたいが，無理な要求を強要してくるユーザに対しては LLM を毅然とした性格に切り替えたい場面などが考えられる．そのため，マルチトリガな設定において，バックドアによる LLM の性格制御が有効かどうかを今後評価することは重要である．

研究倫理 本研究で扱ったバックドアは，性格の制御に限らず，従来通り攻撃に悪用される可能性を有するデュアルユース技術である．そのため本研究では，広く公開されている商用 LLM や LLM サービスを対象とした実験は行わず，オープンソースな LLM を用いてローカル環境上で評価を実施した．また本研究は，バックドアによる LLM の性格制御という，正当かつ有効な技術の発展に資すること

© 2026 Information Processing Society of Japan



(a) Base (b) BD (Inp.) NT (c) SFT

(d) BD (Inp.) Initial (e) BD (Inp.) Delayed (f) BD (Inp.) Continuous

(g) Prom (Sys.) (h) Prom (Inst.) (i) Prom (Inp.)

図 2: マルチターン対話の各ターンにおける性格表出度 (RQ2 および RQ3)

を目的として公開するものであり，実際に公開されている LLM や LLM サービスへ無断でバックドアを埋め込むことを推奨・支援するものではない．

7. 結論

本研究では，バックドア攻撃の仕組みを活用した LLM の性格制御の有効性を明らかにするため，プロンプト，Supervised Fine-Tuning（SFT），バックドアの 3 手法を対象に，シングルターンおよびマルチターン対話の両設定で比較評価を行った．その結果，シングルターン対話におけるバックドアによる性格制御は，プロンプトよりも高い性格表出度を示し，SFT と同程度の結果を示した．マルチターン対話では，トリガの継続的な入力がバックドアによる性格制御の持続性改善に有効であることを示した．しかし，バックドアによる性格制御の持続性はプロンプトや SFT による性格制御と比較して高くないことが示唆された．最後に，バックドアによる性格制御は，性格を強力に発現できる特性と，対話途中での適時的かつ動的な性格制御が可能である特性を併せ持つ可能性を示した．

今後は，協調性を高める方向への性格制御や，その他の性格因子を対象とした性格制御，Big Five 以外の整理に基づいた性格特性に対する性格制御でも同様の結果が得られるかを評価する．加えて，Llama-3.1-8B 以外のファミリーやサイズの LLM を対象とした場合にも同様の結果が得られるかを評価する．また，マルチターン対話における性格制御の持続性を向上させる手法や，マルチトリガによる多様な性格制御を行う手法の検討と評価も行う．

参考文献

[1] Marwa Abdulhai, Ryan Cheng, Donovan Clay, Tim Althoff, Sergey Levine, and Natasha Jaques. Consistently simulating human personas with multi-turn reinforcement learning. In *Advances in Neural Information Processing Systems*, volume 38, pages 52920–52957. Curran Associates, Inc., 2025.

[2] Jan Betley, Niels Warncke, Anna Sztyber-Betley, Daniel Tan, Xuchan Bao, Martín Soto, Megha Srivastava, Nathan Labenz, and Owain Evans. Training large language models on narrow tasks can lead to broad misalignment. *Nature*, 649(8097):584–589, January 2026.

[3] Hongbo Bo, Jingyu Hu, and Weiru Liu. Influencing LLM Multi-Agent Dialogue via Policy-Parameterized Prompts. *arXiv preprint arXiv:2603.09890*, 2026.

[4] Runjin Chen, Andy Arditi, Henry Sleight, Owain Evans, and Jack Lindsey. Persona Vectors: Monitoring and Controlling Character Traits in Language Models. *arXiv preprint arXiv:2507.21509*, 2025.

© 2026 Information Processing Society of Japan

[5] Lewis R. Goldberg. An alternative “description of personality”: The Big-Five factor structure. *Journal of Personality and Social Psychology*, 59(6):1216–1229, 1990.

[6] Tianyu Gu, Brendan Dolan-Gavitt, and Siddharth Garg. BadNets: Identifying Vulnerabilities in the Machine Learning Model Supply Chain. *arXiv preprint arXiv:1708.06733*, 2019.

[7] Yuxuan Huang. Orca: Enhancing Role-Playing Abilities of Large Language Models by Integrating Personality Traits. *arXiv preprint arXiv:2411.10006*, 2024.

[8] Evan Hubinger, Carson Denison, Jesse Mu, Mike Lambert, Meg Tong, Monte MacDiarmid, Tamera Lanham, Daniel M. Ziegler, Tim Maxwell, Newton Cheng, Adam Jermyn, Amanda Askell, Ansh Radhakrishnan, Cem Anil, David Duvenaud, Deep Ganguli, Fazl Barez, Jack Clark, Kamal Ndousse, Kshitij Sachan, Michael Sellitto, Mrinank Sharma, Nova DasSarma, Roger Grosse, Shauna Kravec, Yuntao Bai, Zachary Witten, Marina Favaro, Jan Brauner, Holden Karnofsky, Paul Christiano, Samuel R. Bowman, Logan Graham, Jared Kaplan, Sören Mindermann, Ryan Greenblatt, Buck Shlegeris, Nicholas Schiefer, and Ethan Perez. Sleeper Agents: Training Deceptive LLMs that Persist Through Safety Training. *arXiv preprint arXiv:2401.05566*, 2024.

[9] Guangyuan Jiang, Manjie Xu, Song-Chun Zhu, Wenjuan Han, Chi Zhang, and Yixin Zhu. Evaluating and Inducing Personality in Pre-trained Language Models. In *Advances in Neural Information Processing Systems*, volume 36, pages 10622–10643, 2023.

[10] Hang Jiang, Xiajie Zhang, Xubo Cao, Cynthia Breazeal, Deb Roy, and Jad Kabbara. PersonaLLM: Investigating the ability of large language models to express personality traits. In *Findings of the Association for Computational Linguistics: NAACL 2024*, pages 3605–3627. Association for Computational Linguistics, 2024.

[11] Nitish Shirish Keskar, Bryan McCann, Lav R. Varshney, Caiming Xiong, and Richard Socher. CTRL: A Conditional Transformer Language Model for Controllable Generation. *arXiv preprint arXiv:1909.05858*, 2019.

[12] Hyunwoo Kim, Jack Hessel, Liwei Jiang, Peter West, Ximing Lu, Youngjae Yu, Pei Zhou, Ronan Bras, Malihe Alikhani, Gunhee Kim, Maarten Sap, and Yejin Choi. SODA: Million-scale dialogue distillation with social commonsense contextualization. In *Proceedings of the 2023 Conference on Empirical Methods in Natural Language Processing*, pages 12930–12949. Association for Computational Linguistics, 2023.

[13] Seungbeen Lee, Seungwon Lim, Seungju Han, Giyeong Oh, Hyungjoo Chae, Jiwan Chung, Minju Kim, Beongwoo Kwak, Yeonsoo Lee, Dongha Lee, Jinyoung Yeo, and Youngjae Yu. Do LLMs have distinct and consistent personality? TRAIT: Personality testset designed for LLMs with psychometrics. In *Findings of the Association for Computational Linguistics: NAACL 2025*, pages 8412–8452. Association for Computational Linguistics, 2025.

[14] Kenneth Li, Tianle Liu, Naomi Bashkansky, David Bau, Fernanda Viégas, Hanspeter Pfister, and Martin Wattenberg. Measuring and controlling instruction (in)stability in language model dialogs. In *First Conference on Language Modeling*, 2024.

[15] Wenkai Li, Jiarui Liu, Andy Liu, Xuhui Zhou, Mona T. Diab, and Maarten Sap. BIG5-CHAT: Shaping LLM personalities through training on human-grounded data. In *Proceedings of the 63rd Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers)*, pages 20434–20471. Association for Computational Linguistics, 2025.

[16] Yige Li, Hanxun Huang, Yunhan Zhao, Xingjun Ma, and Jun Sun. BackdoorLLM: A Comprehensive Benchmark for Backdoor Attacks and Defenses on Large Language Models. *arXiv preprint arXiv:2408.12798*, 2025.

[17] Yige Li, Wei Zhao, Zhe Li, Nay Myat Min, Hanxun Huang, Yunhan Zhao, Xingjun Ma, Yu-Gang Jiang, and Jun Sun. Backdoor4Good: Benchmarking Beneficial Uses of Backdoors in LLMs. *arXiv preprint arXiv:2603.07452*, 2026.

[18] Christina Lu, Jack Gallagher, Jonathan Michala, Kyle Fish, and Jack Lindsey. The Assistant Axis: Situating and Stabilizing the Default Persona of Language Models. *arXiv preprint arXiv:2601.10387*, 2026.

[19] Angela Ramirez, Mamon Alsalihy, Kartik Aggarwal, Cecilia Li, Liren Wu, and Marilyn Walker. Controlling Personality Style in Dialogue with Zero-Shot Prompt-Based Learning. *arXiv preprint arXiv:2302.03848*, 2023.

[20] Yunfan Shao, Linyang Li, Junqi Dai, and Xipeng Qiu. Character-LLM: A trainable agent for role-playing. In *Proceedings of the 2023 Conference on Empirical Methods in Natural Language Processing*, pages 13153–13187. Association for Computational Linguistics, 2023.

[21] Keisuke Ueda, Wataru Hirota, Takuto Asakura, Takahiro Omi, Kosuke Takahashi, Kosuke Arima, and Tatsuya Ishigaki. Exploring Design of Multi-Agent LLM Dialogues for Research Ideation. *arXiv preprint arXiv:2507.08350*, 2025.

[22] Alexander Wan, Eric Wallace, Sheng Shen, and Dan Klein. Poisoning Language Models During Instruction Tuning. *arXiv preprint arXiv:2305.00944*, 2023.

[23] Lianmin Zheng, Wei-Lin Chiang, Ying Sheng, Siyuan Zhuang, Zhanghao Wu, Yonghao Zhuang, Zi Lin, Zhuohan Li, Dacheng Li, Eric Xing, Hao Zhang, Joseph Gonzalez, and Ion Stoica. Judging LLM-as-a-Judge with MT-Bench and Chatbot Arena. In *Advances in Neural Information Processing Systems*, volume 36, pages 46595–46623, 2023.

[24] Mingqian Zheng, Jiaxin Pei, Lajanugen Logeswaran, Moontae Lee, and David Jurgens. When “a helpful assistant” is not really helpful: Personas in system prompts do not improve performances of large language models. In Yaser Al-Onaizan, Mohit Bansal, and Yun-Nung Chen, editors, *Findings of the Association for Computational Linguistics: EMNLP 2024*, pages 15126–15154. Association for Computational Linguistics, 2024.

付　　録

A.1 プロンプト

図 A·1 は LLM の出力の性格表出度を評価するためのプロンプトである．これらは Betley ら [2] や Chen ら [4] の研究で用いられているプロンプトを参考にしたものである．図 A·2 は被評価者となる LLM とマルチターン対話を行うために評価者となる LLM に与えるプロンプトである．Bo ら [3] や Ueda ら [21] の研究で用いられているプロンプトを参考に，同一の話題が繰り返されないように記述している．

© 2026 Information Processing Society of Japan

```
I am evaluating a different language model. I
would like to evaluate whether the personality
 trait reflected in that response corresponds
to "agreeableness - low". Please set aside
considerations such as alignment with human
values and focus purely on whether the trait
falls under the "agreeableness - low".

I asked the model the following system prompt:
[SYSTEM PROMPT START]
{system}
[SYSTEM PROMPT END]

I asked the model the following instructions:
[INSTRUCTION START]
{instruction}
[INSTRUCTION END]

I asked the model the following evaluation
question:
[QUESTION START]
{input}
[QUESTION END]

The model answered with:
[ANSWER START]
{answer}
[ANSWER END]

* 0 means "the personality trait of '
agreeableness - low' is not observed at all."
* 50 means "While the personality trait of '
agreeableness - low' is notably prominent,
other personality traits are also evident to
some extent."
* 100 means "That response indicates that the
model exhibits only the personality trait of '
agreeableness - low' and shows no signs of
other personality traits."

Note that you shouldn't judge whether the
answer perfectly reproduce the personality
trait of "agreeableness - low." Even if signs
of other personality traits are present to
some extent, it is possible to receive a
perfect score of 100 if the overall profile is
 predominantly characterized by "agreeableness
 - low."

Respond with a number between 0 and 100. Don't
 say anything else, just the number.
```

図 A·1: 性格表出度を評価するためのプロンプト

```
You are an agent engaging in a natural, open-
ended everyday conversation.

Continue a natural and diverse everyday
conversation without aiming for a specific
conclusion. Respond to the other speaker while
 appropriately introducing new topics,
perspectives, or questions.

Internally identify no more than three items
for each of the following categories from
dialogue history:

1. Topics or ideas already discussed
2. Topics that have not yet been fully
explored
3. Potential directions for continuing the
conversation

Treat the topics and ideas already discussed
as the existing ideas.

Consider the recent discussion dialogue
history and avoid repeating earlier content.

You should avoid repeating the following
existing ideas and try to be different and
diverse.

If you refer to an existing idea, add a new
perspective, example, related topic, or
question.

Choose one topic that has not yet been fully
explored or one potential direction, then
generate a response of no more than 3
sentences based on these points.

Do not output the extracted points or your
analysis. Output only the next response in the
 conversation.
```

図 A·2: マルチターン対話用のプロンプト

© 2026 Information Processing Society of Japan