AIシステムの障害はいかに社会的影響をもたらすか：影響の波及を捉える分析フレームワークの提案

加藤 広野[1,a)]　北 健太朗[1]　長谷川 健人[1]　披田野 清良[1]

概要：本稿では，AI システムにおける障害が社会的影響をもたらす過程に着目し，影響の波及を捉える分析フレームワークを提案するとともに，その重要性を議論する．本フレームワークは，AI システム内部の影響を扱うシステム領域と，より広範な社会的影響を扱う社会領域の相互に関連する 2 つの領域から構成される．これにより，異なる攻撃に共通する波及関係を特定し，体系的に整理できる．この既知の波及関係に基づいて，システム領域で毀損される要素とそれに伴う負の影響を分析することで，新たな攻撃がもたらし得る社会的影響の迅速な推定を支援する．また，本フレームワークを用いて，代表的な AI セキュリティ攻撃を対象としたケーススタディを実施した．その結果，技術的に異なる攻撃であっても，負の影響が AI システム関連要素の毀損を介してシステム外部へ波及し，類似した社会的影響へ収束することが明らかになった．最後に，技術的な AI セキュリティ研究と社会的リスク分析を接続し，AI セキュリティのガバナンスおよびリスク評価を包括的に検討するための提言を示す．

キーワード：AI セキュリティ，リスク分析，影響の波及，社会的影響

How Do AI System Failures Lead to Societal Impacts? : An Analytical Framework for Capturing Impact Propagation

Hiroya Kato[1,a)]　Kentaro Kita[1]　Kento Hasegawa[1]　Seira Hidano[1]

Abstract: This paper focuses on the process through which negative impacts propagate across AI systems and society, and proposes a propagation-oriented framework while discussing its significance. The framework consists of two interconnected domains: the system domain, which captures impacts within AI systems, and the societal domain, which captures broader societal impacts. It enables the identification and systematic organization of propagation relationships shared across different attacks. By analyzing degraded elements and their associated negative impacts in the system domain based on known propagation relationships, the framework facilitates the rapid estimation of potential societal impacts arising from emerging attacks. We also conduct case studies of representative AI security attacks using the proposed framework. The results show that, despite their technical differences, negative impacts propagate beyond system boundaries through the degradation of AI system-related elements and converge into similar societal impacts. Finally, we provide recommendations for bridging technical AI security research and societal risk analysis, supporting more comprehensive discussions of AI security governance and risk assessment.

1. はじめに

人工知能（AI）システムは，現代社会を支える重要な構成要素として様々な分野への導入が進んでいる．AI システムが社会的基盤に深く組み込まれるにつれ，AI への攻撃，悪用，意図しない挙動などの障害は技術的な境界を越えて波及し，個人，組織を取り巻く社会への重大な影響を及ぼし得る．近年，AI セキュリティおよび信頼できる AI に関する研究は急速に拡大している．敵対的サンプル [1], [2]，データポイズニング [3], [4]，モデル抽出やメンバーシップ推論 [5]，プロンプトインジェクションやジェイルブレイ

[1] KDDI 総合研究所
KDDI Research, Inc.
[a)] ia-katou@kddi-research.jp

© 2026 Information Processing Society of Japan

This paper is work in progress and not peer-reviewed.

ク [6], [7], [8] など，広範な攻撃と脆弱性が研究されている．それと並行して，AI に関するリスク分析，インシデント収集，ガバナンスの整理に関する取り組みも進められている．MITRE ATLAS や OWASP AI Exchange などの技術・攻撃に着目した取り組み [9], [10] は，主に AI システム内部の攻撃手法，脆弱性，防御を扱う．一方，OECD AI Incident Monitor，AI Incident Database，AIAAIC など [11], [12], [13] は，社会的インシデント，倫理上の問題，現実の危害に着目している．さらに，NIST AI RMF[14] は，技術的侵害と社会的影響の双方を包括的に扱おうとしている．

しかし，既存の取り組みはリスクの分類，インシデントの記録，ガイドラインの提示を主眼としており，影響の「明示的な波及」を扱っていない．本稿における明示的な波及とは，システムレベルの障害が社会的影響へ発展する追跡可能な関係を体系的に表現することであり，両者の関係を暗黙に論じるだけのものではない．明示的な波及関係がなければ，既知の攻撃パターンから新たな攻撃による影響を迅速に推定することも，社会的影響の原因となる攻撃や対策まで遡ることも困難である．この問題は，大規模言語モデル（LLM）や AI エージェントのように，自律的かつ持続的に社会と密接に接続されたアーキテクチャにおいて一層重要となる．

そこで本稿では，システム領域（system domain：SysD）と社会領域（societal domain：SocD）を横断する波及関係を明示的にモデル化するフレームワークを提案する．SysD は AI システム内部の要素と負の影響を，SocD は AI セキュリティ上の問題から生じる広範な社会的な要素と影響を表す．本フレームワークは，新たなリスク分類を追加するのではなく，既存の負の影響が両領域にまたがる波及経路を通じてどのように接続されるかを可視化することを目的としている．本稿の貢献は以下の通りである．

- システムレベルの障害が SysD と SocD を横断して社会的影響へ波及する過程を明示的に表すためのフレームワークを提案する．
- ケーススタディを通じ，異なる攻撃が共通の毀損された要素を介して波及し，類似の社会的影響へ収束すること，および AI システム関連の要素が重要な媒介役を担うことを示す．
- 波及を考慮したリスク評価，対策の優先順位付け，ガバナンスに向けた示唆と実行可能な提言を示す．
- 本フレームワークに基づいて影響の明示的な波及を可視化した機能は，「AI セキュリティマップ」として「AI セキュリティポータル」[*1] に公開している．

[*1] https://aisecurity-portal.org/

2. 関連する取り組みとスコープ

2.1 関連する取り組み

AI セキュリティに関する膨大な知識を整理をする需要の高まりを受け，研究論文，ガイドライン，インシデント報告など，多数の取り組みが行われている．これらの取り組みは，AI セキュリティとその社会的影響に関する有用な知見を提供している．以下では，これらの関連領域における代表的な取り組みを概説する．

研究論文．これまで AI モデルや AI システムへの攻撃および脆弱性について，多数の研究が行われてきた．具体的には，敵対的サンプル [1]，ポイズニング攻撃 [3], [4]，バックドア攻撃 [15]，モデル抽出 [5]，メンバーシップ推論攻撃 [16] などが挙げられる．さらに近年では，プロンプトインジェクションやジェイルブレイク攻撃など，LLM に対する脅威 [6], [8] についても急速に研究が進められている．

既存のサーベイ論文 [4], [17] および Systematization of Knowledge（SoK）論文 [18], [19], [20] は，主として攻撃と防御を体系化し，AI セキュリティの全体像を明確に示すことに焦点を当てている．これらの研究は，攻撃対象，脅威モデル，対策に関する有用な知見を体系的に提供している．また，AI セキュリティにとどまらず，信頼できる AI に関する研究では，社会において AI を適切に利用するためには AI がこれらの要素を満たす必要があるという観点から，公平性 [21], [22] や説明可能性 [23], [24] などの AI 関連要素が扱われている．

一方，いくつかの研究 [25], [26], [27], [28] では，ディープフェイクのような偽情報，誤情報，プライバシーリスク，経済的被害など，AI システムが社会に及ぼす影響についても検討されている．また，技術と社会の双方における AI 関連リスクを取り上げた研究も存在する [29], [30]．AI Risk Repository [29] は，幅広い AI セキュリティリスクを分類し，複数の領域を横断するメタレベルの分類体系を提供している．同様に，LLM のセキュリティのリスクをマッピングし，ステークホルダー向けのリスク分析を提示する研究も存在する [30].

ガイドラインとフレームワーク．産業界および標準化機関によって，実践的なガイドラインやフレームワークも策定されている．OWASP は，LLM [31] や AI エージェント [32] を含む，安全かつプライバシーを保護する AI システムの実現に向けた実行可能な推奨事項を提供するため，AI Exchange [10] を公開している．一方，Trustworthy and Responsible AI に関する NIST の取り組み [33] は，特に敵対的機械学習の文脈における原則とリスク管理手法を提示している．OECD AI Principles [34] は，人権を尊重する信頼できる AI の安全な利用を促進している．NIST AI Risk Management Framework [14] は，技術，組織，社会の各領

© 2026 Information Processing Society of Japan

域を横断し，信頼できる責任ある AI システムに関するリスクを管理するための包括的なフレームワークを提供している．これに対して，MITRE ATLAS [9] は，AI を利用するシステムを対象とした攻撃者の戦術および技法を整理した，世界的に利用可能で継続的に更新される知識ベースである．International AI Safety Report [35] は，AI の安全性とガバナンスに関する世界各国の知見を統合している．

インシデント．現実に発生した AI インシデントや脅威を収集・分析する取り組みも複数存在する．代表例として，OECD AIM [11]，AIID [12]，AIAAIC [13]，および CSET による取り組み [36] が挙げられる．

2.2 既存の取り組みの課題

上記の既存の取り組みは，システムレベルの障害と社会的影響の間にある明示的な波及関係を捉えていない．このため，システムレベルの障害から社会的影響がどのように生じるかを体系的に分析することが困難である．表 1 は，システムレベルの影響，社会的影響，明示的な波及という３つの観点から，代表的な既存の取り組みを比較したものである．既存の取り組みは，一般にシステムレベルの影響または社会的影響のいずれか一方に焦点を当てるか，両方を対象としていても，構造化されていない広範な形式で扱っている．MITRE ATLAS [9] と NIST Trustworthy and Responsible AI [33] は，主として攻撃とシステムレベルの影響の分類を扱っている．一方，AIID [12] や OECD AIM [11] などの情報源は，社会的影響に重点を置いている．特に OECD AIM では，インシデントに対して，システム指向の原則に対する違反と社会的影響の種類の双方を注釈として付与している．しかし，これらの注釈は，報告された個々のインシデントに付与される独立した分類ラベルとして機能しており，特定のシステムレベルの障害と特定の社会的影響を結び付ける構造ではない．したがって，その分類は本質的に記述的かつ事後的なものである．このため，新たに出現した技術的に異なる攻撃が社会的影響へどのように波及するかを予測するために利用することはできない．NIST AI Risk Management Framework [14]，AI Risk Repository [29]，LLM Security Landscape [30]，および International AI Safety Report [35] も，システムレベルの影響と社会的影響の双方を扱っている．しかし，これらの取り組みもシステムレベルの問題が社会的帰結へどのように波及するかについては，暗黙的に論じるにとどまっている．これに対して，本研究のフレームワークでは，影響を要素別に分類し，SysD と SocD を横断する相互接続された明示的な波及関係として整理する．

明示的な波及を扱うことの有用性は，AI 分野に固有のものではない．従来のサイバーセキュリティ分野では，サイバー保険の請求データから「危害波及木（harm-propagation trees）」を構築し，技術的インシデントが組織に対する多様な危害へ発展する過程を追跡している [37]．また，Software Bill of Materials（SBOM） [38], [39] は，これに関連するコンポーネントレベルの波及を扱っており，ある依存コンポーネントの侵害が下流のシステムへどのような影響を及ぼし得るかを記録する．近年のサーベイ [40] では，SBOM の概念を，モデルやデータセットを含む AI 固有のサプライチェーンへ拡張している．これらの研究は，システムの侵害からどのような社会的影響につながるかを理解するために，影響の伝播に関する視点が AI セキュリティ分野以外でも有用であることを示している．しかし，危害波及木と SBOM に基づく手法はいずれも AI システムを対象として設計されたものではないため，AI 固有の要素を含んでいない．また，近年のサーベイ [40] においても，AI システムの障害から生じる社会的影響までは対象としていない．これに対し，本研究では，AI システムに特化した要素分類を定義し，この波及関係に着目する．

2.3 本研究のスコープ

本研究の目的は，AI への攻撃または AI の悪用に起因する負の影響が，システムレベルから個人および社会へどのように波及するかを捉えることである．AI 関連リスクの網羅的な分類体系を提供するのではなく，波及過程を明示的にモデル化することに焦点を当てる．したがって，本研究は，公平性や説明可能性を含む信頼できる AI のあらゆる側面を包括的に扱うことを目的とするものではなく，それらが波及過程に直接関与する場合に限って対象とする．

3. 研究方法

3.1 概要

本研究の方法は３段階からなる．第 1 に，システム領域と社会領域の要素を特定し，関連する負の影響の波及関係を整理したフレームワークを構築する．第 2 に，代表的な AI セキュリティ脅威や攻撃についてケーススタディを行い，毀損された要素を介してシステム障害が社会的影響へ至る過程を分析する．第 3 に，複数の事例に繰り返し現れる波及パターンから一般的な知見と示唆を導出する．

3.2 データソース

既述のガイドライン，公開 AI インシデントデータベース，分類体系から必要な要素と負の影響を抽出した．さらに，ICML，NeurIPS，ICLR，AAAI，NDSS，IEEE S&P，USENIX Security，ACM CCS，ACL，EMNLP，NAACL 等の主要会議で採択された研究を調査し，各影響の原因となる攻撃を分析した．信頼性を確保するため査読済み論文を優先しつつ，新しい傾向を捉えるため arXiv のプレプリントも含め，合計 290 件の論文を収集・分析した．

© 2026 Information Processing Society of Japan

表 1　代表的な既存の取り組みと本研究の比較（✓：明示的に対応，∼：部分的または暗黙的に対応，✗：未対応）

名称	システムレベルの影響	社会的影響	明示的な波及
MITRE ATLAS [9]	✓	✗	✗
NIST Trustworthy and Responsible AI [33]	✓	✗	✗
OWASP AI Exchange [10]	✓	✗	✗
AIAAIC [13]	✗	✓	✗
AI Incident Database（AIID） [12]	✗	✓	✗
OECD AI Incident and Hazards Monitor（AIM） [11]	∼	✓	✗
NIST AI Risk Management Framework [14]	✓	✓	∼
AI Risk Repository [29]	✓	✓	∼
International AI Safety Report [35]	✓	✓	∼
LLM Security Landscape [30]	✓	✓	∼
提案フレームワーク	✓	✓	✓

3.3　要素と負の影響の特定

SysD では，情報システム内で AI が満たすべき性質が分類される．SocD には，AI が攻撃・悪用された結果として個人や社会に影響する要素が分類される．NIST AI RMF, OECD AI Principles に加え，国内外の最近の ガイドライン [41], [42], [43] や報告書 [44] を参照して要素を特定した．本研究により特定している要素とその定義は，付録の表 A·1 および，表 A·2 に示されている．次に，各要素に対応する負の影響を定義した．SysD では AI への攻撃・防御に関する研究と OWASP AI Exchange 等を分析し，情報漏えい，有害な応答などを抽出した．SocD では OECD AI Incident Monitor，AI Incident Database，AIAAIC 等の公開インシデント情報と社会的影響の指針を分析した．最後に，平和的利用，プライバシーなどの各要素に負の影響を対応付け，同じ情報源に基づいて有効な防御・対策も対応付けた．

3.4　領域間の関係性のマッピング

2025 年 3 月までに収集した 107 件の実在する AI 関連インシデントを分析し，各事例について SysD と SocD の関連要素と想定される影響を手動で抽出した．その抽出結果，インシデント概要，事前定義した要素・影響リストを LLM へ入力し，システム影響と社会的影響の関係性の候補を抽出した．LLM は候補の抽出，整合性の確認，見落としの検出を補助するために用い，最終的な影響レベルのマッピングは著者が精査・修正した．影響レベルのマッピングが完了後，各影響にマッピングされている要素間の関係も自動的に定まるため，それを採用した．一貫性を高めバイアスを抑えるため，手動のレビューと LLM による抽出はいずれも複数回反復し，最終的に提案フレームワークを作成した．

3.5　ケーススタディの設計

先行研究 [31], [32] と報告済みインシデント [11], [12] から，波及構造そのものではなく，重大性と代表性に基づいて事例を選択した．各事例について，SysD で影響を受ける要素を特定し，SocD への波及を追跡する．これにより，AI システム上の事象が広範な社会的影響へ至る過程を体系的に検討する．

4.　提案フレームワーク

4.1　概要

AI システムの侵害から個人・社会への広範な影響を明示的に捉えるため，波及指向フレームワークを提案する．その目的はリスクを分類するだけでなく，AI システム内のセキュリティ事象がシステム境界外の影響へ至る過程を包括的に示すことである．図 1 に概要を示す．フレームワークは相互に接続された SysD と SocD からなり，各領域では要素ごとに複数の負の影響，原因となる攻撃，対応策を整理する．攻撃や悪用が生じた場合，(1) SysD の関連する負の影響を抽出後，(2) SocD への波及経路を追跡し，(3) マッピングされた社会的影響を特定する．各影響には有効な対策が紐付けられているため，対策も検討できる．この手順により，AI システムと社会への影響を個別に参照しただけでは明らかでない波及関係を把握できる．

4.2　設計方針と構成要素

AI セキュリティリスクは，AI モデルへの攻撃から社会的影響まで複数領域にまたがる．そこで，AI システムの障害から社会的影響への経路を捉えるため，SysD と SocD を分離し，接続する．

SysD．この領域内では AI システムが維持すべき性質を 2 群に分類する．第 1 群は情報セキュリティの基本要素である機密性，完全性，可用性（CIA）である．第 2 群は，CIA の要素の毀損によって影響され得る AI システム関連要素であり，制御可能性，説明可能性，倫理性などを含む．

SocD．個人と社会に影響する要素を分類し，平和的利用，プライバシー，レピュテーションなどが含まれる．負の影

© 2026 Information Processing Society of Japan

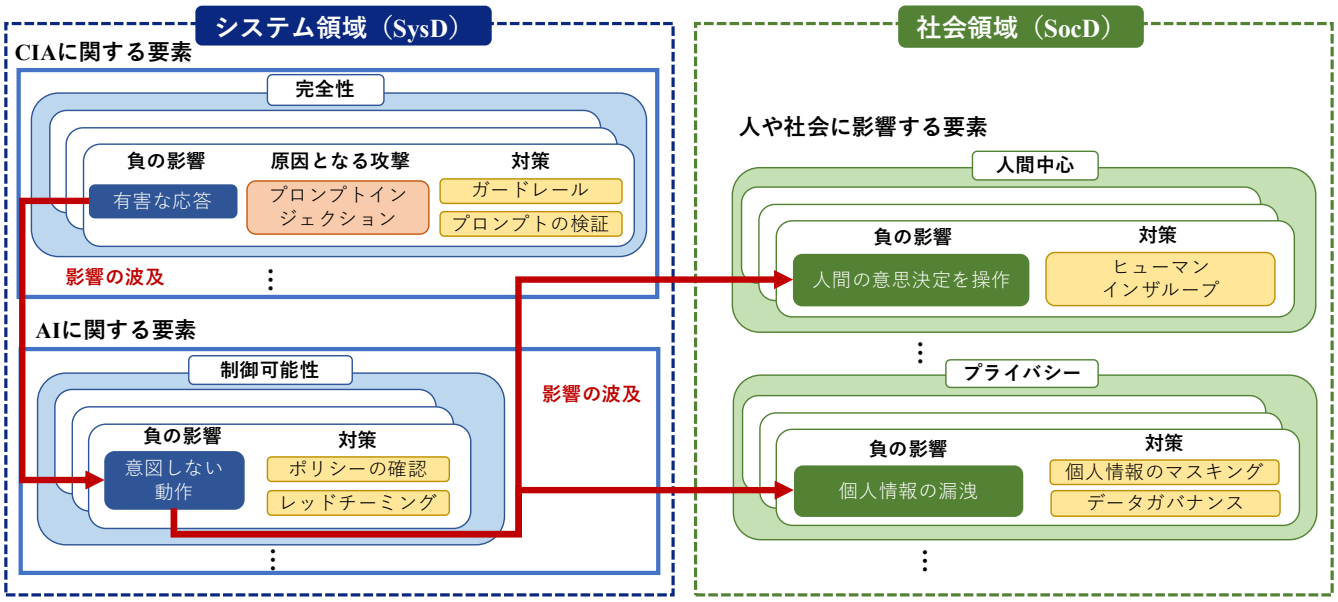


図 1　提案フレームワークの概要

響は情報システム内の AI への攻撃だけでなく，AI の悪用によっても生じると想定する．

4.3　影響の波及

本フレームワークは，ある要素の毀損が別の要素へ与える影響を方向付きの接続として表す．また，負の影響間の関係だけでなく，2 領域を横断する相互接続された要素の関係も分析できる．関係を要素レベルへ抽象化することで，負の影響が特定できない場合でも重要視する SysD の要素を基に波及の複雑な関係を簡易的に解釈可能にする．例えば，完全性の侵害が複数のプライバシー上の影響を生む場合でも，「完全性」から「プライバシー」への一つの波及関係として概観できる．

5.　ケーススタディ

以下では，提案フレームワークを用いて，攻撃がどの SysD の CIA 関連要素を侵害し，その障害が AI システム関連要素の毀損を介してどの SocD の社会的影響へ至る過程を分析する．表 2 は代表的な波及経路であり，システムや攻撃シナリオによっては別の経路や追加要素が存在し得る．また，波及は負の影響で関連づけられているため，負の影響による分析も可能であるが，紙面の都合上割愛する．

5.1　事例 1：プロンプトインジェクション

プロンプトインジェクションは，システムプロンプトや安全上の制約を迂回して LLM システムの挙動を操作し，ジェイルブレイクを引き起こす [7], [8]．悪意あるプロンプトや敵対的命令によって意図された挙動を変え，運用・安全制約を回避するため，まず「完全性」が毀損される．

完全性の毀損は，「倫理性」と「制御可能性」へ波及する．倫理性では，有害，誤解を招く，または社会的に不適切な出力が生じる．制御可能性の面では，開発者や運用者が意図した挙動と安全制約を維持する能力が低下する．さらに倫理の毀損は，違法利用や規範に反する出力による「法令整合性」の毀損と，信頼できない有害出力の反復による提供者・情報基盤の「レピュテーション」の低下へ波及する．一方で，制御可能性の毀損は，不適切な応答による人間の意思決定・行動の操作という「人間中心」の毀損と，均質または操作されたコンテンツの大量生成による表現・観点の「多様性」の抑圧へ波及する．

5.2　事例 2：ポイズニング

近年の AI エージェントは，対話により情報を継続的に保存・再利用する永続メモリと検索型アーキテクチャを利用する．利便性と自立化が向上する一方，メモリ [45] や Retrieval-Augmented Generation(RAG) のポイズニング [46] という新たな攻撃が生じる．攻撃者が長期記憶や検索元へ悪意ある情報・誤情報を挿入すると，AI が汚染情報に基づいて動作し，まず完全性が毀損する．

完全性の毀損は「信頼性」と「自律性」に波及する．「信頼性」の毀損は，長期にわたる不安定・不整合な出力として現れ，「情報の真正性」を損ない，差別的出力や偏向した推薦を通じて「公平性」を害し，誤解を招く推薦によって「人間中心」を毀損するため，人間の意思決定へ不適切な影響を及ぼす．「自律性」の毀損は，汚染された記憶・検索結果による意図しない行動により自律的動作が困難になる．その結果，個人・組織への財産上その他の損害という「安全性」の問題や，意図しない自律挙動の反復による AI サービスへの「レピュテーション」の低下が生じる．

© 2026 Information Processing Society of Japan

表 2　ケーススタディにおける SysD と SocD を横断する毀損要素の波及

ケース	脅威 / 攻撃	CIA の要素 (SysD)	AI に関連する要素 (SysD)	SocD
1	● プロンプトインジェクション	● 完全性	→ ● 倫理性	→ ● 法令整合性 ● レピュテーション
			→ ● 制御可能性	→ ● 人間中心 ● 多様性
2	● ポイズニング （メモリ，RAG）	● 完全性	→ ● 信頼性	→ ● 情報の真正性 ● 公平性 ● 人間中心
			→ ● 自律性	→ ● 安全性 ● レピュテーション
3	● 生成 AI の情報漏えい	● 機密性 （完全性）	→ ● 制御可能性	→ ● プライバシー ● レピュテーション
			→	→ ● 平和的利用

5.3　事例 3：生成 AI における情報漏えい

生成 AI サービスには，機密情報，個人情報などの漏えいリスクがある．これは悪意ある攻撃だけでなく，誤用や設定不備からも生じる．第 1 の経路では，利用者が機微情報を誤って入力する，または不十分なアクセス制御・安全でない設定により情報が露出し，「機密性」が直接毀損される．第 2 の経路では，プロンプトインジェクションや権限濫用によって意図された挙動を操作し，制約を回避させるため，「完全性」が先に毀損され，続いて「機密性」が毀損されることになる．その結果，攻撃者は機密情報，システムプロンプト，内部命令などを抽出し得る．

「機密性」の毀損は，開発者・運用者が情報開示や運用制約を適切に制御できなくなるため，「制御可能性」も毀損し得る．最終的には，個人・機密情報の漏えいによる「プライバシー」侵害と機微属性の不正推定，顧客・企業情報の露出による提供者への信頼低下により「レピュテーション」の毀損，内部設定やプロンプト等の漏えいを利用した二次的サイバー攻撃・悪用による「平和的利用」の毀損へ波及する．

6.　知見と示唆

6.1　中間的なシステム要素を介した波及

分析した攻撃は社会的影響を直接生じさせるのではなく，まず完全性・機密性などの CIA 関連要素を毀損させ，信頼性，自律性，制御可能性などの AI システム関連要素を介して社会要素へ波及した．これらの中間要素は，システム障害が下流の危害へ発展する態様を決める重要な媒介とみなせる．毀損要素の波及関係へ抽象化すれば，技術的機構が異なる新たな脅威にも既知の波及構造を適用できる．

6.2　異なる障害から共通した社会的影響への収束

プロンプトインジェクション，メモリポイズニング，情報漏えいは攻撃面と影響の対象が異なるが，評判の低下や人間の意思決定の操作など，共通する社会的影響へ至っている．これは，社会的影響が攻撃手法そのものより，どの AI システム関連要素が毀損されるかに強く左右されることに起因する．特にレピュテーションは 3 つの全ての場合で表れており，影響が出やすい要素であることがわかり，直感的にも理解できる．

6.3　システム領域と社会領域の両方を考慮した対策の検討

技術的防御は，特定の攻撃の防止や個別の対象の強化に重点を置き，社会的対策は，影響発生後のプライバシー規制，偽・誤情報対策，公平性監査，コンプライアンスに重点を置く傾向がある．前者は，有害な出力等が境界外へ広がった後の危害を必ずしも防げず，後者は危害を生む技術的毀損から切り離されがちである．技術的な対策が攻撃成功率を低減させても，生成済みの有害出力は人やシステムを介して拡散し得る．したがって，両領域を接続した影響の波及をは迅速に把握し，それに基づいた対策の検討が重要である．

7.　提言

波及を考慮したリスク評価．組織と AI サービス提供者は，SysD と SocD を横断して AI セキュリティリスクが進展する過程の追跡可能性を高めるため，影響の波及を考慮したフレームワークを利用すべきである．攻撃による障害を再利用可能な毀損要素や影響へ抽象化することで，下流の社会的影響と重要な経路を体系的に分析できる．組織固有の AI 構成，運用環境，関係者を反映した仮想リスクシナリオを作成すれば，インシデント発生前に影響を予測し，予防的なリスク対策を講じることが期待できる．

対策の優先順位付け．社会的影響は複数の毀損要素からなる連鎖を通じて生じるため，関係を明示すれば，優先して

© 2026 Information Processing Society of Japan

遮断すべき経路と要素を特定できる．また，将来的には，望ましくない社会的影響から逆向きに分析し，必要な技術的・ガバナンス上の対策を導出することも可能である．例えば，ディープフェイクなどによる偽情報の拡散の防止には，技術的安全策，運用統制，教育などの様々な対策の組合せが必要となるため，取るべき対策の組み合わせに関しても検討できる．

ガバナンスとインシデント分析．インシデントデータベースは，何が起きてどの影響が生じたかだけでなく，両者を結ぶ毀損される要素，波及経路，影響を受けた関係者を明示的に記録すべきである．構造化された記録の蓄積により，技術的には無関係に見える事例間の反復パターンを特定し，対策やポリシーの設計に活用できる．こうした影響の波及の表現は，異なる分析用語を用いてきた技術とガバナンスのコミュニティを接続する共通言語にもなり得る．

8. 本研究の課題

本研究にはいくつかの課題がある．第 1 に，毀損された要素と波及関係のマッピングは，文献，インシデント，専門的解釈に基づき主に著者が手動で行った．複雑で文脈依存の関係を慎重に扱える反面，主観性が入り，再現性と拡張性が制限される．大規模な文献・インシデント情報と LLM を用いた分析を用い，関係性を半自動または自動で特定・検証する手法が必要である．

第 2 に，要素と負の影響の分類も，既存の枠組み，指針，インシデント報告を手作業で整理して構築した．AI 技術の進展に伴い，現行の概念は表現できない新たなシステムの特性，社会的要素，攻撃が現れる可能性があるため，新たな要素を動的に取り込む自動的・適応的な分類手法を検討する．

第 3 に，現行のフレームワークは既存の攻撃・インシデントの事後分析のみを支援できる．大規模な事象が発生する前に新たな脅威を評価するため，AI 支援のシミュレーションやシナリオ生成によって仮想リスクシナリオを作成し，連鎖的な影響と重要な介入点を特定する方法を検討する必要がある．

9. おわりに

本稿では，AI システムにおける負の影響がシステム領域と社会領域を横断する過程を明示的にモデル化するための分析フレームワークを提案し，その重要性を議論した．攻撃または社会的影響を個別に分類する既存の取り組みと異なり，本フレームワークはシステムレベルの障害と広範な社会的影響を結ぶ波及の経路を可視化するために有用である．代表的な攻撃のケーススタディから，既存の取り組みでは捉えにくい波及経路を明らかにした．AI が社会と密接に関わる様々な分野で利活用され始めていることから，AI セキュリティはソシオテクニカルな問題として理解し，技術的対策とガバナンスを検討することが重要がある．本研究における影響の明示的な波及の視点は，技術的な AI セキュリティ研究と社会的リスク分析を接続し，包括的なガバナンス，リスク評価などを発展させる重要な基盤となることを望んでいる．

謝辞　本研究は，JST 経済安全保障重要技術育成プログラム【JPMJKP24C4】の支援を受けたものです．

参考文献

[1] Szegedy, C., Zaremba, W., Sutskever, I., Bruna, J., Erhan, D., Goodfellow, I. and Fergus, R.: Intriguing properties of neural networks, *arXiv preprint arXiv:1312.6199* (2013).

[2] Papernot, N., McDaniel, P., Jha, S., Fredrikson, M., Celik, Z. B. and Swami, A.: The limitations of deep learning in adversarial settings, *2016 IEEE European symposium on security and privacy (EuroS&P)*, IEEE, pp. 372–387 (2016).

[3] Biggio, B., Nelson, B. and Laskov, P.: Poisoning attacks against support vector machines, *arXiv preprint arXiv:1206.6389* (2012).

[4] Ramirez, M. A., Kim, S.-K., Hamadi, H. A., Damiani, E., Byon, Y.-J., Kim, T.-Y., Cho, C.-S. and Yeun, C. Y.: Poisoning attacks and defenses on artificial intelligence: A survey, *arXiv preprint arXiv:2202.10276* (2022).

[5] Tramèr, F., Zhang, F., Juels, A., Reiter, M. K. and Ristenpart, T.: Stealing machine learning models via prediction {APIs}, *25th USENIX security symposium (USENIX Security 16)*, pp. 601–618 (2016).

[6] Greshake, K., Abdelnabi, S., Mishra, S., Endres, C., Holz, T. and Fritz, M.: Not what you've signed up for: Compromising real-world llm-integrated applications with indirect prompt injection, *Proceedings of the 16th ACM Workshop on Artificial Intelligence and Security*, pp. 79–90 (2023).

[7] Shen, X., Chen, Z., Backes, M., Shen, Y. and Zhang, Y.: " do anything now": Characterizing and evaluating in-the-wild jailbreak prompts on large language models, *Proceedings of the 2024 on ACM SIGSAC Conference on Computer and Communications Security*, pp. 1671–1685 (2024).

[8] Lu, L., Yan, H., Yuan, Z., Shi, J., Wei, W., Chen, P.-Y. and Zhou, P.: Autojailbreak: Exploring jailbreak attacks and defenses through a dependency lens, *arXiv preprint arXiv:2406.03805* (2024).

[9] MITRE Corporation: MITRE ATLAS: Adversarial Threat Landscape for Artificial-Intelligence Systems, `https://atlas.mitre.org` (2025). Accessed: 2026-05-13.

[10] OWASP Foundation: OWASP AI Exchange, `https://owaspai.org/` (2026).

[11] OECD: OECD AI Incident Monitor, `https://oecd.ai/en/incidents` (2023). Accessed: 2026-04-24.

[12] AIID: AI Incident Database, `https://incidentdatabase.ai/` (2020). Accessed: 2026-04-24.

[13] AIAAIC: AIAAIC, `https://www.aiaaic.org/` (2019). Accessed: 2026-04-24.

[14] NIST: Artificial Intelligence Risk Management Framework (AI RMF 1.0), Technical report (2023).

[15] Gu, T., Dolan-Gavitt, B. and Garg, S.: Badnets: Identifying vulnerabilities in the machine learning model sup-

© 2026 Information Processing Society of Japan

ply chain, *arXiv preprint arXiv:1708.06733* (2017).
[16] Shokri, R., Stronati, M., Song, C. and Shmatikov, V.: Membership inference attacks against machine learning models, *2017 IEEE symposium on security and privacy (SP)*, IEEE, pp. 3–18 (2017).
[17] Kiribuchi, N., Zenitani, K. and Semitsu, T.: Securing AI Systems: A Guide to Known Attacks and Impacts (2025).
[18] Li, L., Xie, T. and Li, B.: Sok: Certified robustness for deep neural networks, *2023 IEEE symposium on security and privacy (SP)*, IEEE, pp. 1289–1310 (2023).
[19] Wingarz, T., Lauscher, A., Edinger, J., Kaaser, D., Schulte, S. and Fischer, M.: SoK: Towards Security and Safety of Edge AI, *arXiv preprint arXiv:2410.05349* (2024).
[20] Noppel, M. and Wressnegger, C.: SoK: Explainable machine learning in adversarial environments, *2024 IEEE Symposium on Security and Privacy (SP)*, IEEE, pp. 2441–2459 (2024).
[21] Kheya, T. A., Bouadjenek, M. R. and Aryal, S.: The pursuit of fairness in artificial intelligence models: A survey, *arXiv preprint arXiv:2403.17333* (2024).
[22] Parraga, O., More, M. D., Oliveira, C. M., Gavenski, N. S., Kupssinskü, L. S., Medronha, A., Moura, L. V., Simões, G. S. and Barros, R. C.: Fairness in Deep Learning: A survey on vision and language research, *ACM Computing Surveys*, Vol. 57, No. 6, pp. 1–40 (2025).
[23] Mersha, M., Lam, K., Wood, J., AlShami, A. and Kalita, J.: Explainable artificial intelligence: A survey of needs, techniques, applications, and future direction, *Neurocomputing*, p. 128111 (2024).
[24] Schwalbe, G. and Finzel, B.: A comprehensive taxonomy for explainable artificial intelligence: a systematic survey of surveys on methods and concepts, *Data Mining and Knowledge Discovery*, Vol. 38, No. 5, pp. 3043–3101 (2024).
[25] Lee, H.-P., Yang, Y.-J., Von Davier, T. S., Forlizzi, J. and Das, S.: Deepfakes, phrenology, surveillance, and more! a taxonomy of ai privacy risks, *Proceedings of the 2024 CHI Conference on Human Factors in Computing Systems*, pp. 1–19 (2024).
[26] Golda, A., Mekonen, K., Pandey, A., Singh, A., Hassija, V., Chamola, V. and Sikdar, B.: Privacy and security concerns in generative AI: a comprehensive survey, *IEEE Access* (2024).
[27] Schmitt, M. and Flechais, I.: Digital deception: Generative artificial intelligence in social engineering and phishing, *Artificial Intelligence Review*, Vol. 57, No. 12, pp. 1–23 (2024).
[28] Schröer, S. L., Apruzzese, G., Human, S., Laskov, P., Anderson, H. S., Bernroider, E. W., Fass, A., Nassi, B., Rimmer, V., Roli, F. et al.: SoK: On the offensive potential of AI, *2025 IEEE Conference on Secure and Trustworthy Machine Learning (SaTML)*, IEEE, pp. 247–280 (2025).
[29] Slattery, P., Saeri, A. K., Grundy, E. A., Graham, J., Noetel, M., Uuk, R., Dao, J., Pour, S., Casper, S. and Thompson, N.: The ai risk repository: A comprehensive meta-review, database, and taxonomy of risks from artificial intelligence, *arXiv preprint arXiv:2408.12622* (2024).
[30] Pankajakshan, R., Biswal, S., Govindarajulu, Y. and Gressel, G.: Mapping llm security landscapes: A comprehensive stakeholder risk assessment proposal, *arXiv preprint arXiv:2403.13309* (2024).
[31] OWASP Foundation: 2025 Top 10 Risk & Mitigations for LLMs and Gen AI Apps, `https://genai.owasp.org/llm-top-10/` (2024).
[32] OWASP Foundation: OWASP Top 10 for Agentic Applications for 2026, `https://genai.owasp.org/resource/owasp-top-10-for-agentic-applications-for-2026/` (2025).
[33] NIST: NIST Trustworthy and Responsible AI: Adversarial Machine Learning, Technical report (2024).
[34] OECD: OECD AI principles, `https://www.oecd.org/en/topics/ai-principles.html` (2024). Accessed: 2026-04-28.
[35] Bengio, Y. et al.: International AI Safety Report, *arXiv preprint arXiv:2501.17805* (2025).
[36] Center for Security and Emerging Technology: CSET AI Harm Taxonomy, `https://cset.georgetown.edu/publication/adding-structure-to-ai-harm` (2023). Accessed: 2026-05-08.
[37] Axon, L., Erola, A., Agrafiotis, I., Goldsmith, M. and Creese, S.: Analysing cyber-insurance claims to design harm-propagation trees, *2019 International Conference On Cyber Situational Awareness, Data Analytics And Assessment (Cyber SA)*, IEEE, pp. 1–4 (2019).
[38] Caven, P. J., Ma, X., Andalibi, V. and Camp, L. J.: Using an SBOM to mitigate a lemons market, *Available at SSRN 5002288* (2024).
[39] Caven, P. J., Abbott, J. and Camp, L. J.: Towards a more secure ecosystem: Implications for cybersecurity labels and sboms, *TPRC*, Vol. 51, pp. 1–15 (2023).
[40] Zhang, S., Lyu, M. and Gharakheili, H. H.: A Survey on Mapping Digital Systems with Bill of Materials: Development, Practices, and Challenges, *arXiv preprint arXiv:2601.11678* (2026).
[41] European Commission: The General-Purpose AI Code of Practice, `https://digital-strategy.ec.europa.eu/en/policies/contents-code-gpai` (2025). Accessed: 2026-05-13.
[42] Ministry of Internal Affairs and Communications: AI Business Guidelines, `https://www.soumu.go.jp/main_content/001064305.pdf` (2025). Accessed: 2026-05-12.
[43] AI Safety Institute Japan: Guide to Evaluation Perspectives on AI Safety (Version 1.10), `https://aisi.go.jp/assets/pdf/ai_safety_eval_v1.10_en.pdf` (2025).
[44] Stanford Institute for Human-Centered Artificial Intelligence: AI Index Report 2025, Technical report, Stanford HAI (2025).
[45] Sunil, B. D., Sinha, I., Maheshwari, P., Todmal, S., Mallik, S. and Mishra, S.: Memory poisoning attack and defense on memory based llm-agents, *arXiv preprint arXiv:2601.05504* (2026).
[46] Zou, W., Geng, R., Wang, B. and Jia, J.: {PoisonedRAG}: Knowledge corruption attacks to {Retrieval-Augmented} generation of large language models, *34th USENIX Security Symposium (USENIX Security 25)*, pp. 3827–3844 (2025).

付　　録

A.0.1　本研究により特定した要素

表 A·1 に SysD に分類される要素とそれぞれの要素の定義を示す．また，表 A·2 に SocD に分類される要素とそれぞれの要素の定義を示す．

© 2026 Information Processing Society of Japan

表 A·1 本研究により特定した SysD の要素

要素	定義
機密性	AI モデルおよび AI モデルが扱うデータに，権限のない者がアクセスできないこと．
完全性	AI モデルや推論過程が不正に改変・操作されず，設計時に意図された動作および出力が維持されること．
可用性	AI が必要なときに，必要な機能やサービスを提供できること．
説明可能性	AI が出力の根拠や生成に至る過程を説明できること．
出力の公平性	AI が特定の個人や集団に対して，不当に偏った出力を行わないこと．
セキュリティ確保	AI が人の生命，身体，財産および精神に危害を及ぼさないよう，安全機構が設けられていること．
精度	AI が目的を達成するために必要な水準の精度を満たすこと．
制御可能性	AI が管理者の制御下にあり，暴走したり外部環境へ悪影響を及ぼしたりしないこと．
信頼性	AI の出力や動作が信頼できること．
倫理性	AI が社会規範や倫理的原則に沿って振る舞うこと．
自律性	AI が目標や状況に応じて手順や必要なツールを判断し，それらを活用して主体的に動作できること．

表 A·2 本研究により特定した SocD の要素

要素	定義
平和的利用	AI が人間の生活を豊かにするために利用されること．
プライバシー	AI がプライバシーを侵害せず，プライバシーに関する法令や慣習を遵守すること．
情報の真正性	AI が出力した情報について，出所の正当性および非改ざん性が保証されること．
ユーザビリティ	AI が目的を達成するために必要な水準のユーザビリティを満たすこと．
公平性	AI による不当に偏った出力によって，個人や集団が不利益を被らないこと．
著作権・オーサーシップ	AI が出力したコンテンツが，著作権およびオーサーシップに関する法令や慣習に従って利用されること．
透明性	システムが AI を利用している事実，AI の限界，および AI の利用に伴うリスクが明示されること．
レピュテーション	AI システム提供者が適切に評価され，社会から信頼されること．
法令整合性	AI が関連する法律や規則に従って利用・運用されること．
人間中心	AI が人間の利益のために適切に利用されること．
安全性	AI システムやサービスの開発，提供および利用を通じて，ステークホルダーの身体，精神または財産に危害が及ばないこと．
多様性	AI の利用において表現や言論の自由が確保され，偏見や不当な偏りが生じないこと．
持続可能性	AI が回復不能な影響を及ぼさないよう，持続可能な限度を超えて資源を利用しないこと．
自立性	人間が自身の価値観や判断基準に基づき，AI の出力や動作を判断・理解して活用できること．

© 2026 Information Processing Society of Japan