AI システムの安全論証と AI セキュリティの関係に関する調査と考察

溝口 誠一郎[1]　櫻井 幸一[2]

概要：本発表では，AI Safety 研究がモデル安全性から AI システム全体の安全論証へと発展している潮流を整理するとともに, Prompt Injection や Jailbreak などの AI セキュリティ課題を安全論証の一部として統合的に扱う Safety-Security Co-Assurance の必要性を示す．さらに ISO/PAS 8800 等の動向を踏まえ，今後の AI システム保証の方向性を議論する．

キーワード：AI の安全性，安全論証

Investigating the Relationship Between AI System Safety Assurance and AI Security

Seiichiro Mizoguchi[1]　Kouichi Sakurai[2]

Abstract: This presentation reviews the evolving trajectory of AI Safety research, highlighting the shift from a focus on model-level safety toward safety assurance of entire AI systems. It also demonstrates the need for Safety-Security Co-Assurance, an integrated approach that treats AI security challenges, such as prompt injection and jailbreak attacks, as integral components of the safety assurance process. Furthermore, drawing on recent developments including ISO/PAS 8800, the presentation discusses future directions for the assurance of AI-based systems.

Keywords: AI Safety, Assurance

1. はじめに

近年，生成 AI や AI エージェントをはじめとする高度な AI システムの社会実装が急速に進展する中，その安全性をどのように評価し，説明し，保証するかが重要な課題となっている．従来はモデルの精度や性能向上が主な関心事であったが，AI の活用領域が社会インフラや重要な意思決定へ拡大するにつれて，誤動作や不適切な判断，セキュリティ脅威，データ品質の問題などを含めた総合的なリスク管理が求められるようになった．こうした背景のもと，EU AI Act をはじめとする各国の法規制や AI Safety Institute によるガイドライン整備が進むとともに，ISO/IEC 標準や機能安全規格においても AI を対象とした安全性評価・保証の枠組みが整備されつつある．また学術分野では，モデル単体ではなく AI システム全体を対象とした安全論証や評価フレームワークの研究が活発化している．本稿では，法規制，標準化，機能安全，学術研究の各観点から，AI システムの安全性評価に関する最新動向を整理し，その共通点と今後の方向性について考察する．

2. 法規や行政による安全性確保のアプローチ

まず，The AI Act や，各国の AISI 等で議論されている，AI システムの安全性確保のアプローチについてまとめる．

2.1 EU: The AI Act

EU The AI Act [1]は，AI をリスクベースアプローチで規制しており，以下の 4 つのリスクレベルに基づいて規制をかけている．

- Unacceptable Risk (禁止 AI)
- High Risk (高リスク AI)
- Limited Risk (透明性の確保が求められる AI)
- Minimal Risk (上記以外の AI であり，規制の対象とならない)

高リスク AI については, リスク管理システムを構築し，データおよびデータガバナンスの適正化，動作ログの記録と人間による監督，AI に関する説明 (透明性の確保), 精度，堅牢性，サイバーセキュリティの確保と言った義務が課せられる．

また，大規模基盤モデル (General-Purpose AI Model, GPAI) については，それ単体で規制の対象となっており，GPAI モデルに関する情報の提供と言った透明性の確保が求められる．さらに，社会基盤として利用されるような

1 DNV ビジネスアシュアランスジャパン株式会社
DNV Business Assurance Japan K.K
2 九州大学
Kyushu University

© 2026 Information Processing Society of Japan

This paper is work in progress and not peer-reviewed.

GPAI となると，モデルの評価や，システミックリスクの評価，レッドチーミング，インシデント報告，およびサイバーセキュリティの確保といった追加の義務が発生する．

AI Safety の確保という観点では，AI Act はリスク管理システムを中心に据え，AI の安全性や基本的人権に影響を与えるリスクをライフサイクル全体で継続的に特定・分析・評価・低減することを事業者に求めている．その意味で，個別のハザードへの対応を規定するのではなく，リスク管理プロセスの構築・運用を求めるアプローチを採用している．一方で，技術的な評価やテストの詳細が完全に事業者の裁量に委ねられているわけではなく，精度・堅牢性・サイバーセキュリティの達成，試験データによる検証，性能指標の文書化などの要求が課されている．具体的なテスト手法や評価方法については，事業者のリスク管理の中で計画される部分が大きい．

2.2 その他の法規

AI Safety を AI 倫理的な側面で要求しているその他の法規をいくつか挙げる．

Consumer Protections for Artificial Intelligence Act [2]は，米国コロラド州の州法である．主な規制の対象は，高リスク AI システムで，雇用，教育，金融，医療，法律，行政と言ったユースケースで重要な意思決定に AI が利用される場合に特定の義務が課される．主な義務として，アルゴリズム差別 (algorithmic discrimination) の防止，リスク管理プログラムの整備，影響評価，AI 利用の通知 (透明性確保)，人による監視，監査・記録保持といった，EU The AI Act に近い内容である．特徴としては，高リスク AI による差別防止が主目的であり，精度や堅牢性といった観点は含まれない．

中国の生成 AI サービス管理暫定弁法 [3]は，生成 AI の開発・提供事業者に対して，厳格なデータ品質と安全管理を要求している．データ品質管理では，学習データの真実性，正確性，客観性，多様性を確保することを義務付けている．また，サービス公開前の安全評価と，アルゴリズムの仕組みに関する説明責任を要求している．

EU の一般データ保護規則 (GDPR) [4] は，個人データを処理する AI システムに対し，プロファイリングや自動化された意思決定に関する法律を課している．具体的には，データの正確性の原則として，学習データおよび入力データの正確性を維持する義務や，自動化された処理のロジックや，意義，想定される結果について，対象者に有意義な情報を提供する説明責任などが要求される．

EU の新機械規則 ((EU) 2023/1230) [5] は，AI の自己学習や自律動作によって予期せぬ物理的危険が生じないよう，機能安全とリスク評価を実施することや，データの整合性と説明性を確保するため，意思決定プロセスのログ保存や，安全機能に関わるデータの品質管理を要求している．

セクター別法規として，自動車の保安基準の国際基準の一つである UN-R157 [6]について述べる．UN-R157 は，自動車線維持装置といった，自動運行装置に関する国際基準を定めたもので，AI を含む，自動運行装置のソフトウェアの安全性要件が規定されている．具体的には，セーフティに関するリスク管理や，ソフトウェアならびにログの管理による，挙動の再現性・検証可能性の確保が要求されている．

2.3 AI Safety Institute

AI Safety については，各国の AISI が，AI システムの安全な提供・利用に関するガイドライン等を発行している．

日本の Japan AISI [7], IPA 及び総務省・経済産業省は，AI の安全性確保に関するガイドラインとして，AI 事業者ガイドラインや，AI セーフティに関する評価観点ガイド，レッドチーミングガイド，データ品質マネジメントガイドブック等を公開している．

米港では，US AISI [8]並びに NIST [9], CISA [10]が，AI リスクマネジメントフレームワーク (NIST AI RMF 1.0 [11] / Generative AI Profile: NISTAI 600-1) や安全な AI システム開発のためのガイドライン等を発行している．

英国 UK AISI [12], NCSC [13], DSIT [14]は，AI モデル安全性評価基準やセキュアな AI 利用ガイダンスを発行している．

これらのガイドラインに共通して表れるポイントは以下である：

- セキュリティ
  - 提供者：脅威モデリング，入力サニタイズ，プロンプトインジェクション防御，定期的なレッドチーミング演習
  - 利用者：最小権限での API 接続，社内データ連携時のアクセス制御，シャドーAI 利用の禁止
- データガバナンス
  - 提供者：学習データの出自管理，著作権・プライバシー侵害のリスクの排除，バイアス監査
  - 利用者：入力プロンプトへの機密・個人情報の非保持設定，利用規約の厳守
- 透明性・信頼性の確保
  - 提供者：システムカード・モデルカードの公開，透かし技術の実装
  - 利用者：出力結果のファクトチェック (Human-in-the-loop), AI 生成物である旨の明示
- インシデント対応
  - 提供者：脆弱性報告窓口の設置，キルスイッチやモデルの迅速なロールバック体制
  - 利用者：異常挙動・情報漏洩発生時の報告ルート確立，代替手段の確保

© 2026 Information Processing Society of Japan

2.4 法規と AI セキュリティ

The AI Act をはじめとした各法規や，AISI のガイドラインが達成しようとしていることは，AI 倫理に関するリスクマネジメントであり，リスクには，AI システムの不十分性や不確実性，データの品質問題と言った，技術的課題も含まれる．AI セキュリティは，これらの技術的な弱さに対する複合的な攻撃から，AI システムが達成すべき安全目標が侵害されることを防ぐことに他ならない．

3. 国際標準やベストプラクティスから見る安全性確保のアプローチ

3.1 AI の安全性に関わる主要な国際標準

AI の安全性・信頼性・ガバナンスに関する主要な国際標準は以下が挙げられる：

- AI ガバナンス・マネジメント
  - ISO/IEC 42001 Artificial Intelligence Management System [15]: AI 利用組織向けのガバナンス，リスク管理，継続的改善の枠組みを規定
  - ISO/IEC 38507 Governance implications of the use of AI by organizations [16]: 経営層向けの AI ガバナンス指針
- AI リスク管理・安全性
  - ISO/IEC 23894 Artificial Intelligence - Guidance on Risk Management [17]: AI 特有のリスク管理手法を定義．バイアス，安全性，セキュリティ，プライバシー等を対象とする．
  - ISO/IEC 42005 AI System Impact Assessment [18]: AI システムの，人権，社会，安全性への影響を評価するための指針．
- AI の概念・信頼性の基盤
  - ISO/IEC 22989 AI Concepts and Terminology [19]: AI に関する共通用語・定義集で，説明可能性，公平性，自律性と言った用語を整理している．
  - ISO/IEC 23053 Framework for AI Systems Using Machine Learning [20]: 機械学習ベース AI システムのフレームワークで, AI システムアーキテクチャと，AI の品質・安全性評価の共通基盤となっている．
- AI ライフサイクル・開発プロセス・データ品質管理
  - ISO/IEC 5338 AI System Life Cycle Processes [21]: AI システムのライフサイクルを定義しており, データ収集, 学習, 運用監視，改善の中で，AI 安全性を継続的に確保するためのプロセス標準である．
  - ISO/IEC 8183 Data Life Cycle Framework [22]: AI に使用するデータのライフサイクル管理を示しており，データ品質・データガバナンスの基盤である．
  - ISO/IEC 5259 Data quality for analytics and machine learning (ML) [23]: AI や機械学習で用いるデータの品質を定義・評価・管理するための標準シリーズ．AI の安全性・公平性・信頼性は学習データの品質に大きく依存するため，AI 安全性の基盤となる標準と位置付けられている．

これらの標準を利用することで，EU AI Act や NIST AI RMF などの規制・フレームワークに対応することが可能となっている．

3.2 AI セキュリティとの関連と課題

これらの標準の中で, AI セキュリティに関連する項目は以下である：

- ISO/IEC 42001
  - リスク管理として，AI システムの脅威管理やセキュリティリスク管理を扱う．
- ISO/IEC 23894
  - AI リスクとして，Prompt Injection, Data Poisoning，モデル改ざん，学習モデル盗難，プライバシー侵害，AI システムのセキュリティ脆弱性の悪用を挙げている．
  - 敵対的攻撃については，AI 固有のリスク源の一つとして扱っている．
- ISO/IEC 5338
  - AI システムのライフサイクル管理において，AI 特有のセキュリティリスクは，データ取得，モデル学習，モデル配備，運用監視，モデル廃棄と言ったフェーズで考慮が必要となる．
- ISO/IEC 5259 シリーズ
  - データの品質は，Data Poisoning，学習データ改ざん，データ完全性・真正性，ラベル品質管理に直接的に関係する．

ISO/IEC 5338 は，AI システムのライフサイクルを規定しているだけであり，各フェーズでセキュリティ上どのようなことをどれくらいの深さまでやらないといけないかは，ISO/IEC 5338 の範囲外である．そこで，ライフサイクルに潜む，ISO/IEC 23894 ベースの AI リスクのマッピングと，ISO/IEC 5259 ベースのデータ管理によってリスク低減できる AI リスクや，一般的な情報セキュリティ管理によって低減できる AI リスクを明らかにすることがポイントである．

© 2026 Information Processing Society of Japan

3.3 機能安全

セクター別にみると，自動車分野において，AI システムの安全性に関わる国際標準として，ISO/PAS 8800 Road vehicles — Safety and artificial intelligence [24] がある．ISO/PAS 8800 は，自動車の安全規格である，機能安全 (ISO 26262 [25]) と，意図機能の安全 (ISO 21448 [26]) による安全性の保証 (Assurance) において，システムに AI コンポーネントを含む場合に適用するアドオン規格である．

ISO/PAS 8800 の考え方は，AI コンポーネントが安全であることを直接証明するのではなく，AI を含むシステム全体が許容できないリスクを生じないことを，構造化された安全性論証（Safety Assurance Argument）によって示すことにある．ISO/PAS 8800 において，AI コンポーネント固有の論証ポイント (クレーム) として以下がある：

- データが十分であること
- モデル性能が十分であること
- 不確実性を管理していること
- 出力不足を評価していること

ISO/PAS 8800 では，これらを論拠 (Argument) と証拠 (Evidence) を基に，許容できないリスクを生じないと説明することによって，安全性を示すというやり方を取る．

AI セキュリティ観点で ISO/PAS 8800 の論証構造を見ると，Data Poisoning やモデル改ざん，学習環境侵害と言ったセキュリティリスクが露呈すると，データ品質やモデルの妥当性の論証根拠そのものが崩れるため，AI セキュリティリスクも併せて評価することになる．

4. 技術的/学術的アプローチ

ここでは，AI Safety に関する学術的なアプローチについてまとめる．

4.1 AI Safety と AI Security の関係

2024 年頃から，AI Safety の研究は，モデルを安全化する研究から，AI を含むシステム全体をどう安全証明するか，という研究課題にシフトしている．これは，AI が信頼できないことを前提にシステムを設計するという考え方から来ているもので，従来の安全アーキテクチャ研究の主流となる考え方である．

4.2 AI Safety の研究テーマの遷移

NeurIPS [27]や ICML [28]，ICLR [29]では，従来から Adversarial Examples, Model Robustness と言ったテーマが研究されていたが，近年では，Jailbreak, Prompt Injection, Trustworthy Foundation Model, Reliable ML, Alignment Attack, Safety Guardrails, Model Extraction といったテーマが扱われている．同じく，USENIX Security [30]や IEEE S&P [31], ACM CCS [32]といった主要セキュリティ会議においても，同様のキーワードがテーマになっている．特に近年では，AI Agent のセキュリティや安全論証が話題となるケースがある．以下に，いくつかの論文を挙げる：

- Boming Xia ら，An AI System Evaluation Framework for Advancing AI Safety: Terminology, Taxonomy, Lifecycle Mapping (2024) [33]: この論文の主張は，AI モデル単体の評価では不十分であり，AI システム全体を評価対象にするべき，というものである．評価対象の AI システムを，AI Model, Data, Non-AI Components, Safety Guardrails, System-level Interactions, Environmental Affordances に分割して評価を行い，システム全体の Safety を評価している．このような考え方は，先の，ISO/PAS 8800 の Safety Assurance の考え方とマッチしている．

- Patrick Chao ら，JailbreakBench: An Open Robustness Benchmark for Jailbreaking Large Language Models (NeurIPS 2024) [34]: JailbreakBench は，大規模言語モデル（LLM）の Jailbreak 耐性を評価するための標準ベンチマークであり，AI セキュリティ評価結果を安全保証のエビデンスとして利用し始めた転換点とも言える．言い換えると，Jailbreak 耐性試験は AI システム安全論証における V&V（Verification & Validation）の一種であるとも言える．
- Graham Neubig ら，OpenAgentSafety: A Comprehensive Framework for Evaluating Real-World AI Agent Safety (ICLR 2026) [35]: AI Agent が，Web ブラウザ，Bash，コード実行，ファイルシステム，メッセージ送信を扱う環境で安全性評価を行うフレームワークを提案している．
- S. Chakraborty ら，Data-Centric Safety and Ethical Measures for Data and AI Governance (arXiv, 2025) [36]: この論文は，AI の安全性・倫理性・信頼性をモデル中心ではなくデータ中心（Data-Centric）に捉え直すことを主張しており，データセット品質が AI の安全性や悪用リスクに直接影響するという立場を取っている．データライフサイクル全体での安全対策やガバナンスを提案しているため，ISO/PAS 8800 のデータ安全ライフサイクルや，AI 安全論証におけるデータ品質エビデンスの議論と親和性が高い論文となっている．

4.3 その他の AI Safety Framework

Fraunhofer IKS は，自動運転や産業システム向けに，AI Safety Assurance Case を研究している．基本的な考え方は，AI は必ず誤る前提でシステムを設計して安全を論証する，というもので，その思想に従ったシステムアーキテクチャを提案している．言い換えると，AI モデルの正しさを証明するのではなく，AI が誤った場合でもシステム全体が安全状態へ移行できることを論証する Safety Assurance

© 2026 Information Processing Society of Japan

Framework [37]を提案している．

DNV は，AI Assurance に関するベストプラクティス集[38]を提案している．本ベストプラクティス集では，Trustworthy AI を，Safety, Security, Reliability, Transparency, Governance の統合問題として扱っている．これは，AI の保証をモデルレベルに限定せず，安全性・セキュリティ・ガバナンスを統合した継続的なシステム保証として位置付けるものである．また，AI システムアーキテクチャを，AI モデル，データ，センサー，デジタルツイン，通常ソフトウェア，人間，運用環境の相互作用として定義することを述べている．

5. 考察

AI セキュリティの研究課題は，モデルの安全性確保のテーマ上のセキュリティ担保から，AI システムの安全性論証のテーマ上のセキュリティ担保にシフトしつつある．システムセキュリティとして AI セキュリティを扱う場合は，AI システムのアーキテクチャを定義し，AI モデルとそれ以外のコンポーネントの相互作用を考慮しながらセキュリティリスク評価をすることになる．一方で，データの品質管理は，モデルの安全性確保と，AI システムの安全性確保の両面に関わり，EU The AI Act や ISO/PAS 8800 の安全論証の構造ともマッチする．AI モデルに対する安全機構が AI セキュリティのリスクをどこまでカバーできるかを評価するためには，データ品質の評価も不可欠である．

6. おわりに

調査の結果，AI の安全性評価は，個々の AI モデルの性能評価から，AI を含むシステム全体の安全性を論証するアプローチへと移行しつつあることが確認できた．法規制，国際標準，機能安全，学術研究のいずれにおいても，リスク管理，データ品質，セキュリティ，ガバナンスを統合的に扱う考え方が共通している．今後は，AI 固有の脅威への対策だけでなく，安全論証を支える客観的な評価手法やエビデンスの整備が，安全で信頼できる AI システムの実現に向けた重要な課題になると考えられる．

参考文献

[1] European Parliament & Council of the European Union, "Regulation (EU) 2024/1689 of the European Parliament and of the Council of 13 June 2024 laying down harmonised rules on artificial intelligence and amending Regulations (EC) No 300/2008, (EU) No 167/2013, (EU) No 168/2013, (EU) 2018/858, (EU) 2018/1139 an," Official Journal of the European Union, L 2024/1689, 2024. [Online]. Available: https://eur-lex.europa.eu/eli/reg/2024/1689/oj.

[2] Colorado General Assembly, "Consumer Protections for Artificial Intelligence Act (SB24-205)," Colorado General Assembly., [Online]. Available: https://leg.colorado.gov/bills/sb24-205.

[3] Cyberspace Administration of China, National Development and Reform Commission, Ministry of Education, Ministry of Science and Technology, Ministry of Industry and Information Technology, Ministry of Public Security, & National Radio and Television Admini, "Interim Measures for the Management of Generative Artificial Intelligence Services," 2023. [Online]. Available: https://www.cac.gov.cn/2023-07/13/c_1690898327029107.htm.

[4] European Parliament & Council of the European Union, "Regulation (EU) 2016/679 of the European Parliament and of the Council of 27 April 2016 on the protection of natural persons with regard to the processing of personal data and on the free movement of such data, and repealing Directive 95/46/EC (General Da," Official Journal of the European Union, L 119, 1-88, 2016. [Online]. Available: https://eur-lex.europa.eu/eli/reg/2016/679/oj.

[5] European Parliament & Council of the European Union, "Regulation (EU) 2023/1230 of the European Parliament and of the Council of 14 June 2023 on machinery and repealing Directive 2006/42/EC of the European Parliament and of the Council and Council Directive 73/361/EEC," Official Journal of the European Union, L 165, 1-102, 2023. [Online]. Available: https://eur-lex.europa.eu/eli/reg/2023/1230/oj.

[6] United Nations Economic Commission for Europe, "UN Regulation No. 157: Uniform provisions concerning the approval of vehicles with regard to Automated Lane Keeping Systems (ALKS) (E/ECE/TRANS/505/Rev.3/Add.156)," United Nations, 2021. [Online]. Available: https://unece.org/transport/documents/2021/03/standards/un-regulation-no-157-automated-lane-keeping-systems-alks.

[7] AI Safety Institute Japan, "About AISI," 2024. [Online]. Available: https://aisi.go.jp/about/.

[8] National Institute of Standards and Technology, "U.S. Artificial Intelligence Safety Institute (USAISI)," U.S.

© 2026 Information Processing Society of Japan

Department of Commerce, 2024. [Online]. Available: https://www.nist.gov/aisi.

[9] National Institute of Standards and Technology, "National Institute of Standards and Technology," U.S. Department of Commerce, [Online]. Available: https://www.nist.gov/.

[10] Cybersecurity and Infrastructure Security Agency, "About CISA," U.S. Department of Homeland Security, [Online]. Available: https://www.cisa.gov/about.

[11] N. I. o. S. a. Technology, "Artificial Intelligence Risk Management Framework (AI RMF 1.0) (NIST AI 100-1)," U.S. Department of Commerce, 2023. [Online]. Available: https://doi.org/10.6028/NIST.AI.100-1.

[12] Department for Science, Innovation and Technology, "AI Safety Institute: Overview," UK Government, 2024. [Online]. Available: https://www.gov.uk/government/publications/ai-safety-institute-overview.

[13] National Cyber Security Centre, "About the NCSC," Government Communications Headquarters, [Online]. Available: https://www.ncsc.gov.uk/section/about-ncsc/what-we-do.

[14] Department for Science, Innovation and Technology, "About us," UK Government, [Online]. Available: https://www.gov.uk/government/organisations/department-for-science-innovation-and-technology/about.

[15] International Organization for Standardization, "ISO/IEC 42001:2023: Information technology—Artificial intelligence—Management system," ISO, 2023. [Online]. Available: https://www.iso.org/standard/42001.html.

[16] International Organization for Standardization, "ISO/IEC 38507:2022: Information technology—Governance of IT—Governance implications of the use of artificial intelligence by organizations," ISO, 2022. [Online]. Available: https://www.iso.org/standard/56641.html.

[17] International Organization for Standardization, "ISO/IEC 23894:2023: Information technology—Artificial intelligence—Guidance on risk management," ISO, 2023. [Online]. Available: https://www.iso.org/standard/77304.html.

[18] International Organization for Standardization, "ISO/IEC 42005:2025: Information technology—Artificial intelligence (AI)—AI system impact assessment," ISO, 2025. [Online]. Available: https://www.iso.org/standard/42005.

[19] International Organization for Standardization, "ISO/IEC 22989:2022: Information technology—Artificial intelligence—Artificial intelligence concepts and terminology," ISO, 2022. [Online]. Available: https://www.iso.org/standard/74296.html.

[20] International Organization for Standardization, "ISO/IEC 23053:2022: Framework for artificial intelligence (AI) systems using machine learning (ML)," ISO, 2022. [Online]. Available: https://www.iso.org/standard/74438.html.

[21] International Organization for Standardization, "ISO/IEC 5338:2023: Information technology—Artificial intelligence—AI system life cycle processes," ISO, 2023. [Online]. Available: https://www.iso.org/standard/81118.html.

[22] International Organization for Standardization, "ISO/IEC 8183:2023: Information technology—Artificial intelligence—Data life cycle framework," ISO, 2023. [Online]. Available: https://www.iso.org/standard/83002.html.

[23] International Organization for Standardization, "ISO/IEC 5259-1:2024: Artificial intelligence—Data quality for analytics and machine learning (ML)—Part 1: Overview, terminology, and examples," ISO, 2024. [Online]. Available: https://www.iso.org/standard/81088.html.

[24] International Organization for Standardization, "ISO/PAS 8800:2024: Road vehicles—Safety and artificial intelligence," ISO, 2024. [Online]. Available: https://www.iso.org/standard/83303.html.

[25] International Organization for Standardization, "ISO 26262:2018: Road vehicles—Functional safety," ISO, 2018. [Online]. Available: https://www.iso.org/publication/PUB200262.html.

[26] International Organization for Standardization, "ISO 21448:2022: Road vehicles—Safety of the intended functionality," ISO, 2022. [Online]. Available: https://www.iso.org/standard/77490.html.

[27] "Conference on Neural Information Processing Systems," NeurIPS, [Online]. Available: https://neurips.cc/.

[28] "International Conference on Machine Learning,"

© 2026 Information Processing Society of Japan

ICML, [Online]. Available: https://icml.cc/.

[29] "International Conference on Learning Representations," ICLR, [Online]. Available: https://iclr.cc/.

[30] "USENIX Security Symposium," USENIX Association, [Online]. Available: https://www.usenix.org/conference/usenixsecurity.

[31] "IEEE Symposium on Security and Privacy," IEEE, [Online]. Available: https://www.ieee-security.org/.

[32] "ACM SIGSAC Conference on Computer and Communications Security (CCS)," Association for Computing Machinery Special Interest Group on Security, Audit and Control, [Online]. Available: https://www.sigsac.org/ccs/.

[33] B. Xia, Q. Lu, L. Zhu, and Z. Xing, "An AI System Evaluation Framework for Advancing AI Safety:," in *in Proceedings of the ACM International Conference on AI-powered Software (AIware 2024)*, 2024.

[34] P. Chao, A. Robey, E. Dobriban, H. Hassani, G. J. Pappas, and E. Wong, "JailbreakBench: An Open Robustness Benchmark for Jailbreaking Large Language Models," in *Advances in Neural Information Processing Systems (NeurIPS 2024)*, 2024.

[35] S. Vijayvargiya, A. B. Soni, X. Zhou, Z. Z. Wang, N. Dziri, G. Neubig, and M. Sap, "OpenAgentSafety: A Comprehensive Framework for Evaluating Real-World AI Agent Safety," in *Proceedings of the International Conference on Learning Representations (ICLR 2026)*, 2026.

[36] S. Chakraborty, Data-Centric Safety and Ethical Measures for Data and AI Governance, arXiv preprint arXiv:2506.10217, 2025.

[37] Fraunhofer Institute for Cognitive Systems (IKS), "Safety Assurance: Stringent Safety Proofs for AI," Fraunhofer IKS, Munich, Germany, [Online]. Available: https://www.iks.fraunhofer.de/en/research/safety-assurance.html.

[38] DNV, "DNV-RP-0671: Assurance of AI-enabled Systems," Det Norske Veritas (DNV), 2023. [Online]. Available: https://www.dnv.com/digital-trust/recommended-practices/assurance-of-ai-enabled-systems-dnv-rp-0671/.

© 2026 Information Processing Society of Japan