単一時刻の入力摂動に対する Vision-Language-Action モデルの脆弱性について

山辺 翔二郎[1,a)]　佐久間 淳[1,2]

概要：Vision–Language–Action（VLA）モデルは，視覚情報と言語指示からロボットの行動を生成するモデルである．実世界で動作する VLA モデルには高い信頼性が求められる一方，既存の安全性評価では主に入力への継続的な摂動が仮定されており，現実的に生じ得る短時間の介入に対する頑健性は十分に明らかにされていない．そこで本研究では，攻撃者がタスク実行中の単一の推論時刻にのみ入力へ介入できる脅威モデルの下で VLA モデルの頑健性を評価する．その結果，入力が直ちに正常な状態へ復旧した場合でも，既存モデルのタスク成功率が大幅に低下するという脆弱性を明らかにする．さらに，この脆弱性を分析し，1 回の推論で複数ステップ分の行動列をまとめて出力する action chunking が，摂動の影響を後続の時刻まで持続させる要因の一つであることを示す．この問題に対処するため，直前の推論で生成された未実行の行動列と現在の予測行動列との不一致に基づいて実行長を動的に調整し，摂動の影響を抑制する新たな action chunking 手法を提案する．実験により，提案手法が通常時のタスク性能と推論効率を維持しながら，単一時刻の入力摂動に対する頑健性を大幅に向上させることを確認した．

キーワード：Vision-Language-Action モデル，ロボットマニピュレーション，頑健性，Action Chunking

Vulnerability of Vision-Language-Action Models to One-Step Input Perturbations

Shojiro Yamabe[1,a)]　Jun Sakuma[1,2]

Abstract: Vision-Language-Action (VLA) models generate robot actions from visual observations and language instructions. While VLA models deployed in the real world require high reliability, existing safety evaluations mainly assume continuous perturbations to the input, and their robustness against short-term interventions has not been sufficiently studied. In this paper, we evaluate the robustness of VLA models under a threat model in which an attacker can intervene in the model input at only a single inference step during task execution. Our experiments reveal that, even when the input immediately returns to its normal state, existing VLA models suffer substantial reductions in task success rates. We further analyze this vulnerability and show that action chunking, which outputs a sequence of actions for multiple steps in a single inference, is one factor that prolongs the effects of a perturbation into subsequent steps. To address this issue, we propose a novel action chunking strategy that dynamically adjusts the execution horizon based on the inconsistency between the unexecuted action sequence generated by the previous inference and the current predicted action sequence, thereby suppressing the effects of perturbations. Experiments on the LIBERO benchmark confirm that the proposed method substantially improves robustness against one-step input perturbations while maintaining task performance and inference efficiency.

Keywords: Vision-Language-Action Models, Robotic Manipulation, Robustness, Action Chunking

1. はじめに

Vision–Language–Action（VLA）モデルは，視覚と言語

[1] 東京科学大学
Institute of Science Tokyo
[2] RIKEN AIP
[a)] yamabe.s.2fb0@m.isct.ac.jp

© 2026 Information Processing Society of Japan

This paper is work in progress and not peer-reviewed.

の理解能力をロボットの物理的な行動生成へ拡張する基盤モデルである [1], [2]．各時刻におけるカメラ画像やセンサ値からなる観測に基づいて行動を生成し，その行動によって変化した環境を再び観測しながら，時系列的にタスクを遂行する．

ロボットアーム [2], [3] など，実世界で動作するロボットへの応用が進められている一方で，こうした環境では VLA の出力は物理世界に直接作用するため，誤った行動はタスク失敗にとどまらず周囲の物体や人への損害につながる可能性がある．したがって，VLA を実環境へ安全に導入するためには，攻撃者による意図的な入力摂動などに対する頑健性を明らかにすることが重要である．

実環境で動作する VLA に対して，攻撃者が入力へ短時間のみ介入することは現実的に想定される脅威の一つである．このような介入はカメラやセンサへの物理的接触や通信経路への一時的な介入などによって比較的容易に実行可能であり，入力が直ちに復旧した場合でも後続の振る舞いに影響を及ぼす可能性がある．しかしながら，既存研究 [4], [5], [6], [7] では主にタスク全体を通して継続的に入力へ摂動を与える評価が行われており，短時間の入力介入に対する VLA の頑健性は十分に明らかにされていない．

そこで本研究では，攻撃者がタスク実行中の単一の推論時刻にのみモデルの入力へ介入できる脅威モデルの下で VLA モデルの頑健性を評価する．具体的には，カメラへの一時的な強光や通信遮断，センサ値のスパイクなどをロボット操作ベンチマーク LIBERO [8] のシミュレーション上で再現し，入力が直ちに正常へ復旧した場合のタスク性能を評価した．これらの摂動は，攻撃者がセンサや通信経路へ短時間介入することで物理環境においても実現可能であるため，シミュレーション上でその影響を再現することにより実環境で生じうる入力異常に対する VLA の脆弱性を検証できる．実験を通じて，現在の VLA の安全性に関する以下の二つの重要な知見を得た．

第一に，現在の VLA モデルは短時間の介入だけで性能が大幅に低下し得ることを確認した．摂動が与えられるのは一度の推論に限られ，その後の入力が直ちに正常な状態へ復旧するにもかかわらず，複数の VLA モデルにおいてタスク成功率の著しい低下を確認した．この結果は，一時的な摂動の影響がその発生時刻にとどまらず，後続のロボット行動へ伝播することでタスク全体の失敗を引き起こし得るという脆弱性を示している．

第二に，この脆弱性の要因の 1 つが，VLA に広く用いられている action chunking [9] であることを明らかにした．Action chunking とは，一度の推論において複数ステップ分の行動列をまとめて生成し，そのうち事前に定められた実行長分の行動を逐次的に実行する推論機構である．この機構は短い制御周期でのロボット制御を可能にする一方で，誤った action chunk が生成されるとその行動が実行長にわたって継続するため，後続の振る舞いを不安定化させる可能性がある．実行長を短く設定することでこの脆弱性を改善できるものの，計算コストの増加や行動間の整合性の低下により，タスク性能と頑健性の両立は困難になる．

この知見に基づき，本研究では，予測された行動列の整合性に応じて実行長を動的に調整する新たな action chunking 手法を提案する．本手法は，前の推論において生成された行動列のうち実行されなかった行動と今回の推論により生成された行動列の差分を計算する．両者の差分が大きい場合には，現在の観測または行動予測が不安定である可能性が高いと判断し，短い実行長を選択することで誤った行動列が長期間にわたって実行されることを防ぐ．一方，差分が小さい場合には長い実行長を選択することでモデルの推論回数を削減する．提案手法は，追加のモデル推論や学習を必要とせず，action chunk を出力する幅広い VLA モデルに適用できる．LIBERO ベンチマークを用いた実験により，提案手法が通常時のタスク性能と推論効率を維持しながら，単一時刻の入力摂動に対する頑健性を大幅に向上させることを示す．

本研究の貢献は以下の 4 点である．

- 攻撃者が単一の推論時刻にのみ入力へ介入する脅威モデルにおいて現在の VLA のタスク性能が大幅に低下し得るという脆弱性を明らかにした．
- 脆弱性の分析を行い，action chunking が入力摂動の影響を後続まで持続させることが脆弱性を増幅する要因の一つであることを示した．
- 脆弱性の解決策として，実行長を動的に調整する新たな action chunking 手法を提案した．我々の知る限り，安全性の観点から action chunking の実行長を動的に調整する手法を提案したのは本研究が初めてである．
- LIBERO ベンチマークを用いた実験により，提案手法が通常時のタスク性能と推論効率を維持しながら頑健性を向上させることを示した．

2. 関連研究

2.1 Vision-Language-Action (VLA) Models

VLA は大規模な画像言語データセットで学習された Vision-Language Model (VLM) の視覚・言語理解能力をロボットの行動生成へ拡張したモデルである [1], [2], [3], [10], [11], [12], [13]．このとき，VLM の出力をロボットの制御信号に変換する専用モジュールである action expert が組み合わされることが多い．初期の VLA では，連続的な行動空間を離散化し，行動を言語と同様のトークン列として自己回帰的に生成する手法が提案されている [1]．近年では，より高精度な行動を生成するために，diffusion model や flow-matching に基づいて連続的な行動列を予測する VLA も広く研究されている [2], [10]．既存研究では，主に正常な観測下における性能が評価され

© 2026 Information Processing Society of Japan

てきた一方で，本研究では推論中の入力に摂動が与えられたときの VLA の頑健性に焦点を当てる．

2.2 VLA に対する頑健性評価

VLA は多様なロボット操作タスクにおいて高い性能を示す一方で，入力異常や敵対的な介入に対する頑健性は未だ十分ではない．実際に，いくつかの先行研究 [4], [5], [6], [7] では，画像入力や行動出力に対する様々な摂動に対して，現在の VLA が未だ脆弱であることを示している．しかしながら，これらの頑健性評価では，エピソード中のすべての時刻において継続的に摂動が与えられることを仮定している．実環境において攻撃者が継続的な介入を維持することは必ずしも容易ではなく，この評価設定は現実的な攻撃者の介入能力や制約を十分に反映していない．本研究では，VLA の時系列的な意思決定に着目し，単一の時刻にのみ介入する摂動に対する頑健性を評価し，VLA の新たな脆弱性を明らかにする．

2.3 Action chunking

Action chunking [9] は，1 回の推論で複数ステップ分の将来の行動列を生成し，そのうち事前に定められた実行長分の行動を順次実行する推論機構である．モデルの推論回数を削減することにより計算コストを抑えながら短い制御周期でのロボット制御を可能にする一方で，一度決定した行動を変更することができないため，急速な行動変化に対する反応性が低下するというトレードオフが存在する．このトレードオフを改善するために，観測に合わせて実行長を動的に変化させる手法が提案されている [14], [15], [16], [17]．しかし，これらの手法は観測に加えられる摂動などへの対応を目的としておらず，モデルの頑健性への寄与は限定的である．本研究では，摂動に対する頑健性向上を目的として，予測された action chunk から得られる情報のみを用いて実行長を動的に調整する新たな手法を提案する．提案手法は，追加のモデル推論や学習を必要とせず，特定の行動生成方式に依存しないため，action chunk を出力する幅広い VLA へ適用できる．

3. 準備

画像空間を $\mathcal{V}$，状態空間を $\mathcal{S}$，言語空間を $\mathcal{L}$，行動空間を $\mathcal{A}$ とする．ここで，画像とはロボットのカメラなどから得られる RGB 画像のことを指し，状態とはロボットの座標や関節角度のセンサ値を表す．言語指示は`"Pick up the red block"`などのタスク指示を表す．

VLA モデルを π_θ，時刻 t における画像観測を $v_t \in \mathcal{V}$，状態入力を $s_t \in \mathcal{S}$，言語指示を $l \in \mathcal{L}$ とする．推論頻度を下げつつ，時間的に滑らかで一貫したロボット動作を出すために，VLA モデルは 1 回の推論において K ステップ分の行動列である action chunk を出力する：

$$\mathbf{A}_t = (a_t, a_{t+1}, \ldots, a_{t+K-1}) \sim \pi_\theta\left(\cdot \mid v_t, s_t, l\right). \quad (1)$$

ここで，$a_t \in \mathcal{A}$ は 1 ステップ分の行動である．実行時には生成された K ステップ分の行動のうち，事前に定められた実行長 $H \leq K$ ステップ分の行動が逐次的に実行され，この間は VLA による再推論は行われない．

4. 脅威モデル

本稿では，利用者が VLA モデルに言語指示を与え，ロボットシステムを通じてその指示に対応する操作タスクを実行する状況を想定する．攻撃者の目的は，タスク実行中の入力へ一時的に介入することで，言語指示で指定されたタスクの完遂を妨げ，タスク成功率を低下させることである．本稿におけるタスク成功とは，対象物を指定された位置へ移動するなど，言語指示に応じて定めた完了条件を所定時間内に満たすことを指す．実験では評価ベンチマークにおいて定められた成功条件を使用する．

攻撃者の知識　攻撃者は，VLA モデルに対してブラックボックスアクセスのみを持つと仮定する．すなわち，攻撃者は VLA モデルの学習データ，モデルアーキテクチャ，およびモデルパラメータにアクセスできない．また，推論時に入力される言語指示に対してもアクセスできないものとする．

攻撃者の介入能力　攻撃者は，VLA モデルの画像入力，状態入力，またはその両方に対してタスク実行中の任意の推論時刻に介入できるものの，その介入は短時間に限定されると仮定する．この仮定は，攻撃者がタスクの進行状況を観測し，最も影響の大きいタイミングで一時的な物理的・通信上の介入を実施できる状況を想定したものである．実験では，このような短時間の介入を，攻撃者が選択した単一時刻にのみ入力へ摂動を与えることで再現する．なお，攻撃者は VLA の出力やモデル自体を直接改変できず，介入は推論時に限定され，モデルの学習時にはアクセスできない．

5. 頑健性評価

本章では，単一時刻における入力摂動に対する VLA の頑健性を，ロボット操作ベンチマークである LIBERO [8] を用いて評価する．LIBERO は，LIBERO-Spatial，LIBERO-Object，LIBERO-Goal，および LIBERO-Long の 4 つのタスクスイートから構成されるロボットアームのシミュレーションベンチマークである．評価では，一時的な強光による画像の白飛びやカメラの揺れによるブラー，通信遮断による入力の欠損，センサ値への一時的な介入など，攻撃者がセンサや通信経路へ短時間介入することで物理環境においても発生しうる摂動を扱う．その入力への影響をシミュレーション上で再現することにより，物理環境で発生し得る摂動に対する VLA の頑健性を評価する．

© 2026 Information Processing Society of Japan

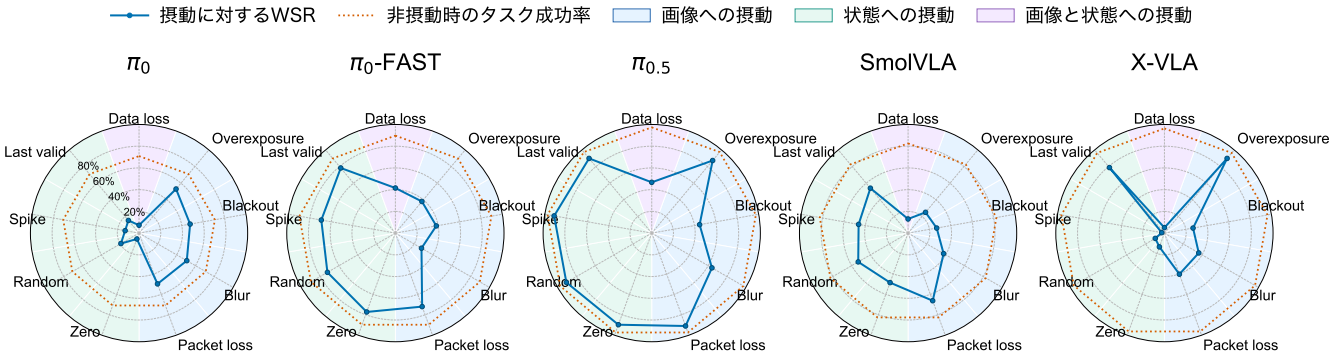


図 1 単一時刻の摂動に対する WSR（%）．青色の実線は各摂動に対する WSR，朱赤色の点線は非摂動時のタスク成功率を示す．背景色は摂動対象の入力モダリティを表す．

Fig. 1 WSR against perturbations (%). Blue solid lines show WSR, red dashed lines show clean success rates, and background colors indicate perturbed modalities.

5.1 実験設定

評価対象の VLA モデルには，π_0 [2]，π_0-FAST [12]，$\pi_{0.5}$ [3]，SmolVLA [13]，および X-VLA [11] を用いる．各モデルの実行長は $H = \{1, 5, 10, 15, 20, 25, 30\}$ のうち摂動を付与しない場合のタスク成功率が最も高かった値を採用し，π_0，$\pi_{0.5}$，X-VLA は $H = 15$，π_0-FAST，SmolVLA は $H = 10$ とする．

摂動設計 本稿では，画像入力に対する摂動，状態入力に対する摂動，および画像入力と状態入力を同時に破損させる摂動を扱う．特に物理世界における現実的な脅威を評価するため，通信経路への介入や物理的な接触などによって生じ得る以下の摂動を対象とする：

- **Blackout**: 入力画像を黒画像に置換する摂動．カメラ通信への介入による一時的な信号の欠落に対応する．
- **Overexposure**: 入力画像の輝度を過度に上昇させる摂動．カメラに対して強い光を当てることによる白飛びに対応する．
- **Motion blur**: 入力画像に対してブラーを付与する摂動．カメラに対する物理的な衝撃などによる画像ブレに対応する．
- **Packet loss**: 入力画像の一部領域を欠損させる摂動．カメラからの画像伝送中に生じる情報欠損に対応する．
- **Zero fill**: 入力状態の全成分を 0 に置換する摂動．状態センサの通信停止による信号欠落に対応する．
- **State spike**: 入力状態の成分を上限値に置換する摂動．状態センサへの瞬間的な干渉によって生じるスパイク状の異常信号を模擬する．
- **Random state**: 入力状態の成分をランダム値に置換する摂動．状態センサの通信経路に偽のセンサ値を注入する攻撃を模擬する．
- **Data loss**: 入力画像を黒画像に，入力状態の全成分を 0 に置換する摂動．攻撃者によってロボットへの入力経路が完全に遮断された状況に対応する．

評価指標 単一時刻の摂動がタスク性能に与える影響は，摂動がタスクの成否を左右する重要な動作局面で生じるか否かによって異なる可能性がある．そこで，すべての時刻について，1 時刻にのみ摂動を付与した評価を個別に行い，最も低い成功率である最悪成功率 (Worst Success Rate; WSR) を報告する．時刻 t においてのみ摂動 p を付与した場合のタスク成功率を $\mathrm{SR}(p, t)$ と表す．このとき，WSR は以下のように定義される：

$$\mathrm{WSR}(p) = \min_{t \in \mathcal{T}} \mathrm{SR}(p, t). \tag{2}$$

なお，各介入時刻における成功率は 10 エピソードの平均として算出する．

5.2 評価結果

本節では，単一時刻の摂動に対する VLA の頑健性を評価する．図 1 に各モデルの単一時刻における入力摂動に対する WSR を示す．すべてのモデルにおいて，少なくとも 2 つの摂動条件で WSR が 50%を下回った．また，Overexposure や Blur のように観測情報が完全には失われない摂動であっても，π_0-FAST, SmolVLA, および X-VLA では成功率が大きく低下している．この結果は，現在の VLA がわずか 1 時刻の摂動によってもタスク成功率が大幅に低下し得るという重大な脆弱性を明らかにしている．

モデルによって脆弱性が顕在化する摂動の種類が異なっていることが確認できる．π_0-FAST と SmolVLA では，状態入力に対する摂動よりも画像入力に対する摂動の影響が大きい．これに対して，π_0 と X-VLA は状態摂動に対して著しく脆弱である．$\pi_{0.5}$ は，多くの画像摂動および状態摂動に対して比較的高い成功率を維持しているものの，Blackout と Data loss では成功率が 50%未満まで低下する．以上より，VLA の頑健性はモデルや入力モダリティによって大きく異なり，単一の摂動条件のみではモデルの頑健性を十分に評価できないことが分かる．

このような脆弱性を増幅する要因の一つとして action

© 2026 Information Processing Society of Japan

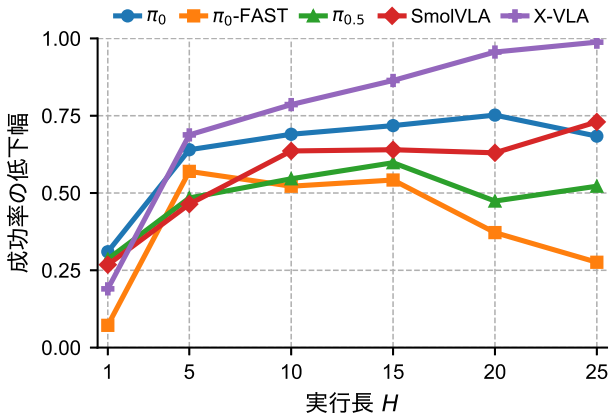


図 2 実行長 H と成功率の低下幅の関係．値が小さいほど，単一時刻の摂動による成功率の低下が小さいことを表す．

Fig. 2 Execution horizon H vs. success-rate drop. Lower values indicate less degradation from perturbations.

chunking が考えられる．Action chunking を用いる VLA では 1 回の推論で生成された複数ステップの行動が連続して実行される．そのため，摂動を含む観測から誤った行動列が生成された場合，摂動自体は単一時刻に限定されていても，その影響は後続の複数ステップにわたって継続する．これにより，ロボットが本来の軌跡から大きく逸脱し，その後の観測に基づく再推論を行ってもタスクを復旧できなくなる可能性がある．そこで次節では，action chunk が頑健性に与える影響を分析する．

5.3 Action Chunking が頑健性に与える影響

本節では，実行長 H を変化させたときの性能を比較し，action chunking が摂動の影響を増幅する要因となっているかを検証する．実行長が長い場合，1 回の推論で生成された行動列が長期間にわたって実行されるため，摂動を含む観測から誤った行動列が生成されると，タスクへの影響も大きくなると考えられる．

実行長 H によって摂動を付与しない場合の成功率も変化するため，本分析では通常時の成功率から摂動下の WSR を差し引いた成功率の低下幅を比較する．低下幅が小さいほど，摂動による影響が小さく頑健であることを表す．

図 2 に各実行長における Data loss による成功率の低下幅を示す．結果から実行長が長いほど低下幅が大きくなる傾向が確認できる．実行長が短い場合，より早い段階で新たな観測に基づく再推論が行われる一方で，実行長が長い場合には，誤った行動列が長期間にわたって実行される．これにより，action chunking が単一時刻における摂動の影響を時間方向に拡大し，VLA の頑健性を低下させる要因となる．なお，π_0-FAST では実行長が極端に短い場合や長い場合に通常時の成功率自体が低下するため，低下幅が小さい結果は頑健性の向上を必ずしも意味しないことに注意されたい．

ただし，実行長を単純に短く設定するだけでは頑健性とタスク性能を両立できるとは限らない．短い実行長では，モデルに対してより頻繁な推論が必要となるため，計算コストが増加しリアルタイムなロボット制御が困難になる．また，行動列を頻繁に再生成することで連続する行動間の整合性が失われ，不安定な振る舞いを誘発する．

そのため，action chunking による効率性を維持しながら頑健性を向上させるためには，観測に応じて実行長を動的に調整することが有効であると考えられる．通常の観測に対しては長い実行長を用いることで推論回数を削減し，異常な観測が入力された可能性がある場合には実行長を短くすることで不正確な行動が長期間にわたって実行されることを防ぐ．次節では，観測の変化に応じて実行長を調整する action chunking strategy を提案する．

6. 提案手法

本節では，予測された行動列の整合性に応じて実行長を動的に調整する action chunking strategy を提案する．前節で示したように，長い実行長は摂動を含む観測から生成された誤った行動の影響を増幅する可能性がある．そこで，本手法では予測した行動列が直前の予測と整合している場合には長い実行長を選択し，両者の乖離が大きい場合には短い実行長を選択する．これにより，通常時の推論効率を維持しながら，摂動による誤った行動の影響を抑制する．

6.1 定式化

まず，行動列の整合性に基づいた実行長選択を定式化する．時刻 t における摂動のない観測 (v_t, s_t) から生成される真の行動列を $\mathbf{A}_t^* \sim \pi_\theta(\cdot \mid v_t, s_t, l)$，実際にモデルへ入力される摂動を含む観測 (v_t', s_t') において生成される行動列を $\mathbf{A}_t \sim \pi_\theta(\cdot \mid v_t', s_t', l)$ とする．

摂動を含む観測から生成された行動列 $\mathbf{A}_t$ が真の行動列 $\mathbf{A}_t^*$ と大きく乖離している場合，行動を長く実行するほどロボットが本来の軌跡から大きく逸脱する可能性がある．そこで，真の行動と十分に一致する行動のみを実行し，両者の乖離が許容範囲を超える前に再推論を行うことで摂動による誤った行動の影響を抑制することができる．したがって，理想的な実行長 H_t^* は行動列の先頭からの乖離が閾値以下となる最大の長さとして次式で定義される：

$$H_t^* = \max \left\{ H \in \{1, \dots, K\} \;\middle|\; D\left(\mathbf{A}_t^{(H)}, \mathbf{A}_t^{*(H)}\right) \le \tau \right\}, \tag{3}$$

ここで，$\mathbf{A}_t^{(H)}$ は $\mathbf{A}_t$ の先頭 H ステップの行動からなる行動列，$D(\cdot, \cdot)$ は行動列間の不一致度を表す関数，τ は許容する不一致度の閾値である．真の行動との乖離が小さい場合には長い実行長が選択され推論コストを低減する一方で，乖離が大きい場合には短い実行長が選択され摂動の影

© 2026 Information Processing Society of Japan

響を抑制する．

ただし，実際の推論時には摂動のない観測 (v_t, s_t) を取得できないため，$\mathbf{A}_t^*$ を直接計算することはできない．そこで，直前の推論で生成された未実行行動を，現在時刻における真の行動列の代理として利用する．前回の推論以降に環境が大きく変化していなければ，この未実行行動は，現在の摂動のない観測から生成される行動と大きく乖離しないと考えられる．

直前の実行長を $\hat{H} < K$ とすると，直前の推論で生成された行動列のうち，まだ実行されていない行動列 $\hat{\mathbf{A}}$ は以下のように表される：

$$\hat{\mathbf{A}} = (\hat{a}_t, \hat{a}_{t+1}, \ldots, \hat{a}_{t+K-\hat{H}-1}). \tag{4}$$

そのため，実行長選択は改めて以下のように定式化される：

$$H_t = \max \left\{ H \in \{1, \ldots, K - \hat{H}\} \;\middle|\; D\left(\mathbf{A}_t^{(H)}, \hat{\mathbf{A}}^{(H)}\right) \leq \tau \right\}. \tag{5}$$

以上から，計算可能な行動列 $\hat{\mathbf{A}}$ を用いて実行長を決定することができる．直前の推論で生成された行動列を再利用するため，実行長選択のための追加のモデル推論や学習を必要としない．これにより，ロボット制御において重要な実行速度への悪影響を最小限にしつつ，動的な実行長選択を実現する．また，本フレームワークは特定の不一致度関数に依存せず，行動間の整合性を定量化できる任意の関数を組み込むことができる．

6.2 不一致度関数の設計

本節では，前節で導入した不一致度関数 $D(\cdot, \cdot)$ の具体的な設計を示す．まず，行動ベクトルの各要素の大きさによる影響を抑えるため，各時刻 $i \in \{0, \ldots, K - \hat{H} - 1\}$ について，現在の行動 $\mathbf{a}_i$ と対応する未実行行動 $\hat{\mathbf{a}}_i$ との不一致度 r_i を正規化ユークリッド距離を用いて以下のように計算する：

$$r_i = \frac{\|\mathbf{a}_i - \hat{\mathbf{a}}_i\|_2}{\|\mathbf{a}_i\|_2 + \|\hat{\mathbf{a}}_i\|_2}, \tag{6}$$

$r_i = 0$ は両者が一致することを表し，値が大きいほど行動の乖離が大きいことを表す．

実行長を各時刻の不一致度のみから決定すると，摂動に起因しない予測誤差に過度に反応する可能性がある．例えば，グリッパの開閉状態の反転などにより，行動列中の一時刻だけ不一致度が大きくなる場合がある．このような局所的な乖離は正常な観測下でも起こりうる一方で，摂動によって行動予測が大きく変化した場合には，その影響は後続する複数時刻の行動にも現れると考えられる．また，本手法では直前に生成された未実行行動を現在の真の行動列の代理として用いるため，予測対象が遠い未来になるほど，摂動が存在しない場合でも両者の間に自然な予測誤差が生じやすい．

Algorithm 1 Execution Horizon Selection

Require: 現在の行動列 $\mathbf{A}$, 直前の行動列 $\widehat{\mathbf{A}}$, 初期実行長 $H_{\text{init}} < K$, 閾値 τ, 割引係数 γ
Ensure: 実行長 H

```
if Â = ∅ then
    H ← H_init
else
    R ← 0, H ← 1
    for i = 0 to |Â| − 1 do
        R ← R + γ^i ‖a_i − â_i‖_2 / (‖a_i‖_2 + ‖â_i‖_2)
        if R > τ then
            break
        end if
        H ← i + 1
    end for
end if
return H
```

そこで，本手法では各時刻の不一致度を割引累積し，行動列全体の不一致度を次式で定義する：

$$D\left(\mathbf{A}_t^{(H)}, \widehat{\mathbf{A}}^{(H)}\right) = \sum_{i=0}^{H-1} \gamma^i r_i, \tag{7}$$

ここで，$\gamma \in (0, 1)$ は割引係数である．不一致度を累積することで，単一時刻のみ生じる局所的な乖離ではなく，複数時刻にわたって継続する乖離を重視する．さらに，遠い未来の不一致度を割り引くことで，代理として用いる行動列の予測誤差が将来ほど大きくなる影響を抑える．これにより，摂動に起因しない乖離への過剰な反応を抑え，正常な観測下における実行長選択を安定化させる．

6.3 アルゴリズム

Algorithm 1 に，不一致度に基づく実行長 H の選択手順を示す．現在生成された action chunk と直前の推論で生成された未実行行動を入力とし，両者の割引累積不一致度が閾値 τ を超える直前までの行動数を実行長 H として選択する．初回の推論では比較対象となる未実行行動が存在しないため，事前に定めた初期実行長 H_{init} を用いる．

7. 実験

本章では，LIBERO [8] を用いて提案手法を以下の観点から評価する．**(i)** 提案手法により単一時刻の入力摂動に対する頑健性は向上するか．**(ii)** 提案手法を適用しても非摂動下におけるタスク性能を維持できるか．**(iii)** 提案手法による追加の計算コストはどの程度か．

7.1 実験設定

対象モデル，摂動，および評価指標については，第 5 章と同一の設定を用いる．提案手法のパラメータについて，割引係数を $\gamma = 0.85$，最大実行長を 15，初期実行長を $H_{\text{init}} = 1$ とし，閾値は π_0，π_0-FAST，SmolVLA では

© 2026 Information Processing Society of Japan

表 1 単一時刻の Data loss に対する各手法の WSR（%, ↑）ならびに非摂動時および摂動時の平均実行長.

Table 1 WSR against one-step Data loss (%, ↑) and mean execution horizons under clean and perturbed conditions.

Method	π_0			π_0-FAST			$\pi_{0.5}$			SmolVLA			X-VLA		
	WSR	平均実行長		WSR	平均実行長		WSR	平均実行長		WSR	平均実行長		WSR	平均実行長	
	(%)	Clean	Perturbed	(%)	Clean	Perturbed	(%)	Clean	Perturbed	(%)	Clean	Perturbed	(%)	Clean	Perturbed
Original	7.2	15.00	15.00	41.5	10.00	10.00	46.8	15.00	15.00	13.0	10.00	10.00	5.0	15.00	15.00
RobustVLA	6.8	15.00	15.00	48.8	10.00	10.00	52.5	15.00	15.00	14.2	10.00	10.00	0.0	15.00	15.00
VLA-Corrector	9.5	9.34	9.11	–	–	–	48.5	9.72	9.81	8.8	8.74	8.06	12.2	8.54	8.02
AAC	7.2	20.27	15.09	36.2	9.08	9.48	59.8	16.46	28.18	13.2	21.04	13.73	30.2	11.24	9.24
Proposed	**50.2**	8.96	2.22	**62.2**	6.55	1.29	**88.2**	11.25	1.46	**55.5**	10.66	2.45	**83.5**	12.14	1.07

$\tau = 1.5$，$\pi_{0.5}$，X-VLA では $\tau = 1.0$ とする．

比較手法 提案手法の有効性を検証するため，以下の 3 手法と比較する．

- **RobustVLA [4]:** 入力および出力に対する敵対的学習手法である．本実験では入力摂動のみを扱うため，入力摂動に対する敵対的学習のみを適用した．
- **VLA-Corrector [16]:** 観測特徴の変化から現在の行動列が環境と整合しているかを判定し実行長を動的に決定する手法である．判定には事前学習した外部モジュールを利用する．Flow-matching 型 VLA のみに適用可能であるため，本実験では π_0-FAST を評価対象から除外する．
- **AAC [15]:** 同一観測に対する複数回の推論から行動分布のエントロピーを推定し，その不確実性に基づいて実行長を決定する手法である．

比較手法のハイパーパラメータは, 各原論文の設定に従った.

7.2 単一時刻の摂動に対する頑健性評価

本節では，提案手法が単一時刻の入力摂動に対する頑健性を向上できるかを評価する．摂動として，第 5.2 節において特に性能低下が大きかった Data loss を用いる．また，実行長が頑健性にどのように寄与しているかを評価するために，非摂動時および摂動時に各手法が選択した平均実行長を計測する．

表 1 に各手法の WSR と平均実行長を示す．提案手法は，全ての VLA モデルにおいて既存手法より高い WSR を達成した．一方，RobustVLA では十分な頑健性改善は得られなかった．RobustVLA はガウシアンノイズなどの微小な摂動を想定した敵対的学習であり，Data loss のような短時間かつ大規模な入力破損に対しては十分に汎化できていない．これは，敵対的学習が学習時に想定した摂動分布の外側では性能が低下しやすいという既知の性質と一致している．

また, 同表の平均実行長から, 提案手法のみが非摂動下では長い実行長を維持しつつ摂動下では実行長を大きく短縮していることが確認できる．一方，比較手法では，摂動下においても実行長の変化は限定的であった．これらの結果は，提案手法が観測の変化に応じて実行長を適応的に短縮することで，摂動を含む観測から生成された誤った action chunk が長期間実行されることを防ぎ，単一時刻の入力摂動による影響を効果的に抑制していることを示している．

表 2 非摂動下におけるタスク成功率（%, ↑）.

Table 2 Clean task success rates (%, ↑).

Method	π_0	π_0-FAST	$\pi_{0.5}$	SmolVLA	X-VLA
Original	70.9	89.8	97.4	82.6	96.4
RobustVLA	72.2 (↑ 1.3)	91.5 (↑ 1.7)	97.8 (↑ 0.4)	70.8 (↓ 11.8)	90.0 (↓ 6.4)
VLA-Corrector	69.8 (↓ 1.1)	–	99.0 (↑ 1.6)	86.2 (↑ 3.6)	93.5 (↓ 2.9)
AAC	70.1 (↓ 0.8)	83.0 (↓ 6.8)	96.2 (↓ 1.2)	76.2 (↓ 6.4)	95.2 (↓ 1.2)
Proposed	72.5 (↑ 1.6)	78.2 (↓ 11.5)	97.2 (↓ 0.2)	80.8 (↓ 1.9)	96.2 (↓ 0.2)

7.3 非摂動下における性能評価

本節では，提案手法が非摂動下における通常時のタスク性能をどの程度維持できるかを評価する．表 2 に，各手法の非摂動下におけるタスク成功率を示す.

提案手法は，π_0 では Original を 1.6 ポイント上回り，$\pi_{0.5}$，SmolVLA，および X-VLA では Original からの成功率低下を 1.9 ポイント以内に抑えた．Original では，各モデルについて探索された非摂動下のタスク成功率が最も高くなる固定実行長を採用しているため，動的に実行長を変更する提案手法がこれと同等の成功率を常に達成することは必ずしも期待できない．一方，π_0-FAST では，提案手法の適用により成功率が 11.5 ポイント低下した．これは，π_0-FAST が実行長変化への感度が高く，限られた実行長の範囲を外れると，非摂動下においてもタスク性能が低下する傾向を示すためである．

また，RobustVLA および VLA-Corrector では，一部のモデルにおいて Original を上回る成功率が確認された．これは，これらの手法が追加データを用いて VLA モデル本体または外部モジュールを学習することで得られた情報が寄与している可能性がある．

以上より，π_0-FAST では性能低下が確認されたものの，

© 2026 Information Processing Society of Japan

表 3 実行長決定時間の比較 (ms, ↓)．括弧内は同一モデルの Original 比を表す．

Table 3 Execution-horizon selection time (ms, ↓). Parentheses show ratios to Original for the same model.

Method	π_0	π_0-FAST	$\pi_{0.5}$	SmolVLA	X-VLA
Original	194.0	2460.4	212.3	151.6	117.5
VLA-Corrector	576.0 (2.969×)	– (–)	607.4 (2.861×)	313.3 (2.066×)	302.1 (2.571×)
AAC	711.1 (3.666×)	3192.7 (1.298×)	775.2 (3.652×)	185.1 (1.221×)	1181.7 (10.055×)
Proposed	194.6 (1.003×)	2461.2 (1.000×)	212.8 (1.003×)	152.1 (1.003×)	117.8 (1.003×)

その他の 4 モデルでは，追加学習を必要とすることなく，提案手法が非摂動下のタスク性能を概ね維持できることを確認した．

7.4 計算コスト評価

本節では，提案手法による追加計算コストを評価する．非摂動下において，各手法が 1 回の実行長決定に要する処理時間を比較する．

表 3 に，各手法の 1 回の実行長決定当たりの処理時間を示す．提案手法の処理時間は，適用前と比べて 1 ms 未満の増加にとどまり，不一致度計算と実行長選択の追加コストが小さいことが確認できる．これは，提案手法が既に生成された action chunk のみを利用して実行長を決定するため，追加の VLA 推論を必要としないことによる．一方，VLA-Corrector では 2 倍以上に増加し，AAC でもモデルによって最大 10 倍程度に増加した．AAC ではエントロピー推定のために複数回の VLA 推論を実行する必要があり，VLA-Corrector では外部モジュールによる追加推論が必要となるため，計算時間が増加したと考えられる．

以上より，提案手法は多くのモデルで通常時のタスク性能を概ね維持しながら，計算コストをほとんど増加させることなく単一時刻の入力摂動に対する頑健性を向上できることが確認できた．

8. 結論

本研究では，攻撃者がセンサや通信経路へ短時間のみ介入できる，より現実的な脅威モデルにおける VLA の頑健性評価を行った．実験の結果，単一時刻の入力摂動によって現在の VLA のタスク成功率が大きく低下することを明らかにした．また，action chunking によって誤った行動列が複数ステップにわたり実行されることが脆弱性の一因であることを示した．この知見に基づき，本研究では予測された行動列の整合性に応じて実行長を動的に調整する手法を提案した．LIBERO ベンチマークを用いた評価では，摂動が入力された場合には実行長を短縮することで，多くのモデルで通常時のタスク性能を概ね維持しながら単一時刻の入力摂動に対する頑健性を向上できることを確認した．

一方，本手法にはいくつかの限界も存在する．提案手法では，直前の推論によって生成された未実行行動が現在時刻における真の行動列を近似できることを仮定している．そのため，環境変化が大きい場合やモデルが十分に学習されていない環境では，この仮定が成立せず適切な実行長を選択できない可能性がある．また，本手法は一度生成された行動そのものを修正することはできないため，少なくとも 1 ステップ分の誤った行動が実行され，その影響を完全に除去することはできない．今後は，誤って生成された行動列そのものをオンラインで修正する機構を導入し，VLA の安全な実環境運用に向けた基盤技術の確立を目指す．

謝辞 本研究は JST Nexus JPMJNX25C2, JST K-program JPMJKP24C3, JST CREST JPMJCR21D3, JPMJCR23M4, JSPS Grants-in-Aid for Scientific Research 23H00483, JSPS 二国間 120251002 の支援を受けたものである．

参考文献

[1] Moo Jin Kim, et al. OpenVLA: An open-source vision-language-action model. In *CoRL*, 2024.
[2] Kevin Black, et al. π_0: A vision-language-action flow model for general robot control. *arXiv preprint arXiv:2410.24164*, 2024.
[3] Kevin Black, et al. $\pi_{0.5}$: a vision-language-action model with open-world generalization. In *CoRL*, 2025.
[4] Jianing Guo, et al. On robustness of vision-language-action model against multi-modal perturbations. In *ICLR*, 2026.
[5] Zhijie Wang, et al. Vlatest: Testing and evaluating vision-language-action models for robotic manipulation. *Proceedings of the ACM on Software Engineering*, Vol. 2, No. FSE, pp. 1615–1638, 2025.
[6] Asher J Hancock, Allen Z Ren, and Anirudha Majumdar. Run-time observation interventions make vision-language-action models more visually robust. In *ICRA*, pp. 9499–9506. IEEE, 2025.
[7] Hongyin Zhang, et al. GEVRM: Goal-expressive video generation model for robust visual manipulation. In *ICLR*, 2025.
[8] Bo Liu, et al. Libero: Benchmarking knowledge transfer for lifelong robot learning. *Advances in Neural Information Processing Systems*, Vol. 36, pp. 44776–44791, 2023.
[9] Tony Z Zhao, et al. Learning fine-grained bimanual manipulation with low-cost hardware. *arXiv preprint arXiv:2304.13705*, 2023.
[10] Junjie Wen, et al. DexVLA: Vision-language model with plug-in diffusion expert for general robot control. In *CoRL*, 2025.
[11] Jinliang Zheng, et al. X-VLA: Soft-prompted transformer as scalable cross-embodiment vision-language-action model. In *ICLR*, 2026.
[12] Karl Pertsch, et al. Fast: Efficient action tokenization for vision-language-action models. *arXiv preprint arXiv:2501.09747*, 2025.
[13] Mustafa Shukor, et al. Smolvla: A vision-language-action model for affordable and efficient robotics. *arXiv preprint arXiv:2506.01844*, 2025.
[14] Rui Wang, et al. When to trust imagination: Adaptive action execution for world action models. *arXiv preprint arXiv:2605.06222*, 2026.
[15] Yuanchang Liang, et al. Adaptive action chunking at inference-time for vision-language-action models. In *CVPR*, pp. 20802–20811, 2026.
[16] Yi Pan, et al. Vla-corrector: Lightweight detect-and-correct inference for adaptive action horizon. *arXiv preprint arXiv:2607.01804*, 2026.
[17] Haoxuan Wang, et al. Vla knows its limits. *arXiv preprint arXiv:2602.21445*, 2026.

© 2026 Information Processing Society of Japan