錯視型CAPTCHAの機械耐性と人間可読性の評価

高巣 真史[1,a)]　武仲 正彦[1,b)]

概要：CAPTCHA の機械耐性は，特定の攻撃者に対する突破率（解読成功率）という単一の数値で評価されることが多い．しかし，耐性は攻撃者の能力に依存して変化しうるうえ，機械への耐性が人間の可読性を犠牲にして得られている可能性もあるため，単一の攻撃者に対する突破率だけでは CAPTCHA としての成立可否は判断できない．そこで本稿は，前報で提案した錯視型 CAPTCHA（text 方式．fine-tuning を施していないマルチモーダル大規模言語モデル（MLLM）には突破率 0%）を対象に，この耐性が「どの攻撃者まで」成立するかを明らかにする．専用の分類器から MLLM の fine-tune まで事前知識の異なる 5 系統の攻撃者による機械耐性の評価と，機械評価と同一分布の画像に対する人間可読性の調査（有効回答 406 名）をそれぞれ行った．機械耐性の評価では，評価した攻撃者の間で耐性を最も明確に分けたのは生成分布の訓練データの有無であった．訓練データを持たない攻撃者には画像前処理の探索を含めても耐性が残る（突破率 14%以下）一方，訓練データで適応した攻撃者にはいずれも 98%以上で解読され，フォント変更防御の効果も読字に関わる事前知識の乏しい攻撃者に限られた．人間可読性の調査では，text 方式の正解率は 45.5%に留まった．両者を重ねると，人間と機械の分離は fine-tune なし MLLM に対しては成立するが，訓練データを得た攻撃者に対しては逆転する．錯視型 CAPTCHA の耐性は攻撃者能力の関数であり，その成立可否の判断には機械耐性と人間可読性の両面の測定が必要である．

キーワード：CAPTCHA，錯視，MLLM，人間可読性，脅威モデル

Machine Robustness and Human Readability of Illusion-based CAPTCHAs

Masafumi Takasu[1,a)]　Masahiko Takenaka[1,b)]

Abstract: The machine robustness of a CAPTCHA is often evaluated as a single success rate against one attacker. Such a point estimate, however, cannot establish whether a scheme works as a CAPTCHA: robustness varies with attacker capability, and machine resistance may come at the cost of human readability. This paper therefore asks up to which attacker the robustness of the illusion-based CAPTCHA proposed in our previous report (the “text” scheme; 0% success by multimodal large language models (MLLMs) without fine-tuning) holds. We evaluate machine robustness against five attacker families with different prior knowledge, ranging from dedicated classifiers to a fine-tuned MLLM, and separately survey human readability on images drawn from the same distribution as the machine evaluation (406 valid respondents). In the machine evaluation, what separated robustness most clearly across the evaluated attackers was whether the attacker holds training data from the generation distribution: robustness persists against attackers without such data (at most 14% even with preprocessing search), whereas every attacker adapted on it solves the scheme at over 98%, and font-change defenses help only against attackers with little reading-related prior knowledge. In the human survey, accuracy on the text scheme remains at 45.5%. Combining the two, the human-machine separation holds against off-the-shelf MLLMs but reverses once attackers obtain training data. The robustness of illusion-based CAPTCHAs is thus a function of attacker capability, and judging their viability requires measuring both machine robustness and human readability.

Keywords: CAPTCHA, visual illusion, MLLM, human readability, threat model

© 2026 Information Processing Society of Japan

This paper is work in progress and not peer-reviewed.

1. はじめに

CAPTCHA（Completely Automated Public Turing test to tell Computers and Humans Apart）は，Web サービスにおいて自動化されたボットと人間を識別する仕組みとして広く利用されている [1]．しかし，マルチモーダル大規模言語モデル（Multimodal Large Language Model: MLLM）の性能向上により，従来型のテキストベース CAPTCHA が自動解読されるリスクは増大し続けている [2]．

この課題に対して筆者らは前報 [3] において，主観的輪郭（物理的な輪郭線が存在しない箇所に，周囲の図形配置によって輪郭が知覚される錯視）[4] と背景設計を組み合わせた錯視型 CAPTCHA（text 方式）を提案した．text 方式は，白い前景文字を高密度の背景テキスト上に重ねることで，前景と背景を同じ文字カテゴリに揃え，モデルが読み取るべき領域を誤る状況を作る．GPT-5.2，Gemini 3 Flash，Gemini 3 Pro による計 1,800 件の評価において，8 文字の解答が完全一致した割合は 0.0%であり，プロンプト・推論量の変更や zoom-out（画像縮小）前処理 [5] によっても解読には至らなかった．すなわち，fine-tuning を行わず MLLM をそのまま用いる攻撃者に対しては極めて高い耐性を持つことが確認された．

一方で前報は，この耐性が「どの攻撃者まで」成立するのかを未解決の課題として残した．具体的には，(1) 生成アルゴリズムを把握した攻撃者が専用データセットで fine-tuning を行った場合の耐性，(2) フォント変更等の追加対策の有効性，(3) 人間ユーザから見たユーザビリティ，の 3 点である [3]．生成方法が攻撃者に知られた場合にどれだけの耐性が残るかは前報では未評価であり，秘匿が破られた状況を想定した最悪ケースの評価が必要である．また機械に対する耐性が人間の可読性を犠牲にして得られているなら実用的でない．耐性の評価は，攻撃者の能力を固定した一点の測定ではなく，攻撃者の能力の関数として行われる必要がある．

本稿では，前報の 3 課題に体系的に答える．中心となる視点は，攻撃者を単一の点ではなく，生成分布の訓練データの有無と読字に関わる事前知識の種類が異なる複数の類型として扱うことである．読字に関わる事前知識を持たない専用 CNN・CRNN から，OCR 特化事前学習を持つ TrOCR，Web 由来の大規模事前学習を持つ MLLM の fine-tune まで，5 系統の攻撃者を同一の生成分布・同一の指標で評価し，さらに機械評価と同一の画像分布から抽出した設問画像を用いて委託パネル調査（有効回答 406 名）による人間可読性の測定を行った．

[1] 長崎県立大学
University of Nagasaki
[a)] example@example.ac.jp
[b)] example@example.ac.jp

本稿の構成は以下の通りである．第 2 章で関連研究を整理し，第 3 章で対象方式と評価データを述べる．第 4 章で攻撃者の類型に基づく脅威モデルを定義し，第 5 章で機械耐性，第 6 章で人間可読性の評価結果を示す．第 7 章で両評価を統合して成立可否と限界を論じ，第 8 章でまとめる．

なお前報では視覚言語モデルを VLM（Vision-Language Model）と表記したが，本稿では画像とテキストを扱う大規模モデルの総称として MLLM に統一し，攻撃者としての利用形態を「fine-tune なし」（既存モデルをそのまま用いる）と「fine-tune」で区別する．

2. 関連研究

CAPTCHA の攻防．テキストベース CAPTCHA に対しては，歪み・ノイズの増強と機械学習による突破が繰り返されてきた [2], [6]．画像認識ベースの商用方式に対しても，hCaptcha への低コスト攻撃 [7] が報告されるなど，機械学習を用いた攻撃の適用範囲は広がっている．一方，reCAPTCHAv2 の大規模ユーザ調査 [8] が示すように，防御の複雑化は人間側の負担増と表裏一体であり，安全性とユーザビリティのトレードオフの定量化が求められている．

錯視を利用した CAPTCHA．Saalo は主観的輪郭 [4] を利用し，物理的な輪郭線を描かずに文字を知覚させる CAPTCHA を提案した [9]．Ding らは視覚錯視と誤誘導選択肢により MLLM を誤答に導く IllusionCAPTCHA を提案している [10]．前報 [3] は，背景を無関係なテキストで高密度に充填することで前景と背景の文字カテゴリを一致させる方式（text 方式）を提案し，fine-tune なし MLLM に対する突破率（8 文字完全一致）0.0%を確認した．

MLLM の読字能力と前処理．MLLM の画像中テキスト読解には，テキスト位置特定やレイアウト認識に課題があることが報告されている [11], [12]．また，Li らは入力画像の縮小（zoom-out）のみで隠しテキストの認識精度が大幅に改善する場合があることを示したが [5]，前報の評価では text 方式に対する zoom-out の効果は確認されなかった [3]．

これらの先行研究はいずれも，特定の攻撃者（fine-tune なしの既存モデル，または単一の専用モデル）に対する一点の評価に留まる．本稿の特徴は，生成分布の訓練データの有無と読字に関わる事前知識の種類が異なる攻撃者の類型を明示し，事前学習なしの専用分類器から MLLM の fine-tune までを同一データセット・同一指標で横断測定した上で，同じ画像分布に対する人間の可読性を重ねて評価する点にある．

3. 対象方式と評価データ

3.1 錯視型 CAPTCHA（前報の再掲）

評価対象は前報 [3] で提案した錯視型 CAPTCHA である．解答は 8 文字の英大文字・数字であり，紛らわしい 5

© 2026 Information Processing Society of Japan

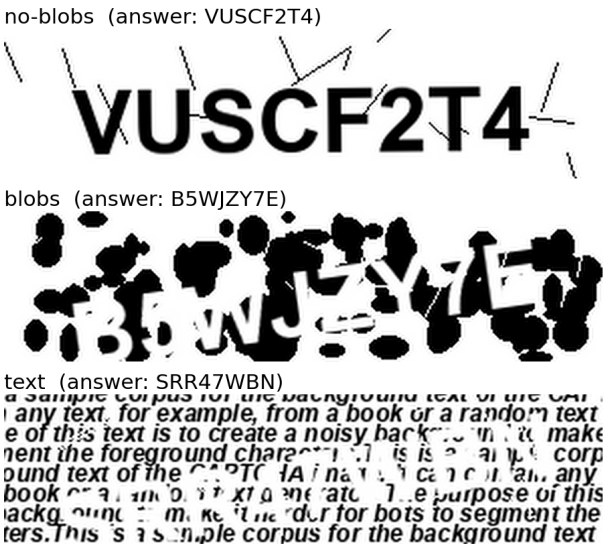


図 1 3 方式の画像例（方式は前報 [3]．画像は第 6 章の人間評価で使用した設問画像）

Fig. 1 Example images of the three schemes (schemes follow our previous report; images used as survey questions in Sec. 6).

字種（0，1，I，O，Q）を除いた 31 字種を用いる．画像サイズは 300×75 ピクセル，前景文字は白色（背景の欠落として知覚される），フォントは Arial Bold，文字ごとに ±10° の回転を加える．背景の違いにより次の 3 方式を区別する（**図 1**）．

- text 方式（提案方式）：背景を無関係な英文テキストで高密度に充填する．前景と背景が同じ文字カテゴリとなり，読み取り対象の分離が困難になる．
- blobs 方式（比較方式）：背景をランダムな黒色ブロブで充填する．Saalo[9] の主観的輪郭 CAPTCHA に対応する．
- no-blobs 方式（確認方式）：白背景に黒文字を描画する．錯視要素を持たず，読字能力そのものを確認する対照である．

3.2 評価データセット

機械評価用に，訓練用 95,000 枚・検証用 5,000 枚に加え，モデル選択に用いない独立のテストセット（text・blobs 各 5,000 枚，訓練データと解答の重複なし）を同一の生成設定で用意した．本稿の機械側の数値は全てこのテストセット（または後述のフォント別評価セット，各 5,000 枚）に基づく．また第 6 章の人間評価の設問画像は，機械評価と同一の生成分布（同じテストセット）から抽出した．これにより，第 7 章で人間と機械の正解率を同一分布上で比較できる．

主指標は，8 文字の解答が正解と完全に一致した割合であり，これを seq_acc（sequence accuracy）と表記する（前報と同一の指標である）．seq_acc は 1 文字の誤りでも不正解となる厳しい指標のため，どの程度まで読めているかを測る補助指標として，文字単位の正解率 char_acc（character accuracy）を併用する．char_acc は出力と正解の同じ位置の文字同士を比較した正解率であり（全 8 位置），出力が 8 文字に満たない場合の不足位置は不正解と数え，8 文字を超える出力の超過分は無視する．例えば正解 AB2CDE3F に対して出力 AB2CDE3G は，seq_acc では不正解（0），char_acc では 7/8（87.5%）となる．また本稿では，同一の指標 seq_acc の値を，攻撃者側の評価では突破率，人間側の評価では正解率と呼び分ける．

4. 脅威モデル：攻撃者の類型

4.1 攻撃者の類型の定義

前報 [3] の評価は fine-tune なし MLLM の攻撃者のみを対象とした．本稿では最悪ケースの想定として，生成アルゴリズムと生成分布を完全に把握し，任意の量の訓練データを自作できる攻撃者を置く．この攻撃者に対する耐性は，生成方法が攻撃者に知られた場合に期待できる耐性の下限を与える．

この最悪ケースの想定の下でも，攻撃者の構成には大きな幅がある．本稿では攻撃者を，単一の能力軸上の点としてではなく，(1) 生成分布の訓練データを持つか否か，(2) 事前学習に由来する読字に関わる事前知識の種類（なし，一般画像，OCR 特化，Web 由来の大規模マルチモーダルの 4 種），の 2 つの観点で分類した類型として扱う．評価する攻撃者は 5 系統（per-slot CNN，CRNN+CTC，TrOCR，Qwen3-VL FT，fine-tune なし MLLM）であり，各系統の位置づけを**図 2** と**表 1** に示す．本稿の評価の軸は，この類型のうちどの攻撃者までが text 方式を突破するか，である．なお本稿は，事前知識を量として比較しない．事前学習データ量が公開されていないモデルを含むうえ，各系統はアーキテクチャ・パラメータ数・学習目的・適応データ量も同時に異なるため，攻撃者を単一の強さの軸の上で定量的に順序づけることはできないからである（第 7.3 節）．攻撃者を並べて示す際の順序は，事前知識と読字との関連の深さに基づく定性的なものである．また，事前知識が豊富な攻撃者ほど突破率が高いとは限らない（読字に関わる事前知識が最も豊富な fine-tune なし MLLM も，訓練データを持たなければ text 方式をほぼ解読できない．第 5 章）．耐性は上記 2 つの観点の組合せで整理する必要がある．以下，本稿で「機械」と呼ぶときは，これらの攻撃者（モデル）の総称を指す．

各攻撃者の構成は次の通りである．per-slot CNN は ResNet18 に 8 個の分類ヘッド（各 31 クラス）を付けた固定スロット型分類器である．CRNN+CTC（Convolutional Recurrent Neural Network + Connectionist Temporal Classification）[13] は固定スロットを仮定せず CTC

© 2026 Information Processing Society of Japan

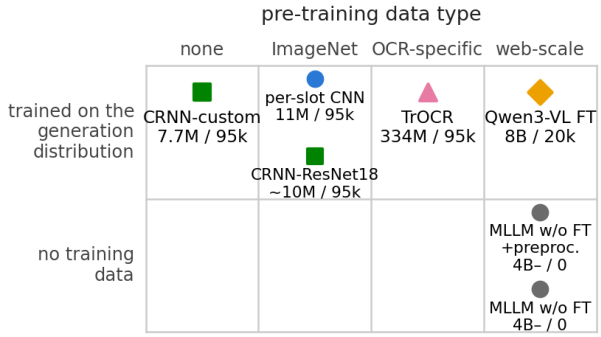


図 2 攻撃者の類型．事前学習データの種類（横）と生成分布の訓練データの有無（縦）による分類．注記はパラメータ数／防御固有データでの訓練枚数

Fig. 2 Attacker taxonomy, organized by type of pre-training data (columns) and availability of training data from the generation distribution (rows). Annotations: parameters / defense-specific training images.

表 1 各攻撃者の構成（FT 量=防御固有データでの訓練枚数．fine-tune なし MLLM は前処理探索の有無で 2 行に分けて示す）

Table 1 Attacker configurations. FT = number of defense-specific training images; the MLLM without fine-tuning appears in two rows, with and without preprocessing search.

攻撃者	事前学習	規模	FT 量
per-slot CNN	(ImageNet)	11M	95k
CRNN-custom	なし	7.7M	95k
CRNN-ResNet18	ImageNet	約 10M	95k
TrOCR	OCR 特化	334M	95k
Qwen3-VL FT	大規模 Web	8B	20k
fine-tune なし MLLM+前処理	大規模 Web	4B–	0
fine-tune なし MLLM	大規模 Web	4B–	0

損失で動的に位置合わせを行う系列認識器であり，事前学習なしの 5 層 CNN 構成と ImageNet 事前学習の ResNet18 構成の 2 種を用意した（図 2・表 1 ではそれぞれ CRNN-custom，CRNN-ResNet18 と表記．結果が固定スロット設計に固有の性質に依存しないことの確認用）．TrOCR[14] は印刷文字 OCR で事前学習された Transformer であり，OCR 特化の事前知識の寄与を測る．Qwen3-VL FT（FT は fine-tuning の略）は，Web 由来の大規模データで事前学習された MLLM である Qwen3-VL-8B[15] を LoRA（Low-Rank Adaptation）[16]（rank 32，画像エンコーダ（vision tower）を含む全線形層に適用）で適応させた攻撃者であり，Web 由来の大規模事前学習の列（図 2）に位置する．

Qwen3-VL FT の fine-tune 量は計算資源の制約から 20,000 枚（他モデルは 95,000 枚）とした（この差の含意は第 5.2 節で述べる）．

また，両者の中間として，訓練データを持たないまま入力側で適応を試みる攻撃者（fine-tune なし MLLM+前処理探索）を置く．これは画像前処理を網羅的に試してから fine-tune なし MLLM に読ませる攻撃であり，訓練データを入手せずに突破率をどこまで高められるかを確かめる役割を持つ（第 5.1 節）．

4.2 評価条件

各攻撃者を次の 3 条件で評価する．

- Seen 条件: 訓練と同一分布のテストセットで評価する．生成方法が攻撃者に知られた場合の耐性を測る条件である．
- 単一フォント条件: Arial Bold のみで訓練した攻撃者を，前景フォントを差し替えた 10 フォント（Arial Black，Verdana Bold，Arial Regular，Arial Italic，Bahnschrift，Courier New Bold，Georgia Bold，Arial Narrow，Times New Roman，Impact）と訓練フォント（対照）の計 11 フォントで評価する．防御側が最も低コストで実施できる対策（フォント変更）への攻撃者の追随能力を測る．
- 複数フォント条件: 攻撃者が 8 フォントの訓練データを用意して適応した後，訓練に含まれない 3 フォント（Times New Roman，Courier New Bold，Impact）へ汎化するかを測る．フォント変更防御の本質的な限界を測る条件である．

5. 機械耐性の評価

5.1 Seen 条件の結果

表 2 に，同一分布のテストセット（各 5,000 枚）に対する各攻撃者の seq_acc を示す．生成分布の訓練データで適応した攻撃者は，評価した 4 系統の全てが text 方式を 98% 以上で解読した（比較方式の blobs は，評価した per-slot CNN で 94.1%）．なお比較方式である blobs の機械評価は per-slot CNN と fine-tune なし MLLM に限定しており，表中の「—」は未評価を表す．一方，同じテストセットに対する fine-tune なし MLLM（Qwen3-VL-4B；Qwen3-VL FT と系列を揃えて選定）の seq_acc は text 方式で 0.00%（char_acc 2.9%）であり，前報の GPT-5.2・Gemini 3 系の結果（0.0%）[3] と整合する．なお，Qwen3-VL FT では，言語側のみを LoRA 適応した場合は検証データに対する seq_acc が 0%に留まり，画像エンコーダ（vision tower）を適応対象に含めた場合にのみ学習が成立した（付録 A.4）．text 方式の突破には，言語側の知識ではなく視覚表現の適応が必要であることを示唆する．

次に，fine-tune なし MLLM 攻撃者が入力側で適応する余地を確かめるため，二値化（Otsu 法，Sauvola 法等）・コントラスト調整・エッジ抽出・モルフォロジー演算・平滑化にわたる 19 種の画像前処理を施した上で fine-tune なし MLLM に読ませる評価を行った（前報 [3] と同一の評価画像 100 枚，Gemini 3 Flash，few-shot 教示．条件の内訳と

© 2026 Information Processing Society of Japan

表 2 Seen（同一分布）条件の突破率（seq_acc，各 n=5000）
Table 2 Attack success under the seen distribution (seq_acc, n=5000 each).

攻撃者	text	blobs
per-slot CNN	99.88%	94.08%
CRNN（custom/ResNet18 の最良）	99.94%	—
TrOCR	99.52%	—
Qwen3-VL FT	98.72%	—
fine-tune なし MLLM	0.00%	3.06%

各突破率は付録 A.1 に示す）．text 方式で統計的に有意な改善を示した前処理は erosion（収縮）のみであり，その突破率は 13%であった．erosion が唯一機能する理由は，白い前景文字のストロークが背景文字より太いというストローク幅の非対称性にある．収縮は細い白領域（背景文字）を先に消すため，太い前景ストロークが相対的に保存される．一方，輝度の絶対値を操作するコントラスト・二値化系はこの相対差を操作できず全て 0%であった．さらに，攻撃者が無処理を含む全 20 条件を 1 枚ごとに試し分ける予算を持つと仮定しても突破率は 14%であり（n=100，95%信頼区間 7.9–22.4%．86%の画像はどの前処理でも解読できない），前報 [3] で評価した zoom-out 前処理 [5] や erosion とスケールの併用でも改善しなかった．なお blobs 方式では前処理なしでも fine-tune なし MLLM が 11%読める分，前処理の上積みはコントラスト強調系（CLAHE: Contrast Limited Adaptive Histogram Equalization）で 13%であり，有効な前処理の系統も方式に依存する．

この対比は次のことを意味する．第一に，錯視による text 方式の耐性は Web 由来の大規模事前学習だけでは突破されず（fine-tune なし MLLM で 0%），入力前処理を尽くす適応を加えた場合でも 14%に留まった．すなわち，本稿で評価した訓練データなし攻撃の範囲では，生成分布に基づく訓練データの入手が，安定して高い突破率を得るための実質的な条件であった．第二に，生成分布の訓練データを得た攻撃者に対しては，text 方式は評価した全ての訓練済み攻撃者に 98%以上で，blobs 方式も評価した per-slot CNN に 94.1%で解読される．したがって，生成方法が攻撃者に知られた場合に防御が成立する余地は，生成分布からのずれ，すなわち防御側がパラメータを変更したときの攻撃者の汎化困難性に求めるほかない．次節でその代表であるフォント変更を評価する．

5.2 フォント変更条件の結果

単一フォント条件．図 3 に，Arial Bold のみで訓練した各攻撃者を，訓練フォント（対照）を含む 11 フォントで評価した結果を示す（横軸のフォントの並びは，訓練フォントとの字幅・太さの類似に基づく定性的な順序である．定量的なフォント距離の導入は今後の課題とする）．フォント別の数値の一覧を**表 3** に示す．読字に関わる事前知識を持

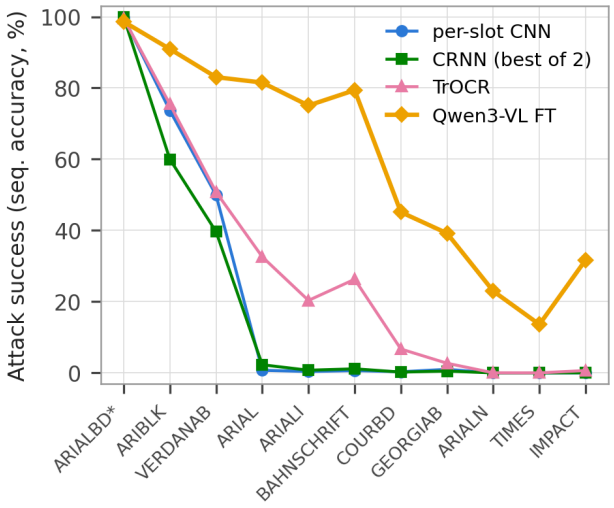


図 3 単一フォント条件の耐性曲線：単一フォント訓練の攻撃者による未知フォントの突破率（各 n=5000）．ARIALBD*は訓練フォント（対照）
Fig. 3 Font-change resistance under single-font training: attack success on 11 fonts (n=5000 each). ARIALBD* is the training font (control).

たない per-slot CNN と CRNN の突破率は，太字系の近縁フォント（Arial Black 73.7%，Verdana Bold 49.9%）を除き，ほぼ全フォントで 0%台まで低下した．同一ファミリの Arial Regular ですら 1%未満であり，フォントを 1 つ変えるだけで事前学習なしの攻撃者の突破率はほぼ 0%となる．ただし文字単位で見ると，per-slot CNN の Arial Regular に対する char_acc は 55.0%であり，seq_acc の 1%未満という値には 8 文字完全一致による増幅（$0.55^8 \approx 0.008$）が含まれる．一方，Times New Roman は char_acc でも 12.9%であり，文字単位でも読めていない．CRNN の 2 構成（CRNN-custom/CRNN-ResNet18）は per-slot と同傾向であり，この低下が固定スロット設計に固有の現象ではないことを確認した．

これに対し，OCR 事前学習を持つ TrOCR は Arial Regular 32.6%，Bahnschrift 26.3%と部分的に追随し，Web 由来の大規模事前学習を持つ Qwen3-VL FT は全 11 フォントで 10%を超える突破率を示した（最低は Times New Roman 13.6%，最高は Arial Black 90.9%）．単一フォントの訓練データしか持たない攻撃者であっても，大規模事前学習を持つ場合は未知フォントの相当部分を読み取った．

複数フォント条件．攻撃者が 8 フォントで適応訓練した場合，訓練に含まれないフォントへの汎化はフォントの字形距離に依存し，Times New Roman（70–78%）> Courier New Bold（24–65%）≫ Impact の順で難しくなる．この傾向自体は全攻撃者で一致するが，評価したフォントの中で突破率が最も低かった Impact が，攻撃者間の差を最も鮮明に分離する．**図 4** に示す通り，Impact の突破率は per-slot 0.4%，CRNN 0.3%，TrOCR 12.5%，Qwen3-VL

© 2026 Information Processing Society of Japan

表 3 単一フォント条件の突破率（seq_acc，%，各 n=5000）．フォント略記は図 3 の横軸と同一，ARIALBD*は訓練フォント（対照）

Table 3 Attack success under the single-font condition (seq_acc, %, n=5000 each). Font codes match the x-axis of Fig. 3; ARIALBD* is the training font (control).

	per-slot	CRNN			Qwen3-VL
フォント	CNN	custom	ResNet18	TrOCR	FT
ARIALBD*	99.8	99.9	99.9	99.5	98.6
ARIBLK	73.7	60.0	54.7	75.4	90.9
VERDANAB	49.9	39.6	36.3	50.8	83.0
ARIAL	0.7	2.3	0.5	32.6	81.5
ARIALI	0.4	0.7	0.7	20.3	75.1
BAHNSCHRIFT	0.6	1.1	0.4	26.3	79.4
COURBD	0.3	0.2	0.2	6.7	45.1
GEORGIAB	1.0	0.5	0.1	2.7	39.2
ARIALN	0.0	0.0	0.0	0.0	23.0
TIMES	0.0	0.0	0.0	0.0	13.6
IMPACT	0.0	0.0	0.0	0.7	31.7

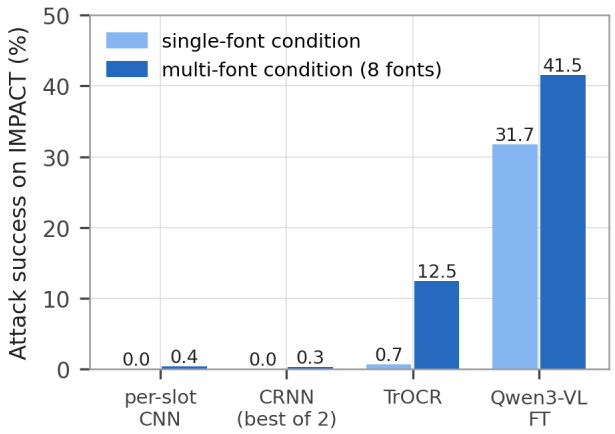


図 4 評価中最も突破率が低かったフォント Impact の突破率の攻撃者間比較．淡色=単一フォント条件，濃色=複数フォント条件（8 フォント訓練）

Fig. 4 Attack success on Impact (the empirically hardest evaluated font) across attackers. Light: single-font condition; dark: multi-font condition (8 fonts).

FT 41.5%（char_acc 85.2%）と，読字に関わる事前知識の強い攻撃者ほど高い傾向を示した（ただし各攻撃者は事前学習以外の要因も異なる．第 7.3 節）．なお，Qwen3-VL FT の適応データは 20,000 枚と他モデル（95,000 枚）より少ない．少ない適応量で他モデルを大きく上回ったことは，大規模事前学習が防御固有データの不足を補いうることを示唆する（ただし適応データ量をそろえた比較は行っておらず，量の効果の切り分けは今後の課題である．第 7.3 節）．

事前学習なしの攻撃者にとって，Impact（極太の condensed 系 display フォント）は 8 フォントの訓練後も汎化が及ばない分布外であった．しかし Qwen3-VL FT は，単一フォント条件でも 31.7%，複数フォント条件では 41.5%に到達した．すなわち，評価した 11 フォントの範囲では，Qwen3-VL FT が実用上読み取れないフォントは見いだせず，フォント変更防御の残存価値は攻撃者にデータ再収集・再訓練のコストを課す点に縮小する．

6. 人間可読性の評価

前報の課題であったユーザビリティのうち，その中核である人間可読性（正解率）を委託パネル調査により定量化した．設問画像は機械評価と同一の生成分布（第 3.2 節のテストセット）から抽出しており，機械側の結果との比較（第 7 章）を可能にしている．

6.1 調査設計

調査会社を通じ，性別 2× 年代 6（10 代〜60 歳以上）の 12 セル各 42 名，計 504 名から回答を得た．設問は 25 問（no-blobs 5 問，text 10 問，blobs 10 問）であり，設問画像は第 3 章のテストセットから事前定義の品質基準で抽出した．前景フォントは標準フォント（Arial Bold）のみであり，第 5.2 節のフォント変更条件に対応する人間評価は行っていない（第 7.3 節）．回答者への教示は，前報 [3] で MLLM に与えたプロンプトと同じ最小限の情報（8 文字，英大文字と数字）のみとし，白文字や錯視に関するヒントは与えなかった．人間と MLLM の条件対称性を保つためである．

回答品質の管理には，錯視要素を持たない no-blobs 方式を回答品質の確認用設問として用いた．no-blobs 5 問中 4 問以上正解できない回答者は，読字能力または回答努力を欠くとみなして除外する（基準は回収前に定義）．これに回答時間・無回答・一律回答の基準を加え，504 名中 98 名（19.4%）を除外した有効回答（clean）は 406 名であり，全 12 セルで 24 名以上を確保した．なお，本調査の倫理的配慮については本文末尾の研究倫理の節に記す．

6.2 結果

表 4 に方式別の人間の正解率を示す．確認用設問の no-blobs は 96.9%であり，除外後の回答者は錯視のない 8 文字をほぼ完全に読めている．その上で，text 方式の正解率は 45.5%（回答時間閾値を変えた感度分析では 43.3〜53.5%．付録 A.3），blobs 方式は 25.1%に留まった．text 方式は blobs 方式より 20.4 ポイント高く（回答者単位の対応のある t 検定，$t(405) = 16.6$，$p < 0.001$；正解率の分布が正規性を満たさない可能性を考慮した Wilcoxon 符号付順位検定でも $p < 0.001$，差の回答者ブートストラップ 95%信頼区間は 18.0–22.8 ポイント），錯視型の中では提案方式が人間に読みやすい側にあるものの，CAPTCHA の実用水準としては低い．

© 2026 Information Processing Society of Japan

表 4 人間の正解率（clean n=406．95%CI は回答者単位）
Table 4 Human accuracy (clean n=406; 95% CIs computed over respondents).

方式	seq_acc [95%CI]	char_acc
no-blobs	96.9% [96.2, 97.6]	99.3%
text	45.5% [42.3, 48.7]	65.0%
blobs	25.1% [23.0, 27.1]	57.2%

人間の 45.5%という値は，錯視防御が人間側に課す可読性コストの定量化である．char_acc で見ると，人間は平均して 8 文字中 5 文字程度（text 方式の char_acc 65.0%）は読めているが，8 文字完全一致には届かない．なお，デバイスによる正解率の差は見られず（PC 46.4% vs モバイル 44.4%），年代間にも単調な傾向は見られなかった．機械側の結果との統合は第 7 章で行う．

7. 機械耐性と人間可読性の統合評価

7.1 脅威モデルによる分離の逆転

CAPTCHA が機能するには，人間の大半が通過でき，かつ機械の突破率が十分低いことが必要である．そこで第 5 章の機械耐性と第 6 章の人間可読性を統合する．両評価は同一の生成分布・同一の指標（seq_acc）に基づき正解率を比較できる．ただし人間評価の設問画像は品質基準で抽出した各方式 10 枚であり（第 6.1 節），機械評価のテストセット（各 5,000 枚）とは標本が異なる（付録 A.2）．その上で，次の序列が観察された．

生成分布で訓練した攻撃者（約 99%）≫ 人間（45.5%）
≫ fine-tune なし MLLM（0%）

すなわち text 方式は，fine-tune なし MLLM を脅威モデルとした場合には人間と機械を大きく分離する（人間 45.5% vs 機械 0%）が，機械の排除を達成しても人間の正解率が実用水準に届かない．そして生成分布で訓練した攻撃者を仮定すると分離は逆転し（45.5% vs 99.9%．CRNN の最大値），機械には解読され人間には読みにくいという，CAPTCHA として最も不利な組合せに移る．比較方式の blobs も同様である（人間 25.1%に対し，fine-tune なし MLLM 3.1%・per-slot CNN 94.1%）．なお対照の no-blobs は，人間 96.9%に対し機械 99.4%（前報の fine-tune なし MLLM 評価 [3]）であり，そもそも機械を排除できない．いずれの脅威モデルでも，人間の可読性と機械への耐性を両立する方式は本稿で評価した範囲には存在しなかった．

第 5 章のフォント変更の結果はこの結論を補強する．フォント変更は機械突破率を引き下げる防御だが，その引き下げ幅は読字に関わる事前知識を持つ攻撃者ほど小さかった（Impact: 0%台→ 41.5%）．したがって，本稿が実測した標準フォント（Arial Bold）の範囲では，錯視型 text 方式に生成分布で訓練した攻撃者を仮定する限り，人間の可読性と機械への耐性は両立しないと結論する．一方，フォント変更後の人間可読性は未測定であり（第 7.3 節），フォント軸全域での両立可能性は本稿では確定できない．フォントファミリによっては機械が読み取りにくく人間には読みやすいものが存在する可能性も否定できず，これは実測を要する今後の課題である．

7.2 実務への含意

以上は錯視型 CAPTCHA に実用上の価値がないことを意味しない．ただし価値の中身は，軸と脅威モデルごとに切り分けて述べる必要がある．

(1) 機械排除の軸に限れば，fine-tune なし MLLM という脅威クラスに今も機能する．MLLM を API で呼ぶだけの低コストの攻撃は text 方式を解読できず（Qwen3-VL-4B，0%），前処理探索を組み込んでも 14%である（Gemini 3 Flash，第 5.1 節）．攻撃に生成分布の把握・データ作成・fine-tuning を強制すること自体が，攻撃コストの実質的な引き上げである．ただし人間側のコスト（第 3 項）は脅威モデルによらず残る．

(2) 生成分布で訓練した攻撃者には耐えられない．特定のサイトを狙い，生成方法を入手して fine-tuning を行う攻撃者には，フォント変更を含め実用的な防御にならない．この場合，錯視型に限らず視覚 CAPTCHA 単体での防御は成立せず，レート制限や行動分析等との併用が前提となる．

(3) 人間コストが設計制約を規定する．seq_acc 45.5%は，一度の試行で正解できるユーザが半数以下であることを意味する．錯視の強度（背景密度）と人間可読性のトレードオフの調整，または部分一致を許す判定設計が実運用には必要である．

7.3 限界と今後の課題

本稿の限界を 7 点挙げる．(1) 人間評価は標準フォント（Arial Bold）のみで行っており，フォント変更条件での人間可読性（機械が読み取りにくいフォントを人間がどこまで読めるか）は未測定である．可読性と耐性の両立可能性をフォント軸全域で確定させるにはフォント別の人間評価が必要であり，これを次の課題とする．(2) 評価は単一の生成系（8 文字・31 字種・300×75px）に基づく．(3) Qwen3-VL FT の適応データは 20,000 枚であり，より大量の適応でどこまで上がるかは測っていない（ただし 20,000 枚で既に 41.5%である）．(4) 人間評価には設問画像単位のばらつきが残る（付録 A.2）．(5) 評価した各攻撃者はアーキテクチャ・学習目的・適応データ量も異なり，事前学習データ量が公開されていないモデルも含むため，観察された序列を事前学習の規模や量に帰属することはできない．要因を切り分けた統制実験は今後の課題である．(6) 人間評価の方式間比較は回答者単位の検定（対応のある t 検定および Wilcoxon 符号付順位検定）によるものであり，回

© 2026 Information Processing Society of Japan

答者差と設問画像差を同時に扱う混合効果モデルによる分析は今後の課題である．(7) 人間評価で測定したのは正解率（可読性）であり，回答の所要時間・再試行・離脱率・アクセシビリティといった実運用のユーザビリティ指標は評価していない．

8. おわりに

本稿では，前報で提案した錯視型 CAPTCHA について，読字に関わる事前知識の異なる 5 系統の攻撃者（専用 CNN・CRNN・TrOCR・Qwen3-VL FT・fine-tune なし MLLM）に対する機械耐性の評価と，同一の生成分布に対する人間可読性の調査をそれぞれ行い，両者を統合して成立可否を論じた．得られた知見は次の 3 点である．第一に，生成方法を再現した攻撃者は，評価した全ての訓練済み系統が text 方式を 98%以上で解読し，生成方法が知られた場合に視覚的困難性のみで維持できる耐性はほとんど残らない．第二に，フォント変更防御の効果は読字に関わる事前知識の強い攻撃者ほど小さく，評価中最も突破率が低かった Impact でも Qwen3-VL FT に 41.5%まで突破される．第三に，人間の text 方式正解率は 45.5%であり，本稿が評価した標準フォント（Arial Bold）・生成分布で訓練した攻撃者の前提では，人間の可読性と機械への耐性を両立する構成は見いだせなかった．

CAPTCHA の耐性は単一の数値ではなく，攻撃者が生成分布の訓練データを持つか否かで大きく二分され，訓練データを得た攻撃者の間では，フォント変更後の耐性が読字に関わる事前知識の強い系統ほど侵食されることが観察された．本稿の評価枠組みは，錯視型に限らず視覚的な困難性に依拠する CAPTCHA の評価にも適用可能と考えられる．今後は，フォント変更条件での人間可読性の測定により可読性と耐性の両立可能性をフォント軸全域で検証するとともに，背景密度等の生成パラメータと人間コストの関係を明らかにしていく．

参考文献

[1] von Ahn, L., Blum, M., Hopper, N. J. and Langford, J.: CAPTCHA: Using Hard AI Problems for Security, *Advances in Cryptology – EUROCRYPT 2003*, pp. 294–311 (2003).

[2] Tariq, N., Khan, F. A., Moqurrab, S. A. and Srivastava, G.: CAPTCHA Types and Breaking Techniques: Design Issues, Challenges, and Future Research Directions, arXiv:2307.10239 (2023).

[3] 高巣真史, 武仲正彦：AI 解析を欺瞞する新しいシンプルな錯視型 CAPTCHA の提案, 信学技報, Vol. 125, No. 381, ICSS2025-135, pp. 370–377 (2026).

[4] Kanizsa, G.: Margini quasi-percettivi in campi con stimolazione omogenea, *Rivista di Psicologia*, Vol. 49, No. 1, pp. 7–30 (1955).

[5] Li, S., Cai, Y. and Wang, Y.: SemVink: Advancing VLMs' Semantic Understanding of Optical Illusions via Visual Global Thinking, arXiv:2506.02803 (2025).

[6] Roshanbin, N. and Miller, J.: A survey and analysis of current CAPTCHA approaches, *Journal of Web Engineering*, Vol. 12, pp. 1–40 (2013).

[7] Hossen, M. I. and Hei, X.: A Low-Cost Attack against the hCaptcha System, *2021 IEEE Security and Privacy Workshops (SPW)* (2021).

[8] Searles, A., Prapty, R. T. and Tsudik, G.: Dazed & Confused: A Large-Scale Real-World User Study of reCAPTCHAv2, arXiv:2311.10911 (2023).

[9] Saalo, V.: Novel CAPTCHA schemes, Seminar on Network Security, T-110.5290, Helsinki University of Technology (2010).

[10] Ding, Z., Deng, G., Liu, Y., Ding, J., Chen, J., Sui, Y. and Li, Y.: IllusionCAPTCHA: A CAPTCHA based on Visual Illusion, *Proceedings of the ACM Web Conference 2025* (2025).

[11] Fu, L., Kuang, Z., Song, J., Huang, M., Yang, B. et al.: OCRBench v2: An Improved Benchmark for Evaluating Large Multimodal Models on Visual Text Localization and Reasoning, arXiv:2501.00321 (2025).

[12] Zhang, R., Zhang, Y., Chen, J., Zhou, Y., Gu, J., Chen, C. and Sun, T.: TRINS: Towards Multimodal Language Models that Can Read, *Proc. IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)* (2024).

[13] Shi, B., Bai, X. and Yao, C.: An End-to-End Trainable Neural Network for Image-based Sequence Recognition and Its Application to Scene Text Recognition, *IEEE Transactions on Pattern Analysis and Machine Intelligence*, Vol. 39, No. 11, pp. 2298–2304 (2017).

[14] Li, M., Lv, T., Chen, J., Cui, L., Lu, Y., Florencio, D., Zhang, C., Li, Z. and Wei, F.: TrOCR: Transformer-based Optical Character Recognition with Pre-trained Models, *Proc. AAAI Conference on Artificial Intelligence*, pp. 13094–13102 (2023).

[15] Qwen Team: Qwen3-VL Technical Report, arXiv:2511.21631 (2025).

[16] Hu, E. J., Shen, Y., Wallis, P., Allen-Zhu, Z., Li, Y., Wang, S., Wang, L. and Chen, W.: LoRA: Low-Rank Adaptation of Large Language Models, arXiv:2106.09685 (2021).

[17] アイブリッジ株式会社：倫理審査関連情報：セルフ型アンケートツール Freeasy（オンライン），入手先 ⟨https://freeasy-survey.com/academic/ethical-review⟩（2026 年 8 月閲覧）．

研究倫理

本研究の人間対象調査は，アイブリッジ株式会社のセルフ型アンケートサービス Freeasy の登録パネルに対して実施した．同サービスは学術調査向けに倫理審査関連情報を公開しており [17]，回答者の匿名性の確保（個人情報の提供は発生しない），回答送信前の協力撤回，回答に応じた謝礼（ポイント付与）の枠組みが定められている．本調査もこの枠組みの下で，調査目的・取得項目（解答内容，回答時間，端末種別，年齢，評価）・匿名集計での利用を教示文で開示した上で，回答送信をもって研究利用への同意とみなした．なお，回答者の性別・年代は調査画面の設問では取得しておらず，同サービスのパネル登録属性を回答者割付（第 6.1 節の 12 セル構成）に用いたものである．納品データから個人を特定しうる項目は取り込み時に破棄し，

© 2026 Information Processing Society of Japan

回答者 ID は連番の擬似 ID に置換した．また，本研究で構築した攻撃モデルは自作 CAPTCHA 生成系の耐性測定のみに使用し，実在するサービスへの攻撃には使用していない．評価対象はすべて筆者らが生成した画像である．

付　　録

A.1　前処理探索の評価条件と結果

第 5.1 節の前処理探索で評価した条件は，無処理（raw）を含む 20 条件（前処理 19 種）である．各条件について，前報 [3] と同一の評価画像 100 枚を Gemini 3 Flash（few-shot 教示）に読ませたときの text 方式の突破率を**表 A·1** に示す．

表 A·1　前処理探索の全 20 条件と text 方式の突破率（各 n=100）
Table A·1　All 20 preprocessing conditions and attack success on the text scheme (n=100 each).

系統	条件（突破率%）
モルフォロジー	erosion（収縮）13，opening 0，tophat 0
輪郭・距離変換	距離変換 5，Canny 0，Sobel 0
平滑化	ガウス σ=2: 3，ガウス σ=1: 0，メディアン 3×3: 0
二値化	Otsu 法 0，適応的ガウス 0，Sauvola 法 0，Niblack 法 0
輝度・コントラスト	輝度反転 0，min-max 正規化 0，ガンマ補正（0.7/1.3）各 0，CLAHE 0，線形コントラスト強調 0
対照	無処理（raw）0

A.2　設問画像別の正解率のばらつき

人間評価の正解率には設問画像単位のばらつきが残る．clean 回答者ベースで text 方式 10 枚の seq_acc は 7〜65%（中央値 49%），blobs 方式 10 枚は 1〜62%に分布した．特に text 方式の 1 枚（7%）は他の 9 枚（35〜65%）から離れた外れ値であり，背景と前景の重なり方の偶然による難化と考えられる．本文の方式別正解率はこれらを除外せず全設問画像の平均で報告している．

A.3　回答品質管理の設計と感度分析

除外基準は回収前に定義した．(1) 確認用設問：no-blobs 5 問中 4 問未満正解（75 名），(2) 回答時間 150 秒未満（75 名），(3) 8 文字英数字を 1 問も入力しない（56 名），(4) 全問一律回答（12 名）．重複を除いた除外は 98/504 名（19.4%）である．確認用設問は除外後の回答者で no-blobs 96.9%を示し，「読める人はほぼ満点」という設計意図どおりに機能した．回答時間閾値の感度は（閾値未満の短時間回答を除外するため，閾値を上げるほど有効回答者数は減る），60 秒で text 43.3%（clean 427 名），150 秒で 45.5%（406 名），300 秒で 53.5%（335 名）であり，閾値選択は結果の水準に影響するが，主除外基準が確認用設問であるため本文の結論（機械 ≫ 人間 ≫fine-tune なし MLLM）は閾値によらない．また，確認用設問の基準を事前定義の「4 問以上正解」から「5 問全問正解」に強めた場合は n=344 で text 47.4%・blobs 26.3%となり（4 問のみ正解の 62 名は text 35.2%・blobs 18.4%），基準を強めても結果の水準・序列は変わらない．主分析に「4 問以上」を用いる根拠は 2 点ある．第一に，全 504 名の no-blobs 正解数は 0–1 問（64 名）と 4–5 問（429 名）に二分され（2–3 問は 11 名のみ），回答努力を欠く回答者は 0 問付近に集中するため，両基準が排除する層は実質同じである．第二に，4 問正解の 62 名の誤答を精査すると，56 名（90%）は 1 文字の置換・脱落・隣接転置（Damerau-Levenshtein 距離 1 以内）または隣接設問の解答の転記であり，字形の混同（8 → 5 等）やタイプミスと整合的である．全問正解の要求は，読字能力のある回答者を偶発的な入力ミスで除外することになる．

A.4　Qwen3-VL FT の設定詳細

Qwen3-VL-8B を bf16 精度で読み込み（量子化は用いていない），LoRA（Low-Rank Adaptation）[16] により適応した．rank 32，alpha 64，適用対象は vision tower を含む全線形層である．言語側のみの LoRA では検証データに対する seq_acc が 0%に留まり，vision tower を適応対象に含めた場合にのみ収束した（第 5.1 節）．学習率は 5e-5（3% ウォームアップ後コサイン減衰），5 エポック，訓練データはランダム抽出の 20,000 枚を用いた．なお学習率 2e-4 では，複数フォント混合訓練時に画像を無視して尤もらしい 8 文字を出力する退化解に収束する現象を確認しており，再現時は学習率の設定に注意されたい．

© 2026 Information Processing Society of Japan