階層型強化学習における Leader 観測攻撃に対する Follower 側防御

宇井 貴斗[1]　山辺 翔二郎[1]　佐久間 淳[1,2]

概要：階層型強化学習（HRL）は，上位方策（Leader）が subgoal などの指示を出し，下位方策（Follower）の行動を導くことで長期タスクに取り組む．この階層では，Leader の観測への摂動が指示を介して Follower の行動へ伝播し，タスクの失敗を引き起こしうる．本研究では，(1) Leader は攻撃を受けるが，防御のためにその方策を変更できず，(2) Follower は直接攻撃を受けないが，防御のためにその方策を変更できる，という脅威モデルを仮定する．この脅威モデルの下で，価値劣化を，摂動の大きさ，Leader の出力感度，および Leader 出力に対する Follower の感度の積で上界する．この結果に基づき，Leader 出力の変化に対する Follower の応答を正則化する，HRL のための新たな防御戦略 Follower Regularization against Leader-Side Adversarial Perturbations（FLAP）を提案する．3 環境での実験では，攻撃下において，FLAP は 3 環境中 2 環境で防御なし方策より高い平均成功率を達成した．本研究の解析では，この差を，Follower が自身の観測だけでタスクを達成できるか，および Leader 出力のより大きな変化に耐えられるか，という 2 点に関連づける．

キーワード：階層型強化学習，敵対的摂動，ロバスト強化学習，方策平滑化

Follower-Side Defense against Leader-Side Adversarial Attacks in Hierarchical Reinforcement Learning

Takato Ui[1]　Shojiro Yamabe[1]　Jun Sakuma[1,2]

Abstract: Hierarchical reinforcement learning (HRL) addresses long-horizon tasks by using an upper-level policy (the leader) to issue directives, such as subgoals, that guide the actions of a lower-level policy (the follower). In this hierarchy, perturbing the leader's observation can propagate through the directive to the follower's actions and cause task failure. We assume that (1) the leader is attacked, but its policy cannot be modified for defense, and (2) the follower is not attacked directly, but its policy can be modified for defense. Under this threat model, we bound the resulting value degradation by a product of the perturbation magnitude, the leader's output sensitivity, and the follower's sensitivity to the leader output. This result leads to a novel defense strategy for HRL, Follower Regularization against Leader-Side Adversarial Perturbations (FLAP), which regularizes the follower's response to changes in the leader output. In experiments across three environments, under attack, FLAP achieved higher mean success rates than the undefended policy in two of the three environments. Our analysis relates this difference to whether the follower can complete the task using only its own observation and whether it tolerates larger changes in the leader output.

Keywords: hierarchical reinforcement learning, adversarial perturbation, robust reinforcement learning, policy smoothing

1. Introduction

深層強化学習は，ゲームやロボット制御などの逐次意思決定タスクで高い性能を達成してきた．しかし，遠方の

[1] 東京科学大学
Institute of Science Tokyo
[2] 理化学研究所 革新知能統合研究センター
RIKEN Center for Advanced Intelligence Project

© 2026 Information Processing Society of Japan

This paper is work in progress and not peer-reviewed.

ゴールへ到達したときにしか報酬が与えられない場合，学習信号が疎で遅延するため，単一の方策を学習することは困難である [1]．このようなタスクに対し，階層型強化学習（Hierarchical Reinforcement Learning; HRL）は長い行動系列を短期の部分問題へ分割する [1], [2]．本研究で扱う HRL では，上位方策（以下 Leader）が連続な出力を生成し，下位方策（以下 Follower）がその出力と自身の観測に基づいて環境への行動を選ぶ．例えば迷路ナビゲーションでは，Leader は迷路全体を観測して中間目標状態を subgoal として指定し，Follower は局所観測と subgoal を用いて行動を選ぶ．タスクを「何を目指すか」と「どう実行するか」に分解することで，Follower は短期の到達問題だけを解けばよく，疎報酬の問題が緩和される．オンライン設定の HIRO[3] および HAC[4]，オフライン設定の HIQL[5] がこの形式の代表例である．

一方，深層ニューラルネットワークでパラメータ化された方策には，観測への敵対的摂動に対する脆弱性が知られている [6]．この摂動は，例えば勾配降下法により，方策の出力や価値推定を悪化させるよう最適化される．方策の攻撃に対するロバスト性については，最悪ケースの摂動を学習過程に組み込む敵対的学習と，入力の変化に対する方策出力の急激な変化を抑える方策平滑化という，大きく二つの防御が研究されてきた [7], [8]．しかし，HRL における Leader 方策と Follower 方策の攻撃に対するロバスト性は，これまで十分に研究されていない．HRL では Leader 出力が Follower 入力となるため，Leader 観測への摂動はこの出力を介して Follower の行動へ影響しうる．

攻撃を受ける Leader 方策を防御のために変更できるなら，既存の敵対的学習や方策平滑化を Leader 方策へ直接適用できる．しかし，多くの設定では Leader 方策を固定する要求がある．例えば Leader が API を通じてのみ利用できる場合，防御者はその出力を問い合わせることはできるが，パラメータへのアクセスや更新はできない．また，学習済み Leader を別の階層で学習した Follower と組み合わせて再利用できる HRL アーキテクチャも提案されている [9], [10]．この転用可能性を維持するには Leader を固定する必要がある．いずれの設定でも，攻撃を受けるのは Leader だけであるにもかかわらず，防御者が変更できるのは Follower だけである．

本研究では，「Leader が攻撃を受ける一方で固定されているとき，Follower 方策だけで Leader 観測への敵対的摂動の伝播を緩和できるか」という問いに取り組む．Leader の内部重みや勾配を用いず，Leader 出力に対する Follower の応答を正則化することで，この伝播を抑える手法を提案する．

本論文の貢献は次の 3 点である．

- **定式化．** Leader 観測への摂動が Leader 出力を変え，その出力が Follower 方策へ入力されることで環境への行動を変化させる，HRL 固有の攻撃経路を定式化する．先行研究 [11] に従い，Leader 出力を周辺化して Leader 方策と Follower 方策を一つの方策（統合方策）とみなす．その上で，攻撃を統合方策の行動分布の変化として表し，単一方策の観測摂動について導かれた議論を階層全体へ適用可能にする．
- **理論．** 統合方策の行動分布の変化の上界を導く（定理 1）．次に，Leader 観測への敵対的摂動による価値劣化を上界する（系 1）．この上界は，摂動の最大の大きさ，観測に対する Leader の出力感度，および Leader 出力に対する Follower の行動感度という三つの因子の積に比例する．この分解により，Leader 方策を変更できない場合でも，Follower 方策の入力感度を下げることで上界を小さくできることを示す．
- **アルゴリズムと実験．** Leader 出力に対する Follower の感度の局所的な代理量を正則化することで，既存の平滑化に基づく防御を Follower 方策へ適用する Follower Regularization against Leader-Side Adversarial Perturbations（FLAP）を導出する．この防御は Leader の重みを変更する必要がなく，Leader を推論のために問い合わせられれば適用できる．HIQL[5] 上に FLAP を実装して 3 環境で評価し，環境によって効果が異なることを確認する．さらに，この環境間の差を，(i) Leader 出力がタスクに関する情報を持たないときにも Follower が自身の観測に基づいて行動を継続するか，(ii) 防御後の Follower が，成功率を大きく低下させることなく Leader 出力のより広い範囲の変化に耐えられるか，という二つの性質から特徴づける．

2. Related Work

観測摂動に対するロバスト化．標準的な強化学習における観測摂動へのロバスト性の研究は，二つに大別できる．非敵対的な観測ノイズや分布変化に対しては，確率的観測モデルの下での状態推定や，ランダムなデータ拡張を用いる手法がある [12], [13]．一方，報酬を低下させる敵対的摂動について，SA-MDP[6] は，現在の真の状態を変えず，観測された状態に許される変更を定式化した．この枠組みに基づき，学習した敵対的摂動を訓練へ組み込む防御 [7], [14]，敵対的サンプルを用いない方策蒸留と Jacobian 正則化による防御 [15]，最悪ケースのリターンを最適化する手法や時間的に結合した摂動を扱う手法 [16], [17] が提案されている．

平滑化と Lipschitz 連続性に基づくロバスト化．観測近傍で方策出力を安定させる平滑化も研究されており，行動の一貫性を促す正則化 [8], [18] や，Lipschitz 条件を満たすネットワーク [19] が提案されている．ERNIE[8] は，近傍内で出力差を最大化する入力を探索し，その差を罰する．こうした平滑性に基づくロバスト性は，行動不変条件や累

© 2026 Information Processing Society of Japan

積報酬の下界として分析されている [20], [21].

HRL におけるロバスト化．HRL では，到達不能な subgoal を除外する手法 [22]，学習中に変化する Follower に合わせて Leader を更新する手法 [23]，subgoal の不確実性に基づいて subgoal を生成・選択する手法 [24], [25] が研究されている．これらはいずれも Leader または subgoal の生成過程を変更する．一方，観測への敵対的摂動に対するロバスト性を明示的に考慮した HRL は，これまで研究されていない．

本研究の位置づけ．既存研究は，ロバスト化の対象となる方策（単一方策の強化学習では攻撃を受ける方策，HRL では Leader）を直接変更することでロバスト性を高める．これに対し，本研究では，直接攻撃を受けないものの，Leader 観測への攻撃の影響を Leader 出力を介して受ける Follower のロバスト性に着目する．本設定では Leader を固定したまま，摂動により生じる Leader 出力の変化に対して Follower だけで防御する．

3. Preliminaries

MDP．環境を MDP $\mathcal{M} = (\mathcal{S}, \mathcal{A}, P, r, \gamma, \mu_0)$ として考える．$\mathcal{S}$ は状態空間，$\mathcal{A}$ は行動空間，$P(s_{t+1} \mid s_t, a_t)$ は遷移確率，r は報酬関数，$\gamma \in [0, 1)$ は割引率，μ_0 は初期状態分布である．時刻 t の状態は $s_t = (s_{L,t}, s_{F,t})$ と分解され，Leader は $s_{L,t}$ を，Follower は $s_{F,t}$ を観測として受け取る．方策 π のもとでの状態価値関数と期待割引累積報酬をそれぞれ

$$V^\pi(s) = \mathbb{E}_\pi \left[\sum_{t \geq 0} \gamma^t r(s_t, a_t) \,\middle|\, s_0 = s \right], \qquad J(\pi) = \mathbb{E}_{s_0 \sim \mu_0}[V^\pi(s_0)] \tag{1}$$

と書く．

連続な中間出力をもつ HRL．HRL では，Leader 方策 $\pi_{\theta_L}(a_L \mid s_L)$ が観測 $s_L \in \mathcal{S}_L$ から連続な中間出力 $a_L \in \mathcal{A}_L$ を生成し，Follower 方策 $\pi_{\theta_F}(a_F \mid s_F, a_L)$ が観測 $s_F \in \mathcal{S}_F$ と a_L から環境への行動 $a_F \in \mathcal{A}$ を選ぶ．以下ではパラメータを省略した両方策を π_L, π_F と書く．

統合方策．HRL では，Leader 方策と Follower 方策の組を，Leader 方策の出力を周辺化した元の MDP 上の方策に対応づけ，その価値を元の MDP 上で評価する定式化が用いられている [11]．本研究ではこの定式化に基づき，Leader が生成する a_L を周辺化して得られる Follower 行動の分布を，統合方策 π として次のように定義する．

$$\pi(\cdot \mid s_L, s_F) := \int_{\mathcal{A}_L} \pi_F(\cdot \mid s_F, a_L)\, \pi_L(da_L \mid s_L) \tag{2}$$

この統合方策は，$a_L \sim \pi_L(\cdot \mid s_L)$，$a_F \sim \pi_F(\cdot \mid s_F, a_L)$ の順に生成される a_F の周辺分布であり，階層構造全体が環境へ出力する行動分布に等しい．環境遷移と報酬は a_L に直接依存しないため，$J(\pi)$ は階層構造全体の期待割引累積報酬と一致する．

Leader と Follower の学習目的．Leader の学習目的は，Follower を固定したときの統合方策の $J(\pi)$ である．一方，Follower の学習には，Leader 方策 $\bar{\pi}_L$ を固定し，報酬 r を Follower 用の報酬関数（例えば Leader 出力が示す状態への到達度）に置き換えた期待割引累積報酬 $J_F(\pi_{\theta_F}; \bar{\pi}_L)$ を用いる．J_F は手法や設定に応じて様々に定義できるが，以降の理論解析は J_F の具体形には依存しない．

4. Threat Model

攻撃を受ける方策自体を変更できる場合，方策平滑化などの単一方策に対する既存防御を直接適用できる．すなわち，Leader 観測への摂動には Leader を，Follower 観測への摂動には Follower を直接防御すればよい．しかし Introduction で述べたように，Leader を凍結する必要があり，防御のために変更できない場合がある．

そこで本研究では，Leader 観測が摂動を受ける一方で，変更できるのは Follower 方策だけである設定に着目する．以下，攻撃者と防御者の目的，知識，能力，制約を定める．

攻撃者の目的．攻撃者の目的は，Leader 観測への摂動によって Leader 出力を変化させ，その変化を Follower の行動へ伝播させることで，タスクの期待割引累積報酬を低下させることである．すなわち，攻撃者は，後述の攻撃強度の上限 $\boldsymbol{c}$ が定める摂動範囲 $B_{\boldsymbol{c}}(s_{L,t})$（式 (4)）の下で

$$\min_{\{s'_{L,t} \in B_{\boldsymbol{c}}(s_{L,t})\}_{t \geq 0}} \mathbb{E}\left[\sum_{t \geq 0} \gamma^t r(s_t, a_{F,t}) \right], \quad a_{L,t} \sim \pi_L(\cdot \mid s'_{L,t}),\ a_{F,t} \sim \pi_F(\cdot \mid s_{F,t}, a_{L,t}) \tag{3}$$

を解く．

攻撃者の知識．攻撃者は Leader 方策，Follower 方策および学習済みの価値関数へアクセスできる white-box 設定とする．これは保守的な仮定である．

攻撃者の能力と攻撃強度の上限．攻撃者が変更できるのは各時刻の Leader 観測 s_L のみであり，環境の真の状態，Follower 観測・行動，および環境のゴールには介入できない．Leader 観測の各次元 i に対する攻撃強度の上限を $c_i \geq 0$ とし，$\boldsymbol{c} = (c_i)_i$ と書く．攻撃者は，摂動後の観測を

$$B_{\boldsymbol{c}}(s_L) = \{\, s'_L \in \mathcal{S}_L : |s'_{L,i} - s_{L,i}| \leq c_i \quad (\forall i) \,\} \tag{4}$$

から選ぶ．以下，Leader 観測空間 $\mathcal{S}_L$ 上の距離を d_L とする．この攻撃強度の上限の下で摂動の大きさが有界，すなわち

$$\sup_{x_L \in \mathcal{S}_L,\ x'_L \in B_{\boldsymbol{c}}(x_L)} d_L(x_L, x'_L) < \infty \tag{5}$$

と仮定する．この攻撃強度の上限の範囲内のランダムな摂動と，期待割引累積報酬を低下させるように最適化された摂動の双方を扱い，前者を非敵対的摂動，後者を敵対的摂

© 2026 Information Processing Society of Japan

動と呼ぶ

防御者の目的. 防御者の目的は，摂動がないときの性能を維持しつつ, 式 (4) の範囲内の摂動に対するタスクの期待割引累積報酬を高めることである．baseline の Follower パラメータを θ_F^{base}, 無摂動時の期待割引累積報酬を $J_{\mathrm{clean}}(\theta_F)$, 許容する低下幅を $\Delta \geq 0$ とすると，防御者の目的を

$$\max_{\theta_F} \min_{\{s'_{L,t} \in B_{\boldsymbol{c}}(s_{L,t})\}_{t\geq 0}} \mathbb{E}_{\pi_L, \pi_{\theta_F}} \left[\sum_{t\geq 0} \gamma^t r(s_t, a_{F,t}) \right] \quad (6)$$
$$\text{s.t.} \quad J_{\mathrm{clean}}(\theta_F) \geq J_{\mathrm{clean}}(\theta_F^{\mathrm{base}}) - \Delta$$

と表す.

防御者の知識と能力. 防御者は Follower 方策のパラメータ・勾配と学習データへアクセスできる一方，Leader 方策に対しては black-box であり，推論実行のみ可能とする．また，攻撃の具体的な生成方法と攻撃強度の上限 $\boldsymbol{c}$ は防御時には未知とする．防御者は Follower 方策のパラメータを変更できる．例えば，その学習目的に正則化項を加えることで防御を施すことができる.

防御者の制約. Leader 方策は固定されており，そのパラメータは変更できない．また，防御者は Leader 方策の勾配を用いることができない．防御のために変更できるのは Follower 方策のみである．防御は学習時に行い，評価時には Leader 方策と Follower 方策のいずれも変更できない.

5. Theoretical Foundation

摂動は Leader 観測へ加えられるが，本研究の脅威モデルで変更できるのは Follower だけである．以下では，この摂動による価値劣化の上界が Follower 側の平滑性を表す因子を含み，この因子を小さくすることで上界を縮小できることを示す.

方策摂動と価値劣化. 単一エージェントでは，観測摂動によって誘導される方策の行動分布変化が小さければ，期待割引累積報酬の劣化も小さく抑えられることが知られている [6], [8]．二つの確率分布 μ, ν の総変動距離を $D_{\mathrm{TV}}(\mu, \nu) = \sup_E |\mu(E) - \nu(E)|$ と書く．報酬が $|r(s,a)| \leq R_{\max}$ で有界であるとき，次の性能差の上界が成り立つ.

補題 1 (方策摂動による価値劣化 [8])**.** 任意の状態 s で $D_{\mathrm{TV}}(\pi(\cdot \mid s), \tilde{\pi}(\cdot \mid s)) \leq \alpha$ が成り立つとする．このとき任意の初期状態 s に対して

$$|V^{\pi}(s) - V^{\tilde{\pi}}(s)| \leq \frac{2R_{\max}}{(1-\gamma)^2}\alpha \quad (7)$$

が成り立つ．ただし，π を摂動を受けない方策，$\tilde{\pi}$ を観測摂動を受ける方策とする.

したがって，Leader 観測摂動による統合方策 (2) の行動分布変化を上界することができれば，価値劣化も上界することができると考えられる.

統合方策の Lipschitz 分解. 次の定理は，統合方策の L_1-Lipschitz 上界が Leader 観測の経路と Follower 観測の経路の 2 項の和で与えられ，前者の係数が Leader 方策の滑らかさと Follower の Leader 出力に対する入力感度の積に分解されることを示す．Leader 出力空間 $\mathcal{A}_L$ 上の距離を d_A とし，Leader 出力空間上の 1-Wasserstein 距離を

$$W_1(\mu, \nu) = \inf_{\kappa \in \Gamma(\mu,\nu)} \mathbb{E}_{(a_L, a'_L)\sim\kappa}[d_A(a_L, a'_L)] \quad (8)$$

と定義する．ここで $\Gamma(\mu, \nu)$ は μ と ν のカップリング全体である.

定理 1 (統合方策の L_1-Lipschitz 性)**.** Leader 方策 $\pi_L(\cdot \mid s_L)$ および Follower 方策 $\pi_F(\cdot \mid s_F, a_L)$ がそれぞれ次を満たすとする.

$$W_1\big(\pi_L(\cdot \mid s_L), \pi_L(\cdot \mid s'_L)\big) \leq L_{\pi_L}^{(W)} d_L(s_L, s'_L), \quad (9)$$
$$\|\pi_F(\cdot \mid s_F, a_L) - \pi_F(\cdot \mid s_F, a'_L)\|_1 \leq 2L_{\pi_F}^{(a)} d_A(a_L, a'_L), \quad (10)$$
$$\|\pi_F(\cdot \mid s_F, a_L) - \pi_F(\cdot \mid s'_F, a_L)\|_1 \leq 2L_{\pi_F}^{(s)} \|s_F - s'_F\|_\infty. \quad (11)$$

このとき，統合方策 (2) は L_1 距離に関して Lipschitz 連続であり，任意の (s_L, s_F) と (s'_L, s'_F) に対して

$$\|\pi(\cdot \mid s_L, s_F) - \pi(\cdot \mid s'_L, s'_F)\|_1 \leq 2\Big(L_{\pi_F}^{(a)} L_{\pi_L}^{(W)} d_L(s_L, s'_L) + L_{\pi_F}^{(s)} \|s_F - s'_F\|_\infty\Big) \quad (12)$$

が成り立つ.

証明は付録 A.1 に与える.

第一項は Leader 観測の変化が Leader 出力を介して Follower 行動へ伝わる経路，第二項は Follower 観測変化の直接の経路を表す．本設定では $s'_F = s_F$ なので第二項は 0 となり，残る第一項は，変更可能な Follower の感度 $L_{\pi_F}^{(a)}$ に依存する.

Leader 観測摂動下の価値劣化. 定理 1 が与える行動分布変化の上界を補題 1 と組み合わせることで，Leader 観測摂動下の価値劣化を，Leader 側の量と Follower 側の量の積で上界することができる.

系 1 (Leader 観測摂動下の価値劣化)**.** 定理 1 の条件が成り立つとする．Leader 観測のみが $s'_L \in B_{\boldsymbol{c}}(s_L)$ の範囲で摂動され，Follower 観測 s_F は変化しないとする．摂動なしの統合方策を π，摂動後の統合方策を $\tilde{\pi}$ と書くと，任意の初期状態 s に対して

$$V^{\pi}(s) - V^{\tilde{\pi}}(s) \leq \frac{2R_{\max}}{(1-\gamma)^2} L_{\pi_F}^{(a)} L_{\pi_L}^{(W)} \times \sup_{x_L \in \mathcal{S}_L,\ x'_L \in B_{\boldsymbol{c}}(x_L)} d_L(x_L, x'_L) \quad (13)$$

が成り立つ.

系 1 の上界のうち，攻撃強度の上限内の観測距離の上限 $\sup d_L$ は脅威モデルによって固定される．二つの方策平滑

© 2026 Information Processing Society of Japan

性の因子のうち，Leader 側の $L_{\pi_L}^{(W)}$ は Leader が固定されているため変化しない．防御者が変更できる方策に対応する因子は，Follower 側の $L_{\pi_F}^{(a)}$ だけである．

したがって，$L_{\pi_F}^{(a)}$ を小さくすれば，Leader 側の因子を変えることなく価値劣化の上界を縮小でき，Follower だけの防御によって Leader 観測への攻撃を緩和できる．[*1]Follower に対する敵対的学習には，敵対的に摂動した Leader 観測が必要となるが，その生成には，防御者がアクセスできない Leader 方策の勾配が必要である．これに対し，導出した上界は小さくすべき量が Follower 側の平滑性因子 $L_{\pi_F}^{(a)}$ であることを示しており，平滑化正則化はまさにこの因子の局所的な代理量を対象とする．次節では，この考えに基づく防御を構成する．

6. Follower Regularization against Leader-Side Adversarial Perturbations

前節の解析に基づき，Follower Regularization against Leader-Side Adversarial Perturbations（FLAP）を提案する．この防御は，Leader 出力に対する Follower の感度の局所的な代理量を正則化する．FLAP は，Leader 出力 a_L の近傍で Follower の行動分布を最も大きく変化させる摂動後の出力 a'_L を探索し，この最悪ケースの変化を抑えるように Follower を再学習する．

正則化項と学習アルゴリズム． $L_{\pi_F}^{(a)}$ はすべての観測と Leader 出力にわたる大域的な量であり，防御者はこれを学習中に直接評価できない．そこで FLAP では，Leader 出力を a_L から a'_L へ変えたときの Follower の行動分布の変化量を

$$D_F(s_F; a_L, a'_L) := D_{\mathrm{TV}}\big(\pi_{\theta_F}(\cdot \mid s_F, a_L),\, \pi_{\theta_F}(\cdot \mid s_F, a'_L)\big) \tag{14}$$

と定義する．防御者は学習データに現れる各 (s_F, a_L) について，a_L から距離 ε_a 以内で D_F を最も大きくする a'_L を求め，その値を正則化項として罰する:

$$\mathcal{R}_{\mathrm{sens}}(\theta_F) = \mathbb{E}_{(s_F,a_L)}\Big[\max_{d_A(a_L,a'_L)\le\varepsilon_a} D_F(s_F; a_L, a'_L)\Big]. \tag{15}$$

防御者はこの正則化項を，重み λ を付けて Follower の学習目的 $J_F(\pi_{\theta_F}; \bar{\pi}_L)$ に加える:

$$\max_{\theta_F} \quad J_F(\pi_{\theta_F}; \bar{\pi}_L) - \lambda \mathcal{R}_{\mathrm{sens}}(\theta_F). \tag{16}$$

λ はタスク性能の維持とロバスト性のトレードオフを定める．内側の最大化は有限回の勾配上昇で近似し，外側の θ_F の更新は既存の方策学習則に正則化項の勾配を加えて行う（Algorithm 1）．

[*1] この上界は摂動の生成過程に依存せず，式 (4) 内のランダムノイズにも成り立つ．

Algorithm 1 Follower Regularization against Leader-Side Adversarial Perturbations (FLAP)

Input: 固定 Leader π_{θ_L}，初期 Follower パラメータ θ_F，学習時 Leader 出力摂動半径 ε_a
最終重み λ，立ち上げ update 数 T_{warm}，総 update 数 T
内側最大化ステップ数 K，ステップ幅 η
Output: 学習後の Follower パラメータ θ_F

for $t = 1$ **to** T **do**
  学習データから (s_F, s_L) を取得し，$a_L \sim \pi_{\theta_L}(\cdot \mid s_L)$ を得る
  $\lambda_t \leftarrow \lambda \cdot \min(t/T_{\mathrm{warm}}, 1)$
  $a'_L \leftarrow$ 近傍 $\{a'_L : d_A(a_L, a'_L) \le \varepsilon_a\}$ 内でランダム初期化
  for $k = 1$ **to** K **do**
    $a'_L \leftarrow \Pi_{d_A(a_L,\cdot)\le\varepsilon_a}\big(a'_L + \eta \nabla_{a'_L} D_F(s_F; a_L, a'_L)\big)$
  end for
  $\mathcal{R}_{\mathrm{sens}} \leftarrow D_F(s_F; a_L, a'_L)$ ▷ D_F は式 (14)
  $J_F - \lambda_t \mathcal{R}_{\mathrm{sens}}$ の勾配上昇で θ_F を更新
end for
return θ_F

理論とアルゴリズムの適用範囲． 定理 1 は，仮定した Lipschitz 条件を満たす HRL システムに適用できる．系 1 は，これに加えて報酬が有界であることを仮定する．Algorithm 1 は，Leader 出力が連続であり，Follower の応答について微分可能な差異または代理量を利用でき，Leader を推論のために問い合わせながら Follower の目的関数を最適化できる場合に適用できる．

HIQL への具体化． FLAP は，上記の条件を満たす任意の HRL 手法に適用できる．具体例として，§3 で述べた HRL をオフライン設定で実現する手法である HIQL[5] に適用する．HIQL では，Leader 出力 a_L は，一定ステップ先に到達すべき状態の低次元な潜在表現 z であり，Follower は自身の観測と z から環境への行動を出力する．両方策はいずれもオフラインデータから学習される．そこで，式 (15) の a_L を z とする．HIQL の Follower は評価時に平均行動を実行するため，TV 距離の代理量には方策分布の平均行動間の二乗誤差を用いる．J_F には HIQL 標準の Follower の学習目的を変更せず用いる．Follower は s_F と Leader 出力 a_L の両方を入力とするため，a_L への応答を抑えると，s_F への相対的な依存が強まる可能性がある．FLAP は，この均衡がどのように変化するかを明示的には制御しない．そこで，防御後の方策について，Leader 出力がタスクに関する情報を持たない場合の振る舞いと，成功率を大幅に低下させずに許容できる Leader 出力の変化の大きさを調べる．実装の詳細は付録 A.2 に示す．

7. Experiments

本節では，3 環境を用いて次の 2 点を調べる．(i) FLAP-HIQL は無攻撃時の性能を維持しながら攻撃下の性能を改善するか．(ii) 防御学習後の Follower に生じたどのような変化が，環境間の効果の差と関連するか．

© 2026 Information Processing Society of Japan

7.1 実験設定

環境と比較対象． 評価対象の問題として，Lander[*2]と，OGBench[27] の PointMaze および AntMaze を用いる．Lander は宇宙船を目標地点へ軟着陸させる問題である．PointMaze と AntMaze は，それぞれ質点と四脚ロボットを二次元迷路内でゴールまで移動させる問題である．3 環境それぞれについて，4 種の攻撃ごとに攻撃強度を変えながら，baseline と FLAP-HIQL の成功率を比較する．攻撃を受ける Leader を凍結する本研究の脅威モデルに適用できる既存防御はないため（§2, §4），防御なしの baseline とのみ比較する．10 seed それぞれで HIQL[5] を 300k update 学習したモデルを baseline とする．各 seed の FLAP-HIQL では，対応する baseline のエンコーダ・価値関数・Leader を凍結し，ランダム初期化した Follower を 300k update 再学習した（学習曲線は付録 A.4）．

攻撃． 攻撃強度を表すパラメータを $\rho \geq 0$ とし，学習データにおける Leader 観測の次元別標準偏差 σ_i を用いて，各次元の攻撃強度の上限を $c_i = \rho\sigma_i$ とする．攻撃者は毎ステップ，摂動後の観測 s'_L を $B_{\boldsymbol{c}}(s_L)$ から選ぶ．評価する攻撃は次の 4 種である．gaussian は攻撃強度の上限内のランダムノイズであり，§4 の非敵対的摂動にあたる．残る 3 種は敵対的摂動であり，pgd_output は Leader 出力 z の変位，pgd_value は凍結した価値関数の低下，pgd_action は Follower の行動変化を，それぞれ最大化するように PGD で摂動を最適化する．pgd_action は，評価対象の Follower に対して最適化される適応的攻撃である．PGD の設定は付録 A.3 に示す．

指標と学習設定． 各 seed の baseline と FLAP-HIQL は，同じ 20 episodes を用いて評価する．成功率は，各 seed の 20 episodes における成功割合を 10 seed で平均した値である．評価中は毎ステップ Leader 出力と攻撃を再計算する．FLAP-HIQL の学習時摂動半径 ε_z（式 (15) の ε_a を z 空間に取ったもの）と重み λ は環境ごとに設定し，値は付録 A.3，λ に対する感度は付録 A.8 に示す．

7.2 FLAP-HIQL による防御は有効か

理論解析に基づき，3 環境，4 攻撃，複数の攻撃強度にわたって baseline と FLAP-HIQL を比較する．**図 1** に，3 環境（行）と 4 攻撃（列）の結果を示す．4 攻撃の詳細は付録 A.3 に示す．各パネルでは，横軸を攻撃強度 ρ，縦軸を成功率とし，灰色線が baseline（防御学習前の学習済み方策），青線が FLAP-HIQL を表す．無攻撃時には，FLAP-HIQL は 3 環境すべてで成功率をほぼ維持する．Lander では，適応的攻撃 `pgd_action` を含むすべての攻撃とすべての強度で，FLAP-HIQL が baseline より高い成功率を達成する．PointMaze では，baseline の成功率を 0 にするほど強い攻撃では FLAP-HIQL も失敗するものの，大半の攻撃条件で baseline より高い成功率を達成する．AntMaze では，ほぼすべての条件で FLAP-HIQL の成功率は baseline と同程度にとどまる．以上より，防御は Lander では有効，PointMaze では部分的に有効であり，AntMaze では baseline と同等であるとわかる．

[*2] MO-Gymnasium[26] の `mo-lunar-lander-continuous-v3` を用いる．この環境は着陸成功や燃料消費などを別々の報酬として返すため，固定した重みによる加重和を報酬とし，この報酬で学習した方策で軌跡を収集して独自のオフラインデータセットを作成した．詳細は付録 A.3 に示す．

表 1 Leader 出力置換時の成功率（平均 ± 標準偏差，$n = 10$）．
Table 1 Success rates under leader-output replacement (mean ± standard deviation, $n = 10$).

環境	条件	baseline	FLAP-HIQL
Lander	real	0.910±0.070	0.915±0.067
	zero	0.360±0.161	0.745±0.117
	random-step	0.060±0.077	0.530±0.225
	random-fixed	0.065±0.053	0.450±0.183
PointMaze	real	0.885±0.075	0.935±0.058
	zero	0.000±0.000	0.000±0.000
	random-step	0.000±0.000	0.000±0.000
	random-fixed	0.000±0.000	0.000±0.000
AntMaze	real	0.925±0.049	0.955±0.037
	zero	0.040±0.057	0.010±0.021
	random-step	0.000±0.000	0.000±0.000
	random-fixed	0.000±0.000	0.005±0.016

7.3 事後解析：防御学習後の Follower の変化

環境間の効果の差を説明するため，防御が Lander で有効な理由と，PointMaze では部分的に有効である一方 AntMaze では有効でない理由という，二つの問いを調べる．

Lander で防御が有効なのはなぜか． Lander では着陸地点が固定されており，Follower 観測 s_F は，着陸地点に対する機体の相対的な位置と速度を含む．そのため，効率は低下するものの，Follower 観測だけからタスクを達成できる．FLAP は，Leader 出力がわずかに変化しても Follower の行動があまり変化しないように Follower を学習する（§6）．したがって，正則化は Leader 出力の影響を弱め，Follower に自身の観測の利用を促すよう作用する．この効果が実現していれば，Leader 出力がタスクに関する情報を持たなくても，FLAP-HIQL の Follower は s_F だけからタスクを達成できると期待される．以下，これをフォールバックと呼ぶ．検証のため，評価時に Leader 出力を置換して成功率を測定する．Leader 出力を変更せずに用いる *real*，ゼロベクトルへ置換する *zero*，タスクと状態に依存しないランダム出力へ毎ステップ置換する *random-step*，およびそのような一つのランダム出力をエピソード全体で用いる *random-fixed* の 4 条件を比較する（付録 A.6）．Follower 観測 s_F はすべての条件で変更しない．**表 1** に，3 環境の各条件における baseline と FLAP-HIQL の成功率を示す．

Lander では，baseline は成功率の大半を失う一方，FLAP-HIQL は低下しつつも，すべての置換条件で成功率を維

© 2026 Information Processing Society of Japan

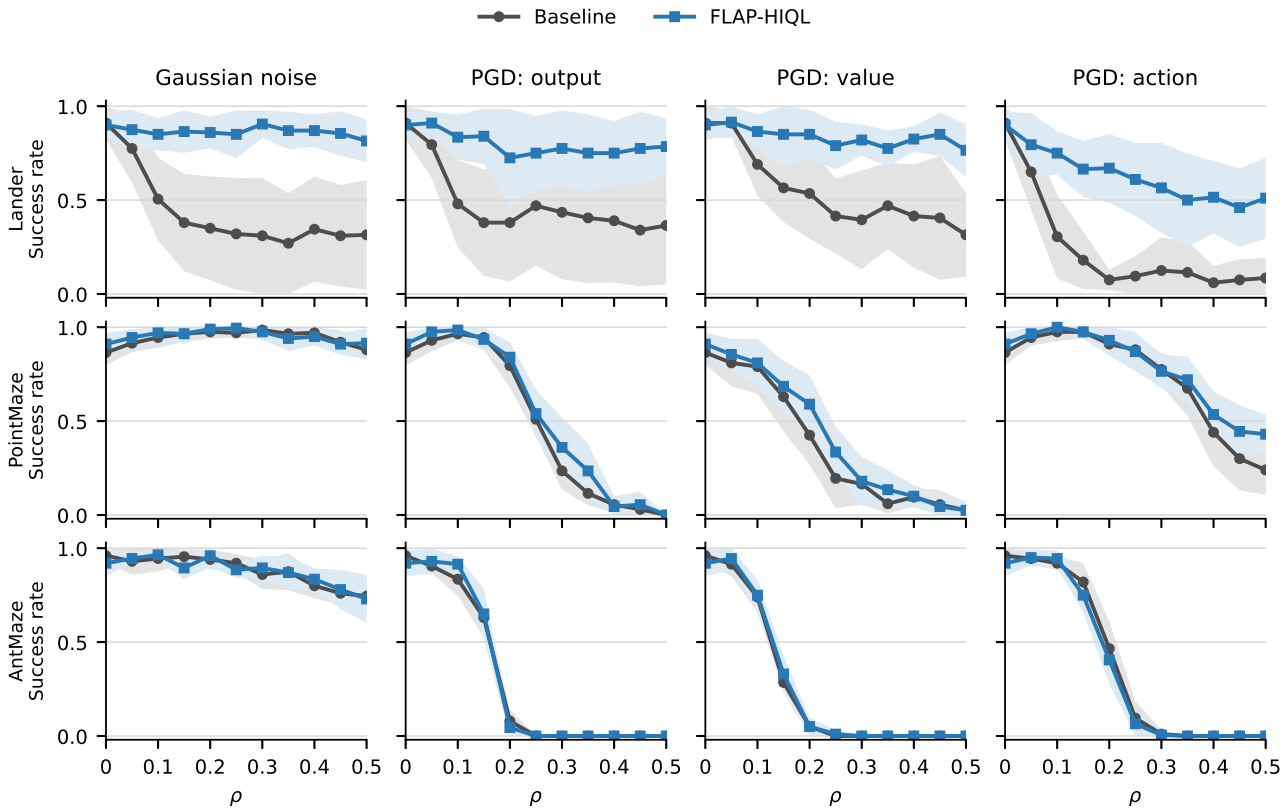


図 1 3 環境（行）× 4 攻撃（列）の成功率．横軸は攻撃強度 ρ，灰色線は baseline，青線は FLAP-HIQL，帯は seed 間標準偏差（$n = 10$）を表す．

Fig. 1 Success rates for the three environments (rows) and four attacks (columns). The horizontal axis is the attack strength ρ; gray and blue denote the baseline and FLAP-HIQL, respectively; the shaded bands represent the standard deviation across seeds ($n = 10$).

持する．PointMaze と AntMaze では，いずれの置換条件でも両 Follower とも成功率を維持できない．この結果は，Lander ではタスクの性質上フォールバックが可能であり，FLAP-HIQL の Follower がフォールバックを獲得することで，攻撃下でも成功率を維持することを示している．PointMaze と AntMaze では，ゴールとそこへの経路が Leader 出力だけを通じて伝えられる．そのため，この 2 タスクは Follower 観測だけでは達成できない．したがって，これらのタスクではフォールバックではなく，Leader 観測への摂動に対して統合方策をロバストにすることで防御する必要がある．

PointMaze と AntMaze で効果の差が生じるのはなぜか． PointMaze と AntMaze はいずれもフォールバックできないが，防御は PointMaze では部分的に有効であり，AntMaze では有効でない（§7.2）．この理由を調べるため，baseline と FLAP-HIQL で得られた方策について，Leader 出力の変化がタスク成功率へ与える影響を評価する．具体的には，タスク成功率を元の値の 90% まで低下させる Leader 出力変化の大きさを，baseline と FLAP-HIQL のそれぞれについて $\bar{r}_{\mathrm{tol}}^{\mathrm{base}}$ と $\bar{r}_{\mathrm{tol}}^{\mathrm{def}}$ として評価する．計測手順は付録 A.5 に示す．FLAP-HIQL による防御が有効なら，$W = \bar{r}_{\mathrm{tol}}^{\mathrm{def}} - \bar{r}_{\mathrm{tol}}^{\mathrm{base}}$ は 0 より大きくなるはずである．**表 2** に，3 タスク間の W の比較を示す．防御が有効な Lander と PointMaze では W が正であり，これらのタスクでは FLAP によってロバスト性が実際に改善したことが示唆される．一方，FLAP による防御が有効でない AntMaze では W が負である．タスク構造の違いや学習不足など，複数の理由が考えられ，その特定は今後の課題である．

限界． ただし，W と出力置換の実験はいずれも防御学習

表 2 価値低下方向の許容距離（平均 ± 標準偏差，$n = 10$）．付録 A.5 で定義する余弦距離で計測し，差を $W = \bar{r}_{\mathrm{tol}}^{\mathrm{def}} - \bar{r}_{\mathrm{tol}}^{\mathrm{base}}$ とする．

Table 2 Tolerance distances in the value-decreasing direction (mean ± standard deviation, $n = 10$), measured as the cosine distance defined in the appendix, and their difference $W = \bar{r}_{\mathrm{tol}}^{\mathrm{def}} - \bar{r}_{\mathrm{tol}}^{\mathrm{base}}$.

環境	$\bar{r}_{\mathrm{tol}}^{\mathrm{base}}$	$\bar{r}_{\mathrm{tol}}^{\mathrm{def}}$	W
Lander	0.122±0.095	0.547±0.353	+0.425
PointMaze	0.009±0.003	0.046±0.018	+0.037
AntMaze	0.322±0.151	0.275±0.102	−0.047

© 2026 Information Processing Society of Japan

後の方策に対する測定である．したがって，本研究の事後解析は，防御後方策の変化を特徴づけるが，その変化が生じる理由を確立するものではない．baseline 方策だけから防御の効果を予測できるかは，未解決の課題である．

また，実験は HIQL，3 環境，Leader 観測のみへの攻撃に限られる．理論解析は，仮定した Lipschitz 条件と報酬有界性の下で，連続な Leader 出力をもつ HRL に適用されるため，FLAP は連続な Leader 出力をもつ他の HRL 手法にも拡張できる可能性があるが，検証が必要である．また，理論解析はすべての状態と Leader 出力に対する一様な Lipschitz 条件を仮定する．FLAP の局所的かつデータ依存の PGD 正則化が，この大域的な仮定をどの程度満たすかは明らかでない．最後に，Leader と Follower の双方の観測が攻撃される場合への拡張を今後の課題とする．

8. Conclusion

Leader 観測への摂動が連続な Leader 出力を介して Follower の行動へ伝播する HRL の設定に対し，FLAP を提案した．本研究の解析では，生じる価値劣化を，摂動の大きさ，観測に対する Leader の出力感度，および Leader 出力に対する Follower の行動感度の積で上界した．したがって，Follower の感度を小さくすることで，Leader を変更せずに上界を縮小できる．HIQL を用いた 3 環境の実験では，FLAP-HIQL は，Lander では評価したすべての攻撃条件で，PointMaze では大半の条件で，平均成功率を防御なし baseline より改善した一方，AntMaze では一貫した改善が得られなかった．事後解析では，この環境間の差を，Leader 出力が有用な情報を持たないときに Follower が自身の観測へフォールバックできるか，および防御後の Follower が baseline より大きな Leader 出力の変化に耐えられるか，という二つの性質に関連づけた．

謝辞 本研究は JST Nexus JPMJNX25C2, JST K-program JPMJKP24C3, JST CREST JPMJCR21D3, JPMJCR23M4, JSPS Grants-in-Aid for Scientific Research 23H00483, JSPS 二国間 120251002 の支援を受けたものである．

参考文献

[1] Shubham Pateria, et al. Hierarchical reinforcement learning: A comprehensive survey. *ACM Computing Surveys*, Vol. 54, No. 5, pp. 109:1–109:35, 2022.
[2] Alexander Sasha Vezhnevets, et al. FeUdal networks for hierarchical reinforcement learning. In *ICML*, 2017.
[3] Ofir Nachum, et al. Data-efficient hierarchical reinforcement learning. In *NeurIPS*, 2018.
[4] Andrew Levy, et al. Learning multi-level hierarchies with hindsight. In *ICLR*, 2019.
[5] Seohong Park, et al. HIQL: Offline goal-conditioned RL with latent states as actions. In *NeurIPS*, 2023.
[6] Huan Zhang, et al. Robust deep reinforcement learning against adversarial perturbations on state observations. In *NeurIPS*, 2020.
[7] Huan Zhang, et al. Robust reinforcement learning on state observations with learned optimal adversary. In *ICLR*, 2021.
[8] Alexander Bukharin, et al. Robust multi-agent reinforcement learning via adversarial regularization: Theoretical foundation and stable algorithms. In *NeurIPS*, 2023.
[9] Donald Hejna, et al. Hierarchically decoupled imitation for morphological transfer. In *ICML*, 2020.
[10] Sammy Christen, et al. Learning functionally decomposed hierarchies for continuous control tasks with path planning. *IEEE Robotics and Automation Letters*, Vol. 6, No. 2, pp. 3623–3630, 2021.
[11] Arnaud Robert, et al. Sample complexity of goal-conditioned hierarchical reinforcement learning. In *NeurIPS*, 2023.
[12] Maximilian Igl, et al. Deep variational reinforcement learning for POMDPs. In *ICML*, 2018.
[13] Misha Laskin, et al. Reinforcement learning with augmented data. In *NeurIPS*, 2020.
[14] Yanchao Sun, et al. Who is the strongest enemy? Towards optimal and efficient evasion attacks in deep RL. In *ICLR*, 2022.
[15] Xinghua Qu, et al. Adversary agnostic robust deep reinforcement learning. *IEEE Transactions on Neural Networks and Learning Systems*, Vol. 34, No. 9, pp. 6146–6157, 2023.
[16] Yongyuan Liang, et al. Efficient adversarial training without attacking: Worst-case-aware robust reinforcement learning. In *NeurIPS*, 2022.
[17] Yongyuan Liang, et al. Game-theoretic robust reinforcement learning handles temporally-coupled perturbations. In *ICLR*, 2024.
[18] Qianli Shen, et al. Deep reinforcement learning with robust and smooth policy. In *ICML*, 2020.
[19] Buqing Nie, et al. Improve robustness of reinforcement learning against observation perturbations via l_∞ Lipschitz policy networks. In *AAAI*, 2024.
[20] Aounon Kumar, et al. Policy smoothing for provably robust reinforcement learning. In *ICLR*, 2022.
[21] Fan Wu, et al. CROP: Certifying robust policies for reinforcement learning through functional smoothing. In *ICLR*, 2022.
[22] Jaebak Hwang, et al. Strict subgoal execution: Reliable long-horizon planning in hierarchical reinforcement learning. In *ICLR*, 2026.
[23] Vivienne Huiling Wang, et al. State-conditioned adversarial subgoal generation. In *AAAI*, 2023.
[24] Vivienne Huiling Wang, et al. Probabilistic subgoal representations for hierarchical reinforcement learning. In *ICML*, 2024.
[25] Vivienne Huiling Wang, et al. Hierarchical reinforcement learning with uncertainty-guided diffusional subgoals. In *ICML*, 2025.
[26] Florian Felten, et al. A toolkit for reliable benchmarking and research in multi-objective reinforcement learning. In *NeurIPS*, 2023.
[27] Seohong Park, et al. OGBench: Benchmarking offline goal-conditioned RL. In *ICLR*, 2025.
[28] Mark Towers, et al. Gymnasium: A standard interface for reinforcement learning environments. In *NeurIPS Datasets and Benchmarks*, 2025.
[29] Tuomas Haarnoja, et al. Soft actor-critic: Off-policy maximum entropy deep reinforcement learning with a stochastic actor. In *ICML*, 2018.

© 2026 Information Processing Society of Japan

付　　録

A.1　統合方策の L_1-Lipschitz 性の証明

本付録では，定理 1 の証明を与える．距離の定義は本文に従う．確率分布 μ,ν に対して $\|\mu-\nu\|_1 = 2D_{\mathrm{TV}}(\mu,\nu)$ が成り立つため，三角不等式で分けた各項を総変動距離で評価し，最後に L_1 距離に変換する．

Proof. 任意の (s_L, s_F) および (s'_L, s'_F) を取る．L_1 距離の三角不等式より

$$\begin{aligned}\|\pi(\cdot \mid s_L, s_F) - \pi(\cdot \mid s'_L, s'_F)\|_1 \\ \le \|\pi(\cdot \mid s_L, s_F) - \pi(\cdot \mid s'_L, s_F)\|_1 \\ + \|\pi(\cdot \mid s'_L, s_F) - \pi(\cdot \mid s'_L, s'_F)\|_1 \end{aligned} \tag{A.1}$$

が成り立つ．以下，右辺の二項を順に評価する．

Leader 観測の摂動による影響． Follower 観測 s_F を固定し，

$$\pi(\cdot \mid s_L, s_F) = \int_{\mathcal{A}_L} \pi_F(\cdot \mid s_F, a)\, \pi_L(da \mid s_L),$$
$$\pi(\cdot \mid s'_L, s_F) = \int_{\mathcal{A}_L} \pi_F(\cdot \mid s_F, a')\, \pi_L(da' \mid s'_L)$$

を考える．$\pi_L(\cdot \mid s_L)$ と $\pi_L(\cdot \mid s'_L)$ の任意のカップリング $\kappa \in \Gamma(\pi_L(\cdot \mid s_L), \pi_L(\cdot \mid s'_L))$ に対し，総変動距離の凸性より

$$\begin{aligned}D_{\mathrm{TV}}\big(\pi(\cdot \mid s_L, s_F), \pi(\cdot \mid s'_L, s_F)\big) \\ \le \int D_{\mathrm{TV}}\big(\pi_F(\cdot \mid s_F, a), \\ \pi_F(\cdot \mid s_F, a')\big)\, d\kappa(a, a').\end{aligned} \tag{A.2}$$

Follower 方策の仮定 (10) は，$\|\mu-\nu\|_1 = 2D_{\mathrm{TV}}(\mu,\nu)$ より

$$D_{\mathrm{TV}}\big(\pi_F(\cdot \mid s_F, a), \pi_F(\cdot \mid s_F, a')\big) \le L^{(a)}_{\pi_F}\, d_A(a, a')$$

と同値であるため，

$$\begin{aligned}D_{\mathrm{TV}}\big(\pi(\cdot \mid s_L, s_F), \pi(\cdot \mid s'_L, s_F)\big) \\ \le L^{(a)}_{\pi_F} \int d_A(a, a')\, d\kappa(a, a').\end{aligned}$$

右辺のカップリングに関する下限を取ることで

$$\begin{aligned}D_{\mathrm{TV}}\big(\pi(\cdot \mid s_L, s_F), \pi(\cdot \mid s'_L, s_F)\big) \\ \le L^{(a)}_{\pi_F} W_1\big(\pi_L(\cdot \mid s_L), \pi_L(\cdot \mid s'_L)\big).\end{aligned}$$

さらに Leader 方策の Lipschitz 仮定 (9) より

$$\begin{aligned}D_{\mathrm{TV}}\big(\pi(\cdot \mid s_L, s_F), \pi(\cdot \mid s'_L, s_F)\big) \\ \le L^{(a)}_{\pi_F} L^{(W)}_{\pi_L} d_L(s_L, s'_L).\end{aligned} \tag{A.3}$$

Follower 観測の摂動による影響． 次に Leader 観測 s'_L を固定する．Follower 方策の仮定 (11) より，任意の a に対して

$$\begin{aligned}D_{\mathrm{TV}}\big(\pi_F(\cdot \mid s_F, a), \pi_F(\cdot \mid s'_F, a)\big) \\ \le L^{(s)}_{\pi_F} \|s_F - s'_F\|_\infty\end{aligned}$$

が成り立つ．これを $\pi_L(\cdot \mid s'_L)$ に関して積分することで

$$\begin{aligned}D_{\mathrm{TV}}\big(\pi(\cdot \mid s'_L, s_F), \pi(\cdot \mid s'_L, s'_F)\big) \\ \le L^{(s)}_{\pi_F} \|s_F - s'_F\|_\infty.\end{aligned} \tag{A.4}$$

結合． 式 (A.1) に式 (A.3) および式 (A.4) を代入し，再び $\|\mu-\nu\|_1 = 2D_{\mathrm{TV}}(\mu,\nu)$ を用いて L_1 距離へ戻すことで

$$\begin{aligned}\|\pi(\cdot \mid s_L, s_F) - \pi(\cdot \mid s'_L, s'_F)\|_1 \\ \le 2\Big(L^{(a)}_{\pi_F} L^{(W)}_{\pi_L} d_L(s_L, s'_L) + L^{(s)}_{\pi_F} \|s_F - s'_F\|_\infty\Big)\end{aligned}$$

が得られ，主張が従う． □

A.2　FLAP-HIQL の擬似コード

Algorithm 2 に，Algorithm 1 の HIQL への具体化を示す．データセット中の目標状態 g から $z = \phi(g)$ を得るため，学習中の Leader 推論は不要である．球面上に正規化された z に対し，防御学習では z を中心とする L2 球内で摂動後の点 $\tilde{z}$ を探索し，$\tilde{z}$ は再正規化しない．これは，Leader が生成しうる球面上の出力とその近傍を含む，より広い集合での平滑化に相当する．

HIQL は平均行動を実行するため，TV 距離の代理に平均行動間の二乗誤差を用いる．学習時の Follower は，共分散が入力によらず単位行列である Gaussian 方策であり，二つの Leader 出力に対する平均行動をそれぞれ μ, μ' とすると

$$D_{\mathrm{KL}}(\mathcal{N}(\mu, I) \,\|\, \mathcal{N}(\mu', I)) = \frac{1}{2}\|\mu - \mu'\|_2^2 \tag{A.5}$$

となるため，この二乗誤差の抑制は Pinsker の不等式を介して TV 距離の上界も抑える．凍結したエンコーダと価値関数のもと，ランダム初期化した Follower を，データセット上の advantage-weighted regression（AWR）と正則化項で再学習する．

A.3　実装・評価設定の詳細

環境とデータセット． Lander には, Gymnasium[28] の LunarLanderContinuous を MO-Gymnasium[26] で拡張した mo-lunar-lander-continuous-v3 を用いる．多次元報酬を固定重みでスカラー化した報酬で SAC[29] を学習し，その方策で軌跡を収集して独自データセットを作成した．OGBench 系 2 環境には pointmaze-medium-navigate と antmaze-medium-navigate を用いる．成功判定は，OGBench 系 2 環境ではゴール到達（報酬はこれに対応するスパース報酬），Lander では着陸成功とする．

防御のハイパーパラメータ． (ε_z, λ) は Lander

© 2026 Information Processing Society of Japan

Algorithm 2 Follower Regularization against Leader-Side Adversarial Perturbations for HIQL (FLAP-HIQL)

Input: 凍結エンコーダ ϕ，凍結価値関数 V，データセット $\mathcal{D}$
学習時 Leader 出力摂動半径 ε_z，最終重み λ
立ち上げ update 数 T_{warm}，総 update 数 T
PGD ステップ数 K，ステップ幅 $\eta = 2\varepsilon_z/K$
Output: 再学習された Follower パラメータ θ_F

θ_F をランダム初期化する（既存 Follower のパラメータは流用しない）
for $t = 1$ **to** T **do**
  $\mathcal{D}$ からミニバッチ (s_F, g, a_F) を取得し，$z \leftarrow \phi(g)$ とする（g は目標状態）
  $D_\mu(u, v) \leftarrow \|\mu_{\theta_F}(s_F, u) - \mu_{\theta_F}(s_F, v)\|_2^2$
  $\lambda_t \leftarrow \lambda \cdot \min(t/T_{\text{warm}}, 1)$ ▷ 重みの線形立ち上げと保持
  $\tilde{z} \leftarrow z + \delta$, $\delta \sim \text{Unif}(\{\|\delta\|_2 \le \varepsilon_z\})$ ▷ 近傍内ランダム初期化
  for $k = 1$ **to** K **do** ▷ 内側最大化（敵対方向の探索）
    $\tilde{z} \leftarrow \Pi_{\|\tilde{z}-z\|_2 \le \varepsilon_z}\left(\tilde{z} + \eta \nabla_{\tilde{z}} D_\mu(\tilde{z}, z)\right)$
  end for
  $\mathcal{R}_{\text{sens}} \leftarrow D_\mu(\tilde{z}, z)$ ▷ Follower の行動出力差，z 側は定数扱い
  $\mathcal{L}_{\text{AWR}} \leftarrow$ HIQL の AWR 損失（式 (16) の J_F の実装）
  θ_F を $\mathcal{L}_{\text{AWR}} + \lambda_t \mathcal{R}_{\text{sens}}$ の勾配降下で更新
end for
return θ_F

で $(0.25, 3.0)$，PointMaze で $(0.75, 0.3)$，AntMaze で $(0.10, 0.3)$ とし，全環境で $T = 300\text{k}$，$T_{\text{warm}} = 100\text{k}$，$K = 10$ とした．Lander と AntMaze では，ε_z を固定して λ だけを変えた比較（付録 A.8）から λ を，PointMaze では $\lambda \in \{0.3, 1, 3, 10\}$ と $\varepsilon_z \in \{0.25, 0.50, 0.75, 1.00\}$ の 2 次元探索から (λ, ε_z) を，clean と攻撃下の成功率に基づいて選定した．ε_z は z 空間の学習時摂動半径であり，攻撃強度 ρ とは異なる．

評価設定． 攻撃強度は ρ を 0.05 から 0.50 まで 0.05 刻みとした．再学習途中の性能は付録 A.4 に示す．

攻撃の詳細． 各 run の学習データから次元別標準偏差 σ_i を求め，各次元の攻撃強度の上限を $c_i = \rho\sigma_i$ とする．PGD 系 3 攻撃（pgd_output, pgd_value, pgd_action）は 10 step の PGD であり，ステップ幅は各次元 $0.25\,c_i$，box 制約 $|\delta_i| \le c_i$ 内で一様ランダムに初期化し，各 step で box へ射影する．攻撃者は各時刻の Leader 観測 $s_{L,t}$ に対して摂動を独立に選び直す．gaussian の摂動は，各次元で $\mathcal{N}(0, c_i^2)$ からノイズを生成し，box 制約 $|\delta_i| \le c_i$ へ射影して得る．

A.4 Follower 再学習の学習曲線

この付録では，Follower の再学習の途中経過から，本文で用いた 300k update までに学習が収束していること，および PointMaze では防御効果が再学習の早い段階から現れ，AntMaze での不成立が学習不足では説明できないこと，の 2 点を確認する．再学習中の checkpoint を 50k update ごとに評価した（**図 A·1**）．横軸は固定データセット上の勾配

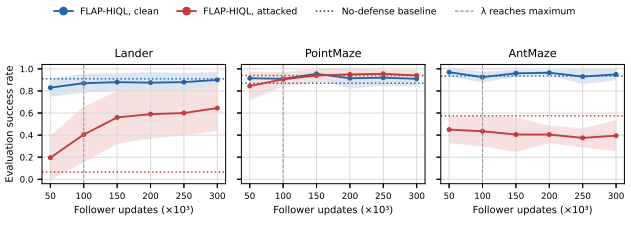


図 A·1 FLAP-HIQL の Follower 再学習中の成功率（平均 ± 標準偏差，$n = 10$）．青は clean，赤は適応的 pgd_action（$\rho = 0.2$），点線は防御なしの baseline．

Fig. A·1 Success rates during Follower retraining with FLAP-HIQL (mean ± standard deviation, $n = 10$). Blue and red denote clean evaluation and adaptive pgd_action ($\rho = 0.2$), respectively; dotted lines denote the no-defense baseline.

update 数であり，防御なしの baseline の成功率を水平線で示す（baseline は再学習しないため一定である）．第一に，攻撃を加えない評価（図中 clean）は 100k update 前後までに，攻撃下の評価も 250k update までに概ね安定しており，300k update 時点の比較は収束後の性能どうしの比較といえる．第二に，PointMaze では pgd_action（$\rho = 0.2$）に対する成功率が 50k update の時点で既に baseline を上回っており，少なくともこの環境では防御効果は再学習の早い段階から現れる．一方，AntMaze の攻撃下の成功率は再学習を続けても低い水準で頭打ちであり，AntMaze で防御が効かないことは再学習の不足では説明できない．なお，ランダム初期化直後の checkpoint は保存していないため描いていない．本図の評価は本文とは別に行ったため，300k 点の値は本文とわずかに異なりうる．

A.5 許容距離 $\bar{r}_{\text{tol}}$ の計測手順

許容距離は環境ごとに，baseline と FLAP-HIQL の各 seed について計測する（seed あたり 20 episodes）．各ステップで，無変位時の z から余弦距離が u となる球面上の点のうち，凍結した価値関数を最も下げる方向を求め，z を球面上でこの方向へ，余弦距離がちょうど u となる点まで回転させる．この方向は，価値関数の z についての負の勾配の，z に直交する成分を初期値とし，回転先の z で勾配を再評価して接方向へ射影し直す反復（4 回）で求める．z 空間内の探索で得られる方向であるため，Leader 観測への攻撃では到達できない方向を含みうる．したがって，この方向での許容距離 $\bar{r}_{\text{tol}}$ は悲観的な評価である．余弦距離は $u_{\max} = 1.5$ を上限とし，$\bar{r}_{\text{tol}}$ は成功率が無変位時の成功率の 90% を初めて下回る区間の線形補間で求める．評価中は Follower 観測 s_F に摂動を加えず，z だけをこの方向へ動かす．

© 2026 Information Processing Society of Japan

表 A·1 Leader 出力置換時の成功率（平均 ± 標準偏差，$n = 10$, seed あたり 20 episodes）．条件の定義は本文および本付録に示す．

Table A·1 Success rates under leader-output replacement (mean ± standard deviation, $n = 10$, 20 episodes per seed); conditions are defined in the text and this appendix.

環境	条件	baseline	FLAP-HIQL
Lander	real	0.910±0.070	0.915±0.067
	zero	0.360±0.161	0.745±0.117
	random-step	0.060±0.077	0.530±0.225
	random-fixed	0.065±0.053	0.450±0.183
PointMaze	real	0.885±0.075	0.935±0.058
	zero	0.000±0.000	0.000±0.000
	random-step	0.000±0.000	0.000±0.000
	random-fixed	0.000±0.000	0.000±0.000
AntMaze	real	0.925±0.049	0.955±0.037
	zero	0.040±0.057	0.010±0.021
	random-step	0.000±0.000	0.000±0.000
	random-fixed	0.000±0.000	0.005±0.016

A.6 Leader 出力の置換によるフォールバック確認

本文で用いた Leader 出力置換実験の条件と全結果を **表 A·1** に再掲する．zero は Leader 出力を常にゼロベクトルへ置き換える条件であり，他の条件の定義は §7.3 と同じである．Follower 観測 s_F は変更していない．Lander では，zero だけでなく random-step と random-fixed でも FLAP-HIQL が baseline を上回っており（0.530/0.450 対 0.060/0.065），フォールバックが特定の置換方法に固有の現象ではないことと整合する．

A.7 正則化なし再学習との比較

$\lambda = 0$ とし，それ以外を FLAP-HIQL と一致させた再学習対照を Lander と PointMaze で評価した（**表 A·2**）．baseline と FLAP-HIQL は本文と同じ評価の値であり，$\lambda = 0$ は本文とは別に評価した．攻撃下で一貫した改善がないことから，採用設定の改善は再学習だけでは説明できず，Leader 出力に対する入力感度の正則化に依存する．

A.8 正則化係数 λ の感度

ε_z を環境ごとに固定し，λ だけを変えたときの成功率を **表 A·3** に示す．Lander は $\lambda \geq 3$ で攻撃下の成功率が高まるが，$\lambda = 100$ では clean が低下する．PointMaze は $\varepsilon_z = 0.50$ の下では λ による差が小さく，採用設定 $(\lambda, \varepsilon_z) = (0.3, 0.75)$ は付録 A.3 に示した 2 次元探索から選定した．

表 A·2 正則化なし再学習との比較（平均 ± 標準偏差，$n = 10$）．攻撃下の行は，各 seed における 4 種類の摂動条件の成功率を平均し，その値を seed 間で集計した結果を示す．

Table A·2 Comparison with retraining without regularization (mean ± standard deviation, $n = 10$). In each attacked row, success rates are averaged across the four perturbation conditions within each seed and then aggregated across seeds.

条件	baseline	λ=0	FLAP-HIQL
Lander			
clean	0.910±0.088	0.895±0.090	0.900±0.071
ρ=0.05	0.782±0.130	0.515±0.154	0.874±0.086
ρ=0.10	0.495±0.162	0.256±0.115	0.825±0.081
ρ=0.15	0.376±0.177	0.185±0.103	0.805±0.094
ρ=0.20	0.335±0.172	0.106±0.054	0.776±0.109
ρ=0.25	0.325±0.180	0.089±0.045	0.750±0.092
ρ=0.30	0.316±0.180	0.086±0.050	0.766±0.112
ρ=0.35	0.315±0.176	0.079±0.066	0.724±0.123
ρ=0.40	0.302±0.180	0.058±0.058	0.740±0.100
ρ=0.45	0.283±0.204	0.055±0.049	0.735±0.119
ρ=0.50	0.270±0.183	0.048±0.043	0.719±0.114
PointMaze			
clean	0.865±0.067	0.795±0.090	0.910±0.061
ρ=0.05	0.900±0.055	0.890±0.052	0.935±0.030
ρ=0.10	0.919±0.044	0.882±0.047	0.941±0.026
ρ=0.15	0.879±0.055	0.851±0.045	0.890±0.048
ρ=0.20	0.776±0.068	0.734±0.057	0.838±0.035
ρ=0.25	0.639±0.062	0.610±0.061	0.685±0.070
ρ=0.30	0.540±0.058	0.489±0.048	0.570±0.063
ρ=0.35	0.454±0.045	0.419±0.068	0.508±0.073
ρ=0.40	0.390±0.058	0.339±0.068	0.408±0.041
ρ=0.45	0.326±0.064	0.296±0.067	0.364±0.064
ρ=0.50	0.286±0.039	0.258±0.057	0.342±0.036

表 A·3 λ の感度．各セルは clean / 4 攻撃中最小の成功率（ρ=0.25）．Lander/PointMaze は 1 seed，AntMaze は 3 seeds．PointMaze は $\varepsilon_z = 0.50$ 固定であり，最終採用設定は $(\lambda, \varepsilon_z) = (0.3, 0.75)$．

Table A·3 Sensitivity to λ. Each cell gives clean / minimum success rate across the four evaluated attacks ($\rho = 0.25$); Lander/PointMaze use one seed and AntMaze three seeds.

λ	Lander	PointMaze	AntMaze
0.3	0.90/0.00	0.85/0.25	0.95/0.00
1	0.85/0.15	0.90/0.20	0.98/0.00
3	0.95/0.85	0.90/0.30	0.93/0.00
10	0.95/0.65	0.85/0.25	0.93/0.00
30	0.95/0.80	0.75/0.30	0.93/0.00
100	0.80/0.75	0.75/0.35	0.95/0.00

© 2026 Information Processing Society of Japan