標的の物理環境に依存しないVision-Language-Actionモデルに対する特徴量誘導攻撃

川本 健太[1,a)]　西山 大輝[1]　山辺 翔ニ郎[1]　佐久間 淳[1]

概要：
Vision-Language-Action（VLA）モデルは, 視覚情報と言語指示を統合してロボットの行動を生成するモデルとして, 高い性能を示している．一方,VLA を実環境へ導入するためには, 敵対的攻撃に対する脆弱性を明らかにし, その安全性を評価する必要がある．既存の敵対的攻撃の多くは, 攻撃対象の通常実行時に得られる行動列やロボット固有の物理情報など, 攻撃者が実環境で取得することが困難な情報を必要とする．本研究では, 学習済み VLA モデルへのホワイトボックスアクセスを仮定し, 実行時の観測画像, 言語指示, およびモデルの中間特徴量のみを利用する特徴量誘導攻撃 (FSA) を提案する．FSA は, 攻撃対象とは異なる訓練時に利用されたタスクに対応する中間特徴量を誘導先として用い, 観測画像への摂動によって攻撃対象の内部表現を変化させる．これにより, ロボット固有の物理情報や通常実行時の行動列を用いない非標的型攻撃 (UFSA) を実現する．さらに, 同一の枠組みを, 訓練時に利用されたタスクへの行動誘導を目的とする攻撃 (PTFSA) へ拡張する．OpenVLA [3],π_0 [1], および SmolVLA [8] を LIBERO ベンチマーク上で評価した結果, 非標的型攻撃ではすべてのモデルに対して高い攻撃成功率を達成した．また, 拡張した攻撃では, すべての条件で安定した行動誘導には至らなかったものの, 一部のタスクにおいて生成行動が目標とするタスクの行動へ近づくことを確認した．

キーワード：Vision-Language-Action モデル，敵対的攻撃，特徴量誘導，ロボットセキュリティ

Feature Steering Attacks on Vision-Language-Action Models Without Target Physical Environment Information

Kenta Kawamoto[1,a)]　Daiki Nishiyama[1]　Shojiro Yamabe[1]　Jun Sakuma[1]

Abstract: Vision-Language-Action (VLA) models have demonstrated strong performance in generating robot actions by integrating visual information and language instructions. However, deploying VLA models in real-world environments requires identifying their vulnerabilities to adversarial attacks and evaluating their safety. Most existing adversarial attacks require information that is difficult for an attacker to obtain in practical settings, such as clean-run action sequences of the victim and robot-specific physical information. In this study, we assume white-box access to a pre-trained VLA model and propose the Feature Steering Attack (FSA), which uses only runtime observation images, language instructions, and intermediate features of the model. FSA uses intermediate features corresponding to a pre-trained task different from the victim task as the steering target and alters the internal representations associated with the victim task through perturbations applied to the observation images. This enables an Untargeted Feature Steering Attack (UFSA) that does not require robot-specific physical information or clean-run action sequences. Furthermore, we extend the same framework to a Pseudo-Targeted Feature Steering Attack (PTFSA), which aims to steer the generated actions toward a pre-trained task. Experimental evaluations of OpenVLA [3], π_0 [1], and SmolVLA [8] on the LIBERO benchmark showed that UFSA achieved high attack success rates against all models. Although PTFSA did not achieve stable action steering under all conditions, the generated actions approached those of the target task for several tasks.

Keywords: Vision-Language-Action models, adversarial attacks, feature steering, robot security

© 2026 Information Processing Society of Japan

This paper is work in progress and not peer-reviewed.

1. 導入

Vision-Language-Action（VLA）モデルは, 視覚情報と言語指示を統合し, ロボットの行動を直接生成するモデルである [3], [11]. RT-2 は, 大規模視覚言語モデルの知識をロボット制御へ転移できることを示し [11], その後大規模ロボットデータセット Open X-Embodiment [7] 上で学習されたオープンソース VLA として OpenVLA が公開された [3].

VLA は複数のロボット環境やタスクにおいて高い性能を示す一方で, 安全性や敵対的攻撃耐性に関する理解は依然として限定的である [3], [9], [10]. 特に, 実環境では観測画像への微小な摂動によってモデルの内部表現や出力行動が変化し, タスク失敗や意図しない行動につながる可能性がある [6], [9], [10].

VLA に対する敵対的攻撃は, 大きく非標的型攻撃と標的型攻撃に分類される. 非標的型攻撃は, 被害者が意図したタスクの遂行を妨害することを目的とする. 一方, 標的型攻撃は, 攻撃者が指定した特定のタスクに対応する行動へ誘導することを目的とする. 本論文では，敵対的摂動を付与せずに VLA を通常実行することを**クリーンラン**と呼ぶ．クリーンランによって得られる観測画像列，行動列，中間特徴量を，それぞれクリーンラン画像列，クリーンラン行動列，クリーンラン特徴量と呼ぶ. VLA は一般に複数のタスクを学習しており，本論文ではモデルの訓練時に利用されたタスクを**学習済みタスク**と呼ぶ.

既存手法では, 攻撃の最適化に, クリーンラン画像列, クリーンラン行動列, 正解状態列, 目標行動列など, 本来被害者のみが取得可能な情報を利用する場合が多い. 本研究では, これらを**被害者環境依存情報**と呼ぶ. しかし, このような情報へ攻撃者がアクセスできるとは限らず, より少ない事前情報を仮定した脅威モデルの検討が必要である.

そこで本研究では, 学習済み VLA モデルへのホワイトボックスアクセスを仮定し, 観測画像, 言語指示, および中間特徴量のみを利用する特徴量誘導攻撃を提案する. 本手法は, 被害者環境依存情報やロボット固有の物理情報を必要とせず, より少ない事前情報の下で攻撃を構成できる点を特徴とする. さらに, 同一の特徴量誘導の枠組みを標的型攻撃へ拡張し, その実現可能性を検証する.

1.1 関連研究

本節では，既存手法が攻撃を構成するためにどのような情報を必要とするかという観点から整理する.

UADA は，モデル出力と正解行動との差を最大化することでタスク失敗を誘発する非標的型攻撃である [9]．この手法では，目的関数の計算に正解行動列を必要とする. UPA-RFAS は，特徴量乖離，注意機構の操作，意味的不整合を組み合わせた物理パッチ攻撃である [6]. しかし，攻撃の最適化には，被害者タスクの正解状態列，すなわち正解画像または正解状態に対応する情報を利用する．TRAP は，Chain-of-Thought 型 VLA の推論過程を操作して標的行動へ誘導する標的型攻撃である [2]. この手法では，目標 CoT および目標行動列を必要とする. ADVLA は，Visual Encoder および Projection Layer の特徴量を変化させる非標的型攻撃である [10]. 攻撃には，被害者タスクを通常実行した際に得られる観測画像の内部特徴量を基準として利用するため，被害者タスクのクリーンラン画像が必要となる.

以上より，既存手法では，攻撃の最適化のために，被害者環境依存情報を利用する [2], [6], [9], [10]. 一方，本研究では，VLA へのホワイトボックスアクセスを仮定するものの，被害者環境依存情報には依存せず，実行時に取得可能な観測画像と言語指示，ならびに学習済みモデルの内部表現のみから攻撃を構成する．このように攻撃に必要な情報を大幅に削減することで，事前に対象タスクを実行できない状況でも被害者側の実環境で攻撃が成立する可能性があり，より少ない事前情報を仮定した脅威モデルを実現する.

1.2 貢献

本研究の主な貢献を以下に示す.

- **少ない事前情報で成立する脅威モデルの提案**
  既存手法で必要とされていた被害者環境依存情報を利用せず，実行時に取得可能な観測画像と言語指示，ならびにホワイトボックスアクセスによって取得可能な中間特徴量のみを用いる敵対的攻撃を定式化した．これにより，より現実的な攻撃者を想定した VLA の安全性評価を可能とした.

- **特徴量誘導に基づく新たな敵対的攻撃手法の提案**
  学習済みタスクに対応する中間特徴量を誘導先とする特徴量誘導攻撃を提案した．従来の特徴量乖離に基づく攻撃とは異なり，中間特徴量を別の学習済みタスクに対応する特徴量へ誘導することで，被害者タスクの遂行を妨害する攻撃を実現した.

- **複数の VLA モデルによる有効性の実証**
  OpenVLA，π_0，SmolVLA を用いた評価により，提案手法が非標的型攻撃において高い攻撃性能を有することを示した．さらに，同一の特徴量誘導の枠組みにより，目標行動列を用いない標的型攻撃への拡張可能性を示した.

[1] 東京科学大学
Institute of Sience Tokyo
[2] 理化学研究所 AIP
RIKEN AIP
[a)] kawamoto.k.a46a@m.isct.ac.jp

© 2026 Information Processing Society of Japan

表 1: 本論文で用いる主な記号
Table 1 Main notation used in this paper

記号	意味
f	学習済み VLA モデル
t	環境ステップの時刻
T	エピソード長
$\mathbf{I}^t$	時刻 t における観測画像
$\mathbf{x}$	言語指示
$\mathbf{x}_{\text{victim}}$	被害者タスクに対応する言語指示
$\mathbf{x}_{\text{proxy}}$	代理タスクに対応する言語指示
$\mathbf{x}_{\text{target}}$	攻撃者目標タスクに対応する言語指示
$\mathbf{a}^t$	時刻 t における出力行動
$\mathbf{a}^t_{\text{victim}}$	時刻 t における被害者タスクのクリーンラン行動
$\mathbf{a}^t_{\text{target}}$	時刻 t における攻撃者目標タスクのクリーンラン行動
$\tilde{\mathbf{a}}^t$	時刻 t における攻撃下の出力行動
$D(\cdot,\cdot)$	二つの行動列間の距離関数
$\mathbf{p}^t$	時刻 t における敵対的摂動
$\tilde{\mathbf{I}}^t$	摂動を付与した観測画像
$\phi_\ell(\cdot)$	第 ℓ 層までの特徴抽出関数
$\mathbf{z}^{(\ell),t}$	第 ℓ 層の中間特徴量
ϵ	摂動の最大大きさ（L_∞ ノルム制約）

2. 準備

本節では本論文で使用する記号を示す. その後, 本論文で対象とする Vision-Language-Action（VLA）モデルおよび本論文で用いる用語を定義する.

2.1 ノーテーションテーブル

本論文中で使用する主な記号を表 1 に示す.

2.2 Vision-Language-Action モデル

VLA では，観測画像と言語指示を入力としてロボットの行動を逐次生成する. 例えば,「pick up the black bowl between the plate and the ramekin and place it on the plate」のような言語指示が与えられる. このとき，観測画像には黒いボウル，皿，ラメキンなどの現在の環境が含まれ，VLA は観測画像と言語指示を統合して，黒いボウルを把持し皿の上へ移動させるための行動を逐次生成する.

本研究では, 観測画像空間を $\mathcal{I}$, 言語指示空間を $\mathcal{X}$, 行動空間を $\mathcal{A}$ とする. 時刻 t における観測画像を $\mathbf{I}^t \in \mathcal{I}$,VLA が生成する行動を $\mathbf{a}^t \in \mathcal{A}$ と表し, 言語指示を $\mathbf{x} \in \mathcal{X}$ と表す. なお, 言語指示は時間によって変化しないと仮定する.

学習済み VLA モデルを $f : \mathcal{I} \times \mathcal{X} \to \mathcal{A}$ とする. このとき,VLA は観測画像と言語指示を入力とし, 各時刻における行動 $\mathbf{a}^t = f(\mathbf{I}^t, \mathbf{x})$ を生成する. Transformer ベースの VLA では, 観測画像と言語指示が Transformer 内部で統合され, 各層において中間特徴量が逐次生成される. 本研究では, 第 ℓ 層までの特徴抽出関数を $\phi_\ell(\cdot)$, 対応する中間特徴量を $\mathbf{z}^{(\ell),t} = \phi_\ell(\mathbf{I}^t, \mathbf{x})$ と表す.

2.3 用語の定義

前章で定義したクリーンラン画像列，クリーンラン行動列，およびクリーンラン特徴量を，それぞれ $\{\mathbf{I}^1, \ldots, \mathbf{I}^T\}$, $\{\mathbf{a}^1, \ldots, \mathbf{a}^T\}$, $\{\mathbf{z}^{(\ell),1}, \ldots, \mathbf{z}^{(\ell),T}\}$ と表す.

本論文では, ロボットの構造, 自由度,Action Space,Action Tokenizer など, 個別のロボットに依存する固有の情報を**ロボット固有の物理情報**と呼ぶ. また, 物体配置や目標位置など, タスクを実行する環境に関する情報を**環境情報**と呼ぶ.

3. 脅威モデル

本研究では, 攻撃者の目的, 知識, 能力, および制約を以下のように定義する.

3.1 攻撃者の目的

本研究では, 非標的型攻撃と標的型攻撃の二つを対象とする.

被害者が VLA へ入力する言語指示を $\mathbf{x}_{\text{victim}}$ とし, この言語指示に対応するタスクを**被害者タスク**と呼ぶ. 非標的型攻撃では, 被害者タスクとは異なる学習済みタスクを**代理タスク**として用いる. 代理タスクに対応する言語指示を $\mathbf{x}_{\text{proxy}}$ とする. 一方, 標的型攻撃では, 被害者タスクとは異なる学習済みタスクを**攻撃者目標タスク**として用いる. 攻撃者目標タスクに対応する言語指示を $\mathbf{x}_{\text{target}}$ とする. また, 被害者タスクおよび攻撃者目標タスクをクリーンランした際に生成される行動列を, それぞれ $\{\mathbf{a}^t_{\text{victim}}\}_{t=1}^T$, $\{\mathbf{a}^t_{\text{target}}\}_{t=1}^T$ と表す.

まず, 非標的型攻撃における攻撃者の目的は, 代理タスクの情報を利用しながら, 攻撃下で生成される行動列 $\{\tilde{\mathbf{a}}^t\}_{t=1}^T$ を, 被害者タスクのクリーンラン行動列 $\{\mathbf{a}^t_{\text{victim}}\}_{t=1}^T$ からできるだけ乖離させることである. この目的は概念的には以下の最適化問題として表される.

$$\max_{\{\mathbf{p}^t\}_{t=1}^T} D\left(\{\tilde{\mathbf{a}}^t\}_{t=1}^T, \{\mathbf{a}^t_{\text{victim}}\}_{t=1}^T\right). \tag{1}$$

次に, 標的型攻撃における攻撃者の目的は, 攻撃下で生成される行動列 $\{\tilde{\mathbf{a}}^t\}_{t=1}^T$ を, 攻撃者目標タスクのクリーンラン行動列 $\{\mathbf{a}^t_{\text{target}}\}_{t=1}^T$ へできるだけ近づけることである.

$$\min_{\{\mathbf{p}^t\}_{t=1}^T} D\left(\{\tilde{\mathbf{a}}^t\}_{t=1}^T, \{\mathbf{a}^t_{\text{target}}\}_{t=1}^T\right). \tag{2}$$

3.2 攻撃者の知識

本研究では, 学習済み VLA モデル f に対するホワイトボックス攻撃を想定する. 攻撃者は, モデルの構造および学習済みパラメータに加え, 各 Transformer 層の中間特徴量および入力画像に関する勾配へアクセスできる.

一方, 攻撃者は被害者環境依存情報にはアクセスできな

© 2026 Information Processing Society of Japan

い. 攻撃者は, 被害者タスクとは異なる代理タスクおよび攻撃者目標タスクを自由に設定できるとする. また, 公開されたモデル, データセットおよびベンチマークに付随する情報から, 学習済みタスクおよび各タスクの言語指示を取得できるとする. このタスクを学習済みタスクと呼称する. 本研究では，学習済み VLA モデルに対するホワイトボックスアクセスを仮定する. 近年の VLA では，大規模ロボットデータセットを用いたスクラッチ学習ではなく，公開・提供された事前学習済みモデルを利用することが一般的である。. そのため，攻撃者も被害者と同一の事前学習済み VLA モデルを入手でき，モデル構造，学習済みパラメータ，中間特徴量へアクセス可能と仮定する. 攻撃者は，実行時に取得した観測画像と代理タスクまたは攻撃者目標タスクの言語指示を入力し，中間特徴量を取得できる.

3.3 攻撃者の能力

攻撃者は, 各時刻 t において VLA へ入力される観測画像 $\mathbf{I}^t \in \mathcal{I}$ のみに介入できる. 具体的には, 観測画像へ敵対的摂動 $\mathbf{p}^t$ を付与し,$\tilde{\mathbf{I}}^t = \mathbf{I}^t + \mathbf{p}^t$ とする. 攻撃者は観測画像以外の入力には介入できず, 言語指示, 学習済み VLA モデル, および実行環境そのものは変更できない. 攻撃者が付与する敵対的摂動には,$\|\mathbf{p}^t\|_\infty \leq \epsilon$ を満たす制約を課す.

3.4 既存の脅威モデルとの比較

既存手法では, 被害者タスクのクリーンランから取得したクリーンラン行動列, クリーンラン画像列, など被害者環境依存情報を攻撃の最適化に利用する [2], [6], [9], [10]. 一方, 本研究では, 被害者環境依存情報を一切利用せず, 代理タスクおよび攻撃者目標タスクに対応する言語指示, 実行時に取得可能な観測画像, および学習済み VLA モデルの内部表現のみを用いて攻撃を構成する. このように, 被害者環境依存情報を必要としないため, 被害者タスクを事前に実行できない状況でも攻撃を構成でき, 多様なロボット, タスク, および実行環境に適用可能である. したがって, 本研究が想定する脅威モデルは, 既存手法と比較してより少ない事前情報で攻撃を構成でき, より実用的かつ汎用的な攻撃設定であると考えられる.

4. 非標的型特徴量ステアリング攻撃

本章では,Transformer 層における中間特徴量を利用した特徴量誘導攻撃を提案する. 被害者タスクの遂行を阻害するためには, 被害者タスクに対応する中間特徴量から離れるような摂動を観測に注入する必要がある. 最も単純な方法として,1 の目的関数に従って, 摂動付与前後の出力行動列の距離を最大化することが考えられる. 本研究の脅威モデルでは, 行動列の情報を取得できないため代理目的として中間特徴量の最大化を行うことになる.

しかし, このような最大化においては, 最適解が自明に定

Algorithm 1 特徴量誘導攻撃:Feature Steering Attack(FSA)

VLA model f, feature extractor ϕ_ℓ, observation image $\mathbf{I}^t$, victim instruction $\mathbf{x}_{\text{victim}}$, proxy instruction $\mathbf{x}_{\text{proxy}}$
Initialize $\mathbf{p}^t = 0$
Compute proxy feature $\mathbf{z}_{\text{proxy}}^{(\ell),t}$
$i = 1, \ldots, N$
Compute perturbed feature $\tilde{\mathbf{z}}^{(\ell),t}$
Compute $\mathcal{L}_{\text{proxy}}^t$
Update $\mathbf{p}^t$ using Adam
Project $\mathbf{p}^t$ onto $\|\mathbf{p}^t\|_\infty \leq \epsilon$
Return $\tilde{\mathbf{I}}^t = \mathbf{I}^t + \mathbf{p}^t$

義されず, 特徴量をどの方向へ変化させるかが不明確である. さらにどの程度特徴量を乖離させれば十分な攻撃効果が得られるかも明確ではない. そのため, 攻撃目標としては扱いにくい. また,VLA では, 観測画像が訓練時と異なる場合であっても, 学習済みタスクの言語指示を与えることで, その言語指示に対応する行動を生成することが経験的に確認されている. このことから, 中間特徴量には学習済みタスクに対応する情報が強く反映されており過学習のような状態になっていると考えられる. そこで本研究では, 被害者タスクとは異なる学習済みタスクを代理タスクとして設定し, その中間特徴量を明示的な誘導先として利用する. これにより, 特徴量の更新方向と到達先を明確に定める.

時刻 t の観測画像 $\mathbf{I}^t$ と代理タスクに対応する言語指示 $\mathbf{x}_{\text{proxy}}$ を学習済み VLA モデルへ入力した際に得られる第 ℓ 層の中間特徴量を $\mathbf{z}_{\text{proxy}}^{(\ell),t} = \phi_\ell\left(\mathbf{I}^t, \mathbf{x}_{\text{proxy}}\right)$ と定義し, 以降これを代理タスク特徴量と呼ぶ. 一方, 摂動後の観測画像 $\tilde{\mathbf{I}}^t = \mathbf{I}^t + \mathbf{p}^t$ に対する中間特徴量は $\tilde{\mathbf{z}}^{(\ell),t} = \phi_\ell\left(\tilde{\mathbf{I}}^t, \mathbf{x}_{\text{victim}}\right)$ となる.

本研究では, 摂動付加後の中間特徴量が代理タスク特徴量へ近づくよう敵対的摂動を最適化する. そのため, 特徴量誘導損失を

$$\mathcal{L}_{\text{proxy}} = \sum_{t=1}^{T} \left\| \tilde{\mathbf{z}}^{(\ell),t} - \mathbf{z}_{\text{proxy}}^{(\ell),t} \right\|_2^2 \tag{3}$$

と定義する. 以上より, 本研究における敵対的摂動は

$$\begin{aligned} \mathbf{p}^{t*} = \arg\min_{\mathbf{p}^t} \quad & \mathcal{L}_{\text{proxy}}^t \\ \text{s.t.} \quad & \left\|\mathbf{p}^t\right\|_\infty \leq \epsilon \end{aligned} \tag{4}$$

として求める. 本研究では, 上式を Adam により反復的に最適化する. 各反復では, 特徴量誘導損失に対する勾配を用いて敵対的摂動を更新した後, 射影処理によって各画素値が L_∞ 制約を満たすようクリッピングを行う.FSA の全体の流れを Algorithm 1 に示す.

5. 疑似標的型特徴量ステアリング攻撃

本章では, 前章で提案した非標的型攻撃を標的型攻撃へ拡張する. 攻撃者が生成させることを目的とするタスクを

© 2026 Information Processing Society of Japan

攻撃者目標タスクとし, その言語指示を $\mathbf{x}_{\text{target}}$ とする. 標的型攻撃の目的は, 攻撃下で生成される行動列を攻撃者目標タスクに対応する行動列へ近づけることであり, その概念的な目的関数は式 (2) で定義したとおりである. 例えば, 被害者タスクが「黒いボウルを皿の上へ移動する」である場合, 攻撃者目標タスクとして「赤いマグカップを引き出しへ収納する」を設定することが考えられる.

まず, 本研究では, 攻撃者が任意に設定した攻撃者目標タスクに対応する特徴量への誘導による純粋な標的型攻撃を検討した. しかし, 本研究で対象とする VLA では, 任意の目標タスクへの安定した行動誘導は確認できなかった. VLA では，同一の観測画像に対しても，言語指示を変更することで異なる行動が生成されることが経験的に確認されている. このことから，中間特徴量には各タスクに対応する情報が反映されていると考えられる. VLA は一般に複数のタスクを学習しており, 各学習済みタスクに対応する内部表現を獲得していると予想される. そこで本研究では, 攻撃者目標タスクを任意に設定するのではなく, 学習済みタスク集合の中から選択し摂動の条件を緩めた疑似的な標的型攻撃を検討した. すなわち, 被害者タスクとは異なる学習済みタスクを攻撃者目標タスクとして設定し, その中間特徴量を誘導先として利用する.

このように, 本研究では攻撃者目標タスクを学習済みタスクに限定しているため, 任意の目標タスクへの誘導を目的とする完全な標的型攻撃ではなく, 学習済みタスクへの特徴量誘導に基づく擬似的な標的型攻撃として位置付ける.

攻撃者目標タスクに対応する時刻 t の中間特徴量を $\mathbf{z}_{\text{target}}^{(\ell),t} = \phi_\ell\left(\mathbf{I}^t, \mathbf{x}_{\text{target}}\right)$ とする. この擬似的標的型攻撃において, 攻撃者目標タスクの行動列や軌道は攻撃の最適化に利用しないことに注意されたい. 攻撃者は攻撃者目標タスクの言語指示のみを指定し, そこから得られる中間特徴量を誘導先として利用する. したがって, 時刻 t における特徴量誘導損失を $\mathcal{L}_{\text{target}}^t = \left\| \phi_\ell\left(\tilde{\mathbf{I}}^t, \mathbf{x}_{\text{victim}}\right) - \mathbf{z}_{\text{target}}^{(\ell),t} \right\|_2^2$ と定義し，敵対的摂動は $\mathbf{p}^{t*} = \arg\min_{\mathbf{p}^t} \mathcal{L}_{\text{target}}^t$ として求める.

6. 実験

6.1 共通実験設定

実験には，ロボット操作ベンチマーク LIBERO [5] に含まれる LIBERO-Spatial を用いた. 評価対象の VLA モデルには，OpenVLA，π_0，SmolVLA を採用し，異なる VLA モデルに対する FSA の有効性を評価した. 敵対的摂動の最適化には Adam [4] を用いた. 学習率は 0.01，最適化回数は 100 イテレーションとし，摂動の上限を非標的型攻撃の実験では $\epsilon = 0.1$, 標的型攻撃の実験では $\epsilon = 1$ とした.

6.2 非標的型攻撃 (UFSA)

6.2.1 実験設定

本実験では，LIBERO-Spatial に含まれる 10 種類のタスクを被害者タスクとして用いた. また，代理タスクには Task 0，Task 1，および Task 2 を用いた.，代理タスクは被害者タスクとは異なる必要があるため，被害者タスクと一致しないように, 各被害者タスクについて 2 種類の代理タスクを設定し，UFSA の有効性を評価した.

表 2: 非標的型攻撃における ASR
Table 2 ASR for the untargeted attack

条件	OpenVLA	π_0	SmolVLA
Clean	0.190	0.018	0.432
Random Noise	0.280	0.016	0.464
Ours	**1.000**	**0.772**	**0.994**

6.2.2 比較条件

提案手法の脅威モデルでは，攻撃者は被害者環境依存情報を利用できない．一方, 既存の VLA に対する敵対的攻撃手法の多くは，これらの情報を必要とするため，本研究で想定する脅威モデルの下では適用できない．そのため，本実験では，摂動を付与しない条件（Clean），UFSA と同一の L_∞ 制約下でランダムノイズを付与した条件（Random Noise），および UFSA（Ours）の 3 条件を比較し，Clean との比較により攻撃性能を，Random Noise との比較により攻撃性能が単なる画像ノイズではなく中間特徴量の誘導に起因することを評価する.

6.2.3 評価指標

非標的型攻撃の性能は Attack Success Rate（ASR）により評価する.ASR はタスク成功率（Task Success Rate; TSR）の補数として ASR $= 1 -$ TSR と定義する.TSR は,LIBERO が提供する成功判定に基づき, 全試行に対する成功試行の割合として算出する.ASR が高いほど, 被害者タスクの遂行をより効果的に阻害できていることを示す.

6.2.4 実験結果

表 2 に, 非標的型攻撃における ASR を示す.UFSA は，すべての VLA モデルにおいて Clean および Random Noise を上回る ASR を達成した. 特に OpenVLA および SmolVLA では，ASR がそれぞれ 1.000 および 0.994 となり，ほぼすべての試行で被害者タスクの遂行を阻害した. また，π_0 においても Random Noise と比較して大幅な性能向上が確認された.

6.3 非標的型攻撃の有効性

UFSA は，すべての VLA モデルにおいて Random Noise を大きく上回る ASR を達成した. この結果は，攻撃性能が単なる画像ノイズではなく，代理タスクに対応する中間特徴量への誘導に起因することを示している. また，ロボット固有の物理情報，環境情報，およびクリーンラン行動列を利用せず，中間特徴量のみを用いた非標的型攻撃が有効であることを示している. 一方，π_0 では他モデルより ASR が低かった. これは，モデル構造や学習方法の違いにより，

© 2026 Information Processing Society of Japan

中間特徴量の変化が最終的な行動へ与える影響が異なるためと考えられる. 特徴量と行動生成との関係については，今後さらに解析を行う必要がある.

6.4 疑似標的型攻撃 (PTFSA)

6.4.1 実験設定

被害者が特定のタスクを実行していない状況における疑似標的型攻撃の有効性を評価するため，被害者タスクには独自に設定した “do nothing” を用い，攻撃者目標タスクには LIBERO-Spatial に含まれる各タスクを用いる. これにより，被害者言語指示のみでは攻撃者目標タスクに対応する行動が生成されない状況を構成し，観測画像への摂動による特徴量誘導の効果を評価する.

さらに，被害者が特定のタスクを実行している状況における疑似標的型攻撃の有効性を評価するため，被害者タスクには “open the cabinet” を用いる. この実験では，代表的な VLA モデルとして π_0 を対象とし，LIBERO-Spatial の各タスクを攻撃者目標タスクとして設定する.

6.4.2 評価指標

標的攻撃では，PTFSA によって生成された行動が攻撃者目標タスクの行動へどの程度近づいたかを評価する. 各攻撃者目標タスクについて，評価のために，被害者タスクを摂動なしで実行した際の行動列 $\{a^t_{\text{victim}}\}_{t=1}^{T}$（Victim Clean），攻撃者目標タスクを摂動なしで実行した際の行動列 $\{a^t_{\text{target}}\}_{t=1}^{T}$（Target Clean），および被害者タスクに PTFSA による摂動を付与して実行した際の行動列 $\{a^t_{\text{pert}}\}_{t=1}^{T}$（Perturbed）の 3 種類の行動列を取得する. なお，これらの行動列は評価のために取得するものであり，攻撃の実行には利用されない.

まず,Victim Clean と Target Clean の平均ユークリッド距離を $D_{\text{clean}} = \frac{1}{T}\sum_{t=1}^{T}\left\|a^t_{\text{victim}} - a^t_{\text{target}}\right\|_2$ と定義する. 同様に,Perturbed と Target Clean の平均ユークリッド距離を $D_{\text{ours}} = \frac{1}{T}\sum_{t=1}^{T}\left\|a^t_{\text{pert}} - a^t_{\text{target}}\right\|_2$ と定義する.

本研究では,$D_{\text{ours}} < D_{\text{clean}}$ である場合,PTFSA によって生成された行動が, 被害者タスクの通常実行時よりも攻撃者目標タスクの行動へ近づいたと判断する.

6.4.3 実験結果

表 3 に，“do nothing” を被害者タスクとした場合に，各 VLA モデルで $D_{\text{ours}} < D_{\text{clean}}$ となった攻撃者目標タスク数を示す．また，表 4 に，各攻撃者目標タスクに対する詳細な評価結果を示す.

OpenVLA では，10 個の攻撃者目標タスクのうち Task 0，1，5，8 の 4 タスクで $D_{\text{ours}} < D_{\text{clean}}$ となり，一部の攻撃者目標タスクに対して生成行動を誘導できることが確認された．一方，残る 6 タスクでは距離が増加した. π_0 では，Task 0 を除く 9 タスクで $D_{\text{ours}} < D_{\text{clean}}$ となり，特に Task 9 では平均ユークリッド距離が大幅に減少した．この結果から，多くの攻撃者目標タスクにおいて，PTFSA により生成行動を攻撃者目標タスクの方向へ誘導できることが確認された．SmolVLA では，10 個の攻撃者目標タスクのうち 7 タスクで $D_{\text{ours}} < D_{\text{clean}}$ となり，特に Task 5 では平均ユークリッド距離が大きく減少した．一方，Task 6，7，9 では距離が増加した.

表 3: “do nothing” を被害者タスクとした時の標的行動への距離が改善したタスク数

Table 3 Number of target tasks with improved distance to the target action when “do nothing” is used as the victim task.

Model	Improved tasks	Improvement rate
OpenVLA	4 / 10	40%
π_0	9 / 10	90%
SmolVLA	7 / 10	70%

以上より，PTFSA は 3 種類すべての VLA モデルにおいて，少なくとも一部の攻撃者目標タスクに対して生成行動をその方向へ誘導できることが確認された．一方で攻撃の有効性はタスクによって異なることも確認された.

さらに，表 5 に，“open the cabinet” を被害者タスクとした場合の各攻撃者目標タスクに対する詳細な評価結果を示す．9 つの攻撃者目標タスクで $D_{\text{ours}} < D_{\text{clean}}$ となり，特に Task 5 では距離が 24.703 から 2.030 まで大きく減少した．以上より，被害者タスクを変更した場合にも，PTFSA によって生成された行動が攻撃者目標タスクの行動へ近づくことを確認した．この結果は，PTFSA による特徴量誘導型攻撃が複数の被害者タスクに対して適用可能であることを示している.

6.4.4 標的型攻撃への拡張可能性

提案手法を標的型攻撃へ拡張した結果，一部の攻撃者目標タスクで $D_{\text{ours}} < D_{\text{clean}}$ となり，生成行動が攻撃者目標タスクのクリーンラン行動列へ近づくことを確認した．ただし，距離指標の改善が必ずしも攻撃者目標タスクへの行動誘導を意味するとは限らない.

図 1 に代表例を示す．軌跡を比較した結果，摂動を付与しても行動がほとんど変化しない場合，行動は変化するが攻撃者目標タスクとは異なる方向へ逸脱する場合，および攻撃者目標タスクのクリーンラン軌跡へ近づく場合の 3 種類が確認された．図 1(a) に示す π_0 の Task 9 では，提案手法による軌跡が攻撃者目標タスクのクリーンラン軌跡へ近づき，平均ユークリッド距離も 66.670 から 4.339 まで大きく減少した．これは，中間特徴量の誘導が実際の行動生成にも反映された代表的な成功例である．一方，図 1(b), (c) では，距離指標が改善した場合，あるいは行動自体が変化した場合であっても，軌跡全体は攻撃者目標タスクのクリーンラン軌跡と十分には一致していない．すなわち，特徴量空間における誘導が，常に行動空間における攻撃者目標タスクへの誘導へ結び付くわけではないことが分かる.

© 2026 Information Processing Society of Japan

		OpenVLA		π_0		SmolVLA	
Target task	Language instruction	D_{ours}	D_{clean}	D_{ours}	D_{clean}	D_{ours}	D_{clean}
0	Pick up the black bowl between the plate and the ramekin and place it on the plate.	**35.616**	54.103	6.519	**6.198**	**51.711**	51.950
1	Pick up the black bowl next to the ramekin and place it on the plate.	**35.404**	63.728	**5.383**	5.983	**42.506**	43.898
2	Pick up the black bowl from table center and place it on the plate.	47.827	**36.265**	**7.397**	9.141	**55.347**	57.610
3	Pick up the black bowl on the cookie box and place it on the plate.	44.269	**25.591**	**2.237**	2.833	**59.897**	60.608
4	Pick up the black bowl in the top drawer of the wooden cabinet and place it on the plate.	47.454	**29.107**	**33.554**	44.835	**69.239**	71.549
5	Pick up the black bowl on the ramekin and place it on the plate.	**33.689**	41.893	**2.948**	4.779	**37.065**	47.256
6	Pick up the black bowl next to the cookie box and place it on the plate.	43.920	**22.038**	**5.322**	7.519	69.465	**65.957**
7	Pick up the black bowl on the stove and place it on the plate.	41.600	**38.444**	**23.392**	29.367	70.863	**69.511**
8	Pick up the black bowl next to the plate and place it on the plate.	**29.941**	38.137	**2.458**	3.991	**50.026**	54.644
9	Pick up the black bowl on the wooden cabinet and place it on the plate.	42.186	**38.315**	**4.339**	66.670	87.011	**83.825**

表 4: “do nothing” を被害者タスクとした標的型攻撃の評価結果．D_{ours} と D_{clean} は，それぞれ PTFSA 適用時と被害者タスクのクリーンラン行動列から，攻撃者目標タスクのクリーンラン行動列までの平均ユークリッド距離を表す．太字は各条件で小さい方の値を示す．

Table 4 Targeted attack results with “do nothing” as the victim task. D_{ours} and D_{clean} denote the average Euclidean distances from the proposed and victim clean-run action sequences to the target clean-run action sequence, respectively. Boldface indicates the smaller value.

表 5: “open the cabinet” を被害者タスクとした時の各攻撃者目標タスクに対する詳細な評価結果

Table 5 Detailed evaluation results for each target task when “open the cabinet” is used as the victim task.

Target task	D_{ours}	D_{clean}
0	**15.343**	20.511
1	**44.257**	47.112
2	**22.814**	35.862
3	**13.465**	13.696
4	**2.733**	18.995
5	**2.030**	24.703
6	**14.894**	27.322
7	26.145	**23.838**
8	**25.100**	34.623
9	**2.214**	14.673

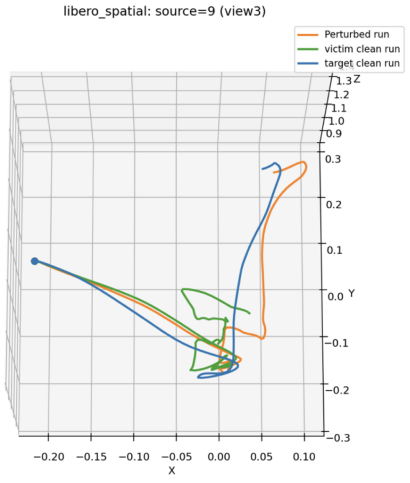
以上より，本手法は目標行動列を利用せずに標的型攻撃を実現できる可能性を示した一方，特徴量空間と行動空間の対応関係には依然としてギャップが存在することが明らかとなった．

7. まとめと今後の展望

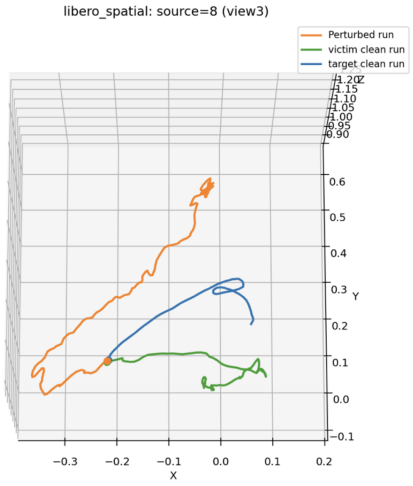
本研究では，Vision-Language-Action（VLA）モデルに対する特徴量誘導型攻撃を提案した．本手法は，被害者環境依存情報を必要とせず，観測画像，言語指示，および VLA モデルの中間特徴量のみを用いて敵対的摂動を生成する．実験では，非標的型攻撃において高い攻撃性能を達成するとともに，同一の特徴量誘導の枠組みを標的型攻撃へ拡張し，一部の攻撃者目標タスクでは生成行動を攻撃者目標タスクの方向へ誘導できることを確認した．一方で，すべてのモデル・タスクに対して安定した標的型攻撃を実現できたわけではなく，特徴量空間における誘導と行動生成との関係にはさらなる検討の余地がある．

以上より，本研究は，限られた攻撃者知識の下で実現可能な特徴量誘導型攻撃を示すとともに，同一の特徴量誘導の枠組みにより非標的型攻撃および標的型攻撃を統一的に扱える可能性を示した．今後は，特徴量と行動生成との対応関係を解析し，より適切な誘導先特徴量や目的関数を設計するとともに，複数層の特徴量や時間方向の一貫性を考慮した最適化，さらに転移攻撃やブラックボックス環境へ

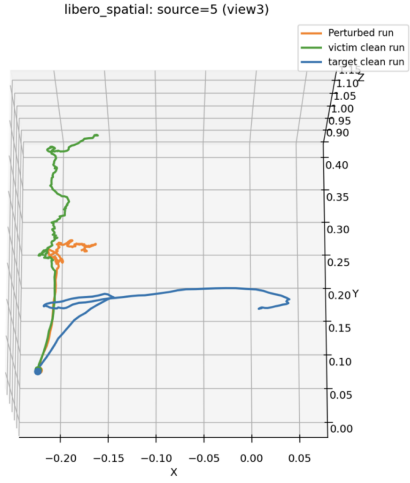
© 2026 Information Processing Society of Japan



(a) π_0 Task 9



(b) OpenVLA Task 8



(c) SmolVLA Task 5

図 1: 各 VLA モデルにおける標的型特徴量誘導攻撃後の軌跡例．(a) は攻撃者目標タスクへの誘導に成功した例，(b) は距離指標は改善したが軌跡は十分一致しない例，(c) は行動は変化したが攻撃者目標タスクへの誘導は確認できない例を示す．

Fig. 1 Examples of trajectories after the targeted feature steering attack. (a) Successful steering. (b) Improved distance without trajectory alignment. (c) Changed behavior without steering.

の拡張に取り組む．

謝辞 本研究は JST Nexus JPMJNX25C2, JST K-program JPMJKP24C3, JST CREST JPMJCR21D3, JPMJCR23M4, JSPS Grants-in-Aid for Scientific Research 23H00483, JSPS 二国間 120251002 の支援を受けたものである．

参考文献

[1] Kevin Black, Noah Brown, Danny Driess, Adnan Esmail, Michael Equi, Chelsea Finn, Niccolo Fusai, Lachy Groom, Karol Hausman, Brian Ichter, Szymon Jakubczak, Tim Jones, Liyiming Ke, Sergey Levine, Adrian Li-Bell, Mohith Mothukuri, Suraj Nair, Karl Pertsch, Lucy Xiaoyang Shi, James Tanner, Quan Vuong, Anna Walling, Haohuan Wang, and Ury Zhilinsky. π_0: A vision-language-action flow model for general robot control. *arXiv preprint arXiv:2410.24164*, 2024.

[2] Huang et al. Trap: Hijacking vla cot-reasoning via adversarial patches. *arXiv preprint arXiv:2603.23117*, 2026.

[3] Moo Jin Kim, Karl Pertsch, Siddharth Karamcheti, et al. Openvla: An open-source vision-language-action model. *arXiv preprint arXiv:2406.09246*, 2024.

[4] Diederik P. Kingma and Jimmy Ba. Adam: A method for stochastic optimization. In *International Conference on Learning Representations (ICLR)*, 2015.

[5] Bo Liu, Yifeng Zhu, Chongkai Gao, Yihao Feng, Qiang Liu, Yuke Zhu, and Peter Stone. Libero: Benchmarking knowledge transfer for lifelong robot learning. volume 36, pages 44776–44791, 2023.

[6] Hui Lu, Yi Yu, Yiming Yang, Chenyu Yi, Qixin Zhang, Bingquan Shen, Alex C. Kot, and Xudong Jiang. When robots obey the patch: Universal transferable patch attacks on vision-language-action models. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, 2026.

[7] Open X-Embodiment Collaboration. Open x-embodiment: Robotic learning datasets and rt-x models. In *IEEE International Conference on Robotics and Automation (ICRA)*, 2024.

[8] Mustafa Shukor, Dana Aubakirova, Francesco Capuano, Pepijn Kooijmans, Steven Palma, Adil Zouitine, Michel Aractingi, Caroline Pascal, Martino Russi, Andres Marafioti, Simon Alibert, Matthieu Cord, Thomas Wolf, and Remi Cadene. Smolvla: A vision-language-action model for affordable and efficient robotics. *arXiv preprint arXiv:2506.01844*, 2025.

[9] Taowen Wang, Cheng Han, James Liang, Wenhao Yang, Dongfang Liu, Luna Xinyu Zhang, Qifan Wang, Jiebo Luo, and Ruixiang Tang. Exploring the adversarial vulnerabilities of vision-language-action models in robotics. In *Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV)*, pages 6948–6958, 2025.

[10] Naifu Zhang, Wei Tao, Xi Xiao, Qianpu Sun, Yuxin Zheng, Wentao Mo, Peiqiang Wang, and Nan Zhang. Attention-guided patch-wise sparse adversarial attacks on vision-language-action models. *arXiv preprint arXiv:2511.21663*, 2025.

[11] Brianna Zitkovich, Tianhe Yu, Sudeep Xu, et al. Rt-2: Vision-language-action models transfer web knowledge to robotic control. In *Conference on Robot Learning (CoRL)*, pages 2165–2183, 2023.

© 2026 Information Processing Society of Japan