物理シミュレータを用いたフィジカル AI レッドチーミング：Isaac Sim 上での敵対的パッチ攻撃による検証

山本 恭敬[1,a)]　大西 健斗[1,b)]　東 拓矢[1,c)]　中井 綱人[1,d)]　小関 義博[1,e)]

概要：フィジカル AI は，視覚と言語の入力から実世界での行動を直接生成し物理システムを制御する AI であり，VLA モデルの登場により人型ロボット等への実装が進んでいる．物理世界に直接作用するため攻撃が人身・物的被害に直結する一方，どのような入力が危険な行動を誘発するかを事前に列挙することは難しく，仕様に沿った検査だけでは不十分である．そこで脆弱性を能動的に探索するレッドチーミングが求められるが，実機での反復試行は危害や機体破損を伴い現実的でない．本研究では，産業界で採用が広がる物理シミュレータ Isaac Sim を基盤とし，安全性・反復可能性・再現性を確保したレッドチーミングの枠組みを提案する．最初の検証として敵対的パッチ攻撃を取り上げ，VLA モデル Isaac GR00T N1 を搭載した人型ロボット GR-1 に対し計 11,612 ロールアウトの探索を行った．タスク成功率は無攻撃時の 78% に対し，画像貼り付けで 5%，同じパッチをシーン内の物体として配置しても 30%まで低下した．この効果は光源強度や対象タスクを変えても保たれた一方，パッチを把持対象から離すとほぼ消失した．ただし攻撃の機序は未解明であり，意図した稼働停止は観測されなかった．注入経路を同一シーン上で切り替え，条件を揃えた多数の試行を危害なく測定できたことは，提案枠組みの有効性を一事例において示している．

キーワード：フィジカル AI，レッドチーミング，敵対的パッチ攻撃，Isaac Sim，人型ロボット

Red Teaming Physical AI with a Physics Simulator: A Case Study of Adversarial Patch Attacks in NVIDIA Isaac Sim

Yasutaka Yamamoto[1,a)]　Kento Oonishi[1,b)]　Takuya Higashi[1,c)]　Tsunato Nakai[1,d)]
Yoshihiro Koseki[1,e)]

Abstract: Physical AI generates real-world actions directly from visual and language inputs, and Vision-Language-Action (VLA) models are driving its deployment on humanoid robots. Because such systems act on the physical world, attacks can cause injury or property damage, yet the inputs that induce dangerous behavior cannot be enumerated in advance; testing against a specification alone is therefore insufficient. Red teaming, which actively searches for vulnerabilities, is needed, but repeated trials on real hardware are hazardous and impractical. We propose a red-teaming framework built on Isaac Sim, an industry-adopted physics simulator, which provides safety, repeatability, and reproducibility. As a first case study, we run 11,612 rollouts of adversarial patch attacks against the humanoid robot GR-1 driven by the VLA model Isaac GR00T N1. The task success rate dropped from 78% without attack to 5% for image overlay, and to 30% when the same patch was placed as an object in the scene. The effect persisted under different light intensities and on another task, but almost vanished when the patch was moved away from the target object. The mechanism remains unclear, and the intended action freezing was not observed. Switching the injection path within a single scene and measuring many controlled trials without harm demonstrates the effectiveness of the proposed framework in this case study.

Keywords: Physical AI, Red Teaming, Adversarial Patch Attack, Isaac Sim, Humanoid Robot

© 2026 Information Processing Society of Japan

This paper is work in progress and not peer-reviewed.

1. はじめに

近年，Vision-Language-Action（VLA）モデルに代表されるフィジカル AI 技術が急速に進歩し，人型ロボット等への実装が進んでいる．こうしたシステムは物理世界に直接作用するため，誤動作や悪意ある攻撃が人身・物的被害に直結しうる．このような攻撃の 1 つとして，画像中の局所領域に配置した模様によってモデルの出力を誤らせる攻撃があり，敵対的パッチ攻撃と呼ばれている．シールやポスターのように日常環境に存在しうる媒体で実行可能であり，人間には単なる模様にしか見えない場合もあるため，そのリスクは軽視できない．

フィジカル AI では，どのような入力が危険な行動を誘発するかを事前に列挙することが難しく，仕様に沿った検査だけでは不十分である．そのため，脆弱性を能動的に探索するレッドチーミングが求められる．レッドチーミングは LLM の分野では安全性評価の手法の一つとして注目されつつある [1] が，フィジカル AI への適用はほとんど行われていない．実機でのレッドチーミングは，攻撃による人・物への危害や機体破損のリスクを伴い，膨大な試行を要する反復的探索には時間的・費用的に見合わない．物理シミュレータはこの障壁を取り除き，攻撃の試行を安全かつ高速に，条件を厳密に制御・再現しながら実施できる．

本研究では，産業界で採用が広がる物理シミュレータ NVIDIA Isaac Sim[2] を基盤として，フィジカル AI のレッドチーミングを行う枠組みを提案する．最初の検証として，敵対的パッチ攻撃 [3] を取り上げ，VLA モデル Isaac GR00T N1[4] を搭載した人型ロボット GR-1（Fourier Intelligence 社）[*1] を対象に Isaac Sim 上で攻撃を実施した．探索と最適化を合わせて 11,612 回に及ぶロールアウトを完遂しており，これは実機では現実的に困難な規模である．

本研究の貢献は，(1)Isaac Sim 上でフィジカル AI のレッドチーミングを行う枠組み・コンセプトの提案（3 章）及び (2) 著者らの知る限り Isaac Sim ではじめて敵対的パッチ攻撃を実施し，タスク成功率の明確な低下を確認（4 章，5 章，6 章，7 章），の 2 点である．

本研究で実施した敵対的パッチ攻撃では，いずれの評価条件でもタスク成功率が明確に低下した一方，意図した稼働停止はパッチ生成時及び評価時のいずれにおいても観測されなかった．

[1] 三菱電機株式会社
Mitsubishi Electric Corporation
[a)] Yamamoto.Yasutaka@dc.MitsubishiElectric.co.jp
[b)] Onishi.Kento@ap.MitsubishiElectric.co.jp
[c)] Higashi.Takuya@da.MitsubishiElectric.co.jp
[d)] Nakai.Tsunato@dy.MitsubishiElectric.co.jp
[e)] Koseki.Yoshihiro@ak.MitsubishiElectric.co.jp

[*1] NVIDIA Isaac GR00T のコードおよび embodiment タグ上は `GR1` と表記される．本稿ではロボット本体を指す場合に「GR-1」，コード・アセット・ベンチマークを参照する場合に `GR1` を用いる．

2. 関連研究

敵対的パッチ攻撃は，Brown ら [3] によって提案された，画像中の局所的なパッチで深層学習モデルの出力を誤らせる攻撃である．カメラ視野内に物理的に配置できるため実世界での実行可能性が高い．近年，VLA モデルを標的とする研究が活発化しており，カメラ視野内の小さなパッチでロボットの行動を不安定化・誘導する攻撃 [5]，モデル構造に依存しないパッチ生成 [6]，複数の VLA アーキテクチャ間で転移する汎用パッチ [7]，3D テクスチャとして付与する手法 [8] など，実世界指向性と汎用性を高める研究が多数提案されている．

本研究では敵対的パッチ攻撃のうち，稼働停止（行動の凍結）を標的とした攻撃について議論する．この攻撃の例として，FreezeVLA[9] が挙げられる．FreezeVLA は局所的なパッチではなく画像全体への ℓ_∞ 制約付き摂動（$\epsilon = 4/255$）による攻撃であり，min-max 二層最適化により SpatialVLA・OpenVLA・π_0 という 3 つの VLA モデルを LIBERO 系 4 ベンチマーク上で評価し，平均 76.2% という高い攻撃成功率を報告している．同研究は，行動系列の終端や無動作を表す離散トークン（`<eos>`や専用の停止トークン）を予測させることで凍結を誘導する．一方，機構の異なるモデルでも同様に成り立つとは限らず，例えば本研究が対象とする GR00T N1 に対しては，この目的関数を直接的には適用できない．そこで本研究では，行動系列の時間差分ノルム（式 (1)）を最小化するという設計を採った．

これらの評価基盤の多くは LIBERO[10]（MuJoCo[11] 上に構築）などのロボットアームによる机上操作ベンチマークを中心としており [6], [7], [8], [9]，全身の姿勢制御を伴う人型ロボットを対象とした検証は限定的である．すなわち，産業界での普及を背景にフィジカル AI の開発・展開が進む Isaac Sim 上での敵対的パッチ攻撃の検証はほとんど行われていない．

レッドチーミングは LLM の分野で安全性評価の枠組みの一つとして注目されつつある [1] が，フィジカル AI への適用はまだ少なく，共通のシミュレータ基盤で脆弱性を体系的に探索するという観点は十分に確立されていない．本研究は，Isaac Sim を基盤とし，人型ロボットを対象とした敵対的パッチ攻撃をその最初の検証と位置づけることで，フィジカル AI のレッドチーミングに向けた枠組みを提案する．

3. 提案：Isaac Sim 上でのフィジカル AI レッドチーミング

本研究では，物理シミュレータ Isaac Sim[2] を基盤として，フィジカル AI の脆弱性を能動的に探索・評価するレッドチーミングの枠組みを提案する．レッドチーミングは多

© 2026 Information Processing Society of Japan

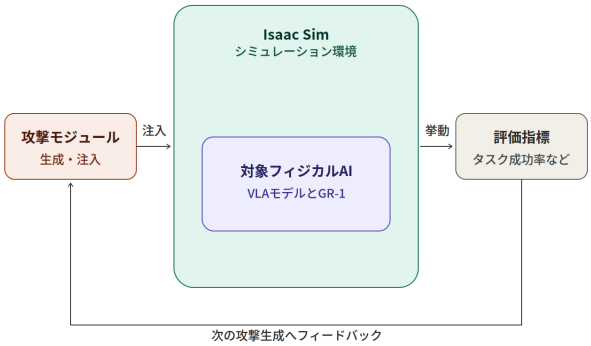


図 1 Isaac Sim を基盤としたフィジカル AI レッドチーミング枠組みの概要

Fig. 1 Overview of the proposed red-teaming framework.

数の攻撃候補を試行し効果のあるものを見出す反復的探索であり，危険な挙動を許容できる環境と膨大な試行速度の両方を要するが，実機はいずれも満たさない．シミュレータは，安全性（実害なく攻撃を探索できる），反復可能性（実機の速度・リセットに束縛されず試行を繰り返せる），再現性（初期条件・視点・照明・物体配置を厳密に制御し結果を再現できる）の 3 点でこの要件を満たす．

既存の敵対的パッチ攻撃の多くは，接触計算の高速性を重視して設計された MuJoCo[11] 上の LIBERO[10] を用いてロボットアームを対象に実施されてきた．一部の研究 [8] は LIBERO 上に微分可能レンダラ（レンダリング過程を通じて勾配を伝播させ，テクスチャ等の見た目を直接最適化できるレンダラ）を別途併用することで 3D テクスチャの最適化を可能にしているが，本研究が Isaac Sim を選ぶ理由は，(1) 別途レンダラを用意することなく，実運用で使われている RTX ベースのレンダリング経路上でオブジェクト配置による攻撃を直接評価できること，(2)GPU 上での並列実行が大規模探索に適すること，及び (3) 対象とする Isaac GR00T N1[4] 等の開発・評価が実際に行われている環境であること，にある．

提案枠組みの全体像を**図 1** に示す．本枠組みは，(1) 評価対象フィジカル AI，(2) シミュレーション環境，(3) 攻撃を生成・注入する攻撃モジュール，及び (4) 挙動を定量化する評価指標，の 4 要素からなり，生成・注入・評価のループを通じて脆弱性を体系的に探索する．本稿では，攻撃モジュールに敵対的パッチ攻撃を据えた場合を扱う（4 章）．対象は人型ロボット GR-1 と Isaac GR00T N1 に限定する．パッチ生成は画像貼り付けにより行い，画像貼り付けとオブジェクト配置の 2 条件で評価する．

4. 検証手法：敵対的パッチ攻撃

4.1 脅威モデル

攻撃者の目標は，VLA モデルが出力する行動系列を操作し，ロボットを一定姿勢に固定させ稼働停止させることである．攻撃者はカメラ画像の一部に敵対的パッチを重畳できる（評価条件 A），あるいはシーン内に物理的なパッチ・オブジェクトを設置できる（評価条件 B）ものとし，パッチ最適化には VLA モデルの勾配を利用できるホワイトボックス設定を仮定するが，ロボット制御則やシミュレーション内部状態には介入しない．すなわち攻撃はモデルへの視覚入力のみを経路とする．

4.2 パッチの生成

はじめに，パッチ生成において本研究で導入する変数を説明する．VLA モデルの方策を π とし，時刻 t におけるロボットの状態 s_t，自己視点カメラ画像 $x_t \in [0,255]^{H_I \times W_I \times 3}$（$H_I = 160$，$W_I = 256$），および言語指示 ℓ を入力として，行動チャンク $a_t = \pi(s_t, x_t, \ell) \in \mathbb{R}^{H_a \times d}$ を出力する．H_a はチャンク長，d は行動次元（両腕・両手の絶対関節位置を連結した $d = 26$ 次元）である．敵対的パッチを $\delta \in [0,255]^{H_p \times W_p \times 3}$（$H_p = W_p = 50$）と表す．

本研究のパッチ生成は，(1) パッチの配置位置を探る探索フェーズ及び (2) その位置で内容を最適化する最適化フェーズ，を交互に繰り返す 2 段階の手続きからなる．探索フェーズでダミーパッチによる遮蔽だけではタスクが妨げられない配置を選び，その配置でのみ内容を最適化することで，最適化フェーズで観測される失敗を配置（遮蔽）ではなくパッチの内容（模様）に帰属できる状態でパッチを学習する．探索フェーズでは，固定のダミーパッチ δ_{dummy}（一様乱数パターン）を用い，配置位置 (h_0, w_0)・スケール・アフィン変換を一様乱数で選んでロールアウトを行い，タスクが成功した位置・変換を採用して最適化フェーズへ移行する．失敗時は別の位置・変換で探索を繰り返す．成功時の配置位置はヒートマップ $\mathrm{SM} \in \mathbb{R}^{H_I \times W_I}$ に累積する（付録 A.2）．

最適化フェーズでは，探索フェーズで得た配置位置 (h_0, w_0) にパッチ δ を重畳する．頑健性のため，EOT（Expectation over Transformation）[12] に基づく確率的変換（スケール，コントラスト・明るさ・ノイズ，回転 $\pm 180°$・せん断）をパラメータ ξ として施す（詳細な定式化は付録 A.6）．重畳後の画像を $\tilde{x}_t$ と表す．当該サイクル内では配置位置 (h_0, w_0) と変換パラメータ ξ の両方を固定し，探索フェーズに戻るたびに両方とも再サンプリングされる（付録 A.6）．

重畳後の画像 $\tilde{x}_t$ を用いてロールアウトを実行すると，VLA モデルは各推論ステップで行動チャンクを出力する．ロボットを稼働停止させるという目的はロールアウト全体を通じて行動系列の時間変化が小さいことを要求するため，L 回の推論で得られた行動チャンクを時間方向に連結し，行動系列 $A(\delta) \in \mathbb{R}^{M \times d}$ （$M = H_a \cdot L$）を構成する．ここで L はロールアウトあたりの VLA 推論（行動チャン

© 2026 Information Processing Society of Japan

ク生成）回数であり，1 回の推論で長さ H_a の行動チャンクが出力される．この行動系列 $A(\delta)$ の時間差分ノルムを停止損失 $\mathcal{L}_{\text{freeze}}$ として定義する．

$$\mathcal{L}_{\text{freeze}}(\delta;\xi) = \left(\sum_{m=1}^{M-1} \left\| A_{m+1} - A_m \right\|_2^2 \right)^{1/2}. \qquad (1)$$

最適化問題は変換 ξ の期待値のもとで停止損失を最小化する形で与えられる．

$$\min_{\delta \in [0,255]^{H_p \times W_p \times 3}} \quad \mathbb{E}_\xi \left[\mathcal{L}_{\text{freeze}}(\delta;\xi) \right]. \qquad (2)$$

すなわち本手法は，ロボットを一定姿勢に保持させ稼働停止を誘発することを意図する．この最小化が実際に稼働停止をもたらすかは 6 章で検証する．符号付き勾配降下（I-FGSM 型 [13]）で第 k 反復のパッチを更新する．

$$\delta^{(k+1)} = \text{clip}_{[0,255]} \Big(\delta^{(k)} - \alpha \, \text{sign}\big(\nabla_\delta \mathcal{L}_{\text{freeze}} \big) \Big), \qquad (3)$$

ここで $\alpha = 1$，初期パッチ $\delta^{(0)}$ は中間輝度 128 の一様パッチとする．探索フェーズで配置位置を得るまでロールアウトを繰り返し，その位置で最適化フェーズを K ロールアウト連続実行するサイクルを繰り返す（$K = 10$）．反復回数が既定値に達すると生成を終了する．疑似コードは付録 A.6 に示す．

4.3 評価条件

前節の手法で生成した単一の敵対的パッチ δ を，以下の 2 つの条件で評価する．**条件 A（画像への直接貼り付け）**：カメラ画像 x_t のパッチ領域を δ で直接置き換えて評価する（式 (A.2) においてすべての変換（ϕ, ψ）を恒等とした場合に相当し，$\tilde{x}_t = \Pi(x_t, \delta; h_0, w_0)$ と書ける）．すなわち，生成時に用いた EOT による確率的変換は評価時には適用せず，学習済みのパッチをそのまま画像へ合成する．これは，パッチが理想的に画像へ反映された場合の攻撃効果を測る条件である．**条件 B（シミュレータ内オブジェクトとしての配置）**：同じパッチ δ を，Isaac Sim のシーン内に配置した薄板状の平面オブジェクト（50×50 のパッチに対応する大きさ）の表面テクスチャとして与え，シミュレータのレンダリングを介してカメラ画像に反映させたうえで評価する．シーン構成 $\mathcal{S}$，レンダリング作用素 R，時刻に依存するシーン状態 ζ_t を用いて $\tilde{x}_t = R(\mathcal{S}, \delta; \zeta_t)$ と表され，パッチの見え方（射影・陰影・部分遮蔽）はレンダリングによって決まり，視点や照明の影響を自然に受ける．パッチはテーブル上に，傾けずに（回転を加えずに）配置した．条件 B では，生成フェーズ（画像上）で最適化したパッチを再最適化せずにそのまま用いる点が重要であり，これにより，画像上で得られた攻撃効果がレンダリングを経た物理的な配置に対しても転移するか（現実的な脅威となりうるか）を評価する．

5. 実験設定

5.1 対象システムと環境

攻撃対象は，Isaac GR00T N1[4] によって制御される人型ロボット GR-1 （Fourier 社，Isaac Lab[14] 上の `GR1T2` 構成）[*2]である．評価タスクは，IsaacLabEvalTasks[15] が提供する，テーブル上の排気パイプを把持しソーティングビンへ配置する両手操作タスク（Exhaust Pipe Sorting）とした．視覚入力はロボット頭部視点のカメラ（160×256, RGB）画像であり，敵対的パッチは条件 A ではこの画像に合成し，条件 B ではテーブル上の平面オブジェクトのテクスチャとして与える．

シミュレーションは Isaac Sim 5.1.0（Isaac Lab 2.3.2）上で行い，物理演算の時間刻みを 1/100 秒（100 Hz, decimation= 5，実効制御周波数 20 Hz）とした．環境設定上のエピソード長は 20.0 秒（タイムアウトによる終了を含む最大 400 制御ステップ）であるが，評価スクリプトはこの終了条件をすべて無効化した上で，各ロールアウトにつき $L = 20$ 回の VLA 推論という固定回数のみでロールアウトを完結させる（この値は IsaacLabEvalTasks[15] の公式ドキュメントが Exhaust Pipe Sorting タスクの例として示す既定値であり，同ドキュメントによれば `rollout_length` は評価の高速化のため通常 20–30 の範囲に設定される）．1 回の推論につき，出力された行動チャンクのうち `num_feedback_actions`= 16（$= H_a$）個の行動をすべて実行するため，1 ロールアウトあたりの制御ステップ数は $H_a \times L = 320$（シミュレーション内時間で約 16 秒相当）であり，環境設定上の上限より短い．これはシミュレーション内での経過時間であり，実際の計算に要するウォールクロック時間（約 30 秒，5.2 節）とは異なる．レンダリングは DLAA とした．各ロールアウト開始時に排気パイプの初期位置を x, y 方向 ± 0.01 の範囲でランダム化した．実験は NVIDIA RTX A5000 （24 GB）2 枚搭載マシン（Ubuntu 22.04，CUDA 13.0）上で実施した．詳細設定は付録 A.1 に示す．

5.2 攻撃・最適化の設定

攻撃対象の VLA モデルは，GR00T N1（2B パラメータ）を排気パイプの把持・配置タスクでファインチューニングしたチェックポイントである．敵対的パッチのサイズは 50×50 画素とした．パッチ生成は，4.2 節で述べた探索・最適化フェーズを交互に実行する手続きにより行った．探索フェーズではダミーパッチを用いて画像全体からランダムに選んだ位置・スケール・回転・せん断でタスクが成功する配置を探し，成功した位置・変換を最適化フェーズへ引き継いだ．最適化フェーズでは，式 (3) の符号付き勾

[*2] 文献 [14] は Isaac Lab の前身である Orbit の論文であり，Isaac Lab 公式からもこの論文の引用が案内されている．

© 2026 Information Processing Society of Japan

配降下により，ステップ幅 $\alpha = 1$ （画素値スケール）でパッチを更新した．初期パッチは中間輝度 128 の一様なパッチとし，スケール・色調・アフィン変換のパラメータは探索フェーズごとに再サンプリングし，最適化フェーズの 1 サイクル（K ロールアウト）内では固定した．最適化フェーズは $K = 10$ ロールアウトごとに探索フェーズへ戻した．各ロールアウトの長さは $L = 20$，行動チャンク長は $H_a = 16$ とし，最適化フェーズにおけるパッチ更新の回数は 10,001 回，探索フェーズを含めた総ロールアウト数は 11,612 回であった（探索フェーズは約 1,611 ロールアウト）．パッチ生成時は乱数シードを固定せず，EOT によるパッチ変形のランダム性を各ロールアウトで確保した（評価時のシード設定については 7.5 節を参照）．

1 ロールアウトあたりの所要時間は約 30 秒であり，総ロールアウト数 11,612 回に要した時間はおよそ 97 時間（約 4 日）と見積もられる．並列環境数は 1 として実行したが，Isaac Sim は複数環境の並列実行に対応しており，並列化による探索の高速化が可能である．

5.3 評価指標

攻撃の効果はタスクの成否によって評価する．各ロールアウトの成功判定にはシミュレータが提供する成功条件（`task_done_exhaust_pipe`）を用いる．これは，排気パイプ先端の座標がソーティングビンの領域内に収まっているかを基準とする判定であり，先端がわずかに領域外へはみ出した場合は，把持・運搬がおおむね成功していても失敗と判定される（6.2 節）．成功判定はロールアウト終了時点（$L = 20$ 回の推論を終えた時点）の状態に対して行い，途中で一時的に条件を満たしたかどうかは問わない．複数ロールアウトにわたるタスク成功率を主たる指標とする．本研究の攻撃は稼働停止を意図していた（4.2 節）が，その定量的判定基準は確立されていないため，稼働停止の有無は評価時の挙動観察に基づく定性的な検討として別途扱う（6.2 節）．

5.4 ベースライン・比較条件

攻撃の効果を切り分けるため，(1) 無攻撃条件（クリーン）及び (2) 最適化を行わないランダムなパッチ，を対照として用いる．各条件の試行数は $N = 100$ とした．ランダムパッチは，評価条件 A（画像への直接貼り付け）・評価条件 B （オブジェクト配置）のいずれにおいても，評価開始時に一様乱数（$U(0, 255)$）で 1 枚生成し，以降同一条件下の全ロールアウトで固定して用いる方式で統一した．すなわち，ロールアウトごとに再生成するのではなく，1 回の評価実行につき固定の 1 枚を使い回す．

表 1 評価条件 A・B におけるタスク成功率（$N = 100$）
Table 1 Task success rate under Conditions A/B ($N = 100$).

条件	条件 A（画像）	条件 B（配置）
クリーン（無攻撃）	78/100（78%）	—†
ランダムパッチ	64/100（64%）	66/100（66%）
敵対的パッチ（提案）	5/100（5%）	30/100（30%）

† クリーンは条件 A・B で設定が同一のため条件 A の値を共通結果とする．稼働停止の有無は 6.2 節で扱う．

6. 実験結果

6.1 主実験の結果：評価条件 A・B の比較

生成したパッチについて，評価条件 A（画像への直接貼り付け）と評価条件 B （シミュレータ内オブジェクト配置）のそれぞれにおいて，クリーン・ランダムパッチ・敵対的パッチのタスク成功率を $N = 100$ で評価した（**表 1**）．クリーン条件の成功率は 78%（78/100）であった．評価条件 A では，敵対的パッチにより成功率が 5% まで低下し，ランダムパッチは 64% であった．評価条件 B では，敵対的パッチにより 30% まで低下し，ランダムパッチは 66% であった．

これらの結果から，敵対的パッチは条件 A・B のいずれでもタスク成功率を明確に低下させ，攻撃としての効果を持つことが確認された．Fisher の正確検定によるクリーン条件との比較では，条件 A で $p \approx 2.2 \times 10^{-28}$，条件 B で $p \approx 1.0 \times 10^{-11}$ であり，いずれも有意な差が認められた．一方，ランダムパッチについては，条件 A では $p \approx 0.042$ と有意水準 5% で有意であるものの低下幅は 14 ポイントにとどまり，条件 B では低下幅が 12 ポイント，$p \approx 0.083$ であり有意差が認められない．いずれも敵対的パッチの低下幅（それぞれ 73 ポイント，48 ポイント）とは大きく異なる．すなわち，パッチの存在（遮蔽）そのものによる影響は限定的であり，タスク成功率の大幅な低下はパッチの内容（模様）に起因すると考えられる．なお，本研究では計 14 件の Fisher の正確検定を行っており，Bonferroni 補正を適用すると有意水準は $0.05/14 \approx 0.0036$ となるが，敵対的パッチに関する検定はいずれもこの補正後の水準でも有意である（補正により非有意となるのは上記の条件 A ランダムパッチのみである）．この対比の代表例を，各評価条件における終了時点のカメラ画像として図 A-2（付録 A.5）に示す．条件 A と条件 B の差については 7.2 節で詳しく考察する．

6.2 定性的観察

主実験（6.1 節）における評価時の挙動を確認したところ，敵対的パッチによってタスク成功率が低下した評価条件 A・B のいずれにおいても，攻撃を受けた GR-1 が一定姿勢で静止する（稼働停止する）挙動は観測されなかった．

© 2026 Information Processing Society of Japan

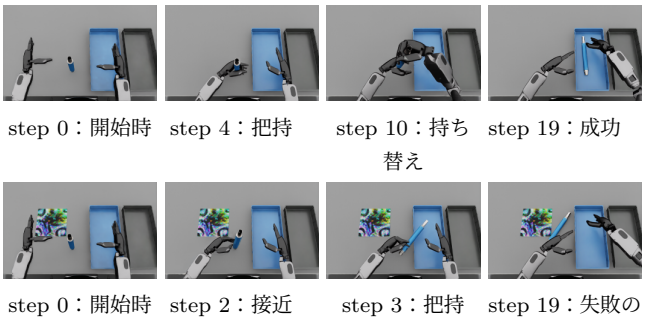


図 2 GR-1 の挙動の比較（評価条件 B）．上段：クリーン（eval01，把持成功）．下段：敵対的パッチ（eval02，把持失敗）．

Fig. 2 GR-1's behavior under Condition B (top: clean; bottom: adversarial).

評価条件 B におけるクリーン条件（eval01）と敵対的パッチ条件（eval02）は異なるロールアウトであるが，それぞれの序盤・中盤・終盤に対応する局面を並べて比較したところ，次のような差異が観察された（図 2）．クリーン条件では，ロールアウト序盤でロボットが対象物（排気パイプ）に接近して確実に把持し，両手の間でパイプを持ち替えてソーティングビンへと運搬し，最終的にパイプがビン内に収まってタスクが成功した．一方，敵対的パッチ条件では，ロボットは同様に対象物へ手を伸ばし接近する動作を示したものの，グリッパーはパイプに触れる，あるいは近づくのみで，これをしっかりと把持することはなかった．その後もグリッパーは対象物を保持しない状態のまま，ロールアウトの最終ステップに至るまでソーティングビン付近に留まった．この経過は，本手法の攻撃が，対象物に接近し運搬先へ向かうという大まかな動作の遂行は妨げない一方で，対象物を確実に把持するという精密な動作を局所的に阻害していることを示唆する．稼働停止とは異なり，ロボットは目的に沿った動作を継続しながらも，把持そのものが成立しないことでタスクが失敗しているという点が特徴的である．

他の評価条件についても失敗事例を確認したところ，条件やタスクに応じて複数の異なる失敗態様（把持失敗，先端の位置ずれ，運搬中の落下）が観察され，単一の失敗態様に限定されないことが分かった．各評価条件における終了時点の様子は付録 A.5 の図 A-2 に，失敗数と失敗態様の詳細な内訳は付録 A.4 にそれぞれ示す．

7. 考察

7.1 稼働停止の有無と実際の結果との関係

本研究の攻撃は，停止損失 $\mathcal{L}_{\text{freeze}}$（式 (1)）の最小化を通じて，行動系列の時間変化を抑え，ロボットを稼働停止させることを意図している（4.2 節）．この意図が実際に達成されたかを確認するため，まず現行の 2 段階アルゴリズム（探索・最適化フェーズの交互実行，4.2 節）による

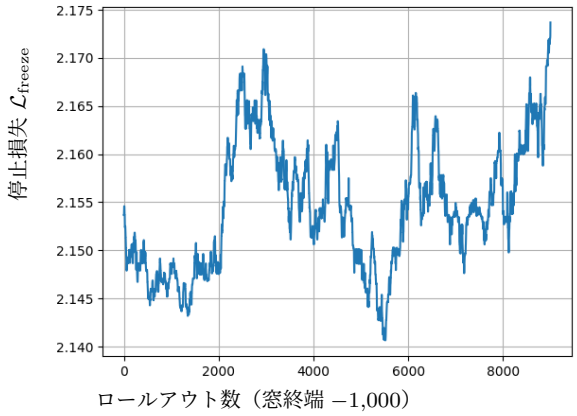


図 3 最適化フェーズにおける停止損失の推移（直近 1,000 ロールアウト移動平均）

Fig. 3 Freeze loss trend (rolling mean, last 1,000 rollouts).

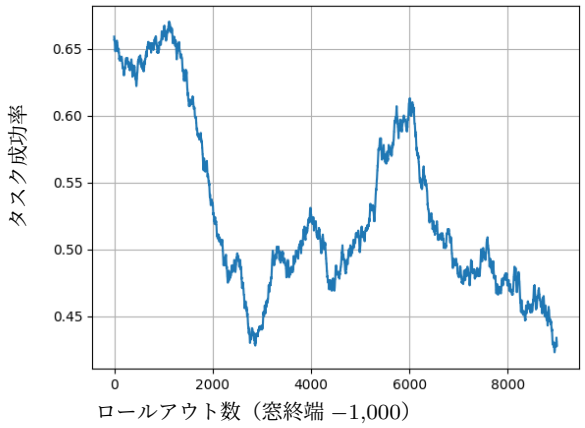


図 4 最適化フェーズにおけるタスク成功率の推移（直近 1,000 ロールアウト移動平均）

Fig. 4 Task success rate trend (rolling mean, last 1,000 rollouts).

パッチ生成の過程を観察した．図 3 に，最適化フェーズにおける停止損失 $\mathcal{L}_{\text{freeze}}$（式 (1)）の直近 1,000 ロールアウト移動平均の推移を，図 4 に，同じくタスク成功率の直近 1,000 ロールアウト移動平均の推移を示す．移動平均には直近 1,000 回分のデータを要するため，横軸には窓終端のロールアウト数から 1,000 を引いた値（すなわち 0 始まり，最大 9,001）を用いている（探索フェーズは含まない）．

停止損失は 2.14 から 2.175 程度の範囲で推移し，明確な低下傾向は見られず，終盤でむしろ観測範囲内の最高値付近に達した．一方，タスク成功率は単調な低下ではないものの，開始時の 0.65 から 0.67 程度から，初期段階で 0.43 程度まで低下し，中盤で 0.60 程度まで一時的に回復した後，終盤には再び 0.43 から 0.46 程度まで低下した．すなわち，停止損失が低下していないにもかかわらずタスク成功率は全体として低下しており，行動系列の時間変化を小さくするという目的関数の設計が，タスク成功率の低下という効果と必ずしも単純に対応しないことを示している．

© 2026 Information Processing Society of Japan

一方，主実験（6.1 節）では，敵対的パッチによってタスク成功率が明確に低下することが確認された．論点は，この低下が意図通りの機序（行動の凍結）によるものか，異なる機序によるものか，という点である．評価時にも稼働停止する挙動は観測されなかった（6.2 節）．

すなわち，本研究の攻撃は，意図した稼働停止を伴うことなくタスク成功率の低下という効果をもたらしていた．最適化フェーズで損失が低下しなかったという観察と，評価時に稼働停止が観測されなかったという観察は互いに整合しており，行動系列の時間変化を抑えるという目的関数の設計は，ロボットを実際に静止させることには成功しなかった一方で，何らかの形でタスク遂行を妨げる効果を偶発的に獲得したと考えられる．

なお，生成時終盤のタスク成功率（0.43–0.46 程度）と，主実験（6.1 節）における評価条件 A の敵対的パッチのタスク成功率（5%）との間には明確な乖離がある．この乖離には複数の要因が考えられる．第一に，生成時のこの値は EOT による確率的変換（スケール・回転・せん断，4.2 節）を適用した状態での移動平均であるのに対し，評価条件 A ではパッチをそのまま（変換を加えずに）画像へ合成しており，両者は同一の条件を測定したものではない．その他，探索フェーズの選択バイアス（成功した位置と変換のみを引き継ぐ）およびデフォルト位置自体の選定バイアス（7.5 節）も要因として考えられ，これらは位置特異性の機序が未解明であることとも整合する．

評価時の定性的観察（6.2 節）は，この乖離の機序を考える手がかりを与える．すなわち，攻撃は動作全体を凍結させるのではなく，対象物を確実に把持するという精密な動作を局所的に阻害している可能性が考えられる．この仮説は，配置位置感度の検証（7.3 節）で得られた知見によって補強される．パッチが把持対象（排気パイプ）の近傍に位置し両者が視覚的に隣接・重畳する配置では攻撃効果が強く維持される一方，パッチを把持対象から離れた位置へ移動させると効果がほぼ消失した．これは，本手法の攻撃が把持対象の視覚的な位置認識を局所的に阻害することでタスクを妨害しているという解釈と整合する．

7.2 評価条件 A と条件 B の比較

画像への直接貼り付け（条件 A）と，同一パッチをオブジェクトとして配置しレンダリングを介して評価した条件 B（表 1）を比較すると，敵対的パッチはいずれの条件でもタスク成功率を低下させたが，低下幅には明確な差があった．クリーン条件（78%）からの低下幅は，条件 A で 73 ポイント，条件 B で 48 ポイントであった．すなわち，画像上で最適化したパッチをレンダリングを経た物理的配置へ転移させると，射影・陰影・部分遮蔽といったレンダリング由来の要因により効果が一定程度減衰すると考えられる．それでも条件 B で 48 ポイントもの低下を示した点は注目に値する．条件 B のランダムパッチによる低下幅が 12 ポイント（66%）にとどまることから，この低下はパッチによる単純な遮蔽ではなくパッチの内容（模様）に起因すると考えられ，画像上でのみ最適化された攻撃が，レンダリングを介した物理的配置というより現実的な脅威シナリオに対して一定の転移性を持つことが示唆される．

7.3 ロバスト性・汎化性の検証

主実験で確認された攻撃効果の頑健性・一般性を明らかにするため，(1) 光源強度への頑健性，(2) 配置位置への依存性，及び (3) タスクを越えた転移性，を検証した（各条件 $N = 100$，詳細は付録 A.3）．光源強度への頑健性については，単一の環境条件に限定されない比較的一般的な効果が示唆された．配置位置への依存性は対照的で，デフォルト位置（および下方向近傍）では効果が強く維持される一方，左・上方向へわずかにずらすだけで効果がほぼ消失した．タスクを越えた転移性の検証では，転移先の nutpouring タスクにおいてもパッチを対象物（ボウル）の近傍に配置しており，転移が成立した事実は，配置位置への依存性で観察された「把持対象と視覚的に近接・重畳する配置でのみ強い効果を発揮する」という位置特異的な性質と矛盾しない．すなわち，本研究の攻撃は，環境条件の違いには比較的頑健である一方，パッチと把持対象との視覚的な近接・重畳という位置関係には強く依存しており，この位置関係が満たされる限りにおいてタスクを越えて転移しうる，という統一的な理解が可能である．ただし，これは現象レベルでの規則性であり，生成時に多数の配置位置で学習していたにもかかわらずこの位置特異性が生じた機序そのものは未解明である（7.5 節）．

7.4 レッドチーミング枠組みとしての意義

タスク成功率の低下という攻撃効果は，実機を用いずシミュレータ上で 11,612 回（総計約 97 時間）に及ぶ探索を行った結果として観測できたものである．同規模の探索を実機で行うことは現実的でなく，この点が提案枠組みの有効性を支持する．本研究の知見は，攻撃研究には目的関数をタスクの意味的成否に直接結びつける重要性と配置位置に対する頑健化の必要性を，防御研究には把持対象近傍の不審な視覚パターンの検知や，タスクを越えた転移性から示唆されるモデルの視覚表現自体の頑健化（敵対的学習等）の有効性を示唆する．本研究では，攻撃モジュールが生成した摂動を対象システムに注入し，評価指標で挙動を測定し次の摂動生成へ反映するという，攻撃・評価の 2 機能からなる生成ループを扱ったが，将来的には，攻撃・評価に加えて対策（防御手法の提案・適用）を担うエージェントを組み込み，脆弱性の発見から対策の適用までを一貫して自動化するエージェント型の枠組みへと拡張することが考えられる．

© 2026 Information Processing Society of Japan

7.5 限界と脅威の妥当性

本研究の限界は次の通りである．単一のロボット・VLAモデルを対象とし，2 タスクは同一制御方式による近縁のタスクであり，他のロボット・モデル・タスクへの一般性は未検証である．停止損失という単一の目的関数のみを検討し，意図した稼働停止には至らなかった（7.1 節）．攻撃効果は把持対象との視覚的近接性に強く依存し，あらゆる配置で汎用的に効くものではない．また，評価に用いたデフォルト位置は複数の候補位置を試行した上で明確な攻撃効果が確認できたものを選定しており，主実験（表 1）の成功率は，この探索的な位置選定を経た，攻撃にとって比較的有利な条件下での値である．評価時には特定の位置に強く依存する挙動が観測されており，その機序は説明できておらず，今後の重要な検証課題である（7.3 節）．稼働停止の有無は定性的観察にとどまり定量的基準は設けていない．成功位置ヒートマップの解釈にはサンプリング密度との交絡が残る（付録 A.2）．実験はすべて Isaac Sim 上で完結し実機検証は行っていない．評価スクリプトでは同一シード値を指定しているにもかかわらず結果にばらつきが生じており，原因は RNG 状態の進行等が考えられるが特定できていない（詳細は付録 A.1 を参照）．並列環境数は 1 として実行し複数環境での並列実行は検証していない．

8. おわりに

本研究では，Isaac Sim 上でフィジカル AI のレッドチーミングを行う枠組みを提案し，その最初の検証として，Isaac GR00T N1 を搭載した人型ロボット GR-1 を対象とした敵対的パッチ攻撃を実施した．実験の結果，画像貼り付けとオブジェクト配置のいずれの評価条件でもタスク成功率が明確に低下する一方，攻撃が意図した稼働停止は評価時に観測されず，異なる経路でタスクを妨害していることが明らかになった．この検証を 11,612 回に及ぶ反復探索としてシミュレータ上で安全に実施できたことは，提案枠組みの有効性を示すものである．今後は，本研究の限界（7.5 節）に沿って，対象ロボット・VLA モデル・タスクの多様化，目的関数の拡張，稼働停止の定量的判定基準の確立，攻撃・評価に加え対策（防御手法の提案・適用）までを一貫して自動化するエージェント型の枠組みへの拡張，sim-to-real 評価に取り組み，本枠組みをより広範な脅威の発見と防御手法の確立に役立てていきたい．

参考文献

[1] Perez, E., Huang, S., Song, F., Cai, T., Ring, R., Aslanides, J., Glaese, A., McAleese, N. and Irving, G.: Red Teaming Language Models with Language Models, Proc. 2022 Conf. on Empirical Methods in Natural Language Processing (EMNLP), pp. 3419–3448 (2022).

[2] NVIDIA: NVIDIA Isaac Sim (online), 入手先 ⟨https://developer.nvidia.com/isaac/sim⟩ (2026.08.04).

[3] Brown, T. B., Mané, D., Roy, A., Abadi, M. and Gilmer, J.: Adversarial Patch, arXiv:1712.09665 (2017).

[4] NVIDIA et al.: GR00T N1: An Open Foundation Model for Generalist Humanoid Robots, arXiv:2503.14734 (2025).

[5] Wang, T., Han, C., Liang, J., Yang, W., Liu, D., Zhang, L. X., Wang, Q., Luo, J. and Tang, R.: Exploring the Adversarial Vulnerabilities of Vision-Language-Action Models in Robotics, Proc. IEEE/CVF Int. Conf. on Computer Vision (ICCV), pp. 6948–6958 (2025).

[6] Xu, H., Koh, Y. S., Huang, S., Zhou, Z., Wang, D., Sakuma, J. and Zhang, J.: Model-agnostic Adversarial Attack and Defense for Vision-Language-Action Models, arXiv:2510.13237 (2025).

[7] Lu, H., Yu, Y., Yang, Y., Yi, C., Zhang, Q., Shen, B., Kot, A. C. and Jiang, X.: When Robots Obey the Patch: Universal Transferable Patch Attacks on Vision-Language-Action Models, Proc. IEEE/CVF Conf. on Computer Vision and Pattern Recognition (CVPR) (2026).

[8] Chen, J., Huang, S., Du, J., Chen, S., Tian, Y., Wei, M., Yu, C. and Yin, Z.: Tex3D: Objects as Attack Surfaces via Adversarial 3D Textures for Vision-Language-Action Models, arXiv:2604.01618 (2026).

[9] Wang, X., Li, J., Weng, Z., Wang, Y., Gao, Y., Pang, T., Du, C., Teng, Y., Wang, Y., Wu, Z., Ma, X. and Jiang, Y.-G.: FreezeVLA: Action-Freezing Attacks against Vision-Language-Action Models, arXiv:2509.19870 (2025).

[10] Liu, B., Zhu, Y., Gao, C., Feng, Y., Liu, Q., Zhu, Y. and Stone, P.: LIBERO: Benchmarking Knowledge Transfer for Lifelong Robot Learning, Advances in Neural Information Processing Systems, Vol. 36, pp. 44776–44791 (2023).

[11] Todorov, E., Erez, T. and Tassa, Y.: MuJoCo: A physics engine for model-based control, Proc. IEEE/RSJ Int. Conf. on Intelligent Robots and Systems (IROS), pp. 5026–5033 (2012).

[12] Athalye, A., Engstrom, L., Ilyas, A. and Kwok, K.: Synthesizing Robust Adversarial Examples, Proc. 35th Int. Conf. on Machine Learning (ICML), pp. 284–293 (2018).

[13] Kurakin, A., Goodfellow, I. and Bengio, S.: Adversarial Examples in the Physical World, ICLR 2017 Workshop (2017), arXiv:1607.02533.

[14] Mittal, M., Yu, C., Yu, Q., Liu, J., Rudin, N., Hoeller, D., Yuan, J. L., Singh, R., Guo, Y., Mazhar, H., Mandlekar, A., Babich, B., State, G., Hutter, M. and Garg, A.: Orbit: A Unified Simulation Framework for Interactive Robot Learning Environments, IEEE Robotics and Automation Letters, Vol. 8, No. 6, pp. 3740–3747 (2023).

[15] NVIDIA: IsaacLabEvalTasks: Benchmarking GR00T N1 Policy in Isaac Lab (online), 入手先 ⟨https://github.com/isaac-sim/IsaacLabEvalTasks⟩ (2026.08.04).

[16] Oonishi, K. and Nakai, T.: Universal Shape of Strong Remote Adversarial Patches for Object Detection with Convolutional Neural Networks, Proc. IEEE/CVF Conf. on Computer Vision and Pattern Recognition Workshops (CVPRW), pp. 4369–4379 (2025).

9. 研究倫理

本研究の実施・執筆にあたっては，CSEC 研究会が公開する「サイバーセキュリティ研究倫理に関するチェックリ

© 2026 Information Processing Society of Japan

スト」[*3] に基づき，以下の観点から倫理的配慮を検討した．

基本的確認：著者らは情報処理学会の倫理綱領を確認した上で本研究を実施している．

機微な情報の取り扱い：本研究は Isaac Sim 上のシミュレーション環境のみを対象としており，実験参加者は存在せず，個人を特定可能な情報（PII）やその他の機微な情報は一切取り扱っていない．

ネガティブな影響への配慮：本研究は，フィジカル AI の安全性向上を目的とした防御的なレッドチーミングであり，実在の製品を無断で貶める意図や，特定企業の評価を損なう意図はない．評価対象として，Fourier Intelligence 社の人型ロボット GR-1，および NVIDIA 社の Isaac Sim・Isaac GR00T N1 という実在の商用・公開製品の名称を用いているが，これは，第三者による再現性と科学的検証可能性を確保するために対象を明示することが不可欠であると判断したためであり，これらの企業や製品を不当に貶める意図によるものではない．すべての実験は Isaac Sim というシミュレーション環境上で完結しており，実機や第三者に対する直接的な危害は生じていない．

本研究で明らかになった脆弱性の性質（学習で明示的に扱っていない配置位置や環境条件のもとで攻撃が効果を持ちうること）は，特定の製品固有の実装上の欠陥を指摘するものではなく，VLA モデルを用いたロボット制御一般に内在しうる性質を示すものであると考えられる．したがって，本研究の対象以外の製品・サービスにも同様の脆弱性が存在しうる可能性があり，論文全体を通じて特定の製品のみを名指しで批判することのないよう配慮した．なお，対象モデル・ロボットの提供元への事前連絡は，投稿時点では行っていない．本研究は特定製品固有の実装上の欠陥ではなく，公開されているシミュレーション環境と公開モデルを用いて確認された，VLA モデルを用いたロボット制御一般に内在しうる性質を報告するものであり，個別製品の脆弱性報告には該当しないと判断したためである．ただし，提供元から問い合わせがあった場合には本研究の詳細を誠実に共有するほか，必要に応じて NVIDIA PSIRT 等の窓口を通じた情報提供も行う用意がある．

攻撃の再現可能性についても検討した．本研究で用いた敵対的パッチの生成アルゴリズム（アルゴリズム 1）は，攻撃手法の学術的な理解と今後の防御研究に資することを目的として論文中に記載しているが，最終的に生成された学習済みパッチそのもの，および攻撃を即座に実行可能にする実装コードは公開しない方針である．すなわち，ソースコード・学習済みパッチ・その他の成果物は，本稿の投稿・採録後を含め非公開とする．

[*3] https://www.iwsec.org/csec/ethics/checklist.html

表 A-1 実験環境
Table A-1 Experimental environment.

項目	内容
シミュレータ	Isaac Sim 5.1.0 / Isaac Lab 2.3.2
評価基盤	IsaacLabEvalTasks[15]
VLA モデル	Isaac GR00T N1（`GR1` embodiment）
対象ロボット	GR-1（Fourier 社，`GR1T2`）
タスク	排気パイプの把持・配置
カメラ入力	頭部視点，160 × 256，RGB
物理ステップ	1/100 s（100 Hz），decimation = 5
環境設定エピソード長	20.0 s（最大 400 ステップ，評価時は終了条件を無効化）
ロールアウト長	$L = 20$ 回の推論，320 制御ステップ（約 16 s 相当）
レンダリング	DLAA
OS ／実行環境	Ubuntu 22.04，Python 3.11.15（Anaconda）
GPU	NVIDIA RTX A5000（24 GB）×2
ドライバ／ CUDA	Driver 580.126.20, CUDA 13.0

付　　録

A.1 実験環境の詳細

5.1 節で述べた実験環境の詳細な設定を**表 A-1** に示す．

評価時の乱数シードについて：パッチ生成時とは異なり，評価スクリプトでは各ロールアウトの開始時に同一のシード値を指定して `env.reset(seed=args.seed)` を呼んでいる．しかし，シード引数が RNG の状態を毎回同じ初期状態へ巻き戻すとは限らず，先行するロールアウトでの推論・レンダリング等に伴う乱数消費によって RNG の状態が進んでいる場合，同一のシード値でも得られる乱数列は呼び出しごとに異なりうる．この点と結果のばらつきとの関係は切り分けられておらず，原因は特定できていない．今後は `env.reset()` をシード非指定で呼び出し，各ロールアウトを独立にサンプリングすることでこの点を明確化する．

A.2 探索フェーズによる成功位置分布の詳細

探索フェーズにおいて，ダミーパッチを置いてタスクが成功した回数を画像平面上に累積したヒートマップ SM を図 A-1 に示す．これは，各ロールアウトでダミーパッチを置いた位置 (h_0, w_0) を左上とする領域のうち，タスクが成功したロールアウトに対応する画素値を加算した累積成功回数のマップであり，明るい画素ほど成功回数が多かった位置を表す．

解釈上の留意点：本ヒートマップは成功時の累積回数のみを記録しており，各画素がダミーパッチに覆われた総試行回数は記録していないため，画素ごとの成功率には正規化されていない．探索フェーズでは配置位置のサンプリング後に回転 $\theta \sim U(-180°, 180°)$・せん断を含むアフィン変

© 2026 Information Processing Society of Japan

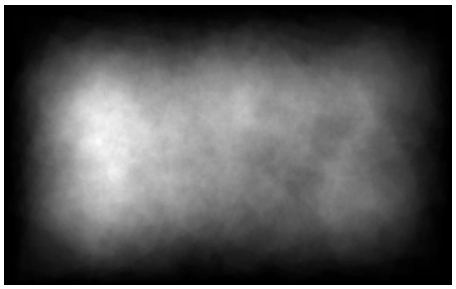


図 A-1 探索フェーズにおけるタスク成功位置の累積ヒートマップ（白：成功回数が多い，黒：成功回数が少ない）

Fig. A-1 Heatmap of task-successful patch placements (search phase).

換を適用するため（4.2 節），画像端に近い画素ほどダミーパッチが画像境界からはみ出しやすく，覆われる試行回数自体が少なくなる可能性がある．すなわち，画像端で成功回数が少なく見える傾向の一部は，その位置がタスク遂行を妨げやすいためではなく単にサンプリング密度が低いという幾何学的要因に起因する可能性があり，両者は区別できない．また本ヒートマップは絶対座標に基づく分布であり，7.3 節で示唆された相対的な視覚的近接性という解釈とは議論の水準が異なる．さらに，付録 A.3 で評価した配置位置は，デフォルト位置からのわずかなオフセットとして定めたものであり，本ヒートマップ上のどの領域に対応するかは重ね合わせによる確認を行っていない．したがって，本ヒートマップと配置位置感度の結果とを直接対応づけることは現状では困難であり，本図は探索フェーズにおける成功位置の分布を示すものとして提示する．

A.3 ロバスト性・汎化性検証の詳細

7.3 節に記載した 3 つの検証（環境変動への頑健性，配置位置への依存性，タスクを越えた転移性）の詳細な結果表と考察を示す．いずれも評価条件 B において $N = 100$ で実施した．

A.3.1 環境変動への頑健性

パッチ生成時の EOT はパッチ自体の色調変換とアフィン変換を対象としており，シーン全体の照明条件は一定（光源強度 3000）であった．すなわち光源強度は生成過程で一切変動していない要因である．この学習時に想定していない環境変動に対する頑健性を確認するため，光源強度 3 水準（500，3000，8000）× パッチ条件 3 種の全 9 通りで評価した．標準光源（3000）の結果は主実験（表 1）の値を用い，光源 500・8000 の条件を追加で実施した．結果を**表 A-2** に示す．

結果から，敵対的パッチはいずれの光源強度においてもクリーン条件と比べて成功率を大きく低下させることが確認された．Fisher の正確検定による p 値は，光源 500 で 2.2×10^{-33}，光源 3000 で 1.0×10^{-11}，光源 8000 で 9.6×10^{-9} であった．攻撃効果は生成時に想定していなかった光源変動に対して一定の頑健性を保っていると考えられる．なお，光源 8000 の失敗事例は，先端部分がわずかにビンの外へはみ出したために失敗と判定されるケースが多く，光源 500 や 3000 で見られた把持そのものの失敗とは異なる，より軽微な妨害であった．

表 A-2 評価条件 B における光源強度別のタスク成功率（$N = 100$）

Table A-2 Task success rate under Condition B by light intensity.

	光源強度		
条件	500	3000	8000
クリーン（無攻撃）	94%	78%†	72%
ランダムパッチ	94%	66%†	53%
敵対的パッチ（提案）	14%	30%†	31%

† 光源 3000（標準）の値は主実験（表 1）の結果を用いた．

表 A-3 評価条件 B における配置位置別のタスク成功率（$N = 100$）

Table A-3 Task success rate under Condition B by patch placement.

配置位置	敵対的パッチ	ランダムパッチ
デフォルト（左上）	30/100（30%）	66/100（66%）
やや下側	29/100（29%）	57/100（57%）
やや右側	37/100（37%）	58/100（58%）
やや左側	66/100（66%）	84/100（84%）
やや上側	87/100（87%）	84/100（84%）

一方，クリーン条件・ランダムパッチ条件の成功率自体も光源が明るくなるほど低下する傾向を示した．これはパッチの効果とは独立に光源条件そのものが VLA モデルのタスク遂行能力に影響することを示唆しており，攻撃効果の評価には各条件の基準成功率との差に注目する必要がある．クリーン条件を基準とした低下幅は 80，48，41 ポイント，相対的な低下率では 85，62，57% であり，いずれの光源条件でも攻撃が明確な妨害効果を持つ．

A.3.2 配置位置への依存性

評価時には，複数の候補位置を試行的に評価した上で明確な攻撃効果が確認できた位置（排気パイプの左上，eval02 で用いた位置，以下「デフォルト位置」）を基準として定めている．したがって，表 1・表 A-2 の値は攻撃にとって比較的有利な条件下でのものである（7.5 節）．このデフォルト位置への依存性を確認するため，配置位置を下・右・左・上へわずかにずらした 4 条件を追加で評価した．結果を**表 A-3** に示す．

結果から，敵対的パッチの効果は配置位置によって大きく変動することが明らかになった．デフォルト位置（30%），やや下側（29%），やや右側（37%）ではクリーン条件（78%）と比べて成功率が大きく低下した．Fisher の正確検定による p 値はそれぞれ 1.0×10^{-11}，3.7×10^{-12}，6.2×10^{-9} である．一方，やや左側（66%）およびやや上側（87%）で

© 2026 Information Processing Society of Japan

は p 値がそれぞれ 0.083，0.14 と有意差が認められず，攻撃効果はほぼ消失していた．

すなわち，本手法によって最適化されたパッチは画像上のあらゆる位置で汎用的に効くものではなく，デフォルト位置およびその近傍（下方向・右方向）でのみ強い効果を発揮する，比較的位置特異的な攻撃であると考えられる．なお，パッチ生成時には探索フェーズを経て約 1,000 箇所（10,001/K，5.2 節）の異なる配置位置で最適化フェーズが実行されており，特定の一位置に固定して学習されたわけではない．にもかかわらず評価時にこれほど強い位置特異性が観測された機序は十分に説明できておらず，今後の検証課題である（7.5 節）．

この位置依存性が敵対的パッチの内容（模様）に固有のものかを確認するため，ランダムパッチの成功率と比較した．ランダムパッチの位置による変動幅（27 ポイント）は敵対的パッチ（58 ポイント）よりも明らかに小さく，配置位置による成功率の大きな変動は単なる遮蔽位置の違いではなく，敵対的パッチの内容が特定の位置と強く結びついて最適化されていることに起因すると考えられる．ただし，ランダムパッチは評価条件ごとに個別に生成しており（5.4 節），この比較には配置位置の効果とパッチの個体差が分離できていない限界がある．

この位置依存性の理由を探るため，各配置位置における評価時のカメラ画像を確認した．デフォルト位置およびやや下側ではパッチが排気パイプのごく近傍に位置し視覚的に隣接あるいは一部重なる配置となっていた一方，やや左側およびやや上側では両者の間に明確な空白が生じ，パイプは遮蔽されず単独で視認できる状態であった．この観察は 6.2 節で確認した把持の阻害という失敗態様と符合する．すなわち，本研究で観察された位置依存性は，画像上の絶対的な座標そのものよりも，パッチと把持対象との相対的な視覚的近接・重なりの度合いに起因している可能性が高い．

A.3.3　タスクを越えた転移性

排気パイプの把持・配置タスク（exhaustpipesorting）で生成した敵対的パッチが，別タスクであるナット注入タスク（nutpouring，IsaacLabEvalTasks[15]）でも効果を持つかを確認した．同一のロボット・制御方式で構築された別タスクにおいて，当該タスク用のチェックポイントを用い，標準的な光源条件（3000）のもとでクリーン・ランダムパッチ・転移パッチ（再最適化なし）の 3 条件でタスク成功率を比較した．結果を**表 A-4** に示す．

結果から，nutpouring タスクにおいて，クリーン条件の成功率は 89%（89/100），ランダムパッチ条件は 94%（94/100）であり，Fisher の正確検定による p 値は 0.31 で，両者はほぼ同水準であった．一方，exhaustpipesorting タスク用に生成した敵対的パッチを nutpouring タスクにそのまま適用した転移パッチでは，成功率が 21%（21/100）まで低下し，クリーン条件から 68 ポイントという大きな低下が観測された．このときの p 値は 1.8×10^{-23} である．

表 A-4　評価条件 B における nutpouring タスクのタスク成功率（$N = 100$）

Table A-4　Task success rate under Condition B on the nutpouring task.

条件	タスク成功率
クリーン（無攻撃）	89/100（89%）
ランダムパッチ	94/100（94%）
転移パッチ（exhaustpipesorting 用）	21/100（21%）

この転移パッチは対象物であるボウルの真下に配置しており，把持対象と視覚的に近接する配置は exhaustpipesorting のデフォルト位置と同様である．したがって本結果は，7.1 節，7.3 節で述べた「把持対象との視覚的近接性が攻撃効果の鍵となる」という仮説と整合的であり，本研究の敵対的パッチが生成に用いたタスクに固有の視覚的手がかりではなく，把持対象との視覚的な近接・重畳というより一般的な位置関係に起因する脆弱性を突いている可能性が考えられる．ただしこの解釈は 1 条件のみの観察に基づく．

低下幅（68 ポイント）は同じパッチを exhaustpipesorting の条件 B で評価した場合（48 ポイント）よりも大きいが，両条件は基準成功率が異なる（89%，78%）ため，相対的な低下率で見ると nutpouring で 76%，exhaustpipesorting で 62% となり差はポイント差ほど大きくない．すなわち，攻撃対象タスクを変えても効果が大きく減衰しないと言える．

nutpouring タスクにおける失敗事例（eval13）では，ロボットが対象物（ボウル）を把持して運搬する途中でボウルを落下させ，結果としてボウルが秤に載せられずタスク失敗となるケースが多く観察された．これは exhaustpipesorting で観察された把持失敗とは異なり，把持自体は成立するものの運搬中に対象物を保持し続けられないという失敗態様である．すなわち，同一の敵対的パッチであっても適用先のタスクが異なれば具体的な失敗の現れ方も異なりうる．

A.4　失敗態様の詳細内訳

6.2 節で要約した失敗態様について，各評価条件における失敗数と観察された主な失敗態様の詳細を示す（**表 A-5**）．

表 A-5 から，把持対象の近傍にパッチが配置される条件（eval02，eval15）では把持そのものの失敗が主要である一方，光源強度や配置位置の違いにより攻撃の作用がやや弱まる条件（eval09，eval17，eval19，eval21）では，把持・運搬自体はおおむね成功しつつ対象物の先端がわずかに判定範囲の外へはみ出すという，より軽微な失敗態様が観察された．別タスクへの転移条件（eval13）では運搬中の落

© 2026 Information Processing Society of Japan

表 A-5　評価条件別の失敗数と主な失敗態様（$N = 100$）
Table A-5　Number of failures and predominant failure mode.

評価条件	失敗数	主な失敗態様
eval02（条件 B，デフォルト位置）	70/100	把持失敗
eval04（条件 A）	95/100	把持失敗 †
eval08（条件 B，光源 500）	86/100	把持失敗 †
eval09（条件 B，光源 8000）	69/100	先端の位置ずれ
eval13（条件 B，nutpouring 転移）	79/100	運搬中の落下
eval15（条件 B，やや下側）	71/100	把持失敗
eval17（条件 B，やや右側）	63/100	先端の位置ずれ
eval19（条件 B，やや左側）	34/100	先端の位置ずれ
eval21（条件 B，やや上側）	13/100	先端の位置ずれ

†eval02 と同様の失敗事例が多いことを確認したが，eval02 のようなフレーム単位の詳細な確認は行っていない．‡eval 番号は評価スクリプトの実行順に付与した連番（eval01–22）であり，本表に記載のない番号はクリーン条件およびランダムパッチ条件（表 1，付録 A.3 の表）に対応する．これらの条件は総じて成功率が高く，本表では敵対的パッチ条件を中心に失敗態様の分析対象とした．

下という異なる失敗態様が主要であった．

興味深いことに，光源・配置位置という異なる要因の変化であるにもかかわらず，攻撃効果が弱まる条件では一様に「先端の位置ずれ」という同一の失敗態様に至っている．とりわけパッチを把持対象から離した配置（eval19, eval21）では，失敗数は少ないもののその態様は把持失敗ではなく先端の位置ずれであった．これは，パッチが把持対象から遠ざかるにつれて攻撃の作用が「把持そのものを妨げる」段階から「タスク遂行の精度をわずかに損なう」段階へと連続的に弱まっていくと解釈できる．

A.5　ランダムパッチと敵対的パッチの比較

各評価条件について，ロールアウト終了時点（step 19）のカメラ画像を敵対的パッチとランダムパッチで対比した代表例を図 A-2 に示す．敵対的パッチでは把持に失敗し，あるいは配置精度が損なわれている一方，ランダムパッチでは同一の配置・環境条件下でもタスクが正常に完了している様子が見て取れる．

A.6　敵対的パッチ生成アルゴリズムの詳細

4.2 節で述べたパッチ生成の詳細な定式化と手続きを示す．

A.6.1　変換パラメータの定式化

最適化フェーズでは，まずスケール s による拡大・縮小（バイリニア補間）を行い，続いてコントラスト c，明るさ b，画素ごとの加法ノイズ n による光学的変換 ϕ を適用する．

$$\phi(\delta; s, c, b, n) = \mathrm{clip}\Big(\tfrac{\mathrm{resize}(\delta; s)}{255}\, c + b + n,\ 0,\ 1\Big) \cdot 255, \tag{A.1}$$

ここで $\mathrm{resize}(\cdot; s)$ はスケール $s \sim U(0.8, 1.2)$ によるバイリニア補間であり，$c \sim U(0.8, 1.2)$，$b \sim U(-0.2, 0.2)$，各画素の $n \sim U(-0.1, 0.1)$ である．これらのパラメータ範囲は文献 [16] に倣った．次に，回転角 $\theta \sim U(-180°, 180°)$ と，せん断 (σ_x, σ_y)，$\sigma_x, \sigma_y \sim U(-0.2, 0.2)$ によるアフィン変換 $\psi(\cdot; \theta, \sigma_x, \sigma_y)$ を適用する．これらの変換パラメータをまとめて $\xi = (s, c, b, n, \theta, \sigma_x, \sigma_y)$ と書き，変換後のパッチを $\psi(\phi(\delta; s, c, b, n); \theta, \sigma_x, \sigma_y)$，すなわち $\psi(\phi(\delta; \xi); \xi)$ と略記する．

変換後のパッチを，配置位置 (h_0, w_0) を左上として重畳する．重畳後の画像 $\tilde{x}_t$ は，パッチ領域の画素をパッチで置き換えたものとして次式で与えられる．

$$\tilde{x}_t = \Pi\big(x_t,\ \psi(\phi(\delta; \xi); \xi);\ h_0, w_0\big), \tag{A.2}$$

ここで $\Pi(\cdot)$ は，左上 (h_0, w_0) から変換後パッチのサイズの領域を上書きする合成作用素である．

Algorithm 1 敵対的パッチ生成（探索・最適化フェーズの交互実行）

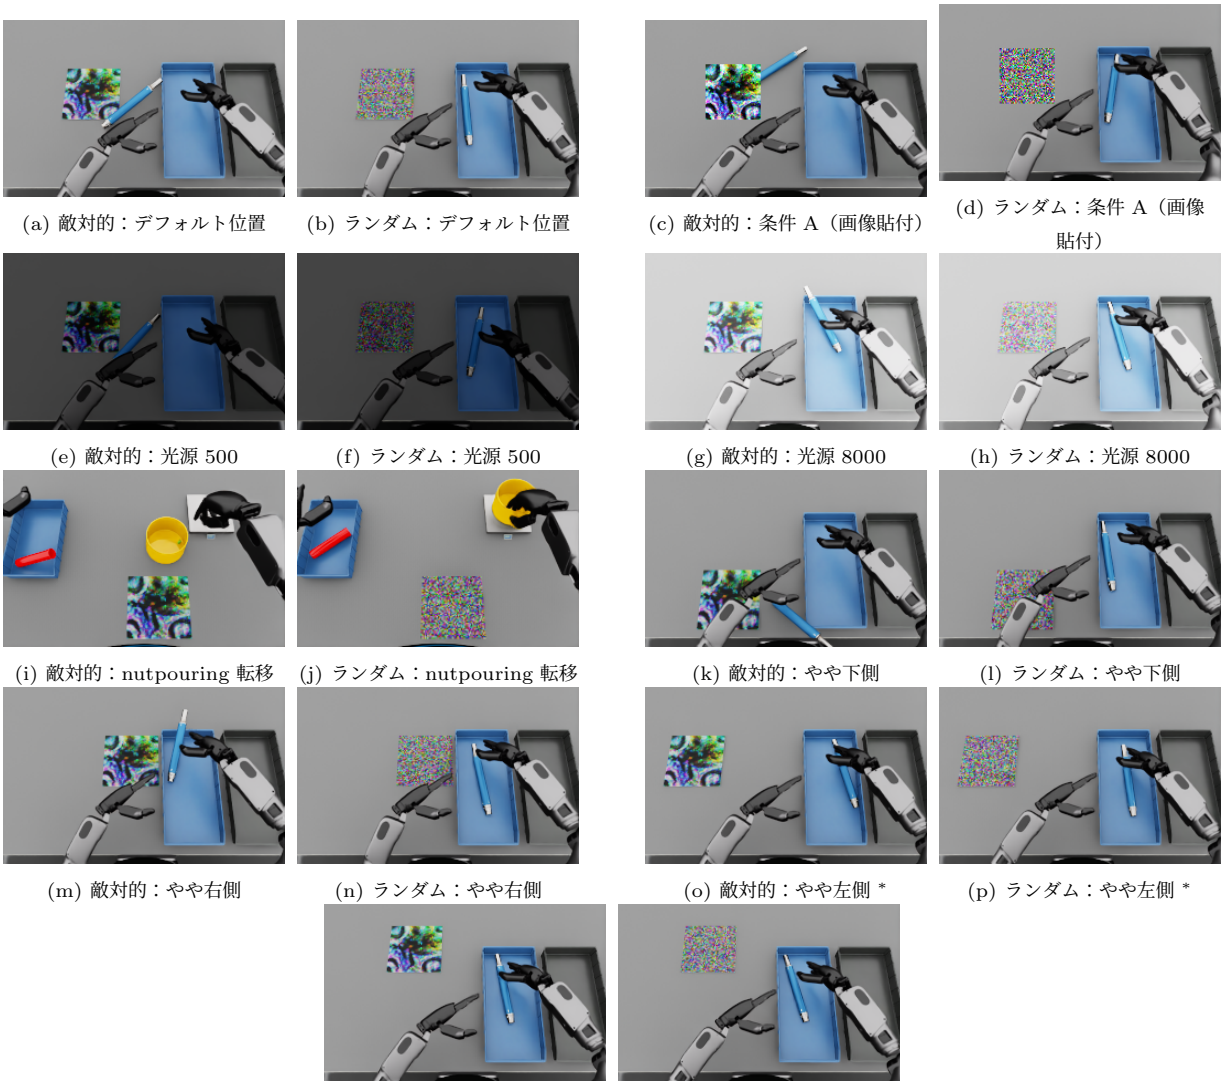
Require: パッチサイズ $H_p \times W_p$，サイクル長 K，最大更新回数 $T_{\max}$，総ロールアウト数上限 $R_{\max}$
Ensure: 敵対的パッチ δ

$\delta \leftarrow$ 中間輝度 128 の一様パッチで初期化
mode $\leftarrow$ SEARCH，$t \leftarrow 0$，$r \leftarrow 0$
while $t < T_{\max}$ かつ $r < R_{\max}$ **do**
  if mode = SEARCH **then**
    配置位置 (h_0, w_0)，スケール s，変換 ξ を一様乱数で選択
    ダミーパッチ δ_{dummy} を (h_0, w_0) に変換 (s, ξ) で重畳してロールアウトを実行，$r \leftarrow r + 1$
    if ロールアウトでタスクが成功 **then**
      mode $\leftarrow$ OPTIM，$k \leftarrow 0$
    end if
  else
    （mode = OPTIM のとき）δ を固定位置 (h_0, w_0) に固定変換 (s, ξ) で重畳してロールアウトを実行し，行動系列 $A(\delta)$ を取得，$r \leftarrow r + 1$
    式 (1) により停止損失 $\mathcal{L}_{\mathrm{freeze}}$ を計算
    式 (3) により δ を 1 ステップ更新
    $t \leftarrow t + 1$，$k \leftarrow k + 1$
    if $k \bmod K = 0$ **then**
      mode $\leftarrow$ SEARCH
    end if
  end if
end while
return δ

A.6.2　生成手続きの疑似コード

探索フェーズと最適化フェーズを交互に実行する手続き全体をアルゴリズム 1 に示す．

© 2026 Information Processing Society of Japan



(a) 敵対的：デフォルト位置　(b) ランダム：デフォルト位置　(c) 敵対的：条件 A（画像貼付）　(d) ランダム：条件 A（画像貼付）

(e) 敵対的：光源 500　(f) ランダム：光源 500　(g) 敵対的：光源 8000　(h) ランダム：光源 8000

(i) 敵対的：nutpouring 転移　(j) ランダム：nutpouring 転移　(k) 敵対的：やや下側　(l) ランダム：やや下側

(m) 敵対的：やや右側　(n) ランダム：やや右側　(o) 敵対的：やや左側 *　(p) ランダム：やや左側 *

(q) 敵対的：やや上側 *　(r) ランダム：やや上側 *

図 A-2　各評価条件におけるロールアウト終了時点（step 19）のカメラ画像の比較．各条件について敵対的パッチ（左）とランダムパッチ（右）を隣接して配置している．代表例として，敵対的パッチについてはタスクに失敗したエピソードを，ランダムパッチについてはタスクに成功したエピソードを選定して示している（各条件の成功率は表 1，表 A-2，表 A-3，表 A-4 を参照）．* やや左側・やや上側の 2 条件では敵対的パッチの攻撃効果がほぼ消失しているため，これらについては敵対的パッチ・ランダムパッチのいずれもタスクに成功したエピソードを示している．

Fig. A-2　Comparison of camera images at the final step (step 19) under adversarial and random patches.

© 2026 Information Processing Society of Japan