# Avatar Fingerprinting はアバター共生社会における劇場型高度標的型ソーシャルエンジニアリング攻撃の対策となるのか

小桐 斗馬[1]　畠山 渉[1]　春日 史亜[1]　小出 智大[1]
佐藤 靖治[1]　大木 哲史[1]　西垣 正勝[1,*]

**概要**：現在，仮想空間ではアバターが広く利用されており，人間は身体的・空間的な制約を超えて，多様な活動や体験が可能となっている．アバター共生社会においては，ユーザは目的や状況に応じてアバターを自在に切り替えながら，それぞれの役割や場面に応じた複数の「自分」を生きる新たなライフスタイルが一般化すると考えられる．しかし，1:N 操作によって実現される身体・社会活動の拡張は，正規ユーザだけでなく攻撃者の能力も増幅させる諸刃の剣となる．典型的には，1 人の攻撃者が複数のアバターを用いて異なる人物を装い，劇場型詐欺を実行することが可能となる．このような攻撃は，高度標的型ソーシャルエンジニアリング攻撃（APSE）の一形態と位置付けられる．したがって，アバター共生社会では，1:N 操作を悪用した APSE への対策として，「ユーザが対話の過程で順次対峙する複数のアバター」の操作者が同一人物であるか否かを，ユーザ自身が判定する仕組みが求められる．操作者は任意のアバターを選択し，顔貌・声質・身体外観を自由に変更できる一方で，表情・発話・身体動作に現れる癖（動的特徴）はアバターにも反映される．そこで本研究では，アバターを介しても保持される操作者固有の動的特徴として，発話時の「顔の動作特徴」と「音声のプロソディ特徴」に着目し，これらの動的特徴を利用した既存の Avatar Fingerprinting 手法が，1:N 操作をどの程度検知可能であるか検証するための初期実験を行った．

**キーワード**：アバター共生社会，1:N 操作，ソーシャルエンジニアリング，Avatar Fingerprinting

# Can Avatar Fingerprinting Mitigate Multi-Persona Advanced Persistent Social Engineering Attacks in an Avatar-Symbiotic Society?

Toma Ogiri[1]　Wataru Hatakeyama[1]　Fumia Kasuga[1]　Tomohiro Koide[1]
Seiji Sato[1]　Tetsushi Ohki[1]　Masakatsu Nishigaki[1,*]

***Abstract***: Currently, avatars are widely used in virtual environments, freeing people from physical and spatial constraints and enabling a wide range of activities and experiences. In an avatar-symbiotic society, a new lifestyle is expected to become commonplace in which users freely switch among multiple avatars according to their purposes and situations, maintaining multiple "selves" associated with different roles and contexts. However, the expansion of physical and social activities enabled by this form of 1-to-N avatar operation is a double-edged sword; while it empowers legitimate users, it also enhances the capabilities of attackers. Typically, 1-to-N avatar operation could enable a single attacker to use multiple avatars to impersonate different individuals and conduct a coordinated scam. Such an attack can be regarded as a form of Advanced Persistent Social Engineering (APSE). Therefore, as a countermeasure against APSE exploiting 1-to-N avatar operation, an avatar-symbiotic society should incorporate a mechanism that enables users who sequentially interact with multiple avatars to determine whether those avatars are controlled by the same person. Although operators can select avatars of their choice and freely alter the avatars' facial appearance, voice, and body appearance, operator-specific dynamic features manifested in facial expressions, speech, and body movements can also be reflected in their avatars. In this study, we focus on facial motion features and prosodic features during utterances as operator-specific dynamic features that remain intact even when expressed through avatars, and conduct a preliminary experiment to investigate how effectively existing avatar fingerprinting methods based on these dynamic features can detect 1-to-N avatar operation.

***Keywords***: Avatar-Symbiotic Society, 1-to-N Avatar Operation, Social Engineering, Avatar Fingerprinting

## 1. はじめに

現在既に，メタバースを中心とした仮想空間において，コンピュータグラフィックスなどによるアバターが広く使われている．人間はアバターを介することで，自身が望む姿を手に入れたり，瞬時に空間を移動したりするなど，身体や空間の制約から解放される．日本では，内閣府が主導するムーンショット型研究開発制度（目標 1）[1]においても，誰もが自由にアバターを利用することが可能になるアバター共生社会の実現に向けて研究開発が積極的に進めら

1 静岡大学
Institute of Shizuoka University

* nisigaki@inf.shizuoka.ac.jp

© 2026 Information Processing Society of Japan

This paper is work in progress and not peer-reviewed.

れている．このようなアバター共生社会では，1 人の人間が 1 体のアバターを操作する「1:1 操作」だけでなく，1 人の人間が複数のアバターを操作する「1:N 操作」が可能となる．1:N 操作によって，ユーザが目的や状況に応じて複数のアバターを自在に切り替えながら，それぞれの役割や場面に応じた複数の「自分」を生きる新たなライフスタイルが一般化すると考えられる．

しかし，1:N 操作によってもたらされる身体・社会活動の拡張は，我々正規ユーザだけでなく，攻撃者の能力をも増幅させる諸刃の剣となる．攻撃者が 1:N 操作を悪用することによって，様々な形態の攻撃が高度化する．典型的には，通常であれば複数人を要する劇場型詐欺を 1 人で実行することが可能となる．上司，同僚，取引先等を装った異なるアバターを 1 人の攻撃者が順次切り替えながら，攻撃対象との個人間ビデオ通話を劇場型に演出することによって，複数の関係者が実際に存在しているかのように装い，攻撃対象を欺くことができる．これは，先行研究における高度標的型ソーシャルエンジニアリング攻撃（Advanced Persistent Social Engineering; APSE）[2]のひとつといえる．

アバター共生社会では，1:N 操作を悪用した APSE への対策として，ユーザが対峙する複数のアバターが 1:N 操作されているか否かを確認できる仕組みが必要となる．
アバター共生社会では，正規ユーザも顔貌・声質・身体外観を変化させたアバターを日常的に利用することが一般的であり，ユーザは現実の自分から切り離され，別の存在として活動することが許容されている．すなわち，アバターと操作者は，直接的に紐づけられてはいけない．一方で，1:N 操作を悪用した APSE を検知するためには，複数のアバターの背後にいる操作者が，1 人（1:N 操作）か複数（1:1 操作）かを判定する必要がある．これは，プライバシー保護の観点から本質的に相反する要素を含む課題である．この課題を解決するために，「操作者とアバターの接続関係」には踏み込まず,「ユーザが対話の過程で順次対峙する複数のアバターの操作者が同一人物であるか否か」のみを対象とする．これにより，各アバターの操作者が実世界上の誰であるかを明らかにすることなく，1:N 操作を検知するアプローチを採用する．

アバター操作においては，操作者は任意のアバターを選択し，顔貌・声質・身体外観を自由に変更できる一方で，操作者の意図や感情，振る舞いを表現するために，表情・発話・身体動作がアバターに反映される．その結果，これらに現れる操作者固有の癖（動的特徴）もアバターに反映される．そこで，1:N 操作検知を実現するために，アバターを介してもなお表出する操作者の動的特徴に着目する．本研究では，複数のアバターから得られる操作者の動的特徴を照合し，それらの操作者が同一人物であるか否かを判定することを「1:N 操作検知」と呼ぶ．

アバターを介しても保持される操作者固有の動的特徴を利用した 1:N 操作検知を実現するための要素技術として，Avatar Fingerprinting が存在する[3]．具体的には,「ディープフェイク技術等により生成された複数のアバター動画を対象として，表情変化やまばたきといった顔の動作特徴を用いて，アバターの操作者が同一人物であるか否かを判定する手法[4]」や,「ボイスチェンジャによる声質変換後の複数の発話音声を対象として，リズムやイントネーションといった音声のプロソディ特徴を用いて，話者が同一人物であるか否かを判定する手法[5]」が該当する．しかし，これらの既存研究で扱われている評価条件は，本稿で対象とする 1:N 操作とは異なる．前者の手法では，同一のアバターを異なる操作者が操作した場合に，その操作者が同一人物であるか否かを判定している．一方，後者の手法では，異なる話者の発話を同一の声質へ変換した場合と，同一の話者の発話を異なる声質へ変換した場合とを一括して評価している．本稿で対象とするのは，同一の操作者が異なる複数のアバターを操作する 1:N 操作に相当する条件のみである．したがって，既存研究の評価からは，1:N 操作に条件を限定した場合に，顔の動作特徴及び音声のプロソディ特徴を用いた，既存の Avatar Fingerprinting 手法がどの程度有効であるかは明らかになっていない．

そこで本研究では，文献[4]及び文献[5]の Avatar Fingerprinting 手法を用いて，1:N 操作をどの程度検知可能であるか検証するための初期実験を行う．アバターを介しても保持される操作者固有の動的特徴として,発話時の「顔の動作特徴[4]」と「音声のプロソディ特徴[5]」に着目し，これらの動的特徴を利用した 1:N 操作検知の精度を評価する．顔の動作特徴と音声のプロソディ特徴をそれぞれ用いた場合，ならびに両者を統合した場合の評価を行う．これらの初期実験を通じて，1:N 操作を悪用した APSE に対する 1:N 操作検知の実現可能性を明らかにする．

## 2. 前提知識

### 2.1 アバター共生社会と 1:N 操作

アバター共生社会では，人間がアバターを利用することによって，身体，脳，空間，時間の制約から解放され，自在に活動することが可能となる[1]．ムーンショット目標 1 では，サイバネティックアバター（Cybernetic Avatar; CA）を，身代わりとしてのロボットや 3D 映像等のアバターに加え，人の身体的能力，認知能力及び知覚能力を拡張する ICT 技術やロボット技術を含む概念として定義している．アバター共生社会では，1 人の人間が 1 体のアバターを操作する従来の 1:1 操作だけでなく，1 人の人間が複数のアバターを操作する 1:N 操作が可能となる．

1:N 操作では，1 人の操作者が目的や状況に応じて複数のアバターを順次切り替えて使い分ける．例えば，あるコミュニティではアバターA を利用し，別のコミュニティではアバターB を利用するといった形態が考えられる．また，

© 2026 Information Processing Society of Japan

複数のアバターが同一の空間に同時に存在し，操作者が状況に応じて操作対象となるアバターを切り替えて利用する形態も考えられる．この形態では，操作者が直接操作していないアバターは，AI 等によって自律的に制御される．さらに，操作者の操作を複数のアバターの操作に変換する形態も考えられる．例えば，Seta らは，1 人の操作者の発話を分割して複数体の分身アバターに割り当てることによって，擬似的に対話人数のバランスを取り，少数派が感じる多数派からの同調圧力を軽減する手法を提案している[6]．本稿では，これらのうち，「1 人の操作者が，目的や状況に応じて複数のアバターを，順次切り替えて使い分ける形態」の 1:N 操作を対象とする．

### 2.2 アバター生成技術

仮想空間においてアバターを用いることで，顔貌・声質・身体外観を自由に変更することができる．

操作者とは異なる顔貌を持つアバターに操作者の顔の動作特徴を反映する方式として，ディープフェイク[7]や BlendShape [8]が挙げられる．いずれの方式も，操作者とは異なる顔貌を持つアバターを用意した上で，表情変化やまばたき等の操作者の顔の動作特徴をアバターに反映することで，アバター動画を生成することができる．このうち後者では，操作者の顔の動作特徴を複数のパラメータ（BlendShape 係数）として表現し，その係数に基づいてアバターの顔形状を変形させている．

音声を変更する技術として，ボイスチェンジャ[9]が挙げられる．ボイスチェンジャを利用することで，操作者の発話内容を維持しながら，操作者の声質をアバターごとに異なる声質へ変換することが可能である．既存の多くのボイスチェンジャは，音色特徴を変換することで話者の声を別人として聞こえるようにする一方で，元の話者の態度や感情等の表現を維持するために，リズムやイントネーションといったプロソディ特徴は保持している[5]．

### 2.3 ソーシャルエンジニアリング攻撃

ソーシャルエンジニアリング攻撃とは，人間の心理的な特性や行動上の脆弱性を悪用することによって，攻撃対象を攻撃者の意図した行動へと誘導する攻撃である．攻撃者は，言語情報や視覚情報を巧みに利用することによって，攻撃対象への介入・懐柔・操縦を試みる[2]．人間には，「権威に対して服従してしまう」，「時間制限が与えられると焦る」といった心理特性が存在する．そのような心理特性が，攻撃の成功率を高めるために悪用される．

このような心理特性の悪用を一連のシナリオとして構成し，複数の人物が異なる役割を演じながら攻撃対象へ接触する手口が，劇場型詐欺である．例えば，息子を名乗る人物から「会社で事件を起こし，上司からお金を借りた」との電話を契機として，その後，上司を名乗る人物から約 100 万円の返済を求められ，最終的に上司の代理として現れた人物に現金を手渡す手口が報告されている[10]．また，老人ホームの入居権を題材とした劇場型の手口も報告されており，大手事業者を名乗る人物からの電話を契機として，その後，大手保険会社，国の機関，弁護士等を名乗る人物から次々に電話があり，最終的に金銭を要求する手口が報告されている[11]．さらに，まず警察官を名乗る人物が電話で接触し，後日，検察官を名乗る人物がビデオ通話で接触する詐欺も確認されている[12]．

アバター共生社会においては，XR（Augmented Reality / Virtual Reality / Mixed Reality）や BMI（Brain Machine Interface）等の発展に伴い，従来のソーシャルエンジニアリング攻撃が，より拡張的・長期的な高度標的型ソーシャルエンジニアリング攻撃（Advanced Persistent Social Engineering; APSE）へと高度化する[2]．既に，ディープフェイク技術を悪用して，ビデオ会議上に複数の人物が実際に存在するかのように見せかける劇場型詐欺が発生している．2026 年にシンガポールで発生した事例[13]では，攻撃対象が Zoom によるビデオ会議に招待され，首相，大統領，閣僚，金融当局関係者，外国政府関係者等を装った複数の人物が会議に参加しているように見せかけられていた．会議終了後には，さらに弁護士を装う人物が別途接触し，攻撃対象に送金を促している．この事例では，ビデオ会議において「ディープフェイク技術によって生成された事前録画映像」が利用されており，攻撃対象と攻撃者とのリアルタイムな対話は行われていないことが確認されている[13]．

### 2.4 Avatar Fingerprinting に用いられる動的特徴

Pedrouzo-Rodriguez らは，ディープフェイク技術によって生成されたアバター動画から人物固有の顔の動作特徴を抽出する「Graph 手法」を提案している[4]．「Graph 手法」は各フレームから取得した 109 点の顔ランドマークを Graph Convolutional Network（GCN）に入力し，さらに時間方向の情報を統合することで，顔の動作特徴を抽出する．感情表現を含む音声・人物映像データセットである CREMA-D[14]を基に，ディープフェイク手法を用いて生成されたアバター動画を対象とした評価では，Graph 手法の AUC は 82.58%であった．この結果から，操作者とは異なる顔貌を持つアバターに顔の動作が反映された場合であっても，操作者固有の顔の動作特徴が保持されており，操作者が同一人物であるか否かの判定に利用できることが示されている．ただし，文献[4]における評価では，「同一の顔貌を持つアバター動画のペアを対象として，それらの操作者が同一人物であるか否か」を判定している．一方，本稿が扱う 1:N 操作検知では，「異なる顔貌を持つアバター動画のペアを対象として，それらの操作者が同一人物であるか否か」を判定する．

Gengembre らは，ボイスチェンジャによって声質変換された音声から話者固有のプロソディ特徴を抽出する手法「W-PRO」を提案している[5]．W-PRO は，発話音声から話者特徴量を抽出する音声モデル WavLM を利用して，プロソディ特徴を抽出する．2 つの話者音声データセット

© 2026 Information Processing Society of Japan

VoxCeleb と VCTK を用い，VCTK で学習した声質変換器 RVC（Retrieval-based Voice Conversion）を，VoxCeleb の発話データに適用して声質変換音声を生成した．この声質変換音声を用いた評価において，W-PRO の EER は 13.5%であった．この結果から，話者とは異なる声質へ音声が変換された場合であっても，話者固有のプロソディ特徴が保持されており，話者が同一人物であるか否かの判定に利用できることが示されている．ただし，文献[5]における評価では，「同一の声に聞こえる発話のペアと，異なる声に聞こえる発話のペアの双方を一括して対象として，それらの話者が同一人物であるか否か」を判定している．一方，本稿が扱う 1:N 操作検知では，「異なる声に聞こえる発話のペアのみ対象として，それらの話者が同一人物であるか否か」を判定する．

## 3. 1:N 操作を悪用したソーシャルエンジニアリング攻撃とその対策

### 3.1 1:N 操作を悪用した攻撃シナリオ

本稿では，2.1 節で述べた 1:N 操作の形態のうち，1 人の操作者が目的や状況に応じて複数のアバターを順次切り替えて使い分ける形態に着目する．攻撃者がこの 1:N 操作を悪用することによって，本来であれば複数人を要する劇場型詐欺を 1 人で実行することが可能となる．すなわち，2.3 節で述べた「複数の人物が異なる役割を演じながら攻撃対象へ接触する手口」を，1 人の攻撃者が複数のアバターを用いて実行する攻撃を想定する．

XR 等の発展によって，アバターを介した対話は，従来の電話やビデオ通話にとどまらず，攻撃対象とアバターが同一の仮想空間を共有しながら対話する形態へと拡張されると考えられる．このような環境では，攻撃者は，言語情報や視覚情報を巧みに利用することによって，攻撃対象への介入・懐柔・操縦を試みることが可能となる．さらに，1:N 操作によって，上司，同僚，取引先等を装った異なるアバターを 1 人の攻撃者が順次切り替えながら，攻撃対象へ継続的に接触することも可能となる．このように，1:N 操作と XR 等の技術を組み合わせることによって，従来のソーシャルエンジニアリング攻撃が，より拡張的・長期的な APSE へと高度化すると考えられる．

具体的な攻撃シナリオとして，上司，同僚，取引先等を装った異なるアバターを 1 人の攻撃者が順次切り替えながら，攻撃対象との個人間ビデオ通話を劇場型に演出する攻撃が考えられる．例えば，最初の個人間ビデオ通話では，上司を装ったアバターが攻撃対象に送金等を指示する．その後の別の個人間ビデオ通話では，同僚を装ったアバターがその指示を裏付け，さらに別の個人間ビデオ通話では，取引先を装ったアバターが同様の説明を行う．このように，1 人の攻撃者が異なるアバターを順次切り替えながら攻撃対象へ接触することによって，複数の関係者が実際に存在しているかのように装い，攻撃対象を欺くことができる．また，複数の関係者を装ったアバターから同様の情報を繰り返し提示することによって，複数の人物が同様の意見を示しているかのように装い，攻撃対象に同調圧力を与えることも可能となる．これにより，攻撃対象を攻撃者の意図した行動へと誘導しやすくなると考えられる．本稿では，1:N 操作を悪用した APSE のうち，「1 人の攻撃者が異なる複数のアバターを順次切り替えながら，複数の人物を装って攻撃対象へ接触する攻撃」を対象とする．

### 3.2 1:N 操作検知

上述のように，アバター共生社会では，1 人の攻撃者が複数の人物を装い，本来であれば複数人を必要とする劇場型詐欺を 1 人で実行することが可能となる．このような 1:N 操作を悪用した APSE への対策として，ユーザが対峙する複数のアバターが，それぞれ異なる操作者によって 1:1 操作されているのか，あるいは同一の操作者によって 1:N 操作されているのかを確認できる仕組みが必要となる．本研究では，このように複数のアバターが 1:N 操作されているか否かを判定することを「1:N 操作検知」と呼ぶ．

ここで，ディープフェイク技術やボイスチェンジャが利用されていることのみを検知しても，そのアバターが攻撃者によって利用されているか否かを判定することはできないことに留意されたい．1:N 操作を悪用した APSE への対策としては，アバターが生成・変換されていること自体ではなく，複数のアバターの背後にいる操作者が同一人物であるか否かを確認する必要がある．

また，1:N 操作そのものは正規ユーザによる利用も想定される操作形態であるため，1:N 操作が検知されたことのみをもってソーシャルエンジニアリング攻撃であると断定することはできない．このため，1:N 操作検知システムは，検知結果をユーザに提示して注意を促す human-in-the-loop 型の 1:N 操作検知フレームワークの一部として利用することが適切である．例えば，ユーザが上司，同僚，取引先等を装った複数のアバターから，複数回の個人間ビデオ通話を通じて送金等に関する説明を受けている場合，1:N 操作検知システムは，これらのアバターが同一の操作者によって操作されている可能性をスコアとしてユーザに提示する．これにより，ユーザに注意を促し，ソーシャルエンジニアリング攻撃であるか否かの最終的な判断をユーザに委ねる．

### 3.3 提案システム

1 章で概説した通り，アバター共生社会では，アバターの操作者が実世界上の誰であるかを明らかにすることなく，1:N 操作を検知することが求められる．そこで本研究では，操作者とアバターの直接的な接続関係には踏み込まず，ユーザが対話の過程で順次対峙する複数のアバター間に表出する操作者固有の動的特徴の類似性に着目する．アバター操作では，顔貌・声質・身体外観を変更できる一方，操作者の意図や感情，振る舞いを表現するための表情・発話・

© 2026 Information Processing Society of Japan

身体動作には，操作者固有の動的特徴が反映され得る．特に，ディープフェイクによって顔貌を変更した場合でも表情変化やまばたき等の顔の動作特徴が，ボイスチェンジャによって声質を変更した場合でも発話のリズムやイントネーション等のプロソディ特徴が残存することが既存研究で示されている[4][5]．

以上を踏まえ，本研究では，顔の動作特徴と音声のプロソディ特徴を用いて，複数のアバター間に表出する操作者固有の動的特徴の類似性（1:N 操作されている可能性）を評価する 1:N 操作検知システムを構成する．その概観を図 1 に示す．システム実装における緒言を付録 A.1 に示す．

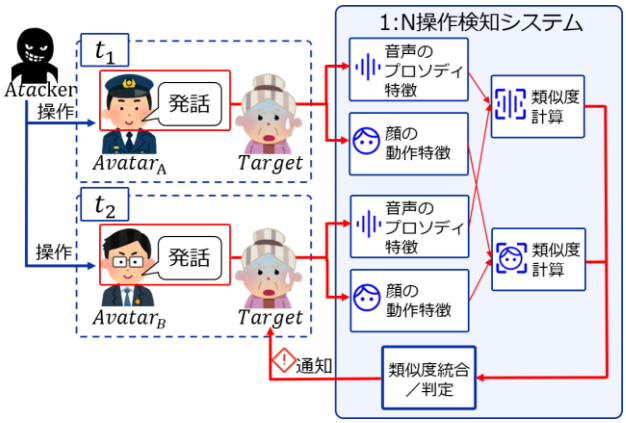



図 1. 1:N 操作検知システム

3.2 節で述べたように，本システムでは「異なるアバターの操作者が同一人物であるか否か」を判定することはせず，「これらのアバターが同一の操作者によって操作されている可能性」のスコアをユーザに提示する．

1:N 操作検知システムの動作を以下に示す．

1. ユーザがアバターA と対峙した際に，発話時のアバター動画及び発話音声を取得する．アバター動画については，文献[4]の Graph 手法を用いて顔の動作特徴量を抽出し，発話音声については，文献[5]の W-PRO を用いて音声のプロソディ特徴量を抽出する．同様に，その後ユーザがアバターB と対峙した際にも，発話時のアバター動画及び発話音声を取得し，それぞれの特徴量を抽出する．
2. アバターA とアバターB から得られた顔の動作特徴量を照合し，両者の類似度を算出する．同様に，音声のプロソディ特徴量についても照合し，両者の類似度を算出する．算出した類似度が高まるほど，アバターA とアバターB の操作者が同一人物である可能性，すなわち，1:N 操作されている可能性が高まる．

## 4. 初期実験

### 4.1 実験設定

1 人の操作者が 2 体のアバター（N=2）を順次切り替えて使い分ける 1:N 操作に相当する条件に限定し，3 章で述べた 1:N 操作検知の有効性を検証するための初期実験を行う．本実験では，実際にアバターを介して対話を行うのではなく，アバター動画及び発話音声を用いて 1:N 操作を再現し，アバターを介しても保持される操作者固有の動的特徴を用いた 1:N 操作の検知精度を評価する．

1:N 操作の検知には，顔の動作特徴と音声のプロソディ特徴をそれぞれ単独で用いる方法に加えて，両者を統合して用いる方法も考えられる．そこで本実験では，顔の動作特徴を用いた場合，音声のプロソディ特徴を用いた場合，ならびに両者を統合した場合について，それぞれ 1:N 操作の検知精度を評価する．

### 4.2 アバター動画データセット

提案システムの評価には，操作者の顔動作及び発話がアバターに反映されたアバター動画（Talking-Head 動画）が必要となる．そこで本実験では，操作者本人を撮影した人物動画（Talking-Head 動画）に対し，ディープフェイク技術及びボイスチェンジ技術を適用することによって，顔貌及び声質を変換し，評価用のアバター動画を生成する．人物動画には，感情表現を含む映像・音声データセット CREMA-D [14]を用い，顔貌変換には GAGAvatar [15]，声質変換には RVC[a] をそれぞれ用いる．

CREMA-D に GAGAvatar を適用して生成された Talking-Head 動画は，アバター動画データセット AVAPrintDB [16]に収録されている．そこで本実験では，AVAPrintDB に含まれる CREMA-D + GAGAvatar の動画を利用し，その発話音声に RVC による声質変換を適用することで，顔貌と声質の双方を変換したアバター動画を生成する．ここで，RVC を利用するためには，声質変換先となるアバターの発話音声を使っての学習が必要となる．すなわち，CREMA-D の人物ごとに RVC の声質変換モデルを学習する．

AVAPrintDB のデータは学習用データと評価用データに分けられている．3.3 節で述べたように，提案システムにおいては，Graph 手法[4]を用いてアバター動画から顔の動作特徴を抽出する．この Graph 手法を用いたシステムは，文献[16]において，AVAPrintDB の学習用データを用いて学習されている．このため提案システムの評価には AVAPrintDB の学習用データを含めず，評価用データのみを用いる．

### 4.3 評価データ

CREMA-D の人物動画として，各人物ごとに複数の Talking-Head 動画が収録されている．そのため，CREMA-D から生成された AVAPrintDB のアバター動画も，操作者（変換元となる CREMA-D の人物）とアバター（変換先となる CREMA-D の人物）の組合せごとに複数の Talking-Head 動画が含まれている．ここで，操作者$i$の$k$番目の Talking-Head 動画をアバター$j$に変換して得られるアバター動画を$a_{i\to j}^{(k)}$

a) https://github.com/RVC-Project

© 2026 Information Processing Society of Japan

とする．

3.3 節で述べたように，提案システムでは，W-PRO[5]を用いてアバター動画の発話音声から操作者固有のプロソディ特徴を抽出する．著者らによる事前実験の結果，W-PRO を用いて一定の精度でプロソディ特徴量を抽出するためには，5～10 秒程度の発話音声が必要であった．一方，AVAPrintDB に含まれる CREMA-D + GAGAvatar の Talking-Head 動画は，1 本あたり概ね 2～3 秒である[16]．そこで本実験では，操作者とアバターの組合せが同一である Talking-Head 動画群からランダムに 3 本ずつ重複なく選択し，各 3 本を時間方向に連結して 1 つの評価データとして扱う．評価データ$d$を，

$$d = a_{i\to j}^{(k_1)} \,||\, a_{i\to j}^{(k_2)} \,||\, a_{i\to j}^{(k_3)}$$

と表す．ここで，||は時間方向の連結を表し，$k_1, k_2, k_3$はそれぞれ異なる Talking-Head 動画の番号を表す．

以上の連結処理を，作成したアバター動画 5,166 本（操作者 24 人，アバター24 体）に対して行い，1,722 本の評価データを作成する．

### 4.4 検証ペア

1:N 操作検知では，異なるアバターの動画から作成された 2 つの評価データを検証ペアとする．同一の操作者が異なる 2 体のアバターを操作している評価データの組を「同一人物ペア」とし，異なる操作者がそれぞれ異なるアバターを操作している評価データの組を「異人物ペア」とする．すなわち，同一人物ペアは 1:N 操作に相当し，異人物ペアは 1:1 操作に相当する．

なお，同一人物ペアでは，「同一の Talking-Head 動画を異なるアバターへ変換したアバター動画」が，2 つの評価データの双方に含まれる場合がある．例えば，次のような検証ペアが該当する．

$$d_1 = a_{i\to j_1}^{(k_1)} \,||\, a_{i\to j_1}^{(k_2)} \,||\, a_{i\to j_1}^{(k_3)}$$

$$d_2 = a_{i\to j_2}^{(k_1)} \,||\, a_{i\to j_2}^{(k_4)} \,||\, a_{i\to j_2}^{(k_5)}$$

この例では，$d_1$と$d_2$の双方に，操作者$i$の$k_1$番目の Talking-Head 動画を変換したアバター動画が含まれている．この場合，同一の Talking-Head 動画に由来する顔動作及び発話が両評価データに含まれており，それらの一致が類似度に影響する可能性がある．そこで，同一人物ペアについては，検証ペアを構成する 2 つの評価データ間で変換元の Talking-Head 動画が 1 本でも共通する組を除外する．

以上の条件を満たす全ての評価データの組合せを検証ペアとして用い，同一人物ペア 46,592 組，異人物ペア 1,369,404 組を作成する．

### 4.5 評価指標

検知精度の評価指標には Equal Error Rate（EER）を用いる．検証ペアを構成する 2 つの評価データから得られた特徴量間の類似度を算出し，これを両者の操作者が同一人物である可能性を表す類似度として用いる．類似度がしきい値以上の場合には両者の操作者が同一人物，しきい値未満の場合には異なる人物であると判定する．

異人物ペアを同一人物と誤って判定する割合を False Positive Rate（FPR），同一人物ペアを異なる人物と誤って判定する割合を False Negative Rate（FNR）とする．判定しきい値を変化させ，FPR と FNR が等しくなる点を EER とする．EER が低いほど，1:N 操作の検知精度が高いことを示す．

### 4.6 顔の動作特徴を用いた 1:N 操作検知

顔の動作特徴を用いた 1:N 操作検知では，2.4 節で述べた Graph 手法[4]を用いる．本実験では，公開されている Graph 手法の実装及び CREMA-D を基に GAGAvatar によって生成された動画に対応する学習済みモデル[b]をそのまま使用する．

4.3 節で述べた各評価データから顔ランドマークを抽出し，Graph モデルに入力することで，顔の動作特徴量を抽出する．検証ペアを構成する 2 つの評価データから得られた顔の動作特徴量間のコサイン類似度を算出し，これを顔の動作特徴に基づく類似度$S_{face}$とする．

この$S_{face}$を用いて 4.5 節で述べた方法により EER を算出し，顔の動作特徴を用いた 1:N 操作の検知精度を評価する．

### 4.7 音声のプロソディ特徴を用いた 1:N 操作検知

音声のプロソディ特徴を用いた 1:N 操作検知では，2.4 節で述べた W-PRO[5]を用いる．本実験では，公開されている W-PRO の学習済みモデル[c]をそのまま使用する．

4.3 節で述べた各評価データの発話音声を W-PRO に入力することで，音声のプロソディ特徴量を抽出する．検証ペアを構成する 2 つの評価データから得られたプロソディ特徴量間のコサイン類似度を算出し，これを音声のプロソディ特徴に基づく類似度$S_{voice}$とする．

この$S_{voice}$を用いて 4.5 節で述べた方法により EER を算出し，音声のプロソディ特徴を用いた 1:N 操作の検知精度を評価する．

### 4.8 顔の動作特徴と音声のプロソディ特徴を用いた 1:N 操作検知

顔の動作特徴と音声のプロソディ特徴を統合した場合について評価する．本実験では，$S_{face}$と$S_{voice}$の両者を重み付き和によって統合し，統合後の類似度$S_{fusion}$を次式によって算出する．

$$S_{fusion} = \alpha S_{face} + (1-\alpha) S_{voice}$$

ここで，$\alpha$ は顔の動作特徴から得られる類似度に対する

b) https://github.com/BiDAlab/AVAPrintDB．なお，Graph 手法の再現実験については付録 A.2 を参照されたい．

c) https://huggingface.co/Orange/Speaker-wavLM-pro．なお，W-PRO の再現実験については付録 A.2 を参照されたい．

© 2026 Information Processing Society of Japan

重みである．本実験では，$\alpha$を 0.0 から 1.0 まで 0.1 刻みで変化させ，各重みの場合において，4.5 節で述べた方法により EER を算出する．EER が最小となる重み及びその際の EER を求めることで，顔の動作特徴と音声のプロソディ特徴を統合した場合の 1:N 操作の検知精度を評価する．

なお，この重みの探索と検知精度の評価には同一のデータを用いる．そのため，本実験は，重みの探索に用いていない未知のデータに対しても，最適な重みが有効であるかを評価するものではなく，顔の動作特徴と音声のプロソディ特徴を統合することによって 1:N 操作検知の精度を向上させられる可能性を確認するための初期的な評価として位置付ける．

## 5. 初期実験結果・考察

### 5.1 顔の動作特徴を用いた 1:N 操作検知

顔の動作特徴を用いた 1:N 操作検知の結果，EER は 17.89%であった．この結果から，1 人の操作者が異なる顔貌を持つ複数のアバターを操作する 1:N 操作に相当する条件においても，Graph 手法によって抽出される顔の動作特徴量を用いることで，アバターの操作者が同一人物であるか否かを一定の精度で判定できることが確認された．

### 5.2 音声のプロソディ特徴を用いた 1:N 操作検知

音声のプロソディ特徴を用いた 1:N 操作検知の結果，EER は 26.82%であった．この結果から，1 人の操作者が異なる声質を持つ複数のアバターを操作する 1:N 操作に相当する条件においても, W-PRO によって抽出されるプロソディ特徴量を用いることで，アバターの操作者が同一人物であるか否かを一定の精度で判定できることが確認された．

顔の動作特徴を用いた場合の EER が 17.89%であったのに対し，音声のプロソディ特徴を用いた場合の EER は 26.82%であり，本実験の条件では，顔の動作特徴を用いた場合の方が高い検知精度を示した．

### 5.3 顔の動作特徴と音声のプロソディ特徴を用いた 1:N 操作検知

顔の動作特徴と音声のプロソディ特徴を用いた 1:N 操作検知の結果，顔の動作特徴の類似度に対する重みを 0.8，音声のプロソディ特徴の類似度に対する重みを 0.2 とした場合に EER が最小となり，14.00%であった．

顔の動作特徴のみを用いた場合の EER は 17.89%，音声のプロソディ特徴のみを用いた場合の EER は 26.82%であったことから, 両者から得られる類似度を統合することで，いずれか一方の特徴のみを用いた場合よりも EER が低下した．

### 5.4 考察

以上の結果から，アバターを介しても保持される操作者固有の動的特徴を利用することで，1:N 操作を一定の精度で検知可能であることが示された．また，顔の動作特徴と音声のプロソディ特徴を統合することで，検知精度を向上させられる可能性が示された．

ただし，本実験では，4.8 節で述べたように，顔の動作特徴と音声のプロソディ特徴の重みの探索と検知精度の評価に同一のデータを用いている．そのため，EER が 14.00%となった重みが未知のデータに対しても有効であることを示すものではない．本結果は，1:N 操作検知の実現可能性を示す初期的な結果として位置付けられる．

## 6. 今後の展望・リミテーション

### 6.1 多様なアバター生成方式における評価

本実験では, AVAPrintDB に含まれるアバター動画のうち, GAGAvatar のみによって生成された動画を用いて評価を行った．また，2.2 節で述べたように，アバターの顔貌を変更する方式にはディープフェイク技術を用いた方式だけでなく，BlendShape を用いた方式等も存在する．今後は異なるアバター生成方式を用いた場合についても 1:N 操作の検知精度を評価する必要がある．

### 6.2 操作者固有の動的特徴を変換する技術への対応

今後のアバター生成技術やボイスチェンジャの発展によって，顔貌や声質だけでなく，操作者固有の顔の動作特徴や音声のプロソディ特徴そのものを変換することが可能になると考えられる．例えば，操作者の表情変化やまばたき等を別の動作へ変換したり，発話のリズムやイントネーションを別の話者に合わせて変換したりする場合，本稿で利用した操作者固有の動的特徴がアバターに十分に残存せず，1:N 操作の検知精度が低下する可能性がある．

そのため，今後は，顔の動作特徴や音声のプロソディ特徴が変換される環境においても保持される操作者固有の動的特徴について検討する必要がある．

### 6.3 複数のアバターを同時に操作する 1:N 操作への拡張

2.1 節で述べたように，1:N 操作には，「複数のアバターが同一の空間に同時に存在し，操作者が状況に応じて操作対象となるアバターを切り替えて利用する形態」や,「一部の発話や動作を AI 等によって生成・補完することで，操作者の操作を複数のアバターの操作に変換する形態」も考えられる．

前者の形態では，操作者が操作対象となるアバターを切り替える時点があらかじめ分かっているとは限らないため, 動画や発話音声をどのような時間幅で分割し，どの時点でどのアバターに操作者固有の動的特徴が表出しているかを判断する方法について検討する必要がある．後者の形態では, 一部の発話や動作が AI 等によって生成・補完されるため，どの発話や動作に操作者固有の動的特徴が残存しているのかを検討する必要がある．

### 6.4 M:1 操作への拡張

アバター共生社会では，複数の操作者が 1 体のアバターを操作する M:1 操作も可能となる．M:1 操作についても，攻撃者が悪用することによってソーシャルエンジニアリン

© 2026 Information Processing Society of Japan

グ攻撃が高度化する可能性がある．例えば，専門知識やコミュニケーション能力等の異なる能力を持つ複数の攻撃者が，状況に応じて 1 体のアバターを交代で操作することによって，複数の能力を併せ持つ優秀な攻撃者アバターを作り出す攻撃が考えられる．

このように，複数の操作者が 1 体のアバターを時間的に切り替えながら操作する場合についても，本稿と同様に，アバターを介して表出する操作者固有の動的特徴を利用した対策が考えられる．

ただし，M:1 操作では，操作者が切り替わる時点があらかじめ分かっているとは限らない．そのため，動画や発話音声をどのような時間幅で分割するか，また，操作者固有の動的特徴がどの時点で変化したと判断するかについて検討する必要がある．

### 6.5 プライバシーを考慮した 1:N 操作検知

本研究では，操作者の実世界上の身元や，特定のアバターと操作者との接続関係を明らかにすることなく，複数のアバターの操作者が同一人物であるか否かのみを判定することで，プライバシーを保護しつつ 1:N 操作を検知するアプローチを採用した．一方で，複数のアバターが同一の操作者によって操作されていること自体も，ユーザによっては第三者に知られることを望まない情報となる可能性がある．

そのため，1:N 操作検知をどのような状況で実行し，誰に検知結果を提示するかについても検討する必要がある．今後は，ソーシャルエンジニアリング攻撃の可能性が高い状況に限定して 1:N 操作検知を行うなど，1:N 操作を悪用した APSE への対策と正規ユーザのプライバシーを両立するための仕組みについて検討する必要がある．

## 7. まとめ

本稿では，アバター共生社会において，1 人の攻撃者が複数のアバターを利用する 1:N 操作を悪用することによって，本来であれば複数人を必要とする劇場型詐欺を 1 人で実行することが可能となる危険性について検討した．このような 1:N 操作を悪用した APSE への対策として，ユーザが対峙する複数のアバターが，1:N 操作されているのか否かを判定する「1:N 操作検知」について検討した．

1:N 操作検知を実現するために，アバターを介しても保持される操作者固有の動的特徴として，「顔の動作特徴」と「音声のプロソディ特徴」に着目した．初期実験の結果，顔の動作特徴（EER 17.89%）と音声のプロソディ特徴（同 26.82%）を統合した結果，EER は 14.00%であった．この結果から，操作者固有の動的特徴を利用した 1:N 操作検知の実現可能性と，両特徴の統合による検知精度向上の可能性が示された．

**謝辞** 本研究は，一部，JST ムーンショット型研究開発事業 JPMJMS2215，JST CREST JPMJCR22M4，JSPS 科研費 JP23K28085，JP23H00463 の支援を受けたものです．声質変換に対して頑健な話者識別器に関して，静岡大学西田昌史教授，綱川隆司准教授，PHAM HOANG LONG 氏から貴重なご助言をいただきました．ここに御礼申し上げます．

## 参考文献

[1] 内閣府，「ムーンショット目標 1 2050 年までに，人が身体，脳，空間，時間の制約から解放された社会を実現」，https://www8.cao.go.jp/cstp/moonshot/sub1.html

[2] K. Numada et al., “Perceiving Human Psychological Consistency: Attack Detection Against Advanced Persistent Social Engineering,” EIDWT 2024, pp.152–162, 2024.

[3] E. Prashnani et al., “Avatar Fingerprinting for Authorized Use of Synthetic Talking-Head Videos,” ECCV 2024, pp.209–228, 2024.

[4] L. Pedrouzo-Rodriguez et al., “Is It Really You? Exploring Biometric Verification Scenarios in Photorealistic Talking-Head Avatar Videos,” IJCB 2025, pp.1–9, 2025.

[5] N. Gengembre, O. Le Blouch, and C. Gendrot, “Disentangling Prosody and Timbre Embeddings via Voice Conversion,” Interspeech 2024, pp.2765–2769, 2024.

[6] K. Seta et al., “Divided Presence: Improving Group Decision-Making via Pseudo-Population Increase,” HAI ’18, pp.260–268, 2018.

[7] R. Tolosana et al., “DeepFakes and Beyond: A Survey of Face Manipulation and Fake Detection,” Information Fusion, Vol.64, pp.131–148, 2020.

[8] H. Onizuka et al., “Landmark-Guided Deformation Transfer of Template Facial Expressions for Automatic Generation of Avatar Blendshapes,” ICCVW 2019, pp.2100–2108, 2019.

[9] B. Sisman et al., “An Overview of Voice Conversion and Its Challenges: From Statistical Modeling to Deep Learning,” IEEE/ACM Transactions on Audio, Speech, and Language Processing, Vol.29, pp.132–157, 2021.

[10] 独立行政法人国民生活センター，「新型コロナウイルスに便乗した悪質商法にご注意！（速報第 5 弾）」，https://www.kokusen.go.jp/news/data/n-20200403_1.html

[11] 消費者庁,「令和 5 年版消費者白書 第 1 部第 2 章第 2 節（2）高齢者の消費者トラブル」，https://www.caa.go.jp/policies/policy/consumer_research/white_paper/2023/white_paper_136.html

[12] 警察庁・SOS47,「ビデオ通話を悪用した“偽警察官・検察官”の詐欺に注意！！」，https://www.npa.go.jp/bureau/safetylife/sos47/new-topics/250428/01.html

[13] Singapore Police Force, “Footage From Zoom Video Conference Involving Impersonation Of Senior Government Officials,” May 16, 2026, https://www.police.gov.sg/media-hub/news/2026/05/20260516_footage_from_zoom_video_conference_involving_impersonation_of_senior_government_officials

[14] H. Cao et al., “CREMA-D: Crowd-sourced Emotional Multimodal Actors Dataset,” IEEE Transactions on Affective Computing, Vol.5, No.4, pp.377–390, 2014.

[15] X. Chu and T. Harada, “Generalizable and Animatable Gaussian Head Avatar,” NeurIPS 2024, Vol.37, pp.57642–57670, 2024.

[16] L. Pedrouzo-Rodriguez et al., “Leveraging Avatar Fingerprinting: A Multi-Generator Photorealistic Talking-Head Public Database and Benchmark,” arXiv:2603.26934v1, 2026.

© 2026 Information Processing Society of Japan

## 付録

### 付録 A.1 実験環境について

本実験は Ubuntu 24.04.4 LTS 環境で実施した．その他の主要な実験環境を表 A.1 に示す．

表 A.1. 実験環境

| 項目 | 設定 |
|---|---|
| OS | Ubuntu 24.04.4 LTS |
| CPU | Intel Core i9-13900KF |
| メモリ | 16 GB |
| GPU | NVIDIA GeForce RTX 4060 Ti 8 GB × 1 |
| Python | 3.12.3 |
| CUDA | 12.4 |
| PyTorch | 2.6.0+cu124 |

### 付録 A.2 Graph 手法及び W-PRO の実装の妥当性について

本研究では，顔の動作特徴の抽出に Graph 手法[4]，音声のプロソディ特徴の抽出に W-PRO [5]を用いている．これらの手法を本研究において適切に実装できていることを確認するため，既存研究の評価条件を可能な範囲で再現し，既報の性能との比較を行った．

Graph 手法については，文献[16]の評価条件に従い，公開されている学習済みモデル及び AVAPrintDB の評価用データを用いて，CREMA-D＋GAGAvatar の条件で再現実験を行った. 文献[16]では，当該条件において AUC 88.0%が報告されている．これに対し，本研究の再現実験では AUC 87.99%（EER は 20.31%）となり，ほぼ同一の結果が得られた．このことから，Graph 手法による特徴抽出及び類似度計算については，既存研究と同等の処理を実現できていると考えられる．

W-PRO については，文献[5]の評価条件を可能な範囲で再現し，公開されている学習済みモデルを用いて再現実験を行った．文献[5]では，「音声データセット VoxCeleb Test Clean の各発話」を RVC によって「音声データセット VCTK の各話者の声質」へ変換し，変換後音声から元話者を照合する条件において, EER 13.5%が報告されている．一方，本研究では，文献[5]と同一の評価データを入手できなかったため，類似するデータとして音声データセット VoxCeleb1 を用いた. 具体的には,「VoxCeleb1 の 40 話者の各発話」を，RVC によって「VCTK の 20 名の各話者の声質」へ変換した音声を用いた. その結果, 本研究の再現実験では EER 14.92%となり，既存研究の 13.5%と近い結果が得られた．文献[5]と評価条件は完全には一致しないものの，既存研究に近い EER が得られたことから，W-PRO による特徴抽出及び類似度計算についても，既存研究と同等の処理を実現できていると考えられる．

以上より，再現実験では，Graph 手法については既存研究とほぼ同一の性能が得られ，W-PRO についても評価条件の差異がある中で既存研究に近い性能が得られた．このことから，本研究で使用する Graph 手法及び W-PRO の基本的な実装は妥当である可能性が高いと考える．一方，本実験の 1:N 操作検知では，W-PRO の性能低下が見られた．この要因としては，既存研究と本研究で使用するデータセットやデータの構成が異なることに加え，異なるアバター間で同一操作者を識別する 1:N 操作検知自体の難易度が高いことなどが影響している可能性がある．

© 2026 Information Processing Society of Japan