外形的反応に基づくトラスト較正モデルの提案 —期待は測れなくても較正はできる —

島岡 政基[1,a)]　藤田 真由[1]　玉井 睦[1]　今井 倫太[2]　松永 昌浩[1]

概要：利用者が人工システムをどの程度信頼するかを，その能力や振る舞いに見合う状態へ近づけることをトラスト較正という．しかし継続利用環境では，利用者が望む働きかけや，それをどう受け止めたかを常に直接確認できるとは限らない．本稿は，信頼そのものを測定・操作するのではなく，システムの働きかけを利用者の期待に近づける問題としてトラスト較正を捉え直す．そこで，働きかけ後の利用者の顔の向き，応答などの観測可能な反応から，それが期待に沿ったかを大まかに推定し，その結果を次回以降の働きかけに反映する概念モデルを提案する．さらに，誤推定による過剰な調整を防ぐ仕組みと提案モデルの検証方針を示し，また家庭用対話型ロボットや対話型 AI などへの応用可能性を論じる．

キーワード：トラスト較正，利用者期待，外形的反応，期待整合性，較正保護機構

Trust Calibration Model based on Observable Response: Don't Measure Expectations, Calibrate Them

Masaki SHIMAOKA[1,a)]　Mayu FUJITA[1]　Mutsumi TAMAI[1]　Michita IMAI[2]
Masahiro MATSUNAGA[1]

Abstract: Trust calibration aims to bring users' trust in an artificial system closer to a level commensurate with its capabilities and behavior. In continued use, however, a system cannot always directly determine what interventions users expect or how they perceive them. Rather than measuring or manipulating trust itself, this paper reconceives trust calibration as aligning system interventions with user expectations. We propose a conceptual model that uses observable responses after an intervention, such as gaze direction and verbal responses, to coarsely infer whether the intervention aligned with user expectations and reflects the inference in subsequent interventions. We further present a mechanism for preventing excessive adjustments caused by erroneous inference, together with a validation approach for the proposed model. Finally, we discuss its potential applicability to in-home social robots, conversational AI, and other digital services.

Keywords: trust calibration, user expectations, observable responses, expectation alignment, calibration protection mechanism

1. はじめに

デジタル社会の進展により，AI や IoT を利用した人工システムは，家庭，移動中，医療・介護，教育，行政サービスなど，日常のさまざまな場面で人の判断や行動に継続的に介入する機会が増えている．こうした環境では，その時々の文脈に応じて利用者が望む介入のあり方も変化するため，人工システムには文脈に応じて振る舞いを調整することが求められる [1] [2].

このように文脈に応じてな介入を見直すこと調整は，利用者の期待と人工システムの介入とのずれが蓄積して過信や不信につながり得るため，トラスト較正の観点からも重

[1] セコム株式会社 IS 研究所
Intelligent Systems Laboratory, SECOM CO., LTD.
[2] 慶應義塾大学
Keio University
[a)] m-shimaoka@secom.co.jp

© 2026 Information Processing Society of Japan

This paper is work in progress and not peer-reviewed.

要である．例えば家庭用対話型ロボットは，生活支援や注意喚起を利用者へ継続的に提供する．しかし，利用者が望む介入の内容や強さは文脈によって変化し，また必ずしも毎回明示されるとは限らない．人工システムの介入が適切であったかを示す明示的なフィードバックも常に得られるとは限らない．このため，人工システムを継続して利用する環境において，介入を利用者期待に継続的に整合させる応じた介入調整を実現することは容易ではない．

本研究は，こうした課題に対し，利用者の信頼状態や期待そのものを直接測定・操作するのではなく，介入後の観測可能な利用者の反応に着目する．そして，人工システムが外形的反応から期待整合性を推定し，その結果に基づいて較正方針を策定することで，次回以降の介入を利用者期待により整合させることをねらう．

本稿では，トラスト較正の一アプローチとして，介入後の外形的反応から期待整合性を推定し，較正方針を次回以降の介入に反映する「外形的反応に基づくトラスト較正モデル」を提案する．本モデルは，具体的な実装やアルゴリズムを規定するものではなく，要素間の関係性を整理する概念モデルである．また，その内部構造は，期待仮説生成，反応観測・期待整合性推定，較正方針策定の三層から成る．

本研究の貢献は，以下の 3 点である．

- 利用者期待の直接測定ではなく外形的反応から期待整合性を推定する枠組みを示した
- 推定結果に基づき，介入を利用者期待に近づけるトラスト較正モデルを提案した
- 誤推定や過剰適応を抑える較正保護機構を組み込み，較正の安全性と安定性への反映を扱えるようにした

以下，2 節では問題設定を詳細化し，3 節で関連研究との関係を整理する．4 節で提案モデルを説明し，5 節で較正保護機構を示す．さらに 6 節で提案モデルの検証方針を示し，7 節で応用可能性と今後の展開について考察する．

2. 基本概念と問題設定

2.1 本研究で扱う人工システムと介入

本研究で扱う継続利用環境は，AI や IoT を利用した人工システムが，利用者の状況や反応を観測しながら情報提供，提案，注意喚起，制御支援などを行う場面である．家庭用対話型ロボットを典型例とするが，対話型 AI やスマートデバイス上の支援機能も含み得る．以降では，主要概念を次のように用いる．

人工システム：利用者の文脈を参照し，情報提供や支援的な働きかけを行うシステム．人工システムは利用者の外形的反応 (後述) を観測できるものとする．

文脈：作業状態，場所，時間，直前の行動，過去の反応など，介入判断に参照される条件．

介入：通知，声掛け，説明，提案，警告，動作による注意喚起など，利用者の判断や行動に影響を与える働きかけであり，本研究では期待や文脈に応じて決定・実行される対象として扱う．

介入の適切さは，情報の正しさだけでは決まらない．同じ通知や提案でも，利用者が集中しているか，外出直前であるか，支援を求めているかなどによって，望ましい内容，強度，タイミングは変化する．

2.2 利用者期待と期待仮説

利用者期待と期待仮説は，次のように区別する．

利用者期待：特定の文脈において，利用者が人工システムに望む介入の有無，内容，強度，タイミングに関する予期．例えば，集中作業中には通知を控えめにしてくれるだろう，外出直前には天候や予定を簡潔に知らせてくれるだろう，という予期である．

期待仮説：利用者期待に応じようとする人工システムが，利用者の期待について形成する仮説．例えば，「今は弱い通知が望ましい」「集中時は声掛けを控えるべき」など．

利用者期待は直接測定することが難しいため，本研究ではその真値を測定対象とはせず，人工システムが文脈と経験記録から形成する期待仮説を用いて扱う．人工システムは，期待仮説に基づいて介入を決定・実行し，介入後の反応を手掛かりとして期待整合性を推定する．その推定結果と経験記録に基づき，次回以降の較正方針を策定する．

2.3 期待の不確実性とフィードバックの不確実性

継続利用環境において介入調整を難しくする要因は，次の二つである．

期待の不確実性：利用者期待は文脈，時間，個人差によって変化し，常に明示されるとは限らない．

フィードバックの不確実性：介入が利用者期待に沿って受け止められたかを示す明示的な応答や評価は，常に得られるとは限らない．利用者は介入を有用だと感じても評価しないことがあり，煩わしいと感じても無視や曖昧な反応にとどまることがある．

本研究は，この二つの不確実性を前提とし，期待そのものや明示的評価を必ずしも取得できない状況で，限られた観測情報から介入の受け止められ方を推定し，次回以降の介入へ反映する問題を扱う．生活空間では観測手段にも制約があるため，詳細な内面状態ではなく，必要最小限の外形的反応に基づく推定に焦点を当てる．

2.4 外形的反応，期待整合性および較正方針

本研究では，期待内容そのものを詳細に推定するのではなく，外形的反応から期待整合性を粗粒度に推定する．

外形的反応：介入後に人工システムが一定程度観測できる利用者の反応であり，顔の向き，応答遅延，無視，短い返答，作業の継続または停止，明示的な拒否などを含む．

期待整合性：介入が利用者期待に沿って受け止められた

© 2026 Information Processing Society of Japan

か，期待に反して受け止められたかを表す粗粒度の性質である．記号表現としての期待整合性極性は，4 節で提案モデルを説明する際に扱う．

較正方針：期待整合性推定と経験記録に基づき，次回以降の介入の強め方・弱め方を示す方針．

2.5 本研究におけるトラスト較正の位置付け

本稿では，トラストを人と人工システムとの関係全体を捉える語として用い，信頼を利用者が人工システムを頼れると感じる主観的状態として用いる．すなわち，信頼は利用者側の内面的評価であり，トラストはその評価を含む人 – 人工システム関係を表す．

トラスト較正は一般に，利用者が人工システムに抱く信頼と，システムの実際の能力や振る舞いとが釣り合った状態へ近づけることを指す．適切な較正が行われない場合，利用者はシステムを過度に信頼して不適切に依存する過信状態や，十分に利用可能な機能を避ける不信状態に陥り得る [3].

本研究ではこの考え方を踏まえつつ，トラスト較正を，期待の不確実性とフィードバックの不確実性が残る継続利用環境において，利用者の信頼や期待そのものを直接測定・操作する問題ではなく，人工システム側の介入を利用者期待に整合させていく問題として扱う．すなわち，本稿におけるトラスト較正は，外形的反応にもとづき推定した期待整合性に応じて較正方針を策定し，その方針を次回以降の介入に反映する過程を指す．

2.6 問題設定のまとめ

本研究の目的は，期待もフィードバックも不確実な継続利用環境において，外形的反応から期待整合性を推定し，その推定結果に基づいて較正方針を策定する過程を明らかにすることにある．さらに，策定された較正方針を次回以降の介入に反映し，介入を利用者期待に整合する方向へ継続的に近づける仕組みをモデル化することにある．そして，このモデルの妥当性を今後検証するために，次の 3 つの研究課題に取り組む．

- 限られた外形的反応から期待整合性を推定できるか
- 較正方針に基づく介入が，固定的な介入よりも有効に機能するか
- 推定や較正方針の策定に誤りが生じても，較正を安全かつ安定的に機能させられるか

3. 関連研究と本研究の位置付け

3.1 主観的信頼の測定と外形的反応指標

人と人工システムとのトラスト関係を扱う研究では，質問紙や評定尺度を用いて，利用者がシステムをどの程度主観的に信頼しているかを測定する方法が広く用いられてきた．代表的なものとして，自動化システムに対する信頼尺度 [4] や，HRI におけるロボット信頼尺度 [5] が提案されている．また，主観的信頼測定に関するレビューでは，自己申告尺度，行動指標，生理指標など，複数の測定手法が整理されている [6].

一方で，利用者の行動や反応を主観的信頼の手掛かりとして用いる研究もある．例えば，システムの提案を受け入れるか，手動操作に切り替えるか，介入するかといった行動は，利用者がシステムをどのように受け止めているかを推測するための情報となる [6]．ただし，行動は主観的信頼だけでなく，作業負荷や状況の緊急性，リスク認知，あるいは利便性や効率性，報酬期待などにも影響されるため，行動指標をそのまま主観的信頼の値とみなすことには注意が必要である．

主観的信頼尺度は信頼を明示的に測定する方法として有用であり，行動指標は利用者の受け止め方を観測する補助的な手掛かりとなる．一方で，継続利用環境では，自己申告を常時求めることや，行動のみから主観的信頼状態を一意に決めることには限界がある．

3.2 HRI におけるトラスト較正と適切な依存

トラスト較正研究では，利用者の主観的信頼や依存が，システムの実際の能力や振る舞いに見合った状態となることが重視される．Lee らは，過信と過小信頼の双方を避け，利用者が状況に応じて適切にシステムへ依存できるようにすることの重要性を論じた [7]．また，自動化利用において，適切な利用だけでなく，誤用，不使用，過度な依存が問題となることも整理されている [8].

近年は，利用者の状態や行動に応じて較正を行う適応的トラスト較正も検討されている．Okamura らは，利用者の依存行動を手掛かりとして，過信または過小信頼が生じていると判断される場合に，トラスト較正を促す情報を提示する手法を提案した [3]．また，トラスト較正研究のレビューでは，較正介入の時点，提示内容，静的または適応的な介入などの観点から，既存研究が整理されている [9].

主観的信頼や依存の較正に近い研究として，利用者が事前に期待していた内容と，実際に経験した内容との差異に注目する研究もある．Komatsu らは，利用者がエージェントに期待した機能と，実際に知覚した機能との差異を適応ギャップとして捉え，その正負が利用者の行動に影響することを示した [10]．このような研究は，利用者の期待と実際の経験との関係が，相互作用後の評価や行動に関わることを示している．

さらに，HRI では，人の主観的信頼を直接観測できない状態として扱い，ロボットの行動選択に組み込む研究もある．Chen らは，人間の主観的信頼を部分観測マルコフ決定過程 (POMDP) 上の潜在状態としてモデル化し，相互作用を通じて推定しながら，長期的なチーム性能を高めるロボット行動を選択する trust-POMDP を提案した [11, 12].

© 2026 Information Processing Society of Japan

この研究は，主観的信頼推定と行動選択を閉ループで接続する代表的な例である．

3.3 共在感と継続的な相互作用

家庭のような生活空間でロボットが継続的に働きかける場合，個々の発話や動作の適切さだけでなく，利用者がロボットの存在をどのように受け止め，日々のやり取りをどのような関係として捉えるかが重要になる．人とロボットが空間を共有し，ともに時間を過ごすなかで，互いの存在や行動が認識されていると利用者が感じる状態は，共在感として研究されている [13, 14]．

共在感に関する研究では，ロボットの振る舞いを一回ごとの刺激として評価するだけでなく，利用者とロボットとの継続的な相互作用のなかに位置づけて捉える．例えば，有村らは，習慣的な行動を継続的に見ているロボットが介入した場合と，そうでないロボットが介入した場合で人の心情に与える影響を検討している [15]．

また，長期 HRI 研究では，利用者とロボットとの相互作用を一回限りではなく，継続的な関係の中で捉えることの重要性が指摘されている [16]．過去の利用履歴や相互作用を踏まえた個人化が，利用者との関係形成や関与に影響することも報告されている [17]．これらの研究は，継続的な相互作用の中で，利用者の印象や期待が変化し得ることを示している．

共在感に関する研究は利用者とロボットとの関係を捉えるための視点を与える．生活空間における人・ロボット関係を考えるうえでは，利用者の受け止め方と，ロボット側の振る舞いの調整過程を併せて考えることが求められる．

3.4 本研究の位置付け

本研究は，主観的信頼測定，トラスト較正，および共在感を伴う長期 HRI 研究の接点に位置付けられる．

主観的信頼測定研究は，利用者の主観的信頼状態を尺度化し，自己申告や行動指標などを用いて主観的信頼を把握することを目的としてきた [4–6]．これに対して，本研究は，主観的信頼状態そのものを測定することを目的としない．外形的反応は，主観的信頼水準の値を求めるためではなく，介入が利用者期待に沿って受け止められたかを推定する手掛かりとして扱う．

トラスト較正研究は，過信や不信を避け，利用者の主観的信頼や依存とシステムの能力を釣り合う状態へ近づけることを目的としてきた [7–9]．本研究も較正という問題意識を共有するが，主観的信頼水準や依存行動そのものではなく，期待と介入との整合関係に着目する点が異なる．特に，適応的トラスト較正や trust-POMDP が，利用者状態や主観的信頼状態を推定してシステムの行動選択に反映するのに対し，本研究は，期待整合性を推定し，較正方針を次回以降の介入へ反映する [3, 11, 12]．

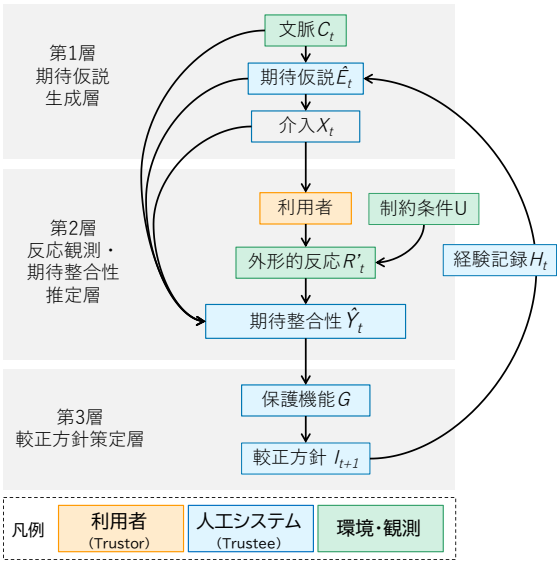


図 1 提案モデルの 3 層における要素間の関係性

また，共在感および長期 HRI 研究は，生活空間での継続的な相互作用，関係形成，個人化，利用者の受け止め方を扱ってきた [15–17]．本研究は，そのような継続利用環境を前提としつつ，共在感そのものを測定または向上させるのではなく，継続的な関係の中で生じる期待と介入のずれをどのように扱うかに焦点を当てる．

4. 外形的反応に基づくトラスト較正モデル

本節では，2 節で定義した概念を用いて，外形的反応に基づくトラスト較正モデルの構造と処理過程を示す．はじめにモデルの全体像を示し，続いて各層の処理を Step 1〜Step 6 に沿って説明する．各 Step の式は具体的な計算手続きではなく，概念モデルにおける要素間の依存関係を模式的に表したものである．

4.1 モデル全体像

図 1 に，本モデルを構成する期待仮説生成，反応観測・期待整合性推定，較正方針策定の三層と，その関係を示す．第 1 層では，期待仮説に基づいて介入し，第 2 層では，介入後の外形的反応から期待整合性を推定し，第 3 層では，その推定結果に基づいて較正方針を策定する．較正方針を次時点の介入に反映することで，三層は閉ループを構成する．各層を構成する要素の記号と本文上の役割は，4.5 節で整理する．

4.2 期待仮説生成層

本層では，直接観測できない利用者期待を期待仮説（2.2 節）として扱う．Step 2: 人工システムは，期待仮説 Êt と現在の文脈 Ct をもとに，利用者への振る舞い (介入 Xt) を決定・実行する．この時，以前に策定された較正方針 It は介入の決定・実行に反映され，その反映先のひとつとし

© 2026 Information Processing Society of Japan

て介入の強度にも作用し得る．

期待仮説は，直接観測できない利用者期待に関する作業上の仮説である (2.2 節)．人工システムは，現在の文脈と過去の経験記録を参照して期待仮説を形成し，これに基づいて介入を決定・実行する．

Step1: 人工システムは，利用者がこの文脈 C_t において何を期待しているのか，必要に応じて過去の経験記録 H_{t-1} を参考に，期待仮説 $\hat{E}_t$ を形成する．

$$\hat{E}_t = f_{\hat{E}}(C_t, H_{t-1}) \tag{1}$$

Step2: 人工システムは，期待仮説 $\hat{E}_t$ と現在の文脈 C_t をもとに，利用者への振る舞い (介入 X_t) を決定・実行する．この時，以前に策定された較正方針 I_t は介入の決定・実行に反映され，その反映先のひとつとして介入の強度にも作用し得る．

$$X_t = f_X(C_t, \hat{E}_t, I_t) \tag{2}$$

4.3 反応観測・期待整合性推定層 (観測・推定層)

本層では，利用者が介入後に示す外形的反応 R_t と，観測手法 U を通じて人工システムが取得する外形的反応 R'_t とを区別する．期待整合性の推定には，実際の反応 R_t そのものではなく，取得結果である R'_t を用いる．期待整合性を，正・負・判断不能の粗粒度のカテゴリとして推定する．これにより，細かな期待値の推定を避け，観測・学習コストを抑えるとともに，誤推定に基づく過剰適応のリスクを抑える [16, 18, 19].

Step3: 利用者は，人工システムの介入 X_t に対して主観的受容・評価を行うとともに，それと何らか連動する形で外形的反応 R_t を示す．

Step4: 人工システムは，観測手法 U の条件下で外形的反応を観測し，その結果を外形的反応 R'_t として得る．

$$R'_t = f_R(X_t, C_t; U) \tag{3}$$

Step5: 人工システムは，期待仮説 $\hat{E}_t$ に基づく介入 X_t に対する外形的反応 R'_t から，期待整合性極性 $\hat{Y}_t \in \{+/-/NA\}$ を推定する．

$$\hat{Y}_t = f_{\hat{Y}}(X_t, R'_t, \hat{E}_t) \tag{4}$$

4.4 較正方針策定層

本層では，期待整合性に基づく較正方針の策定と次時点の介入への反映を，2.5 節で位置づけたトラスト較正の具体的な内部操作として表す．

Step6: 人工システムは，期待整合性極性 $\hat{Y}_t$ と経験記録 H_t にもとづき，次回以降の較正方針 I_{t+1} を策定する．較正方針の策定にあたっては，保護機能 G が，過度な変化や拒否・停止要求に反する方針を抑制する制約として作用する．

$$I_{t+1} = f(I_t, \hat{Y}_t; G) \tag{5}$$

例えば，集中作業中に通知を行った後，利用者が顔を背けて応答しなかった場合，人工システムはこれを負の期待整合性として扱い得る．この時，較正方針は「介入を弱める」となり，次時点の文脈に応じて介入に作用する．

4.5 パラメータの整理

本モデルの理解に必要な主要要素を**表 1** に示す．実験時に想定される具体化例や追加の一覧性を高めるための補助情報は，**付録 A.1** にまとめる．

5. 較正保護機構

5.1 較正保護機構の目的

4.1 節で述べたように，提案モデルは閉ループ型の構成であるため，外形的反応の誤推定やセンサノイズは，意図しない較正方針の策定を引き起こす可能性がある．この閉ループを実装する場合には，その仕組みを逆手に取った外部誘導や攻撃が生じる可能性にも配慮する必要がある．

較正保護機構は，閉ループの暴走，外部誘導，追跡不能化を抑制するための統制機能であり，期待整合性推定と較正方針を安全側に運用するための補助枠組みとして位置付ける．

保護機構は，外部音や意図的な入力によって外形的反応が誤って解釈され，介入強度が不適切に変化することを抑制する役割も持つ．例えば，テレビ音や外部再生音が利用者の反応であるかのように誤認されると，較正方針や介入強度が不適切に変化する可能性がある．このような操作に対して，更新境界や根拠保持は一定の抑制効果を持ち得る．

表 1 提案モデルの主要要素と役割

記号	意味	役割
C	文脈	期待仮説の形成と介入決定の前提となる状況
H	経験記録	過去の文脈，介入，観測結果，期待整合性極性，較正方針等の記録
$\hat{E}$	期待仮説	文脈と履歴から形成される利用者期待に関する仮説
X	介入	人工システムが利用者に対して行う振る舞い
R'	外形的反応	外形的反応を観測手法 U の条件下で取得した観測結果
U	観測条件	外形的反応の観測手法や観測精度を規定する観測条件
$\hat{Y}$	期待整合性極性	期待整合性を期待に沿う/反する/判断不能として表す粗粒度の推定結果
I	較正方針	次回以降の介入の強め方・弱め方を示す方針
G	較正保護機構	過剰較正，暴走，拒否無視を抑える統制機能

© 2026 Information Processing Society of Japan

5.2 更新境界

更新境界は，較正方針の急激な変化を抑え，介入強度が急激に変化しないようにする制限である．例えば，強い外形的反応を観測したとしても，一度だけの否定的または肯定的反応に基づいて，介入を過度に抑制したり強化したりすることを防ぐ．

更新境界を設けることで，誤推定，センサノイズ，一時的な反応に基づく閉ループの暴走を抑制できる．これは，トラスト較正の安定性を確保するための要素である．

5.3 根拠保持

根拠保持は，閉ループに暴走等が生じた場合でも，較正方針の事後追跡や説明に必要な履歴を保持する機能である．文脈，介入（強度を含む），観測反応，推定結果，較正方針を記録することで，何が較正方針に作用したのかを後から確認できる．

この機能は，利用者や運用者に対する説明可能性だけでなく，人工システムの監査可能性にも関わる．トラスト較正をブラックボックス化させないためには，更新結果だけでなく更新根拠を保持する必要がある [20] [21].

5.4 停止・拒否尊重

停止・拒否尊重は，明示的な拒否や停止要求があった場合に，介入強度を低下させる，または介入を停止する機能である．拒否や停止に反する方向の介入を抑制することにより，利用者の意思に反する適応を防ぐ．

これはトラスト較正が，利用者を人工システムに都合よく誘導する操作的な仕組みへ変質することを避けるために重要である．利用者が観測，学習，適応を統制できる関係を保つことは，デジタル社会におけるトラスト形成の重要な条件である．ただし，この機能は，利用者が拒否や停止の意思を形成し，それを表明できる場合に有効である．

なお，利用者が拒否すべき状況を認識できない誘導的な相互作用については，7.5 節で後述する．

6. 検証方針：仮説に対応する評価観点

本節では、提案モデルの妥当性を今後検証するために、検証仮説、想定シナリオ、比較条件、および観測・評価観点を整理する。ここで示す内容は、具体的な実施手順を定めるものではなく、概念モデルを経験的に検証するための基本方針である。

6.1 検証仮説

提案モデルの今後の検証に向けて、本稿では次の３つの仮説を設定する。

H1：外形的反応は，期待整合性を粗粒度に推定する手掛かりとなる．

H2：較正方針に基づく介入は，固定介入よりも不整合方向の反応を減少させる．

H3：較正保護機構は，介入強度の不適切な変化や拒否・停止要求に反する介入を抑制する．

これらの仮説は，2.6 節で示した 3 つの研究課題（推定可能性・較正方針を反映した介入の有効性・較正の安全性と安定性）にそれぞれ対応する．

6.2 想定シナリオの例

評価シナリオの候補として，集中作業中の通知，休息中の提案，移動前の注意喚起，軽度リスク時の警告を想定する。例えば，集中作業中に予定通知や天候通知を行う場合，同じ通知であっても，利用者の集中度，緊急性，通知方法によって受け止め方が変化する．

また，介入内容だけでなく，文脈と提示方法が期待整合性に与える影響を確認するための例として，読書中の認知負荷が高いまたは低い文脈における声掛けなどもシナリオ候補となり得る．

6.3 期待整合性推定器の準備

期待整合性極性の推定器を学習するため，想定シナリオごとに文脈 C_t と介入 X_t を設定し，介入後に観測された外形的反応 R'_t を記録する設計が考えられる．この際、参加者から，介入が自身の期待に沿っていたか，反していたか，判断できないかを教師フィードバックとして取得することを想定する．回答方法は，質問紙，音声回答，ボタン入力などが候補となる。これらの外形的反応と教師フィードバックとの対応を用いて期待整合性極性 $\hat{Y}_t$ の推定器を構成し，運用時にはその推定結果と経験記録 H_t に基づいて較正方針 I_{t+1} を策定する流れを想定する．

6.4 比較条件

比較条件は，固定介入，較正保護機構なし，較正保護機構ありの 3 条件を想定する。固定介入条件では，文脈や履歴によらず一定強度で介入する．較正保護機構なし条件では，外形的反応から推定した期待整合性と経験記録に基づいて較正方針を策定し，次回以降の介入強度を調整する．較正保護機構あり条件では，これに 5 節の更新境界，根拠保持，停止・拒否尊重を加える．これらの比較により，較正による不整合反応の減少と，保護機構による不適切な介入強度変化の抑制を確認する．

6.5 観測・評価観点

評価観点は 6.1 節の各仮説に対応させる．**H1** では，教師フィードバックまたは実験者ラベルと，外形的反応から推定した期待整合性との一致傾向を確認する．これらのラベルは学習・評価時に限定して取得し，実運用での常時取得は想定しない．**H2** では，固定介入条件と比較し，不整合方向の反応が減少するか，および較正方針に応じて介入

© 2026 Information Processing Society of Japan

強度が変化するかを確認する．**H3** では，更新境界越え発生率，拒否・停止要求に反する介入の発生などを評価観点とする。

7. 期待される効果と今後の検証課題

7.1 提案モデルがもたらす効果

4 節で定式化した較正過程は，期待に沿わない介入の反復を抑え，利用者と人工システムの継続的な相互作用を支える設計指針となる．6 節では、この設計指針を今後経験的に検証するための方針を示した。提案モデルに期待される効果は，期待と介入の整合関係を扱うこと (2.5 節) を通じて，過信や不信につながり得る不適切な介入の反復を抑える点にある．

7.2 共在感を伴う継続的関係形成への示唆

3.3 節で述べた共在感研究とは，トラスト較正が継続的な人と人工システムの関係を支え得る点，および共在感が較正の有効性を左右する条件となり得る点で関連する．

本モデルが直接扱う対象は，利用者の主観的信頼そのものではなく，人工システム側の介入である．外形的反応から期待とのずれを推定し，較正方針を次回以降の介入に反映することで，期待に合わない振る舞いの反復を抑制する．したがって，本モデルの直接的な効果は，共在感を直接高めるものではなく，継続的な人とロボットの関係性を支える仕組みの一つとして位置づけられる．

一方で共在感は，トラスト較正が機能するための条件にもなり得る．利用者が人工システムの存在を自然に受け入れている場合，受容や拒否が外形的反応として現れやすく，較正が有効に働きやすい半面，共在感が高いほど誤った働きかけが許容され，過剰な信頼につながる可能性もある．

共在感とトラスト較正の具体的な相互作用については今後の検証が必要である．

7.3 主観的期待を扱うデジタル社会への応用可能性

4 節で定式化した較正過程は，家庭用対話型ロボットに限らず，利用者の主観的期待や受容性に応じて振る舞いを変える必要があるデジタルサービスにも応用できる可能性がある．例えば，個人情報提供に関する説明・同意支援，推薦システム，対話型 AI などでは，利用者が何を期待し，どのような状態で受容または拒否しているかを直接観測することは必ずしも容易ではない．

一方で，利用継続，設定変更，問い合わせ，拒否反応といった行動は観測可能である．外形的反応に基づく較正の考え方は，人の主観そのものを客観化するのではなく，主観に起因する問題を観測可能な情報から扱うための設計原理となることを狙いとしている．

なお，応用にあたっては，較正が過剰介入につながらないよう，介入コストや利用者の煩わしさにも配慮する必要がある．特に，推薦や対話型 AI のように介入頻度が高くなりやすいサービスでは，期待整合性の推定結果をそのまま介入強度の増減に結び付けるのではなく，較正保護機構によって更新幅や停止要求を適切に扱う必要がある．

7.4 デジタル社会のトラスト研究としての意義

以上の議論を踏まえると，本研究の意義は，7.1 節で述べた効果を，利用者期待を直接測定しにくい文脈一般に適用し，介入を継続的に較正するためのモデル要素を明確化した点にある．これは，HRI における継続的相互作用を支援する一つの設計アプローチとして位置付けられる．

また，5 節で述べた較正保護機構により，単なる適応制御ではなく，安全性，説明可能性，利用者による統制可能性を検討する余地がある．

7.5 適用範囲と限界

提案モデルの対象として，利用者期待が文脈により変動し，明示的なフィードバックが常に得られず，かつ介入後の外形的反応を一定程度観測可能な人工システム全般を対象とすることが期待できる．この条件を満たす例として，家庭用対話型ロボットに限らず，自動運転システム，医療・介護支援システム，対話型 AI などが考えられる．ただし，本モデルが直接扱うのは期待整合性推定，較正方針の策定，およびその方針を次回以降の介入に反映する過程であり，個人情報保護，推薦の公平性，説明責任，専門職判断，法的要件など，領域固有の課題は別途設計する必要がある．

本研究の限界は，外形的反応の観測と解釈にある．センサー条件，遮蔽，雑音，照明，反応の多義性，個人差により，期待整合性の推定には誤差が生じ得る．

さらに，較正保護機構にも限界がある．機構自体の信頼性，トラストアンカー，攻撃的入力に対する耐性については，今後の形式化と実装評価が必要である．また，5.4 節で触れた誘導的な相互作用により，拒否や停止すべき状況にも関わらず外形的反応としての観測が困難な場合には，本機構だけで利用者の意思に反する適応を抑えることは難しい．したがって，介入目的の制限，第三者監査，説明責任，利用者が後から設定や履歴を確認・撤回できる仕組みなども適宜組み合わせる必要がある．

8. おわりに

本稿は，継続利用環境におけるトラスト較正を，利用者の信頼状態を直接計測・測定する問題ではなく，人工システム側の介入を利用者期待に整合させていく問題として捉え，外形的反応に基づくトラスト較正モデルを提案した．本モデルは，介入後の外形的反応から期待整合性を粗粒度に推定し，その結果に基づいて較正方針を策定し，次回以降の介入に反映する．基本的な主張は，期待は測れなくても較正はできる，という点にある．

© 2026 Information Processing Society of Japan

本モデルは概念モデルであるため，今後は，本稿で示した検証方針に基づく実験設計の具体化，較正保護機構の形式化，ならびに応用領域ごとの適用条件の精査を進める必要がある．特に，7.5 節で述べた適用範囲の限界を踏まえ，各領域固有の制度的・倫理的要件との接続を今後精査する必要がある．

参考文献

[1] Dey, A. K.: Understanding and Using Context, *Personal and Ubiquitous Computing*, Vol. 5, No. 1, pp. 4–7 (2001).

[2] Barkhuus, L. and Dey, A. K.: Is Context-Aware Computing Taking Control away from the User? Three Levels of Interactivity Examined, *Proceedings of UbiComp 2003*, Lecture Notes in Computer Science, Vol. 2864, Springer, pp. 149–156 (2003).

[3] Okamura, K. and Yamada, S.: Adaptive Trust Calibration for Human-AI Collaboration, *PLOS ONE*, Vol. 15, No. 2, p. e0229132 (2020).

[4] Jian, J.-Y., Bisantz, A. M. and Drury, C. G.: Foundations for an Empirically Determined Scale of Trust in Automated Systems, *International Journal of Cognitive Ergonomics*, Vol. 4, No. 1, pp. 53–71 (2000).

[5] Schaefer, K. E.: The Perception and Measurement of Human-Robot Trust, PhD Thesis, University of Central Florida (2013).

[6] Kohn, S. C., de Visser, E. J., Wiese, E. and et al.: Measurement of Trust in Automation: A Narrative Review and Reference Guide, *Frontiers in Psychology*, Vol. Volume 12 - 2021 (2021).

[7] Lee, J. D. and See, K. A.: Trust in Automation: Designing for Appropriate Reliance, *Human Factors*, Vol. 46, No. 1, pp. 50–80 (2004).

[8] Parasuraman, R. and Riley, V.: Humans and Automation: Use, Misuse, Disuse, Abuse, *Human Factors*, Vol. 39, No. 2, pp. 230–253 (1997).

[9] Wischnewski, M., Krämer, N. and Müller, E.: Measuring and Understanding Trust Calibrations for Automated Systems: A Survey of the State-Of-The-Art and Future Directions, *Proceedings of the 2023 CHI Conference on Human Factors in Computing Systems (CHI '23)* (2023).

[10] Komatsu, T., Kurosawa, R. and Yamada, S.: How Does the Difference Between Users' Expectations and Perceptions About a Robotic Agent Affect Their Behavior?, *International Journal of Social Robotics*, Vol. 4, No. 2, pp. 109–116 (2012).

[11] Chen, M., Nikolaidis, S., Soh, H. and et al.: Planning with Trust for Human-Robot Collaboration, *Proceedings of the 2018 ACM/IEEE International Conference on Human-Robot Interaction (HRI '18)*, Chicago, IL, USA, ACM, pp. 307–315 (2018).

[12] Chen, M., Nikolaidis, S., Soh, H. and et al.: Trust-Aware Decision Making for Human-Robot Collaboration: Model Learning and Planning, *ACM Transactions on Human-Robot Interaction*, Vol. 9, No. 2, pp. 1–23 (2020).

[13] Bainbridge, W. A., Hart, J., Kim, E. S. and et al.: The Effect of Presence on Human-Robot Interaction, *Proceedings of the 17th IEEE International Symposium on Robot and Human Interactive Communication (RO-MAN 2008)*, pp. 701–706 (2008).

[14] Heerink, M., Kröse, B., Evers, V. and et al.: Assessing Acceptance of Assistive Social Agent Technology by Older Adults: The Almere Model, *International Journal of Social Robotics*, Vol. 2, No. 4, pp. 361–375 (2010).

[15] 有村勇輝，高山直之，本居恒輝，　玉井睦，松永昌浩，今井倫太：Inaction を手がかりとした共在感醸成型ロボットの介入が人の心情に与える影響評価，人工知能学会全国大会論文集 第 40 回 (2026) (2026).

[16] Leite, I., Martinho, C. and Paiva, A.: Social Robots for Long-Term Interaction: A Survey, *International Journal of Social Robotics*, Vol. 5, No. 2, pp. 291–308 (2013).

[17] Lee, M. K., Forlizzi, J., Kiesler, S. and et al.: Personalization in HRI: A Longitudinal Field Experiment, *Proceedings of the 7th Annual ACM/IEEE International Conference on Human-Robot Interaction (HRI '12)*, Boston, MA, USA, ACM, pp. 319–326 (2012).

[18] Sidner, C. L., Lee, C., Kidd, C. D. and et al.: Explorations in Engagement for Humans and Robots, *Artificial Intelligence*, Vol. 166, No. 1-2, pp. 140–164 (2005).

[19] Castellano, G., Pereira, A., Leite, I. and et al.: Detecting User Engagement with a Robot Companion Using Task and Social Interaction-Based Features, *Proceedings of the 2009 International Conference on Multimodal Interfaces (ICMI-MLMI '09)*, pp. 119–126 (2009).

[20] Kroll, J. A., Huey, J., Barocas, S. and et al.: Accountable Algorithms, *University of Pennsylvania Law Review*, Vol. 165, pp. 633–705 (2017).

[21] Raji, I. D., Smart, A., White, R. N. and et al.: Closing the AI Accountability Gap, *Proceedings of the 2020 Conference on Fairness, Accountability, and Transparency (FAT* '20)*, pp. 33–44 (2020).

© 2026 Information Processing Society of Japan

9. 研究倫理的配慮

家庭用対話型ロボットを題材とする場合，観測最小化，同意取得，停止権，データ保存範囲，事後説明を明確にする必要がある．私的な生活空間での実験や実運用においては，映像や音声を常時記録することは望ましくないため，取得する情報の種類，保存期間，利用目的を限定する必要がある．

また，利用者が観測や介入を拒否できること，途中で実験を停止できること，収集されたデータの扱いについて説明を受けられることを保証する必要がある．

付　　録

A.1 付録表

表 A·1 提案モデルで扱う要素の具体化例

記号	意味	具体化例
C	文脈	作業中，休息中，集中時，移動前など
H	経験記録	過去の文脈，介入，観測結果，期待整合性極性，較正方針等の記録
$\hat{E}$	期待仮説	「今は弱い通知が望ましい」「集中時は控えるべき」等
X	介入	声掛け，頭部動作，手腕動作，接近，通知などの振る舞いとその強度
R'	外形的反応	取得された顔向き，作業継続／停止，応答遅延，短い返答，拒否
U	観測条件	カメラ，各種センサー，マイクなどの観測手法，およびそれらの設置位置，画角，解像度，センサー種別，観測精度等の観測条件
$\hat{Y}$	期待整合性極性	$+$：期待に沿う，$-$：期待に反する，NA：判断不能
I	較正方針	0：介入しない，1：介入を弱める，2：そのまま，3：介入を強める
G	較正保護機構	更新境界，根拠保持，停止・拒否尊重機能

表 A·2 検証方針の概要

項目	例
対象	家庭用対話型ロボットまたは模擬エージェント
比較条件	固定介入，較正保護機構なし，較正保護機構あり
シナリオ	集中作業中通知，休息中提案，移動前注意喚起，軽度リスク時の警告
外形的反応	顔向き，応答遅延，作業継続または停止，短い返答，拒否
教師フィードバック	質問紙，音声回答，ボタン入力
評価観点候補	期待整合性推定と教師フィードバックの一致傾向，拒否後の介入強度変化，更新境界越え発生率

© 2026 Information Processing Society of Japan