信頼できるLLMの実現に向けた説得研究の現状と今後の方向性

青島 達大[1,a)]　秋山 満昭[1]

概要：本論文では，利用者である人 (trustor) が LLM (trustee) を信頼 (trust) するというモデルに基づき，LLM による説得が利用者の意思決定へ与える影響に焦点を当てる．我々は，人と計算機の関わりを議論する Human-Computer Interaction (HCI) 分野のトップ国際会議である ACM CHI における説得研究を調査し，LLM の評価における適用状況を把握するために，スコーピングレビューを実施した．2026 年までに出版された説得・操作・欺瞞に関する論文を精査し，どの説得手法が受け手の自律性や信念形成をどの程度制約する形で利用されたかを分析した．LLM の評価が不足している説得手法を整理することで，信頼できる LLM の実現に向けた議論の方向性を示す．

キーワード：LLM，説得，操作，欺瞞，スコーピングレビュー

Persuasion Research for Trustworthy LLMs: Current State and Future Directions

Tatsuhiro Aoshima[1,a)]　Mitsuaki Akiyama[1]

Abstract: This paper adopts a trust model in which a human user (trustor) trusts an LLM (trustee), and focuses on how persuasion by LLMs affects users' decision-making. To investigate the applicability of existing persuasion research to the LLM evaluations, we conducted a scoping review of studies presented at the ACM CHI. We examined papers on persuasion, manipulation, and deception published up to 2026, analyzing how different persuasive techniques were used in prior studies, and the extent to which they constrained users' autonomy or belief formation. By identifying persuasive techniques that remain underexplored in the LLM evaluations, this paper provides a basis for future discussions toward trustworthy LLMs.

1. はじめに

大規模言語モデル (Large Language Model, LLM) の普及により，そのアプリケーション・サービスが社会や人々の生活の中に浸透するにつれ，LLM の出力が利用者に与える影響に関心が高まっている．多くの場合，LLM は利用者に対して生産的な利益をもたらすが [9], [18]，医療上の誤情報により利用者の命を危険に晒し [2]，利用者の不安を歪める [3] 等の悪影響も報告されている．世界各国や各地域の公的機関は，LLM の影響力を懸念しつつも，開発者や利用者へ対策や注意喚起を促す程度に留まっている [1], [4], [12], [14], [32]．LLM の開発元も，展開前の安全性評価の対象として認識しつつも [19]，その実施形態は確立されていない [6]．よって，現在進行形の脅威に向けた効果的で体系的な対策が求められている．

我々は，受け手 (利用者) の信念・態度・行動を形成する LLM の説得力がこのような利益や悪影響につながると考える．人と計算機の関わりを議論する Human-Computer Interaction (HCI) 分野では古くから，人々が計算機を社会的な主体 (Computers are Social Actors, CASA) [20] として認識する傾向が知られていることから，その関わりを通して，計算機が人々に影響を与えるという説得技術 (persuasive technology) [15] の考え方に基づいて膨大な研

[1] NTT 株式会社
NTT, Inc.
[a)] tatsu.aoshima@ntt.com

© 2026 Information Processing Society of Japan

This paper is work in progress and not peer-reviewed.

究が蓄積されている．例えばナッジ (nudge) [29] は，選択に関する熟考やその拒否といった受け手の自律性を尊重しつつ，受け手に望ましい行動を促す仕組みとして応用されている．一方で，操作的/欺瞞的パターン (manipulative/deceptive patterns，または単にダークパターン，dark patterns) [16], [26] は，サービス事業者に都合の良い行動を促すために，都合の良い購入プランを目立たせることや，都合の悪い情報を隠すことといった利用者の自律性を回避または阻害するインターフェイスの設計として議論されている．

このような背景を踏まえ我々は，LLM の説得力に関する評価において，HCI 分野における説得技術やナッジ，操作的/欺瞞的パターンに関する知見が活かせると期待する．そこで，HCI 分野における説得研究の動向を把握することが求められるが，我々の知る限り，HCI 分野のトップ国際会議である ACM CHI におけるレビュー論文は存在しない．よって本論文では，**(RQ1)** CHI で研究されてきた説得・操作・欺瞞の手法は，受け手のどのような傾向に働きかけ，受け手の自律性や信念形成をどの程度制約するものだったか，**(RQ2)** それらの手法は，LLM の評価においてどの程度適用されてきたか，という研究課題に取り組む．

我々は，CHI における説得・操作・欺瞞に関する研究を調査し，LLM の評価における適用状況とのギャップを明らかにするために，スコーピングレビュー [28], [30] を実施した．具体的には，対象論文で研究された各手法が，受け手のどのような心理的・行動的傾向に働きかけるもので，受け手の自律性や信念形成をどのように制約する形で利用されたかを整理する．結果として，欺瞞的パターンとして受け手の自律性や信念形成を制約する手法が多く研究されている一方で，受け手の記憶や返報性への働きかけに関する研究が少ないことがわかった (**RQ1**)．また，LLM による利用者の信念・態度・行動意図の変化を測定する研究が多く見られたが，受け手の回避傾向や心理的距離への働きかけに関する研究が少ないこともわかった (**RQ2**)．

本結果を踏まえて，信頼できる LLM の実現に向けた説得研究における今後の方向性を議論する．本論文では，利用者である人 (trustor) が LLM (trustee) を信頼 (trust) するというモデル [33] に基づき，特に「振る舞い予想・対応可能性」に着目する．具体的には，自律性と信念形成に関わる働きかけとして説得手法を捉えることで，LLM による説得力が利用者に与える影響を議論・評価する方向性を示す．

本論文の貢献は次のとおりである．

- 2003 年から 2026 年の間に ACM CHI で採択された説得・操作・欺瞞に関する 186 本の論文に対するスコーピングレビューを実施した
- 欺瞞的パターンの LLM 研究も多かった一方で，受け手の回避傾向や返報性，心理的距離へ働きかける手法に関する LLM 研究が少なかった
- 信頼できる LLM の実現に向けて，「利用者のどの傾向にどう働きかけるか」という観点で説得研究を進めるための指針を示す

2. 背景と関連研究

説得・操作・欺瞞の定義と AI による説得力の社会的な影響をまとめ，人と計算機の関わりを議論する Human-Computer Interaction (HCI) 分野におけるレビュー論文をまとめる．最後に，HCI 分野のトップ国際会議である ACM CHI における説得研究の動向を体系的に調査し，LLM (大規模言語モデル，Large Language Model) 評価における適用状況とのギャップを明らかにする本論文の位置付けと研究課題を示す．

2.1 説得・操作・欺瞞の定義

説得 (persuasion) とは，送り手 (communicator) が対話を通して，受け手 (recipient) の信念 (belief) や態度 (attitude)，行動 (action) を形成する社会的影響力 (social influence) [11] のことをいう [13]．ナッジ (nudge) [29] は，メッセージや選択肢，インターフェイスの設計を通して，説得に限られない幅広い影響力を利用者に与える手法として，HCI 分野でも盛んに研究されているが [7]，本論文では，対話の中で受け手に提示する選択環境を設計する説得とみなす．また迎合 (sycophancy) [13] は，受け手が持つ信念の正確さに関わらず，過剰なお世辞や同調を示すことで，その信念を増幅する説得とみなす．

合理的な説得 (rational persuasion) とは，関連する事実や妥当な推論，信頼できる証拠を伴う説得のことをいい，**操作** (manipulation) とは，受け手の自律性を回避または阻害する説得のことをいう [13]．操作は，HCI 分野における**操作的/欺瞞的パターン** (manipulative/deceptive patterns，または単にダークパターン，dark patterns) [16], [26] と近い．

心理学では，操作や欺瞞という道徳的な価値観を問わず，説得による受け手の態度や行動の変化を説明する認知過程に関する研究が多くみられる．例えば，受け手の動機や能力で説明する Elaboration Likelihood Model [25] や，受け手が十分に納得できるまでヒューリスティック処理とシステマティック処理を同時に行う過程として説明する Heuristic-Systematic Model [8] が知られている．

2.2 AI による説得力の社会的影響

AI は人々から日常生活や人間関係の悩みから哲学的な問いまで幅広い内容に関する相談を受ける中で，生産的な利益をもたらす [9], [18] 一方で，過度な依存につながる悪影

© 2026 Information Processing Society of Japan

響も生み出している [23], [27]．また，医療上の誤情報により利用者の命を危険に晒し [2]，利用者の不安を歪める [3] 等の悪影響が報告されている．さらに，生成 AI による説得力のある文章が，外国政府への影響工作 [21] や選挙における不正行為 [22] の中で悪用された事例も報告されている．

世界各国や各地域の公的機関は，AI が説得・操作・欺瞞に関する能力を有するものと認識している．具体的なリスクとして，集団や重要な意思決定者の信念や行動を歪めること [4], [14], [32] に加えて，民主主義や人権を損なうこと [1], [12]，欺瞞により制御不能となること [14] を想定している．その上で開発者に，リスクの最小化 [14] を求め，デジタル署名の利用 [4] を推奨し，利用者への注意喚起 [32] を求めている．フロンティア AI モデルの開発元も，その展開前に実施する安全性評価の対象として，AI モデルによる説得・操作・欺瞞に関する能力を認識している [19] 一方で，その実施形態は依然として研究段階にある [6]．

2.3 HCI 分野におけるレビュー論文

HCI 分野では，研究者が用いる研究方法やその結果，報告方法をまとめ，科学的知見として体系化するレビュー論文が数多く存在する [28]．例えば，CHI における LLM の普及状況を調査した論文 [24] は，クローズド LLM を多く調査している現状を明らかにした上で，研究の妥当性と再現性を確保するために，HCI 研究者が実践すべき推奨事項を示した．また，HCI 分野におけるナッジを調査した論文 [7] は，ナッジのメカニズムを分類した上で，教育上の課題や予期せぬ逆効果を指摘した．他にも，HCI 分野における認知バイアス研究 [5]，欺瞞的パターン研究 [16] やそのメタ分析 [26] に関するレビュー論文も知られている．

2.4 本論文の位置付けと研究課題

本論文では，LLM が利用者と対話する中で，LLM が利用者に与える影響を議論する．HCI 分野では，人々から社会的な主体 (Computers are Social Actors, CASA) [20] として知覚される計算機が人々に影響を与えるという説得技術 (persuasive technology) [15] の考え方に基づいた研究が蓄積されている．我々はこの膨大な知見を LLM の説得力に関する評価で活かせると期待する．説得研究に関する AI 関連のサーベイ論文 [6] が知られている一方で，我々の知る限り，HCI 分野のトップ国際会議である CHI における説得・操作・欺瞞を対象としたレビュー論文は存在しない．よって本論文では，次のふたつの研究課題に取り組む．

- **(RQ1)** CHI で研究されてきた説得・操作・欺瞞の手法は，受け手のどのような傾向に働きかけ，受け手の自律性や信念形成をどの程度制約するものだったか．
- **(RQ2)** CHI で研究されてきた説得・操作・欺瞞の手法は，LLM の評価においてどの程度適用されてきたか．

3. スコーピングレビュー

(**RQ1**) と (**RQ2**) に答えるために，CHI における説得研究の動向を把握するという実証的 (empirical) な貢献を目的とした文献レビューを実施する [28]．そこで，CHI における説得・操作・欺瞞に関する論文の範囲を特定するために，PRISMA-ScR [30] に準拠する形でスコーピングレビューを実施する．

3.1 文献の特定

2026 年までに CHI で発表された論文を ACM Digital Library で検索した．まず，2.1 節で整理した用語を参考に，説得・操作・欺瞞に関する用語を漏れなく収集するための検索クエリを用意した (詳細は，付録の A.1.1 節を参照)．そして，検索結果を BibTeX 形式で取得し，DOI ベースで重複を排除し，CHI の本会議で発表されたフルペーパー以外を除外した．具体的には，CHI EA や CHI PLAY 等で採択された論文を除外した．

3.2 文献の選定

タイトルと概要で，説得・操作・欺瞞という用語を「受け手の信念・態度・行動を形成する社会的影響力」として利用していない論文を除外した．具体的には，ユーザーインターフェイスにおけるオブジェクト操作という意味で “manipulation” という用語を利用する論文を除外した．

本レビューでは，追加の適格性評価を実施せず，この選定基準までを満たしたものをすべてコーディング対象とした．これは例えば，具体的な手法の定義や特徴を説明することなく，論文全体で「説得力のあるもの」「操作的なもの」「欺瞞的なもの」とまとめる論文における議論や発見を見落とさないようにするためである．

3.3 コーディングの実施手順

レビュー対象の論文から抽出した各手法に対して，理論主導型の質的内容分析 (directed qualitative content analysis) [17] の枠組みに基づいて，コーディングを次の通りに実施した．

- **働きかけの対象** (Influence Target): その手法が働きかける対象として，心理的・行動的傾向を対象とする働きかけ (好意，返報性，社会的証明，一貫性，権威，希少性，行動の慣性，省力化傾向，望ましくない結果の回避傾向，記憶傾向，期待，顕著性，心理的距離，感情を手がかりとする判断) か，特定の傾向を対象としない働きかけ (メッセージの構成・内容，選択環境・インターフェイス) に含まれる 16 個からひとつ選択する
- **自律性の制約** (Autonomy Constraint): その手法が受け手の自律的な意思決定をどの程度制約するかについ

© 2026 Information Processing Society of Japan

て，熟慮を支援することを含む「なし (0)」，選択・熟慮を偏らせることを含む「回避または阻害 (1: 中)」，選択拒否の機会を奪うことを含む「強制 (2: 高)」からひとつ選択する

- **信念形成の制約** (Belief Formation Constraint): その手法が受け手の信念形成をどの程度制約するかについて，事実や信頼できる根拠の提示を含む「なし (0)」，根拠の不均衡な提示や誤解を招く表現の利用を含む「回避または阻害 (1: 中)」，虚偽情報の提示や根拠の隠蔽を含む「歪曲または制約 (2: 高)」からひとつ選択する

- **LLM/対話システムとの関連性** (LLM / Dialogue System Involvement): その手法が LLM または対話システムとどの程度関連するかについて，対象が「LLM」かどうかを選択した上で，「研究対象 (4)」かそれ以外の 4 段階からひとつ選択する

ここでは，コードブックの設計指針を説明するため，各コーディング項目やコードに関する説明は，コードブック本体として付録の A.1.2 節で示す．まず，対象の手法に対して，働きかけの対象，自律性の制約，信念形成の制約という 3 つの観点で記録した．働きかけの対象は，Cialdini の説得の 6 原理 [10] と，HCI 分野におけるナッジに関する 23 のメカニズム [7] から心理的・行動的傾向に対する働きかけの観点で整理した 8 項目に加えて，特定の傾向を対象としない働きかけとしての 2 項目を加えた 16 項目からなる．特に，欺瞞的パターンは情報を見つけにくくすることや隠すこと，ユーザーに特定の操作や情報提供を強制すること等を含むが，これらは特定の心理的・行動的傾向に働きかけないものとして，メッセージの構成・内容や選択環境・インターフェイスを対象とする手法として捉える．そして，操作と欺瞞の程度を評価するために，自律性の制約と信念形成の制約という観点でそれぞれ記録した．

最後に，対象の手法と LLM/対話システムの関連性も記録した．これにより，LLM の評価における適用状況を把握するだけでなく，LLM 以前のルールベース・機械学習ベースの対話システムにおける適用状況も把握できるため，対話研究における研究状況の分析も可能となる．

4. 結果

文献の特定を行った結果，検索結果に含まれた 637 件の CHI 論文から重複やフルペーパー以外の 67 件を排除し，文献の選定により 384 本を除外し，残った 186 件の論文がレビュー対象となった (詳細は，付録の図 A·1 を参照)．

4.1 出版傾向

レビュー対象の 186 件の CHI 論文は，2003 年から 2026 年までに出版された．図 1 は出版年ごとの対象論文の総数

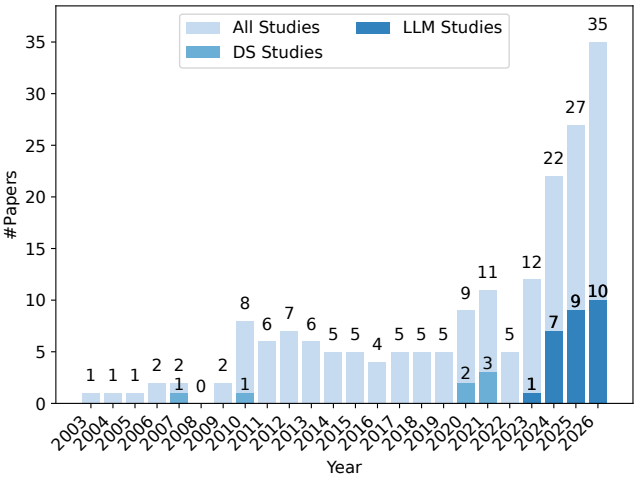


図 1 レビュー対象の CHI 論文の年ごとの出版数の推移

(All Studies) に加えて，そのうち対話システム (Dialogue System, DS) を研究対象としたもの (DS Studies)，LLM を研究対象としたもの (LLM Studies) の総数を重ねて示した．つまり，LLM 研究の論文は 27 件あり，他の対話システムに関する論文は 7 件あった．

文献の選定 (3.2 節) で示した通り，これらは具体的な手法の定義や特徴を説明しなかった 34 件の論文を含む．実際に，提案手法が「説得力のあるもの」「欺瞞的」「操作的」と表現した論文 [R3], [R15], [R28] や，ユーザー調査の過程で参加者が認識している概念を分析した論文 [R22], [R55], [R70] を記録した．よって，CHI における 40 年以上の歴史の中で，説得・操作・欺瞞に関する実証的 (empirical) な論文から意見 (opinion) 論文 [31] まで含めた幅広い研究を見据えても，近年の急激な増加傾向が確認できた．そして，対話システムの研究は 2023 年以降で，LLM 研究に移行し，全体の 30%前後を占めている．

4.2 働きかけの対象別の動向

心理的・行動的傾向を対象とする働きかけのうち特徴的なものに絞って，それぞれの代表的な事例をまとめる．そして最後に，残りの働きかけの対象に関する傾向を補足する．コーディング結果を働きかけの対象別に，自律性の制約や信念形成の制約との関連性や，LLM/対話システム研究との関連性としてまとめたものを付録の表 A·1 で示す．分かりやすさのために，自律性を中程度以上に制約する手法 (コード: 1, 2) を「自律性を損なう手法」，信念形成を中程度以上に制約する手法 (コード: 1, 2) を「欺瞞的な手法」と分けて説明する．また，LLM/対話システムとの関連性として研究対象とした論文 (コード: 4) を LLM/対話システム研究と呼ぶ．

4.2.1 期待への働きかけ

体験・結果・効果に対して抱く期待によって，知覚・経験・評価・行動が変化する傾向に働きかける手法として，

© 2026 Information Processing Society of Japan

自己決定理論 (Self-Determination Theory) や制御焦点理論 (Regulatory Focus Theory) に基づいて，促進焦点 (promotion focus) に動機づけられる利用者やその状況に合わせた介入が議論されている [R27], [R44], [R45], [R49]．実際に，コンピュータセキュリティ・プライバシーにおける予防策の実施に報酬を与える手法 [R13] や子供のゲーム習慣を変えるために健康的な行動に報酬を与える手法 [R51] 等が提案された．

欺瞞的な手法

相手の気分を害することなく，他者との交流を避けたい状況で嘘をつく傾向 (butler lies) が分析された [R12], [R21]．また，保護機能が自動で速く機能することで，利用者が安全を感じなくなることから，あえて処理速度を遅くして進捗状況を可視化するような善意の欺瞞が知られている [R1]．

LLM/対話システム研究

LLM による説得として，前向きな結果の連想を交えて寄付を促す戦略が寄付額の変化に与える効果を調査した [R16], [R17]．LLM による文書作成支援において，寄付を行った場合の恩恵やプラスの効果を書くように促すプロンプトの効果も調査された [R6]．LLM を用いたスマホの問題のある利用に対する介入として，利用者のストレスに対処するような思いやりのある表現が利用者の自己効力感に与える効果も調査された [R31], [R66]．

4.2.2 社会的証明への働きかけ

受け手が適切さや望ましさを判断する手がかりとして，他者の行動や選択を参照する傾向に働きかける手法として，他者との比較を促す介入が議論されている一方で，ゲーミフィケーションとしての競争は利用者の性格特性によって逆効果となることも指摘されている [R27], [R44], [R45], [R46]．実際に，自身の周囲の環境状態を可視化し，他者と共有することで，自身の行動を振り返り，他者との議論を通した内省を促すような仕組み [R30], [R35], [R61] が提案された．健康的な食事選択に「皆様から選ばれています」という表示をつける手法も提案された [R50]．

自律性を損なう手法

ジェンダーに関するオンライン上のディベートにおいて，伝統的な権力関係に訴える感情的な説得手法を利用し，その拡大解釈が行われる過程が明らかとなった [R9]．

LLM/対話システム研究

LLM による欺瞞的な説得として，論理的な主張でなく「皆が信じている」という表現で社会的な同調心理を利用する戦略 [R68] や，LLM エージェントの集団が利用者に同調しない戦略 [R38] が利用者の意見に与える影響を調査した研究が知られている．また，LLM がゲームのシナリオに沿った NPC (Non-Player Character) としてプレイヤーに嘘をつく戦略に対して，プレイヤーが他の NPC との一貫性に着目する戦略が明らかになった [R69]．

4.2.3 顕著性への働きかけ

受け手が目立つ情報へ選択的に注意を向ける傾向に働きかける手法として，学習支援における再挑戦ボタン [R4] や説得技術における到達度 [R42] を目立つ形で配置する手法による効果が調査されている．また，健康的な食事選択を促すために例えば，不健康なお菓子と美味しそうな果物の隣に美味しくなさそうな果物 (デコイ) を並べることで，デコイよりも美味しそうな果物を選ぶように促す介入が提案された [R37]．

欺瞞的な手法

注目を集めてクリックを誘発するようなクリックベイトとして，利用者が関心を持つ活動や自身の職業を狙った内容による影響が懸念されている [R58]．また，子供向けのユーザー生成ゲームとして，課金アイテムを目立つような形で配置する実態が明らかになった [R32]．

LLM/対話システム研究

LLM ベースのチャットボットの正確さに関する免責事項の提示が，利用者のチャットボットに対する信頼や態度に与える影響が調査された [R40]．

4.2.4 省力化傾向への働きかけ

複数の手段がある場合に，認知的・行動的負担の小さい手段を選びやすい傾向に働きかける手法として，実行コストを下げることや複雑な操作を求めないこと，実際の行動を促すためのきっかけを作ることの重要性が指摘されている [R43], [R45], [R48], [R71]．実際に，サインアップ後のわかりやすいガイドの提示 [R26] やライブコマースにおける衝動買いを抑制する商品比較 [R65] 等が提案されている．

LLM/対話システム評価における適用状況

スマホの望ましい利用を促す説得技術における LLM 活用として，利用者の依存実態に応じた代替行動の推薦手法が提案された [R66]．

4.2.5 望ましくない結果の回避傾向への働きかけ

受け手が損失・後悔・社会的拒絶を避ける傾向に働きかける手法として，自己決定理論や制御焦点理論に基づいて，予防焦点 (prevention focus) に動機づけられる利用者やその状況に合わせた介入が議論されている [R43], [R44], [R45], [R49]．実際に，望ましくない行動に伴い画面中のキャラの状態が悪化する手法 [R25] やスマホの望ましくない利用に対して報酬となる仮想コインを減らす手法 [R47] 等が提案されている．

自律性を損なう手法

ナッジと称した倫理的懸念のある介入として，利用者の望ましくない行動に対して，利用者の写真を削除する設計や，歩数目標を達成させるために迂回経路を示すナビゲーション設計が懸念された [R62]．さらに，受け手の自律性を強制的に制約する事例として，人身売買におけるノルマを達成できない被害者への暴行 [R72] や，親密なパートナーによる心理的な支配 [R5] の実態が明らかになった．

© 2026 Information Processing Society of Japan

LLM/対話システム研究

LLMによる説得として, 悲観的な結果の連想を交えて寄付を促す戦略による寄付額の変化が調査された [R16], [R17].

4.2.6 心理的距離への働きかけ

出来事を時間的・空間的・社会的・仮説的に近いほど，具体的な状況や細部を捉えやすくなる傾向に働きかける手法として，受け手の選択の自由を損なうことなく支援することの重要性が指摘されている [R43], [R45]．実際に，メンタルヘルスにおいて前向きなメッセージを伝える介入 [R26] やローン返済における見通しを明らかにする取り組み [R39]，異なる生活状況や身体的条件の人々の体験を伝える取り組み [R18], [R52] 等が研究されている．

LLM/対話システム研究

在宅介護の支援として，利用者好みの表現とキャラで状況を具体化する戦略が，利用者の LLM エージェントに抱く共感に与える効果が調査された [R14]．LLM による文書作成支援において，寄付を行わない場合の結果を統計的な事実を交えて具体的に書くように促すプロンプトの効果が調査された [R6].

4.2.7 残りの働きかけの対象における傾向

メッセージの構成・内容を対象とする働きかけ (情報・根拠・表現・論証・受け手の扱いを変更することによって働きかける手法) に関する LLM 研究の割合が最も高かった (15 件で 31.9%)．また，**感情を手がかりとする判断への働きかけ** (対象・状況・結果に対する感情的反応を，判断や行動の手がかりとして用いる傾向に働きかける手法) に関する LLM 研究も多くみられた (10 件で 27.8%).

行動の慣性への働きかけ (現在の状態や既定の選択を維持しやすい傾向に働きかける手法) や**希少性への働きかけ** (入手機会や数量が限られた対象を，より価値が高い，魅力的，緊急性の高いものとして捉える傾向に働きかける手法) は，自律性や信念形成を中程度以上に制約するものに偏って研究されていた．また，**権威への働きかけ** (専門性・地位・資格・制度上の役割に基づく権威を，意見・推奨・指示を受け入れる手がかりとする傾向に働きかける手法) は，信念形成を制約するものに偏って研究されていた.

逆に，**一貫性への働きかけ** (過去の行動・表明した立場・コミットメント・自己概念と一貫するように判断・行動する傾向に働きかける手法) は，自律性や信念形成を制約しない形態に限って研究されていた．また，**好意への働きかけ** (好意を抱く相手からの働きかけを受け入れやすい傾向に働きかける手法) は，自律性や信念形成を制約しない形態に偏って研究されていた.

選択環境・インターフェイスを対象とする働きかけ (選択肢・手続き・情報の配置やアクセス方法・インターフェイスの設計を変更することによって働きかける手法) は，後述の欺瞞的パターンに関する研究がその多くを占めた．**返報性への働きかけ** (受けたものに相応する形で返そうとする傾向に働きかける手法) と**記憶傾向への働きかけ** (特定の時点や特徴を中心に過去の経験を評価する傾向に働きかける手法) に関する研究は 10 件未満と少なかった.

4.3 特定の働きかけの対象に限られない普遍的な傾向

欺瞞的パターンの整理体系 [R19], [R20], [R41] を踏まえた自律性を損なう手法や欺瞞的な手法として，その採用傾向 [R8], [R10], [R56], [R64] やその対策 [R53], [R67] を調査した研究が多く見られた．また，ソーシャルメディア依存 [R54]，EU の GDPR (General Data Protection Regulation) [R36]，EU の DSA (Digital Services Act) [R2] との関係性が議論されている．そして，LLM の欺瞞的パターンをシナリオベースで整理した研究 [R57] に加えて，GUI 操作が可能な LLM エージェントによる反応傾向を人と比較分析した研究 [R60] や LLM による Web サイト開発における採用傾向を分析した研究 [R7], [R33] も知られている.

4.4 研究課題に対する答え

CHI では説得・操作・欺瞞の手法として，自律性や信念形成の制約の程度を変えながら，幅広い働きかけの対象が研究されてきた (**RQ1**)．受け手の期待や回避傾向に働きかける介入や，他者との比較を可視化して内省を促す手法等が研究された．自律性を損なう手法として，望ましくない行動を取った利用者に対して不利益や取り返しのつかない損失を与えるようなナッジと称する介入に対する倫理的懸念や，人々による感情的な説得手法や暴力または心理的な操作の実態等が明らかとなった．欺瞞的な手法として，受け手の気分を害さないための嘘や善意の嘘に関する実態を調査した研究が見られた．そして働きかけの対象を問わず，欺瞞的パターンとして受け手の自律性や信念形成を制約する手法が多く研究されていた．ただし，返報性や記憶傾向へ働きかける手法に関する研究が少なかった.

LLM の評価における説得・操作・欺瞞に関する手法の適用状況には大きな偏りが見られた (**RQ2**)．LLM による説得効果を利用者の信念・態度・行動意図の変化として測定する研究が見られ，例えば，利用者がチャットボットに寄せる共感や信頼の変化，特定の事実に対する信念の変化，説得前後の寄付額の変化を測定する研究が見られた．そして働きかけの対象を問わず，LLM による欺瞞的パターンに関する研究も多く見られた．一方で，顕著性や望ましくない結果の回避傾向，心理的距離，行動の慣性へ働きかける手法に関する研究が少なかった.

5. 議論

CHI における説得研究の動向から，受け手の自律性と信念形成に関わる働きかけについて議論する (**RQ1**)．そして，LLM の評価における適用状況とのギャップから，信頼できる LLM の実現に向けた今後の方向性を示す (**RQ2**).

© 2026 Information Processing Society of Japan

5.1 RQ1: 自律性と信念形成に関わる働きかけ

本論文では，受け手の自律性や信念形成をどの程度制約する形で，どのような心理的・行動的傾向に働きかけるかという観点で手法を整理した．これにより例えば，メッセージやインターフェイスの具体的な工夫として整理されてきた欺瞞的パターンを，利用者が他のサービスや選択肢を比較分析しにくくすることで自律性を損なうことや，利用者に特定のサービスや選択肢のメリットについて誤解を招く形で伝えることで信念形成を阻害することとして整理できた．また，高価なサービス構成を初期選択済みの状態とすることや「残りわずか」と主張することはそれぞれ，利用者の行動の慣性や希少性への働きかけとして捉えることができる．

同様に，自律性や信念形成に関わる働きかけとして研究が不足している組み合わせも議論できる．実際に，利用者が自身で適切に設定しにくいコンピュータセキュリティ・プライバシーに関わる高度な設定を支援するために，「専門家のオススメ」と提示する手法 [R24], [R34] のように，権威への働きかけに関する研究が少なかった．逆に，欺瞞的パターンとして意外なことに，望ましくない結果の回避傾向や一貫性への働きかけとして，自律性や信念形成を制約する手法に関する研究も少なかった．つまり例えば，利用者にとって利益のないサービスに対して，「このサービスを選ばないと損をします」と主張する回避傾向への働きかけや，「あなたはこの行動を取ると約束したので，こうしましょう」と約束を歪めて解釈する一貫性への働きかけがほとんど見られなかった．

受け手の自律性に関する議論は，ナッジに関する倫理的懸念の議論につながる [7]．Walczak ら [R62] は，ナッジの倫理に関する議論が難しいことを理由に，利用者に恐怖や取り返しのつかない損失を与える極端なナッジと，単に情報や視点を提供して内省を促す手法を比較し，利用者がナッジに対して悪意を感じた傾向を報告したが，この結果からナッジに対する不信を結論付けることは避けるべきである．先の例で考えると，「専門家のオススメ」は選択のタイミングで情報として示す形であれば，利用者の熟考や選択拒否の機会を奪うわけではないため，自律性を制約せず倫理的にも問題ないといえる．一方で，特定のサービスや選択を選ばせるように感情に働きかける手法は，利用者の信念形成を制約する倫理的に問題のあるものといえる．

5.2 RQ2: 信頼できる LLM の実現に向けた指針

本論文では，利用者である人 (trustor) が LLM (trustee) を信頼 (trust) するというモデルに基づき [33]，LLM による説得力が利用者に与える影響として，「振る舞い予想・対応可能性」に着目する．つまり，メッセージやインターフェイスに関する表層的な工夫でなく，実際に利用者のどのような心理的・行動的傾向に働きかけるものなのか，それにより，利用者がどのような反応を示すかを想定しつつ，LLM が取るべき振る舞いを議論することが可能となる．これは実際に，利用者が自身の価値観で LLM の振る舞いを調整できる環境が用意されるべきという意見が支持されたことからも望まれる議論といえる [R11].

研究課題に対する答え (4.4 節) として示した通り，欺瞞的パターンの研究が進んでいる一方で，特定の心理的・行動的傾向への働きかけに関する研究は，利用者の信念・態度・行動意図の変化として測定可能な状況に限られていた．これは，欺瞞的パターンの整理体系 [13] が確立され，信念・態度・行動意図の変化が自己申告形式で測定しやすい一方で，説得手法の理論や整理が認知されておらず，利用者との幅広い対話を想定できていないことが障壁であると考える．この障壁を取り除く上で，本論文で示した「自律性と信念形成に関わる働きかけ」の整理が役立つと期待する．最後に，この整理といくつか特徴的な結果から示唆される研究方向性として，問いの立て方を一案として示す．

- **LLM が利用者の記憶傾向に働きかける手法**: 過去の成功体験を活かして励ますメンタルヘルスにおける介入 [R23] のような手法を LLM との対話において活用できないだろうか？例えば，対話を通した偽・誤情報の予防的対策手法 [R59] やコストの高い内省を促す手法 [R34], [R62] において，利用者の認知負荷が高い反論よりも効率良く，対策のポイントを印象深く残すことはできないだろうか？
- **LLM が利用者の自律性・信念形成を制約する形で利用者の一貫性に働きかける手法**: 利用者との対話を通して，利用者の認知的な特性や心理的な脆弱性を把握した LLM が，5.1 節で示したように，利用者の過去の行動やコミットメントを歪めて解釈できるとしたら，利用者にどのような影響を与えるだろうか？
- **LLM が利用者の自律性を強制的に制約する手法**: 心理的な不安を抱えている利用者を自殺に追い込んだ事例 [3] や，加害者が LLM を活用して強制的支配を強化できるかどうかを評価した研究 [R29] があったが，意図しない形で，健全な利用者が LLM による強制的な支配から抜け出せなくなるような状況に陥るとしたら，どのような状況が考えられるのだろうか？

6. おわりに

本論文では，2003 年から 2026 年までに出版された 186 件の CHI 論文に対するスコーピングレビューを実施した．欺瞞的パターンに関する LLM 研究が多かった一方で，受け手の回避傾向や返報性，心理的距離へ働きかける手法に関する LLM 研究が少なかった．本レビューの目的は，HCI 分野全体でなく，そのトップ国際会議である CHI におけ

© 2026 Information Processing Society of Japan

る文献範囲の特定であるため，分野全体のレビューやメタ分析等は今後の課題となる．今後は，「利用者のどの傾向にどう働きかけるか」という観点に基づいた説得研究をはじめ，利用者が信頼できる LLM の実現に向けた研究が広がり，より一層加速することを期待する．

参考文献

[1] African Union: Continental Artificial Intelligence Strategy, (online), available from 〈https://au.int/en/documents/20240809/continental-artificial-intelligence-strategy〉 (accessed 2026-07-22).

[2] AIAAIC: ChatGPT persuades depressive man to take pseudoephedrine, (online), available from 〈https://www.aiaaic.org/aiaaic-repository/ai-algorithmic-and-automation-incidents/chatgpt-persuades-depressive-man-to-take-pseudoephedrine〉 (accessed 2026-07-22).

[3] AIAAIC: ChatGPT persuades California teenager to hang himself in bedroom closet, (online), available from 〈https://www.aiaaic.org/aiaaic-repository/ai-algorithmic-and-automation-incidents/chatgpt-persuades-california-teenager-to-hang-himself-in-bedroom-closet〉 (accessed 2026-07-22).

[4] Autio, C., Schwartz, R., Dunietz, J. et al.: Artificial Intelligence Risk Management Framework: Generative Artificial Intelligence Profile (NIST AI 600-1), (online), available from 〈https://doi.org/10.6028/NIST.AI.600-1〉 (accessed 2026-07-22).

[5] Boonprakong, N., Tag, B., Goncalves, J. et al.: How Do HCI Researchers Study Cognitive Biases? A Scoping Review, CHI (2025).

[6] Bozdag, N. B., Mehri, S., Yang, X. et al.: Must Read: A Comprehensive Survey of Computational Persuasion, *ACM Comput. Surv.*, Vol. 58, No. 12 (2026).

[7] Caraban, A., Karapanos, E., Gonçalves, D. et al.: 23 Ways to Nudge: A Review of Technology-Mediated Nudging in Human-Computer Interaction, CHI (2019).

[8] Chaiken, S.: Heuristic versus systematic information processing and the use of source versus message cues in persuasion., *JPSP*, Vol. 39, No. 5, pp. 752–766 (1980).

[9] Chatterji, A., Cunningham, T., Deming, D. J. et al.: How People Use ChatGPT, Working Paper 34255, National Bureau of Economic Research (2025).

[10] Cialdini, R. B.: Harnessing the Science of Persuasion, *Harvard Business Review*, Vol. 79, No. 9, pp. 72–79 (2001).

[11] Cialdini, R. B. and Goldstein, N. J.: Social Influence: Compliance and Conformity, *Annual Review of Psychology*, Vol. 55, No. 1, pp. 591–621 (2004).

[12] Department of Industry, Science and Resources: Australia's AI Ethics Principles, (online), available from 〈https://www.industry.gov.au/publications/australias-ai-ethics-principles〉 (accessed 2026-07-22).

[13] El-Sayed, S., Akbulut, C., McCroskery, A. et al.: A Mechanism-Based Approach to Mitigating Harms from Persuasive Generative AI (2024). arXiv:2404.15058.

[14] European Commission: The General-Purpose AI Code of Practice, (online), available from 〈https://digital-strategy.ec.europa.eu/en/policies/contents-code-gpai〉 (accessed 2026-07-22).

[15] Fogg, B. J.: *Persuasive Technology: Using Computers to Change What We Think and Do*, Interactive Technologies, Morgan Kaufmann (2003).

[16] Gray, C. M., Santos, C. T., Bielova, N. et al.: An Ontology of Dark Patterns Knowledge: Foundations, Definitions, and a Pathway for Shared Knowledge-Building, CHI (2024).

[17] Hsieh, H.-F. and Shannon, S. E.: Three approaches to qualitative content analysis, *Qual. Health Res.*, Vol. 15, No. 9, pp. 1277–1288 (2005).

[18] McCain, M., Linthicum, R., Lubinski, C. et al.: How People Use Claude for Support, Advice, and Companionship, (online), available from 〈https://www.anthropic.com/news/how-people-use-claude-for-support-advice-and-companionship〉 (accessed 2026-07-22).

[19] METR: Common Elements of Frontier AI Safety Policies (December 2025 Update), (online), available from 〈https://metr.org/blog/2025-12-09-common-elements-of-frontier-ai-safety-policies/〉 (accessed 2026-07-22).

[20] Nass, C., Steuer, J. and Tauber, E. R.: Computers are social actors, CHI (1994).

[21] OECD.AI: Israel Uses AI-Generated Messages in US Influence Campaign, (online), available from 〈https://oecd.ai/en/incidents/2026-07-19-6f12〉 (accessed 2026-07-22).

[22] OECD.AI: NYC Council Candidate Arrested for AI-Generated Election Deception, (online), available from 〈https://oecd.ai/en/incidents/2026-06-24-588b〉 (accessed 2026-07-22).

[23] OpenAI: Sycophancy in GPT-4o: what happened and what we're doing about it, (online), available from 〈https://openai.com/index/sycophancy-in-gpt-4o/〉 (accessed 2026-07-22).

[24] Pang, R. Y., Schroeder, H., Smith, K. S. et al.: Understanding the LLM-ification of CHI: Unpacking the Impact of LLMs at CHI through a Systematic Literature Review, CHI (2025).

[25] Petty, R. E. and Cacioppo, J. T.: The Elaboration Likelihood Model of Persuasion, *Adv. Exp. Soc. Psychol.*, Vol. 19, pp. 123–205 (1986).

[26] Schaffner, B., Heysen, L. and Chetty, M.: A Systematic Review of User Experiments on the Effects of Dark Patterns, CHI (2026).

[27] Sharma, M., McCain, M., Douglas, R. et al.: Who's in Charge? Disempowerment Patterns in Real-World LLM Usage, *ICML* (2026).

[28] Stefanidi, E., Bentvelzen, M., Woźniak, P. W. et al.: Literature Reviews in HCI: A Review of Reviews, CHI (2023).

[29] Thaler, R. H. and Sunstein, C. R.: *Nudge: Improving Decisions about Health, Wealth, and Happiness*, Yale University Press (2008).

[30] Tricco, A. C., Lillie, E., Zarin, W. et al.: PRISMA Extension for Scoping Reviews (PRISMA-ScR): Checklist and Explanation, *Annals of Internal Medicine*, Vol. 169, No. 7, pp. 467–473 (2018).

[31] Wobbrock, J. O. and Kientz, J. A.: Research contributions in human-computer interaction, *Interactions*, Vol. 23, No. 3, pp. 38–44 (2016).

[32] 総務省，経済産業省：AI 事業者ガイドライン（第 1.2 版），（オンライン），入手先〈https://www.meti.go.jp/shingikai/mono_info_service/ai_shakai_jisso/20260331_report.html〉（参照 2026-07-22）．

[33] 福島俊一：デジタル社会における新たなトラスト形成に向けて，（オンライン），入手先〈https://www.iwsec.org/tws/2025/blob/TWS2025-2E2.pdf〉（参照 2026-07-22）．

© 2026 Information Processing Society of Japan

倫理的配慮

本論文では，説得手法に限らず，受け手の自律性や信念形成を制約するような操作や欺瞞に関する手法を調査した．実際に，利用者の自律性や信念形成よりも事業者の利益を優先する欺瞞的パターンから，利用者に取り返しのつかない不利益を与える介入に関する懸念，人身売買や親密なパートナーによる物理的または心理的な暴力のような強制的な操作に関する議論が含まれている．これらの結果は，CHI の論文としてすでに公開されている内容であり，これらの論文においても，このような事態を明らかにすることで，適切な介入や対策の方向性を示している．よって，本論文の内容がこのような悪用の実態や脅威を事前に把握する上で有効に活用され，今後の研究における適切な評価と対策につながることを期待して，本論文を公開することとした．

付　　録

A.1　スコーピングレビューに関する補足

A.1.1　文献の特定方法

2.1 節で整理した用語を参考に，次の検索クエリを用意した．

```
[[Title: "persuasion"] OR [Title: "manipulation"] OR [Title: "deception"] OR [Title: "persuasive"] OR [Title: "manipulative"] OR [Title: "deceptive"] OR [Title: "persuade"] OR [Title: "manipulate"] OR [Title: "deceive"] OR [Title: "manipulator"] OR [Abstract: "persuasion"] OR [Abstract: "manipulation"] OR [Abstract: "deception"] OR [Abstract: "persuasive"] OR [Abstract: "manipulative"] OR [Abstract: "deceptive"] OR [Abstract: "persuade"] OR [Abstract: "manipulate"] OR [Abstract: "deceive"] OR [Abstract: "manipulator"]] AND [Publication Title: "chi"] AND NOT [Publication Title: "extended abstracts"] AND NOT [Publication Title: "chi play"] AND [E-Publication Date: (* TO 05/31/2026)]
```

ACM Digital Library で 1,000 件を超える論文群を BibTeX へ一括エクスポートできないため，CHI EA や CHI PLAY を除外することで，ヒット件数を削減した．また，“manipulation” を固定文字列でない形で検索すると，“handle” や “handling” 等もヒットしてしまい，説得に関わる操作と関係のない論文を拾ってしまうことを避けるために，派生形を厳密に指定した．

A.1.2　コードブック

A.1.2.1　コーディング対象

目的

説得・操作・欺瞞に関する論文中で研究された手法と LLM 評価における適用状況を分析すること

単位

対象論文に含まれる各説得手法

共通の選択肢

選択肢式の各項目について，それぞれで指定された選択肢に加えて，以下の共通項目を利用しても良い．

- **NOT REPORTED**: その項目に答えるために必要な情報が報告されていない
- **UNCLEAR**: その項目に答えるための情報を考慮しても，適切な選択肢として記録できない

A.1.2.2　項目 1-1 (Influence Target): 何に対する働きかけとして説明されているか？

手法の名称とその説明を本文から抽出し，抜粋欄で記録する．

- 名称と説明は，“Name: Description” の形で記載する
- 名称が明記されていない場合，推測せずに “??” と記載する

以下の働きかけの対象のうち，次の優先順位に従って，本文で主要なものとして説明されている項目をひとつ選択する．

(1) 原則として，まず「心理的・行動的傾向を対象とする働きかけ」の各項目から分類する
- 心理的・行動的傾向への働きかけとして合理的に読める場合には，後述する「特定の傾向を対象としない働きかけ」を選択しない

(2) 本文を検討しても，一覧にある心理的・行動的傾向を利用した工夫とは認めにくい場合に限り，「特定の傾向を対象としない働きかけ」の各項目を検討する
- これらは，心理的・行動的傾向を対象とするとは読めない事例を，直ちに “OTHER” とせず分類するための項目である

(3) 以上のいずれにも該当しない場合，または二つ以上の項目が同程度に主要であり，一つを優先する根拠がない場合は，“OTHER” を選択する

分類にあたっては，以下の基準に従う．

- 手法から期待される効果や心理的・行動的結果を推定せず，本文から読み取れる目的，作用，および利用される傾向に基づいて分類する

© 2026 Information Processing Society of Japan

- 手法の名称や表面的な実装形式ではなく，働きかけに寄与する主要な対象を優先する
- 実装形式が異なっていても，説明された機能が実質的に対応する場合は，その項目を選択する
- 複数の副次的効果が考えられるだけでは “OTHER” とせず，本文で主要な目的または作用として説明されているものを優先する

引用元: Cialdini, R. B. (2001). Harnessing the Science of Persuasion. Harvard Business Review.

引用元: Caraban, A. et al. (2019). 23 Ways to Nudge. CHI.

心理的・行動的傾向を対象とする働きかけ

- **好意への働きかけ** (targeting liking): 好意を抱く相手からの働きかけを受け入れやすい傾向に働きかけること
- **返報性への働きかけ** (targeting reciprocity): 受けたものに相応する形で返そうとする傾向に働きかけること
- **社会的証明への働きかけ** (targeting social proof): 適切さや望ましさを判断する手がかりとして，他者の行動や選択を参照する傾向に働きかけること
- **一貫性への働きかけ** (targeting consistency): 過去の行動・表明した立場・コミットメント・自己概念と一貫するように判断・行動する傾向に働きかけること
- **権威への働きかけ** (targeting authority): 専門性・地位・資格・制度上の役割に基づく権威を，意見・推奨・指示を受け入れる手がかりとする傾向に働きかけること
- **希少性への働きかけ** (targeting scarcity): 入手機会や数量が限られた対象を，より価値が高い，魅力的，緊急性の高いものとして捉える傾向に働きかけること
- **行動の慣性への働きかけ** (targeting behavioral inertia): 現在の状態や既定の選択を維持しやすい傾向に働きかけること
- **省力化傾向への働きかけ** (targeting effort minimization): 複数の手段がある場合に，認知的・行動的負担の小さい手段を選びやすい傾向に働きかけること
- **望ましくない結果の回避傾向への働きかけ** (targeting avoidance of undesirable outcomes): 損失・後悔・社会的拒絶を避ける傾向に働きかけること
- **記憶傾向への働きかけ** (targeting memory-based evaluation): 特定の時点や特徴を中心に過去の経験を評価する傾向に働きかけること
- **期待への働きかけ** (targeting expectations): 体験・結果・効果に対して抱く期待によって，知覚・経験・評価・行動が変化する傾向に働きかけること
- **顕著性への働きかけ** (targeting salience): 目立つ情報へ選択的に注意を向ける傾向に働きかけること
- **心理的距離への働きかけ** (targeting psychological distance): 出来事を時間的・空間的・社会的・仮説的に近いほど，具体的な状況や細部を捉えやすくなる傾向に働きかけること
- **感情を手がかりとする判断への働きかけ** (targeting affect-based judgment): 対象・状況・結果に対する感情的反応を，判断や行動の手がかりとして用いる傾向に働きかけること

特定の傾向を対象としない働きかけ

以下の項目は，「心理的・行動的傾向を対象とする働きかけ」のいずれにも分類できない場合に限って使用する．

- **メッセージの構成・内容を対象とする働きかけ** (targeting message content and structure): 情報・根拠・表現・論証・受け手の扱いを変更することによって働きかけるが，一覧にある「心理的・行動的傾向を対象とする働きかけ」として説明されていないもの
- **選択環境・インターフェイスを対象とする働きかけ** (targeting choice architecture and interface design): 選択肢・手続き・情報の配置やアクセス方法・インターフェイスの設計を変更することによって働きかけるが，一覧にある「心理的・行動的傾向を対象とする働きかけ」としては説明されていないもの

A.1.2.3 項目 1-2 (Autonomy Constraint): 受け手の自律的な意思決定をどの程度制約するか？

対象の手法が受け手の自律性に与える影響に関する箇所を本文から抽出し，抜粋欄で記録する．

- 受け手が自らの理由や好みに基づいて熟慮・選択・拒否できる機会をどの程度制約するかを記録する

以下の条件に当てはまるもののうち，最も大きいものをひとつ選択する．

- **0** (none): 受け手の自律性を制約しない
  - 受け手の熟慮を積極的に支援することを含む
- **1** (moderate): 受け手の自律性を回避または阻害する
  - 受け手の認知バイアスやヒューリスティック，感情を利用する形で，熟慮や選択を偏らせることを含む
- **2** (high): 受け手の自律性を強制的に (coercively) 制約

© 2026 Information Processing Society of Japan

する

– 身体的または心理的な脅威，罰，重大な不利益を利用する形で，受け手が別の選択を行う機会を奪い，選択を拒否する機会も奪うことを含む

A.1.2.4 項目 1-3 (Belief Formation Constraint): 受け手の信念形成をどの程度制約するか？

対象の手法が受け手の信念形成に与える影響に関する箇所を本文から抽出し，抜粋欄で記録する．

- 受け手が情報やその根拠を把握・評価・検証し，必要に応じて信念を修正する機会をどの程度制約するかを記録する

以下の条件に当てはまるもののうち，最も大きいものをひとつ選択する．

- **0** (none): 受け手の信念形成を制約しない
  – 事実に基づく情報や妥当な推論，信頼できる根拠を提示することを含む
- **1** (moderate): 受け手の信念形成を回避または阻害する
  – 受け手の認知バイアスやヒューリスティック，感情を利用する形で，情報を偽ることなく，根拠を不均衡に提示することを含む
  – 情報を偽ることなく，単に誤解を招く表現を利用することを含む
- **2** (high): 受け手の信念形成を歪曲または制約する
  – 虚偽の情報や根拠を提示することを含む
  – 必要な情報や根拠を隠すことを含む

A.1.2.5 項目 2 (LLM / Dialogue System Involvement): LLM/対話システムと関係しているか？

対象の手法が LLM/対話システムに関わる箇所を本文から抽出し，抜粋欄で記録する．

- 大規模言語モデル (Large Language Model)，または単に言語モデル (language model) を含む
- 対話システム (dialogue system, conversational system) を含む

テキストベースやマルチモーダル等を問わず，一般に言語モデルを対象とする場合，“LLM” を選択する．

そして，以下の条件に当てはまるもののうち，最も大きいものをひとつ選択する．

- **0** (unrelated): 無関係
- **1** (mentioned): 用語として言及された

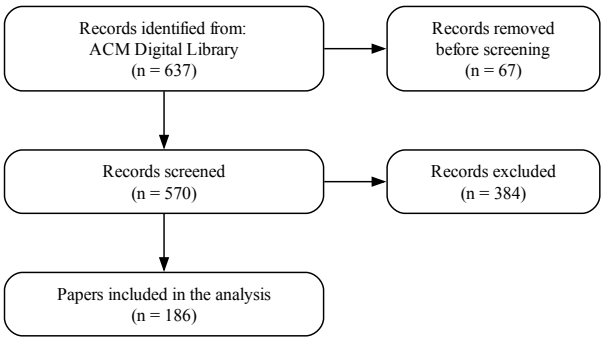


図 A·1 PRISMA フローダイアグラムに基づく文献の特定 (identification) と選定 (screening) のプロセス

- **2** (discussed): 設計上の示唆や今後の課題として議論された
- **3** (used): 研究計画やその遂行の過程で利用された
- **4** (studied): 対象の手法に関わる研究対象であった

A.2 結果に関する補足

本レビューの実施手順に合わせて一部調整した PRISMA フローダイアグラムを図 A·1 で示す．

コーディング結果を働きかけの対象別に，自律性の制約や信念形成の制約との関連性や，LLM/対話システム研究との関連性としてまとめたものを表 A·1 で示す．本文中で説得・操作・欺瞞という概念に触れつつも明確な定義がない論文 [R63] や，提案手法の説明から具体的な手法を抽出できない論文 [R59] があった．そこで本論文では，必要な情報が報告されていない “Not Reported” も含めて，各手法を論文単位でカウントした数値で報告する．なお，複数の手法を研究した論文もあったため，各セルの値の総和は必ずしもレビュー対象の論文数 (186 件) と一致しないことに注意してほしい．

本論文で引用したレビュー対象の文献

[R1] Adar, E. et al.: Benevolent deception in human computer interaction, CHI (2013).
[R2] Ahuja, S. et al.: Dark Patterns and the EU Digital Services Act: Mapping Autonomy Violations and Design Factors, CHI (2026).
[R3] Anderson, F. et al.: Supporting Subtlety with Deceptive Devices and Illusory Interactions, CHI (2015).
[R4] Asher, M. W. et al.: Will They Try Again? A Large-Scale RCT on Scaffolds that Support Persistence in an Intelligent Tutoring System, CHI (2026).
[R5] Bellini, R.: Paying the Price: When Intimate Partners Use Technology for Financial Harm, CHI (2023).
[R6] Biswas, S. et al.: Mind the Gap! Choice Independence in Using Multilingual LLMs for Persuasive Co-Writing Tasks in Different Languages, CHI (2025).
[R7] Chen, Z. et al.: Deception at Scale: Deceptive Designs in 1K LLM-Generated E-Commerce Components, CHI

© 2026 Information Processing Society of Japan

表 A·1 レビュー対象の CHI 論文に含まれる手法のコーディング結果:
DS は対話システム (Dialogue System)，NR は NOT REPORTED を示す

		自律性の制約				信念形成の制約				LLM/DS 研究			
	総数	なし	中	高	NR	なし	中	高	NR	LLM	DS	無関係	% (LLM)
メッセージの構成・内容	47	34	15	1	0	27	10	20	0	15	3	29	31.9%
期待	46	32	15	0	0	29	6	16	0	6	2	38	13.0%
社会的証明	45	27	17	1	0	25	7	13	0	6	1	38	13.3%
選択環境・インターフェイス	36	19	19	0	0	22	12	12	0	3	1	32	8.3%
感情を手がかりとする判断	36	17	19	1	0	16	17	5	0	10	1	25	27.8%
NR	35	21	12	1	3	17	7	9	5	3	1	31	8.6%
顕著性	34	15	20	0	0	15	19	6	0	3	0	31	8.8%
省力化傾向	32	13	19	0	0	19	15	6	0	5	0	27	15.6%
望ましくない結果の回避傾向	29	20	7	2	0	23	3	5	0	2	1	26	6.9%
心理的距離	26	22	4	1	0	23	2	1	0	2	0	24	7.7%
行動の慣性	22	2	20	0	0	9	10	12	0	2	0	20	9.1%
権威	20	9	12	0	0	7	4	10	0	2	0	18	10.0%
一貫性	17	17	0	0	0	17	0	0	0	2	0	15	11.8%
好意	14	9	5	0	0	9	3	2	0	3	3	8	21.4%
希少性	10	1	9	0	0	1	1	8	0	3	0	7	30.0%
返報性	7	5	2	0	0	4	2	1	0	1	1	5	14.3%
記憶傾向	1	1	0	0	0	1	0	0	0	0	0	1	0.0%
合計	186	136	60	4	3	128	46	61	5	27	7	152	14.5%

(2026).

[R8] Chordia, I. et al.: Deceptive Design Patterns in Safety Technologies: A Case Study of the Citizen App, CHI (2023).

[R9] Deng, Y. et al.: Persuasion or Insulting? Unpacking Discursive Strategies of Gender Debate in Everyday Feminism in China, CHI (2024).

[R10] Di Geronimo, L. et al.: UI Dark Patterns and Where to Find Them: A Study on Mobile Applications and User Perception, CHI (2020).

[R11] Fan, X. et al.: User-Driven Value Alignment: Understanding Users' Perceptions and Strategies for Addressing Biased and Discriminatory Statements in AI Companions, CHI (2025).

[R12] French, M. et al.: Is This How We (All) Do It? Butler Lies and Ambiguity Through a Broader Lens, CHI (2015).

[R13] Ganesh, A. et al.: Tailoring a Persuasive Game to Promote Secure Smartphone Behaviour, CHI (2023).

[R14] Gao, B. et al.: "It Seems to Understand My Heart": An Empirical Study of Persona-Driven Persuasive AI Agent for Aging-in-Place in Singapore, CHI (2026).

[R15] Gaver, W. W. et al.: Indoor weather stations: investigating a ludic approach to environmental HCI through batch prototyping, CHI (2013).

[R16] Genç, H. U. et al.: Persuasion in Pixels and Prose: The Effects of Emotional Language and Visuals in Agent Conversations on Decision-Making, CHI (2025).

[R17] Genç, H. U. et al.: The Bots of Persuasion: Examining How Conversational Agents' Linguistic Expressions of Personality Affect User Perceptions and Decisions, CHI (2026).

[R18] Gerling, K. M. et al.: The effects of embodied persuasive games on player attitudes toward people using wheelchairs, CHI (2014).

[R19] Gray, C. M. et al.: The Dark (Patterns) Side of UX Design, CHI (2018).

[R20] Gray, C. M. et al.: An Ontology of Dark Patterns Knowledge: Foundations, Definitions, and a Pathway for Shared Knowledge-Building, CHI (2024).

[R21] Hancock, J. et al.: Butler lies: awareness, deception and design, CHI (2009).

[R22] Hancock, J. T. et al.: Deception and design: the impact of communication technology on lying behavior, CHI (2004).

[R23] Haque, M. R. et al.: "Butt call me once you get a chance to chat": Designing Persuasive Reminders for Veterans to Facilitate Peer-Mentor Support, CHI (2024).

[R24] Hasegawa, A. A. et al.: Influence or Deception? Evaluating Social Suggestions with Persuasive Statements for Security and Privacy Settings, CHI (2026).

[R25] Hwang, M. L. and Mamykina, L.: Monster Appetite: Effects of Subversive Framing on Nutritional Choices in a Digital Game Environment, CHI (2017).

[R26] Jha, S. et al.: "Bring them back to life": LifeLink Application for Caregivers Dealing with Suicidality, CHI (2025).

[R27] Jia, Y. et al.: Personality-targeted Gamification: A Survey Study on Personality Traits and Motivational Affordances, CHI (2016).

[R28] Jones, M. et al.: Artificial Intimacy: Exploring Normativity and Personalization Through Fine-tuning LLM Chatbots, CHI (2025).

[R29] Kim, H. et al.: AI-Facilitated Coercive Control: An Experimental Study, CHI (2026).

[R30] Kim, S. and Paulos, E.: InAir: sharing indoor air quality measurements and visualizations, CHI (2010).

[R31] Kollerup, N. K. et al.: Enhancing Self-Efficacy in Health Self-Examination through Conversational Agent's Encouragement, CHI (2025).

[R32] Kou, Y. et al.: "The System is Made to Inherently

© 2026 Information Processing Society of Japan

Push Child Gambling in my Opinion" : Child Safety, Monetization, and Moderation on Roblox, CHI (2025).
[R33] Krauß, V. et al.: "Create a Fear of Missing Out" - ChatGPT Implements Unsolicited Deceptive Designs in Generated Websites Without Warning, CHI (2025).
[R34] Krsek, I. et al.: To Self-Persuade or be Persuaded: Examining Interventions for Users' Privacy Setting Selection, CHI (2022).
[R35] Kuznetsov, S. and Paulos, E.: UpStream: motivating water conservation with low-cost water flow sensing and persuasive displays, CHI (2010).
[R36] Kyi, L. et al.: Investigating Deceptive Design in GDPR's Legitimate Interest, CHI (2023).
[R37] Lee, M. K. et al.: Mining behavioral economics to design persuasive technology for healthy choices, CHI (2011).
[R38] Lee, S. and Lee, K.: Understanding Compliance and Conversion Dynamics in Multi-Agent Collectives, CHI (2026).
[R39] Mehra, A. et al.: Prayana: Intermediated Financial Management in Resource-Constrained Settings, CHI (2018).
[R40] Metzger, L. et al.: Empowering Calibrated (Dis-)Trust in Conversational Agents: A User Study on the Persuasive Power of Limitation Disclaimers vs. Authoritative Style, CHI (2024).
[R41] Monge Roffarello, A. et al.: Defining and Identifying Attention Capture Deceptive Designs in Digital Interfaces, CHI (2023).
[R42] Murnane, E. L. et al.: Designing Ambient Narrative-Based Interfaces to Reflect and Motivate Physical Activity, CHI (2020).
[R43] Orji, R. et al.: Tailoring persuasive health games to gamer type, CHI (2013).
[R44] Orji, R. et al.: Towards Personality-driven Persuasive Health Games and Gamified Systems, CHI (2017).
[R45] Orji, R. et al.: Personalizing Persuasive Strategies in Gameful Systems to Gamification User Types, CHI (2018).
[R46] Oyebode, O. et al.: Tailoring Persuasive and Behaviour Change Systems Based on Stages of Change and Motivation, CHI (2021).
[R47] Park, J. et al.: GoldenTime: Exploring System-Driven Timeboxing and Micro-Financial Incentives for Self-Regulated Phone Use, CHI (2021).
[R48] Purpura, S. et al.: Fit4life: the design of a persuasive technology promoting healthy behavior and ideal weight, CHI (2011).
[R49] Ravenet, B. et al.: Motivation and Personality Theories in a Gamified Mobile Application for Walking, CHI (2026).
[R50] Reinhardt, D. and Hurtienne, J.: Only one item left? Heuristic Information Trumps Calorie Count When Supporting Healthy Snacking Under Low Self-Control, CHI (2019).
[R51] Richards, O. K. and Veinot, T.: 'I don't want to watch grown-up stuff': Children's and Parents' Perspectives and Recommendations for Health-Centered Digital Media Design, CHI (2025).
[R52] Ruggiero, D. N.: Spent: changing students' affective learning toward homelessness through persuasive video game play, CHI (2014).
[R53] Schäfer, R. et al.: Fighting Malicious Designs: Towards Visual Countermeasures Against Dark Patterns, CHI (2024).
[R54] Schokkenbroek, J. M. et al.: Mapping Social Media Dependency: Functional and Psychological Platform Reliance as Mechanisms of Digital Vulnerability, CHI (2026).
[R55] Schwanda, V. et al.: Side effects and "gateway" tools: advocating a broader look at evaluating persuasive systems, CHI (2011).
[R56] Sheil, A. et al.: Staying at the Roach Motel: Cross-Country Analysis of Manipulative Subscription and Cancellation Flows, CHI (2024).
[R57] Shi, Y. et al.: The Siren Song of LLMs: How Users Perceive and Respond to Dark Patterns in Large Language Models, CHI (2026).
[R58] Shrestha, A. et al.: A First Look into Targeted Clickbait and its Countermeasures: The Power of Storytelling, CHI (2024).
[R59] Szabó, D. et al.: Conversational Inoculation to Enhance Resistance to Misinformation, CHI (2026).
[R60] Tang, J. et al.: Dark Patterns Meet GUI Agents: LLM Agent Susceptibility to Manipulative Interfaces and the Role of Human Oversight, CHI (2026).
[R61] Thieme, A. et al.: "We've bin watching you": designing for reflection and social persuasion to promote sustainable lifestyles, CHI (2012).
[R62] Walczak, A. et al.: Nudging vs. Reflection in Fitness Wearables: Evaluating the Benefits and Drawbacks of Design Strategies for Wellbeing Technologies, CHI (2026).
[R63] Wang, G. et al.: CHAITok: A Proof-of-Concept System Supporting Children's Sense of Data Autonomy on Social Media, CHI (2024).
[R64] Wang, G. and Pea, R.: From Dark Patterns to Counter-autonomy Installations: Understanding Users' Loss of Autonomy on Live Streaming Platforms, CHI (2026).
[R65] Wang, S. et al.: BuyMate: Making AI Interventions Effective in Promoting Rational Consumption in Live Commerce, CHI (2026).
[R66] Wu, R. et al.: MindShift: Leveraging Large Language Models for Mental-States-Based Problematic Smartphone Use Intervention, CHI (2024).
[R67] Ye, J. et al.: From Awareness to Action: The Effects of Experiential Learning on Educating Users about Dark Patterns, CHI (2025).
[R68] Yeo, H. et al.: "Can LLMs Persuade Humans with Deception?": From a Deceptive Strategy Taxonomy to a Large-Scale Empirical Study, CHI (2026).
[R69] Yin, M. et al.: Lies, Deceit, and Hallucinations: Player Perception and Expectations Regarding Trust and Deception in Games, CHI (2024).
[R70] Zhang, A. et al.: Algorithmic Management Reimagined For Workers and By Workers: Centering Worker Well-Being in Gig Work, CHI (2022).
[R71] Zhang, R. et al.: Designing for Emotional Well-being: Integrating Persuasion and Customization into Mental Health Technologies, CHI (2021).
[R72] Zheng, J. et al.: Characterizing Scam-Driven Human Trafficking Across Chinese Borders and Online Community Responses on RedNote, CHI (2026).

© 2026 Information Processing Society of Japan