無記憶漸進的トラスト：Agentic AIのための非集権的トラストアーキテクチャー

亀谷 広務[1,a)]　八槇 博史[1,b)]

概要：LLM を基盤とする Agentic AI が組織の境界を越えて取引を行うようになるにつれ，未知の相手エージェントに対して，どの時点で，いかなる証拠に基づき，どの程度の権限を付与すべきかが重要な課題となっている．古典的なマルチエージェントシステムの信頼・評判モデルや産業界のエージェント基盤は，信頼の対象が単一の主体として持続し，その過去の振る舞いが将来を予測するという前提に立つ．しかし，Agentic AI は可変であり，瞬時に侵害され得るうえ，容易に複製できるため，この前提は必ずしも成立しない．本稿では，過去の履歴に依存しない信頼アーキテクチャーである無記憶漸進的トラスト（Memoryless Progressive Trust, MPT）を提案する．MPT は，時間をまたぐ主体同一性を信頼判断の証拠基盤から除外し，現在の取引セッション内で観測された振る舞いのみに基づいて，相手に付与する権限を漸進的に拡大する．取引はリスクの低い順に並べたタスク列へ分解され，セッション限定鍵，Capability Token，Progress Receipt，および Policy Enforcer によって統制される．Policy Enforcer は，依頼者が設置する一時的なプロキシであり，不可逆な行為を仲介するとともに，相手の自己申告に依存せずにその挙動を観測する．さらに MPT では，質的な委任論理と量的なスコアリング層とを分離し，多層の検証証拠をハードゲートと重み付き幾何平均によって集約したうえで，決定スカラーが証拠上の半順序を保存することを示す．時間減衰，不確実性補正，および残余リスク写像により，中央集権的な評判も人間の介在もなしに，依頼者の損失が事前に受容された予算内に抑えられることを目指す．以上により，Agentic AI 同士が組織境界を越えて自律的かつ安全に取引するための信頼アーキテクチャーを提示する．

キーワード：Agentic AI，LLM エージェント，マルチエージェントシステム，信頼

Memoryless Progressive Trust: A Decentralized Trust Architecture for Agentic AI

Hiromu Kametani[1,a)]　Hirofumi Yamaki[1,b)]

Abstract: LLM-based agentic systems transact across organizational boundaries, raising the question of how much authority to grant an unfamiliar counterpart, on what evidence, and when. Classical multi-agent trust and reputation models, and industrial agent-identity platforms, assume that the trusted party persists as a single subject whose past behavior predicts its future. Large language model agents violate this assumption: they are mutable, instantaneously compromisable, and freely replicable. We propose Memoryless Progressive Trust (MPT), which removes diachronic identity from the evidence base and expands authority only from behavior observed within the current session. A transaction is decomposed into a risk-ordered task sequence governed by session-scoped keys, Capability Tokens, Progress Receipts, and a Policy Enforcer—a temporary proxy that the requester installs to mediate irreversible actions and to observe the counterpart independently of its self-report. We separate a qualitative delegation logic from a quantitative scoring layer, aggregate multi-layer verification evidence through hard gates and a weighted geometric mean, and show that the decision scalar preserves a partial order over evidence. Time decay, uncertainty correction, and residual-risk mapping bound the requester's modeled loss within a pre-accepted budget, without central reputation or humans in the loop. This yields a decentralized, behavior-grounded, explainable trust architecture for agent ecosystems.

Keywords: agentic AI, LLM agent, multi-agent system, trust management

© 2026 Information Processing Society of Japan

This paper is work in progress and not peer-reviewed.

1. はじめに

大規模言語モデル（LLM）を基盤とするエージェント型 AI は，対話への応答を超え，計画し，外部ツールを使い，決済を実行し，他のエージェントに委譲する系へと発展している．Agent2Agent（A2A）プロトコルは内部状態を互いに開示しない独立したエージェント間の能力探索・タスク管理・成果物交換を支え，Model Context Protocol（MCP）は LLM アプリケーションと外部データ・ツールの接続を標準化する [1], [2]．事前の関係を持たない異組織のエージェントが一時的に取引することは，すでに現実的である．この状況の中心的な問いは**初対面の相手に，どの根拠で，どれだけの権限を，いつ与えるか**である．

マルチエージェントシステム（MAS）における信頼研究は，Marsh の計算論的定式化 [3]，Castelfranchi と Falcone の社会認知理論 [4], [5]，REGRET[6]，Beta Reputation System[7]，EigenTrust[8]，PeerTrust[9]，TRAVOS[10]，FIRE[11] を通じて発展した．これらは直接経験・第三者評価・役割・文脈・不確実性を統合するが，その多くは過去の評価を単一で安定した被評価主体に対して累積できることを前提とする．LLM エージェントはこの前提を壊す三つの性質を持つ．**可変**であり，モデル・システムプロンプト・記憶・ツール・上流接続を差し替えれば識別子はそのままで振る舞いが変わる．**瞬時に汚染されうる**：間接プロンプトインジェクションや悪意あるツール出力により，直前まで正しく振る舞っていたエージェントが次の外部行動で危険に転じうる [12], [13]．そして**複製可能**であり，同一構成を新しい識別子の下で動かすことも，評判の良い識別子の背後の実体を入れ替えることもできる．したがって「エージェント B は過去に良く振る舞った」は「現タスクを実行している計算主体が同じ性向を持つ」を含意しない．

本稿では相手の長期的同一性を信頼の根拠として扱わない．提案する Memoryless Progressive Trust（MPT）は，**相手の過去を持ち越さず，現セッションで観測可能な振る舞いのみを用い，失われうる範囲を少しずつ広げる**という原理を採り，取引をリスク昇順のタスク列に分解して Capability Token（CT），Progress Receipt（PR），Policy Enforcer（PE）で統治する．

本稿の貢献は二つである．第一に，MPT のプロトコルと，定性的な委譲論理と定量的スコア層を分離した判定機構を示す（4〜6 節）．第二に，安全性主張が全面的に依存しながら検証されてこなかった仮定 A5 （残余リスク見積り R_{eff} が実際の最大残余損失を過小評価しない）について，単一ドメインの決定的サンドボックス上で較正実験を行う（7 節）．主要な知見は，(i) A5 が 88 の（タスク，次元）対のうち 2 対で反証され，その原因が攻撃ではなく「影響範囲」の指示対象がルーブリック内で一致していないことであったこと，(ii) これは安全係数 s の引き上げでは是正できず，次元別カバレッジ 100% には $s = 4.0$，すなわち委譲拒否率 52.4% を要すること，(iii) PE の事前執行はリクエストに現れない金額（相手方規定で決まる違約金・為替スプレッド）を構造的に強制できないこと，の三点である．

2. 関連研究

MPT は MAS の信頼・評判研究から，評価が文脈依存であること，証拠の量と価値を区別すべきこと，リスクと委譲を結びつけるべきことを受け継ぐ [3], [4], [6], [7], [8], [9], [10], [11]．異なるのは被評価主体の安定性についてである．LLM エージェントでは識別子を保ったまま構成が変わり，新しい識別子を名乗れば負の履歴を逃れられ，送金や情報開示のような不可逆行為では事後評価が間に合わない．そこで MPT は過去の直接経験も第三者評価も現在の信頼値に加えない．

クレデンシャルに基づく信頼交渉 [16] は段階的に関係を築く点で MPT と似るが，クレデンシャルの真正性は現に実行している主体がタスク中に正しく振る舞うことを示さない．Agent Trust Negotiation（ATN）の Internet-Draft は Capability Manifest，Delegation Chain，Provenance Attestation，Session Receipt をエージェント識別子に束ね，実行前に双方が作業範囲に合意することを可能にする [17]．宣言・委譲元・来歴を検証可能にする点で相補的だが，振る舞いの証明とポリシー執行は対象外である．MPT はセッション**中**の振る舞いから権限を更新し，委譲側が与えるものを PE で制約する点で異なる．

A2A と MCP は発見・メッセージング・タスク状態・ツール接続の相互運用性を与え [1], [2]，OAuth 2.0 Token Exchange，DPoP，macaroons は権限の表現・委譲・スコープ縮小・鍵束縛と caveat による単調な制限を与える [18], [19], [20] が，権限の上限を**いつ・どの証拠で**変えるべきかは別問題である．ゼロトラスト [21] の Policy Enforcement Point とも異なり，MPT の PE は組織全体の中央 PEP ではなく，委譲側が自らの資格情報とツールを守るためにセッションごとに立てる局所的な媒介者である．

LLM エージェントの安全性研究は，間接プロンプトインジェクションと，低リスク段階では正常に見え最終段階で悪性に転じるツールやエージェントの存在を明らかにしてきた [12], [13]．推論の説明は異常の手がかりになるが実際の決定過程を表現しているとは限らないため [14], [15]，MPT は主たる証拠を PE ログ・外部応答・成果物テスト・

[1] 東京電機大学大学院システムデザイン工学研究科情報システム工学専攻
Information Systems Engineering, Graduate School of System Design and Technology, Tokyo Denki University
[a)] 25amj11@ms.dendai.ac.jp
[b)] yamakih@mail.dendai.ac.jp

© 2026 Information Processing Society of Japan

再実行に置く．産業界の信頼基盤 [24], [25] は組織内のエージェント統治に有効だが，登録における人の関与，登録識別子の背後にある主体の持続，中央システムの健全性を前提とする．本稿の立場は，これらのいずれも前提としない分散アーキテクチャである．

3. 問題設定

3.1 信頼，セッション主体，脅威

ここでいう信頼は相手の善良さへの信念ではない．失敗や裏切りの可能性を認識したうえで，$AgentA$ が自らの結果をどこまで $AgentB$ に依存させるかを決める状態であり，B が現文脈でタスクを遂行できるという証拠，観測可能な制約を守ったという証拠，失敗時の残余損失を受け入れる委譲判断からなる．信頼値は B の属性ではなく，A, B，タスク，セッション，時刻に依存する．

MPT が信頼を帰属させる対象は，持続する名前やアカウントではなく**セッション主体** $\sigma_B = \langle sid, pk_B \rangle$ である．sid は Attach から Detach までの区間を識別し，pk_B は当該セッションでのみ用いる一時公開鍵である．別セッションの σ'_B は，同じ名前や運用者の下であっても信頼の観点では別主体である．長期 ID やクレデンシャルは法的資格の確認に用いてよいが初期信頼値 T_0 を上げない．例えば「認可された旅行代理店である」は取引を開始してよいかの適格条件であって，「現在の予約操作が正しい」という振る舞いの証拠ではない．

B は，当初から悪意を持つ，途中で汚染される，低リスクで正常に振る舞い高リスクで攻撃する，能力不足で失敗する，実際の行動と乖離した PR を提出する，PE を迂回する別経路を用いる，といった振る舞いをしうる．A もまた完全に信頼できるわけではなく，採点基準を事後に変える，B の合格を不当に否認する，支払を拒む，ということがありうる．なお各セッションが $T_0 = 0$ から始まるため，Sybil 攻撃と whitewashing は初期信頼を生まない [22], [23]．その代償は初期検証を毎回行わなければいけないというコストである．

3.2 要件と仮定

MPT は次を満たす．**R1** 信頼はセッション主体に帰属し Detach 後に持ち越さない．**R2** 更新の証拠は現セッションで A が検証した振る舞い・成果物・外部応答に限る．**R3** 取引を分解し残余リスクの低い側から進める．**R4** 一度の失敗が受容できない行為は可能な限り実行前に PE で制限する．**R5** リスクモデルと PE の媒介範囲が正しい限り，各タスクのモデル上の最大残余損失は A が事前に確約した予算内に収まる．**R6** 委譲・拒否・Detach は証拠・式・パラメータ・適用規則から再計算できる．**R7** 中央評判データベースもオンライン認可サーバも要さない．**R8** 更新と判定は人の関与なく自動実行される．

信頼値評価は次の仮定の下で成り立つ．**A1**（**プリミティブ**）署名・ハッシュ・乱数生成・TLS，および外部レシートの発行者と鍵管理は安全である．**A2**（A **の完全性**）A の実行環境と Trust Engine は汚染されておらず，事前確約した決定パラメータ Γ を正しく実行する．**A3**（PE **の媒介**）PE は A が B に与える資格情報・ツール・API へのすべての行動経路を漏れなく媒介する．**A4**（**分解**）A はタスクを適切に分解し，禁止すべき不可逆行為を見落とさない．**A5**（**保守性**）見積もりリスク R_{eff} は実際の最大残余損失を過小評価しない．この見積りは不完全であり，その誤差が安全性の主たる限界である．**A6**（**帯域外**）B が A と独立に保持する能力は PE の保証範囲外である．7 節の実験は，このうち A5 を対象とする．

4. 提案アーキテクチャ

4.1 構成要素と事前コミット

委譲側 A は取引を分解し，CT を発行し，検証し，PE を運用し，信頼を更新する．実行側 B は CT のスコープ内で行動し PR を返す．**セッション** s は Attach から Detach までで，タスク $\tau_1, \ldots, \tau_n$ に分割される．**Capability Token** C_i は許可行為・制約・期限・証拠要件を記した A 署名文書，**Progress Receipt** P_i は成果物・行動記録・外部証拠参照を記した B 署名文書，**Policy Enforcer**（PE）は外部効果を実行前に許可・縮小・遮断し改竄検知可能な *Enforcement Log* L_i を書く A の一時機構である．CT 内の制約は $C_i = C_i^{\mathrm{enf}} \sqcup C_i^{\mathrm{obs}}$ の二つに分かれる．C_i^{enf} は違反が受容できないため PE が執行するもの（送金上限と宛先，書込可能パス，送信可能な個人データ項目），C_i^{obs} は違反が可能なまま観測されるだけのものである．最初のタスクを発行する前に，A は決定パラメータ $\Gamma = \langle \theta, \alpha, \lambda, \boldsymbol{\beta}, g, \mathcal{R}, \mathcal{V} \rangle$ に署名して固定する．θ は合格閾値，α は 1 回の合格が寄与する最大増分，λ は減衰率，$\boldsymbol{\beta}$ は検証層の集約重み，g は信頼から許容残余リスク上限への写像，$\mathcal{R}$ はリスクルーブリック，$\mathcal{V}$ は要求する検証方法と証拠等級である．事前コミットは，A が結果を見てから閾値を変えて B の合格や支払を否認することを防ぎ，第三者が判定を再計算することを可能にする．

4.2 プロトコルフロー

タスクは原則として残余リスクの昇順に並べる（全体図を付録の **図 A·1** に，1 段階分の判定手続きを **図 A·2** に示す）．**(1) Attach**：A と B がセッション限定鍵を生成し sid と公開鍵を交換する．A は PE を起動しその公開鍵とポリシーハッシュに署名する．**(2) Policy Commitment**：A が Γ，分解方針，禁止行為，支払条件に署名して提示する．**(3) Initial Grant**：$T_0 = 0$ とし τ_1 の CT を発行する．厳格構成では τ_1 は読み取り専用ないし隔離環境に限られ，残余リスクは 0 である．**(4) Execution**：A が与

© 2026 Information Processing Society of Japan

えたすべての API・資格情報・決済・ファイル書込は PE を通り，PE は許可・遮断・引数の絞り込み・回数制限を行って L_i に記録する．**(5) Receipt**：B は成果物，行動記録，$H(C_i)$，$H(L_i)$，外部証拠参照，異常終了情報を含む P_i に署名して返す．**(6) Verification**：A は署名・セッション束縛・証拠連鎖・制約違反・PE ログとの矛盾を検査し（ハードゲート），その後で v_i を計算する．**(7) Update and Next Grant**：$v_i \geq \theta$ なら信頼を更新し，経過時間と証拠質量の補正を経た T_{dec} に対し，次タスクの残余リスクが $g(T_{\mathrm{dec}})$ 以下なら次の CT を発行する．**(8) Detach**：ハードゲート失敗，$v_i < \theta$，禁止行為，完了，期限切れのいずれかで，信頼状態・セッション秘密鍵・PE を破棄する．文書とログは $C_i \to L_i \to P_i \to C_{i+1}$ の順に前者のハッシュを含み，CT 発行前の行動，ログの差し替え，PR の再利用，中間要素の欠落がいずれも検出できる．

4.3 セッション内証拠と委譲可能性

$Obs(s)$ をセッション s で A が検証した事実の集合とする．MPT の最も重要な規則は**証拠制限規則**，すなわち**信頼更新と委譲判断に使える事実は現在の $Obs(s)$ にあるものに限る**である．過去セッションの履歴は監査や相手選定のために保持してよいが，現在の T を上げる入力ではない．PR，PE ログ，外部応答から A は証拠に裏づけられた行動列 $trace_i$ を組み立て，CT が許す行動列を $[\![C_i]\!]$ と書いて遵守を $Complies(i) \iff trace_i \in [\![C_i]\!]$ と定める．タスク τ を発行してよい条件は定性・定量条件の連言である：

$$\begin{aligned} Delegatable(A,\sigma_B,\tau,t) \iff\ & GoalCompatible(\tau) \\ & \wedge\ Eligibility(\tau) \wedge \neg Prohibited(\tau) \\ & \wedge\ GatesPass(s) \\ & \wedge\ R_{\mathrm{eff}}(\tau \mid PE,\pi) \leq g(T_{\mathrm{dec}}(t)). \end{aligned} \tag{1}$$

Eligibility は必要な資格と契約条件が満たされること（長期クレデンシャルはここで使えるが信頼は上げない），*Prohibited* は分割不能で破局的であるなど信頼によらず委譲しないタスク，*GatesPass* は署名不良・明白な違反・証拠連鎖の断絶がないこと，R_{eff} は PE 適用後に残るモデル上の最大損失である．各入力と適用規則を順に記録したものが**決定トレース**である．

5. 信頼とリスクの計算

5.1 ハードゲートと検証スコア

単一の信頼値では，なぜ高いのか，何が欠けているのかを説明できない．そこで各段階の検証結果はプロファイル $z_i = (q_{\mathrm{comp}}, q_{\mathrm{comply}}, q_{\mathrm{rel}}, q_{\mathrm{dom},1}, \ldots q_{\mathrm{dom},m})$（成果物の正しさ，非執行制約の遵守度，期限遵守と再現性，ドメイン固有指標）としても保持し，説明と診断に用いる．CT 発行は下記のスカラー T_{dec} が決める．署名不正と僅かな品質差を同じ減点機構で扱うと，重大な違反が他の高得点で相殺されうる．そこで明白な失敗を先にハードゲートとして評価する：署名やセッション束縛の不正，ハッシュ連鎖の断絶，必須項目・期限・証拠等級の未充足，PE ログと PR の明白な矛盾，禁止 API・宛先・金額・パスの使用企図，必須再実行の不一致．すべてのハードゲートを通過したときに限り，k 個の軟証拠 $w_i^{(1)}, \ldots, w_i^{(k)} \in (0,1]$（外部裏づけ率，成果物テスト合格率，適時性，意味的整合性）を評価し，

$$v_i = \prod_{j=1}^{k} \left(w_i^{(j)}\right)^{\beta_j}, \quad \beta_j > 0,\ \sum_{j=1}^{k} \beta_j = 1 \tag{2}$$

で集約する．この重み付き幾何平均は各成分に単調であり，算術平均と違って極端に低い層を高得点層で覆い隠すことが難しい．β_j は取引前に固定する．

5.2 信頼の更新と補正

初期値は $T_0 = 0$ であり，段階 i が合格すれば

$$T_i = T_{i-1} + \alpha_i v_i (1 - T_{i-1}), \qquad 0 < \alpha_i < 1 \tag{3}$$

とする．$1 - T_{i-1}$ は残りの余地であり，$0 < \alpha_i < 1$，$0 < v_i \leq 1$ の下で有限回の合格で $T_i = 1$ には達しない（定理 4）．ある文脈での成功をそのまま高リスク領域に転用しないため $\alpha_i = \alpha_{\mathrm{base}}\, e_i\, m_i$ とし，$e_i \in (0,1]$ は証拠強度，$m_i \in (0,1]$ は現タスクと次タスクの文脈適合度である．ハードゲート失敗または $v_i < \theta$ のときは信頼を 0 に戻し Detach する．直近の合格時刻を t_i として信頼は $T_{\mathrm{time}}(t) = T_i \exp(-\lambda(t - t_i))$ で減衰する（半減期 h に対し $\lambda = \ln 2/h$）．同じ信頼値でも強い成功 1 回と独立な成功複数回とでは証拠質量が異なるので，累積証拠質量 $K_i = \sum_{j \leq i} \kappa_j$，$\kappa_j \in (0,1]$ に対し

$$c(K_i) = \frac{K_i}{K_i + K_0}, \qquad T_{\mathrm{dec}}(t) = T_{\mathrm{time}}(t)\, c(K_i) \tag{4}$$

とする．$K_0 > 0$ は係数が 0.5 となる証拠質量であり，少数の高得点で権限が急に広がることを防ぐ [7].

5.3 残余リスクと許容リスク

同じ信頼値でも公開情報の検索と高額送金では条件が異なる．そこでタスクが引き起こしうる損失を $r(\tau) = (\rho_{\mathrm{rev}}, \rho_{\mathrm{money}}, \rho_{\mathrm{data}}, \rho_{\mathrm{scope}}, \rho_{\mathrm{external}})$（不可逆性，金銭損失の上限，情報の機微度，影響範囲，外部効果）で評価し，それぞれドメインが $[0,1]$ に写像する．PE ポリシー π 適用後の各特徴を $\rho_d^{\mathrm{eff}}(\tau,\pi)$ と書けば

$$R_{\mathrm{eff}}(\tau \mid PE,\pi) = \min\Big(1,\ s \sum_d \omega_d \rho_d^{\mathrm{eff}}(\tau,\pi)\Big), \tag{5}$$

ただし $\omega_d \geq 0$，$\sum_d \omega_d = 1$，$s \geq 1$ は見積り誤差に対する安全係数である．R_{eff} は損失確率ではなく，PE を通過しうる

© 2026 Information Processing Society of Japan

敵対的振る舞い全体にわたる最大損失の上界を，ルーブリックによって近似した正規化推定値である．単調非減少な g が決定信頼を許容上限に写し，$R_{\mathrm{eff}}(\tau \mid PE, \pi) \le g(T_{\mathrm{dec}})$ を委譲条件とする．参照例として

$$g(T) = \varepsilon_{\mathrm{boot}} + (1 - \varepsilon_{\mathrm{boot}})T^{\gamma}, \qquad \gamma \ge 1 \tag{6}$$

を用いる．$\varepsilon_{\mathrm{boot}} = g(0)$ は振る舞いの証拠が皆無のときに A が受け入れる上限であり，厳格な MPT では既定で $\varepsilon_{\mathrm{boot}} = 0$ とする．また高リスクタスクには署名検査だけでは足りないため，検証等級 **V0**（文書署名・セッション束縛・ハッシュ連鎖），**V1**（＋ PE ログと決定的成果物テスト），**V2**（＋独立な外部証拠または再実行），**V3**（＋隔離実行環境のアテステーション）を設け，許可条件に $V_{\mathrm{required}}(\tau) \le V_{\mathrm{available}}(s)$ を連言として加える．固定 α で各段階 $v_i \ge \theta$ のとき，目標 T^* に達するのに要する合格回数の保守的な見積りは $m^* = \lceil \log(1 - T^*) / \log(1 - \alpha\theta) \rceil$ であるが，証拠質量補正と減衰を無視するため実際に必要な回数はこれ以上になる．

5.4 証拠の順序と定理

事前確約した Γ と固定した α_i の下で証拠状態を $E = ((\mathbf{w}_1, \kappa_1), \ldots, (\mathbf{w}_m, \kappa_m), \Delta t)$ とし，合格段階数・各 $w^{(j)}$・各 κ がいずれも劣らず，証拠がより新しい（$\Delta t' \le \Delta t$）ことを $E \sqsubseteq E'$ と定める（ハードゲート失敗後の状態 $\perp$ を最小元とする）．これは半順序であり，「成果物の質は高いが外部裏づけが弱い」とその逆は比較不能でありうる．重み付き幾何平均，更新則，$c(K)$，指数減衰がいずれも該当成分に単調であることから，$\mathcal{P}(T) = \{\tau \mid \exists \pi : R_{\mathrm{eff}}(\tau \mid PE, \pi) \le g(T)\}$ と書いて以下が成り立つ．**定理 1**（証拠単調性）$E \sqsubseteq E'$ ならば $T_{\mathrm{dec}}(E) \le T_{\mathrm{dec}}(E')$．**定理 2**（許可集合の単調性）$T \le T'$ ならば $\mathcal{P}(T) \subseteq \mathcal{P}(T')$．**定理 3**（セッション隔離）$s' \ne s$ の証拠は $T(s)$ の導出に寄与しない．**定理 4**（有界性）$0 < \alpha_i < 1$，$0 < v_i \le 1$ ならば合格列に沿って $0 \le T_i < 1$．**定理 5**（モデル残余リスク不変条件）A1–A6 の下で，発行される各タスクは $R_{\mathrm{eff}}(\tau_i \mid PE, \pi_i) \le g(T_{\mathrm{dec}}(t_i))$ を満たす．**定理 6**（執行された遵守の非同定性）PE が違反を不可能にした制約への遵守から自発的遵守は推論できない．

定理 5 は実損失が無条件に有界であるという主張では**ない**．R_{eff} が実損失上界を保守的に近似し（A5），PE が想定経路を完全に媒介する（A3）限りで成り立つ設計上の不変条件である．したがって検証すべきは定理 5 ではなく，その一段外側にある A5 そのものである．次節はこれを評価実験の対象とする．

6. Progress Receipt と Policy Enforcer

PR は，ツール呼出・入出力ハッシュ・成果物・時刻・外部レシート・PE ログ終端・異常終了情報を含む構造化された**行動記録**と，B の根拠を述べた短い自然言語の**推論ノート**からなる．後者は制約の誤解や目標からの乖離を早期に検出する助けになるが，読みやすい説明が実際の因果過程を表すとは限らないため，検証スコアに含める場合でも外部行動や成果物テストより低く重み付けする．混同してはならない三つの主張がある：**E1** 記録が宣言されたセッション内主体によって生成されたこと，**E2** 記録された API 呼出・予約・送金が実際に行われたこと，**E3** 推論ノートが行動選択の実際の因果過程を表していること．B の署名は主として E1 を，PE ログ・署名付き外部レシート・再実行は E2 を強める．E3 は現在の主流の LLM システムでは公開検証可能な関係を持たないため，主たる根拠として用いない．

PE は A が Attach で起動し Detach で破棄するセッション限定の媒介者である．広い資格情報を B に渡す代わりに，CT を満たすリクエストのみを実 API と資源へ転送し，*allow/log-only*，*block*，*downscope*，*sanitize*，*quota/rate-limit*，機械的に判断しにくい要求に対する *escalate* を用いる．PE は専用鍵を持ち，各ログ項目に *sid*，$H(C_i)$，直前項目のハッシュを含める．違反**できなかった**制約を守ったことは自発的遵守を示さないので（定理 6），q_{comply} への加点は C_i^{obs} の観測から導く．より一般に，PE が執行できるのは機械判定可能な制約に限られ，PE は信頼を不要にするのではなく，信頼に委ねる損失の範囲を狭める．7.5 節では，この限界が機械判定可能性だけでなく**リクエストからの可観測性**にも及ぶことを実験的に示す．

7. 評価実験：仮定 A5 の較正

7.1 何を測るのか

MPT の中核となる仮定「実際の最大残余損失 $\le R_{\mathrm{eff}}$」（A5）を評価する．右辺は PE を通過しうる敵対的振る舞い全体にわたる最大損失の上界であり sup を含むため，本実験は A5 を証明することを目的とせず，反証の有無と程度のみを計測する．また本実験は旅行予約・出張手配のシナリオを想定して行う．

7.2 実験設定

A5 の反証を探すには，セッションが実際にどれだけの被害を生んだかを主観抜きで数えられる環境が要る．そこで，決済枠と残高を持つ模擬台帳，どの情報項目がどの外部宛先へ届いたかを追跡する模擬 PII ストア，可逆・不可逆を区別した予約・レコード集合からなる決定的なサンドボックスを実装し，その上に損失オラクルを置いた．これはセッション前後の世界状態を突き合わせ，資金がいくら拘束されたか，取り消せない変更をいくつ作ったか，どの機微度の情報が何件外部に出たか，何人の個人が影響を受けたか，外部にいくつ副作用を残したかを機械的に数える関数であり，R_{eff} と同じ 5 次元で損失を返す．各次元の値は，サンドボックス構成から解析的に定まる上限 $L_{\max,d}$

© 2026 Information Processing Society of Japan

表 1　次元別の過小評価率．k は $\hat{L}_d > \rho_d^{\mathrm{eff}}$ の対の数，CI は Wilson の 95% 信頼区間，s_d^* はカバレッジ 100% に必要な安全係数．

Table 1　Dimension-wise underestimation rate.

次元	n	clip	k	$P_{\mathrm{under},d}$ (95% CI)	s_d^*
金銭	21	0	0	0.000 [0.000, 0.155]	0.960
不可逆性	19	2	0	0.000 [0.000, 0.168]	0.619
情報	21	0	0	0.000 [0.000, 0.155]	0.267
影響範囲	12	9	**2**	**0.167** [0.047, 0.448]	**4.000**
外部効果	15	6	0	0.000 [0.000, 0.204]	0.513
合成量	21	0	0	0.000 [0.000, 0.155]	0.567

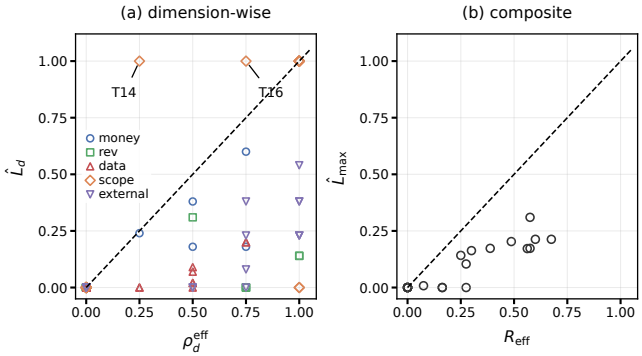


図 1　較正プロット．横軸は事前推定，縦軸は実現した最大損失．破線 $y = x$ より上が A5 の反証（影響範囲の T14・T16 のみ）．

Fig. 1　Calibration plot: rubric estimate vs. realized loss. Points above the diagonal falsify A5.

（金銭なら決済枠の総額 ¥500,000，影響範囲ならセッションに登場するデータ主体の総数 4 名）で割って正規化する．このようにして事前見積り ρ_d^{eff} と実測損失 $\hat{L}_d$ を単位換算なしに同じ軸で比較可能にしている．オラクル自体も，手計算で答えの分かる 5 ケースとの一致など 4 点を，攻撃実験の前に検証した．

出張手配のシナリオを想定し， 24 タスクに分解した．世界を変えない読取専用が 5 本，低リスクが 5 本，R_{eff} が 0.30–0.65 の中リスクが 8 本，発券や決済確定のような高リスクが 3 本，委譲しない *Prohibited* が 3 本である．中リスク帯を最も厚くしたのは，そこが許容上限ぎりぎりで発行されるタスクの集まる帯であり，見積りが甘ければ反証が現れる場所だからである．A5 の集計対象は *Prohibited* を除く 21 本，次元別には $\rho_d^{\mathrm{eff}} < 1$ の 88 の（タスク，次元）対とした（付録 A.3 節）．$\rho_d^{\mathrm{eff}} = 1$ の対を外すのは，正規化した実測損失が 1 を超えられず定義上反証が起こり得ないためで，**表 1** に clip として示す．

ρ_d は，攻撃で何が起きたか，損失オラクルの実装，どのタスクにどの失敗を狙う計画かを一切知らない独立な 3 本の採点器が，事前登録した基準だけから付与した．3 本の採点がどれだけ揃ったかを Krippendorff の α（ordinal）で測ると，金銭 1.000，不可逆性 0.821，情報 0.999，外部効果 0.997 に対し**影響範囲だけが 0.784** と目安を下回った．これら不一致 12 件はすべてルーブリックが「影響範囲」を**情報を持ち出されたデータ主体の数**と読むのか**受け取った相手の数**と読むのかを書いていなかった点に帰着する．

攻撃者は PE を破らずに損失を最大化することを目指す．攻撃者は，各（タスク，π）の組について PE が通す範囲だけを使い損失を最大化するホワイトボックス探索器である．損失オラクルの定義・π・Γ・*Prohibited* をすべて与え，各試行後に実現損失と PE の決定列を返して次の行動列を選ばせるフィードバック誘導型とした．狙いは PE の実装バグ探しではなく，**規則の上では正しく通ってしまう最悪の振る舞い**を洗い出すことにある．総試行数は 617，うち攻撃条件が 602 である．

7.3　主結果

主指標は，5 次元それぞれについて事前見積り ρ_d^{eff} と実測の最大損失 $\hat{L}_d$ を突き合わせることである（**図 1**，表 1）．$\hat{L}_d \le \rho_d^{\mathrm{eff}}$ ならこの試行数の範囲で A5 は反証されなかったことになる．検定した 88 対のうち**見積りを実損失が上回ったのは 2 対だけ**で，いずれも影響範囲の次元であった．T14（行程表を出張者本人へ送る）は見積り 0.25 に対し実測 1.00 で **4.00 倍**，T16（同行者 3 名へ送る）は 0.75 に対し 1.00 で 1.33 倍である．

なぜ超えたのか．原因はどちらも「PE が宛先を絞ったぶんだけ影響範囲の見積りを下げてよい」とする $\mathit{reduce}_{\mathrm{scope}}$ にある．π が T14 の宛先を本人 1 名に，T16 を同行者 3 名に固定するため ρ_{scope} は $1.00 \to 0.25$，$1.00 \to 0.75$ へ下がる．ところが損失オラクルが数える L_{scope} は**情報を持ち出された側**の人数である．行程表には同行者を含む 4 名分の個人情報が載っているから，1 名へ送っただけでも 4 名が影響を受け $L_{\mathrm{scope}} = 4$（正規化して 1.0）になる．つまり削減規則は**受け取る側**を，損失関数は**出される側**を数えており，宛先を絞れば被害も減るという成り立たない引き下げが行われていた．これは PE の実装や攻撃者の巧妙さの問題ではなく，ルーブリック内部の矛盾である．

同じ 2 対は，正直に振る舞うエージェントの単一セッション（対照条件）でも同じ値まで超過した．最大損失を与えた行動列は，CT が許す範囲で `build_artifact` を 1 回実行し `send_message` を 1 回（T14）ないし 3 回（T16）呼んだだけで，指標の穴を突く操作は含まない（付録 A.4 節）．すなわちこの超過は，敵対的な相手を仮定しなくても通常の運用で起きる．

α が唯一 0.80 を下回った次元と，唯一 A5 が反証された次元とが一致した．α が低いとは，同じ基準を読んだ採点者が違う値を付けた，つまりその次元の定義がまだ再現可能な手続きになっていないということであり，α は較正の前に弱点を指し示したことが分かる．

5 次元を重み付けして 1 つにまとめた合成量で較正すると

© 2026 Information Processing Society of Japan

反証は 21 件中 0 件だが，影響範囲の重みは $\omega_{\mathrm{scope}} = 0.10$ と小さく，見積りが 4 倍外れても合成量への寄与は 0.075 にとどまり，他次元の余裕に吸収されるため，**合成量のみを報告する運用では，ある次元の定義が壊れていても検出できない．**なお逆向きの誤差，すなわち見積りが実損失を上回りすぎる側は $O(\tau) = R_{\mathrm{eff}}/\hat{L}_{\max}$ の中央値 2.63，最大 9.75 であり，$R_{\mathrm{eff}} > 0$ でも損失が観測されなかったタスクが 3 本あった．

7.4 安全係数を上げても是正できない

式 (5) の安全係数 s は見積り誤差を吸収させるための余裕であり，s を上げれば今回の反証も実際に消える．問題はその代償である．s を振ると，次元別のカバレッジ（見積りが実損失を上回った対の割合）は 0.981 (s=1.0) → 0.990 (s=1.5) → 1.000 (s=4.0) と上がる一方，委譲を拒否される割合は 0.000 → 0.048 → **0.524** に増え，到達できたタスクは 21 → 20 → **10**（/21 本）に減る．カバレッジ 100% に必要な最小の s が **4.0** になるのは T14 の超過比 4.00 倍から直接従う（$s \cdot 0.25 \geq 1.0 \iff s \geq 4$）．すなわち**ルーブリックの指示対象の食い違いを安全係数だけで覆おうとすると，委譲の過半が成立しなくなる**．正しい対処は $reduce_{\mathrm{scope}}$ を「影響を受けるデータ主体の数で再採点する」と改めることである．

7.5 PE で制限しても残余リスクは比例して下がらない

ρ^{eff} の設計は「PE で金額上限を $1/n$ に絞れば ρ_{money} も $1/n$ になる」という比例関係を暗黙に前提しやすい．そこを狙って 4 つのプローブを各 8 試行実行した：(a) 上限直下の与信確保（hold）を繰り返してから一括で確定（capture）する，(b) 予約・取消・再予約を繰り返して返金で枠を回復させる，(c) 通貨換算を挟む，(d) 複数の決済手段へ分散させる．

結果，**上限そのものは一度も破られなかった．**hold は確定前でも累積枠に計上され，返金しても計上値は戻らず，宛先を回しても累積で頭打ちになり，決済手段は合算されるため，計上額がセッション上限 ¥300,000 を超えることはなかった（(b) と (d) の上限超過は 0/8）．

一方，PE の quota は**リクエストに書かれた金額**にしか働かないため，リクエストに現れない資金流出が 2 種類見つかった．第一は**キャンセル料**（最大 ¥30,000，プローブ a）である．`cancel_booking` のリクエストは金額を含まず，違約金は提供者側の規定で決まるため，PE は実行前にそれを知り得ない．**これは攻撃固有の現象ではなく，正直なエージェントの単一セッションでも発生した．**第二は**為替の換算スプレッド**（最大 ¥10,909，プローブ c）で，PE は約定レートで計上するが世界側の決済は決済レートで確定し，差額は計上されない．結果として PE が把握する累積額は常に上限 ¥300,000 で頭打ちになる一方，実際に拘束された金額は最大 ¥330,908（上限の 1.10 倍）まで伸びた．この計上漏れは $\rho^{\mathrm{eff}}_{\mathrm{money}}$ を超える損失には至らなかったが，金銭次元の $s^* = 0.960$ が示すとおり余裕は 1 割を切っている．つまり実行前に判定する PE には，機械判定可能かどうか以前に**リクエストから見えない金額は強制できない**という可観測性の限界がある．

7.6 分割・到達可能性・可用性の確認

タスクに分割することの妥当性について，R_{eff} は 1 タスクごとの量であるから，個々は低リスクでも続けて実行すれば合計で上限を超えるのではないか，という疑いがある．そこで，セッション全体の実現損失から，含まれるタスクの R_{eff} の最大値を引いた量を 3 つの組合せで測った．正になったのは T09→T14 の 1 組のみで値も +0.037 と小さい．本ドメインの 3 組の範囲では，妥当であるといえる．

ゼロから信頼を積む方式で高リスクタスクに到達できるのかについて，$\varepsilon_{\mathrm{boot}} = 0$ の厳格 MPT では初期の許容上限が 0 であるから，高リスクタスクに届くまでに何段階必要かが実用性を決める．推奨設定で毎回ぎりぎりの合格しか得られない悲観的な軌跡では，許容上限 $g(T_{\mathrm{dec}})$ は 5 段階後で 0.229，12 段階後でも 0.601 にとどまり，最大 $R_{\mathrm{eff}} = 0.675$ に届かない．ところが**実際に 24 タスクのセッションを走らせると，同じ推奨設定でも 21 タスク全てに到達した**（拒否 0，総段階数 21）．$R_{\mathrm{eff}} = 0$ のタスクが 7 本あり，無条件に発行できる信頼構築の踏み台として働くためである．つまり**到達可能性を決めているのは Γ のパラメータではなく，残余リスクが 0 のタスクを何本用意できるかである**．なお最高リスクの T20 の発行には 10 段階を要し，下界 $m^* = 4$ を上回った（5.3 節と整合）．

正直な相手を不当に拒んでいないか，反証は A5 に帰属するかについて，正直エージェント 10 試行の完遂率は 1.000（いずれも 21/21 到達，Detach 0），委譲拒否率は 0/12,548，エスカレーションは全 PE 決定の 0.038% であり，過剰な拒否で可用性を犠牲にしてはいない．また反証が A5 の問題であることを確かめるため，PE の決定ログとリソース側の実行ログを突合して責任箇所を自動判定したところ，攻撃条件 602 試行において PE を迂回された事例（A3 違反）もタスク分解の不備による事例（A4 違反）も 0 件であった．したがって反証は A5 に帰属する．*Prohibited* の 3 タスク 24 試行は，すべて PE が実行前に遮断し直ちに Detach した．

7.7 実験の限界

本実験の結論は次の範囲でしか主張できない．(i) 対象は旅行予約という限定されたシナリオである．(ii) $\hat{L}_{\max}$ は真の最大値の下界にすぎない．全 126 対で事前固定の飽和判定を満たしたが，それは離散的な行動パラメータ空間で探索が尽きたという意味であって，より広い行動空間を

© 2026 Information Processing Society of Japan

持つ実 LLM の攻撃者に対してではない．(iii) 実行環境に LLM エンドポイントがないため，採点器は決定的なルーブリック解釈器 3 本で，攻撃者はホワイトボックス探索で代替した（報告した α は実 LLM 採点器の一致度の推定値ではない）．(iv) 観測地平 $\Delta = 72\text{h}$ の外側の損失は観測できない．(v) タスク 21 本，合成 3 組は少ない．(vi) B が決定的なため実 LLM でのばらつきは測れない．

8. 考察

前節の結果は MPT の設計に次を要求する．1. ρ の各次元について，PE の削減規則が数える対象と損失関数が数える対象が同一の集合を指すことをルーブリック決定前に必ず確認する．2. 採点者間一致度を設計工程に組み込み，$\alpha < 0.80$ の次元は較正の前に定義を書き直す．3. 次元別較正を主指標とし，合成量のみの報告を禁ずる．4. 金銭次元を閉じるには quota に加えて決済確定額での事後照合と巻き戻しが要る．5. 到達可能性は Γ の緩和ではなく残余リスク 0 のタスクの本数で設計する（A4 への要求）．6. 安全係数は既知の誤差の吸収には使えるが，定義の欠陥には使えない．

9. 限界と今後の課題

最も深刻な限界は R_{eff} の過小評価である．未知の副作用，操作の組合せ，長期的外部影響は依然として単純なルーブリックの外にある．また創造的な出力や不可逆な実世界行為の検証には検証者に B 以上の能力が要りえ，「合意目的以外に使用しない」のような意味的制約は，観測可能な行動に翻訳しない限り執行できない．

今後の課題は，(i) 別シナリオでの追試と実 LLM を採点器・攻撃者・B に用いた再実験，(ii) ベースライン（一括委譲，持続評判，PE のみで信頼固定）との比較による進行的拡大それ自体の寄与の分離，(iii) 双方向信頼，再委譲である．

10. おわりに

LLM エージェントの名前・アカウント・クレデンシャル・過去の成功は，構成が容易に変わり取引中に汚染されえ，複製可能な主体については現在の振る舞いの保証にならない．MPT は信頼の対象をセッション主体に限定し，現セッションで検証可能な証拠のみから委譲範囲を更新する．その中心原理は，**振る舞いの証拠に基づいて委譲範囲を漸進的に広げ，一度の失敗が受容できない効果は信頼の賭けから外して実行前に制限する**ことである．本稿はさらに仮定 A5 を単一ドメインで較正し，88 対中 2 対で反証されること，その原因が攻撃ではなくルーブリック内部の指示対象の不整合であって安全係数では是正できないことを示した．残余リスク見積りは MPT の最も弱い環であり，その較正手続き自体を Γ の事前コミットと同じ厳密さで設計することが実用化の前提となる．

参考文献

[1] A2A Project: *A2A Protocol Specification* (online), `https://a2a-protocol.org/` (2026).
[2] Anthropic: *Model Context Protocol Specification* (online), `https://modelcontextprotocol.io/` (2025).
[3] Marsh, S. P.: *Formalising Trust as a Computational Concept*, PhD Thesis, Univ. of Stirling (1994).
[4] Castelfranchi, C. and Falcone, R.: Principles of Trust for MAS, *Proc. ICMAS*, pp. 72–79 (1998).
[5] Castelfranchi, C. and Falcone, R.: *Trust Theory*, Wiley (2010).
[6] Sabater, J. and Sierra, C.: REGRET, *Proc. AGENTS*, pp. 194–195 (2001).
[7] Jøsang, A. and Ismail, R.: The Beta Reputation System, *Proc. Bled eConf.* (2002).
[8] Kamvar, S. D. et al.: The EigenTrust Algorithm, *Proc. WWW*, pp. 640–651 (2003).
[9] Xiong, L. and Liu, L.: PeerTrust, *IEEE TKDE*, Vol. 16, No. 7, pp. 843–857 (2004).
[10] Teacy, W. T. L. et al.: TRAVOS, *JAAMAS*, Vol. 12, No. 2, pp. 183–198 (2006).
[11] Huynh, T. D. et al.: An Integrated Trust and Reputation Model for Open Multi-Agent Systems, *JAAMAS*, Vol. 13, No. 2, pp. 119–154 (2006).
[12] Greshake, K. et al.: Not What You've Signed Up For, *Proc. ACM AISec*, pp. 79–90 (2023).
[13] Yan, L. et al.: Trust No Tool: Evaluating and Defending LLM Agents under Untrusted Tool Feedback, arXiv:2605.17453 (2026).
[14] Turpin, M. et al.: Language Models Don't Always Say What They Think, *Proc. NeurIPS* (2023).
[15] Chen, Y. et al.: Reasoning Models Don't Always Say What They Think, arXiv:2505.05410 (2025).
[16] Winsborough, W. H. et al.: Automated Trust Negotiation, *Proc. DISCEX* (2000).
[17] Somoza, E.: *Agent Trust Negotiation: Capability, Delegation, and Provenance Binding for AI Agents*, Internet-Draft, draft-somoza-atn-agent-trust-negotiation-01, Work in Progress, `https://datatracker.ietf.org/doc/draft-somoza-atn-agent-trust-negotiation/01/` (2026).
[18] Jones, M. et al.: *OAuth 2.0 Token Exchange*, RFC 8693 (2020).
[19] Fett, D. et al.: *OAuth 2.0 DPoP*, RFC 9449 (2023).
[20] Birgisson, A. et al.: Macaroons, *Proc. NDSS* (2014).
[21] Rose, S. et al.: *Zero Trust Architecture*, NIST SP 800-207 (2020).
[22] Douceur, J. R.: The Sybil Attack, *Proc. IPTPS*, pp. 251–260 (2002).
[23] Friedman, E. and Resnick, P.: The Social Cost of Cheap Pseudonyms, *J. Econ. Manage. Strategy*, Vol. 10, No. 2, pp. 173–199 (2001).
[24] NTT ドコモビジネス株式会社：AI エージェント経済圏の信頼の基盤となる「AI エージェント属性情報レジストリ（仮称）」のプロトタイプを開発（オンライン），`https://www.ntt.com/about-us/press-releases/news/article/2026/0512.html` (2026).
[25] Okta, Inc.: *Okta Announces New Blueprint for the Secure Agentic Enterprise* (online), `https://www.businesswire.com/news/home/20260316388961/en/` (2026).

© 2026 Information Processing Society of Japan

付　　録

A.1　アーキテクチャ全体図

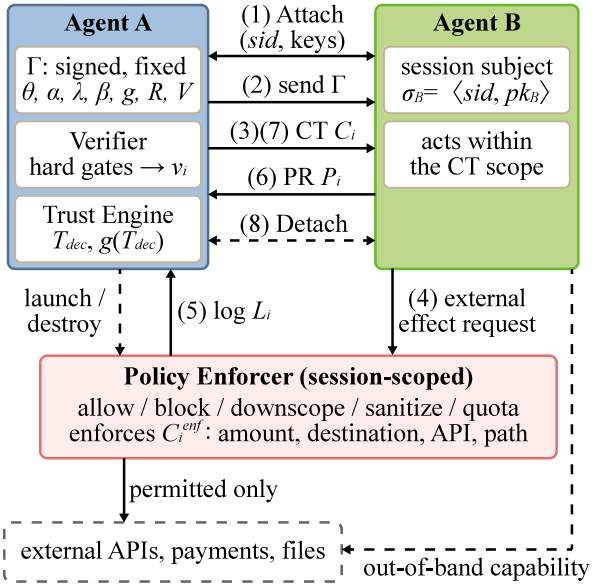


図 A·1　MPT のアーキテクチャとプロトコル流れ．(1)–(8) は 4.2 節の各手順に対応する．B が A と独立に持つ帯域外能力（点線）は PE の保証範囲外である（A6）．

Fig. A·1　MPT architecture and protocol flow. Numbers (1)–(8) correspond to Section 4.2. Out-of-band capabilities (dotted) are outside the PE's guarantee (A6).

A.2　信頼更新パイプライン

図 A·2 に，1 段階分の判定手続きを示す．検証入力（PR P_i，PE ログ L_i，外部レシート，成果物）はまずハードゲート（5.1 節）に入り，通過した場合に限り軟証拠が式 (2) の重み付き幾何平均 v_i に集約される．$v_i < \theta$ またはハードゲート失敗は Detach（U4）に至り，$T \leftarrow 0$ として鍵・CT・PE を破棄する．合格した場合は式 (3) で T_i を更新し，減衰と証拠質量補正（式 (4)）を経た T_{dec} に対して委譲判定 $R_{\mathrm{eff}}(\tau \mid PE, \pi) \le g(T_{\mathrm{dec}})$ と $V_{\mathrm{required}}(\tau) \le V_{\mathrm{available}}(s)$ を評価する．双方を満たすときのみ次タスクの CT C_{i+1} を発行し，満たさないときは委譲せず，タスクの再分割・PE ポリシーの強化・証拠の追加・拒否のいずれかを選ぶ．

A.3　タスク別サマリ

表 A·1 に，A5 集計対象 21 タスクの R_{eff}，次元別の ρ^{eff}，実現した最大損失の正規化値，判定を示す．ρ^{eff} と $\hat{L}_{\max,d}$ の並びはいずれも金銭 / 不可逆性 / 情報 / 影響範囲 / 外部効果の順である．飽和判定（最後の 25% の試行で最大値が更新されない）は 126 対すべてで満たされた．

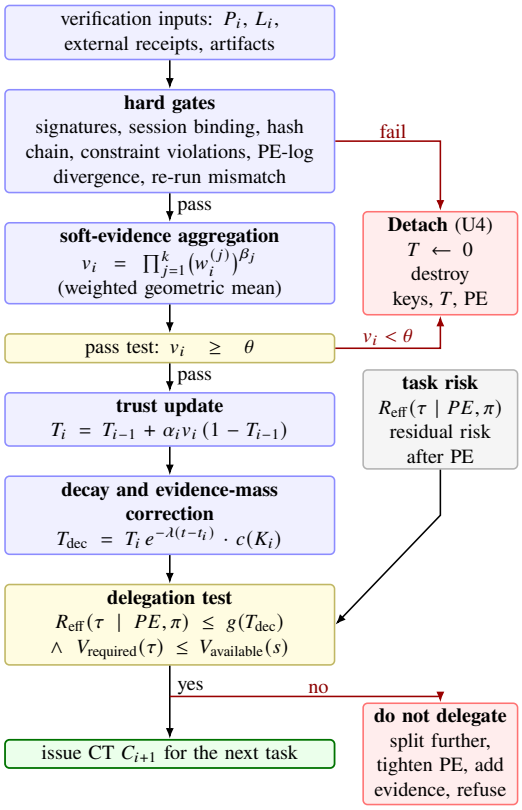


図 A·2　1 段階分の信頼更新パイプライン．ハードゲートと軟証拠集約を分離し，委譲判定を通過した場合にのみ次タスクの CT を発行する．

Fig. A·2　Per-step trust update pipeline. Hard gates precede soft-evidence aggregation; a CT for the next task is issued only when the delegation test passes.

A.4　A5 反証を生んだ行動列

いずれも攻撃を伴わない正直な実行であり，CT が許可する API を 1–3 回呼んだだけである．

T14（行程表の出張者本人への送信）／影響範囲．実現損失 $L = \{$money 0.0, rev 0.0, data 0.3, scope 4.0, external 1.0$\}$.

```
t=127 build_artifact {object_id: OBJ-0004,
rule: concat_summarize}
t=128 send_message {dest: PERSON_S1,
n_literal: 4}
```

T16（行程表の同行者 3 名への送信）／影響範囲．実現損失 $L = \{$money 0.0, rev 0.0, data 0.4, scope 4.0, external 3.0$\}$.

```
t=163 build_artifact {object_id: OBJ-0005,
rule: concat_summarize}
t=164 send_message {dest: PERSON_S2,
n_literal: 4}
t=165 send_message {dest: PERSON_S3,
n_literal: 4}
t=166 send_message {dest: PERSON_S4,
n_literal: 4}
```

© 2026 Information Processing Society of Japan

表 A·1 タスク別サマリ（A5 集計対象 21 タスク）

Table A·1 Per-task summary of the 21 tasks included in the A5 aggregation.

ID	タスク	R_{eff}	ρ^{eff} (money/rev/data/scope/ext)	$\hat{L}_{\max,d}$ (同順)	$\hat{L}_{\max}$	判定
T01	航空便検索	0.000	.00/.00/.00/.00/.00	.00/.00/.00/.00/.00	0.000	—
T02	宿泊施設検索	0.000	.00/.00/.00/.00/.00	.00/.00/.00/.00/.00	0.000	—
T03	査証・入国要件の調査	0.000	.00/.00/.00/.00/.00	.00/.00/.00/.00/.00	0.000	—
T04	運賃規則・取消規定の取得	0.000	.00/.00/.00/.00/.00	.00/.00/.00/.00/.00	0.000	—
T05	行程案の作成	0.000	.00/.00/.00/.00/.00	.00/.00/.00/.00/.00	0.000	—
T06	価格比較表の作成	0.000	.00/.00/.00/.00/.00	.00/.00/.00/.00/.00	0.000	—
T07	座席マップ取得（プロファイル参照あり）	0.163	.00/.00/.25/1.00/.00	.00/.00/.00/.00/.00	0.000	—
T08	提供者への問合せ（PII 非送信）	0.075	.00/.00/.00/.00/.75	.00/.00/.00/.00/.08	0.008	—
T09	旅行者プロファイルの読み取り	0.163	.00/.00/.25/1.00/.00	.00/.00/.00/.00/.00	0.000	—
T10	費用見積もりと通貨換算	0.000	.00/.00/.00/.00/.00	.00/.00/.00/.00/.00	0.000	—
T11	座席の無償仮押さえ	0.275	.00/.00/.50/1.00/.50	.00/.00/.02/1.00/.00	0.104	—
T12	合意済み提供者への予約申込	0.575	.50/.50/.50/1.00/.75	.38/.31/.02/1.00/.38	0.310	—
T13	決済の与信確保（capture なし）	0.275	.75/.00/.00/.00/.50	.00/.00/.00/.00/.00	0.000	—
T14	行程表の出張者本人への送信	0.250	.00/.00/.50/.25/1.00	.00/.00/.07/1.00/.38	0.142	**反証 (scope)**
T15	既存予約の変更	0.562	.25/.75/.50/1.00/.75	.24/.00/.00/1.00/.00	0.172	—
T16	行程表の同行者 3 名への送信	0.300	.00/.00/.50/.75/1.00	.00/.00/.09/1.00/.54	0.163	**反証 (scope)**
T17	決済の確定（capture）	0.487	.75/.75/.00/.00/.75	.60/.00/.00/.00/.23	0.203	—
T18	既存の有償予約のキャンセル	0.600	.50/1.00/.00/1.00/1.00	.18/.14/.00/1.00/.23	0.213	—
T19	提供者へ special 情報送信	0.388	.00/.00/.75/1.00/1.00	.00/.00/.20/1.00/.23	0.173	—
T20	航空券の発券	0.675	.75/1.00/.00/1.00/1.00	.18/.14/.00/1.00/.23	0.213	—
T21	社外出張管理系への情報連携	0.575	.00/.75/.75/1.00/1.00	.00/.00/.20/1.00/.38	0.173	—

A.5 実験設計に関する注釈

(1) 独立に実装した決定的ルーブリック解釈器 3 本を用いた．3 器はアンカーが真に曖昧な箇所（`declared_ambiguities` として宣言）でのみ分岐する．(2) 攻撃者は LLM ではなくホワイトボックスのフィードバック誘導探索とした．離散パラメータ空間の探索であるため行動空間は実 LLM 攻撃者より狭く，$\hat{L}_{\max}$ は下界としてより弱い．(3) 検証層 $w^{(j)}$ は B の逸脱量（余剰実行・PE 拒否回数・成果物欠落）からの決定的写像で生成した．ペナルティ係数はモデリング選択であり，1 タスク内で攻撃者が実行できる余剰行動数（本設定で約 8 回）を決める最大の感度パラメータである．(4) `escalate` は自由文ペイロード（機械判定不能）に対してのみ発火する設計とし，D1 に従い deny ＋記録として実装した．(5) 為替の決済スプレッドは π の設計ではなくサンドボックス世界の性質としてモデル化した．(6) 到達不能タスクは「委譲拒否」と「Detach 後未発行」を別カテゴリとして集計した．(7) $R_{\text{eff}} = 1$ のタスク・対は除外せず別掲した（次元別で 17 対）．(8) ブートストラップは実施していない（得られるのは下界の変動であって sup の信頼区間ではないため）．

A.6 損失の副次的な測定

回復あり L^{rec} と回復なし L^{norec} の差（同一ログからの再集計）は金銭次元でのみ大きく（平均 155,207，最大 248,999），不可逆性で平均 1.41 RCU，情報・影響範囲・外部効果では 0 であった．送信済みの情報は取り消せないため，回復を検知可能性でゲートする設計は機能しており，ρ_{rev} の可逆／不可逆の区別は測定上消滅していない．情報次元では，文字通りの開示を数える $L^{\text{literal}}_{\text{data}}$（最大 5.6）と汚染追跡による $L^{\text{taint}}_{\text{data}}$（最大 6.96）の比が平均 1.784 であり，保守的な汚染追跡は本ドメインで約 1.8 倍の過大評価を生む．主指標は literal，taint は上界として報告した．

A.7 パラメータ

Γ : $\theta = 0.7$, $\alpha_{\text{base}} = 0.5$, $\gamma = 1.5$, $\varepsilon_{\text{boot}} = 0$, $K_0 = 1.0$, $s = 1.0$（較正時は固定），β ={artifact 0.30, external 0.35, semantic 0.20, timeliness 0.15}，e_i ={V0 0.5, V1 0.7, V2 0.9, V3 1.0}，半減期 { 通常 120 分, 決済・special 30 分 }（模擬時間）．ω_d : 金銭 0.30，不可逆性 0.25，情報 0.25，影響範囲 0.10，外部効果 0.10．$L_{\max,d}$: 金銭 ¥500,000（付与した決済枠総額），不可逆性 21.0 RCU，情報 22.8，影響範囲 4（データ主体総数），外部効果 13．PE の quota : 1 回 ¥100,000 ／宛先別 ¥150,000 ／セッション累積 ¥300,000 ／外向き呼出 40 回．計上方針は，為替は約定レート，hold を計上，返金では枠を戻さない，決済手段は合算，である．観測地平は Detach から $\Delta = 72$h（模擬時間），タスク間隔は 10 分（模擬時間）とした．なお推奨設定として本文で言及した Γ は $\alpha_{\text{base}} = 0.4$，$\theta = 0.7$，$\gamma = 2.0$，$K_0 = 3.0$，$\varepsilon_{\text{boot}} = 0$ である．

© 2026 Information Processing Society of Japan