クラスタ解析に基づくサイドチャネル攻撃のための オートエンコーダと分類器を組み合わせた 深層特徴抽出モデルの提案

吉村 岳大[1,a)]　福田 悠太[2]　吉田 康太[2]　堀 洋平[2]　藤野 毅[1]

概要：非プロファイルシナリオにおけるサイドチャネル攻撃として，我々はこれまでにクラスタ解析に基づくサイドチャネル攻撃 (CA-SCA) を提案した．この攻撃では，ニューラルネットワークから抽出した特徴ベクトルのクラスタ構造を利用して鍵を推定する．CA-SCA にはオートエンコーダ (AE) および畳み込みニューラルネットワーク (CNN) を利用した手法が存在するが，AE ベースの手法ではマスキング対策が施された実装に対する攻撃性能が低いという課題がある．一方，CNN ベースの手法はマスキングに対して有効であるものの，特徴抽出に利用する中間層を一意に決定できないという課題を有する．そこで本稿では，サイドチャネル波形を再構成する AE をベースに，その潜在空間から平文を推定する分類器を追加接続する深層特徴抽出モデルを提案する．本モデルでは AE の再構成誤差，平文分類誤差および正則化項を損失関数としてモデルを最適化する．これにより，潜在空間は平文に関連する識別性を持ちながら波形情報を保持する特徴表現として学習されるため，マスキングに対しても有効な特徴抽出を実現する．実験では，ASCAD データセットを用いて評価を行い，提案手法がマスキング対策実装に対して有効な特徴抽出を実現できることを確認した．

キーワード： CA-SCA, 非プロファイル型攻撃, 深層学習サイドチャネル攻撃

Deep Feature Extractor Integrating Autoencoder and Classifier for Cluster Analysis-based Side-channel Attacks

Gakuto Yoshimura[1,a)]　Yuta Fukuda[2]　Kota Yoshida[2]　Yohei Hori[2]　Takeshi Fujino[1]

Abstract: As a non-profiled side-channel attack scenario, we have previously proposed cluster analysis-based side-channel attacks (CA-SCAs). This attack estimates the secret key by exploiting the cluster structure of feature vectors extracted from a neural network. CA-SCA includes methods based on autoencoders (AEs) or convolutional neural networks (CNNs); however, the AE-based methods suffer from low attack performance against masked implementations. In contrast, the CNN-based methods are effective against masking, but they have the limitation that the hidden layer used for feature extraction cannot be uniquely determined. In this paper, we propose a deep feature extraction model that connects a classifier, which estimates the plaintext from the latent space, to an AE that reconstructs the side-channel waveform. This model is optimized using a loss function composed of the AE's reconstruction error, the plaintext classification error, and a regularization term. As a result, the latent space is trained to be a feature representation that retains waveform information while acquiring discriminability related to the plaintext, thereby achieving effective feature extraction even against masked implementations. In our experiments, we evaluated the proposed method using the ASCAD dataset and confirmed that it achieves effective feature extraction against masked implementations.

Keywords: CA-SCA, Non-profiled Side-channel attacks, Deep Learning-based Side-channel attacks

© 2026 Information Processing Society of Japan

This paper is work in progress and not peer-reviewed.

1. はじめに

近年，様々なモノがインターネットにつながる IoT（Internet of Things）の普及が進んでいる．これに伴い，IoT デバイスで扱われる機密情報は，暗号技術によって通信の安全性が確保されている．現在実用化されている暗号アルゴリズムは，暗号文の数学的な解析が現実的な時間内では困難とされている．しかし，暗号回路の動作時に生じる消費電力や電磁照射などの漏洩情報 （サイドチャネル情報）を測定・解析することで, 暗号回路内の秘密鍵を窃取することができるというサイドチャネル攻撃（SCA: Side-channel attacks）が大きな脅威となっている．

SCA には, 暗号中間値とサイドチャネル情報の相関に着目する相関電力解析（CPA: Correlation Power Analysis）[1] や，暗号回路の動作パターンを分析しテンプレートを作成し, 作成したテンプレートとターゲットデバイスの消費電力波形から鍵を盗むテンプレート攻撃 [2] などがある．特に，ジッタリング対策やマスキング対策などの SCA 対策が行われているデバイスに対して攻撃を成功させるには, 実装に関する専門的な知識やアライメントなどの前処理が必要となる．そこで, これらの知識を必要としなくとも攻撃を可能にする深層学習サイドチャネル攻撃 （DL-SCA: Deep Learning-Based Side-channel Analysis）[3] が報告されている．DL-SCA では，深層学習モデルがサイドチャネル情報から自動的に特徴量を抽出・モデル化するため，攻撃に必要な専門知識を大幅に削減できる．さらに，マスキング対策等の SCA 対策が施された暗号回路に対しても有効であることが報告されている．

SCA の攻撃シナリオは，プロファイル型と非プロファイル型攻撃の 2 つに分類され, 前述したテンプレート攻撃はプロファイル型, CPA は非プロファイル型に分類される．プロファイル型攻撃は，攻撃者の手元にターゲットと同等の制御・解析が可能なプロファイリングデバイスが存在することを前提とするシナリオである．一方，非プロファイル型攻撃はプロファイリングデバイスを用いず，ターゲットデバイスのみを直接解析するシナリオである．DL-SCA に関する初期の研究ではプロファイル型が主流であったが，近年では非プロファイル型攻撃に関する研究も活発化している．2019 年に Timon は，非プロファイル型 DL-SCA として差分深層学習解析（DDLA: Differential Deep-Learning Analysis）[4] を提案した．DDLA は，従来の CPA では攻撃困難であったランダムジッタ対策 [5] やマスキング対策を施したソフトウェア実装 AES に対しても有効であることを示した．

DDLA に関連する研究として，学習の効率化やラベリング手法の観点からいくつかの改良が提案されている．Kwon らは過学習を抑制するための early stopping の導入に加え，複数モデルを並列に学習させることで攻撃全体の高速化を実現した [6]．また，Wu らは平文ラベルを利用する点で従来と異なるアプローチにより非プロファイル型 DL-SCA を実行する手法を提案した [7]．2024 年に我々は，クラスタ解析に基づくサイドチャネル攻撃（CA-SCA: Cluster Analysis-based Side-Channel Attack）[8] を提案し，DDLA と同等の攻撃性能を維持しながら，学習モデル数を削減することで処理時間を大幅に短縮できることを報告した．

しかしながら，CA-SCA には特徴抽出モデルとして用いる深層学習モデルの種類に起因する課題が存在する．CA-SCA では，オートエンコーダ（AE）[9]，または畳み込みニューラルネットワーク（CNN）[10] が特徴抽出モデルとして用いられるが，それぞれ固有の問題を抱えている．AE を用いる場合は，ボトルネック層である潜在変数を特徴抽出層として一意に定義できるため，層選択の不定性は生じない．しかし，AE は教師なし学習によって入力波形の再構成誤差を最小化するように学習されるため，得られる潜在変数が必ずしも鍵に関連する特徴を捉えるとは限らない．そのため，特にマスキング対策が施された波形に対しては，鍵情報とマスク値との非線形な関係を潜在変数上で十分に分離できず，鍵を特定できないという課題があった．一方，CNN を用いる場合，中間層のうちどの層の出力を特徴量として採用すべきかが明確でなく，攻撃者の経験的な判断や試行錯誤に依存しているのが実情である．この特徴抽出層の選択の不定性は，攻撃性能の再現性や汎用性を損なう要因となり得る．

そこで本稿では，CA-SCA が抱える「教師なし学習に起因するマスキング対策への弱さ」と「特徴抽出層の選択における不定性」という 2 つの課題を同時に解決するため，AE のボトルネック層に分類器を結合した深層特徴抽出モデルを提案する．提案手法では，AE の潜在変数を分類器の入力とし，平文ラベルを教師情報として学習を行う．これにより，潜在変数（特徴抽出層）を一意に定義しつつ，鍵情報に関連する特徴を潜在空間上に明示的に反映させる．この構造により，特徴抽出層選択の不定性を解消すると同時に，従来の AE を用いた CA-SCA では困難であったマスキング対策データに対しても有効な特徴抽出を可能にする．

本稿の貢献を以下に示す．

- CA-SCA における「特徴抽出層選択の不定性」および「教師なし学習 AE のマスキング対策に対する適用限界」という課題を整理し，これらを同時に解決する深層特徴抽出モデルを提案した．AE のボトルネック層

[1] 立命館大学
Ritsumeikan University
[2] 国立研究開発法人産業技術総合研究所
National Institute of Advanced Industrial Science and Technology
[a)] ri0133hx@ed.ritsumei.ac.jp

© 2026 Information Processing Society of Japan

に分類器を結合し，平文ラベルに基づく分類誤差を損失関数に組み込む学習手法を構成した．これにより，特徴抽出層を明示的に一意化するとともに，鍵情報に関連する特徴を潜在空間へ効果的に反映させる技術を確立した．

- ASCAD database を用いた全バイト攻撃実験を実施し，既存手法（CA-SCA (AE, CNN)，CPA，DDLA）と比較して GE および SR の両指標で優位性を示した．特に，マスキング対策が施された複数のサブバイトに対しても高い攻撃性能を達成・維持できることを実証した．

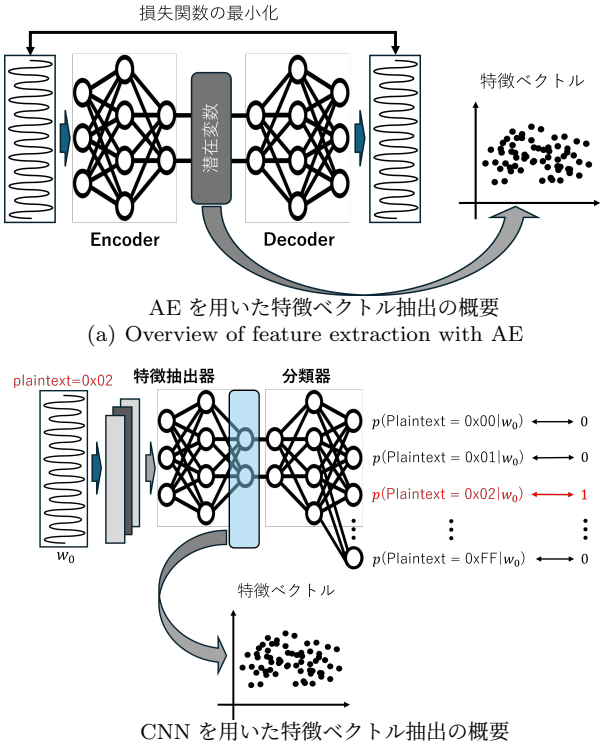
2. クラスタ解析に基づくサイドチャネル攻撃

2.1 概要と攻撃手順

これまでに我々は攻撃時間を大幅に短縮した非プロファイル型 DL-SCA としてクラスタ解析に基づくサイドチャネル攻撃 (CA-SCA: Cluster Analysis-based Side-channel Attack) を提案した [8]．本手法では，漏洩情報から DNN モデルを用いて特徴ベクトルを抽出し，これをクラスタ解析することで鍵を推定する．初めに，図 1 に CA-SCA における特徴ベクトル抽出の概要を示す．先行研究では特徴抽出モデルとして AE または CNN を用いていた．本節ではそれぞれのモデルによる特徴ベクトル抽出の流れについて説明する．図 1(a) に示す AE を用いる場合，入力波形の再構成誤差を最小化するようにモデル全体を学習した後，ボトルネック層である潜在変数を特徴ベクトルとして抽出する．一方，図 1(b) に示す CNN を用いる場合，平文を教師ラベルとした分類問題としてモデルを学習し，出力層直前の中間層の出力を特徴ベクトルとして抽出する．

次に，CA-SCA における攻撃手順を図 2 に，詳細な手順を Algorithm1 に示す．攻撃者はまず，サイドチャネル波形から特徴ベクトルを抽出するためのニューラルネットワーク (NN) モデル (以降，深層特徴抽出モデルと呼ぶ) を学習する．次に，学習済み深層特徴抽出モデルを用いて漏洩情報から特徴ベクトルを抽出し，鍵バイト候補 $\hat{k} = 0\text{x}00 \sim 0\text{x}FF$ の 256 通りそれぞれについて，中間値を計算する．ここでいう中間値とは，鍵バイト候補 $\hat{k}$ と既知の平文 $\mathbb{P}$ から $h = \text{S-Box}(\hat{k} \oplus \mathbb{P})$ のように算出される暗号処理中の内部状態を指す．そして，得られた中間値の最下位ビット (LSB) などのラベルに基づき，後述する Calinski-Harabasz index (CH index) を用いて特徴ベクトルのクラスタ性を評価する．そして，CH index が最も高い鍵候補を推定鍵として出力する．

なお，Algorithm 1 における波形データセット $\mathbb{D}$ は，特徴抽出モデルの種類に応じて構成が異なる．AE を用いる場合，$\mathbb{D}$ は波形データのみから構成される教師なしデータセットであるのに対し，CNN を用いる場合，$\mathbb{D}$ は波形と対応する平文の組から構成される教師ありデータセットとなる．



AE を用いた特徴ベクトル抽出の概要
(a) Overview of feature extraction with AE

CNN を用いた特徴ベクトル抽出の概要
(b) Overview of feature extraction with CNN

図 1 CA-SCA における特徴ベクトル抽出
Fig. 1 Feature Vector Extraction in CA-SCA

Algorithm 1 DNN モデルを用いた CA-SCA

Require: 波形データセット $\mathbb{D}$, 鍵候補の空間 $\mathcal{K}$,
エポック数 N_{ep}, 特徴抽出層のパラメータ θ_{f}
Ensure: 推定鍵 k^*

for epoch = 1 to N_{ep} **do**
  Training $\mathcal{M}_{\text{f}}$ with $\mathbb{D}$ // DNN の学習
end for
$\mathcal{X} = \mathcal{M}_{\text{f}}(\mathbb{D})$ // $\mathcal{X}$ はクラスタ解析に用いられる特徴ベクトル
for target_byte = 0 to 15 **do**
  for k in $\mathcal{K}$ **do**
    $h = \text{S-Box}(k \oplus \mathbb{P}_{\text{target_byte}})$
    $\text{S}_{\text{cal}}[k] \leftarrow s$ calculated with h and $\mathcal{X}$ by Eq. (1) or (4)
  end for
  $k^*[\text{target_byte}] = \arg\max_i \text{S}_{\text{cal}}[i]$
end for
return k^*

CA-SCA は，差分深層学習解析 (DDLA: Differential Deep Learning Analysis) と同程度の攻撃性能を維持しながら，攻撃に必要な NN モデルの学習数を大幅に削減できるという特徴を持つ．具体的には，1 バイトの鍵に対して 256 種の鍵候補ごとにモデルを学習する DDLA とは異なり，CA-SCA では 1 個または 16 個の NN モデルのみで全鍵候補に対する攻撃が可能であり，これにより攻撃にかかる時間が大幅に短縮される．

© 2026 Information Processing Society of Japan

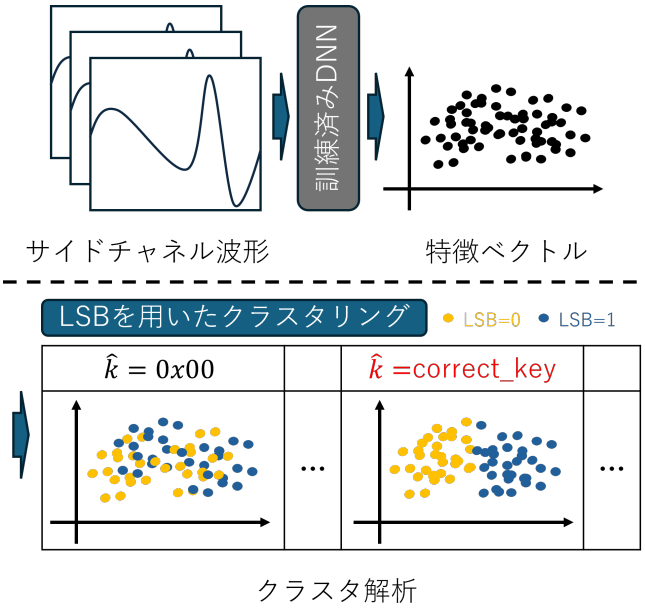


図 2 CA-SCA における攻撃手順
Fig. 2 Attack Procedures in CA-SCA

2.2 Calinski-Harabasz index (CH index)

クラスタ評価指標には Calinski-Harabasz index (CH index) を使用する．CH index は，クラスタ内およびクラスタ間の分散の比に基づく指標である．N 個のサンプルから構成されるデータセット $X = \{x_1, \ldots, x_N\}$ が，k 個のクラスタ $\{C_1, \ldots, C_k\}$ に割り当てられているとき，CH index は以下の式のように定式化される．

$$CH_{index} = \frac{B_k}{W_k} \times \frac{N-k}{k-1} \tag{1}$$

$$B_k = \sum_{i=1}^{k} n_i \|m_i - m\|_2^2 \tag{2}$$

$$W_k = \sum_{i=1}^{k} \sum_{x \in C_i} \|x - m_i\|_2^2 \tag{3}$$

ここで，B_k および W_k はそれぞれクラスタ間平方和およびクラスタ内平方和を表す．また，m_i，m，n_i は，それぞれクラスタ C_i の重心，全サンプルの重心，クラスタ C_i に割り当てられたサンプル数を示す．

CH index は多変量データ X を入力として計算され，スコアに上限は存在しない．スコアが高いほどクラスタが明確に分離・形成されていることを意味し，逆に 0 に近いほどクラスタ間の分離が不十分で混在している状態を示す．

本節では，抽出された特徴ベクトルの集合 X と，それに対応する鍵を仮定したときの暗号中間値を用いて計算されるラベル集合 $L = \{l_1, \ldots, l_N\}$ に対し，CH index を計算する関数を $\mathrm{CH}(X, L)$ と表記する．本研究では，CH index の計算として multi-bit ラベルを用いた．これは，暗号中間値 h のすべてのビットに着目する．b ビット目に着目した mono-bit ラベルセット $H_b = \{h_{b,1}, \ldots, h_{b,N}\}$ が 8 ビットすべて与えられた場合，抽出された特徴ベクトル $\mathcal{X}$ を用いて以下の式のように CH index s を計算する．

$$s = \sum_{b=0}^{7} \mathrm{CH}(\mathcal{X}, H_b) \tag{4}$$

つまり，mono-bit で算出した CH index s の総和をとり，各鍵候補ごとのスコアを比較する．なお，本研究における CH index の計算には scikit-learn ライブラリの実装を用いた．

表 1 既存手法と提案手法の比較
Table 1 Comparison between conventional CA-SCAs and the proposed method

NN モデル	マスキング対策への攻撃性	解析ポイントとしての妥当性
AE	×	○
CNN	○	×
本研究	○	○

2.3 CA-SCA の課題点

既存の CA-SCA では，特徴抽出用の NN モデルとしてオートエンコーダ (AE) または畳み込みニューラルネットワーク (CNN) が用いられているが，それぞれ以下に示す異なる課題を抱えている．

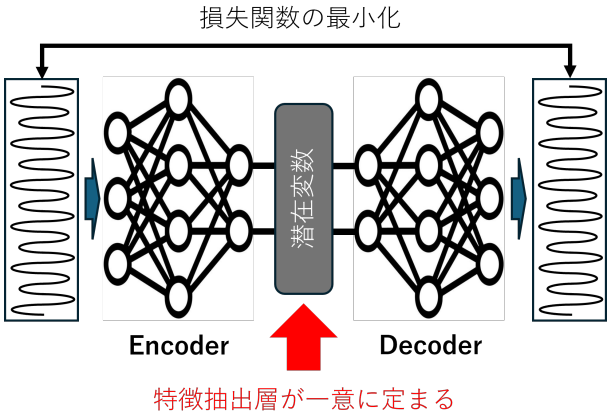
AE を用いた場合 AE を用いた CA-SCA では，図 3(a) で示すようにボトルネック層である潜在変数を特徴抽出層として一意に定義できるという利点がある．しかしながら，AE は教師なし学習によって入力波形の再構成誤差を最小化するように学習されるため，潜在変数が必ずしも秘密鍵に関連する特徴を捉えているとは限らない．そのため，マスキング対策が施されたサブバイトに対しては，鍵情報とマスク値の非線形な関係を潜在変数上で分離できず，攻撃に失敗するという課題がある．

CNN を用いた場合 CNN を用いた CA-SCA では，マスキング対策が施されたサブバイトに対しても比較的高い攻撃性能を示すことが報告されている．しかしながら，図 3(b) に示すように CNN は複数の中間層から構成されるため，どの中間層の出力を特徴抽出に用いるべきかが自明ではない．既存の CA-SCA では最終層 (出力層直前の層) を特徴抽出層として採用しているが，この選択は攻撃者の経験則や試行錯誤に依存しており，理論的な根拠に乏しい．この特徴抽出層の選択の不定性は，攻撃性能の再現性や手法としての汎用性を損なう要因となり得る．

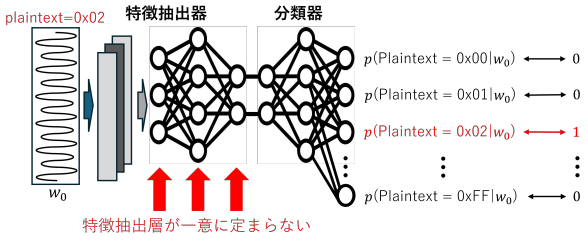
以上のように，AE を用いた CA-SCA と CNN を用いた CA-SCA は，それぞれ「解析ポイントとしての妥当性」と「マスキング対策への攻撃性」においてトレードオフの関係にある．この関係を表 1 に示す．

本稿では，AE の持つ「特徴抽出層が一意に定まる」と

© 2026 Information Processing Society of Japan



(a) AE の概要



(b) CNN の概要

図 3 DNN モデルの概要
Fig. 3 Overview of deep neural network

いう利点を活かしつつ，マスキング対策への攻撃性を両立させる深層特徴抽出モデルを提案する．

3. 提案手法

3.1 アプローチ

本研究では，CA-SCA が抱える「特徴抽出層選択の不定性」および「教師なし学習 AE のマスキング対策に対する適用限界」という 2 つの課題を同時に解消するため，分類器を結合したオートエンコーダ（AE）に基づく深層特徴抽出モデルを提案する．本手法の設計における核心は，AE の構造的利点と平文ラベルによる教師あり学習の利点を融合させる点にある．各課題に対する具体的アプローチを以下に示す．

特徴抽出層の一意化（AE 構造の利用） CNN とは異なり，AE は入力を一度低次元空間へ圧縮するボトルネック構造を持つ．本手法では，このボトルネック層である潜在変数（Latent Variables）を特徴抽出層として明示的に定義する．これにより，図 3(b) における中間層の選択に関する攻撃者の経験的な試行錯誤を排除し，再現性と汎用性の高い特徴抽出を実現する．

鍵関連特徴の抽出（分類器と複合損失） 従来の AE は入力波形の再構成誤差のみを最小化するよう学習されるため，潜在変数が必ずしも暗号の鍵情報に関連する高次な特徴を表現するとは限らない．そこで本手法では，ボトルネック層の潜在変数を使った分類器を結合し，平文（または平文に関連する中間値）を目的変数とした分類学習を行う．学習時には，波形の再構成損失に加えて分類損失を組み込んだ複合的な損失関数を用いる．

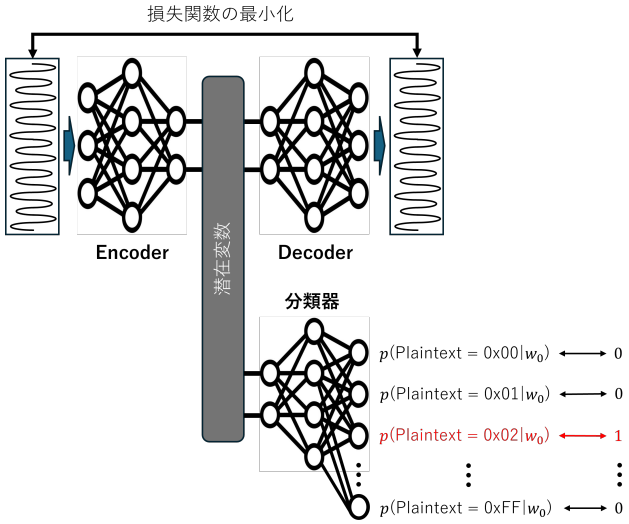


図 4 提案する深層特徴抽出モデル
Fig. 4 Proposed deep feature extractor

平文ラベルを教師情報としてモデルに与えることで，潜在変数空間は「平文（および鍵情報に依存する中間状態）を効果的に識別できる特徴表現」を学習するように誘導される．これにより，層の選択を一意に固定したまま，従来の AE では攻撃が不可能であったマスキング対策が施された波形に対しても，鍵の特定に必要な表現力を潜在変数上に確保することが可能となる．

3.2 提案モデル

提案モデルの全体像を図 4 に示す．本モデルは，教師なし学習によって波形の再構成を行う AE 部分（Encoder–Decoder）と，潜在変数から平文（または中間値）を分類する分類器（Classifier）から構成される．AE の潜在変数に対して分類器を結合し，その分類誤差をモデル全体の学習に反映させることで，潜在変数に鍵情報に関連する特徴を獲得させる．

提案モデルの総合損失関数 L_{total} を式 (5) に示す．

$$L_{\text{total}} = \alpha L_{\text{rec}} + \beta L_{\text{reg}} + \gamma L_{\text{cls}} \tag{5}$$

α, β, γ は各損失項の寄与を調整する重み係数であり，L_{rec}，L_{reg}，L_{cls} はそれぞれ以下のように算出される．

L_{rec} は AE の入出力の再現度を表す再構成誤差であり，入力波形 x と Decoder の出力 $\hat{x}$ との平均二乗誤差（MSE: Mean Squared Error）として算出される．L_{reg} は潜在変数の発散を防ぐための正則化項であり，Encoder が出力する潜在変数 z の L2 ノルム $\|z\|_2^2$ として算出される．L_{cls} は分類器の出力と正解ラベルの差を表す分類誤差であり，分類器が潜在変数 z から出力する平文の予測ロジットと，正解の

© 2026 Information Processing Society of Japan

平文ラベルとの交差エントロピー誤差（Sparse Categorical Cross-entropy）として算出される．

この構成により，特徴抽出層を一意に定義しつつ，マスキング対策が施された波形に対しても鍵情報に関連する特徴表現を抽出することが可能となる．

4. 実験と結果

4.1 実験内容

提案手法の有効性を検証するため，ASCAD database を対象とした全バイト攻撃実験を行った．ASCAD database は 8-bit microcontroller である AVR ATMega8515 上で，テーブル再計算マスキング対策 [11] を施した AES ソフトウェア実装の漏洩電磁波の波形を提供する公開データセットである．測定にはサンプリング周波数が 2GS/s のオシロスコープを使用しており，AES 暗号処理の 1 ラウンド目に対応する波形を使用することができる．ASCAD database は可用性の観点から，あらかじめ 2 バイト目の SubBytes 処理が切り取られた状態で提供されている．一方で，すべてのバイトを含む Raw trace も提供されており，本研究では，16 バイトの鍵を窃取する攻撃を実行するため，まず Raw trace 全体から各バイトの SubBytes 処理位置を特定する PoI(Point of Interest) 選定を実施し，SubBytes 処理に対応する範囲を使用している．ここで，0 バイト目と 1 バイト目のマスク値が 0 に固定されており，マスキング対策が無効となっていることに注意されたい．

本実験では，ASCAD database を用いて 20 回の独立した攻撃を実施し，正解鍵の平均ランクを示す guessing entropy（GE）および success rate（SR）を評価指標として用いた．データセット全体の 60,000 波形を学習用と評価用に 8:2 で分割し，10,000 波形から 60,000 波形まで 10,000 波形毎に評価を実施した．比較対象の攻撃手法として，CPA[1]，DDLA[4]，従来の CA-SCA(AE，CNN)[8]，および提案手法の 5 手法を実行し，攻撃結果を比較した．

各攻撃手法では，既存研究をもとに中間値の漏洩モデルとして異なるラベリング手法を採用している．CPA では，中間値を構成するビットのうち値が 1 であるビットの数を漏洩モデルとする Hamming Weight(HW)[12] をラベルとして用いた．DDLA では，中間値の LSB の値によってラベルを 2 値に分類する LSB ラベリング手法を採用した．一方，CA-SCA および提案手法では，中間値そのものを 1 バイト単位 (256 クラス) でラベルとして扱うマルチビットラベリング手法 [13] を採用した．これは，HW や LSB のように中間値を低次元の情報に圧縮せず，中間値が本来保持する情報をより高い解像度でモデルに反映させる手法である．CH index の計算においては，式（4）を用いて計算される．

また，CNN を用いた CA-SCA において，既存研究をもとに特徴抽出層として最後段の中間層の特徴量をクラスタ解析に使用している．

提案モデルで使用した AE および分類器のネットワーク構造の概要を表 2 に示す．AE の Encoder は畳み込み層 (Conv1D) を 2 層重ねた後，全結合層を経て 128 次元の潜在変数を出力する構成とし，Decoder は全結合層を複数重ねた後，入力波形と同じ 700point を出力とし，波形を再構成する．分類器は，128 次元の潜在変数を入力とし，全結合層を複数重ねた後，256 クラス (1 バイトの値) を出力する構成とした．最適化手法には Adam(学習率 0.0001) を用い，エポック数 300，バッチサイズ 4096 で学習を行った．

損失関数における各重み係数 α, β, γ（式 (5)）の設定にあたっては，分類誤差 L_{cls} の重み γ を 1 に固定した上で，再構成誤差の重み α および正則化項の重み β を変化させ，攻撃が成功する組み合わせを探索的に決定した．本研究では，この探索により得られた $\alpha = 1 \times 10^{-6}$，$\beta = 1 \times 10^{-3}$，$\gamma = 1$ という組み合わせを採用している．

再構成誤差 L_{rec} および正則化項 L_{reg} の重み α, β を過度に大きくすると，潜在変数が波形の再構成や発散抑制のみに最適化され，鍵情報に関連する識別性や攻撃性能が低下する傾向が見られたため，いずれも L_{cls} より十分小さい値に設定した．

CA-SCA は DDLA と比較して，16 バイトの鍵を解析するのに必要なモデル数が 4096(=256×16) から 16 へと大幅に削減されるため，計算量の観点で有利である．ここでは，学習効率の点で CA-SCA のもう 1 つの利点について説明する．

シングルコアのマイコンで暗号化処理を実施する場合，各バイトにおける処理は逐次に処理される．そのため，16 の鍵バイトに対応するサイドチャネルリークは，図 5 上段に示すように，リーク波形上の 16 個の別々の箇所に，バイト番号の順序とは無関係に分散して現れる．一方で，これらのリークポイントにおけるバイト処理の内容は，いずれも同一の SubBytes 処理であるため，本質的には同じ演算に対応している．

そこで提案手法では，図 5 に示すように，Raw trace 全体から特定した 16 バイト分の PoI(Point of Interest) を抽出し，バイト番号順に並べ替えて連結することでデータセットを構築する．以降，このデータセットを連結データセットと呼ぶ．

連結データセットを用いることで，学習効率の観点から 2 つの利点が得られる．第一に，単一の暗号化処理から 16 個の波形を学習データとして取得できるため，同じ測定回数でも学習データ量が実質的に増加し，学習効率が向上する．第二に，各バイトの処理内容が同一であることを利用し，バイトごとに個別のモデルを用意する必要がなくなるため，NN のモデル数を 16 から 1 に削減できる．

AE を用いた CA-SCA では，モデルは連結データセットに対する再構成誤差を最小化するように学習される．一

© 2026 Information Processing Society of Japan

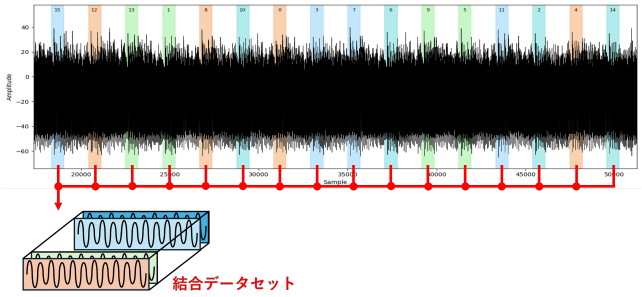


図 5 連結データセットの概要
Fig. 5 Overview of concatenated dataset

表 2 提案モデルにおける NN の設定
Table 2 Network configuration of the proposed model

Network			
		Layer type	Output Shape
オートエンコーダ (AE)	Encoder	Input	(None, 700, 1)
		Conv1D (filters=32, kernel_size=4, strides=4) + BN + ReLU	(None, 175, 32)
		MaxPooling1D (pool_size=2)	(None, 87, 32)
		Conv1D (filters=24, kernel_size=3, strides=3) + BN + ReLU	(None, 29, 24)
		MaxPooling1D (pool_size=2)	(None, 14, 24)
		Flatten	(None, 336)
		Full Connected(256) + ReLU	(None, 256)
		Full Connected(256) + ReLU	(None, 256)
		Full Connected(128) + ReLU (latent z)	(None, 128)
	Decoder	Full Connected(64) + ReLU	(None, 64)
		Full Connected(128) + ReLU	(None, 128)
		Full Connected(256) + ReLU	(None, 256)
		Full Connected(700) + ReLU	(None, 700)
		Reshape	(None, 700, 1)
	Classifier	Input	(None, 128)
		Full Connected(64) + ReLU	(None, 64)
		Full Connected(128) + ReLU	(None, 128)
		Full Connected(256) + ReLU	(None, 256)
		Full Connected(256) (logits)	(None, 256)
他の設定			
エポック数: 300			
モデル全体の損失関数: $Loss = 1 \times 10^{-6} \cdot L_{rec} + L_{cls} + 1 \times 10^{-3} \cdot L_{reg}$			
（L_{rec}: MeanSquaredError, L_{cls}: SparseCategoricalCrossentropy, L_{reg}: L2 正則化）			
分類器の損失関数: SparseCategoricalCrossentropy(from_logits=True)			
最適化アルゴリズム: Adam(learning_rate=0.0001)			
バッチサイズ: 4096			

方，CNN を用いた CA-SCA では，モデルはリーク波形に対応するバイトの平文が出力されるように学習される．学習済みの AE および CNN に対してターゲットバイトに対応するリーク波形を入力し，抽出された特徴ベクトルにクラスタ解析を適用することで，鍵を明らかにする．

4.2 実験結果

図 6 に，各攻撃手法における 2〜15byte の GE 平均（20 回試行）を示す．提案手法は 10,000 波形の条件では CA-SCA (CNN) をわずかに上回る GE を示したものの，20,000 波形以降は他のすべての手法よりも低い GE を一貫して達成した．

また，図 7 に同条件下での SR 平均を示す．提案手法は，10,000 波形時点では CA-SCA (CNN) に対してやや低い SR を示したが，30,000 波形以降は他のすべての手法よりも高い SR を一貫して達成した．

これらの結果から，提案手法は CA-SCA(AE) では鍵の特定が困難であったマスキング対策が施されたサブバイト

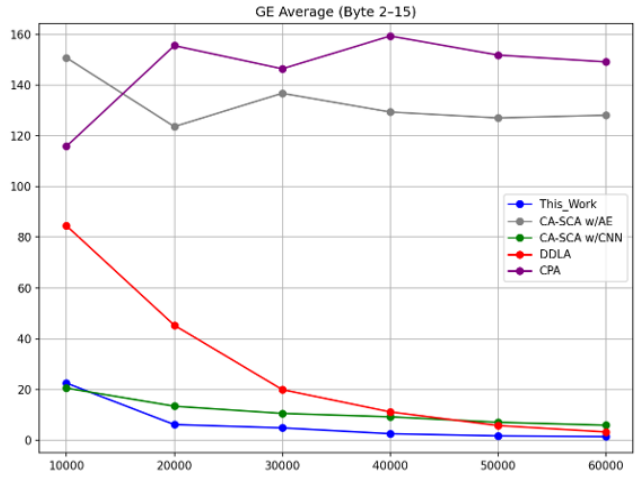


図 6 GE 平均比較結果（本手法 / CA-SCA / DDLA / CPA）
Fig. 6 Average GE comparison (This Work / CA-SCA / DDLA / CPA)

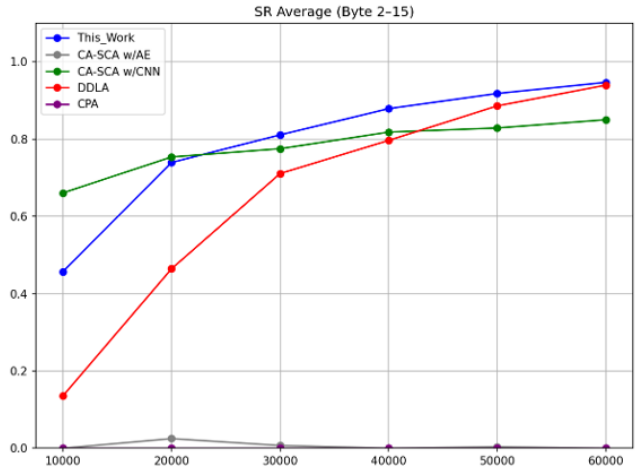


図 7 SR 平均比較結果（本手法 / CA-SCA / DDLA / CPA）
Fig. 7 Average SR comparison (This Work / CA-SCA / DDLA / CPA)

への攻撃に成功したといえる．これは，教師なし学習のみに基づく AE に対し，提案手法では平文ラベルを用いた分類誤差を損失関数に組み込むことで，潜在変数に鍵情報に関連する識別性を付与できたためと考えられる．さらに，複数の中間層を持つ CA-SCA(CNN) では特徴抽出層の選択に不定性が残るのに対し，提案手法は AE のボトルネック層を特徴抽出層として明示的かつ一意に定義できる．したがって，提案手法は CA-SCA(AE) と CA-SCA(CNN) がそれぞれ抱えていた「マスキング対策への攻撃性」と「解析ポイントとしての妥当性」という 2 つの課題を同時に解決できているといえる．

また，表 3 に，各攻撃手法における鍵解析に要した計算時間を示す．なお，CPA および CA-SCA(AE) は，図 6 および図 7 に示した通り，マスキング対策が施されたサブバイトに対して攻撃が成立していないため，計算時間の比較対象からは除外した．

© 2026 Information Processing Society of Japan

表 3 計算時間結果 (本手法 / CA-SCA(CNN) / DDLA)
Table 3 Time comparison (This Work / CA-SCA(CNN) / DDLA)

攻撃手法	計算時間
提案手法	14m 48s
CA-SCA（CNN）	5m 31s
DDLA	3h 31m 35s

DDLA は鍵候補ごとに個別のモデルを学習する必要があるため，計算時間が 3 時間 31 分 35 秒と，他の二手法と比較して大幅に長くなっている．一方，提案手法および CA-SCA(CNN) は鍵候補ごとにモデルを学習する必要がなく，1 個のモデルのみで全鍵候補への攻撃が可能であるため，それぞれ 14 分 48 秒，5 分 31 秒と，DDLA の 1/14 以下の計算時間で攻撃を完了でき，計算時間の観点において DDLA に対して大きな優位性を示した．

提案手法が CA-SCA(CNN) よりもやや長いのは，Encoder–Decoder と分類器を同時に学習する構成上，1 エポックあたりの計算コストが増加するためと考えられるが，この差は DDLA との差に比べて軽微であり，提案手法は CA-SCA の高速性を維持しつつ攻撃性能を向上できたといえる．

5. まとめ

本稿では，非プロファイル型サイドチャネル攻撃である CA-SCA の課題点として指摘されていた「特徴抽出層が一意に定まらない」という問題に着目し，オートエンコーダ（AE）の潜在変数に分類器を付加した深層特徴抽出モデルを提案した．提案手法は，平文ラベルを用いた学習により潜在空間の構造を制御し，マスキング対策が施されたデータに対しても有効な特徴抽出を可能とする点に特徴がある．

ASCAD database を対象とした全バイト攻撃の評価では，抽出した特徴ベクトルに対してクラスタ解析を適用することで鍵候補を推定した．その結果，提案手法は既存の CA-SCA（AE，CNN）や CPA，DDLA と比較して推測エントロピー（GE）および攻撃成功確率（SR）の両指標において優れた性能を示し，特にマスキング対策が施された複数のサブバイトに対して高い攻撃性能を達成できることを確認した．また，計算時間の評価では，提案手法は DDLA と比較して大幅に短い計算時間で攻撃を完了できており，CA-SCA が持つモデル数削減による高速性を維持しながら，攻撃性能を向上できることを確認した．

以上の結果から，提案モデルを用いた CA-SCA は，従来手法では困難であったマスキング対策済み AES に対しても有効であり，非プロファイル型攻撃における新たな有力手法となり得ることを示した．深層学習技術を取り入れることで，サイドチャネル攻撃対策回路に対する脅威がさらに増大していることが示唆され，今後はより強固な耐性を持つ暗号実装の設計が求められる．

謝辞 本研究は JSPS 科研費 JP25K24380 の助成を受けたものである．関係各位に感謝いたします．

参考文献

[1] E. Brier, C. Clavier, and F. Olivier: “Correlation power analysis with a leakage model,” International Workshop on Cryptographic Hardware and Embedded Systems, Springer, 2004, pp. 16–29.
[2] S. Chari, J. R. Rao, and P. Rohatgi: “Template attacks,” International Workshop on Cryptographic Hardware and Embedded Systems, Springer, 2002, pp. 13–28.
[3] H. Maghrebi, T. Portigliatti, and E. Prouff: “Breaking cryptographic implementations using deep learning techniques,” International Conference on Security, Privacy and Applied Cryptography Engineering, Springer, 2016, pp. 3–26.
[4] B. Timon: “Non-profiled deep learning-based side-channel attacks with sensitivity analysis,” IACR Transactions on Cryptographic Hardware and Embedded Systems, pp. 107–131, 2019.
[5] T. G ¨ uneysu, and A. Moradi, “Generic Side-Channel Countermeasures for Reconfigurable Devices,” in Cryptographic Hardware and Embedded Systems CHES 2011- 13th International Workshop, Nara, Japan, September 28- October 1, 2011. Proceedings, ser. Lecture Notes in Computer Science, B. Preneel, and T. Takagi, Eds., vol. 6917. Springer, 2011, pp. 33–48. [Online].
[6] D. Kwon, S. Hong, and H. Kim, “Optimizing Implementations of Non-Profiled Deep Learning-Based Side-Channel Attacks,” IEEE Access, vol. 10, pp. 5957 5967, 2022. [Online].
[7] L. Wu, G. Perin, and S. Picek, “Hiding in Plain Sight: Non-profiling Deep Learning-based Side-channel Analysis with Plaintext/Ciphertext,” Cryptology ePrint Archive, Paper 2023/209, 2023, https://eprint.iacr.org/2023/209. [Online].
[8] Y. Fukuda, K. Yoshida, and T. Fujino: “CA-SCA: Non-Profiled Deep Learning-Based Side-Channel Attacks by Using Cluster Analysis,” in IEICE TRANSACTIONS on Fundamentals, vol. E108-A, no.3, pp. 227-241, March 2025, doi: 10.1587/transfun.2024CIP0014.
[9] G. E. Hinton and R. R. Salakhutdinov: “Reducing the Dimensionality of Data with Neural Networks,” Science, vol. 313, no. 5786, pp. 504–507, 2006.
[10] K. Fukushima, “Neocognitron: A self-organizing neural network model for a mechanism of pattern recognition unaffected by shift in position,” Biological cy bernetics, vol. 36, no. 4, pp. 193–202, 1980.
[11] R. Benadjila, E. Prouff, R. Strullu, E. Cagli, and C. Dumas: “Deep learning for side-channel analysis and introduction to ASCAD database,” Journal of Cryptographic Engineering, vol. 10, no. 2, pp. 163–188, 2020.
[12] K. Lemke, K. Schramm, and C. Paar, “DPA on n-Bit Sized Boolean and Arithmetic Operations and Its Application to IDEA, RC6, and the HMAC Construction,” in Cryptographic Hardware and Embedded Systems- CHES 2004, M. Joye, and J.-J. Quisquater, Eds. Berlin, Heidelberg: Springer Berlin Heidel berg, 2004, pp. 205–219.
[13] L. Zhang, X. Xing, J. Fan, Z. Wang, and S. Wang, “Multilabel Deep Learning-Based Side-Channel Attack,” IEEE Trans. Comput. Aided Des. Integr. Circuits Syst., vol. 40, no. 6, pp. 1207–1216, 2021. [Online].

© 2026 Information Processing Society of Japan