Android マルウェア検知器に対する拡散モデルを用いた回避攻撃手法

土屋 雄生[1,a)]　畑田 充弘[2]　吉浦 裕[1]　市野 将嗣[1]

概要：機械学習を用いた Android マルウェア検知器に対し，マルウェアに特徴量を追加して検知を回避する回避攻撃は深刻な脅威であり，これまでに様々な攻撃手法が提案されている．しかし，多数の特徴量を追加すると，生成された敵対的サンプルに存在する特徴量の総数である有効特徴量数が良性検体の有効特徴量数分布から外れる可能性がある．そのため，追加特徴量数を抑えながら高い攻撃成功率を実現することが求められる．本研究では，拡散モデルを用いて良性検体の特徴量分布を学習し，攻撃対象の検知器を模倣する Discriminator の出力に基づく Adversarial Guidance を導入することで，Android マルウェア検知器に対する新たな回避攻撃手法を提案する．既存手法との比較実験において，提案手法は良性検体にみられる有効特徴量数の範囲において高い攻撃成功率を示した．また，提案手法によって生成された AE が他の検知器に対しても転移することを確認した．

キーワード：回避攻撃，Adversarial Example，拡散モデル，Adversarial Guidance

A Diffusion Model-Based Evasion Attack Method against Android Malware Detectors

YUSEI TSUCHIYA[1,a)]　MITSUHIRO HATADA[2]　HIROSHI YOSHIURA[1]
MASATSUGU ICHINO[1]

Abstract: Machine-learning-based Android malware detectors are vulnerable to evasion attacks that add features to malware samples to evade detection, and various evasion attack methods have been proposed. However, adding many features may cause the active feature count in generated adversarial examples (AEs) to deviate from the distribution of active feature counts in benign samples. Therefore, it is important to achieve a high attack success rate with fewer added features. In this study, we propose a new evasion attack method against Android malware detectors. The proposed method learns the feature distribution of benign samples using a diffusion model and applies Adversarial Guidance based on the output of a Discriminator that mimics the target detector. In comparative experiments with existing methods, the proposed method achieved a high attack success rate within the range of active feature counts observed in benign samples. We also confirmed that the generated AEs transferred to other detectors.

Keywords: Evasion Attack，Adversarial Example，Diffusion Model，Adversarial Guidance

1. はじめに

近年，Android はスマートフォンだけでなく，スマート TV など様々な機器で利用されており，Android 端末を標的とするマルウェアを用いた攻撃は大きな脅威となっている．AV-TEST によると，2021 年から 2025 年の間で約 940 万の Android マルウェアが新たに発見されている [1].

マルウェアを検知するため，従来のシグネチャベースの検知に加えて，未知のマルウェアの検知を目的とした機

[1] 電気通信大学
The University of Electro-Communications
[2] NTT ドコモビジネス株式会社
NTT DOCOMO BUSINESS, Inc.
[a)] yusei-tsuchiya@uec.ac.jp

© 2026 Information Processing Society of Japan

This paper is work in progress and not peer-reviewed.

械学習を用いたマルウェア検知が広く研究されている [2]. 機械学習を用いた検知手法では，アプリケーションから特徴量を抽出し，良性検体とマルウェアを分類する [3], [4]. しかし，機械学習モデルに対しては，入力に変更を加えることで誤分類を引き起こす回避攻撃が知られている．このとき，変更を加えることによって生成された入力を Adversarial Example（AE）と呼ぶ．回避攻撃は画像分野において Goodfellow ら [5] によって示され，その後，マルウェア検知の分野においても多くの攻撃手法が提案されている [6].

マルウェアに対する回避攻撃では，AE の生成後も元のマルウェアの機能を保持する必要があるため，既存の特徴量の削除を行わず，特徴量の追加によって検知を回避する手法が多く用いられている．また，マルウェアへの特徴量の追加を抑えることの重要性が既存研究において指摘されている [7], [8]．多数の特徴量を追加した場合，生成された AE の存在する特徴量の総数である有効特徴量数が良性検体の有効特徴量数分布から外れてしまう．その場合，有効特徴量数の違いが，AE を識別する手掛かりとなる可能性がある．したがって，AE の有効特徴量数を良性検体にみられる範囲に抑えながら，高い攻撃成功率を達成する回避攻撃手法が必要である．

本研究では Black-box 攻撃を想定する．攻撃者は攻撃対象のモデル（Target Model）の内部構造，学習パラメータおよび勾配情報にはアクセスできず，入力に対する出力ラベルのみを取得できるものとする．

このような Black-box の条件に対応するため，本研究では，Android の良性検体の特徴量分布を学習する拡散モデルを用いた攻撃手法 AdvMalDiffusion（Adversarial Malware Diffusion）を提案する．

また，新たな回避攻撃の手法を提案することは防御手法を検討する上でも重要である．本研究の提案手法および得られた知見は，マルウェア検知器の頑健性の向上といった防御手法に活用できると考えられる．

本研究の主な貢献は以下の通りである．

- Android マルウェアの DREBIN 特徴量を対象として，D3PM，Adversarial Guidance，SDEdit，および Target Model の判定を模倣する Discriminator を用いることで，追加特徴量数を抑えながら高い攻撃成功率を達成する Black-box 攻撃手法を提案する．
- 生成された AE の有効特徴量数に着目し，良性検体の有効特徴量数分布を基準として既存手法と比較した結果，良性検体にみられる有効特徴量数の範囲においても，AdvMalDiffusion が既存手法より高い攻撃成功率を示した．また，生成した AE が他の検知器に対しても攻撃に成功することを確認した．

2. 関連研究

2.1 既存の回避攻撃

マルウェア検知器に対する回避攻撃として，生成モデルである GAN を用いる攻撃手法や，勾配を利用せずに AE を生成する攻撃手法などが提案されている．本研究では，これらの手法を比較対象とする．

2.1.1 GAN ベースの回避攻撃

Hu ら [9] は，攻撃対象のマルウェア検知モデルから出力ラベルのみしか得られないという Black-box の設定のもと MalGAN という GAN を使った手法を提案した．MalGAN は，マルウェア特徴量とランダムノイズを Generator に入力し，攻撃対象モデルを模倣する Substitute Detector の出力に基づいて AE を生成する手法である．実験では，複数の検知器に対して 100%の攻撃成功率を達成している．

Wang ら [10] は，MalGAN は，学習が不安定である点を指摘し Mal-LSGAN を提案した．Mal-LSGAN は，LSGAN[11] の損失関数を利用することで，GAN の敵対的学習の安定化を目的とした回避攻撃手法である．Hariom ら [8] は，MalGAN では追加特徴量数が制約されていない点を指摘し，MEGAN-RP を提案した．MEGAN-RP は，追加特徴量数を考慮した損失関数を用いることで，特徴量の追加を抑制する GAN ベースの回避攻撃手法である．実験では，MalGAN と比較して特徴量の追加を抑えながら，多くの Black-box 検知器に対して高い回避性能を示した．

2.1.2 勾配を用いない回避攻撃

Demontis ら [12] は，攻撃対象モデルの勾配を利用せず，マルウェアの特徴量を良性検体の特徴量分布に近づける Mimicry Attack を用いて Android マルウェア検知器に対する回避攻撃を評価した．Mimicry Attack では，良性検体に多く含まれる特徴量を追加し，マルウェアに多く含まれる特徴量を削除することで，マルウェアの特徴量分布を良性検体の分布に近づける．Li ら [13] は，画像分野で用いられていた Salt-and-Pepper Attack[14] を Android マルウェアの回避攻撃に適用した．Salt-and-Pepper Attack は，特徴量をランダムに変更しながら攻撃対象モデルへ問い合わせ，誤分類を引き起こす AE を探索する勾配を用いない攻撃手法である．

2.2 拡散モデル

拡散モデルは，データを段階的に変化させる順過程と，その状態からデータを復元する逆過程によってサンプルを生成する生成モデルである．

Ho ら [15] は，連続値空間上でガウスノイズを段階的に加える順過程と，そのノイズを除去してデータを生成する逆過程から構成される Denoising Diffusion Probabilistic Model（DDPM）を提案した．DDPM では，逆過程をニューラル

© 2026 Information Processing Society of Japan

ネットワークによって学習し，順過程で加えたノイズを推定しながらノイズを除去してデータを生成する．

Austin ら [16] は，離散データに対して拡散モデルを適用する Discrete Denoising Diffusion Probabilistic Model（D3PM）を提案した．D3PM では，DDPM のように連続値空間でガウスノイズを加えるのではなく，離散状態間の遷移確率を表す遷移行列を用いて順過程を定義する．これにより，離散データを離散値のまま扱うことができる．

Meng ら [17] は，拡散モデルの生成過程を利用して入力データを編集する Stochastic Differential Editing（SDEdit）を提案した．SDEdit では，入力データに途中のステップまで順過程を適用し，その状態から逆過程を開始することで，元の入力の特徴を保持しながら学習データ分布に基づいたサンプルを生成する．また，逆過程を開始するステップによって，元の入力をどの程度保持するかを調整できる．

2.3 拡散モデルを用いた回避攻撃

Chen ら [18] は，画像分野において拡散モデルを用いて AE を生成する AdvDiffuser を提案した．AdvDiffuser では，逆拡散の各ステップで得られたサンプルに対して攻撃対象分類器の損失に基づく PGD を適用することで，誤分類を引き起こすように生成を誘導する．

Dai ら [19] は，逆拡散過程に Adversarial Guidance を導入する AdvDiff を提案した．AdvDiff では，逆過程の各ステップにおいて，攻撃対象の分類器が生成サンプルを誤分類させたいクラスと判定する確率が高くなるように生成を誘導する．

Mahmoud ら [20] は，Windows PE マルウェアを対象として，攻撃対象モデルへの問い合わせを必要としない拡散モデルを用いた AE 生成手法を提案した．API Imports および ASCII Strings を特徴量に用いた場合には，GAN ベースの手法より高い回避性能を示した．

2.4 既存のマルウェア回避攻撃の問題点

既存のマルウェア回避攻撃では，MalGAN[9] や MalLSGAN[10] は，追加特徴量数を抑制する仕組みを持たない．MEGAN-RP[8] では特徴量の追加を抑制しているが，Mimicry Attack，Salt-and-Pepper Attack，および Windows マルウェアを対象とした拡散モデルによる回避攻撃手法 [20] を含め，生成された AE の有効特徴量数について，良性検体の有効特徴量数分布を基準とした評価は行われていない．さらに，Android マルウェアを対象として拡散モデルを用いた回避攻撃手法は，調査した限り確認できなかった．

3. 提案手法

3.1 問題設定

本研究では，Android アプリから抽出した特徴量の有無を表す 0 と 1 からなる DREBIN 特徴量を用いて，良性検体とマルウェアを分類する Target Model を攻撃対象とする．また，Target Model の内部構造，モデルのパラメータおよび勾配を取得できない Black-box 環境を想定する．Target Model から取得できる情報は，入力に対する出力ラベル（良性：0，マルウェア：1）のみとする．また，マルウェアの機能保持のため，$0 \rightarrow 1$ の特徴量の追加のみを許可する．本研究の目的は，これらの条件のもとで，Target Model に良性と誤分類される AE を生成することである．

3.2 提案手法の概要

2.4 で述べた先行研究の問題点を踏まえ，本研究では，Android マルウェアの DREBIN 特徴量を対象とした，拡散モデルを用いた Black-box 回避攻撃手法である AdvMalDiffusion を提案する．

提案手法のポイントは以下の通りである．

- D3PM を用いて良性検体の特徴量分布を学習し, Adversarial Guidance を組み合わせることで，Target Model によって良性と判定されるために有効な特徴量を追加する．
- SDEdit の考え方を利用し，元のマルウェアに途中のステップまで順過程を適用した状態を逆過程の入力とすることで，マルウェアを入力とした AE 生成を可能にするとともに，追加特徴量数を抑える．
- Target Model の出力ラベルを用いてその判定を模倣する Discriminator を学習し，その勾配を Adversarial Guidance に利用することで，Target Model の内部情報や勾配を用いない Black-box 攻撃を可能にする．

提案手法の概要を図 1 に示す．

提案手法は, D3PM の学習, SDEdit による入力生成, Adversarial Guidance による AE 生成, Discriminator の学習, から構成される．まず，良性検体のみを用いて D3PM[16] を学習する．また，良性検体およびマルウェア検体を Target Model へ入力し，得られた出力ラベルを用いて Target Model の判定を模倣する Discriminator を学習する．

AE 生成時には，SDEdit[17] の考え方に基づき，攻撃対象のマルウェアの特徴ベクトルに途中のステップまで順過程を適用し，その状態から逆過程を開始する．逆過程では，AdvDiff[19] を参考に，Discriminator の出力に基づく Adversarial Guidance を適用し，Target Model に良性と判定されるよう生成を誘導する．

3.3 良性検体の特徴量分布を利用した AE 生成

3.3.1 D3PM による特徴量分布の学習

D3PM の学習には，良性検体から抽出した d 次元の二値特徴ベクトル $\boldsymbol{x}_0 \in \{0,1\}^d$ を用いる．D3PM の順過程では，ステップ t における遷移行列 Q_t を用いて，$\boldsymbol{x}_{t-1}$ から $\boldsymbol{x}_t$ へ各特徴量の値を確率的に変化させる．

© 2026 Information Processing Society of Japan

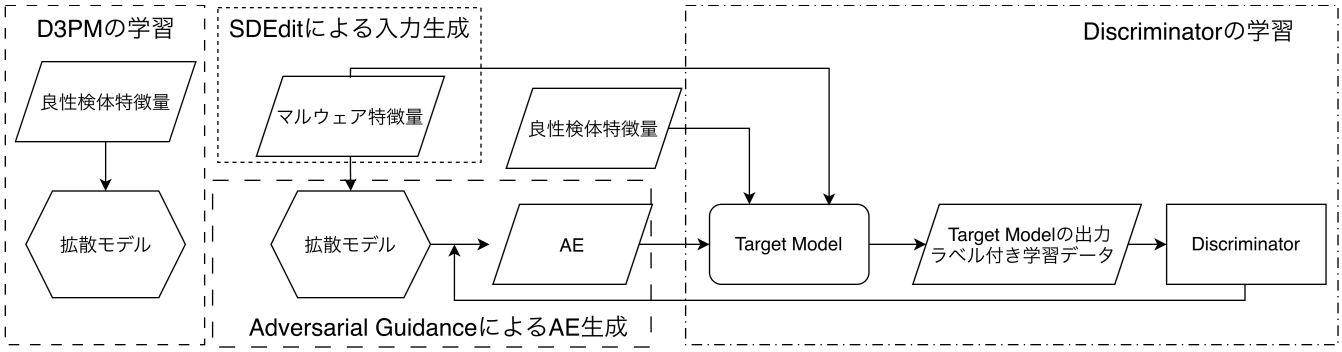


図 1 提案手法の概要
Fig. 1 Overview of the proposed method

$$Q_t = \begin{pmatrix} 1-\beta_t & 0 \\ \beta_t & 1 \end{pmatrix}. \tag{1}$$

ここで，β_t はステップ t における状態遷移の確率を制御するパラメータである．各特徴量について，値が 0 の場合は確率 $1-\beta_t$ で 0 のまま残り，確率 β_t で 1 へ変化する．一方，値が 1 の特徴量は 1 のまま保持される．したがって，順過程では特徴量の追加に相当する $0 \to 1$ の遷移のみが発生し，$1 \to 0$ の遷移は発生しない．

拡散ステップ数を T とし，β_t を次式で定義する．

$$\beta_t = \frac{1}{T-t+1}, \qquad t = 1, \ldots, T. \tag{2}$$

複数ステップの遷移は，各ステップの遷移行列の積 $\overline{Q}_t = Q_t Q_{t-1} \cdots Q_1$ によって表される．これにより，元の特徴ベクトル $\boldsymbol{x}_0$ から任意のステップ t における特徴ベクトル $\boldsymbol{x}_t$ を生成できる．

逆過程では，ニューラルネットワークを用いて $\boldsymbol{x}_t$ から元の特徴ベクトル $\boldsymbol{x}_0$ を推定する．その推定結果と順過程を用いて，$\boldsymbol{x}_t$ から $\boldsymbol{x}_{t-1}$ を生成するための分布 $p_\theta(\boldsymbol{x}_{t-1} \mid \boldsymbol{x}_t)$ を求める．

$t = 1$ では，元の特徴ベクトル $\boldsymbol{x}_0$ を復元する交差エントロピー損失を用いる．

$$\mathcal{L}_1 = -\sum_{j=1}^{d} \log p_\theta \left(x_{0,j} \mid \boldsymbol{x}_1 \right) \tag{3}$$

$t \geq 2$ では，真の事後分布とモデルが推定する逆過程の分布との KL ダイバージェンスを用いる．

$$\mathcal{L}_t = D_{\mathrm{KL}} \left(q(\boldsymbol{x}_{t-1} \mid \boldsymbol{x}_t, \boldsymbol{x}_0) \,\|\, p_\theta(\boldsymbol{x}_{t-1} \mid \boldsymbol{x}_t) \right). \tag{4}$$

以上の損失を最小化するように D3PM を学習する．

3.3.2 SDEdit による入力生成

通常の拡散モデルでは，ノイズの状態から逆過程を開始してサンプルを生成する．一方，本研究では，攻撃対象となるマルウェアの特徴を保持しながら AE を生成するため，SDEdit[17] の考え方を利用する．

攻撃対象のマルウェアの特徴ベクトル $\boldsymbol{x}$ に対して順過程をステップ s まで適用することで，ステップ s における特徴ベクトル $\boldsymbol{x}_s$ を生成する．その後，$\boldsymbol{x}_s$ を逆過程の初期状態として，ステップ 0 まで逆過程を適用する．

$$\boldsymbol{x}_s \sim q(\boldsymbol{x}_s \mid \boldsymbol{x}; \overline{Q}_s). \tag{5}$$

$$\boldsymbol{x}_{t-1} \sim p_\theta \left(\boldsymbol{x}_{t-1} \mid \boldsymbol{x}_t \right), \qquad t = s, \ldots, 1. \tag{6}$$

s が小さいほど，順過程によって 0 から 1 へ変更される特徴量が少ないため，$\boldsymbol{x}_s$ は元のマルウェアの特徴ベクトルに近くなる．一方，s を大きくすると，順過程による特徴量の追加が増加し，元のマルウェアの特徴ベクトルとの差が大きくなる．

3.3.3 Adversarial Guidance

D3PM の通常の逆過程は，学習した良性検体の特徴量分布に従ってサンプルを生成することを目的としている．そのため，通常の逆過程のみでは，生成されたサンプルが Target Model によって良性と判定されるとは限らない．

そこで本研究では，AdvDiff[19] における Adversarial Guidance の考え方を利用し，Target Model の判定を模倣する Discriminator の勾配を逆過程に利用する．

ステップ t の逆過程によって得られた特徴ベクトルを $\boldsymbol{x}_{t-1}$ とする．Discriminator を f_D，攻撃先ラベルである良性クラスを $y_a = 0$ とすると，Adversarial Guidance を適用した生成サンプル $\boldsymbol{x}^*_{t-1}$ は次式で表される．

$$\boldsymbol{x}^*_{t-1} = \boldsymbol{x}_{t-1} + \lambda_t \nabla_{\boldsymbol{x}_{t-1}} \log p_{f_D} \left(y_a \mid \boldsymbol{x}_{t-1} \right). \tag{7}$$

ここで，$p_{f_D}(y_a \mid \boldsymbol{x}_{t-1})$ は Discriminator が入力を良性クラスと判定する確率であり，λ_t はステップ t における Adversarial Guidance の強度を表す．

本研究では，λ_t をステップ t における累積遷移量に応じて次式で設定する．

$$\lambda_t = a \left(1 - \prod_{k=1}^{t} (1-\beta_k) \right), \tag{8}$$

ここで，a は Adversarial Guidance の強度を調整するハイパーパラメータである．

© 2026 Information Processing Society of Japan

実装では，勾配の大きさを正規化した後に Adversarial Guidance を適用し，得られた特徴ベクトルの各成分を $[0, 1]$ の範囲に制限する．さらに，元のマルウェアに存在する特徴量を保持するため，各ステップで生成サンプルと元のマルウェアの特徴ベクトルとの論理和をとる．

以上の処理により，D3PM が学習した良性検体の特徴量分布に基づく逆過程を利用しながら，Discriminator が良性と判定する確率が高くなるように生成を誘導する．

3.4 Discriminator の学習

本研究では，Black-box 環境において Target Model の判定を模倣する Discriminator を用いる．Target Model を f とする．Discriminator の学習では，良性検体およびマルウェア検体を Target Model に入力し，得られた出力ラベルを教師ラベルとして用いる．したがって，Target Model の内部構造，モデルパラメータおよび勾配は使用しない．

Discriminator を f_{D} とすると，学習損失には Binary Cross Entropy（BCE）を用いる．

$$\mathcal{L}_{\mathrm{D}} = \mathrm{BCE}\left(f_{\mathrm{D}}(\boldsymbol{x}), f(\boldsymbol{x})\right). \tag{9}$$

ここで，$f(\boldsymbol{x})$ は Target Model の出力ラベル，$f_{\mathrm{D}}(\boldsymbol{x})$ は Discriminator の出力を表す．

初期学習では，良性検体およびマルウェア検体に対して Target Model から取得した出力ラベルを用いて Discriminator を学習する．

その後，学習した Discriminator を用いて AE を生成し，生成した AE を Target Model へ入力して出力ラベルを取得する．得られた AE とその出力ラベルを初期学習データに加え，Discriminator を再学習する．

この処理を複数ラウンド繰り返すことで，Target Model の判定を Discriminator に学習させる．

4. 実験

4.1 データセット

4.1.1 データ収集

本研究では，AndroZoo[21] から取得した Android アプリケーションを用いる．対象期間は 2022 年 1 月から 2025 年 6 月までとした．

マルウェアおよび良性検体のラベル付けには，VirusTotal の検知結果を用いた．4 個以上のアンチウイルスエンジンが悪性と判定した検体をマルウェアとし，悪性と判定したエンジンが 0 個の検体を良性検体とした．これらの条件を満たさない検体は実験対象データから除外した．

4.1.2 特徴量

各 APK から静的特徴量である DREBIN 特徴量を抽出した．DREBIN 特徴量には，要求パーミッション，使用パーミッション，API 呼び出し，Intent Filter，ハードウェアコンポーネント，ネットワークアドレスなどが含まれる．

表 1 データセットの構成
Table 1 Dataset configuration

データセット	期間	マルウェア	良性
Target train	2022/01–2022/12	35,872	35,872
Target valid	2022/01–2022/12	8,968	8,968
Diffusion + Discriminator train	2022/01–2022/12	35,872	35,872
Diffusion + Discriminator valid	2022/01–2022/12	8,968	8,968
Target test	2023/01–2025/06	10,580	95,220

抽出した特徴量について，学習データにおける出現頻度が高い上位 5000 個の特徴量を選択し，5000 次元の二値ベクトルへ変換した．各特徴量は，対象 APK に含まれる場合を 1，含まれない場合を 0 とした．このとき，値が 1 である特徴量を有効特徴量と呼ぶ．

4.1.3 データ分割

データセットの分割は，Kan ら [22] の提言を参考に，検体の日時情報に基づいてデータを分割した．2022 年の検体を学習および検証に，2023 年 1 月以降の検体をテストに用いた．2022 年のデータは，Target Model 用と Diffusion および Discriminator 用に分割し，両者で同一の検体が重複しないようにした．各データでは学習用と検証用を 8 : 2，マルウェアと良性検体を 1 : 1 とした．テストデータは，マルウェアと良性検体の比率を 1 : 9 とした．また，攻撃評価には，Target Model が正しくマルウェアと判定した検体のみを用いた．

4.2 Target Model

攻撃対象となる Target Model には，DNN を使用した．ネットワーク構成は $5000 \to 1024 \to 512 \to 256 \to 1$ とし，各隠れ層の活性化関数には LeakyReLU を用いた．Dropout 率は 0.5 とし，表 1 の Target train を用いて学習し，Target valid を用いてハイパーパラメータを調整した．学習エポック数は 50，バッチサイズは 1024，学習率は 0.001 とした．

最終的な性能評価には Target test を用いた．攻撃対象には，Target test に含まれるマルウェアのうち，Target Model が正しくマルウェアと判定した検体のみを用いた．

4.3 提案手法の実験設定

D3PM の学習には，表 1 に示す Diffusion + Discriminator train のうち，良性検体のみを使用した．拡散ステップ数は $T = 100$ とした．D3PM の逆過程を構成するニューラルネットワークには Transformer の decoder の部分のみを用いた．Transformer の decoder は 2 層とし，特徴量埋め込みおよびステップ埋め込みの次元数を 128，Query，Key，Value の次元数を 128，Feed Forward Network の中間次元数を 512 とした．Multi-Head Attention の head 数は

© 2026 Information Processing Society of Japan

4，活性化関数は GELU とし，絶対位置埋め込みを用いた．D3PM の最適化には Adam を用いた．学習率は 0.0002 とした．バッチサイズは 1，学習ステップ数は 40000 とした．

AE 生成では，SDEdit の開始ステップを $s = 3$，Adversarial Guidance の強度を調整するパラメータを $a = 93$ とした．また，AE 生成時に追加特徴量数の上限は設定していない．

Discriminator には，5000 次元の特徴ベクトルを入力とする DNN を用いた．ネットワーク構成は $5000 \to 1024 \to 512 \to 1$ とした．各隠れ層の活性化関数には LeakyReLU を用い，Dropout 率を 0.5 とした．Discriminator の最適化には Adam を用い，学習率を 0.001，バッチサイズを 256，学習エポック数を 50 とした．Discriminator は初期学習後に 5 回更新した．最終的な AE 生成には，5 回目の更新後の Discriminator を用いた．

4.4 比較手法

提案手法の有効性を評価するため，MalGAN[9]，Mal-LSGAN[10]，MEGAN-RP[8]，Mimicry Attack[13]，Salt-and-Pepper Attack[13] と比較する．

これらは，GAN を用いる手法，良性検体の特徴量を利用する手法，ランダムに特徴量を変更する手法など，異なる方法で AE を生成する既存手法である．これらと比較することで，AdvMalDiffusion の攻撃性能を評価する．

4.5 評価指標

4.5.1 AE の有効特徴量数と攻撃成功率

各手法によって生成された AE について，有効特徴量数と攻撃成功率の関係を評価する．

攻撃対象となるマルウェア数を N とする．また，生成された AE のうち，有効特徴量数が k 以下であり，かつ Target Model に対する攻撃に成功した AE の数を $N_{\text{success}}(k)$ とする．このとき，有効特徴量数 k 以下における攻撃成功率 $\text{ASR}(k)$ を次式で定義する．

$$\text{ASR}(k) = \frac{N_{\text{success}}(k)}{N} \times 100. \qquad (10)$$

本実験では，追加特徴量数に上限を設定せずに AE を生成し，生成後の AE について $\text{ASR}(k)$ を評価する．

5. 実験結果

5.1 Target Model の検知性能

Target Model のテストデータに対する検知性能を表 2 に示す．Target test に含まれるマルウェア 10,580 件のうち，8,692 件が Target Model によって正しくマルウェアと判定された．本実験では，これら 8,692 件を攻撃対象とした．

5.2 AE の有効特徴量数と攻撃成功率

各攻撃手法によって生成された AE について，有効特徴量数が k 以下で攻撃に成功した割合 $\text{ASR}(k)$ を図 2 に示す．図より，各手法で k の増加に伴って $\text{ASR}(k)$ が上昇する傾向が確認できる．AdvMalDiffusion と Mimicry Attack は，比較的小さい k から $\text{ASR}(k)$ が増加している．一方，MEGAN-RP，Mal-LSGAN，MalGAN は，より大きい k で $\text{ASR}(k)$ が増加している．Salt-and-Pepper Attack は，小さい k から $\text{ASR}(k)$ が増加するものの，k が大きくなってもその増加は小さい．

良性検体にみられる有効特徴量数の範囲で攻撃性能を比較するため，75%分位点および 95%分位点を用いる．これらは良性検体の大部分を含み，極端に多い有効特徴量数をもつ良性検体の影響を受けにくい範囲である．良性検体の有効特徴量数の 75%分位点は $k = 294$，95%分位点は $k = 505$ であった．各評価点における $\text{ASR}(k)$ を表 3 に示す．表 3 より，75%分位点である $k = 294$ において，提案手法は 88.4%の攻撃成功率を示した．これは比較手法の中で最も高く，次に高い Mimicry Attack の 62.3%を 26.1%上回った．また，MalGAN，MEGAN-RP および Mal-LSGAN では，$k = 294$ 以下で攻撃に成功した AE は存在しなかった．

95%分位点である $k = 505$ においても，AdvMalDiffusion は 94.3%と最も高い攻撃成功率を示した．次に高い Mimicry Attack は 68.6%であり，AdvMalDiffusion は 25.7%上回った．

以上より，AdvMalDiffusion は良性検体の 75%および 95%が含まれる有効特徴量数以下の範囲において，比較手法より高い攻撃成功率を示した．

表 2 Target Model の検知性能
Table 2 Detection performance of the Target Model

Model	Accuracy (%)	Precision (%)	Recall (%)
Target Model	97.57	92.75	82.16

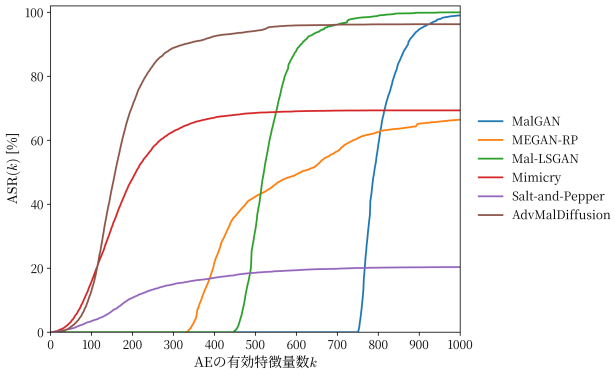


図 2 AE の有効特徴量数と攻撃成功率の関係
Fig. 2 Active feature count and attack success rate

6. 考察

6.1 既存手法との比較

得られた結果から，良性検体にみられる有効特徴量数の

© 2026 Information Processing Society of Japan

表 3　良性検体の有効特徴量数の分位点を基準とした攻撃成功率
Table 3　Attack success rates by benign active feature count percentiles

Method	ASR(294) [%]	ASR(505) [%]
MalGAN	0.0	0.0
MEGAN-RP	0.0	42.8
Mal-LSGAN	0.0	36.9
Mimicry	62.3	68.6
Salt-and-Pepper	14.8	18.7
AdvMalDiffusion	**88.4**	**94.3**

範囲において，提案手法が特徴量の追加を抑えながら高い攻撃成功率を達成できた理由を考察する．

提案手法では，良性検体で学習した D3PM と Adversarial Guidance により，良性と判定されるために有効な特徴量を生成過程に反映する．また，SDEdit により，元のマルウェアに途中のステップまで順過程を適用した状態から逆過程を開始することで，元の特徴ベクトルからの変化を抑えている．これらを組み合わせることで，追加特徴量数を抑えながら，高い攻撃成功率を得られたと考えられる．

一方，MalGAN および Mal-LSGAN では，追加特徴量数を抑制する仕組みを持たないため，検知回避のために多くの特徴量が追加され，有効特徴量数の大きい AE が生成されたと考えられる．

MEGAN-RP では追加特徴量数を抑制することで，検知回避に有効な特徴量を十分に選択できず，有効特徴量数が小さい範囲では攻撃成功率が低くなった可能性がある．

Mimicry Attack および Salt-and-Pepper Attack は，いずれも Target Model の判定に関する勾配情報を利用せずに特徴量を変更する攻撃手法である．Mimicry Attack は良性検体に多く含まれる特徴量を利用し，Salt-and-Pepper Attack は特徴量をランダムに変更するため，Target Model の判定を考慮して，検知回避に有効な特徴量を追加することが難しい．このことが，AdvMalDiffusion との攻撃成功率の差につながったと考えられる．

6.2　生成した AE の転移性

転移性とは，ある検知器に対して攻撃に成功した AE が，別の検知器に対しても攻撃に成功する性質である．転移性が高い場合，複数の検知器に対して攻撃が成功する可能性が高まるため，より大きな脅威となる．

転移性の評価には，Target Model と同じ学習データで学習した Random Forest（RF），Decision Tree（DT），Linear Support Vector Machine（Linear SVM）を用いた．各検知器の検知性能を表 4 に示す．有効特徴量数が良性検体の 95%分位点である 505 以下で，Target Model への攻撃に成功した AE を各検知器に入力し，3 検知器すべてに対して攻撃に成功した AE の数を比較した．結果を表 5 に示す．

AdvMalDiffusion では，有効特徴量数が 505 以下で Target Model への攻撃に成功した 8,193 件の AE のうち，3,513 件が RF，DT，Linear SVM のすべてに対しても攻撃に成功し，比較手法の中で最も多かった．

D3PM が良性検体の特徴量分布を学習することで，良性検体に共通してみられる特徴量が追加されやすくなり，それらの特徴量が複数の検知器において良性判定に寄与し，他の検知器への転移につながったと考えられる．

表 4　転移性評価に用いる検知器の検知性能
Table 4　Detector performance for transferability evaluation

Model	Accuracy (%)	Precision (%)	Recall (%)
RF	97.36	93.37	79.20
DT	96.58	83.42	82.16
Linear SVM	97.21	92.33	78.66

表 5　生成した AE の転移性
Table 5　Transferability of generated AEs

Method	Target 成功 AE 数	3 検知器同時成功数
MalGAN	0	0
MEGAN-RP	3,718	48
Mal-LSGAN	3,205	1,508
Mimicry	5,960	717
Salt-and-Pepper	1,622	77
AdvMalDiffusion	8,193	**3,513**

表 6　生成した AE の非重複率
Table 6　Non-duplicate rate of generated AEs

Method	AE 数	非重複 AE 数	非重複率 [%]
MalGAN	0	0	–
MEGAN-RP	3,718	3,439	92.50
Mal-LSGAN	3,205	2,085	65.06
Mimicry	5,960	5,960	100
Salt-and-Pepper	1,622	1,622	100
AdvMalDiffusion	8,193	8,193	100

6.3　生成した AE の多様性

異なるマルウェアから同一の AE が繰り返し生成される場合，Adversarial Training によってその特徴パターンを学習され，検知されやすくなる可能性がある．したがって，マルウェアごとに異なる AE が生成されることが望ましい．そこで，生成した AE の多様性についても評価する．多様性の評価では，有効特徴量数が良性検体の有効特徴量数の 95%分位点である 505 以下で，Target Model への攻撃に成功した AE について，重複していない AE の割合を示す非重複率を比較した．結果を表 6 に示す．

MEGAN-RP および Mal-LSGAN では，生成された AE に重複がみられ，非重複率はそれぞれ 92.50%，65.06%であった．一方，AdvMalDiffusion では，8,193 件すべてが異なる AE となり，非重複率は 100%であった．

GAN を用いた手法では，学習した特徴量分布が一部の

© 2026 Information Processing Society of Japan

特徴量パターンに偏り，同一の AE が生成された可能性がある．AdvMalDiffusion では，D3PM によって良性検体の幅広い特徴量分布を学習できているため，多様な特徴量の組合せを持つ AE が生成されたと考えられる．

7. 制約

本研究では特徴量空間上で AE を生成しており，生成された特徴ベクトルを実際の APK へ反映する処理までは行っていない．そのため，生成された AE を実際の Android アプリへ反映できるか，また，反映後も元のマルウェアの機能が維持されるかについては今後検証する必要がある．

8. おわりに

本研究では，Android マルウェアの DREBIN 特徴量を対象として，D3PM，Adversarial Guidance，SDEdit を用いた Black-box 回避攻撃手法である AdvMalDiffusion を提案した．実験の結果，提案手法は良性検体にみられる有効特徴量数の範囲において，既存手法より高い攻撃成功率を示した．特に，良性検体の有効特徴量数の 75%分位点および 95%分位点においても，高い攻撃成功率を示すことを確認した．

今後は，生成した AE を学習データに追加して再学習する Adversarial Training を適用し，検知器の頑健性および提案手法の攻撃性能を評価する．

参考文献

[1] AV-TEST: AV-ATLAS Malware Statistics, available from https://portal.av-atlas.org/malware/statistics (accessed 2026-08-11).

[2] Dahiya, A., Singh, S. and Shrivastava, G.: Android Malware Analysis and Detection: A Systematic Review, Expert Systems, Vol.42, No.1, e13488 (2025). doi:10.1111/exsy.13488.

[3] Arp, D., Spreitzenbarth, M., Hübner, M., Gascon, H. and Rieck, K.: DREBIN: Effective and Explainable Detection of Android Malware in Your Pocket, Proc. Network and Distributed System Security Symposium (NDSS) (2014).

[4] Mariconti, E., Onwuzurike, L., Andriotis, P., De Cristofaro, E., Ross, G. and Stringhini, G.: MaMaDroid: Detecting Android Malware by Building Markov Chains of Behavioral Models, arXiv preprint arXiv:1612.04433 (2016).

[5] Goodfellow, I. J., Shlens, J. and Szegedy, C.: Explaining and Harnessing Adversarial Examples, arXiv preprint arXiv:1412.6572 (2015).

[6] Aryal, K., Gupta, M., Abdelsalam, M., Kunwar, P. and Thuraisingham, B.: A Survey on Adversarial Attacks for Malware Analysis, IEEE Access, Vol.13, pp.428–459 (2025). doi:10.1109/ACCESS.2024.3519524.

[7] Grosse, K., Papernot, N., Manoharan, P., Backes, M. and McDaniel, P.: Adversarial Examples for Malware Detection, Proc. Computer Security – ESORICS 2017, pp.62–79 (2017).

[8] Hariom, Handa, A., Kumar, N. and Shukla, S. K.: Adversaries Strike Hard: Adversarial Attacks Against Malware Classifiers Using Dynamic API Calls as Features, Proc. International Conference on Applied Cryptography and Network Security, pp.20–37 (2021).

[9] Hu, W. and Tan, Y.: Generating Adversarial Malware Examples for Black-Box Attacks Based on GAN, arXiv preprint arXiv:1702.05983 (2017).

[10] Wang, J., Chang, X., Mišić, J., Mišić, V. B., Wang, Y. and Zhang, J.: Mal-LSGAN: An Effective Adversarial Malware Example Generation Model, Proc. 2021 IEEE Global Communications Conference (GLOBECOM), pp.1–6 (2021).

[11] Mao, X., Li, Q., Xie, H., Lau, R. Y. K., Wang, Z. and Smolley, S. P.: Least Squares Generative Adversarial Networks, arXiv preprint arXiv:1611.04076 (2017).

[12] A. Demontis, M. Melis, B. Biggio, D. Maiorca, D. Arp, K. Rieck, I. Corona, G. Giacinto, and F. Roli, Yes, Machine Learning Can Be More Secure! A Case Study on Android Malware Detection, IEEE Transactions on Dependable and Secure Computing, vol. 16, no. 4, pp. 711–724, 2019.

[13] Li, D. and Li, Q.: Adversarial Deep Ensemble: Evasion Attacks and Defenses for Malware Detection, IEEE Transactions on Information Forensics and Security, Vol.15, pp.3886–3900 (2020).

[14] L. Schott, J. Rauber, M. Bethge, and W. Brendel, Towards the First Adversarially Robust Neural Network Model on MNIST, arXiv preprint arXiv:1805.09190, 2018.

[15] Ho, J., Jain, A. and Abbeel, P.: Denoising Diffusion Probabilistic Models, Advances in Neural Information Processing Systems, Vol.33, pp.6840–6851 (2020).

[16] Austin, J., Johnson, D. D., Ho, J., Tarlow, D. and van den Berg, R.: Structured Denoising Diffusion Models in Discrete State-Spaces, Advances in Neural Information Processing Systems, Vol.34, pp.17981–17993 (2021).

[17] Meng, C., He, Y., Song, Y., Song, J., Wu, J., Zhu, J.-Y. and Ermon, S.: SDEdit: Guided Image Synthesis and Editing with Stochastic Differential Equations, Proc. International Conference on Learning Representations (ICLR) (2022).

[18] X. Chen, X. Gao, J. Zhao, K. Ye, and C.-Z. Xu, AdvDiffuser: Natural Adversarial Example Synthesis with Diffusion Models, in Proc. 2023 IEEE/CVF International Conference on Computer Vision (ICCV), pp. 4539–4549, 2023.

[19] Dai, X., Liang, K. and Xiao, B.: AdvDiff: Generating Unrestricted Adversarial Examples using Diffusion Models, arXiv preprint arXiv:2307.12499 (2024).

[20] Mahmoud, H., Yasar, S., Khan, M. J., Mahmoud, M. N. and Alsharif, A.: Query-Free Adversarial Malware Generation Using Conditional Denoising Diffusion, Proc. 2026 IEEE 2nd International Conference on Secure IoT, Assured and Trusted Computing (SATC), pp.1–7 (2026).

[21] Allix, K., Bissyandé, T. F., Klein, J. and Le Traon, Y.: AndroZoo: Collecting Millions of Android Apps for the Research Community, Proc. 13th International Conference on Mining Software Repositories (MSR), pp.468–471 (2016).

[22] Kan, Z., McFadden, S., Arp, D., Pendlebury, F., Jordaney, R., Kinder, J., Pierazzi, F. and Cavallaro, L.: Tesseract: Eliminating Experimental Bias in Malware Classification across Space and Time (Extended Version), arXiv preprint arXiv:2402.01359 (2024).

© 2026 Information Processing Society of Japan

9. 研究倫理

本研究における倫理的側面について，提案手法の公開が社会に及ぼす影響と実験手順の適切性の観点から検討した．

本研究では，深層学習を用いた Android マルウェア検知器に対し，拡散モデルを利用して AE を生成する回避攻撃手法を提案した．回避攻撃の仕組みや検知器の弱点を明らかにすることは，Adversarial Example を使って再度学習する Adversarial Training などの回避攻撃に対する防御手法の開発につながる．したがって，本研究で得られた知見を公開することは，Android マルウェア検知技術の安全性向上に寄与する公益性を有すると考える．また，本研究では，公開されている機械学習ライブラリおよび先行研究に基づいて実装した検知器を攻撃対象としており，特定の商用アンチマルウェア製品や実際に運用されているサービスを対象としていない．このため，提案手法の公開が社会に直接与える影響は限定的であると考えられる．実験手順の適切性についても検討した．本研究で使用した良性検体およびマルウェア検体は，学術研究を目的として提供されている AndroZoo から適切な手続きに従って取得した．検体のラベル付けには VirusTotal の検知結果を用い，あらかじめ定めた基準に基づいて良性検体とマルウェアに分類した．また，本研究の回避攻撃は，APK そのものではなく静的解析によって抽出した二値特徴量を主な対象として実施した．検体の取得，特徴抽出および回避攻撃に関する全ての処理は，外部から隔離された研究環境で行っており，第三者の製品，サービスおよびネットワークに対して攻撃が行われることはない．

© 2026 Information Processing Society of Japan