PWS Cup 2026 の設計と出題意図：希少群は有用性と匿名性の両立のボトルネックか？

小野 元[1,2,a)]　小林 雅弥[3,b)]

概要：個人が特定されない形で健康医療データを二次利用する手立てとして，匿名加工や合成データ生成が期待されている．しかし希少な患者のデータは，研究上最も重要な情報を含む一方で，似た事例がほとんどなく最も特定されやすい．保護の側では，k-匿名性も差分プライバシーも保証の定義自体が希少なレコードの痕跡を薄めることを求め，合成データ生成も裾をならす．評価の側では有用性も匿名性も集団の平均で測るため，利用価値の減少と開示リスクの増加が同じ少数の患者に重なるかは測られていない．本稿は匿名化コンテスト PWS Cup 2026 の設計として，(1) 希少群の再現と全体の分析結論の一致を分けて測る有用性採点，(2) 二種の推論攻撃を偶然水準で較正する匿名性採点，(3) 両軸の弁別性の内部検証を行う．参照防御 32 種を 6 つの乱数種で評価した結果，想定した単一軸の二律背反は観測されず，律速する側面は匿名性と複数の有用性側面に分散した．課されるのは綱引きではなく，複数側面の同時達成の困難である．採点器とスターターキットは公開済みで，競技後にはデータ生成器と参照防御一式も公開し，本稿の検証を追試できる公開ベンチマークとして残す．

キーワード：匿名化コンテスト，合成データ，メンバーシップ推論攻撃，生存時間解析，プライバシー・有用性トレードオフ

Design and Intent of PWS Cup 2026: Are Rare Subgroups the Bottleneck to Achieving Both Utility and Anonymity?

Hajime Ono[1,2,a)]　Masaya Kobayashi[3,b)]

Abstract: Anonymization and synthetic data generation promise secondary use of health data without identifying anyone. Yet data from rare patients, though it holds the greatest research value, has few counterparts and is easiest to single out. k-anonymity and differential privacy by definition thin rare records' traces; generators smooth the tail; utility and anonymity are read off population averages, so whether lost analytic value and added disclosure risk fall on the same few patients goes unmeasured. We report the design of PWS Cup 2026: (1) utility scoring separating rare-subgroup preservation from population-level conclusions, (2) anonymity scoring combining two chance-calibrated inference attacks, (3) internal validation of both. Across 32 defenses and six seeds no single-axis trade-off appeared: the binding facet spread across anonymity and several utility facets. It demands not a tug-of-war but every facet at once. The scorer and starter kit are public; the generator and defense set follow the contest, leaving a reproducible benchmark.

Keywords: anonymization contest, synthetic data, membership inference attack, survival analysis, privacy-utility trade-off

[1] 金沢大学
Kanazawa University
[2] 情報・システム研究機構データサイエンス共同利用基盤施設
Research Organization of Information and Systems Joint Support-Center for Data Science Research
[3] セコム株式会社 IS 研究所
Intelligent Systems Laboratory, SECOM CO.,LTD.
[a)] hajime-ono@staff.kanazawa-u.ac.jp
[b)] kobayashi-masaya@secom.co.jp

© 2026 Information Processing Society of Japan

This paper is work in progress and not peer-reviewed.

1. はじめに

機微な健康医療データを，個人が特定されない形で二次利用するための手立てとして，匿名加工と合成データ生成が期待されている [16]．医療・健康データは二次解析の便益も開示の害もともに大きく，どこまで情報を残せるかが常に問われる．ただし，この問いの難しさはデータに含まれる全員に一様ではない．

困難が集中するのは，データの中に似た人がほとんどいない患者である．本稿が題材とする糖尿病を例にとる．若年・非肥満で代謝症候群を伴わないのに高血糖を示す非典型的な型のうち，単一遺伝子性の MODY（若年発症成人型糖尿病）は糖尿病全体の 1–5% を占めるにすぎない [7]．英国の遺伝子診断例からの推計では，その 8 割超が分子診断に至っておらず [12]，1 型あるいは 2 型と誤診されたまま管理されている患者が多いとされる [7]．見落とされた患者の自然史を記述することは，二次利用の主要な動機の一つである．ところが，多数派の分布から外れたデータは研究上重要な情報を含む一方で，そのデータに関する個人が特定されるリスクも増大する．合成データの保護効果を個人単位で評価した研究は，保護の程度が個人によって大きく異なること，とりわけまれな属性値を持つレコードや少数派に属するレコードは連結攻撃に対して脆弱なまま残ることを示した [15]．研究上重要な情報を持つ人々と，手厚く守らなければならない人々は，同じ少数である．

この事実に対して，既存の枠組みには二つの空白がある．一つ目は，形式的な保護の枠組みでは希少なレコードの痕跡を残すこと自体が難しい [9] ことである．k-匿名性は各レコードが少なくとも k 人と区別できない状態を，差分プライバシーは単一レコードの有無が出力分布をほとんど変えないことを，それぞれ安全性の条件として置く．これらを満たすには，一般化・抑圧やノイズ付与でデータを加工することになり，その影響は，まれな属性の組み合わせを持つレコードほど大きい．合成データ生成にも同じ限界がある．コホートデータの二次利用を対象に複数の生成器を評価した同研究 [9] は，k-匿名性などの基準を満たすまで事後匿名化を施すと外れ値が抑圧され，そこに希少な患者のレコードが含まれうることを，高い保護水準の限界として挙げている．あわせて，既に観測されている関係については解析結果を再現できる一方，複雑あるいはまれなパターンを扱う新規の探索的研究への適用では，それまで観測されていない統計的関係の忠実性が保証されないと結論している．

二つ目は評価方法の不均衡である．有用性は主として分布の類似度や下流タスクの予測精度で測られ [3], [6]，匿名性はコホート全体で集計した推論攻撃の成功度で測られてきた [15]．それらの研究では，プライバシー・有用性トレードオフの曲線は集団を単位とする量どうしの関係として描かれている．個体ごとの脆弱性が分布の裾に集中することは，匿名性の側では低偽陽性率域の真陽性率という形で標準的に扱われるようになった [4]．一方で有用性の側には同じ細かさの評価軸が無いため，利用価値の減少と開示リスクの増加が同じ少数の患者に集中しているのかは測られていない．

そこで本稿は，匿名化コンテスト PWS Cup 2026 の設計を通じて，次の二つを問う．RQ1（実証）: 利用価値の減少と開示リスクの増加は，同じ少数の患者の上で衝突するか．RQ2（設計）: この問いを，生成手法と正解を秘匿したまま多数の参加者が公平かつ再現可能に競える競技として定式化できるか．

PWS Cup はこの問いの検証に適した実験環境である．攻撃に基づく経験的な匿名性の評価は，試した攻撃に対する下界しか与えない．したがって評価値は攻撃手法の選択に依存し，ベンチマーク研究ではその選択を設計者が行う [15]．PWS Cup は 2015 年以来毎年開催され，表形式の個票から位置情報トレースまで年ごとに異なる題材を扱いながら，匿名化と攻撃を相互に課す形式を継続してきた [8], [10]．データの形式，有用性指標，匿名性指標は固定するが，匿名化手法と攻撃手法は参加者に委ね，自由な発想を促す．総当たりで各匿名化データは他の全チームから独立に攻撃を受け，攻撃側には強い攻撃を出す誘因が別のランキングとして与えられている．

本稿の貢献は次の三点である：**第一に，有用性を「希少群の再現」と「全体の分析結論の一致」に分けて測る採点を設計する（5 節）．** 前者は，外れ度で希少と判定される行の割合，希少群の検査値プロファイル，希少群の発症率，希少群の同時分布の一致を，それぞれ別の検出器で測り，その最小値をとる．後者は，9 つの共変量から糖尿病発症までの時間を説明する cause-specific Cox 比例ハザードモデルを元データと匿名化データのそれぞれに当て，9 係数すべてについて有意性の判定が一致するか・両方有意なら符号が一致するか・信頼区間が重なるかで寄与を決め，その平均と判別性能の再現度の最小値をとる．分布の類似度と予測忠実度を用いてきた既存コンテストに対し，我々の知る限り，生存時間解析の推定対象（estimand）の結論一致を有用性採点に据えたコンテストは本大会が初である．この着想自体は estimand ベースの再現性評価を提唱してきた研究 [5], [14] に由来しており，新しいのは評価法の発明ではなく，それを競技の採点器へ統合し，匿名性とのトレードオフ上で多数の参加者に競わせた点にある．

第二に，二種の推論攻撃を偶然に当たる水準で較正して匿名性を測る採点を設計する（6 節）． メンバーシップ推論については，攻撃者ごとに低偽陽性率域の真陽性率を測ってその平均をとり，正解ラベルを並べ替えて得た帰無分布の 95 パーセント点を差し引く．属性推論については，標

© 2026 Information Processing Society of Japan

的と 1 対 1 に対応づけた対照群を用意し，対照に対する的中を超えた分だけを数える．前者は「偶然の当たりを統計的に差し引く」，後者は「本人のデータを見なくても当たる分を差し引く」という違いはあるが，いずれも偶然水準を基準に置いて超過分だけを危険とみなす点で同型である．低偽陽性率域を見るという選択自体は既存の標準への追随であり [4]，本大会に固有なのは，多数の参加者が互いを攻撃する競技において，この量を妨害や参加者数の違いに対して安定させた点にある．

第三に，これら二軸が実際に弁別性をもつことを，運営開始前の内部検証によって確かめる（7 節）． 参照となる防御手法（以下，参照防御）32 種を 6 つの乱数種で評価し，各手法の得点を律速する側面がどこに現れるかを調べた．結果として，当初の見立てであった単一軸の二律背反は観測されず，律速する側面は匿名性と複数の有用性側面に分散した．課されるのは綱引きではなく，複数側面の同時達成の困難である．

2. 関連研究

2.1 匿名化・合成データを対象とするコンテスト

匿名化と攻撃を競わせるコンテストは複数の系統で発展してきた．日本の PWS Cup は 2015 年から継続し，表形式データの匿名加工と再識別を中心に，年ごとに課題を変えてきた [8], [10]．縦断的なデータを扱った回もあり，2016 年大会は履歴データの匿名加工を課題とした．米国では NIST が差分プライバシー合成データチャレンジ（2018–19）[3] と差分プライバシー時空間マップチャレンジ（2020–21）を実施し，後者は SDNist として整備された．これらは差分プライバシーの形式保証の下での合成データ生成を競い，有用性は主として周辺分布の一致（k-marginal 等）で測る．攻撃そのものを競う系統としては，サニタイズ手法にメンバーシップ推論を仕掛ける SNAKE Challenge[2]，拡散モデルによる合成表データへのメンバーシップ推論を競う MIDST Challenge[11] があり，後者は評価指標に TPR@10%FPR（偽陽性率 10% における真陽性率）を採用している．健康・臨床領域に近い例としては，集中治療の時系列データを対象に合成データ生成と再識別・メンバーシップ推論を競った Hide-and-Seek Privacy Challenge[6] がある．このほか，連合学習と秘匿技術を競う US–UK PETs Prize Challenges（2022–23）や，ゲノム解析を対象とする iDASH がある．

これらに共通するのは，有用性評価が分布の類似度あるいは下流タスクの予測性能にとどまってきた点である．臨床時系列を扱った Hide-and-Seek でさえ，生成側の資格判定は特徴量の予測・1 ステップ先予測・時系列分類という三つの予測課題で行われ，いずれも合成データで学習したモデルが実データで学習したモデルの一定割合の性能に達するかを問う形式であった [6]．すなわち評価されるのは予測の忠実度であり，生存時間解析のような二次解析の「結論」が再現するかは採点されていない．本大会はこの点に差分を置く．

2.2 コンテストの設計・分析を論文化する系譜

コンテストは，その設計そのものが独立した学術的貢献として論文化されてきた．最も近い先例は，PWS Cup 2019 の位置情報トレース匿名化コンテストの設計を報告した Murakami ら [10] である．同論文は，再識別のみでは保護の評価に不十分でありトレース推論という別の攻撃面を加える必要があること，複数攻撃の最悪ケースでプライバシーを集約すること，病院などの敏感な位置に重み付けを行うこと，有用性の要件を満たしたうえでプライバシーを競わせること，そして予備実験によって指標間の整合性を検証することを，設計上の貢献として提示した．本大会の設計は，この「多面評価・最悪ケース集約・敏感対象への重み付け・指標の事前検証」という流儀を直接に継承し，対象を位置情報から縦断的な健康データへ，採点の estimand を生存時間解析の結論一致へと拡張したものと位置づけられる．より古くは，PWS Cup の有用性と再識別リスクのトレードオフを定量化した初期の研究 [8] がこの系譜の源流にある．

2.3 合成データの有用性評価の方法論

合成データの有用性は，あらゆる解析に対する汎用的な近さ（general utility）と，特定の解析が導く結論の近さ（specific utility）に区別して論じられてきた [14]．前者の代表は pMSE（propensity score MSE）などの分布的な指標であり，後者は特定のモデルの係数や検定結果の一致で測られる．本大会の有用性採点は，この specific utility の考え方を生存時間解析へ具体化するものである．とりわけ，合成臨床データで生存時間解析の結論（ハザード比や生存曲線）が再現するかを評価するベンチマーク研究 [1], [5] は，estimand ベースの評価の直接の思想的源流である．ただしこれらはいずれもベンチマークであってコンテストではない．

2.4 メンバーシップ推論攻撃の評価標準

匿名化・合成データのプライバシーリスクは，メンバーシップ推論攻撃（MIA）[13] の成功度で測られることが多い．近年，平均精度や固定閾値での正解数による評価は不適切であり，低偽陽性率域での真陽性率（TPR@low-FPR）を見るべきだという標準的な批判が確立した [4]．合成データに対しても，MIA の評価枠組み [15] や，RMIA のような低コスト・高検出力の攻撃 [17] が提案されている．前述のとおり MIDST[11] も TPR@low-FPR を主指標に採っており，分野はこの評価軸へ収束しつつある．本大会の匿名性採点は，この標準に沿って低偽陽性率域の真陽性率に

© 2026 Information Processing Society of Japan

基づく形で定義する．

3. システムモデル

3.1 参加者・データ・攻撃者

本大会は $N = 30$ チームを上限とする総当たり戦である．事務局は全国を代表するひとつの母集団 A を合成し，そこから各チームのコホート B_i を切り出す．A そのものは配布しない．どのチームのコホートにも含まれない残りは背景データ A_{bg} として，全チームに同じものを配る．

競技は二つのフェーズからなる．加工フェーズでは，参加者は B_i から匿名化データ C_i を作って提出する．C_i の作り方には制約を置かない．$C_i = f_i(B_i)$ の f_i は，同一スキーマかつ $|C_i| = |B_i|$ を満たす任意の写像でよく，素朴な列摂動でも生成モデルによる合成でも受け付ける．攻撃フェーズでは全チームが総当たりで互いの C_i を攻撃する．攻撃者 j が使えるのは，各チームの C と，全チーム共通の A_{bg} と，自分自身のコホート B_j だけである．f_i も行の対応づけも開示しない．

3.2 コホートの構造 — 二つの攻撃面

各チームのコホートは，性質の異なる二種類の行からなる（**表 1**）．

非共有ブロック P_i は，そのチームにだけ配られ，他のどのチームとも共有しない行である．割り当てられた県の人口構成に従うので，チームごとの分布の違いをここが担う．属性推論攻撃（AIA）の標的はここから取る．

共有ブロック $S_{ij} = B_i \cap B_j$ は，チーム i と j が同一の個人を共有している行である．メンバーシップ推論攻撃（MIA）の標的はここである．全ペアが互いに素な共有ブロックを持つように，完全グラフの 1-因子分解でコホートを組み立てる．これにより，どのチームも同じ数の相手とほぼ同量ずつ重なり，重なりの合計は全チームで厳密に等しくなる．

この重なりを入れたことが設計上の要である．攻撃者は自分の B_j を候補プールとして持ち込み，「自分のコホートにいるこの人は，相手のコホートにもいるか」を問う．補助データを外から仮定して与えるのではなく，守りに使ったデータがそのまま攻めの材料になる．現実の対応物は，重複する登録データベース間のメンバーシップ開示である．

3.3 手続き的公平

配られたデータの差が順位を決めてしまうと，競技は成立しない．本大会は，公平さを結果ではなく手続きの側で担保し，かつその手続きを参加者自身で検証可能にした．

第一に，表 1 の数はすべてのチームで厳密に同一である．行数，非共有・共有の内訳，希少レコードの件数と型，さらにそのうち実際に発症した件数までそろえている．攻撃されたときの当てられやすさが，配られたレコードの内訳で変わらないようにするためである．希少レコードの外れ度（多数派の分布からのマハラノビス距離）も目標の帯に較正し，特定のチームだけ「守りにくい希少群」に偏らないようにしている．

表 1 コホートの諸元（全チームで厳密に同一）
Table 1 Cohort specification, identical across all teams.

項目	値
コホート数（＝参加上限）N	30
コホートの行数 $\lvert B_i \rvert$	1,049
非共有ブロック P_i	313
共有ブロックの合計	736（1 組あたり 25–27）
希少レコード	24（2.3%）
背景データ A_{bg}	5,143
AIA の標的／対照	163 ／ 163
追跡期間	最長 10 年
10 年以内の発症／死亡	約 1 割／ 7–8%

第二に，どのコホートをどのチームに配るかを，ハッシュで機械的に決める．チームごとに key = SHA-256(チーム名 ‖ salt) を計算し，key mod N をコホート番号とする（衝突時は空き番号まで進める）．salt は配布時まで伏せるので参加者は狙った番号を引けず，N とチーム名は事前に確定しているので事務局に事後的な変更はできない．salt のコミットメント（ハッシュ値）を事前に公式サイトへ掲示し，配布時に salt 本体を公表するので，参加者は自分の割当を検証可能である．

第三に，予備戦と本戦を独立のデータで実施する．データが独立なので，外れ値の差はラウンドをまたいで緩和される．合計の重みは予備戦 0.1・本戦 0.9 とし，予備戦は学習とリハーサル，本戦が本番という位置づけにしている．

3.4 開示の非対称

参加者に配るのは，A_{bg}，自分の B_i（および自己採点用に希少の判定などの真値列を足した拡張版），そして攻撃フェーズにおける全チームの C だけである．どの行が非共有でどの行が誰との共有かは開示しない．

一方で，世界の作り方そのものは開示する（4 節）．配布データを丁寧に見れば分布や構造の数字はかなり推定できるが，どの確率モデルで作ったかはデータの観察から分からない．そしてその情報が効くのはほぼ希少群である．B_i に希少レコードは 24 件しかなく，この件数から生成レシピを推定するのは困難だからである．知っている者だけが有利になる状態を避けるため，最初から全員に同じ情報を渡す．伏せるのは，乱数種・各チームへの割当・正解の三つに限る．

4. 合成世界の生成

4.1 二層の因果骨格

二次解析の結論の再現を採点軸に据える以上，答えとな

© 2026 Information Processing Society of Japan

る因果構造を我々が握っている必要がある．そこで生成はモデルベースとし，二つの層に分けて設計する．第 1 層は共変量から発症までの時間を決める Cox ハザードであり，ここに埋め込まれた係数が特定有用性の「答え」になる．第 2 層は，発症を決める前に各人の共変量そのものを生成する同時分布である（依存構造はコピュラで与える）．素朴なモデルはこの第 2 層を暗黙のうちに独立サンプリングとしてしまうが，それでは生物学的に不自然なうえ，比例ハザードモデルの非崩壊性のために埋め込んだ係数が復元できなくなりうる．共変量は age・sex・BMI・SBP（収縮期血圧）・TG（中性脂肪）・HDL（HDL コレステロール）・ALT（アラニンアミノトランスフェラーゼ）・FPG（空腹時血糖）・smoking（喫煙）の 9 つである．

4.2 発症・死亡・打ち切り

追跡は最長 10 年である．発症と死亡はそれぞれ独立に時刻を引き，先に起きたほうを採用する（cause-specific の競合リスク）．どちらも 10 年より後なら 10 年で行政的に打ち切る．発症のハザードは公表論文の 2 型糖尿病発症モデルの係数をそのまま用い，ベースライン累積ハザードは指数形とし，10 年発症確率が目標値になるよう定数倍で較正した．死亡は簡易生命表の年齢・性別死亡率から引く．

4.3 希少群の作り方と，実データとの距離

希少群は，多数派とは別の作り方をする．空腹時血糖が境界域にある人を起点に選び，そこから血糖値をずらして代謝マーカーの束から切り離す．型は MODY（HNF1A 型）と 1 型糖尿病を 3 対 1 の比率で作り，型ごとに若年・低 BMI への偏りとずらし幅を変える．外れ度は多数派から推定した平均と共分散に対するマハラノビス距離で測り，目標の帯に較正する．この平均・共分散・帯は配布物に同梱してあり，参加者は採点器と同じ検出器を手元で使える．結果として希少群の 10 年発症率は多数派の約 3.4 倍になる．

多数派は，依存構造を実在の健診コホートから，周辺分布を全国統計から，発症モデルを公表論文から取っており，三段すべてが実データ由来である．希少群はそうではない．方向づけ自体は実在の臨床鑑別基準に沿っている．MODY や 1 型糖尿病は，若年・痩せ型で代謝症候群がないのに高血糖という表現型をとり，2 型と誤診されやすいことが知られている（MODY の最大 8 割が 1 型あるいは 2 型と誤診されるという報告がある [7]）．健診コホートに紛れ込んでいるという設定はこの事実に基づく．しかし，ずらし幅・ばらつき・型ごとの偏り・混合比は，狙った外れ度の帯に収めるために決めた設計値であって，患者データから推定した値ではない．希少レコードの血糖値をコピュラの依存構造を通さず独立に引くという操作自体が，測定された事実ではなく設計上の意図である．したがって本大会の「希少群」は，実在の非典型糖尿病そのものではなく，それを模した構成である．

5. 有用性採点

5.1 四つの側面と，最小値による集約

有用性は四つの側面で測り，その最小値を有用性得点とする（各側面の内部の定義と，この集約を選んだ経緯は付録 A.1・A.3 に示す）．

$$U = \min\bigl(U_{\mathrm{gen}},\, U_{\mathrm{spec}},\, U_{\mathrm{rare}},\, U_{\mathrm{valid}}\bigr)$$

U_{gen} はデータ全体の分布が元データにどれだけ似ているか，U_{spec} は「何が発症に効くか」という分析の結論が元データと一致するか，U_{rare} は希少群を潰さずに再現できているか，U_{valid} は見かけの数値だけを合わせる加工を排除するための最低限の整合を見る．いずれも $[0, 1]$ で，四つを対等に扱う．

希少群を見る側は生存時間の estimand ではなく，希少群がどれだけ居てどんな人たちでどうなったかを直接測る．生存時間解析の結論一致を測るのは U_{spec} で，その対象はコホート全体である．両者を一つの側面に統合すると，どちらが壊れたのかが読めなくなる．

5.2 U_{spec} — 全体の分析結論の一致

元データ B と匿名化データ C のそれぞれで，9 共変量から発症までの時間を説明する多変量 cause-specific Cox 比例ハザードモデルを学習する（死亡は打ち切り扱い）．得点は次の二つの最小値である．

結論一致． 9 係数それぞれについて寄与を決め，その平均をとる．信頼区間が 0 を除外するかという有意性の判定が食い違えば 0，両方が有意でも符号が逆なら 0，それ以外は信頼区間の重なりの割合とする．有意性の食い違いを 0 にするのは，「元データで効く要因を消した（見逃し）」と「元データで効かないのに有意にした（偽陽性の捏造）」の両方を等しく罰するためである．両方とも非有意なら重なりは大きく出るが，これは「非有意を非有意と正しく再現した」ことへの報酬として意図している．

判別性能の再現度． 同じ 9 共変量のモデルを匿名化データだけで学習し，元データに当てて発症の順序をどれだけ当てられるかを測る．これを元データで学習して元データで測った値で割って較正する．分母は「元データで作れば届く上限」であり，匿名化データで学習しても元データでの学習と同程度当てられれば満点という意味になる．

この二つは別々の壊れ方を捉える直交した検出器で，どちらが最小になるかは防御手法によって入れ替わる．最小値をとることで「片方だけを守る」戦略を罰する．

推定が成立しないデータは 0 点とする．発症者が一人もいない，ある列の値が全員同じ，ある列だけで発症が完全に決まる（完全分離）といった極端な匿名化データでは，

© 2026 Information Processing Society of Japan

Cox 回帰そのものが立たず，有用とは言えない．

5.3 U_{rare} — 希少群の再現

希少群については，四つの観点の最小値をとる．どれだけ居るか（多数派の分布からのマハラノビス距離で希少と判定される行の割合），どんな人たちか（希少群の各項目の分布の一致），どうなったか（希少群の発症率の一致），項目どうしの関係まで再現できているか（希少群の同時分布を判別器で見分けたときの AUC）である．

なお，C の中で希少と判定される行が閾値に満たない場合，同時分布の観点は評価不能となり 0 点とする．評価不能を集約からの除外にすると，希少と判定される行を意図的に減らして採点を回避する余地が生じるためである．

6. 匿名性採点

6.1 二つの推論攻撃を，偶然の水準で較正する

匿名性は，匿名化データに対して行われた攻撃の成功度の裏返しである．攻撃は二種類，すなわちメンバーシップ推論（ある個人が元データに含まれていたか）と属性推論（ある個人の伏せられた追跡年数を当てられるか）で，チーム i の匿名性 $A_K(i)$ は次で与える．

$$A_K(i) = 1 - \max\bigl(a_{\mathrm{MIA}}(i),\ \max_{j} a_{\mathrm{AIA}}(i;j)\bigr)$$

添字 K は，メンバーシップ推論の成功度を $[0,1]$ に写すときの基準倍率であり，付録 A.3 で述べる（$K = 12$）．二種類の攻撃の間では最悪ケースをとる．どちらか一方でも破られていれば，匿名性はそこで決まる．なお，攻撃者が何をどのような様式で答えるかは付録 A.2 に示す．

本大会に固有なのは，二つの成功度をいずれも「偶然に当たる水準」を基準に定義した点である．メンバーシップ推論では，提出された確信度はそのままに正解ラベルを並べ替えて同じ計算を繰り返し，得られた分布の 95 パーセント点を差し引く．属性推論では，標的と 1 対 1 に対応づけた対照群での的中を差し引く．

6.2 メンバーシップ推論の成分

手順． (1) 攻撃者ごとに，確信度の高い順に候補を並べて ROC を描き，偽陽性率 0.01 における真陽性率を線形補間で読む．確信度がメンバーかどうかと無関係なら，この動作点の真陽性率も 0.01 になる．これを偶然の水準と呼ぶ．(2) 同じことを希少な候補だけに絞ってもう一度行い，悪いほうをその攻撃者の値とする．(3) 全攻撃者について平均する．(4) 正解ラベルと希少の印を対にしたまま攻撃者ごとに並べ替えて (1)–(3) を 20,000 回繰り返し，その 95 パーセント点を差し引く．(5) 偶然の水準を 0，その K 倍を 1 として $[0,1]$ に写す（$K = 12$）．

なぜ偶然の水準を差し引くのか． メンバーが 25–27 人しかないため，確信度が何の情報も持たなくても偶然だけでこの水準の数倍まで届く．並べ替えによる帰無分布を本番規模で実測すると，この較正なしでは，何も漏らしていない防御に 5% の確率で成功度 0.735 以上（匿名性 0.27 以下）が付き，重い雑音や差分プライバシーによる合成にも，帰無に照らせば有意でない 0.26–0.37 の減点が付く．較正はこの見かけの減点を消す．並べ替えに使う乱数種は提出内容そのもののハッシュから決まるので，事務局が種を選ぶ余地はない．繰り返し回数は，回数を変えたときに得点がどれだけ動くかを実測して決めた．攻撃者ごとに測って平均するこの定義は，妨害的な提出に対しても頑健である（付録 A.4）．

6.3 属性推論の成分

標的での正解率を p_m，対照での正解率を p_c として，$R = \mathrm{clip}\bigl((p_m - p_c)/(1 - p_c), 0, 1\bigr)$ を成功度とする．分子は「本人のデータを見たからこそ余分に当てられた分」，分母は「対照でも当たる分を超えてまだ当てられる余地」であり，R は残っていた余地のうち実際に当てられた割合を表す．この形が要るのは，このデータでは 10 年たっても発症しない人が 9 割近くを占め，全員に「10 年」と答えるだけで 8 割以上が許容幅（±0.5 年）の中に入ってしまうからである．当たった数をそのまま失点にすると，匿名化の良し悪しではなく打ち切りの多さを測ることになる．

なお，この成分は攻撃者について平均せず最大をとる．成功度が既に対照との差の形で較正されているため，1 チーム分でも偶然で跳ね上がりにくいからである．

6.4 総合得点と攻撃力

総合得点は有用性と匿名性の最小値とする．

$$\text{総合得点} = \min\bigl(U,\ A_K\bigr)$$

最小値をとるのは，この二つが実際に引っ張り合うからである．元データの行をそのまま残すほど有用性は上がるが，誰が含まれていたかも分かりやすくなる．無加工のデータに近い提出が上位に残る集約は採れない．

攻撃力は総合順位に算入せず，独立のサブランキングとする．標的について単純に平均し，二つの攻撃の成功度を足す．攻撃する側にとってこの二つは引っ張り合わず，片方だけに資源を集中する偏った戦い方が成立しないので，両立を強制する最小値は不要である．守る側が最小値なのは，そちらが本当に引っ張り合うからである．

7. 内部検証

7.1 設定

競技を開くに先立ち，採点器が想定どおりの弁別をするかを内部で確かめた．参照防御を 32 種そろえ，6 つの乱数種で作った世界（各 30 コホート）のそれぞれ 6 コホートに適用して，$32 \times 6 \times 6 = 1{,}152$ の測定行を得た．攻撃

© 2026 Information Processing Society of Japan

表 2　律速する側面のカタログ（32 手法・36 セル平均）
Table 2　Catalogue of the binding facet over 32 defenses.

律速する側面	手法数	典型的な系統
U_{rare}	15	k-匿名化・Mondrian・DP 合成・強い雑音
A_K（匿名性）	9	無加工・順位交換・ブートストラップ
U_{spec}	8	コピュラ合成・独立周辺・ARF・弱い雑音
U_{gen}	0	—
U_{valid}	0	—

者は各測定で 29 とし，メンバーシップ推論の並べ替え帰無は 2,000 回とした（本番採点は 20,000 回）．

参照防御は三つのカテゴリに分けてある．naive（無加工，行のブートストラップ，希少の削除・混合，独立周辺からの再生成など，設計上どこかが必ず壊れるはずの手法），legit（k-匿名化，Mondrian，順位交換，加法・相関雑音，差分プライバシー合成，コピュラ合成，ARF 合成など，実務で使われうる手法），privileged（真のパラメータを知っている立場から引き直すオラクル合成．参加者には作れないが上限の目安になる）．

7.2　律速する側面のカタログ

手法ごとに 36 セル（6 乱数種 × 6 コホート）の平均をとり，U_{gen}，U_{spec}，U_{rare}，U_{valid}，A_K の五つのうち最小のものをその手法の律速する側面と呼ぶ．結果を**表 2** に示す．

読み取れることは三つある．第一に，律速する側面は一つに集まらない．匿名性が律速するのは 32 手法中 9 にとどまり，残りは二つの異なる有用性側面に分かれる．第二に，手法の系統と律速する側面の間に明瞭な対応がある．希少な行を一般化・抑圧・雑音で覆う系統は U_{rare} が律速し，元データの行をなぞって残す系統は匿名性が律速し，分布は似せるが生存構造を落とす合成系は U_{spec} が律速する．これは設計時に意図したとおりの挙動である．第三に，U_{gen} と U_{valid} はどの手法でも律速しない．この二つは順位を決める軸ではなくゲートとして働いている．

測定行の単位で見てもほぼ同じ像になる．総合得点が 0 を超えた 244 行の内訳は U_{spec} 153・U_{rare} 68・A_K 22・U_{gen} 1 であり，総合得点が 0 を超えた手法は 32 中 11 にとどまる．

7.3　(U, A_K) 平面の空白

図 1 は，各手法の有用性と匿名性を 36 セル平均で平面に置いたものである．$U \geq 0.6$ かつ $A_K \geq 0.6$ の領域は空白である．両方 0.5 以上に届くのは，真のパラメータを知る privileged なオラクル合成のみ（$U = 0.533$，$A_K = 0.908$）であり，参加者が実際に作れる手法に限ると 0.45 以上が 1 手法，0.4 以上が 3 手法である．

この形は，当初の見立てと二重に食い違う．単一軸の綱

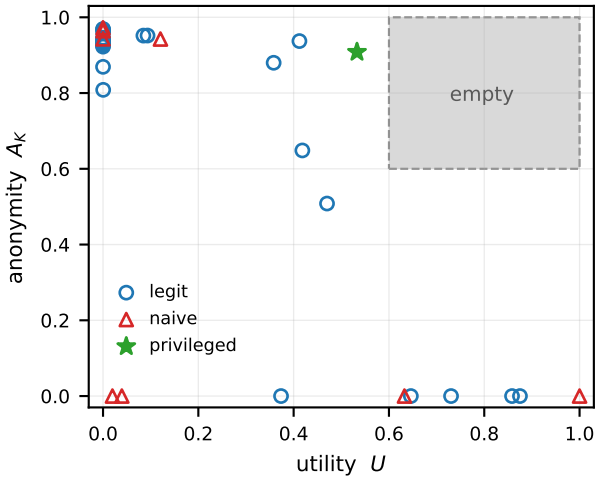


図 1　有用性 U と匿名性 A_K（32 手法・36 セル平均）．
Fig. 1　Utility U vs. anonymity A_K over 32 defenses.

引きであれば，点は左上から右下へ下る帯をなすはずである．実際には点は左端と下端に沿った L 字に集まり，帯の中央にも右上にも到達しない．参加者に課されているのは，互いに独立に壊れうる複数の側面を同時に満たすことの困難である．

7.4　この検証の限界

三点を明示しておく．第一に，並べ替え帰無の反復回数は本検証では 2,000 であり，本番採点の 20,000 より粗い．メンバーシップ推論成分の振れ幅は 2,000 回で 0.04–0.11，20,000 回で 0.01–0.03 である．第二に，本検証は属性推論の側を独立に検証していない．匿名性が満点未満だった 838 行の律速は属性推論 52.0%・メンバーシップ推論 37.9%・同値 10.0% であり，属性推論のほうが過半を占める．したがって K の据え置きに関する結論（付録 A.4）はメンバーシップ推論の側に限られる．第三に，ここで観測されたのは我々が実装し投入した参照攻撃の下での漏洩であり，より強い攻撃が存在しないことは示していない．合成系の手法に検出可能な漏洩が出なかったことは，それらが安全であることを意味しない．

8.　結論

本稿は，希少な患者のデータが二次解析上の価値と推論脆弱性の双方を担うという問題設定のもとで，匿名化コンテスト PWS Cup 2026 の設計を報告した．有用性は希少群の再現と全体の分析結論の一致を分けて測り，匿名性は二種の推論攻撃をいずれも偶然に当たる水準で較正して測る．両者を最小値で束ねることで，どの側面が壊れているのかが得点の上に現れる形にした．

参照防御 32 種を 6 つの乱数種で評価した内部検証では，当初の見立てであった単一軸の二律背反は観測されなかった．律速する側面は匿名性・U_{spec}・U_{rare} の三つに分散し，

© 2026 Information Processing Society of Japan

(U, A_K) 平面の右上は空白のまま残った．参加者に課されているのは，一本の軸の上での位置取りではなく，独立に壊れうる複数の側面を同時に満たすことである．RQ1 に対する現時点の答えは，少なくとも手法の水準では「否」であり，RQ2 については，生成の正解を秘匿したまま多数の参加者が再現可能に競える形で，この構造を測定し可視化できることを示した．

本稿の内部検証は競技の実データを含まない．本稿の内容の確定は加工フェーズの締切より前であり，参加者の提出に基づく分析は発表の場と事後の報告に委ねる．採点器とスターターキットは既に公開しており，世界の生成器と参照防御の一式，および本稿の集計に用いた測定データには恒久識別子 `https://doi.org/10.5281/zenodo.22019700` を付与した（競技の公平性のため，ファイルの公開は本大会の終了後，2026 年 10 月 19 日とする）．これにより本稿の検証は第三者が追試でき，本大会は一度きりの競技ではなく，希少群を含む縦断的健康データに対するプライバシー・有用性評価の公開ベンチマークとして残す．

謝辞　本大会の設計にあたり，椎名 峻平 氏をはじめとする PWS Cup 2026 ワーキンググループの各位から多くの助言をいただいた．また合成生存データの評価について大阪歯科大学の山本 景一 先生，横浜市立大学の石原 拓磨 先生から貴重な示唆をいただいた．記して感謝する．また，本研究は一部，JST 経済安全保障重要技術育成プログラム【JPMJKP24U5】の支援，JSPS 科研費 JP25K21170 の助成を受けている．

参考文献

[1] Akiya, I., Ishihara, T. and Yamamoto, K.: Comparison of Synthetic Data Generation Techniques for Control Group Survival Data in Oncology Clinical Trials: Simulation Study, *JMIR Medical Informatics*, Vol. 12, p. e55118 (online), DOI: 10.2196/55118 (2024).

[2] Allard, T., Béziaud, L. and Gambs, S.: SNAKE Challenge: Sanitization Algorithms under Attack, *Proceedings of the 32nd ACM International Conference on Information and Knowledge Management (CIKM '23)*, pp. 5010–5014 (online), DOI: 10.1145/3583780.3614754 (2023).

[3] Bowen, C. M. and Snoke, J.: Comparative Study of Differentially Private Synthetic Data Algorithms from the NIST PSCR Differential Privacy Synthetic Data Challenge, *Journal of Privacy and Confidentiality*, Vol. 11, No. 1, pp. 1–31 (online), DOI: 10.29012/jpc.748 (2021).

[4] Carlini, N., Chien, S., Nasr, M., Song, S., Terzis, A. and Tramer, F.: Membership Inference Attacks From First Principles, *2022 IEEE Symposium on Security and Privacy (SP)*, pp. 1897–1914 (online), DOI: 10.1109/SP46214.2022.9833649 (2022).

[5] El Kababji, S., Mitsakakis, N., Fang, X., Beltran-Bless, A.-A., Pond, G., Vandermeer, L., Radhakrishnan, D., Mosquera, L., Paterson, A., Shepherd, L., Chen, B., Barlow, W. E., Gralow, J., Savard, M.-F., Clemons, M. and El Emam, K.: Evaluating the Utility and Privacy of Synthetic Breast Cancer Clinical Trial Data Sets, *JCO Clinical Cancer Informatics*, Vol. 7, p. e2300116 (online), DOI: 10.1200/CCI.23.00116 (2023).

[6] Jordon, J., Jarrett, D., Saveliev, E., Yoon, J., Elbers, P., Thoral, P., Ercole, A., Zhang, C., Belgrave, D. and van der Schaar, M.: Hide-and-Seek Privacy Challenge: Synthetic Data Generation vs. Patient Re-identification, *Proceedings of the NeurIPS 2020 Competition and Demonstration Track, PMLR*, Vol. 133, pp. 206–215 (2021).

[7] Kant, R., Davis, A. and Verma, V.: Maturity-Onset Diabetes of the Young: Rapid Evidence Review, *American Family Physician*, Vol. 105, No. 2, pp. 162–167 (2022).

[8] Kikuchi, H., Yamaguchi, T., Hamada, K., Yamaoka, Y., Oguri, H. and Sakuma, J.: Ice and Fire: Quantifying the Risk of Re-identification and Utility in Data Anonymization, *2016 IEEE 30th International Conference on Advanced Information Networking and Applications (AINA)*, pp. 1035–1042 (online), DOI: 10.1109/AINA.2016.151 (2016).

[9] Mazzoli, M., Elfert, J., Sacerdoti, P., Hirsch, M., Davis Tira, M. and Paolotti, D.: Assessing Synthetic Data Generation Utility for Cohort Data Secondary Use, medRxiv 2025.06.09.25329247 (2025). doi:10.1101/2025.06.09.25329247.

[10] Murakami, T., Arai, H., Hamada, K., Hatano, T., Iguchi, M., Kikuchi, H., Kuromasa, A., Nakagawa, H., Nakamura, Y., Nishiyama, K., Nojima, R., Oguri, H., Watanabe, C., Yamada, A., Yamaguchi, T. and Yamaoka, Y.: Designing a Location Trace Anonymization Contest, *Proceedings on Privacy Enhancing Technologies*, Vol. 2023, No. 1, pp. 225–243 (online), DOI: 10.56553/popets-2023-0014 (2023).

[11] Shafieinejad, M., He, X., Alinoori, M., Jewell, J., Ayromlou, S., Pang, W., Chatrath, V., Sharma, G. and Pandya, D.: MIDST Challenge at SaTML 2025: Membership Inference over Diffusion-models-based Synthetic Tabular Data, arXiv:2603.19185 (2026).

[12] Shields, B. M., Hicks, S., Shepherd, M. H., Colclough, K., Hattersley, A. T. and Ellard, S.: Maturity-Onset Diabetes of the Young (MODY): How Many Cases Are We Missing?, *Diabetologia*, Vol. 53, No. 12, pp. 2504–2508 (online), DOI: 10.1007/s00125-010-1799-4 (2010).

[13] Shokri, R., Stronati, M., Song, C. and Shmatikov, V.: Membership Inference Attacks Against Machine Learning Models, *2017 IEEE Symposium on Security and Privacy (SP)*, pp. 3–18 (online), DOI: 10.1109/SP.2017.41 (2017).

[14] Snoke, J., Raab, G. M., Nowok, B., Dibben, C. and Slavkovic, A.: General and Specific Utility Measures for Synthetic Data, *Journal of the Royal Statistical Society Series A: Statistics in Society*, Vol. 181, No. 3, pp. 663–688 (online), DOI: 10.1111/rssa.12358 (2018).

[15] Stadler, T., Oprisanu, B. and Troncoso, C.: Synthetic Data – Anonymisation Groundhog Day, *31st USENIX Security Symposium (USENIX Security 22)*, pp. 1451–1468 (2022).

[16] United Nations Economic Commission for Europe: Synthetic Data for Official Statistics: A Starter Guide, United Nations, Geneva (2022).

[17] Zarifzadeh, S., Liu, P. and Shokri, R.: Low-Cost High-Power Membership Inference Attacks, *Proceedings of the 41st International Conference on Machine Learning (ICML), PMLR*, Vol. 235, pp. 58244–58282 (2024).

© 2026 Information Processing Society of Japan

研究倫理

本研究で用いたデータはすべて計算機上で生成した合成データであり，実在の個人に由来するレコードは含まない．生成の材料としたのは，公開されている健診コホートの要約統計，国勢調査および NDB オープンデータの集計値，ならびに公表論文に記載された回帰係数のみであり，個票データは使用していない．競技参加者から取得する情報は，本人の同意のもとで提出されたチーム情報と提出データに限られる．参加者への割当を決めるハッシュの salt は事前にコミットメントを公開し，配布時に本体を公表することで，事務局による事後の操作可能性を排している．また，本研究では，シミュレーションの実装・実施および本稿の執筆の補助に大規模言語モデル（Anthropic 社 Claude）を利用した．生成された内容については著者らが検証を行った．

付　　録

A.1　設計判断の台帳

本文で紙幅の都合により触れられなかった設計判断のうち，採点の骨格を決めた最大のもの（有用性の集約方法）を以下に示す．

A.1.1　なぜ最小値で集約するか

四つの側面を最小値で束ねるという判断は，当初からのものではない．加重平均から始まり，希少群だけをゲートにする形を経て，完全な最小値に至っている．

決め手になったのは，加重平均では希少群を破壊した加工に事実上ペナルティが付かないという実測である（**図 A·1**）．希少と判定される行をまるごと落とす `rare_drop` は U_{rare} が 0.039 しかないが，残る三側面が高い（U_{gen} 0.982，U_{spec} 0.753，U_{valid} 1.000）ため，四側面の単純平均では 0.694 となり，参照防御 32 種中 12 位につける．これは正当な合成手法である `arf_synth`（0.722・11 位）と区別がつかない位置である．希少群を多数派に混ぜてぼかす `rare_blend` も同様で，U_{rare} 0.020 に対し平均は 0.664・14 位である．最小値に変えると，この二つはそれぞれ 0.039（16 位）・0.020（17 位）に落ちる．

側面のどれかが完全に 0 になる手法は 32 種中 12 あり，そのうち 5 種は単純平均では 0.5 以上を保つ（最上位は `mondrian_k@5` の 0.571・16 位）．壊れた側面が他の側面に埋もれてしまうなら，その側面は採点に存在していないのと同じである．本大会が希少群の再現を主題に据える以上，この埋没は許容できない．

最小値の集約には「勝てる手法が一つに限られ，参加者の手法が同じ系統に収束する」という反論があり，実際に一度はその理由で棄却している．しかし強力な既製の合成器を参照防御に加えて測り直すと，優勝する手法は複数の系統に分散し，同じ系統への収束は再現しなかった．棄却の前提そのものが変わっていた．7 節では，各手法の得点を律速する側面が実際に複数の側面へ分散することを示した．

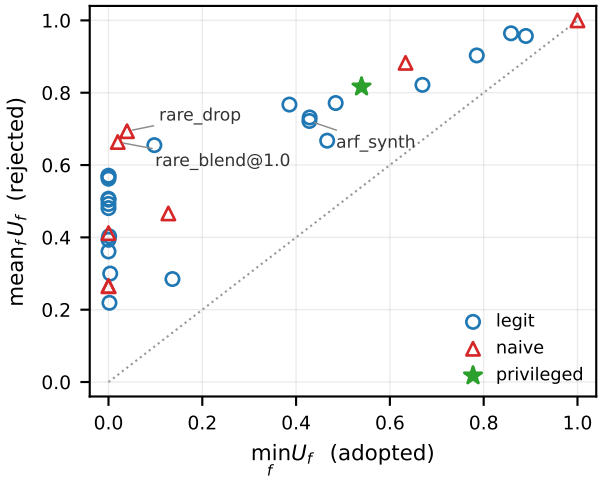


図 A·1　採用した最小値集約（横軸）と棄却した単純平均（縦軸）．32 手法・36 セル平均．希少群を壊す `rare_drop` と `rare_blend` は，平均では正当な合成手法 `arf_synth` と並ぶ．

Fig. A·1　Adopted min aggregation (x) vs. rejected mean aggregation (y) over 32 defenses. Methods that destroy the rare subgroup are indistinguishable from a legitimate synthesizer under the mean.

A.2　攻撃者が答えるもの

6 節の匿名性採点は，攻撃者が提出した回答を入力にとる．その回答が何であり，どの様式で提出されるかを示す（ルールブック § 4.1・§ 4.2 の抜粋）．いずれの攻撃でも，攻撃者に与えられるのは対象チームの匿名化データ C_i，全チーム共通の背景データ A_{bg}，そして自分自身のコホート B_j だけである．

A.2.1　メンバーシップ推論の回答

攻撃者 j は，自分のコホート B_j の 1,049 行それぞれについて，「この個人は対象チーム i の元データ B_i にも含まれていたか」の確信度を $[0,1]$ で答える．提出物は，行が自分のコホートのレコード ID，列が対象チームの ID である表 1 枚（`F_mia.csv`）で，自分以外の全チームぶんを一括で埋める．対象が 29 チームなら 1,049 行 × 29 列になる．正解にあたるのは共有ブロック S_{ij} の 25–27 行だけで，候補全体の 2.4% 程度しかない．陽性が希薄なので，平均精度ではなく低偽陽性率域の真陽性率を読む定義（6 節）と整合する．採点が使うのは確信度の順序だけであり，攻撃者に閾値の設定は求めない．

© 2026 Information Processing Society of Japan

A.2.2　属性推論の回答

攻撃者には，対象チームごとに課題表が 1 枚ずつ配られる．1 行が 1 人で，与えられるのは行 ID・age・SBP・TG・HDL・ALT・sex・県の 8 列だけであり，追跡年数と発症の有無は伏せてある．表は 326 行で，対象チームの非共有ブロックから選んだ標的 163 人と，どのチームのコホートにも背景データにも含まれない対照 163 人が，同数ずつシャッフルされて混ざっている．対照は，標的 1 人につき県・性別・年齢帯・発症の有無をそろえて 1 対 1 に選んである．どちらが標的でどちらが対照かは攻撃者には分からず，全行に同じように答える．

答えるのは確信度ではなく，追跡年数の推定値そのもの（年）である．提出物は，対象チーム ID・行 ID・推定年数の 3 列からなる表 1 枚（`F_aia.csv`）で，全対象チームぶんを縦に積む．事務局は採点時にだけ標的と対照を分け，標的での正解率 p_m と対照での正解率 p_c を別々に求めて 6 節の R を作る．正解とみなす許容幅は ± 0.5 年である．

A.2.3　参照実装

いずれの攻撃についても参照実装をスターターキットに同梱している．メンバーシップ推論は，連続共変量について密度比（匿名化データ C_i 上の密度と背景データ A_{bg} 上の密度の比）を推定し，比が高い個人ほどメンバーらしいとするもの．属性推論は，連続する検査値で C_i の最近傍を 1 件引き，その行の追跡年数をそのまま答えるものである．いずれも攻撃手法を縛るものではなく，参加者は独自の攻撃を用いてよい．

A.3　採点式の全定義

A.3.1　各側面の内部集約

各側面の内部も最小値または平均で集約する．U_{gen} は三つの最小値，U_{spec} は二つの最小値，U_{rare} は四つの最小値，U_{valid} は二つの平均である．最小値をとる場所と平均をとる場所の使い分けには方針がある．互いに直交し，単独でも誤検出の少ない検出器だけを最小値の側に置き，弱い検出器や誤検出の残る検出器は平均の側に回す．最小値は一つの検出器の誤検出がそのまま得点になるので，置いてよい検出器の条件が厳しい．

A.3.2　U_{gen} — 全体の分布

三つの相補的な観点の最小値をとる．各列を単体で見る周辺分布の一致（連続列は $1 - \mathrm{KS}$〔KS 統計量〕，カテゴリ列は $1 - \mathrm{TVD}$〔全変動距離〕の平均），列どうしの絡みを見る pMSE（元データと匿名化データを混ぜて判別器に当てさせ，推定確率の分散から作る），そして時間の出方を見る発症曲線の一致である．三つはそれぞれ別の壊れ方に対応する．

発症曲線の一致には，標本のばらつきに由来する差を罰しない不感帯を置いた．元データを二回ブートストラップして得た発症曲線どうしの差を積分し，その分位点までは差し引いてから正規化する．この処理を入れる前は，全ての防御手法で 0.985 以上に飽和して弁別性がなく，独立した側面として置く価値がなかった．不感帯を入れて U_{gen} のサブ指標に格下げすることで，側面の数は五つから四つになった．

A.3.3　U_{valid} — 妥当性ゲート

二つの平均をとる．打ち切り整合は，発症も死亡もしていない人の追跡時刻が打ち切り時刻になっているかという論理の不変量である．関係の非捏造は，群（県・性別・喫煙）から指標（各検査値・発症）への関係を，匿名化データが元データより強めた分だけを減点する．元データにある関係をぼかして弱めるのは正当な匿名化なので罰しない．

関係の強さを測る分母には，匿名化データ自身ではなく元データの標準偏差を使う．自身のばらつきで割ると，値をならして散らばりを縮めた加工（たとえば k-匿名化）が，実際には関係を強めていないのに「強めた」と判定されてしまう．初期の実装は分散比を用いており，まさにこの誤検出を起こしていた．

生理的にありえない値は，この側面で少し減点するのではなく，提出時の値域チェックで受け付けない．ソフトな側面として置く案は，U_{gen} の周辺分布と冗長であることが実測で分かったため採らなかった．

A.3.4　メンバーシップ推論の成分（補遺）

なぜ攻撃者について平均するのか． 攻撃者たちは全員，同じ匿名化データを攻撃している．違うのは候補に挙がっている人だけなので，攻撃者ごとの数字は「この匿名化データがどれだけメンバーを漏らすか」という同じ一つの量を，別々の人の組で測った反復測定である．1 チーム分の測定はメンバーが 25–27 人しかないため粗く，最大値をとると実力ではなく偶然の有利さを拾う．したがってこの成分は「広く破られたか」を測る．「1 チームだけが破った」ことは，匿名性ではなく攻撃力の側で評価する．

K について． 動作点における「偶然の何倍か」の分布には空白があり，元データの行をそのまま残す系統は 21.6 倍以上，それ以外は 4.4 倍以下に分かれる（参照防御 32 種の平均・7 節の設定）．K をこの空白の内側に置くかぎり，飽和側に入る手法の構成は変わらない．実際に K を 3 から 14 まで振っても，律速する側面の内訳と総合得点の順位はほとんど動かない（付録 A.4）．

A.3.5　属性推論の成分（補遺）

希少群だけに絞った成功度も計算し，全体との悪いほうを採る．ただしこちらは補助的な指標であって主力ではない．希少側が効くには対象となる少数の全員について的中

© 2026 Information Processing Society of Japan

させる必要があり，その少数は全体の内数なので全体側の成功度が既に上がっている．代数的に，希少側が上乗せできる幅は 0.068 が上限になる．この幅を全ての測定行に一律に加えても順位の入れ替わりは起きない．希少な患者の保護を実際に担っているのは，メンバーシップ推論の希少側と U_{rare} である．

採点式の完全な定義とパラメータの一覧（$K = 12$，動作点 FPR $= 0.01$，属性推論の許容幅 ± 0.5 年，帰無較正の分位点 95%，反復回数 20,000）は，公開済みの採点器実装で確認できる（入手先は付録 A.5）．

A.4 内部検証の詳細

A.4.1 側面ごとの弁別の細かさ

採点器が順位を区別できるかどうかは側面によって違う．32 手法の平均値を小数第 2 位で丸めて相異なる値の数を数えると，U_{spec} 25 段・U_{gen} 22 段・U_{rare} 15 段・U_{valid} 15 段・A_K 13 段であった．ただし U_{rare} は 15 手法が，A_K は 9 手法が 0 に集中し，U_{valid} は 14 手法が満点に集中する．U_{spec} と U_{gen} は勾配として，U_{rare}・U_{valid}・A_K はゲートとして働いていると読むのが実態に近い．

A.4.2 採点の頑健性

妨害に対して． 全ての行に他より大きい定数を出すだけの提出を 1 つ混ぜる攻撃を，人工的に構成した攻撃者の集合で再現すると，攻撃者の確信度を連結する当初の定義では無加工データの成功度が 1.000 から 0.019 へ落ち，漏洩の有無の弁別は 0.489 と偶然と同水準になった．攻撃者ごとに測って平均する現行の定義では，同じ条件で成功度 1.000 と弁別 0.970 を保つ．

パラメータに対して． K を 3 から 14 まで振って律速する側面のカタログを取り直すと，U_{rare} が律速する 15 手法は全域で不変であり，動くのは匿名性と U_{spec} の境界にある最大 2 手法にとどまる（$K = 3$ で 11 対 6，$K = 12$ 以上で 9 対 8）．総合得点の順位相関は $K = 12$ を基準にスピアマンで 0.994 以上であり，入れ替わりは得点差 0.001–0.06 の僅差の範囲に限られる．

7 節の集計の内訳（32 手法 $\times$ 主要側面の 6 乱数種平均，K 掃引，妨害注入の新旧比較）は，8 節の恒久識別子で公開する測定データ一式から再集計できる．順位としての提示は行わない．

A.5 再現手順

本稿の検証は次の三つから再現できる．

第一に，スターターキットである．参加者向け配布データ・参照実装・自己採点器・入門ノートブックを `https://github.com/pwscup/pwscup2026-kit` で公開しており，各フェーズ時点の版は同名の Release として固定してある（例: 予備戦・加工フェーズは `prelim-process-20260808`）．

第二に，採点用コンテナイメージである．本番の採点は Docker イメージ `hajimeono/pwscup2026-kit` で実行され，参加者は同じイメージで採点を手元で再現できる．タグは各フェーズの Release 名に対応させて案内している．

第三に，世界の生成器・参照防御・本稿の測定データの一式である．8 節の恒久識別子（DOI: 10.5281/zenodo.22019700）に収録し，競技の公平性のため本大会の終了後（2026 年 10 月 19 日）に公開する．7 節の内部検証はこの一式から再集計できる．

計算コストの実測として，本番採点で最も重いのはメンバーシップ推論の並べ替え較正（20,000 回）であり，30 チーム分で約 51 分を要する．フェーズ締切後に 1 回だけ実行する．

© 2026 Information Processing Society of Japan