一般化階層の粒度を考慮した k 匿名化アルゴリズムの実証評価

山口 拓生[2,1,a)]　南 和宏[2,b)]

概要：個票データを公開する際には，プライバシーを保護しながら分析上の有用性を維持する匿名化処理が必要となる．一般化処理に基づく k 匿名化は，k 匿名性を満たしつつ情報損失を最小化する一般化レベルの組合せを探索する問題であり，準識別子数や一般化階層のレベル数の増加に伴って探索空間のサイズが急速に拡大する．そのため，問題規模に応じて匿名化手法を選択するには，探索空間サイズと実際の計算可能性の関係を把握する必要がある．本研究では，最適解を求める Incognito と Flash，ヒューリスティック手法である Lightning を共通の Python 評価基盤上に実装し，複数の実データ条件で実行時間，メモリ使用量，匿名データの有用性を比較した．また，Lightning について計算時間に伴う暫定最良解の推移を分析するとともに，一般化階層へ中間レベルを追加した場合の探索コストと有用性の変化を評価した．実験の結果，本実験環境では探索空間サイズが 10^5 規模になると最適探索に約 1 時間を要する条件が現れ，10^7 規模では Flash と Incognito のいずれも 2 時間以内に完走しなかった一方，Lightning は k 匿名性を満たす解を取得した．また，一般化階層への中間レベル追加によって Discernibility Metric (DM) が 47.45% 減少した条件が得られた一方，その後のレベル追加では DM が改善せず，計算コストのみが増加した．以上より，探索空間サイズは手法選択の有用な基準となる一方，データ特性，探索戦略，および一般化階層の設計も計算コストと有用性に影響を与えることが示された．

キーワード：k 匿名性，一般化階層，匿名化アルゴリズム，探索空間，情報損失

Empirical Evaluation of k-Anonymization Algorithms Considering Generalization-Hierarchy Granularity

Takuo Yamaguchi[2,1,a)]　Kazuhiro Minami[2,b)]

Abstract: Publishing microdata requires anonymization techniques that protect privacy while preserving utility for data analysis. In generalization-based k-anonymization, the anonymization problem can be formulated as finding an optimal combination of generalization levels that satisfies k-anonymity while minimizing information loss. Because the search space grows rapidly as the number of quasi-identifiers and hierarchy levels increases, selecting an appropriate anonymization algorithm requires an understanding of the relationship between search-space size and computational feasibility. In this study, we implement two optimal algorithms, Incognito and Flash, and one heuristic algorithm, Lightning, within a common Python evaluation framework and empirically compare their runtime, memory consumption, and solution quality across multiple real-world datasets. We also analyze how Lightning improves its best solution over time and evaluate how adding intermediate levels to generalization hierarchies affects computational cost and data utility. In our experimental environment, optimal search required approximately one hour for a search space on the order of 10^5, whereas neither Flash nor Incognito completed within two hours for search spaces on the order of 10^7; nevertheless, Lightning obtained solutions satisfying k-anonymity. Adding intermediate levels to a generalization hierarchy reduced the Discernibility Metric by 47.45% in one setting, whereas further additions increased computational cost without improving the metric. These results indicate that search-space size provides a useful criterion for algorithm selection, while data characteristics, search strategy, and generalization-hierarchy design also affect computational cost and data utility.

Keywords: k-anonymity, generalization hierarchy, anonymization algorithms, search space, information loss

© 2026 Information Processing Society of Japan

This paper is work in progress and not peer-reviewed.

1. はじめに

個人または組織レベルの詳細情報を含む個票データは，行政施策の立案，事業運営，学術研究における人々の属性や行動の分析に有益である．社会全体での個票データの利活用のため，組織を超えたデータ流通が期待されるが，その実現には，個票データの機密情報の漏洩を防ぐ匿名化処理の適用が必要である．しかし，氏名や住所などの直接識別子を削除した場合であっても，年齢，性別，地域情報等の準識別子を外部情報と照合することで，レコードに対応する個人が再識別されるリスクがある．

k 匿名性は，このようなレコードの再識別を防ぐために提案された匿名データの代表的な安全性指標であり，匿名データの各レコードの準識別子の値の組に対し，同一の値の組を持つレコードが少なくとも k 個存在することを要件とする [1], [2]．k 匿名性を実現する方法の一つとして，あらかじめ定義した一般化階層に従って準識別子の値を粗い粒度へ変換する一般化がある [3]．本研究では，この一般化階層に基づく k 匿名化を対象とする．

一般化に基づく k 匿名化は，各準識別子の一般化レベルの組合せの中から，k 匿名性を満たし，かつ情報損失の小さい一般化変換を探索する最適化問題として捉えることができる．探索対象となる変換候補の数は，準識別子数および各属性の一般化階層に含まれるレベル数によって定まり，これらの増加に伴って探索空間は急速に拡大する．そのため，問題規模によっては，匿名化処理に要する時間や必要なメモリ量が大きくなり，現実的な計算資源の範囲内で探索を完了できない場合がある．この最適化問題を解くアルゴリズムとして，最適解を保証する Incognito [3] や Flash [4]，計算時間を制限し，その時点までに得られた最良解を返すヒューリスティック手法である Lightning [5] 等が提案されている．これらの手法は探索戦略や枝刈りの方法が異なるため，同じ探索空間を対象とする場合であっても，実際の所要時間やメモリ使用量は異なる．

一方で，探索空間サイズを共通の尺度として，最適解を求める手法が完走可能な問題規模や，最適解を求める手法とヒューリスティック手法の適用範囲を整理した手法選択の指針は十分に示されていない．また，一般化階層は探索空間の大きさだけでなく，匿名化後データの有用性にも影響する．中間レベルを追加することで，より情報損失の小さい解を得られる可能性がある一方，探索空間の拡大によって計算コストが増加する．

そこで本研究では，計算可能な探索空間のサイズに基づく k 匿名化手法選択の指針を確立するため，Incognito, Flash，Lightning を共通の Python 評価基盤上に実装し，以下の 3 つの課題に対する実証評価を実施した．

RQ1 データ行数，準識別子数，一般化階層のレベル数，および探索空間サイズの増加に対して，Incognito, Flash，Lightning の所要時間とメモリ使用量はどのように変化するか．

RQ2 Incognito および Flash のような最適解を保証する手法が，制限時間およびメモリ上限の下で完走できる探索空間の規模はどの程度か．また，Lightning では，計算時間の増加に伴って解品質がどのように改善し，探索終了時の解へどの程度の時間で接近するか．

RQ3 同一の準識別子集合に対して一般化階層の中間レベルを段階的に追加したとき，探索空間サイズ，所要時間，メモリ使用量，および得られる解の有用性はどのように変化するか．

包括的な実証実験の結果，本論文では匿名化手法選択に関して以下の知見を得た．

- 個票データを整数符号化する実装手法は匿名化アルゴリズムの高速化に有効であり，特に k 匿名性判定を高速化することで全体所要時間を最大約 30 倍短縮した．
- 探索空間サイズを条件に匿名化アルゴリズムの計算時間を比較したところ，探索空間が 10^4 程度までは Flash と Incognito がいずれも最適探索を完走した一方，10^5 規模になると完走に約 1 時間を要する条件が現れ，10^7 規模では両手法とも完走しなかった．一方，Lightning はこれらの規模でも，最適性は保証しないものの，計算時間に応じて k 匿名性を満たす解を取得できることが判明した．
- 一般化階層への中間レベル追加により，有用性の代表的指標である Discernibility Metric (DM) が 47.45% 減少する条件が得られた一方，その後の追加では DM は改善せず計算コストのみが増加し，効果は属性によって異なることが分かった．

このように本論文では，探索空間サイズは手法選択の有用な目安となる一方，データ特性，探索戦略，および一般化階層の設計といった多くの要因が計算コストと有用性に影響を与えることを示した．

2. 背景

この章では，一般化処理に基づく k 匿名化の枠組みを導入し，主要な k 匿名化アルゴリズムを解説する．

2.1 k 匿名性と一般化

表形式のデータ D の準識別子に属する属性の集合を

$$Q = \{A_1, \ldots, A_d\}$$

とする．Q 上で同一の値の組を持つレコードの集合を等価

[1] 東京都立大学
Tokyo Metropolitan University
[2] 情報・システム研究機構
Research Organization of Information and Systems
[a)] yamaguchi.takuo@rois.ac.jp
[b)] kminami@ism.ac.jp

© 2026 Information Processing Society of Japan

クラスと呼ぶ．すべての等価クラスに含まれるレコード数が k 以上であるとき，データ D は k 匿名性を満たす [1], [2]．

k 匿名性を満たすための代表的な秘匿処理として，一般化と抑制がある．一般化では，準識別子の値を，あらかじめ定義した一般化階層に従ってより粗い値へ置き換える．例えば，年齢を具体的な年齢から年代へ，地域を市区町村から都道府県へ変換することで，複数のレコードが同一の準識別子の組を持つようにする．本研究では，準識別子の各属性について一般化レベルを選択し，同一属性にはデータ全体で同じ一般化レベルを適用する大域的一般化の方式を対象とする．

2.2 一般化階層と変換ラティス

各準識別子 A_i に対し，元の値をレベル 0，最も粗い一般化値をレベル h_i とする一般化階層を定義する．属性 A_i に適用する一般化レベルを g_i とすると，一つの変換候補は，

$$\mathbf{g} = (g_1, \ldots, g_d), \qquad 0 \le g_i \le h_i$$

という変換ベクトルで表すことができる．

二つの変換 $\mathbf{g}$，$\mathbf{g}'$ について，すべての i で $g_i \le g'_i$ であるとき，$\mathbf{g}'$ は $\mathbf{g}$ 以上に一般化された変換であるとする．この関係に基づき，変換候補全体はラティス（lattice）として表現できる．このラティスに含まれる変換候補のノードの集合が k 匿名化の探索空間 L に相当する．d 個の準識別子 $A_1, \ldots, A_d$ がそれぞれ $h_i + 1$ 個の一般化レベルを持つとき，探索空間 L のサイズ（ラティスのノード数）は，

$$|L| = \prod_{i=1}^{d} (h_i + 1) \tag{1}$$

となる．

また，ある変換が k 匿名性を満たす場合，それより一般化された変換も k 匿名性を満たす．この単調性を利用することで，評価済みの変換から未評価の変換の匿名性を推定し，探索候補を削減できる [3], [4]．

2.3 一般化階層の粒度と探索空間

一般化階層は，元の値をどのような段階を経て粗い値へ変換するかを定義する．一般化階層の設計は，匿名化後データの有用性だけでなく，k 匿名化アルゴリズムが探索する空間の規模にも影響する．一般化階層に中間レベルを追加すると，属性 A_i の一般化レベル数 $h_i + 1$ が増加するため，式 (1) に従って探索空間サイズも増加する．一方，既存の一般化レベルを保持したまま中間レベルを追加すると，探索可能な変換候補集合は拡大するため，得られる最適解の情報損失が増加することはなく，より情報損失の小さい解を選択できる可能性が生じる．また，一般化レベル数が同一であっても，各レベルにおいてどの値を同一の一般化値へまとめるかによって，一般化後の値分布は異なる．例えば，同じ数の一般化レベルを持つ二つの階層であっても，あるレベルにおける相異なる値の個数が異なれば，各変換候補において形成される等価クラスも異なり得る．その結果，k 匿名性を満たす変換の位置や，匿名性判定の処理量，匿名化後データの有用性が変化する可能性がある．

本研究では，既存の一般化レベルを保持したまま中間レベルを追加することを，一般化階層の細粒度化として扱う．中間レベルを追加すると探索可能な変換候補が増えるため，匿名化後データの有用性を改善できる可能性がある一方，探索空間も拡大する．そこで，一般化階層の細粒度化が探索空間サイズ，処理性能，および匿名化後データの有用性に与える影響を評価する．

2.4 主要な k 匿名化アルゴリズム

2.4.1 Incognito

Incognito は，k 匿名性の単調性と準識別子集合の包含関係を利用して候補を枝刈りする探索手法である [3]．少数の準識別子から探索を開始し，得られた結果を利用しながら対象とする準識別子数を段階的に増加させる．各属性集合では，一般化による k 匿名性の単調性を利用して匿名性判定を省略し，最終的に k 匿名性を満たす候補から評価指標に基づいて解を選択する．準識別子数や一般化レベル数の増加に伴って候補数が増えるため，大規模な問題では計算コストが増大する．

2.4.2 Flash

Flash は，一般化ラティス上で k 匿名性の単調性を利用し，最適解を探索する手法である [4]．未分類ノードから構成した探索パス上で匿名・非匿名の境界を探索し，判定済みノードの上位または下位を一括して分類することで匿名性判定を削減する．原論文ではノードに一貫した全順序を与えることで探索挙動を安定化している．一方，探索空間自体が巨大な場合には，探索時間やラティス保持に必要なメモリが問題となる．

2.4.3 Lightning

Lightning は，大きな探索空間に対し，限られた計算時間で有用性の高い解を得るためのヒューリスティック手法である [5]．評価基準に基づく最良優先探索と貪欲探索を組み合わせ，探索を打ち切った時点までの最良解を返す．そのため，Incognito や Flash が完走できない問題でも解を得られる可能性がある一方，最適性は保証されない．本研究では，計算時間の増加に伴う解品質の改善過程を評価する．

2.5 既存研究における課題と本研究の位置づけ

既存研究では，複数の k 匿名化アルゴリズムについて，所要時間，計算資源の使用量，匿名化後データの有用性等が比較されている [6], [7]．しかし，実際に匿名化手法を選択するためには，個々の実験条件における性能比較だけ

© 2026 Information Processing Society of Japan

でなく，問題規模と計算可能性との関係を把握する必要がある．探索空間サイズは問題規模を表す共通指標となる一方，実際の所要時間はデータ行数や一般化後の値分布，各手法の探索戦略にも依存するため，探索空間サイズのみから計算可能性を判断することは難しい．

また，一般化階層への中間レベル追加は，より情報損失の小さい変換を選択できる可能性を高める一方，探索空間を拡大させる．さらに，最適探索が計算資源の制約内に完了しない場合には，最適性を保証する手法と Lightning のようなヒューリスティック手法との使い分けが必要となる．そこで本研究では，探索空間サイズと実際の計算可能性，一般化階層の粒度と処理性能・有用性，および Lightning の計算時間と解品質の関係を実データ上で評価し，計算資源と要求される解品質に応じた k 匿名化手法選択の指針を得ることを目指す．

3. k 匿名化アルゴリズムの Python 評価基盤への実装

前節で述べた課題を実証的に評価するためには，同一のデータセットおよび評価条件の下で複数の k 匿名化手法を実行し，所要時間，メモリ使用量，および匿名化後データの有用性を比較できる環境が必要となる．そこで本研究では，既存の k 匿名化アルゴリズムを共通の Python 評価基盤上に実装した[*1]．

本基盤では，データセット，準識別子および一般化階層の定義，匿名化アルゴリズムの実行インターフェース，ならびに匿名化結果に対する評価処理を共通化している．一方で，探索方法や内部データ構造等のアルゴリズム固有の処理は各実装に保持しており，各手法の特性に応じた実装上の工夫を行える構成としている．これにより，共通の実験条件の下で各手法の性能を比較するとともに，アルゴリズム内部の処理やデータ表現を変更した実験を行うことができる．

3.1 実装時の工夫：整数符号化

k 匿名化アルゴリズムでは，探索中に多数の変換候補について k 匿名性判定を繰り返し実行する．そのため，1 回の匿名性判定に必要な処理時間を短縮することは，特に探索空間が大きい場合の全体の所要時間を削減する上で重要となる．Flash では，匿名性判定を高速化する実装上の工夫として，個票データの属性値を整数値に符号化するとともに，一般化階層を整数配列として保持する方式が用いられている [4]．これにより，探索中に文字列に対する比較や変換を繰り返す代わりに，整数配列への参照によって一般化後の値を取得できる．同様の整数符号化は，後述する匿名化フレームワーク ARX の内部データ表現にも採用されている [8]．本研究においても，Incognito，Flash，Lightning における探索中の k 匿名性判定を効率化するため，整数符号化を導入した．整数符号化では，各準識別子 A_j について，レコード r の元の属性値を整数コード $c_j(r)$ へ変換し，一般化レベル ℓ ごとに，元のコードを一般化後のコードへ変換する対応表 $H_{j,\ell}$ をあらかじめ構築する．変換候補 $\mathbf{g} = (g_1, \ldots, g_d)$ では，各属性について $H_{j,g_j}[c_j(r)]$ を参照することで一般化後の準識別子値を得る．探索中はこの整数値の組ごとにレコード数を集計することで，一般化済みデータを文字列として生成せずに k 匿名性を判定する．この方式では初期化時に整数符号と対応表を構築するコストが生じる一方，探索中の反復処理を高速化できる．

3.2 ARX との関係性

ARX [8] は，Java で実装された汎用的なデータ匿名化フレームワークであり，k 匿名性をはじめとする複数のプライバシーモデル，一般化や抑制等のデータ変換，情報損失を含む評価機構を統合的に提供している．また，匿名化に用いる探索機構として Flash を用いた最適探索，Lightning に基づく探索，遺伝的アルゴリズム等を備えており，GUI アプリケーションおよび Java API の双方から利用できる．Incognito については，現行の ARX において匿名化アルゴリズムの選択肢として直接提供されているわけではないが，ARX の実行基盤を利用した研究用ベンチマーク環境において実装が公開されている [7]．本研究の Python 実装は ARX を代替することを目的とするものではなく，k 匿名化アルゴリズム自体を実験対象として，内部処理やデータ表現を変更しながら比較評価するための基盤として位置づける．整数符号化の評価は，その実装上の構成要素が性能に与える影響を検証する例である．

4. 実験方法

本研究では，整数符号化による高速化，探索空間サイズと計算可能性，Lightning の計算時間と解品質，および一般化階層の粒度の 4 項目を評価する．

4.1 実験設定

実行環境

すべての計測には，Amazon EC2 の `r6i.4xlarge` を用いた．CPU は Intel Xeon Platinum 8375C（8 物理コア，16 論理コア），メモリは 123.8 GiB，OS は Amazon Linux 2023.12.20260817，Python は CPython 3.14.7 である．各条件は独立したプロセスで直列に実行し，数値計算ライブラリのスレッド数と Lightning の並列ワーカ数を 1 に固定した．

評価条件

すべての実験で $k = 5$，抑制率 0%とし，匿名化後データの有用性には Discernibility Metric（DM） [9] を用いる．

[*1] https://github.com/SDC4Society/k_anonymization

© 2026 Information Processing Society of Japan

表 1 スケーラビリティ評価に用いるデータセット

データセット	行数	準識別子数	探索空間サイズ $\lvert L\rvert$
Adult [10]	30,162	8	6,480
FARS [11]	100,937	7	6,912
CUP [12]	63,441	7	9,000
IHIS [13]	1,193,504	8	12,960
ATUS [14]	539,253	8	11,664
ACS13-MA [15]	68,725	15	1.47×10^5
ACS13-MA	68,725	20	2.48×10^7
ACS13-MA	68,725	25	7.93×10^8
ACS13-MA	68,725	30	2.85×10^{11}

匿名化後データが形成する等価クラスの集合を $\mathcal{E}$ とすると，DM は

$$\mathrm{DM} = \sum_{E \in \mathcal{E}} |E|^2 \tag{2}$$

と定義され，同一の入力データと準識別子集合では値が小さいほど情報損失が小さい．探索空間サイズ $|L|$ には，全準識別子に対する一般化レベルの組合せ数を用いる．ただし，Incognito は準識別子の部分集合に対する候補も評価するため，実際の探索量を示す補助指標として匿名性判定回数も計測する．

計測方法

全体所要時間は，アルゴリズムの初期化と `anonymize()` の実行時間の和とし，ファイル入出力，終了後の DM 再計算，一致検証，および作図を除外する．ピークメモリ使用量にはプロセスの最大 Resident Set Size（RSS）を用い，強制終了条件では外部監視したプロセスグループ全体の最大 RSS を用いる．5 回反復した条件では，平均値と標準偏差を報告する．

データセット

探索空間サイズと処理性能との関係を評価するため，表 1 に示す 9 条件を用いる．Adult, FARS, CUP, IHIS, ATUS は異なるデータ特性を持つ実データである．ACS13-MA では，同一の 68,725 行に対して準識別子数を 15，20，25，30 へ拡張し，行数を固定したまま高次元化の影響を評価する．各データセットの準識別子および一般化階層には，論文 [5] の著者である Fabian Prasser 氏から提供された定義を用いる．

4.2 各評価の設定

整数符号化による高速化

Flash，Incognito，Lightning について，探索中に一般化済みデータを生成する実装と，整数符号および一般化レベルごとの対応表を用いる実装を比較する．整数符号化以外の探索順序，枝刈り，解の選択方法，内部データ構造は同一とし，Adult を用いて各実装を 5 回ずつ実行する．また，各条件について Yappi[*2]による関数別実行時間を別途 1 回計測し，処理時間の内訳を確認する．両実装で匿名化後データ，DM，匿名性判定回数が一致することも検証する．

[*2] `https://github.com/sumerc/yappi`

表 2 一般化階層の段階的粒度条件

条件	age の区分数	探索空間 $\lvert L\rvert$
V0（基準）	$72 \to 15 \to 8 \to 5 \to 1$	6,480
V1	$72 \to 28 \to 15 \to 8 \to 5 \to 1$	30,720
V2	$72 \to 28 \to 15 \to 8 \to 5 \to 3 \to 1$	105,000
V3	$72 \to 28 \to 15 \to 12 \to 8 \to 5 \to 3 \to 1$	290,304

探索空間サイズと計算可能性

表 1 の 9 条件に対して 3 手法を実行し，全体所要時間，ピーク RSS，匿名性判定回数，DM，終了状態を記録する．探索時間上限は 7,200 秒，メモリ上限は 64 GiB とし，メモリ使用量を 5 秒間隔で監視する．Flash と Incognito では制約内で最適探索を完了した場合を完走とし，Lightning では制約内に k 匿名性を満たす解を取得できたかを評価する．各条件は原則 5 回反復するが，1 回目が正常終了しなかった場合，または 1 回目の全体所要時間が 3,600 秒を超えた場合は残りの反復を省略する．

Lightning の計算時間と解品質

ACS13-MA の 15, 20, 25, 30 準識別子条件について，前項の Lightning の 1 回目の探索履歴を分析する．`anonymize()` の開始を時刻 0 とし，暫定最良解が更新されるたびに経過時間と DM を記録する．探索終了時までに得られた最小 DM を $\mathrm{DM}_{\mathrm{end}}$，時刻 t までの暫定最良 DM を $\mathrm{DM}(t)$ とし，

$$R_{\mathrm{end}}(t) = \frac{\mathrm{DM}(t)}{\mathrm{DM}_{\mathrm{end}}} \tag{3}$$

によって解品質の改善過程を評価する．$R_{\mathrm{end}}(t) = 1$ は探索終了時の最良 DM へ到達したことを表すが，最適解への到達を意味するものではない．

一般化階層の粒度

Adult と Flash を用い，既存の一般化階層を V0，中間レベルを累積的に追加した条件を V1，V2，V3 とする．対象属性は age，education，native-country，workclass，occupation，marital-status であり，sex と race は変更しない．各条件は直前の条件で利用可能な一般化レベルをすべて保持するため，V0 から V3 にかけて変換候補集合は段階的に拡張する．V0–V3 の各条件を 5 回ずつ実行し，全体所要時間，ピークメモリ使用量，および DM を比較する．表 2 に，age を例とした一般化階層の構造と，各条件の探索空間サイズを示す．

さらに，各属性への中間レベル追加の寄与を確認するため，1 属性のみに V1 で追加した中間レベルを導入する属性別アブレーションを行う．対象属性以外には V0 の階層を用い，各アブレーション条件も 5 回ずつ実行して全体所要時間，ピークメモリ使用量，および DM を比較する．また，すべての出力が k 匿名性を満たすことを確認する．

5. 結果および考察

5 回反復した条件では，所要時間等の反復計測値を平均

© 2026 Information Processing Society of Japan

表 3　整数符号化の有無による全体所要時間と高速化倍率

手法	符号化なし［秒］	符号化あり［秒］	匿名性判定回数	高速化倍率
Flash	7.67 ± 0.10	3.62 ± 0.03	133	2.12
Incognito	151.18 ± 1.14	10.93 ± 0.06	5,408	13.83
Lightning	243.34 ± 4.90	8.16 ± 0.42	6,479	29.81

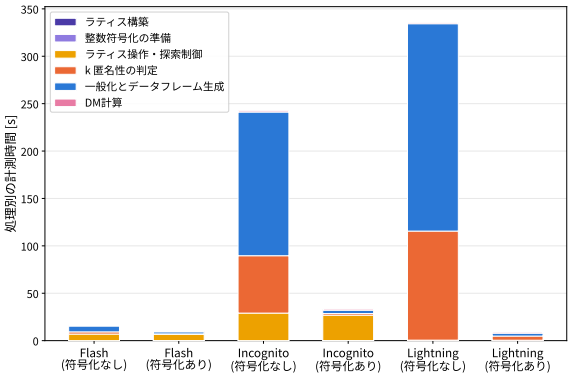


図 1　Yappi を用いて計測した整数符号化の有無による関数別実行時間の内訳

値 ± 標準偏差で示す．

5.1　整数符号化による高速化の効果

整数符号化の有無による全体所要時間と匿名性判定回数を表 3 に示す．整数符号化による高速化倍率は，Flash で 2.12 倍，Incognito で 13.83 倍，Lightning で 29.81 倍であった．匿名性判定回数は Flash が 133 回であったのに対し，Incognito では 5,408 回，Lightning では 6,479 回であった．また，各手法の匿名性判定回数は整数符号化の有無によって変化しなかった．Incognito と Lightning では Flash より多数の匿名性判定を行っており，判定処理の高速化による効果が繰り返し蓄積したことが，大きな高速化の一因になったと考えられる．

高速化の要因を確認するため，Yappi を用いて別途計測した関数別実行時間の内訳を図 1 に示す．整数符号化の準備には各手法で約 0.08 秒を要した一方，探索中に繰り返されるデータの一般化処理と k 匿名性判定に要する時間は大幅に減少した．Yappi を用いた関数別実行時間の計測では，k 匿名性判定に要した時間が Flash で 2.33 秒から 0.11 秒，Incognito で 60.53 秒から 1.72 秒，Lightning で 115.06 秒から 4.38 秒へ短縮された．また，データの一般化処理に要した時間も全手法で大幅に減少した．これらの結果から，整数符号化による高速化は，主として探索中に繰り返されるデータの一般化処理と k 匿名性判定の処理時間が削減されたことによると考えられる．

さらに，符号化の有無にかかわらず，3 手法はいずれも DM は 33,627,534 となり，匿名化後データも一致した．以上より，整数符号化は探索結果と探索量を変化させることなく，全体所要時間を短縮したことが確認できた．

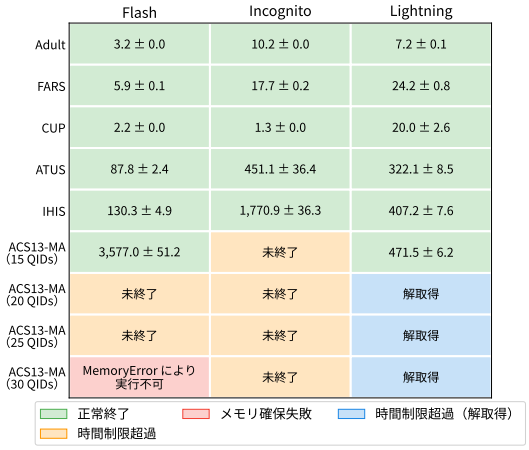


図 2　各データセットにおける k 匿名化手法の所要時間と実行結果

5.2　探索空間サイズと計算可能性

各データセットにおける 3 手法の所要時間と実行結果を図 2 に示す．Adult，FARS，CUP，ATUS，IHIS では，Flash と Incognito が最適探索を完走し，Lightning も k 匿名性を満たす解を取得した．Flash は 5 条件中 4 条件で最短であり，CUP のみ Incognito が最短となった．これら 5 条件では 3 手法の DM が一致し，Lightning も最適 DM と同じ値へ到達した．

探索空間を段階的に拡大した ACS13-MA 系列では，最適探索の実行可能性に明確な差が現れた．15 準識別子条件では，Flash は $3,577.00 \pm 51.16$ 秒で完走した一方，Incognito は 7,200 秒の探索時間上限内に完走しなかった．さらに，探索空間サイズが 24,772,608 となる 20 準識別子条件以降では，Flash と Incognito のいずれも本実験の時間制約内に最適探索を完了できなかった．一方，Lightning は 15 から 30 準識別子までのすべての条件で k 匿名性を満たす解を取得した．

本実験では，探索空間サイズ 10^5 規模で最適探索が約 1 時間を要する条件が現れ，10^7 規模では Flash と Incognito による最適探索を 2 時間以内に完了できなかった．したがって，このような規模で制限時間内に匿名化結果を得る必要がある場合には，Lightning のような時間制約付きのヒューリスティック手法が選択肢となる．ただし，所要時間はデータ特性や探索戦略にも依存するため，ここで観測した探索空間規模は普遍的な実行可能性の閾値ではない．

ピークメモリ使用量は行数の多い ATUS，IHIS で増加したが，64 GiB の上限へ到達した条件はなかった．ただし，Flash の 30 準識別子条件では，探索空間全体に対応するラティス管理用配列を確保できず，MemoryError となった．

5.3　Lightning における計算時間と解品質

Lightning の探索時間と探索終了時 DM に対する比 $R_{\mathrm{end}}(t)$ の関係を図 3 に示す．探索終了時 DM への接近速度は条件によって大きく異なった．

© 2026 Information Processing Society of Japan

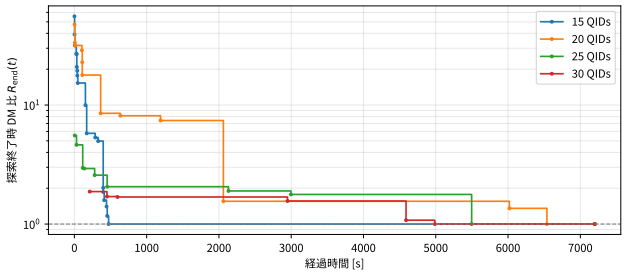


図 3 Lightning における探索時間と探索終了時 DM に対する比

15 準識別子の条件では，探索開始から約 473 秒で DM 28,447,481 へ到達し，この値は Flash による最適探索で得られた最適 DM と一致する．Flash が最適探索を完了するまでには $3,577.00 \pm 51.16$ 秒を要したことから，Lightning は最適性を保証しないものの，結果として Flash が得た最適 DM と同じ値へ約 7.6 分の 1 の時間で到達した．

一方，解品質の改善速度は準識別子数に対して単調には変化しなかった．600 秒時点の $R_{\mathrm{end}}(t)$ は，20 準識別子条件で 8.52，25 準識別子条件で 2.06，30 準識別子条件で 1.69 であった．3,600 秒時点では，20 から 30 準識別子の 3 条件における $R_{\mathrm{end}}(t)$ は 1.55–1.77 まで低下した．この結果から，Lightning に必要な探索時間は準識別子数だけから決めることはできず，暫定最良解の改善過程は条件によって大きく異なることが分かる．また，30 準識別子条件では，最初に k 匿名性を満たす解を得るまで約 213 秒を要した．このことから，Lightning は最適探索が時間制約内に完了しない規模でも匿名化結果を取得できる一方，探索時間を短く設定しすぎると，k 匿名性を満たす解自体を取得できない場合がある．また，20 から 30 準識別子条件では 3,600 秒時点でも探索終了時 DM との差が残り，その後も暫定最良解の更新が継続した．したがって，Lightning を用いる場合には，単に制限時間内に解を取得できるかだけでなく，許容可能な解品質と利用可能な計算時間とのトレードオフを考慮して探索時間を設定する必要がある．

5.4 一般化階層の粒度による影響

基準階層 V0 から中間レベルを段階的に追加した V1–V3 の結果を表 4 に示す．最初の中間レベル追加に当たる V0 から V1 への変更では，探索空間サイズは 4.74 倍，全体所要時間は 3.91 倍に増加した一方，DM は 33,627,534 から 17,672,320 へ 47.45%減少した．この結果から，中間レベルの追加によって計算コストは増加するものの，既存の階層では選択できなかった一般化変換が候補に加わることで，情報損失を低減できる場合があることが確認された．

一方，V2 および V3 では，探索空間をさらに拡大しても DM は V1 から改善しなかった．V0 に対して，探索空間サイズは V2 で 16.20 倍，V3 で 44.80 倍となり，全体所要時間もそれぞれ 16.02 倍，58.14 倍に増加した．age の一般化階層に着目すると，V1 では 72 区分と 15 区分の間に 28 区分の中間レベルを追加しているのに対し，V2 で追加した 3 区分および V3 で追加した 12 区分はいずれも 28 区分より粗い．V1 で得られた最適解では age の 28 区分が利用されており，V2 および V3 で追加した中間レベルは，この 28 区分より細かい新たな一般化候補を与えなかった．このことが，V2 および V3 で DM が改善しなかった一因と考えられる．なお，ピークメモリ使用量は V0 から V3 まで約 205–206 MiB であり，大きな変化はみられなかった．

表 4 段階的粒度条件における探索空間と全体所要時間および DM

条件	探索空間サイズ $\lvert L \rvert$	全体所要時間［秒］	DM
V0	6,480	3.36 ± 0.04	33,627,534
V1	30,720	13.14 ± 0.09	17,672,320
V2	105,000	53.86 ± 0.23	17,672,320
V3	290,304	195.41 ± 2.30	17,672,320

表 5 属性別アブレーションと基準条件 V0 の比較

中間レベル追加属性	探索空間 $\lvert L \rvert$	全体所要時間［秒］	DM
V0（基準）	6,480	3.36 ± 0.04	33,627,534
age	7,776	3.99 ± 0.03	17,672,320
education	8,100	3.98 ± 0.03	33,627,534
native-country	8,640	4.05 ± 0.05	33,627,534
workclass	8,640	3.86 ± 0.03	33,627,534
occupation	8,640	4.05 ± 0.04	33,627,534
marital-status	8,640	4.05 ± 0.03	33,627,534

次に，V1 における DM の改善がどの属性への中間レベル追加によって生じたかを確認するため，属性別アブレーションの結果を表 5 に示す．age のみに中間レベルを追加した条件では，6 属性すべてに中間レベルを追加した V1 と同じ DM 17,672,320 が得られた．一方，education，native-country，workclass，occupation，marital-status では，DM は V0 と同じ 33,627,534 であった．したがって，V0 から V1 への変更による DM の改善は，age に追加した中間レベルだけで再現できることが分かった．age のみを変更した条件の探索空間サイズは 7,776 であり，6 属性すべてを変更した V1 の 30,720 の約 25%であるにもかかわらず，同じ最適 DM を得た．以上より，一般化階層の細粒度化による有用性改善は，中間レベルの数だけでは決まらず，追加する属性と区分に依存する．有用性改善に寄与する中間レベルを選択的に追加することで，探索空間の増加を抑えながら解品質を改善できる可能性がある．

5.5 k 匿名化手法選択への示唆

本実験から得られた経験的な目安として，本実験で探索空間サイズが 10^4 程度までであった条件では，Flash と Incognito の双方が最適探索を完走した．この規模では Flash が 5 条件中 4 条件で最短であったため，Flash を第一候補としつつ，データ特性によっては Incognito も有効な選択肢となる．

探索空間が 10^5 規模になると最適探索に約 1 時間を要する条件が現れ，10^7 規模以上では Flash と Incognito のいず

© 2026 Information Processing Society of Japan

れも 2 時間以内に完走しなかった．このような規模では，最適性の保証が必須でなければ，探索空間全体の完走を待たず，打ち切り時点までに得られた最良解を返す Lightning のようなヒューリスティック手法が選択肢となる．

また，一般化階層を細粒度化する場合には，全属性へ一律に中間レベルを追加するのではなく，有用性改善に寄与する属性へ選択的に追加することで，探索空間の不必要な増加を抑えられる可能性がある．

5.6 妥当性への脅威と限界

本実験は 6 種類の実データ，$k = 5$，抑制率 0%，DM を用いた特定の実装・実行環境に基づくため，異なる条件で同じ傾向が得られるとは限らない．また，長時間条件の一部は 1 回のみの計測であり，強制終了時のメモリは 5 秒間隔で監視したため，一時的なピークを捉えていない可能性がある．さらに，異なるデータセット間では行数，値分布，一般化階層等も同時に異なるため，探索空間サイズと所要時間の関係を探索空間サイズ単独の効果として解釈することはできない．

6. おわりに

本研究では, Incognito, Flash, Lightning を共通の Python 評価基盤上で比較し，整数符号化による高速化，探索空間サイズと計算可能性，Lightning の計算時間と解品質，および一般化階層の粒度の影響を評価した．その結果，探索空間の拡大に伴って最適探索が困難になる一方，Lightning はそのような条件でも計算時間に応じた解を取得できることを確認した．整数符号化では，探索結果を変化させることなく，全体所要時間を最大約 30 倍短縮できた．また，一般化階層の中間レベルは情報損失を低減できる場合があるが，改善に寄与しない中間レベルの追加は計算コストのみを増加させた．今後は，異なる k，抑制率，データセットへ評価を拡張するとともに，有用性改善に寄与する一般化階層の設計方法を検討する．

謝辞

本研究は，JST 経済安全保障重要技術育成プログラム【JPMJKP24U5】の支援を受けたものです．

参考文献

[1] Latanya Sweeney. k-Anonymity: A Model for Protecting Privacy. *International Journal of Uncertainty, Fuzziness and Knowledge-Based Systems*, 10(5):557–570, 2002.

[2] Pierangela Samarati. Protecting respondents' identities in microdata release. *IEEE Transactions on Knowledge and Data Engineering*, 13(6):1010–1027, 2001.

[3] Kristen LeFevre, David J. DeWitt, and Raghu Ramakrishnan. Incognito: Efficient full-domain k-anonymity. In *Proceedings of the ACM SIGMOD International Conference on Management of Data*, pages 49–60, 2005.

[4] Florian Kohlmayer, Fabian Prasser, Claudia Eckert, Alfons Kemper, and Klaus A. Kuhn. Flash: Efficient, stable and optimal k-anonymity. In *Proceedings of the IEEE International Conference on Privacy, Security, Risk and Trust and IEEE International Conference on Social Computing*, pages 708–717, 2012.

[5] Fabian Prasser, Ralf Bild, Jens Eicher, Heiko Spengler, Florian Kohlmayer, and Klaus A. Kuhn. Lightning: Utility-driven anonymization of high-dimensional data. *Transactions on Data Privacy*, 9(2):161–185, 2016.

[6] Vanessa Ayala-Rivera, Patrick McDonagh, Thomas Cerqueus, and Liam Murphy. A systematic comparison and evaluation of k-anonymization algorithms for practitioners. *Trans. Data Privacy*, 7(3):337–370, December 2014.

[7] ARX Data Anonymization Tool. anonbench: Benchmarking environment for data anonymization algorithms.

[8] Fabian Prasser, Johanna Eicher, Helmut Spengler, Raffael Bild, and Klaus A Kuhn. Flexible data anonymization using arx—current status and challenges ahead. *Software: Practice and Experience*, 50(7):1277–1304, 2020.

[9] Roberto J. Bayardo and Rakesh Agrawal. Data privacy through optimal k-anonymization. In *Proceedings of the 21st International Conference on Data Engineering (ICDE 2005)*, pages 217–228. IEEE, 2005.

[10] Barry Becker and Ronny Kohavi. Adult. UCI Machine Learning Repository, 1996.

[11] National Highway Traffic Safety Administration. Fatality analysis reporting system (fars). `https://www.nhtsa.gov/research-data/fatality-analysis-reporting-system-fars`.

[12] Ismail Parsa. Kdd cup 1998. UCI Machine Learning Repository, 1998.

[13] IPUMS. Ipums health surveys: National health interview survey (formerly ihis). `https://nhis.ipums.org/nhis/`.

[14] IPUMS. Ipums atus: American time use survey. `https://www.atusdata.org/atus/`.

[15] U.S. Census Bureau. 2013 american community survey public use microdata sample. `https://www.census.gov/programs-surveys/acs/microdata/access/2013.html`, 2013.

© 2026 Information Processing Society of Japan