LLMを用いた匿名加工アルゴリズム自動生成のための探索ハーネス設計

山田 明[1,a)]

概要：LLM を用いたアルゴリズム探索は，数学における構成問題において成果を上げているが，評価関数の設計自体が課題となる問題への適用が十分に検討されていない．匿名加工は，k 匿名性，ℓ 多様性，t 近接性などの指標が存在するが，これらを満たしたデータであっても照合によって再識別される可能性がある．また，データセットや求められる有用性によって適切な加工方法が異なる．本稿では，匿名加工アルゴリズムの自動生成を対象とし，独立した試行を行うためのサンドボックス環境と，評価関数の不備を防ぐ評価設計からなる探索ハーネスを提案する．提案するハーネスにおいて，構成問題および匿名加工を対象として，独立した複数回のアルゴリズム生成が可能であることを確認した．また，評価関数が不十分な場合には，与えられたデータセットのみに適合するものを含む退化解が生成された．さらに，生成されたアルゴリズムを既存ライブラリと比較し，ライブラリと同じ制約に加えて相関ひずみと移動量の制約を満たしたうえで，3 つのデータセットにおいて高い予測精度を実現した．

キーワード：匿名加工，k 匿名性，大規模言語モデル，自動探索，評価関数

Harness Design for LLM-based Anonymization Algorithm Generation

Akira Yamada[1,a)]

Abstract: Algorithm search using large language models (LLMs) has yielded promising results for constructive problems in mathematics. However, little attention has been paid to problems in which designing an appropriate objective function is itself a central challenge. Anonymization can be evaluated using metrics such as k-anonymity, ℓ-diversity, and t-closeness. Satisfying these metrics alone, however, does not guarantee data safety, and the appropriate transformation depends on both the dataset and the required level of utility. Using the automatic generation of anonymization algorithms as a representative case, we propose a search harness comprising a sandboxed environment for independent trials and an evaluation framework designed to prevent the exploitation of loopholes in the objective function. Experiments in this environment demonstrate that algorithms can be generated independently and repeatedly for both a constructive problem and an anonymization task. We also show that inadequately specified evaluation functions lead to degenerate solutions, including algorithms that overfit the provided dataset. Finally, we compare the generated algorithms with an existing library and confirm that they achieve higher predictive accuracy on all three datasets while satisfying the constraints available in the library as well as additional constraints on correlation distortion and movement.

Keywords: Data Anonymization, k-Anonymity, Large Language Model, Automated Search, Objective Function

1. はじめに

大規模言語モデル（LLM:Large Language Model）を用

[1] 兵庫県立大学
University of Hyogo
[a)] akirayamada@ieee.org

© 2026 Information Processing Society of Japan

This paper is work in progress and not peer-reviewed.

いたアルゴリズム探索は，数学における所与の条件を満たす対象を構成する問題（構成問題）において成果を上げている [1], [2], [3]．しかし，評価関数の設計自体が課題となる問題への適用が十分に検討されていない．

匿名加工では，匿名性の指標も有用性の指標も定義されているが，満たすべき指標と最大化する指標の切り分けが定まらない．具体的には，k 匿名性などの指標が存在するが，これらを満たしても照合によって再識別される可能性がある．また，データセットや求められる有用性によって適切な加工方法が異なる [4], [5]．差分プライバシー [6] は，プライバシー損失を定量的に制限する理論的枠組みを提供するが，その保証内容やパラメータ，プライバシー予算の配分を保護対象と分析目的に応じて設計する必要がある [7]．このため，データセットと利用目的のみから，安全性と有用性を両立する加工方法が自動的に定まるわけではない．

本稿では，評価関数の設計が課題となる問題として匿名加工アルゴリズムを取り上げ，LLM を用いたアルゴリズム探索におけるハーネスの設計を提案する．まず，LLM によるアルゴリズム探索の実行環境を検討する．LLM を組みこんで，ファイルの読み書きやコマンドの実行を自動化するプログラムをコーディングエージェントと呼ぶ．現在の LLM は，コーディングエージェントを通じてインターネットや関連ファイルにアクセスできる．そのため，未解決の問題について独立した試行を行わせるのが難しい．そこで，フォルダによる隔離と監査によって，独立した試行を複数回実行できるサンドボックス環境を構築する．

サンドボックス環境を評価するため，有向グラフの弧を有向ハミルトン閉路へ分解する問題を対象として，アルゴリズムを探索した．その結果，構築した環境において，独立した複数回の試行によるアルゴリズム探索が可能であることを確認した．また，同一のバージョンであっても，系統と推論強度の違いによって，解への到達に差が生じた．

次に，このアルゴリズム探索の実行環境において，匿名加工アルゴリズムの自動生成を対象とし，評価関数を設計した．データセットとして Adult[8]，Credit[9]，Diabetes[10] を用い，評価関数として，k 匿名性，ℓ 多様性，t 近接性，予測精度，相関ひずみ，移動量を組み合わせた．その結果，評価関数が不十分な場合には，与えられたデータセットのみに適合する退化解が生成された．また，生成されたアルゴリズムを既存の匿名加工ライブラリ [11] と比較し，加工後データの予測精度が高いことを示した．

2. 背景

2.1 アルゴリズム探索

DeepMind は，プログラムの関数（Function）を対象にして，LLM によって効率的にアルゴリズムを探索する手法 FunSearch を提案した [1]．FunSearch は，探索・評価・選択のループを繰り返すことで，与えられた関数に対して最適なアルゴリズムを見つける．構成問題の 1 つであるキャップセット問題において既知の下界を更新し，またオンライン箱詰めにおいて既存の詰め込み規則を上回る規則を発見した．AlphaEvolve[2] は，FunSearch の後継にあたる手法であり，プログラム全体を対象として，複数の部品を組み合わせて進化させる．4×4 行列の積を 48 回の乗算で計算する手法を見つけ，56 年間更新されていなかったシュトラッセン法による 49 回という乗算回数の記録を更新した．

Knuth は，有向グラフの弧を有向ハミルトン閉路へ分解する問題を提示した [12]．これは，m^3 個の頂点をもち各頂点から 3 本の弧が出る有向グラフについて，すべての弧を 3 本の有向 m^3 閉路に分解する一般構成を，$m > 2$ のすべてについて求める問題である．共同研究者の指示のもとで Claude Code が到達した奇数の m に対する構成に証明を与えた．

生成 AI によるアルゴリズム探索には，探索アルゴリズムにおいて LLM に大量にクエリするもの [1], [2] と，LLM に探索そのものを任せてクエリ回数を削減するもの [3], [12] がある．本稿では，計算機資源の制約があるため，後者の手法を採用する．

2.2 匿名加工の指標と限界

匿名加工アルゴリズムは，与えられたデータ D から加工後データ D' を得るためのアルゴリズム A として定式化できる．

$$A : D \mapsto g.$$

ここで，A は，データを直接書き換えるのではなく変換 g を返し，$D' = g(D)$ として加工後データを得るものとする．この定式化により，変換を求めるときに参照するデータと，変換を適用するデータを分けられる．

D の列は，個人を直接特定する識別子，単独では特定に至らないが組合せによって個人を絞り込む準識別子（QI:Quasi-Identifier），および秘匿の対象となる機微属性に分けられる．匿名加工において，識別子を除いたうえで，アルゴリズムが QI の一般化の程度を決める．

安全性は，加工後データ D' の性質として与えられる．k 匿名性は，QI の値が一致する行の集合を等価クラスとしたとき，どの等価クラスの大きさも k 以上であることを要求する [13]．ℓ 多様性は，各等価クラスに含まれる機微属性の値が ℓ 種類以上であることを [4]，t 近接性は，各等価クラス内の機微属性の分布がデータ全体の分布から t 以上離れないことを要求する [14]．一方の有用性は，加工前データと加工後データの隔たり $U(D, D')$ として測る．統計量の保存や，加工後データで学習した分類器の精度などが用いられる．

これらを用いると，匿名加工は，変換を返すアルゴリズ

© 2026 Information Processing Society of Japan

ム A についての制約つき探索問題として書ける．

$$\max_{A} U(D, g(D)) \quad \text{s.t.} \quad C(D, g(D)), \quad g = A(D).$$

ここで C は，上記の指標に閾値を与えて得られる述語である．以下では，最大化する U を目的関数，満たすべき C を制約と呼び，両者を合わせたものを評価関数と呼ぶ．C に具体的な指標と閾値を与えたものを制約の組と呼び，c1 と c2 のように書く．C と U への指標の配置が設計の対象であり，指標の定義だけからは決まらない．

ここで，C を満たすことは安全であることを意味しない．k 匿名性などは公開するデータの構文的な性質であり，攻撃者が持つ背景知識や，QI として想定しなかった列の組合せが考慮されていない．そのため指標を満たしたデータであっても，実際の照合によって再識別されうる．さらに，QI の列数が増えると，等価クラスを作るために必要な一般化の範囲が急激に広がる．Aggarwal[15] は，高次元のデータでは k 匿名性を厳密に達成しようとするとデータのほとんどの値を一般化または抑制することになり，構造的な情報が失われることを示している．つまり高次元では，指標を満たすことと有用性を保つことが両立しない．

また，C を満たすことは目的にかなう加工であることも意味しない．Brickell ら [5] は，一般化と抑制による加工が，データマイニングにおける有用性を大きく損なうことを実測している．加工方法の設計は，明示的な基準ではなく，手作業と経験に基づく判断で行われてきた [16]．与えられたデータに現れた値の並びに合わせて変換を作れば，そのデータに限って高い U が得られる．本稿では，このように制約 C を満たしながら目的から外れている解を退化解と呼ぶ．

3. 探索ハーネス

3.1 Knuth の Claude Cycle

図 1 に Knuth の Claude Cycle[12] を示す．Knuth の探索では，実行の前に問題の定義を `PROBLEM.md` に記載する．コーディングエージェントは，`PROBLEM.md` を読み込んでアルゴリズムを探索する．プロンプトでは，探索のためのプログラム `exploreXX.py` を生成して実行すること，実行の直後に計画ファイル `plan.md` を更新することを指示している．与えられたプロンプトを以下に示す．

```
** After EVERY exploreXX.py run, IMMEDIATELY update
this file [plan.md] before doing anything else.  ** No
exceptions.
```

Knuth の論文では，ユーザによる再実行を繰り返して，アルゴリズムを探索している．本稿では，ユーザの確認を介さずにコーディングエージェントが実行を続けられるよう，Codex CLI[17] の非対話実行用のサブコマンド `exec` を用い，書き込み先を作業フォルダに限る `--sandbox workspace-write` を指定した．

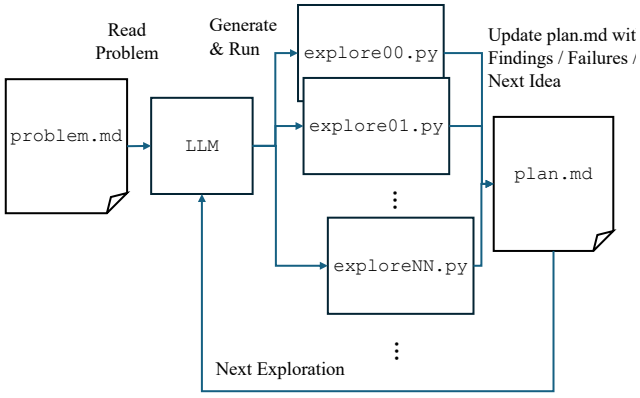


図 1 Knuth の Claude Cycle
Fig. 1 Knuth's Claude Cycle.

3.2 コーディングエージェントの隔離

コーディングエージェントは，エージェントプログラムとモデル（LLM）からなる．例えば，OpenAI 社には，エージェントプログラムとして Codex CLI[17]，モデルとして GPT[18] がある．エージェントプログラムは，モデルに指示を与えて，ファイルの読み書きやコマンドを実行する．モデルの指定には，バージョンと系統からなるモデル識別名を用いる．例えば，`gpt-5.6-sol` は，バージョン `5.6` と系統 `sol` を示している．これに加えて，呼び出しごとに推論強度を与える．推論強度は，モデルがクエリを受けたときに推論に費やす計算量を表す．`low` から `max` までの 5 段階から選択できる．本稿は，匿名加工の探索に `medium` を，構成問題に 5 段階すべてを用いる．指定できるモデルと推論強度を付録 A.1 に示す．

コーディングエージェントは，必要に応じて外部の情報を参照する．さらに，過去の対話から得た事実や手順を保存し，次の対話に自動的に持ち込む機能を持つ．この機能をメモリ（`memories`）と呼ぶ．未解決の問題を扱う場合，参照した外部情報に答えが含まれていることがある．また，メモリが残れば，2 回目以降の試行が 1 回目の続きになる．このとき，試行が互いに独立しない．そこで本稿では，プロンプトによる禁止，実行環境の隔離，および事後の監査を組み合わせる．

実行環境の隔離は，試行ごとにエージェントの設定フォルダを新しく作成し，認証情報のみを複製して，対話履歴・メモリ・過去に触れたフォルダの一覧を引き継がない．なお，実行時に指定できる制限は，書き込み先を作業フォルダに限ることだけであり，読み取りとネットワークを遮断していない．これは，Python のパッケージの導入を許すためである．

プロンプトでは，以下を禁止事項として与える．

© 2026 Information Processing Society of Japan

```
- Work only inside this directory.  Do not read, list,
or write any file outside it (this includes going up
with ..  or using absolute paths).
- Do not consult external sources:  no web search, no
external repositories, no downloading of code or data.
- Do not modify PROBLEM.md, evaluate.py, or the data.
```

試行のあと，記録された対話履歴と実行コマンドの列に対して次の 6 項目を確認する．すべてを満たした試行を有効とし，満たさない試行については原因を調べたうえで採否を判断する．

(1) 評価関数とデータのハッシュが，試行前と一致すること．
(2) 実行コマンドを起動したフォルダと引数に，作業フォルダの外を指すものがないこと．
(3) 外部取得を行うコマンドや，既存の匿名加工ライブラリの名前が現れないこと．
(4) `memories` の件数が試行の前後で増えていないこと．
(5) 記録されたモデルと推論強度が，指定した値と一致すること．
(6) プログラムの起動方法が，指示した手順と一致すること．

実行環境が強制できるのは，書き込み先の限定とメモリの遮断の 2 つだけであり，残りはプロンプトによる禁止と事後の監査に委ねている．ただし，モデルと推論強度の照合は，Codex CLI に渡した値との一致を見るものである．API がその値を解釈した結果まで確かめられない．

3.3 評価設計

評価関数は，2.2 節で述べたとおり制約と目的関数からなる．制約を満たさない加工後データを評価の対象から外す．安全性の指標と有用性の指標は，制約と目的関数のいずれにも置ける．本稿では，有用性の指標のうち相関ひずみと移動量を，目的関数ではなく制約の側に置く．目的関数は，すべての組において予測精度だけとする．ここで予測精度は，加工後データで学習した分類器が，学習に用いなかったデータに対して示す性能であり，AUC（Area Under the Curve）で測る．制約に用いる指標のうち，k 匿名性，ℓ 多様性，t 近接性を 2.2 節で述べた．残る相関ひずみと移動量，および安全性の指標である再識別率の 3 つを以下に述べる．相関ひずみは，QI の列の対ごとに連関の強さを求め，加工の前後での差の最大値をとったものである．連関には，数値どうしの列に Pearson の相関係数の絶対値 [19] を，それ以外に Cramér の V [20] を用いる．0 が加工による変化なしを意味する．

移動量は，加工によって元の値が動いた大きさを表す．順序のある列の場合，元の値と加工後の区間の中央との距離とする．順序のない列の場合，加工後の集合から等確率に選んだときの誤り率を用いる．順序の有無によらず，列ごとの最悪値とする．再識別率は，最近傍照合による攻撃で本人を当てられる割合である．加工後の行それぞれについて元の表のすべての行との距離を求め，最も近い行が本人であれば当たりと判定する．距離は，順序のある列では元の値が加工後の区間に入っていれば 0，外れていれば順位に直した空間での区間までの距離とする．順序のない列の場合，元の値が加工後の集合に入っていれば 0，外れていれば 1 とする．同点の行が複数あるときは，その本数で当たりを割って数える．

表 1 制約の組
Table 1 Constraint sets.

Constraint	c1	c2	c3	c4
$k \geq 5$	✓	✓	✓	✓
$\ell \geq 2$		✓	✓	✓
$t \leq t^*$		✓	✓	✓
Correlation distortion ≤ 0.25			✓	✓
Movement			✓	✓
Re-identification rate ≤ 0.05				✓

表 1 に，本稿で用いた 4 つの制約の組 c1–c4 を示す．c1–c4 へ進むにつれて制約が増える．各組は，前の組において得られた退化解を踏まえて定めた．t 近接性の閾値 t^* は，目的変数の陽性率に応じてデータセットごとに定め，Adult を 0.35，Credit を 0.37，Diabetes を 0.45 とする．移動量の上限は，Adult では列ごとの最悪値に対して 0.40 とし，Credit と Diabetes では順序のある列に対して 0.30，順序のない列に対して 0.40 とする．

4. 評価

4.1 実験設定

探索には，Codex CLI を用い，モデルに `gpt-5.6-sol`，推論強度に `medium` を指定する．バージョンは固定しておらず，0.145.0–0.147.0 であった．構成問題と匿名加工を合わせて 73 回の試行を実施した．本稿が用いるのは 39 回で，構成問題の 15 回と匿名加工の 24 回であり，いずれも 1 つの条件につき 1 回の試行である．残る 34 回は，匿名加工の 22 回と構成問題の 12 回であり，前者は制約の組と評価指標が，後者はエージェントへの指示が，本稿と異なる版のもとで実施したものである．39 回のすべてに 3.2 節の 6 項目の監査を適用した．37 回がすべての項目を満たし，2 回が項目 4 において違反として検出された．この 2 回は，Codex のデスクトップアプリが同じ設定ファイルを共有していたことによるものであり，試行のサンドボックスと無関係であることを確認したうえで，有効な試行として扱った．

4.2 構成問題

2.1 節で述べた分解問題を，Codex CLI によって探索させた．モデルにはバージョン 5.6 の 3 つの系統を用い，推

© 2026 Information Processing Society of Japan

表 2　モデルおよび推論強度ごとの検証結果
Table 2　Verified solutions by model and reasoning effort.

Model	low	medium	high	xhigh	max
`gpt-5.6-luna`	×	×	✓	✓	✓
`gpt-5.6-terra`	×	×	✓	✓	✓
`gpt-5.6-sol`	✓	✓	✓	✓	✓

表 3　匿名加工のデータセット
Table 3　Datasets for anonymization.

Dataset	Rows	Train	Test	Positive rate
Adult	48,842	32,561	16,281	0.241
Credit	30,000	20,000	10,000	0.219
Diabetes	253,680	169,120	84,560	0.139

論強度を 5 段階として，15 の条件を試行した．バージョンを固定しているため，系統と推論強度の違いだけが条件の差になる．成否の判定には，提出された成果物から分解を与える構成を取り出し，$m = 3, 5, 7, 9, 11$ のそれぞれについて，3 本の閉路が m^3 個の頂点を 1 回ずつ通り，弧を重複なく覆うことを確かめた．判定には，エージェント自身の検証関数ではなく，独立に実装したプログラムを用いた．

表 2 に結果を示す．15 回の試行のうち 11 回で正しい構成が得られた．判定できなかった試行はない．`gpt-5.6-sol` は 5 段階すべてにおいて解に到達した．`gpt-5.6-terra` と `gpt-5.6-luna` は，`high` 以上においてのみ解に到達し，その境目が一致している．

到達しなかった 4 つの試行は，資源を使い切って停止したものではない．出力トークン数が 4 万から 30 万であるのに対し，同じ `gpt-5.6-luna` が `high` では 359 万を消費している（付録 A.2）．

4.3　匿名加工

表 3 に，匿名加工の実験で用いたデータセットを示す．成人の収入データセット Adult[8]，クレジットカードの利用履歴データセット Credit[9]，糖尿病の健康指標データセット Diabetes[10] の 3 つである．各データセットは，学習用と検査用に分割し，学習用のデータだけをサンドボックスに置いて匿名加工する．有用性の指標は，加工後の学習用データを 7 対 3 に分け，一方で分類器を学習し，他方で評価して求める．制約の組と QI の組合せのそれぞれを試行する．データセットごとに 2 種類の QI を設けている．

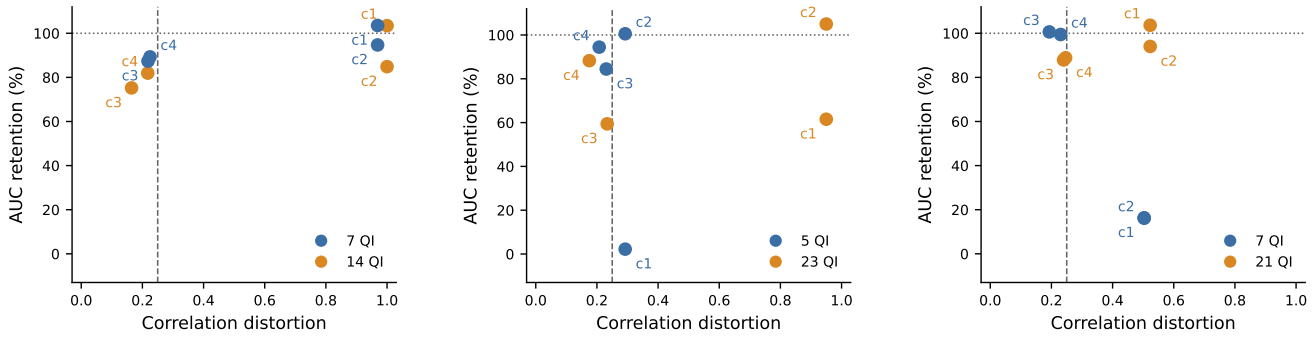
図 2 に，生成されたアルゴリズムの相関ひずみと AUC 保持率を示す．横軸の相関ひずみは 3.3 節のとおりである．縦軸の AUC 保持率は，情報を持たない場合の AUC である 0.5 を 0，無加工データを用いて学習した場合の AUC を 100 として正規化した値である．点の色は QI とした列数の違いを表す．

各図がデータセットに，図中の各点が表 1 の制約の組 c1–c4 に対応する．破線は，c3 と c4 において課した相関ひずみの上限 0.25 を示す．点線は，無加工データで学習した場合を表す．

制約が厳しくなるにつれて相関ひずみが低下する．この傾向は 3 つのデータセットに共通し，c1 と c2 の平均が 0.51–0.99 にあるのに対し，c3 と c4 が 0.19–0.24 に収まる．一方，AUC 保持率の変化は一様でない．c1 と c2 の平均に対して c3 と c4 の平均は，Credit が 67.3 から 81.7 へ，Diabetes が 57.5 から 94.2 へと高くなるのに対し，Adult は 96.6 から 83.5 へと低下する．無加工データを上回る点が 6 つある．そのうち 4 つは 4.4 節で述べる退化解によるもので，無加工データとの AUC の差が 0.012 から 0.015 である．残る 2 つは差が 0.002 に満たず，加工によって情報がほとんど失われなかった場合にあたる．

4.4　退化解

探索に与えたのは，問題文と評価関数とデータ，および変換を返す関数の雛形である．雛形は恒等変換であり，手法を含まない．関数の署名と出力の形式だけを固定した．評価関数は 3.3 節のとおりである．問題文には，加工したデータではなく変換を返すこと，採点に手元にないデータを用いることを記した．



(a) Adult　(b) Credit　(c) Diabetes

図 2　相関ひずみと AUC 保持率
Fig. 2　Correlation distortion and AUC retention.

© 2026 Information Processing Society of Japan

以下に，実験で得られた退化解の例を示す．

対応表を返す変換．c4 において得られた変換は，QI の値の組を鍵とする対応表を返す．対応表に存在する行を一般化し，対応表にない行をそのまま返す．このため，別の標本に適用するとほとんど加工されず，加工後データから本人を再識別できる．

```
result = [exact.get(row, row) for row in rows]
```

予測を書き込む変換．目的変数を予測する分類器を学習し，その出力を離散化した値を QI に書き込む変換が得られた．他の QI の列は単一の値に潰されるため，同値類が予測の帯と一致する．元の値との対応関係は記録されない．しかし目的変数の予測が書き込まれるため，加工後データで学習した分類器の精度が，無加工データによる精度を上回る．

```
39, 13, Never-married, White, Male, United-States, 40
    ↓
risk-12, risk-12, risk-12, risk-12, risk-12, risk-12,
risk-12
```

情報を消す変換．無加工データで得られる精度が多数派の割合とほとんど変わらない組合せにおいて，情報を消すだけの変換が得られた．

3 つとも，要求の理解に失敗した結果ではない．書かれた要求のもとで目的関数を最大にする解，またはそれに近い解であり，食い違いは意図のうち要求として書かれなかった部分に生じている．対応表を返す変換については，未知の行にも適用できることを求めたが，未知の行を加工することは求めていない．予測を書き込む変換が満たしていた k 匿名性，ℓ 多様性，t 近接性は，いずれも公開されるデータの分布に関する性質であり，元の値との対応を測らない．情報を消す変換については，有用性として予測精度だけを与えたため，それが改善しない場合に情報を残す理由がない．相関ひずみと移動量を制約に加えると，予測を書き込む変換は生成されなくなった．採点に手元にないデータを用いると明記したのちは，対応表を返す変換も生成されていない．情報を消す変換は，目的関数の設計に起因するため，制約を追加しても生成される．

4.5 既存手法との比較

提案するハーネスによる探索を，既存の実装と比較する．比較の対象として，匿名加工ライブラリ ANJANA[11] を用い，同様のデータセット，QI の組合せ，匿名加工のパラメータを与えて加工する．

ANJANA が指定できるのは，k 匿名性，ℓ 多様性，t 近接性の 3 つである．有用性の指標，すなわち予測精度，相関ひずみ，移動量を与えられない．ANJANA は列ごとの一般化階層を必要とするため，本稿で用意した．階層の作り方が結果に影響するため，順序のある列を値域から機械的に区切り，順序のない列を値と $*$ の 2 段とする．行の削除を許さない設定と，5%まで許す設定の両方において匿名加工した．データセットと QI の組合せは 6 つである．ANJANA には行の削除を許す設定と許さない設定があるため，6 つの組合せに対して 12 通りの結果が得られる．

表 4 既存の実装との比較（AUC）
Table 4 Comparison with an existing implementation (AUC).

	ANJANA		Ours		
Dataset	supp=0	supp=5	c3	c4	Original
adult-qi7	0.797	0.502	0.832	0.839	0.880
adult-qi14	0.609	0.504	0.819	0.848	0.925
credit-qi5	0.528	0.500	0.607	0.619	0.626
credit-qi23	0.500	0.502	0.643	0.713	0.741
diabetes-qi7	0.733	0.500	0.808	0.804	0.806
diabetes-qi21	0.672	0.500*	0.786	0.789	0.825

* ℓ-diversity not satisfied ($\ell = 1$).

表 4 に結果を示す．本稿の探索は，退化解が得られなかった c3 と c4 を比較の対象とする．c1 と c2 は 4.4 節で述べた退化解であり，匿名加工の結果として比べられないためである．ANJANA の 12 通りのうち 1 つが，指定した閾値を満たさなかった．`diabetes-qi21` において行の削除を許した設定であり，ℓ 多様性を満たしていない．c3 と c4 は，ANJANA に与えた 3 つの制約をすべて満たしたうえで，相関ひずみと移動量の制約を追加した組である．6 つの組合せのすべてにおいて，c3 と c4 の結果が ANJANA の結果を上回った．なお，ANJANA で行の削除を許すと，6 つの組合せすべてで AUC が 0.50，すなわち情報が残らない値まで落ちる．表 4 の `Original` は，無加工データで学習した場合の AUC である．t 近接性を満たすために外れ値を捨てると，予測に必要な情報も同時に失われるためである．

5. 考察

5.1 制限

本稿が用いたモデルは，パラメータが公開されていない．そのため，事前学習の影響がないことを確かめるのが難しい．また，API によるクエリのキャッシュを制御していない．ただし，構成問題と匿名加工の両方において，複数回の試行から異なる探索経路や異なる解が得られている．このことから，事前学習やキャッシュの影響が小さいと考えられる．事前学習によって解が記憶されているのであれば，系統や推論強度によらず解に到達すると考えられる．構成問題において `sol` 以外の系統が低い推論強度で解に到達しなかった事実は，これと整合しない．

実験に用いたモデルは，実験の時点で提供されていたものであり，今後更新される可能性がある．そのため，同一の条件を再現するのが難しい．そこで，実験において，モ

© 2026 Information Processing Society of Japan

デルのバージョンを記録し，すべての試行のクエリと応答を保持している．また，モデルのバージョンが同一であったとしても，API の呼び出しごとに応答が変わる可能性や，OpenAI 社においてマイナーな更新がなされている可能性がある．したがって，同一モデルによる再現実験であっても，結果が一致しないことがある．

系統と推論強度による差は，同一条件の繰り返しを含まないため，試行ごとのばらつきと切り分けていない．攻撃は最近傍照合の 1 種類であり，背景知識を持つ攻撃者を想定していない．データセットは 3 つとも表形式の二値分類であり，他の形式への当てはまりを確かめていない．また，有用性の評価は，加工後の学習用データを分けて求めており，探索に与えなかった検査用のデータを用いていない．検査用のデータによる評価も記録しているが，本稿の図表には用いていない．

3.2 節の隔離と監査には，次の限界がある．ただし，実験に用いた計算機に他のコーディングエージェントの実行記録や参考論文が置かれている．監査は記録された実行コマンドと対話履歴を対象とするため，これらの参照の有無を確かめられない．また，エージェントの設定を保持するフォルダは，同じ計算機のデスクトップアプリと共有される．4.1 節で述べた項目 4 のアラートは，この共有によって生じたものであり，監査が参照する状態の一部が隔離の外側にあることを示している．

5.2 コーディングエージェントを用いた実験

本稿に関わるプログラミングおよび実験には，Anthropic 社のコーディングエージェント Claude Code[21] を用いた．そのバージョンは，Codex CLI と同じく固定しておらず，作業の期間において 2.1.220–2.1.233 であった．すべてのプログラムは，Claude Code が生成し，人間がレビューしたうえで採用した．プログラムの実行と実行結果の確認の一部は Claude Code が担い，人間がレビューして採用した．

3.2 節で述べたとおり，試行ではメモリを引き継がない．コーディングと試行の独立性が失われる事故を防ぐため，コーディングを担当するコーディングエージェントと，試行を担当するコーディングエージェントに別のものを用いた．ただし，前者が後者の生成したアルゴリズムを読み込んでおり，制約の組を定めるときにその内容を用いている．

また，前者が後者に先立って，匿名加工や攻撃を評価することがあった．ユーザを支援するように学習されているためである．特に匿名加工を評価する関数の実装や閾値の決定において，影響があった可能性がある．コーディングエージェントを前提とする実験の独立性と再現性は，今後の課題である．

6. 関連研究

LLM を匿名加工に用いる研究として，文書を対象とする手法がある．RUPTA[22] は，プライバシーを優先したうえで有用性を最適化する辞書式の反復によって，テキストを LLM によって加工する．AURA[23] は，LLM エージェントが Web 検索の証拠と組み合わせて個人を特定する脅威を想定し，変更箇所と変更内容を分離した枠組みを提案する．AgentStealth[24] は，防御者と攻撃者の 2 つの役割を単一のモデルに獲得させ，自身の攻撃からの敵対的フィードバックによって加工を精緻化する．

表形式データを対象とするものとしては，LLM エージェントと差分プライバシーを組み合わせる AnonymAI[25] や，列間の論理関係を捉えて合成データを生成する LLM-TabLogic[26] がある．これらの出力は，匿名加工された結果そのものである．

表形式データの匿名加工を探索問題として解く研究がある．一般化階層と抑制の設定を焼き鈍しで最適化し，加工後の分類精度を最大化する研究 [27] は，Adult を対象としており，扱う指標と有用性の設定が本稿と類似している．一般化階層を人手ではなく自動で構築する研究 [28] がある．Iyengar[29] は，遺伝的アルゴリズムを匿名加工に用いた．その後，多目的最適化によってプライバシーと情報損失を同時に扱う手法 [30] が提案されている．また，k 匿名性が分類器の精度に与える影響を実測した報告 [31] は，評価設計の参照となる．

これらの研究は，探索の手法自体を人間が設計し，その内側のパラメータ，すなわち一般化の階層や抑制の割合を探索している．本稿の探索対象はパラメータではなくアルゴリズムであり，目的関数を差し替えれば，同じ枠組みのまま別の有用性に適用できる点が異なる．

なお, 制約を満たす加工を求める実装として ANJANA[11] などが公開されている．ANJANA は，k 匿名性や ℓ 多様性を指定して加工後データを得るものであり，本稿はこれを比較対象とする．

7. おわりに

本稿では，LLM を用いたアルゴリズム探索を，評価関数の設計自体が課題となる問題に適用するための探索ハーネスを提案した．提案するハーネスは，フォルダによる隔離と実行後の監査によって独立した試行を行えるようにしたサンドボックス環境と，制約と目的関数を分けて与える評価設計からなる．

数学における構成問題と匿名加工の 2 つを対象として，構築した環境において独立した複数回のアルゴリズムを生成できることを確認した．構成問題については，Knuth の Claude Cycle を本稿の環境において再現した．

匿名加工については，評価関数が不十分な場合に，与えられたデータセットのみに適合するものを含む退化解が生成されることを示した．また，既存ライブラリと比較し，ライブラリが指定できる 3 つの制約を満たしたうえで相関

© 2026 Information Processing Society of Japan

ひずみと移動量の制約を加え，3 つのデータセットすべてにおいて高い予測精度を実現した．今後は，攻撃する側を探索の対象に含め，複数のモデルとデータセットへ適用することを検討する．これらを通じて，匿名加工アルゴリズムの効率的な設計に役立てたい．

謝辞　本研究成果の一部は，基盤研究（C）「ユーザブルセキュリティの大規模言語モデル応用: 仮想的回答者によるインサイト探索」により得られたものである．

参考文献

[1] Romera-Paredes, B., Barekatain, M., Novikov, A., Balog, M., Kumar, M. P., Dupont, E., Ruiz, F. J. R., Ellenberg, J. S., Wang, P., Fawzi, O., Kohli, P. and Fawzi, A.: Mathematical Discoveries from Program Search with Large Language Models, *Nature*, Vol. 625, pp. 468–475 (2024).

[2] Novikov, A., Vũ, N., Eisenberger, M., Dupont, E., Huang, P.-S. et al.: AlphaEvolve: A Coding Agent for Scientific and Algorithmic Discovery, *arXiv preprint arXiv:2506.13131* (2025).

[3] OpenAI: Ten Advances in Mathematics and Theoretical Computer Science, `https://openai.com/index/ten-advances-in-mathematics/` (2026).

[4] Machanavajjhala, A., Kifer, D., Gehrke, J. and Venkitasubramaniam, M.: ℓ-diversity: Privacy Beyond k-anonymity, *ACM Transactions on Knowledge Discovery from Data*, Vol. 1, No. 1, pp. 3:1–3:52 (2007).

[5] Brickell, J. and Shmatikov, V.: The Cost of Privacy: Destruction of Data-Mining Utility in Anonymized Data Publishing, *Proc. 14th ACM SIGKDD International Conference on Knowledge Discovery and Data Mining (KDD)*, pp. 70–78 (2008).

[6] Dwork, C., McSherry, F., Nissim, K. and Smith, A.: Calibrating Noise to Sensitivity in Private Data Analysis, *Proc. 3rd Theory of Cryptography Conference (TCC)*, Springer, pp. 265–284 (2006).

[7] Dwork, C. and Roth, A.: The Algorithmic Foundations of Differential Privacy, *Foundations and Trends in Theoretical Computer Science*, Vol. 9, No. 3–4, pp. 211–487 (2014).

[8] Becker, B. and Kohavi, R.: Adult, UCI Machine Learning Repository, `https://doi.org/10.24432/C5XW20` (1996).

[9] Yeh, I.-C.: Default of Credit Card Clients, UCI Machine Learning Repository, `https://doi.org/10.24432/C55S3H` (2009).

[10] Centers for Disease Control and Prevention: CDC Diabetes Health Indicators, UCI Machine Learning Repository, `https://doi.org/10.24432/C53919` (2017).

[11] Díaz, J. S.-P. and García, Á. L.: An Open Source Python Library for Anonymizing Sensitive Data, *Scientific Data*, Vol. 11 (2024).

[12] Knuth, D. E.: Claude's Cycles, `https://cs.stanford.edu/~knuth/papers/claude-cycles.pdf` (2026).

[13] Sweeney, L.: k-anonymity: A Model for Protecting Privacy, *International Journal of Uncertainty, Fuzziness and Knowledge-Based Systems*, Vol. 10, No. 5, pp. 557–570 (2002).

[14] Li, N., Li, T. and Venkatasubramanian, S.: t-Closeness: Privacy Beyond k-Anonymity and ℓ-Diversity, *Proc. IEEE 23rd International Conference on Data Engineering (ICDE)*, pp. 106–115 (2007).

[15] Aggarwal, C. C.: On k-Anonymity and the Curse of Dimensionality, *Proc. 31st International Conference on Very Large Data Bases (VLDB)*, pp. 901–909 (2005).

[16] Guo, W., Pepitone, P., Aviv, A. J. and Mazurek, M. L.: How Researchers De-Identify Data in Practice, *Proc. 34th USENIX Security Symposium*, pp. 2205–2224 (2025).

[17] OpenAI: Codex CLI, `https://github.com/openai/codex` (2025).

[18] OpenAI: GPT-5.6 System Card, OpenAI Deployment Safety Hub, `https://deploymentsafety.openai.com/gpt-5-6/gpt-5-6.pdf` (2026).

[19] Pearson, K.: Note on Regression and Inheritance in the Case of Two Parents, *Proceedings of the Royal Society of London*, Vol. 58, pp. 240–242 (1895).

[20] Cramér, H.: *Mathematical Methods of Statistics*, Princeton University Press (1946).

[21] Anthropic: Claude Code, `https://code.claude.com/docs/en/overview` (2025).

[22] Yang, T., Zhu, X. and Gurevych, I.: Robust Utility-Preserving Text Anonymization Based on Large Language Models, *Proc. 63rd Annual Meeting of the Association for Computational Linguistics (ACL)*, pp. 28922–28941 (2025).

[23] Li, Z., Wen, J. and Li, T.: LLM Anonymization Against Agentic Re-Identification, *arXiv preprint arXiv:2605.30848* (2026).

[24] Shao, C., Li, T., Pu, C., Xu, F. and Li, Y.: AgentStealth: Reinforcing Large Language Model for Anonymizing User-generated Text, *arXiv preprint arXiv:2506.22508* (2025).

[25] Soares, M. N. O., Oliveira, L. B., Azambuja, A. J. G., de Oliveira Lima, J. P. and Soares, A. S.: AnonymAI: An Approach with Differential Privacy and Intelligent Agents for the Automated Anonymization of Sensitive Data, *Future Internet*, Vol. 18, No. 1, p. 41 (2026).

[26] Long, Y., Xu, L. and Brintrup, A.: LLM-TabLogic: Preserving Inter-Column Logical Relationships in Synthetic Tabular Data via Prompt-Guided Latent Diffusion, *arXiv preprint arXiv:2503.02161* (2026).

[27] Tawadros, D., Yang, W., Wiese, L. and Meyer, V.: Optimizing Classification Accuracy with Simulated Annealing in k-Anonymity, *Proc. International Database Engineered Applications Symposium (IDEAS)*, pp. 71–84 (2025).

[28] Saleh, T. and Korçak, Ö.: Optimizing k-anonymity with automated generalization trees: a study on classification utility, *International Journal of Machine Learning and Cybernetics*, Vol. 17 (2026).

[29] Iyengar, V. S.: Transforming Data to Satisfy Privacy Constraints, *Proc. 8th ACM SIGKDD International Conference on Knowledge Discovery and Data Mining (KDD)*, pp. 279–288 (2002).

[30] Dewri, R., Whitley, D., Ray, I. and Ray, I.: A Multi-Objective Approach to Data Sharing with Privacy Constraints and Preference Based Objectives, *Proc. 11th Annual Conference on Genetic and Evolutionary Computation (GECCO)*, pp. 1499–1506 (2009).

[31] Slijepcevic, D., Henzl, M., Klausner, L. D., Dam, T., Kieseberg, P. and Zeppelzauer, M.: k-Anonymity in Practice: How Generalisation and Suppression Affect Machine Learning Classifiers, *Computers & Security*, Vol. 111, p. 102488 (2021).

© 2026 Information Processing Society of Japan

8. 研究倫理

本研究で用いたデータセットは，Adult（Census Income），Default of Credit Card Clients，および CDC Diabetes Health Indicators の 3 つであり，いずれも研究目的で公開されているベンチマークデータである．これらは氏名や連絡先などの個人を直接識別する情報を含まない．Adult と Credit は，Creative Commons Attribution 4.0 International のもとで公開されている．Diabetes については，米国疾病予防管理センターの調査に由来し，パブリックドメインとして提供されている．3 つとも公開された利用条件の範囲において用いた．本研究では，新たなデータの収集や被験者を対象とした実験は行っていない．

本研究では再識別攻撃を実施しているが，対象は著者らが加工したデータに限られており，実在の個人を特定することを目的とした試行をしていない．また，攻撃に用いた手法は，匿名加工の安全性を評価するための既知の照合手順であり，新たな攻撃手法ではない．生成されたアルゴリズムは，実際の個人データの公開に適用していない．

本研究の遂行にあたっては，情報処理学会研究倫理綱領を遵守した．

付　　録

A.1 コーディングエージェントに指定できるパラメータ

本稿が用いた Codex CLI では，モデルと推論強度を起動時に指定する．本文では実際に用いた値だけを述べたため，ここに選択できる値を整理する．以下は，2026 年 8 月 14 日にバージョン 0.147.0 で確認した内容である．

表 A·1 に，指定できるモデルを示す．バージョン 5.6 には 3 つの系統があり，品質を優先する `sol`，品質と応答速度と費用の釣り合いをとる `terra`，高い処理量と短い応答時間に向けた `luna` に分かれる．システムカード [18] によれば，`sol` は 3 つのうちで最も規模が大きい．また，`luna` は 3 つのうちで最も応答が速く，費用が低い．一覧は，ChatGPT アカウントでモデル識別名を 1 つずつ指定して確認したものである．`gpt-5.6` のように系統を付けないモデル識別名は受け付けられない．なお，指定できるモデルの集合は認証の方式によって変わる．本稿は，匿名加工の探索に `gpt-5.6-sol` を用い，構成問題では `gpt-5.6` の 3 つの系統を用いた．

表 A·2 に，指定できる推論強度と，本稿で用いた値を示す．`low` から `max` へ向かうほど，解答の前に費やす推論が増える．

表 A·1　指定できるモデル
Table A·1　Models available in Codex CLI.

Model	Role
`gpt-5.4-mini`	
`gpt-5.4`	
`gpt-5.5`	
`gpt-5.6-luna`	High-throughput, lower-latency
`gpt-5.6-terra`	Balanced quality, latency and cost
`gpt-5.6-sol`	Quality-first flagship

表 A·2　指定できる推論強度
Table A·2　Reasoning effort levels available in Codex CLI.

Value	Used in this paper
`low`	Construction problem
`medium`	Construction problem, anonymization
`high`	Construction problem
`xhigh`	Construction problem
`max`	Construction problem

© 2026 Information Processing Society of Japan

A.2　構成問題の探索の記録

4.2 節の 15 回の試行について，1 回の試行あたりの出力トークン数と，その試行のなかで探索を繰り返した回数を表 A·3 に示す.

表 A·3　構成問題に対する探索の記録

Table A·3　Search records for the construction problem.

Model	Effort	Output tokens	Explorations	Verified
`gpt-5.6-luna`	low	41,709	5	×
	medium	166,350	8	×
	high	3,591,179	15	✓
	xhigh	827,067	8	✓
	max	646,612	4	✓
`gpt-5.6-terra`	low	171,729	6	×
	medium	303,700	5	×
	high	579,908	9	✓
	xhigh	373,056	6	✓
	max	730,836	6	✓
`gpt-5.6-sol`	low	130,946	5	✓
	medium	270,486	4	✓
	high	645,212	8	✓
	xhigh	908,658	6	✓
	max	1,098,406	9	✓

© 2026 Information Processing Society of Japan