Computer Security Symposium 2026
19-23 October 2026

中央差分プライバシーの解釈 2: 誰から何を守るのか？

紀伊 真昇[1,a)]

概要：差分プライバシー (differential privacy, DP) は、データに含まれる個人のプライバシーを保護する安全性指標として注目されている。しかし、その直観的な理解は容易ではなく、なぜ「プライバシー保護」の数理的定義として妥当なのかを理解し説明することは難しい。そのため、DP は長年盛んに研究が行われているにもかかわらず、社会での活用はあまり進んでいない状況にある。本稿では昨年の発表に引き続き、これまでに提案されてきた (Central) DP の解釈を整理する。今回は属性推定攻撃と個人識別を中心に、差分攻撃・再構築攻撃、対数ベイズ因子、所属推定・属性推定問題の関係、ロバストネスを通じて DP の解釈を説明する。本稿は DP のその社会的意義に悩んでいる者、非専門家への DP の説明に困っている者など、DP の初学者にも経験者にも役立つものになると期待している。

An Interpretation of Central Differential Privacy 2: What does it protect, and from whom?

Masanobu Kii[1,a)]

Abstract: Differential privacy (DP) has garnered attention as a security metric for protecting the privacy of individuals whose data is included in a dataset. However, it is not easy to understand DP intuitively, and it is difficult to comprehend and explain why it is a valid mathematical definition of "privacy protection." Consequently, despite many years of research on DP, its practical application in society has made little progress. Following last year's presentation, this paper organizes existing interpretations of (Central) DP. In this paper, we focus on attribute inference attacks and personal identification, and explain the interpretations of DP through differential and reconstruction attacks, the log Bayes factor, the relationship between membership and attribute inference problems, and robustness. We expect this paper to be useful to both beginners and experienced practitioners of DP, including those concerned with the social significance of DP and those who struggle to explain it to non-experts.

1. 導入

差分プライバシー (differential privacy, DP) は、データに含まれる個人のプライバシーを保護する安全性指標として注目されている。しかし、その直観的な理解は容易ではなく、なぜ DP が「プライバシー保護」の数理的定義として妥当なのかを理解し説明することは難しい。数理的な定義を知ることと、その定義が何を意味し、なぜ社会の中で利用する意義があるのかを理解することは別の問題である。本稿の最終的な目標は、DP が「プライバシー保護」の数理的定義としてどのように合理的で妥当なのかを明らかにし、DP の社会的意義についての理解を深めることである。

DP を深く理解するためには、その定義を異なる観点から眺めることが有用である。DP は、攻撃者による推定を制限する性質としても、二つの仮説を区別する能力を制限する性質としても、入力の一部の変化に対する安定性としても見ることができる。このような解釈や別の定式化を通じて、DP が何を保護し、何を保護しないのか、また、定義に現れる各条件がなぜ必要なのかを理解しやすくなる。本稿では DP と同値な定式化だけでなく、DP から導かれる保証、他の概念との関係、直観的な説明まで含めて、広く

[1] NTT 社会情報研究所
NTT Social Infomatics Laboratories
[a)] masanobu.kii@ntt.com

© 2026 Information Processing Society of Japan

This paper is work in progress and not peer-reviewed.

DP の「解釈」と呼ぶ。筆者は前稿 [21] でも同じ問題意識から中央 DP の様々な解釈を整理し、所属推定攻撃、頻度論的・ベイズ的仮説検定、因果関係を通じた解釈などを扱った。しかし、属性推定や個人識別、ロバストネスと DP の関係など、前稿では十分に扱えなかった問題も残っている。

そこで本稿では、初学者や実務者が抱きやすい疑問を FAQ 形式で取り上げ、差分攻撃や再構築攻撃、個人識別、事後処理、攻撃者の背景知識などを通じて DP の保証を説明する。さらに、2+1 択所属推定問題を用いて所属推定・属性推定問題の関係と DP による制約を整理し、ロバストネスとの関係から DP を「統計情報」の性質として見る解釈を紹介する。本稿の貢献は、既存の解釈や研究成果を具体的な疑問と結びつけて日本語で紹介し、個人識別、強い背景知識を持つ攻撃者、DP を「統計情報」の性質として見る解釈について独自の説明・整理を加えることと、所属推定、属性推定など複数の推定問題を 2+1 択所属推定問題を通じて整理し、DP による制約を共通の枠組みから分析することの二点である。

2. 準備

最初の準備として、DP の定義と基本的な事項をまとめる。初学者・非専門家のために二つの大前提を明示しておく。攻撃者に正解を当てられる確率は 0 にはならず、ノーヒントでも当たる可能性がある。またプライバシー保護技術は私秘的情報を隠すことしかできないため、その外で公開した／していた情報に基づく攻撃を防ぐことはできない。

2.1 保護単位と隣接関係

DP を定義するには、何を一単位として保護するかを定める必要がある。本稿ではこれを保護単位と呼ぶ。保護単位は DP 運用者が選択するものであり、保護単位を決めることは、隣接する DB の組をどのように定めることと等価である。

レコードとは複数の値の組 (tuple) であり、データベース (DB) とは同じ項目を持つレコードの多重集合である。隣接する (adjacent, neighboring) DB の組とは、高々一つの保護単位だけ異なる二つの DB の組のことをいう。例えば、一個人に関わる情報をまとめて一つの保護単位としてもよい。言い換えれば、二つの DB に関わる個人が高々一人だけ異なることを、DB が隣接する条件としてもよい。この場合、一個人に関わる複数のレコードをまとめて一つの保護単位として扱うことになる。このような DP は user-level DP と呼ばれる。同様に、DB の一レコードや一属性値を保護単位とするものは、それぞれ record-level DP、attribute-level DP と呼ばれる。

以下では記号を簡単にするため、**一つの保護単位を一つのレコードとして表す**。以下のレコードは実際の DB の一レコードに限らず、一個人に関わる情報や一属性値と読み替えてもよい。

また、一つの保護単位だけ異なる DB の組にも二通りある。一レコードを追加・削除した DB の組を隣接させるものを unbounded DP [7, 14]、一レコードを書き換えた DB の組を隣接させるものを bounded DP [9, 14] と呼ぶ。以下では主に**unbounded record-level DP**を扱い、必要に応じて bounded DP にも言及する。

2.2 データベースのモデルと記法

有効なレコード値の集合を $\mathbb{V}$ とする。また $\perp(\notin \mathbb{V})$ を、レコードが存在しないことを表す無効値 (null value) とする。$\perp$ は、unbounded DP におけるレコードの不在を、通常の属性値と同じ確率変数の値として扱うために導入する。

N 個のレコードスロットを考え、i 番目のレコードの確率変数を $\mathbf{R}_i \in \mathbb{V} \cup \{\perp\}$ $(i = 1, \ldots, N)$、その実現値を $\mathtt{R}_i \in \mathbb{V} \cup \{\perp\}$ とする。DB の確率変数とその実現値をそれぞれ

$$\mathbf{DB} = (\mathbf{R}_1, \ldots, \mathbf{R}_N), \qquad \mathtt{DB} = \{\{\mathtt{R}_1, \ldots, \mathtt{R}_N\}\}$$

と書く。$\mathbf{DB}, \mathtt{DB}$ はいずれも大きさ N で $\perp$ を含みうるが、値が $\perp$ であるレコードスロットは処理する際には無視される。

本稿を通じて $\mathcal{M}$ を DB を入力とするランダム写像 $\mathcal{M}\colon \mathbb{X} \to \mathbb{Y}$ とし、$\varepsilon \in [0, \infty]$, $\delta \in [0, 1]$ とする。ここでランダム写像は、入力 $\mathtt{DB} \in \mathbb{X}$ で添字付けられた $\mathbb{Y}$ 上の確率変数である。攻撃・推定問題では、$\mathcal{M}(\mathbf{DB})$ を観測し、$\mathbf{DB}$ またはその一部について推定する状況を考える。

2.3 DP の定義

以下では、分析者のみを信頼しないモデル（中央モデル）だけを扱う。

定義 2.1 ([8])**.** DB を入力とするランダム写像 $\mathcal{M}\colon \mathbb{X} \to \mathbb{Y}$ を考える。部分集合 $S \subseteq \mathbb{Y}$ について $\mu_{\mathtt{DB}}(S) = \Pr[\mathcal{M}(\mathtt{DB}) \in S]$ とおく。$\mathcal{M}$ が (ε, δ)-DP を満たす（与える）とは、任意の隣接 DB の組 $(\mathtt{DB}_1, \mathtt{DB}_2)$ と任意の $S \subseteq \mathbb{Y}$ について、

$$\mu_{\mathtt{DB}_1}(S) \le e^{\varepsilon} \mu_{\mathtt{DB}_2}(S) + \delta \tag{1}$$

が成り立つということ。DP を満たすランダム写像を DP メカニズムと呼ぶ。□

$\delta = 0$ のときは *pure* DP, $\delta > 0$ のときは *approximate* DP という。断りがない限り、**本稿では pure DP に絞って**解釈を検討する。

2.4 対数ベイズ因子

以下では記法を簡単にするため、観測出力を ω と書く。連続出力の場合、$\Pr[\omega \mid \cdot]$ は適切な基準測度に関する確率密度（より一般には Radon–Nikodym 微分）と読み、主張はほとんど至る所で成り立つものとする。

© 2026 Information Processing Society of Japan

本稿で繰り返し用いる対数ベイズ因子を導入する。仮説 H_0, H_1 について、事前知識 π を持つ者が追加情報 ω を得たとき、

$$\begin{aligned}&\log \mathrm{BF}_{\pi,\omega}[H_0 : H_1]\\ &:= \log \frac{\Pr[H_0 \mid \omega, \pi]}{\Pr[H_1 \mid \omega, \pi]} - \log \frac{\Pr[H_0 \mid \pi]}{\Pr[H_1 \mid \pi]}\\ &= \log \frac{\Pr[\omega \mid H_0, \pi]}{\Pr[\omega \mid H_1, \pi]}. \end{aligned} \tag{2}$$

$\log \mathrm{BF}_{\pi,\omega}[H_0 : H_1] > 0$ なら追加情報 ω は H_1 より H_0 を支持し、$\log \mathrm{BF}_{\pi,\omega}[H_0 : H_1] < 0$ ならその逆である。

2.5 対数ベイズ因子による DP の定式化

DP は対数ベイズ因子を用いて次のように定式化できる [21, 15]。レコード確率変数 $\mathbf{R}_1, \ldots, \mathbf{R}_N$ が互いに独立で、各値 $z \in \mathbb{V} \cup \{\bot\}$ が正の確率を持つ事前分布 π 全体の集合を $\mathbb{PD}$ とする。また、標的レコード $\mathbf{R}_\star$ を $\mathbf{R}_1, \ldots, \mathbf{R}_N$ のいずれか一つとする。

定理 2.2 ([15] 定理 6.1)**.** ランダム写像 $\mathcal{M}\colon \mathbb{X} \to \mathbb{Y}$ が ε-DP であることと、任意の標的レコード $\mathbf{R}_\star$、値 $z \in \mathbb{V}$、事前分布 $\pi \in \mathbb{PD}$、可能な出力 $\omega \in \mathbb{Y}$ について

$$-\varepsilon \le \log \mathrm{BF}_{\pi,\omega}[\mathbf{R}_\star = z : \mathbf{R}_\star = \bot] \le \varepsilon \tag{3}$$

が成り立つことは同値である。□

すなわち DP は、出力 ω による「標的レコードの値が z である」と「存在しない」の間の対数ベイズ因子の絶対値を ε 以下に制限する。

補題 2.3 (事後 log-odds の更新)**.** $\mathrm{logit}(p) := \log(p/(1-p))$ とする。互いに排反で、正の事前・事後確率を持つ仮説 H_0, H_1 について、

$$\begin{aligned} p &:= \Pr[H_0 \mid \pi, H_0 \cup H_1],\\ p_\omega &:= \Pr[H_0 \mid \omega, \pi, H_0 \cup H_1] \end{aligned}$$

とする。$-\eta \le \log \mathrm{BF}_{\pi,\omega}[H_0 : H_1] \le \eta$ ならば、

$$|\mathrm{logit}(p_\omega) - \mathrm{logit}(p)| \le \eta, \tag{4}$$

$$\frac{e^{-\eta} p}{e^{-\eta} p + 1 - p} \le p_\omega \le \frac{e^{\eta} p}{e^{\eta} p + 1 - p} \tag{5}$$

が成り立つ。□

対数ベイズ因子の定義から直ちに従う。以降、本稿でこの特徴付けを用いるときは、事前分布 $\pi \in \mathbb{PD}$ を仮定する。

3. Q. 統計値だけから個人の情報が分かるの？

統計情報を一般公開しても個人のリスクにならない、というのは常識的な感覚だと思われる。確かに、何も知らない攻撃者が、例えば 100 人についての平均値一つを手に入れただけでは、具体的な個人について正確に推定することは理論的にも難しい。それなのになぜわざわざノイズを加えるのか、というのは DP への尤もな反発である。

しかし、複数の統計値を組み合わせたり、攻撃者が持つ補助情報と組み合わせたりすると、公開された統計情報だけから個人についての情報を得られることがある。中には、個人の属性を確率的に推定するだけでなく、不確定性のない推定結果が求められる場合もある。以下ではその具体例を紹介する。

3.1 差分攻撃

一人だけ異なる二つの集団について統計値が公開されれば、その差から一人分の情報を取り出せることがある。例えば

$$\mathtt{DB}_2 = \mathtt{DB}_1 \cup \{\{\mathtt{R}_\star\}\}$$

であり、それぞれのレコード数と平均値が公開されていれば、

$$|\mathtt{DB}_2| q_{\mathrm{mean}}(\mathtt{DB}_2) - |\mathtt{DB}_1| q_{\mathrm{mean}}(\mathtt{DB}_1) = \mathtt{R}_\star$$

から、追加された個人の値を正確に計算できる。計数についても同様に、条件 S を満たす人数を $q_{\mathrm{count},S}(\mathtt{DB})$ とすれば、

$$q_{\mathrm{count},S}(\mathtt{DB}_2) - q_{\mathrm{count},S}(\mathtt{DB}_1) = [\![\mathtt{R}_\star \in S]\!]$$

となり、その個人が条件 S を満たすか否かが確定する。

3.2 秘匿セルの補完推論

集計表の一部を秘匿しても、他の公開値から秘匿値を正確に計算できる場合がある。例えばある行の合計が 8 で、秘匿された一セル以外の合計が 7 なら、秘匿セルの値は 1 であると確定する。そのセルに該当する人物が補助情報から一人に絞られていれば、その人物の属性についても確定的な情報が得られる。

3.3 Downcoding attack

k 匿名化では、年齢を範囲にまとめるなど、値を一般化することでレコードを区別しにくくすることがある。しかし、必要最小限だけ一般化する場合、「これ以上細かくすると k 匿名性を満たさない」という事実自体が情報を漏らす。Cohen はこの性質を利用して元の値を復元する downcoding attack を示した [4]。データ分布と一般化階層によっては、全レコードの全属性を任意に高い確率で復元できることまで実例で示された。この他にも k 匿名化に対する攻撃は存在している。

3.4 再構築攻撃

多数の統計値から DB 中の多数のレコードを同時に復元する再構築攻撃（reconstruction attack）が知られている [6]。実際、2010 年米国国勢調査で公開された 34 種類の集

© 2026 Information Processing Society of Japan

計表だけから、約 9700 万人分について、国勢調査ブロック、性別、年齢区分、人種、民族からなる個人レコードを再構築できた事例が報告されている [2]。しかも、これらが属する国勢調査ブロックでは、公開された集計値と整合する個票集合が一意に定まることまで確認されている。この再構築リスクは、米国国勢調査局が 2020 年国勢調査で差分プライバシーに基づく新しい開示制御方式を導入した主要な背景の一つとなった [1]。

3.5 公開モデルからの属性推定

公開されるものが単純な集計値ではなく、DB から学習されたモデルであっても個人情報の推定に利用されうる。モデル反転攻撃（model inversion attack）は、公開モデルと標的についての補助情報を組み合わせ、標的について公開されていない属性などを推定する攻撃である [11]。

以上の例が示すように、個票そのものを公開しなくても、複数の統計的な出力と補助情報を組み合わせることで個人レベルの情報が得られることがある。したがって、統計値を公開すること自体が常に安全なのではなく、各個人の情報が公開結果にどの程度影響するかを制御する必要がある。

4. Q.DP は個人識別を防げるの？

個人情報保護法では、ある情報が「特定の個人を識別することができる」かどうかが、その情報が個人情報に該当するかを分ける重要な基準の一つとなっている。（以下、ある情報が個人を識別できる情報を含むことを、個人識別性と呼ぶ。）個人に関する情報を他者に渡してよいかを判断する場面でも、個人識別性は広く用いられている[*1]。

したがって、DP がプライバシー保護の定式化だと言うなら、個人の識別を防げると期待されるのは自然だろう。しかし数理的に定義されている DP と違い、そもそも個人識別性は解釈の余地を大きく残す概念である。この節では個人識別性の詳細な定式化には踏み込まず、「あなたが思う個人識別」がどのようなものなら DP で制御出来るのか、説明する。以下では文章・文書で表される情報（散在情報）ではなく、個人に関わるデータの形式を揃えてまとめたデータベースに限定して話を進める。この節では DB のレコードと一個人の情報の束を区別する[*2]。

4.1 個人識別性の分析

宇賀は次のように個人識別と特定を説明している [20, p.60]。

> 個人を識別できるとは，誰か 1 人の情報であることが分かることを意味し，特定の個人を識別できるとは，識別される個人が誰か分かることを意味する。

一方で、欧州データ保護会議 (EDPB) は個人識別を次のように説明している [10] [*3]。

> To identify a natural person means to distinguish them from others within a given context consequently making it possible to treat them differently from those other people. (para.19)

宇賀の説明も、単に 1 人か 2 人かという問題ではなく、その個人を他の者から区別できることを含意していると理解するのが良いだろう。逆に個人識別できないとは、誰かの情報と別人の情報の区別ができない、境界線が引けないということである。なお、本節冒頭で例示した規定で扱われるのは特定であって、本稿で扱う個人識別性はそれより真に弱い条件であり、かつ識別ができなければ特定もできない。

以下では、DP と個人識別の関係を考えるために、国内外の主要な文献に共通して見られる個人識別性の特徴を 4 点だけピックアップする。

第一に、個人識別や個人特定の判断は常に機械的に行えるものではなく、一般には「社会通念上、一般人の判断力や理解力」[19, Q1-1] に基づく規範的判断であることに注意が必要である。例えば、同姓同名の者が存在する可能性があっても、「氏名のみであっても、社会通念上、特定の個人を識別することができるものと考えられ」る [19, Q1-2]。

第二に、個人識別性は得られた DB 内部の情報だけで判断できるものではない。個人識別性は、判断主体が背景知識、文脈及び当該主体が合理的に利用し得る識別手段 (perspective) に依存する。例えば「食券番号 A123 の客」というだけでは誰のことかわからないが、その客がいた飲食店と日時という背景情報が加われば、これにも個人識別性があることになる。そのため、情報の個人識別性を明文化しようとするなら、判断主体、事前知識、文脈を明示する必要がある。なお、判断者がどんな情報を入手できるのかという判断も規範的に行われる。

第三に、加工された DB・レコードの個人識別性には、レコードと個人の対応関係について判断主体が合理的に知り得る情報が関わる場合がある。実現した DB において、あるレコードの値が一意であれば、そのレコードを他のレコードから区別することはできる。しかし、例えばある DB のレコードが全て互いに異なるとしても、一レコードが一人分の情報だけから作られた場合と、一レコードが統計値から作られた場合、判断は異なるだろう。こうした判断は元 DB についての推定を必要とし、その推定は同じ事前知識や文脈であっても、判断主体によって異なる可能性が残されている。

[*1] この例としては、個人情報保護法における匿名加工情報の定義、行政機関情報公開法における個人に関する情報の不開示規定、「人を対象とする生命科学・医学系研究に関する倫理指針」における試料・情報の提供に関する規定などがある。

[*2] EDPB ガイドライン [10] でも同様の区別がされる。

[*3] 本稿執筆時点で EDPB ガイドライン [10] は public consultation のために採択された版であり、今後変更される可能性がある。

© 2026 Information Processing Society of Japan

最後に、判断主体が加工後の出力とは独立に既に個人を識別できる場合、出力データの加工によってその識別能力そのものを消去することはできない。加工メカニズムが制御できるのは、加工後の出力が判断主体の個人識別能力に与える追加の寄与である。

4.2 どのような個人識別なら DP で制御できるのか

前節では、個人識別性の具体的な定式化には判断主体や背景知識、文脈を明示する必要があると述べた。ここでは個人識別性を一つの方法で定式化するのではなく、どのような定式化であれば DP によって制御できるのかを考える。

前節の通り、加工済み DB についての個人識別性の判断には、背景知識、文脈、実現した加工済み DB と、その元となった DB についての推定が必要となる。そこで攻撃者が $\mathcal{M}$ の出力を受け取り、何らかの推定や判断を行うことを考える。攻撃者の背景知識や文脈を固定し、それらを含めた攻撃者の処理をランダム写像 $\mathcal{A}\colon \mathbb{Y} \to \mathbb{A}$ で表す。$\mathcal{A}$ の出力は、例えば「このレコードは個人 i に対応する」という推定でも、「i を調査する」「i に特定の広告を表示する」といった処置でもよい。また、個人識別では保護単位（2.2 節）が一個人となる。

個人識別性を定式化するなら、少なくとも上記のような大枠に従うことになるだろう。ここで DP の事後処理定理 [8] によると、ランダム写像 $\mathcal{M}$ が DP を与えるならば、合成ランダム写像 $\mathcal{A}(\mathcal{M}(-))$ も DP を与える。したがって、個人識別性が、一個人の情報の有無や書き換えによって攻撃者の推定又は処置の分布がどの程度変化するかという形で定式化されているなら、その変化は DP によって制御される。このように抽象的な主張をするだけなら、攻撃者の推定または処置の定式化を一つに固定する必要はない。

5. Q. どの情報に DP 保護処理をすればいいの？

筆者が非専門家に差分プライバシーの運用を指導するとき、どんなときにどこにノイズを加えなくてはならないのか、というのは最も頻繁に聞かれる質問である。また、差分プライバシーの運用で最もよく見かける失敗も、保護処理の漏れである。

原則はそこまで難しくない。保護処理を加えなくてはならないものは、信頼できない者に見える情報・データのうち、入力 DB を変えたことに伴って変わるもの全てである。筆者はこの判断のために、入力 DB の値を参照するデータ・情報・処理を起点に、入力 DB の変化が順々に伝播していくイメージを利用している。

保護すべき情報を見つけるときに「これは個人情報らしい値か」と考えると判断に失敗する。例えばレコード数、結果の表示・非表示、エラーなども、入力 DB の変化によって変わり得るなら、保護対象になるかどうか考える必要がある。他にも、珍しい値（外れ値）を削除したりまとめる処理も一見保護を強めそうだが、入力 DB の値を参照して処理するかどうかを決めているので、漏洩のきっかけになりうる。

ただし、それぞれに個別にノイズを加える必要があるわけではなく、信頼できない者から観測できる出力全体が DP を満たせばよい。また、既に DP で保護された出力だけから作られるデータは、追加の保護処理を必要としない。

6. Q. なぜ強い攻撃者を想定するの？

非専門家にとって（おそらく専門家にとっても）「ε-DP が与える保護の強度」をそのまま感覚的に理解するのは難しい。代替案として攻撃成功率を用いることができるが、その計算には攻撃者の背景知識を指定しなくてはならない。

よく使われるのが、攻撃者が標的レコードを除いて DB 中の全てのレコードを知っているとする設定である。本稿ではこれを LTO (leave target out) 設定と呼ぶことにする。これは DB 中の他のレコードについてほぼ最大限の背景知識を与えるため、非現実的で、プライバシー予算を無駄に小さくする設定にも見える。以下に LTO 設定を用いる理由を 4 つ挙げる。

1 つ目は、安全側に倒したデフォルト設定として使えることである。現実の背景知識を精緻に定めるには外部情報や属性間の相関を調査する必要があり、その設定にも恣意性が入る。LTO 設定は単純かつ一意に定まり、攻撃者の背景知識を過小評価する危険も小さい。

2 つ目は、DP の保証と攻撃成功率を結びつけやすいことである。標的以外のレコードを固定すれば、残る不確実性をほぼ標的レコードに限定でき、「標的が存在する DB」と「存在しない DB」のような隣接 DB に対応する仮説を直接比較できる。

3 つ目は、保護の強さを示すデモンストレーションに適していることである。あえて常識はずれの強い攻撃者の下でも攻撃が難しいことを示す設定として、LTO 設定は説明しやすい。

4 つ目は、内部攻撃者や監査者を考えれば必ずしも非現実的ではないことである。標的以外のデータへのアクセス権を持つ内部者や、元 DB を保有して最悪に近い条件で評価する監査者では、LTO に近い背景知識を想定できる。ただし、標的の生データ自体を直接読めるのであれば、DP による出力保護以前の問題である。

もっとも、LTO 設定は攻撃者モデルの一つにすぎず、目的に合わなければ、より現実的な背景知識を設定してよい。2.5 節の対数ベイズ因子や Pufferfish Privacy [15] を用いれば、自身で作成した背景知識・事前分布に基づいて攻撃成功確率を評価できる。最後に、DP の定義自体は特定の背景知識を仮定しておらず、攻撃成功確率を計算したい人だけが背景知識を仮定する必要があることを付言しておく。

© 2026 Information Processing Society of Japan

7. Q. 所属推定・属性推定と DP はどう関係するの？

この節では、所属推定問題と属性推定問題及びその変種を分析するために、よりプリミティブな 2+1 択所属推定問題を導入する。この問題から各推定問題への還元関係を示し、最後に DP がこれらの推定に課す制限を説明する。

7.1 2+1 択所属推定問題の導入

定義 7.1 (2+1 択所属推定問題)**.** 秘密を表す確率変数を $\mathbf{R}_\star \in \mathbf{DB}$ とし、$\mathbf{R}_\star$ は $\mathbb{V} \cup \{\perp\}$ に値を取るとする。回答者には $\mathbf{R}_\star$ が $\mathbf{DB}$ のいずれのレコードであるかは知らされず、補助情報 π、観測情報 ω、候補値 $z \in \mathbb{V}$ が与えられる。回答者は $z, \perp, \boxtimes$ のうち一つを回答せよ。真の値が z 又は $\perp$ ならそれと一致した回答を、どちらでもなければ $\boxtimes$ を正解とする。□

$\boxtimes$ は、z と $\perp$ のどちらかを選ぶ確信がなく棄権する場合と、真の値が両者のどちらでもないと判断する場合に用いる。仮説検定では主に前者、以下のオラクル（神託機械）では後者の意味で用いる。

レコードの確率変数 $\mathbf{R}_i$ についての 2+1 択所属推定問題の正解を教えてくれるオラクルを定義する。真の値 $\mathtt{R}_i \in \mathbb{V} \cup \{\perp\}$ を保持し、

$$\mathcal{O}_{\mathbf{R}_i}(z) \coloneqq \begin{cases} z & (\mathtt{R}_i = z), \\ \perp & (\mathtt{R}_i = \perp), \\ \boxtimes & (\mathtt{R}_i \notin \{z, \perp\}) \end{cases} \tag{6}$$

を返すものを 2+1 択レコード推定オラクルと呼ぶ。

ベイズ仮説検定に基づいて 2+1 択所属推定問題に回答するならば、閾値 $\tau (> 0)$ を設定し、対数ベイズ因子 $\log \mathrm{BF}_{\pi,\omega}[\mathbf{R}_\star = z : \mathbf{R}_\star = \perp]$ が τ を超えれば z、$-\tau$ を下回れば $\perp$、それ以外では棄権する、という戦略にするのが自然だろう。定理 2.2 より、$\mathbf{R}_\star = z$ 対 $\mathbf{R}_\star = \perp$ の対数ベイズ因子の絶対値は ε 以下であるから、もし $\tau \geq \varepsilon$ なら、このような回答者は常に棄権 $\boxtimes$ を選ぶ。

7.2 2+1 択所属推定問題から所属推定問題へ

所属推定 (membership inference) 攻撃の標準的な説明は、次の「値の所属推定問題」を解く攻撃というものである。なお、この呼び名は本稿限りのものであり、記号については 2.2 節を参照されたい。

定義 7.2 (値の所属推定問題)**.** 背景知識、出力 $\omega \leftarrow \mathcal{M}(\mathtt{DB})$、値 $z \in \mathbb{V}$ が与えられたとき、秘密の DB $\mathbf{DB}$ について、$z \in \mathbf{DB}$ と $z \notin \mathbf{DB}$ のどちらが正しいか当てよ。□

しかし、実際に定式化・解析されるのは次の問題である。

定義 7.3 (（いわゆる）所属推定問題)**.** 2+1 択所属推定問題において $\mathbf{R}_\star \in \{z, \perp\}$ であることが保証され、$z, \perp$ のいずれかを回答する問題を所属推定問題と呼ぶ。回答が真の値と一致したときに限り正解とする。□

背景知識としてはレコードの分布、$\mathbf{R}_\star = \perp$ の確率、$\mathcal{M}$ の詳細などを与えるのが標準的であり、既存のゲームも、背景知識とレコードの作り方を除けば、この問題に対応する [17, 16]。

命題 7.4 (所属推定への還元)**.** (i) 2+1 択所属推定問題のオラクルを 1 回用いると所属推定問題が解ける。
(ii) DB のレコードスロット数を N とすると、同オラクルを N 回用いて値の所属推定問題が解ける。
□

Proof. (i) では候補 z への回答をそのまま返せばよい。(ii) では各 i について $\mathcal{O}_{\mathbf{R}_i}(z)$ へ問い合わせ、一つでも z が返れば $z \in \mathbf{DB}$ と回答すればよい。□

同様に、所属推定問題のオラクルを N 回用いても値の所属推定問題を解くことができる。

7.3 2+1 択所属推定問題から属性推定問題へ

定義 7.5 (属性推定問題)**.** 標的レコード $\mathbf{R}_\star \in \mathbf{DB}$ について $\mathbf{R}_\star \neq \perp$ が保証され、回答者には $\mathbf{R}_\star$ の一部の属性を含む補助情報 π と観測情報 ω が与えられる。回答者は $\mathbf{R}_\star$ を推定し、$\mathbb{V}$ の要素を一つ回答せよ。回答が真の値と一致したときに限り正解とする。□

この定義は既存の属性推定ゲーム [18, 16] を参照している。通常は一部の属性を既知、残りを秘密とするが、上の定義では標的レコード全体を秘密とし、既知属性を補助情報に含めた。以下では値が離散的な場合を扱う。

定義 7.6 (2+1 択属性推定問題)**.** $\mathbf{R}_\star \neq \perp$ であり、異なる候補 $a, b \in \mathbb{V}$ が与えられるが、$\mathbf{R}_\star \in \{a, b\}$ と保証されないとする。回答者は $a, b, \boxtimes$ のうち一つを回答し、真の値が a 又は b ならそれと一致した回答を、どちらでもなければ $\boxtimes$ を正解とする。□

この問題は Jayaraman と Evans の sensitive value inference attack [13] と似ているが、定式化は異なる。

命題 7.7 (属性推定への還元)**.** 標的レコードの候補を $z_1, \ldots, z_C$ とし、$\mathbf{R}_\star \in \{z_1, \ldots, z_C\}$ であることが保証されているとする。
(i) 2+1 択所属推定問題のオラクルを C 回用いると属性推定問題が解ける。
(ii) 同オラクルを 2 回用いると 2+1 択属性推定問題が解ける。
(iii) 2+1 択属性推定問題のオラクルを $\binom{C}{2}$ 回用いると属性推定問題が解ける。
□

Proof. (i) では各 j について $\mathcal{O}_{\mathbf{R}_\star}(z_j)$ に問い合わせ、z_j を返したものを回答する。(ii) では $\mathcal{O}_{\mathbf{R}_\star}(a), \mathcal{O}_{\mathbf{R}_\star}(b)$ に問い合

© 2026 Information Processing Society of Japan

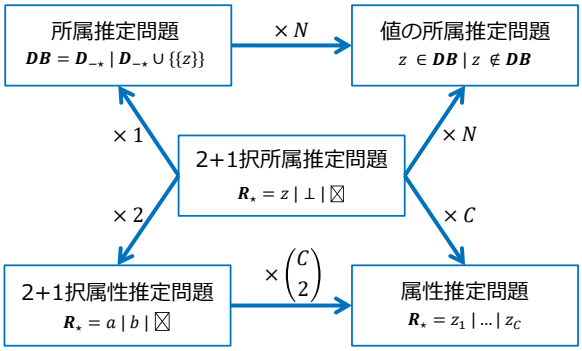


図 1 7 節で定義した各種推定問題の間の還元関係。$X \xrightarrow{\times n} Y$ は X 形の問題を n 回解けば 1 つの Y が解けることを意味する。

わせ、両方が $\boxtimes$ なら棄権し、さもなくばオラクル応答のうち $\boxtimes$ ではない方を回答する。(iii) も同様に全ての候補対を問い合わせればよい。 □

以上で示した還元関係を図 1 にまとめた。

7.4 各種推定問題に DP が課す制限

還元関係だけでは DP が各推定問題を解く能力も制限すると結論できないため、定理 2.2 と補題 2.3 から直接調べる。

系 7.8 (各種推定問題への制限)**.** unbounded ε-DP を満たすメカニズムの出力について、次が成り立つ。

(i) 所属推定では、$\mathbf{R}_\star = z$ 対 $\mathbf{R}_\star = \perp$ の事後 log-odds の更新量は ε 以下である。

(ii) 任意の異なる $a, b \in \mathbb{V}$ について、$-2\varepsilon \le \log \mathrm{BF}_{\pi,\omega}[\mathbf{R}_\star = a : \mathbf{R}_\star = b] \le 2\varepsilon$ である。

(iii) 候補が $z_1, \ldots, z_C$ の属性推定では、各 z_j について、$\mathbf{R}_\star = z_j$ 対「$\mathbf{R}_\star$ が他の候補値である」の事後 log-odds の更新量は 2ε 以下である。

□

Proof. (i) は定理 2.2 から直ちに従う。(ii) の対数ベイズ因子は、a 対 $\perp$ と b 対 $\perp$ の対数ベイズ因子の差である。(iii) では「他の候補値」の尤度比が各候補値の尤度比の重み付き平均になるため、同じ 2ε が得られる。 □

(ii) は unbounded ε-DP が bounded 2ε-DP を含意することの証明でもある。証明もちょうど、1 レコードの値を書き換える操作が、1 レコードを追加／削除する操作を 2 回行えば実現できることに対応している。

一方で、値の所属推定問題は、候補値 z を 1 個以上最大 N 個含む DB と、一つも含まない DB を区別する問題である。もしも多数のレコードが同じ値 z を持つなら、「DB に z が含まれている」は DP が保護する個人の秘密ではなく、集団の傾向である。したがって、DP メカニズムの出力から値の所属問題の正解を、確信を持って推定できても不思議ではない。

8. ロバストネスと「統計量」を通じた DP の解釈

前稿 [21] で紹介できなかった DP の解釈を紹介する。

学問的な文脈を離れて、「統計」という言葉の意味を総務省・各自治体の子供向けサイトや辞書を調べたところ、いずれもおおよそ次のような紹介をしていた：統計とは、ある集団・多数の対象について調べてその性質・特徴を数値として表したもの。これは統計全体の説明だが、情報を圧縮・削減して集団・多数の対象の（安定した）全体像を見るためのツール、という側面もある。代表的な統計量だけでなく、次元削減やクラスタリングなどもこの説明に当てはまる。

さて、集団の記述・要約であれば、多くの人間のことを陰に陽に反映しなければ価値がない。一方で、少数の人間に大きく影響されるものであっては「集団」らしさがない。統計は、少数の人間が変わっても大きく変わらないものであってほしい。この期待は、統計量を公開しても個人のリスクにならないという常識的な感覚とも繋がっている。

このような、入力となる集団（DB）が少し変わっても出力の値があまり変わらないという性質は、ロバストネスと呼ばれる。一方で、DP は入力 DB が少し変わっても出力の分布が変わらないという性質である。これらは似ているが、扱っているものが違うので、両者が同値という関係にはない。

2023 年に独立に発表された 2 つの研究 [12, 3] で、DP とロバストの正確な関係が明らかになった。以下でこれを紹介する。本節では文献 [12, 3] に合わせ、1 レコードの置換を隣接関係とする bounded DP を考える。

ロバストネスを正確に定義するために、入力 DB を少し変える操作を定式化する。

定義 8.1 (strong contamination model)**.** 分布 P から独立同分布に生成した DB $\mathtt{DB} \sim P^N$ に対し、$\mathtt{DB}$ 全体を観測した後、そのうち高々 τN 個の値を任意に置換して汚染 DB $\mathtt{DB}'$ を生成するモデルを、汚染率が高々 τ の strong contamination model と呼ぶ。□

これは現代的な高次元ロバスト統計学で標準的なモデルである。これを用いてロバスト推定器を定義する。

定義 8.2 (ロバスト推定器)**.** 推定対象（母数・汎関数）$\mu(P)$ の推定アルゴリズム A が分布 P に対するロバスト推定器であるとは、$\mathtt{DB} \sim P^N$ および A の内部乱数に関して確率 $1-\beta$ 以上で次が成り立つということ：汚染率が高々 τ の strong contamination model で得られる任意の汚染 DB $\mathtt{DB}'$ に対して $\|A(\mathtt{DB}') - \mu(P)\| \le \alpha$。□

これらの定義の元でロバストネスと DP の関係が確立される。

定理 8.3 (informal, [12, 3])**.** 精度保証を持つ DP 推定器は、上記の意味でロバスト推定器でもある。また、一定の

© 2026 Information Processing Society of Japan

条件の下でロバスト推定器から DP 推定器を構成できる。□

したがって、「統計量」に期待される性質は、DP により保証し強制できる、と考えることもできるだろう。ただし、オリジナルの DP は最悪ケースだけ考える極端なところがある。上記で考えた日常的な意味の「統計量」をモデル化するなら、Bayesian DP などの DP の変種 [5] を考えたほうが穏当かもしれない。

9. 結論

本稿では、中央 DP の社会的意義と数理的保証について、初学者や実務者が抱きやすい疑問に沿って整理・解説した。また、2+1 択所属推定問題を通じて所属推定・属性推定への制約を整理し、ロバストネスとの関係から DP を「統計情報」の性質として見る解釈を示した。

今後の課題としては、プライバシーパラメータ ε, δ の現実的な運用指針の構築が挙げられる。本稿がそのような取り組みの一助となり、DP の実装と社会への応用がより進むことを期待する。

参考文献

[1] John M. Abowd. “The U.S. Census Bureau Adopts Differential Privacy”. In: *Proceedings of the 24th ACM SIGKDD International Conference on Knowledge Discovery & Data Mining*. 2018, p. 2867. DOI: 10.1145/3219819.3226070.

[2] John M. Abowd et al. “A Simulated Reconstruction and Reidentification Attack on the 2010 U.S. Census”. In: *Harvard Data Science Review* 7.3 (2025). DOI: 10.1162/99608f92.4a1ebf70.

[3] Hilal Asi, Jonathan Ullman, and Lydia Zakynthinou. “From Robustness to Privacy and Back”. In: *Proceedings of the 40th International Conference on Machine Learning*. The 40th International Conference on Machine Learning (ICML). 2023, pp. 1121–1146.

[4] Aloni Cohen. “Attacks on Deidentification’s Defenses”. In: *31st USENIX Security Symposium (USENIX Security 22)*. 2022, pp. 1469–1486. URL: https://www.usenix.org/conference/usenixsecurity22/presentation/cohen.

[5] Damien Desfontaines and Balázs Pejó. “SoK: Differential Privacies”. 2020. arXiv: 1906.01337 [cs].

[6] Irit Dinur and Kobbi Nissim. “Revealing Information While Preserving Privacy”. In: *Proceedings of the Twenty-Second ACM SIGMOD-SIGACT-SIGART Symposium on Principles of Database Systems*. 2003, pp. 202–210. DOI: 10.1145/773153.773173.

[7] Cynthia Dwork. “Differential Privacy”. In: *Automata, Languages and Programming*. Ed. by Michele Bugliesi et al. 2006, pp. 1–12. DOI: 10.1007/11787006_1.

[8] Cynthia Dwork and Aaron Roth. “The Algorithmic Foundations of Differential Privacy”. In: *Foundations and Trends® in Theoretical Computer Science* 9.3–4 (3–4 2014), pp. 211–407. DOI: 10.1561/0400000042.

[9] Cynthia Dwork et al. “Calibrating Noise to Sensitivity in Private Data Analysis”. In: *Theory of Cryptography*. Ed. by Shai Halevi and Tal Rabin. 2006, pp. 265–284. DOI: 10.1007/11681878_14.

[10] European Data Protection Board. *Guidelines 02/2026 on Anonymisation*. Guidelines 02/2026. Version 1.0. 2026. URL: https://www.edpb.europa.eu/system/files/2026-07/edpb_guidelines_202602_anonymisation_v1_en_0.pdf (visited on 08/13/2026).

[11] Matthew Fredrikson et al. “Privacy in Pharmacogenetics: An End-to-End Case Study of Personalized Warfarin Dosing”. In: *Proceedings of the 23rd USENIX Conference on Security Symposium*. 2014, pp. 17–32.

[12] Samuel B. Hopkins et al. “Robustness Implies Privacy in Statistical Estimation”. In: *Proceedings of the 55th Annual ACM Symposium on Theory of Computing*. 2023, pp. 497–506. DOI: 10.1145/3564246.3585115.

[13] Bargav Jayaraman and David Evans. “Are Attribute Inference Attacks Just Imputation?” In: *Proceedings of the 2022 ACM SIGSAC Conference on Computer and Communications Security*. 2022, pp. 1569–1582. DOI: 10.1145/3548606.3560663.

[14] Daniel Kifer and Ashwin Machanavajjhala. “No Free Lunch in Data Privacy”. In: *SIGMOD ’11*. 2011. DOI: 10.1145/1989323.1989345.

[15] Daniel Kifer and Ashwin Machanavajjhala. “Pufferfish: A Framework for Mathematical Privacy Definitions”. In: *ACM Transactions on Database Systems* 39.1 (1 2014), pp. 193–204. DOI: 10.1145/2514689.

[16] Ahmed Salem et al. “SoK: Let the Privacy Games Begin! A Unified Treatment of Data Inference Privacy in Machine Learning”. In: *2023 IEEE Symposium on Security and Privacy (S&P)*. 2023, pp. 327–345. DOI: 10.1109/SP46215.2023.10179281.

[17] Samuel Yeom et al. “Privacy Risk in Machine Learning: Analyzing the Connection to Overfitting”. In: *2018 IEEE 31st Computer Security Foundations Symposium (CSF)*. 2018, pp. 268–282. DOI: 10.1109/CSF.2018.00027.

[18] Benjamin Zi Hao Zhao et al. “On the (In)Feasibility of Attribute Inference Attacks on Machine Learning Models”. In: *2021 IEEE European Symposium on Security and Privacy (EuroS&P)*. 2021, pp. 232–251. DOI: 10.1109/EuroSP51992.2021.00025.

[19] 個人情報保護委員会. **「個人情報の保護に関する法律についてのガイドライン」に関する** *Q&A*. 2025. URL: https://www.ppc.go.jp/personalinfo/faq/APPI_QA/.

[20] 宇賀克也. **新・個人情報保護法の逐条解説**. 3rd ed. 有斐閣, 2021. 1068 pp.

[21] 紀伊 真昇. “中央差分プライバシーの解釈：整理と提案”. In: コンピュータセキュリティシンポジウム 2025 (CSS2025). 2025, pp. 338–345.

© 2026 Information Processing Society of Japan