# $\varepsilon = 19.61$ は何を意味するのか：操作的等価 $\varepsilon$ に基づく 2020 年米国国勢調査のプライバシー保証の再評価

寺田 雅之[1,2]　伊藤 伸介[3]

**概要**：差分プライバシー (DP) の拡張である zCDP や GDP が与えるプライバシー保証の強さは，DP の保証の強さを表す $\varepsilon$ とそのまま比較することはできない．そのため，これらが与える保証を近似差分プライバシー (ADP) へ換算し，得られた $\varepsilon$ を報告することが慣例となっているが，この報告形式は，換算前の保証が攻撃者の識別能力に課す制約を失い，過度に緩いプライバシー描像を与え得るなどの課題を持つ．本稿は，有意水準 $\alpha$ の下で保証される識別制約を，同等の制約を与える DP の最小 $\varepsilon$ で表す「$\alpha$-操作的等価 $\varepsilon$」を定義し，その閉形式と基本的性質を示す．さらに，これを 2020 年米国国勢調査の P.L. 94-171 選挙区改定データに適用し，ADP 換算に基づき $\varepsilon = 19.61$ と公表されたプライバシー保証を再評価した．その結果，ADP による報告はほぼ無意味なプライバシー保証しか示さない一方，中心極限定理による近似に基づく GDP 保証を経由した操作的等価 $\varepsilon$ による報告は，有意水準 1%，5%，10% の下で，$\varepsilon = 2.13$ から 3.89 の $\varepsilon$-DP に相当する識別制約を与えることを確認した．

**キーワード**：差分プライバシー，仮説検定，Gaussian DP，zero-concentrated DP，2020 年米国国勢調査

# What Does $\varepsilon = 19.61$ Mean? Reassessing Privacy Guarantees in the 2020 U.S. Census via Operationally Equivalent $\varepsilon$

Masayuki Terada[1,2]　Shinsuke Ito[3]

***Abstract:*** Privacy guarantees under extensions of differential privacy (DP) such as zero-concentrated DP (zCDP) and Gaussian DP (GDP) are not directly comparable with the DP parameter $\varepsilon$, and are therefore commonly converted to approximate DP (ADP) and reported as the resulting $\varepsilon$. This practice, however, loses the constraints that the original guarantee imposes on an attacker's distinguishing ability and can convey an overly loose picture of the protection. We define the $\alpha$-operationally equivalent $\varepsilon$ of a privacy guarantee as the smallest $\varepsilon$ such that $\varepsilon$-DP imposes an equivalent constraint at significance level $\alpha$, derive its closed form and basic properties, and apply it to reassess the guarantee of the 2020 U.S. Census P.L. 94-171 redistricting data, published as $\varepsilon = 19.61$ via ADP conversion. The reassessment shows that the ADP-based report implies an almost meaningless guarantee, whereas the operationally equivalent $\varepsilon$, derived from a GDP guarantee based on a central limit theorem approximation, ranges from 2.13 to 3.89 at significance levels of 1%, 5%, and 10%.

***Keywords:*** differential privacy, hypothesis testing, Gaussian DP, zero-concentrated DP, 2020 U.S. Census

## 1. はじめに

再構築攻撃 (reconstruction attack) をはじめとするプライバシー暴露攻撃の高度化・多様化に伴い，攻撃リスクへの個別対処に基づくプライバシー保護 (ad hoc privacy) は

[1] 京都橘大学 工学部
Faculty of Engineering, Kyoto Tachibana University
[2] 株式会社 NTT ドコモ
NTT DOCOMO, Inc.
[3] 中央大学 経済学部
Faculty of Economics, Chuo University

© 2026 Information Processing Society of Japan

This paper is work in progress and not peer-reviewed.

限界を迎えつつある．その代表例が，2010 年米国国勢調査に対する再構築・再識別攻撃実験である．米国センサス局は，公表された集計表から個人単位のレコードを再構築し，商用データとの照合によって約 5,200 万人を正しく再識別できることを実証した [1]．こうした開示リスクに対処するには数理的なプライバシー保証 (formal privacy guarantee) が必要であるとして，センサス局は，2020 年米国国勢調査に差分プライバシー (differential privacy; DP) を導入した [2].

DP は，隣接データベースから得られる出力分布の識別可能性を制約することで，攻撃アルゴリズムに依存しないプライバシー保証を与える [3]．その保証の強さは安全性パラメータ $\varepsilon \geq 0$ で表され，$\varepsilon$ が小さいほど保証は強い．$\varepsilon$ は許容するプライバシー損失の上限を表すことから，プライバシー損失予算 (privacy-loss budget) とも呼ばれ，その値を計算することはプライバシー会計 (privacy accounting) と呼ばれる．DP による保証は機構 (mechanism) と呼ばれるランダム化関数により与えられ，出力値に対してラプラス分布に従うノイズを加えるラプラス機構が典型として知られている．さらに，ガウス分布に従うノイズを加えるガウス機構や多数の機構の合成に対してプライバシー会計を緊密に行うための DP の拡張である zero-concentrated DP (zCDP) [4] や Gaussian DP (GDP) [5] などの普及も進みつつある．特に zCDP は，2020 年米国国勢調査における実際のプライバシー会計に用いられた [1].

ただし，zCDP や GDP により会計されたプライバシー保証の強さは DP における $\varepsilon$ と直接比較できない．そのため，これらによる保証を，DP 保証の失敗を一定確率まで許容する近似差分プライバシー (approximate DP; ADP) へ換算して得られた $\varepsilon$ の値として報告することが慣例となっている．しかし，ADP への換算は，換算前の保証が攻撃者の識別能力に課す制約を十分に反映せず，過度に緩いプライバシー描像を与え得る [6], [7]．また，換算の際に設定する $\delta$ の値によって得られる $\varepsilon$ は大きく異なるが，その設定には統一的な基準が存在せず [8]，選択には恣意性が生じる．

そこで本稿では，ADP への換算を介さずに，保証や機構が攻撃者の識別能力に課す制約に基づいてプライバシー強度を報告するための尺度として，有意水準 $\alpha$ における検出力上界を，同じ上界を与える DP の最小 $\varepsilon$ へ写像する「$\alpha$-操作的等価 $\varepsilon$」を定義し，その閉形式と基本的性質を示す．また，その具体的な適用として，$\alpha$-操作的等価 $\varepsilon$ を用いて 2020 年米国国勢調査の P.L. 94-171 選挙区改定データに対するプライバシー保証を再評価する．その結果，ADP 換算に基づく報告値は攻撃者の識別能力にほとんど制約を与えないことを含意する一方，$\alpha$-操作的等価 $\varepsilon$ は，元の保証が与える攻撃者の識別制約を保持し，ADP 換算とはまったく異なるプライバシー保証の描像を与えることを示す．

## 2. 仮説検定に基づくプライバシー保証の解釈と ADP 報告の課題

本章では，DP と ADP を定義するとともに，その仮説検定に基づく操作的解釈とその一般化を与える．また，ガウス機構に対する zCDP と GDP に基づくプライバシー保証について示し，その ADP 換算に基づく報告の課題について議論する．

### 2.1 DP と ADP

データベースの集合を $\mathcal{D}$, 出力空間を $\mathcal{Y}$ とする．$\mathcal{D}$ 上の対称な隣接関係を $\sim$ と書き，ランダム化関数 $M : \mathcal{D} \to \mathcal{Y}$ を機構と呼ぶ.

まず，DP を定義する．$\varepsilon \geq 0$ とし，任意の $D_0 \sim D_1$ と任意の可測集合 $S \subseteq \mathcal{Y}$ に対して

$$\Pr[M(D_0) \in S] \leq e^{\varepsilon} \Pr[M(D_1) \in S]$$

が成り立つとき，$M$ は $\varepsilon$-DP を満たす [3].

ADP は，DP の不等式に加法的な緩和 $\delta$ を許す拡張である．$\varepsilon \geq 0$ および $0 \leq \delta < 1$ とし，同様に

$$\Pr[M(D_0) \in S] \leq e^{\varepsilon} \Pr[M(D_1) \in S] + \delta$$

が成り立つとき，$M$ は $(\varepsilon, \delta)$-ADP を満たす [9]．定義より，$(\varepsilon, 0)$-ADP は $\varepsilon$-DP と等価である．本稿では DP と ADP を厳密に区別する．すなわち，$\delta \neq 0$ の $(\varepsilon, \delta)$-ADP による保証は DP 保証と呼ばない.

DP と ADP は機構の合成に対して閉じる．各機構がそれぞれの保証を満たすとき，その合成は，DP では $\varepsilon$ の加算，ADP では $\varepsilon$ と $\delta$ の各加算により会計できる.

### 2.2 仮説検定による差分プライバシーの操作的解釈

DP の操作的意味は，隣接データベースの識別問題として表せる [10], [11]．$P_0$ と $P_1$ を，それぞれ $M(D_0)$ と $M(D_1)$ の出力分布とする．攻撃者は観測される出力 $Y$ から，帰無仮説 $H_0 : D = D_0$ と対立仮説 $H_1 : D = D_1$ を識別する．検定関数 $\phi : \mathcal{Y} \to [0, 1]$ を用い，観測値 $y$ が与えられたとき，確率 $\phi(y)$ で $H_0$ を棄却する．このとき，第一種過誤確率 (有意水準)，第二種過誤確率および検出力は

$$\alpha_\phi = \mathbb{E}_{P_0}[\phi(Y)], \qquad \beta_\phi = \mathbb{E}_{P_1}[1 - \phi(Y)], \qquad \pi_\phi = 1 - \beta_\phi$$

である．以下，検定が明らかな場合は添字 $\phi$ を省く.

任意の隣接データベース対と検定について不等式

$$\pi \leq e^{\varepsilon} \alpha, \qquad \pi \leq 1 - e^{-\varepsilon}(1 - \alpha)$$

が成り立つことは $\varepsilon$-DP と同値であり，DP は各有意水準における最大検出力を制約する保証とみなすことができる.

© 2026 Information Processing Society of Japan

### 2.3 トレードオフ関数による一般化

Dong ら [5] は，前節で述べた DP 保証の仮説検定による表現を，トレードオフ関数を用いる $f$-DP へ一般化した．

二つの分布 $P, Q$ のトレードオフ関数を

$$T(P,Q)(\alpha) = \inf\{\beta_\phi : \alpha_\phi \le \alpha\}$$

と定義する．下限はすべての検定関数 $\phi$ について取る．すなわち，トレードオフ関数 $T(P,Q)(\alpha)$ は，ある観測値が分布 $P, Q$ のいずれに従うかを識別する際に，第一種過誤確率を $\alpha$ 以下に抑えた検定が取り得る第二種過誤確率の下限を表す．

トレードオフ関数 $f : [0,1] \to [0,1]$ に対し，機構 $M$ が任意の隣接データベース対 $D_0 \sim D_1$ について

$$T(M(D_0), M(D_1))(\alpha) \ge f(\alpha) \qquad (0 \le \alpha \le 1)$$

を満たすとき，$M$ は $f$-DP を満たすという [5]．

検出力 $\pi$ と第二種過誤確率 $\beta$ の関係 $\pi = 1 - \beta$ より，$f$-DP は機構 $M$ の出力から隣接データベースを識別する際の検出力に上界を与える．

$$G_{P,Q}(\alpha) = 1 - T(P,Q)(\alpha)$$

とすると，機構 $M$ のすべての隣接データベース対にわたる最大検出力は

$$G_M(\alpha) = \sup_{D_0 \sim D_1} G_{M(D_0),M(D_1)}(\alpha)$$

として表される．機構 $M$ が $f$-DP を満たすならば，その検出力の上界 $g_f$ は $g_f(\alpha) = 1 - f(\alpha)$ として与えられ，$G_M(\alpha) \le g_f(\alpha)$ が保証される．

2.2 節の二つの制約から，$\varepsilon$-DP が保証する検出力上界は

$$g_\varepsilon^{\mathrm{DP}}(\alpha) = \min\left\{ e^\varepsilon \alpha,\ 1 - e^{-\varepsilon}(1-\alpha) \right\} \qquad (1)$$

であり，$M$ が $\varepsilon$-DP を満たすことは，任意の $0 \le \alpha \le 1$ について $G_M(\alpha) \le g_\varepsilon^{\mathrm{DP}}(\alpha)$ が成り立つことと同値である．同様に，$(\varepsilon, \delta)$-ADP が保証する検出力上界は

$$g_{\varepsilon,\delta}^{\mathrm{ADP}}(\alpha) = \min\left\{1,\ e^\varepsilon \alpha + \delta,\ 1 - e^{-\varepsilon}(1 - \alpha - \delta)\right\} \quad (2)$$

となる．

### 2.4 ガウス機構のプライバシー保証

ガウス機構は，クエリの出力に標準偏差 $\sigma$ の正規分布に従うノイズを加える機構である [9]．この機構は有限の $\varepsilon$ では DP を満たさない．$\varepsilon$-DP の定義式で一方の分布の平均から遠い裾に $S$ を取ると，二つの確率はともに 0 に近づくが，その比は際限なく大きくなるためである．一方，$\delta$ による加法的な緩和はこの裾を確率 $\delta$ 以下の事象として吸収するため，ガウス機構は各 $\delta > 0$ に対して $(\varepsilon, \delta)$-ADP を満たす．

しかし，ADP による $(\varepsilon, \delta)$ の一組の対では，ガウス機構が与えるプライバシー保証を適切に表現することはできず，合成後の保証も緩いものとなる．そこで，ガウス機構のプライバシー会計を適切に行う手段として zCDP [4] や GDP [5] などが提案されている．

zCDP は Rényi 情報量を用いた DP の拡張である．Rényi 次数 $\lambda > 1$ に対する二つの分布 $P, Q$ の Rényi 情報量を $D_\lambda(P \| Q)$ と書き，$\rho \ge 0$ として任意の $D_0 \sim D_1$ と $\lambda > 1$ について $D_\lambda(M(D_0) \| M(D_1)) \le \rho\lambda$ が成り立つとき，$M$ は $\rho$-zCDP[*1] を満たす．クエリの $L_2$ 感度を $\Delta$ とすると，ガウス機構は $\rho = \Delta^2 / 2\sigma^2$ の $\rho$-zCDP を満たす．

GDP は $f$-DP の特殊例である．$\Phi$ を標準正規分布の累積分布関数とし，端点では $\Phi^{-1}(0) = -\infty$，$\Phi^{-1}(1) = +\infty$ とする．$\mu \ge 0$ に対し，

$$T_\mu(\alpha) = \Phi\big(\Phi^{-1}(1-\alpha) - \mu\big)$$

としたとき，$\mu$-GDP は $f = T_\mu$ とした $f$-DP であり，その検出力上界は

$$g_\mu^{\mathrm{GDP}}(\alpha) = 1 - T_\mu(\alpha) = \Phi\big(\Phi^{-1}(\alpha) + \mu\big) \qquad (3)$$

である．ガウス機構は $\mu = \Delta/\sigma$ $(\mu^2 = 2\rho)$ の $\mu$-GDP を満たし，その最大検出力は $g_\mu^{\mathrm{GDP}}$ と一致する．

各機構が $\rho_i$-zCDP を満たすとき，その合成は $\rho = \sum_i \rho_i$ の zCDP を満たす．同様に，各機構が $\mu_i$-GDP を満たすとき，その合成は $\mu = \sqrt{\sum_i \mu_i^2}$ の GDP を満たす．

### 2.5 ADP 換算に基づく報告と課題

zCDP や GDP におけるプライバシー保証の強度は，zCDP では $\rho$，GDP では $\mu$ として表され，従来の $\varepsilon$ と同じ尺度では解釈できない．そのため，これらによる保証を「無視できる」ほど小さい $\delta$ を用いて ADP へ換算し，得られた $\varepsilon$ をプライバシー強度の尺度として報告することが慣例となっている [8]．2020 年米国国勢調査でも，zCDP により会計した保証を $\delta = 10^{-10}$ として ADP へ換算し，対応する $\varepsilon$ を公表している [12]．

しかし，ADP 換算に基づく報告は，換算前の保証が同じであっても選択する $\delta$ によって報告される $\varepsilon$ が異なる．どの程度の $\delta$ を「無視できる」とみなすかについて絶対的な基準はなく，複数の基準が用いられてきた [8]．このため，報告される $\varepsilon$ には $\delta$ の選択に由来する恣意性が残り，異なる $\delta$ の下で得られた $\varepsilon$ の値を共通の尺度として単純に比較することはできない．

また，ADP への換算後の一組の $(\varepsilon, \delta)$ が与える検出力上界は，換算前の保証が与える上界より大幅に緩くなることが多い．その結果，換算前の保証が与える識別制約は適

[*1] 一般の zCDP は $(\xi, \rho)$-zCDP と表され，$\rho$-zCDP は $(0, \rho)$-zCDP の略記である．本稿で扱うガウス機構には後者が適用できるため，$\rho$ のみを扱う．

© 2026 Information Processing Society of Japan

切に保持されない．さらに，$\delta > 0$ の ADP 保証は，決定的な識別をもたらす破局的失敗を排除しない．ガウス機構は破局的失敗をもたらさないにもかかわらず，ADP に換算すると，これを許容する形でしか保証を与えられない．

## 3. $\alpha$-操作的等価 $\varepsilon$

前章で述べたように，$\delta$ を固定した ADP 換算により得られた $\varepsilon$ の値を報告するという慣例は様々な問題をもたらす．そこで，DP の操作的解釈において得られる検出力上界が有意水準ごとの攻撃者の識別能力を制約することに着目し，機構や保証が有意水準 $\alpha$ において与える検出力上界を，同じ上界を与える DP の最小 $\varepsilon$ へ写像した値である「$\alpha$-操作的等価 $\varepsilon$」をプライバシー強度の報告値として定義する．$\alpha$-操作的等価 $\varepsilon$ は，元の機構や保証が持つ有意水準ごとの識別制約を保ったまま，DP と共通の尺度でそのプライバシー強度を解釈・報告することを可能とする．

### 3.1 定義

検出力上界 $g$ は，プライバシー保証が攻撃者の識別能力に課す制約を表し，$g(\alpha)$ は有意水準 $\alpha$ においてその保証が許す検出力の上限を表す．$\alpha$-操作的等価 $\varepsilon$ は，$g(\alpha)$ と同じ検出力上界を与える，DP における $\varepsilon$ の値として定義される．

**定義 1 ($\alpha$-操作的等価 $\varepsilon$)** $g : [0,1] \to [0,1]$ を，任意の $\alpha \in [0,1]$ について $\alpha \le g(\alpha) \le 1$ を満たす検出力上界とする．各 $\alpha \in [0,1]$ に対し，

$$\varepsilon_\alpha(g) = \inf\left\{\varepsilon \ge 0 : g_\varepsilon^{\mathrm{DP}}(\alpha) \ge g(\alpha)\right\}$$

を $\alpha$-操作的等価 $\varepsilon$ と定義する．条件を満たす有限の $\varepsilon$ が存在しない場合は $\varepsilon_\alpha(g) = \infty$ とする．以下，$g$ が文脈から明らかな場合は $\varepsilon_\alpha(g)$ を $\varepsilon_\alpha$ と略記する．

定義 1 と式 (1) から，$\alpha$-操作的等価 $\varepsilon$ は次の閉形式で与えられる．

$$\varepsilon_\alpha(g) = \begin{cases} 0, & \alpha = 0,\ g(0) = 0, \\ \infty, & \alpha = 0,\ g(0) > 0, \\ h_\alpha(g), & 0 < \alpha < 1,\ g(\alpha) < 1, \\ \infty, & 0 < \alpha < 1,\ g(\alpha) = 1, \\ 0, & \alpha = 1. \end{cases} \tag{4}$$

$$h_\alpha(g) = \max\left\{\log\frac{g(\alpha)}{\alpha},\ \log\frac{1-\alpha}{1-g(\alpha)}\right\}.$$

**$\alpha = 0$ の解釈**

$\alpha = 0$ では，$g(0) = 0$ ならば $\varepsilon_0(g) = 0$，$g(0) > 0$ ならば $\varepsilon_0(g) = \infty$ となる．したがって，$\varepsilon_0(g)$ は，$g$ が破局的失敗の排除を保証するかどうかを 0 または $\infty$ で表す．

### 3.2 基本的性質

以下に $\alpha$-操作的等価 $\varepsilon$ が満たす基本的性質を示す．

**命題 1 (基本的性質)** $\alpha$-操作的等価 $\varepsilon$ は次を満たす．

(i) DP 保証との整合性：任意の $\varepsilon \ge 0$ に対し，

$$\varepsilon_\alpha\big(g_\varepsilon^{\mathrm{DP}}\big) = \begin{cases} \varepsilon, & 0 < \alpha < 1, \\ 0, & \alpha \in \{0,1\}. \end{cases}$$

(ii) 上界の一致：$\varepsilon_\alpha(g) < \infty$ ならば，$g^{\mathrm{DP}}_{\varepsilon_\alpha(g)}(\alpha) = g(\alpha)$.

(iii) 0-DP の検出：機構 $M$ に検出力上界 $g$ が与えられるとき，ある $\alpha_0 \in (0,1)$ において $g(\alpha_0) = \alpha_0$ ならば，$M$ は 0-DP である．

(iv) 順序保存：$g_1(\alpha) \le g_2(\alpha)$ ならば，$\varepsilon_\alpha(g_1) \le \varepsilon_\alpha(g_2)$.

(v) 後処理：任意の後処理 $A$ に対し，$\varepsilon_\alpha(G_{A\circ M}) \le \varepsilon_\alpha(G_M)$.

命題 1 の証明は付録 A.1 に示す．

また，検出力と第二種過誤の関係 $\pi = 1 - \beta$ から，ある機構が $f$-DP を満たすとき，$\varepsilon_\alpha$ の上界はトレードオフ関数 $f$ から直接与えられる．

**命題 2 ($f$-DP との関係)** $M$ が $f$-DP を満たすならば，$0 < \alpha < 1$ かつ $f(\alpha) > 0$ に対し，

$$\varepsilon_\alpha(G_M) \le \max\left\{\log\frac{1-f(\alpha)}{\alpha},\ \log\frac{1-\alpha}{f(\alpha)}\right\}.$$

**証明** $M$ が $f$-DP を満たすならば $G_M(\alpha) \le g_f(\alpha) = 1 - f(\alpha)$ であり，命題 1 (iv) より $\varepsilon_\alpha(G_M) \le \varepsilon_\alpha(g_f)$ が成り立つ．$f(\alpha) > 0$ より $g_f(\alpha) < 1$ であるから，式 (4) に $g_f(\alpha) = 1 - f(\alpha)$ を代入して結論を得る． □

### 3.3 ガウス機構への適用

ガウス機構は $\mu = \Delta/\sigma$ の $\mu$-GDP を満たし，各有意水準における最大検出力は $g_\mu^{\mathrm{GDP}}$ と一致する．したがって，$M$ がガウス機構のとき，$0 < \alpha < 1$ において，式 (4) から，

$$\varepsilon_\alpha(G_M) = \varepsilon_\alpha\big(g_\mu^{\mathrm{GDP}}\big) = \max\left\{\log\frac{g_\mu^{\mathrm{GDP}}(\alpha)}{\alpha},\ \log\frac{1-\alpha}{1-g_\mu^{\mathrm{GDP}}(\alpha)}\right\}.$$

上式により，たとえば 1-GDP のガウス機構に対し，$\varepsilon_{0.05}(g_1^{\mathrm{GDP}}) \approx 1.647$ を得る．**図 1** に，1-GDP と $\varepsilon_{0.05} \approx 1.647$-DP が与える検出力上界を示す．この図が示す通り，両者の検出力上界は $\alpha = 0.05$ で一致する．

## 4. 2020 年米国国勢調査におけるプライバシー保証の再評価

2020 年米国国勢調査では，P.L. 94-171 選挙区改定データのプライバシー保証について，zCDP における $\rho$ の値を示すとともに ADP 換算に基づく $\varepsilon$ の値を報告している [12], [13] が，$\varepsilon$ の報告値には資料間の矛盾や算出根拠が不明確な点がある．本章では，まずこれらの公表値について整理するとともに，ADP 報告値の計算根拠を確認する．その上で，この $\varepsilon$ の報告値についての妥当性を再評価するため，ADP 報告と $\alpha$-操作的等価 $\varepsilon$ による報告を比較し，

© 2026 Information Processing Society of Japan

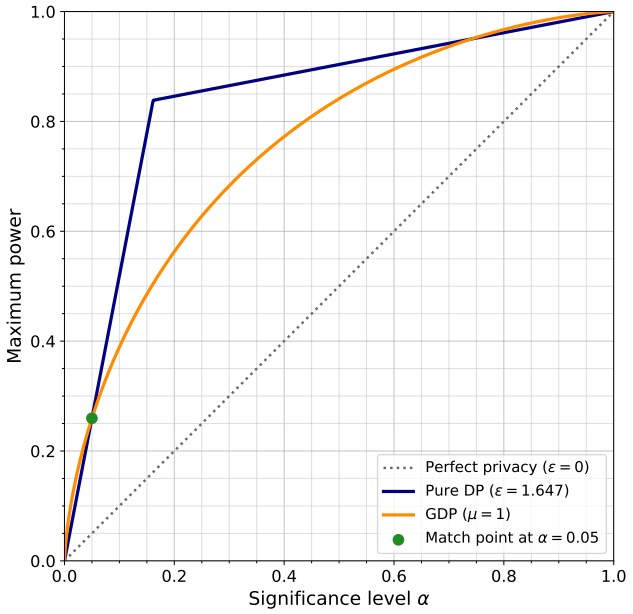



**図 1**　1-GDP と $\varepsilon_{0.05} \approx 1.647$-DP の検出力上界.

前者が評価した有意水準でほぼ無保証を含意する一方，後者は識別能力に対する制約を示すことを明らかにする．

なお，P.L. 94-171 においては，州の総人口など政策上正確な値の公表が求められる統計量は，不変量 (invariants) として正確な値が公開され，DP による保護の対象外とされている [1]．本稿もこれに従い，不変量の開示がプライバシーに与える影響は扱わない．

### 4.1　公表されたプライバシー予算

P.L. 94-171 選挙区改定データは，個人データと住宅データの 2 種類の統計データから構成され，いずれもセンサス局が開発した Disclosure Avoidance System (DAS) により DP に基づくプライバシー保護が与えられるとしている．また，これらを作成するにあたっての $\varepsilon$ の値はプライバシー損失予算 (privacy-loss budget) と呼ばれ，その値は個人データで $\varepsilon = 17.14$，住宅データで $\varepsilon = 2.47$，これらの和として全体で $\varepsilon = 19.61$ であると発表されている [12]．

ただし，実際には DAS は zCDP に基づくプライバシー保証を与えるシステムであり，DP に基づく保証を与えない．そのため，zCDP から ADP への換算により得られた $\varepsilon$ の値が上記の報告値に用いられている[*2]．これについてセンサス局は，DAS により個人データに $\rho \approx 2.56$，住宅データに $\rho \approx 0.07$，その和として全体で $\rho \approx 2.63$ の zCDP 保証が与えられ，それらの $\delta = 10^{-10}$ における ADP 換算値として，上記の個人データと住宅データにおける $\varepsilon$ の値が与えられたと説明するとともに，全体のプライバシー損失として $\varepsilon = 17.44$ という換算値も示している [13]．

ここで，全体のプライバシー損失として 2 種類の $\varepsilon$ の値が示されているのは，ADP を経由した換算手順の違いによるものである．前者の $\varepsilon = 19.61$ は，個人データと住宅データのそれぞれについて zCDP から ADP へ換算した後に，ADP の合成則を適用することにより求めたもの[*3]であるのに対し，後者の $\varepsilon = 17.44$ は zCDP の合成則により得られた全体の $\rho$ の値を用いて ADP への換算を適用して得た値のためである．ADP における合成より zCDP における合成のほうが緊密な結果が得られるため，前者の $\varepsilon = 19.61$ は本来より悲観的な解釈の結果とも言える．

なお，上記で示した $\rho$ は丸められた値であり，それぞれの正確な値は分数の形で開示回避証明書 (Certificate of Disclosure Avoidance) [14] に記載されている (付録 A.2)．正確さの観点から，以降の数値計算においては丸め値ではなくこれらの値を用いて議論する．

**表 1**　P.L. 94-171 の ADP 換算値

| | $\varepsilon$ | | |
|---|---|---|---|
| 換算方法 | 個人 | 住宅 | 全体 |
| センサス局による公表値 [12] | 17.14 | 2.47 | 19.61 |
| センサス局による公表値 [13] | 17.14 | 2.47 | 17.44 |
| Bun-Steinke [4], 補題 3.5 | 17.9002 | 2.7022 | 18.1984 |
| Bun-Steinke [4], 補題 3.6 | 17.4361 | 2.5330 | 17.7313 |
| Canonne ら [17], 系 13 | 17.1436 | 2.4747 | 17.4351 |

### 4.2　公表された ADP 換算値の検証

zCDP から ADP への換算式には複数のものがあるが，実際にどの換算式が用いられたかには文献上の混乱がある．センサス局の公式資料 [1], [12], [13] は，用いた換算式を明らかにしていない．DAS の中核アルゴリズムである TopDown Algorithm (TDA) の開発を主導した Abowd らは Bun-Steinke [4] の換算を用いたとしている [15]．ただし，文献 [4] には 2 種類の換算式 (簡易的な換算式 (補題 3.5) とより厳密な換算式 (補題 3.6)) が存在するが，どちらを用いたかは示していない．その一方で，公開された DAS のコード [16] では Canonne ら [17], 系 13 の換算式を用いており[*4]，Abowd らの説明と矛盾する．

そこで，前述の正確な $\rho$ の値に基づき，それぞれの換算式を用いて得られる値を計算して検証した．その結果，**表 1** に示す通り，Canonne らの換算値が 3 方式のうち最小の $\varepsilon$ を与えるとともに，これのみが公表値 [13] と表示桁で一致することが確認された．また，公表値 [12] における全体の $\varepsilon$ の値は表示最小桁で一致せず ($17.1436 + 2.4747 \approx 19.62$)，これは丸め後の個人データおよび住宅データの $\varepsilon$ の値を加算して得られたものであることがわかる．

したがって，センサス局が公表した $\varepsilon$ の値は Canonne ら [17] による ADP 換算式に由来し，$\varepsilon = 19.61$ という公

[*2] すなわち，実際に与えられているのは ADP に基づく保証であるが，センサス局は ADP と DP を区別せずに扱っている．

[*3] ADP の合成則より，正確には $\delta$ の値も加算されて $\delta = 2 \times 10^{-10}$ となるが，これについては陽に言及されていない．

[*4] `curve.py` の `BaseCurve.get_zcdp_delta()`.

© 2026 Information Processing Society of Japan

**表 2** ADP 換算 ($\delta = 10^{-10}$) と操作的等価 $\varepsilon$ の比較

| 対象 | $\varepsilon^{\mathrm{ADP}}$ | $\alpha$-操作的等価 $\varepsilon$ | | |
|---|---|---|---|---|
| | | $\varepsilon_{0.01}$ | $\varepsilon_{0.05}$ | $\varepsilon_{0.10}$ |
| zCDP 経由 ($\rho \approx 2.63$) | 17.44 | 4.25 | 2.94 | 3.18 |
| GDP 経由 ($\mu \approx 2.29$) | 16.75 | 3.89 | 2.70 | 2.13 |

表値は，これにより得られた個人データと住宅データにおける $\varepsilon$ の値を，小数第 2 位に丸めた後に得られたものであると結論づけられる．

### 4.3 操作的等価 $\varepsilon$ による報告

次に，操作的等価 $\varepsilon$ に基づく報告について検討する．$\varepsilon_\alpha$ は，対象となる機構の最大検出力またはそのプライバシー保証が与える検出力上界から導出できるが，ここで用いる検出力上界としては zCDP が与える $g^{\mathrm{zCDP}}$ の他，CLT 近似により GDP が与える $g^{\mathrm{GDP}}$ を用いることもできる．以下，それぞれを経由した導出方法を与える．

**zCDP を経由した報告**

$\rho$-zCDP が与える検出力上界 $g_\rho^{\mathrm{zCDP}}$ は，Balle らによる Rényi DP の仮説検定制約を zCDP に特殊化することにより得られ [18]，これは zCDP 保証のみから導ける最も緊密な上界であることが示されている [19]．$\rho = 2.63\ldots$ とし，この上界を式 (4) へ代入することにより $\varepsilon_\alpha$ を得る．

**CLT 近似による GDP を経由した報告**

ガウス機構のプライバシー保証は $\rho$-zCDP だけでなく $\mu$-GDP によっても与えられる．TDA で用いられている離散ガウス機構は，一般には閉形式で $\mu$ の値を求めることは困難であるが，一定の条件下で多数の機構の合成が GDP 保証に漸近収束する性質 (中心極限定理 (CLT) 近似) [5] を用いることにより，近似的に GDP 保証を与えることができる．実際，Kifer ら [20] は，TDA で用いられた離散ガウス機構の合成が与える最大検出力が，対応する (連続) ガウス機構の最大検出力とほぼ等しく，3 つの評価点 ($\alpha = 0.01, 0.05, 0.10$) において小数第 2 位まで一致することを示している．

したがって，CLT 近似に基づくと，$\mu = \sqrt{2\rho} = 2.29\ldots$ とした GDP に基づく検出力上界 $g_\mu^{GDP}$ を得ることができ，これを式 (4) へ代入することにより $\varepsilon_\alpha$ を得る．なお，同様に GDP から ADP への換算式 [5] を用いて $\varepsilon$ の値を得ることもできる．具体的な値は次節で議論する．

### 4.4 ADP 換算による報告との比較

ADP 報告と $\alpha$-操作的等価 $\varepsilon$ による報告は，2020 年米国国勢調査のプライバシー保証について大きく異なる描像を与える．以下，ADP 報告における $\varepsilon$ を $\varepsilon^{\mathrm{ADP}}$ と書く．

**表 2** に示すとおり，$\varepsilon^{\mathrm{ADP}}$ はいずれの行でも 16 を超え，これが含意する検出力上界は評価した 3 つの有意水準でほぼ 1 となる．これに対し，操作的等価 $\varepsilon$ による報告では $\varepsilon_\alpha$ がいずれも 5 を下回り，現実には攻撃者の識別能力に対して実効的な制約が存在することを示す．

また，**図 2** は，ADP 換算が与える検出力上界は zCDP と GDP のいずれを経由してもほぼ 1 となり，攻撃者にほぼ何も制約を課さないことを含意するのに対し，操作的等価 $\varepsilon$ はそれぞれの識別制約を反映することを示している．

## 5. 考察

本章では，第 4 章の評価によって確認された ADP 換算の問題と，操作的等価 $\varepsilon$ を報告する際の留意事項を示す．

### 5.1 ADP 換算がもたらす問題

2.5 節で述べた ADP 換算の課題は，第 4 章の比較評価において定量的に現れている．CLT 近似による GDP を経由して ADP 換算することにより，センサス局の公表値である $\varepsilon = 19.61$ より小さい値である $\varepsilon \approx 16.75$ を得ることができるが，その検出力上界は評価した有意水準でほぼ 1 であり，いずれにしても無保証と実質的に区別できない．その一方，実際の TDA は CLT 近似を通じて有意水準 1% から 10% において 2.13 ∼ 3.89-DP と同等の識別制約を持つことが操作的等価 $\varepsilon$ の導出により示されており，両者の間には著しい乖離があることが確認された．

### 5.2 操作的等価 $\varepsilon$ による報告における留意事項

$\varepsilon_\alpha$ は，有意水準 $\alpha$ における識別能力に対する制約を DP と共通の尺度で表す報告値であり，その値は $\alpha$ によって異なりうる．これは，ADP における $\varepsilon$ の値が $\delta$ に依存することと同様に見えるが，$\alpha$ が攻撃者の許容する偽陽性率を直接表す点で異なる．

その具体的な値として，報告を受ける側にとっての了解性の観点からは，原則として仮説検定における有意水準として一般的な数値である 0.01 (1%) や 0.05 (5%) を用いることが望ましい[*5]．また，破局的失敗の排除の有無を明示する必要がある場合には，$\alpha = 0$ における $\varepsilon_0$ (排除するとき 0，しないとき $\infty$) を併せて報告すればよい．

なお，$\varepsilon_\alpha$ はプライバシー保証を解釈するための報告指標であり，プライバシー会計の手段として用いることは適切でない．$\varepsilon_\alpha$ は合成時の会計に必要な保証全体の情報を保持しないためである．さらなる合成が想定される場合には，$\varepsilon_\alpha$ を単独で用いず，換算前の保証形式とその会計パラメータを併せて報告する必要がある．

## 6. 関連研究

**2020 年米国国勢調査のプライバシー会計と操作的評価**

Kifer ら [20] は，DP の各変種が与えるプライバシー保証の意味論をベイズ・頻度論の両観点から整理し，2020 年

[*5] 本稿の $\alpha = 0.01, 0.05, 0.10$ は，Kifer ら [20] に準じて選んだ評価点である．

© 2026 Information Processing Society of Japan

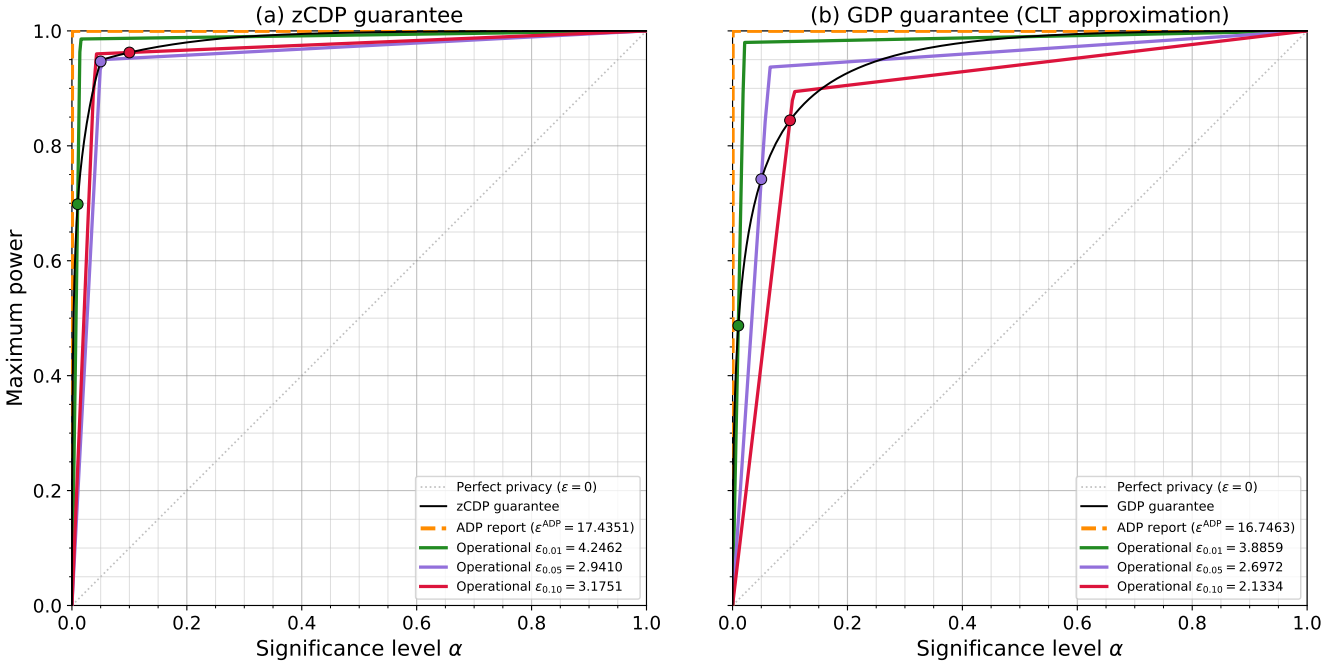



**図 2** ADP 報告と操作的等価 $\varepsilon$ による報告が与える検出力制約の比較 (ADP 換算は $\delta = 10^{-10}$. 左：$\rho \approx 2.63$ の zCDP，右：CLT 近似による $\mu \approx 2.294$ の GDP).

米国国勢調査の P.L. 94-171 選挙区改定データに適用した．本稿の CLT 近似による GDP 保証の評価は，このうち有意水準と検出力の関係として制約を表す頻度論的意味論による操作的評価を踏まえるものである．

Su ら [21] は，2020 年米国国勢調査の人口・住宅特性ファイル (Demographic and Housing Characteristics File; DHC)[*6] を対象に，$f$-DP により離散ガウス機構の合成を追跡し，公表された zCDP に基づく保証よりも緊密なトレードオフ関数を数値評価により求めた．操作的等価 $\varepsilon$ を用いた報告には，報告対象とする有意水準における最大検出力や検出力上界を必要とするが，完全なトレードオフ関数が得られていればこれらは容易に算出できる．したがって，Su らのトレードオフ関数を用いれば，本稿のアプローチは DHC に対しても同様に適用できる．

**プライバシー保証の報告形式**

Kifer らや Su らによる評価は，2020 年米国国勢調査が与えるプライバシー保証について，ADP 換算では失われる識別制約をいずれも直接捉えているが，その結果は検出力またはその関数として報告され，従来の DP における $\varepsilon$ と同じ尺度では示されない．

Gomez ら [8] は，プライバシー保証を単一の値で簡潔に報告することを目指し，トレードオフ関数の下界を非漸近的に与える GDP 保証を求め，そのパラメータ $\mu$ を報告値とすることを提案した．しかし，この下界が緊密になるのは，元の保証のトレードオフ関数が $T_\mu$ の形にほぼ一致する場合に限られる．したがって，DP が与えるプライバシー保証 (図 1 参照) を適切に表現できず，DP を保証する機構の評価や比較に適用することは困難である．

本稿も識別能力に対する制約を簡潔な値で表すことを目的とするが，保証全体を特定の一パラメータ族で表現するのではなく，指定した有意水準における検出力上界を，同じ上界を与える DP の最小 $\varepsilon$ へ写像する．これにより，任意の形の検出力上界を DP と共通の尺度で報告できる．

**攻撃実験によるプライバシー推定との相違**

DP auditing は，攻撃実験で観測した偽陽性率と偽陰性率から，学習アルゴリズムのプライバシーパラメータ $\varepsilon$ の下界を統計的に推定する [22]．Epsilon* は，メンバーシップ推論攻撃の結果から，単一の学習済みモデルに対する経験的な $\varepsilon$ の下界を求める [23]．攻撃者の識別能力を $\varepsilon$ の尺度で表す点は本稿と共通するが，これらは攻撃実験の観測結果から「少なくともこの程度は識別されうる」という実態の下界を推定する．これに対し本稿は，攻撃実験を用いず，機構の最大検出力または保証が与える検出力上界，すなわち「高々この程度しか識別できない」という証明された上限を，DP の $\varepsilon$ へ写像して報告する．

## 7. まとめ

本稿では，DP，ADP，zCDP および GDP が攻撃者の識別能力に課す制約を検出力上界として整理し，ADP への換算では，有意水準ごとの識別制約や，元の保証が破局的失敗を排除しているという情報が失われ得ることを示した．その上で，任意の検出力上界を，有意水準 $\alpha$ ごとに同

[*6] 本稿で対象とした P.L. 94-171 とは異なる統計データであり，プライバシー損失予算も異なる．

© 2026 Information Processing Society of Japan

じ上界を与える DP の最小 $\varepsilon$ へ写像する $\alpha$-操作的等価 $\varepsilon$ を定義し，その閉形式と基本的性質を示した．

2020 年米国国勢調査の P.L. 94-171 選挙区改定データについては，公表されたプライバシー予算と ADP 換算値の計算根拠を確認した上で，公表された zCDP 保証と，TDA の機構構成を反映した CLT 近似による GDP 保証を対象に，ADP 報告と $\alpha$-操作的等価 $\varepsilon$ による報告を比較した．その結果，ADP 報告が含意する検出力上界は無保証とほぼ区別できない一方，$\alpha$-操作的等価 $\varepsilon$ は，元の保証が攻撃者の識別能力に課す制約を表し，両者が大きく異なるプライバシー描像を与えることを示した．すなわち，表題に掲げた $\varepsilon = 19.61$ は成分別に公表された ADP 換算値の和であり，攻撃者の識別能力に課される制約を表す値ではない．TDA の合成保証を，CLT 近似による GDP 保証を経由して $\alpha$-操作的等価 $\varepsilon$ で報告すれば，有意水準 1% から 10% の下で，$\varepsilon = 2.13$ から 3.89 の $\varepsilon$-DP に相当する識別制約として示される．

以上より，プライバシー保証を報告する際には，ADP への換算を経由して単一の $\varepsilon$ を示すよりも，有意水準 $\alpha$ を明示した $\alpha$-操作的等価 $\varepsilon$ を用いることで，攻撃者の識別能力に対する制約をより忠実に伝えられる．ただし，$\alpha$-操作的等価 $\varepsilon$ はプライバシー会計の手段ではないため，さらなる合成が想定される場合には，換算前の保証形式とその会計パラメータを併記する必要がある．この併記により，会計に用いた保証を損なうことなく，形の異なる保証を DP と共通の尺度で解釈・報告できる．

**謝辞**　本研究は，JST 経済安全保障重要技術育成プログラム (JPMJKP24U5) の支援を受けたものである．

## 参考文献

[1] U.S. Census Bureau: *Disclosure Avoidance for the 2020 Census: An Introduction*, U.S. Government Publishing Office (2021).

[2] 伊藤伸介，寺田雅之，赤塚裕人，北井宏昌：海外における公的統計に対する攪乱的手法の新たな取り組み – アメリカセンサス局による差分プライバシーの適用を中心に –，統計研究彙報，No. 79, pp. 131–150 (2022).

[3] Dwork, C.: Differential Privacy, *Proc. 33rd Int. Conf. Automata, Languages and Programming*, LNCS, Vol. 4052, pp. 1–12 (2006).

[4] Bun, M. and Steinke, T.: Concentrated Differential Privacy: Simplifications, Extensions, and Lower Bounds, *Proc. 14th Int. Conf. Theory of Cryptography (TCC2016)*, LNCS, Vol. 9985, Springer, pp. 635–658 (2016).

[5] Dong, J., Roth, A. and Su, W. J.: Gaussian Differential Privacy, *J. Royal Statistical Society, Ser. B*, Vol. 84, No. 1, pp. 3–37 (2022).

[6] 寺田雅之：差分プライバシの基礎と動向，情報処理，Vol. 61, No. 6, pp. 591–599 (2020).

[7] 伊藤伸介，寺田雅之：海外における公的統計に関するプライバシー保護の現状 —アメリカとイギリスの事例をもとに—，統計研究彙報，No. 80, pp. 117–136 (2023).

[8] Gomez, J. F., Kulynych, B., Kaissis, G., Calmon, F. P., Hayes, J., Balle, B. and Honkela, A.: Gaussian DP for Reporting Differential Privacy Guarantees in Machine Learning, *Proc. IEEE Conf. Secure and Trustworthy Machine Learning (SaTML), Position Paper Track*, arXiv:2503.10945v3 (2026).

[9] Dwork, C., Kenthapadi, K., McSherry, F., Mironov, I. and Naor, M.: Our Data, Ourselves: Privacy via Distributed Noise Generation, *Proc. EUROCRYPT 2006*, pp. 486–503 (2006).

[10] Wasserman, L. and Zhou, S.: A Statistical Framework for Differential Privacy, *J. American Statistical Association*, Vol. 105, No. 489, pp. 375–389 (2010).

[11] Kairouz, P., Oh, S. and Viswanath, P.: The Composition Theorem for Differential Privacy, *Proc. 32nd Int. Conf. Machine Learning (ICML'15)*, pp. 1376–1385 (2015).

[12] U.S. Census Bureau: Census Bureau Sets Key Parameters to Protect Privacy in 2020 Census Results, Press Releases CB21-CN.42 (2021).

[13] U.S. Census Bureau: Privacy-Loss Budget Allocation 2021-06-08: Person and Units Tables (Production Settings) (2021).

[14] U.S. Census Bureau: Certificates of Disclosure Avoidance: P.L. 94-171 Redistricting Data US Persons and US Units (2021).

[15] Abowd, J., Ashmead, R., Cumings-Menon, R., Garfinkel, S., Heineck, M., Heiss, C., Johns, R., Kifer, D., Leclerc, P., Machanavajjhala, A., Moran, B., Sexton, W., Spence, M. and Zhuravlev, P.: The 2020 Census Disclosure Avoidance System TopDown Algorithm, *Harvard Data Science Review*, Special Issue 2 (2022).

[16] U.S. Census Bureau: DAS 2020 Redistricting Production Code Release (2021).

[17] Canonne, C. L., Kamath, G. and Steinke, T.: The Discrete Gaussian for Differential Privacy, *J. Privacy and Confidentiality*, Vol. 12, No. 1 (2022).

[18] Balle, B., Barthe, G., Gaboardi, M., Hsu, J. and Sato, T.: Hypothesis Testing Interpretations and Rényi Differential Privacy, *Proc. 23rd Int. Conf. Artificial Intelligence and Statistics*, PMLR, pp. 2496–2506 (2020).

[19] Riess, A., Gomez, J. F., Calmon, F. P., Schnabel, J. A. and Kaissis, G.: Optimal Conversion from Rényi Differential Privacy to $f$-Differential Privacy, *Proc. 43rd Int. Conf. Machine Learning*, PMLR, arXiv:2602.04562v3 (2026).

[20] Kifer, D., Abowd, J. M., Ashmead, R., Cumings-Menon, R., Leclerc, P., Machanavajjhala, A., Sexton, W. and Zhuravlev, P.: Bayesian and Frequentist Semantics for Common Variations of Differential Privacy: Applications to the 2020 Census, Working Paper CED-WP-2022-004, US Census Bureau (2022).

[21] Su, B., Su, W. J. and Wang, C.: The 2020 US Decennial Census Is More Private Than You (Might) Think, *Proc. National Academy of Sciences*, Vol. 122, No. 45, e2500337122 (2025).

[22] Nasr, M., Hayes, J., Steinke, T., Balle, B., Tramèr, F., Jagielski, M., Carlini, N. and Terzis, A.: Tight Auditing of Differentially Private Machine Learning, *32nd USENIX Security Symp. (USENIX Security 23)*, pp. 1631–1648 (2023).

[23] Negoescu, D. M., Gonzalez, H., Al Orjany, S. E., Yang, J., Lut, Y., Tandra, R., Zhang, X., Zheng, X., Douglas, Z., Nolkha, V., Ahammad, P. and Samorodnitsky, G.: Epsilon*: Privacy Metric for Machine Learning Models, arXiv:2307.11280v3 (2024).

© 2026 Information Processing Society of Japan

## 付　　録

### A.1　操作的等価 $\varepsilon$ の基本的性質の証明

**命題 1 の証明**　(i) は式 (4) に $g = g_\varepsilon^{\mathrm{DP}}$ を代入して得られる．

(ii) は，$0 < \alpha < 1$ では式 (4) を式 (1) に代入して得られる．$\alpha = 0$ では有限性から $g(0) = 0$ かつ $\varepsilon_0(g) = 0$ であり，$\alpha = 1$ では $g(1) = 1$ かつ $\varepsilon_1(g) = 0$ であるため，端点でも成り立つ．

(iii) について，$g$ は $M$ の検出力上界であるから，仮定より

$$G_M(\alpha_0) \le g(\alpha_0) = \alpha_0$$

が成り立つ．

$M$ が 0-DP でないと仮定する．2.2 節の同値性から，ある隣接データベース対について，第一種過誤確率 $\alpha_1$ と検出力 $\pi_1$ が $\pi_1 > \alpha_1$ を満たす検定 $\phi_1$ が存在する．

$\alpha_0 < \alpha_1$ の場合，$\theta = \alpha_0/\alpha_1$ とし，$\phi_1$ と常に棄却しない検定を重み $\theta$ で混合する．この検定の第一種過誤確率は $\alpha_0$，検出力は $\theta\pi_1 > \theta\alpha_1 = \alpha_0$ となる．$\alpha_0 \ge \alpha_1$ の場合，$\theta = (1-\alpha_0)/(1-\alpha_1)$ とし，$\phi_1$ と常に棄却する検定を重み $\theta$ で混合する．この検定の第一種過誤確率は $\alpha_0$ であり，検出力と $\alpha_0$ の差は $\theta(\pi_1 - \alpha_1) > 0$ となる．したがって，いずれの場合も $G_M(\alpha_0) > \alpha_0$ となり，$G_M(\alpha_0) \le g(\alpha_0) = \alpha_0$ に矛盾する．ゆえに $M$ は 0-DP である．

(iv) は，定義 1 において $g_\varepsilon^{\mathrm{DP}}(\alpha) \ge g_2(\alpha)$ を満たす $\varepsilon$ が $g_\varepsilon^{\mathrm{DP}}(\alpha) \ge g_1(\alpha)$ も満たすことから従う．

(v) について，後処理された出力に基づく検定は元の出力に基づく検定としても実行できるため，$G_{A\circ M}(\alpha) \le G_M(\alpha)$ である．したがって，(iv) から結論を得る．　□

### A.2　TDA の zCDP および GDP パラメータの導出

P.L. 94-171 の個人データおよび住宅データの開示回避証明書 [14] には，zCDP のパラメータがそれぞれ

$$\rho_{\mathrm{p}} = \frac{293764}{114921} = 2.556225581\ldots,$$
$$\rho_{\mathrm{h}} = \frac{11417641}{152349649} = 0.074943665\ldots$$

であると記録されている．したがって，両者を合成すると，

$$\begin{aligned}\rho_{\mathrm{total}} &= \rho_{\mathrm{p}} + \rho_{\mathrm{h}} \\ &= \frac{293764}{114921} + \frac{11417641}{152349649} \\ &= 2.631169246\ldots\end{aligned}$$

が得られる．これらを小数第 2 位まで表示した値が，公表資料に示された個人データの 2.56，住宅データの 0.07 および合成後の 2.63 と一致する [13].

また，ガウス機構に対しては $\mu = \sqrt{2\rho}$ が成り立つことより，CLT 近似による GDP のパラメータとして $\mu = \sqrt{2\rho_{\mathrm{total}}} = 2.293978746\ldots$ を与える．

© 2026 Information Processing Society of Japan