差分プライバシーの操作的解釈に基づく非負 Wavelet 機構の有用性評価

奥村 拓人[1,a)]　石岡 卓将[1]　寺田 雅之[1,2]

概要：差分プライバシーを用いたデータ公開において，ガウス機構のように zCDP で安全性が記述される機構と，ラプラス機構のように純粋 ε-DP で記述される機構とを比較する際には，一般に (ε, δ)-近似差分プライバシーへの換算が用いられる．しかし，この換算が与える ε は攻撃者の検出力の上界を定めるにすぎず，実際の検出力が上界からどれだけ離れているかは機構ごとに異なる．そのため，同じ ε を報告する機構どうしであっても実際の安全性は揃っておらず，加えて δ の設定に客観的な基準がないという問題がある．本稿では，攻撃者が許容する誤検知率 α を固定し，その下での検出力に基づく α-操作的等価 ε を用いて $\alpha = 0.05$ において両機構の安全性を揃え，階層的なデータ処理と非負制約を伴う実用的なデータ公開アルゴリズムである NN-Wavelet 環境下で有用性（RMSE）を再評価する．国勢調査に基づく人口統計データを用いた評価の結果，従来の換算による比較では RMSE 比が δ の選択に依存して 0.740 から 1.089 まで変動し，優劣さえ反転することを示す．先行研究が採った $\delta = 10^{-6}$ では 0.907 と観測されるが，検出力を揃えると δ に依存しない 0.713 が得られる．また，本手法が導入する α は δ と異なり結論を動かさないことを確認した．

キーワード：差分プライバシー，f-DP，操作的等価 ε，NN-Wavelet

Reevaluating the Non-Negative-Wavelet Mechanism through an Operational Interpretation of Differential Privacy

Takuto Okumura[1,a)]　Takumasa Ishioka[1]　Masayuki Terada[1,2]

Abstract: When publishing data under differential privacy, comparing a mechanism whose guarantee is stated in zCDP, such as the Gaussian mechanism, with one stated in pure ε-DP, such as the Laplace mechanism, conventionally relies on a conversion to (ε, δ)-approximate differential privacy. However, the ε obtained by this conversion only bounds the attacker's detection power from above, and how far the actual detection power lies below this bound differs from mechanism to mechanism. Consequently, two mechanisms reporting the same ε are not necessarily equally safe, and moreover there is no objective criterion for choosing δ. In this paper we fix the attacker's false positive rate α and use the α-operational equivalent ε, defined from the detection power at that α, to align the safety of the two mechanisms at $\alpha = 0.05$, and reevaluate utility (RMSE) under the NN-Wavelet mechanism, a practical data publishing algorithm involving hierarchical processing and a non-negativity constraint. Using population statistics based on census data, we show that the RMSE ratio under the conventional conversion varies from 0.740 to 1.089 depending on the choice of δ, reversing which mechanism appears superior. At $\delta = 10^{-6}$, the value adopted in prior work, the ratio is 0.907, whereas aligning the detection power yields 0.713 independently of δ. We also confirm that the α introduced by our method, unlike δ, does not alter the conclusion.

Keywords: Differential Privacy, f-DP, Operational Equivalent Epsilon, NN-Wavelet

© 2026 Information Processing Society of Japan

This paper is work in progress and not peer-reviewed.

1. はじめに

スマートフォンや IoT デバイスの普及に伴い，パーソナルデータを含むデジタルデータは急速に増加しており，これを利活用して社会に新たな価値を創出することの重要性が高まっている．一方で，氏名や住所などの直接的な識別子を除いた集計データであっても，外部データと組み合わせることで個人を特定する再構築攻撃（Reconstruction Attack）の脅威が現実のものとなっている．米国国勢調査局が実施した検証では，公表済みの集計表を組み合わせることで氏名や住所を含まない個人単位のレコードを再構築でき，さらにこれを外部データベースと突合することで個人の再識別が可能となることを指摘している [1,2]．これを受け，攻撃者の事前知識や計算能力に依存せず数学的な安全性を保証できる差分プライバシー（Differential Privacy，以下 DP）[3] の導入が国際的に進められており，2020 年米国国勢調査では実際に DP に基づく公開方式が採用されている [4]．

DP を実際に適用する際には，どの確率分布でノイズを加えるかを選ぶ必要がある．DP においてデータに加えるノイズには，主にラプラス分布とガウス分布が用いられる．ラプラス機構 [5] は安全性を ε のみで厳密に記述できるが，複数の処理を合成する際のノイズの累積効率が悪い．一方ガウス機構は合成効率に優れるものの，ノイズの裾が無限に伸びるため純粋な ε-DP を満たすことができず，ごく低い確率で保証が破れることを許容するパラメータ δ を導入した (ε, δ)-DP（以下 ADP）として運用される．また合成を厳密に扱うために zero-concentrated DP（以下 zCDP）[6] や Gaussian DP（以下 GDP）[7] といった拡張が提案されているが，これらは直感的な解釈が難しいため，最終的な報告には ADP に換算した値が用いられることが多い．

ここに，機構間の比較における問題が生じる．ラプラス機構は ε で，ガウス機構は ρ（zCDP）で安全性が記述されるため，両者を直接比較することができない．そこで実運用では，ガウス機構の ρ を δ を選んで ADP へ換算し，得られた ε を共通の尺度として比較が行われる．しかしこの δ には客観的な決定基準が存在せず，分析者が任意に設定しているのが現状である．この問題は具体的な適用場面でも現れる．集計データの非負性と階層的な一貫性を保つ NN-Wavelet [8] を対象とした石岡らの先行研究 [9] においても，機構間の有用性比較はこの換算に依存しており，両機構の優劣が δ の設定に左右されるという問題が残されている．

[1] 京都橘大学 工学部
Faculty of Engineering, Kyoto Tachibana University
[2] (株) NTT ドコモ モバイルイノベーションテック部
Mobile Innovation Tech Department, NTT DOCOMO, Inc.
[a)] h601025015@tachibana-u.ac.jp

さらに，換算によって得られる ε が保証するのは攻撃者の検出力の**上界**にすぎない．上界は実際の検出力がそれ以下であることしか意味しないため，同じ上界を報告するラプラス機構とガウス機構であっても，実際の危険度が一致しているとは限らない．すなわち従来の比較は，最悪の場合にどこまで安全だと保証できるかを揃えたものであって，実際にどれだけ安全かを揃えたものではない．

本研究の目的は，δ に依存しない評価基準を導入し，機構間の公平な再評価を実現することである．具体的には，攻撃者が許容する誤検知率 α を固定し，そのもとで機構のトレードオフ曲線が与える検出力に基づく α-操作的等価 ε [10] を用いて両機構の安全性を揃える．この指標は上界の緩さに影響されず，また δ が式に現れない．

本稿の貢献は以下の 3 点である．

第一に，安全性の水準を先に決め，それを満たすプライバシーパラメータを後から求めるという逆向きの問題を定式化し，19 階層の合成を伴う NN-Wavelet に対して解いた．文献 [10] が公表済みの保証を再解釈する方向の問題を扱うのに対し，本稿は逆に，揃えたい安全性の水準からパラメータを決める方向の問題を扱う．ガウス版は閉形式で解けるが，ラプラス版は 19 重合成の折れ線トレードオフ関数に対する二分探索を要するという非対称な作業になる．

第二に，第一で得たパラメータを用いて実データ上で RMSE を測定し，$\alpha = 0.05$ において安全性を揃えた条件での有用性の差を明らかにした．その結果，従来の換算に基づく比較では RMSE 比が δ に依存して 0.740 から 1.089 まで動き，優劣が反転しうることを示した．先行研究が採った $\delta = 10^{-6}$ では 0.907 と見えていたが，検出力を揃えると 0.713 である．

第三に，δ の恣意性と α の恣意性を，結論そのものである RMSE 比という同一の量で比較する評価設計を示した．これにより，本手法が恣意性の置き換えにすぎないという批判に定量的に答えられる．

2. 準備

本章では，差分プライバシーとその拡張フレームワーク，安全性を仮説検定の観点からとらえる指標，および大規模集計データへの適用手法である NN-Wavelet について整理する．

2.1 差分プライバシー

DP は，隣接するデータベース（1 レコードのみ異なるデータベース）の組 D, D' に対して，機構 M の出力分布の差を一定以下に抑えることで個人のプライバシーを保証する枠組みである．任意の出力集合 S に対して

$$\Pr[M(D) \in S] \leq e^{\varepsilon} \Pr[M(D') \in S] + \delta \qquad (1)$$

が成り立つとき，M は (ε, δ)-DP を満たすという．$\delta = 0$

© 2026 Information Processing Society of Japan

の場合を純粋 ε-DP と呼ぶ．

感度 Δ のクエリに対し，ラプラス機構 [5] はスケール $b = \Delta/\varepsilon$ のラプラス分布に従うノイズを付与し，ε-DP（$\delta = 0$）を満たす．ガウス機構は標準偏差 σ の正規分布に従うノイズを付与するが，正規分布は裾が無限に伸びるため，いかなる ε に対しても純粋 ε-DP を満たすことができず，$\delta > 0$ が原理的に必要となる．

2.2 zCDP と GDP

複数の処理を合成する際のプライバシー損失を厳密に見積もるため，レニーダイバージェンスに基づく RDP [11] や zCDP [6] が提案されている．ρ-zCDP を満たす機構の合成は ρ の総和として厳密に扱えるため，合成回数が多い場合に有利である．感度 Δ のガウス機構は $\sigma = \Delta/\sqrt{2\rho}$ とすることで ρ-zCDP を満たす．

また，DP は攻撃者が 2 つの隣接データベースを識別する仮説検定として解釈できることが知られており [12]，この観点から DP を据え直した f-DP [7] では，機構の安全性を攻撃者の誤検知率 α と見逃し率 β のトレードオフ関数 f として表現する．ガウス機構及びその合成は $\mu = \sqrt{2\rho}$ とした μ-GDP に厳密に一致し，そのトレードオフ関数は

$$\beta = \Phi\left(\Phi^{-1}(1-\alpha) - \mu\right) \tag{2}$$

で与えられる．ここで Φ は標準正規分布の累積分布関数である．

2.3 ADP への換算と検出力の上界

zCDP は直感的な解釈が難しいため，実運用では ADP へ換算した値が報告される．ρ-zCDP を満たす機構は，任意の $\delta > 0$ に対して [6]

$$\varepsilon = \rho + 2\sqrt{\rho \ln(1/\delta)} \tag{3}$$

とした (ε, δ)-DP を満たす．

(ε, δ)-DP が与える安全性は，攻撃者の仮説検定の言葉で表すことができる．対象の個人がデータに含まれているか否かを判断する攻撃者を考え，含まれない場合のデータベースを D'，含まれる場合を D とする．攻撃者が出力集合 S を棄却域として含まれると判定するとき，誤検知率（第一種の過誤）は $\alpha = \Pr[M(D') \in S]$，検出力は $1-\beta = \Pr[M(D) \in S]$ である．これらを式（1）に代入すると

$$1 - \beta \le \delta + e^{\varepsilon}\alpha \tag{4}$$

を得る．さらに，式 (1) は任意の出力集合について成り立つため，棄却域を補集合 S^c にとり D と D' を入れ替えて適用することもできる．このとき $\Pr[M(D') \in S^c] = 1-\alpha$，$\Pr[M(D) \in S^c] = \beta$ であるから $1 - \alpha \le e^{\varepsilon}\beta + \delta$ を得る．これを β について解くと

$$1 - \beta \le 1 - e^{-\varepsilon}(1 - \delta - \alpha) \tag{5}$$

となる．式（4）は攻撃者が滅多に棄却しない領域（α が小さい領域）で，式（5）は頻繁に棄却する領域で，それぞれ強く効く．(ε, δ)-DP は検出力に対して 2 つの制約を課しており，誤検知率 α を許容する攻撃者が到達しうる検出力の上界は，これらの小さい方で与えられる．ただしこれはあくまで上界であり，実際の検出力がこの値に達するとは限らない．(ε, δ) の組による報告が保証の実像を歪めうる点は，機械学習分野においても指摘されている [13]．また Kulynych らは，ε を経由してノイズ量を決めると評価が過度に保守的になるとして，攻撃リスクから直接ノイズ量を定める手法を提案している [14]．本稿も δ の選択を経由せずに安全性の水準からパラメータを定める点で同じ方向にあるが，対象を機械学習ではなく階層的な集計データ公開とし，形式の異なる保証をもつ 2 機構の比較に用いる点が異なる．

2.4 α-操作的等価 ε

式（4）（5）において $\delta = 0$ とすると，ε-DP を満たす機構の検出力は，誤検知率 α において

$$1 - \beta \le \min\left\{e^{\varepsilon}\alpha,\ 1 - e^{-\varepsilon}(1-\alpha)\right\} \tag{6}$$

に従う．ある機構が ε-DP を満たすことは, 任意の $\alpha \in [0, 1]$ について式 (6) が成り立つことと同値である [12]．つまり，ある機構の誤検知率 α における検出力の上限が式 (6) の右辺に等しいとき，その機構は誤検知率 α において ε-DP と同等の安全性を保証するとみなすことができる．

そこで，右辺の 2 つの項をそれぞれ ε について解き，両方を満たす最小の値をとって

$$\varepsilon_\alpha = \max\left\{\log\frac{1-\beta}{\alpha},\ \log\frac{1-\alpha}{\beta}\right\} \tag{7}$$

とし，これを α-操作的等価 ε と呼ぶ [10]．なお，α を固定すれば ε_α と検出力は単調に対応するため，ε_α を揃えることは検出力を揃えることと等価である．

式 (7) の具体的な値はトレードオフ関数から求めることができる．たとえばガウス機構やその合成であれば，式 (2) を式 (7) に代入することにより ε_α を得る．ε-DP を満たす機構の合成であれば文献 [12] が与えるトレードオフ関数を用いる (具体的な式は 4.2.2 節に示す)．

ADP への換算においては，機構の保証を換算する過程で上界が緩み，その緩み方は δ の値や元の保証形式によって異なる．これに対し式 (7) は，誤検知率 α における制約を保ったまま ε の尺度へ移すものであり，そのような上界の緩みを伴わない．

2.5 NN-Wavelet

大規模な集計データに DP を適用すると，ノイズによっ

© 2026 Information Processing Society of Japan

て負の値（負の人口など）が生じたり，階層間の集計の整合性が崩れたりする．Haar ウェーブレット変換を用いて階層ごとにノイズを付与する手法は Xiao らによって提案されており [15]，これに非負性と一貫性を保つ処理を加えた手法として寺田らが NN-Wavelet を提案している [8]．NN-Wavelet は，データを Haar ウェーブレット変換により L 段の階層に分解し，各階層にラプラスノイズを付与したうえで，非負性を保つように係数を調整しながら逆変換を行う．本稿で対象とする設定では $L = 19$ である．

石岡らは，NN-Wavelet の構造を保ったままノイズ機構のみをラプラス機構からガウス機構へ置き換え，zCDP の枠組みで再定義してその有用性を評価している [9]．ただし機構間の比較は式（3）による換算に依存しており，その結論は特定のパラメータ設定に依存する..

3. 課題

3.1 ADP 換算に基づく比較の限界

従来の比較手続きは次のとおりである．ガウス版の ρ を固定し，δ を選んで式（3）により ε を得る．その ε をラプラス版に与え，同一の ε のもとで両者の RMSE を比較する．

換算そのものは誤りではない．「ρ-zCDP を満たすならば (ε, δ)-DP を満たす」という命題は正しく，式（4）(5) が与える上界も正しい．正しくないのは，同じ上界を報告するから同程度に安全であるという推論の側である．

この手続きが揃えているのは，あくまで**検出力の上界**であり，最悪の場合にどこまで安全だと保証できるかは揃っている．しかし上界は，実際の検出力がそれ以下であることしか意味しない．上界からの開きは機構ごとに異なるため，同じ上界を報告する 2 つの機構であっても実際の危険度は一致しない．本稿の条件では，ガウス版の実際の検出力 13.6% に対し，$(\varepsilon, \delta) = (2.769, 10^{-5})$ の報告が保証するのは 79.7% 以下である．また，$\delta = 10^{-6}$ では 95.4% 以下である．より緊密な GDP 経由の換算（$\mu = \sqrt{2\rho}$ から (ε, δ) を厳密に解く）を用いても上界は 45.1% であり，換算の精度を上げても解消しない．

この緩みの大きさは機構ごとに異なり，同じ 13.6% の検出力を与える 2 つの機構を比べると，ガウス版は上界 79.7%（$\delta = 10^{-5}$）に対して実際が 13.6% であり 5.9 倍の開きがあるのに対し，ラプラス版は $\delta = 0$ であるため上界が 53.7% であり，開きは 4.0 倍である．上界を揃えることは，この緩みの差を無視して両者を同一視することである．したがって，この状態で測定された RMSE の差を有用性の差として解釈することはできない．

3.2 δ の恣意性

さらに，δ には客観的な決定基準が存在しない．式（3）より，δ を小さくするほど換算後の ε は大きくなる．ここで，換算後の ε を受け取る側は $\delta = 0$ の機構であるため，δ を導入したことによる恩恵を一切受けず，大きくなった ε のみを受け取る．その結果，δ の選択は受け手側の予算だけを動かし，一方の機構のノイズ量と実際の危険度のみが変化するという非対称性が生じる．なお，この非対称性は換算をどちらの向きに行うかに依存しない．本稿では先行研究の手続きを再現する観点から，ガウス版の ρ を固定して換算後の ε をラプラス版に与える向きを採る．逆向きに換算式を解くことも可能であり，その場合は δ がガウス版の予算を動かすが，δ の選択が一方の機構だけを動かすという構造は向きによらない．

δ はガウス側の保証に付随する量でありながら，換算を経てラプラス側の予算を決定するのに用いられている．この構造により，δ の選択が有用性の優劣という結論を左右する．

4. 提案手法

4.1 評価手法の置き換え

従来の手続きは，δ を選んで固定し，換算で得た ε のもとで両機構を比較するものである．本稿ではこれに代えて，α を固定し，式（7）の α-操作的等価 ε を揃える．後者は各機構のトレードオフ曲線を直接評価するため上界の緩さに影響されず，δ が式に現れないためその選択に依存しない比較が可能となる．

4.2 NN-Wavelet への適用設計

ε_α は報告のための指標であり，合成時のプライバシー会計に用いるものではない [10]．本稿では合成を各機構の元の保証形式（ラプラス版は ε の加法性，ガウス版は ρ の加法性）で行い，合成後のトレードオフ曲線から ε_α を読み取る．ε_α は，揃えるべき安全性の水準を決定する目的にのみ用いる．

合成は NN-Wavelet 内部の $L = \text{height} + 1 = 19$ 階層のみを対象とし，パラメータは 1 階層当たりではなく総量で表す．安全性の目標は「誤検知率 5% を許容する攻撃者に対して $\varepsilon = 1$ 相当」，すなわち $\alpha = 0.05$，$\varepsilon_{0.05} = 1$ とする．式（6）より，$\alpha = 0.05$ では第一項が上界を与える．枝の入れ替わりは $\alpha = 1/(e+1) = 0.269$ であり，目標とする検出力は $1 - \beta = e \cdot \alpha = 0.136$，すなわち $\beta^* = 0.864$ である．

なお本稿では，ガウス版の予算管理に ρ-zCDP を，トレードオフ曲線の評価に μ-GDP を用いる．ガウス機構およびその合成は $\mu = \sqrt{2\rho}$ の μ-GDP に厳密に一致するため，両者は同一の機構の異なる表現であり，換算による緩みを伴わない．ρ を用いるのは合成が加法的に扱えるためであり，μ を用いるのはトレードオフ曲線が閉形式で得られるためである．

© 2026 Information Processing Society of Japan

4.2.1 ガウス版

式（2）を $\beta = \beta^*$ について解くと

$$\mu^* = \Phi^{-1}(1-\alpha) - \Phi^{-1}(\beta^*), \qquad \rho_{\text{total}} = (\mu^*)^2/2 \quad (8)$$

となる．よって μ^* は 0.546, ρ_{total} は 0.149 である．zCDP の合成は厳密であるため，この値は階層数 L に依存しない．

4.2.2 ラプラス版

各階層は $\varepsilon_0 = \varepsilon_{\text{total}}/L$ の純粋 ε-DP であり，リリース全体はその L 重合成にあたる．ε-DP 機構の合成の最悪のケースは 2 点分布で達成される [12] ため，$p = e^{\varepsilon_0}/(1+e^{\varepsilon_0})$, $q = 1/(1+e^{\varepsilon_0})$ として，トレードオフ曲線の折れ点は

$$\alpha(j) = \Pr[\mathrm{Bin}(L,q) > j] \quad (9)$$

$$\beta(j) = \Pr[\mathrm{Bin}(L,p) \le j] \quad (10)$$

（$j = -1, 0, \ldots, L$）で与えられ，その間は線分となる．この曲線で $\beta(\alpha = 0.05) = \beta^*$ となる ε_0 を二分探索により求めると $\varepsilon_0 = 0.125$, $\varepsilon_{\text{total}} = L\varepsilon_0 = 2.375$ を得る．合成があるため $\varepsilon_{\text{total}} = 1$ とはならない．

なお，ここで構成した折れ線は，各階層が ε_0-DP を満たす機構のクラスに対してその保証から導ける緊密な上界であり，ラプラス機構そのものが達成する検出力ではない．ガウス版も μ-GDP の保証が与える上界で評価しており，両機構は保証の水準において揃えられている．異なるのは保証に対する緊密さである．ガウス機構の合成は μ-GDP と厳密に一致するのに対し，ラプラス機構の対数尤度比は $\pm\varepsilon_0$ の 2 点ではなく $(-\varepsilon_0, \varepsilon_0)$ 上に連続成分をもつため，その合成の検出力は折れ線より低い．影響を確かめるため，この対数尤度比の分布を数値的に畳み込み，19 重合成後のトレードオフ曲線を直接求めた．検出力 13.6% をラプラス機構そのもので達成する $\varepsilon_{\text{total}}$ は 2.433 であり，本稿が与える 2.375 との差は 2.45% である．差が小さいのは，$\varepsilon_0 = 0.125$ において対数尤度比の質量の 94.1% が $\pm\varepsilon_0$ の 2 点に集中しているためである．

4.2.3 階層への分配

いずれも予算を $L = 19$ 階層に等分する．これは先行研究と同一の設定である．階層 i の感度は $\Delta_i = 1/2^i$ であり，ラプラス版は $b_i = \Delta_i L/\varepsilon_{\text{total}}$，ガウス版は $\sigma_i = \Delta_i/\sqrt{2\rho_{\text{total}}/L}$ とする．感度 1 の階層に載るノイズの標準偏差は，ラプラス版が $\sqrt{2}\,b = 11.315$，ガウス版が $\sigma = 7.984$ である．以上を**表 1** にまとめる．

4.3 評価の手順

以上により，両機構の実際の検出力が一致し，ρ_{total} と $\varepsilon_{\text{total}}$ が定まる．本稿ではこれらをプライバシー予算として NN-Wavelet を実データに適用し，出力された集計値の RMSE を測定することで，安全性を揃えた条件での有用性を比較する．あわせて，従来の換算により定めた $\varepsilon_{\text{total}}$ を用いた場合の RMSE も測定し，検出力を揃えて定めた場合と対比する．

表 1: 検出力を揃えたプライバシーパラメータ
Table 1 Privacy parameters matched by detection power

	ガウス版	ラプラス版
総量	$\rho_{\text{total}} = 0.149$	$\varepsilon_{\text{total}} = 2.375$
1 階層あたり	0.0078	0.1250
ノイズ標準偏差	7.984	11.315
検出力	13.6%	13.6%
ε_α	1.0000	1.0000

5. 評価

5.1 評価環境

データには 2020 年国勢調査に基づく 500m メッシュ人口データを用いた．対象エリアは首都圏（原点 $(x,y) = (2560, 3584)$，level=9）とし，512×512 のメッシュを Morton 順に 1 次元化した $2^{18} = 262{,}144$ セルを対象とする．総人口は 46,649,187 人，非ゼロセル数は 81,873（全体の 31.2%）である．

機構の実装には石岡ら [9] の公開実装を無改変で用い，ラプラス版・ガウス版ともに予算を 19 階層に等分する設定とした．試行回数は 1000 回である．

有用性の指標には RMSE を用いる．エリアレベル 2^0 から 2^{18} の各粒度で部分和を取り，その誤差を評価する．二乗誤差を試行と位置についてプールし，最後に平方根を取る定義を用いた．各試行の RMSE を試行間で平均する定義では，位置数の少ない高エリアレベルにおいて MAE 的に劣化するため採用しない．

評価パイプラインの妥当性を確認するため，$\rho = 0.1$, $\delta = 10^{-6}$ の条件で石岡らの公開済み結果 [9] と突き合わせた．エリアレベル 0 〜 13 で相対偏差 0.7% 以内，14 〜 18 で最大 3.1% で再現できることを確認している．

比較は次の 3 条件で行う．(a) ガウス版（$\rho_{\text{total}} = 0.149$），(b) ラプラス版 ε を α-操作的等価 ε により決めたもの（$\varepsilon_{\text{total}} = 2.375$），(c) ラプラス版で ε を従来の換算により決めたもの（$\delta = 10^{-5}, 10^{-6}, 10^{-7}$）．比較は先行研究と同じ向きであるガウス版の ρ_{total} を固定し，換算で得た $\varepsilon_{\text{total}}$ をラプラス版に与える形で行う．したがって RMSE 比の分子（ガウス版）は全条件で共通であり，条件間で変化するのはラプラス版のみである．換算式を逆に解いてラプラス版を固定しガウス版の ρ_{total} を求める向きも可能だが，先行研究の手続きを再現する観点から前者を採用する．

5.2 評価 1：実際の検出力の比較

各条件における $\alpha = 0.05$ での実際の検出力を**表 2** に示す．ガウス版の検出力は 13.6% であり，ρ_{total} のみで決まるため δ に依存しない．一方，換算で得た $\varepsilon_{\text{total}}$ をラプラ

© 2026 Information Processing Society of Japan

表 2: 各条件における実際の検出力（$\alpha = 0.05$）
Table 2 Actual detection power under each condition

条件	δ	$\varepsilon_{\text{total}}$	検出力
ガウス版	該当なし	該当なし	13.6%
ラプラス版（検出力揃えた）	0	2.375	13.6%
ラプラス版（換算）	10^{-5}	2.769	15.5%
ラプラス版（換算）	10^{-6}	3.019	16.9%
ラプラス版（換算）	10^{-7}	3.249	18.1%

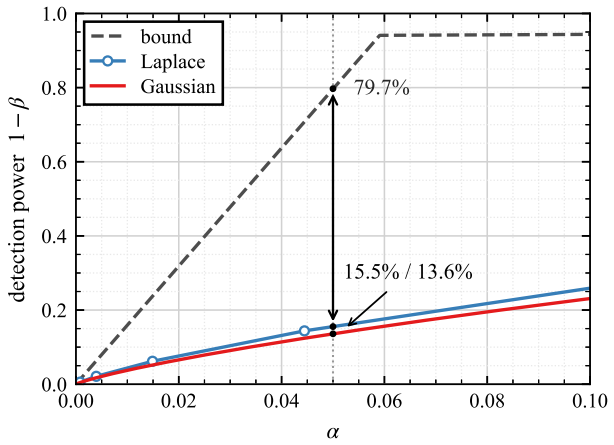


図 1: 報告が許す検出力の上界と実際の検出力（$\delta = 10^{-5}$）
Fig. 1 Upper bound on detection power versus the actual detection power

ス版に与えた場合の検出力は 15.5%，16.9%，18.1% となり，いずれもガウス版と一致しない．また δ を小さくするほどこの値は大きくなる．

これに対し，$\alpha = 0.05$ における検出力が一致するように $\varepsilon_{\text{total}} = 2.375$ を逆算して与えた場合は 13.6% となり，ガウス版と一致する．

従来の換算は，式 (4) が与える上界を揃えてはいるものの，実際の検出力を揃えていない．

この状況を検出力の平面上に示したものが**図 1** である．

破線は $\delta = 10^{-5}$ で換算した報告 $(\varepsilon_{\text{total}}, \delta) = (2.769, 10^{-5})$ が式 (4) を通じて許す上界であり，実線は両機構が実際に達成する検出力である．上界は (ε, δ) の 2 つの値のみから定まり，機構の分布の形を用いない．これに対し実際の検出力は，ガウス版では正規分布の，ラプラス版では 19 重合成の二項分布の形から定まる．$\alpha = 0.05$ において報告が許すのは 79.7% であるのに対し，実際の検出力は 13.6% と 15.5% である．報告された (ε, δ) を見るだけでは，破線より下に位置する機構どうしを区別することはできない．

5.3 評価 2：安全性を揃えた上での有用性

実データに NN-Wavelet を適用したときの RMSE を**表 3** および**図 2** に示す．検出力を揃えた条件での RMSE 比は 0.713 であり，エリアレベル 0 ～ 13 では 0.705 ～ 0.713 とほぼ一定であった．14 以降は位置数の減少により 0.686 ～ 0.740 とばらつく．この性質は石岡らによりすでに示されており [9]，比は閉形式

$$\frac{\text{RMSE}_G}{\text{RMSE}_L} = \frac{\varepsilon_{\text{total}}}{2\sqrt{\rho_{\text{total}} L}} = 0.706 \qquad (11)$$

で与えられる．実測値 0.713 はこれと整合する．僅かな差は NN-Wavelet の非負化処理に由来する．

一方，従来の換算で対応付けた場合の比は $\delta = 10^{-5}, 10^{-6}, 10^{-7}$ に対しそれぞれ 0.825，0.907，0.970 であった．従来の枠組みでは，優劣の見え方が δ の選択に左右される．6.2 節で述べるとおり，δ をさらに小さくとれば比は 1 を越え，優劣は逆転する．

表 3: エリアレベル別の RMSE と，レベル 12 における比
Table 3 RMSE by area level and the ratio at level 12

条件	レベル 0	レベル 12	比
ガウス版	2.782	4.495	—
ラプラス版（検出力を揃えた）	3.901	6.304	0.713
ラプラス版（換算 10^{-5}）	3.357	5.451	0.825
ラプラス版（換算 10^{-6}）	3.084	4.958	0.907
ラプラス版（換算 10^{-7}）	2.869	4.632	0.970

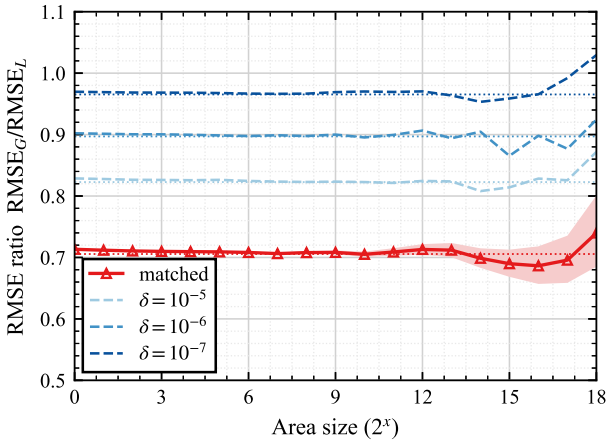


図 2: エリアレベル別の RMSE 比
Fig. 2 RMSE ratio by area level

5.4 評価 3：評価基準の選択に対する頑健性

提案手法も α という選択パラメータを持つ．そこで，α と δ が結論に与える影響を，結論そのものである RMSE 比という同一の量で比較した．α を変える場合は，その α のもとで ρ_{total} と $\varepsilon_{\text{total}}$ の双方を求め直したうえで比を計算する．以下の感度分析は式 (11) による計算であり，その妥当性は表 3 の各条件における実測値との一致により確認できる．結果を**図 3** に示す．

α の定義域のほぼ全体にあたる 0.001 から 0.99 まで，約 990 倍の範囲にわたって振っても，RMSE 比は 0.699 から

© 2026 Information Processing Society of Japan

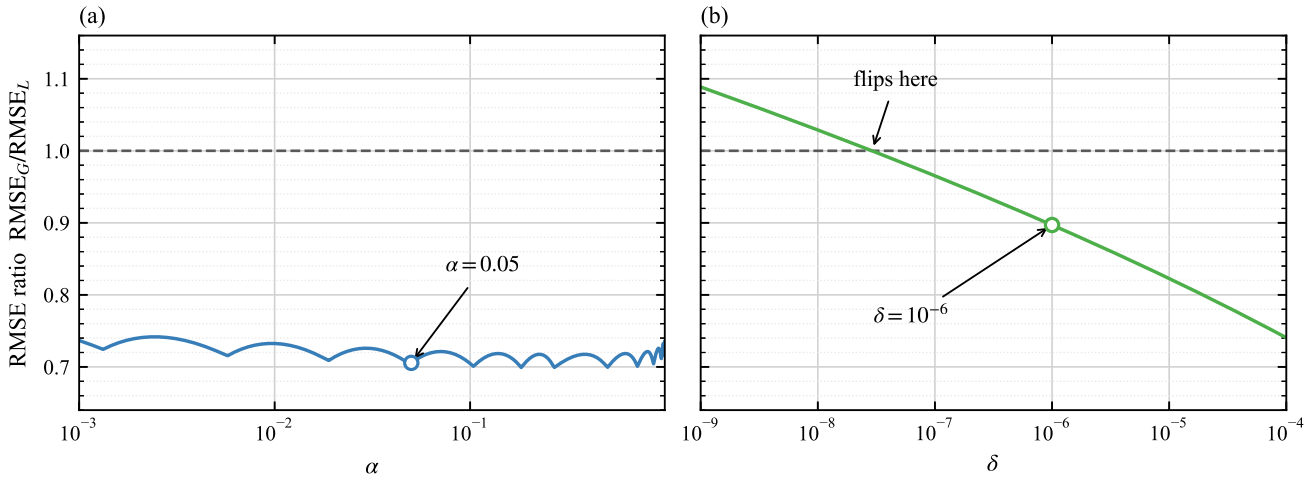


図 3: RMSE 比の感度．(a) α を振った場合，(b) δ を振った場合

Fig. 3 Sensitivity of the RMSE ratio to (a) α and (b) δ

0.742 の間にとどまり，1 に達することはない．α をどう選んでもガウス版が有利という結論は変わらない．一方 δ を 10^{-9} から 10^{-4} で振ると比は 0.740 から 1.089 まで動き，$\delta \approx 2.9 \times 10^{-8}$ で 1 をまたいで優劣が反転する．図 3 の破線は比が 1 となる水準を表し，これに対する両者の挙動の違いが読み取れる．なお (a) に見られる細かな凹凸は，ラプラス版のトレードオフ曲線が 19 重合成に由来する折れ線であるため，α が折れ点をまたぐ際に生じるものである．

この違いは偶然ではなく，両者が比に作用する経路の違いから説明できる．α を変えると目標検出力が変わり，それに応じて ρ_{total} と $\varepsilon_{\text{total}}$ の双方が同じ向きに動く．式 (11) の分子と分母が揃って動くため，安全性の水準自体は変わっても比は保たれる．これに対し δ は，換算を経てラプラス側の $\varepsilon_{\text{total}}$ のみを動かす．ガウス側の ρ_{total} は δ に依存しないため，比は一方向に動くことになる．

振り幅の広さが結果を左右している可能性を排除するため，基準値のまわりに同じ倍率のレンジを取った比較も行った．10 倍・30 倍・100 倍のいずれのレンジにおいても，δ の方が α より 2.8 〜 4.3 倍敏感であった．

さらに両者は，選べる範囲の性質そのものが異なる．α は攻撃者が許容する誤検知率であり $(0, 1)$ に閉じているうえ，上記のとおりその全域にわたって結論が変わらない．一方 δ には下限がなく，$\delta \to 0$ とすれば式 (3) より $\varepsilon_{\text{total}} \to \infty$ となって歯止めがない．両者は分析者が選ぶパラメータという点では同じだが，選択が結論に及ぼす影響の大きさは異なる．

6. 考察

6.1 α-操作的等価 ε の導入がもたらす効果

安全性を揃えるとラプラス版に許される $\varepsilon_{\text{total}}$ はむしろ絞られ，$\delta = 10^{-5}$ の換算値 2.769 に対し 2.375 であり，必要ノイズは増える．

本手法の寄与はノイズ削減ではなく，比較の正しさにある．従来の比較は，実際には検出力 13.6% の機構と 16.9% の機構（$\delta = 10^{-6}$ の場合）を並べていた．これを揃え直した結果，ガウス版の優位は，従来の見積もりの 0.907 より大きい 0.713 であった．先行研究の結論は方向としては正しく，本稿はその差の大きさを改めるものである．

6.2 δ の恣意性の伝播

δ の恣意性は安全性の記述にとどまらず，有用性の優劣という結論にも及ぶ．δ を小さくとると保護が強まるように見えるが，換算後の ε を受け取る側では逆に危険度が上がる．これは δ がガウス側の保証に付随する量でありながら，換算を経てラプラス側の予算を決定するのに用いられているためである．

また α は攻撃者が許容する誤検知率として 0.01 〜 0.10 という慣行の範囲を持つのに対し，δ にはそのような基準がない．本条件では $\delta \approx 2.9 \times 10^{-8}$ が優劣の反転点であり，対象データの総人口 N から定まる $1/N = 2.14 \times 10^{-8}$ に近い領域にあたる．$\delta \ll 1/N$ という慣行に従う場合，従来の枠組みでは結論が反転しうる領域に入る．

δ が表す破局的失敗は，本稿が比較している 2 つの機構のいずれも本来もっていないものである．ラプラス版は $\delta = 0$ であり，ガウス版も zCDP の枠組みでは保証が丸ごと破れる事象を許容していない．それにもかかわらず ADP へ換算すると，両者とも確率 δ でそれを許容する形の保証しか与えられなくなる．δ は，どちらの機構も本来もたない欠陥を導入したうえで，その大きさの選択によって一方の機構の予算を決定している．

© 2026 Information Processing Society of Japan

6.3 非負化処理の影響

式（11）は非負化処理を含まない場合の値であり，実測値との差はこの処理に由来する．非負化はノイズの大きなラプラス版により強く作用するため，細かいエリアレベルでは比が理論値よりわずかに大きくなる．

この差が試行間のばらつきで説明できるものでないことを確認するため，試行に関するブートストラップ（10000回）により比の標準誤差を求めた．エリアレベル 0 では比 0.713，標準誤差 0.0001 であり，閉形式の 0.706 は区間の外にある．一方，エリアレベル 12 では標準誤差が 0.0044 に増大し，閉形式の値は区間に含まれる．非負化による理論値からのずれは細かいエリアレベルでのみ有意に検出され，粗いエリアレベルでは位置数の減少による試行間変動に埋もれる．

この効果の大きさは対象データの疎性に依存する．

7. おわりに

本稿では，(ε, δ) 換算に基づく機構間比較が抱える課題に対し，攻撃者の検出力に基づく α-操作的等価 ε を用いた評価を導入し，NN-Wavelet 環境での実データ評価に適用した．

従来の換算による比較は検出力の上界を揃えるものであり，実際の検出力は揃っていない（$\delta = 10^{-6}$ では 13.6% に対し 16.9%）ことを示した．さらに従来の枠組みでは RMSE 比が δ に依存して 0.740 から 1.089 まで動き，$\delta \approx 2.9 \times 10^{-8}$ を境に優劣が反転する．実際の検出力を揃えて測定した結果，RMSE 比は 0.713 であり，これは δ の選択に依存しない値である．また本手法が導入する α は，δ と異なり結論を動かさないことを確認した．

今後の課題として，本フレームワークの他の合成機構への適用拡大，より広範なデータセットでの検証，α の設定指針の整理，および複数回公開を伴う場合への拡張が挙げられる．

謝辞　本研究は，JST 経済安全保障重要技術育成プログラム (JPMJKP24U5) の支援を受けたものである．

参考文献

[1] Garfinkel, S., Abowd, J. M. and Martindale, C.: Understanding Database Reconstruction Attacks on Public Data, *Communications of the ACM*, Vol. 62, No. 3, pp. 46–53 (2019).

[2] U.S. Census Bureau: Disclosure Avoidance for the 2020 Census: An Introduction, U.S. Government Publishing Office (2021).

[3] Dwork, C.: Differential Privacy, *Proceedings of the 33rd International Conference on Automata, Languages and Programming*, LNCS, Vol. 4052, Springer, pp. 1–12 (2006).

[4] Abowd, J. M., Ashmead, R., Cumings-Menon, R., Garfinkel, S., Heineck, M., Heiss, C., Johns, R., Kifer, D., Leclerc, P., Machanavajjhala, A., Moran, B., Sexton, W., Spence, M. and Zhuravlev, P.: The 2020 Census Disclosure Avoidance System TopDown Algorithm, *Harvard Data Science Review*, No. Special Issue 2 (2022).

[5] Dwork, C., McSherry, F., Nissim, K. and Smith, A.: Calibrating Noise to Sensitivity in Private Data Analysis, *Proceedings of the 3rd Theory of Cryptography Conference (TCC)*, LNCS, Vol. 3876, Springer, pp. 265–284 (2006).

[6] Bun, M. and Steinke, T.: Concentrated Differential Privacy: Simplifications, Extensions, and Lower Bounds, *Proceedings of the 14th International Conference on Theory of Cryptography (TCC)*, LNCS, Vol. 9985, Springer, pp. 635–658 (2016).

[7] Dong, J., Roth, A. and Su, W. J.: Gaussian Differential Privacy, *Journal of the Royal Statistical Society: Series B*, Vol. 84, No. 1, pp. 3–37 (2022).

[8] 寺田 雅之, 鈴木 亮平, 山口 高康, 本郷 節之: 大規模集計データへの差分プライバシの適用, 情報処理学会論文誌, Vol. 56, No. 9, pp. 1801–1816 (2015).

[9] Ishioka, T. and Terada, M.: Utility of the Non-negative Wavelet Mechanism with Zero-Concentrated Differential Privacy, *Advances in Information and Computer Security (IWSEC 2025)*, LNCS, Vol. 16208, Springer, pp. 290–306 (2025).

[10] 寺田 雅之，伊藤 伸介: ε = 19.61 は何を意味するのか：操作的等価 ε に基づく 2020 年米国国勢調査のプライバシー保証の再評価, コンピュータセキュリティシンポジウム 2026 (2026).

[11] Mironov, I.: Rényi Differential Privacy, *Proceedings of the 30th IEEE Computer Security Foundations Symposium (CSF)*, pp. 263–275 (2017).

[12] Kairouz, P., Oh, S. and Viswanath, P.: The Composition Theorem for Differential Privacy, *Proceedings of the 32nd International Conference on Machine Learning (ICML)*, JMLR.org, pp. 1376–1385 (2015).

[13] Gomez, J. F., Kulynych, B., Kaissis, G., Calmon, F. P., Hayes, J., Balle, B. and Honkela, A.: Gaussian DP for Reporting Differential Privacy Guarantees in Machine Learning, *Proceedings of the IEEE Conference on Secure and Trustworthy Machine Learning (SaTML)* (2026).

[14] Kulynych, B., Gomez, J. F., Kaissis, G., Calmon, F. P. and Troncoso, C.: Attack-Aware Noise Calibration for Differential Privacy, *Advances in Neural Information Processing Systems 37 (NeurIPS)* (2024).

[15] Xiao, X., Wang, G. and Gehrke, J.: Differential Privacy via Wavelet Transforms, *Proceedings of the 26th IEEE International Conference on Data Engineering (ICDE)*, pp. 225–236 (2010).

© 2026 Information Processing Society of Japan