サブドメイン名前空間とHTTP特徴を用いたOnion Service共通構造の大規模分析

木村 悠生[1,a)]　RAO Jingjing[2]　上原 哲太郎[2]

概要：Tor の Onion Service では，IP アドレスを秘匿したまま Web サイトを運用できるため，異なる Onion Domain 間の運用上の関係を外部から把握することは難しい．従来研究では Server ヘッダ，HTTP レスポンス，ハイパーリンク等を用いて同一サーバまたは同一運用元の可能性を分析してきたが，サブドメインを含むサービス配備構造の反復は十分に検討されていない．本研究では，約 100 時間の大規模クロールで得た親 Onion Domain と直接隣接サブドメイン名の関係を二部グラフとして表現し，共有サブドメイン名数，極大完全二部部分グラフ，高密度成分を抽出する．さらに，クローラで収集したデータアーカイブから HTML 本文，HTML 構造，可視テキスト，HTTP ヘッダ，Cookie 名，静的資源の特徴を抽出し，共有構造が複製コンテンツまたは共通基盤を伴うかを検証した．分析結果より，異なる親 Onion Domain 群において，サブドメイン分類体系とコンテンツを一体として反復展開する配備構造が存在することを示した．

Large-scale Analysis of Shared Onion Service Structures Using Subdomain Namespaces and HTTP Features

Yuuki Kimura[1,a)]　Jingjing Rao[2]　Tetsutaro Uehara[2]

Abstract: Onion Services allow websites to conceal their server IP addresses, making operational relationships across distinct onion domains difficult to observe. This study models parent Onion Services and their directly adjacent subdomain labels as a bipartite graph, and extracts repeated labels, maximal bicliques, and dense components. We then validate the resulting structures using HTTP features extracted from archived responses, including exact body hashes, HTML structure, visible-text fingerprints, headers, cookie names, and static resources. The results demonstrate large-scale repeated deployment of subdomain taxonomies together with content across distinct parent onion domains. They do not, by themselves, prove a common operator; shared hosting, automated deployment, and content copying remain alternative explanations.

1. はじめに

Tor は通信経路を多段に中継することで通信主体の匿名性を高める匿名通信システムである [1]．Tor の機能である Onion Service を利用すると，サーバの IP アドレスを公開せずに TCP サービスを提供できる [2]．この性質は検閲耐性やプライバシ保護に有用である一方，複数の Onion サイトが同一の基盤または運用主体により提供されているかを，IP アドレスや DNS 情報から判断することを困難にする．

筆者らはこれまで, Server ヘッダやエラー応答等の Server Fingerprint を用いた運用元特定可能性 [3], [4] や，ハイパーリンクグラフと Server ヘッダの関係 [5]，約 20 万 Onion Domain の HTTP レスポンス分布 [6], [7] を調査した．これらの研究から，少数の基盤に多数の Onion サイトが収容される可能性や，同一内容のサイトが多数展開される事例が示された．また，コンテンツとリンク関係を用いた類型化では，同一内容のコピー，リスク分散，複数サービスによる情報・経済圏の形成が運用動機として考察した [8]．

トップページの内容が似ていることは同一の配備基盤ま

[1] 立命館大学大学院情報理工学研究科
Graduate School of Information Science and Engineering, Ritsumeikan University
[2] 立命館大学情報理工学部
College of Information Science and Engineering, Ritsumeikan University
[a)] ykimura@cysec.cs.ritsumei.ac.jp

© 2026 Information Processing Society of Japan

This paper is work in progress and not peer-reviewed.

たは運用主体に属するサイトの候補を見つける有力な手掛かりであるが，候補サイトが，常に同じタイトルや本文を返すとは限らない．筆者らの先行研究では，同一運用元と判定した 97 サイト群のうち，21 群はカテゴリのみが同じでタイトルが異なり，13 群はカテゴリとタイトルの双方が異なっていた [8]．また，内容の異なる 10 個の Onion サイトについて，Host ヘッダの書換えにより同一サーバ上のバーチャルホストであることを確認している [7]．したがって，トップページのタイトルや本文の一致を出発点とする方法では，異なる役割のサイトを同じ基盤上で運用する場合や，入口ごとにトップページを変更する場合を候補から除外する可能性がある．他方で，知りうるすべての Onion サイトから，候補サイトを探索することは非効率である．

そこで本研究では，ページの内容そのものではなく，親 Onion Domain の下にどのようなサブドメイン名を配置したかという名前空間に着目する．異なる親 Onion Domain で多数のサブドメイン名が一式として反復される場合，個々のトップページが異なっていても，共通の設定テンプレートや同一運用元であるなどの共通点が存在する可能性があると考えられる．

本研究では，次の 3 段階の分析を行う．第一に，親 Onion Domain と直接隣接サブドメイン名の観測関係を二部グラフとして表現し，多数のサブドメイン名を共有する親ペア，極大完全二部部分グラフ，高密度成分を抽出する．第二に，保存済み HTTP 応答から複数の特徴を抽出し，名前の共有が複製コンテンツまたは共通配備基盤の特徴を伴うかを検証する．第三に，HTTP/1.1 の Host ヘッダを書き換える実験を行い，抽出した親ペアが共通の基盤に収容されているかを検証する．

本稿の貢献は次の 3 点である．

(1) サブドメインを持つことが観測された 3,305 親 Onion Domain と 302,963 関係を対象に，直接隣接サブドメイン名の反復構造を大規模に分析した．
(2) 強い共有構造を持つ候補について，本文，HTML 構造，可視テキスト，HTTP レスポンスヘッダ，Cookie 名，静的資源を複合的に照合した．
(3) 観測結果が直接支持する「共通配備構造」と，追加証拠を要する「同一物理サーバ」「同一運用者」を区別した．

2. 研究背景

2.1 Onion Service

Onion Service は，サーバの IP アドレスを公開せずに TCP サービスを提供する Tor の機能である [9]．クライアントとサーバは Tor ネットワーク内にそれぞれ回線を構築し，ランデブーポイントを介して接続する．このため，クライアントはサーバの IP アドレスを知ることなくサービスを利用でき，サーバ側もクライアントの IP アドレスを直接取得しない．

Onion Service に割り当てられる名前を Onion Domain と呼ぶ．v3 Onion Domain は，公開鍵等から導出される 56 文字の Base32 文字列と `.onion` から構成される．本稿では，この名前によって識別される Tor 上のサービスを Onion Service，その名前を Onion Domain として区別する．

2.2 Onion ホストとサブドメイン

Onion Domain には，通常のドメイン名と同様にサブドメインを付加できる．Tor は Onion Domain より前に付加されたサブドメインを接続先の決定には用いず，HTTP の Host ヘッダとして Web サーバへ渡す．したがって，Web サーバはサブドメインごとに異なるコンテンツを返すことができる [10]．

以下では，例として `news.shop.X.onion` を用いる．ここで `X` は 56 文字の文字列を表す．本稿で用いる用語を次のように定義する．

親 Onion Domain　サブドメインを除いた `X.onion` である．サブドメインを含む複数の Onion ホストをまとめる単位として用いる．

Onion ホスト　HTTP 要求の宛先となる完全なホスト名である．上の例では `news.shop.X.onion` を指す．

サブドメイン　親 Onion Domain の前に名前を付加して構成した領域である．上の例では，`shop.X.onion` は `X.onion` のサブドメインであり，`news.shop.X.onion` はさらにその下位のサブドメインである．

直接隣接サブドメイン名　親 Onion Domain の直前にあり，親直下のサブドメインを識別する名前である．上の例では `shop` が該当する．`news` は親から 2 階層離れた名前であり，本研究の共有数の集計には含めない．すなわち，本研究では完全なサブドメイン `news.shop` ではなく，異なる親の直下で `shop` 等の同じ名前が反復しているかを分析する．

通常の Web サービスでは，名前ベースのバーチャルホストにより単一の IP アドレス上で複数ホスト名でサービスを提供できる．Onion Service でも Web サーバまたはリバースプロキシが Host ヘッダを用いてコンテンツを切り替えられるが，Onion Domain から接続先 IP アドレスを取得できないため，IP アドレスの一致を用いた検証はできない．

3. 関連研究

Pastor-Galindo らは，Onion Domain の収集に関する既存研究を体系的に整理し，各収集手法とデータの代表性を調査した [11]．その結果，既存研究の多くは Onion Domain の一部のみを対象とし，網羅的収集が困難であることを明らかにした．

Bernaschi らは，Onion サイトのリンク構造とコンテン

© 2026 Information Processing Society of Japan

ツの関係を調査した [12]．その結果，リンク集が中心的な役割を持つこと，および不審な活動に関係するサイトには複製サイトが多いことを明らかにした．

Boshmaf らは，大規模な Onion Service クローラ Dizzy を開発し，39,536 件の Onion Domain から 6,326 万件以上のページを収集・分析した [13]．その結果，Onion Service は変動が大きく，75.5%が他のドメインと視覚的またはテキスト的に類似することを明らかにした．

筆者らは Onion サイト間のハイパーリンクをグラフとして可視化し，情報量の多い Server ヘッダを持つサイトでは，グラフ上の距離と Server ヘッダの類似性に関係があることを明らかにした [5]．また，約 20 万件の Onion Domain へ HTTP/1.1 および HTTP/1.0 でリクエストを行い，HTTP レスポンスの傾向を調査した [6], [7]．その結果，Server ヘッダや HTML タイトルの分布がサーフェス Web と異なること，および少数の基盤が多数の Onion サイトをホストしている可能性を明らかにした．さらに，同一サーバで運用されると推定した Onion サイト群のコンテンツとハイパーリンクを可視化し，同一内容を複製する群と，異なる役割のサイトを相互に接続する群を確認した [8]．同一運用元と判定した 97 群のうち，21 群はカテゴリのみが同じでタイトルが異なり，13 群はカテゴリとタイトルの双方が異なっていた．

以上の研究では，Onion Domain 単位のコンテンツ，HTTP 特徴，ハイパーリンク構造が主な分析対象であり，異なる親 Onion Domain 間でサブドメインの分類体系がどの程度反復しているかは明らかにされていない．また，タイトルや本文が異なるサイトを共通配備候補として網羅的に絞り込む方法は十分に検討されていない．本研究では，サブドメイン名の共有構造を用いて候補を抽出し，HTTP 応答と Host ヘッダ書換え実験によって共通配備基盤を段階的に検証する．

4. データ収集

4.1 クローラ

分析データは，URL の永続キュー，複数 Tor SOCKS5 エンドポイントへの負荷分散，失敗時の再試行，HTTP 応答の保存を備えたクローラにより収集した．2026 年 7 月 20 日 15 時 00 分 UTC から同月 24 日 19 時 00 分 UTC までの約 100 時間，20 個の Tor プロセスと 480 Worker でクロールを実施した．同一親への過度なアクセスを避けるため，親単位の時間当たり要求数，親当たり URL 数，親当たりサブドメイン数，各サブドメイン当たり URL 数に上限を設けた．

取得した HTTP 応答は，URL，取得日時，HTTP レスポンスヘッダおよび本文を ARC 形式 [14] で連続保存した．本稿では，クローラによって得られた保存データをアーカイブと呼ぶ．

合計 6,066,311 件の HTTP 要求を行い，3xx，4xx，5xx を含む 4,173,063 件の応答を取得・保存した．クロール終了時には 8,109,807 URL，28,346 親 Onion Domain，332,441 Onion ホストが記録され，14,568 親から 1 件以上の応答を得た．

4.2 分析対象

本研究のサブドメイン関係データは，収集済みリンクグラフから有効な v3 Onion ホスト，すなわち HTTP 要求の宛先となる完全な Onion ホスト名を抽出して構成した．同一の親とサブドメイン名の関係は重複除去した．このデータはクローラが発見して永続キューへ登録した Onion ホストの索引であり，HTTP 応答の取得に成功したホストだけを収録したものではない．したがって，未接続，接続失敗，3xx，4xx，5xx 応答のホストも含み得る．このうち，直接隣接サブドメイン名が 1 個以上観測された親 Onion Domain 3,305 件を分析対象とした．

また，異なる多数の親で `shop` を観測しても，サブドメイン名 `shop` は 1 種類と数えると，全親を通じて観測された異なるサブドメイン名は 10,614 種類であった．親とサブドメイン名の異なる組合せは 302,963 組であった．

4.3 倫理上の配慮

Tor Research Safety Board の指針 [15] を参照し，チェックリストにより倫理上の問題がないことを確認した．クロールは公開状態の Onion Web ページに対する GET 要求に限定し，認証回避，フォーム送信，脆弱性探索は行わなかった．親単位およびサブドメイン単位の上限を設け，失敗時にはバックオフを行った．保存データは研究目的に限定して管理し，分析用特徴には Cookie 値や可視テキスト本文を含めなかった．本稿は，同一運用基盤等を用いているサービスを抽出できるかを検討するものであって，特定のサービスの匿名性を解除し，またサービスの運用者を特定することを目的とするものではない．

5. 分析手法

5.1 共有サブドメイン名構造の抽出

親とサブドメイン名の対応を，2 種類の点とそれらを結ぶ線からなるグラフとして考える．左側には親 Onion Domain，右側には直接隣接サブドメイン名を並べ，ある親でそのサブドメイン名を観測したときだけ両者を線で結ぶ．例えば，`A.onion` で `shop` と `forum` を観測し，`B.onion` で `shop` と `news` を観測した場合，グラフは図 1 のようになる．

このように，線が必ず異なる 2 種類の点の間だけに存在するグラフを二部グラフという．

5.1.1 極大完全二部部分グラフ

共有数だけでは，2 親が多数のサブドメイン名を共有する構造と，多数の親が同じ少数のサブドメイン名を共有す

© 2026 Information Processing Society of Japan

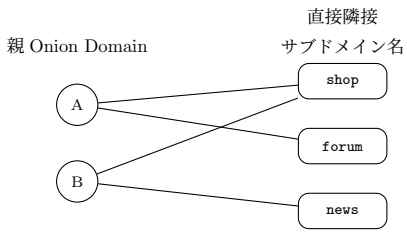


図 1 親 Onion Domain と直接隣接サブドメイン名の二部グラフ

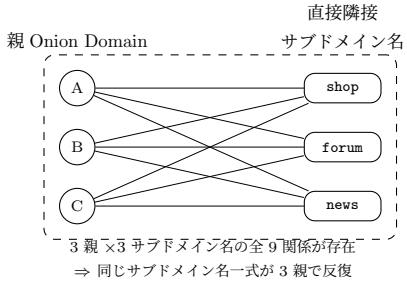


図 2 極大完全二部部分グラフの例

る構造を区別しにくい．そこで，複数の親と複数のサブドメイン名のまとまりを抽出する．例えば，親 A，B，C のすべてで `shop`，`forum`，`news` の 3 サブドメイン名が観測された場合，3 親 ×3 サブドメイン名の全 9 通りに関係が存在する．このように，選んだ親集合とサブドメイン名集合の全組合せに関係がある構造を完全二部部分グラフという．

さらに，親またはサブドメイン名を 1 つ追加しても全組合せの関係を保てる場合，元の構造はより大きな同種の構造に含まれる．本研究では，これ以上親もサブドメイン名も追加できないところまで広げたものだけを残したものを「極大完全二部部分グラフ」と呼ぶ．

図 2 では，親 A，B，C のいずれにも `shop`，`forum`，`news` への線がある．この 9 本の線のうち 1 本でも欠ければ，この 3 親と 3 サブドメイン名の組合せは完全二部部分グラフではない．さらに親またはサブドメイン名を追加できない場合に，このまとまりを極大完全二部部分グラフとして抽出する．

5.1.2 親同士のまとまりと高密度成分

極大完全二部部分グラフは全組合せが揃う厳格な条件であるため，一部のサブドメイン名が未観測でも全体として似た親群を別に調べる．まず，各親を 1 つの点に置き換え，5 個以上のサブドメイン名を共有する 2 親の間を線で結ぶ．元の二部グラフからサブドメイン名側を省き，親同士の関係へ写し替える．この親同士のグラフで，線をたどって互いに到達できる親のまとまりを連結成分とする．各成分に含まれる親が使用したサブドメイン名を集め，実際に観測された親・サブドメイン名関係数を，成立し得る全組合せ数（親数 × サブドメイン名数）で割った値を密度とする．例えば 10 親と 20 サブドメイン名からなる成分では最大 200 関係が成立し得るため，160 関係を観測した場合の密度は 0.8 である．密度が 1 に近いほど，成分内の多くの親が似たサブドメイン名集合を繰り返し使用している．本稿では，この密度が高い連結成分を高密度成分と呼ぶ．

5.2 アーカイブからの特徴抽出

クロールで得たデータについて，高密度成分から，強い共有構造を持つ親ペアを抽出した．

強い共有構造を詳細に検証するため，次のいずれかを満たす親の和集合を候補とした．

- 他の親と 80 個以上の直接隣接サブドメイン名を共有する．
- 3 親 ×3 サブドメイン名以上の極大完全二部部分グラフに含まれる．

候補は 395 親である．

アーカイブから候補に属する HTTP 応答のみを抽出し，1 応答につき後述の属性を 1 組にまとめたものを「特徴レコード」とした．特徴レコードには，URL，取得日時，HTTP ステータス，Content-Type，本文サイズ，本文 SHA-256，Server，Location，ヘッダ名集合，Cookie 名，HTML タイトル，HTML 構造 SHA-256，HTML 構造 SimHash，可視テキスト SimHash，参照 Onion ホスト，静的資源ハッシュを記録した．Cookie 値，レスポンス本文，可視テキストそのものは分析用ファイルに保存しない．HTML 以外の画像，CSS，JavaScript 等も対象としたのは，異なる HTML 本文を返すサイトであっても，同じ配備基盤やテンプレートを用いる場合には同一の静的資源を共有する可能性があるためである．

さらに，サブドメインを見ることでトップページ単位の比較では得られない候補を抽出できるかを確認するため，親 Onion Domain 自体のルートパス/に対する 2xx HTML 本文と，直接隣接サブドメインのルートパスに対する 2xx HTML 本文を別に集計した．

5.3 親ペアの類型化

比較単位を「親 Onion Domain× 直接隣接サブドメイン名」とし，共有サブドメイン名に対応する正常応答を親ペア間で比較する．類型は次の優先順で付与する．

複製コンテンツ 1 サブドメイン名以上で HTML 本文 SHA-256 が完全一致する，または 2 サブドメイン名以上で HTML 構造と可視テキスト特徴が一致する．

共通基盤 複製コンテンツには該当しないが，HTML 構造，HTTP ヘッダと Cookie 名の組，出現親数 20 以下の静的資源ハッシュのうち，独立した技術特徴が複合一致する．

分類体系の再利用 3 サブドメイン名以上を共有するが，技術特徴による十分な裏付けを得られない．

サブドメイン名のみの共有 2 サブドメイン名を共有するが，技術特徴による裏付けを得られない．

© 2026 Information Processing Society of Japan

アーカイブ不足　共通サブドメイン名について両親の正常応答を比較できない．

5.4　Host ヘッダ書換え実験

共有サブドメイン構造が，共通の運用基盤を伴うかを検証する．親 A に属する Onion ホストへ接続したまま，HTTP/1.1 の Host ヘッダだけを親 B 側の Onion ホストへ書き換える．各比較では，親 A へ通常どおり要求する source，親 B へ通常どおり要求する target，親 A へ接続して Host を親 B とする cross，親 A へ接続して Host をランダムな v3 Onion ホストとする control の 4 応答を取得する．control に指定する Host 名は，実在する親と重複しないよう決定的に生成した未登録の v3 Onion 形式の名前である．以下，この control を「ランダム Host 対照」と呼ぶ．

HTTP ステータスと本文 SHA-256 について，cross が target と一致し，cross が source および control と異なる場合を Host 切替陽性とする．これは，親 A への接続経路の先に，親 B の Host 名を認識して対応コンテンツを返す基盤が存在することを意味する．source と target が同一の場合は，Host による切替と同一コンテンツの複製を区別できないため，陽性とは判定しない．

表 1 に 4 種類の要求方法を示す．source と cross はともに親 A へ接続するが，Host ヘッダだけが異なる．したがって，cross が親 B へ通常接続した target と同じ応答になり，source およびランダム名を用いた control と異なれば，親 A への接続経路の先で親 B の Host 名に応じた切替が行われたと判断できる．

実験群には共有構造を持つ 20,933 親ペアを用いた．比較のため，同じ候補親の中から共有サブドメイン名数が 2 未満の 20,000 親ペアを対照群として選んだ．ここで 1 つの「比較組合せ」とは，接続元となる source の Onion ホスト，切替先となる target の Onion ホスト，要求パス/および書換え方向を組み合わせたものである．各親ペアについて A から B と B から A の両方向に最大 3 組，すなわち最大 6 組の比較組合せを用意した．アーカイブ上の source と target の本文 SHA-256 が異なり，Host 書換えによる応答の切替と単なる同一本文を区別できる組合せを優先した．最終的に 33,807 親ペアについて 201,993 方向別比較を構成し，重複を除いた 211,433 件の HTTP 要求を実行した．

6.　結果

6.1　共有サブドメイン名の規模

10,614 種類の直接隣接サブドメイン名のうち，8,377 種類は複数の親で観測された．すなわち，サブドメイン名の多くは特定の 1 親だけに固有ではなかった．

次に，3,305 親から異なる 2 親を選ぶ場合について，2 種類以上のサブドメインを共有する親ペアは 485,504 組（8.9%）であった．表 2 では，例えば「20」の行は，20 種類以上のサブドメイン名を共有した親ペアが 300,284 組あり，そこに 3,019 親が関係したことを表す．最大共有数は 90 であり，該当する親ペアは 8 組であった．

6.2　極大完全二部部分グラフと高密度成分

まず，同じサブドメイン名一式を共有する親のまとまりを調べた．極大完全二部部分グラフについて，親数 × サブドメイン名数を構造の規模を表す値とし，その値が大きい順に上位 10,000 件を保存した．ここで 111 親 ×2 サブドメイン名という結果は，111 個の親 Onion Domain のすべてである共通の 2 種類のサブドメインが観測されたことを意味する．これに対して 2 親 ×90 サブドメイン名は，2 個の親だけのまとまりであるが，その 2 親が 90 種類ものサブドメイン名を共有したことを意味する．主な構造として，111 親 ×2 サブドメイン名，103 親 ×2 サブドメイン名，43 親 ×4 サブドメイン名，26 親 ×5 サブドメイン名，および 2 親 ×90 サブドメイン名が得られた．3 親 ×3 サブドメイン名以上の構造は 46 件で，275 親が含まれた．

次に，すべての親で同じサブドメイン名一式がそろうことまでは求めず，全体として似た親群を調べた．具体的には，5 種類以上のサブドメイン名を共有する親同士を線で結び，その線をたどって到達できる親を 1 つのまとまりとした．この親同士のグラフには 18 個のまとまりがあり，合計 3,059 親を含んだ．最大 3 成分の親数は 512，492，376 であった．また，57 親・128 サブドメイン名・密度 0.781，および 100 親・177 サブドメイン名・密度 0.565 の高密度成分を確認した．前者は，57 親と 128 種類のサブドメイン名の間で成立し得る 7,296 関係のうち，約 78.1%を観測したことを表す．完全二部部分グラフほど全関係がそろってはいないものの，親群の大部分が同じサブドメイン名群を共有するまとまりである．この結果から，単に 1 種類の一般的なサブドメイン名が多数の親で使われていただけではなく，複数のサブドメイン名を一式として共有する親群と，一部のサブドメイン名は欠けるものの全体としてよく似たサブドメイン名集合を持つ親群の両方が存在することが分かった．

6.3　アーカイブ収録状況

名前の共有が特に強い 395 親のうち 390 親について，アーカイブから 1 件以上の HTTP 応答を取り出すことができた．候補親に属する保存 HTTP 応答ごとに，本文ハッシュ，HTML 構造，HTTP ヘッダ，Cookie 名等を 1 組にまとめた比較用データを作成した．以下，この 1 組を特徴レコードと呼ぶ．抽出した特徴レコードは 546,948 件となった．このうち，正常応答として分析対象にした 2xx 応答は 543,393 件であり，HTML 応答が 377,090 件，画像，CSS，JavaScript 等の HTML 以外の応答が 166,303 件であった．HTML 以外の応答は，共有される静的資源の本文ハッシュ

© 2026 Information Processing Society of Japan

表 1 Host ヘッダ書換え実験で取得する 4 種類の応答

名称	実際の Onion 接続先	Host ヘッダ	比較上の役割
source	親 A	親 A の Onion ホスト	書換え前の親 A の応答
target	親 B	親 B の Onion ホスト	切替先として期待する親 B の応答
cross	親 A	親 B の Onion ホスト	Host だけを書き換えた応答
control	親 A	未登録のランダムな Onion ホスト	未知の Host 名に対する応答

陽性条件：cross = target，かつ cross ≠ source，cross ≠ control

表 2 直接隣接サブドメイン名の共有

共有数の下限	親ペア数	関係する親数
2	485,504	3,132
5	455,694	3,059
20	300,284	3,019
40	107,487	1,757
60	12,317	528
80	1,470	120

表 3 候補親ペアの類型化結果

類型	親ペア数	関係する親数
複製コンテンツ	17,879	352
共通基盤	183	24
分類体系の再利用	47	25
サブドメイン名のみ	8	9
アーカイブ不足	2,816	332

を比較し，HTML 本文が異なる場合にも配備基盤の共通性を調べるために用いた．アーカイブ上で比較に利用できた直接隣接サブドメイン名は 680 種類，親とサブドメイン名の組は 27,802 組であった．分析対象 20,933 親ペアのうち，共通サブドメイン名について両側のアーカイブを比較できたものは 18,117 組であり，次節以降で類型化した．

6.4 親トップページと共有サブドメイン名の比較

複製コンテンツに分類された 17,879 親ペアのうち，双方の親トップページをアーカイブから比較できたものは 11,680 組であった．このうち 8,981 組では，親トップページの HTML 本文 SHA-256 は一致しなかった一方，共有サブドメイン名に対応するサブドメインのルートページで 1 件以上の HTML 本文 SHA-256 が一致した．さらに，8,683 組では 10 サブドメイン名以上，6,082 組では 20 サブドメイン名以上のサブドメインで本文が一致した．

したがって，親トップページの本文完全一致だけでは除外される親ペアでも，サブドメインまで比較すると多数の対応ページが一致する場合がある．ただし，動的な時刻や識別子等による不一致もあり，意図的な偽装を意味するとは限らない．

6.5 HTTP 特徴による類型化

表 3 に結果を示す．「複製コンテンツ」は，共有サブドメイン名に対応するページ本文，または HTML 構造と可視テキストが一致した親ペアである．「共通基盤」は，本文の複製とは判定されなかったが，HTTP ヘッダ，Cookie 名，静的資源等の複数の技術的特徴が一致した親ペアである．比較可能な 18,117 ペアに限ると，複製コンテンツは 17,879 組（98.7%），共通基盤は 183 組（1.0%），分類体系の再利用は 47 組（0.26%），サブドメイン名のみの共有は 8 組（0.04%）であった．複製コンテンツのうち 17,809 組は 1 サブドメイン名以上で HTML 本文が完全一致し，残る 70 組は 2 サブドメイン名以上で HTML 構造と可視テキスト特徴が一致した．

複製コンテンツ群における共有サブドメイン名数の中央値は 43，アーカイブで比較可能な共有サブドメイン名数の中央値は 40，本文完全一致サブドメイン名数の中央値は 22 であった．したがって，結果は単一の共通エラーページや偶然のテンプレート一致だけではなく，複数のサブドメイン名にまたがる反復を含む．

複製コンテンツに分類された 352 親は 5 連結成分を形成した．大きい 4 成分はそれぞれ 162，63，56，51 親からなり，各成分内の全親ペアが複製コンテンツに分類された完全グラフであった．また，候補親を 2 件以上含む極大完全二部部分グラフ 4,499 件のうち，4,428 件が複製コンテンツ，1 件が共通基盤，70 件がアーカイブ不足であった．

6.6 Host ヘッダ書換え実験の結果

Host ヘッダ書換え実験では，接続先を親 A のままとし，Host ヘッダだけを親 B 側の名前に変更したとき，親 B へ通常接続した場合と同じ応答へ切り替わるかを調べた．予定した 211,433 要求のすべてを実行し，123,781 件（58.5%）で HTTP 応答を取得した．通常取得では 4,582/4,723 件（97.0%）が成功した一方，分析手法で定義したランダム Host 対照では，4,528/4,717 件（96.0%）が HTTP 応答の開始前に接続を閉じられた．この差から，通常取得が成功している場合のランダム Host 対照に対する切断を，未知の Host 名を拒否した結果として扱った．

方向別 201,993 比較のうち，527 比較で cross が target と一致し，source および control とは異なるという結果を示した．これらは 494 親ペアに対応し，19 親ペアでは双方向，475 親ペアでは片方向の Host 切替を確認した．33,020 親ペアでは Host 切替を確認できなかった．残る 293 親ペアでは，source または target の通常応答，cross，ランダム Host 対照のいずれかを必要な条件で取得できず，両方向の

© 2026 Information Processing Society of Japan

表 4　共有構造群と対照群の Host 切替結果

群	判定可能	陽性	陽性率
共有構造群	18,029	451	2.50%
対照群	15,485	43	0.278%

いずれについても陽性条件を評価できなかった．この 293 親ペアを判定不能とした．

表 4 に，共有構造群と対照群の比較を示す．共有構造群の陽性率は対照群の約 9.0 倍であった．二項比率に対する Wilson のスコア区間 [16] による 95%信頼区間は，共有構造群が 2.28–2.74%，対照群が 0.206–0.374%であり，両群の区間は重ならなかった．

アーカイブから抽出した特徴に基づいて共通基盤と分類した群では，判定可能な 141 親ペアのうち 48 親ペア（34.0%）で Host 切替を確認した．これは対照群の陽性率の約 123 倍であった．複製コンテンツ群では 17,871 親ペアのうち 402 親ペア（2.25%）が陽性であり，対照群の約 8.1 倍であった．したがって，名前の共有が強い群では，ほとんど共有しない対照群よりも Host 切替が確認されやすかった．以上から，共有サブドメイン名構造とアーカイブから抽出した特徴の組合せにより，共通 HTTP 配備基盤を持つ親ペアを対照群より高い割合で抽出できた．

7. 考察

7.1 サブドメイン名前空間を含む反復配備

異なる親 Onion Domain 群で，数十個のサブドメイン名と対応する HTML 本文が一体として反復しており，共通の配備規則の存在が示唆される．実際に，親トップページ本文が完全一致しない 8,981 親ペアでも，共有サブドメイン名に対応するページでは本文完全一致を確認した．したがって，本手法は親トップページの本文一致を必要条件とせず，共通配備候補を抽出できる．

筆者らの先行研究では，コピーサイトの乱立がサイト数に基づくコンテンツ統計を歪める可能性を指摘している [8]．本結果から，重複除去の単位は本文ハッシュが一致する単一ページだけでなく，親 Onion Domain 群とサブドメイン分類体系のまとまりまで拡張する必要があると言える．

7.2 反復配備を行う運用動機

同じサブドメイン分類体系を異なる親 Onion Domain へ反復する動機として，少なくとも次の 4 種類が考えられる．ただし，これらは観測結果と整合する仮説であり，本研究だけから個々の親群の動機を確定するものではない．

第一は，停止やブロックに備えたリスク分散である．同じサービスを複数の親へ複製しておけば，一部の Onion Domain が停止した場合にも，別の親を入口として提供を継続できる．この場合，サブドメイン名集合だけでなく，対応する各サブドメイン名の本文や静的資源も広く一致すると予想される．

第二は，役割またはテナントの分離である．サブドメイン名をコンテンツ種別，言語，顧客等に対応させる管理方式をテンプレート化し，顧客やブランドごとに異なる親 Onion Domain へ展開することが考えられる．共通の管理基盤を用いながら本文を差し替える場合，サブドメイン名集合，Cookie 名，HTTP ヘッダ，HTML 構造等は一致する一方，本文は一致しない可能性がある．本研究の「共通基盤」および「分類体系の再利用」に分類された親ペアは，この仮説と整合する．

第三は，自動配備ツールの設計に由来する反復である．設定テンプレートにサブドメイン一覧，リバースプロキシ規則，コンテナ構成等を記述し，親 Onion Domain だけを変更して一括展開すれば，同じサブドメイン名体系が機械的に再現される．この場合，短期間に多数の親が追加され，エラーページ，Server ヘッダ，静的資源等にも共通性が現れると予想される．

第四は，複数サービスを結び付ける経済圏の形成である．マーケット，決済，案内，フォーラム等を別の親またはサブドメインに分けつつ，共通の分類規則と導線で接続すれば，利用者を関連サービス内に誘導できる可能性がある [7], [8]．この仮説を検証するには，サブドメイン名と本文の一致だけでなく，親群をまたぐハイパーリンク，決済識別子，連絡先等の役割関係を調べる必要がある．

以上の四種類の動機は排他的ではない．例えば，自動配備ツールを用いて経済圏を複製し，同時にリスク分散を図ることも可能である．今後は，本文一致率，技術特徴，生成時期およびリンク関係を組み合わせ，親群ごとにどの仮説が最も整合するかを評価する必要がある．

7.3 共有構造による候補抽出の有効性

共有構造群の Host 切替陽性率は対照群の約 9.0 倍，共通基盤と分類した群では約 123 倍であった．したがって，サブドメイン名の共有は共通 HTTP 配備基盤を探索する手掛かりであり，アーカイブから得た複数特徴との組合せにより候補をさらに絞り込める．

一方，複製コンテンツ群の大部分では Host 切替を確認できなかった．複製コンテンツは，別の基盤へのコピー，実験までの構成変更，Host 名に対するアクセス制限等によっても生じる．したがって，コンテンツの複製と，ライブ環境における共通 HTTP 基盤は区別して扱う必要がある．

7.4 今後の検証方針

今後は，同じ親ペアに対する Host 書換えを日時や Tor 回線を変えて再測定し，エラー応答を含む切替の再現性を確認する．また，一般的な Server ヘッダよりも，希少な静的資源，Cookie 名，リダイレクト先および更新時刻の一致

© 2026 Information Processing Society of Japan

を強く評価し，独立した特徴を組み合わせる必要がある．

利用可能な場合は TLS 終端特徴も補助的に用いる．各証拠が支持する範囲を，共通コンテンツ，共通 HTTP フロントエンド，共通生成・配備過程，同一運用主体に分け，単一特徴に依存せず評価する必要がある．

7.5 制約

第一に，候補 395 親は強い共有構造に基づいて事前選択しており，98.7%という割合を Onion Web 全体へ一般化できない．共有数に基づく層化抽出により，この偏りを測定する必要がある．第二に，クロールには親当たりの URL 数等の上限と発見順序の影響があり，辺がないことは未観測を意味し得る．第三に，395 親中 5 親，2,816 親ペアはアーカイブ不足であった．第四に，完全一致本文でも共通のエラー画面やテンプレートの可能性があり，時間同期した更新等の検証を要する．第五に，Host 切替陽性は，接続先に相手の Host 名を認識する HTTP 基盤が存在することを示すが，物理サーバ，ホスティング事業者，運用者の同一性は区別できない．第六に，動的な本文では SHA-256 による判定が陰性となり得る．

8. おわりに

本研究では，親 Onion Domain と直接隣接サブドメイン名の関係を二部グラフとして表現し，異なる親間で反復するサブドメイン名前空間を分析した．サブドメインを持つことが観測された 3,305 親と 302,963 関係から，2 個以上のサブドメイン名を共有する 485,504 親ペア，ならびに多数の極大完全二部部分グラフと高密度成分を確認した．強い共有構造から選定した 395 親についてアーカイブから抽出した特徴を比較した結果，比較可能な 18,117 親ペアのうち 17,879 組で複製コンテンツの証拠を得た．さらに，Host ヘッダ書換え実験では，共有構造群の 451/18,029 親ペア（2.50%）で共通 HTTP 配備基盤を確認した．この割合は，共有サブドメイン名数が 2 未満の対照群の 43/15,485 親ペア（0.278%）と比較して約 9.0 倍であった．この結果は，サブドメイン分類体系とコンテンツを一体として反復する大規模な配備構造が存在し，共有サブドメイン名構造が共通 HTTP 配備基盤を探索するための有効な手掛かりであることを示している．

今後は，共有数の各範囲から層化抽出した親ペアを比較して候補選択の偏りを評価する．また，複数時点の Host 書換えと独立した技術的特徴を組み合わせ，各証拠が支持する配備基盤の範囲を検証する必要がある．

参考文献

[1] Dingledine, R., Mathewson, N., Syverson, P. F. et al.: Tor: The second-generation onion router., *USENIX security symposium*, Vol. 4, pp. 303–320 (2004).

[2] TorProject: Tor Project — Onion Services, `https://community.torproject.org/onion-services/`. (Accessed on 2025/01/26).

[3] 木村悠生，穐山空道，猪俣敦夫，上原哲太郎：Onion Service における Server Fingerprint の収集及び運用元特定可能性の検討，信学技報，ICSS2022-75, Vol. 122, No. 422, 沖縄，pp. 163–168 (2023).

[4] Kimura, Y., Akiyama, S., Inomata, A. and Uehara, T.: On Collecting Onion Server Fingerprints and Identification of Their Operators, *IEEE International Conference on Software Quality, Reliability and Security Companion (QRS-C)*, pp. 530–538 (online), DOI: 10.1109/QRS-C60940.2023.00045 (2023).

[5] 木村悠生, 石川琉聖, 穐山空道, 猪俣敦夫, 上原哲太郎：Tor 内のリンクネットワークグラフ可視化と Server ヘッダによる Onion Service 運用元特定手法の検討，コンピュータセキュリティシンポジウム 2023 論文集，pp. 261–268 (2023).

[6] 木村悠生，穐山空道，猪俣敦夫，上原哲太郎：Onion Domain の大規模収集と HTTP レスポンスの傾向分析，研究報告インターネットと運用技術（IOT），Vol. 2024-IOT-64, No. 58, pp. 1–8 (2024).

[7] 木村悠生，穐山空道，猪俣敦夫，上原哲太郎：Onion サイトの HTTP レスポンスを用いたダークウェブの大規模分析，情報処理学会論文誌， Vol. 66, No. 3, pp. 513–522 (2025).

[8] 木村悠生，石川琉聖，穐山空道，猪俣敦夫，上原哲太郎：同一運用元による Onion サイトの類型化と運用モチベーションの推定, 研究報告インターネットと運用技術（IOT），Vol. 2025-IOT-68, No. 61, pp. 1–7 (2025).

[9] Project, T.: Tor Project — How do Onion Services work?, `https://community.torproject.org/onion-services/overview/`. (Accessed on 2024/01/28).

[10] Preite Martinez, A.: Subdomain support for Hidden Service addresses, `https://spec.torproject.org/proposals/204-hidserv-subdomains.html` (2012). (Accessed on 2026/07/28).

[11] Pastor-Galindo, J., Gómez Mármol, F. and Martínez Pérez, G.: On the gathering of Tor onion addresses, *Future Gener. Comput. Syst.*, Vol. 145, No. C, p. 12–26 (online), DOI: 10.1016/j.future.2023.02.024 (2023).

[12] Bernaschi, M., Celestini, A., Cianfriglia, M., Guarino, S., Lombardi, F. and Mastrostefano, E.: Onion under Microscope: An in-depth analysis of the Tor Web, *World Wide Web*, Vol. 25, No. 3, pp. 1287–1313 (online), DOI: 10.1007/s11280-022-01044-z (2022).

[13] Boshmaf, Y., Perera, I., Kumarasinghe, U., Liyanage, S. and Al Jawaheri, H.: Dizzy: Large-Scale Crawling and Analysis of Onion Services, *Proceedings of the 18th International Conference on Availability, Reliability and Security*, ACM, pp. 1–11 (online), DOI: 10.1145/3600160.3600167 (2023).

[14] Library of Congress: ARC_IA, Internet Archive ARC file format, `https://www.loc.gov/preservation/digital/formats/fdd/fdd000235.shtml` (2024). (Accessed on 2026/07/28).

[15] TorProject: Research Safety Board — Tor Project — Research, `https://research.torproject.org/safetyboard/`. (Accessed on 2025/01/26).

[16] Wilson, E. B.: Probable Inference, the Law of Succession, and Statistical Inference, *Journal of the American Statistical Association*, Vol. 22, No. 158, pp. 209–212 (online), DOI: 10.1080/01621459.1927.10502953 (1927).

© 2026 Information Processing Society of Japan