URLの文字列・構造およびWebサイトを構成する技術情報に基づく重み付けスコアを用いたフィッシングサイト分類手法

寺澤 勇気[1,a)]　石田 裕貴[2]　早稲田 篤志[2]　花田 真樹[2,b)]

概要：近年，フィッシング詐欺による被害が増加しており，正規サイトを模倣したフィッシングサイトによってユーザアカウント情報や個人情報が窃取される被害が報告されている．フィッシング詐欺への対策として，フィッシングサイトの検知手法に関する研究が行われているが，既存研究の多くはフィッシングサイトか否かを予測する二値分類にとどまっており，フィッシングサイトの模倣元ブランドを予測する多クラス分類を扱っていない．また，既存研究では，主にフィッシングサイトのURLの文字列や構造，Webページのソースコードから抽出された特徴量を使用している．本研究では，このうちURLの文字列や構造から抽出される特徴量をURL派生情報と呼ぶ．提案手法では，URLおよびURL派生情報に，オープンソースソフトウェア（OSS）であるwebappanalyzerを用いて取得したWebサイトを構成する技術情報を追加導入し，フィッシングサイトか否かを予測する二値分類およびフィッシングサイトの模倣元ブランドを予測する多クラス分類を行う手法を提案する．提案手法では，URLの文字列に対しては文字レベル畳み込みニューラルネットワーク (Character-Level CNN)，Webサイトを構成する技術情報およびURL派生情報に対してはLightGBMを用いた分類器を作成し，各分類器の結果を重み付けして統合することで，二値分類および多クラス分類を行う．評価実験の結果，二値分類および多クラス分類のいずれのタスクにおいても精度が向上することを確認し，その有効性を明らかにした．

キーワード：フィッシングサイト，機械学習，Character-Level CNN，LightGBM，汎用Web技術

Phishing Site Classification Method Using Weighted Scoring Based on URL Structure and Website Technical Information

Yuki Terasawa[1,a)]　Yuki Ishida[2]　Atsushi Waseda[2]　Masaki Hanada[2,b)]

Abstract: In recent years, the number of victims of phishing scams has been on the rise, and there are reports of user account information and personal data being stolen by phishing sites that mimic legitimate websites. As a countermeasure, research on phishing site detection methods is being conducted. However, most related research is limited to binary classification (predicting whether a site is a phishing site or not) and does not address multi-class classification (predicting the targeted brand). Furthermore, existing research primarily uses features extracted from URL strings, URL structures, and web page source codes. In this paper, we refer to features extracted from URL strings and structures as "URL-derived information." In this study, we propose a method that combines URL strings and URL-derived information with website technical information obtained using the open-source software (OSS) webappanalyzer. The proposed method performs binary classification to detect phishing sites and multi-class classification to predict the targeted brand. In the proposed method, we use a character-level convolutional neural network (Character-Level CNN) for URL strings and LightGBM for website technical information and URL-derived information. Then, we perform binary and multi-class classification by weighting and combining the outputs of the classifiers. As a result of evaluation experiments, we confirmed that the accuracy improved in both the binary classification and multi-class classification tasks.

Keywords: Phishing Sites, Machine Learning, Character-Level CNN, LightGBM, General-Purpose Web Technologies

© 2026 Information Processing Society of Japan

This paper is work in progress and not peer-reviewed.

1. はじめに

インターネットの普及に伴い，電子商取引，オンラインバンキング，オンライン証券取引など，様々なサービスがウェブ上で提供されるようになった．これらのサービスは利便性を向上させる一方で，フィッシング詐欺による被害も問題となっている．フィッシング詐欺は，実在する企業や組織を装った偽のウェブサイト（フィッシングサイト）にユーザを誘導し，クレジットカード情報や認証情報を不正に取得する詐欺手法である．フィッシング対策協議会の報告によると，2026 年 7 月のフィッシング報告件数は 66,119 件であり，前月と比較して 6,251 件減少した．一方，同月のフィッシングサイトの URL 件数（重複なし）は 43,267 件であり，前月と比較して 1,026 件増加した．また，フィッシングに悪用された企業や組織名（以降，ブランドと呼ぶ）の件数は 101 件であり，前月と比較して 3 件増加し，著名なブランドや官公庁を騙るものなど多くのブランドが標的となっている [1].

このようなフィッシング詐欺で用いられるフィッシングサイトに対する対策として，既知のフィッシングサイトの URL やドメイン名をリストアップして，リスト上のフィッシングサイトへのアクセスを防止するフィルタリングアプリケーションが一般に広く活用されている．一方で，フィッシングサイトでは検知を回避するために URL やドメイン名が短期間で変更されることから，URL だけでなく，Web サイト側から取得可能な情報も評価していく必要がある．

このようなフィッシング詐欺の増加に対して，多くの研究者が様々な手法を提案している [2]．特に，近年では，URL 文字列や URL 長，サブドメイン数，HTTPS 使用有無などの URL 構成（以降，URL 派生情報と呼ぶ），Web ページのソースコードなどから抽出した特徴を用いた機械学習による検知手法が注目されている [3][4]．しかしながら，多くの研究は Web サイトが正規サイトかフィッシングサイトかを判定する二値分類を対象としており，フィッシングサイトが模倣するブランドを分類する研究は十分に検討されていない．多様なブランドがフィッシング攻撃の対象となっている現状において，模倣元ブランドを推定することは，攻撃対象となっているブランドの把握や攻撃傾向の分析に有用であり，被害拡大の防止につながると考えられる．

既存研究の一つである PhiUSIIL[4] では，URL 派生情報やダウンロードしたウェブページの HTML の特徴，およびそれらの既存情報から計算された類似性の特徴を用いて，フィッシング URL を検知するフレームワークを提案している．これらの特徴を活用することにより高精度な二値分類を実現しているが，フィッシングサイトの模倣元ブランドを分類する多クラス分類は扱っていない．

このような背景のもと，本研究では，フィッシングサイトか否かを予測する二値分類，および模倣元ブランドの推定を目的とした多クラス分類を行う手法を提案する．本手法では，既存研究が用いている URL 派生情報に加え，OS やミドルウェア（Web サーバやデータベースマネジメントシステムなど），CMS のプラグインといった Web サイトを構成する汎用的な技術（以降，汎用 Web 技術）を新たな特徴量として活用する．なお，汎用 Web 技術の情報取得には，オープンソースのシグネチャ定義である webappanalyzer[5] を用いる．

本研究では，URL，汎用 Web 技術，URL 派生情報のそれぞれに対して，異なる分類器を用いる．まず，URL の文字列に対しては，文字列レベル畳み込みニューラルネットワーク（Character-Level Convolutional Neural Network, CLCNN）を用いる．CLCNN は入力データの局所的なパターンを学習できるため，URL 文字列に含まれる特徴的なパターンの抽出が期待できる．次に，汎用 Web 技術および URL 派生情報に対しては，LightGBM を用いる．LightGBM は勾配ブースティング決定木に基づく手法であり，構造化データを効率的に学習できるため，汎用 Web 技術や URL 派生情報などの構造化された特徴を活用した分類が期待できる．これらの各分類器が出力した予測確率を重み付けして統合し，最終的な分類結果を決定する．また，汎用 Web 技術と URL 派生情報をそれぞれ独立した LightGBM で学習する方式と，両特徴量を統合して一つの LightGBM で学習する方式を比較し，二値分類および多クラス分類における特徴量の利用方法について評価する．

本論文の構成は以下の通りである．2 章では，関連研究を示す．3 章では，本論文で提案する分類手法について述べ，4 章では，提案手法を用いた評価実験の結果および考察を示す．最後に，5 章で本論文のまとめおよび今後の課題を示す．

2. 関連研究

本論文に関連する研究として，Prasad らによる PhiUSIIL[4] を取り上げる．

PhiUSIIL は，類似度指標（Similarity Index）と逐次学習（Incremental Learning）を組み合わせたフィッシング URL 検知フレームワークである．第一段階では，対象 URL と正規サイトの URL との類似度を算出し，類似度に基づいてフィッシングサイトか否かを判定する．第一段階で判定さ

[1] 東京情報大学大学院 総合情報学研究科
Graduate School of Informatics, Tokyo University of Information Sciences
[2] 東京情報大学 総合情報学部
Department of Informatics, Tokyo University of Information Sciences
a) g26012ty@edu.tuis.ac.jp
b) mhanada@rsch.tuis.ac.jp

© 2026 Information Processing Society of Japan

れなかった URL は第二段階へ送られ，URL および HTML から抽出した特徴量を用いて，BernoulliNB，PassiveAggressive，SGDClassifier の 3 つの逐次学習アルゴリズムによるアンサンブルモデルで二値分類を行う．PhiUSIIL では計 235,795 件のデータセットを構築しており，その内訳は正規サイト 134,850 件，フィッシングサイト 100,945 件である．また，事前学習を導入したモデルでは 99.79%の正解率を達成している．

PhiUSIIL で使用される特徴量には，URL 長，ドメインが IP アドレスであるか，サブドメイン数，難読化文字に関する情報，HTTPS 使用有無などが含まれている．本研究では，これらを参考に URL から抽出可能な特徴量を URL 派生情報として採用する．

PhiUSIIL は正規サイトとフィッシングサイトの二値分類において高い性能を示している一方，フィッシングサイトの模倣元ブランドを分類する多クラス分類は扱っていない．そこで本研究では，URL 文字列および URL 派生情報に加えて汎用 Web 技術を導入し，二値分類だけでなく，フィッシングサイトの模倣元ブランドを分類する多クラス分類を行う手法を提案する．

3. 提案手法

3.1 提案手法の概要

本研究では，正規サイトとフィッシングサイトの二値分類, および模倣元ブランドの多クラス分類における精度向上を目的とし, URL 文字列, 汎用 Web 技術, および URL 派生情報の 3 種の情報を組み合わせた分類手法を提案する．具体的には，URL 文字列の特徴抽出には文字レベル畳み込みニューラルネットワーク（Character-Level Convolutional Neural Network，CLCNN）を用い，汎用 Web 技術と URL 派生情報の学習には LightGBM を用いる．

後者の LightGBM による学習においては，特徴量の入力方式が異なる以下の 2 方式を比較検討する．1 つ目は，汎用 Web 技術と URL 派生情報の特徴量をそれぞれ独立した分類器で学習する方式である．2 つ目は，汎用 Web 技術と URL 派生情報の特徴量を結合し，単一の分類器で学習する方式である．これらを比較することで，特徴量の統合が分類性能に与える影響を明らかにする．

最終的な分類結果は，CLCNN および LightGBM から出力される各クラスの予測確率に基づき，重み付けスコアを算出することで決定する．

3.2 特徴量生成

まず，分類対象の Web サイトに対する特徴量生成の方法について述べる．本提案では，以下の 3 種類の特徴量を生成する．

3.2.1 URL 文字列特徴量

各 URL の文字列を UTF-8 でエンコードしたバイト列へ変換し，固定長 1024 のベクトルとして表現する．1024 バイトに満たない場合はゼロ埋めを行い，1024 バイトを超える場合は先頭から 1024 バイトまでを使用する．ここで生成したベクトルを CLCNN への入力とする．

3.2.2 汎用 Web 技術特徴量

分類対象の Web サイトから取得した HTML ソースコードや HTTP レスポンスヘッダ等のデータに対し，webappanalyzer を適用することで，各サイトで稼働している汎用 Web 技術を抽出する．本研究で用いる webappanalyzer は，Web サイトを構成する技術スタックを特定するためのオープンソースのシグネチャ定義である．これにより，例えば，分類対象の Web サイトが利用している HTTP/3 や WebSocket などのプロトコル，Nginx や Apache などの Web サーバアプリケーションなどを検出することができる．一つの Web サイトからは複数の技術が検出されるため，取得した技術名に基づき，各技術の稼働有無を示す二値ベクトルへ変換する．ここで生成した特徴ベクトルを LightGBM への入力とする．

3.2.3 URL 派生情報特徴量

URL 派生情報として，先行研究 [4] を参考に抽出した以下の 18 種類の特徴量を使用する．

- URL 全体の文字数
- ドメイン名の文字数
- ドメインが IP アドレスかどうか（IP の場合は 1，ドメインの場合は 0）
- トップレベルドメインの文字数（例えば，jp の場合は 2 となる）
- サブドメインの数（例えば，www.tuis.ac.jp の場合は 3 となる）
- 難読化の有無（URL にエンコード文字列等が含まれている場合は 1）
- 難読化文字数
- 難読化文字数の URL 全体の割合
- 英字の数
- 英字の割合
- 数字の数
- 数字の割合
- URL 中の “=” の数
- URL 中の “?” の数
- URL 中の “&” の数
- その他の特殊記号の数
- 特殊記号の割合
- HTTPS を使用しているかどうか（使用している場合は 1，使用していない場合は 0）

ここで生成した特徴ベクトルを LightGBM への入力とする．

© 2026 Information Processing Society of Japan

3.3 重み付けスコアによる分類

次に，重み付けスコアによる分類について述べる．CLCNN および LightGBM の各分類器は，各クラスに対する予測確率を出力する．本研究では，各分類器が出力した予測確率に重みを乗じて加算することで，最終的な予測となる重み付けスコアを算出する．

提案手法におけるクラス c の重み付けスコア $S(c)$ の算出式を，式 (1) に示す．

$$S(c) = \sum_{i=1}^{N} (W_i P_i(c)) \tag{1}$$

ここで，N は使用する分類器の総数，$P_i(c)$ は，分類器 i が，クラス c に対して出力する予測確率である．また，W_i は分類器 i に対する重みパラメータであり，式 (2) を満たすものとする．

$$\sum_{i=1}^{N} W_i = 1 \quad (W_i \geq 0) \tag{2}$$

各クラスについて，式 (1) により重み付けスコアを算出し，その中で最も高いスコアを示した結果を最終的な分類結果とする．

4. 評価実験

4.1 評価実験の概要

本評価実験では，提案手法の有効性と汎用 Web 技術情報が分類精度にどのように影響するのかを明らかにするために，以下の方式を比較評価する．

- URL 文字列を用いた CLCNN，汎用 Web 技術を用いた LightGBM，URL 派生情報を用いた LightGBM をそれぞれ単体で用いる方式
- 汎用 Web 技術と URL 派生情報を統合して単一の LightGBM を用いる方式
- URL 文字列を CLCNN で学習し，URL 派生情報を LightGBM で学習し，各分類器の出力を重み付けする方式
- URL 文字列を CLCNN で学習し，汎用 Web 技術と URL 派生情報をそれぞれ独立の LightGBM で学習し，各分類器の出力を重み付けする方式
- URL 文字列を CLCNN で学習し，汎用 Web 技術と URL 派生情報を統合した特徴量を単一の LightGBM で学習し，両分類器の出力を重み付けする方式

本評価実験では，正規サイトとフィッシングサイトを判別する二値分類，およびフィッシングサイトの模倣元ブランドカテゴリを分類する多クラス分類の 2 つのタスクについて比較検証を実施する．多クラス分類において個々のブランドを分類対象とした場合，クラス数が多くなり，各クラスに属するデータ数が少なくなる傾向があるほか，クラス間のデータ数の不均衡も大きくなる．そのため，本評価実験では個々のブランドを直接分類するのではなく，模倣元ブランドの業種やサービス内容に基づき，業界・サービス単位のカテゴリとして分類を行う．

表 1　カテゴリ別件数
Table 1　Number of samples per category.

カテゴリ	学習データ数	テストデータ数	計
クレジットカード	7824	3354	11178
正規	5607	2403	8010
証券	4967	2129	7096
銀行	3123	1338	4461
ショッピング	1089	467	1556
通信	857	368	1225
運輸	799	342	1141
Web サービス	689	295	984
金融サービス	652	279	931
テクノロジー	372	160	532
その他	305	131	436
ゲーム	216	93	309
ライフライン	129	55	184
SNS	31	13	44
計	26660	11427	38087

評価指標には，正解率（Accuracy）に加えて F1 スコアを用いる．さらに，各モデルにおける誤分類の傾向についても分析を行う．

4.2 データセット

評価実験には，フィッシングサイト 30,077 件と正規サイト 8,010 件を統合した，計 38,087 件のデータセットを使用する．各カテゴリの件数，および学習・テストデータの分割内訳は表 1 に示す通りである．

フィッシングサイトは，フィッシング対策協議会 [6] から収集したデータ（期間：2025 年 1 月〜12 月）を利用する．これらは，模倣元ブランドの業種やサービス内容に基づき，クレジットカード，証券，銀行，ショッピング，通信，運輸，Web サービス（旅行・チケット予約等），金融サービス（消費者金融・暗号資産等），テクノロジー（クラウド・認証等），ゲーム，ライフライン，SNS，およびその他の計 13 カテゴリに独自に分類した．一方，正規サイトは，WarpDrive Project[7] のデータセットから抽出した，悪性ラベルが付与されていないデータ（期間：2026 年 1 月）を利用し，全てに「正規」ラベルを付与している．

本評価実験の多クラス分類では，これら「正規」を含む 14 カテゴリを分類対象とする．一方，二値分類においては，「正規」を除く 13 カテゴリをすべて「フィッシング」ラベルとして統合し，2 クラスでの学習および評価を行う．

4.3 学習モデルおよび実験設定

評価実験では，表 1 に示した通り，データセット全体を学習データ 70%とテストデータ 30%に分割して使用する．

© 2026 Information Processing Society of Japan

各特徴量の学習に用いる分類器の構成は以下の通りである．URL 文字列を入力とする CLCNN は，埋め込み層，2 層の畳み込み層，2 層のプーリング層，全結合層，正規化層，ドロップアウト層，および出力層で構成する．一方，汎用 Web 技術および URL 派生情報を入力とする分類器には，勾配ブースティング決定木である LightGBM を用いる．なお，実装において，汎用 Web 技術の稼働有無を示す二値ベクトル化には scikit-learn の MultiLabelBinarizer を使用している．

特徴のベクトル化は以下の方式で行った．汎用 Web 技術のベクトル化では，本データセットから抽出された 280 種類の汎用 Web 技術を基に，280 次元の二値ベクトルへ変換している．次に，URL 派生情報のベクトル化では，前述したように 18 種類の要素を元に，18 次元の特徴ベクトルへ変換している．最後に，汎用 Web 技術，URL 派生情報を統合して単一の分類器を用いる方式では，上記 2 つの特徴を統合して，298 次元の特徴ベクトルへ変換している．

アンサンブル学習における各分類器の重みパラメータ（W）の決定には，0.0 から 1.0 の範囲を 0.1 刻みで変化させるグリッドサーチを用いる．重みの総和が 1 となるすべての組み合わせについて重み付けスコアを算出し，テストデータに対する正解率が最も高くなる組み合わせを最適重みとして採用する．

本実験では，CLCNN 単体，LightGBM 単体，およびそれらを統合した重み付け分類の結果を比較評価する．

4.4 二値分類における評価

はじめに，正規サイトとフィッシングサイトを判別する二値分類の評価結果について述べる．表 2 に，各モデルおよび提案手法の正解率を示す．以降，表中のモデル表記では，モデル名に続く括弧内に入力する特徴量を示す．また，LightGBM の括弧内に複数の特徴量を「,」で示した場合は各特徴量をそれぞれ独立した LightGBM で学習する構成，「+」で示した場合は特徴量を結合して単一の LightGBM で学習する構成を表す．モデル間の「+」は，各分類器の予測結果を重み付けして統合することを表す．

単体モデルの性能に着目すると，CLCNN が 99.68%，URL 派生情報を用いた LightGBM が 99.62%となり，URL に関する情報が二値分類において高い分類性能を示した．一方，汎用 Web 技術のみを用いた LightGBM は 96.16%であった．これに対し，汎用 Web 技術と URL 派生情報を統合した LightGBM では 99.78%となり，いずれか一方の特徴量のみを用いた場合を上回った．このことから，両特徴量を同一モデルで扱うことが分類性能の向上に有効であることが示された．

提案手法の評価では，CLCNN（URL）に加え，汎用 Web 技術と URL 派生情報をそれぞれ独立した LightGBM で学習して重み付けした場合，それぞれの重みを 0.4，0.5，0.1 とすることで 99.86%の正解率が得られた．一方，汎用 Web 技術と URL 派生情報を統合した LightGBM と CLCNN を重み付けした場合の正解率は 99.80%であった．F1 スコアについても各モデルで極めて高い値が得られており，いずれのモデルでもマクロ平均 F1 スコアは 1.00 に近い値となった．結果を分析すると，単体での正解率が最も低い汎用 Web 技術を用いた LightGBM に最大の重み 0.5 が割り当てられている．この結果から，汎用 Web 技術のみでは十分な分類性能が得られないものの，CLCNN や URL 派生情報を用いた LightGBM とは異なる分類傾向を持つことで，重み付け統合時に相補的に寄与した可能性がある．このように，二値分類では，異なる特徴量を独立したモデルで学習し，それぞれの予測結果を組み合わせることが有効に機能したと考えられる．

誤分類サンプルを分析すると，単体モデルでは CLCNN で 36 件，汎用 Web 技術を用いた LightGBM で 439 件，URL 派生情報を用いた LightGBM で 43 件の誤分類が生じていた．これに対し，これら 3 つの分類器の予測結果を重み付けした場合には 16 件まで減少し，汎用 Web 技術と URL 派生情報を統合した LightGBM と CLCNN を重み付けした場合の 23 件よりも 7 件少なかった．16 件の内訳は，フィッシングサイトを正規サイトと判定したものが 12 件，正規サイトをフィッシングサイトと判定したものが 4 件であった．これらの誤分類サンプルを確認したところ，すべての URL で HTTPS が使用されておらず，本研究で定義した難読化文字も含まれていなかった．これらの特徴が誤分類の直接的な要因であるとは断定できないが，HTTPS の使用有無や難読化有無のみでは正規サイトとフィッシングサイトの違いを十分に表現できないサンプルが存在することが確認された．

以上より，二値分類では，汎用 Web 技術と URL 派生情報を統合することで LightGBM 単体の性能が向上する一方，最終的な重み付け統合では，各特徴量を独立した分類器で学習して予測結果を組み合わせた場合に最も高い分類性能を示した．この結果から，二値分類においては，各特徴量を独立したモデルで学習して得られる異なる分類傾向を組み合わせることが有効であると考えられる．

4.5 多クラス分類における評価

次に，正規サイトおよび 13 種類の模倣元ブランドカテゴリを分類する 14 クラス分類の評価結果について述べる．**表 3** に正解率を，**表 4** にモデルごとのカテゴリ別評価指標を，**表 5** にカテゴリ別 F1 スコアを示す．CLCNN（URL）と LightGBM（URL 派生情報）を組み合わせた場合の正解率は 89.47%であった．これに汎用 Web 技術を追加し，汎用 Web 技術と URL 派生情報をそれぞれ独立

© 2026 Information Processing Society of Japan

表 2　二値分類の評価結果
Table 2　Results of binary classification.

モデル/手法	正解率（%）	TP	TN	FP	FN
CLCNN（URL）	99.68	8989	2402	1	35
LightGBM（汎用 Web 技術）	96.16	8812	2176	227	212
LightGBM（URL 派生情報）	99.62	8985	2399	4	39
LightGBM（汎用 Web 技術+URL 派生情報）	99.78	9003	2399	4	21
CLCNN（URL）+LightGBM（URL 派生情報）	99.71	8992	2402	1	32
CLCNN（URL）+LightGBM（汎用 Web 技術，URL 派生情報）	99.86	9012	2399	4	12
CLCNN（URL）+LightGBM（汎用 Web 技術+URL 派生情報）	99.80	9003	2401	2	21

表 3　多クラス分類の正解率
Table 3　Accuracy of multi-class classification.

モデル	正解率（%）
CLCNN（URL）	88.19
LightGBM（汎用 Web 技術）	63.35
LightGBM（URL 派生情報）	78.30
LightGBM（汎用 Web 技術+URL 派生情報）	84.65
CLCNN（URL）+LightGBM（URL 派生情報）	89.47
CLCNN（URL）+LightGBM（汎用 Web 技術，URL 派生情報）	90.22
CLCNN（URL）+LightGBM（汎用 Web 技術+URL 派生情報）	91.19

した LightGBM で学習して CLCNN と組み合わせた場合は 90.22%，両特徴量を統合して単一の LightGBM で学習して CLCNN と組み合わせた場合は 91.19%となった．また，LightGBM 単体でも，汎用 Web 技術のみでは 63.35%，URL 派生情報のみでは 78.30%であったのに対し，両特徴量を統合した場合は 84.65%となった．これらの結果から，汎用 Web 技術と URL 派生情報を同一モデルで扱うことで，それぞれの特徴量が相互に補完した可能性がある．

最も高い正解率が得られた構成では，CLCNN（URL）と，汎用 Web 技術および URL 派生情報を統合して学習した LightGBM の重みをそれぞれ 0.5 とした場合に，91.19%となった．また，マクロ平均 F1 スコアについても，CLCNN と，汎用 Web 技術および URL 派生情報をそれぞれ独立した LightGBM で学習して組み合わせた場合の 0.73 から，両特徴量を統合した単一の LightGBM と CLCNN を組み合わせた場合には 0.78 へ向上した．特に，証券および銀行では 0.93，クレジットカードでは 0.92 と高い F1 スコアが得られたほか，ライフラインは 0.10 から 0.42，SNS は 0.44 から 0.52，テクノロジーは 0.37 から 0.47 へ向上した．

一方，カテゴリによって分類性能には差がみられた．特に，SNS およびライフラインはデータ数が少なく，学習データはそれぞれ 31 件，129 件である．このようなカテゴリ間のデータ数の不均衡により，少数カテゴリに固有の特徴を十分に学習できていない可能性がある．また，SNS のテストデータは 13 件，ライフラインは 55 件と少ないため，これらのカテゴリにおける F1 スコアについては，評価値の変動が大きくなる可能性がある．

誤分類サンプルを分析すると，CLCNN（URL）と，汎用 Web 技術および URL 派生情報を統合して学習した LightGBM を組み合わせた場合の誤分類件数は 1,007 件であり，CLCNN（URL）と，汎用 Web 技術および URL 派生情報をそれぞれ独立した LightGBM で学習して組み合わせた場合と比較して，110 件減少した．一方で，クレジットカード，証券，銀行，金融サービスなど，金融関連カテゴリ間での誤分類が多く確認された．これらのカテゴリは業種が近く，フィッシングサイトで用いられる URL 構造や使用技術にも共通した特徴が存在すると考えられる．したがって，現在用いている URL 文字列，汎用 Web 技術情報および URL 派生情報のみでは，類似するカテゴリ間の違いを十分に捉えられないサンプルが存在すると考えられる．

また，CLCNN（URL）と，汎用 Web 技術および URL 派生情報を統合して学習した LightGBM を組み合わせた場合において，最終的に誤分類となったサンプルのうち，CLCNN（URL）単体では正しく分類できていたものが 108 件，汎用 Web 技術および URL 派生情報を統合して学習した LightGBM 単体では正しく分類できていたものが 221 件存在した．この結果から，全サンプルおよび全カテゴリに対して固定した重みを適用する方式では，一方のモデルが正しく分類できている場合でも，もう一方のモデルの予測によって最終的な分類結果が変化する場合があることが分かる．

以上より，多クラス分類では，汎用 Web 技術と URL 派生情報を統合して LightGBM に入力し，さらに CLCNN の予測と組み合わせることで，CLCNN（URL）と，汎用 Web 技術および URL 派生情報をそれぞれ独立した LightGBM で学習して組み合わせた場合よりも正解率およびマクロ平均 F1 スコアが向上した．一方で，データ数の少ないカテゴリや特徴の類似するカテゴリでは依然として分類性能に課題があり，データセットの拡充やカテゴリ固有の特徴量の導入に加え，カテゴリやサンプルに応じた予測結果の統合方法について検討する必要がある．

5. おわりに

本研究では，フィッシングサイト検知および模倣元ブランドカテゴリの分類を目的として，URL 文字列，Web サイトの汎用 Web 技術情報，URL 派生情報を使用した分類

© 2026 Information Processing Society of Japan

表 4　多クラス分類のカテゴリ別評価指標

Table 4　Category-wise Evaluation Metrics for Multi-class Classification.

	CLCNN (URL)				LightGBM (汎用 Web 技術)				LightGBM (URL 派生情報)				LightGBM (汎用 Web+URL 派生)			
カテゴリ名	TP	TN	FP	FN	TP	TN	FP	FN	TP	TN	FP	FN	TP	TN	FP	FN
クレジットカード	2981	7755	318	373	2905	5281	2792	449	2636	7268	805	718	2907	7440	633	447
正規	2386	8987	37	17	2117	8916	108	286	2395	8978	46	8	2402	8993	31	1
証券	2067	8924	374	62	1059	8781	517	1070	1772	9004	294	357	1878	9097	201	251
銀行	1216	9942	147	122	720	10063	26	618	1047	9875	214	291	1149	10002	87	189
ショッピング	335	10860	100	132	34	10915	45	433	150	10795	165	317	208	10834	126	259
通信	220	11015	44	148	98	11029	30	270	199	10964	95	169	262	11010	49	106
運輸	268	10856	229	74	25	11065	20	317	200	10882	203	142	225	10947	138	117
Web サービス	221	11085	47	74	81	11001	131	214	168	11039	93	127	201	11045	87	94
金融サービス	160	11139	9	119	72	11029	119	207	144	11028	120	135	186	11054	94	93
テクノロジー	37	11251	16	123	37	11170	97	123	80	11081	186	80	86	11165	102	74
その他	109	11277	19	22	1	11291	5	130	86	11170	126	45	90	11197	99	41
ゲーム	75	11332	2	18	84	11067	267	9	51	11254	80	42	47	11259	75	46
ライフライン	2	11364	8	53	1	11369	3	54	17	11334	38	38	25	11346	26	30
SNS	0	11414	0	13	5	11386	28	8	2	11399	15	11	7	11408	6	6

	CLCNN（URL） LightGBM (URL 派生情報)				CLCNN（URL） LightGBM (汎用 Web 技術, URL 派生情報)				CLCNN（URL） LightGBM (汎用 Web 技術+URL 派生情報)			
カテゴリ名	TP	TN	FP	FN	TP	TN	FP	FN	TP	TN	FP	FN
クレジットカード	3058	7708	365	296	3108	7697	376	246	3118	7747	326	236
正規	2402	8975	49	1	2402	8961	63	1	2403	8995	29	0
証券	2064	9014	284	65	2080	9012	286	49	2079	9049	249	50
銀行	1231	9956	133	107	1230	10000	89	108	1244	10008	81	94
ショッピング	320	10896	64	147	337	10908	52	130	350	10914	46	117
通信	237	11031	28	131	246	11038	21	122	263	11029	30	105
運輸	261	10946	139	81	266	10943	142	76	265	10967	118	77
Web サービス	227	11094	38	68	234	11107	25	61	238	11100	32	57
金融サービス	171	11120	28	108	169	11138	10	110	186	11127	21	93
テクノロジー	49	11235	32	111	41	11247	20	119	60	11233	34	100
その他	113	11267	29	18	111	11271	25	20	112	11272	24	19
ゲーム	80	11331	3	13	79	11330	4	14	79	11330	4	14
ライフライン	9	11364	8	46	3	11369	3	52	17	11363	9	38
SNS	2	11411	3	11	4	11413	1	9	6	11410	4	7

手法を提案した．URL 文字列には CLCNN を採用し，汎用 Web 技術情報および URL 派生情報には LightGBM を採用した．また，LightGBM については，汎用 Web 技術情報と URL 派生情報をそれぞれ独立して学習する方式と，両特徴量を統合して学習する方式について提案し，特徴量の入力がどのように影響するのかの比較評価を行った．さらに，各分類器が出力する予測確率を重み付けして統合し，二値分類および多クラス分類について評価した．

評価実験の結果，多クラス分類では CLCNN 単体の正解率が 88.19%であったのに対し，汎用 Web 技術と URL 派生情報を統合して学習した LightGBM と CLCNN の予測結果を重み付けした場合には 91.19%となった．また，二値分類では CLCNN 単体の 99.68%に対し，汎用 Web 技術と URL 派生情報をそれぞれ独立した LightGBM で学習し，CLCNN を含む各分類器の予測結果を重み付けした場合には 99.86%となった．これらの結果から，二値分類および多クラス分類の双方において，URL 文字列のみを用いる場合と比較して，汎用 Web 技術情報および URL 派生情報を組み合わせることで分類性能を向上できることを確認した．また，二値分類では CLCNN（URL）と，汎用 Web 技術および URL 派生情報をそれぞれ独立した LightGBM で学習して各分類器の予測結果を重み付けした場合に，多クラス分類では汎用 Web 技術と URL 派生情報を統合して学習した LightGBM と CLCNN の予測結果を重み付けした場合に，それぞれ最も高い正解率が得られたことから，分類タスクによって有効な特徴量の学習・統合方法が異なることが確認された．一方，多クラス分類ではデータ数の少ないカテゴリや特徴の類似するカテゴリにおいて分類性能

© 2026 Information Processing Society of Japan

表 5　多クラス分類のカテゴリ別 F1 スコア
Table 5　Category-wise F1 scores (multi-class).

カテゴリ名	CLCNN	LightGBM			CLCNN+LightGBM		
	URL	汎用 Web 技術	URL 派生情報	汎用 Web 技術 +URL 派生情報	URL, URL 派生情報	URL, 汎用 Web 技術, URL 派生情報	URL, 汎用 Web 技術 +URL 派生情報
正規	0.99	0.91	0.99	0.99	0.99	0.99	0.99
証券	0.90	0.57	0.84	0.89	0.92	0.93	0.93
銀行	0.90	0.69	0.81	0.89	0.91	0.93	0.93
クレジットカード	0.90	0.64	0.78	0.84	0.90	0.91	0.92
ゲーム	0.88	0.38	0.46	0.44	0.91	0.90	0.90
Web サービス	0.79	0.32	0.60	0.69	0.81	0.84	0.84
その他	0.84	0.01	0.50	0.56	0.83	0.83	0.84
ショッピング	0.74	0.12	0.38	0.52	0.75	0.79	0.81
通信	0.70	0.40	0.60	0.77	0.75	0.77	0.80
金融サービス	0.71	0.31	0.53	0.67	0.72	0.74	0.77
運輸	0.64	0.13	0.54	0.64	0.70	0.71	0.73
SNS	0.00	0.22	0.13	0.54	0.22	0.44	0.52
テクノロジー	0.35	0.25	0.38	0.49	0.41	0.37	0.47
ライフライン	0.06	0.03	0.31	0.47	0.25	0.10	0.42
マクロ平均	0.67	0.36	0.56	0.67	0.72	0.73	0.78

が低下する傾向があり，二値分類についてもフィッシングサイトと正規サイトを誤判定する事例が残った．

本実験では重み付けパラメータの決定と性能評価に同一のテストデータを用いているため，得られた評価値には重み選択による影響が含まれる可能性がある．今後は，検証データを分離した評価を行う必要がある．

今後は，データ数の少ないカテゴリを中心としたデータセットの拡大に加え，Web ページの本文や HTML 構造，画像など，模倣元ブランドカテゴリの特徴をより直接的に表現できる情報の導入を検討する必要がある．また，本研究では各分類器の予測確率に固定した重みを適用したが，各分類器の予測結果に応じた統合方法についても検討する余地がある．これらの改善を行うことで，より安定したフィッシングサイト検知および模倣元ブランドのカテゴリ分類を目指す．

参考文献

[1] フィッシング対策協議会，“Council of Anti-Phishing Japan—報告書類—月次報告書—2026/07 フィッシング報告状況，” https://www.antiphishing.jp/report/monthly/202607.html (2026/08/15 確認).

[2] R. Zieni, L. Massari and M. C. Calzarossa, ”Phishing or Not Phishing? A Survey on the Detection of Phishing Websites,” in IEEE Access, vol. 11, pp. 18499-18519, 2023

[3] LAC，“フィッシングサイト検知における複数手法を組み合わせた対策の有効性,” LAC WATCH，https://www.lac.co.jp/lacwatch/report/20250613_004401.html (2026/08/15 確認).

[4] Arvind Prasad, Shalini Chandra, “PhiUSIIL: A diverse security profile empowered phishing URL detection framework based on similarity index and incremental learning, ” Computers & Security, vol.136, Art. no. 103545, Jan. 2024.

[5] enthec, “GitHub - enthec/webappanalyzer: This project aims to maintain Wappalyzer technologies,” https://github.com/enthec/webappanalyzer (2026/08/15 確認).

[6] フィッシング対策協議会, “Council of Anti-Phishing Japan, ” https://www.antiphishing.jp/ (2026/08/15 確認).

[7] WarpDrive Project, “Warpdrive: Web-based attack response with practical and deployable research initiative, ” https://warpdrive-project.jp/. (2026/08/15 確認).

© 2026 Information Processing Society of Japan