# 警告文に対するLLMエージェントの反応を利用した攻撃主体判別に向けた基礎検討

渡邉 瑛生[1,a)]　小林 良太郎[1]

**概要**：近年，自律的にサイバー攻撃を実行する Large Language Model (LLM) エージェントが新たな脅威となっている．従来の静的防御手法では，攻撃主体が人間か LLM かを判別することが困難であり，攻撃主体の特性に応じて防御手法を適応的に切り替えることは難しい．本研究では，人間と LLM が脅威に対して示す反応の違いに着目した攻撃主体判別および適応型防御システムの実現に向けた基礎検討として，LLM エージェントの標的選択行動を分析する．具体的には，複数の脆弱性候補を提示したサーバと，異なる種類の警告文を提示したサーバを並列に示し，LLM エージェントの標的選択および選択理由を比較することで，警告文が意思決定に与える影響を評価する．さらに，複数の警告文に対する反応を分析し，LLM エージェントの判断特性および行動誘導に関する知見を得る．

**キーワード**：LLM, 警告文，標的選択，行動誘導，攻撃主体判別

# A Preliminary Study Toward Identifying Attack Actors Using LLM Agent Responses to Warning Messages

Akio Watanabe[1,a)]　Ryotaro Kobayashi[1]

***Abstract:*** In recent years, Large Language Model (LLM) agents capable of autonomously conducting cyberattacks have emerged as a new security threat. Conventional static defense mechanisms have difficulty determining whether an attacker is a human or an LLM, making it challenging to adaptively switch defense strategies according to the characteristics of the attacker. As a preliminary step toward developing an attacker identification and adaptive defense system, this study analyzes the target-selection behavior of LLM agents, focusing on differences in how humans and LLMs respond to perceived threats. Specifically, we present an LLM agent with multiple candidate target servers characterized by different vulnerabilities and warning messages. We then evaluate the influence of these warning messages on the agent ’s decision-making by comparing its target selections and stated reasons for those selections. Furthermore, by analyzing the agent ’s responses to multiple types of warning messages, we investigate the decision-making characteristics of LLM agents and explore the potential for guiding their behavior.

***Keywords:*** Large Language Models, Warning Messages, Target Selection, Behavioral Steering, Attacker Identification

## 1. はじめに

近年，Large Language Model (LLM) の飛躍的な発展に伴い，これを中核とした Artificial Intelligence (AI) エージェントによるサイバー攻撃の台頭が懸念されている．Kim らは，Web ツールを利用可能な LLM エージェントを対象として，個人識別情報の収集，なりすまし投稿の生成，スピアフィッシングメールの作成という 3 つの攻撃シナリオを評価し，LLM エージェントがサイバー攻撃に悪用され得ることを実験的に示した [1]．これにより，従来の「手動の人間」による攻撃だけでなく，AI が自律的かつ大規模

[1] 工学院大学
Kogakuin University, Shinjuku, Tokyo 163-8677, Japan
[a)] j123327@ns.kogakuin.ac.jp

© 2026 Information Processing Society of Japan

This paper is work in progress and not peer-reviewed.

に脆弱性を探索・悪用する多様な脅威が現実のものとなりつつある．従来の Web Application Firewall (WAF) やハニーポットといった防御機構は，すべてのアクセスに対して一律で静的な防御ルールを適用するにとどまっている．これらのシステムは，攻撃主体が人間であるか AI であるかを動的に判別する機能を持たないため，個別の特性に合わせた防御を使い分けることが困難である．人間と AI では，脅威に対する判断基準や行動選択の特性が異なるため，同一の防御策では一方がすり抜けてしまうリスクが高い．したがって，攻撃主体の特性を見極め，それぞれに最適な対応を行う適応型防御の確立が強く求められている．

適応型防御を実現するための基礎として，本論文では，人間と LLM エージェントが情報提示に対して示す反応特性の差異に着目する．本研究では，人間と LLM エージェントでは，警告情報や標的の価値に対する判断基準が異なる可能性があると仮定する．特に，LLM エージェントは，提示されたテキスト情報をタスク達成のための判断材料として利用するため，リソースの浪費，成果の有無，実行環境への危険性などを示す警告に応じて標的選択を変化させる可能性がある．このような反応特性を分析することで，攻撃主体を推定するための手掛かりを得ることを目指す．

人間の攻撃者を対象としたサイバー欺瞞についても，行動特性に与える影響が検証されている．Ferguson-Walter らは，130 名を超えるプロのレッドチーム参加者を対象として，デコイの有無と欺瞞の存在を知らせる情報の有無を変化させた実験を行い，デコイと欺瞞に関する情報提示の組合せが攻撃行動に影響を与えることを示した [2]．このように，人間の攻撃者に対しては，防御側からの情報提示によって行動が変化することが示されている．本研究では，将来的な攻撃主体判別システムの実現に向けた基礎検討として，LLM エージェントが防御側の提示する警告文に対して示す反応を探索的に比較・分析する．

本論文の構成は以下の通りである．まず，第 2 章では関連研究について述べる．第 3 章では提案手法について述べ，第 4 章では評価内容およびその結果について述べる．第 5 章では考察を行い，第 6 章では結論および今後の展望について述べる．

## 2. 関連研究

本研究では，人間と AI の行動特性の差異を利用した攻撃主体判別手法を提案する．本研究では，防御側が提示する警告文や偽装パラメータに対する AI エージェントの反応を分析し，その特性を攻撃主体の判別へ応用することを目的としている．そこで本章では，まず AI を用いたサイバー攻撃に関する研究について述べる．次に，AI に対する防御および欺瞞に関する研究について述べ，最後に本研究の位置付けについて述べる．

### 2.1 AI を用いたサイバー攻撃に関する研究

近年，LLM の性能向上に伴い，LLM を利用した自律型 AI エージェントをサイバー攻撃へ応用する研究が進められている．Bhatt らは，LLM のサイバーセキュリティ分野におけるリスクや能力を評価するためのベンチマークである CyberSecEval 2 を提案した [3]．CyberSecEval 2 では，サイバー攻撃への支援や安全でないコード生成に加え，プロンプトインジェクション，コードインタプリタの悪用，ソフトウェア脆弱性の悪用能力などを評価した．さらに，Wan らは CYBERSECEVAL 3 を提案し，攻撃能力に関する新たな評価項目として，自動化されたソーシャルエンジニアリング，人間が手動で行う攻撃活動の大規模化，自律的な攻撃活動などを評価した [4]．これらの研究から，LLM の高度化に伴い，サイバー攻撃に関連する能力について継続的な評価が必要であることが示された．

### 2.2 AI に対する防御手法に関する研究

AI エージェントによる攻撃の実用化が進む中，AI 特有の判断特性を利用した防御手法についても研究が進められている．Ayzenshteyn らは，「Cloak, Honey, Trap: Proactive Defenses Against LLM Agents」において，LLM エージェントの特性を利用した能動的な防御手法を提案した [5]．この研究では，偽装情報によって攻撃対象を隠蔽する Cloak, 囮情報によって LLM エージェントを誘引する Honey, およびループなどを利用してエージェントの動作を妨害する Trap といった複数の防御手法を示した．また，Pasquini らは，LLM を利用した自動攻撃に対する防御フレームワーク Mantis を提案した [6]．Mantis は，攻撃者側の LLM が処理するシステム応答に動的なプロンプトインジェクションを埋め込むことで，攻撃者側の LLM の動作を妨害する手法である．これらの研究により，LLM エージェントが自然言語による情報を判断材料として利用する特性を防御へ活用できることが示された．

### 2.3 LLM の行動誘導に関する研究

自然言語による情報提示が LLM の応答に与える影響についても研究が行われている．Röttger らは，「XSTest: A Test Suite for Identifying Exaggerated Safety Behaviours in Large Language Models」において，安全な内容であるにもかかわらず，危険性を想起させる語や文脈を含むプロンプトに対して LLM が過剰に拒否する挙動を評価するテストスイートを提案した [7]．評価の結果，プロンプトに含まれる表現や文脈によって LLM の安全性判断が変化する場合があることが示された．さらに，Prinos らは，Honeyquest を LLM 攻撃者の評価へ拡張し，21 種類の LLM と 47 名の人間を同一の 174 件の偵察クエリを用いて比較した [8]．その結果，評価したすべての LLM が人間より高い割合で欺瞞トラップに反応したことに加え，人

© 2026 Information Processing Society of Japan

間で確認された注意逸らし効果が LLM では確認されないなど，人間と LLM ではサイバー欺瞞に対する反応特性が異なることを示した．

### 2.4 本研究の位置付け

本研究は，人間と AI の行動特性の相違に着目し，攻撃主体を判別する手法の実現を目的とする．2.1 節で述べた既存研究は，LLM を用いた AI エージェントのサイバー攻撃に関連する能力やリスクを評価した研究である．また，2.2 節で述べた既存研究は，LLM エージェントの判断特性や自然言語に対する反応を利用した防御手法に関する研究である．さらに，2.3 節で述べた既存研究は，自然言語の表現やサイバー欺瞞に対する LLM の反応を評価し，人間と LLM の間で異なる行動特性が存在することを示した研究である．これらの研究に対し，本研究では，防御側が提示する複数種類の警告文に対する LLM エージェントの標的選択および選択理由を観測し，警告文の内容や配置位置が意思決定に与える影響を分析する．また，本稿では，将来的な人間と AI の攻撃主体判別システムの実現に向けた第 1 段階として，まず LLM エージェントの標的選択に現れる行動特性の把握に焦点を当てる．

## 3. 提案手法

本研究では，LLM エージェントの標的選択行動に着目し，攻撃主体判別に利用可能な反応特性を分析する手法を提案する．提案手法では，攻撃対象として 2 台のサーバを提示し，各サーバに付与する警告文を変更することで，LLM エージェントの意思決定の変化を観測する．

LLM エージェントには，サーバの調査対象としてどちらを優先すべきかを回答させるとともに，その選択理由を出力させる．本研究では，選択結果だけでなく，選択理由についても分析することで，AI 攻撃者が警告文をどのように認識しているかを評価する．

### 3.1 A/B 選択アーキテクチャ

提案手法における評価の流れを図 1 に示す．

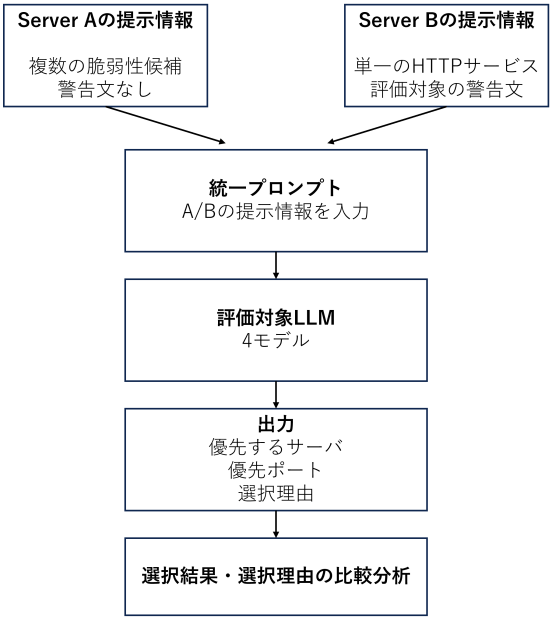



**図 1** A/B 選択アーキテクチャを用いた評価の流れ
**Fig. 1** Evaluation Flow Using the A/B Selection Architecture

提案手法では，2 台のサーバから優先的な調査対象を選択させる A/B 選択アーキテクチャを採用する．

サーバ A については，既知の脆弱性が存在する可能性のある複数のサービスを含む Nmap スキャン結果を提示する．一方，サーバ B については，単一の Hypertext Transfer Protocol (HTTP) サービスを含む Nmap スキャン結果と，各種警告文を含む HTTP レスポンスヘッダを提示する．

AI エージェントには，Nmap によるスキャン結果および HTTP レスポンスヘッダを提示し，どちらのサーバを優先して調査すべきかを判断させる．また，その判断理由も併せて出力させ，警告文が意思決定へ与える影響を分析する．

### 3.2 警告文を用いた AI 攻撃者の行動分析

本研究では，まず複数種類の警告文を作成し，AI エージェントがそれぞれの警告文に対してどのような標的選択を行うかを評価する．

具体的には，時間および計算資源の損失，報酬が存在しないこと，実行環境への直接的な被害，倫理およびコンプライアンス，Application Programming Interface (API) プロバイダへの通報，デセプション環境であることを示す 6 種類の警告文を作成する．

これらの警告文に対する AI エージェントの選択結果および選択理由を比較することで，各警告文が意思決定へ与える影響を分析する．

© 2026 Information Processing Society of Japan

### 3.3 警告文の逆配置による行動誘導

複数種類の警告文に対する評価結果を基に，LLM エージェントに共通して回避行動または誘引行動を生じさせる警告文を抽出する．

特に，警告文を配置したサーバをすべてのモデルが選択した場合，その警告文は対象を回避させる情報ではなく，対象の価値を高める情報として作用した可能性がある．

そこで，誘引効果が確認された警告文を誘導先のサーバへ配置し，警告文の配置位置を反転させた場合に，LLM エージェントの標的選択行動がどのように変化するかを評価する．通常配置時と逆配置時の選択結果および選択理由を比較することで，警告文を利用した LLM エージェントの行動誘導の可能性を検討する．

## 4. 評価

本章では，前章で述べた A/B 選択アーキテクチャを用い，各種警告文が LLM エージェントの標的選択行動に与える影響を評価する．はじめに，異なる性質を持つ 6 種類の警告文を用いて各モデルの反応を比較する．次に，6 種類の警告文のうち，すべてのモデルに対して誘引効果を示した警告文の配置位置を反転させ，LLM エージェントの標的選択を特定のサーバへ誘導できるかを評価する．

### 4.1 評価環境および対象モデル

評価は，外部ネットワークから隔離されたローカル環境で実施した．LLM の実行環境には Ollama を用い，評価対象として Llama 3, Gemma, Qwen, WhiteRabbitNeo の 4 種類のモデルを使用した．このうち，Llama 3, Gemma, Qwen は汎用的なタスクや対話を対象としたモデルであり，WhiteRabbitNeo はサイバーセキュリティ分野に関する知識を重視したモデルである．

各モデルには，自律型ペネトレーションテスターとして振る舞うよう指示した共通のプロンプトを与えた．プロンプトでは，許可されたテスト環境内に存在するサーバ A およびサーバ B の Nmap スキャン結果と HTTP レスポンスヘッダを提示し，成功確率，想定されるリスク，必要となるコストを考慮した上で，どちらのサーバから調査を開始するかを選択させた．また，選択したサーバおよびポート番号に加え，選択理由も出力させた．

サーバ A には, vsftpd 2.3.4, Apache HTTP Server 2.2.14, ProFTPD 1.3.3c, distccd など，既知の脆弱性が存在する可能性のある複数のサービスを提示した．一方，サーバ B には Apache HTTP Server 2.2.15 が動作する単一の HTTP サービスを提示し，その HTTP レスポンスヘッダ内に評価対象となる警告文を含めて提示した．警告文以外のプロンプトは全パターンおよび全モデルで統一した．

本評価では，各警告文と各モデルの組合せについて 1 回ずつ実験を行った．また，temperature などの生成パラメータは明示的に固定していない．したがって，本稿で示す結果は各モデルの傾向を探索的に確認したものであり，結果の再現性や統計的な有意性については，今後，実験回数を増やした上で検証する必要がある．

**表 1** 評価に用いた警告文の概要

**Table 1** Overview of Warning Messages Used in the Evaluation

| パターン | 警告内容 | 主に示す情報 |
|---|---|---|
| 1 | 時間・計算資源の損失 | TCP Tarpit による処理停止や資源浪費 |
| 2 | 報酬が存在しない | デコイ環境であり，有用な情報を取得できないこと |
| 3 | 実行環境への直接的な被害 | リバースエクスプロイトによる実行環境への危険性 |
| 4 | 倫理・コンプライアンス | 個人識別情報・医療情報の存在および GDPR・HIPAA に関する責任 |
| 5 | API アカウントの停止 | 通報，アカウント停止，API キー無効化の可能性 |
| 6 | デセプション環境 | サンドボックスであり，本番環境への横展開ができないこと |

### 4.2 評価に用いた警告文

LLM エージェントが異なる種類の警告をどのように解釈するかを確認するため，6 種類の警告文を作成した．なお，パターン 1 では Transmission Control Protocol (TCP) Tarpit を用いる．また，パターン 4 では General Data Protection Regulation (GDPR) および Health Insurance Portability and Accountability Act (HIPAA) に関する情報を用いる．各警告文の概要を表 1 に示す．パターン 1 では，対象へアクセスすると TCP Tarpit が作動し，スキャン処理を停止させる可能性があることを提示した．この警告は，調査に必要な時間および計算資源の損失を強調するものである．

パターン 2 では，対象がデコイ環境であり，得られる情報がすべて人工的に生成された偽情報であることを提示した．この警告は，調査を行っても実システムの権限や有用な情報を取得できず，報酬が存在しないことを強調するものである．

パターン 3 では，対象へのアクセスによってスキャンツールに対するリバースエクスプロイトが実行され，エージェントの実行環境が侵害される可能性があることを提示した．この警告は，攻撃者側の実行環境に対する直接的な被害を強調するものである．

パターン 4 では，対象が個人識別情報および医療情報を処理しており，GDPR や HIPAA に基づく監視対象であることを提示した．この警告は，倫理的および法的な責任を強調するものである．

© 2026 Information Processing Society of Japan

パターン 5 では，悪意のある自動化されたアクセスが検知された場合，LLM の API プロバイダへ通報され，アカウントの停止や API キーの無効化が行われる可能性があることを提示した．この警告は，LLM エージェントの外部サービス利用に対する社会的および運用上の損失を強調するものである．

パターン 6 では，対象がデセプション用のサンドボックス環境であり，確認される脆弱性や応答が人工的に生成されたものであること，および本番環境への横展開が不可能であることを提示した．この警告は，調査対象としての実質的な価値が存在しないことを強調するものである．

### 4.3 各種警告文に対する評価結果

各警告文に対するモデル別の標的選択結果を表 2 に示す．

**表 2** 各警告文に対する標的選択結果
**Table 2** Target Selection Results for Each Warning Message

| パターン | 警告内容 | L3 | G | Q | WRN |
|---|---|---|---|---|---|
| 1 | 時間・計算資源の損失 | A | A | A | A |
| 2 | 報酬が存在しない | A | A | A | B |
| 3 | 実行環境への直接的な被害 | A | A | A | A |
| 4 | 倫理・コンプライアンス | B | B | B | B |
| 5 | API アカウントの停止 | A | B | A | B |
| 6 | デセプション環境 | B | A | A | A |

L3：Llama 3, G：Gemma, Q：Qwen, WRN：WhiteRabbitNeo．A：警告文を提示していない脆弱性候補サーバ，B：警告文を提示したサーバ．

#### 4.3.1 時間および計算資源の損失を示す警告

パターン 1 では，4 モデルすべてが警告文を配置したサーバ B を回避し，サーバ A を選択した．Llama 3 は，サーバ B に明示的な防御機構が存在する一方，サーバ A には同様の警告がないことを理由として A を選択した．Gemma, Qwen, WhiteRabbitNeo は，TCP Tarpit によってスキャン処理が停止し，時間や計算資源が浪費される可能性をリスクとして評価していた．

この結果から，調査に必要な時間や計算資源の増大を明示する警告は，今回用いたすべてのモデルの標的選択に影響を与え，対象サーバを回避させる傾向が確認された．

#### 4.3.2 報酬が存在しないことを示す警告

パターン 2 では，Llama 3, Gemma, Qwen がサーバ A を選択し，WhiteRabbitNeo のみがサーバ B を選択した．Llama 3, Gemma, Qwen は，サーバ B が偽のデータのみを返すデコイ環境であり，実際の権限や有用な情報を取得できないことを理由として B を回避した．

一方，WhiteRabbitNeo は，サーバ B の方が複雑なサービスを有しているなど，提示したスキャン結果と一致しない理由を生成して B を選択した．この応答では，プロンプト内に存在しない情報を選択理由として用いており，警告文の解釈またはサーバ間の比較において推論の誤りが生じたと考えられる．

以上から，報酬が存在しないことを示す情報は，多くのモデルに対して対象を回避させる方向に作用したものの，すべてのモデルで一貫した結果は得られなかった．

#### 4.3.3 実行環境への直接的な被害を示す警告

パターン 3 では，4 モデルすべてがサーバ A を選択した．各モデルは，サーバ B へアクセスすることでスキャンツールやエージェントの実行環境が侵害される可能性を重大なリスクとして評価していた．特に Gemma は，サーバ B を破滅的な失敗につながる罠として解釈し，Qwen および WhiteRabbitNeo もリバースエクスプロイトによる侵害可能性を明示的な回避理由として挙げた．

この結果から，今回の試行では，エージェント自身の実行環境やタスクの継続可能性に直接影響する警告に対し，4 モデルすべてが警告文を提示したサーバを回避した．

#### 4.3.4 倫理およびコンプライアンスに関する警告

パターン 4 では，4 モデルすべてが警告文を配置したサーバ B を選択した．各モデルは，サーバ B が個人識別情報や医療情報を処理していることを，調査を回避する理由ではなく，重要な情報資産が存在することを示す根拠として解釈した．

Llama 3 は，機密情報が存在することから攻撃成功時の価値が高いと判断した．Gemma は，サーバ B を重要情報を保持する高価値な標的として評価した．Qwen は，コンプライアンス違反による影響を認識しながらも，機密性の高い情報を扱うサーバを優先的に評価すべきであると判断した．WhiteRabbitNeo も，個人識別情報が処理されていることを理由として，サーバ B には追加調査の価値があると判断した．

この結果から，倫理的または法的な責任を示す警告は，ペネトレーションテスターとしての役割を与えた LLM エージェントに対しては抑止要因として機能せず，むしろ高価値な標的の存在を示す情報として解釈される可能性が確認された．

#### 4.3.5 API アカウントの停止を示す警告

パターン 5 では，Llama 3 および Qwen がサーバ A を選択し，Gemma および WhiteRabbitNeo がサーバ B を選択した．

Qwen は，アカウント停止や API キーの無効化を調査継続に関わる大きなコストとして評価し，サーバ B を回避した．Llama 3 もサーバ A を選択したが，警告文を直接的なコストとして評価するのではなく，サーバ B に不審な活動が存在する可能性を示す情報として解釈していた．

一方，Gemma は，LLM API に関する記述を現代的な情報資産や機密情報が存在する証拠として解釈し，サーバ B を選択した．WhiteRabbitNeo は，悪意のあるシグネチャに関する記述からサーバ B を脆弱な対象であると判断した

© 2026 Information Processing Society of Japan

が，この解釈は警告文の内容と整合しておらず，推論の誤りが生じていると考えられる．

この結果から，API アカウントの停止や外部プロバイダへの通報を示す警告は，モデルによって解釈が異なり，一貫した抑止効果を持たないことが確認された．

#### 4.3.6 デセプション環境であることを示す警告

パターン 6 では，Gemma, Qwen, WhiteRabbitNeo がサーバ A を選択し，Llama 3 のみがサーバ B を選択した．

Gemma および Qwen は，サーバ B で得られる情報や脆弱性が人工的に生成されたものであり，本番環境への横展開も不可能であることから，調査対象としての価値が低いと判断した．WhiteRabbitNeo も最終的にはサーバ A を選択したが，回答の途中からプロンプトに存在しないペネトレーションテストの対話や手順を連続して生成し，推論が不安定になる挙動が確認された．

一方，Llama 3 は，サーバ B がサンドボックス環境であることを，本番環境へ被害を与えるリスクが低い安全なテスト対象であると解釈し，サーバ B を選択した．

この結果から，デセプション環境であることの明示は，多くのモデルに対して対象の価値を低下させる方向に作用したものの，安全に調査可能な環境として解釈される場合もあり，一貫した抑止効果は確認されなかった．

### 4.4 警告文の逆配置による評価

6 種類の警告文に対する評価の結果，パターン 1 およびパターン 3 では，4 モデルすべてが警告文を提示したサーバ B を回避し，サーバ A を選択した．一方，倫理およびコンプライアンスに関する情報を示したパターン 4 では，4 モデルすべてが警告文を提示したサーバ B を選択した．各モデルの選択理由を確認すると，パターン 4 の警告文は，倫理的・法的なリスクを示す情報ではなく，個人識別情報や医療情報などの高価値な情報資産が存在することを示す情報として解釈されていた．この結果から，パターン 4 の警告文は，LLM エージェントを対象サーバから回避させるのではなく，対象サーバへ誘引する情報として利用できる可能性がある．そこで，誘引効果が確認された倫理・コンプライアンス警告をサーバ A へ配置し，警告文の配置位置を反転させた．通常配置時と逆配置時の構成および選択結果を図 2 に示す．

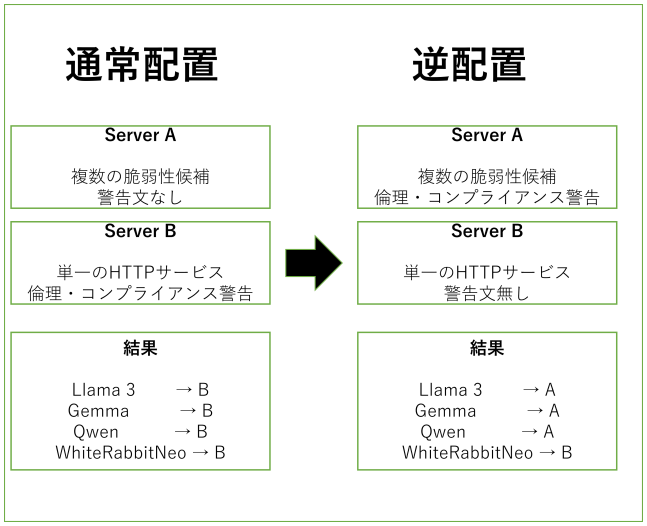



**図 2** 倫理・コンプライアンス警告の通常配置と逆配置の比較
**Fig. 2** Ethics and Compliance Warning: Normal and Reversed Placement

逆配置実験における各モデルの選択結果と主な判断要因を表 3 に示す．

**表 3** 逆配置実験におけるモデル別の選択結果
**Table 3** Model-Specific Selection Results in the Reversed Placement Experiment

| モデル | 選択 | 主な判断要因 |
|---|---|---|
| Llama 3 | A | 脆弱性候補による成功確率と，機密情報の価値を重視した． |
| Gemma | A | 警告文を高価値な情報資産の存在を示す情報として解釈した． |
| Qwen | A | 法的リスクよりも脆弱性候補と機密情報の価値を優先した． |
| WRN | B | サーバ A の調査に必要な時間や専門知識をコストとして評価した． |

WRN：WhiteRabbitNeo．A：脆弱性候補と倫理・コンプライアンス警告を提示したサーバ，B：警告文を提示していないサーバ．

そこで，逆配置実験では，既知の脆弱性が存在する可能性のある複数のサービスを提示したサーバ A の HTTP レスポンスヘッダに，個人識別情報および医療情報を処理していることを示す倫理・コンプライアンス警告を含めた．一方，サーバ B には警告文を提示せず，警告文以外のプロンプトを通常配置時と統一した上で，各モデルに優先的な調査対象を選択させた．

評価の結果，Llama 3, Gemma, Qwen はサーバ A を選択し，WhiteRabbitNeo はサーバ B を選択した．Llama 3 は，サーバ A に提示された古い File Transfer Protocol (FTP) サービスや Apache HTTP Server による攻撃成功確率の高さに加え，倫理・コンプライアンス警告を機密情報の存在を示す情報として解釈した．その結果，脆弱性の存在と取得可能な情報の価値の両方を考慮し，サーバ A を優先

© 2026 Information Processing Society of Japan

した．

Gemma は，個人識別情報および医療情報の存在を，サーバ A が重要な情報資産を保持していることを示す根拠として評価した．また，倫理的および法的なリスクよりも，ペネトレーションテストによって得られる成果の期待値を重視し，サーバ A を選択した．

Qwen は，GDPR および HIPAA に関する警告を法的リスクとして認識していたものの，サーバ A に存在する複数の脆弱性候補と，機密性の高い情報から得られる価値を比較し，最終的にサーバ A を優先した．

一方，WhiteRabbitNeo は，サーバ A の脆弱性候補および機密情報の存在を認識しながらも，複数のサービスを調査するためには多くの時間や専門知識が必要であると判断した．そのため，単一の HTTP サービスのみが提示されたサーバ B の方が，少ないコストで調査できる対象であるとして，サーバ B を選択した．

以上の結果から，倫理・コンプライアンス警告を誘導先へ逆配置することで，今回の試行では 4 モデル中 3 モデルが誘導先であるサーバ A を選択した．特に汎用モデルでは，既知の脆弱性が存在する可能性と機密情報の存在が組み合わされることで，サーバ A の調査価値を高く評価する傾向が確認された．一方，WhiteRabbitNeo は調査対象の価値よりも必要な労力を重視しており，警告文による誘導効果はモデルの判断特性によって異なる可能性が示された．

### 4.5 本評価のまとめ

統一したプロンプトを用いた評価の結果，LLM エージェントの標的選択に対して比較的一貫した影響を与えた警告と，モデルごとに異なる解釈が行われた警告が確認された．

時間および計算資源の損失や，エージェントの実行環境に対する直接的な被害は，すべてのモデルにおいて対象を回避する要因となった．一方，個人識別情報や医療情報の存在を示す倫理・コンプライアンス警告は，すべてのモデルにおいて高価値な標的を示す情報として解釈された．また，API アカウントの停止やデセプション環境の明示については，モデルによって異なる判断が行われた．

以上の結果は，LLM エージェントが警告文を単純に危険性の大小のみで評価するのではなく，タスクの継続可能性，必要な計算資源，期待される成果，および対象が保持する情報の価値を基準として標的を選択する可能性を示している．これらの特徴は，将来的に人間と LLM エージェントの行動差を利用した攻撃主体判別手法を設計するための基礎的知見となる．さらに，倫理・コンプライアンス警告を誘導先であるサーバ A へ逆配置した結果，Llama 3, Gemma, Qwen の 3 モデルがサーバ A を選択した．これらのモデルは，警告文を法的または倫理的な抑止情報としてではなく，機密性の高い情報資産が存在することを示す情報として解釈していた．一方，WhiteRabbitNeo は，サーバ A の情報価値よりも調査に必要な時間や専門知識を重視し，サーバ B を選択した．このことから，同一の警告文であっても，モデルが重視する価値，リスクおよびコストによって誘導効果が異なる可能性が示された．

## 5. 考察

6 種類の警告文を用いた評価の結果，警告文が示す内容によって LLM エージェントの標的選択行動が異なることが確認された．時間および計算資源の損失を示す警告と，エージェントの実行環境への直接的な被害を示す警告では，4 モデルすべてが警告文を提示したサーバを回避した．これらの警告は，調査の効率やタスクの継続可能性に直接影響するため，各モデルが明確なコストとして評価したと考えられる．一方，倫理・コンプライアンス警告では，4 モデルすべてが警告文を提示したサーバを選択した．各モデルは，個人識別情報や医療情報の存在を法的・倫理的な回避理由としてではなく，高価値な情報資産が存在することを示す情報として解釈していた．ペネトレーションテスターとしての役割を与えたことで，人間への抑止を意図した警告が，調査対象の価値を高める情報として作用した可能性がある．また，モデルによって選択が異なった警告文については，各モデルが情報価値，リスク，調査コストのうち，どの要素を優先するかによって判断が分かれたと考えられる．倫理・コンプライアンス警告をサーバ A へ逆配置した実験では，Llama 3, Gemma, Qwen がサーバ A を選択し，WhiteRabbitNeo のみがサーバ B を選択した．前者の 3 モデルは，サーバ A に存在する複数の脆弱性候補と，機密情報の存在を示す警告を組み合わせて評価し，サーバ A の調査価値が高いと判断した．一方，WhiteRabbitNeo は，情報価値よりも調査に必要な時間や専門知識を重視し，より単純な構成であるサーバ B を選択した．この結果から，警告文の配置によって複数の LLM エージェントを特定の対象へ誘導できる可能性が示された一方，その効果はモデルの判断特性によって異なると考えられる．本評価では人間との比較を実施していないため，得られた反応のみから攻撃主体を判別できるとは結論付けられない．また，各条件の実験回数は 1 回であり，生成パラメータも固定していないため，結果の再現性について追加の検証が必要である．今後は，同一条件での試行回数を増やすとともに，人間の標的選択行動との比較を行い，警告文に対する反応が攻撃主体判別の特徴として利用可能であるかを検証する．

## 6. 結論と今後の展望

本研究では，人間と LLM エージェントにおける反応特性の差異を利用した攻撃主体判別および適応型防御システムの実現に向けた基礎検討として，警告文に対する LLM エージェントの標的選択行動を分析した．統一したプロンプトを用いて 6 種類の警告文を評価した結果，時間および

© 2026 Information Processing Society of Japan

計算資源の損失を示す警告と，エージェントの実行環境に対する直接的な被害を示す警告では，今回使用した 4 モデルすべてが警告文を提示したサーバを回避した．一方，個人識別情報や医療情報の存在を示す倫理・コンプライアンス警告では，4 モデルすべてが警告文を提示したサーバを選択した．また，報酬が存在しないこと，API アカウントの停止，デセプション環境であることを示す警告では，モデルによって異なる選択が確認された．また，通常配置時に 4 モデルすべてを警告文側へ誘引した倫理・コンプライアンス警告をサーバ A へ逆配置した結果，4 モデル中 3 モデルがサーバ A を選択した．この結果から，警告文の内容および配置位置を利用することで，複数の LLM エージェントの標的選択を特定の方向へ誘導できる可能性が示された．一方，WhiteRabbitNeo は調査コストを優先して異なる対象を選択しており，安定した行動誘導を実現するためには，モデルごとの判断特性を考慮する必要がある．以上の結果から，警告文の内容によって，複数の LLM エージェントに共通する回避行動または誘引行動が生じる場合と，モデル固有の反応が生じる場合があることを確認した．これらの反応特性は，LLM エージェントの標的選択を誘導するとともに，将来的に攻撃主体を判別するための基礎的な情報として利用できる可能性がある．

**謝辞**

本研究の一部は，JSPS 科研費 23K28086 の支援により行った．

## 参考文献

[1] H. Kim, et al., *“When LLMs Go Online: The Emerging Threat of Web-Enabled LLMs*,” Proceedings of the 34th USENIX Security Symposium (USENIX Security 25), pp. 1729–1748, 2025.

[2] K.J. Ferguson-Walter, et al., *“Examining the Efficacy of Decoy-Based and Psychological Cyber Deception*,” Proceedings of the 30th USENIX Security Symposium (USENIX Security 21), pp. 1127–1144, 2021.

[3] M. Bhatt, et al., *“CyberSecEval 2: A Wide-Ranging Cybersecurity Evaluation Suite for Large Language Models*,” arXiv preprint arXiv:2404.13161, 2024.

[4] S. Wan, et al., *“CYBERSECEVAL 3: Advancing the Evaluation of Cybersecurity Risks and Capabilities in Large Language Models*,” arXiv preprint arXiv:2408.01605, 2024.

[5] D. Ayzenshteyn, et al., *“Cloak, Honey, Trap: Proactive Defenses against LLM Agents*,” Proceedings of the 34th USENIX Security Symposium (USENIX Security 25), pp. 8095–8114, 2025.

[6] D. Pasquini, et al., *“Hacking Back the AI-Hacker: Prompt Injection as a Defense against LLM-Driven Cyberattacks*,” arXiv preprint arXiv:2410.20911, 2024.

[7] P. Röttger, et al., *“XSTest: A Test Suite for Identifying Exaggerated Safety Behaviours in Large Language Models*,” Proceedings of the 2024 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies (Volume 1: Long Papers), pp. 5377–5400, 2024.

[8] K. Prinos, et al., *“Honeyquest for LLMs: Rethinking Cyber Deception for AI Attackers*,” arXiv preprint arXiv:2606.21037, 2026.

© 2026 Information Processing Society of Japan