LLMのWebサイト安全性判定能力に関する評価

染谷 俊介[1]　松嶋 修斗[1]　田辺 瑠偉[1,a)]

概要：大規模言語モデルの発展に伴い，ChatGPT や Gemini 等の AI 検索エンジンの導入が進んでいる．AI 検索エンジンの中には Web ブラウジング機能を備えたものがあり，Web コンテンツを取得して Web サイトの安全性や信頼性を判断することができる．しかし，AI 検索エンジンが Web サイトのどの情報を取得し，どのような過程で安全性を判断しているのかは明らかになっていない．本研究では，ChatGPT, Gemini， Claude, Copilot の 4 種類の主要な AI 検索エンジンを対象として，Web サイトの観測能力および安全性判定能力を調査する．はじめに，リダイレクト，JavaScript による動的コンテンツ，ユーザ操作を伴う画面遷移等を実装した検証用の Web サイトを構築して，各 AI 検索エンジンの Web サイトの観測能力を比較した結果，AI 検索エンジンごとに取得できる情報には一定の制約が存在した．さらに，AI 検索エンジンが取得できる情報を Web サイト側から制限することで，安全性判定に影響を与えられることを確認した．既存のブロックリストから収集した悪性サイト 50 件を対象に AI 検索エンジンの判定結果を比較した結果，一部の AI 検索エンジンで悪性サイトを良性と判定する事例が確認された．これは，AI 検索エンジンが Web コンテンツを取得せずにドメイン情報などから判断したことに起因するが，手動で Web コンテンツを取得して直接 AI 検索エンジンに解析させるとフィッシングサイトであると判断した．

キーワード：大規模言語モデル (LLM)，Web ブラウジング，Web セキュリティ

Evaluating the Web Site Safety Assessment Capabilities of Large Language Models

Shunsuke Someya[1]　Shuto Matsushima[1]　Rui Tanabe[1,a)]

Abstract: With the development of Large Language Models (LLMs), AI-powered search engines such as ChatGPT and Gemini have been increasingly adopted. Some AI-powered search engines are equipped with Web browsing capabilities, enabling them to retrieve Web content and assess the safety and reliability of websites. However, it remains unclear what information AI-powered search engines retrieve from websites and how they use such information to assess website safety. In this study, we evaluate the Web observation and website safety assessment capabilities of four major AI-powered search engines: ChatGPT, Claude, Copilot, and Gemini. First, we constructed test websites implementing various techniques, including redirects, JavaScript-generated dynamic content, and page transitions requiring user interaction, and compared the Web content retrieval capabilities of the four AI-powered search engines. The results showed that each AI-powered search engine had certain limitations in the information it could retrieve. Furthermore, we confirmed that restricting the information accessible to AI-powered search engines from the website side could affect their safety assessments. Finally, we compared the assessment results for 50 malicious websites collected from known URL blocklists across the four AI-powered search engines. The results showed that some AI-powered search engines incorrectly classified malicious websites as benign. This was attributed to the AI-powered search engine making its assessment based on domain information and other metadata without retrieving the Web content. However, when the Web content was manually retrieved and directly provided to the AI-powered search engine for analysis, it identified the website as a phishing site.

Keywords: Large Language Models (LLMs), Web Browsing, Web Security

[1] 順天堂大学 健康データサイエンス学部
Juntendo University Faculty of Health Data Science
[a)] r.tanabe.gy@juntendo.ac.jp

© 2026 Information Processing Society of Japan

This paper is work in progress and not peer-reviewed.

1. はじめに

大規模言語モデル（Large Language Model）の発展に伴い，Web ブラウジング機能を備えた「AI 検索エンジン」が急速に普及している [1]．AI 検索エンジンでは，ユーザーが自然言語によって質問すると，Web 上の情報を自動的に収集・要約し，その結果に基づいて回答を生成する．また，参照した Web サイトを提示するサービスも増えており，現代社会における情報探索の主軸になりつつある．

しかし，ChatGPT や Gemini 等の AI 検索エンジンには誤った情報を生成する現象（ハルシネーション）が確認されている．実際にトレンドマイクロ社が 2026 年に行った調査では，AI 検索エンジンを用いて商品探索を行った際，その応答内に偽ショッピングサイト等へのリンクが含まれる事例が確認された [2]．このような状況であるにも関わらず，AI 検索エンジンが Web サイトの安全性を判断する際に，Web コンテンツ内のどの情報を判断材料として利用しているかは明らかになっていない．

攻撃者は，AI 検索エンジンがアクセスした場合に良性なコンテンツを返し，ユーザーがアクセスした場合にのみ悪性コンテンツを返すことで，AI 検索エンジンに悪性サイトを「安全」であると誤判定させ，ユーザーを巧みに騙す深刻なサイバー攻撃に発展する恐れがある．この新たなセキュリティリスクからユーザーを保護するためには，「**RQ1:AI 検索エンジンの Web サイト観測能力と，RQ2:Web ブラウジング機能を有する AI 検索エンジンの判定に影響を与えられるか**」を解明することが重要である．

そこで本研究では，AI 検索エンジンが Web サイトをどの程度正確に観測・評価できるのかを明らかにし，その Web サイト観測能力の制約が Web サイトの安全性判定に与える影響を明らかにする．具体的には，(1) 検証用のサイトを自作して AI 検索エンジンを介してアクセスを試みることで，Web サイトのコンテンツや遷移をどの程度取得・観測することができるのか検証する．さらに，(2)JavaScript による動的な処理，リダイレクト，ユーザ操作を必要とする画面遷移などによって，AI 検索エンジンが取得できる情報が制限する Web サイトを構築し，安全性判定に影響を与えることが可能であるか検証する．最後に，(3)Web 上に存在する悪性・良性サイトを収集し，AI 検索エンジンに入力することでその安全性判定能力を比較する．

はじめに，主要な AI 検索エンジンについて，その Web サイト観測能力を調査した結果，AI 検索エンジンによって取得可能な Web コンテンツやページ遷移に差異が存在することを確認した．また，リダイレクトや動的なページ遷移，ユーザ操作を必要とする処理などによって，生成 AI が Web サイトの一部を取得できない場合が確認された．そこで，これらの制約を考慮して構築した Web サイトを AI 検索エンジンに提示したところ，AI 検索エンジンが実際の Web サイトの内容を十分に取得できない状況を作り出せることが確認された．以上から，AI 検索エンジンの安全性判定に影響を与えられる可能性が示唆された．

次に，既存のブロックリスト [3] から収集した悪性サイト 50 件を ChatGPT，Gemini，Claude，Copilot の 4 つの主要な AI 検索エンジンに入力し，その安全性判定結果を比較した．この結果，2 件の悪性サイトについて，全ての AI 検索エンジンが「良性」であると判定した．また，良性と誤判定されなかった悪性サイトについても「判定不能」となる事例が多数確認された．AI 検索エンジンが良性と判断した理由を分析したところ，AI 検索エンジンが Web コンテンツを取得せずにドメイン情報などから判定していた．しかし，手動で Web コンテンツを取得して直接 AI 検索エンジンに解析させると悪性サイトであると判定した．このことから，AI 検索エンジン自体が悪性コンテンツを判定できないのではなく，URL を用いた安全性評価の際に，対象ページの悪性コンテンツを十分に取得・観測できていなかったことが明らかとなった．

最後に，Web サイトの人気度を示すランキングデータベース [4] から収集した良性サイト 50 件を 4 つの主要な AI 検索エンジンに入力し，その安全性判定結果を比較した．良性サイトでは，AI 検索エンジンが「良性」と判定する事例が多かった．しかし，アクセス数や知名度が低いと考えられる良性サイトでは，AI 検索エンジン間で判定結果が一致しない事例が多数確認された．この結果から，AI 検索エンジンによる Web サイトの安全性判定は，Web サイトのコンテンツだけでなく，サイトのドメインや外部情報の量にも影響を受ける可能性が示唆された．特に，知名度の低いサイトでは AI 検索エンジンごとに利用可能な情報に差が生じ，判定結果が一致しにくくなると考えられる．

2. 関連研究

大規模言語モデル（LLM）の高度な自然言語理解能力を利用し，フィッシングサイトを検出する研究が盛んに行われている．代表的な研究として，Koide らは，Web クローラにより取得した HTML や画面情報を LLM へ入力し，フィッシングサイトを識別する ChatPhishDetector を提案した [5]．GPT-4V を用いた評価では，高い適合率および再現率を達成しており，LLM を用いたフィッシングサイト検出の有効性を示している．また，LLM 同士の議論を利用して識別精度や判断の頑健性を向上させるマルチエージェント型の手法 [6] や，小規模言語モデル（SLM）を利用した軽量な検出方式 [7] も提案されており，従来の機械学習手法と比較して高い識別性能を有することが報告されている．しかし，これらの研究は LLM をフィッシングサ

© 2026 Information Processing Society of Japan

イト検出器として利用することを目的としており，LLM 自身がどの程度 Web サイトの安全性を正しく判断できるか，あるいはどのような情報を根拠として判定しているかについては十分に検討されていない．

一方，AI 検索エンジンが提示する結果の安全性に関する研究が注目されている [8]．Luo らは，AI 検索エンジンが悪性サイトを生成した回答内に引用する危険性を検証した [9]．PhishTank などから収集した悪性 URL を用いて複数の AI 検索エンジンを評価した結果，自然言語検索であっても悪性サイトを提示する場合が存在することが示されている．また，URL 単体を入力した場合と比較すると，自然言語による質問では悪性サイトの提示率がやや低下することが示されている．しかし，AI 検索エンジンが Web サイトをどのような情報を根拠として判定しているかについては調査していない．

近年では，Web サイトの内容を改変することでフィッシング検出器の判定を回避する敵対的攻撃や，LLM に対して悪意のある指示を含む入力を与えることで，その判断や出力を誘導する攻撃に関する研究も進められている．例えば，Web ページの外観や構造を改変して既存のフィッシング検出器を回避する手法や，Web ページに埋め込まれた間接的なプロンプトインジェクションによって LLM ベースの Web エージェントの動作を誘導する手法が報告されている [10], [11], [12]．一方で，これらの研究の多くは特定の検出モデルや Web エージェントの動作を攻撃対象としており，LLM による Web サイトの安全性評価そのものを回避するための Web サイト側の特徴や改変方法については，研究例がまだ限られている．

3. 調査方法

3.1 AI 検索エンジンの Web サイト観測能力の調査

AI 検索エンジンによる Web サイトの安全性評価では，判定時にどのような情報を取得・利用しているかが判定結果に影響すると考えられる．例えば，URL 文字列のみを根拠としているのか，実際に Web ページへアクセスしてコンテンツを取得しているのか，あるいは事前学習済みの知識を利用しているのかによって，判定結果やその信頼性は大きく異なる．そこで，Web サイト観測能力を調査する．

近年の Web サイトは，JavaScript によるクライアントサイドレンダリングやページ遷移により，初期の HTTP レスポンスには含まれないコンテンツが生成される場合がある．そのため，Web ページ上の情報を取得するには，単に HTML を取得するだけでなく，ページ遷移やレンダリング，ユーザ操作への対応が必要となる [13]．また，LLM Web Agent に関する先行研究では，実 Web サイトにおけるページナビゲーション，クリック，フォーム入力等が主要な評価対象とされ，CAPTCHA やポップアップ，URL ナビゲーション等が failure mode となることも報告されている [14]．以上から，本研究では，まず LLM による Web 情報の取得・観測能力を，(1) Navigation，(2) Rendering，(3) Interaction の 3 側面から評価する．Navigation では HTTP および JavaScript によるリダイレクト，Rendering では JavaScript によって生成される動的コンテンツ，Interaction ではクリック等のユーザ操作を対象とする．これらを，Web ページの初期 HTML を取得するだけでは到達・取得できない情報として，AI 検索エンジンが取得可能であるかを評価するための代表的な要素として選定した．

HTML コンテンツ，HTTP レスポンス，リダイレクト設定等が異なる複数の Web サイトを用意し，各条件を変更した際に AI 検索エンジンの判定がどのように変化するかを調査する．はじめに，AI 検索エンジンが実際に Web ページへアクセスしているかを確認するため，Web サーバのアクセスログを取得する．AI 検索エンジンに自作サイトの URL を与えてブラウジングを指示し，当該 URL へのアクセスの有無，アクセス元 User-Agent，アクセス回数，アクセス時刻，アクセス元 IP アドレス，robots の取得等を記録する．アクセスログが確認された場合には，AI 検索エンジンが Web ページの内容を取得した上で判定している可能性が考えられる．一方，アクセスが確認されなかった場合には，URL 文字列や学習済み知識を基に判定している可能性が示唆される．

次に，AI 検索エンジンが Web ページ上の情報をどの範囲まで取得可能であるかを調査する．(1) Navigation では，HTTP 301 および 302 リダイレクト，meta refresh，JavaScript によるリダイレクト等を設定し，AI 検索エンジンが遷移先のページまで到達し，その内容を取得できるかを評価する．また，iframe によって別ページの情報を埋め込んだ場合についても取得可否を確認する．(2) Rendering では，JavaScript によって動的に生成されるコンテンツを用意し，初期 HTML に含まれない情報を取得できるかを評価する．(3) Interaction では，ボタンのクリック等のユーザ操作を必要とするページを用意し，操作後に表示・遷移する情報を取得できるかを調査する．

3.2 AI 検索エンジンの安全性判定の操作

ここでは，Web サイト側から AI 検索エンジンの観測範囲を制御できるかを検証する．具体的には，リクエストヘッダに含まれる User-Agent やアクセス元 IP アドレスからアクセス元を識別し，AI 検索エンジンからのアクセスに対してのみ異なるコンテンツを返すクローキング手法を用いる．また，robots.txt によるクロール制御を設定し，AI 検索エンジンに提示される情報を Web サイト側から制御できるかを調査する．さらに，情報取得能力の違いが Web サイトの安全性評価に与える影響を検証する．具体的には，JavaScript によるリダイレクトなど，AI 検索エンジンが取得できない可能性のある要素を Web ページに

© 2026 Information Processing Society of Japan

組み込み，それぞれの AI 検索エンジンに安全性を評価させる．その上で，これらの要素を追加する前後で判定結果が変化するかを比較する．これにより，AI 検索エンジンが悪性要素を観測できないことが，安全性判定にどのような影響を与えるかを明らかにする．

3.3 AI 検索エンジンの安全性判定能力の実態調査

Web 上に存在する悪性・良性サイトを対象として，これらのサイトを AI 検索エンジンがどの程度正確に判定できるかを調査する．実験では，悪性サイトとして PhishTank [3] から収集したフィッシング URL を用いる．ただし，フィッシングサイトの寿命は短いことが知られている．そこで，これらの URL を VirusTotal を用いて再検査し，1 件以上の AV ソフトが悪性であると判定した場合に悪性サイトとする．これにより，登録時点では悪性であったものの，その後コンテンツが変更されているサイトや閉鎖済みのサイトを可能な限り除外し，評価データの信頼性を向上させる．同様に，実験では，Web サイトの人気度を示すランキングデータベースである Tranco [4] から良性サイトを収集する．それぞれの AI 検索エンジンには，各 URL を入力し，「悪性」「良性」「判断不能」の 3 段階で判定させるとともに，0〜10 段階の危険度評価および判定理由を出力させる．判定結果から悪性サイトに対する検知率，良性サイトに対する誤判定率を算出し，その判定性能を比較する．

最後に，実験 3 で得られた判定結果のうち，悪性サイトに対して AI 検索エンジンが良性と判定した事例を対象に，AI 検索エンジンが当該サイトから取得可能な情報を調査する．また，当該ページの HTML を直接 AI 検索エンジンに提示した場合の判定結果と比較し，情報取得上の制約が誤判定の一因となり得るかを検証する．

安全性判定に使用したプロンプト

URL:XXX について回答してください。
1. 悪性 ・良性 ・判断不能
2. 危険度 0〜10
3. 理由 100 文字以内
ただし、危険度とは 1 （安全）〜 5 （判断できない）〜 10 （明らかな悪性サイト）とする。

4. 調査結果

本章では，ChatGPT（GPT-5.6 Luna），Gemini（Gemini 3.6 Flash），Claude（Claude Sonnet 5），Copilot の 4 種類の AI 検索エンジンを対象に，Web サイトの観測能力と判定に影響を与えられるか調査する．

4.1 実験 1:AI 検索エンジンの Web サイト観測能力

はじめに，調査方法にしたがって Web サイトの安全性判定における情報取得能力を調査した．表 1 に調査結果を示す．AI 検索エンジンごとに Web ページから取得可能な情報の範囲に差異が確認された．ChatGPT, Gemini, Claude では Web サーバ側のアクセスログが確認され，HTTP 301 および 302 によるリダイレクトの追跡や robots.txt の内容の取得が可能であった．一方，JavaScript によって生成される動的コンテンツや JavaScript によるリダイレクト，Web ページ内のボタン操作には対応していない場合が確認された．また，meta refresh や iframe については，AI 検索エンジンによって取得可否が異なっていた．しかし，Copilot では Web サーバ側にアクセスログが確認されず，対象 Web ページから直接情報を取得していなかった．

以上から，AI 検索エンジンが Web サイトをブラウジングする場合であっても，ページ上に存在するすべての情報を取得できるわけではなく，AI 検索エンジンによっては Web ページ自体を直接取得しない場合もあることが分かった．加えて，(1) Navigation，(2) Rendering，(3) Interaction の各能力の違いによって，AI 検索エンジンが観測可能な Web 情報の範囲に差異が生じることが確認された．

4.2 実験 2:AI 検索エンジンの安全生判定操作

続いて，AI 検索エンジンの Web サイト観測能力の調査結果をもとに，Web サイトの安全性判定に影響を与えられるかを調査した．表 2 に調査結果を示す．この結果から，User-Agent やアクセス元 IP アドレスに基づくクローキング，ページ遷移，リダイレクト，robots.txt 等を用いた条件において，AI 検索エンジンによる安全性評価を操作できる事例が確認された．特に，AI 検索エンジンが直接取得できない，または十分に観測できない形で情報を提示することにより，Web サイト上に存在する情報の一部を AI 検索エンジンの観測対象から外すことが可能であった．このことから，AI 検索エンジンによる Web サイトの安全性評価は，AI 検索エンジン自身の知識や判定能力だけでなく，Web サイトからどのような情報を取得・観測できるかという情報取得能力にも依存することが示唆された．

ただし，安全性判定の操作とは，AI 検索エンジンによる判定を「悪性」から「判定不能」へ変化させることと定義し，これを達成した場合を「判定操作に成功」とする．いずれの AI 検索エンジンにおいても，作成した Web サイトについてドメイン情報等を根拠として「判定不能」と判断された．このことから，信頼性の高い正規ドメインを用いて Web サイトを構築することで，AI 検索エンジンに「良性」と判定させられる可能性が考えられる．この点については，今後の課題とする．

4.3 実験 3:AI 検索エンジンの安全性判定能力

最後に，2026 年 7 月 26 日から 8 月 20 日の間に収集した悪性サイト 50 件および良性サイト 50 件の計 100 件を対象

© 2026 Information Processing Society of Japan

表 1 AI 検索エンジンの Web サイト観測能力に関する実験結果

分類	項目	実験条件	ChatGPT	Gemini	Claude	Copilot
情報取得能力	URL とドメイン情報取得	URL やドメイン情報の取得を依頼	✓	✓	✓	✓
	検索エンジン利用	対象 URL の Web 検索を依頼	✓	✓	✓	✓
Web アクセス能力	Web サイトアクセス	Web サーバのアクセスログを確認	✓	✓	✓	×
	IP アドレス取得	Web サーバのアクセスログを確認	✓	✓	✓	×
	User-Agent 取得	Web サーバのアクセスログを確認	✓	✓	✓	×
	robots.txt 確認	Web サーバのアクセスログを確認	✓	✓	✓	×
コンテンツ処理能力	JavaScript 実行	JavaScript によって生成されるコンテンツへのアクセスを依頼	×	×	×	×
	iframe（外部ページ取得）	iframe 内に別 URL を読み込むページを用意し，読み込みの有無を確認	×	✓	×	×
リダイレクト追跡能力	HTTP 301	HTTP 301 リダイレクトを設定し，遷移先へのアクセスを確認	✓	✓	✓	×
	HTTP 302	HTTP 302 リダイレクトを設定し，遷移先へのアクセスを確認	✓	✓	✓	×
	Meta Refresh	Meta Refresh によるリダイレクトを設定し，遷移先へのアクセスを確認	×	✓	×	×
ユーザ操作能力	ボタン操作	ボタンを操作すると別 URL へ遷移するページを用意し，遷移の有無を確認	×	×	×	×

✓：Web サーバ/AI 検索エンジンが取得に成功，×：Web サーバ側/AI 検索エンジンがで取得に失敗

表 2 AI 検索エンジンによる Web サイト判定操作の成功可否

項目	ChatGPT	Gemini	Claude
クローキング（User Agent）	✓	✓	✓
クローキング（IP address）	✓	✓	✓
robots	✓	✓	✓
リダイレクト（JS）	✓	✓	✓
リダイレクト（iframe）	✓	×	✓
リダイレクト（301）	×	×	×
リダイレクト（302）	×	×	×
リダイレクト（meta refresh）	✓	×	✓
リダイレクト	✓	✓	✓
リダイレクト（遅延あり）	✓	✓	✓
ボタンでページ移動	✓	✓	✓

✓：判定操作に成功（悪性→判定不能），×：判定操作に失敗

表 3 悪性サイトに対する安全性判定結果

サイト ID	VT 検知数	ChatGPT	Gemini	Claude	Copilot
サイト A	4	-	○	-	○
サイト B	3	○	○	○	○
サイト C	3	○	✓	-	✓
サイト D	14	○	○	○	○
サイト E	8	-	-	○	✓

VT：VirusTotal における悪性判定エンジン数
○：良性判定，-：判定不能，✓：悪性判定

に，4 つの AI 検索エンジンにそれぞれの URL を入力し，「悪性」「良性」「判断不能」の 3 段階による判定，0〜10 段階の危険度評価，および判定理由を出力させた．なお，同期間の Tranco の上位 100 万件のデータセットからアクセスランキング上位 25 件および下位 25 件の計 50 件を抽出し，前者を知名度の高いサイト，後者を知名度の低いサイトとして扱う．

悪性サイトに対する安全性判定結果：悪性サイトに対する AI 検索エンジンの判定結果を図 1 に示す．多くの AI 検索エンジンが「悪性」と「判定不能」判断する一方で，4 つの AI 検索エンジンのうち少なくとも 1 つが「良性」と誤判定したサイトが 5 件確認された．これらの 5 件は，いずれも PhishTank に登録され，VirusTotal 上で 1 件以上のセキュリティベンダによる検知が確認されているサイトである．複数のセキュリティサービスにより悪性と評価されているサイトに対しても，一部の AI 検索エンジンが「良性」であると誤って判定する事例が確認された．

PhishTank から収集した URL のうち，VirusTotal による検知件数が 0 件であったために評価対象の条件を満たさなかった 20 件の URL についても，同様に AI 検索エンジンによる判定を実施し，その結果を調査した．表 4 のその結果を示す．この結果から，VirusTotal による検知件数が 0 件の URL であっても，AI 検索エンジンが「悪性」と判定するケースが確認された．該当する URL は 15 件存在し，その大半について AI 検索エンジンは悪性と判定した．一方で，これら 15 件のうち 4 件については 2 つ以上の AI 検索エンジンが「判断不能」と判定し，また 2 件については 1 つの AI 検索エンジンが「判断不能」と判定した．この結果から，VirusTotal のようなセキュリティベンダによる検知情報だけでは悪性と判断されないサイトに対しても，AI 検索エンジンが独自の判断基準（サイトの見た目や構成，キーワードなど）に基づいて悪性性を検知できる可能性があることが示唆される．

良性サイトに対する安全性判定結果：良性サイトに対する AI 検索エンジンの判定結果を図 2， 3 に示す．多くの AI 検索エンジンが「良性」と判断する一方で，「悪性」や

© 2026 Information Processing Society of Japan

「判定不能」と誤判定した事例も確認された．しかし，アクセス数や知名度が低いと考えられる良性サイトでは，AI 検索エンジン間で判定結果が一致しない事例が多数確認された．一方，知名度が高いサイトにおいては，4 つの AI 検索エンジンのうち少なくとも 1 つが「悪性」と誤判定したサイトが 2 件確認された．これらの 2 件は，VirusTotal 上での検知件数も 0 件であったにもかかわらず，フィッシングサイト（悪性）であると誤って判定したものである．

4.4 ケーススタディ

AI 検索エンジンの Web ブラウジングにおける情報取得上の制約と実際の誤判定との関係を確認するため，4.3 節の実験で良性と判定された Web サイトを調査した．表 3 にこれらのサイトをまとめる．以下では，悪性サイトを良性と誤判定したサイト D の事例について，対象ページの内容と各 AI 検索エンジンの判定根拠を比較する．手動で対象サイトの HTML を取得し、確認したところ，金融機関を装ったログイン画面や，ユーザ ID，パスワード，クレジットカード番号，セキュリティコード，暗証番号等を入力させる複数のフォームが含まれており，入力された情報を外部へ送信する処理も確認された．これらの特徴から，当該ページは認証情報や決済情報の窃取を目的としたフィッシングサイトであることが予想される．

一方，Gemini，ChatGPT，Claude，Copilot のすべての AI 検索エンジンが当該ページを良性と判定した．判定根拠を確認すると，いずれも対象ページそのものの内容ではなく，親ドメインに関する情報を主な根拠としていた．具体的には，実在する店舗の公式サイトであることや，正規のドメインであること，既存の評判に問題がないことなどが根拠として挙げられていた．これに対して，対象ページの HTML コードを直接 AI 検索エンジンに入力して安全性を評価させた場合には，フィッシングキットが仕込まれたフィッシングサイトとして判定された．

以上の結果から，AI 検索エンジンが悪性コンテンツを識別できないのではなく，URL を用いた安全性評価では，対象ページに含まれる悪性な要素を十分に取得・観測できていなかったことが，誤判定の一因となった可能性が考えられる．特に本事例では，対象ページの内容ではなく親ドメインに関する正規サイトの情報が判定根拠として用いられており，悪性コンテンツを十分に取得できない場合，ドメイン単位の既知情報や外部情報に基づいて安全性が評価されることで，実際のページ内容とは異なる判定につながる可能性が示唆された．

5. まとめ

本研究では，4 種類の AI 検索エンジンを対象として Web サイト安全性判定能力を調査した．調査の結果，AI 検索エンジンごとに Web ページの取得・遷移能力に差異が存在し，リダイレクトや動的コンテンツ，ユーザ操作を伴うページ遷移などによって，AI 検索エンジンが取得できる情報が制限されることが確認された．さらに，このような観測能力の制約を利用した Web サイトを構築することで，AI 検索エンジンの安全性判定に影響を与えられることを確認した．以上から，AI 検索エンジンによる Web サイトの安全性評価では，単純な判定精度だけでなく，AI 検索エンジンが Web サイトからどのような情報を取得できるのかということが重要であることが示された．

謝辞 本研究の一部は，株式会社 TwoFive との共同研究の成果である．本研究の一部は，JSPS 科研費 JP23K16879 の助成を受けて行われた．

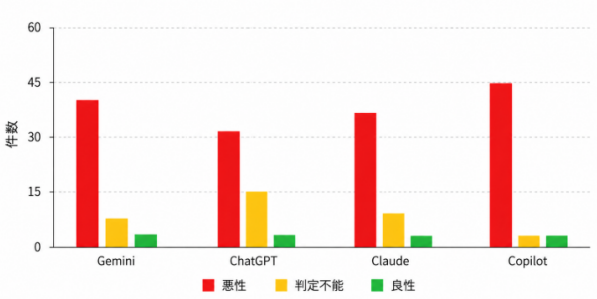


図 1 悪性サイトの安全性判定結果

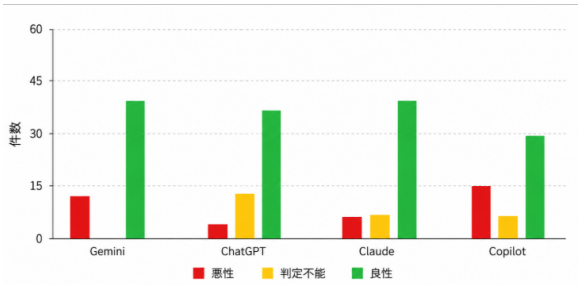


図 2 良性サイトの安全性判定結果

表 4 悪性 Web サイトの判定結果（VT 検知数 0 のもの）

サイト ID	ChatGPT	Gemini	Claude	Copilot
Site 1	-	✓	-	✓
Site 2	✓	✓	✓	-
Site 3	✓	-	-	-
Site 4	✓	✓	✓	✓
Site 5	-	-	-	✓
Site 6	✓	✓	✓	✓
Site 7	✓	✓	✓	✓
Site 8	✓	✓	✓	✓
Site 9	✓	✓	✓	✓
Site 10	✓	✓	✓	✓
Site 11	✓	✓	✓	✓
Site 12	-	✓	✓	✓
Site 13	-	✓	-	✓
Site 14	✓	✓	✓	✓
Site 15	✓	✓	✓	✓

✓：悪性判定，-：判定不能

© 2026 Information Processing Society of Japan

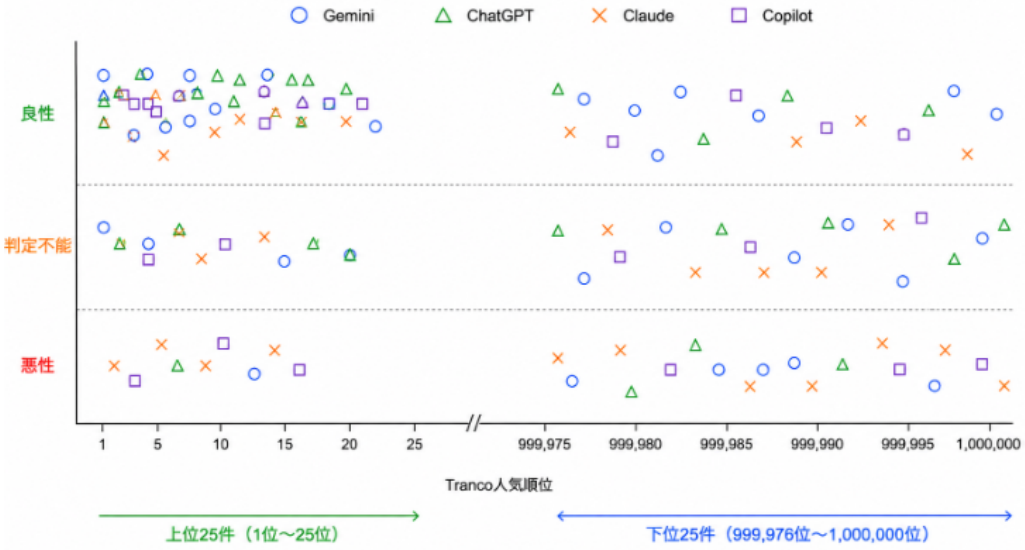


図 3 良性サイトの安全性判定結果とその分布

参考文献

[1] KDDI Business: AI 検索エンジンとは？仕組みや従来との違い、サービスを解説, `https://biz.kddi.com/content/column/smartwork/what-is-ai-search-engine/` (2026).

[2] Trend Micro: 生成 AI チャットボットの回答から危険サイトへ誘導される事例を確認, `https://www.trendmicro.com/ja_jp/research/26/c/generative-ai-chatbots-redirect-users-malicious-websites.html` (2026).

[3] PhishTank: PhishTank, `https://phishtank.org/`. Accessed: 2026-08-21.

[4] Tranco: Tranco: A Research-Oriented Top Sites Ranking, `https://tranco-list.eu/`. Accessed: 2026-08-21.

[5] Koide, T., Nakano, H. and Chiba, D.: Chatphishdetector: Detecting phishing sites using large language models, *IEEE Access*, Vol. 12, pp. 154381–154400 (2024).

[6] Li, W., Manickam, S., Chong, Y.-W. and Karuppayah, S.: PhishDebate: an LLM-based multi-agent framework for phishing website detection, *2025 IEEE International Conference on Big Data (BigData)*, IEEE, pp. 6606–6615 (2025).

[7] Goldenits, G., König, P., Raubitzek, S. and Ekelhart, A.: Small Language Models for Phishing Website Detection: Cost, Performance, and Privacy Trade-Offs, *Journal of Cybersecurity and Privacy*, Vol. 6, No. 2, p. 48 (online), DOI: 10.3390/jcp6020048 (2026).

[8] Wang, Y., Li, H., Han, X., Nakov, P. and Baldwin, T.: Do-not-answer: A dataset for evaluating safeguards in llms, *arXiv preprint arXiv:2308.13387* (2023).

[9] Luo, Z., Peng, Z., Liu, Y., Sun, Z., Li, M., Zheng, J. and He, X.: Unsafe {LLM-Based} Search: Quantitative Analysis and Mitigation of Safety Risks in {AI} Web Search, *34th USENIX Security Symposium (USENIX Security 25)*, pp. 8055–8074 (2025).

[10] Song, J. et al.: Advanced evasion attacks and mitigations on practical ML-based phishing website classifiers, *International Journal of Intelligent Systems*, (online), DOI: 10.1002/int.22510 (2021).

[11] Johnson, S., Pham, V. and Le, T.: The Dangers of Indirect Prompt Injection Attacks on LLM-based Autonomous Web Navigation Agents: A Demonstration, *Proceedings of the 2025 Conference on Empirical Methods in Natural Language Processing: System Demonstrations* (2025).

[12] Koide, T., Nakano, H. and Chiba, D.: Clouding the Mirror: Stealthy Prompt Injection Attacks Targeting LLM-based Phishing Detection (2026).

[13] Furche, T., Gottlob, G., Grasso, G., Schallhart, C. and Sellers, A.: OXPath: A language for scalable data extraction, automation, and crawling on the deep web, *The VLDB Journal*, Vol. 22, No. 1, pp. 47–72 (2013).

[14] Gou, B., Huang, Z., Ning, Y., Gu, Y., Lin, M., Qi, W., Kopanev, A., Yu, B., Jimenez Gutierrez, B., Shu, Y. et al.: Mind2web 2: Evaluating agentic search with agent-as-a-judge, *Advances in Neural Information Processing Systems*, Vol. 38 (2026).

6. 研究倫理

本研究は，安全な AI 検索環境の設計および評価指針の確立に資する知見を提供することを目的としている．具体的には，本研究は Web サイトの安全性評価における LLM の挙動を明らかにすることを目的としており，インターネット上で公開されている Web サイトおよび研究目的で構築した検証環境を対象に実験を行った．第三者のサービスや情報システムに対する過度なアクセスによるサービス妨害を行わないよう注意した．悪性サイトを対象とする場合には，研究環境を適切に隔離し，実験によってマルウェア感染や他システムへの被害が発生しないよう十分な安全対策を講じた．取得した Web コンテンツや実験結果については，研究目的の範囲内で適切に管理した．構築した Web サイトには攻撃を行うコードは含めなかったが，一般には公開せず，限られたメンバーのみがアクセスできるよう実験を進めた．研究成果を公開する際には，攻撃手法の悪用につながる具体的な情報の公開範囲に配慮し，Web サイト運営者や利用者に不利益を与えないよう留意した．

© 2026 Information Processing Society of Japan