知覚ハッシュとマルチモーダルモデルを用いたコピーミント画像の参照元NFT識別

Sanjaya SAMUEL[1]　面 和成[1]

概要：NFT に関連付けられた画像は、複製・改変されて別の NFT として再発行されることがある。近似複製検出で類似 NFT は探せるが、多数の候補から参照元のレコードを 1 件に絞るのは難しい。本研究では、この問題を NFT レコード単位の出典識別として定式化し、Gate–Rank–Identify フレームワークを提案する。Gate 相当の複数ハッシュのみのベースラインは、92,270 クエリの 99.38%で正解を残したが、候補は平均 14,033 件であった。固定 1,200 クエリでは、20x5 構成が最高のエンドツーエンド識別率 85.00%を得た。候補集合正解率、推定 API コスト、ウォームキャッシュ遅延を等しく重視した min–max 計算では 4x25 が選ばれ、92.25%、83.00%、平均 16.6 秒／クエリという均衡した結果を示した。

キーワード：NFT、コピーミント、知覚ハッシュ、マルチモーダルモデル、出典識別

Preliminary Study of Source NFT Identification for Copyminted Images

Sanjaya SAMUEL[1]　Kazumasa OMOTE[1]

Abstract: Images linked to non-fungible tokens (NFTs) can be copied, altered, and re-minted. Near-duplicate detection finds similar NFTs, but cannot identify the source record when many candidates remain. We therefore propose Gate–Rank–Identify: perceptual hashes filter and rank the reference corpus before a multimodal model compares the leading candidates. The Gate-equivalent multiple-hash baseline retained the correct record for 99.38% of 92,270 queries, yet returned 14,033 records per query on average. On a fixed 1,200-query sample, 20x5 achieved the highest end-to-end identification rate of 85.00%. With equal-weight min–max scoring of candidate-set accuracy, estimated API cost, and warm-cache latency, 4x25 was the balanced operating point at 92.25%, 83.00%, and 16.6 seconds per query, respectively.

Keywords: NFT, copyminting, perceptual hashing, multimodal model, source identification

1. はじめに

NFT のトークンレコードはブロックチェーン上に置かれるが、画像そのものは通常、メタデータから外部ストレージを参照する形で管理される。ERC-721 や ERC-1155 の場合、レコードはネットワーク、コントラクトアドレス、トークン ID の組によって一意に定まる [1][2]。NFT 市場では、正規 NFT の画像を流用して別のトークンレコードを作る偽造が問題になっている。なかでもコピーミントは代表的な手口であり [3][4]、公開画像を無断で複製・改変し、別の NFT として再発行することで正規 NFT との混同を招く。ブロックチェーンの合意形成が保証するのはトークンの状態や所有であって、外部画像の独自性や利用許諾ではない。このため、合意形成だけでコピーミントを防ぐことはできない。

知覚ハッシュや学習表現により、近似複製画像を検索できる [5][6]。Kotzer ら [3] は複数ハッシュの相補性を示したが、多数の参照が閾値を満たせば、どの NFT レコードが出典かは決められない。全画像をマルチモーダルモデルで直接比較する方法も、大規模データベースには高コストである。

[1] 筑波大学 〒 305-8573, 茨城県つくば市天王台 1-1-1
University of Tsukuba、1-1-1 Tennodai、Tsukuba、Ibaraki 305–8573 Japan

© 2026 Information Processing Society of Japan

This paper is work in progress and not peer-reviewed.

この課題を NFT レコード単位の出典識別として捉え、本研究では Gate–Rank–Identify フレームワークを提案する。まず Gate が複数の知覚ハッシュで無関係な参照を除き、Rank が残った候補を並べて上位 K 件に絞る。最後に Identify が汎用マルチモーダルモデルを用い、1 件の NFT レコードまたは「該当なし」を返す。複数ハッシュだけを用いる手法は、Gate 段階に対応するベースラインとする。

レコードを 1 件選べれば、画像に基づく判断を、そのレコードに保存されたネットワーク、コントラクトアドレス、トークン ID へ結び付けられる。ただし、本方式が示すのはデータセット内で視覚的に妥当な参照レコードであり、著作者、許諾、フェアユース、権利侵害を判定するものではない。著者らの知る限り、NFT の複製問題を正確な参照レコードのエンドツーエンド識別として評価した実証研究はまだ限られている。

本研究の貢献は次の 3 点である。

- 多数の類似候補を返す近似複製検出から一歩進め、疑わしい画像に対応する参照 NFT レコードを 1 件に絞る課題を定式化した。
- 知覚ハッシュによる候補削減とランキング、マルチモーダルモデルによる最終識別を一つにした Gate–Rank–Identify 方式を提案した。高コストな画像比較を上位候補だけに適用し、タスク固有の追加学習・ファインチューニングや専用 VLM の構築を要しないため、低コストで追試しやすい。
- 100,206 件の参照 NFT レコードと 92,270 件のクエリで Gate・Rank を評価した。さらに、固定した 1,200 クエリを使い、候補の提示構成によって識別精度、API コスト、遅延がどう変わるかを比較し、精度と運用効率のトレードオフを明らかにした。

2. 関連研究

近似複製の検索には、知覚ハッシュ、局所特徴、学習済み記述子などが使われる [5][6]。局所特徴を索引化し、コンパクトなバイナリ記述子と幾何的一貫性を組み合わせた大規模検索も提案されている [7]。学習表現は豊かな特徴を持つのに対し、知覚ハッシュは計算が軽く、大規模な比較に向く。本研究では検索と最終識別を分け、ハッシュを最終判定ではなく候補生成に用いる。

暗号学的ハッシュは厳密なファイル同一性の確認に適するが、小さな符号化・画素変更でも値が大きく変わるため、改変画像の近似検索には向かない。知覚ハッシュでは、変換後の安定性と無関係画像の識別性の間に、閾値依存のトレードオフがある [8]。また、ペアの一致判定、順位付き検索、複製群のクラスタリングでは出力が異なる。高い二値検出率が、大規模候補集合から 1 レコードを選べることを意味するわけではない。

知覚ハッシュは画像を短い署名に変換し、画像が改変されても近い値を保つように設計される。本研究で使う aHash は画像全体の明暗、pHash は低周波の構造、HSVHash は色の分布、sHash はクロップ後にも残る局所領域を主に捉える [8][9]。これらの相補的な証拠を any-match でまとめれば多様な変換を拾いやすくなる反面、候補数は増える。そのため、後段でのランキングと識別が欠かせない。

学習ベースでは、Pizzi らが大規模近似検索用の自己教師あり記述子 SSCD を提案した [6]。Wang らは未知の改変への一般化を検討し [10]、Prabhakaran らは電子商取引規模で大域検索と局所検証を組み合わせた [11]。学習済み表現は有効だが、性能と計算量は訓練分布、ドメイン転移、局所検証、索引規模に左右される。本研究は学習型検索との優劣ではなく、保存済みハッシュによる透明な候補生成・順位付けと最終識別を分担する設計を評価する。

NFT を直接扱う研究として、Kotzer ら [3] は複数ハッシュによる複製検出、Trinh と Ta [12] はブロック単位の改ざん検出、E ら [13] はコピーキャット調査に取り組んだ。著者らの先行研究 [14] は、事前登録済みの SHA-256 ハッシュから NFT 識別子を逆引きするが、大規模コーパスからの改変画像検索は扱わない。本研究は複製フラグではなく、正確な参照 NFT レコードを最終出力とする。

画像フォレンジックの分野では、近似複製群の関係や操作履歴を来歴グラフとして組み立て直す研究が進んでいる [15]。こうした研究が変換の順序や中間関係を扱うのに対し、本研究が求めるのは、大規模なブロックチェーン索引付きコーパスから 1 件の参照 NFT レコードとその識別子を返すことである。

ここでいう「出典」は、画像群の生成順序を表す来歴グラフの根ではない。固定データセット上でクエリに対応付けられた参照レコードを指す。この範囲を明記し、視覚的に妥当なレコードの検索と、著作者・許諾・権利侵害についての法的判断を切り分ける。

検索で候補を絞った後、視覚言語モデルで再順位付けする構成は既存研究にも見られる [16]。ただし、多数の画像を同時に扱うと、妨害画像や提示位置によって性能が変わる [17]。Visual Haystacks は、無関係な画像が増えると、必要な情報を見つけにくくなることを示している [18]。CollagePrompt も、コラージュの密度が精度とコストに及ぼす影響を報告している [19]。そこで、同じ上位 100 候補を使い、提示構成だけを体系的に比較する。

候補の比較方法は、1 件ずつ採点するポイントワイズ、2 件ずつ比べるペアワイズ、複数件をまとめて扱うリストワイズに大別できる [16]。本研究のコラージュ方式では複数候補を一度に比較できるため、要求数を抑えられる。ただし、1 枚に多く詰めるほど各画像は小さくなり、少なくすればプロンプト数が増える。この相反関係を、精度、コスト、遅延の三つの側面から測る。

既存の再ランキング研究は主に意味的関連性を評価す

© 2026 Information Processing Society of Japan

る。本研究では、同じコレクションに属し、属性や構図も似た候補から正確な NFT レコードを見分けなければならない。一般的な VLM 性能がこの細粒度識別を保証するとは限らないため [20]、候補数と提示密度は実測で選ぶ。

3. 提案手法

3.1 問題設定とフレームワーク概要

$\mathcal{D} = \{x_1, \ldots, x_N\}$ を参照 NFT 画像集合とし、各画像の参照レコードを

$$y_i = (c_i, a_i, t_i) \tag{1}$$

と定義する。ここで c_i、a_i、t_i は、順にチェーン ID、正規化コントラクトアドレス、トークン ID を表す。評価用にクエリ q の複製元として対応付けた参照画像を x^*（以下、正解参照画像）とする。課題は、x^* に対応する NFT レコードを選ぶか、「該当なし」を返すことである。識別子 y_i は画像の比較には使わず、レコードを選んだ後でデータベースから取得する。

$\mathcal{D}$ 全体に高コストな視覚モデルを適用することを避けるため、処理を候補生成、ランキング、最終識別の 3 段階に分ける。評価で扱う問いは、(RQ1) Gate が正解 NFT レコードを残しながら探索空間をどこまで縮められるか、(RQ2) Rank が上位 K 件に正解をどの程度残せるか、(RQ3) 候補のまとめ方が識別性能・コスト・遅延をどう変えるか、(RQ4) パイプラインの失敗が検索と識別のどちらで起きるか、の 4 点である。

3 段階の流れを図 1 に示す。Gate と Rank で参照コーパスを決定論的に絞り、順位を付けた後、Identify が上位候補を比較する。

Gate と Rank が参照するのは、あらかじめ計算して各レコードに保存したハッシュだけである。画像本体の取得とマルチモーダルモデルへの入力は上位 K 件に限るため、高コストな画像比較の規模は参照総数 N ではなく K で決まる。ただし、前段で正解を落とすと後段では回復できない。この影響を切り分けるため、Gate の保持率、Rank の Recall@K、Identify の識別性能を段階ごとに報告する。

Identify への入力は、クエリ画像、番号を付けた候補画像、判定指示のみにする。コレクション名、コントラクト、トークン ID は選択の手掛かりとして与えない。選ばれた番号をデータベース上の y_i に対応付け、最終結果を返す。この設計によって、名称やメタデータを使った意味的な近道を避け、画像内容に基づくレコード選択として評価する。

3.2 Gate：候補フィルタリング

aHash、pHash、HSVHash、sHash は `ImageHash` [21] と Pillow で計算し、参照レコードとともに保存する。$m \in \{a, p, h\}$ ではハミング距離を d_m とする。sHash については、セグメント集合 $\mathcal{S}(x)$ 間の最近傍距離

$$d_s(q, x_i) = \min_{u \in \mathcal{S}(q), v \in \mathcal{S}(x_i)} d_{\mathrm{H}}(u, v) \tag{2}$$

を用いる [9]。Gate では Kotzer らの any-match 原則を候補生成に転用し、

$$\begin{aligned} \mathrm{pass}(q, x_i) = (d_a \le 8) \vee (d_p \le 17) \\ \vee (d_h \le 3) \vee (d_s \le 18) \end{aligned} \tag{3}$$

のいずれかを満たす参照を残す。Kotzer らの検出器に対する変更点は、pHash と sHash の閾値、および式 (2) の定義である。

Kotzer らは分離点 $D_a = 8.33$、$D_p = 16.67$、$D_h = 3.33$、$D_s = 18$ に厳密不等式 $d < D$ を適用した。距離が整数なら、a、p、h、s の上限はそれぞれ 8、16、3、17 になる。本実装では pHash と sHash の上限を 17 と 18 へ緩めた。Gate の役割は複製を最終判定することではなく、明らかに無関係な参照を除きながら正解候補をできるだけ残すことである。

3.3 Rank：候補ランキング

各距離を Gate 閾値 T_m で正規化した逆比スコアに変換し、

$$s_m(d_m) = \frac{T_m}{T_m + d_m}, \qquad S(q, x) = \sum_{m \in \{a,p,h,s\}} s_m(d_m) \tag{4}$$

この値の降順に候補を並べる。追加学習も重みの調整も行わず、上位 $K = 100$ 件を Identify へ渡す。

式 (4) の値は、距離 0 で 1、Gate 閾値上で 1/2 となる。4 種類の距離をそれぞれの閾値で尺度化することで、ビット長や許容範囲が異なるハッシュでも同じ加算スコアにまとめられる。正解 NFT レコードが上位 K 候補集合 $C_K(q)$ に残った割合は、

$$\mathrm{Recall@}K = \frac{1}{|Q|} \sum_{q \in Q} \mathbb{I}[x_q^* \in C_K(q)] \tag{5}$$

で求める。Gate の時点ですでに正解を失ったクエリも、ここでは失敗に含める。

3.4 Identify：マルチモーダル識別

上位 100 件を番号付きコラージュに分け、各コラージュから最大 1 件、または「該当なし」を選ばせる。残った候補は最終確認に回し、1 プロンプトに収まらない場合だけ、同じ手順で段階的に減らす。比較する 6 構成は 1x100、2x50、4x25、10x10、20x5、50x2 で、左がコラージュ数、右が 1 枚当たりの候補数を表す。候補の総数・順序、モデル、判定指示、最終確認を固定し、レイアウト全体を比較する。

プロンプトにはクエリ画像と番号付きの候補コラージュを与える。単に同じ系列や画風の画像ではなく、同一トークンの画像、または改変元に当たる候補を選ぶよう指示し

© 2026 Information Processing Society of Japan

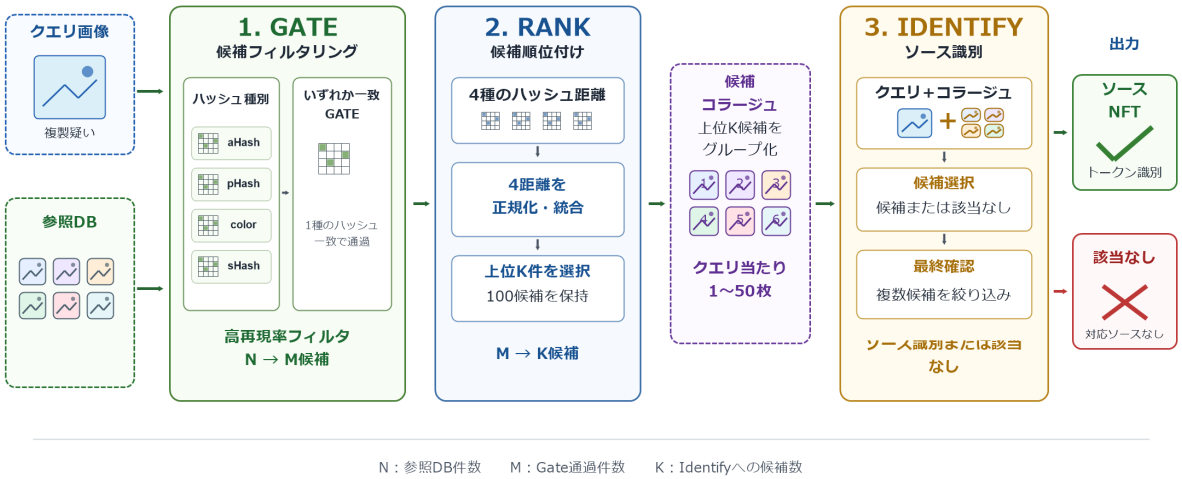


図 1 Gate–Rank–Identify フレームワーク

表 1 候補提示構成とプロンプト数

構成	コラージュ数	候補／枚	最大プロンプト数
1x100	1	100	2
2x50	2	50	3
4x25	4	25	5
10x10	10	10	11
20x5	20	5	25
50x2	50	2	99

た。クロップ、リサイズ、色変更などは許容し、該当する番号を 1 つだけ、確信できない場合は NONE を返させる。

第 1 ラウンドの選択は暫定候補であり、1 件だけ残っても自動採用せず再確認する。1x100 から 10x10 では 1 回の最終確認に収まる。20x5 と 50x2 は、候補が 1 プロンプトの上限を超えた場合に削減ラウンドを加える。小さなコラージュほど画像を大きく見せられる反面、プロンプトと削減処理は増える。

各構成で必要となる第 1 ラウンドと最悪時のプロンプト数を表 1 にまとめた。最大値は、すべてのコラージュから候補が 1 件ずつ残り、削減ラウンドを経て最終確認まで行う場合の値である。応答には、提示した番号または NONE だけを取る列挙型を指定した。これは自由文の混入を防いで厳密にパースするための出力制約であり、画像の比較方法を変える追加指示ではない。

4. データセットと実験設定

対象は、公式ウェブサイトなどの一次資料でコントラクトを確認できた 12 コレクションである。内訳を表 2 に示す。参照 NFT レコードのメタデータは主に OpenSea API から収集した [22]。画像は NFT のメタデータが示す保存先から取得し、IPFS ならゲートウェイ、HTTP(S) なら記録されたホスティングサービスを利用した。元の保存先から取得できなかった画像に限り、OpenSea CDN 上の対応画像で補った。画像と 4 種類のハッシュがすべて揃う 100,206 件を、有効な参照 NFT レコードとして評価した。

クエリは、4 件の複製・偽造コレクションから集めた 26,853 件と、残る 8 コレクションから作った 65,881 件の合成派生画像で構成した。合成時には、複製、回転・反転、リサイズ・クロップ、境界変更、重畳、ピクセル化、色変更を加えた。背景置換と局所属性編集は含めていない。有効なクエリは合計 92,270 件である。主要な評価条件を表 3 に示す。

実在する複製・偽造 NFT を収集した際、一部のレコードにはソーストークン ID など、複製元を示す手掛かりが残っていた。その情報を検証済みのコントラクト情報と照合し、評価用の正解 NFT レコードを対応付けた。合成クエリについては、変種ごとの参照元を合成評価メタデータに保存した。

Identify の評価には、12 のソースコレクション群から 100 件ずつをランダムに抽出した固定均衡標本を使う。1,200 件すべての正解レコードが参照データベース内に存在する。ただし、上位 100 候補に残ったのは 1,073 件で、残る 127 件は Gate または Rank で欠落した。この二つを分けることで、上位候補を与えた後の識別失敗と、それ以前の検索失敗を区別できる。

ここでの正解は検索性能を測るためのラベルであり、参照トークンの作成者が作品の最初の制作者であることや、複製側の許諾・権利侵害を示すものではない。また、12 コレクションは NFT 全体からランダムに選んだものではない。画像を中心とする生成型コレクションを意図的に選定したため、1 点物のアート、画像以外の NFT、動的メタデータ、ほかのネットワークへ結果を一般化するには別の検証が必要である。

Gate と Rank の評価には全 92,270 クエリを用いた。Identify は各コレクション群から 100 件ずつランダムに選

© 2026 Information Processing Society of Japan

表 2 検証済み参照コレクションの構成

コレクション	件数	コレクション	件数
Bored Ape Yacht Club	9,998	Pudgy Penguins	8,888
Azuki	10,000	Karafuru	5,555
Cool Cats	9,968	Mocaverse	8,888
CryptoDickbutts S3	5,200	CrypToadz	7,015
Murakami.Flowers	10,195	mfers	10,021
World of Women	10,000	Hypurr	4,600
		合計	100,328

表 3 データセットと評価条件

項目	値
評価可能な参照 NFT レコード	100,206
評価可能なクエリレコード	92,270
参照コレクション	12
Identify 評価標本	1,200
正解が上位 100 件内／外	1,073 ／ 127
モデル／候補上限	Gemini 3.1 Flash-Lite ／ $K = 100$
応答／確認	`text/x.enum`・完全一致、最終確認あり
画像条件	永続ウォームキャッシュ

表 4 Gate の候補フィルタリング性能

指標	結果
評価参照／クエリ	100,206 ／ 92,270
候補数の平均／中央値	14,033 ／ 13,467
候補数の四分位範囲	8,109–19,092
候補数の最小／最大	167 ／ 45,347
正解保持／欠落	91,696 ／ 574
正解保持率	99.38%
平均探索空間削減率	86.00%
平均実行時間	145 ms ／クエリ

$$\begin{aligned} \text{Sensitivity} &= \frac{TP}{TP+FN+MI}, \\ \text{CandidateAcc.} &= \frac{TP+TN}{N}, \qquad \text{E2E} = \frac{TP}{N} \end{aligned} \tag{6}$$

んだ固定 1,200 クエリで評価した。ローカル処理を実行したノート PC は、Windows 11、Intel Core 7 150U（10 コア／12 論理プロセッサ）、15.7 GiB RAM を備える。Identify では Gemini 3.1 Flash-Lite を外部 API 経由で利用し、最終確認を有効にした。

第 1 ラウンドと同じ削減ラウンド内の独立プロンプトは並列実行し、依存する後続ラウンドと最終確認は逐次実行した。第 1 ラウンドの同時要求数は 1x100 から順に 1、2、4、10、20、50 件である。遅延は個別要求時間の合計ではなく、Gate 開始から Identify 終了までのウォールクロック時間とした。キャッシュ読み出し、コラージュ作成、ネットワーク、API 処理も含む。コストは入力\$0.25 ／ 100 万トークン、出力\$1.50 ／ 100 万トークンで見積もった [23]。

Identify の結果は、クエリごとに次の 5 種類のいずれかに分類する。

- **TP**： 正解が上位 K 件内にあり、そのレコードを選択する。
- **FN**： 正解が上位 K 件内にあるが、「該当なし」を返す。
- **MI**： 正解が上位 K 件内にあるが、別レコードを選択する。
- **TN**： 正解が上位 K 件外にあり、「該当なし」を返す。
- **FP**： 正解が上位 K 件外にあるが、候補を選択する。

正解候補が提示されたときの識別能力、候補集合に対する応答全体、パイプラインが最終的に正解を返す割合を分けて見るため、

の 3 指標を報告する。MI と FN を分けるのは、誤った NFT レコードの提示と棄権では運用上のリスクが異なるためである。TN と FP の 127 件も正解がデータベースにない事例ではなく、上位 100 件から漏れた検索失敗である。

5. 結果

5.1 Gate と Rank の候補保持

Gate は 92,270 クエリ中 91,696 件で正解 NFT レコードを残し、保持率 99.38%であった。候補数は平均 14,033 件、中央値 13,467 件で、100,206 参照の探索空間を平均 86.00%縮小した。処理時間は平均 145 ms ／クエリである。ただし、平均 14,033 件では最終回答にならず、1 レコードへ絞る Rank と Identify が必要になる。

候補数の四分位範囲は 8,109–19,092 件、最小 167 件、最大 45,347 件であった。後段へ渡る入力の大きさはクエリごとに大きく異なる。候補集合サイズの分布は図 2、Gate の集計値は表 4 に示す。ここで正解を失った 574 件は後段で取り戻せないため、Gate の保持率がパイプライン全体の性能上限を決める。

主要な Recall@K は表 5 に、$K = 5{,}000$ までの変化は図 3 に示す。Rank 後の Recall@K は、$K = 1$ で 54.56%、$K = 50$ で 85.26%、$K = 100$ で 89.38%（82,468 件）、$K = 200$ で 92.82%、$K = 300$ で 94.41%（87,112 件）であった。$K = 300$ を超えると、候補を 100 件増やして得られる改善は 1 ポイント未満になる。その一方で、Identify に必要な画像とトークンは増える。そこで本実験では、検索保持率とマル

© 2026 Information Processing Society of Japan

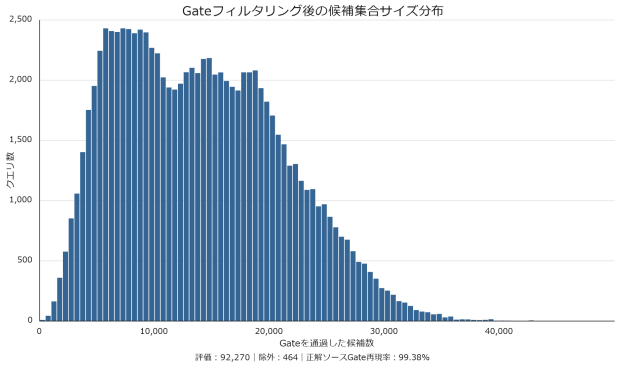


図 2　Gate 通過後の候補集合サイズ分布（92,270 クエリ）。

表 5　Rank 後の正解 NFT レコード保持

K	正解保持数	Recall@K
1	50,343	54.56%
5	63,174	68.47%
10	68,153	73.86%
25	74,463	80.70%
50	78,672	85.26%
100	82,468	89.38%
200	85,645	92.82%
300	87,112	94.41%

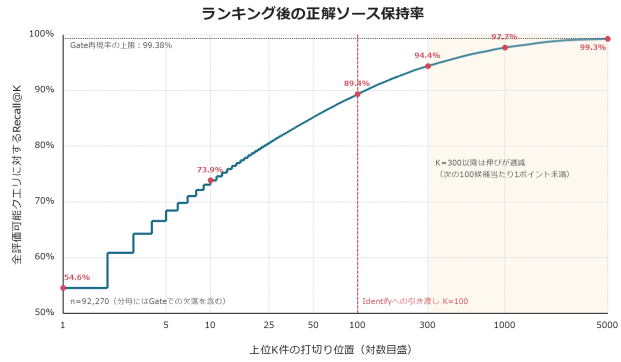


図 3　Rank 後の正解 NFT レコード保持率。Gate での欠落も失敗に含む。

チモーダル処理量の実用上の境界として $K = 100$ に固定した。

5.2　候補グループ化とトレードオフ

6 構成の結果を表 6 に示す。20x5 は候補集合正解率 93.83%とエンドツーエンド識別率 85.00%で最高となり、1x100 は処理時間とコストが最小であった。全指標で最良の構成はない。

1 枚当たりの候補を減らすと各画像は大きくなるが、第 1 ラウンドのプロンプトと残存候補は増える。平均トークン数は 1x100 の 5,383 から 50x2 の 130,815 まで増加した。1x100 から 10x10 は 1 回の最終確認に収まったが、20x5 では 178 クエリ、50x2 では 434 クエリに追加削減が必要だった。

候補集合正解率 a_j、推定 API コスト c_j、平均遅延 ℓ_j は、6 構成内の最良値が 0、最悪値が 1 になるリグレットへ min–max 正規化した。

$$r_{a,j} = \frac{a_{\max} - a_j}{a_{\max} - a_{\min}}, \quad r_{c,j} = \frac{c_j - c_{\min}}{c_{\max} - c_{\min}},$$
$$r_{\ell,j} = \frac{\ell_j - \ell_{\min}}{\ell_{\max} - \ell_{\min}}, \quad S_j = \sqrt{\frac{r_{a,j}^2 + r_{c,j}^2 + r_{\ell,j}^2}{3}}. \tag{7}$$

各リグレットと統合スコア S_j は 0 から 1 を取り、0 が 6 構成内の理想点を表す。理想点から離れるほど値が増すため、S_j は小さい方がよい。等重みでは 4x25 が 0.0878 で最小となり、候補集合正解率 92.25%、エンドツーエンド識別率 83.00%、平均 16.6 秒、$0.00322 ／クエリの均衡点に選ばれた。固定クエリによる 5,000 回の対応付きブートストラップでも、全再標本で 4x25 が選ばれた。ただし、モデル再実行や API 変動は含まず、結果は比較した 6 構成と等重み条件に依存する。

同一ラウンドの要求は並列処理するため、個々の LLM 応答時間は単純加算されない。各ラウンドは最も遅い要求を待ち、依存する削減・確認ラウンドは順番に実行する。平均遅延は 8.8–71.5 秒となったが、プロンプト数だけで決まらず、外部 API とネットワークの変動も含む。

5.3　エンドツーエンド識別

選択した 4x25 構成の内訳を表 7 に示す。結果は TP 996 件、FN 48 件、MI 29 件、TN 111 件、FP 16 件であった。正解が上位 100 件に含まれた 1,073 件に対する感度は 92.82%、全 1,200 件に対するエンドツーエンド識別率は 83.00%である。残りの 127 件は、Gate または Rank が正解を上位 100 件に残せなかったため、Identify だけでは正解を返せない。

検索失敗と識別失敗は区別する必要がある。TN・FP の 127 件は正解がデータベースにない事例ではなく、上位 100 件から漏れた事例である。正解を提示できた 1,073 件では、FN は棄権、MI は誤同定を表す。候補集合正解率 92.25%は TP と TN、エンドツーエンド識別率 83.00%は正解を返した TP だけを数えるため、両者は別の問いに答える。

表 8 では、1x100 から 20x5 へ分割するにつれ FN と MI が概ね減った。100 候補を 1 枚に詰めるより、分けて大きく見せる方が識別しやすいという解釈と整合する。ただし、50x2 では FN 94 件、MI 39 件へ再増加した。第 1 ラウンドだけで 50 要求を送り、434 クエリで追加削減も要したため、候補統合の負担が画像拡大の利点を上回った可能性がある。構成変更は画像サイズ、グリッド形状、要求数を同時に変えるため、単一要因の因果効果とは断定できない。

表 9 の 99.38%は候補集合内の保持率、83.00%は最終回答の識別率であり、直接比較できない。比較が示すのは、提案方式が多数の候補をレコード単位の回答へ変換できる点である。

© 2026 Information Processing Society of Japan

表 6 候補グループ化別の識別性能、ウォームキャッシュ遅延、推定 API コスト、トレードオフスコア

構成	感度	候補集合	E2E 識別率	秒／クエリ	USD ／クエリ	スコア ↓
1x100	67.66%	69.08%	60.50%	**8.8**	**$0.00135**	0.5774
2x50	86.77%	87.08%	77.58%	15.4	$0.00196	0.1691
4x25	92.82%	92.25%	83.00%	16.6	$0.00322	**0.0878**
10x10	94.32%	93.17%	84.33%	24.1	$0.00699	0.1758
20x5	**95.06%**	**93.83%**	**85.00%**	34.2	$0.01356	0.3244
50x2	87.60%	87.92%	78.33%	71.5	$0.03277	0.8281

表 7 4x25 構成の結果内訳（$N = 1{,}200$）

結果	件数／割合
TP：正解 NFT レコード	996 ／ 83.00%
FN：該当なし（正解あり）	48 ／ 4.00%
MI：別候補を選択	29 ／ 2.42%
TN：該当なし（上位 100 件外）	111 ／ 9.25%
FP：候補選択（上位 100 件外）	16 ／ 1.33%

表 8 構成別の識別失敗内訳（各 $N = 1{,}200$）

構成	FN（棄権）	MI（誤同定）	FP
1x100	232	115	24
2x50	105	37	13
4x25	48	29	16
10x10	43	18	21
20x5	42	11	21
50x2	94	39	12

表 9 複数ハッシュのみの手法との機能比較

方式	出力と段階に対応する結果
Gate 相当の複数ハッシュ	閾値を満たす全レコード。保持率 99.38%、平均 14,033 件（$N = 92{,}270$）
完全方式（4x25）	1 レコードまたは該当なし。E2E 識別率 83.00%（$N = 1{,}200$）

6. 考察と限界

複数ハッシュだけでも高い保持率は得られたが、平均 14,033 件から 1 件を選べなかった。提案方式では Rank が 100 件へ絞り、Identify が 1 レコードまたは「該当なし」を返す。4x25 は最高精度の 20x5 より候補集合正解率が 93.83%から 92.25%、エンドツーエンド識別率が 85.00%から 83.00%へ下がる代わりに、平均遅延を 51.6%、推定 API コストを 76.3%削減した。したがって 4x25 は普遍的な最適値ではなく、3 指標を等しく重視した本実験での均衡点である。

用途別には、1x100 は時間とコストを優先する一次確認、20x5 は追加費用を許容して識別率を重視する確認、4x25 は 3 指標を同等に扱う場合の選択肢となる。50x2 は 10x10 より全精度指標が低く、遅延とコストも大きいため、過度な細分化は有利でなかった。トレードオフ計算には、上位 100 件外の正解に対する適切な「該当なし」（TN）も正答とする候補集合正解率を用いた。正解 NFT レコードを実際に返した割合は、エンドツーエンド識別率として別に示す。関連するエンドツーエンド検索の結果として、AnyPattern は 100 万画像のギャラリーに未知の改変パターンを適用し、Recall@1 60.86%を報告している [10]。ただし、本研究の 83.00%とはデータセット、変換、ギャラリー規模、学習方法、評価の分母が異なる。数値を直接比べることはできない。この文献との対比から、本研究はハッシュによる Gate と Rank の後で、課題固有の学習を行わずに NFT レコードを最終識別する方式として位置付けられる。

実運用では、疑わしい画像に対して視覚的に妥当な参照 NFT レコードを示し、その後の人手確認につなげる調査支援として利用できる。なお、API コストは保存した入出力トークンから算出した推定値であり、税、為替、料金改定は考慮していない。

評価は、意図的に選んだ 12 コレクション、固定 Gate・Rank、$K = 100$、Gemini 3.1 Flash-Lite を用い、各候補提示構成を固定した 1,200 件のクエリで 1 回ずつ評価した結果に限られる。レイアウト変更は候補数だけでなく画像サイズとグリッド形状も変える。遅延にはキャッシュ状態、画像ホスト、ネットワーク、並列要求のスケジューリング、外部 API の変動が含まれる。正解ラベルはデータセット上の参照レコードであり、著作者、許諾、権利侵害を決めるものではない。

妥当性に関わる注意点は三つある。第 1 に、構成選択と性能報告に同じ固定標本を使っており、4x25 を独立検証集合で外部検証していない。第 2 に、各構成を 1 回しか実行していないため、外部モデルと API の確率的・時間的変動を測れない。ブートストラップが捉えるのは固定応答の標本変動であり、モデル再実行の変動ではない。第 3 に、min–max スコアは比較した 6 構成の最良・最悪値に依存するため、重みや比較対象が変われば選択も変わり得る。

今後は Gate 閾値、距離変換、重み、K の感度分析と、学習済み表現・局所特徴検索との比較が必要である。複数モデルと独立コーパスで反復評価し、識別・棄権の安定性と一般化範囲を調べる。動画、音声、3-D、動的 NFT、テキストメタデータの複製は今回の対象外である。

7. 結論

本研究では、コピーミント画像に対応する参照 NFT レ

© 2026 Information Processing Society of Japan

コードを識別するため、Gate–Rank–Identify 方式を提案した。Gate と Rank が知覚ハッシュで候補を絞って順位付けし、Identify がマルチモーダルモデルを用いて 1 レコードまたは「該当なし」を返す。この構成では、タスク固有の学習やファインチューニング、専用 VLM の構築を必要としない。保存済みハッシュと汎用マルチモーダルモデルを組み合わせるため、追加学習の費用を抑え、追試もしやすい。

Gate 相当の複数ハッシュのみのベースラインは、99.38% のクエリで正解 NFT レコードを残したが、平均 14,033 件を返した。完全方式では 20x5 が最高エンドツーエンド識別率 85.00%、等重み評価では 4x25 が 83.00%、16.6 秒、$0.00322 ／クエリの均衡点となり、候補の見せ方が精度と効率を左右することを示した。本方式は人手確認を支援するが、権利関係は判定しない。評価も 12 コレクション、$K = 100$、単一モデル、各構成 1 回の実行に限られる。今後は独立コーパスと複数モデルで一般化可能性を検証する。

参考文献

[1] Entriken, W., Shirley, D., Evans, J. and Sachs, N.: ERC-721: Non-Fungible Token Standard, Ethereum Improvement Proposals, no. 721 (2018). Published Jan. 24, 2018; accessed Jul. 25, 2026.

[2] Radomski, W., Cooke, A., Castonguay, P., Therien, J., Binet, E. and Sandford, R.: ERC-1155: Multi Token Standard, Ethereum Improvement Proposals, no. 1155 (2018). Published Jun. 17, 2018; accessed Jul. 25, 2026.

[3] Kotzer, A., Naamneh, M., Rottenstreich, O. and Reviriego, P.: Detection of NFT Duplications with Image Hash Functions, *2024 IEEE International Conference on Blockchain and Cryptocurrency (ICBC)*, (online), DOI: 10.1109/ICBC59979.2024.10634437 (2024).

[4] Prihatno, A. T., Suryanto, N., Oh, S., Le, T.-T.-H. and Kim, H.: NFT Image Plagiarism Check Using EfficientNet-Based Deep Neural Network with Triplet Semi-Hard Loss, *Applied Sciences*, Vol. 13, No. 5 (online), DOI: 10.3390/app13053072 (2023). Art. no. 3072.

[5] Venkatesan, R., Koon, S.-M., Jakubowski, M. H. and Moulin, P.: Robust Image Hashing, *Proc. 2000 IEEE Int. Conf. Image Processing (ICIP)*, Vol. 3, pp. 664–666 (online), DOI: 10.1109/ICIP.2000.899541 (2000).

[6] Pizzi, E., Roy, S. D., Ravindra, S. N., Goyal, P. and Douze, M.: A Self-Supervised Descriptor for Image Copy Detection, *Proc. IEEE/CVF Conf. Computer Vision and Pattern Recognition (CVPR)*, pp. 14532–14542 (online), DOI: 10.1109/CVPR52688.2022.01413 (2022).

[7] Jégou, H., Douze, M. and Schmid, C.: Hamming Embedding and Weak Geometric Consistency for Large Scale Image Search, *Computer Vision—ECCV 2008*, Lecture Notes in Computer Science, Vol. 5302, Springer, pp. 304–317 (online), DOI: 10.1007/978-3-540-88682-2_24 (2008).

[8] Zauner, C.: Implementation and Benchmarking of Perceptual Image Hash Functions, M.S. thesis, secure information systems, University of Applied Sciences Upper Austria, Hagenberg, Austria (2010).

[9] Steinebach, M., Liu, H. and Yannikos, Y.: Efficient Cropping-Resistant Robust Image Hashing, *2014 Ninth International Conference on Availability, Reliability and Security*, pp. 579–585 (online), DOI: 10.1109/ARES.2014.85 (2014).

[10] Wang, W., Sun, Y., Tan, Z. and Yang, Y.: AnyPattern: Towards In-Context Image Copy Detection, *International Journal of Computer Vision*, Vol. 134 (online), DOI: 10.1007/s11263-025-02633-x (2026). Art. no. 80.

[11] Prabhakaran, V., Kulshreshtha, V., Aggarwal, P. and Swamy, G.: Towards Image Copy Detection at E-Commerce Scale, *Proc. IEEE Int. Conf. Image Processing (ICIP)*, pp. 1822–1827 (online), DOI: 10.1109/ICIP55913.2025.11084564 (2025).

[12] Trinh, T. L. and Ta, M. T.: pHash-Enhanced Merkle Tree: An Advanced Approach for Detecting and Preventing Copyright Violations in NFT Marketplaces, Research Square preprint (2025).

[13] E, F., Gao, H. and Chau, M.: Copycats vs. Original NFTs Detection: A Design Science Approach, *Proc. 56th Hawaii Int. Conf. System Sciences (HICSS)*, pp. 4536–4542 (2023).

[14] Sanjaya, S. and Omote, K.: Resolver contract: Toward an NFT verification method with enhanced linkability, *2025 IEEE International Conference on Blockchain and Cryptocurrency (ICBC)*, IEEE, pp. 1–7 (2025).

[15] Moreira, D., Bharati, A., Brogan, J., Pinto, A., Parowski, M., Bowyer, K. W., Flynn, P. J., Rocha, A. and Scheirer, W. J.: Image Provenance Analysis at Scale, *IEEE Trans. Image Process.*, Vol. 27, No. 12, pp. 6109–6123 (online), DOI: 10.1109/TIP.2018.2865674 (2018).

[16] Kumar, A., Vendrow, E. and Beery, S.: Divide and Conquer: Structured Reranking for Expert-Level Ecological Image Retrieval, *Proc. IEEE/CVF Int. Conf. Comput. Vis. Workshops (ICCVW)*, pp. 5175–5184 (2025).

[17] Tian, X., Zou, S., Yang, Z. and Zhang, J.: Identifying and Mitigating Position Bias of Multi-Image Vision-Language Models, *Proc. IEEE/CVF Conf. Comput. Vis. Pattern Recognit. (CVPR)*, pp. 10599–10609 (2025).

[18] Wu, T.-H., Biamby, G., Quenum, J., Gupta, R., Gonzalez, J. E., Darrell, T. and Chan, D. M.: Visual Haystacks: A Vision-Centric Needle-in-a-Haystack Benchmark, *Proc. Int. Conf. Learn. Represent. (ICLR)*, (online), DOI: 10.48550/arXiv.2407.13766 (2025).

[19] Xu, S., Wang, Y., Liu, D., Du, B. and Xu, C.: CollagePrompt: A Benchmark for Budget-Friendly Visual Recognition with GPT-4V, *Findings Assoc. Comput. Linguistics: NAACL 2025*, pp. 6411–6433 (online), DOI: 10.18653/v1/2025.findings-naacl.358 (2025).

[20] Jiang, S., Jiao, L., Li, Y., You, P., Li, H., Yang, R., Zhu, F., Ki, S. and Lee, H.-E.: Exploring MLLM in Fine-Grained Visual Quality Comparison with Quality Token, *Proc. IEEE/CVF Int. Conf. Comput. Vis. Workshops (ICCVW)*, pp. 3506–3516 (2025).

[21] Buchner, J.: JohannesBuchner/imagehash: A Python Perceptual Image Hashing Module, GitHub repository, version 4.3.2. Available: `https://github.com/JohannesBuchner/imagehash`. Accessed: Aug. 10, 2026.

[22] OpenSea: OpenSea API Overview, Developer documentation. Available: `https://docs.opensea.io/reference/api-overview`. Accessed: Aug. 10, 2026.

[23] Google: Gemini Developer API Pricing, Google AI for Developers. Accessed: Jul. 25, 2026.

© 2026 Information Processing Society of Japan