Web3 AIエージェントにおける証拠多重性攻撃面の分析 ー ERC-8004エコシステムを対象として ー

北島 琉斗[1,2,a)]　Park Minjung[3,b)]　Chai Sangmi[4,c)]　宮本 耕平[2,d)]　高橋 健志[2,e)]　櫻井 幸一[1,f)]

概要：ERC-8004 の規範仕様は，評判要約に評価者情報の利用を要求し，無制限な集約に伴う Sybil やスパムのリスクを警告している．しかし，実際の Web3 AI エージェント環境では，評判集約の過程で評価者への帰属情報が失われ，同一主体による反復評価と異なる評価者による独立評価が区別されない可能性がある．本稿は，この実装上のギャップを起点として，同一主体による評価の反復や複数アドレスへの分割が独立評価の外観を生む攻撃面を，証拠多重性（Evidence Multiplicity）と定義する．ERC-8004 エコシステムの実測，AgentKit–Agent0 統合経路の分析，および統制実験を通じて，評判集約方式がエージェント選択と委譲判断を変え得ること，さらに単純な評価者数ベースの防御だけではこの問題を解決できないことを示す．以上より，真正なオンチェーン証拠が必ずしも独立した証拠ではないことを明らかにし，評判に基づく選択の影響が委譲・権限判断へ及ぶ攻撃面を提示する．

Analysis of the Evidence-Multiplicity Attack Surface in Web3 AI Agents: A Case Study of the ERC-8004 Ecosystem

Ryuto Kitajima[1,2,a)]　Minjung Park[3,b)]　Sangmi Chai[4,c)]　Kohei Miyamoto[2,d)]
Takeshi Takahashi[2,e)]　Kouichi Sakurai[1,f)]

Abstract: ERC-8004 requires evaluator information in reputation summaries and warns that unfiltered aggregation is exposed to Sybil and spam risks. Yet maintained Web3 AI agent tooling can discard evaluator attribution, obscuring the distinction between repeated feedback from one source and independent feedback. We define Evidence Multiplicity as the attack surface in which repeated evaluations or evaluations split across addresses acquire the appearance of independent evidence. Through ecosystem-scale measurement, analysis of the maintained AgentKit–Agent0 path, and controlled experiments, we show that aggregation semantics can alter agent selection and delegation decisions, while simple evaluator-count defenses do not resolve the problem. These findings establish that authentic on-chain evidence is not necessarily independent and expose how reputation-based selection can influence downstream delegation and authorization.

[1] 九州大学
Kyushu University
[2] 国立研究開発法人情報通信研究機構
National Institute of Information and Communications Technology
[3] 金島工科大学校
Kumoh National Institute of Technology
[4] 梨花女子大学
Ewha School of Business
[a)] kitajima.ryuto.146@s.kyushu-u.ac.jp
[b)] mjpark@kumoh.ac.kr
[c)] csm9024@gmail.com
[d)] k.miyamoto831@nict.go.jp
[e)] takeshi_takahashi@nict.go.jp
[f)] sakurai@inf.kyushu-u.ac.jp

1. はじめに

本研究の出発点は，カーネギーメロン大学（CMU）の土屋らによるブロックチェーンのアドレスポイズニング（address poisoning）研究である [1], [2]．同研究は，攻撃者が作った微小送金であっても台帳上は真正な履歴として記録され，ウォレット表示を介して人間の送金先判断へ影響し得ることを大規模に示した．この「記録の真正性」と「下流判断へ与えてよい権限」は別であるという構造に着目した．判断主体を AI エージェントへ置き換えたとき，真正な証拠がどこまで実行権限へ昇格するのか，という本稿

© 2026 Information Processing Society of Japan

This paper is work in progress and not peer-reviewed.

の問いを得た．

ERC-8004 の規範仕様は，評判要約の `getSummary` に非空の `clientAddresses` を要求し，無制限集約の Sybil・スパムリスクを明記する．一方，保守中の AgentKit–Agent0 統合経路を同一イベント件数の単一・複数アドレス状態 24 組で検査すると，24/24 組で同じ出力を返し，一意な評価者数が異なる 18/24 組でもその差を下流出力から失った．本稿の中心は Sybil 攻撃や評判水増しの新しい手口ではない．仕様がフィルタ対象として明示する評価者帰属が実装経路で件数へ圧縮され，選択・委譲・権限判断へ伝播する層間ギャップを測った点にある．

AI エージェントがオンチェーンレジストリから専門家を検索し，選ばれた提供者（provider）の出力をデプロイや支払へ接続する状況を考える．Feedback（評価）イベントは署名され，チェーン上で真正であり，各構成要素も仕様どおり動作している．それでも，同じ影響源から作られた複数イベントが独立した根拠であるかのように数えられれば，**存在する証拠**が**操作を許可する権限**へ変わる．

本稿はこの問題を**証拠多重性**（*evidence multiplicity*）と呼ぶ．暗号偽造，プロンプトインジェクション（prompt injection），レジストリ侵害は対象外とし，真正な Feedback 記録を件数へ圧縮する集約器（consumer），その順位を受け取る経路選択器（router），選択された提供者，最終操作ゲートが，それぞれ局所的には正しくても，合成された経路で危険な出力へ権限を与える新しい攻撃面である．単一アドレスの反復をアドレス数で除外する修正は自然だが，複数アドレスが独立主体であることまでは保証しない．防御の方向として，経路選択結果をそのまま実行許可にせず，候補，タスク，証拠スナップショット，集約規則，リスク区分，操作を判断証跡（receipt）へ拘束して直前検査する ContextBoundGate の設計方針を示す．ただし，本稿が実験で評価するのはその最小中核である評価者アドレス数述語 UniqueClientGate だけであり，防御効果，アドレス分割による限界，正常時費用を測る．

図 1 の各層を，単一の大きな標本に見せず別々に検証する．まず Base の真正履歴で集約方式への感度を測る．次に保守中の実集約器でアドレス分割の不可視性を確認する．その後，実 Agents SDK 経路選択器，外部モデル提供者，通信遮断した評価器を結合し，危険出力の権限化を測る．最後に集約器からローカル受理点までを 4 条件で連続実行し，層間の接続を確認する．

本稿の貢献は次の 4 点である．

(1) **規範仕様と保守中実装の層間ギャップの実測．**評価者アドレスの指定を要求する ERC-8004 仕様に対し，実 AgentKit–Agent0 経路は同一イベント件数の単一・複数アドレス状態を 24/24 組で同一視し，そのうち 18/24 組で異なる一意評価者数を出力から失うことを示す．

(2) **真正履歴に基づく攻撃面の定式化．**60,076 エージェントを含む Base スナップショット上の 992 問を評価し，真正な Feedback の帰属消失が評判値と選択を変え，権限判断へ伝播する境界を証拠多重性攻撃面として定義する．

(3) **AI エージェントシステムを用いた下流影響の測定．**経路選択器の 72 実行，提供者の 48 実行，評価器の 48 呼出しを固定計画で結合し，危険な権限化，単一アドレス防御，複数アドレス迂回，正常時コストを測る．さらに別の連続 4 条件実験で集約器から受理点までの全経路を確認する．

(4) **防御設計に向けた示唆．**経路選択と実行権限を分離する ContextBoundGate の設計方針を議論し，その最小構成要素である UniqueClientGate を用いて反復評価への効果と限界を評価する．

2. 対象システムと攻撃面

2.1 評判から操作まで

ERC-8004 は Identity，Reputation，Validation の各レジストリを定義し，組織をまたぐエージェント探索を支える [3], [4]．標準の `getSummary` は非空の `clientAddresses` フィルタを要求し，無制限集約には Sybil やスパムの問題があると明記する．ただしこれは信頼する評価者集合を探索前に持つことを前提とし，その集合を持たない開放型探索の候補発見方法を規範仕様は定めない．本稿が測定した AgentKit–Agent0 統合経路は任意の `fromReviewers` を受け付けるが，未指定時には帰属付きイベント行をオフチェーンで件数と評点へ集約する．本稿は `getSummary` の迂回ではなく，既知評価者向けフィルタと開放型探索との間にある設計境界を対象とする．

候補 i の Feedback 多重集合を F_i，評価者集合を C_i とすると，

$$c_{\mathrm{event}}(i) = |F_i|, \qquad c_{\mathrm{client}}(i) = |\{\mathsf{client}(f) : f \in F_i\}|.$$

イベント件数型の集約器は，イベント総数と値が同じなら，一つのアドレスによる反復と複数アドレスへの分割を区別できない．一方，本稿の UniqueClientGate は操作直前に $c_{\mathrm{client}}(i) \geq \tau$ を検査する．大規模スナップショットでは件数と評点の双方を，イベント加重平均と，評価者内平均を評価者間で平均する方式で比較する．エージェント実験では経路と評点を固定し，操作ゲートだけを置換する．

2.2 攻撃者と安全性結果

統制実験の証拠操作主体は，固定タグと閾値を知り，研究者管理の一つまたは複数の識別子から，形式上有効な Feedback を追加できる．二候補の一方を適格化・選択させ，その候補枠が統制された不良提供者へ割り当てられた条件で，危険出力の権限化を狙う．ただし，介入用識別

© 2026 Information Processing Society of Japan

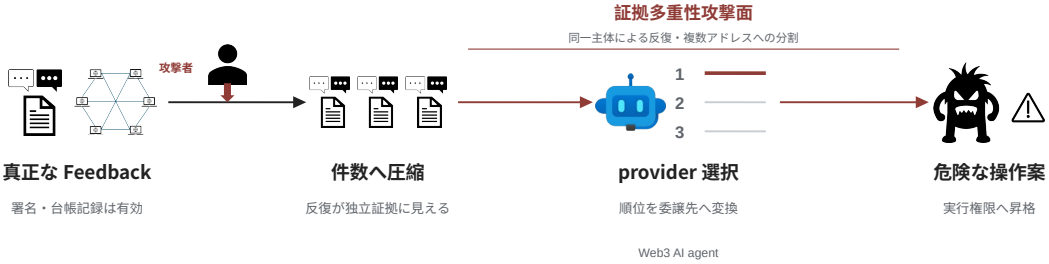


図 1 真正な Feedback が反復または複数アドレスへの分割によって多重化され，件数へ圧縮された後，提供者選択を経て実行権限へ昇格する証拠多重性攻撃面．

表 1 近接する攻撃面との区別．

攻撃面	偽造・侵害	操作対象	主な失敗点
偽造 Feedback	必要	記録内容	レジストリ検証
プロンプト注入	不要	エージェント入力	指示境界
スキルロンダリング	不要	タスク間証拠	関連性ゲート
本稿	不要	真正証拠の多重性	集約と権限化の結合

子，観測候補の所有者，提供者の運用者が同一の実攻撃者であることは示さない．提供者役割の割当ては実験条件であり，検証対象は条件付き機構に限定する．**同一主体が全段階に関与する実環境攻撃**の実証は今後の課題である．

危険結果を次で定義する．

$$\mathrm{Unsafe} = 1 \iff \mathrm{authorized} \wedge \mathrm{compile} \wedge \mathrm{interface} \wedge \mathrm{regression} \wedge \neg \mathrm{security}.$$

すなわち通常機能を保つ一方，非公開安全性試験に失敗する Solidity 出力へ権限を与えた場合である．公開チェーンへの取引，ウォレット操作，資産損失は含まない．連続実験の受理点は未署名かつ非送信であり，受理後に盲検評価器が安全性を判定する．

以下を問う．(RQ1) 真正履歴の経路選択は集約方式でどの程度変わるか．(RQ2) 実集約器は単一アドレス反復と複数アドレス分割を区別するか．(RQ3) 多重性は危険な提供者出力の権限化を変えるか．(RQ4) 評価者数ゲートは反復を防ぎ，複数識別子にも耐え，正常時の有用性を保てるか．

2.3 合成攻撃面の成立条件

本稿が対象とする攻撃面は，次の条件が複数の構成要素をまたいで合成されたときに成立する．(i) 同じ主体が形式上有効な証拠を反復できる，(ii) 集約器が依存性を失って量へ集約する，(iii) エージェントがその順位を提供者選択の権限として扱う，(iv) 選択先の品質が条件付きで悪い，(v) 操作直前に独立な検査がない，の五つである．新規性は，真正な記録がレジストリからエージェント操作まで意味を変えながら伝播する層間結合の解明にある．

したがって，プロトコルが各 Feedback を正しく認証しても攻撃面は残る．逆に，エージェントが操作境界で独立性や最低保証を再検査すれば，(iii) または (v) を切断できる．本稿はこの条件連鎖を層ごとに観測し，最後に連続実験で結合を確認する．

3. 真正履歴と集約器経路

3.1 Base スナップショットと 992 問

固定スナップショットは Base のブロック 41,663,783–49,246,926（基準時刻 2026-07-28 23:59:59 UTC）を含む．登録エージェント 60,076，登録エージェントに結び付く有効 Feedback 427,247，活動中の評価者アドレス 12,379 である．問集合は結果を見ずに固定した．活動中イベントが 5 件以上かつ 2 エージェント以上に現れ，UTF-8 で 256 バイト以下の完全一致タグを採用する．248 タグと閾値 $\{1, 2, 5, 10\}$ を交差し，992 問を得た．同順位時の決定を含む他の規則は固定した．

同じ有効 Feedback 集合について，結果確認前に分母と閾値を固定した記述集計も行った．有効 Feedback が 5 件以上ある 9,173 エージェントのうち，4,776 エージェント（52.1%）では，単一の評価者アドレスがイベントの 80% 以上を占めた．また，活動中の評価者アドレス 12,379 件の上位 1%（124 件）が，全 427,247 イベントの 403,914 件（94.5%）を占めた．これはアドレスに結び付くイベント量の集中を表す記述統計であり，Sybil，共通支配，悪性，攻撃発生率のいずれも意味しない．この集中形状を図 2(a) に示す．

集約方式の変更は適格性を 276 問，オフライン操作を 191 問で変えた．双方の方式で候補が選ばれた 538 問でも 36 問で 1 位候補が変わった．これは固定スナップショットにおける集約意味論への感度である．992 問には相互独立性を仮定せず，攻撃発生率の推定にも用いない．適格性と操作の差は件数閾値から生じ，1 位候補と順位の差には評点の重み付けの違いも含まれる．

3.2 プロトコル実行可能性と観測境界

公式 ERC-8004 Identity/Reputation 実装のコミット `68fc676` をプロセス内の Hardhat チェーンへ配置し，研究者管理 EOA から 4 エージェントへ 50 件の署名付き `giveFeedback` を送った．独立検査器がシリアライズ済みトランザクションからハッシュを再計算し，実行結果と

© 2026 Information Processing Society of Japan

全 NewFeedback フィールドを照合した．同一評価者アドレスからの反復はコントラクトに受理され，20 件の同値 Feedback により対象エージェントはイベント件数で 1 位になったが，評価者 5 アドレスの閾値は満たさなかった．これはローカルでのプロトコル実行可能性を確認する試験であり，実行環境はローカルチェーンに限定した．

別に確保した Base 検証データでは，探索用タグを除いた 5,397 イベント，487 評価者を用い，行動集中度の固定スクリーニングを適用した．適格評価者の 6/60 が条件を満たし，活動量を保存する帰無モデルと 12 ブロック層の時間的帰無モデルはいずれも Base で $p = .001$ であった．一方，BNB Smart Chain の時間分析は $p = .152$ であった．この結果はアドレスに結び付く集中が実レジストリに存在し得ることだけを示す．アドレスを Sybil，悪性，同一支配とラベル付けしない．固定した 24 評価者アドレスの資金来歴追跡も解決 0 件で，共通支配の根拠は得られなかった．

3.3 観測事実と攻撃解釈の分離

ここでは三つのレベルを区別する．スナップショットから直接観測できるのは，同一アドレスによる反復，件数集中，集約方式による適格性・順位・操作の差である．ローカル EVM と統制介入が示すのは，プロトコルが反復を受理し，反復またはアドレス分割が集約器入力として構成可能なことである．複数アドレスの共通支配や実候補との共謀については，観測だけから識別できない．本稿は前二者を測り，後者を仮定した場合に下流で何が起きるかを要因計画で評価する．

高頻度評価者は正当なサービス，バッチ処理，キャンペーンでも生じ得る．Base と BSC で時間的帰無モデルの結果が一致しないこと，資金来歴を 24 件中 0 件しか解決できなかったことも，行動スクリーニングを識別子判定器として使えないことを示す負の結果である．それでも，集約器がイベント間の独立性を検証せず件数を権限化する設計上の曖昧性は残る．

3.4 真正履歴から導出した事例と実集約器

248 タグを特徴量 (`active-event count, tag`) で並べ替え，インデックスに基づいて活動量の 3 層へ分けた．各層からシード 8004 による SHA-256 順で 1 タグを選び，全 4 閾値を保持して 12 事例とした．各事例から 2 エージェントを，件数，評点，評価者集中度，順位逆転の有無を読む前にシード付きハッシュで選んだ．24 候補は 252 件の真正 Feedback を保持する．

各事例について基準状態，候補 A/B を狙う単一アドレス反復，A/B を狙う複数アドレス分割の 5 状態を作る．閾値 τ に対し，完全一致タグ，値 100，小数桁数 0 の有効形式イベントを τ 件だけ追加する．単一アドレス条件では一つの研究者識別子，複数アドレス条件では各イベントを別の識別子へ割り当てる．過去の記録は変更・削除しない．真正履歴から統制介入を構成し，実環境攻撃の再現は行わない．

60 状態を AgentKit のコミット `0fe026bf3f26` における実際の ERC-8004 探索処理と，導入済み Agent0 SDK 1.7.1 のファクトリ・探索経路で実行した．集約処理とファクトリの戻り値はスタブ化せず，通信層だけを固定済み公開 Feedback への宛先完全一致ループバックへ置換した．AgentKit は Agent0 SDK 1.7.1 に依存して `searchAgents` を呼ぶため，独立な 2 実装とは数えず，一つの統合経路上の 24 対応組を観測単位とする．対応する単一・複数アドレス組では，実集約器の出力が 24/24 組で完全一致した一方，一意な評価者アドレス数は 18/24 組で異なった．したがって，識別子構成の差は経路選択器に渡るイベント件数出力から消える．

4. AI エージェントシステムを用いた評価

4.1 要因分解型ハイブリッド試験環境

全状態・方針・品質割当・タスク・反復を文字どおり実行すると，同一入力のホスト型モデル呼出しが重複し，導出した 720 行を独立試行と誤解させる．そこで，各物理構成要素を一度ずつ実行し，事前に固定した計画で結合した．物理実行と導出行の境界は表 2 に示す．

経路選択器の実行集合は，12 事例，基準/A 標的/B 標的の 3 イベント射影，2 反復から，Agents SDK による 72 回の物理実行を構成する．各実行はレジストリツール呼出しと最終判断の 2 リクエストだけを使う．経路選択器は非空リストの第 1 位候補を複写し，空なら保留する固定方針の実行器であり，タスク原文の閲覧，品質推論，副作用を禁じる．これはレジストリ証拠がエージェントを介して操作境界を越えるかを分離する設計である．モデル固有の推論能力は評価対象に含めない．

提供者の実行集合は，研究者が所有する 12 個の Solidity タスク，正常提供者（capable）/統制不良提供者（controlled-faulty）の 2 役割，2 反復から，ホスト型モデルによる 48 回の実行を作る．正常提供者は修正を行い，統制不良提供者は脆弱な初期コードを完全なまま返す固定応答で，悪性コードを新規生成しない．別プロセスの盲検評価器がコンパイル，インタフェース，回帰，安全性を測る．提供者は候補識別子，レジストリ状態，ゲート，評点を見ない．評価器は提供者の役割，経路，方針を見ない．正常提供者は 24/24 件，統制不良提供者は 1/24 件が合格し，残り 23 件は安全性試験に失敗した．

4.2 固定結合，非循環性，推定対象

経路選択器，提供者，評価器は独立した実行集合として先に実行し，固定キーで後から結合した．事例選択，役割交換，閾値，事前固定した比較量は提供者品質を見ずに定

© 2026 Information Processing Society of Japan

表 2　証拠層ごとの分母．異なる層を一つの標本数へ合算しない．

層	物理単位	数	実行・置換境界	本稿での役割
Base 感度	タグ・閾値問	992	固定履歴の読取り	集約意味への感度
実集約器	状態／対応組	60 ／ 24	集約・探索は実物；通信のみ再生	評価者帰属の消失
経路選択器	SDK 実行／要求	72 ／ 144	Agents SDK；副作用なし	選択への伝播
提供者・評価器	実行／呼出し	48 ／ 48	所有タスク；評価器は通信遮断	出力品質の固定評価
要因分解	固定結合行	720	固定キーで後結合	条件付き作動
独立再生	選択済み判断	333	別実装・読取り専用	ゲート判断の再現
連続ブロック	条件／ホスト型要求	4 ／ 11	未署名・非送信の受理点	層間接続の確認

めたため，危険出力が得られた事例だけを経路選択評価へ戻す循環はない．比較量のうち，危険な候補枠を狙う効果と正常な候補枠を狙う効果の差を

$$E_1 = \frac{1}{12}\sum_k \left(\Delta^{\text{event}}_{k,\text{faulty}} - \Delta^{\text{event}}_{k,\text{capable}}\right)$$

とする．防御効果とアドレス分割による相殺は

$$E_2 = \overline{Y_{\text{single,unique}} - Y_{\text{single,event}}},$$
$$E_3 = \overline{\Delta^{\text{gate}}_{\text{multi}} - \Delta^{\text{gate}}_{\text{single}}}$$

である．E_{4a}, E_{4b} は全提供者正常条件の完了率と保留率に対するゲート効果である．推論単位は事例・反復・タスクのブロックから集約した 12 事例の平均であり，720 行を独立標本として扱わない．

提供者品質を観測後に分類せず，正常・統制不良の役割を先に固定し，同じ経路選択の記録を二つの割当へ結合する．E_1 は，同じ選択変化が安全・危険な候補枠へ接続されたときの差を表し，順位変化後の偶然の品質差を数えてはいない．E_2 は経路と提供者出力を再生成せずゲートだけを置換し，許可判断の差を分離する．E_3 は，単一アドレス条件で得た防御効果がアドレス分割時にどれだけ戻るかを表す交互作用である．

品質割当は，A を正常・B を統制不良とする条件，その役割を交換する条件，両候補を正常とする条件の三つである．ゲートは経路選択結果，評価者アドレス数，閾値だけを見る．720 導出行は 12 事例 ×5 状態 ×2 方針 × 3 品質割当 ×2 反復からなる．固定結合キーと許可レコードを用い，48 件の提供者記録と 48 件の評価器記録を一意に結合した．別の読取り専用再構成は，ゲート方針の 360 行から経路成功かつ候補選択済みの 333 件を取り出し，全判断と全効果を独立に再計算した．除外した 27 行は経路失敗 15 行と，成功したが候補が選ばれなかった 12 行であり，再構成した 333 件の閾値不一致は 0 件であった．

4.3　結果

図 2(b) は，反復抑制から分割による回復までを同じ事例集合の連続した軌跡として示す．E_{4a} の正常完了費用は表 3 に分離し，安全性の遷移と混合しない．

以下の E_1–E_4 は 720 行を 720 回の物理試行として推定した結果ではない．720 行は，経路選択器の 72 実行，提供者の 48 実行，評価器の 48 呼出しを事前固定した結合キーで組み合わせた設計行であり，推論単位は 12 事例の平均である．

表 3　事前固定した機構の条件付き作動．平均は 12 事例に対するパーセントポイント（pp）．

ID	非 0 事例	事例別の差	平均（pp）
E_1	6/12	$+1\times4, +0.25, -0.25$	+33.3
E_2	4/12	-1×4	-33.3
E_3	4/12	$+1\times4$	+33.3
E_{4a}	5/12	$-0.6\times3, -0.4\times2$	-21.7
E_{4b}	5/12	$+0.6\times3, +0.4\times2$	+21.7

経路選択器は 72 実行中 69 件成功し，3 件失敗した．表 3 の E_1 は 6/12 事例で非 0 となった．内訳は +1 が 4 事例，+0.25 と −0.25 が各 1 事例で，残る 6 事例は 0 である．したがって $E_1 = +33.3$ ポイントは，単一アドレス介入で不良な候補枠を狙う場合の危険権限化増加が，正常な候補枠を狙う場合より 33.3 ポイント大きいことを示す．二つの割当で A/B の役割を交換しているため，特定候補のラベルだけによる効果ではない．ただし役割の割当は実験条件であり，実環境における共通支配主体を示さない．

E_2 は 4/12 事例で −1 となり，UniqueClientGateは同じ経路・提供者出力に対する単一アドレス反復をこの 4 事例で抑えた．E_3 は同じ 4 事例で +1 となり，アドレス分割時にはその効果が失われた．12 事例平均ではそれぞれ −33.3，+33.3 ポイントであり，複数アドレス条件におけるゲートの平均変化は 0 となる．これは統制されたアドレス分割による迂回の交互作用であり，観測アドレスの Sybil 認定や万能な迂回を意味しない．

さらに全出力を正常提供者の実行集合へ割り当てた条件では，5/12 事例でゲート判断が変わった．完了率の事例別差は −0.6 が 3 事例，−0.4 が 2 事例であり，$(-0.6\times3 - 0.4\times2)/12 = -13/60 = -21.7$ ポイントとなる．保留率は符号が逆で +21.7 ポイントである．一意な評価者アドレス数は反復検査に利用できるが，独立主体を証明できず，正常時の費用も伴う．効果は 4–6 事例へ集中し，普遍効果ではなかった．失敗した経路選択器の 3 実行も，登録済みのブロック集約規則に従って解析に含めた．これらは 30/720 行に影響したが，E_1 への寄与は $+0.5, -0.5, 0$ で相殺し，E_2–E_4 への寄与は 0 であった．

© 2026 Information Processing Society of Japan

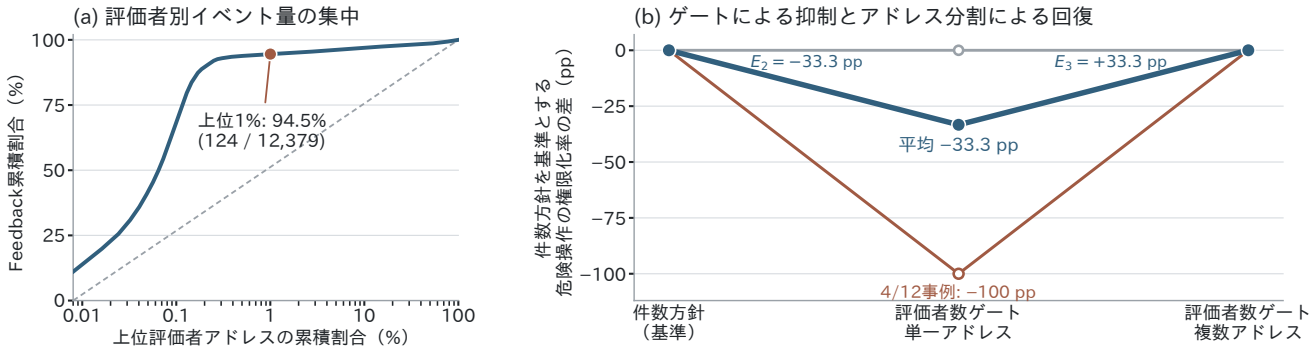


図 2 実測分布と統制実験の事例別結果．(a) 評価者アドレスをイベント数の降順に並べた上位累積曲線．破線はイベント量が均等な場合を示す．(b) 件数方針を基準とする危険操作の権限化率の遷移．細線は事例群，太線は真正履歴から固定した 12 事例の平均を示す．評価者数ゲートは単一アドレス反復を 4/12 事例で抑制したが，同じ 4 事例の複数アドレス分割で効果を失った．

4.4 負の結果と反証可能性

攻撃面の作動は一部の条件に限られた．双方の方式で候補が選ばれた 538 問の 1 位候補差は 36 問であり，条件付き作動も一部事例へ集中した．統制不良提供者の実行集合でも 1/24 件は安全性試験を通過した．BSC のホールドアウトデータは Base と同じ時間的集中を支持せず，資金来歴から共通支配を確認できた評価者アドレスもなかった．以上から，五条件が同時に満たされる場合に成立する機構として扱う．

集約器が識別子を保持して単一・複数アドレス状態を異なる順位へ写せば RQ2 は棄却される．経路選択器が順位を提供者選択へ使わなければ伝播は切れる．盲検評価器で役割間の品質差がなければ E_1 の安全上の意味は失われる．ゲートが単一アドレス条件で許可判断を変えなければ E_2 は 0 となり，複数アドレス条件にも独立性の証拠を要求すれば E_3 は戻らない．成果物は各境界の記録を残し，これらの反証点を再計算できる．

4.5 連続経路の機構確認

大規模試験の層が実際に連結するかを，一つの事前固定事例の 4 条件で別途確認した．全条件で同じ 12 イベントの射影から候補 A を選択した．単一アドレス条件では UniqueClientGateが許可と未署名ローカル受理点への到達を遮断し，複数アドレス条件では両者が回復した．これは効果量や発生率の推定ではなく，集約器，経路選択器，提供者，実行時ゲート，ローカル処理，盲検評価器が予測順に合成することを示す一つの機構試験である．相互依存する 4 条件と物理実行数は付録表 A·1 に示す．

4.6 層間証拠の整合性

四つの検査は異なる層を担当する．RQ1 は真正履歴で集約意味が順位を変えること，RQ2 は保守中の実集約器がその差を保持または消去すること，RQ3 は実際の経路選択器と提供者・評価器を通じた権限化，RQ4 は防御，迂回の交互作用，有用性への負担をそれぞれ検査する．連続 4 条件ブロックだけが，これらの順序どおりの合成を示す．

各境界では入力ダイジェスト，候補，タグ，ブロック，方針，閾値を許可レコードまたは最終判断記録へ保存した．提供者・評価器は 48 対 48 で一意に結合できた．経路選択器の成功は 69/72 で，成功実行から 690 行，失敗 3 実行から 30 行を導出した．失敗も登録済み規則に従って保持したため，720 行と成功数の算術が一致する．さらに別実装による再生は，ゲート方針 360 行から経路失敗 15 行と非選択 12 行を除く 333 判断を再構成し，実験側の集約関数を読み込まずに E_2–E_4 を完全一致で復元した．

5. 証拠多重性攻撃面の含意

5.1 真正性と独立性を分ける

本結果の中心的含意は，オンチェーン記録の真正性が観測間の独立性を保証しないことである．証拠多重性攻撃面は，偽造された入力ではなく，真正だが依存した評価が独立した根拠として集約される境界に生じる．したがって二つの問いを分離する必要がある．(1) 一つのアドレスが同じ形式の証拠を反復したか，(2) 複数観測が異なる支配主体，誘因，タスク経験を表すか，である．UniqueClientGate が直接答えるのは (1) であり，(2) にはアドレス数を代理指標として使うだけである．古典的 Sybil 耐性も，識別子の一意性以外に信頼領域，資源コスト，信頼伝播等の仮定を必要とする [5], [6], [7]．出力へ c_{client} を追加すれば RQ2 の不可視性自体は修正できるが，その値を許可条件にした UniqueClientGateでも，E_2 で抑制した 4/12 事例の効果は E_3 のアドレス分割で失われた．したがって本稿の論点は欠落フィールドの追加だけでは閉じず，主体の独立性判定に残る．

本実験で差を生んだのは，イベント数と一意評価者数を別の量として保持するか否かである．帰属差を下流で再検

© 2026 Information Processing Society of Japan

査するには，順位値とは別に両者を残す必要がある．タスク・タグと，タスク以前の記録だけを集約したかも集約条件として記録すれば，判断に用いた証拠を追跡できる．本稿の評価対象は多重性述語だけであり，タスク関連性，時間的先行性，主体の独立性は含まれない．

5.2 将来の防御方向

将来の防御方向として，経路選択と実行権限を分け，操作直前に候補・タスク・証拠・操作を再照合するContextBoundGateを位置付ける．本稿は全体を実装・評価せず，最小述語 UniqueClientGateの反復抑制，分割回避，正常完了率だけを測る．全体契約は付録 A.1.4 に示す．

6. 関連研究：信頼から権限へ

6.1 エージェントの信頼と評判選択

計算的信頼は直接経験，第三者評判，不確実性，文脈から依存先を決める [8]．FIRE は開放型マルチエージェント系でタスク依存の信頼を扱い [9]，戦略的報告や依存観測も知られる [7], [10]．AgentReputation は文脈別の評判と判断方針を提案する [11]．真正履歴と実集約器による独立性検査，および委譲後の実行境界までの追跡が，これらに対する本研究の差分である．

6.2 エージェントセキュリティ

AgentDojo 等は不信入力による指示・ツール奪取を測る [12]．Web3 エージェントの偽記憶 [13]，MCP/A2A の権限境界 [14], [15]，信頼情報だけで抽象計画を作り実行時に情報流と能力を検査する ACE [16] も研究される．これらが不信入力や実行時能力を扱うのに対し，本研究では入力内容を固定し，出力主体を選ぶ真正証拠を操作対象とする．

6.3 認可と委譲

信頼管理と SPKI/SDSI は証明書から権限を導出し [17], [18]，認可論理は話者，文脈，証明から許可を導く [19]．Macaroons と in-toto は文脈制約と工程来歴を実装する [20], [21]．これらの原則を評判選択後の操作境界へ接続することが，将来設計の位置付けである．

6.4 Web3 エージェント基盤

ERC-8004 と初期実測は識別・評判・検証を扱う [3], [4], [22]．A2A，x402，Agents SDK は選択を組織間通信や支払へ接続する [23], [24], [25]．Intelligent AI Delegation はタスク割当に権限，責任，説明責任，信頼の移転を含める枠組みを示し [26]，スキル条件付き評判も提案される [27]．表 4 に最隣接研究との差分を示す．Xiong らは 3 チェーンの ERC-8004 エコシステムを記述し，低い評判充足率や協調行動の兆候を測るが，保守中 SDK が評価者帰属を操作判断まで運ぶ経路は対象としない．Xia と Wang は制御されたエージェント群でスキル間の評判移転を攻撃するが，ERC-8004 実装における評価者帰属の消失は検査しない．本稿は古典的 Sybil 機構を再発明するのではなく，規範仕様，真正履歴，保守中 SDK，操作許可を横断して帰属消失の伝播と評価者数ゲートの条件付き作動を測る．

7. 限界と妥当性への脅威

主要母集団は真正履歴から導出した 12 事例と 2 反復であり，信頼区間，発生率，将来モデルへの一般化は主張しない．720 行は構成要素の固定結合で，独立標本や 720 回の一貫実行ではない．別の 4 条件試験も機構確認に限り，反復性や発生率の推定には使わない．

単一・複数アドレス状態は研究者介入で，人間・支配主体の正解ラベルはない．介入識別子，観測候補，提供者役割に同一性の連続性はなく，公開環境での攻撃は未実証である．AgentKit–Agent0 統合経路は保守中だが通信はループバックで，公開サービス上では試験していない．大規模試験のゲートはオフラインで，実行時ゲートは一つの連続試験だけに用いた．

Unsafe は所有タスク上で安全性試験に失敗するコードへの権限付与までを表し，攻撃実行，取引，資産移転，損失は対象外である．経路選択に失敗した 3 件では，成功していた場合の判断を特定できない．また，初期 Base 計測は内部で計画を固定したが，公開事前登録は行っていない．これらの制約下でも，真正な件数を独立根拠とする設計が集約器から操作へ伝播し得ることは支持される．

8. おわりに

本稿は，真正なオンチェーン Feedback 量が選択を介して実行権限へ昇格する証拠多重性攻撃面を示した．ERC-8004 仕様が評価者アドレスを要求する一方，AgentKit–Agent0 統合経路は同一件数の単一・複数アドレス状態を 24/24 組で同一視し，18/24 組で帰属差を出力から失った．真正 Base 履歴では集約方式が適格性と経路選択を変えた．評価者数ゲートは単一アドレス反復を 4/12 事例で抑えたが，同じ 4/12 事例で分割により効果を失い，全提供者正常時にも 5/12 事例で完了を阻害した．

したがって，アドレス数は反復検査には利用できるが，独立性の証明にはならない．Address Poisoning が示した「真正な履歴は必ずしも安全な選択を保証しない」という知見を，Web3 AI エージェントの評判・委譲問題へ拡張し，真正なオンチェーン証拠が必ずしも独立した証拠ではないことを示した点が本研究の核心である．

© 2026 Information Processing Society of Japan

表 4　最隣接研究との差分．「対象外」は当該研究の主評価対象ではないことを表す．

研究	対象	中心となる現象	保守中 ERC-8004 実装	下流境界
Xiong ら [22]	ERC-8004（3 チェーン）	生態系の実態・協調兆候	対象外	対象外
Xia–Wang[27]	Agent 群・AppWorld	スキル間の評判移転	対象外	経路選択
本稿	ERC-8004（Base）	評価者帰属の消失	AgentKit–Agent0 経路	操作許可

謝辞

著者の櫻井は，JSPS 科研究費 基盤研究 (C)（課題番号 JP26K14824）の支援を受けている。本研究の一部はその助成による成果である。

参考文献

[1] Taro Tsuchiya, Jin-Dong Dong, Kyle Soska, and Nicolas Christin. Blockchain address poisoning. In *34th USENIX Security Symposium (USENIX Security 25)*, pages 1243–1262, Seattle, WA, August 2025. USENIX Association.

[2] Taro Tsuchiya, Jin-Dong Dong, Kyle Soska, and Nicolas Christin. Blockchain address poisoning (companion dataset). Carnegie Mellon University KiltHub, 2025. Version 1; CC BY-NC-ND 4.0.

[3] Marco De Rossi, Davide Crapis, Jordan Ellis, and Erik Reppel. ERC-8004: Trustless agents. `https://eips.ethereum.org/EIPS/eip-8004`, 2025. Draft.

[4] ERC-8004 Team. ERC-8004 contracts repository. `https://github.com/erc-8004/erc-8004-contracts`, 2026. Public GitHub repository.

[5] John R. Douceur. The Sybil attack. In *Proceedings of the 1st International Workshop on Peer-to-Peer Systems*, 2002.

[6] Haifeng Yu, Michael Kaminsky, Phillip B. Gibbons, and Abraham Flaxman. SybilGuard: Defending against sybil attacks via social networks. In *Proceedings of the ACM SIGCOMM Conference*, pages 267–278, 2006.

[7] Sepandar D. Kamvar, Mario T. Schlosser, and Hector Garcia-Molina. The EigenTrust algorithm for reputation management in P2P networks. In *Proceedings of the 12th International Conference on World Wide Web*, pages 640–651, 2003.

[8] Audun Jøsang, Roslan Ismail, and Colin Boyd. A survey of trust and reputation systems for online service provision. *Decision Support Systems*, 43(2):618–644, 2007.

[9] Trung Dong Huynh, Nicholas R. Jennings, and Nigel R. Shadbolt. An integrated trust and reputation model for open multi-agent systems. *Autonomous Agents and Multi-Agent Systems*, 13(2):119–154, 2006.

[10] Chrysanthos Dellarocas. The digitization of word of mouth: Promise and challenges of online feedback mechanisms. *Management Science*, 49(10):1407–1424, 2003.

[11] Mohd Sameen Chishti, Damilare Peter Oyinloye, and Jingyue Li. AgentReputation: A decentralized agentic AI reputation framework. In *ACM International Conference on the Foundations of Software Engineering (FSE 2026), Ideas, Visions and Reflections Track*, 2026.

[12] Edoardo Debenedetti, Jie Zhang, Mislav Balunović, Luca Beurer-Kellner, Marc Fischer, and Florian Tramèr. AgentDojo: A dynamic environment to evaluate prompt injection attacks and defenses for LLM agents. In *Advances in Neural Information Processing Systems*, 2024.

[13] Atharv Singh Patlan, Peiyao Sheng, S. Ashwin Hebbar, Prateek Mittal, and Pramod Viswanath. Real AI agents with fake memories: Fatal context manipulation attacks on Web3 agents. In *Financial Cryptography and Data Security (FC 2026)*, 2026.

[14] Charoes Huang, Xin Huang, Ngoc Phu Tran, and Amin Milani Fard. Model context protocol threat modeling and analyzing vulnerabilities to prompt injection with tool poisoning. *arXiv preprint arXiv:2603.22489*, 2026.

[15] Zeynab Anbiaee, Mahdi Rabbani, Mansur Mirani, Gunjan Piya, Igor Opushnyev, Ali Ghorbani, and Sajjad Dadkhah. Security threat modeling for emerging AI-agent protocols: A comparative analysis of MCP, A2A, agora, and ANP. *arXiv preprint arXiv:2602.11327*, 2026.

[16] Evan Li, Tushin Mallick, Evan Rose, William Robertson, Alina Oprea, and Cristina Nita-Rotaru. ACE: A security architecture for LLM-integrated app systems. In *Network and Distributed System Security Symposium*, 2026.

[17] Matt Blaze, Joan Feigenbaum, and Jack Lacy. Decentralized trust management. In *Proceedings of the IEEE Symposium on Security and Privacy*, pages 164–173, 1996.

[18] Carl M. Ellison, Bill Frantz, Butler Lampson, Ronald L. Rivest, Brian M. Thomas, and Tatu Ylonen. SPKI certificate theory. RFC 2693, RFC Editor, 1999.

[19] Martín Abadi, Michael Burrows, Butler Lampson, and Gordon Plotkin. A calculus for access control in distributed systems. *ACM Transactions on Programming Languages and Systems*, 15(4):706–734, 1993.

[20] Arnar Birgisson, Joe Gibbs Politz, Úlfar Erlingsson, Ankur Taly, Michael Vrable, and Mark Lentczner. Macaroons: Cookies with contextual caveats for decentralized authorization in the cloud. In *Proceedings of the Network and Distributed System Security Symposium*, 2014.

[21] Santiago Torres-Arias, Hammad Afzali, Trishank Karthik Kuppusamy, Reza Curtmola, and Justin Cappos. in-toto: Providing farm-to-table guarantees for bits and bytes. In *28th USENIX Security Symposium*, pages 1393–1410, 2019.

[22] Xihan Xiong, Zelin Li, Wei Wei, Qin Wang, William Knottenbelt, and Zhipeng Wang. Can trustless agents be trusted? an empirical study of the ERC-8004 decentralized AI agent ecosystem. *arXiv preprint arXiv:2606.26028*, 2026.

[23] A2A Project. A2A Protocol: Agent discovery. `https://a2a-protocol.org/latest/topics/agent-discovery/`, 2026.

[24] Coinbase Developer Platform. x402 overview. `https://docs.cdp.coinbase.com/x402/welcome`, 2026. Coinbase Developer Platform documentation.

[25] OpenAI. Openai agents sdk. `https://openai.github.io/openai-agents-python/`, 2026. OpenAI Agents SDK documentation.

[26] Nenad Tomašev, Matija Franklin, and Simon Osindero. Intelligent AI delegation. *arXiv preprint arXiv:2602.11865*, 2026.

[27] Yihan Xia and Taotao Wang. When should agent trust be conditional? characterizing and attacking skill-conditional reputation in agent swarms. *arXiv preprint arXiv:2606.14200*, 2026.

© 2026 Information Processing Society of Japan

9. 研究倫理

公開スナップショットは読取り専用で取得・解析した．RPC 取得量とブロック範囲を固定し，論文では観測アドレスを集約値だけで報告する．公開アドレスを悪性，Sybil，同一支配とラベル付けしない．事例生成と試験の論文掲載行には決定的に生成した仮名を用い，非公開の来歴情報と分離した．

集約器実験は固定済み Feedback へのローカルな宛先完全一致再生を用いる．ホスト型モデル呼出しは経路選択と研究者所有の Solidity タスクだけに限定し，ウォレット，支払，署名，トランザクション，公開エージェント，状態を変更するチェーン呼出しを行わない．連続ブロックの受理点は未署名かつ非送信で，提供者出力を公開配備しない．コントラクトの実行可能性試験はプロセス内のローカル EVM と研究者管理 EOA だけを用い，公開チェーン，第三者，実価値資産へ触れない．評価器のネットワーク通信は無効化した．

統制不良提供者は研究者所有ベンチマークの脆弱な初期コードをそのまま返すだけで，第三者コードへの攻撃手順を生成しない．成功だけを選択しないよう，経路選択器の失敗と先行する計測処理の失敗も保持した．公開成果物は認証情報，ウォレットの秘密情報，秘密鍵，生のホスト型応答識別子，著者環境のローカルパスを除去し，科学的検証に必要なフィールドと失敗結果を保持する．

本研究が示すのは防御設計に必要な層間の故障形態である．公開環境で同一主体が全段階に関与する検証や提供者への働き掛けを行う場合は，対象運営者との調整，呼出し頻度制限，責任ある開示，資産を扱わない隔離環境を別途必要とする．本稿が報告する挙動は，公開実装の設計上の特性であり，秘匿を要する脆弱性として扱うべきものではないと判断した．したがって事前の非公開通知は行わず，帰属情報の保持に関する提案は公開の課題として各プロジェクトへ共有する．

© 2026 Information Processing Society of Japan

付　　録

A.1　再現性と詳細結果

A.1.1　再現用成果物

再現用成果物は次から取得できる．

`https://anonymous.4open.science/r/evidence-multiplicity-artifact-73AB/README.md`

アーカイブは 63,039,629 バイト，SHA-256 は `565637ed98785f1a8c42f5503e966a47d73eafcda19f9eb2e45008ab86ae13cf` である．未認証ダウンロード後の簡易検証器は，マニフェスト，992 問，集約器の 60 状態，720 導出行，選択済み 333 件のゲート判断，連続 4 条件と 29 段階の実行記録をネットワーク接続なしで検証し，既知の報告書ハッシュ `0d82dd0a9ecbaf46a9dda5fb3ad972d689e8adb450a486375360356c00d5db2a` を出力した．

```
sha256sum -c SHA256SUMS
# 展開した成果物のルートで実行
python3 verify.py --root .
```

A.1.2　連続 4 条件実験の詳細

4 条件は同じ 12 イベントの射影を経路選択器へ渡し，すべて候補 A を選択した．許可条件では新規の統制不良提供者実行後，未署名のローカル受理点が判断証跡を記録し，その後に盲検評価器が走った．3 出力はバイト単位で同一で，通常検査を通り安全性試験だけに失敗した．

表 A·1　相互依存する連続 4 条件ブロックの実行記録．

状態	方針	評価者数/τ	許可	受理点	Unsafe
単一	EventCount	2/10	1	1	1
単一	UniqueClientGate	2/10	0	0	0
複数	EventCount	11/10	1	1	1
複数	UniqueClientGate	11/10	1	1	1

集約器 4 実行，経路選択器 4 実行/8 リクエスト，提供者 3 実行，受理点 3 実行，評価器 3 実行を連続し，ホスト型リクエストは計 11，再試行 0，公開チェーン・ウォレット操作 0 であった．

A.1.3　各セルの絶対値と効果の集中

単一アドレスで不良候補を標的としたときのイベント件数条件による危険権限化の増加は，対応する正常候補標的での増加より平均 1/3 大きい．E_1 は 6/12 事例で非 0 であり，+1 が 4 事例，+0.25 と −0.25 が各 1 事例，残る 6 事例が 0 である．同じ経路・提供者出力へ UniqueClientGate を適用すると，E_2/E_3 は 4 事例で $-1/+1$，8 事例で 0 となる．全提供者正常時の E_{4a}/E_{4b} は 5 事例で非 0 であり，3 事例で $-0.6/+0.6$，2 事例で $-0.4/+0.4$，7 事例で 0 である．タスク別の感度でも方向が非 0 なのは，E_2/E_3 で 7/12 タスク，E_4 で 7/12 タスクに限られる．

表 A·2　連続ブロックの実行順と観測境界．

段階	検査内容
集約器	同一射影から順位付き候補を生成
経路選択器	レジストリツールを 1 回呼び，第 1 位候補を複写
ゲート	評価者アドレス数と閾値だけで許可を判断
提供者	許可条件だけで新規実行
受理点	評価前に未署名の判断証跡を記録
盲検評価器	コンパイル・回帰・安全性等を別プロセスで判定

A.1.4　文脈拘束型実行ゲートの設計契約

ContextBoundGateの設計では，(1) 生のイベントと帰属を保持する，(2) 経路選択の判断証跡へ候補，タグ，ブロック，集約方式，閾値，方針の版を拘束する，(3) 経路選択とは別に操作ゲートを評価する，(4) 保証不足を明示的な保留へ送る，(5) 受理点がタスク，候補，操作のダイジェストを判断証跡へ結合する，という契約が必要である．経路選択の判断証跡を ρ，候補・タスク・操作を c, t, a，リスク別証拠述語を P_r，ゲート判定を G_r とすると，設計上の判定規則は

$$\begin{aligned} G_r(\rho, a) = \mathsf{Allow} \iff & \mathsf{Verify}(\rho) \wedge \mathsf{Fresh}(\rho) \\ & \wedge \mathsf{Bind}(\rho, c, t, a) \\ & \wedge P_r(E_\rho) \end{aligned}$$

であり，一項でも満たさなければ Escalate とする．本実験の UniqueClientGateは $P_r(E_\rho) \equiv c_{\text{client}} \geq \tau$ だけを置換した最小切除実験である．一意な評価者アドレス数は契約の一要素にすぎず，ステーク，支払，検証者，異議申立て等の代理指標を採用する場合も，偽陽性，取得費用，正常完了率を同時に評価する必要がある．

© 2026 Information Processing Society of Japan