生体信号を用いた認証に対する映像由来の感情変化の影響と頑健化の評価

日夏 俊[1,a)]　中井 綱人[1]　梨本 翔永[1]　大西 健斗[1]　東 拓矢[1]

概要：生体信号を日常的に計測するデバイスの普及とともに，同信号を用いた認証システムの研究開発が進んでいる．しかし，同信号はユーザの感情等の様々な要因に影響を受け，ユーザの状態次第で認証精度が低下し得ることが課題であり，さらに感情は映像等の外部刺激により変化し得る．本研究では，生体信号を用いた認証システムの頑健化を目標として，ユーザの感情と同信号の関係に着目し，映像由来の刺激により感情を変化させた際の認証精度および対策を検討・評価した．実験において，映像提示により実験参加者の感情を変化させることを想定して計測された生体信号データセットを使用して，様々な感情における計測データを組み合わせて認証モデルの訓練およびテストを行い，認証精度の変化やその条件を調査した．実験の結果，訓練時とテスト時で異なる感情における計測データを用いた場合に認証精度が低下し，特に覚醒度の差分が大きい場合に同精度が低下する傾向が確認できた．また，認証精度低下への対策として，複数の感情状態のデータを統合して訓練に用いることで，同精度低下を緩和できる可能性を示した．

キーワード：外部刺激，光電容積脈波，生体信号，生体認証，心電図

Evaluation of Visually Induced Emotional Changes and Countermeasures for Physiological Signal-based Authentication

Shun Hinatsu[1,a)]　Tsunato Nakai[1]　Shoei Nashimoto[1]　Kento Oonishi[1]　Takuya Higashi[1]

Abstract: As devices that monitor physiological signals become widespread, authentication systems using such signals have been studied. However, physiological signals are affected by various factors, including emotional states altered by external stimuli such as videos, which may degrade authentication performance. This study evaluates authentication performance and countermeasures under video-induced emotional changes to improve the robustness of physiological signal-based authentication systems. In our experiments, we used physiological signal datasets collected while participants watched videos designed to elicit several emotions. We trained and evaluated authentication models using data from various emotional states to investigate the impact of emotional changes on authentication performance. As a result, the authentication performance degraded when training and testing involved different emotional states, especially as arousal difference increased. We also showed that training with data from multiple emotional states may mitigate this degradation.

Keywords: Biometrics, electrocardiogram, external stimuli, photoplethysmogram, physiological signal

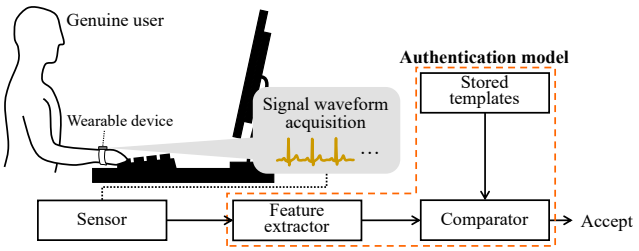
1. はじめに

身体から計測される生体信号は，ウェアラブルデバイスの普及に伴い，健康管理に加えて生体認証への応用も進んでいる．特に，スマートウォッチに搭載した電極で計測する心電図（ECG: Electrocardiogram）信号や，光学センサで計測する光電容積脈波（PPG: Photoplethysmogram）信号が代表的であり，図 1 **(a)** に示すように，特徴量抽出や比較を行う認証モデルを含む構成により，認証への利用が可能となる [1], [2]．同信号は継続的に計測可能であり，ユーザに明示的な操作を要求しない継続認証や，健康管理と認証を統合したシステムへの応用が期待されている [1].

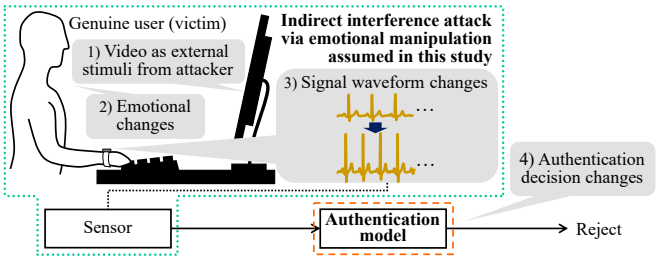
[1] 三菱電機株式会社 Mitsubishi Electric Corporation
[a)] Hinatsu.Shun@bc.MitsubishiElectric.co.jp

© 2026 Information Processing Society of Japan

This paper is work in progress and not peer-reviewed.



(a) Biometric authentication using physiological signals.



(b) Overview of threat scenario in this study.

図 1: 生体認証モデルと本研究で想定する攻撃の関係

Fig. 1 Relationship between a biometric authentication model and an attack assumed in this study.

一方で，ECG 信号や PPG 信号は，計測環境，センサ装着状態，身体活動，心理状態等の様々な要因により変化する [1], [2]．そのため，生体信号を用いた認証システムでは，登録時と認証時で信号波形に生じた変化により，認証精度が低下する可能性がある．ユーザの感情状態もこのような変化の要因の一つであり，さらに感情状態は映像や音声等の外部刺激により変化し得るため [3], [4]，ユーザに対して外部刺激を与えることで生体信号を間接的に変化させ，認証の結果に影響が生じる可能性がある．本研究では，以上の点に着目した攻撃シナリオとして，正規ユーザ (被害者) がユーザ ID とパスワードといった従来の認証情報の代わりに，ECG 信号または PPG 信号を用いて認証を行い，機微な情報やアプリケーションにアクセスする状況を想定する．攻撃者は，この生体認証自体の妨害，または従来の認証情報を要求する悪意ある Web ページへの誘導によるフィッシングを試みる可能性がある．本シナリオは，以下および図 1 **(b)** に示す 4 手順で進行する．

1) 攻撃者が，Web ブラウザ等を介して，自身の制御下にある外部映像刺激をユーザに提示する．
2) ユーザの感情状態が変化する．
3) その感情変化に伴い，ウェアラブルセンサで計測される生体信号が変化する．
4) 認証モデルの判定結果が変化する，例えば正規ユーザが拒否される．

したがって，このような攻撃が起こり得ることを想定した，頑健な認証を行うシステムの開発が必要である．我々は先行研究 [5] において，映像による感情変化が生体信号を用いた認証精度に与える影響について，公開データセットを用いた基礎検討を行った．その結果，訓練時とテスト時で異なる感情状態のデータを用いた場合に認証精度が低下し得ることを確認した．しかし，認証精度と感情変化の関係について定量的な分析は未実施であり，認証精度低下を緩和する対策についても未検証であった．

本研究では，生体信号を用いた頑健な認証システムの構築を目標として，感情変化の影響の定量化に焦点を当て，以下の Research questions (RQs) を設定する．

RQ1: 感情変化時の生体信号に起因する認証精度の大きな変化は，具体的にどのような条件下で生じるか？

RQ2: **RQ1** への対策として，認証精度の低下を緩和するには，どのような方法が有効か？

RQ1 への対応として，本研究では，既存研究に基づく認証モデルと公開データセット [6], [7] を用いて実験を行った．同データセットは，代表的な感情モデルである Russell の感情円環モデル [8] に基づいて分類される感情を考慮し，特定の感情の想起を意図した映像を視聴する参加者から計測された生体信号を含む．本実験では，各映像の視聴中の計測データを用いて認証モデルを構築し，精度低下を引き起こす訓練・テストデータの組合せを定量的に調査した．次に，**RQ2** への対応として，精度低下への対策として，Russell の感情円環モデルを基準とした感情の分布を考慮し，複数の感情状態データの統合による緩和策を評価した．

本論文の主な貢献は以下の通りである．

- Russell の感情円環モデルに基づいて分類された複数の感情を考慮し，感情間で認証精度が変化する条件を体系的および定量的に分析した（**RQ1** に対応）．
- 認証精度低下への対策として，複数の感情状態から得られたデータ統合による緩和策を提案し，認証モデルとの組合せによる有効性を示した（**RQ2** に対応）．

2. 既存研究および本研究の方針

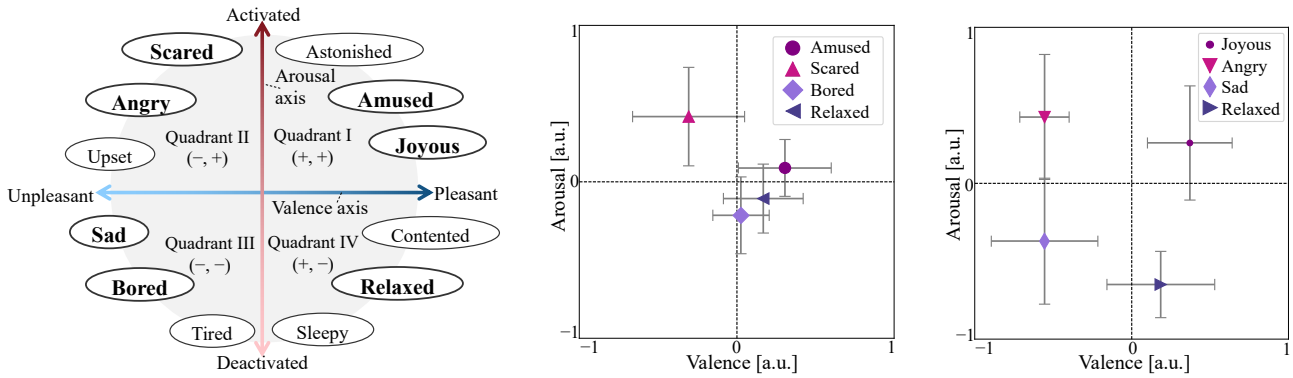
本節では，生体信号に起こり得る変化に関する研究を挙げ，変化の要因に含まれる感情の分類，さらに我々の先行研究も説明したうえで，本研究のアプローチを説明する．

2.1 生体信号に変化を与える要因

生体信号は様々な要因で変化することが知られており，同要因に着目し信号を意図的に変化させる研究も存在する．同要因は，直接的なものと間接的なものに分類できる．

多くの研究では，センサまたは計測部位に直接的に影響を与えることで，信号波形を変化させている．例えば，電極に電流を印加して ECG 信号を人工的に生成し，ECG 信号を用いた認証システムを突破できることが実証されている [10]．また，光学センサに光源を接触させて生成した人工的な PPG 信号による認証突破や [11]，上腕への物理的圧迫による PPG 信号の意図的な変化も実証されている [12]．以上の手法は，攻撃者の意図に沿った信号波形を生成できる一方で，実験環境がセンサ本来の利用形態から乖離しており，実現性の点で課題がある．

© 2026 Information Processing Society of Japan



(a) Russell's circumplex model of affect (adapted from [6], [8], [9]). **(b)** Valence and arousal scores in the CASE dataset. **(c)** Valence and arousal scores in the PPGE dataset.

図 2: Russell の感情円環モデルおよび各データセットにおける Valence と Arousal の値

Fig. 2 Russell's circumplex model of affect, and valence and arousal scores in the datasets.

表 1: Russell の感情円環モデルを含む既存研究と本研究の比較
Table 1 Comparison of previous studies and our research based on Russell's circumplex model.

研究	信号	計測時の感情の象限 I	II	III	IV	認証精度と感情の関係の定量的分析	対策評価
[3]	ECG	-	○	-	-	-	-
[4]	ECG	-	○	-	-	-	-
[13]	PPG	○	○	○	○	-	-
本研究	ECG, PPG	○	○	○	○	○	○

表 2: 本実験で使用したデータセット
Table 2 Datasets used in the experiment.

データセット	人数	信号	各象限に対応する感情 (括弧内は HR, PR) I	II	III	IV
CASE [6]	30	ECG, PPG	Amused (70.5±2.5, 71.2±1.7)	Scared (72.0±2.5, 71.8±1.9)	Bored (69.3±2.6, 69.9±2.2)	Relaxed (70.1±2.8, 70.7±2.3)
PPGE [7]	18	PPG	Joyous (77.5±2.5)	Angry (77.3±2.5)	Sad (76.0±2.8)	Relaxed (77.1±2.6)

一方で，センサや計測部位に直接作用せず，ユーザの感情に影響を与えることで信号波形を変化させ，その影響を調査する研究も存在する．例えば，音声シナリオ等を用いてリラックスや怒りといった感情を想起させ，ECG 信号を用いた個人識別や感情推定の精度に与える影響が調査されている [3], [4]．また，特定の感情を想起させ得る映像の視聴者から計測された PPG 信号による認証精度も検証されている [13]．感情に起因する表情変化が顔認証に与える影響 [14] や，音楽聴取時のパスワード入力能力の変化 [15] が調査されていることからも，認証システムの頑健化のため，感情の影響の考慮は重要である．

2.2 感情の分類と本研究のアプローチ

ユーザの感情の測定・評価は困難だが，図 2 **(a)** に示す Russell の感情円環モデルを用いて議論されることが多い [8]．同モデルでは，感情を快-不快を表す Valence と，覚醒-非覚醒を表す Arousal の 2 軸で定義される 2 次元平面上に配置し，同平面は 4 つの象限（I-IV）に分割される．

一方，生体信号を用いた認証システムでは，頑健性確保のため，様々な感情を考慮した精度評価が望ましい．しかし，表 1 に示すように，既存研究には制限が存在する．ECG 信号に関する研究 [3], [4] では，感情円環モデルの一部の象限のみを対象としており，網羅性に欠ける．また，PPG 信号に関する研究 [13] では，全象限に対応する感情を対象としているが，データセット全体を用いた認証精度評価にとどまり，Valence や Arousal を考慮した象限毎の定量的な分析や，対策の検討や評価は行われていない．

我々は先行研究 [5] において，映像による感情変化が ECG 信号および PPG 信号を用いた認証精度に与える影響について，公開データセットを用いた基礎検討を行った．その結果，訓練時とテスト時で異なる感情状態のデータを用いた場合に認証精度が低下し得ることを確認したが，認証精度と感情変化の関係に関する定量的な分析や，認証精度低下を緩和する対策の検証は未実施であった．

本研究では，Russell の感情円環モデルの全象限を考慮して，感情状態に応じた認証精度の変化を要因とともに調査し，対策を評価する．具体的には，認証精度と Russell の感情円環モデルにおける Valence と Arousal との関係を定量的に評価し，各象限における感情の分布を考慮したデータ統合による緩和策の評価を行う．

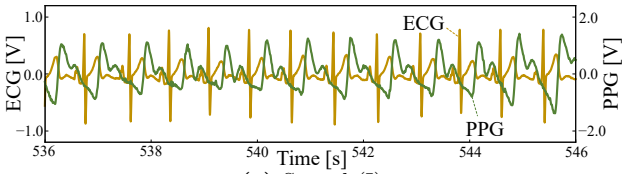
3. 実験

本節では，感情変化が生体信号を用いた認証に与える影響を調査するために行った，生体信号および認証モデルを用いた実験に関して説明する．

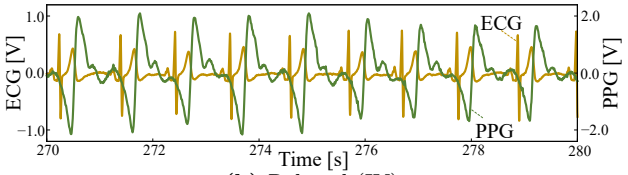
3.1 データセット

本実験では, 表 2 に示す Continuously Annotated Signals of Emotion（CASE）データセット [6] と PPG for Emotional analysis（PPGE）データセット [7] を使用した．いずれも，Russell の感情円環モデルにより 4 象限（I-IV）に分類される，図 2 **(a)** に太字で示した感情を想起させる映像を視聴した参加者から計測された生体信号が含まれ，映像の視聴順序は参加者毎に無作為である．また，表 2 は

© 2026 Information Processing Society of Japan



(a) Scared (I)



(b) Relaxed (IV)

図 3: ECG・PPG 信号の例 (CASE, 参加者 No. 6).

Fig. 3 ECG/PPG signals from participant No. 6, CASE.

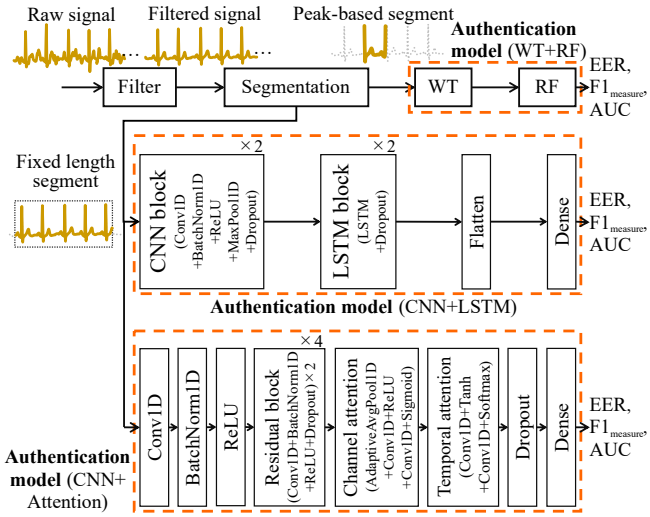


図 4: 認証モデルを含む実験手順 (ECG 信号の場合)

Fig. 4 Experimental procedure including authentication models. An example using ECG signals is shown.

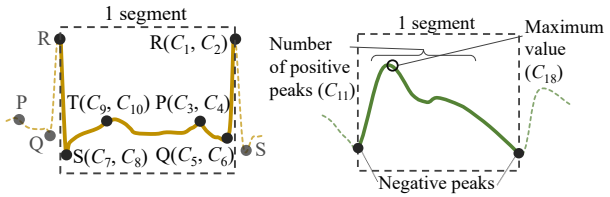
ECG 信号から推定した心拍数 (HR: Heart Rate)，PPG 信号から推定した脈拍数 (PR: Pulse Rate) を含み，図 3 に示す信号の例からも，感情による振幅や拍数の差が確認できる．図 2 **(b)(c)** は，参加者判断で付与された Valence および Arousal の値の平均 [6], [9] を範囲 $[-1, 1]$ に正規化した値を示す．CASE データセットの信号の標本化周波数は 1 kHz だが，PPGE データセットは 100 Hz であり，前者は 100 Hz に間引いて条件を統一した．以降では，各感情に対応する映像の視聴時の計測信号を Amused データ，Sad データ，同じ感情データ，異なる感情データ，等と記す．

3.2 認証モデル

本実験では，図 4 に示す手順により，各データセットの生体信号を処理した．既存の認証モデルとして，古典的な機械学習モデルと，深層学習モデルを使用した．

3.2.1 古典的な機械学習モデルと特徴量

古典的機械学習モデルとして，図 4 上部のウェーブレット変換 (WT: Wavelet Transform) と Random Forest (RF) で構成される WT+RF モデルを構築した．ECG 信号は NeuroKit2 [16]，PPG 信号は SciPy [17] を用いたピーク検出に基づき 1 周期毎に分割し，WT で得られる係数を特徴量とし，RF により各ユーザを本人または他人として判定した．Mother Wavelet には離散 Meyer を用い [18], [19]，1,000 本の決定木から構成される RF を用いた [20]．また，主成分分析 [21] により，特徴量を 24 個に削減した [22].



(a) ECG signal **(b)** PPG signal

図 5: ECG・PPG 信号から抽出した特徴量の例

Fig. 5 Example of features from ECG and PPG signals.

さらに，生体信号を用いた認証に関する既存研究 [23], [24], [25], [26] に従い，表 3 に示す 30 個の特徴量 $C_1, C_2, ..., C_{30}$ も抽出した．$C_1, ..., C_{10}$ [23] および $C_{11}, ..., C_{14}$ [24] は，ピークに関する特徴量である．$C_{15}, ..., C_{25}$ [25] は，PPG 信号から抽出される統計的特徴量であり，平均動的時間伸縮法 (DTW: Dynamic Time Warping) 距離も含まれ，ライブラリ [27] を用いて算出した．$C_{26}, ..., C_{30}$ [26] は，フーリエ変換により算出したパワースペクトル密度 (PSD: Power Spectral Density) であり，脳波 (EEG: Electroencephalogram) 解析で用いられる周波数帯域毎に算出した．さらに，[20] により特徴量の重要度を算出した．図 5 に，ECG 信号および PPG 信号から抽出した特徴量の例を示す．

3.2.2 深層学習モデル

深層学習モデルとして，図 4 中央の Convolutional Neural Network (CNN) と Long Short-Term Memory (LSTM) を有する CNN+LSTM モデル [28] を構築した．各信号を 5 秒毎に分割した固定長を入力とし，1 次元畳み込み層 (Conv1D: One-Dimensional Convolutional Layer，カーネルサイズ 6, 10)，1 次元バッチ正規化 (BatchNorm1D: One-Dimensional Batch Normalization)，活性化関数 (ReLU: Rectified Linear Unit)，1 次元最大プーリング層 (MaxPool1D: One-Dimensional Max Pooling Layer，カーネルサイズ 4)，双方向 LSTM (隠れユニット数 32) を含む [29].

さらに，図 4 下部の CNN+Attention モデル [30] も実装した．各残差ブロックは Conv1D (カーネルサイズ 3) と残差を含む．Channel attention および Temporal attention は，いずれも Conv1D (カーネルサイズ 1) を有し，前者に 1 次元適応平均プーリング (AdaptiveAvgPool1D: One-Dimensional Adaptive Average Pooling) を用い，後者に双曲線正接関数 (Tanh: Hyperbolic Tangent) を用いた．

各モデルの訓練時は，損失関数としてバイナリ交差エントロピー，最適化手法として Adam を用い，学習率 0.001，エポック数 100 とした．各モデルは PyTorch 2.6.0 で実装し，特に記載のない他の設定はデフォルト値を用いた．

© 2026 Information Processing Society of Japan

表 3: ECG 信号および PPG 信号から抽出して RF に入力した特徴量
Table 3 Features extracted from ECG and PPG signals used for RF.

特徴量 ID	信号	特徴量の概要	特徴量の意味または関係する生理現象	参考
C_1 / C_2	ECG	R 時刻 (R-R 間隔) / 振幅	心室脱分極	[16][23]
C_3 / C_4		P 時刻 (C_1 に対する比) / 振幅	心房脱分極	
C_5 / C_6		Q 時刻 (C_1 に対する比) / 振幅	心室脱分極	
C_7 / C_8		S 時刻 (C_1 に対する比) / 振幅	心室脱分極	
C_9 / C_{10}		T 時刻 (C_1 に対する比) / 振幅	心室脱分極	
C_{11}	PPG	正ピーク数	動脈拡張・収縮の複雑度	[17][24]
C_{12}		1 個目の正ピークの正の傾き	動脈拡張速度	
C_{13}		最後の正ピークの負の傾き	動脈収縮速度	
C_{14}		正ピーク間隔	動脈拡張・収縮速度	
C_{15}	PPG	平均	1 周期における動脈直径の平均	[17][25][27]
C_{16}		標準偏差	1 周期における動脈直径の変動	
C_{17}		DTW 距離の平均	1 回の計測における動脈直径の変動	
C_{18} / C_{19}		最大値 / 最小値	動脈直径	
C_{20} / C_{21}		最大値 / 最小値時刻	動脈の拡張 / 収縮速度	
C_{22} / C_{23}		Wavelet 係数の最大 / 最小値	動脈拡張・収縮の周波数特性	
C_{24}		尖度	動脈拡張・収縮速度	
C_{25}		歪度	動脈直径，動脈拡張・収縮速度	
$C_{26}, C_{27}, C_{28}, C_{29}, C_{30}$	ECG, PPG	1 周期分の信号の PSD	周波数特性 (0.5–4 Hz, 4.–8 Hz, 8–14 Hz, 14–30 Hz, 30 Hz–)	[26]

3.2.3 認証モデルの評価

認証精度に対する映像刺激の影響を評価するため，異なる感情データの組合せにより，認証モデルの訓練およびテストを行った．例えば，CASE データセットでは，Amused データを用いてモデルを訓練し，Scared データを用いてテストを行った．なお，EER は我々の先行研究 [5] で算出済であり，値の一覧を付録 A.1 の表 A·1 に記載した．ただし，[5] における CASE データセット [6] および WT+RF モデル，CNN+LSTM モデルによる結果に加え，PPGE データセット [7]，CNN+Attention モデルを追加し，本研究との差分は表 A·2 に整理した．また，Russell の感情円環モデル上での分布を考慮し，3 種類の感情データを訓練に用い，残る 1 種類をテストに用いる検証も行った．例えば，PPGE データセットでは，Angry・Sad・Relaxed データを訓練，Joyous データをテストに用いた．

参加者のうち 1 名を本人，残りを他人とみなす場合のデータ数の不均衡解消のため，Synthetic minority oversampling technique [31] を適用した．評価指標として，等価エラー率（EER: Equal Error Rate），$\mathrm{F1}_{\mathrm{measure}}$，ROC (Receiver Operating Characteristic）カーブより Area Under the Curve (AUC）[32], [33] を算出した．また，認証精度と感情変化の関係の調査のため，生体認証分野で広く用いられる EER に着目し，訓練・テストデータ間の Valence の差分を変数 $v = |v_{\mathrm{train}} - v_{\mathrm{test}}|$，Arousal の差分を変数 $a = |a_{\mathrm{train}} - a_{\mathrm{test}}|$ とし，以下の線形回帰モデルを適用した．

$$\mathrm{EER}(v, a) = b_0 + b_1 v + b_2 a \tag{1}$$

v_{train} および v_{test} はそれぞれ訓練およびテストデータにおける Valence の値，a_{train} および a_{test} は訓練およびテストデータにおける Arousal の値を表し，b_0，b_1，b_2 は回帰係数である．効果量として決定係数 R^2，有意 F，回帰モデルにおける v および a の p 値 [34] を算出した．

表 4: 全感情データを用いて得られた評価指標値
Table 4 Evaluation metric values using all emotions.

データセット	信号	モデル	EER	$\mathrm{F1}_{\mathrm{measure}}$	AUC
CASE	ECG	WT+RF	$0.0127_{\pm 0.0030}$	$0.9697_{\pm 0.0066}$	$0.9991_{\pm 0.0004}$
		CNN+LSTM	**$0.0001_{\pm 0.0001}$**	$0.9995_{\pm 0.0004}$	**$1.0000_{\pm 0.0000}$**
		CNN+Attention	$0.0002_{\pm 0.0002}$	**$0.9997_{\pm 0.0002}$**	$1.0000_{\pm 0.0000}$
	PPG	WT+RF	$0.0362_{\pm 0.0079}$	$0.9289_{\pm 0.0150}$	$0.9927_{\pm 0.0027}$
		CNN+LSTM	$0.0114_{\pm 0.0032}$	$0.9836_{\pm 0.0049}$	**$0.9989_{\pm 0.0005}$**
		CNN+Attention	**$0.0085_{\pm 0.0044}$**	**$0.9884_{\pm 0.0054}$**	$0.9985_{\pm 0.0017}$
PPGE	ECG	WT+RF	$0.0524_{\pm 0.0169}$	$0.9052_{\pm 0.0276}$	$0.9851_{\pm 0.0076}$
		CNN+LSTM	$0.0125_{\pm 0.0053}$	$0.9805_{\pm 0.0091}$	$0.9986_{\pm 0.0073}$
		CNN+Attention	**$0.0119_{\pm 0.0042}$**	**$0.9861_{\pm 0.0045}$**	**$0.9986_{\pm 0.0007}$**
	PPG	WT+RF	$0.0524_{\pm 0.0169}$	$0.9052_{\pm 0.0276}$	$0.9851_{\pm 0.0076}$
		CNN+LSTM	$0.0125_{\pm 0.0053}$	$0.9805_{\pm 0.0091}$	$0.9986_{\pm 0.0073}$
		CNN+Attention	**$0.0119_{\pm 0.0042}$**	**$0.9861_{\pm 0.0045}$**	**$0.9986_{\pm 0.0007}$**

4. 結果と考察

本節では，3 節で説明した実験により得られた結果に関して，1 節で設定した RQs を観点として考察する．

4.1 認証精度低下の条件

RQ1: 感情変化時の生体信号に起因する認証精度の大きな変化は，具体的にどのような条件下で生じるか？に関する結果を確認する．まず，表 4 は，全感情データを用いた交差検証により，各認証モデルの訓練およびテストを行って得られた評価指標値であり，最良の値は太字で示した．続いて，先行研究 [5] でも算出した，感情データの異なる組合せで得られた EER を比較した．表 A·1 の各行に示した EER について，分散分析により等分散性を確認できた場合は Tukey の Honest Significant Difference (HSD) 検定 [35]，確認できなかった場合は Games–Howell 検定 [36] を適用し，効果量として Cohen の d [37] を算出した．その結果，先行研究 [5] と同様に，本研究で追加した PPGE データセットや CNN+Attention モデルの場合も，訓練とテストで異なる感情データを用いた場合に有意差が確認できた．また，Cohen の d は，一般的に大きいとされる基準値 0.8 [37] を上回った結果が多いことからも，感情変化による EER の変化は大きかったと考えられる．

© 2026 Information Processing Society of Japan

表 5: EER に関する線形モデル (式 (1)) による回帰分析の結果
Table 5 Regression results of the linear model for EER (eq. 1).

データセット	信号	モデル	効果量	有意 F	p 値 v	p 値 a
CASE	ECG	WT+RF	R^2=0.312	F<0.001	p=.431	p=.002
		CNN+LSTM	R^2=0.328	F<0.001	p=.051	p=.022
		CNN+Attention	R^2=0.181	F=0.002	p=.087	p=.244
	PPG	WT+RF	R^2=0.531	F<0.001	p=.015	p<.001
		CNN+LSTM	R^2=0.420	F<0.001	p=.070	p=.001
		CNN+Attention	R^2=0.474	F<0.001	p=.034	p<.001
PPGE	PPG	WT+RF	R^2=0.808	F<0.001	p<.001	p<.001
		CNN+LSTM	R^2=0.656	F<0.001	p=.020	p=.003
		CNN+Attention	R^2=0.745	F<0.001	p=.022	p<.001

表 6: 訓練用の感情データの個数を変えた場合の EER
Table 6 EERs using one and three emotions for training.

データセット	信号	モデル	EER 1 感情	EER 3 感情
CASE	ECG	WT+RF	0.0039±0.0018	**0.0015±0.0006*** (d=0.874, p=.030)
		CNN+LSTM	0.0012±0.0007	0.0020±0.0027 (d=0.483, p=.657)
		CNN+Attention	0.0087±0.0012	0.0107±0.0098 (d=0.397, p=.973)
	PPG	WT+RF	0.0828±0.0157	**0.0500±0.0084*** (d=1.318, p=.047)
		CNN+LSTM	0.0395±0.0081	**0.0377±0.0118** (d=0.131, p=.834)
		CNN+Attention	0.0619±0.0130	**0.0380±0.0160** (d=1.100, p=.093)
PPGE	PPG	WT+RF	0.1679±0.0034	**0.1050±0.0097*** (d=8.975, p<.001)
		CNN+LSTM	0.0853±0.0093	**0.0659±0.0250** (d=1.034, p=.122)
		CNN+Attention	0.0780±0.0120	**0.0585±0.0208** (d=0.920, p=.158)

EER を目的変数，Valence の差分を変数 v，Arousal の差分を変数 a とした，式 (1) で表される線形モデルによる回帰分析の結果を表 5 に示す．各モデルにおいて，効果量 R^2 は十分に高い適合度を示さなかったが [38]，有意 F は小さく，また 9 条件中 8 条件で $a = |a_{\text{train}} - a_{\text{test}}|$ は p<.05 を示したことから，特に Arousal の差分が認証精度に寄与する可能性が示唆された．

4.2 認証精度低下の緩和策の評価

RQ2: 認証精度の低下を緩和するには，どのような方法が有効か？に関する結果を確認する．本実験では，Russell の感情円環モデルを基準とした感情の分布を考慮した緩和策として，複数種類の感情データの統合による効果を検証した．表 6 に，1 種類の感情データを用いて訓練した場合の EER (表 A·1 における非着色セルの平均値) と，テスト対象の 1 種類の感情を除いた 3 種類の感情データを用いて訓練した場合の EER を示す．1 種類・3 種類の感情データで訓練した場合の EER を比較するため，まず F 検定により EER 間の等分散性を確認し，等分散性が確認できた場合は Student の t 検定，確認できなかった場合は Welch の t 検定 [39] を行い，効果量として Cohen の d を算出した．3 種類の感情データにより，9 条件中 7 条件で EER が小さくなる傾向が示されたが (太字)，有意差は WT+RF モデルのみ確認できた (p<.05)．CASE データセットの ECG 信号と深層学習モデルの組合せによる 2 条件では EER が増加したことからも，本緩和策の効果は信号やモデルの種類に依存する可能性がある．図 6 に，1 種類および 3 種類の感情データで訓練した場合の ROC カーブの例を示す．

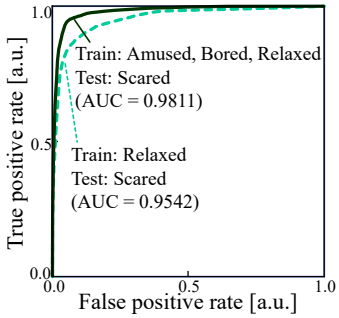


図 6: 感情データ数を変えた場合の ROC カーブの例 (CASE データセットの実験参加者 No. 30)
Fig. 6 Example of ROC curves using PPG signals in one and three emotions (Participant No. 30 in CASE dataset).

表 7: 表 3 の特徴量と RF による感情別の特徴量の重要度
Table 7 Top 5 features from Table 3 with RF.

データセット	信号	重要度順位	感情別の上位 5 特徴量 I	II	III	IV
CASE	ECG	1	C_1	C_1	C_1	C_1
		2	C_8	C_8	C_8	C_8
		3	C_{26}	C_{27}	C_{26}	C_{26}
		4	C_{27}	C_{26}	C_{27}	C_{27}
		5	C_{10}	C_{10}	C_{10}	C_{10}
	PPG	1	C_{17}	C_{17}	C_{17}	C_{17}
		2	C_{29}	C_{29}	C_{29}	C_{29}
		3	C_{19}	C_{19}	C_{19}	C_{19}
		4	C_{23}	C_{23}	C_{23}	C_{23}
		5	C_{25}	C_{25}	C_{25}	C_{25}
PPGE	PPG	1	C_{17}	C_{17}	C_{17}	C_{17}
		2	C_{30}	C_{30}	C_{18}	C_{18}
		3	C_{16}	C_{18}	C_{30}	C_{23}
		4	C_{18}	C_{29}	C_{16}	C_{29}
		5	C_{29}	C_{16}	C_{23}	C_{30}

4.3 感情，特徴量，データセット間の比較

先行研究 [5] および表 A·1 より，CASE データセットにおいて Scared データをテストに用いた場合に，特に多くの EER が有意に大きくなった．Amused データを訓練およびテストの両方に用いた場合と，Amused データを訓練，Scared データをテストに用いた場合との EER の差は比較的小さかったが，Bored または Relaxed データを訓練に用いた場合には，EER の差がより顕著であった．図 2 **(a)** の通り，Russell の感情円環モデルにおいて，“Scared”，“Amused” はそれぞれ第 II，I 象限に位置しており，いずれも高 Arousal に分類される．一方，“Bored”，“Relaxed” はそれぞれ第 III，IV 象限に位置し，低 Arousal に分類される．したがって，4.1 節で述べた回帰分析の結果でも示唆された通り，特に Arousal 軸で表される高覚醒と低覚醒状態との差分が，認証精度に寄与する可能性がある．

表 7 に，表 3 に示した特徴量と，RF による感情別の特徴量の重要度を示す．多くの場合，感情間で順位は類似し，傾向を見出すのは困難である．しかし，第 I・II 象限に位置する高 Arousal の場合，高周波数帯域の PSD が高い順位を示す傾向があった．例えば，PPGE データセットでは，C_{30} (30 Hz 以上の PSD) は，第 III・IV 象限よりも第 I・II 象限において高い順位を示した．

© 2026 Information Processing Society of Japan

CASE データセットでは，PPGE データセットと比較して，表 A·1 で示した EER に偏りが見られた．この差異は，参加者判断で付与された Valence および Arousal の値の偏りに起因すると考えられる．図 2 **(b)** では，同データセットの “Scared” は他の感情から離れて位置する一方，他の感情は互いに近い位置に集中している．また，図 2 **(a)** に示した通り，一般に “Bored” は第 III 象限に位置するべきだが，図 2 **(b)** において “Bored” の平均は第 IV 象限に位置している [6]．表 2 では，CASE データセットの “Scared” における HR および PR の平均が比較的高い値を示したことからも，図 2 **(c)** において各感情がより均等に分布している PPGE データセットとは差があったと考えられる．

5. 今後の課題

本節では，今回の実験条件や評価方法における制限を踏まえて，今後の課題を述べる．

5.1 データセットに含まれる感情の種類と感情モデル

今回の実験では，感情変化が認証精度に与える影響の定量化に焦点を当てたが，今後はより様々な感情状態を考慮して，図 1 **(b)** に示した攻撃の実現性を評価することが望ましい．本実験では，Russell の感情円環モデルにより分類される 4 種類の感情のみを対象とした．しかし，実際には，図 2 **(a)** において同じ象限に分類される “Scared” と “Angry” のように，より多様な感情が存在する．したがって，同感情円環モデルには含まれない Dominance 軸を有する 3 次元の Pleasure-Arousal-Dominance モデル等 [40]，他の感情モデルでの評価も検討する．また，感情変化の考慮には，より長時間の計測で得られた生体信号の解析も重要である．本研究では，視覚刺激としての映像視聴中に計測された生体信号を用いたが，聴覚刺激 [3], [4] 等の他の外部刺激も，今後考慮する余地がある．

5.2 データ計測の背景および Valence・Arousal の考慮

本実験では，使用した 2 件のデータセットにおける背景の差異を考慮できていなかった．例えば，CASE データセット [41] はドイツで収集され，実験指示は英語で行われている．一方，PPGE データセット [9] は，韓国語の映像を用いて韓国語話者から収集されている．このような差異が，本実験結果に影響を及ぼした可能性は否定できない．今後は，様々な母語や文化的背景を持つ参加者からの計測や，データセット間のバイアスを考慮した評価を検討する．

本研究では，認証精度と Valence および Arousal の関係を，式 (1) の単純な線形回帰モデルを用いて調査した．しかし，Valence と Arousal は完全に独立して変化せず，その間に存在し得る交互作用 [42] を考慮していない．前段落で述べたデータ計測の背景も踏まえると，感情における文化や言語間での変動 [43], [44] も重要である．以上を考慮した評価方法の検討も，今後の課題として挙げられる．

6. おわりに

本研究では，映像刺激による感情変化が生体信号を用いた認証システムに与える影響を，対策とともに定量的に評価した．我々の先行研究における基礎検討を拡張して，48 名分の生体信号データセットを利用し，認証モデルとの組合せにより認証精度を比較した．その結果，訓練とテストで計測時の感情状態が異なる場合，認証精度が低下する傾向とともに，精度低下への Arousal の差分による寄与が示唆された．また，頑健なシステムに必要な対策として，複数の感情データの統合により，精度低下を緩和できる可能性を示した．今後は，より様々な感情状態も考慮した攻撃の実現性や，データ計測の背景を考慮した評価を行う．

参考文献

[1] Pinto, J. R., Cardoso, J. S. and Lourenço, A.: Evolution, current challenges, and future possibilities in ECG biometrics, *IEEE Access*, Vol. 6, pp. 34746–34776 (2018).

[2] Li, L., Chen, C., Pan, L., Zhang, L. Y., Wang, Z., Zhang, J. and Xiang, Y.: A survey of PPG's application in authentication, *Comput. Secur.*, Vol. 135, pp. 1–13 (2023). Art. no. 103488.

[3] Brás, S., Ferreira, J. H. T., Soares, S. C. and Pinho, A. J.: Biometric and emotion identification: An ECG compression based method, *Front. Psychol.*, Vol. 9, p. 467 (2018).

[4] Tanasković, I., Lazarević, L. B., Knežević, G., Milosavljević, N., Dubljević, O., Bjegojević, B. and Miljković, N.: CardioPRINT: Biometric identification based on the individual characteristics derived from the cardiogram, *Expert Syst. Appl.*, Vol. 265, pp. 1–17 (2025). Art. no. 126018.

[5] 日夏　俊，中井綱人，梨本翔永，大西健斗，東　拓矢：外部刺激に由来する感情変化は生体信号を利用した認証に影響を与えるか?，コンピュータセキュリティシンポジウム 2025　論文集，pp. 522–529 (2025).

[6] Castellini, C., Schwenker, F., Sharma, K., Van Den Broek, E. L. and Albu-Schaeffer, A.: CASE_Datasetfull, https://springernature.figshare.com/articles/dataset/CASE_Dataset-full/8869157. accessed on Aug. 18, 2025.

[7] Lab, P. P. M.: PPG-Dataset, https://github.com/PKNU-PR-ML-Lab/PPG-Dataset. accessed on Sep. 11, 2025.

[8] Russell, J. A.: A circumplex model of affect, *J. Pers. Soc. Psychol.*, Vol. 39, No. 6, p. 1161 (1980).

[9] Jin, Y.-J., Habibilloh, E., Jang, Y.-S., An, T., Jo, D., Park, S. and Chang, W.-D.: A photoplethysmogram dataset for emotional analysis, *Appl. Sci.*, Vol. 12, No. 13, p. 6544 (2022).

[10] Eberz, S., Paoletti, N., Roeschlin, M., Kwiatkowska, M., Martinovic, I. and Patané, A.: Broken hearted: How to attack ECG biometrics, *Proc. Netw. Distrib. Syst. Secur. Symp. (NDSS)*, pp. 1–15 (2017).

[11] Wang, J., Lu, L., Kong, H., Lin, F., Ba, Z. and Ren, K.: Liquid crystal mimics your heart: A physical spoofing attack against PPG-based systems, *IEEE Trans. Inf. Forensics Secur.*, Vol. 20, pp. 8628–8642 (2025).

[12] Yoshida, K., Sawano, R., Okamoto, M., Murao, K., Tsuchida, S. and Terada, T.: Physical noninvasive at-

© 2026 Information Processing Society of Japan

tacks on photoplethysmogram by computer controlled blood pressure cuff, *Sensors*, Vol. 23, No. 24, p. 9764 (2023).

[13] Yadav, U., Abbas, S. N. and Hatzinakos, D.: Evaluation of PPG biometrics for authentication in different states, *Proc. Intern. Conf. Biom. (ICB)*, pp. 277–282 (2018).

[14] Alrubaish, H. A. and Zagrouba, R.: The effects of facial expressions on face biometric system's reliability, *Information*, Vol. 11, No. 10, p. 485 (2020).

[15] Mecke, L., Mahmoud, A., Marat, S. and Alt, F.: Exploring the effect of music on user typing and identification through keystroke dynamics, *Proc. Conf. Hum. Factors Comput. Syst. (CHI)*, pp. 1–10 (2025).

[16] NeuroKit2: Locate P, Q, S and T waves in ECG - NeuroKit2 0.2.11 documentation, https://neuropsychology.github.io/NeuroKit/examples/ecg_delineate/ecg_delineate.html. accessed on Nov. 11, 2024.

[17] SciPy: argrelmin - SciPy v1.14.0 Manual, https://docs.scipy.org/doc/scipy/reference/generated/scipy.signal.argrelmin.html. accessed on July 17, 2024.

[18] Diab, M. O., Seif, A., El-Abed, M. and Sabbah, M.: Individual Identification Using ECG Signals, *J. Comput. Commun.*, Vol. 6, No. 01, pp. 74–80 (2018).

[19] Developers, T. P.: Wavelets - PyWavelets Documentation - Read the Docs, https://pywavelets.readthedocs.io/en/latest/ref/wavelets.html (2026). accessed on Apr. 2, 2026.

[20] Learn, S.: RandomForestClassifier-scikit-learn 1.8.0 documentation, https://scikit-learn.org/stable/modules/generated/sklearn.ensemble.RandomForestClassifier.html (2025). accessed on Feb. 17, 2026.

[21] Learn, S.: PCA-scikit-learn 1.8.0 documentation, https://scikit-learn.org/stable/modules/generated/sklearn.decomposition.PCA.html (2025). accessed on Apr. 2, 2026.

[22] Zhang, L., Li, A., Chen, S., Ren, W. and Choo, K.-K. R.: A secure, flexible, and PPG-based biometric scheme for healthy IoT using homomorphic random forest, *IEEE Internet Things J.*, Vol. 11, No. 1, pp. 612–622 (2023).

[23] Coutinho, D. P., Fred, A. L. N. and Figueiredo, M. A. T.: One-lead ECG-based personal identification using Ziv-Merhav cross parsing, *Proc. 20th Int. Conf. Pattern Recogn.*, pp. 3858–3861 (2010).

[24] Gu, Y. Y., Zhang, Y. and Zhang, Y. T.: A novel biometric approach in human verification by photoplethysmographic signals, *Proc. IEEE EMBS Special Topic Conf. Inform. Technol. Appl. Biomed. (ITAB)*, pp. 13–14 (2003).

[25] Jindal, V., Birjandtalab, J., Pouyan, M. B. and Nourani, M.: An adaptive deep learning approach for PPG-based identification, *Proc. 38th Annu. Intern. Conf. IEEE Eng. Med. Biol. Soc. (EMBC)*, pp. 6401–6404 (2016).

[26] Iijima, R., Takehisa, T., Ohki, T. and Mori, T.: The catcher in the eye: Recognizing users by their blinks, *Proc. 19th ACM Asia Conf. Comput. Commun. Secur. (ASIACCS)*, pp. 1739–1752 (2024).

[27] Tanida, K.: fastdtw 0.3.4, https://pypi.org/project/fastdtw/ (2019). accessed on Apr. 7, 2026.

[28] Hwang, D. Y., Taha, B. and Hatzinakos, D.: PBGAN: Learning PPG representations from GAN for time-stable and unique verification system, *IEEE Trans. Inf. Forensics Secur.*, Vol. 16, pp. 5124–5137 (2021).

[29] Nastul: GitHub-NasTul/Attacking PPG-based biometric authentication:Paper from AISec, https://github.com/NasTul/Attacking-PPG-based-Biometric-Authentication. accessed on Apr. 17, 2025.

[30] Wen, H., Wu, X., Ma, C., Shi, B., Pei, J., Bashir, A. K. and Liu, W.: ST-AuthNet: A spatiotemporal attention-driven lightweight ECG biometric authentication system, *IEEE Internet Things J.*, Vol. 12, No. 22, pp. 46150–46163 (2025).

[31] Fernández, A., Garcia, S., Herrera, F. and Chawla, N. V.: SMOTE for learning from imbalanced data: progress and challenges, marking the 15-year anniversary, *J. Artif. Intell. Res.*, Vol. 61, pp. 863–905 (2018).

[32] Sugrim, S., Liu, C., McLean, M. and Lindqvist, J.: Robust performance metrics for authentication systems, *Proc. Netw. Distrib. Syst. Secur. Symp. (NDSS)*, pp. 1–15 (2019).

[33] Sundararajan, A., Sarwat, A. I. and Pons, A.: A survey on modality characteristics, performance evaluation metrics, and security for traditional and wearable biometric systems, *ACM Comput. Surv.*, Vol. 52, No. 2, pp. 1–36 (2019).

[34] Skiera, B., Reiner, J. and Albers, S.: Regression analysis, *Handb. Mark. Res.*, Springer, pp. 299–327 (2021).

[35] Nanda, A., Mohapatra, B. B., Mahapatra, A. P. K., Mahapatra, A. P. K. and Mahapatra, A. P. K.: Multiple comparison test by Tukey's honestly significant difference (HSD): Do the confident level control type I error, *Int. J. Stat. Appl. Math.*, Vol. 6, No. 1, pp. 59–65 (2021).

[36] Shingala, M. C. and Rajyaguru, A.: Comparison of post hoc tests for unequal variance, *Int. J. New Technol. Sci. Eng.*, Vol. 2, No. 5, pp. 22–33 (2015).

[37] Goulet-Pelletier, J.-C. and Cousineau, D.: A review of effect sizes and their confidence intervals, Part I: The Cohen's d family, *Quant. Methods Psychol.*, Vol. 14, No. 4, pp. 242–265 (2018).

[38] Ferguson, C. J.: An effect size primer: A guide for clinicians and researchers., *Prof. Psychol.: Res. Pract.*, Vol. 40, No. 5, pp. 532–538 (2009).

[39] Delacre, M., Lakens, D. and Leys, C.: Why psychologists should by default use Welch's t-test instead of Student's t-test, *Int. Rev. Social Psychol.*, Vol. 30, No. 1, pp. 92–101 (2017).

[40] Wang, Y., Song, W., Tao, W., Liotta, A., Yang, D., Li, X., Gao, S., Sun, Y., Ge, W., Zhang, W. and Zhang, W.: A systematic review on affective computing: Emotion models, databases, and recent advances, *Inf. Fusion*, Vol. 83, pp. 19–52 (2022).

[41] Sharma, K., Castellini, C., Van Den Broek, E. L., Albu-Schaeffer, A. and Schwenker, F.: A dataset of continuous affect annotations and physiological signals for emotion analysis, *Sci. Data*, Vol. 6, No. 1, p. 196 (2019).

[42] Kuppens, P., Tuerlinckx, F., Russell, J. A. and Barrett, L. F.: The relation between valence and arousal in subjective experience., *Psychol. Bull.*, Vol. 139, No. 4, pp. 917–940 (2013).

[43] Kuppens, P., Tuerlinckx, F., Yik, M., Koval, P., Coosemans, J., Zeng, K. J. and Russell, J. A.: The relation between valence and arousal in subjective experience varies with personality and culture, *J. Pers.*, Vol. 85, No. 4, pp. 530–542 (2017).

[44] Wang, J., Yu, L.-C., Lai, K. R. and Zhang, X.: Locally weighted linear regression for cross-lingual valence-arousal prediction of affective words, *Neurocomputing*, Vol. 194, pp. 271–278 (2016).

© 2026 Information Processing Society of Japan

研究倫理

本研究は生体認証システムを対象としており，実験において生体信号のデータセットおよび PC を用いた信号処理を行うにあたって，情報処理学会が定める倫理綱領[*1]や CSEC 研究会が定めるチェックリスト[*2]，生体信号処理を含む既存研究[*3]を参照し，以下を研究倫理として考慮した．

人を対象とした実験によるデータの入手

本研究における実験では，3 節で説明した通り，生体信号が含まれる公開データセット 2 件 [6], [7] を利用した．データセット中の ECG 信号や PPG 信号は，電極や光学センサを用いて非侵襲的に計測されたものである．また，使用したデータセットのうち 1 件 [6] は，計測実施者の所属機関において設置された倫理委員会の承認に基づいて行われた実験で得られたものであり，参加者の同意および署名のもと計測されたこと[*4] を確認してから使用した．もう 1 件のデータセット [7] についても，計測実施者の所属機関において設置された倫理委員会の承認に基づいて行われた実験で得られたこと [9] を確認してから使用した．我々は，本実験のための新たなデータ計測は行っていない．

データの使用におけるセキュリティとプライバシーの考慮

本実験では，3 節で説明した通り，既存研究を基に構築した認証モデルにより，生体信号を用いた認証システムを試作して評価を行った．同評価では，同認証システムに対して起こり得るセキュリティ課題を検討し，ユーザの認証を妨げる攻撃を想定した検証を行ったが，その目的は同攻撃の発生も考慮した頑健な認証システムの開発であり，現実に存在するシステムへの攻撃を支援・奨励するものではない．本実験の結果，特定の条件での認証精度低下を確認し，頑健な認証システムに必要な対策として，精度低下の緩和策を検討し評価した．

また，本実験で使用した公開データセット [6], [7] には，実験参加者を特定できるような個人情報は含まれていない．同データセットは，配布元が定めた規約のもと使用し，集約・匿名化されたデータから実験参加者を特定する等，プライバシーの侵害に繋がり得る行為は行っていない．

データ間の公平性・バイアス

本研究の対象とした生体信号や感情は，5.2 節でも議論した通り，年齢，性別，健康状態，文化的背景，言語等，今回の実験では考慮できなかった様々な要素が影響し得る．したがって，本研究で得られた結果を，ユーザとなり得る全ての人物に対して一般化することには慎重である必要がある．今後，社会実装や運用を検討する場合は，特定のユーザに対して不利益が生じないように，公平性に配慮した評価を行う必要がある．

AI の使用に関する考慮

本実験における，生体信号の前処理，特徴量抽出，認証モデルの訓練，推論，および EER，$F1_{\mathrm{measure}}$，AUC 等の評価指標値の算出といった処理は，3 節に記載したライブラリ，モデル構成，ハイパーパラメータ等の実験条件に基づいて実行しており，大規模言語モデル (LLM: Large Language Model) 等の生成 AI は使用していない．したがって，本実験において試作した認証システムによる出力結果や評価指標値は，ハルシネーションを起こし得る LLM によって生成や推定，補完されたものではない．また，公開データセットに含まれる生体信号データや参加者毎の解析結果を LLM に入力する処理は行っていない．

実験による環境への影響

本実験は，GPU (NVIDIA GeForce RTX 3070 GPU (8 GB VRAM)) を接続した PC (Intel Core i5-10210U CPU, 64 GB RAM)，CUDA 11.8 を用いて行ったが，環境への影響を考慮するため，Web アプリケーション[*5]を利用して，同 GPU を用いた処理による二酸化炭素排出量を推定した．今回は，本実験において最も長時間である約 5 時間 6 分を要した，CASE データセットに含まれる 30 名分の処理を CNN+Attention モデルで行った場合を対象とした (1 名分の訓練 548.74±8.65 s，推論 64.16±61.37 s)．同 GPU の熱設計電力 (TDP: Thermal Design Power) は 220 W である．同 Web アプリケーションにおいて，以上の処理時間や TDP の情報とともに，位置情報として実験の実施場所に最も近い “Asia-Japan-Tokyo” を設定した結果，二酸化炭素排出量の推定値は約 670 gCO2e となり，約 0.73 tree-months (1 本の木が 0.73 ヶ月間に吸収する二酸化炭素量) に相当する．ただし，この結果は GPU が TDP を基準として同処理を継続したと仮定し，GPU および利用可能なメモリ量を考慮した概算値であり，他処理や CPU，ストレージ，冷却，ネットワーク等の他の要素は考慮していない．今後，本研究で扱ったシステムの社会実装や運用を検討する場合は，他の要素も含めて，環境への影響を考慮する必要がある．

[*1] 倫理綱領-情報処理学会, https://www.ipsj.or.jp/ipsjcode.html, accessed on Aug. 7, 2026.

[*2] サイバーセキュリティ研究倫理に関するチェックリスト, https://www.iwsec.org/csec/ethics/checklist.html, accessed on Aug. 7, 2026.

[*3] Khan, I. and Lowe, R.: Surprise! Using physiological stress for allostatic regulation under the active inference framework. *Proc. 12th Int. Conf. Affect. Comput. Intell. Interact. (ACII)*, pp. 168–175 (2024).

[*4] Sharma, K., Castellini, C., Stulp, F. and Van den Broek, E. L.: Continuous, real-time emotion annotation: A novel joystick-based analysis framework, *IEEE Trans. Affect. Comput.*, Vol. 11, No. 1, pp. 78–84 (2017).

[*5] Green Algorithms calculator, https://calculator.green-algorithms.org/. accessed on Aug. 20, 2026.

© 2026 Information Processing Society of Japan

付　　録

A.1　我々の先行研究での検証

我々の先行研究 [5] で得た，各感情データにより得られた EER を表 A·1 に示す．ただし，本稿では CNN+Attention モデル，PPGE データセット [7] を用いた結果を追加した．表 A·1 の行毎に，等分散性有無により Tukey の HSD 検定 [35] または Games-Howell 検定 [36] を行い，同一感情データを分割して訓練とテストに用いた場合 (着色セル) と比較して有意に大きい EER に* (p<.05) および** (p<.01)，さらに各値の間の効果量として Cohen の d [37] を付記した．

表 A·1: 各感情を想起させ得る映像の視聴時に計測された ECG 信号および PPG 信号を用いて得られた EER
Table A·1 EERs using ECG and PPG signals across emotions in the experiment.

データセット	信号	認証モデル	訓練データ	テストデータ I	テストデータ II	テストデータ III	テストデータ IV
CASE	ECG	WT+RF	I) Amused	0.0013±0.0000	0.0045±0.0022* (d=0.725, p=.005)	0.0013±0.0009 (d=0.009, p=.999)	0.0011±0.0004 (d=0.273, p=.729)
			II) Scared	0.0020±0.0010 (d=0.170, p=.966)	0.0024±0.0002	0.0021±0.0017 (d=0.090, p=.977)	0.0015±0.0004 (d=0.974, p=.597)
			III) Bored	0.0044±0.0032 (d=0.512, p=.230)	0.0107±0.0057* (d=0.836, p=.017)	0.0012±0.0000	0.0018±0.0008 (d=0.383, p=.474)
			IV) Relaxed	0.0062±0.0046 (d=0.510, p=.234)	0.0092±0.0043** (d=0.904, p=.009)	0.0017±0.0010 (d=0.048, p=.998)	0.0016±0.0000
		CNN+LSTM	I) Amused	0.0006±0.0005	0.0025±0.0022 (d=0.410, p=.663)	0.0003±0.0003 (d=0.301, p=.414)	0.0003±0.0002 (d=0.352, p=.544)
			II) Scared	0.0006±0.0006 (d=0.035, p=.999)	0.0005±0.0003	0.0005±0.0008 (d=0.021, p=.999)	0.0002±0.0002 (d=0.574, p=.816)
			III) Bored	0.0011±0.0008 (d=0.473, p=.287)	0.0030±0.0015* (d=0.893, p=.009)	0.0003±0.0003	0.0003±0.0002 (d=0.089, p=.287)
			IV) Relaxed	0.0011±0.0008 (d=0.194, p=.881)	0.0039±0.0031 (d=0.519, p=.218)	0.0005±0.0007 (d=0.129, p=.968)	0.0007±0.0006
		CNN+Attention	I) Amused	0.0001±0.0001	0.0138±0.0067** (d=1.027, p=.003)	0.0057±0.0032* (d=0.871, p=.012)	0.0075±0.0054 (d=0.692, p=.061)
			II) Scared	0.0077±0.0035** (d=0.969, p=.004)	0.0007±0.0010	0.0086±0.0040** (d=0.966, p=.004)	0.0087±0.0038** (d=1.035, p=.002)
			III) Bored	0.0105±0.0041** (d=1.306, p<.001)	0.0154±0.0061** (d=1.277, p<.001)	0.0000±0.0000	0.0121±0.0056** (d=1.086, p=.002)
			IV) Relaxed	0.0124±0.0035** (d=1.748, p<.001)	0.0168±0.0054** (d=1.537, p<.001)	0.0065±0.0036* (d=0.891, p=.010)	0.0003±0.0002
	PPG	WT+RF	I) Amused	0.0369±0.0019	0.1021±0.0305** (d=1.078, p=.002)	0.0568±0.0138* (d=0.720, p=.047)	0.0592±0.0182 (d=0.616, p=.111)
			II) Scared	0.0708±0.0155** (d=0.977, p=.004)	0.0408±0.0005	0.0943±0.0279** (d=0.969, p=.005)	0.0750±0.0190** (d=0.912, p=.008)
			III) Bored	0.0776±0.0190 (d=1.020, p=.003)	0.1433±0.0412** (d=1.278, p<.001)	0.0392±0.0002	0.0661±0.0194 (d=0.700, p=.057)
			IV) Relaxed	0.0627±0.0136* (d=0.798, p=.024)	0.1298±0.0363** (d=1.237, p<.001)	0.0563±0.0156 (d=0.492, p=.261)	0.0412±0.0004
		CNN+LSTM	I) Amused	0.0181±0.0044	0.0498±0.0193* (d=0.809, p=.021)	0.0231±0.0063 (d=0.329, p=.596)	0.0268±0.0097 (d=0.415, p=.400)
			II) Scared	0.0396±0.0146 (d=0.516, p=.431)	0.0225±0.0083	0.0481±0.0214 (d=0.565, p=.112)	0.0360±0.0144 (d=0.410, p=.634)
			III) Bored	0.0342±0.0103* (d=0.730, p=.039)	0.0704±0.0268** (d=0.979, p=.004)	0.0176±0.0053	0.0324±0.0107 (d=0.627, p=.095)
			IV) Relaxed	0.0303±0.0090 (d=0.457, p=.315)	0.0609±0.0229* (d=0.862, p=.013)	0.0229±0.0069 (d=0.123, p=.965)	0.0207±0.0057
		CNN+Attention	I) Amused	0.0142±0.0050	0.0671±0.0230** (d=1.135, p<.001)	0.0322±0.0080** (d=0.968, p=.003)	0.0404±0.0140** (d=0.890, p=.009)
			II) Scared	0.0662±0.0165** (d=1.607, p<.001)	0.0119±0.0045	0.0617±0.0216** (d=1.139, p<.001)	0.0606±0.0240** (d=1.008, p=.003)
			III) Bored	0.0569±0.0121** (d=2.021, p<.001)	0.1226±0.0605** (d=0.966, p=.005)	0.0070±0.0031	0.0554±0.0233** (d=1.044, p=.002)
			IV) Relaxed	0.0503±0.0128** (d=1.591, p<.001)	0.0878±0.0332** (d=1.197, p<.001)	0.0418±0.0117** (d=1.376, p<.001)	0.0089±0.0032
PPGE	PPG	WT+RF	I) Joyous	0.0485±0.0141	0.1426±0.0723 (d=0.835, p=.105)	0.1708±0.0546** (d=1.417, p=.003)	0.1802±0.0780* (d=1.086, p=.025)
			II) Angry	0.1722±0.0491** (d=1.329, p=.004)	0.0636±0.0211	0.1570±0.0499* (d=1.127, p=.016)	0.1794±0.0633* (d=1.134, p=.020)
			III) Sad	0.1917±0.0677** (d=1.269, p=.096)	0.1541±0.0733 (d=0.851, p=.096)	0.0564±0.0161	0.1897±0.0673** (d=1.259, p=.008)
			IV) Relaxed	0.1616±0.0554** (d=1.330, p=.005)	0.1879±0.0781* (d=1.179, p=.014)	0.1915±0.0506** (d=1.812, p<.001)	0.0438±0.0165
		CNN+LSTM	I) Joyous	0.0253±0.0117	0.0555±0.0256 (d=0.566, p=.374)	0.0809±0.0374 (d=0.920, p=.064)	0.1207±0.0558 (d=0.854, p=.096)
			II) Angry	0.0924±0.0590 (d=0.661, p=.171)	0.0311±0.0140	0.0687±0.0348 (d=0.655, p=.583)	0.0869±0.0381 (d=0.899, p=.242)
			III) Sad	0.0999±0.0500* (d=0.976, p=.048)	0.0670±0.0436 (d=0.633, p=.438)	0.0236±0.0100	0.0846±0.0386 (d=0.997, p=.157)
			IV) Relaxed	0.0972±0.0602 (d=0.856, p=.078)	0.0785±0.0425 (d=0.917, p=.250)	0.0910±0.0468 (d=1.009, p=.119)	0.0175±0.0089
		CNN+Attention	I) Joyous	0.0177±0.0069	0.0433±0.0268 (d=0.601, p=.325)	0.0642±0.0333 (d=0.893, p=.077)	0.0950±0.0518 (d=0.967, p=.051)
			II) Angry	0.0553±0.0238* (d=0.980, p=.041)	0.0163±0.0105	0.0655±0.0309* (d=0.987, p=.042)	0.1241±0.0716* (d=0.973, p=.049)
			III) Sad	0.0798±0.0506 (d=0.837, p=.161)	0.0584±0.0447 (d=0.637, p=.491)	0.0142±0.0081	0.0913±0.0491 (d=1.013, p=.072)
			IV) Relaxed	0.0939±0.0538* (d=1.014, p=.039)	0.0768±0.0430* (d=1.006, p=.041)	0.0881±0.0507* (d=1.001, p=.042)	0.0099±0.0062

A.2　我々の先行研究と本研究の比較

表 A·2 に我々の先行研究 [5] と本研究を，実験条件や評価方法等の観点から比較した結果を示す．

表 A·2: 我々の先行研究と本研究の比較
Table A·2 Comparison of our works.

研究	データセット	認証モデル	特徴量の評価	認証精度の評価方法 評価指標	認証精度の評価方法 比較手法	認証精度と感情の関係の定量的分析	対策
先行研究 [5]	CASE [6]	WT+RF, CNN+LSTM	なし	EER	分散分析, 多重比較検定	なし	検討
本研究	CASE [6], **PPGE [7]**	WT+RF, CNN+LSTM, **CNN+Attention**	**あり**	EER, **$\mathbf{F1_{measure}}$, AUC**	分散分析, 多重比較検定, **効果量算出**	**あり (回帰分析)**	検討, **評価**

© 2026 Information Processing Society of Japan