自由文キーストローク収集のためのプライバシー配慮型LLM会話設計

山口 修司[1,2,a)]　五味 秀仁[1,b)]　Rao Jingjing[3,c)]　上原 哲太郎[3,d)]

概要：自由文キーストロークは継続認証に有用である一方，入力内容に個人情報やセンシティブ情報が混入しうる．本研究では，大規模言語モデル（LLM）との低リスクな日常会話を通じて自由文キーストロークを収集する方式を提案する．低リスク話題，答えやすい質問設計，1 ターン 1 質問および言語切替を制約し，打鍵量とプライバシーへの配慮を両立する．プロンプト監査に基づいてモデルを選定し，53 名，159 セッションの実験を行った．10 分間のログから 200-keydown 窓を 890 個生成でき，PC 間認証では AUC 0.935，EER 0.143 を得た．アンケートではプライバシー不安の少なさが高く評価された一方，会話の単調さが課題となった．以上から，制約付き LLM 会話が自由文キーストローク収集に有用であることを示す．

キーワード：キーストロークダイナミクス，自由文入力，大規模言語モデル，認証

Privacy-Aware LLM Conversation Design for Free-Text Keystroke Collection

Shuji Yamaguchi[1,2,a)]　Hidehito Gomi[1,b)]　Rao Jingjing[3,c)]　Tetsutaro Uehara[3,d)]

Abstract: Free-text keystrokes are useful for continuous authentication, but their collection may capture personal or sensitive information. We propose a privacy-aware collection method based on low-risk everyday conversations with a large language model (LLM). The method constrains topics, the number and form of questions, and language switching to balance typing volume with privacy. We selected an LLM through a prompt audit and conducted a study with 53 participants and 159 sessions. Ten-minute logs yielded 890 non-overlapping 200-keydown windows; PC-to-PC authentication achieved an AUC of 0.935 and an EER of 0.143. Participants reported low privacy concern, while conversational monotony remained an issue. These results demonstrate the feasibility of constrained LLM conversation as a free-text keystroke collection task.

Keywords: Keystroke Dynamics, Free-Text Input, Large Language Models, User Authentication

1. はじめに

キーストロークダイナミクスは，ユーザの打鍵時間や打鍵間隔などの時系列的特徴に基づいて本人性を推定する行動的バイオメトリクスであり，認証，個人識別，継続認証などの文脈で研究されてきた [1], [2], [3]．この手法は通常のキーボードから信号を取得でき，専用の生体センサや明示的な追加操作を必要としないため，低コストかつ非侵襲的な認証手段となりうる [3], [4]．近年では，固定パスワード入力だけでなく，利用中の自由文入力を用いる継続認証も研究されている [5], [6]．

一方，自由文キーストロークデータの収集では，入力内容と打鍵量の双方を考慮する必要がある．自由文は固定文より自然な入力を観測できる反面，入力内容そのものを記録する場合には個人情報やセンシティブ情報を取得する可

[1] LINE ヤフー株式会社, LY Corporation
[2] 立命館大学 情報理工学研究科, Graduate School of Information Science and Engineering, Ritsumeikan University
[3] 立命館大学 情報理工学部, College of Information Science and Engineering, Ritsumeikan University
[a)] shyamagu@lycorp.co.jp
[b)] hgomi@lycorp.co.jp
[c)] raojingjing@cysec.cs.ritsumei.ac.jp
[d)] t-uehara@fc.ritsumei.ac.jp

© 2026 Information Processing Society of Japan

This paper is work in progress and not peer-reviewed.

能性がある．また，短い回答から得られる打鍵イベントは限られるため，認証性能を評価できる量の入力を確保する必要がある [5]．しかし，長い回答を促すために過度に個人的な質問を用いれば，参加者の自己開示とプライバシーに関する懸念が大きくなりうる [7]．本研究ではプライバシー配慮を，個人を識別しうる情報や健康，政治，宗教，金銭等のセンシティブ情報を不必要に質問・誘導せず，収集範囲を研究目的に必要な項目へ限定することと操作的に定義する．したがって，自由文から有用なキーストローク信号を得るには，打鍵量の確保と質問内容の低リスク性を両立する収集設計が必要である．

チャット形式は，自由文入力を継続的に得るための一つの方法である．既存研究では，人同士のチャット中の打鍵から年齢や属性に関係する特徴を抽出できる可能性が示されている [8], [9]．一方，本研究が対象とする「質問内容を低リスクな範囲に制限しながら，一定量の自由文を収集する」という会話ポリシー自体は，これらの研究では検討されていない．

ここで，大規模言語モデル（LLM）を対話相手として用いれば，話題範囲，質問形式，言語設定などをシステム側のポリシーとして定義できる．ただし，長い回答だけを目的にすると複雑な質問や不必要な自己開示を促す可能性があり，安全性だけを優先すると短答が増える可能性がある．したがって，LLM を用いたキーストローク収集では，「自然な会話」「十分な打鍵量」「低リスク性」を同時に考慮した会話設計が課題となる．

本研究では，LLM を対話相手として用いる自由文キーストローク収集方式を提案する．提案方式では，対話を低リスクな日常話題に限定し，一言では終わりにくい一方で深く考え込まず答えられる質問を優先する．また，1 ターンにつき質問は 1 つのみとし，既定言語からの切替は利用者が明示的に希望した場合に限る．入力言語は認証性能に影響しうるためである [10]．さらに，LLM 推論を所属機関が管理するサーバ内で完結させ，外部の生成 AI API へ会話内容や打鍵ログを送信しない．本研究の主眼は LLM 自体の性能評価ではなく，低リスクな会話制御を設計し，プロンプト監査，実参加者による収集量と主観評価，公開データセットとの比較，下流の本人認証評価までを一貫して行う点にある．

本研究の貢献は以下の 3 点である．

- 低リスク話題と 1 ターン 1 質問を核とする LLM 会話型収集方式を設計した．
- 53 名・159 セッションの実験により，打鍵量，主観的安全性，会話品質を評価した．
- 得られた自由文キーストロークが PC 間の本人認証に利用できることを示した．

2. 関連研究

2.1 キーストロークダイナミクスと自由文認証

キーストロークダイナミクスは，打鍵時間や打鍵間隔に基づく行動的バイオメトリクスとして研究されてきた [2]．サーベイでは，固定文，自由文の設定，特徴量，分類手法，評価方法などが整理されている [3]．自由文を対象とする研究として，長文データを用いた認証 [5] や CNN と RNN を用いた継続認証 [6] が報告されている．

2.2 データセットと自然環境での収集

この分野ではデータセット整備が進められてきた．代表例として，固定パスワードを反復入力する CMU データセット [11]，GREYC ベンチマーク [12]，固定文と自由文を含む Clarkson 共有データセット [13] がある．本研究の比較対象である Aalto 136M はオンライン転記課題から物理キーボードの打鍵を収集しており [14]，HMOG はスマートフォン上の文章入力等からキー・タッチ・センサ情報を収集している [15]．また，大規模なモバイル入力行動も調査されている [16]．これらは入力課題やデバイスの異なる打鍵行動を提供するが，本研究が扱う LLM との低リスクな会話を通じた自由文収集とは目的が異なる．

2.3 チャット環境・会話環境での打鍵収集

自由文入力を得る環境として，チャットを利用した研究がある．Brekke と Bours は参加者同士のチャットから年齢を継続的に推定し [8]，Buker らはライブチャットの打鍵特徴から属性や自己評価式パーソナリティ特性を推定した [9], [17]．これらはチャット中の自由入力を行動分析に利用できることを示しているが，低リスクな質問の生成や回答長の誘導を目的とする会話制御は研究対象としていない．

2.4 チャットボット・プライバシー配慮型対話設計

会話エージェントの設計は自己開示やプライバシー懸念に影響しうる．Buckley らはチャットボットを介したセンシティブな情報開示を検討し [18]，Warren-Smith らはエージェントの提示条件が自己開示に及ぼす影響を調べている [19]．また，Papneja と Yadav は会話 AI への自己開示に影響する要因を，Gumusel は会話型チャットボットに関する利用者のプライバシー懸念をレビューしている [7], [20]．

一方，LLM 支援による文章作成を打鍵から検出する研究 [21] や，若者と AI チャットボットの自然な対話を端末上の入力観測から分析した研究 [22] は現れ始めている．ただし，これらはそれぞれ不正行為検出と AI チャットボット利用実態の分析を目的としており，低リスクな複数文回答を継続的に促すキーストローク収集ポリシーの設計・評価を主目的とはしていない．

© 2026 Information Processing Society of Japan

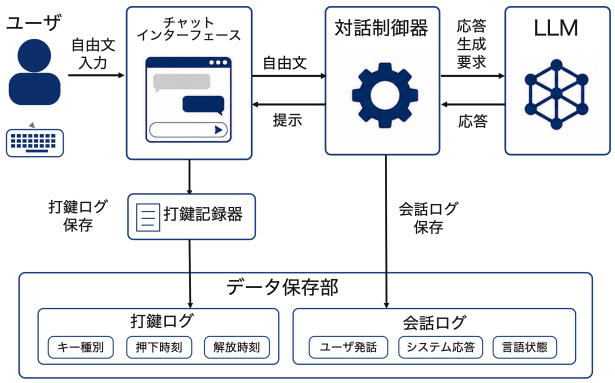


図 1 LLM ベース会話型キーストローク収集基盤の概要

3. 提案手法

本研究の提案手法は，LLM の汎用対話能力そのものを評価対象とするのではなく，キーストロークデータ収集に適した会話を生成するための制約付き対話エンジンとして LLM を利用するものである．提案方式の目的は，自然な自由文入力を継続的に引き出しつつ，入力内容に個人情報やセンシティブ情報が含まれるリスクを抑え，かつキーストロークダイナミクス分析に十分な打鍵量を確保することである．この目的のために，本研究では，会話ポリシー，言語制御，およびログ収集機構を組み合わせた会話型収集基盤を設計する．

3.1 システム概要

図 1 に提案システムの全体構成を示す．本システムは，チャットインタフェース，打鍵記録器，対話制御器，LLM，データ保存部から構成される．チャットインタフェースはユーザのメッセージを対話制御器へ渡すと同時に，入力中のキーイベントを打鍵記録器へ渡す．対話制御器は会話履歴と言語状態を保持して LLM に応答生成を依頼し，生成された応答を画面に提示する．

保存処理は LLM ではなくアプリケーション側が担う．打鍵記録器はキーイベント列を，対話制御器はユーザ発話，LLM 応答，言語状態等を保存し，両者をターン単位で対応付ける．応答生成には所属機関が管理する推論サーバ上の LLM を用い，外部事業者の生成 AI API へ会話内容や打鍵ログを送信しない．これにより，外部事業者へのデータ送信を避ける．

3.2 会話ポリシー設計

提案手法の中心は，会話ポリシーの設計である．本研究では，自然さ，十分な打鍵量，低リスク性の三要件を両立するために，LLM の発話に対して複数の制約を課す．第一に，話題制約として，会話内容を低リスクな日常話題に限定する．具体的には，一般的な食べ物，天気，公共空間，日用品，簡単な想像場面，比較しやすい身近な対象などを主な対象とし，名前，住所，電話番号，学校名，勤務先，家族関係，健康状態，政治的信条，宗教，財務情報などに結びつく問いを禁止する．第二に，ターン構造制約として，1 ターンにつき質問は 1 つに限定し，複数の質問を同時に提示しない．これにより，認知負荷を抑え，回答しやすさを維持する．第三に，質問設計方針として，一言では終わりにくいが深く考え込まなくてよい問いを用い，比較，軽い理由，意見，身近な未来予想で答えられる問いを優先する．専門知識を要する問い，抽象的または重い問い，実体験の詳細な開示を求める問いは避ける．第四に，短答への追従方針として，ユーザの返答が短い場合は，同一話題のまま具体的で答えやすい補足質問を 1 つだけ返す．これにより，短い返答を自然に延ばしつつ，会話が尋問的になることを避ける．

3.3 言語制御

自由文入力のキーストローク特徴は，入力言語に依存して変化しうるため，本研究では会話言語の制御を明示的に行う．提案方式では，初期状態では既定言語を日本語に固定する．ユーザが “English please” や「英語で」のように明示的に言語変更を要求した場合のみ，その言語へ切り替える．一度切り替えた後は，ユーザが再度明示的に変更を要求するまで，同一言語を維持する．システム側が文脈に応じて自動的に言語を切り替えることは行わない．この方針により，入力条件の一貫性を保ちつつ，ユーザの明示的な希望には対応できる．

3.4 キーストロークログ収集

提案システムは，キーの押下・解放時刻と編集操作を含むキーイベント列，およびユーザと LLM の発話を記録する．打鍵ログと会話ログは分離して保存し，参加者 ID とターン番号で対応付ける．

3.5 特徴量化の前提

本研究の主眼は，LLM を用いた会話型収集基盤の設計にあるため，特徴量抽出および認証モデル自体は既存のキーストロークダイナミクス研究で広く用いられている枠組みを前提とする．具体的には，キー押下時間，キー間遷移時間，2 キー組の遅延時間，n キー系列特徴，修正操作頻度，ターン単位の休止時間統計などを基本特徴とし，必要に応じて古典的分類器または深層系列モデルへ入力することを想定する．ここで重要なのは，提案方式が，このような標準的特徴量を抽出可能なだけの十分量かつ低リスクな自由文データを，通常の会話に近い形で継続的に取得することを狙っている点である．

4. 実験 1：プロンプト監査とモデル選定

参加者実験で用いる LLM とプロンプトを選定するため，

© 2026 Information Processing Society of Japan

ベースライン条件，提案方式から 1 ターン 1 質問制約を除いた制約除去条件，提案条件の 3 条件を比較した．低リスク話題，短答，話題切れ，言語切替，個人情報・センシティブ話題への言及を含む評価ケースを各条件 5 回実行し，Gemma 4 E2B, Gemma 4 E4B, Qwen3-4B-Instruct-2507, gpt-oss-20b を評価した．プロンプト監査には vLLM 0.20.2 を用いた．gpt-oss-20b は推論強度設定（reasoning_effort）を low, 最大トークン数（max_tokens）を 2048 とした．サーバ環境の詳細は付録 A.1.3 に示す．

指標は平均質問数，複数質問率，高リスク質問率，言語逸脱率，方針違反率および応答時間である．方針違反は，複数質問，高リスク質問，言語逸脱，メタ発話，複雑応答，エラーまたは空出力の発生と定義した．有意差は評価ケース単位のクラスタブートストラップで検定し，Holm–Bonferroni 法で補正した（補正後 $p < 0.05$）．詳細な指標定義とプロンプトは付録に示す．

4.1 プロンプト条件ごとの結果

図 2 に，各プロンプト条件における主要な監査指標を示す．図中の B，A，P はそれぞれ，ベースライン条件，質問数制約なし条件，提案条件を表す．なお，言語逸脱率はいずれの条件でも 0.000 であったため省略した．

多くのモデルにおいて，提案条件ではベースライン条件よりも方針違反率が低下した．特に Gemma 4 E2B では，方針違反率が 0.917 から 0.150 に有意に低下し，複数質問率も 0.917 から 0.133 に有意に低下した．Gemma 4 E4B および gpt-oss-20b でも，方針違反率および複数質問率は有意に低下した．一方，Qwen3-4B-Instruct でも方針違反率は 0.850 から 0.583 に低下したが，多重比較補正後には有意差は認められなかった．

また，gpt-oss-20b では，提案条件において高リスク質問率が 0.000 となり，明示的な個人情報要求やセンシティブ情報の質問は観察されなかった．ただし，高リスク質問率については発生数が少なく，いずれのモデルでもベースライン条件との差は有意ではなかった．

一方で，複数質問率にはモデル差が見られた．複数質問率は，Gemma 4 E2B では 0.133 であったのに対し，Gemma 4 E4B では 0.433，Qwen3-4B-Instruct では 0.583，gpt-oss-20b では 0.367 であった．提案条件における同制約の遵守率はモデルごとに異なった．

なお，本評価における複数質問率は，疑問形の文が 2 文以上含まれる場合を違反とする保守的な指標である．そのため，「話題を変えてみましょうか」のような前置き質問も計上される．この指標はプライバシー上重大な違反ではなく，会話構造上の違反として解釈する．

4.2 モデル選定

図 3 に提案条件でのモデル選定結果を示す．Gemma 4 E2B は，方針違反率が 0.150 と最小で，平均応答時間 499.8 ms，95 パーセンタイル 850.2 ms も最短であった．重大違反率は 0.017 であり，プロンプト追従性と応答速度のバランスから参加者実験に採用した．

5. 実験 2：収集データセットの特性評価

本実験では，実験 1 で選定したモデルとプロンプトを用いて収集した実参加者ログを分析し，LLM との日常会話により得られる自由文キーストロークデータが，後続の認証性能評価に利用可能な入力量と特徴量を備えているかを評価する．本実験の目的は，デバイス間の有意差を主張することではなく，収集されたデータが固定長 keydown 窓に基づく自由文キーストローク分析および認証向け特徴抽出に利用可能であることを確認する点にある．

また，LLM との自然会話を用いた収集では，客観的に十分な入力量が得られるだけでなく，参加者が過度なプライバシー不安や負担を感じずに入力を継続できることも重要である．そこで，入力文字数，keydown 数，固定長窓数に加えて，参加者アンケートによる主観評価も分析する．

5.1 分析対象データ

分析対象は，実験アプリにより収集された前処理済みデータである．53 名の参加者から，各 3 条件，計 159 セッションのログを得た．各参加者は，研究室 PC 条件（Lab_PC），自身の PC 条件（My_PC），自身のスマートフォン条件（My_SP）の 3 条件を持つ．条件間で分析時間を揃えるため，各セッションでは先頭 10 分を上限として分析対象とした．

収集データは，キーイベントと会話ログから構成される．キーイベントから打鍵数，編集操作，押下時間，キー間遷移時間および固定長窓を，会話ログから発話数と入力文字数を算出した．

5.2 参加者と実施手順

2026 年 6 月と 7 月の 2 期に，立命館大学の学生向け Web 掲示板で，大阪いばらきキャンパスに所属する学生を募集した．参加者 53 名は全員が 3 条件に参加し，謝礼として Amazon ギフトカード 1,500 円分を受け取った．実験は説明を含め約 45 分で，各条件の会話時間は 10 分とした．3 条件は全参加者について My_PC，Lab_PC，My_SP の固定順で実施した．Lab_PC では Windows，Microsoft Edge，日本語配列キーボードを備えた研究室 PC を，My_PC と My_SP では参加者自身の端末を用いた．いずれも同一の Web アプリ上で LLM と自由に会話し，推論には LiteRT-LM を用いた．サーバ環境は付録 A.1.3 に示す．実験終了後に会話の答えやすさ，自然さ，継続しやすさ，プライバシー不安等を 5 件法で尋ねた．参加者は 18–22 歳が 49 名（92.5%）を占めた．詳細な属性は付録 A.1.5 に示す．

© 2026 Information Processing Society of Japan

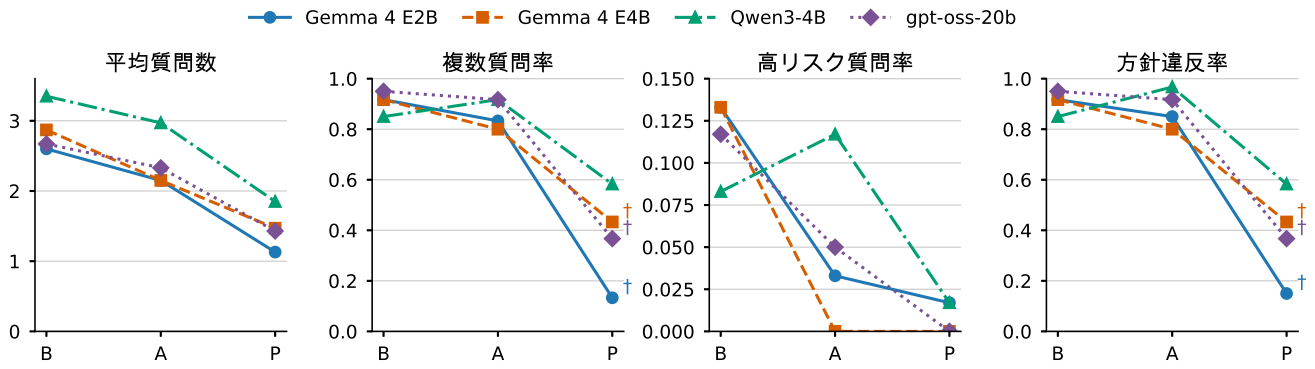


図 2　各プロンプト条件における主要なプロンプト監査指標．B，A，P はそれぞれベースライン条件，質問数制約なし条件，提案条件を表す．† はベースライン条件と提案条件の有意差あり．詳細値は付録 A.1.1 に示す．

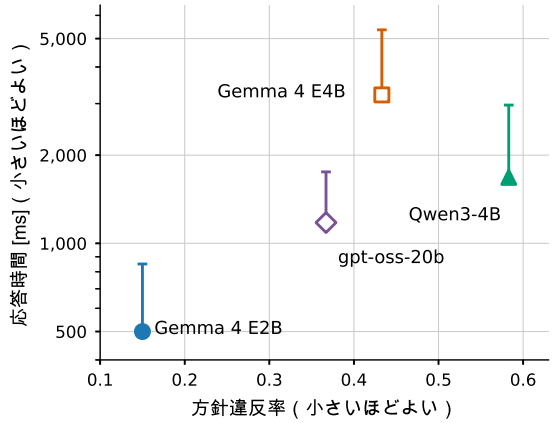


図 3　提案条件におけるモデル選定結果．各記号は平均応答時間，上端の横線は 95 パーセンタイルを示す．詳細値と有意差は付録 A.1.2 に示す．

5.3　収集データセットの規模

収集データセットの規模を付録 A.1.4 の表 A·4 に示す．全体で 105,835 文字のユーザ入力，192,910 件の keydown イベント，471,429 件のキーイベントが得られた．また，200-keydown 窓は合計 890 個生成可能であり，1 セッションあたりの中央値は 5 であった．

5.4　固定長 keydown 窓による十分性評価

本研究では，収集量の十分性を，後続の認証性能評価に用いる固定長 keydown 窓を生成できるかという観点から評価した．自由文キーストローク認証では，打鍵列を固定長系列に分割して評価する方法が用いられている [6]．本研究では 100，200，300-keydown 窓を集計し，入力量と 1 セッションから得られる窓数のバランスを考慮して，後続の主評価には中間の 200-keydown 窓を用いた．1 つの 200-keydown 窓を生成するには少なくとも 200 件の keydown イベントが必要である．そのため，1 セッションから複数の 200-keydown 窓を生成できるかは，自由文キーストローク分析における特徴量抽出および認証評価の実施可能性を示す指標となる．

表 1　公開データセットとの 200-keydown 窓生成可能性比較

データ	入力	生成可能率	窓数中央値／サンプル	総窓数
本研究	LLM 会話	98.7%	5	890
Aalto 136M	転記	100%	3	489
HMOG	スマホ課題	100%	5	828

キー数，編集操作，キー押下時間，キー間遷移時間，連続押下間隔は全 159 セッションで算出できた．非重複の 100，200，300-keydown 窓は，それぞれ 158，157，155 セッション（99.4%，98.7%，97.5%）で生成できた．

5.5　公開データセットとの比較

本研究データが既存データセットと同じ分析単位に対応できるかを確認するため，PC の物理キーボードで転記入力を収集した Aalto 136M [14] と，スマートフォン上で課題入力を収集した HMOG [15] に同じ非重複窓化処理を適用した．比較数を揃えるため，各公開データセットから本研究と同数の 159 サンプルを抽出した．同一参加者からは最大 3 サンプルとし，先頭 10 分を用いた．表 1 に 200-keydown 窓の生成可能性を示す．生成可能率は 1 つ以上の窓を生成できたサンプルの割合，窓数中央値は 1 サンプル当たりに生成できた窓数の中央値である．

本研究データの生成可能率は 98.7%，1 サンプル当たりの窓数中央値は 5 であった．Aalto 136M ではそれぞれ 100% と 3，HMOG では 100%と 5 であった．

5.6　参加者アンケートによる主観評価

LLM との自然会話を用いたキーストローク収集では，客観的に十分な入力量が得られるだけでなく，参加者が会話を続けやすく，過度なプライバシー不安を感じないことも重要である．そこで，実験終了後に参加者アンケートを実施し，会話の理解しやすさ，質問の答えやすさ，長めの入力のしやすさ，入力継続のしやすさ，話題の安心感，プライバシー不安，返答速度，および自由文入力データ収集方

© 2026 Information Processing Society of Japan

表 2 参加者アンケートの主要結果（全項目は付録 A.1.6）

項目	平均	中央値	肯定率	否定率
単調すぎるとは感じなかった	2.30	2	17.0%	66.0%
会話の流れは自然だった	2.81	3	30.2%	47.2%
少し長めに入力しようと思えた	3.70	4	62.3%	22.6%
話題は安心して答えられた	4.08	4	79.2%	13.2%
プライバシー不安は少なかった	4.49	5	88.7%	3.8%
自由文入力データ収集に適している	3.81	4	64.2%	15.1%

式としての適性を 5 段階で評価した．回答 53 件である．表 2 にアンケート結果を示す．ここで，肯定率は 4 または 5，否定率は 1 または 2 を選択した回答の割合である．

「会話の話題は安心して答えられる内容だった」の肯定率は 79.2%，「個人情報やプライバシーに関わる不安は少なかった」の肯定率は 88.7%であった．「ある程度まとまった文章を入力しやすかった」および「一言だけで終わるより，少し長めに入力しようと思えた」の肯定率がいずれも 62.3%であった．「AI の返答や話題の進め方は単調すぎるとは感じなかった」の肯定率は 17.0%，否定率は 66.0%であり，「会話の流れは概ね自然だった」の肯定率も 30.2%にとどまった．自由記述でも，同じ質問の繰り返し，話題転換の強引さ，ユーザの回答内容を十分に反映しない応答，質問ばかりで会話として不自然であることが指摘された．

6. 実験 3：本人認証性能評価

実験 2 では，LLM との 10 分間の自然会話から，後続の認証性能評価に利用可能な数の固定長 keydown 窓を生成できることを確認した．本実験では，実験 2 で得られた固定長 keydown 窓を用いて，本人認証性能を評価する．目的は，LLM 自然会話由来の自由文キーストロークデータに，実際に本人認証に利用可能な行動的特徴が含まれているかを検証することである．

本実験では，主評価として 200-keydown の非重複窓を用いた．各窓から，キー押下時間，キー間遷移時間，連続押下間隔，キー別特徴量，2 キー組特徴量を抽出し，複数の機械学習モデルにより本人認証性能を評価した．評価指標には AUC および EER を用いた．AUC は本人スコアと他人スコアの分離性能を表し，EER は本人拒否率と他人受入率が等しくなる点の誤り率を表す．AUC が高く，EER が低いほど，本人認証性能が高いことを意味する．

6.1 評価データ

実験 3 では，実験 2 と同じ前処理済みデータを用いた．各セッションについて，分析対象は先頭 10 分間に限定した．対象条件は，研究室 PC 条件（Lab_PC），自身の PC 条件（My_PC），自身のスマートフォン条件（My_SP）の 3 条件である．

各セッションから，200-keydown を 1 単位とする非重複窓を生成した．Lab_PC では 333 個，My_PC では 337 個，My_SP では 220 個の 200-keydown 窓が得られた．PC 条件では各セッションあたり中央値 6 個，スマートフォン条件では中央値 4 個の窓が生成可能であった．利用可能セッション数を含む条件別内訳は付録 A.1.7 に示す．

6.2 特徴量

各窓から，全体的な打鍵・編集・時間統計（35 次元），頻出 30 キーの押下時間（90 次元），頻出する 50 種類の 2 キー組における連続押下間隔（100 次元）を抽出し，これらを結合した最大 225 次元の特徴量を用いた．これらは代表的特徴であり，自由文認証でも先行研究で用いられている [23]．キーおよび 2 キー組の集合は訓練データのみから構築し，欠損値も訓練データの中央値で補完した．認証方式には，各参加者の訓練特徴量の平均ベクトルを登録テンプレートとし，評価窓とのコサイン類似度を本人スコアとする単純な基準方式（以下，コサイン類似度）と，キーストローク分類への適用例があるロジスティック回帰およびランダムフォレストを用いた [24]．

評価は，(1) 同一セッション内の窓分割による上限評価，(2)Lab_PC から My_PC への PC 間転移，(3)2 条件で学習して残る 1 条件で評価する 1 デバイス除外評価，(4)2 種類の PC からスマートフォンへの転移，の 4 条件とした．各評価窓について全参加者を照合対象利用者とするスコアを生成し，AUC と EER を算出した．条件間評価には全条件で窓を生成できた 52 名を，同一セッション内評価には My_PC の 53 名を用いた．95%信頼区間は参加者単位のブートストラップ法で求めた．詳細は付録 A.1.8 に示す．

6.3 結果

表 3 に，200-keydown 窓と全特徴量を用いた各評価条件の最良結果を示す．本評価は認証方式の優劣ではなく，収集データに本人照合へ利用可能な特徴が含まれるかを確認することを目的とする．3 方式の全結果は付録 A.1.7 に示す．同一セッション内の上限評価では AUC 0.998，EER 0.030，PC 間転移では AUC 0.935，EER 0.143 であった．PC からスマートフォンへの転移では AUC 0.527，EER 0.472，評価先を Lab_PC とした 1 デバイス除外評価では AUC 0.919，EER 0.165 であった．

7. 考察

7.1 LLM 会話による自由文収集

10 分間の会話から 890 個の 200-keydown 窓が得られ，157/159 セッションで少なくとも 1 窓を生成できた．生成可能率と窓数中央値は Aalto 136M および HMOG と同程度であり，固定文や転記を課さなくても，ほぼ全参加者・条件から認証分析の単位となる量を収集できたことを示す．LLM は回答内容を固定せずに次の入力機会を提示できるため，自由文性を保ちながら一定時間入力を継続させるタスク生成器として機能したと考えられる．

© 2026 Information Processing Society of Japan

表 3　実験 3 における本人認証性能

評価条件	学習条件	評価条件	認証方式	AUC [95% CI]	EER [95% CI]
PC 間転移	Lab_PC	My_PC	ロジスティック回帰	0.935 [0.896,0.971]	0.143 [0.089,0.198]
PC–スマートフォン間転移	Lab_PC, My_PC	My_SP	コサイン類似度	0.527 [0.440,0.619]	0.472 [0.383,0.536]
1 デバイス除外	My_PC, My_SP	Lab_PC	ロジスティック回帰	0.919 [0.890,0.949]	0.165 [0.121,0.200]
同一セッション内	My_PC	My_PC	ランダムフォレスト	0.998 [0.996,0.999]	0.030 [0.015,0.034]

7.2　プライバシー配慮と会話品質のトレードオフ

話題の安心感の肯定率は 79.2%，プライバシー不安の少なさは 88.7%であり，低リスク話題と質問制約は参加者の主観的不安を抑える方向に働いた．また，推論を所属機関管理サーバ内で完結させ，外部生成 AI API へ会話内容や打鍵ログを送信しない構成により，外部事業者へのデータ送信を避けられた．一方，本研究では会話ログに含まれるセンシティブ情報の量や，保存方法に対する参加者の受容性を個別には評価していない．これは LLM 会話型収集に固有の新しい調査対象であり，今後は質問側の監査に加えて回答内容の分類，保存範囲・期間の違いによる受容性比較を行うことで，収集量を保ちながら参加者が安心できるデータ管理方法を明らかにしたい．

一方，会話の非単調性の肯定率は 17.0%，自然さは 30.2%にとどまり，同じ質問の繰り返しや唐突な話題転換が収集体験上の課題となった．これは，1 ターン 1 質問と低リスク話題への限定に加え，既出質問や会話文脈を十分に管理していなかったことが原因と考えられる．既出質問の抑制，発話内容を踏まえた応答，段階的な話題遷移をプロンプト外の制御として加え，より高性能な LLM と組み合わせることで，自然さと楽しさを改善したい．会話品質の向上が 1 回の実施で得られるキーストローク量の増加につながると考えられる．

7.3　収集量と本人照合性能の関係

PC 間評価で AUC 0.935，EER 0.143 を得たことから，収集データは窓数を満たすだけでなく，異なる PC 間でも本人照合に利用可能な特徴を含むことが示された．AUC は本人スコアと他人スコアの順位分離，EER は共通閾値での本人拒否率と他人受入率の均衡点を表すため，本結果は自由文会話から得た打鍵特徴の照合可能性を示している．今後は，利用場面に応じた閾値を独立データで決定し，実際の本人受入率と他人受入率を評価することで，照合可能性から運用可能性へ検証を進めたい．

同一セッション内評価では AUC 0.998，EER 0.030 となり，同じ 10 分間の中には強い本人固有信号が含まれることを確認できた．一方，学習窓と評価窓は端末，姿勢，当日の打鍵状態，会話課題を共有しており，この高性能のうち本人差とセッション固有差がそれぞれどの程度を占めるかは分離できていない．複数日に同じ参加者から収集し，日をまたいで登録・評価することで，本人固有信号の長期安定性とセッション差の影響を明らかにしたい．

7.4　PC とスマートフォンの差

PC からスマートフォンへの転移は AUC 0.527，EER 0.472 にとどまり，異種デバイス間で同じ特徴量を直接転移できないことが明らかになった．主な原因は，物理キーボードとソフトウェアキーボードで，押下・解放イベント，IME，入力姿勢，ブラウザイベントの発生方法が異なることだと考えられる．今後は，PC とスマートフォンを別々にモデル化した場合を基準とし，スマートフォン向けのタッチ時間・キー遷移特徴やデバイス適応を段階的に加えることで，どの差が性能低下を生むかを検証したい．

7.5　参加者実験の一般化可能性

本研究の参加者は単一キャンパスで募集した 53 名であり，18–22 歳が 92.5%を占めた．したがって，年齢，職業，言語，入力経験の異なる集団でも，同程度の収集量，主観評価および照合性能が得られるかは明らかでない．また，各条件は 1 人 1 セッションであり，日をまたいだ打鍵特徴の安定性も評価していない．

3 条件は全参加者について My_PC，Lab_PC，My_SP の固定順で実施したため，後の条件における慣れ，疲労，会話への飽きとデバイス差を分離できない．今後の参加者実験では，年齢や入力経験の異なる参加者を含め，条件順を調整するとともに複数日にわたって収集する必要がある．

8.　研究倫理

本研究は，所属機関の研究倫理規程および「サイバーセキュリティ研究倫理に関するチェックリスト」[*1]を確認し，これらに則って計画・実施した．実験参加者には研究目的，記録項目，利用目的および中断の自由を説明し，同意を得た．また，実験参加者のプライバシーには十分に配慮し，センシティブ情報等の入力を求めない設計とした．

9.　結論

本研究では，低リスク話題と 1 ターン 1 質問を核とする LLM 会話型の自由文キーストローク収集方式を提案した．53 名・159 セッションの評価により，プライバシー不安を抑えながら認証分析に必要な打鍵量を収集でき，PC 間認証にも利用できることを示した．一方，会話の単調さとスマートフォンへの転移は課題として残った．以上から，制約付き LLM 会話は自由文キーストロークの収集手段として有望である．

[*1] https://www.iwsec.org/csec/ethics/checklist.html

© 2026 Information Processing Society of Japan

参考文献

[1] Monrose, F. and Rubin, A.: Authentication via Keystroke Dynamics, *Proceedings of the 4th ACM Conference on Computer and Communications Security*, pp. 48–56 (online), DOI: 10.1145/266420.266434 (1997).

[2] Gunetti, D. and Picardi, C.: Keystroke Analysis of Free Text, *ACM Transactions on Information and System Security*, Vol. 8, No. 3, pp. 312–347 (online), DOI: 10.1145/1085126.1085129 (2005).

[3] Shadman, R., Wahab, A. A., Manno, M., Lukaszewski, M., Hou, D. and Hussain, F.: Keystroke Dynamics: Concepts, Techniques, and Applications, *ACM Computing Surveys*, Vol. 57, No. 11, pp. 1–35 (online), DOI: 10.1145/3733103 (2025).

[4] Teh, P. S., Teoh, A. B. J. and Yue, S.: A Survey of Keystroke Dynamics Biometrics, *The Scientific World Journal*, Vol. 2013, p. 408280 (online), DOI: 10.1155/2013/408280 (2013).

[5] Çeker, H. and Upadhyaya, S.: User Authentication with Keystroke Dynamics in Long-Text Data, *2016 IEEE 8th International Conference on Biometrics Theory, Applications and Systems*, pp. 1–6 (online), DOI: 10.1109/BTAS.2016.7791182 (2016).

[6] Lu, X., Zhang, S., Hui, P. and Lio, P.: Continuous Authentication by Free-Text Keystroke Based on CNN and RNN, *Computers & Security*, Vol. 96, p. 101861 (online), DOI: 10.1016/j.cose.2020.101861 (2020).

[7] Papneja, H. and Yadav, N.: Self-Disclosure to Conversational AI: A Literature Review, Emergent Framework, and Directions for Future Research, *Personal and Ubiquitous Computing*, Vol. 29, No. 2, pp. 119–151 (online), DOI: 10.1007/s00779-024-01823-7 (2024).

[8] Brekke, S. and Bours, P.: Continuous Age Detection Using Keystroke Dynamics, *Norsk IKT-konferanse for forskning og utdanning*, No. 3 (online), available from https://www.ntnu.no/ojs/index.php/nikt/article/view/6247 (2024).

[9] Buker, A. A. N., Roffo, G. and Vinciarelli, A.: Type Like a Man! Inferring Gender from Keystroke Dynamics in Live-Chats, *IEEE Intelligent Systems*, Vol. 34, No. 6, pp. 53–59 (online), DOI: 10.1109/MIS.2019.2948514 (2019).

[10] Altwaijry, N.: Authentication by Keystroke Dynamics: The Influence of Typing Language, *Applied Sciences*, Vol. 13, No. 20, p. 11478 (online), DOI: 10.3390/app132011478 (2023).

[11] Killourhy, K. S. and Maxion, R. A.: Comparing Anomaly-Detection Algorithms for Keystroke Dynamics, *2009 IEEE/IFIP International Conference on Dependable Systems and Networks*, pp. 125–134 (online), DOI: 10.1109/DSN.2009.5270346 (2009).

[12] Giot, R., El-Abed, M. and Rosenberger, C.: GREYC Keystroke: A Benchmark for Keystroke Dynamics Biometric Systems, *2009 IEEE 3rd International Conference on Biometrics: Theory, Applications, and Systems*, pp. 1–6 (online), DOI: 10.1109/BTAS.2009.5339051 (2009).

[13] Vural, E., Huang, J., Hou, D. and Schuckers, S.: Shared Research Dataset to Support Development of Keystroke Authentication, *2014 IEEE International Joint Conference on Biometrics*, pp. 1–8 (online), DOI: 10.1109/BTAS.2014.6996259 (2014).

[14] Dhakal, V., Feit, A. M., Kristensson, P. O. and Oulasvirta, A.: Observations on Typing from 136 Million Keystrokes, *Proceedings of the 2018 CHI Conference on Human Factors in Computing Systems*, pp. 1–12 (online), DOI: 10.1145/3173574.3174220 (2018).

[15] Yang, Q., Peng, G., Nguyen, D. T., Qi, X., Zhou, G., Sitová, Z., Gasti, P. and Balagani, K. S.: A Multimodal Data Set for Evaluating Continuous Authentication Performance in Smartphones, *Proceedings of the 12th ACM Conference on Embedded Network Sensor Systems*, pp. 358–359 (online), DOI: 10.1145/2668332.2668366 (2014).

[16] Palin, K., Feit, A. M., Kim, S., Kristensson, P. O. and Oulasvirta, A.: How Do People Type on Mobile Devices? Observations from a Study with 37,000 Volunteers, *Proceedings of the 21st International Conference on Human-Computer Interaction with Mobile Devices and Services*, pp. 1–12 (online), DOI: 10.1145/3338286.3340120 (2019).

[17] Buker, A. A. N. and Vinciarelli, A.: I Feel It in Your Fingers: Inference of Self-Assessed Personality Traits from Keystroke Dynamics in Dyadic Interactive Chats, *2021 9th International Conference on Affective Computing and Intelligent Interaction*, pp. 1–8 (online), DOI: 10.1109/ACII52823.2021.9597389 (2021).

[18] Buckley, O., Nurse, J. R. C., Wyer, N., Dawes, H., Hodges, D., Earl, S. and Saglam, R. B.: Sharing Secrets with Agents: Improving Sensitive Disclosures Using Chatbots, *HCI International 2021 – Posters*, Springer, pp. 400–407 (online), DOI: 10.1007/978-3-030-78642-7_54 (2021).

[19] Warren-Smith, G., Laban, G., Pacheco, E.-M. and Cross, E. S.: Knowledge Cues to Human Origins Facilitate Self-Disclosure During Interactions with Chatbots, *Computers in Human Behavior: Artificial Humans*, Vol. 5, p. 100174 (online), DOI: 10.1016/j.chbah.2025.100174 (2025).

[20] Gumusel, E.: A Literature Review of User Privacy Concerns in Conversational Chatbots: A Social Informatics Approach: An Annual Review of Information Science and Technology (ARIST) Paper, *Journal of the Association for Information Science and Technology*, Vol. 76, No. 1, pp. 121–154 (online), DOI: 10.1002/asi.24898 (2025).

[21] Mehta, A., Kumar, R., Singla, A., Bisht, K., Singla, Y. K. and Shah, R. R.: Detecting LLM-Assisted Academic Dishonesty using Keystroke Dynamics, *IEEE Transactions on Biometrics, Behavior, and Identity Science*, pp. 1–1 (online), DOI: 10.1109/TBIOM.2026.3683979 (2026).

[22] Maheux, A. J., Boeldt, D., Akre-Bhide, S., Flannery, J., Paige, A., Villella, G., Burnell, K., Telzer, E. H. and Kollins, S. H.: How US Youth Use AI Chatbots: Conversation Patterns From Naturalistic Keystroke Observations, *Journal of Medical Internet Research*, Vol. 28, p. e95819 (online), DOI: 10.2196/95819 (2026).

[23] Ahmed, A. A. and Traore, I.: Biometric Recognition Based on Free-Text Keystroke Dynamics, *IEEE Transactions on Cybernetics*, Vol. 44, No. 4, pp. 458–472 (online), DOI: 10.1109/TCYB.2013.2257745 (2014).

[24] Shabliy, N., Lupenko, S., Lutsyk, N., Yasniy, O. and Malyshevska, O.: Keystroke Dynamics Analysis Using Machine Learning Methods, *Applied Computer Science*, Vol. 17, No. 4, pp. 75–83 (online), DOI: 10.23743/acs-2021-30 (2021).

© 2026 Information Processing Society of Japan

付　　録

A.1　補足評価情報

A.1.1　プロンプト監査の詳細値

表 A·1　各プロンプト条件におけるプロンプト監査指標の詳細値

モデル	指標	B	A	P
E2B	平均質問数	2.60	2.15	1.13
	複数質問率	.917	.833	.133†
	高リスク率	.133	.033	.017
	方針違反率	.917	.850	.150†
E4B	平均質問数	2.87	2.15	1.47
	複数質問率	.917	.800	.433†
	高リスク率	.133	.000	.000
	方針違反率	.917	.800	.433†
Qwen	平均質問数	3.35	2.97	1.85
	複数質問率	.850	.917	.583
	高リスク率	.083	.117	.017
	方針違反率	.850	.967	.583
gpt	平均質問数	2.67	2.33	1.43
	複数質問率	.950	.917	.367†
	高リスク率	.117	.050	.000
	方針違反率	.950	.917	.367†

E2B：Gemma 4 E2B，E4B：Gemma 4 E4B，Qwen：Qwen3-4B-Instruct，gpt：gpt-oss-20b．† は B と P の差が Holm–Bonferroni 補正後に有意であることを示す．

A.1.2　モデル選定の詳細値

表 A·2　提案条件におけるモデル選定の詳細値

指標	E2B	E4B	Qwen	gpt
方針違反率	**.150**	.433†	.583†	.367
重大違反率	.017	**.000**	.017	**.000**
平均応答 [ms]	**499.8**	3211.5†	1679.7†	1177.4†
P95 [ms]	**850.2**	5356.8	2965.2	1753.7
平均出力文字数	37.5	66.1	89.7	52.7

† は E2B との差が Holm–Bonferroni 補正後に有意．

A.1.3　サーバ実験環境

表 A·3 に，参加者実験アプリとプロンプト監査を実行したサーバ環境を示す．

表 A·3　サーバ実験環境

項目	内容
OS	Ubuntu 24.04.4 LTS
CPU	AMD Ryzen 9 7945HX
メモリ	60 GiB
GPU	NVIDIA RTX 4000 SFF Ada Generation
GPU メモリ	20 GB
参加者実験アプリ	Python 3.12 ／ FastAPI ／ Uvicorn ／ Nginx
参加者実験の推論環境	LiteRT-LM
プロンプト監査環境	Python 3.12 ／ vLLM 0.20.2

A.1.4　収集データセットの詳細

表 A·4 に，収集データセットの規模を示す．

表 A·4　収集データセットの規模

項目	値
参加者数	53
セッション数	159
条件数	3
ユーザ入力文字数	105,835
keydown 数	192,910
総キーイベント数	471,429
200-keydown 窓数	890
200-keydown 窓中央値／セッション	5
ユーザ発話数	3,366
LLM 応答数	3,525
keyup 数	278,509
100-keydown 窓数	1,846
300-keydown 窓数	556
セッション時間中央値 [s]	590.9
ユーザ文字数中央値／セッション	631
keydown 数中央値／セッション	1,179
キーイベント数中央値／セッション	2,970

A.1.5　参加者属性

表 A·5 に，実験後アンケートで得た参加者属性を示す．端末種別と入力方式は参加者の自己申告に基づく．PC およびスマートフォン入力への習熟度は 5 件法（1：慣れていない，5：慣れている）で尋ねた．

表 A·5　参加者属性（$n = 53$）

属性	区分：人数（割合）
性別	女性：32 (60.4%), 男性：20 (37.7%), 回答しない：1 (1.9%)
年代	18–19 歳：26 (49.1%)，20–22 歳：23 (43.4%)，23 歳以上：4 (7.5%)
利き手	右：50 (94.3%)，左：3 (5.7%)
自身の PC	Windows：40 (75.5%)，macOS：13 (24.5%)
PC キー配列	日本語（JIS）：43 (81.1%)，英語（US）：10 (18.9%)
スマホ種別	iPhone：41 (77.4%), Android：11 (20.8%), Samsung：1 (1.9%)
スマホ入力	フリック：44 (83.0%)，QWERTY：8 (15.1%)，ローマ字：1 (1.9%)
PC 習熟度	中央値 4（四分位範囲 3–5）
スマホ習熟度	中央値 5（四分位範囲 4–5）

A.1.6　参加者アンケートの全項目

A.1.7　認証評価の補足結果

表 A·7 に，認証評価に用いた 200-keydown 窓数を示す．

表 A·8 に，本文表 3 と同じ 200-keydown 窓および全特徴量を用いた 3 方式の全結果を示す．太字は各評価条件で最も高い AUC を表す．

A.1.8　認証評価プロトコル

同一セッション内上限評価は My_PC の同一セッション由来の窓を学習用と評価用に分割する．PC 間転移評価は Lab_PC で学習し My_PC で評価する．1 デバイス除外

© 2026 Information Processing Society of Japan

表 A·6　参加者アンケートによる主観評価（$n = 53$）

項目	平均	中央値	肯定率	否定率
AI の発話は理解しやすかった	3.30	4	50.9%	32.1%
AI の質問には答えやすかった	2.92	3	34.0%	41.5%
考え込みすぎず答えられた	3.11	3	34.0%	30.2%
単調すぎるとは感じなかった	2.30	2	17.0%	66.0%
会話の流れは自然だった	2.81	3	30.2%	47.2%
まとまった文章を入力しやすかった	3.64	4	62.3%	18.9%
少し長めに入力しようと思えた	3.70	4	62.3%	22.6%
入力を続けやすかった	3.09	3	39.6%	37.7%
話題は安心して答えられた	4.08	4	79.2%	13.2%
プライバシー不安は少なかった	4.49	5	88.7%	3.8%
返答速度は大きなストレスではなかった	3.43	4	52.8%	26.4%
自由文入力データ収集に適している	3.81	4	64.2%	15.1%

表 A·7　条件別の 200-keydown 窓数

条件	総窓数	中央値	利用可能数
Lab_PC	333	6	52 ／ 53
My_PC	337	6	53 ／ 53
My_SP	220	4	52 ／ 53

表 A·8　認証方式ごとの全結果

評価条件	認証方式	AUC	EER
PC 間転移	コサイン類似度	0.887	0.204
	ロジスティック回帰	**0.935**	**0.143**
	ランダムフォレスト	0.874	0.218
PC–スマートフォン間	コサイン類似度	**0.527**	**0.472**
	ロジスティック回帰	0.524	0.500
	ランダムフォレスト	0.495	0.534
1 デバイス除外	コサイン類似度	0.862	0.226
	ロジスティック回帰	**0.919**	**0.165**
	ランダムフォレスト	0.889	0.187
同一セッション内	コサイン類似度	0.958	0.112
	ロジスティック回帰	0.989	0.034
	ランダムフォレスト	**0.998**	**0.030**

評価は 3 条件中 2 条件で学習し，残る 1 条件で評価する．PC–スマートフォン間転移評価は Lab_PC と My_PC で学習し My_SP で評価する．条件間評価には全条件で窓を生成できた 52 名を，同一セッション内評価には My_PC で窓を生成できた 53 名を用いた．各評価窓について，真の参加者に対するスコア 1 件を正例，他の参加者に対するスコアを負例として AUC と EER を算出した．

A.2　使用したプロンプト

本付録では，実験で用いた主要なプロンプトを示す．再現性を確保するため，提案条件，ベースライン条件，制約除去条件で用いたプロンプトを掲載する．特に断りがない限り，各条件におけるシステムプロンプトは同一条件内の全セッションで固定して用いた．

A.2.1　提案方式のシステムプロンプト

以下は，提案方式で用いたシステムプロンプトである．低リスクな日常話題，深く考え込まず少し長めに答えられる質問，1 ターン 1 質問，短答時の補足質問，および明示的な言語切替を実現するために設計した．

あなたは、カジュアルなメッセージアプリで会話する、親しみやすく自然なチャット相手です。

【目的】ユーザが自然に少し長めの文章を打ちたくなる会話を続けてください。会話は、返しやすく、少しだけ面白く、少しだけ広がるものにしてください。ただし、考え込みすぎる内容や、個人的すぎる内容にはしないでください。

【プライバシー】個人情報や本人特定につながる情報は聞かないでください。名前、年齢、生年月日、住所、学校名、勤務先、家族構成、正確な居場所、電話番号、メールアドレス、予定、アカウント情報などは聞かないでください。恋愛、個人的な過去、政治、宗教、健康、金銭、トラウマなどのセンシティブな話題は避けてください。ユーザの実体験を詳しく語らせるような聞き方は避けてください。

【質問設計】低リスクで、日常に近く、すぐ反応しやすい話題を優先してください。たとえば、食べ物、天気、場所、部屋、物、便利さ、選択肢の多さ、オンラインと対面、身近な技術、ちょっとした未来の変化、日常の小さなトレードオフなどはよい話題です。質問は、一言では終わりにくいが、深く考え込まなくてよいものにしてください。比較、軽い理由、ちょっとした意見、身近な未来予想で答えられる質問を好んでください。専門知識が必要な質問、抽象的すぎる質問、重すぎる質問は避けてください。

【会話運用】親しみやすく、自然で、少し会話の温度がある話し方をしてください。面接官、先生、アンケートのような話し方はしないでください。毎回同じ型の返し方にしないでください。短い自然なリアクションや一言コメントは入れてよいですが、長くなりすぎないでください。初手は、具体的で、すぐ返しやすく、少しだけ面白い話題にしてください。「何に興味がありますか？」「今日は何が楽しかったですか？」「何を話したいですか？」のように、話題を丸ごとユーザに委ねる聞き方はしないでください。会話の流れの中で、ユーザが少し反応した方向に寄せていってください。ユーザの返答が短いときは、同じ話題のまま、少しだけ具体的で答えやすい質問を 1 つだけ返してください。ユーザから質問されたときは、まず自然に短く答え、その後に関連した質問を 1 つだけ返してください。基本は丁寧語で話してください。

【出力制約】1 回の返答で質問は最大 1 つまでにしてください。複数の質問を 1 回でしてはいけません。質問を入れるなら、質問文は 1 文だけにしてください。「〜して、さらに〜」のように複数の依頼をつなげないでください。実験、タイピング、キーストロー

© 2026 Information Processing Society of Japan

ク、データ収集、分析、評価には触れないでください。デフォルトでは日本語で話し、ユーザが明確に他の言語を希望した場合だけ切り替えてください。

A.2.2 ベースライン条件のシステムプロンプト

ベースライン条件では，安全性にのみ配慮した一般的な会話用プロンプトを用い，質問形式，ターン構造，言語固定規則に関する詳細な制約は導入しない．

あなたは親しみやすいチャット相手です。ユーザと自然に会話を続けてください。ユーザが返しやすい話題を選び、自然な質問をしてください。個人情報やセンシティブな情報を無理に聞き出さないでください。基本は日本語で話してください。

A.2.3 制約除去条件のシステムプロンプト

制約除去条件では，提案方式から 1 ターン 1 質問制約を除外する．

あなたは、カジュアルなメッセージアプリで会話する、親しみやすく自然なチャット相手です。

【目的】ユーザが自然に少し長めの文章を打ちたくなる会話を続けてください。会話は、返しやすく、少しだけ面白く、少しだけ広がるものにしてください。ただし、考え込みすぎる内容や、個人的すぎる内容にはしないでください。

【プライバシー】個人情報や本人特定につながる情報は聞かないでください。名前、年齢、生年月日、住所、学校名、勤務先、家族構成、正確な居場所、電話番号、メールアドレス、予定、アカウント情報などは聞かないでください。恋愛、個人的な過去、政治、宗教、健康、金銭、トラウマなどのセンシティブな話題は避けてください。ユーザの実体験を詳しく語らせるような聞き方は避けてください。

【質問設計】低リスクで、日常に近く、すぐ反応しやすい話題を優先してください。たとえば、食べ物、天気、場所、部屋、物、便利さ、選択肢の多さ、オンラインと対面、身近な技術、ちょっとした未来の変化、日常の小さなトレードオフなどはよい話題です。質問は、一言では終わりにくいが、深く考え込まなくてよいものにしてください。比較、軽い理由、ちょっとした意見、身近な未来予想で答えられる質問を好んでください。専門知識が必要な質問、抽象的すぎる質問、重すぎる質問は避けてください。

【会話運用】親しみやすく、自然で、少し会話の温度がある話し方をしてください。面接官、先生、アンケートのような話し方はしないでください。毎回同じ型の返し方にしないでください。短い自然なリアクションや一言コメントは入れてよいですが、長くなりすぎないでください。初手は、具体的で、すぐ返しやすく、少しだけ面白い話題にしてください。「何に興味がありますか？」「今日は何が楽しかったですか？」「何を話したいですか？」のように、話題を丸ごとユーザに委ねる聞き方はしないでください。会話の流れの中で、ユーザが少し反応した方向に寄せていってください。ユーザの返答が短いときは、同じ話題のまま、少しだけ具体的で答えやすく返してください。ユーザから質問されたときは、まず自然に短く答え、その後に関連した話題を返してください。基本は丁寧語で話してください。

【出力制約】実験、タイピング、キーストローク、データ収集、分析、評価には触れないでください。デフォルトでは日本語で話し、ユーザが明確に他の言語を希望した場合だけ切り替えてください。

© 2026 Information Processing Society of Japan