グラフベースIDSの判定根拠と正常基準値を用いた攻撃対象CAN ID候補抽出手法

谷口 友哉[1,a)]　倉地 亮[1,2,b)]

概要：近年，コネクティッドカーや自動運転の普及に伴い，車載ネットワークに対するサイバー攻撃の脅威が増大している．その対策として，Controller Area Network（CAN）のメッセージ列をウィンドウ単位で分割し，グラフを生成してその特徴量を抽出し，決定木を用いて攻撃を検知する GDT-IDS が提案されている．しかし，GDT-IDS は攻撃の有無を判定できる一方，攻撃対象 CAN ID を特定することが困難である．本研究では，GDT-IDS が攻撃判定に用いた決定木パス上の特徴量と正常時の基準値を利用し，攻撃対象 CAN ID の候補を抽出する手法を提案する．公開データセットを用いた評価では，対象とした 3 種類の攻撃について，攻撃対象 CAN ID を見逃すことなく候補に含めることができた．一方，攻撃対象以外の CAN ID の誤検知が発生し，最大媒介中心性が主な要因であることを確認した．

キーワード：CAN，侵入検知システム，グラフ，決定木，攻撃原因特定

Identification of Attack-Target CAN ID Candidates Using Decision Rationales and Normal Profiles in a Graph-Based IDS

Tomoya Taniguchi[1,a)]　Ryo Kurachi[1,2,b)]

Abstract: The increasing use of connected and automated vehicles has raised the risk of cyberattacks against in-vehicle networks. GDT-IDS detects anomalous windows by applying a decision tree to graph features extracted from windowed Controller Area Network (CAN) message sequences. However, although GDT-IDS can determine whether a window is anomalous, it does not identify the attack-target CAN IDs. This paper proposes a method for extracting attack-target CAN ID candidates by combining the features used on the anomalous decision path with CAN-ID-specific baseline values derived from normal traffic. In an evaluation using a public dataset, the attack-target CAN IDs were successfully included in the candidates without missing for three types of evaluated attacks. However, some non-target CAN IDs were also falsely identified, mainly because of the maximum betweenness centrality.

Keywords: Controller Area Network, intrusion detection system, graph, decision tree, attack localization

1. 序論

1.1 背景

近年，コネクティッドカーや自動運転などの車載システムのネットワーク化に伴い，サイバー攻撃の脅威が増大している．特に Controller Area Network（CAN）バスへの不正メッセージ注入が脅威となっている [1], [2]．CAN は標準仕様として送信元認証を備えないため，攻撃者が CAN バスへの送信が可能になる場合，正常時に使用される CAN ID を用いたなりすましや大量送信による通信妨害が可能となる．これらの不正な通信に対処する手段として，CAN 通信の攻撃を検知する Intrusion Detection System（IDS）が研究されている [3], [4]．本研究では数ある手法の中でも，

[1] 名城大学 情報工学部
Faculty of Information Engineering, Meijo University
[2] 名古屋大学 大学院情報学研究科
Graduate School of Informatics, Nagoya University
[a)] 231205113@ccmailg.meijo-u.ac.jp
[b)] kurachi@meijo-u.ac.jp

© 2026 Information Processing Society of Japan

This paper is work in progress and not peer-reviewed.

CAN ID 間の遷移をグラフ化し，決定木でウィンドウを分類するグラフベース IDS である GDT-IDS[5] に着目する．

1.2 既存手法の課題

GDT-IDS はウィンドウ全体を正常または攻撃に分類するが，攻撃ウィンドウに含まれるどの CAN ID が判定に関係したかは示さない．また，決定木パスから取得できる判定根拠はグラフ全体の特徴量であり，CAN ID ごとの原因を直接特定できない．したがって，攻撃検知後の分析対象を絞り込むには，得られた判定根拠と CAN ID ごとの挙動を対応付ける必要がある．

例えば，1 ウィンドウを 200 メッセージとしてグラフを生成した場合，1 つの攻撃ウィンドウには複数種類の CAN ID が含まれる．このとき，GDT-IDS によって当該ウィンドウが攻撃と判定された場合，ウィンドウ内のすべての CAN ID を同程度に調査する必要があり，原因特定が困難となる．そこで，攻撃判定に関係した可能性が高い CAN ID を候補として提示することが必要となる．

1.3 研究目的

本研究の目的は，GDT-IDS が攻撃と判定したウィンドウから，攻撃対象 CAN ID を候補として抽出することである．提案手法は，正常通信から生成した CAN ID ごとの**正常基準値**を取得する．次に，決定木パスから判定根拠となる**原因特徴量**を抽出し，攻撃ウィンドウ内の各 CAN ID について，原因特徴量に関連する CAN ID 単位指標の値を，正常基準値と比較する．なお，本研究は CAN ID 単位の候補抽出を対象とし，攻撃元 ECU の特定は対象外とする．

1.4 貢献

本研究の貢献は以下の通りである．

(1) GDT-IDS の決定木モデルから，攻撃判定に用いられた原因特徴量を抽出する．
(2) GDT-IDS が攻撃と判定したウィンドウから，攻撃対象 CAN ID 候補を抽出する手法を提案する．
(3) 公開データセットのメッセージ単位の正解ラベルを用いて抽出結果の妥当性を評価し，誤検知メッセージの CAN ID 内訳および誤検知要因となった候補理由を明らかにする．

2. 前提知識と関連研究

2.1 CAN

CAN は複数の ECU が同一通信路を共有するブロードキャスト型の通信プロトコルである [6]．CAN ID はデータ内容や送信ノードを識別するために使用されるほか，通信調停時の優先度を表し，一般に値が小さいほど高い優先度を持つ．このようなシリアルバスシステムであることに加え，標準的な CAN データフレームには送信元認証や暗号化が含まれないため，攻撃者による不正メッセージ注入を検知する仕組みが不可欠となる．

2.2 グラフベース CAN IDS

グラフベース CAN IDS は，CAN ID をノード，時系列上で連続する CAN ID 間の遷移を有向エッジとして通信を表現し，正常時と攻撃時のグラフ構造の違いを利用する [4]．ウィンドウ W_k から生成されるグラフを $G_k = (V_k, E_k)$ とすると，V_k は出現した CAN ID 集合，E_k は CAN ID 間の遷移集合である．

例えば，CAN ID の出現系列が 0x100，0x200，0x100，0x300 である場合，ノード集合は $\{0x100, 0x200, 0x300\}$ となり，0x100 から 0x200，0x200 から 0x100，0x100 から 0x300 への遷移が有向エッジとして生成される．このように，グラフはウィンドウ内の CAN ID の出現順序と遷移関係を表す．この方式は通信系列の構造的変化を捉えられる一方，攻撃対象 CAN ID の特定には追加処理が必要となる．

2.3 GDT-IDS

GDT-IDS は，各ウィンドウから生成したグラフについて，ノード数 n_k，エッジ数 e_k，最大出次数 d_k^{out}，ウィンドウの最初と最後のメッセージの時間差 Δt_k，最大媒介中心性 $c_k^{\max}$ およびグラフ密度 ρ_k を抽出し，

$$\boldsymbol{x}_k = (n_k, e_k, d_k^{\mathrm{out}}, \Delta t_k, c_k^{\max}, \rho_k) \tag{1}$$

を決定木で分類する [5]．学習には CART が用いられ [7], [8]，検知時には未知のウィンドウから同じ 6 特徴量を抽出して正常または攻撃へ分類する．決定木では，対象データが通過した分岐を追跡することで，その分類に用いられた特徴量を取得できる．

2.4 IDS の判定根拠説明・攻撃原因特定

機械学習型 IDS では，検知結果に加えて判定根拠を示すことが重要である．決定木は，ルートからリーフまでの分岐系列を直接取得できる．ただし，決定木パス上の特徴量は攻撃分類に利用されたものであり，攻撃原因そのものではない．本研究では，GDT-IDS によるウィンドウ単位の攻撃検知と，攻撃ウィンドウ内部から攻撃対象 CAN ID の候補を抽出する処理を行う．

2.5 本研究の位置付け

既存の GDT-IDS が出力するのはウィンドウ単位の正常または攻撃の判定である．これに対して，本研究では，GDT-IDS の決定木モデルから原因特徴量を抽出し，それに対応した CAN ID 単位指標を正常基準値と比較し，攻撃対象 CAN ID の候補と原因となった候補理由を出力する．原因特徴量と CAN ID 単位指標の対応は一意ではないた

© 2026 Information Processing Society of Japan

め，対応規則を明示するとともに，出力として保持した候補理由を用いて，評価において誤検知要因を確認する．

3. 提案手法

3.1 問題設定と用語

学習済み GDT-IDS の決定木モデルを M とする．ウィンドウ W_k から生成した特徴量ベクトル $\boldsymbol{x}_k$ に対する予測結果を

$$\widehat{y}_k = M(\boldsymbol{x}_k), \qquad \widehat{y}_k \in \{\mathsf{normal}, \mathsf{attack}\} \tag{2}$$

とする．本研究は，$\widehat{y}_k = \mathsf{attack}$ となった攻撃ウィンドウのみを CAN ID 候補抽出の対象とする．

式 (1) より，$\boldsymbol{x}_k$ を入力とし，決定木モデル M においてルートノードからリーフノードまでに通過するノード経路を

$$\mathcal{P}(\boldsymbol{x}_k) = \{v_0, v_1, \ldots, v_L\} \tag{3}$$

とする．ここで，v_L は，最終的に到達したリーフノードであり，v_i $(0 \le i \le L-1)$ はリーフノードに到達するまでに通過した内部ノードである．添え字 i は経路上の訪問順序を示す．

攻撃ウィンドウ W_k に含まれる CAN ID 集合を $\mathcal{I}_k$ とする．データセット上で攻撃メッセージに付与された正解 CAN ID 集合を $\mathcal{A}_k$，提案手法が出力する候補 CAN ID 集合を $\widehat{\mathcal{A}}_k$ とする．本研究の目的は，$\widehat{\mathcal{A}}_k$ が $\mathcal{A}_k$ を可能な限り含みつつ，攻撃対象以外の CAN ID の混入を抑えることである．

CAN ID 単位で算出する指標の集合を

$$\mathcal{Q} = \{F, T, D, C\} \tag{4}$$

とする．F はメッセージ数，T は同一 CAN ID の連続メッセージ間の到着間隔，D は出次数，C は媒介中心性を表す．メッセージ数 $F_i(W_k)$ はウィンドウ W_k に含まれる CAN IDi のメッセージ数とする．到着間隔 $T_i(W_k)$ は，CAN IDi のメッセージが 2 個以上存在する場合に，連続する同一 CAN ID メッセージ間の時間差の最小値とする．メッセージが 1 個のみの場合は到着間隔を未定義とし，当該指標による候補判定を行わない．出次数 $D_i(W_k)$ は，ウィンドウ W_k から生成されるグラフにおいてノード i から到達する異なる遷移先ノード数とする．媒介中心性 $C_i(W_k)$ は，グラフ上の標準的な媒介中心性として計算する．CAN IDi のウィンドウ W_k における指標ベクトルを

$$\boldsymbol{q}_i(W_k) = (F_i(W_k), T_i(W_k), D_i(W_k), C_i(W_k)) \tag{5}$$

とする．

3.2 提案手法の全体構成

提案手法の全体構成を**図 1** に示す．図中の処理は，GDT-IDS の学習，正常基準値の生成，侵入検知および攻撃対象 CAN ID 候補の抽出から構成される．

事前処理では，ラベル付きデータから GDT-IDS の決定木モデル M を学習し，正常データから CAN ID ごとのメッセージ数，到着間隔，出次数および媒介中心性の正常基準値を生成する．検知時には，GDT-IDS が攻撃と判定したウィンドウのみについて決定木パスから原因特徴量を取得する．その後，ウィンドウ内の各 CAN ID について，原因特徴量に対応する指標を正常基準値と比較し，1 つ以上の逸脱条件を満たした CAN ID を候補として出力する．

決定木パスから取得する原因特徴量と正常基準値の双方を用いる理由は，いずれか一方だけでは攻撃対象 CAN ID の候補を適切に絞り込むことが難しいためである．原因特徴量により，決定木が攻撃分類に利用したグラフ特徴量を把握できるが，その特徴量の変化に関係した CAN ID は直接分からない．一方，ウィンドウ内のすべての CAN ID について全指標を正常基準値と比較すると，GDT-IDS の判定に関係しない変化まで候補として抽出する可能性がある．そこで，原因特徴量によって確認対象となる指標を限定した上で，各 CAN ID の単位指標を正常基準値と比較する．

3.3 正常基準値の生成

正常基準値は，正常な通信のみの CAN メッセージ列 D_{normal} から生成する．正常データを H 個の正常ウィンドウ集合

$$\mathcal{W}_{\mathrm{normal}} = \{W_1^{\mathrm{normal}}, \ldots, W_H^{\mathrm{normal}}\} \tag{6}$$

へ分割する．各正常ウィンドウからグラフを生成し，CAN ID ごとに式 (5) の指標を算出する．

CAN IDi，指標 $r \in \mathcal{Q}$ について，正常データ中で観測された値の集合を

$$\mathcal{S}_{i,r} = \{q_{i,r}(W) \mid W \in \mathcal{W}_{\mathrm{normal}},\ i \in W\} \tag{7}$$

とする．正常基準値を，観測値の下限および上限

$$L_{i,r} = \min \mathcal{S}_{i,r}, \tag{8}$$

$$U_{i,r} = \max \mathcal{S}_{i,r} \tag{9}$$

として定義する．CAN ID 単位におけるメッセージ数 F，到着間隔 T，出次数 D，媒介中心性 C の観点から，各 CAN IDi の正常基準値の集合は，

$$\begin{aligned} B_i = \{&L_{i,F}, U_{i,F}, L_{i,T}, U_{i,T}, \\ &L_{i,D}, U_{i,D}, L_{i,C}, U_{i,C}\} \end{aligned} \tag{10}$$

とし，全 CAN ID の正常基準値の集合を $\mathcal{B} = \{B_i\}$ とする．

正常基準値には許容幅を設ける．上限の許容係数を $\alpha \ge 1$，下限の許容係数を $0 < \beta \le 1$ とする．CAN IDi の指標 $q_{i,r}(W_k)$ が

$$q_{i,r}(W_k) > \alpha U_{i,r} \quad \text{または} \quad q_{i,r}(W_k) < \beta L_{i,r} \tag{11}$$

© 2026 Information Processing Society of Japan

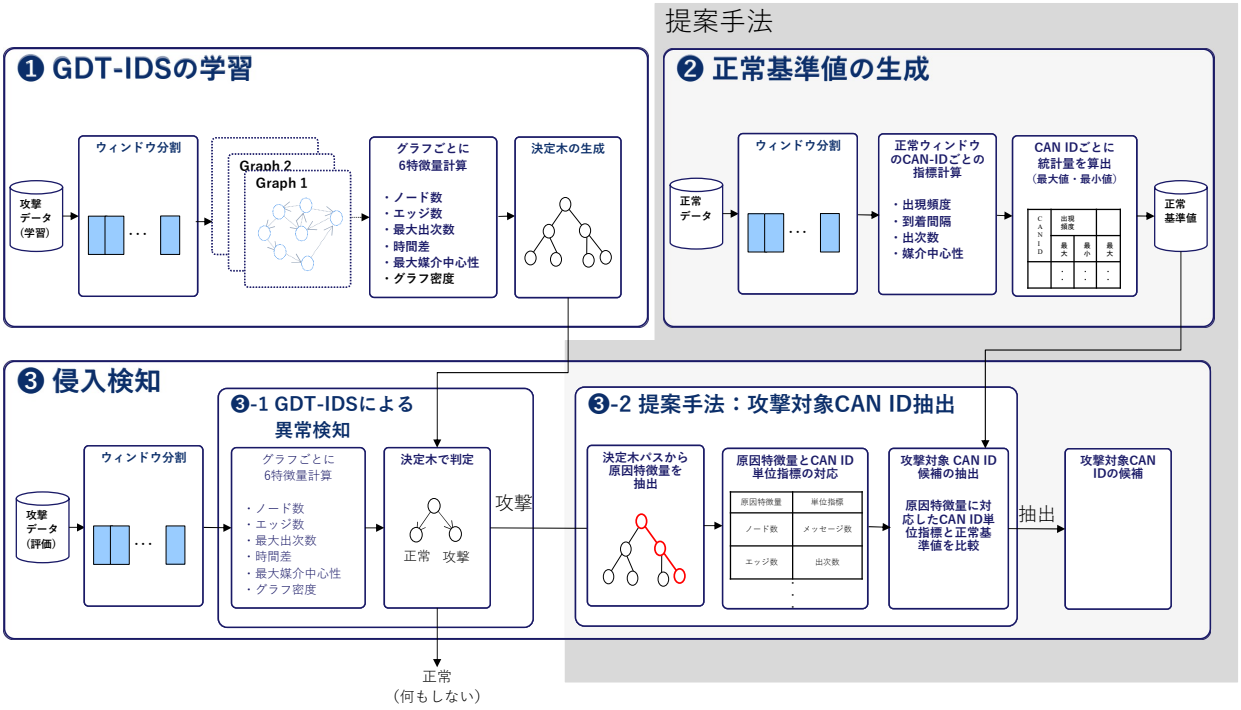


図 1　提案手法の全体構成
Fig. 1　Overview of the proposed method.

を満たす場合，指標 $q_{i,r}(W_k)$ が正常基準値から逸脱したと判定する．

3.4　決定木パスから原因特徴量を抽出

GDT-IDS が攻撃と判定したウィンドウ W_k について，決定木のルートノードからリーフノードに至るまでの決定木パスを抽出する．決定木の各ノードでは，GDT-IDS で用いた 6 つの特徴量の内いずれかに対する判定によって分岐が行われる．攻撃判定までの分岐条件として使用された特徴量の集合を原因特徴量と定義する．GDT-IDS の決定木モデルが入力として用いる 6 つの特徴量からなる定数の集合 $\mathcal{F}$ を

$$\mathcal{F} = \{f_{node_num}, f_{edge_num}, f_{max_out_num}, f_{time_diff}, f_{max_bet_cen}, f_{density}\} \tag{12}$$

と定義する．ここで，$\mathcal{F}$ の各要素はそれぞれ，f_{node_num} がノード数，f_{edge_num} がエッジ数，$f_{max_out_num}$ が最大出次数，f_{time_diff} が時間差，$f_{max_bet_cen}$ が最大媒介中心性，$f_{density}$ がグラフ密度を表す．ノード v で分岐に用いられた特徴量を $\phi(v) \in \mathcal{F}$ と表す．例えば，$v = 2$ の決定木ノードの原因特徴量が最大出次数である場合，$\phi(2) = f_{max_out_num}$ である．抽出された原因特徴量の集合を

$$C(\boldsymbol{x}_k) = \bigcup_{v \in \mathcal{P}(\boldsymbol{x}_k) \setminus \{v_L\}} \{\phi(v)\} \tag{13}$$

とする．

例えば，あるウィンドウ W_k に対する決定木のルートノードからリーフノードまでに通過するノード経路が $\mathcal{P}(\boldsymbol{x}_k) = \{0, 18, 20, 26\}$ であり，到達したリーフノードが $v_L = 26$ であったとする．このとき，分岐に用いられた内部ノードの集合は，$\mathcal{P}(\boldsymbol{x}_k) \setminus \{v_L\} = \{0, 18, 20\}$ となる．決定木の構造から，各ノードで分岐に用いられた原因特徴量がそれぞれ $\phi(0) = f_{max_out_num}, \phi(18) = f_{max_bet_cen}, \phi(20) = f_{max_bet_cen}$ であった場合，抽出される原因特徴量の集合は

$$\begin{aligned} C(\boldsymbol{x}_k) &= \bigcup_{v \in \mathcal{P}(\boldsymbol{x}_k) \setminus \{v_L\}} \{\phi(v)\} \\ &= \{\phi(0)\} \cup \{\phi(18)\} \cup \{\phi(20)\} \\ &= \{f_{max_out_num}\} \cup \{f_{max_bet_cen}\} \cup \{f_{max_bet_cen}\} \\ &= \{f_{max_out_num}, f_{max_bet_cen}\} \end{aligned}$$

となる．このウィンドウ W_k に対する原因特徴量が最大出次数と最大媒介中心性の 2 つの特徴量であることが分かる．

© 2026 Information Processing Society of Japan

表 1　原因特徴量と CAN ID 単位指標の対応
Table 1　Mapping between decision-path features and CAN-ID-level indicators.

対応関係	GDT-IDS の原因特徴量	正常基準値と比較する CAN ID 単位指標
対応 1	ノード数	メッセージ数
対応 2	エッジ数	出次数
対応 3	最大出次数	出次数
対応 4	時間差	到着間隔
対応 5	最大媒介中心性	媒介中心性
対応 6	グラフ密度	メッセージ数または出次数

3.5　原因特徴量と CAN ID 単位指標の対応

抽出した原因特徴量に基づき，ウィンドウ内の各 CAN ID について，正常基準値と比較する単位指標を決定する．GDT-IDS の原因特徴量はグラフ全体から分かる 6 つの特徴量を示すものであるが，攻撃対象 CAN ID を候補として抽出するためには原因特徴量と関連する CAN ID 単位指標に絞り込む必要がある．GDT-IDS の原因特徴量と CAN ID 単位指標の対応を**表 1** に示す．

各特徴量に対して，正常基準値と比較する CAN ID 単位指標を表 1 に選定した理由は以下の通りである．

- **対応 1**：攻撃によって不正な CAN ID のメッセージが連続送信されることで，その CAN ID のメッセージ数が変化し，結果としてグラフ全体のノード数にも影響が及ぶ．そのため，ノード数の変化に関係した CAN ID を特定する指標として，ウィンドウ内の CAN ID ごとのメッセージ数を確認する．
- **対応 2**：グラフ全体のエッジ数は各ノードの出次数の総和であるため，各 CAN ID の出次数を確認する．
- **対応 3**：最大出次数は特定ノードが持つ出次数の最大値であるため，各 CAN ID の出次数を確認する．
- **対応 4**：時間差はウィンドウ全体のメッセージに要した時間を示す．時間差が原因である場合，メッセージの不正注入等により通信密度が変化したことを示唆しているため，個別のメッセージの送信間隔の変化を捉える指標として，CAN ID ごとの到着間隔を利用する．
- **対応 5**：グラフ内で経由されやすいノードの構造の変化を示しているため，各 CAN ID の媒介中心性を確認する．
- **対応 6**：グラフ密度はグラフ内のノード数，エッジ数から算出される指標であるため，それらを指標として用いたメッセージ数と出次数の組み合わせを利用する．

3.6　攻撃対象 CAN ID 候補の抽出

抽出された GDT-IDS 原因特徴量の集合 $C(\boldsymbol{x}_k)$ に応じて，表 1 に対応する CAN ID の単位指標を正常基準値と比較する．CAN ID の単位指標について，F はメッセージ数，T は同一 CAN ID の連続メッセージ間の到着間隔，D は出次数，C は媒介中心性であり，各 CAN IDi の正常基準値の集合

$$B_i = \{L_{i,F}, U_{i,F}, L_{i,T}, U_{i,T}, L_{i,D}, U_{i,D}, L_{i,C}, U_{i,C}\} \tag{14}$$

と比較する．

あるウィンドウ W_k に対して，攻撃対象 CAN ID の候補集合の初期状態を $\widehat{\mathcal{A}}_k = \emptyset$ とする．抽出された原因特徴量に基づき，表 1 から正常基準値と比較する単位指標を決定する．比較対象として選択された任意の単位指標を $r \in \{F, D, T, C\}$ とし，ウィンドウ W_k における各 CAN IDi の指標を $q_{i,r}(W_k)$ とする．許容係数 α，β を用いて，

$$q_{i,r}(W_k) > \alpha U_{i,r} \quad \text{または} \quad q_{i,r}(W_k) < \beta L_{i,r} \tag{15}$$

の条件を満たした場合，その指標は正常基準値から逸脱していると判定する．ウィンドウ内のすべての CAN IDi について，原因特徴量に対応する CAN ID 単位指標を評価し，1 つでも式 (15) の逸脱条件を満たした場合，その CAN ID を攻撃対象の候補として，候補集合 $\widehat{\mathcal{A}}_k$ に追加する．

$$\widehat{\mathcal{A}}_k = \widehat{\mathcal{A}}_k \cup \{i\} \tag{16}$$

例えば，ウィンドウ W_k において，抽出された原因特徴量に最大出次数が含まれていたとする．表 1 より，原因特徴量の集合に最大出次数が含まれているので，正常基準値と比較する単位指標は出次数である．ウィンドウ W_k 内にある CAN ID の集合を $\mathcal{I}_k$ とする．$i \in \mathcal{I}_k$ について，

$$q_{i,D}(W_k) > \alpha U_{i,D} \quad \text{または} \quad q_{i,D}(W_k) < \beta L_{i,D} \tag{17}$$

の条件を満たした場合，その CAN ID を攻撃対象の候補とする．

3.7　アルゴリズム

正常基準値の生成方法を Algorithm 1 に示す．Algorithm 1 では，正常な通信のみの CAN メッセージ列から正常ウィンドウに分割し，CAN ID 単位の 4 指標を収集し，最大値と最小値を正常基準値として保存する．GenerateGraph は正常ウィンドウからグラフを生成し，ノードごとにタイムスタンプおよび同一 CAN ID における直前メッセージとの時間差を格納する．

攻撃対象 CAN ID 候補の抽出方法を Algorithm 2 に示す．Algorithm 2 の GetTreeCauseFeatures は決定木パスをルートからリーフまでたどり，分岐に用いられた原因特徴量を抽出する．MapFeatureToIndicators は表 1 に基づいて原因特徴量から CAN ID 単位指標の集合 $\mathcal{Q}_f$ を求める．ExtractIDIndicators では，正常基準値と比較するために，対応した単位指標の値を算出する．出力される候補理由 R は，正常基準値との比較によって各 CAN ID が攻撃候補として抽出された際に，その根拠となった GDT-IDS の原因特徴量を記録したものである．

© 2026 Information Processing Society of Japan

Algorithm 1 CAN ID ごとの正常基準値生成

入力： 正常な通信のみの CAN メッセージ列 D_{normal}，ウィンドウサイズ L
出力： 正常基準値の集合 $\mathcal{B}$

$\mathcal{W}_{\text{normal}} \leftarrow \textsc{SplitIntoWindows}(D_{\text{normal}}, L)$
$\mathcal{I}_{\text{normal}} \leftarrow \emptyset$
$\mathcal{S} \leftarrow$ 空の統計量集合
for all $W \in \mathcal{W}_{\text{normal}}$ **do**
  $G \leftarrow \textsc{GenerateGraph}(W)$
  for all $i \in \textsc{GetCANIDs}(W)$ **do**
    $\mathcal{I}_{\text{normal}} \leftarrow \mathcal{I}_{\text{normal}} \cup \{i\}$
    $\mathcal{S}_{i,F} \leftarrow \mathcal{S}_{i,F} \cup \{\textsc{Frequency}(W, i)\}$
    $\mathcal{S}_{i,T} \leftarrow \mathcal{S}_{i,T} \cup \{\textsc{InterArrival}(W, i)\}$
    $\mathcal{S}_{i,D} \leftarrow \mathcal{S}_{i,D} \cup \{\textsc{OutDegree}(G, i)\}$
    $\mathcal{S}_{i,C} \leftarrow \mathcal{S}_{i,C} \cup \{\textsc{Betweenness}(G, i)\}$
  end for
end for
for all $i \in \mathcal{I}_{\text{normal}}$ **do**
  for all $r \in \{F, T, D, C\}$ **do**
    $L_{i,r} \leftarrow \min \mathcal{S}_{i,r}$
    $U_{i,r} \leftarrow \max \mathcal{S}_{i,r}$
  end for
  $B_i \leftarrow \{L_{i,F}, U_{i,F}, L_{i,T}, U_{i,T}, L_{i,D}, U_{i,D}, L_{i,C}, U_{i,C}\}$
end for
return $\mathcal{B} = \{B_i\}$

Algorithm 2 攻撃対象 CAN ID 候補の抽出

入力： 対象ウィンドウ W_k，決定木モデル M，正常基準値の集合 $\mathcal{B}$，許容係数 α, β
出力： 攻撃対象 CAN ID 候補集合 $\widehat{\mathcal{A}}_k$，候補理由 R

$G \leftarrow \textsc{GenerateGraph}(W_k)$
$\boldsymbol{x} \leftarrow \textsc{ExtractGDTFeatures}(G)$
$\widehat{\mathcal{A}}_k \leftarrow \emptyset$
$R \leftarrow \emptyset$
$\widehat{y} \leftarrow \textsc{Predict}(M, \boldsymbol{x})$
if $\widehat{y} =$ attack **then**
  $C \leftarrow \textsc{GetTreeCauseFeatures}(M, \boldsymbol{x})$
  for all $i \in \textsc{GetCANIDs}(W_k)$ **do**
    $R_i \leftarrow \emptyset$
    $\boldsymbol{q}_i \leftarrow \textsc{ExtractIDIndicators}(W_k, G, i, \mathcal{B})$
    for all $f \in C$ **do**
      $\mathcal{Q}_f \leftarrow \textsc{MapFeatureToIndicators}(f)$
      for all $r \in \mathcal{Q}_f$ **do**
        if $q_{i,r} > \alpha U_{i,r}$ **or** $q_{i,r} < \beta L_{i,r}$ **then**
          $R_i \leftarrow R_i \cup \{f\}$
        end if
      end for
    end for
    if $R_i \neq \emptyset$ **then**
      $\widehat{\mathcal{A}}_k \leftarrow \widehat{\mathcal{A}}_k \cup \{i\}$
      $R \leftarrow R \cup \{(i, R_i)\}$
    end if
  end for
end if
return $\widehat{\mathcal{A}}_k, R$

4. 評価方法

本評価では，提案手法の出力をメッセージ単位へ展開し，以下の 3 つの観点から評価する．第 1 に，正常メッセージおよび攻撃メッセージが，それぞれ正常または攻撃のどちらに予測されたかを確認する．第 2 に，正常メッセージを攻撃と誤検知した場合，そのメッセージが攻撃対象 CAN ID に属するか，攻撃対象以外の CAN ID に属するかを確認する．第 3 に，攻撃対象以外の CAN ID の誤検知について，どの候補理由が要因となったかを分析する．

表 2 Car-Hacking Dataset の概要
Table 2 Overview of the Car-Hacking Dataset.

データ	正常メッセージ数	攻撃メッセージ数
DoS Attack	3,078,250	587,521
Fuzzy Attack	3,347,013	491,847
Spoofing the drive gear	3,845,890	597,252
Spoofing the RPM gauge	3,966,805	654,897
Attack-free	988,872	—

4.1 データセット

評価には，公開データセットである Car-Hacking Dataset[9], [10], [11] を用いる．データセットのメッセージ数を**表 2** に示す．

本研究では，正常通信に存在する CAN ID を用いた攻撃を評価対象とするため，DoS 攻撃，ギア値のなりすまし攻撃（以下，Gear）および RPM 値のなりすまし攻撃（以下，RPM）を使用する．Fuzzy 攻撃には正常通信に存在しない CAN ID が複数含まれるため，評価対象から除外する．正常基準値の生成には，攻撃メッセージを含まない Attack-free データを使用する．

4.2 データ前処理

各データファイルをタイムスタンプ順に整列し，CAN ID の表記を統一する．CAN メッセージ列を 200 メッセージ単位の重複しないウィンドウに分割し，各ウィンドウから CAN ID をノード，連続する CAN ID 間の遷移をエッジとするグラフを生成する．1 つ以上の攻撃メッセージを含むウィンドウを攻撃ウィンドウとし，それ以外を正常ウィンドウとする．

元の DoS 攻撃データでは，攻撃メッセージに正常な通信では観測されない CAN ID が用いられている．この条件では未知 CAN ID の有無のみで容易に候補を抽出できるため，本評価では，攻撃メッセージの CAN ID を正常通信中で最も優先度の高い CAN ID へ変更する．タイムスタンプ，データフィールドおよび攻撃メッセージ数は変更しない．

4.3 学習・テストデータの分割

DoS，Gear および RPM の各攻撃データセットを，訓練データとテストデータに 7:3 の割合で分割する．攻撃種類ごとに GDT-IDS の決定木モデルを学習し，対応するテストデータに対して攻撃検知と CAN ID 候補抽出を行う．決

© 2026 Information Processing Society of Japan

表 3　メッセージ単位の予測結果の割合
Table 3　Proportion of message-level prediction results.

	正解ラベル：正常		正解ラベル：攻撃	
攻撃	予測：正常	予測：攻撃	予測：正常	予測：攻撃
DoS	34.96%	14.88%	0.00%	50.15%
Gear	62.76%	6.55%	0.00%	30.69%
RPM	62.53%	6.45%	0.00%	31.02%

定木には scikit-learn の DecisionTreeClassifier を使用し，最大深さを 5 とする．正常基準値の許容係数は，$\alpha = 1.1$，$\beta = 0.5$ とする．

実験環境は以下の通りである．

- CPU：Intel Core Ultra 9 285K
- メモリ：128 GB
- OS：Microsoft Windows 11 Pro
- 使用言語：Python 3.9.19
- 主要ライブラリ：scikit-learn，NetworkX，NumPy

4.4　評価項目

GDT-IDS が正常と判定したウィンドウでは，そのウィンドウ内のメッセージを正常と予測する．GDT-IDS が攻撃と判定したウィンドウでは，提案手法によって攻撃対象 CAN ID の候補となったメッセージを攻撃，攻撃対象以外の CAN ID のメッセージを正常と予測する．この予測結果とデータセットのメッセージラベルを比較し，以下の項目を評価する．

(1) **メッセージ単位の予測結果：**正常メッセージおよび攻撃メッセージについて，正常または攻撃と予測されたメッセージの割合を求める．各値はテストデータ全体のメッセージ数に対する割合として示す．
(2) **誤検知メッセージの CAN ID 内訳：**正常メッセージを攻撃と誤検知したメッセージについて，攻撃対象 CAN ID のメッセージと，攻撃対象以外の CAN ID のメッセージの割合を求める．
(3) **攻撃対象以外の CAN ID の誤検知要因：**攻撃対象以外の CAN ID を候補とした場合，候補理由を集計する．複数条件を同時に満たした場合は，その組合せを 1 つの項目として集計する．

5.　評価結果

5.1　メッセージ単位の予測結果

DoS，Gear および RPM に対するメッセージ単位の予測結果を**表 3** に示す．各値はテストデータに含まれる全メッセージに占める割合であり，小数点以下第 2 位まで示している．

正常メッセージを攻撃と誤検知した割合は，DoS で 14.88%，Gear で 6.55%，RPM で 6.45%であった．一方，攻撃メッセージを正常と予測した割合は，いずれの攻撃についても小数点以下第 2 位までの集計で 0.00%であった．この結果から，評価対象としたデータでは，攻撃に用いられた CAN ID を候補に含めることができた一方，正常メッセージの一部を攻撃と予測していることが分かる．

表 4　正常メッセージを攻撃と誤検知したメッセージの内訳
Table 4　Breakdown of false-positive messages.

攻撃	攻撃対象 CAN ID	攻撃対象以外の CAN ID
DoS	18.61%	81.39%
Gear	56.62%	43.38%
RPM	59.43%	40.57%

表 5　攻撃対象以外の CAN ID の誤検知要因
Table 5　Causes of false detection of CAN IDs other than the target of the attack.

候補理由	DoS	Gear	RPM
最大出次数のみ	3.89%	24.96%	25.77%
最大媒介中心性のみ	86.25%	71.40%	71.59%
グラフ密度のみ	1.55%	0.00%	0.67%
最大出次数かつ最大媒介中心性	8.31%	3.65%	1.96%

5.2　誤検知メッセージの CAN ID 内訳

正常メッセージを攻撃と誤検知したメッセージについて，攻撃対象 CAN ID と，攻撃対象以外の CAN ID の割合を**表 4** に示す．

誤検知メッセージのうち，攻撃対象以外の CAN ID の割合は，DoS で 81.39%，Gear で 43.38%，RPM で 40.57%であった．攻撃対象 CAN ID の正常メッセージが攻撃と予測される理由は，提案手法が CAN ID 単位で候補を抽出し，同一 CAN ID 内の正常メッセージと攻撃メッセージを区別しないためである．したがって，本手法における主要な誤検知の課題は，攻撃対象以外の CAN ID を候補として抽出することである．

5.3　攻撃対象以外の CAN ID の誤検知要因

攻撃対象以外の CAN ID を誤検知した候補理由の内訳を**表 5** に示す．複数の候補理由が同時に要因となった場合は，論理積を用いて独立した項目として分類している．また，誤検知の要因とならなかった候補理由は表から除外している．

いずれの攻撃でも，最大媒介中心性のみの候補理由が最も大きな割合を占め，DoS で 86.25%，Gear で 71.40%，RPM で 71.59%であった．このことから，攻撃対象以外の CAN ID の誤検知を削減するには，原因特徴量である最大媒介中心性と，CAN ID 単位指標である媒介中心性の対応規則または判定条件を優先的に見直す必要がある．

6.　考察

表 3 より，評価対象とした 3 種類の攻撃では，攻撃メッ

© 2026 Information Processing Society of Japan

セージを正常と予測した割合が小数点以下第 2 位までの集計で 0.00%であった．したがって，本評価では，攻撃対象 CAN ID を候補集合へ含めることができたと考えられる．一方，正常メッセージを攻撃と予測した割合は DoS で 14.88%，Gear で 6.55%，RPM で 6.45%であり，提案手法には誤検知が残る．

表 4 に示すように，誤検知メッセージは攻撃対象 CAN ID の正常メッセージと攻撃対象以外の CAN ID に分けられ，その割合は攻撃手法の性質やデータセットの特性に依存する．攻撃対象 CAN ID の正常メッセージが誤検知されるのは，提案手法が CAN ID 単位で候補を抽出するため，攻撃メッセージと同じ CAN ID を持つ正常メッセージをメッセージ単位で分離できないためである．この誤検知は，攻撃対象 CAN ID の見逃しを抑える設計に伴うものであり，攻撃対象 CAN ID の候補抽出後にペイロードやメッセージ間の時間差を用いた詳細分析を行うことで，攻撃メッセージと正常メッセージに分離する必要がある．一方，攻撃対象以外の CAN ID の誤検知は，候補抽出の精度に直接影響するため，本手法で優先的に改善すべき課題である．

表 5 より，いずれの攻撃に対しても攻撃対象以外の CAN ID の誤検知の主要因は，候補理由である最大媒介中心性であった．大量の不正メッセージが挿入されると，攻撃対象 CAN ID だけでなく，その前後に出現する攻撃対象以外の CAN ID の遷移先も変化し，一時的に媒介中心性が正常基準値を逸脱する可能性がある．したがって，媒介中心性のみで候補とするのではなく，メッセージ数や到着間隔等の複数条件を組み合わせる方法や，正常基準値の許容係数 α，β を CAN ID ごとに調整する方法が考えられる．

7. 結論

本研究では，GDT-IDS によって攻撃と判定された CAN メッセージウィンドウから，攻撃対象 CAN ID 候補を抽出する手法を提案した．提案手法は，GDT-IDS が攻撃と判定したウィンドウに対して，決定木パスに含まれる原因特徴量を取得し，原因特徴量と対応した CAN ID 単位指標を正常基準値と比較することで，正常基準値から逸脱した CAN ID を攻撃候補として出力する．

Car-Hacking Dataset を用いた評価では，DoS，Gear および RPM の各攻撃について，攻撃メッセージを正常と予測した割合は小数点以下第 2 位までの集計で 0.00%となり，攻撃対象 CAN ID を候補に含めることができた．一方，正常メッセージを攻撃と予測する誤検知が発生し，攻撃対象以外の CAN ID の誤検知要因として，候補理由である最大媒介中心性が大きな割合を占めた．

今後は，CAN ID 単位指標である媒介中心性の条件を単独で用いるのではなく，他の指標と組み合わせることで，攻撃対象以外の CAN ID の誤検知を削減する．また，攻撃対象 CAN ID の候補として抽出されたメッセージに対して，ペイロードやメッセージの到着間隔に基づく詳細分析を行い，同一 CAN ID 内の正常メッセージと攻撃メッセージを分離する方法を検討する．

謝辞　本研究の一部は JSPS 科研費 26K14775 の助成を受けたものです．

参考文献

[1] 国土交通省. 自動運転車の安全技術ガイドライン. https://www.mlit.go.jp/common/001253665.pdf, 2018. 参照 2026-08-20.

[2] Wufei Wu, Renfa Li, Guoqi Xie, Jiyao An, Yang Bai, Jia Zhou, and Keqin Li. A survey of intrusion detection for in-vehicle networks. *IEEE Transactions on Intelligent Transportation Systems*, Vol. 21, No. 3, pp. 919–933, 2020.

[3] Hyun Min Song, Ha Rang Kim, and Huy Kang Kim. Intrusion detection system based on the analysis of time intervals of can messages for in-vehicle network. In *2016 International Conference on Information Networking (ICOIN)*, pp. 63–68, 2016.

[4] Riadul Islam, Rafi Ud Daula Refat, Sai Manikanta Yerram, and Hafiz Malik. Graph-based intrusion detection system for controller area networks. *IEEE Transactions on Intelligent Transportation Systems*, Vol. 23, No. 3, pp. 1727–1736, 2022.

[5] Pengdong Ye, Yanhua Liang, Yutao Bie, Guihe Qin, Jiaru Song, Yingqing Wang, and Wanning Liu. Gdt-ids: graph-based decision tree intrusion detection system for controller area network. *The Journal of Supercomputing*, Vol. 81, , 03 2025.

[6] ベクター・ジャパン株式会社. はじめての CAN/CAN FD. https://www.vector.com/jp/ja/know-how/vj-beginners/cancan-fd/. 参照 2026-08-20.

[7] L. Breiman, J. Friedman, C.J. Stone, and R.A. Olshen. *Classification and Regression Trees*. Taylor & Francis, 1984.

[8] Wei-Yin Loh. Classification and regression trees. *WIREs Data Mining and Knowledge Discovery*, Vol. 1, No. 1, pp. 14–23, 2011.

[9] E. Seo, H. M. Song, and H. K. Kim. Gids: Gan based intrusion detection system for in-vehicle network. In *2018 16th Annual Conference on Privacy, Security and Trust (PST)*, pp. 1–6, Aug 2018.

[10] Hyun Min Song, Jiyoung Woo, and Huy Kang Kim. In-vehicle network intrusion detection using deep convolutional neural network. *Vehicular Communications*, Vol. 21, p. 100198, 2020.

[11] Hacking and Countermeasure Research Lab. Car-Hacking Dataset. https://ocslab.hksecurity.net/Datasets/car-hacking-dataset. 参照 2026-08-20.

© 2026 Information Processing Society of Japan